

随机过程与金融市场

Ou Liu

2026-09-14

目录

引言	iv
第一部分 随机过程的数学基础	1
第一章 测度论基础	2
1.1 可测空间, 测度, Lebesgue 积分	3
1.2 符号测度, Hahn 分解与 Radon–Nikodym 导数	18
第二章 概率论基础	30
2.1 概率空间与随机变量	31
2.2 随机变量的分布	33
2.3 期望与矩	41
2.4 独立性, 条件概率与条件期望	45
2.5 随机变量的收敛与极限定理	52
第三章 随机过程基础	64
3.1 从路径到信息	64
3.2 随机过程, 分布与样本路径	64
3.3 时间与信息	68
3.4 Markov 过程: 当前状态能否代表过去	71
3.5 鞅: 条件平均下没有可预测漂移	73
3.6 计数过程与 Poisson 过程	77
3.7 Brown 运动	79
3.8 有限变差与二次变差: 为随机积分作准备	82
3.9 小结	84
第四章 随机分析基础	85
4.1 从变差到随机微分	85
4.2 路径变差, 二次变差与半鞅	85
4.3 从简单过程构造 Itô 积分	90
4.4 Itô 公式, 乘积公式与随机指数	93
4.5 随机微分方程: 解的含义与基本模型	96
4.6 Girsanov 定理: 在有限期限内改变概率权重	99
4.7 生成元, Kolmogorov 方程与 Feynman–Kac	100
4.8 Poisson 随机测度与跳跃	103
4.9 连续扩散的计算次序	104
4.10 小结	104
第五章 从随机过程到金融交易	105
5.1 一期二叉市场与期权复制	105
5.2 多期离散时间: 鞅, 自融资与基本定理	109
5.3 停时与美式合约: Snell 包络	112
5.4 连续时间的持仓收益与自融资	114
5.5 一个完整例子: 欧式看涨期权的复制与定价	117
5.6 点过程示例: 订单到达与价格变化	121
5.7 从报价到成交: 一笔往返交易的现金账	123
5.8 从模型现金流到具体市场制度	126

第二部分 随机过程与金融市场	127
第六章 金融市场基础	128
6.1 资产头寸, 价格与策略回报	128
6.2 衍生品与或有现金流	133
6.3 预测市场与市场隐含概率	142
6.4 指数, ETF 和被动投资	144
6.5 债券, 美债与利率	150
6.6 美联储, 美元体系与短端资金市场	156
6.7 贴现与无套利	163
6.8 交易, 订单簿与市场微观结构	169
第七章 基本面分析	178
7.1 从资产头寸到可识别价值	178
7.2 常用估值方法: 从经营预测到每股价值	180
7.3 Risk-Reward 框架与情景分析	186
7.4 Agentic R/D Graph: 把研究判断组织成可更新的图	189
第八章 趋势交易与技术指标: 从路径变换到可交易策略	193
8.1 从指标到账本	193
8.2 历史走势, 预测关系与交易结果	193
8.3 离散交易时钟, 信息集与可预测持仓	193
8.4 滤波的统一语言: 平滑, 时滞与尺度	195
8.5 从滤波器到趋势规则	197
8.6 常见指标: 公式, 单位与窗口	200
8.7 随机过程怎样给趋势规则提供基准	202
8.8 怎样减少反复交易: 缓冲区与进出场规则	203
8.9 指标相同, 状态可以不同	205
8.10 从漂亮回测到可信检验	205
8.11 趋势研究与基本面估值怎样配合	208
8.12 实现补充: 数据, 活动订单与现金记录	208
8.13 小结	209
附录 A 金融市场制度史: 危机如何塑造今日结构	210
A.1 荷兰前史: 股份怎样让长期投资可以转手	210
A.2 英国前史: 政府借款与最后贷款人的形成	211
A.3 从 Buttonwood 到 1907 年: 私人组织怎样交易与救急	212
A.4 1913–1935 年: 央行怎样在危机中改变	213
A.5 1934–2006 年: 私人交易所, 全国市场与后台基础设施	213
A.6 1970–1999 年: 利率错配, 跨市场交易与高杠杆	214
A.7 2000–2010 年: 从科技股损失到融资体系危机	214
A.8 2010–2026 年: 更快的交易与银行之外的融资	215
A.9 泡沫与危机留下了什么	217
A.10 为什么平时难改, 危机时却能迅速行动	219
A.11 回到随机过程: 制度变化怎样影响条件分布	220
参考文献	222

引言

研究随时间变化的随机现象时, 我们会同时遇到两类问题: 未来可能发生什么, 以及已经发生的事情能为判断未来提供多少信息. 股价的涨跌, 订单的到达和粒子的运动, 都需要放在这样的时间顺序中理解. 只知道某一时刻的概率分布, 往往还不足以回答关于整个过程的问题.

这份笔记面向学过实分析, 线性代数和基本概率论的高年级本科生与研究生. 前半部从测度与积分出发, 建立研究随机过程所需的数学基础; 后半部以金融市场为主要应用, 讨论价格, 合约, 估值和交易. 选择金融市场, 是因为这里许多看似简单的说法都需要进一步讲清: 根据什么信息作预测, 今天的一笔支出换来什么未来权利, 一条买卖规则又怎样形成实际盈亏. 这些问题既能帮助理解数学概念, 也能检验我们是否真正理解了它们.

从一个随机变量到整个过程

某一时刻的价格可以用一个随机变量描述. 若要研究价格如何变化, 就要在同一概率空间上考察一族随机变量 $(X_t)_{t \in T}$. 这样的随机变量族称为**随机过程**. 把它们放在同一概率空间中, 才能讨论不同时间的取值怎样相互联系.

即使每个时刻的分布都已知, 这些联系仍可能完全不同. 例如, 一个序列的每项都服从标准正态分布, 各项可以相互独立, 也可以全部等于同一个随机变量. 前一种情形中, 观察前几项不会改变下一项的分布; 后一种情形中, 只要看到第一项, 就知道了其余所有项. 因而描述一个过程, 还要给出不同时刻的联合分布. 只有单时点分布, 无法判断过去的观测对未来有多少帮助.

从一次具体实现来看, 不同时刻的取值又组成一条样本路径. 联合分布描述不同时刻的取值共同出现的概率规律; 从路径出发, 则可以研究一次实现是否连续, 何时首次达到某个水平, 长期以后怎样变化. 例如, 年末价格相同的两条路径, 年中经历的跌幅可能很不一样. 若途中存在追加保证金或提前退出的要求, 投资者的经历就不能只用年末价格概括.

路径上还包含一个重要的时间顺序: 在时刻 t 作判断时, 后面的路径尚未发生. 滤过 (filtration, 也称滤链) $(\mathcal{F}_t)$ 用来表示各时刻已经掌握的信息, 条件期望据此计算未来随机量的平均值. 例如, 规定价格首次跌破某一水平时卖出, 到了那个时刻便能凭已有价格判断是否应该行动. 停时给出这类随机时点的数学定义. 相比之下, 事后从整条曲线中挑出最低点买入, 最高点卖出, 用到了当时尚不知道的信息.

要把这些想法写成严谨的数学, 就需要测度与积分. 在典范路径空间中, 一个样本点本身就是一条完整路径, 一个事件则是满足某项条件的一批路径. 我们首先要规定哪些集合可以作为事件, 并在它们上面构造概率测度. 其次, 还要证明从路径中读出的价格, 首次到达时间等量是可测的, 才能讨论它们的分布和期望. 测度论提供了完成这些工作的共同语言.

在这些对象上计算期望或构造新的过程时, 又会反复用到逼近与极限, 这就需要积分理论. 期望是关于概率测度的 Lebesgue 积分; 用简单变量逼近复杂变量以后, 能否把极限移入期望, 要由相应的收敛定理判断. 到了随机积分, 我们也会先对简单过程定义积分, 再估计近似误差, 最后取极限. Brown 路径虽然连续, 却几乎必然具有无限总变差, 而平方增量的累积又有非零极限. 这些性质说明经典有限变差路径的积分方法不够用, 我们需要利用 Brown 增量的概率结构重新构造积分, 也就是后面要介绍的 Itô 积分. 因此, 开头的测度, 积分和收敛理论会在研究过程时反复用到.

数学怎样进入金融问题

在金融市场中, 价格首先对应某种具体权利. 股票持有人享有相应的股东权利, 债券规定还本付息的安排, 衍生合约则按标的价格或事件结果约定收付. 要讨论一项资产值多少钱, 先要弄清买到的是什麼, 将来由谁向谁付款, 又在什么时候付款. 因而笔记中的金融部分既介绍随机模型, 也介绍合约条款, 融资和交易制度.

在这些安排已经明确以后, 随机过程可以帮助研究支付与价格的关系. 期权定价是其中一个例子: 如果在模型允许的交易条件下, 一组股票和现金持仓能够复制合约的未来支付, 那么无套利条件就把合约价格与这组持仓的成本联系起来. 第五章将从一期二叉模型开始说明这件事, 再进入连续时间. 第5.5节则以欧式看涨期权为例, 从 Itô 公式推到复制持仓和定价方程, 并说明怎样用测度变换把价格写成期望.

研究股票投资时,还会遇到复制定价以外的问题.公司的产品能卖多少,利润能维持多久,赚来的钱需要拿出多少继续投入,都影响股东最终能够取得的现金.基本面分析据此预测经营结果,再通过现金流折现或估值倍数计算价值.不同判断可以写成几个明确的经营情景,分别计算价格和回报.这样一来,估值差异就能追溯到具体假设,例如增长持续多久,资本成本多高,而不只是比较两个最终数字.

趋势交易则从已经观察到的价格和成交记录中构造规则.以均线为例,算出均线以后,还要规定什么情况下买入或卖出,每次交易多少,何时发出订单.订单实际成交后,才能结合持仓,现金和费用计算净损益.因而趋势章会把指标,交易规则和完整账户算例连起来讲,比较同一条价格路径上不同进出场规则为何产生不同结果.数据检验所要判断的,是这些历史信息是否有助于后续交易,以及扣除成本后还剩下多少收益.

定价,经营预测和交易执行所需要的模型并不完全相同.假设股价服从几何 Brown 运动,可以研究连续路径下的复制策略;要研究跳空后的平仓结果,就必须考虑突然的价格变化.同样,一个模型价格足以说明理想的自融资关系,但计算大额订单的实际成本时,还要看各档报价,可成交数量与排队情况.模型是否合适,取决于所省略的细节会不会改变眼前问题的答案.

这些交易条件也有各自的历史.交易所怎样组织买卖,银行和交易商怎样取得融资,危机中谁必须筹钱或出售资产,都会改变我们观察到的市场结果.因此,笔记最后用制度史补充前面的模型讨论,说明今天的交易与融资安排怎样形成,以及为什么跨时期使用同一个模型时还要重新检查它的假设.

阅读路线

前半部依次讨论测度与积分,概率论基础,随机过程和随机分析. Markov 过程与 Poisson 过程提供不同的时间演化例子, Brown 运动和鞅则为随机积分,随机微分方程及定价理论作准备.定义之后给出相应构造与证明,并在推导中说明条件用在何处.阅读时可以反复留意三个问题:当前研究的对象是什么,为什么需要这个条件,这一步怎样帮助解决起初提出的问题.

后半部从金融市场基础进入基本面分析和趋势交易,再以制度史收尾.金融基础中的期货,期权,保证金和订单簿例子,用来说明实际的权利,收付与成交;基本面和趋势章的例子,则展示怎样从一组假设或一条规则算到结果.所用教材,讲义,论文和制度资料随正文注明,便于沿感兴趣的问题继续阅读.

若已熟悉概率空间,随机变量及分布,期望,独立性,条件期望,各类收敛和基本极限定理,可以直接从第三章读起.遇到需要核对的积分或 Radon–Nikodym 结果,再回看第一章和第二章.若数学基础较好而不熟悉金融市场,可以先读第六章,弄清各类交易买卖什么,何时付款,再返回第五章阅读定价与复制的推导.

致谢 感谢 Codex 协助整理和修订这份笔记.也感谢熊悠然指出 Codex 撰写的文字中不合中文习惯的西式表达,并提出修改意见.


第一部分

随机过程的数学基础

第一章 测度论基础

先从平面面积说起. 矩形 $R = [a, b] \times [c, d]$ 的面积是 $(b - a)(d - c)$, 有限个互不相交的矩形可以逐块相加. 圆盘却无法用有限个矩形精确拼出. 要从矩形面积算到圆盘面积, 一个办法是用越来越小的方块逼近它, 再对面积取极限.

下图将网格边长逐次减半, 每次只选取闭包完全位于开圆盘 D 内的小方块. 方块越细, 留下的空隙就越小. 沿着这个例子, 可以看清测度论为什么既要规定哪些集合可测, 又要说明取可列并以后集合的测度怎样变化. 本章主要参考 [Bog07; Fol99].



把网格中的方块取为半开矩形, 相邻方块就不会在边界上重叠. 记第 n 次选出的方块之并为 A_n . 下一次细分时, 每个已选方块都会被更小的方块完整分割; 这些小方块仍满足选取条件, 所以 $A_n \subseteq A_{n+1}$.

再看任意一点 $x \in D$. 由于圆盘是开的, x 到圆盘外有正距离. 网格足够细以后, 包含 x 的方块连同闭包都会落在 D 内, 因而 x 最终会被选入. 于是

$$D = \bigcup_{n=1}^{\infty} A_n.$$

每个 A_n 都只是有限个矩形的并; 只有把所有 A_n 作可列并, 才得到整个圆盘. 若希望用这些近似求圆盘面积, 就应要求可测集合的可列并仍然可测.

在一般集合 X 上, 我们也要求全空间可测, 并且可测集的补集仍然可测. 有了补集和可列并, 可列交也随之可测, 因为 De Morgan 律给出

$$\bigcap_{n=1}^{\infty} A_n = \left(\bigcup_{n=1}^{\infty} A_n^c \right)^c.$$

因此选取集合族 $\mathcal{F} \subseteq \mathcal{P}(X)$, 要求

1. $X \in \mathcal{F}$;
2. $A \in \mathcal{F}$ 时, $A^c \in \mathcal{F}$;
3. $A_1, A_2, \dots \in \mathcal{F}$ 时, $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$.

这样的集合族称为 X 上的 σ -代数. 今后就在其中讨论集合的大小.

给集合赋予大小时, 最基本的要求是: 把一个集合分成互不重叠的部分, 各部分的大小应能加回原来的大小. 将这个要求扩展到可列个部分, 就得到测度的定义. 函数 $\mu: \mathcal{F} \rightarrow [0, \infty]$ 须满足 $\mu(\emptyset) = 0$, 并且对两两不交的 $A_1, A_2, \dots \in \mathcal{F}$ 有


$$\mu \left(\bigcup_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} \mu(A_n).$$

此时称 $(X, \mathcal{F}, \mu)$ 为测度空间.

回到圆盘的近似. 将第一次选出的部分, 第二次新增的部分, 第三次新增的部分依次列出, 它们互不相交, 并起来就是圆盘. 上面的可列可加性于是说明, 圆盘的测度正好是 $\mu(A_n)$ 的极限. 这就把用方块逼近面积的想法落实为测度的一个性质.

同样的思路也可以用于积分, 但有两种不同的划分办法. Riemann 积分先划分定义域: 对 $f: [a, b] \rightarrow \mathbb{R}$, 把区间分成小段, 每段选一个函数值作高度, 乘以该段长度后相加. 对非负函数, 图上就是一列竖直矩形.

Lebesgue 积分则先划分函数的取值. 把高度落在同一小区间内的点分为一组, 用一个近似高度代替这些点上的函数值. 这些点即使分散在定义域的不同地方, 也可以一起计算. 下图右侧的两段横轴区域合起来是 $f^{-1}([a, b])$. 计算这部分的积分时, 用近似高度乘以整个原像的测度; 原像本身不必是一段区间.



按函数值分组以后, 首先要能测量每一组点组成的集合. 例如, 要测量满足 $f(x) \leq a$ 的那部分, 就须有 $f^{-1}((-\infty, a]) \in \mathcal{F}$. 实值函数可以用这一族半直线来检验可测性, 因为它们生成了实线的 Borel σ -代数.

一般地, 映射 $f: (X, \mathcal{F}) \rightarrow (Y, \mathcal{G})$ 称为可测映射, 是指每个 $B \in \mathcal{G}$ 的原像 $f^{-1}(B)$ 都属于 $\mathcal{F}$. 这样, 无论在值域中选取哪一个可测范围, 都能测量被 f 送入该范围的点.

只取有限多个非负值的可测函数最容易积分. 将它写为简单函数 $s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$, 其中 $a_i \geq 0$, 各 A_i 可测. 若这些集合两两不交, 积分就是逐项计算高度乘以测度:

$$\int_X s d\mu = \sum_{i=1}^n a_i \mu(A_i),$$

并约定 $0 \cdot \infty = 0$. 集合有重叠时, 可以先作有限细分; 比较两种表示时也用同样的细分, 便知算出的值不依赖写法.

对一般非负可测函数 f , 取所有满足 $s \leq f$ 的非负简单函数, 将它们积分的上确界定义为 f 的积分, 允许取 $+\infty$. 这样定义以后, 再证明可以用一系列简单函数从下方逼近 f , 并让积分同时趋于上述上确界. 有正负值的函数则分别积分正部与负部; 两部同时为无穷时, 不作相减.

将这套定义用于概率, 只需让全空间的测度为一. 概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 满足 $\mathbb{P}(\Omega) = 1$, 可测集称为事件, 并, 交和补用来组合事件. Ω 可以是有限结果的集合, 也可以是完整路径的集合. 对可积随机变量 $X: \Omega \rightarrow \mathbb{R}$, 定义期望

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

因此, 怎样用简单函数逼近积分, 怎样在积分中取极限, 都将直接用于期望的计算. 以下先把可测空间, 测度和 Lebesgue 积分的定义及性质建立起来.

1.1 可测空间, 测度, Lebesgue 积分

1.1.1 可测空间与 σ -代数

前面要求可测集对补集和可列并封闭. 为了看清集合运算中的代数关系, 也可以改用交与对称差来表述同一要求.

两个集合 $A, B \subseteq X$ 的对称差是

$$A \Delta B = (A \setminus B) \cup (B \setminus A).$$

考察并集 $A \cup B$ 中的点. 只属于 A 或只属于 B 的点组成对称差 $A \Delta B$, 同时属于 A 和 B 的点组成交集 $A \cap B$. 这两部分互不相交, 合在一起恰好是整个并集:

$$A \cup B = (A \Delta B) \sqcup (A \cap B).$$

对这些集合上的测度, 因而有 $\mu(A \cup B) = \mu(A \Delta B) + \mu(A \cap B)$. 这项分解只用加法, 即使测度可能无穷, 也不会遇到 $\infty - \infty$.

把对称差看作加法, 交看作乘法, $\mathcal{P}(X)$ 就是布尔环 (Boolean ring). 其中 $\emptyset$ 是加法零元, X 是乘法单位; $A \Delta A = \emptyset$ 表明每个元素都是自己的加法逆元, $A \cap A = A$ 表明每个元素都是幂等的. 测度论还需要对可列多个集合做运算, 因而集合族必须在相应的可列运算下保持封闭. 这就得到下面的定义.

定义 1.1.

σ -代数是指集合族 $\mathcal{F} \subseteq \mathcal{P}(X)$, 其满足:

1. $X \in \mathcal{F}$;
2. 对于任意 $A, B \in \mathcal{F}$, 都有 $A \Delta B \in \mathcal{F}$;
3. 对于任意 $A_1, A_2, \dots \in \mathcal{F}$, 都有

$$\bigcap_{n=1}^{\infty} A_n \in \mathcal{F}.$$

这个定义与补集, 可列并的定义等价. 若满足上面的三条条件, 则对 $A \in \mathcal{F}$ 有 $A^c = X \Delta A \in \mathcal{F}$. 再由 De Morgan 律, $\bigcup_{n=1}^{\infty} A_n = (\bigcap_{n=1}^{\infty} A_n^c)^c \in \mathcal{F}$, 所以 $\mathcal{F}$ 对补集和可列并封闭.

反过来, 若 $\mathcal{F}$ 对补集和可列并封闭, De Morgan 律给出可列交, 而 $A \Delta B = (A \cap B^c) \cup (B \cap A^c)$ 给出对称差. 两种表述因此规定了相同的集合族.

定义 1.2.

可测空间是指二元组 $(X, \mathcal{F})$, 其中 X 为集合, $\mathcal{F}$ 为 X 上的 σ -代数.

选定 $(X, \mathcal{F})$, 就确定了研究的底层集合 X , 以及哪些子集被视为可测. 在概率论中, X 通常记作 Ω , 称为样本空间; $\mathcal{F}$ 称为事件域, 其中的集合称为事件. 此时还没有给任何事件指定概率.

例 1.3.

对于任意集合 X , 总有两个最自然的 σ -代数, 即 $\{\emptyset, X\}$ 以及 $\mathcal{P}(X)$. 当 $X = \emptyset$ 时二者恰好相同.

实际构造时, 往往先选出一族希望测量的集合, 再把作补集和可列并所需的集合一并加入. 例如在拓扑空间中, 我们希望所有开集可测, 但开集的补集未必仍是开集. 因此要寻找包含原集合族的最小 σ -代数.

定义 1.4.

由集合族 $\mathcal{A} \subseteq \mathcal{P}(X)$ 生成的 σ -代数为

$$\sigma(\mathcal{A}) = \bigcap_{\substack{\mathcal{F} \supseteq \mathcal{A} \\ \mathcal{F} \text{ is a } \sigma\text{-algebra}}} \mathcal{F}.$$

至少有一个 σ -代数包含 $\mathcal{A}$, 即 $\mathcal{P}(X)$, 所以上面的交有定义. 若一些集合同时属于所有这些 σ -代数, 它们的补集和可列并也同时属于所有这些 σ -代数. 因而交集仍是 σ -代数. 它包含 $\mathcal{A}$, 又包含在任何一个含有 $\mathcal{A}$ 的 σ -代数中, 所以正是所求的最小者.

将这个构造用于开集, 就得到 Borel σ -代数.

定义 1.5.

拓扑空间 (X, τ) 的 **Borel σ -代数**为

$$\mathcal{B}(X) = \sigma(\tau),$$

其中的集合称为 **Borel 集**.

在通常拓扑的 $\mathbb{R}$ 上, 有理端点的开区间构成可列基, 每个开集都是其中一些区间的可列并. 因

而只用开区间就能生成全部 Borel 集:

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(a, b) \mid a < b\}).$$

闭集是开集的补集, 半开区间和单点集也能由可列次集合运算得到, 所以它们都属于 $\mathcal{B}(\mathbb{R})$.

也可以换一族更便于计算概率的生成元:

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, a] \mid a \in \mathbb{R}\}).$$

这些半直线都是 Borel 集, 所以右边包含于左边. 反向只需得到开区间: 先写 $(-\infty, b) = \bigcup_{n \geq 1} (-\infty, b - 1/n]$, 再减去 $(-\infty, a]$, 就得到 (a, b) . 于是两边相等.

有了较简单的生成族, 就可以尝试先在生成元上证明某个性质, 再推到全部可测集. 为此要弄清楚, 哪些集合运算不会破坏该性质. 下面的 π - λ 定理正是常用的推广工具.

定义 1.6.

集合族 $\mathcal{P} \subseteq \mathcal{P}(X)$ 若对二元交封闭, 即 $A, B \in \mathcal{P}$ 时 $A \cap B \in \mathcal{P}$, 就称为 π -系. 因而它也对非空有限交封闭, 这里不另要求 $X \in \mathcal{P}$.

定义 1.7.

λ -系, 也称为 Dynkin 系, 是指集合族 $\mathcal{D} \subseteq \mathcal{P}(X)$, 其满足:

1. $X \in \mathcal{D}$;
2. 对于 $A, B \in \mathcal{D}$, 如果 $A \subseteq B$, 则 $B \setminus A \in \mathcal{D}$;
3. 对于两两不交的 $A_1, A_2, \dots \in \mathcal{D}$, 有

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{D}.$$

λ -系只要求能对嵌套集合作差, 能对互不相交的集合取可列并. 若它还是 π -系, 就能把任意可列并中的重叠部分依次去掉, 改写为不交可列并; 取 X 中的相对补又给出补集. 因而同时为 π -系和 λ -系的集合族就是 σ -代数.

下面从包含 $\mathcal{P}$ 的最小 λ -系出发. 证明要补上的只有对交的封闭性, 做法是先固定交中的一个集合, 再交换两者的作用.

定理 1.8 (π - λ 定理).

设 $\mathcal{P}$ 是 X 上的 π -系, $\mathcal{D}$ 是包含 $\mathcal{P}$ 的 λ -系, 则

$$\sigma(\mathcal{P}) \subseteq \mathcal{D}.$$

证明. 记 $\lambda(\mathcal{P})$ 为包含 $\mathcal{P}$ 的最小 λ -系. 固定 $A \in \mathcal{P}$, 并令

$$\mathcal{D}_A = \{B \subseteq X : A \cap B \in \lambda(\mathcal{P})\}.$$

由 λ -系对相对补与不交可列并封闭, $\mathcal{D}_A$ 也是 λ -系. 又因为 $\mathcal{P}$ 是 π -系, 对 $B \in \mathcal{P}$ 有 $A \cap B \in \mathcal{P}$, 所以 $\mathcal{P} \subseteq \mathcal{D}_A$. 最小性给出 $\lambda(\mathcal{P}) \subseteq \mathcal{D}_A$.

现在固定 $B \in \lambda(\mathcal{P})$, 并令

$$\mathcal{E}_B = \{A \subseteq X : A \cap B \in \lambda(\mathcal{P})\}.$$

同理, $\mathcal{E}_B$ 是 λ -系; 上一步说明它包含 $\mathcal{P}$, 故它也包含 $\lambda(\mathcal{P})$. 因此 $\lambda(\mathcal{P})$ 对有限交封闭. 一个同时为 π -系和 λ -系的集合族对补集与任意可列并封闭, 因而是 σ -代数. 所以

$$\sigma(\mathcal{P}) = \lambda(\mathcal{P}) \subseteq \mathcal{D}.$$

这一两次固定集合的证明也见 [Kal21, Theorem 1.1]. □

例如, 要证明两个有限测度相等, 可以先考察它们取值相同的那些集合. 若这些集合组成 λ -系, 而两测度又在一个生成 π -系上相同, 上面的定理就说明它们在全部可测集上相同.

推论 1.9.

令 μ, ν 为 $(X, \mathcal{F})$ 上的有限测度, $\mathcal{P}$ 为满足 $\sigma(\mathcal{P}) = \mathcal{F}$ 的 π -系. 若 $\mu(X) = \nu(X)$, 且每个 $A \in \mathcal{P}$ 都有 $\mu(A) = \nu(A)$, 则

$$\mu = \nu.$$

证明. 令 $\mathcal{D} = \{A \in \mathcal{F} : \mu(A) = \nu(A)\}$. 总质量相等保证 $X \in \mathcal{D}$. 若 $A \subseteq B$ 且二者在 $\mathcal{D}$ 中, 有限性允许相减, 因而两测度在 $B \setminus A$ 上仍相等. 可列可加性又保证 $\mathcal{D}$ 对不交可列并封闭. 所以 $\mathcal{D}$ 是包含 $\mathcal{P}$ 的 λ -系, 由定理包含整个 $\mathcal{F}$. $\square$

在实线上, 半直线族 $\{(-\infty, a] : a \in \mathbb{R}\}$ 对交封闭, 又生成 $\mathcal{B}(\mathbb{R})$. 两个概率测度的总质量都是一, 所以只需比较所有这些半直线的概率, 就能判断两测度是否相等. 分布函数能够确定分布, 正是这一推论的应用.

生成族还可以用来检验函数是否可测. 要测量满足某个取值条件的点, 就要考察该取值范围在函数下的原像.

定义 1.10.

对可测空间 $(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$, 若 $f: X \rightarrow Y$ 满足每个 $A \in \mathcal{G}$ 都有

$$f^{-1}(A) \in \mathcal{F},$$

就称 f 为可测映射.

检验时, 只需对 $\mathcal{G}$ 的一族生成元检查原像. 原因是 $\{A \subseteq Y : f^{-1}(A) \in \mathcal{F}\}$ 本身就是 σ -代数: 先取原像再取补集或可列并, 与先取补集或可列并再取原像, 结果相同. 因而它一旦包含生成元, 就包含整个 $\mathcal{G}$.

因此, 实值函数 f 可测, 当且仅当每个 $\{f \leq a\}$ 都可测. 连续映射也是同样的例子: 开集的原像是开集, 而开集生成 Borel σ -代数, 所以连续映射关于两边的 Borel σ -代数可测.

在概率空间上, 这项条件说明 $\{f \leq a\}$ 等取值条件都是事件, 可以计算概率. 实值随机变量就是从概率空间到 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 的可测映射.

注 1.11.

可测映射的复合仍然可测, 因为复合映射的原像可以依次取原像计算. 恒等映射也可测, 所以可测空间与可测映射构成范畴 **Meas**.

1.1.2 测度

可测空间规定了哪些集合可以测量, 测度则给这些集合赋予大小. 像前面用方块逼近圆盘那样, 有限次相加之后还要取极限, 因而测度须对可列个互不相交的集合也满足可加性.

定义 1.12.

函数 $\mu: \mathcal{F} \rightarrow [0, \infty]$ 称为**测度**, 若满足:

1. $\mu(\emptyset) = 0$;
2. 对每列两两不交的 $A_1, A_2, \dots \in \mathcal{F}$,

$$\mu\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

三元组 $(X, \mathcal{F}, \mu)$ 称为**测度空间**. 定义的第二项称为可列可加性或 σ -可加性. 在有限列后面添上空集, 就得到有限可加性.

若 $A \subseteq B$, 则 $B = A \sqcup (B \setminus A)$, 所以 $\mu(B) = \mu(A) + \mu(B \setminus A) \geq \mu(A)$. 这证明了测度的单调性. 当 $\mu(A) < \infty$ 时, 还可以相减得到 $\mu(B \setminus A) = \mu(B) - \mu(A)$; 若两项都是无穷, 就只能保留原来的加法等式.

对一般的 A, B , 用交与对称差作不交分解, 有

$$\mu(A \cup B) = \mu(A \triangle B) + \mu(A \cap B).$$

再分别分解 A 和 B , 得到

$$\mu(A \cup B) + \mu(A \cap B) = \mu(A) + \mu(B).$$

这两式都没有从无穷中减去无穷, 因而不要求测度有限.

对可列个可能重叠的集合, 依次从每项中去掉前面已经出现的部分, 就得到一个不交分解. 新分出的每块都包含在原来那一项中, 所以 $\mu(\bigcup_n A_n) \leq \sum_n \mu(A_n)$. 这称为可列次可加性; 特别地, 可列个测度为零的集合, 并起来仍然测度为零.

若 $A_n \uparrow A$, 还可以把每次新增的部分分别相加. 令 $A_0 = \emptyset$, 则 $A_n \setminus A_{n-1}$ 两两不交, 并起来为 A , 因而

$$\mu(A) = \sum_{n=1}^{\infty} \mu(A_n \setminus A_{n-1}) = \lim_{n \rightarrow \infty} \mu(A_n).$$

这就是从下连续性, 即使 $\mu(A) = \infty$ 也成立. 前面圆盘的面积逼近正是这样的递增极限.

测度为零的集合在这些运算中尤其常见, 因为加入或删除一个可测的零测集, 不改变集合的测度.

定义 1.13.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称可测集 $N \in \mathcal{F}$ 为**零测集**, 是指其满足

$$\mu(N) = 0.$$

零测集未必为空. 例如按实线上的 Lebesgue 测度计算, 每个单点的长度为零, 可数个单点的并也因可列次可加性而为零. 所以一个集合有多少点, 与它的测度多大, 是两回事.

若 $A \subseteq N$ 且 $\mu(N) = 0$, 只要 A 可测, 单调性就说明 $\mu(A) = 0$. 不过, 原来的 σ -代数未必包含 N 的所有子集. 若希望这些子集也都可以测量, 就得到下面的完备性要求.

定义 1.14.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称其为**完备测度空间**, 是指对于任意零测集 $N \in \mathcal{F}$ 以及任意子集 $A \subseteq N$, 都有 $A \in \mathcal{F}$.

在完备测度空间中, 零测集的所有子集都可测, 测度也都为零. 后面构造的完整 Lebesgue 测度满足这一要求, 只定义在 Borel 集合上的版本则不完备.

有时一个性质只在零测集上例外, 我们希望在陈述中保留这项区别, 于是使用几乎处处的说法.

定义 1.15.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称一个关于 $x \in X$ 的性质**几乎处处成立**, 是指存在零测集 N , 使得这个性质对于所有 $x \in X \setminus N$ 都成立. 常记作 μ -a.e., 或者在没有歧义的时候直接写作 a.e.

例如 $f = g$ a.e., 表示两函数只在某个可测零测集上可能不同. 两函数都可测且积分有定义时, 它们的积分相同. 完备性在这里也有用: 在不完备空间中, 若在零测集上任意改动函数, 得到的函数可能不再可测, 此时连积分都未必有定义.

另一个经常影响定理条件的问题是测度是否有限. 整条实线的长度为无穷, 但可以分段处理, 每个有界区间的长度都有限. 这提示我们区分下面两种情况.

定义 1.16.

令 $(X, \mathcal{F}, \mu)$ 为测度空间.

- 称 μ 为一个**有限测度**, 是指其满足 $\mu(X) < \infty$.

- 称 μ 为一个 σ -有限测度, 是指存在一列可测集 $A_1, A_2, \dots \in \mathcal{F}$, 满足

$$X = \bigcup_{n=1}^{\infty} A_n, \quad \mu(A_n) < \infty.$$

有限测度必然 σ -有限, 用全空间自身覆盖即可. 反向不成立: 实线可写为 $\mathbb{R} = \bigcup_{n=1}^{\infty} [-n, n]$, 各区间长度有限, 总长度却为无穷. 遇到这样的空间, 可以先在有限测度部分证明结论, 再让这些部分递增覆盖全空间. 测度扩张的唯一性和 Fubini 定理都将用到这种做法. 概率测度的总质量为一, 已经是有限测度.

若空间还有拓扑, 则可以进一步用紧集从内部逼近, 用开集从外部逼近. 希望这种拓扑上的逼近也能算出集合的测度, 就引出了 Radon 测度.

定义 1.17.

令 X 为局部紧 Hausdorff 空间, μ 为定义在 $\mathcal{B}(X)$ 上的 Borel 测度. 称 μ 为 **Radon 测度**, 是指其满足:

1. 在紧集上有限;
2. 对于任意 Borel 集 A , 有内正则性

$$\mu(A) = \sup\{\mu(K) \mid K \subseteq A, K \text{ compact}\};$$

3. 对于任意 Borel 集 A , 有外正则性

$$\mu(A) = \inf\{\mu(U) \mid A \subseteq U, U \text{ open}\}.$$

内正则性说明, 可以用 A 内部紧集的测度从下方任意逼近 $\mu(A)$; 外正则性则说明, 可以用覆盖 A 的开集测度从上方任意逼近同一个值. 本文按上面的条件使用 Radon 一词. 一般拓扑空间上的文献约定略有不同; 在主要用到的 $\mathbb{R}^n$ 上, 可以将它理解为局部有限且正则的 Borel 测度. Lebesgue 测度的 Borel 限制就是这样的例子.

测度也不必表示几何上的长度或体积. 下面两例分别计数, 或者将全部质量集中在一点.

例 1.18 (计数测度).

在 $(X, \mathcal{P}(X))$ 上定义

$$\mu(A) = \#A,$$

有限集取元素个数, 无限集取 ∞ . 不交集合的元素分别计数, 因而满足可列可加性. 它也可以限制到任意给定的 σ -代数上使用.

例 1.19 (Dirac 测度).

在可测空间 $(X, \mathcal{F})$ 中固定 $x \in X$, 定义

$$\delta_x(A) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

对不交集合列, 至多一项包含 x , 所以这同样给出测度, 且 $\delta_x(X) = 1$. 在允许测量单点的空间中, 可以直接说全部质量集中于 x .

计数测度与 Dirac 测度都符合可列可加性, 却给同一个集合赋予不同的大小. 因而选好可测集合以后, 测度仍须单独指定. 以下回到几何问题, 构造与矩形体积一致的测度.

Lebesgue 测度 在 $\mathbb{R}^d$, $d \geq 1$, 中, 矩形的体积由各边长度相乘得到. 我们要证明, 可以在更大的集合族上定义测度, 使它对每个矩形仍取原来的体积. 为此先处理矩形的有限分解, 再处理可列覆盖.

以下矩形端点都取有限实数, 所以矩形有界. 各边采用半开区间, 是为了让相邻矩形可以沿边界

拼接而不重叠.

定义 1.20 (体积函数).

半开矩形是指形如

$$[a, b) = \prod_{i=1}^d [\alpha_i, \beta_i)$$

的集合, 其中 $a = (\alpha_1, \dots, \alpha_d)$, $b = (\beta_1, \dots, \beta_d) \in \mathbb{R}^d$, 并且对于所有 $i = 1, \dots, d$ 都有 $\alpha_i \leq \beta_i$. 半开矩形 $[a, b)$ 的体积定义为

$$\lambda([a, b)) = \prod_{i=1}^d (\beta_i - \alpha_i).$$

若某个 $\alpha_i = \beta_i$, 相应区间为空, 整个矩形也为空, 上式恰好给出零体积.

注 1.21.

也可以从开矩形或闭矩形开始构造, 这里选半开矩形是为了方便作集合差. 两个半开矩形的交仍是半开矩形, 差则能分成有限个不交半开矩形, 所以这些矩形组成一个半环.

将有限个这样的矩形取并, 得到的集合族就对有限并和集合差封闭. 非空且对这两种运算封闭的集合族称为**集合环**; 再包含全空间时, 才称为全空间上的**集合代数**.

记有界半开矩形有限并所成的环为 $\mathcal{A}$. 每个 $A \in \mathcal{A}$ 都能分成有限个不交矩形, 但仍然有界, 所以 $\mathbb{R}^d \notin \mathcal{A}$. 对分解 $A = \bigsqcup_{i=1}^n I_i$, 定义 $\lambda_0(A) = \sum_{i=1}^n \lambda(I_i)$.

若同一个集合有两种分解, 把两种分解的全部端点一起用来划网格, 就能将它们继续分成相同的小矩形. 各小矩形的体积相加不变, 因而 $\lambda_0(A)$ 与所选分解无关, 且满足有限可加性.

要扩张成测度, 还须检查可列不交分解. 环本身不对任意可列并封闭, 因而先只要求: 可列并仍属于环时, 测度能按这项分解相加. 这就是预测度的条件.

定义 1.22 (预测度).

令 $\mathcal{A}$ 为 X 上的集合环. 函数 $\mu_0: \mathcal{A} \rightarrow [0, \infty]$ 称为**预测度**, 若 $\mu_0(\emptyset) = 0$, 且对两两不交的 $A_n \in \mathcal{A}$, 只要它们的并仍在 $\mathcal{A}$ 中, 就有

$$\mu_0\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu_0(A_n).$$

来验证 λ_0 是预测度. 设 $A = \bigsqcup_n A_n$, 其中 $A, A_n \in \mathcal{A}$. 有限可加性先给出 $\sum_{n=1}^N \lambda_0(A_n) \leq \lambda_0(A)$, 再令 $N \rightarrow \infty$, 就得到一个方向的不等式.

反向要把可列个矩形的比较化为有限个矩形的比较. 在 A 的有限分解中, 将每块略向内缩成紧矩形, 使总体积减少不到 ε . 再把每个 A_n 中的矩形略向外扩大为开矩形, 使这一项增加的总体积不到 $\varepsilon 2^{-n}$. 所有开矩形覆盖了刚才取得的紧集, 因而其中有限多个就已足够. 对这些有限个矩形作共同细分, 比较体积, 得到

$$\lambda_0(A) - \varepsilon \leq \sum_{n=1}^{\infty} \lambda_0(A_n) + \varepsilon.$$

令 $\varepsilon \downarrow 0$, 两个方向合起来便是可列可加性. 这一步只用了矩形的边长乘积, 有限划分和紧性, 所以没有依赖尚未构造的 Lebesgue 测度或积分.

同样的扩张问题也会出现在其他预测度中, 因而先给出一般定理.

定理 1.23 (Carathéodory 扩张定理).

令 $\mathcal{A}$ 为 X 上的集合环, 并假设存在 $E_m \in \mathcal{A}$ 使 $X = \bigcup_m E_m$. 若 μ_0 是 $\mathcal{A}$ 上的预测度, 则存在 $\sigma(\mathcal{A})$ 上的测度 μ 满足

$$\mu|_{\mathcal{A}} = \mu_0.$$

若可以选取上述覆盖使每个 $\mu_0(E_m) < \infty$, 即预测度 σ -有限, 则扩张唯一.

证明. 先用环内集合从外面覆盖任意 $E \subseteq X$, 定义

$$\mu^*(E) = \inf \left\{ \sum_{n=1}^{\infty} \mu_0(A_n) : E \subseteq \bigcup_{n=1}^{\infty} A_n, A_n \in \mathcal{A} \right\}.$$

空集可由空集覆盖, 所以 $\mu^*(\emptyset) = 0$. 覆盖一个集合的办法也覆盖它的任意子集, 因而 μ^* 单调. 对可列个集合, 分别选取总和接近各自下确界的覆盖, 将第 n 项的误差限制在 $\varepsilon 2^{-n}$ 内, 再合并覆盖, 就得到可列次可加性. 所以 μ^* 是外测度.

对环内的 A , 这个定义应当还原 $\mu_0(A)$. 用 A 自身覆盖, 先得 $\mu^*(A) \leq \mu_0(A)$. 再取任意覆盖 $A \subseteq \bigcup_n A_n$, 令 $B_n = A \cap (A_n \setminus \bigcup_{k < n} A_k)$. 这些 B_n 都在环内, 两两不交且并为 A , 所以 $\mu_0(A) = \sum_n \mu_0(B_n) \leq \sum_n \mu_0(A_n)$. 对所有覆盖取下确界, 便得反向不等式, 即 $\mu^*(A) = \mu_0(A)$.

接着选出能使外测度可加的集合. 定义

$$\mathcal{M} = \{C \subseteq X : \mu^*(E) = \mu^*(E \cap C) + \mu^*(E \setminus C) \text{ 对所有 } E \subseteq X\}.$$

对 $C \in \mathcal{A}$, 将覆盖 E 的每个 A_n 分成 $A_n \cap C$ 与 $A_n \setminus C$. 两块仍在环内, 其预测度之和等于 $\mu_0(A_n)$. 它们分别覆盖 $E \cap C$ 和 $E \setminus C$, 故 $\mu^*(E \cap C) + \mu^*(E \setminus C) \leq \mu^*(E)$. 另一方向由次可加性成立, 从而 $\mathcal{A} \subseteq \mathcal{M}$.

将 C 换成补集不改变判据, 连续按两个集合切分也可验证有限集合运算的封闭性. 若 $C_n \in \mathcal{M}$ 两两不交, 记 $C = \bigcup_n C_n$. 先按前 n 个集合依次切分, 再对剩余部分使用单调性, 有

$$\mu^*(E) \geq \sum_{k=1}^n \mu^*(E \cap C_k) + \mu^*(E \setminus C).$$

令 $n \rightarrow \infty$, 并用 $\mu^*(E \cap C) \leq \sum_k \mu^*(E \cap C_k)$, 可知 C 也满足判据. 任意可列并都能先去掉重叠部分, 改写成不交可列并, 所以 $\mathcal{M}$ 是 σ -代数. 上式再取 $E = C$, 结合次可加性, 得到 $\mu^*|_{\mathcal{M}}$ 可列可加. 因而将这个测度限制到 $\sigma(\mathcal{A}) \subseteq \mathcal{M}$, 就是所求扩张.

若 μ_0 σ -有限, 取定理中的有限测度覆盖, 令 $B_m = E_1 \cup \cdots \cup E_m$. 则 $B_m \uparrow X$, 且每个 $\mu_0(B_m) < \infty$. 任意两个扩张限制到 B_m 后都是有限测度. 它们在 $\{A \cap B_m : A \in \mathcal{A}\}$ 这个 π -系上一致, 且在 B_m 上的总质量都为 $\mu_0(B_m)$. 这个 π -系生成迹 σ -代数 $\sigma(\mathcal{A})|_{B_m}$, 所以由 π - λ 定理, 两个扩张在该迹 σ -代数上相同. 对任意 $E \in \sigma(\mathcal{A})$, 再令 $E \cap B_m \uparrow E$, 使用从下连续性, 便知两个扩张在 E 上相同. 外测度构造参见 [Kal21, Theorem 2.5], σ -有限唯一性参见 [Kal21, Lemma 1.18] 或 [Dur19, Theorem A.1.3]. $\square$

从集合代数出发时, 可用 X 自身作覆盖, 通常的代数版本因此包含在上面的定理中. 对这里的有界矩形环, 则有 $[-m, m)^d \uparrow \mathbb{R}^d$, 各块体积有限. 有理端点的开矩形构成可列拓扑基, 每个这样的开矩形又能写成可列个环内半开矩形的并, 所以 $\sigma(\mathcal{A}) = \mathcal{B}(\mathbb{R}^d)$. 定理于是给出了唯一的 Borel 测度, 在矩形上仍取原来的体积.

证明中的外测度还定义在所有子集上. 在这个例子里, 每个环内集合都能拆成有限个矩形, 因而用环内集合覆盖与用可列个矩形覆盖得到相同的下确界. 这就是 Lebesgue 外测度.

定义 1.24 (Lebesgue 外测度).

Lebesgue 外测度是指函数 $\theta: \mathcal{P}(\mathbb{R}^d) \rightarrow [0, \infty]$, 其中对于任意 $A \subseteq \mathbb{R}^d$ 定义

$$\theta(A) = \inf \left\{ \sum_{n=1}^{\infty} \lambda(I_n) \mid A \subseteq \bigcup_{n=1}^{\infty} I_n, I_n \text{ 为半开矩形} \right\}.$$

一次覆盖中的矩形可以重叠, 重叠部分会在总体积中重复计算. 对所有覆盖取下确界, 就把多余的覆盖尽量排除. 这个下确界未必由某次覆盖达到, 但在原来的矩形及其有限并上, 已经证明它恰好等于体积.

外测度满足 $\theta(\emptyset) = 0$, 单调性和可列次可加性

$$\theta\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \theta(A_n).$$

对任意子集, 即使互不相交, 也未必能把这个不等式改为等式. 因此要按照扩张证明中的办法, 选出满足以下切分条件的集合.

定义 1.25 (Carathéodory 可测集).

令 θ 为 $\mathbb{R}^d$ 上的 Lebesgue 外测度. 称集合 $E \subseteq \mathbb{R}^d$ 为 θ -可测集, 是指其满足对于任意 $A \subseteq \mathbb{R}^d$ 都有

$$\theta(A) = \theta(A \cap E) + \theta(A \setminus E).$$

次可加性已经给出 $\theta(A) \leq \theta(A \cap E) + \theta(A \setminus E)$. 可测性要求反向不等式也成立: 无论取哪个 A , 分别计算它在 E 内外两部分的外测度, 相加后都应恰好得到 $\theta(A)$. 把所有满足这一判据的 E 组成的集合族记为

$$\mathcal{L}(\mathbb{R}^d) = \left\{ E \subseteq \mathbb{R}^d \mid \forall A \subseteq \mathbb{R}^d, \theta(A) = \theta(A \cap E) + \theta(A \setminus E) \right\}.$$

前面的 Carathéodory 构造已证明, 这些集合组成 σ -代数, θ 在其上可列可加. 因而可以正式定义 Lebesgue 测度.

定义 1.26 (Lebesgue 测度).

$\mathbb{R}^d$ 上的 **Lebesgue σ -代数**是指 $\mathcal{L}(\mathbb{R}^d)$, 其中的元素称为 **Lebesgue 可测集**.
 $\mathbb{R}^d$ 上的 **Lebesgue 测度**是指测度

$$\lambda_d = \theta|_{\mathcal{L}(\mathbb{R}^d)}.$$

这样就得到测度空间 $(\mathbb{R}^d, \mathcal{L}(\mathbb{R}^d), \lambda_d)$. 矩形仍取原来的体积, 但如今可以测量的集合已不止矩形的有限并或 Borel 集. 对 $d \geq 1$, 有严格包含

$$\mathcal{B}(\mathbb{R}^d) \subsetneq \mathcal{L}(\mathbb{R}^d).$$

差别来自零测集的子集. 外测度为零的集合及其任意子集都满足 Carathéodory 判据, 所以完整 Lebesgue 测度是完备的; Borel σ -代数却没有包含全部这些子集.

反过来, 新增的集合也只比 Borel 集多出零测部分. 对有限测度的 Lebesgue 可测集, 按外测度定义选取测度越来越接近它的 Borel 覆盖, 再对这些覆盖取交, 就得到一个 Borel 集, 两者只相差 Borel 零测集内的一部分. 一般情形在 $[-m, m]^d$ 内分别处理, 再作可列并即可.

因此, 把 Borel 测度的零测集的所有子集补进来, 恰好得到 $\mathcal{L}(\mathbb{R}^d)$. 在 Borel σ -代数上, Lebesgue 测度是 Radon 测度但不完备; 在 $\mathcal{L}(\mathbb{R}^d)$ 上, 它是前者的完备化. 两者对 Borel 集取值相同, 只是定义域不同.

1.1.3 Lebesgue 积分

固定测度空间 $(X, \mathcal{F}, \mu)$. 先对只取有限多个非负值的函数积分. 在每个取值所对应的可测集合上, 函数高度相同, 将这个高度乘以集合的测度后相加, 就是章首按函数值分组的计算.

定义 1.27 (非负简单函数及其积分).

非负简单函数是 $s = \sum_{i=1}^n a_i 1_{E_i}$, 其中 a_i 为非负实数, $E_i \in \mathcal{F}$. 定义

$$\int_X s \, d\mu = \sum_{i=1}^n a_i \mu(E_i),$$

并约定 $0 \cdot \infty = 0$.

定义中允许 E_i 互相重叠. 若一个简单函数有两种表示, 将两种表示中的集合同时细分, 就得到有限个互不相交的部分. 每部分上的总函数值相同, 再由测度的有限可加性, 两种表示算出的积分也相同. 所以积分只依赖 s , 不依赖它写成哪一种和式.

对一般非负可测函数 f , 则从下方用简单函数近似. 先不选定某一列近似, 直接比较所有不超过 f 的非负简单函数.

定义 1.28 (非负可测函数及其积分).

对可测函数 $f: X \rightarrow [0, \infty]$, 定义

$$\int_X f \, d\mu = \sup \left\{ \int_X s \, d\mu \mid s \text{ 是非负简单函数且 } s \leq f \right\}.$$

结果允许为 $+\infty$.

零函数总是不超过 f 的简单函数, 所以上确界有定义. 这个定义只用上确界, 尚未交换极限与积分. 等到证明单调收敛定理以后, 就能选取一列递增简单函数, 用它们积分的极限算出同一个数.

若函数有正有负, 分别将正部与负部按刚才的办法积分, 然后相减. 为了得到有限实数, 要求两部分的积分都有限.

定义 1.29 (Lebesgue 可积函数及其积分).

令 $f: X \rightarrow \mathbb{R}$ 为可测函数, 并记 $f_+ = \max\{f, 0\}$, $f_- = \max\{-f, 0\}$. 则 f_+ 和 f_- 都是非负可测函数, 并且 $f = f_+ - f_-$, $|f| = f_+ + f_-$.

称 f 为 **Lebesgue 可积函数**, 或简称**可积函数**, 是指 f_+ 和 f_- 都具有有限的 Lebesgue 积分. 此时定义

$$\int_X f \, d\mu = \int_X f_+ \, d\mu - \int_X f_- \, d\mu.$$

由于 $|f| = f_+ + f_-$, 可积性等价于 $\int_X |f| \, d\mu < \infty$. 对本来就非负且积分有限的函数, 负部为零, 这个定义与前面的定义一致.

若只在可测集 A 上积分, 就把 A 以外的函数值取为零, 约定

$$\int_A f \, d\mu := \int_X f 1_A \, d\mu.$$

特别地, $\int_A 1 \, d\mu = \mu(A)$, 所以集合的测度也是指示函数的积分.

一些例子 有界矩形上的 Riemann 可积函数也是 Lebesgue 可积的, 而且两种积分相等. 因而改用 Lebesgue 积分后, 原先由 Riemann 积分得到的数值不会改变, 同时还能处理更广的函数类.

这里说的是有界矩形上的 Riemann 积分. 广义 Riemann 积分可能依靠正负抵消而收敛, 绝对值的积分却发散, 这样的函数就不属于 Lebesgue 可积函数.

计数测度将同样的区别变成了级数问题. 在 $X = \mathbb{N}$ 上取计数测度, 有

$$\int_X f \, d\mu = \sum_{n=1}^{\infty} f(n).$$

若 f 非负, 两边都允许为 $+\infty$; 若 f 实值可积, 则恰好要求右边绝对收敛. 因而以下关于积分的性质, 也包含了相应的求和性质.

基本性质与收敛定理 以下仍在测度空间 $(X, \mathcal{F}, \mu)$ 上讨论. 积分由简单函数的上确界定义, 我们先利用这个定义证明单调性和数乘性质, 再研究一列函数的积分怎样随函数取极限.

命题 1.30 (单调性).

令 f, g 同为非负可测函数, 或同为实值可积函数. 若 $f \leq g$ a.e., 则

$$\int f \leq \int g.$$

特别地, $f = g$ a.e. 时积分相等.

证明. 先设 f, g 非负. 取可测零测集 N , 使 $f \leq g$ 在其外成立. 对任意非负简单函数 $s \leq f$, 都有 $s1_{X \setminus N} \leq g$. 从 s 的各个取值集合中删去零测部分不改变测度, 所以 $\int s = \int s1_{X \setminus N} \leq \int g$. 再对所有这样的 s 取上确界, 即得 $\int f \leq \int g$.

若 f, g 实值可积, 则 $f_+ \leq g_+$, $f_- \geq g_-$ a.e. 分别使用已证的非负情形, 再将有限的正负部积分相减即可. 当 $f = g$ a.e. 时, 交换 f, g 再用一次不等式, 得到积分相等. $\square$

命题 1.31 (数乘).

若 f 非负可测且 $a \geq 0$, 或 f 实值可积且 $a \in \mathbb{R}$, 则

$$\int af = a \int f.$$

非负情形沿用 $0 \cdot \infty = 0$ 的约定.

证明. 对非负简单函数, 直接把系数乘以 a 即得等式. $a > 0$ 时, $s \leq af$ 与 $s/a \leq f$ 给出两边所用简单函数的一一对应, 对其积分取上确界就得到非负情形. $a = 0$ 时按约定两边均为零. 对实值可积函数分别使用正负部; $a < 0$ 时正负部互换, 再由积分定义相减. $\square$

现在为任意非负可测函数 f 选取一系列具体的简单函数. 先将超过 n 的高度截在 n , 再把较低的取值向下取到步长为 2^{-n} 的网格上. 这样每个近似只取有限多个值; 随着 n 增大, 截断高度升高, 网格也变细.

引理 1.32 (简单函数逼近).

令 $f: X \rightarrow [0, \infty]$ 可测. 对正整数 n 定义

$$\varphi_n(x) = \begin{cases} 2^{-n} \lfloor 2^n f(x) \rfloor, & f(x) < n, \\ n, & f(x) \geq n. \end{cases}$$

则各 φ_n 都是非负简单函数, 且 $\varphi_1 \leq \varphi_2 \leq \cdots \leq f$, 逐点有 $\varphi_n \rightarrow f$.

证明. 每个取值的原像由 f 的区间原像或 $\{f \geq n\}$ 给出, 所以可测, 取值数也有限. 在 $f(x) < n$ 时, 细化二进网格不会降低向下取整值; 在 $f(x) \geq n$ 时, 下一步的取值仍至少为 n . 因而 $\varphi_n \leq \varphi_{n+1} \leq f$. 若 $f(x) < \infty$, 则从 $n > f(x)$ 开始有 $0 \leq f(x) - \varphi_n(x) < 2^{-n}$. 若 $f(x) = \infty$, 则 $\varphi_n(x) = n \rightarrow \infty$. $\square$

这列 φ_n 已经逐点递增到 f , 还要证明它们的积分也递增到 $\int f$. 下面对任意非负递增函数列证明这一点. 关键是先取一个简单函数 $\phi \leq f$, 再略微降低它的高度. 这样, f_n 虽然未必达到 f , 却会在每一点最终超过降低后的高度, 从而能比较积分.

定理 1.33 (单调收敛定理).

令 $f, f_1, f_2, \dots$ 为非负可测函数. 如果 $f_n \leq f_{n+1}$, 并且 $f_n \rightarrow f$ 逐点成立, 则有

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 由单调性, $(\int f_n)$ 单调递增且 $\int f_n \leq \int f$, 所以 $\lim_n \int f_n \leq \int f$.

反过来, 任取非负简单函数 $\phi \leq f$ 以及 $\alpha \in (0, 1)$, 令 $E_n = \{x \in X \mid f_n(x) \geq \alpha\phi(x)\}$. 则 E_n 递增且 $\bigcup_n E_n = X$, 因而

$$\int f_n \geq \int_{E_n} f_n \geq \alpha \int_{E_n} \phi.$$

对简单函数 ϕ 而言, $A \mapsto \int_A \phi d\mu$ 是一个测度, 所以由测度对于递增集合列的连续性有 $\int_{E_n} \phi \rightarrow \int \phi$. 因而 $\lim_n \int f_n \geq \alpha \int \phi$. 最后令 $\alpha \rightarrow 1^-$, 再对所有满足 $0 \leq \phi \leq f$ 的简单函数取上确界即可. $\square$

将定理用于刚才构造的 φ_n , 就得到 $\int \varphi_n \uparrow \int f$, 即使极限为无穷也成立. 因而定义中的上确界可以用这一列简单函数的积分来逼近.

非负函数的无穷和也适合用同一定理处理, 因为部分和递增. 先证明两个函数的积分可相加, 再对部分和取极限, 就能交换无穷求和与积分.

命题 1.34 (可列加性).

令 $f_1, f_2, \dots$ 为非负可测函数. 则有

$$\int_X \sum_{k=1}^{\infty} f_k d\mu = \sum_{k=1}^{\infty} \int_X f_k d\mu.$$

证明. 先考虑两个函数. 分别取递增简单函数序列 $\phi_n \uparrow f_1$ 和 $\psi_n \uparrow f_2$, 那么 $\phi_n + \psi_n \uparrow f_1 + f_2$. 由简单函数积分的加性以及单调收敛定理,

$$\int (f_1 + f_2) = \lim_n \int (\phi_n + \psi_n) = \int f_1 + \int f_2.$$

有限多个函数的情况由归纳得到. 最后令 $S_n = \sum_{k=1}^n f_k$, 则 $S_n \uparrow \sum_{k=1}^{\infty} f_k$, 再使用一次单调收敛定理即可. $\square$

对实值可积的 f, g , 先由 $|f + g| \leq |f| + |g|$ 得到 $f + g$ 可积. 再将 $f, g, f + g$ 各自拆成正负部, 把等式改写成两边均为非负函数之和, 就能使用刚才的加性. 最后将有限的积分移项, 得到 $\int (f + g) = \int f + \int g$. 连同数乘性质, 这证明了积分的线性性.

回到极限问题. 若非负函数列不单调, 可以从第 k 项起取所有后续函数的下确界. 随 k 增大, 这样的下确界只会升高, 并趋于原函数列的下极限. 因而仍能用单调收敛定理得到一个方向的不等式.

引理 1.35 (Fatou 引理).

令 $f_1, f_2, \dots$ 为非负可测函数. 则有

$$\int \liminf_{n \rightarrow \infty} f_n \leq \liminf_{n \rightarrow \infty} \int f_n.$$

证明. 令 $g_k = \inf_{n \geq k} f_n$, 则 g_k 是非负可测函数, 并且 $g_k \uparrow \liminf_n f_n$. 由单调收敛定理,

$$\int \liminf_n f_n = \lim_{k \rightarrow \infty} \int g_k.$$

对任意 $j \geq k$ 有 $g_k \leq f_j$, 所以 $\int g_k \leq \inf_{j \geq k} \int f_j$. 令 $k \rightarrow \infty$ 即得结论. $\square$

这个不等式确实可能严格成立. 在 $(0, 1)$ 上取 $f_n(x) = n1_{(0, 1/n)}(x)$, 每个固定点最终都落在支撑之外, 所以 $f_n(x) \rightarrow 0$. 但非零区间长度为 $1/n$, 函数高度为 n , 各项积分始终是一. 逐点极限没有留下这块越来越窄, 越来越高的面积.

若能用同一个可积函数从上面控制所有 $|f_n|$, 就能排除这种现象. 对 $g + f_n$ 和 $g - f_n$ 分别使用 Fatou, 可以得到相反方向的两项不等式, 从而证明积分收敛.

定理 1.36 (控制收敛定理).

令 $f, f_1, f_2, \dots$ 为实值可测函数. 若 $f_n \rightarrow f$ a.e., 且存在可积函数 g 使所有 n 都有 $|f_n| \leq g$ a.e., 则 f 可积, 并且

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 将所有例外零测集合并, 在这一共同零测集上把函数改为零, 并可将控制函数取为非负. 可测性与积分不受影响, 以下不等式便可逐点使用. 取极限得到 $|f| \leq g$, 所以 f 与各 f_n 都可积.

对 $g + f_n$ 与 $g - f_n$ 分别使用 Fatou 引理和积分线性性, 得

$$\begin{aligned} \int g + \int f &\leq \int g + \liminf_{n \rightarrow \infty} \int f_n, \\ \int g - \int f &\leq \int g - \limsup_{n \rightarrow \infty} \int f_n. \end{aligned}$$

因为 $\int g < \infty$, 可以消去它, 得到

$$\int f \leq \liminf_n \int f_n \leq \limsup_n \int f_n \leq \int f.$$

两端相等, 故积分收敛. $\square$

两次 Fatou 给出的不等式中都含有 $\int g$, 而 g 可积使我们能够将这项有限数减去, 这正是证明中用到可积控制的地方. 再将定理用于 $|f_n - f| \leq 2g$, 还得到 $\int |f_n - f| d\mu \rightarrow 0$.

标量积分的线性性和收敛性质已经建立, 有限维向量值函数便可以逐坐标处理.

定义 1.37 (可积向量值函数及其积分).

设 V 为有限维实向量空间, 赋予通常的 Borel σ -代数, $f: X \rightarrow V$ 可测. 选取一组基 $v_1, \dots, v_n$, 写成 $f = \sum_{i=1}^n f_i v_i$. 若每个坐标函数 f_i 都可积, 称 f 可积, 并定义

$$\int_X f d\mu = \sum_{i=1}^n \left(\int_X f_i d\mu \right) v_i.$$

换基只是将各坐标作有限线性组合. 由刚才证明的线性性, 换基后各坐标仍可积, 算出的积分向量也相同, 因而定义不依赖选基. 将 $\mathbb{C}$ 看成二维实向量空间, 就得到分别积分实部和虚部的复值积分. 对复值或有限维向量值函数的收敛, 也可在各坐标上应用相应的实值收敛定理.

乘积测度与 Fubini 定理 对两个变量的函数 $f(x, y)$ 积分时, 既可以在乘积空间上一次积分, 也希望先固定一个变量, 对另一个变量积分. 要比较这两种做法, 先在 $X \times Y$ 上建立可测空间和测度.

最先要求可测的是矩形 $A \times B$: 它同时规定 $x \in A$ 和 $y \in B$. 用这些矩形生成 σ -代数, 就得到乘积可测空间.

定义 1.38 (乘积可测空间).

$(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$ 的乘积可测空间为

$$(X \times Y, \mathcal{F} \otimes \mathcal{G}),$$

其中

$$\mathcal{F} \otimes \mathcal{G} = \sigma\{A \times B : A \in \mathcal{F}, B \in \mathcal{G}\}.$$

两个投影 $\pi_X: X \times Y \rightarrow X$ 和 $\pi_Y: X \times Y \rightarrow Y$ 在这个 σ -代数下都可测, 而任何使两投影可测的 σ -代数都必须包含所有矩形. 所以它正是具有这一性质的最小者. 映射到乘积空间时, 可测性等价于两个坐标映射分别可测, 这就是 Meas 中积的性质.

测度则需另行构造. 仿照长乘以宽得到面积的办法, 要求矩形 $A \times B$ 的测度为 $\mu(A)\nu(B)$. 两边 σ -有限时, 这个要求能唯一确定乘积测度.

定义 1.39 (乘积测度).

设 $(X, \mathcal{F}, \mu)$ 与 $(Y, \mathcal{G}, \nu)$ 都 σ -有限. 乘积测度 $\mu \otimes \nu$ 是 $\mathcal{F} \otimes \mathcal{G}$ 上唯一满足

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B)$$

的测度, 其中约定 $0 \cdot \infty = 0$.

构造时, 先在矩形及其有限不交并上定义预测度, 再用 Carathéodory 定理扩张. 两边各有可列个有限测度集合覆盖, 取它们的乘积便得到可列个有限测度矩形, 覆盖整个 $X \times Y$, 因而也能使用 σ -有限情形的唯一性.

这里特别选择了矩形测度相乘的规则. 当 μ, ν 是概率测度时, 它对应两个变量独立的联合分布. 若只固定两个边缘分布, 却不要求独立, 就还可以有别的联合测度. 所以可测空间的积与测度的乘积是两件需要分别规定的事.

Lebesgue 测度的乘积还涉及定义域. 一维 Borel Lebesgue 测度相乘, 得到的是 $\mathcal{B}(\mathbb{R}^2) = \mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R})$ 上的二维 Borel Lebesgue 测度. 若两边都采用完备的一维 Lebesgue 测度, 乘积 $\lambda_1 \otimes \lambda_1$ 定义在 $\mathcal{L}(\mathbb{R}) \otimes \mathcal{L}(\mathbb{R})$ 上, 仍然不完备; 将这个乘积再完备化, 才得到完整的 $(\mathbb{R}^2, \mathcal{L}(\mathbb{R}^2), \lambda_2)$.

以下就在乘积 σ -代数上讨论积分. 先假设 f 非负, 可以对简单函数逼近反复使用单调收敛, 由此证明一次积分与逐次积分相等.

定理 1.40 (Tonelli 定理).

设 $(X, \mathcal{F}, \mu)$ 和 $(Y, \mathcal{G}, \nu)$ 为 σ -有限测度空间, $f: X \times Y \rightarrow [0, \infty]$ 为 $\mathcal{F} \otimes \mathcal{G}$ -可测函数. 则各截面可测, 两个内层积分分别是外层变量的非负可测函数, 且

$$\begin{aligned} \int_{X \times Y} f \, d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) \, d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) \, d\mu(x) \right) d\nu(y). \end{aligned}$$

所有积分均允许为 $+\infty$.

证明. 固定 x 后, 映射 $y \mapsto (x, y)$ 可测, 因而 $y \mapsto f(x, y)$ 可测; 固定 y 时同理. 先设两个测度都有有限, 并取矩形指示函数 $f = \mathbf{1}_{A \times B}$. 直接计算可得两种逐次积分和乘积积分都等于 $\mu(A)\nu(B)$, 内层积分也可测.

现在考察哪些乘积可测集 E 的指示函数满足定理. 这些集合对补集封闭: 补集的两个方向截面测度分别为 $\nu(Y) - \nu(E_x)$ 和 $\mu(X) - \mu(E^y)$, 这里因全空间测度有限而可以相减. 对不交可列并, 各截面测度可按项相加, 再用单调收敛交换求和与外层积分, 也得到定理中的等式. 因而这些 E 组成一个包含全部矩形的 λ -系. 由 π - λ 定理, 所有乘积可测集的指示函数都满足结论.

作非负有限线性组合, 就得到简单函数的情形. 对一般非负 f , 取简单函数 $f_n \uparrow f$. 先对每个截面用单调收敛, 得到内层积分逐点递增, 其极限可测且等于 f 的相应内层积分. 再在外层和乘积空间上分别用单调收敛, 即得所需等式.

若两个空间只是 σ -有限, 取 $X_n \uparrow X, Y_n \uparrow Y$, 其中 $\mu(X_n), \nu(Y_n) < \infty$. 在每个 $X_n \times Y_n$ 上使用已证的有限情形, 并将相应截面积分在 X_n 或 Y_n 外取零. 随 $n \rightarrow \infty$, 再次使用单调收敛, 就得到整个乘积空间上的结论. $\square$

从简单函数推广到一般非负函数时, 上面的证明一直使用递增极限, 所以积分为无穷也不妨碍等式成立. 实值函数则要分别处理正负部. 若先知道 $|f|$ 的乘积积分有限, 两部的积分就都有限, 可以将 Tonelli 得到的等式相减. 这便得到 Fubini 定理.

定理 1.41 (Fubini 定理).

设 $(X, \mathcal{F}, \mu)$ 和 $(Y, \mathcal{G}, \nu)$ 为 σ -有限测度空间, $f: X \times Y \rightarrow \mathbb{R}$ 为 $\mathcal{F} \otimes \mathcal{G}$ -可测函数, 且

$$\int_{X \times Y} |f| \, d(\mu \otimes \nu) < \infty.$$

则对 μ -a.e. x , 截面 $y \mapsto f(x, y)$ 可积; 对 ν -a.e. y , 截面 $x \mapsto f(x, y)$ 可积. 在截面不可积的例外点上, 将内层积分的值规定为零. 这样得到的两个内层积分都是关于相应外层变量的可测可积函数, 且有

$$\begin{aligned} \int_{X \times Y} f \, d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) \, d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) \, d\mu(x) \right) d\nu(y). \end{aligned}$$

证明. 对 $|f|$ 应用 Tonelli. 其乘积积分有限, 所以 $x \mapsto \int_Y |f(x, y)| \, d\nu(y)$ 几乎处处有限, 另一方向同理. 这给出几乎每个截面的绝对可积性. 将例外集上的内层积分取零后, 有

$$\left| \int_Y f(x, y) \, d\nu(y) \right| \leq \int_Y |f(x, y)| \, d\nu(y)$$

几乎处处成立, 所以内层积分关于外层变量可积. 最后分别对 f_+ 与 f_- 使用 Tonelli, 再相减. 两部的乘积积分都有限, 因而相减合法, 得到两种积分次序的等式. 相关证明参见 [Kal21, Theorem 1.29] 或 [Dur19, Theorem 1.7.2]. $\square$

实际计算时, 非负函数可直接用 Tonelli, 不必先证明积分有限. 对有正有负的函数, 则可以先对 $|f|$ 计算逐次积分; 若结果有限, Fubini 就允许交换 f 的积分次序. 个别截面仍可能不可积, 但这些例外只发生在外层变量的零测集上, 按定理取零后不影响外层积分.

前推测度与积分 还有一种常用的积分计算, 是先把测度从定义域移到值域. 设 $F: X \rightarrow Y$ 可测. 要给 Y 中的集合 A 赋予大小, 就回到 X 中, 测量所有被 F 送入 A 的点, 即 $F^{-1}(A)$.

定义 1.42 (前推测度).

设 $(X, \mathcal{F}, \mu)$ 为测度空间, $(Y, \mathcal{G})$ 为可测空间, $F: X \rightarrow Y$ 可测. 定义 μ 沿 F 的**前推测度**

$$(F_*\mu)(A) = \mu(F^{-1}(A)), \quad A \in \mathcal{G}.$$

由于 F 可测, 右边的测度有定义. 目标空间中两两不交的集合, 其原像仍两两不交; 对可列并取原像又等于各原像的并. 因而 $F_*\mu$ 满足可列可加性, 确实是测度. 这个构造只用到原像, 不要求 F 单射, 满射或可微.

若被积函数在 X 上通过 F 取值, 记为 $g \circ F$, 就可以改在 Y 上对 g 积分, 使用刚才的前推测度.

命题 1.43 (前推测度下的积分).

设 $F: (X, \mathcal{F}, \mu) \rightarrow (Y, \mathcal{G})$ 可测, $\nu = F_*\mu$. 若 g 非负可测, 或关于 ν 可积, 则

$$\int_X (g \circ F) \, d\mu = \int_Y g \, d\nu.$$

在可积情形中, $g \circ F$ 也关于 μ 可积.

证明. 先取 $g = 1_A$, 则 $g \circ F = 1_{F^{-1}(A)}$, 等式正是前推测度的定义. 对指示函数作非负有限线性组合, 得到简单函数情形. 再用简单函数 $g_n \uparrow g$, 在两边分别应用单调收敛, 得到非负可测情形. 若 g 实值可积, 先将非负结论用于 $|g|$, 得知 $g \circ F$ 可积, 再分别对正负部使用结论并相减. 有限维向量值情形逐坐标处理即可. $\square$

概率论中, 随机变量 $\xi: \Omega \rightarrow \mathbb{R}$ 的分布就是前推测度

$$\mathbb{P}_\xi = \xi_*\mathbb{P}.$$

因此, 对非负 Borel 函数 g , 或关于 $\mathbb{P}_\xi$ 可积的 g , 有

$$\mathbb{E}[g(\xi)] = \int_{\Omega} g(\xi) d\mathbb{P} = \int_{\mathbb{R}} g(x) d\mathbb{P}_\xi(x).$$

原来的积分遍历样本空间, 右边则只遍历 ξ 的取值空间, 按其分布加权, 算出的数相同. 所以计算一个随机变量的函数的期望时, 知道它的分布就已足够. 若同时研究多个随机变量或根据过去作预测, 才须进一步保留它们的联合分布和相应的信息滤过.

1.2 符号测度, Hahn 分解与 Radon–Nikodym 导数

1.2.1 符号测度与 Radon–Nikodym 定理

前面定义的测度只取非负值. 若将两个有限测度相减, 可列可加性仍然成立, 得到的值却可能为负. 对实值可积函数 h , 逐个集合计算 $\int_A h d\mu$, 也会遇到同样的情形. 为了统一研究这样的集合函数, 我们保留可列可加性, 允许取值有正有负, 称之为符号测度.

定义 1.44.

在可测空间 $(X, \mathcal{F})$ 上, 函数

$$\nu: \mathcal{F} \rightarrow [-\infty, \infty]$$

称为**符号测度**, 若满足:

1. $\nu(\emptyset) = 0$;
2. 对任意两两不交的 $A_1, A_2, \dots \in \mathcal{F}$,

$$\nu\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \nu(A_n);$$

3. 在全部可测集上, ν 至多取 $+\infty$ 与 $-\infty$ 中的一种, 不允许两种无限值同时出现.

定义中的可列和必须有意义, 将不交集合重新编号后也应得到相同结果. 若允许某个集合取 $+\infty$, 另一个集合取 $-\infty$, 相加时就会遇到无定义的抵消, 所以最后一条排除了这种情况. 同样, 两个有限测度总能相减; 两个无限测度若在某个集合上都取无穷, 就不能在那里直接作差.

有了正负值以后, 自然希望将空间分成两部分, 在一部分上只取非负值, 在另一部分上只取非正值. 这里要检查各部分中的所有可测子集. 仅有 $\nu(P) \geq 0$ 不够, 因为 P 的总值可能是内部正负值相消以后的结果. 因而采用下面的正集与负集定义.

定义 1.45.

令 ν 为 $(X, \mathcal{F})$ 上的符号测度.

- 称可测集 $P \in \mathcal{F}$ 为 ν 的**正集**, 是指对于任意可测集 $A \subseteq P$, 都有 $\nu(A) \geq 0$.
- 称可测集 $N \in \mathcal{F}$ 为 ν 的**负集**, 是指对于任意可测集 $A \subseteq N$, 都有 $\nu(A) \leq 0$.

定理 1.46 (Hahn 分解定理).

设 ν 为 $(X, \mathcal{F})$ 上的符号测度. 则存在互不相交的可测集 P, N , 满足

$$X = P \sqcup N,$$

其中 P 是正集, N 是负集.

证明. 先处理 ν 不取 $-\infty$ 的情形, 允许它取 $+\infty$. 若 ν 取过 $-\infty$, 则它不取 $+\infty$, 对 $-\nu$ 使用下面的证明, 再交换正集与负集即可.

我们先证明一个事实: 若 $\nu(A) < 0$, 则 A 内有一个负集 N_A , 且 $\nu(N_A) < 0$. 在当前假设下, $\nu(A)$ 是有限数, A 的每个可测子集的测度也有限. 否则若某个可测子集 $E \subseteq A$ 满足 $\nu(E) = +\infty$, 那么把 E 与 $A \setminus E$ 的测度相加, 就不可能得到有限的 $\nu(A)$.

从 $A_0 = A$ 开始, 不断删去其中测度为正的子集. 令

$$s_n = \sup\{\nu(E) : E \in \mathcal{F}, E \subseteq A_{n-1}\}.$$

空集的测度为零, 所以 $s_n \geq 0$. 若 $s_n = 0$, 则剩下的 A_{n-1} 已是负集, 可以停止. 若 $s_n > 0$, 选择可测的 $E_n \subseteq A_{n-1}$, 使 $\nu(E_n) > \min\{1, s_n/2\}$, 再令 $A_n = A_{n-1} \setminus E_n$. 当 $s_n = +\infty$ 时, 只需选到测度大于 1 的子集.

若一直没有停止, 删去的 E_n 两两不交, 各自的测度均为有限正数. 它们的并仍是 A 的可测子集, 所以 $\sum_n \nu(E_n) = \nu(\bigcup_n E_n) < \infty$, 从而 $\nu(E_n) \rightarrow 0$. 令 $N_A = A \setminus \bigcup_n E_n$. 假如 N_A 内还有可测集 B 满足 $\nu(B) > 0$, 则每个 $s_n \geq \nu(B)$. 按照选取 E_n 的要求, 所有 $\nu(E_n)$ 都会大于同一个正数, 这与 $\nu(E_n) \rightarrow 0$ 矛盾. 因而 N_A 是负集, 且

$$\nu(N_A) = \nu(A) - \sum_n \nu(E_n) \leq \nu(A) < 0.$$

若有限步后停止, 也可作同样的有限次相减, 所以这个事实在两种情形下都成立.

现在在所有负集中寻找测度最小的一个. 先注意负集的可列并仍是负集: 对并集内的任意可测子集, 依次去掉前面负集中已经包含的部分, 便能将它分成两两不交的可测集, 每一块都属于某个负集, 测度非正, 相加后仍非正. 定义

$$\beta = \inf\{\nu(N) : N \text{ 是可测负集}\}.$$

由空集可知 $\beta \leq 0$. 若 $\beta = -\infty$, 就能选取负集 N_n 使 $\nu(N_n) < -n$. 其并集 N 仍是负集, 并且 $\nu(N) \leq \nu(N_n) < -n$ 对所有 n 成立, 于是 $\nu(N) = -\infty$, 与本段开头的假设矛盾. 所以 β 有限.

取负集 N_n 使 $\nu(N_n) \rightarrow \beta$, 令 $N = \bigcup_n N_n$. $N \setminus N_n$ 也是负集, 所以 $\beta \leq \nu(N) \leq \nu(N_n)$, 由此得到 $\nu(N) = \beta$. 若 $P = X \setminus N$ 不是正集, 它就含有测度为负的可测集 A . 由刚才证明的事实, A 内有负集 N_A 且 $\nu(N_A) < 0$. 将它并入 N , 得到一个测度更小的负集:

$$\nu(N \sqcup N_A) = \beta + \nu(N_A) < \beta.$$

两个加数均有限, 严格不等式成立, 这与 β 是下确界矛盾. 因此 P 是正集, $X = P \sqcup N$ 就是所求分解. 相关论证参见 [Kal21, Theorem 2.8] 或 [Dur19, Theorem A.4.5]. $\square$

有了 Hahn 分解, 就可以在正集上用 ν 计算, 在负集上改用 $-\nu$ 计算, 得到两个非负测度. 每个测度只在相应的部分取值, 在另一部分为零. 先为这种情形约定一个术语.

定义 1.47.

测度 μ 集中在可测集 A 上, 是指

$$\mu(X \setminus A) = 0.$$

这一定义只要求补集的测度为零, 不要求 A 是闭集, 也不要求 A 内每个非空可测子集都有正测度. 下面将两个非负测度分别集中在 Hahn 分解的两部分上. 分割中的零测部分可以有不同归属, 但由此得到的两个测度却是唯一的.

定理 1.48 (Jordan 分解定理).

设 ν 为 $(X, \mathcal{F})$ 上的符号测度. 则存在唯一的两个非负测度 ν^+, ν^- , 满足

$$\nu = \nu^+ - \nu^-,$$

并分别集中在某个 Hahn 分解 $X = P \sqcup N$ 的 P 与 N 上. 二者至少有一个是有限测度, 因而这个差在每个可测集上都有定义. ν^+ 与 ν^- 分别称为正变差和负变差.

证明. 给定 Hahn 分解 $X = P \sqcup N$, 定义

$$\nu^+(A) = \nu(A \cap P), \quad \nu^-(A) = -\nu(A \cap N).$$

由正集与负集的定义, 这两个集合函数都非负, 又都由 ν 继承了可列可加性, 所以都是测度. 对每个 $A \in \mathcal{F}$,

$$\nu(A) = \nu(A \cap P) + \nu(A \cap N) = \nu^+(A) - \nu^-(A).$$

ν^+ 在 N 上为零, ν^- 在 P 上为零, 因而分别集中在 P, N 上. 若二者的总质量都为无穷, 则 $\nu(P) = +\infty$, $\nu(N) = -\infty$, 违反符号测度的定义. 因此至少一个测度有限.

再设 $\nu = \alpha - \beta$, 其中非负测度 α, β 分别集中在互不相交的可测集 C, D 上. 这两个集合可能尚未覆盖全空间, 令

$$R = X \setminus (C \cup D), \quad C' = C \cup R.$$

由于 $\alpha(R) = \beta(R) = 0$, 将 R 并入 C 后, α 仍集中在 C' 上, 且 C' 与 D 不交并覆盖 X . 对可测集 $E \subseteq C'$, 有 $\beta(E) = 0$, 所以 $\nu(E) = \alpha(E) \geq 0$; 对可测集 $E \subseteq D$, 有 $\alpha(E) = 0$, 所以 $\nu(E) = -\beta(E) \leq 0$. 因而 $X = C' \sqcup D$ 也是 Hahn 分解.

比较两个分解 $X = P \sqcup N = C' \sqcup D$. $P \cap D$ 同时是正集和负集, 它的每个可测子集的 ν -测度都为零; $N \cap C'$ 也一样. 在计算中删去这些交叉部分, 测度不变. 所以对任意 $A \in \mathcal{F}$,

$$\begin{aligned} \alpha(A) &= \alpha(A \cap C') = \nu(A \cap C') = \nu(A \cap C' \cap P) = \nu(A \cap P) = \nu^+(A), \\ \beta(A) &= \beta(A \cap D) = -\nu(A \cap D) = -\nu(A \cap D \cap N) = -\nu(A \cap N) = \nu^-(A). \end{aligned}$$

于是 $\alpha = \nu^+$, $\beta = \nu^-$, 分解唯一. □

正变差和负变差分别记录两种符号的大小. 求它们的差, 就还原了 ν ; 若希望计算没有正负抵消时的总量, 则将两者相加.

定义 1.49.

符号测度 ν 的全变差测度为

$$|\nu| = \nu^+ + \nu^-.$$

两种大小相减后取绝对值, 不超过它们的和, 所以 $|\nu(A)| \leq |\nu|(A)$. 全变差因此不会把相消的正负部分漏掉.

例如在 $[0, 1]$ 上定义 $\nu(A) = \int_A (2x - 1) dx$. 被积函数在 $[0, 1/2)$ 上为负, 在 $[1/2, 1]$ 上非负, 可以取这两段分别为 N, P . 计算得到

$$\nu^+([0, 1]) = \frac{1}{4}, \quad \nu^-([0, 1]) = \frac{1}{4}, \quad \nu([0, 1]) = 0, \quad |\nu|([0, 1]) = \frac{1}{2}.$$

整个区间上得到零, 是因为两边的积分恰好抵消; 两个半区间中的积分并不为零. 所以对符号测度, 不能像对非负测度那样, 由一个集合的测度为零推断它的每个可测子集也测度为零.

奇异与绝对连续 Jordan 分解中的两个测度分别集中在不交集合上. 这种关系并不限于 Jordan 分解中的两个测度. 另一种常见的比较方法是考察它们的零测集: 若一个集合的 μ -测度为零, 它的 ν -测度是否也必为零?

定义 1.50.

设 μ, ν 为同一可测空间上的测度.

- 若存在互不相交的可测集 A, B , 使 μ 集中在 A 上, ν 集中在 B 上, 则称二者**互相奇异**, 记为 $\mu \perp \nu$.
- 若每个 μ -零测集都是 ν -零测集, 即 $\mu(A) = 0$ 总蕴含 $\nu(A) = 0$, 则称 ν 关于 μ **绝对连续**, 记为 $\nu \ll \mu$.

互相奇异是对称关系, 也可以说 ν 集中在某个 μ -零测集上: 此时 μ 可以集中在该集合的补集上. Jordan 分解的两项便满足

$$\nu^+ \perp \nu^-.$$

实线上的 δ_0 与 Lebesgue 测度 λ 也是一例. 在同一可测空间中, δ_0 集中在 $\{0\}$ 上, 而 $\lambda(\{0\}) = 0$, 所以 λ 集中在其补集上.

绝对连续则有方向. $\nu \ll \mu$ 只要求 μ 的零测集在 ν 下仍为零, 没有对 ν 的其他零测集提出反向要求. 积分可以给出这样的测度: 对非负可测函数 f , 令

$$\nu(A) = \int_A f d\mu.$$

由非负积分的可列加性, ν 是测度. 若 $\mu(A) = 0$, 右边也为零, 因而 $\nu \ll \mu$.

这里用 f 对原来的 μ 加权, f 就是相对于 μ 的密度. 计算 ν 时, 各处的权重由 f 给出; $f = 0$ 的部分对积分没有贡献. 对 μ -零测集积分始终为零, 因而这样得到的 ν 必然关于 μ 绝对连续.

反过来, 若已知 $\nu \ll \mu$, 是否总能这样积分表示 ν ? 在下面的 σ -有限条件下, 答案是肯定的.

Radon-Nikodym 定理

定理 1.51 (Radon-Nikodym 定理).

设 μ, ν 为 $(X, \mathcal{F})$ 上的 σ -有限测度, 且 $\nu \ll \mu$. 则存在非负可测函数 $f: X \rightarrow [0, \infty]$, 使每个 $A \in \mathcal{F}$ 满足

$$\nu(A) = \int_A f d\mu.$$

这样的 f 在 μ -a.e. 意义下唯一.

证明. 先设 μ, ν 都有限. 对非负可测函数 f , 记

$$(f \cdot \mu)(A) := \int_A f d\mu.$$

我们先允许积分小于 $\nu(A)$, 在所有满足这一要求的函数中尽量提高总积分. 令

$$\mathcal{H} = \{f \geq 0 : f \text{ 可测且 } f \cdot \mu \leq \nu\}.$$

其中 $f \cdot \mu \leq \nu$ 表示每个可测集 A 都满足 $\int_A f d\mu \leq \nu(A)$. 零函数属于 $\mathcal{H}$, 而每个 $f \in \mathcal{H}$ 的总积分都不超过 $\nu(X)$, 所以

$$\alpha = \sup_{f \in \mathcal{H}} \int_X f d\mu < \infty.$$

选择 $f_n \in \mathcal{H}$, 使其积分趋于 α . 若 $f, g \in \mathcal{H}$, 则 $\max\{f, g\}$ 也在 $\mathcal{H}$ 中: 将任意可测集按 $f \geq g$ 与 $f < g$ 分成两部分, 在前一部分用 f 的积分不等式, 在后一部分用 g 的积分不等式, 再相加即可. 因而可以改取递增序列

$$g_n = \max\{f_1, \dots, f_n\} \uparrow g.$$

对全空间和各个可测集分别使用单调收敛, 得到

$$\int_X g d\mu = \alpha, \quad \int_A g d\mu = \lim_n \int_A g_n d\mu \leq \nu(A).$$

因此 $g \in \mathcal{H}$, 且它的积分已经达到上确界.

现在要证明每个集合上的不等式都已成为等式. 令

$$\lambda = \nu - g \cdot \mu.$$

两项都是有限测度, 且后一项不超过前一项, 所以 λ 是非负有限测度. 又有 $0 \leq \lambda \leq \nu \ll \mu$, 从而 $\lambda \ll \mu$. 若 $\lambda(X) > 0$, 则 $\mu(X) > 0$. 取足够小的 $\varepsilon > 0$, 使

$$\rho := \lambda - \varepsilon \mu, \quad \rho(X) > 0.$$

对这个有限符号测度作 Hahn 分解. 负集上的值非正, 而总值为正, 所以正集 P 满足 $\rho(P) > 0$. 若 $\mu(P) = 0$, 绝对连续性会给出 $\lambda(P) = 0$, 与 $\rho(P) > 0$ 矛盾, 故 $\mu(P) > 0$. 对每个可测 $E \subseteq P$, 正集的定义又给出 $\lambda(E) \geq \varepsilon \mu(E)$.

因此可以在 P 上将密度提高 ε , 而仍不超过 ν :

$$\begin{aligned}\int_A (g + \varepsilon 1_P) d\mu &= \int_A g d\mu + \varepsilon \mu(A \cap P) \\ &\leq \int_A g d\mu + \lambda(A \cap P) \\ &\leq \int_A g d\mu + \lambda(A) = \nu(A).\end{aligned}$$

这说明 $g + \varepsilon 1_P \in \mathcal{H}$, 但它的总积分是

$$\alpha + \varepsilon \mu(P) > \alpha,$$

与上确界的定义矛盾. 所以 $\lambda = 0$, 即 $\nu = g \cdot \mu$.

再证明唯一性. 若 $f \cdot \mu = g \cdot \mu = \nu$, 则 f, g 的总积分都等于有限数 $\nu(X)$. 因而 $\{f = \infty\} \cup \{g = \infty\}$ 是可测零测集. 在该集合上将两函数都改为零, 不改变任何集合上的积分, 得到处处有限的两个版本. 令 $E_n = \{f \geq g + 1/n\}$, 有

$$\int_{E_n} f d\mu \geq \int_{E_n} g d\mu + \frac{1}{n} \mu(E_n).$$

左右两个函数的积分都等于有限数 $\nu(E_n)$, 所以 $\mu(E_n) = 0$. 又有 $E_n \uparrow \{f > g\}$, 故 $\mu(\{f > g\}) = 0$. 交换 f, g 可得 $\mu(\{g > f\}) = 0$, 因而原来的两个密度也几乎处处相等.

对 σ -有限的 μ, ν , 分别选取有限测度覆盖. 将两组覆盖各自的前 n 项取并, 再将这两个并集相交, 得到 $C_n \uparrow X$, 且 $\mu(C_n), \nu(C_n) < \infty$. 令 $C_0 = \emptyset, D_n = C_n \setminus C_{n-1}$, 就将 X 分成可列个两测度都有限的互不交部分. 在每个 D_n 上应用有限情形, 得到密度 f_n , 然后令 f 在 D_n 上等于 f_n . 这个拼成的函数可测, 对任意 $A \in \mathcal{F}$ 有

$$\int_A f d\mu = \sum_n \int_{A \cap D_n} f_n d\mu = \sum_n \nu(A \cap D_n) = \nu(A).$$

任意两个密度在每个 D_n 上都由有限情形得知几乎处处相等. 将这些可列个例外零测集合并, 仍是零测集, 所以两密度在整个 X 上几乎处处相等. $\square$

定理给出的密度记为

$$f = \frac{d\nu}{d\mu},$$

称为 **Radon–Nikodym 导数**. 虽然写法像导数, 它是由对所有可测集成立的积分等式定义的:

$$\nu(A) = \int_A \frac{d\nu}{d\mu} d\mu.$$

因此, 在没有距离或微分运算的可测空间上, 也可以使用这个记号. 在定理的 σ -有限条件下, 密度在证明中的每个有限测度块上都可积, 所以几乎处处有限; 在例外零测集上改为零, 就得到处处有限的版本.

用密度不只可以计算集合的测度, 还可以换算一般积分. 对非负可测函数 h , 有 $\int h d\nu = \int h f d\mu$. 先取 h 为指示函数, 这就是密度的定义; 再作非负有限线性组合, 并用简单函数递增逼近, 就得到一般非负情形. 对可积实值函数, 分别处理正负部后相减即可.

例如在 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上, 令 λ 为 Lebesgue 测度的 Borel 限制. 若随机变量 ξ 的分布满足 $\mathbb{P}_\xi \ll \lambda$, 则

$$p_\xi = \frac{d\mathbb{P}_\xi}{d\lambda}$$

就是通常的概率密度. 对任意 Borel 集 A ,

$$\mathbb{P}(\xi \in A) = \mathbb{P}_\xi(A) = \int_A p_\xi(x) dx.$$

这个密度非负, 在全实线上的积分为一. 改动零测集上的取值不会改变任何事件的概率, 所以密度只确定到几乎处处相等.

若一个分布还在 Lebesgue 零测集上有正的概率, 那部分就无法通过上述密度积分得到. Lebesgue 分解将说明怎样将它单独分出.

Lebesgue 分解 更一般地, 给定参考测度 μ , 可以将 ν 分成两项: 一项关于 μ 绝对连续, 用密度积分表示; 另一项集中在 μ -零测集上. 证明时先改用 $\rho = \mu + \nu$ 作参考测度, 这样 μ, ν 都有关于 ρ 的密度. 再看 μ 的密度在哪里为零, 就能找到所需的分割.

定理 1.52 (Lebesgue 分解定理).

设 μ, ν 为 $(X, \mathcal{F})$ 上的 σ -有限测度. 则存在唯一的两个测度 ν_{ac}, ν_s , 使

$$\nu = \nu_{ac} + \nu_s, \quad \nu_{ac} \ll \mu, \quad \nu_s \perp \mu.$$

证明. 像上一证明那样, 取 μ, ν 都有限的可列覆盖, 则 $\rho = \mu + \nu$ 在每一块上也有限, 所以 ρ 是 σ -有限测度. 由 $\mu \ll \rho, \nu \ll \rho$ 及 Radon-Nikodym 定理, 可写成

$$\mu = f \cdot \rho, \quad \nu = g \cdot \rho.$$

$f + g$ 与常数函数 1 都是 ρ 关于自身的 Radon-Nikodym 密度, 因而 $f + g = 1$ ρ -a.e. 在例外零测集上调整取值, 可以使 f, g 处处非负且和为一.

按 f 是否为零来分割空间. 令 $A = \{f > 0\}$, 定义

$$\nu_{ac}(E) = \nu(E \cap A), \quad \nu_s(E) = \nu(E \cap A^c).$$

两项相加显然等于 ν . 若 $\mu(E) = 0$, 则 $\int_E f d\rho = 0$. 由于 $f \geq 0$, 它在 E 上几乎处处为零, 所以 $\rho(E \cap A) = 0$. 再由 $\nu \ll \rho$, 得到 $\nu_{ac}(E) = \nu(E \cap A) = 0$, 这就证明了 $\nu_{ac} \ll \mu$. 在另一部分 A^c 上, f 为零, 所以

$$\mu(A^c) = \int_{A^c} f d\rho = 0.$$

ν_s 集中在这个 μ -零测集上, 因而 $\nu_s \perp \mu$.

为证明唯一性, 再设 $\nu = \alpha + \sigma$, 其中 $\alpha \ll \mu, \sigma \perp \mu$. 取 μ -零测集 N, M , 使 ν_s 集中在 N 上, σ 集中在 M 上, 并令 $H = N \cup M$. 在 H 上, 两个绝对连续部分都为零; 在 H^c 上, 两个奇异部分都为零. 因此对任意 $E \in \mathcal{F}$,

$$\begin{aligned} \nu_{ac}(E) &= \nu(E \cap H^c) = \alpha(E), \\ \nu_s(E) &= \nu(E \cap H) = \sigma(E). \end{aligned}$$

两个分解的各项都等于 ν 在同一部分上的限制, 所以分别相等. 这里没有作无穷测度之间的减法, 各集合的测度为无穷时也适用. $\square$

因为 $\nu_{ac} \leq \nu$, 用 ν 的有限测度覆盖也能说明 ν_{ac} 是 σ -有限的. 对它应用 Radon-Nikodym 定理, 就得到

$$\nu_{ac}(E) = \int_E \frac{d\nu_{ac}}{d\mu} d\mu.$$

奇异部分集中在 μ -零测集上, 而关于 μ 的密度在该集合上的积分总为零. 因而除非奇异部分本来就是零测度, 否则无法用同样的密度表示它.

概率分布相对于 Lebesgue 测度也有这种分解. 离散原子属于奇异部分, 但奇异部分还可能没有原子, 形成奇异连续分布. 所以一个分布即使没有单点概率, 也未必具有 Lebesgue 密度.

1.2.2 L^p 空间

积分不仅用于计算测度, 也可以用来比较函数. 若用一个函数近似另一个函数, 先对差值取绝对值, 就不会让正负误差抵消. 将误差积分, 可以衡量它在整个空间中有多大; 若更在意幅度较大的误差, 还可以先取 p 次方再积分.

这与有限维向量的 p -范数是一回事:

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

把这里的求和换成一般测度下的积分, 就得到下面的 L^p 范数. 最后取 p 次根, 使函数乘以常数 a 时, 范数只乘以 $|a|$.

以下固定测度空间 $(X, \mathcal{F}, \mu)$, 取标量域 $\mathbb{K} = \mathbb{R}$ 或 $\mathbb{C}$. 先定义函数的范数和相应空间, 再用它们讨论误差与收敛.

L^p 范数与 L^p 空间**定义 1.53** (L^p 范数).

对可测函数 $f: X \rightarrow \mathbb{K}$, 定义

$$\|f\|_p = \left(\int_X |f|^p d\mu \right)^{1/p}, \quad 1 \leq p < \infty.$$

在端点 $p = \infty$, 定义

$$\|f\|_\infty = \operatorname{ess\,sup}_{x \in X} |f(x)| = \inf\{a \geq 0 : |f| \leq a \text{ a.e.}\}.$$

没有有限本质上界时, 后一个下确界取为 $+\infty$.

有限的本质上确界本身也是一个几乎处处上界. 事实上, 从定义中选取一列上界趋于 $\|f\|_\infty$, 将它们各自的例外零测集合并, 就有 $|f| \leq \|f\|_\infty$ 在同一个零测集之外成立.

对一般可测函数, 上述表达式可能为无穷. 以下只考虑其值有限的函数. 此时数乘齐次性由定义直接得到, 但范数为零只能说明 $f = 0$ 几乎处处, 不能说明它在每一点都为零. 因此要把几乎处处相等的函数视为同一个元素.

定义 1.54 (L^p 空间).

对 $1 \leq p \leq \infty$, 在所有满足 $\|f\|_p < \infty$ 的可测函数中, 将 μ -几乎处处相等的函数归为同一等价类. 所得空间记为 $L^p(X, \mu; \mathbb{K})$, 无歧义时简记为 $L^p(X)$ 或 L^p .

计算时通常仍用代表函数 f 表示它的等价类. 换成同一类中的另一可测函数, 范数不变. 在原函数类上, 上述表达式只是半范数; 取商以后, 零范数才恰好对应零元素. 三角不等式由下面的 Minkowski 不等式给出.

例如在正整数上采用计数测度, 就得到序列空间

$$\ell^p = \left\{ (x_n)_{n \geq 1} : \sum_{n=1}^{\infty} |x_n|^p < \infty \right\}, \quad \|x\|_p = \left(\sum_{n=1}^{\infty} |x_n|^p \right)^{1/p}, \quad 1 \leq p < \infty.$$

计数测度只有空集是零测集, 所以两个序列几乎处处相等, 就是每一项都相等. 无穷端点也相应成为

$$\ell^\infty = \left\{ (x_n)_{n \geq 1} : \sup_{n \geq 1} |x_n| < \infty \right\}, \quad \|x\|_\infty = \sup_{n \geq 1} |x_n|.$$

因此序列的求和范数与一般函数的积分范数, 都属于同一套 L^p 理论.

L^p 收敛 用 $\|f_n - f\|_p$ 衡量近似误差, 就得到相应的收敛概念.

定义 1.55.

对 $f, f_1, f_2, \dots \in L^p(X)$, 若 $\|f_n - f\|_p \rightarrow 0$, 称 f_n 在 L^p 中收敛到 f , 记为

$$f_n \xrightarrow{L^p} f.$$

当 $1 \leq p < \infty$ 时, 这要求误差的 p 次方积分趋于零. 积分中既计算误差有多大, 也计算这些误差发生在多大的集合上, 因而与逐点考察每一条数列是不同的要求. L^p 收敛一般不保证整列函数逐点收敛, 也不保证整列几乎处处收敛.

在 $p = \infty$ 的情形, 取定代表函数, 对每个 n 都有 $|f_n - f| \leq \|f_n - f\|_\infty$ a.e. 将这些可列个例外零测集合并以后, 不等式就在同一个零测集之外对所有 n 成立. 因而 L^∞ 收敛恰好给出删去零测集后的一致误差控制.

在概率空间中, 有限 p 的范数由绝对矩计算:

$$\|X\|_p^p = \mathbb{E}[|X|^p], \quad X \in L^p \iff \mathbb{E}[|X|^p] < \infty, \quad 1 \leq p < \infty.$$

因此 L^1 要求随机变量绝对可积, L^2 要求二阶绝对矩有限. 对序列, 则有

$$X_n \xrightarrow{L^p} X \iff \mathbb{E}[|X_n - X|^p] \rightarrow 0.$$

$p = 1$ 时通常称为平均收敛, $p = 2$ 时称为均方收敛. L^∞ 则要求随机变量几乎必然有有限常数界, 收敛时还要求本质误差上界趋于零. 这些定义按误差的积分或本质上界比较随机变量; 几乎必然收敛考察逐条实现, 依概率收敛考察超出阈值的概率, 依分布收敛则比较各自分布, 概率论部分将分别讨论它们.

基本不等式 计算乘积 fg 的积分时, 可以分别使用 f 和 g 的范数来估计, 这就是 Hölder 不等式. 两个范数的指数要按下面的关系配合. 随后再用 Hölder 估计 $f + g$ 的范数, 得到 Minkowski 不等式, 也就是 L^p 的三角不等式.

定义 1.56.

若 $1 \leq p, q \leq \infty$ 满足

$$\frac{1}{p} + \frac{1}{q} = 1,$$

则称为一对共轭指数, 约定 $1/\infty = 0$.

定理 1.57 (Hölder 不等式).

若 p, q 共轭, $f \in L^p(X)$, $g \in L^q(X)$, 则 $fg \in L^1(X)$, 且

$$\|fg\|_1 \leq \|f\|_p \|g\|_q.$$

证明. 先设 $1 < p, q < \infty$. 任一范数为零时, 相应函数几乎处处为零, 结论成立. 否则分别除以各自范数, 将问题化为两个单位范数函数. 对非负实数使用 Young 不等式

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q},$$

得到

$$\frac{|fg|}{\|f\|_p \|g\|_q} \leq \frac{1}{p} \frac{|f|^p}{\|f\|_p^p} + \frac{1}{q} \frac{|g|^q}{\|g\|_q^q}.$$

右边积分为 $1/p + 1/q = 1$, 同时证明乘积可积和所需上界.

若 $p = 1, q = \infty$, 则 $|fg| \leq \|g\|_\infty |f|$ a.e., 积分即得结论. 若 $p = \infty, q = 1$, 交换 f 与 g 的位置, 使用 $|fg| \leq \|f\|_\infty |g|$ a.e. 后积分. $\square$

在概率空间中, 若 $X \in L^p$, $Y \in L^q$ 且 p, q 共轭, 则

$$\mathbb{E}[|XY|] \leq \|X\|_p \|Y\|_q.$$

右边有限, 所以乘积的期望存在, 并有相应上界. 特别地, $p = q = 2$ 时, 结合 $|\mathbb{E}[X\bar{Y}]| \leq \mathbb{E}[|X\bar{Y}|]$, 得到 Cauchy-Schwarz 不等式:

$$|\mathbb{E}[X\bar{Y}]| \leq \sqrt{\mathbb{E}[|X|^2]} \sqrt{\mathbb{E}[|Y|^2]}.$$

对于和 $f + g$, 可以将其 p 次方拆成两个因子的乘积, 再使用 Hölder. 下面的证明便采用这个办法.

定理 1.58 (Minkowski 不等式).

设 $1 \leq p \leq \infty$, $f, g \in L^p(X)$. 则 $f + g \in L^p(X)$, 且

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p.$$

证明. $p = 1$ 时, 对 $|f + g| \leq |f| + |g|$ 积分即得结论. $p = \infty$ 时, 在两函数上界的共同例外零测集之外, 有 $|f + g| \leq \|f\|_\infty + \|g\|_\infty$, 所以结论也成立.

设 $1 < p < \infty$, $q = p/(p-1)$. 先由凸性得到 $|f + g|^p \leq 2^{p-1}(|f|^p + |g|^p)$. 右边可积, 因而 $f + g \in L^p$. 若 $\|f + g\|_p = 0$, 不等式已成立; 以下设这个范数为正.

将 $|f + g|^p$ 写成 $|f + g||f + g|^{p-1}$, 对第一个因子使用三角不等式, 再对所得两项分别使用 Hölder:

$$\begin{aligned}\|f + g\|_p^p &= \int_X |f + g|^p d\mu \\ &\leq \int_X (|f| + |g|)|f + g|^{p-1} d\mu \\ &\leq (\|f\|_p + \|g\|_p) \| |f + g|^{p-1} \|_q \\ &= (\|f\|_p + \|g\|_p) \|f + g\|_p^{p-1}.\end{aligned}$$

最后一步用了 $(p-1)q = p$. 因为 $\|f + g\|_p$ 已知有限且非零, 两边可以除以 $\|f + g\|_p^{p-1}$, 得到所需不等式. $\square$

结合数乘齐次性和等价类上的正定性, 现已证明 L^p 是赋范向量空间. 将一个误差拆成几项以后, 可以分别估计各项范数, 再用 Minkowski 相加, 得到总误差的上界. 这对 $1 \leq p \leq \infty$ 都适用.

完备性 用范数判断近似误差以后, 还要问: 若函数列是 Cauchy 列, 极限是否仍在同一个函数空间中? 仅限于 Riemann 可积函数时, 即使定义域是有界区间, 答案也未必肯定.

例如固定 $1 \leq p < \infty$, 在 $[0, 1]$ 上令 $f(x) = x^{-1/(2p)}$ 对 $x > 0$ 成立, 并取 $f(0) = 0$. 每个截断函数 $\min\{n, f\}$ 都 Riemann 可积. 由于 $|f|^p = x^{-1/2}$ 在 $(0, 1]$ 上可积, 控制收敛说明这些截断函数在 L^p 中趋于 f , 因而组成 Cauchy 列. 但 f 本质无界, 改动零测集上的取值也无法使它有界, 所以没有与它几乎处处相等的 Riemann 可积函数.

L^p 包含上述 Lebesgue 可积极限. 更一般地, 它包含每个 L^p -Cauchy 列的极限, 这就是下面的完备性定理. 证明先处理各项范数之和有限的级数, 再把一般 Cauchy 列的一个子列写成这种级数的部分和.

定理 1.59 (Riesz–Fisher 定理).

对任意测度空间 $(X, \mathcal{F}, \mu)$ 及 $1 \leq p \leq \infty$, $L^p(X, \mu)$ 关于 $\|\cdot\|_p$ 是 Banach 空间.

证明. 先设 $1 \leq p < \infty$, 取一系列 L^p 函数, 满足

$$B := \sum_{k=1}^{\infty} \|f_k\|_p < \infty.$$

选定各函数的可测代表元, 令

$$G_n = \sum_{k=1}^n |f_k|, \quad G = \sum_{k=1}^{\infty} |f_k|.$$

由 Minkowski, $\|G_n\|_p \leq B$. 再由 $G_n^p \uparrow G^p$ 和单调收敛, 有

$$\int_X G^p d\mu = \lim_n \int_X G_n^p d\mu \leq B^p.$$

因此 G 几乎处处有限, 即级数 $\sum_k f_k$ 几乎处处绝对收敛. 在收敛的地方取其和, 在例外可测零测集上取零, 得到可测函数 F . 由 $|F| \leq G$ a.e., 得 $F \in L^p$.

令 $F_n = \sum_{k=1}^n f_k$. 逐点收敛已经成立于一个零测集之外, 且 $|F - F_n|^p \leq 2^p G^p$ a.e. 右边可积, 所以控制收敛给出

$$\|F - F_n\|_p^p = \int_X |F - F_n|^p d\mu \rightarrow 0.$$

这就证明了: 各项范数之和有限时, 函数级数在 L^p 中收敛.

$p = \infty$ 时, 设 $\sum_k \|f_k\|_\infty < \infty$. 将各不等式 $|f_k| \leq \|f_k\|_\infty$ 的例外零测集并为 N . 在 $X \setminus N$ 上, 各项绝对值都不超过相应常数, 而这些常数之和有限, 所以函数级数绝对且一致收敛. 在 N 上将其和取为零, 得到本质有界的可测函数 F , 并有

$$\left\| F - \sum_{k=1}^n f_k \right\|_\infty \leq \sum_{k>n} \|f_k\|_\infty \longrightarrow 0.$$

因而刚才的级数结论在无穷端点也成立.

最后取任意 L^p -Cauchy 列 (h_n) . 由 Cauchy 性质, 可选取子列使 $\|h_{n_{k+1}} - h_{n_k}\|_p \leq 2^{-k}$. 级数

$$h_{n_1} + \sum_{k=1}^{\infty} (h_{n_{k+1}} - h_{n_k})$$

的各项范数之和有限, 所以在 L^p 中收敛. 它的部分和就是 h_{n_k} , 因而这个子列有 L^p 极限. 原列又是 Cauchy 列, 用三角不等式比较原列, 该子列及其极限, 就得到整列也趋于同一极限. $\square$

因此, 只要一系列 L^p 函数满足 Cauchy 条件, 就能在 L^p 中找到它的极限. 对随机变量而言, 有限 p 时极限仍具有有限的 p 阶绝对矩, $p = \infty$ 时极限仍本质有界.

这里证明的是范数空间的完备性, 与零测集的所有子集是否可测是两种不同的完备性. 证明中没有要求底层测度空间完备, 也没有使用 σ -有限性.

L^2 空间 在 L^2 中, 不仅能用范数比较函数之间的距离, 还能定义内积, 讨论正交与投影. 这个内积诱导的范数恰好就是原来的 L^2 范数.

定义 1.60.

对 $f, g \in L^2(X, \mu)$, 定义

$$\langle f, g \rangle = \int_X f \bar{g} d\mu.$$

本文约定内积对第一个变量线性, 对第二个变量共轭线性. 实值情形省去共轭即可.

定理 1.61.

$L^2(X, \mu)$ 关于上述内积是 Hilbert 空间.

证明. 由 Cauchy-Schwarz, $f\bar{g}$ 可积, 所以积分有定义, 且改动代表元的零测集取值不会改变积分. 积分的线性性和共轭运算给出内积的线性与共轭对称性; 取商后, $\langle f, f \rangle = 0$ 等价于 f 为零元素, 所以正定性也成立. 由 $\langle f, f \rangle = \|f\|_2^2$, 内积诱导的范数就是 L^2 范数. 再用 Riesz-Fisher 定理的完备性, 就知它是 Hilbert 空间. $\square$

在概率空间中, 内积写成

$$\langle X, Y \rangle = \mathbb{E}[X\bar{Y}].$$

对 $X \in L^2$, 将 Cauchy-Schwarz 用于 X 和常数一, 得到 $\mathbb{E}[|X|] < \infty$, 所以均值存在. 减去均值后, 就可以用内积比较两个变量各自的偏差.

对实值 $X, Y \in L^2$, 方差与协方差分别为

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \|X - \mathbb{E}[X]\|_2^2,$$

$$\text{Cov}(X, Y) = \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

因此方差是偏差的平方长度, 协方差为零则表示两个中心化变量正交. 均方预测也可这样处理: 在允许使用的预测变量中寻找离 X 最近的一个, 就成为 Hilbert 空间中的投影问题. 后面的条件期望会给出这一投影的具体形式.

不同 L^p 空间之间的关系 知道 $f \in L^q$ 以后, 能否推出它属于较小指数的 L^p ? 这与全空间的测度有关. 较大的幂次对大取值要求更强, 但函数取值很小的部分, 在无限测度空间中也可能积成无穷, 所以一般没有统一的包含方向.

若全空间测度有限, 则可以对 $|f|^p$ 和常数一使用 Hölder. 常数函数的积分有限, 就得到下面的包含关系.

命题 1.62.

设 $\mu(X) < \infty$, $1 \leq p < q \leq \infty$. 若 $f \in L^q(X)$, 则 $f \in L^p(X)$, 且

$$\|f\|_p \leq \mu(X)^{1/p-1/q} \|f\|_q.$$

证明. $\mu(X) = 0$ 时所有范数均为零, 结论成立. 对 $q < \infty$, 对 $|f|^p$ 和常数一使用共轭指数 q/p 与 $q/(q-p)$, 得

$$\int_X |f|^p d\mu \leq \left(\int_X |f|^q d\mu \right)^{p/q} \mu(X)^{1-p/q}.$$

右边有限, 取 p 次根即得结论. 若 $q = \infty$, 直接对 $|f|^p \leq \|f\|_\infty^p$ a.e. 积分, 再取 p 次根. $\square$

概率空间的总质量为一, 因而上式中的测度因子等于一:

$$L^q(\Omega) \subseteq L^p(\Omega), \quad \|X\|_p \leq \|X\|_q.$$

所以有限的高阶绝对矩可以估计较低阶绝对矩, 本质有界的变量则具有所有有限阶绝对矩. 特别地,

$$X \in L^2 \implies X \in L^1,$$

有限二阶矩保证期望存在, 这也与前面的 Cauchy-Schwarz 计算一致.

在一般测度空间中, 若已经知道 f 同时属于 L^p 和 L^r , 也能估计中间指数的范数, 此时不要求全空间测度有限. 做法是将 $|f|^q$ 分成两个因子, 让 Hölder 所用的两个积分分别成为已知的 p 次与 r 次积分.

定理 1.63 (插值不等式).

设 $1 \leq p < q < r \leq \infty$, $f \in L^p(X) \cap L^r(X)$. 若 $\lambda \in (0, 1)$ 满足

$$\frac{1}{q} = \frac{\lambda}{p} + \frac{1-\lambda}{r},$$

则 $f \in L^q(X)$, 且

$$\|f\|_q \leq \|f\|_p^\lambda \|f\|_r^{1-\lambda}.$$

证明. 先设 $r < \infty$. 两个数 $p/(\lambda q)$ 与 $r/((1-\lambda)q)$ 大于一, 其倒数之和为一. 对

$$|f|^q = |f|^{\lambda q} |f|^{(1-\lambda)q}$$

使用这对 Hölder 指数, 得到

$$\int_X |f|^q d\mu \leq \|f\|_p^{\lambda q} \|f\|_r^{(1-\lambda)q}.$$

取 q 次根即得结论.

若 $r = \infty$, 指数关系变为 $\lambda = p/q$. 由

$$|f|^q \leq \|f\|_\infty^{q-p} |f|^p \quad \text{a.e.}$$

积分并取 q 次根, 得到所需的两个范数幂次. $\square$

已知两端范数的上界后, 按定理中的幂次相乘, 就得到中间范数的上界. 在概率空间中, 有限的 p, r 对应两个绝对矩; $r = \infty$ 时, 则用一个有限阶绝对矩和一个本质上界作同样的估计.

简单函数逼近 前面构造 Lebesgue 积分时, 用简单函数逐点逼近非负可测函数. 若 $f \in L^p$, 还可以使近似误差的 L^p 范数趋于零, 并让每个简单函数只在有限测度集合上非零. 证明仍然使用截断和取整, 误差则由 $|f|^p$ 控制.

命题 1.64.

对 $1 \leq p < \infty$, 具有有限测度支撑的简单函数在 $L^p(X, \mu)$ 中稠密. 这里的有限测度支撑, 指在某个有限测度可测集之外取零, 不涉及拓扑支撑的闭包.

证明. 取 $f \in L^p$, 令

$$E_n = \left\{ \frac{1}{n} \leq |f| \leq n \right\}.$$

因为在 $\{|f| \geq 1/n\}$ 上有 $|f|^p \geq n^{-p}$, 所以

$$\mu \left(\left\{ |f| \geq \frac{1}{n} \right\} \right) \leq n^p \int_X |f|^p d\mu < \infty.$$

特别地, 每个 E_n 的测度有限.

只保留 f 在 E_n 上的取值, 在其外取零, 再将保留的取值离散化. 实值情形按步长 2^{-n} 将绝对值向下取整, 保留原符号; 复值情形将实部和虚部分别按同样步长向零取整. 得到的 f_n 可测且只取有限多个值, 在有限测度集合 E_n 之外为零, 并满足 $|f_n| \leq |f|$.

固定一个 $f(x)$ 有限非零的点, 当 n 足够大时, x 就属于 E_n , 取整误差也随网格加细而趋于零. 在 $f(x) = 0$ 的地方, 各 $f_n(x)$ 始终为零. 因而 $f_n \rightarrow f$ a.e. 又有

$$|f_n - f|^p \leq 2^p |f|^p,$$

右边可积. 由控制收敛, 得到 $\|f_n - f\|_p \rightarrow 0$. □

所需的有限测度集合由 f 的可积性直接给出, 因而证明没有要求全空间 σ -有限. 有了这种逼近, 对一般 L^p 函数的论证就可以先从简单函数做起, 再估计误差并取范数极限. 在概率空间中, 这就是用有限取值的随机变量逼近一般 L^p 随机变量.

无穷端点的误差要求更强. 实线上的常数一属于 L^∞ , 但任何只在有限 Lebesgue 测度集合上非零的函数, 在该集合外都与一相差一, 所以 L^∞ 距离至少为一. 因而这里的有限测度支撑要求不适用于一般 L^∞ 函数. 本质有界函数仍可按整个值域分组, 用简单函数作一致逼近, 只是这些简单函数可能要在无限测度集合上非零.

注 1.65 (积分给出的线性泛函).

Hölder 不等式还把函数与线性泛函联系起来. 对共轭指数 p, q , 固定 $g \in L^q$, 定义

$$\Lambda_g(f) = \int_X fg d\mu.$$

由 $|\Lambda_g(f)| \leq \|g\|_q \|f\|_p$, 这是 L^p 上的连续线性泛函. 在 σ -有限空间上, 若 $1 < p < \infty$, 反过来每个连续线性泛函也都有这种表示. 表示函数 g 几乎处处唯一, 泛函范数为 $\|g\|_q$.

证明反向结论时, 先在有限测度部分上将泛函用于各集合的指示函数, 得到绝对连续的符号测度, 复值时则得到复测度. Radon-Nikodym 定理将这个测度写成密度积分, 简单函数的稠密性再把积分表示推广到一般 L^p 函数. 因此, 前半部分的密度定理和后半部分的范数估计, 简单函数逼近合在一起, 就得到这类线性泛函的积分表示.

第二章 概率论基础

第一章已经建立了测度与积分的基本结果. 将全空间的测度取为一, 就得到概率空间, 可测集此时称为事件. 本章用这些结果研究随机实验中的观测值, 主要参考 [Bil95; Dur19; Kal21; Wil91].

例如连续抛十次硬币, 一次完整记录可以是

$$(H, T, H, H, T, T, H, T, H, H).$$

若要研究正面总数, 就对每条记录数一遍正面, 上面这条记录得到 6. 这样便定义了函数

$$X: \Omega \rightarrow \mathbb{R},$$

其中 Ω 是有可能记录组成的集合. 样本点 ω 给定以后, 正面总数 $X(\omega)$ 就确定了.

要问正面总数落在某个范围内的概率, 就把符合要求的记录收在一起. 一般地, 对 Borel 集 A , 这些记录组成原像 $X^{-1}(A)$, 因而

$$\mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)).$$

要求 X 可测, 正是为了让这些原像都是事件. 随机变量就是按这种方式, 从一次实验的完整结果中取出所研究的数值.

把 X 落入各个 Borel 集的概率记为实线上的一个概率测度, 就得到它的分布 $X_*\mathbb{P}$. 在抛币例子中, 它告诉我们正面总数为 0, 1, 一直到 10 的概率各是多少. 按这些概率对总数加权平均, 就得到期望. 对一般可积随机变量, 定义为

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P}.$$

由前推测度的积分公式, 也可以直接对 X 的分布积分, 得到相同的数.

取值的高次幂也可以积分. 对 $1 \leq p < \infty$,

$$X \in L^p(\Omega, \mathbb{P}) \iff \mathbb{E}[|X|^p] < \infty,$$

而 L^∞ 表示随机变量本质有界. 因此前面的积分收敛定理和范数估计, 都能用于期望, 矩及随机变量的逼近.

同时研究多个观测时, 我们还会问它们是否独立, 知道一个观测以后怎样判断另一个, 以及重复实验所得的平均值如何变化. 这些问题分别引出联合分布, 条件期望与极限定理. 图 2.1 列出了它们的联系. 将同一套方法用于不同时刻的观测, 就逐步进入随机过程的研究.




图 2.1: 从样本和事件走向随机过程

2.1 概率空间与随机变量

建立概率模型时, 先列出可能的实验结果, 再选定哪些结果集合是事件, 最后给这些事件赋予概率. 概率空间将这三项选择写在一起. 在此基础上, 随机变量从每个结果中取出要研究的数值.

2.1.1 概率空间

定义 2.1.

概率空间是三元组 $(\Omega, \mathcal{F}, \mathbb{P})$, 其中 Ω 为样本空间, $\mathcal{F}$ 是其上的 σ -代数, 称为事件域, $\mathbb{P}$ 是满足 $\mathbb{P}(\Omega) = 1$ 的测度. $\mathcal{F}$ 的元素称为事件.

这里的 $\mathbb{P}$ 只定义在 $\mathcal{F}$ 上, 所以只有属于 $\mathcal{F}$ 的子集才有概率. 在同一个 Ω 上选择不同的事件域或概率测度, 会得到不同的概率空间.

全空间 Ω 称为必然事件, 空集称为不可能事件. 若一般事件 A 满足 $\mathbb{P}(A) = 1$, 则称它几乎必然发生 (almost surely, a.s.). 此时 A^c 的概率为零, 但其中可能仍有样本点. 以下两个例子分别用计数和体积构造概率, 第二个例子也说明了非空事件怎样具有零概率.

例 2.2 (古典概型).

设 Ω 为非空有限集, 各样本点等可能, 并取 $\mathcal{F} = \mathcal{P}(\Omega)$. 对事件 A 定义

$$\mathbb{P}(A) = \frac{\#A}{\#\Omega}.$$

不交集合的元素个数可以相加, 全空间的概率为一, 所以这给出了概率测度. 每个样本点的概率都是 $1/\#\Omega$, 事件概率就是其中样本点数占总数的比例.

若各样本点不等可能, 则分别给它们非负权重, 使权重之和为一, 事件概率再按其中各点的权重相加.

例 2.3 (几何概型).

设 $\Omega \subseteq \mathbb{R}^d$ 为 Lebesgue 可测集, 且 $0 < \lambda_d(\Omega) < \infty$. 取迹 σ -代数

$$\mathcal{F} = \{A \cap \Omega : A \in \mathcal{L}(\mathbb{R}^d)\},$$

并定义

$$\mathbb{P}(A) = \frac{\lambda_d(A)}{\lambda_d(\Omega)}, \quad A \in \mathcal{F}.$$

将 Lebesgue 测度限制到 Ω , 再除以有限正数 $\lambda_d(\Omega)$, 可列可加性不变, 全空间的测度成为一. 因而这也是概率测度, 按长度, 面积或体积的比例计算事件概率.

例如在 $[0, 1]$ 上均匀取点, 对 $[a, b] \subseteq [0, 1]$ 有 $\mathbb{P}([a, b]) = b - a$. 每个单点的概率都为零, 全区间的概率却为一. 区间是不可数个单点的并, 测度的可列可加性只适用于可列个集合, 所以不能将所有单点概率按这一公理相加. 一次实验最终落在某个点上, 与事先指定的每个点都具有零概率并不矛盾.

2.1.2 随机变量

样本点不必是单个数. 抛币实验中, 它可以是完整的正反面记录; 研究市场时, 它也可以是一整条价格路径. 从同一条路径中, 可以分别取出某日价格, 某段收益或最大回撤, 得到不同的随机变量.

先只记录一只股票的每日价格, 并假设价格严格为正. 取

$$\Omega = (0, \infty)^{\mathbb{N}_0}, \quad \mathbb{N}_0 = \{0, 1, 2, \dots\}.$$

一个样本点 $\omega = (s_0, s_1, s_2, \dots)$ 就是一条完整路径. 定义坐标函数 $S_t(\omega) = s_t$, 它读出这条路径在第 t 日的价格. 再取

$$\mathcal{F} = \sigma(S_t : t \in \mathbb{N}_0),$$

即包含各坐标 Borel 取值条件的最小 σ -代数. 最后在其上选取概率测度 $\mathbb{P}$, 就得到价格路径的概率模型.

例如, 明日价格高于今日, 按每日价格计算的一个月最大回撤超过 10%, 或截至某日价格曾超过 200, 都能用有限个坐标的不等式和最大值表示, 因而是事件. 若把一天的盘口与成交也记入完整样本, 就还能从中计算总成交量及其他交易数据. 所研究的数值虽然不同, 都是在完整记录上定义一个函数.

要计算这些函数取值的概率, 相应原像必须是事件. 这正是随机变量定义中的可测性要求.

定义 2.4.

令 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间. **随机变量**是指可测映射

$$X: (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

这里 X 是定义在所有样本上的函数, $X(\omega)$ 是一次实验得到的实现值. 要检验 X 可测, 只需检查每个事件 $\{X \leq a\} = X^{-1}((-\infty, a])$ 是否属于 $\mathcal{F}$. 原像可测的那些目标集合本身组成 σ -代数, 而半直线 $(-\infty, a]$ 生成 $\mathcal{B}(\mathbb{R})$, 所以检查这族半直线就已足够.

上述价格模型中的 S_t 按事件域的选取可测. 对 $t \geq 1$, 单期收益率为

$$R_t = \frac{S_t - S_{t-1}}{S_{t-1}}.$$

价格严格为正, 所以分母不为零. 右边由两个可测坐标经连续函数得到, 因而 R_t 也是随机变量. 均线或 MACD 同样由历史价格通过可测运算算出, 可以按相同办法研究.

随机变量所携带的信息 知道 X 的值以后, 就能判断它是否落在某个 Borel 集合中. 所有能这样判断的事件, 组成由 X 生成的 σ -代数.

定义 2.5.

随机变量 X 生成的 σ -代数为

$$\sigma(X) = \{X^{-1}(A) : A \in \mathcal{B}(\mathbb{R})\}.$$

先取原像再取补集或可列并, 与先取补集或可列并再取原像, 结果相同, 所以上面列出的集合族已经是 σ -代数. 它是使 X 可测的最小 σ -代数, 并满足 $\sigma(X) \subseteq \mathcal{F}$. 当二者相等时, 原事件域中的每个事件都能通过观察 X 判断.

若 $X(\omega_1) = X(\omega_2)$, 则任意 Borel 集合的原像要么同时包含这两个样本点, 要么同时不包含它们. 因而只观察 X , 无法区分这样的两个样本.

价格路径的例子更具体. 两条路径在时刻 t 的价格相同, 过去的涨跌顺序却可能不同. 只看当前价格时, 可用信息是 $\sigma(S_t)$; 看过截至 t 的全部价格历史后, 可用信息是 $\sigma(S_0, \dots, S_t)$. 随着 t 增大, 后一族 σ -代数不断增大, 这就是价格的自然滤过.

完整的事件域 $\mathcal{F} = \sigma(S_t : t \in \mathbb{N}_0)$ 还包括关于未来价格的事件. 这些事件可以赋予概率, 但要到观察了相应价格以后才能判断是否发生. 用截至 t 的坐标生成较小的 σ -代数, 就准确表达了当前已经知道的信息.

事件与随机变量 若只想记录一个事件有没有发生, 可以把发生记为一, 没发生记为零.

定义 2.6.

事件 $A \in \mathcal{F}$ 的示性随机变量为

$$\mathbf{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

它对任意 Borel 集合的原像只可能是 A, A^c , 空集或全空间, 所以可测. 反过来, 若 $\mathbf{1}_A$ 可测, 则 $A = \{\mathbf{1}_A = 1\}$ 属于事件域. 简单函数的积分定义还给出 $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$, 所以事件概率也是一种期望.

随机向量与随机过程 将多个数值一起记录, 就得到**随机向量**: $X = (X_1, \dots, X_n): \Omega \rightarrow (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$. 它可测当且仅当每个坐标都可测. 若 X 可测, 与坐标投影复合就得到可测的 X_i . 反过来, 若每个 X_i 可测, 对 Borel 矩形有

$$\left\{ X \in \prod_{i=1}^n B_i \right\} = \bigcap_{i=1}^n \{X_i \in B_i\}, \quad B_i \in \mathcal{B}(\mathbb{R}),$$

右边可测. 再由这些矩形生成 $\mathcal{B}(\mathbb{R}^n)$, 得到 X 可测.

将值域换成一般可测空间 $(E, \mathcal{E})$, 可测映射 $X: \Omega \rightarrow E$ 就称为**随机元素**. 选好路径空间及其 σ -代数以后, 整条路径也可以这样研究.

在同一概率空间上按时间编号的一族随机变量 $(S_t)_{t \in T}$, 称为随机过程. 其中若干时刻的坐标组成随机向量, 整条路径则描述一次实现从头到尾如何变化. 对这些不同的取值空间, 都可以用前推测度来定义分布.

2.2 随机变量的分布

给定随机元素 X , 对每个可测集 A 计算 $\mathbb{P}(X \in A)$, 就能知道它在值域中如何取值. 将这些概率作为值域上的测度, 得到的就是分布.

2.2.1 分布作为前推测度

定义 2.7.

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$ 为随机元素. 称前推测度 $X_*\mathbb{P}$ 为 X 的分布, 记为 $\mathcal{L}(X)$ 或 μ_X . 即对每个 $A \in \mathcal{G}$,

$$(X_*\mathbb{P})(A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(X \in A).$$

若 $(E, \mathcal{G})$ 上的概率测度 μ 满足 $X_*\mathbb{P} = \mu$, 则称 X 服从分布 μ , 记为 $X \sim \mu$.

不交集的原像仍不交, 对可列并取原像又等于各原像的并, 所以前推测度保持可列可加性. 由 $X^{-1}(E) = \Omega$, 它在全值域上的测度为一, 因而确实是概率测度.

反过来, 若先给定 $(E, \mathcal{G})$ 上的概率测度 μ , 也可以寻找具有该分布的随机元素. 为它选择概率空间和可测映射, 称为实现这个分布.

定义 2.8.

若概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 与随机元素 $X: \Omega \rightarrow (E, \mathcal{G})$ 满足 $X_*\mathbb{P} = \mu$, 就称它们给出了分布 μ 的一个实现. 语境清楚时也直接称 X 为该分布的实现.

例 2.9 (典范实现).

对任意 $(E, \mathcal{G})$ 上的概率测度 μ , 直接取概率空间 $(E, \mathcal{G}, \mu)$, 并令 $X = \text{id}_E$. 恒等映射的原像不改变集合, 所以

$$X_*\mu = (\text{id}_E)_*\mu = \mu.$$

因而每个概率测度都有这样的实现.

同一分布可以有不同实现. 比较这些实现时, 使用同分布这个概念.

定义 2.10.

设 $X: (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (E, \mathcal{G})$ 与 $Y: (\Omega', \mathcal{F}', \mathbb{Q}) \rightarrow (E, \mathcal{G})$ 为随机元素. 若

$$X_*\mathbb{P} = Y_*\mathbb{Q},$$

则称它们**同分布**, 记为 $X \stackrel{d}{=} Y$.

定义只比较每个取值集合的概率, 因而允许 X, Y 定义在不同概率空间上. 要计算它们是否相等或相差多少, 则应把两者放在共同概率空间中, 指定如何一起取值.

例如在 $[0, 1]$ 上取均匀概率测度, 令 U 为恒等变量. U 与 $1 - U$ 都服从均匀分布, 但随机向量 (U, U) 的两个坐标始终相等, $(U, 1 - U)$ 的两个坐标却始终相加为一. 各个坐标的分布相同, 两个向量的联合分布不同. 这就具体说明了各自分布与联合分布的区别: 前者分别给出取值概率, 后者还说明这些取值如何同时出现.

分布函数 在 $\mathbb{R}^n$ 中, 可以利用坐标的大小顺序, 只记录一族左下矩形的概率:

$$(-\infty, x] = \prod_{i=1}^n (-\infty, x_i], \quad x = (x_1, \dots, x_n).$$

这些矩形随 x 变化, 对应所有坐标分别不超过给定阈值的事件. 由它们的概率就能确定整个 Borel 分布.

定义 2.11.

随机向量 $X = (X_1, \dots, X_n)$ 的分布函数 (cumulative distribution function, CDF) 为

$$F_X(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

用分布测度表示, 就是 $F_X(x) = \mu_X((-\infty, x])$. 一维时为熟悉的 $F_X(x) = \mathbb{P}(X \leq x)$; 多维时称为联合分布函数, 同时限制所有坐标的取值.

由分布函数确定分布 先算有界矩形的概率. 二维时, 从左下矩形 $(-\infty, b] \times (-\infty, d]$ 中减去左侧和下侧, 再补回被减了两次重叠部分, 得

$$\begin{aligned} \mathbb{P}(a < X \leq b, c < Y \leq d) &= F_{X,Y}(b, d) - F_{X,Y}(a, d) \\ &\quad - F_{X,Y}(b, c) + F_{X,Y}(a, c). \end{aligned}$$

高维时沿各坐标依次作差. 对有界半开矩形 $R = \prod_{i=1}^n (a_i, b_i]$, 其中 a_i, b_i 为有限实数且 $a_i < b_i$, 记

$$\Delta_R F = \sum_{\varepsilon \in \{0,1\}^n} (-1)^{n-|\varepsilon|} F(c_\varepsilon).$$

这里 $|\varepsilon| = \sum_i \varepsilon_i$. 当 $\varepsilon_i = 1$ 时, c_ε 的第 i 个坐标取 b_i , 否则取 a_i . 若 F 是分布函数, 这个和就是矩形 R 的概率, 因而非负.

现在反过来给定函数 F , 希望按这些矩形差分构造概率测度. 所需条件如下.

定义 2.12.

函数 $F: \mathbb{R}^n \rightarrow [0, 1]$ 称为 n 维分布函数, 若满足:

1. 每个有界半开矩形 $R = \prod_{i=1}^n (a_i, b_i]$ 都有 $\Delta_R F \geq 0$;
2. 若 $x^{(k)} \downarrow x$ 逐坐标成立, 则 $F(x^{(k)}) \rightarrow F(x)$;
3. 固定其余坐标, 让任意一个坐标趋于 $-\infty$, 函数值趋于零;
4. 所有坐标同时趋于 $+\infty$ 时, 函数值趋于 1.

第一项称为 n -递增性. 一维时就是单调不减; 多维时则要求整个矩形差分非负, 只沿各坐标分别单调还不够. 第二项是右连续性. 后两项说明, 将某个坐标的上界降到负无穷时概率趋于零, 将全部上界升到正无穷时概率趋于 1. 这些条件恰好保证下面的存在唯一性.

定理 2.13.

函数 $F: \mathbb{R}^n \rightarrow [0, 1]$ 是某个随机向量的分布函数, 当且仅当它满足上述 n 维分布函数条件. 此时存在唯一的 Borel 概率测度 μ_F , 使每个 $x \in \mathbb{R}^n$ 满足

$$\mu_F((-\infty, x]) = F(x).$$

证明. 若 F 来自概率测度, 矩形差分就是矩形的概率, 因而非负. 当 $x^{(k)} \downarrow x$ 时, 相应左下矩形递减到 $(-\infty, x]$, 测度的从上连续性给出 F 的右连续性. 一个坐标趋于负无穷时, 相应事件递减到空集; 全部坐标趋于正无穷时, 相应事件递增到全空间. 分别对这两个极限使用测度连续性, 即得两项边界条件.

反过来, 从有界半开矩形开始构造测度. 令 $\mathcal{A}$ 为这些矩形的有限不交并组成的集合环. 每个成员仍有界, 所以 $\mathbb{R}^n \notin \mathcal{A}$, 它不是全空间上的集合代数. 对矩形令 $\mu_0(R) = \Delta_R F$, 对有限不交并按项相加. 若同一集合有不同矩形分解, 用所有端点作共同细分, 各坐标差分中的相邻项相消, 就得到相同的和. 因而 μ_0 与分解无关, 满足有限可加性, 并由 n -递增性知它非负.

先说明各环内集合的 μ_0 值有限. 固定某个坐标的两个端点, 将其他坐标的下端点依次送到负无穷, 由矩形差分非负及边界条件, 得到 F 对该坐标单调不减. 再固定矩形上端点 b , 有

$$\mu_0\left(\prod_{i=1}^n(-m, b_i]\right) \rightarrow F(b).$$

事实上, 展开差分以后, 除 $F(b)$ 外的每一项都至少有一个坐标为 $-m$. 用坐标单调性将其余坐标提高到相应的固定 b_i , 再用负无穷处的边界条件, 可知这些项都趋于零. 任意 $A \in \mathcal{A}$ 都有界, 可被上述某个固定上端点的递增矩形族覆盖. 有限可加性给出单调性, 所以 $0 \leq \mu_0(A) \leq F(b) \leq 1$.

要证明可列可加性, 先证明空集处的从上连续性. 设 $A_j \in \mathcal{A}$, $A_j \downarrow \emptyset$. 对矩形 $R = \prod_i(a_i, b_i]$, 将各下端点略向右移, 得到 $R_\delta = \prod_i(a_i + \delta, b_i]$. 当 $\delta > 0$ 足够小时, $\overline{R_\delta} \subseteq R$ 是紧集; 当 $\delta \downarrow 0$ 时, 右连续性给出 $\mu_0(R_\delta) \rightarrow \mu_0(R)$. 在每个 A_j 的有限矩形分解中分别这样处理, 可以选出 $B_j \in \mathcal{A}$, 使 $K_j = \overline{B_j} \subseteq A_j$ 为紧集, 且

$$\mu_0(A_j \setminus B_j) < \varepsilon 2^{-j}.$$

因为 $\bigcap_j K_j \subseteq \bigcap_j A_j = \emptyset$, 紧性说明已有有限多个 K_j 的交为空. 因而存在 N , 使 $\bigcap_{j=1}^N K_j = \emptyset$. 对 $j \leq N$ 又有 $A_N \subseteq A_j$, 所以

$$A_N \subseteq \bigcup_{j=1}^N (A_j \setminus K_j) \subseteq \bigcup_{j=1}^N (A_j \setminus B_j).$$

最后这些集合都在环内, 使用有限次可加性便得 $\mu_0(A_N) < \varepsilon$. 由单调性可知其后各项也不超过这个值, 因而 $\mu_0(A_j) \downarrow 0$. 这里用紧性得到某个有限的 N , 使 $\bigcap_{j=1}^N K_j = \emptyset$; 随后的测度估计仍只涉及环中的集合.

现在若 $A = \bigsqcup_j E_j$, 且 $A, E_j \in \mathcal{A}$, 则余集 $A \setminus \bigcup_{j=1}^N E_j$ 在环内递减到空集. 有限可加性给出前 N 项与余集的等式, 令余集的测度趋于零, 得 $\mu_0(A) = \sum_j \mu_0(E_j)$. 因而 μ_0 是预测度. 有界盒 $(-m, m]^n$ 可列覆盖全空间, 各盒测度有限, 且 $\sigma(\mathcal{A}) = \mathcal{B}(\mathbb{R}^n)$. 由集合环版 Carathéodory 扩张定理, 得到唯一的 Borel 测度扩张 μ_F .

对固定的 x , 由 $\prod_i(-m, x_i] \uparrow (-\infty, x]$ 及前面的差分极限,

$$\mu_F((-\infty, x]) = F(x).$$

再让所有上端点一起趋于正无穷, 得

$$\mu_F(\mathbb{R}^n) = \lim_{m \rightarrow \infty} F(m, \dots, m) = 1.$$

所以 μ_F 是概率测度, 在其上取恒等随机向量便实现了 F . 唯一性也可直接使用 π - λ 定理: 两个候选概率测度总质量都为一, 又在生成 Borel σ -代数的左下矩形 π -系上相同, 因而在全部 Borel 集上相同. $\square$

上述构造同时给出了分布函数的典范实现.

推论 2.14.

令 F 为任意 n 维分布函数. 则存在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 以及随机向量 $X: \Omega \rightarrow \mathbb{R}^n$, 使得 $F_X = F$.

证明. 令 μ_F 为 F 对应的 Borel 概率测度. 直接取概率空间 $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mu_F)$ 以及恒等随机向量 $X = \text{id}_{\mathbb{R}^n}$ 即可. $\square$

随机向量各坐标的分布称为**边缘分布**. 要从联合分布求一个坐标的边缘分布, 就将其他坐标的限制放开. 二维时, 令 $y \uparrow \infty$, 事件 $\{X \leq x, Y \leq y\}$ 递增到 $\{X \leq x\}$, 因而

$$F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y).$$

高维时, 将不考察的那些坐标上界都送到正无穷, 做法相同.

2.2.2 一些常见的分布

下面从单次实验, 重复计数和等待时间等具体问题介绍常用分布. 对相互独立的重复实验, 可以用概率乘法推导二项分布和几何分布. 到了连续时间, 同一个到达模型又把 Poisson 计数与指数, Gamma 等待时间联系起来.

离散分布

定义 2.15.

若存在有限或可数集 $S \subseteq \mathbb{R}$, 使随机变量 X 满足 $\mathbb{P}(X \in S) = 1$, 就称 X 具有**离散分布**. $p_X(x) = \mathbb{P}(X = x)$ 称为**概率质量函数** (probability mass function, PMF).

此时全部概率都集中在 S 上. 由于不同单点互不相交, 对任意 Borel 集 A ,

$$\mathbb{P}(X \in A) = \sum_{x \in A \cap S} p_X(x), \quad \sum_{x \in S} p_X(x) = 1.$$

给出这些单点概率以后, 就可以按上式计算任何取值事件的概率. 样本中即使出现 S 外的取值, 所有这样的样本也只组成一个零概率事件.

例 2.16 (单点分布).

令 $a \in \mathbb{R}$. 如果随机变量 X 满足 $\mathbb{P}(X = a) = 1$, 那么称 X 服从位于 a 的**单点分布**. 它的分布就是 Dirac 测度 δ_a , 即

$$\delta_a(A) = \begin{cases} 1, & a \in A, \\ 0, & a \notin A. \end{cases}$$

这是最简单的概率分布: 所有概率质量全部集中在一个点上.

例 2.17 (Bernoulli 分布).

令 $p \in [0, 1]$. 如果随机变量 X 只取 0 和 1 两个值, 并满足 $\mathbb{P}(X = 1) = p$, $\mathbb{P}(X = 0) = 1 - p$, 那么称 X 服从参数为 p 的 **Bernoulli 分布**, 记作 $X \sim \text{Bernoulli}(p)$.

Bernoulli 分布就是一次“成功或者失败”实验最直接的数学描述. 比如抛一次硬币时, 可以令正面对应 1, 反面对应 0.

例 2.18 (二项分布).

取非负整数 n 和 $p \in [0, 1]$, 独立进行 n 次成功概率为 p 的 Bernoulli 实验. 令 X 为成功总次数, 则

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

X 服从参数为 (n, p) 的**二项分布**, 记为 $X \sim \text{Bin}(n, p)$.

对 $0 < p < 1$, 先指定哪 k 次实验成功, 其余 $n - k$ 次失败. 由独立性, 这一指定结果的概率为 $p^k (1-p)^{n-k}$. 成功位置共有 $\binom{n}{k}$ 种选法, 对应的事件两两不交, 相加就得到上式. $p = 0$ 时全部失败, $p = 1$ 时全部成功, 公式在端点处按 $0^0 = 1$ 的组约定理解. $n = 0$ 时没有进行

实验, 成功总数为零.

若用 X_i 记录第 i 次实验的成功与否, 则 $X = X_1 + \cdots + X_n$, 其中各 X_i 相互独立且服从 Bernoulli(p). 因而独立 Bernoulli 变量的有限和就是二项计数.

例 2.19 (几何分布).

取 $p \in (0, 1]$, 独立重复成功概率为 p 的 Bernoulli 实验, 直到首次成功. 这次将实验总次数 T 作为随机变量, 而不预先固定次数. 它满足

$$\mathbb{P}(T = k) = (1 - p)^{k-1}p, \quad k = 1, 2, \dots,$$

称 T 服从几何分布, 记为 $T \sim \text{Geom}(p)$.

$T = k$ 恰好表示前 $k - 1$ 次失败, 第 k 次成功, 概率相乘即得公式. $p = 1$ 时第一次就成功, 即 $T = 1$ a.s. 对任意 $p > 0$, 进行了 m 次却仍未成功的概率为 $(1 - p)^m$, 随 $m \rightarrow \infty$ 趋于零, 所以实验几乎必然会在有限次以后成功.

本文的 T 包含成功的那一次, 因而从 1 开始取值. 另一种约定只计成功前的失败次数, 对应 $T - 1$, 从 0 开始, 相应均值也少一.

例 2.20 (Poisson 分布).

对 $\lambda > 0$, 若

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k \in \mathbb{N}_0 = \{0, 1, 2, \dots\},$$

则称 X 服从 **Poisson 分布**, 记为 $X \sim \text{Pois}(\lambda)$. 各项非负, 用指数级数相加得到总和一, 所以确实定义了概率分布.

这个公式可以由二项计数取极限得到. 把一段固定观察期划成 n 个小段, 并把每一小段看作一次独立的 Bernoulli 试验. 每次只记录事件是否发生, 发生概率取为 λ/n . 当 n 足够大使 $\lambda/n \leq 1$ 时, 总数服从 $\text{Bin}(n, \lambda/n)$. 保持 λ 与 k 固定, 令 $n \rightarrow \infty$, 有

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda} \frac{\lambda^k}{k!}.$$

其中 $n(n-1)\cdots(n-k+1)/n^k \rightarrow 1$, 而 $(1 - \lambda/n)^n \rightarrow e^{-\lambda}$, 从而得到所述极限.

在这里, λ 是整段观察期的参数, 每次小试验发生事件的概率则随划分减小. 将这种计数用于连续时间时, 相应假设是不同小段相互独立, 发生率稳定, 并且很短一段内多次到达的概率可以忽略. 在这样的 Poisson 过程模型中, 长度为 t 的观察期使用发生率乘以 t 作为计数参数.

绝对连续分布 对离散分布, 按单点概率相加就能计算事件概率. 若分布具有密度, 则改为在相应区域上积分. 前面的 Radon–Nikodym 定理给出了密度存在的条件.

定义 2.21.

设随机向量 $X: \Omega \rightarrow \mathbb{R}^n$ 的分布为 μ_X , λ_n 为 Lebesgue 测度在 $\mathcal{B}(\mathbb{R}^n)$ 上的限制. 若

$$\mu_X \ll \lambda_n,$$

则称 X 具有**绝对连续分布**. 此时存在非负 Borel 可测函数 f_X , 对每个 Borel 集 A 满足

$$\mathbb{P}(X \in A) = \int_A f_X(x) dx.$$

f_X 称为**概率密度函数** (probability density function, PDF).

密度就是 Radon–Nikodym 导数, 并且总积分为一:

$$f_X = \frac{d\mu_X}{d\lambda_n}, \quad \int_{\mathbb{R}^n} f_X(x) dx = 1.$$

因此 f_X 几乎处处有限, 在例外 Borel 零测集上改零, 就能选成处处有限的版本. 反过来, 任意非负 Borel 可测函数只要积分为一, 按集合上的积分定义测度, 就得到一个概率分布.

一维时, 对半直线积分便得到分布函数:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

单点的 Lebesgue 测度为零, 所以每个 $\mathbb{P}(X = x)$ 都为零. $f_X(x)$ 是积分所用的密度值, 而非单点概率; 在零测集上改变密度也不会改变任何事件的概率.

一维分布函数连续, 只说明分布没有原子. 若概率集中在一个 Lebesgue 零测集上而又没有原子, 就得到奇异连续分布, 它没有上述密度. 因而一般分布中, 离散部分, 有密度的部分和奇异连续部分都可能出现.

例 2.22 (均匀分布).

取 $a < b$. 若 X 具有密度

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x),$$

就称它服从 $[a, b]$ 上的均匀分布, 记为 $X \sim \text{Unif}(a, b)$. 概率按区间长度的比例计算: 位于 $[a, b]$ 内的等长区间具有相同概率, 而每个单点的概率为零. 这正是前面几何概型在一维区间上的分布.

例 2.23 (指数分布).

对率参数 $\lambda > 0$, 密度

$$f_T(t) = \lambda e^{-\lambda t} \mathbf{1}_{[0,\infty)}(t)$$

定义指数分布, 记为 $T \sim \text{Exp}(\lambda)$. 将 T 看作等待时间, 对 $t \geq 0$ 积分得到

$$\mathbb{P}(T > t) = \int_t^\infty \lambda e^{-\lambda u} du = e^{-\lambda t}.$$

取 $t = 0$ 可知总概率为一. 若已经等了 s 而事件尚未发生, 再等超过 t 的条件概率为

$$\mathbb{P}(T > s+t \mid T > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(T > t), \quad s, t \geq 0.$$

分母始终为正, 所以这个条件概率可以用概率比计算.

等待了多久, 不改变剩余等待时间的分布, 这称为无记忆性. 几何分布的尾概率为 $(1-p)^m$, 在条件事件概率为正时作相同的比值计算, 就得到离散时间的对应性质. 后文将正式定义恒定强度的 Poisson 过程; 在那个模型中, 首次到达的等待时间正具有这种指数分布.

例 2.24 (Gamma 分布).

取形状参数 $\alpha > 0$ 和率参数 $\lambda > 0$. 密度

$$f_T(t) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\lambda t}, & t > 0, \\ 0, & t \leq 0 \end{cases}$$

定义 Gamma 分布, 记为 $T \sim \text{Gamma}(\alpha, \lambda)$. 其中

$$\Gamma(\alpha) = \int_0^\infty u^{\alpha-1} e^{-u} du.$$

在密度积分中换元 $u = \lambda t$, 就得到总积分为一. 即使 $0 < \alpha < 1$ 时密度在零点右侧趋于无穷, 这个积分仍然有限. 零点本身的取值不影响积分, 上式取为零.

本文使用率参数 λ . 若采用尺度参数 θ , 则 $\theta = 1/\lambda$, 两种记法通过倒数换算.

当形状参数是正整数时, 可以继续沿用前面提到的 Poisson 到达模型, 把 Gamma 变量解释为等待若干次到达的总时间. 设该过程的发生率为 λ , $N(t)$ 为截至 t 的事件数, 则 $N(t) \sim \text{Pois}(\lambda t)$. 固定正整数 k , 令 T_k 为第 k 次到达时刻. 尚未等到第 k 次到达, 就是已经发生的事件不足 k 次, 因而对 $t \geq 0$,

$$\{T_k > t\} = \{N(t) \leq k-1\}.$$

用 Poisson 概率求和, 得

$$\mathbb{P}(T_k \leq t) = 1 - \sum_{j=0}^{k-1} e^{-\lambda t} \frac{(\lambda t)^j}{j!}.$$

在 $t > 0$ 对这项分布函数求导, 相邻幂次的项相消, 得到

$$f_{T_k}(t) = \frac{\lambda^k}{(k-1)!} t^{k-1} e^{-\lambda t}, \quad t > 0.$$

由 $\Gamma(k) = (k-1)!$, 这正是 $\text{Gamma}(k, \lambda)$ 的密度.

因此, 在同一个过程中, 固定时间统计到达次数得到 Poisson 分布, 固定正整数次数计算等待时间得到整数形状的 Gamma 分布. $k=1$ 对应首次等待, 密度便是指数密度. Gamma 族的密度定义允许任意 $\alpha > 0$, 上述第 k 次到达的解释则用于其中的正整数形状.

例 2.25 (正态分布).

取 $\mu \in \mathbb{R}$, $\sigma > 0$. 若 X 具有密度


$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right),$$

就称它服从正态分布 (normal distribution), 也称 Gauss 分布, 记为

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

$\mu = 0$, $\sigma = 1$ 时称为标准正态分布 $\mathcal{N}(0, 1)$.

曲线关于 $x = \mu$ 对称. 改变 μ , 曲线沿实轴平移; 增大 σ , 曲线沿横向拉宽, 峰值则因系数 $1/\sigma$ 而降低, 总面积仍为一. 下图标出距中心一, 二, 三个 σ 的位置. 纵向经过缩放, 未标数值刻度, 用来展示曲线形状.



这种平移和缩放可以直接算出. 对 $a \neq 0$, $b \in \mathbb{R}$, 变量替换给出 $aX + b$ 的密度为 $|a|^{-1}f_X((x-b)/a)$, 代入正态密度并整理, 得

$$aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

若 $a = 0$, 结果为常数 b , 对应单点分布. 特别地, 减去 μ 再除以 σ , 得到

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1),$$

这个变换称为**标准化**.

标准正态密度对称, 所以 $\mathbb{E}[Z] = 0$. 对二阶积分中的 $z^2 e^{-z^2/2}$ 分部积分, 得 $\mathbb{E}[Z^2] = 1$. 因而 $X = \mu + \sigma Z$ 的期望为 μ , 方差为 σ^2 , 标准差为 σ . 图中距中心几个 σ 的范围, 也就是距均值几个标准差的范围.

对 $c \geq 0$, 标准化后有

$$\mathbb{P}(|X - \mu| < c\sigma) = \frac{1}{\sqrt{2\pi}} \int_{-c}^c e^{-z^2/2} dz.$$

取 $c = 1, 2, 3$, 相应概率约为 68.27%, 95.45% 和 99.73%. 所以在正态分布中, 落在 $\mu \pm 3\sigma$ 之外的概率约为 0.27%.

独立正态变量相加以后也服从正态分布. 设 $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$, 且 X, Y 独立, 则联合密度为 $f_X f_Y$. 要计算和在 z 处的密度, 令第一个变量取 u , 第二个取 $z - u$, 再对 u 积分. 在指数中完成平方, 可得

$$f_{X+Y}(z) = \int_{\mathbb{R}} f_X(u) f_Y(z-u) du = \frac{\exp\left(-\frac{(z - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right)}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}}.$$

因而

$$X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

这里均值相加, 方差也因独立性而相加.

更一般的求和问题中, 单项变量可以并不正态. 在适当条件下, 大量小扰动之和经过中心化和尺度归一化以后, 仍会趋于正态分布. 中心极限定理研究的就是一种分布极限.


注 2.26 (多元正态分布).

将正态分布推广到随机向量, 位置由均值向量 $\mu \in \mathbb{R}^n$ 指定, 各坐标的方差与协方差则放在矩阵 Σ 中. 当 Σ 为实对称正定矩阵时, 非退化的 n 元正态分布 $\mathcal{N}(\mu, \Sigma)$ 具有密度

$$f(x) = \frac{1}{(2\pi)^{n/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

一维正态密度中的标准化平方偏差, 在多维情形下变成由 Σ^{-1} 决定的二次型. 因而不同方向上的偏离会按照协方差矩阵给出的尺度进入密度.

下图画出二维正态分布的等密度轮廓. 椭圆以 μ 为中心, 朝向与长短轴由 Σ 决定; 色阶区分由内到外的区域.



固定一个密度值, 就是固定二次型的值:

$$(x - \mu)^\top \Sigma^{-1}(x - \mu) = c.$$

对 $c > 0$, 二维时得到椭圆, 高维时得到椭球面; $c = 0$ 时只剩均值点.

多元正态变量还可以通过线性变换构造. 取各坐标相互独立且标准正态的向量 Z , 令 $X = \mu + AZ$, 则协方差矩阵为 $AA^\top$. 这个构造也允许协方差矩阵半正定而不正定. 当 $\Sigma = AA^\top$ 的秩小于 n 时, X 总落在 $\mu + \text{range}(A)$ 中. 这是低维仿射子空间, 在 $\mathbb{R}^n$ 中的 Lebesgue 测度为零, 所以该分布没有整个 $\mathbb{R}^n$ 上的 Lebesgue 密度. 此时 Σ 也不可逆, 与前面密度公式要求正定的条件相符.

2.3 期望与矩

2.3.1 期望与矩的计算

知道分布以后, 就可以按概率对取值求平均. 取值可能有限, 可数, 也可能遍布一个区间, 前面的 Lebesgue 积分可以统一处理这些情形.

定义 2.27.

在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上, 若实值随机变量 $X \in L^1$, 定义其**期望** (expectation) 为

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P}.$$

对非负随机变量, 也允许扩展值期望

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P} \in [0, \infty].$$

一般实值变量则先写为 $X = X^+ - X^-$, 分别计算两部的期望. 只要两部不同时为无穷, 就能作扩展实数的相减; 两部都有限时, 得到有限期望, 这恰好等价于 $\mathbb{E}[|X|] < \infty$. 若两部都为无穷, 期望便没有定义.

计算时通常直接使用 X 的分布 $\mu_X = X_*\mathbb{P}$. 对 Borel 可测函数 g , 若 $g \geq 0$ 或 $g(X)$ 可积, 前推测度的积分公式给出

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \, d\mu_X(x).$$

非负情形仍允许无穷值. 因而同分布的变量对同一个合适的 g 有相同期望, 可以直接在值域中计算.

例如, 若 X 的全部概率集中在互不相同的可数个数 x_i 上, 则

$$\mathbb{E}[X] = \sum_i x_i \mathbb{P}(X = x_i).$$

若 X 具有密度 f_X , 则

$$\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x) \, dx.$$

两式都在相应期望存在时使用. 有限个结果等可能时, 第一式简化为把取值相加再除以个数; 一般情形则按各自概率加权.

积分的线性性也直接适用. 对 $X, Y \in L^1$ 和 $a, b \in \mathbb{R}$,

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y],$$

这里无须假设 X, Y 独立. 若 $X \leq Y$ a.s., 则由单调性得到 $\mathbb{E}[X] \leq \mathbb{E}[Y]$. 对事件的指示函数, 有 $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$.

此外, $|\mathbb{E}[X]| \leq \mathbb{E}[|X|] = \|X\|_1$, 所以期望是 L^1 上的连续线性泛函. 用 X_n 近似 X 时, $|\mathbb{E}[X_n] - \mathbb{E}[X]| \leq \mathbb{E}[|X_n - X|]$. 因此 L^1 误差趋于零, 期望误差也趋于零. 单纯逐点收敛则要结合前面的单调收敛, 控制收敛等条件处理.

例 2.28 (按情景计算期望).

金融研究中, 可以按不同经营假设将未来结果分成乐观 (Bull), 基准 (Base), 悲观 (Bear) 和尾部 (Tail) 等情景, 再分别估计未来某时点的价值. 设原价值变量 $V \in L^1$, 有限个可测事件 $A_1, \dots, A_m$ 两两不交且覆盖全空间, 每项代表一个情景. 在第 i 个情景中选取有限代表值 V_i , 就得到简单随机变量

$$\tilde{V} = \sum_{i=1}^m V_i \mathbf{1}_{A_i}, \quad \mathbb{E}[\tilde{V}] = \sum_{i=1}^m \mathbb{P}(A_i) V_i.$$

这个加权和算的是所选近似的期望. 它与原期望的差满足

$$|\mathbb{E}[V] - \mathbb{E}[\tilde{V}]| \leq \mathbb{E}[|V - \tilde{V}|].$$

因此, 每个情景中的代表值越接近原变量在该情景中的实际取值, $\mathbb{E}[|V - \tilde{V}|]$ 就越小, 期望误差的上界也随之降低.

若每个正概率情景都取原变量在该情景中的平均,

$$V_i = \frac{\mathbb{E}[V \mathbf{1}_{A_i}]}{\mathbb{P}(A_i)}, \quad \mathbb{P}(A_i) > 0,$$

而零概率情景取任意有限数, 例如零, 则

$$\mathbb{E}[\tilde{V}] = \sum_i \mathbb{E}[V \mathbf{1}_{A_i}] = \mathbb{E}[V].$$

此时组内平均恰好保留了总期望. 这种按情景分组求平均的做法, 是后文条件期望的一个具体例子. 每个情景仍被压成了一个数, 所以情景内部的波动没有保留, 方差和尾部概率应另按所研究的取值计算.

除了平均值, 还可以对取值的幂次求期望. 取绝对值可以避免正负抵消, 提高幂次则使较大的取值在积分中占更大比重.

定义 2.29.

设 $k \geq 1$ 为整数, $X \in L^k$ 为实值随机变量. $\mathbb{E}[|X|^k] = \|X\|_k^k$ 称为 k 阶绝对矩, $\mathbb{E}[X^k]$ 称为 k 阶矩或 k 阶原点矩.

偶数阶时 $X^k = |X|^k$, 两种矩相等. 奇数阶的 X^k 保留正负号, 正负部分会在期望中相消. 绝对矩还可以对任意实数 $p > 0$ 定义; 当 $1 \leq p < \infty$ 时, 它就是 L^p 范数的 p 次方.

若要衡量偏离均值的大小, 就先减去 $\mathbb{E}[X]$. 对 $X \in L^k$, 有限测度空间的包含关系保证 $X \in L^1$, 均值有限, 且 $X - \mathbb{E}[X]$ 仍属于 L^k . 相应地,

$$\mathbb{E}[|X - \mathbb{E}[X]|^k] = \|X - \mathbb{E}[X]\|_k^k$$

称为 k 阶绝对中心矩, $\mathbb{E}[(X - \mathbb{E}[X])^k]$ 称为 k 阶中心矩. 奇数阶中心矩仍会比较两个方向的正负贡献.

因为 $\mathbb{P}(\Omega) = 1$, 对 $1 \leq p < q \leq \infty$ 有 $\|X\|_p \leq \|X\|_q$. 所以高阶绝对矩有限时, 较低阶也有限; 本质有界时, 所有有限阶绝对矩都有限. 下面重点研究二阶矩.

2.3.2 二阶矩与尾概率

L^2 空间, 协方差与方差 本小节取实值 L^2 随机变量, 内积为 $\langle X, Y \rangle = \mathbb{E}[XY]$. Cauchy-Schwarz 保证乘积可积, 也保证每个变量的期望有限.

先用一个常数 c 近似 X , 以 $\mathbb{E}[(X - c)^2]$ 衡量误差. 将 $X - c$ 分成 $X - \mathbb{E}[X]$ 与 $\mathbb{E}[X] - c$, 展开平方, 得

$$\mathbb{E}[(X - c)^2] = \mathbb{E}[(X - \mathbb{E}[X])^2] + (\mathbb{E}[X] - c)^2.$$

交叉项为零, 因为 $\mathbb{E}[X - \mathbb{E}[X]] = 0$. 右边第一项不随 c 改变, 第二项在且仅在 $c = \mathbb{E}[X]$ 时为零. 所以在所有常数中, 用均值近似 X 的均方误差最小.

从内积看, 中心化变量 $X^\circ = X - \mathbb{E}[X]$ 满足 $\langle X^\circ, 1 \rangle = 0$. 因而均值是 X 向常数函数子空间的正交投影, 剩下的偏差与所有常数正交. 比较两个变量的偏差, 就得到协方差.

定义 2.30.

对实值 $X, Y \in L^2$, 定义协方差

$$\text{Cov}(X, Y) = \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

先分别减去均值, 再将两个偏差相乘并取平均. 展开后,

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

两变量同时高于或同时低于各自均值时, 乘积为正; 一个高于, 一个低于时, 乘积为负. 协方差就是把这些乘积按概率平均. 若协方差为零, 称两变量**不相关**, 此时它们中心化以后在 L^2 中正交.

将两个变量取为同一个, 相乘就变成平方, 得到方差.

定义 2.31.

对实值 $X \in L^2$, 定义方差

$$\text{Var}(X) = \text{Cov}(X, X) = \|X - \mathbb{E}[X]\|_2^2.$$

方差非负, 为零当且仅当 $X = \mathbb{E}[X]$ a.s. 展开平方还可写为

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

结合前面的常数近似计算, 方差就是用均值近似 X 时的均方误差, 也是在所有常数预测中能达到的最小值.

定义 2.32.

$X \in L^2$ 的标准差为

$$\text{Std}(X) = \sqrt{\text{Var}(X)} = \|X - \mathbb{E}[X]\|_2.$$

平方误差使用原变量单位的平方, 开方以后便回到原单位. 若将 X 放大 100 倍, 标准差也放大 100 倍, 方差则放大 10,000 倍. 协方差同样会随单位变化: 将其中一个变量放大 100 倍, 协方差就放大 100 倍. 为了比较不受这种正比例缩放影响的关系, 将协方差除以两边的标准差.

定义 2.33.

对实值 $X, Y \in L^2$, 若两者方差均严格为正, 定义**相关系数**

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\text{Std}(X) \text{Std}(Y)}.$$

令 $\tilde{X} = (X - \mathbb{E}[X])/\text{Std}(X)$, 对 Y 同样标准化. 二者都是 L^2 单位向量, 且 $\rho(X, Y) = \langle \tilde{X}, \tilde{Y} \rangle$. 由 Cauchy-Schwarz, $|\rho(X, Y)| \leq 1$. 将任一变量乘以正数不改变该系数, 乘以负数则反转符号. 若某个变量方差为零, 分母也为零, 上述相关系数便没有定义.

不相关描述的是这种中心化后的正交, 两变量之间仍可能有非线性关系. 例如 U 在 $[-1, 1]$ 上均匀分布, 令 $Y = U^2$. 对称性给出 $\mathbb{E}[U] = \mathbb{E}[U^3] = 0$, 因而 $\text{Cov}(U, Y) = 0$, 但知道 U 就完全知道 Y . 具体地, $\{Y \leq 1/4\}$ 与 $\{|U| \leq 1/2\}$ 是同一事件, 两者的交集概率为 $1/2$, 而各自概率的乘积为 $1/4$. 所以它们不满足独立性所要求的概率乘法.

尾部与尾部风险 方差将各种偏差的平方加权平均. 若想知道特别大的偏差出现得多不多, 就要直接考察超过给定阈值的概率. 例如, 各以一半概率取 ± 1 的变量, 与以 0.9 概率取 0, 各以 0.05 概率

取 $\pm\sqrt{10}$ 的变量, 均值都为零, 方差都为一. 前者从不满足 $|X| > 2$, 后者满足这一条件的概率却为 0.1.

远离主要概率质量的部分称为分布的**尾部** (tail). 可以分别用 $\mathbb{P}(X > x)$ 和 $\mathbb{P}(X < -x)$ 考察右尾与左尾, 也可以用 $\mathbb{P}(|X| > x)$ 一起比较两边. 研究损失时, 阈值说明损失有多大, 尾概率则说明超过这个损失的机会有多少.

定义 2.34.

实值随机变量 X 的**右尾函数**或**生存函数**为

$$\bar{F}_X(x) = \mathbb{P}(X > x) = 1 - F_X(x).$$

这里用严格不等号 $>$, 与分布函数中 $X \leq x$ 的事件互为补集. 若改成 $X \geq x$, 还须把 $X = x$ 的点概率算入. 尾概率随阈值增大而下降的快慢, 常用轻尾或重尾形容; 以下直接用尾概率和渐近式说明具体的下降速度.

尾函数还可以用来计算矩. 对非负 X , 固定一次实现 ω , 有

$$X(\omega) = \int_0^\infty \mathbf{1}_{\{X(\omega) > t\}} dt.$$

右边是在数轴上计算区间 $[0, X(\omega))$ 的长度. 被积函数在概率空间与半轴的乘积上可测且非负, 所以可以用 Tonelli 交换积分, 得到

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt.$$

因此非负变量的期望就是尾函数下的面积, 两边允许同时为 $+\infty$.

对任意实值 X 和 $p > 0$, 逐点还有 $|X|^p = \int_0^\infty pt^{p-1} \mathbf{1}_{\{|X| > t\}} dt$. 再次使用 Tonelli, 得

$$\mathbb{E}[|X|^p] = p \int_0^\infty t^{p-1} \mathbb{P}(|X| > t) dt.$$

对尾积分中 $t > 1$ 的部分, p 越大, 权重 t^{p-1} 就越大, 因而高阶矩对大取值更敏感. 当 $1 \leq p < \infty$ 时, 这个积分有限就等价于 $X \in L^p$.

正态密度衰减得比任意固定幂次快, 因而所有正阶绝对矩都有限. 对幂律尾部, 情形不同. 若 $\mathbb{P}(|X| > x) \sim Cx^{-\alpha}$, 其中 $C > 0, \alpha > 0$, 则大阈值处的尾积分与 $\int_1^\infty t^{p-1-\alpha} dt$ 同敛散. 接近零的部分因尾概率不超过一, 对每个 $p > 0$ 都可积. 因而绝对矩在 $0 < p < \alpha$ 时有限, 在 $p \geq \alpha$ 时发散.

这些等式从尾概率算出矩. 若只知道一个有限矩, 也可以反过来给尾概率估计上界.

定理 2.35 (Markov 不等式).

若 $X \geq 0$ 可积, $a > 0$, 则

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

证明. 逐点有 $X \geq a \mathbf{1}_{\{X \geq a\}}$. 取期望得到 $\mathbb{E}[X] \geq a \mathbb{P}(X \geq a)$, 再除以 $a > 0$. □

对 $1 \leq p < \infty$ 和 $X \in L^p$, 将不等式用于非负变量 $|X|^p$, 并取阈值 a^p , 得

$$\mathbb{P}(|X| \geq a) \leq \frac{\mathbb{E}[|X|^p]}{a^p} = \frac{\|X\|_p^p}{a^p}.$$

只要知道右边的矩, 就能据此估计超出阈值的概率. 这里得到的是上界, 与前面的精确尾积分等式用途不同.

将偏差先中心化再平方, 就能直接用方差估计偏离均值的概率.

定理 2.36 (Chebyshev 不等式).

若实值 $X \in L^2$ 且 $a > 0$, 则

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

证明. 将 Markov 不等式用于非负可积变量 $(X - \mathbb{E}[X])^2$ 和阈值 a^2 . 该变量的期望就是方差, 而它至少为 a^2 的事件恰好是 $\{|X - \mathbb{E}[X]| \geq a\}$. $\square$

若标准差为 $\sigma > 0$, 对任意 $k > 0$ 取 $a = k\sigma$, 就得到偏离均值至少 k 个标准差的概率不超过 $1/k^2$. 这个上界适用于任意有限方差分布, 只用到方差, 不需要知道密度的具体形状. 正态分布中的相应概率则可以按前一节的密度积分直接计算.

2.4 独立性, 条件概率与条件期望

2.4.1 独立性与条件概率

事件与随机变量的独立性 观察到新结果以后, 我们对其他事件的概率判断可能改变. 例如将未来一个月股票上涨记为 A , 下次财报超出预期记为 B , 就可以问: 得知 B 发生以后, A 的概率是否与原来相同?

若得知一个事件是否发生, 不改变另一个事件的概率, 就称两事件独立. 定义时直接使用下面的乘法等式, 这样也能处理零概率事件.

定义 2.37.

令 $A, B \in \mathcal{F}$ 为事件. 称 A 与 B **相互独立**, 是指其满足

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

当 $\mathbb{P}(B) > 0$ 时, 将等式除以 $\mathbb{P}(B)$, 就得到条件概率 $\mathbb{P}(A | B) = \mathbb{P}(A)$. 若 $\mathbb{P}(B^c) > 0$, 给定 B 没有发生时也有相同结论. 因而无论得知 B 发生还是没有发生, 对 A 的概率判断都不变.

多个事件相互独立时, 要求任意有限个事件同时发生的概率都能这样相乘.

定义 2.38.

令 $(A_i)_{i \in I}$ 为一族事件. 称它们**相互独立**, 是指对于任意不同的 $i_1, \dots, i_n \in I$ 都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

若只要求任意两个事件独立, 则称为**两两独立**. 两两独立的三个事件未必相互独立. 例如独立抛两次公平硬币, 令 A 为第一次正面, B 为第二次正面, C 为两次结果相同. 各事件的概率都是 $1/2$, 任意两者的交集概率都是 $1/4$, 但

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

只知道第一次结果或只知道第二次结果, 两次相同的概率都是一半. 但两次结果都知道以后, 是否相同就已确定. 因而这里每一对都独立, 三个事件一起却不满足概率乘法.

对随机变量, 则要比各观测能够判断的全部事件. 任取若干个不同的 X_i , 从各自的 $\sigma(X_i)$ 中各选一个事件, 要求这些事件同时发生的概率等于各自概率的乘积, 就得到随机变量的独立性.

定义 2.39.

令 $(X_i)_{i \in I}$ 为定义在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的一族随机元素. 称它们**相互独立**, 是指任意有限子族都满足下面第一条. 在实值情形中, 第一条还等价于后两条:

1. 对于任意不同的 $i_1, \dots, i_n \in I$ 以及任意 $A_{i_k} \in \sigma(X_{i_k})$, 都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

2. 对于实值随机变量 $X_1, \dots, X_n$, 等价地, 任意 Borel 集 $B_1, \dots, B_n \subseteq \mathbb{R}$ 都满足

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i).$$

3. 如果记 $X = (X_1, \dots, X_n)$, 那么从分布的角度来看, 独立性又等价于联合分布分解成各个边缘分布的乘积:

$$\mu_X = \mu_{X_1} \otimes \cdots \otimes \mu_{X_n}.$$

实值情形中, $\sigma(X_i)$ 的事件都是 Borel 集合的原像, 所以前两种表述相同. 第二种又说明联合分布与边缘分布的乘积在所有矩形上一致. 矩形是生成乘积 σ -代数的 π -系, 两个测度的总质量都是一, 由 π - λ 定理就得到第三种表述. 反过来, 对乘积测度计算矩形概率, 便得到第二种.

因此, 独立变量的乘积期望可以用逐次积分计算. 若实值 $X, Y \in L^1$ 独立, 先对绝对值使用 Tonelli, 得

$$\mathbb{E}[|XY|] = \mathbb{E}[|X|]\mathbb{E}[|Y|] < \infty.$$

乘积可积以后, 再用 Fubini, 就有 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. 特别地, 独立的 L^2 变量协方差为零.

前一节的 U 与 U^2 说明, 协方差为零时仍可能有确定的函数关系. 若两个变量联合正态, 则情形不同: 两个方差都为正而协方差为零时, 协方差矩阵为对角矩阵, 联合正态密度恰好分成两个边缘密度的乘积, 所以两变量独立. 若其中一个方差为零, 该变量几乎必然为常数, 同样独立.

条件概率与 Bayes 公式 若已知事件 B 发生, 就把考察范围缩到 B 中. A 在这个范围内对应 $A \cap B$, 将其概率除以 $\mathbb{P}(B)$, 便得到重新归一化以后的概率.

定义 2.40.

对 $A, B \in \mathcal{F}$ 且 $\mathbb{P}(B) > 0$, 定义**条件概率**

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

固定 B 后, 右边作为 A 的函数可列可加, 且在全空间上取一, 所以 $A \mapsto \mathbb{P}(A | B)$ 仍是概率测度. 所有概率都集中在 B 上, B 中各部分原来的相对权重不变. 定义要求 $\mathbb{P}(B) > 0$, 以保证这次归一化有意义.

同一个交集概率可以先给定 A 计算, 也可以先给定 B 计算. 比较这两种写法, 就得到 Bayes 公式.

定理 2.41 (Bayes 公式).

若 $\mathbb{P}(A), \mathbb{P}(B) > 0$, 则

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}.$$

证明. 由条件概率定义, $\mathbb{P}(A | B)\mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B | A)\mathbb{P}(A)$. 两边除以 $\mathbb{P}(B) > 0$ 即得结论. $\square$

将 B 看作新观察到的证据, 公式说明怎样从原来的 $\mathbb{P}(A)$ 算出新的 $\mathbb{P}(A | B)$. 在 A 成立时越容易见到 B , 因子 $\mathbb{P}(B | A)$ 就越大, 更新时赋予 A 的相对权重也越大.

若有限或可数个可测集 (B_i) 两两不交且覆盖 Ω , 则 A 可以分成不交的各部分 $A \cap B_i$. 分别计算再相加, 得到**全概率公式**

$$\mathbb{P}(A) = \sum_{i: \mathbb{P}(B_i) > 0} \mathbb{P}(A | B_i) \mathbb{P}(B_i).$$

若 $\mathbb{P}(B_i) = 0$, 则 $\mathbb{P}(A \cap B_i) = 0$, 该项直接略去, 不作除法.

情景分析正可以这样计算: 各情景互不重叠且覆盖全部结果, 先算每个情景中某事件的条件概率, 再按情景概率加权. 收到新的财报或行业信息以后, 则用 Bayes 公式比较这条信息在各情景中出现的概率, 重新计算情景权重.

还有一类问题要求一连串条件依次成立. 此时不按不交情景求和, 而是反复使用交集概率的条件乘法. 下面的例子计算一段候选文本能连续通过多少个位置.

例 2.42 (DSpark 中的条件概率).

DeepSeek 的 DSpark 采用投机解码 (speculative decoding): 草稿模型先生成候选文本, 再由目标模型验证, 减少目标模型逐步生成的工作 [Che+26]. 要接受前 k 个草稿词元, 前面的各个位置必须连续通过. 因而估计第 k 个位置能否通过时, 给定的条件是前 $k-1$ 个已经通过.

令 A_k 表示第 k 个草稿词元最终被接受, 系统估计

$$c_k \approx \mathbb{P}(A_k | A_1 \cap \cdots \cap A_{k-1}).$$

第一个位置还没有此前条件, 将空前缀对应的事件取为全空间. 若此前各前缀的概率为正, 反复使用条件概率的乘法公式, 得到

$$\mathbb{P}\left(\bigcap_{i=1}^k A_i\right) = \prod_{i=1}^k \mathbb{P}\left(A_i \mid \bigcap_{j<i} A_j\right).$$

相乘的是逐步给定前缀后的条件概率, 所以不要求各位独立. 用估计值 c_i 代替各因子, 就得到前缀存活概率 (prefix survival probability) 的估计

$$a_k = \prod_{i=1}^k c_i \approx \mathbb{P}(A_1 \cap \cdots \cap A_k).$$

这里的近似来自各 c_i 的估计误差. 若某个前缀概率已经为零, 更长前缀的概率也为零, 计算到此即可, 不再定义后续的概率比.

由此估计草稿能连续保留多长以后, 调度器再结合硬件负载安排验证工作.

2.4.2 条件期望

定义与存在性 观察了一段价格和成交量以后, 已知的通常不止某一个事件. 这些观测能让我们判断许多事件是否发生, 用子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$ 记下所有这样的事件.

给定可积变量 X , 我们想根据已有信息对它取平均. 所得变量 Y 必须 $\mathcal{G}$ -可测, 这样每次观察以后, 就能确定 Y 的值. 同时, 对每个已经能够辨认的事件 $B \in \mathcal{G}$, 用 Y 代替 X 后, 在 B 上的积分应当相同.

对可积随机变量及事件 B , 记

$$\mathbb{E}[X; B] = \mathbb{E}[X \mathbf{1}_B] = \int_B X \, d\mathbb{P}.$$

我们因此寻找 $\mathcal{G}$ -可测且可积的 Y , 使所有 $B \in \mathcal{G}$ 都满足

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

这个条件分别要求在每个可辨认事件上积分相同, 比仅有 $\mathbb{E}[Y] = \mathbb{E}[X]$ 更强. 下面先证明满足要求的两个变量必然几乎处处相等, 再构造这样的变量.

命题 2.43 (唯一性).

令 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 假设 $Y, Z \in L^1(\Omega, \mathbb{P})$ 都是 $\mathcal{G}$ -可测的, 并且对于任意 $B \in \mathcal{G}$ 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B] = \mathbb{E}[Z; B].$$

则 $Y = Z$ a.s.

证明. 令 $W = Y - Z$. 因为 W 为 $\mathcal{G}$ -可测, 所以 $B_+ = \{W > 0\}$ 和 $B_- = \{W < 0\}$ 都属于 $\mathcal{G}$.

由假设有 $\mathbb{E}[W; B_+] = 0$, 而 $W\mathbf{1}_{B_+} \geq 0$, 所以 $W\mathbf{1}_{B_+} = 0$ a.s. 由于 $W > 0$ 在 B_+ 上成立, 这推出 $\mathbb{P}(B_+) = 0$. 对 B_- 同理, 因而 $W = 0$ a.s. $\square$

构造时, 先将 X 的正负部分分别积分. 即使只对 $\mathcal{G}$ 中的集合计算, 得到的两个集合函数仍是有限测度, 并且关于 $\mathbb{P}|_{\mathcal{G}}$ 绝对连续. 所以可以在较小的可测空间上使用 Radon–Nikodym 定理.

定理 2.44 (条件期望的存在性).

若实值 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数, 则存在 $\mathcal{G}$ -可测的 $Y \in L^1$, 使每个 $B \in \mathcal{G}$ 满足

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

证明. 在 $(\Omega, \mathcal{G})$ 上定义

$$\nu_+(B) = \mathbb{E}[X^+; B], \quad \nu_-(B) = \mathbb{E}[X^-; B].$$

X 可积, 所以这两个非负测度都有限. 若 $\mathbb{P}(B) = 0$, 两项积分也都为零, 因而 $\nu_+, \nu_- \ll \mathbb{P}|_{\mathcal{G}}$. 由 Radon–Nikodym 定理, 存在非负的 $\mathcal{G}$ -可测密度 U, V , 满足

$$\nu_+(B) = \int_B U \, d\mathbb{P}, \quad \nu_-(B) = \int_B V \, d\mathbb{P}.$$

U, V 的总积分分别为 $\mathbb{E}[X^+]$ 与 $\mathbb{E}[X^-]$, 都有限, 所以它们几乎处处有限. 将两者在共同的 $\mathcal{G}$ -可测例外零测集上改为零, 就能处处作差, 定义实值函数 $Y = U - V$. 由 $|Y| \leq U + V$ 得 $Y \in L^1$. 对每个 $B \in \mathcal{G}$, 将两个有限积分相减, 得

$$\int_B Y \, d\mathbb{P} = \nu_+(B) - \nu_-(B) = \mathbb{E}[X; B].$$

因而 Y 满足要求. $\square$

这样的变量总能找到, 任意两个又几乎必然相等, 因而可以定义如下.

定义 2.45.

令 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 称随机变量 $Y \in L^1(\Omega, \mathbb{P})$ 为 X 关于 $\mathcal{G}$ 的条件期望, 是指其满足:

1. Y 是 $\mathcal{G}$ -可测的;
2. 对于任意 $B \in \mathcal{G}$, 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

这样的 Y 存在且在 a.s. 意义下唯一, 记作

$$Y = \mathbb{E}[X | \mathcal{G}].$$

先看只知道一个正概率事件 B 发生的情形. 在 B 中求平均, 得到一个数, 记为

$$\mathbb{E}[X | B] = \frac{\mathbb{E}[X\mathbf{1}_B]}{\mathbb{P}(B)}, \quad \mathbb{P}(B) > 0.$$

若观测可以区分多个事件, 则在不同事件中会得到不同的平均值, 这些值放在一起就是随机变量.

具体地, 设非空可测集 $B_1, \dots, B_n$ 两两不交并覆盖 Ω , 取 $\mathcal{G} = \sigma(B_1, \dots, B_n)$. 观察者知道结果属于哪个 B_i , 但不能进一步区分同一 B_i 内的结果. 各 B_i 因而称为这个 σ -代数的原子.

任何 $\mathcal{G}$ -可测实值函数都必须在每个原子上取常数. 若同一原子上出现两个不同函数值, 就可以选一个半直线 $(-\infty, a]$, 使其原像把这个原子分成两个非空部分; 这与原子不能再被 $\mathcal{G}$ 中的事件细分相矛盾. 因此, 若条件期望在 B_i 上取 c_i , 定义中的积分等式要求 $c_i \mathbb{P}(B_i) = \mathbb{E}[X \mathbf{1}_{B_i}]$. 在正概率原子上, c_i 只能是刚才定义的条件平均. 将零概率原子上的值取为零, 得到

$$\mathbb{E}[X | \mathcal{G}] = \sum_{i: \mathbb{P}(B_i) > 0} \mathbb{E}[X | B_i] \mathbf{1}_{B_i}.$$

对原子的任意并积分, 等式仍然成立, 所以这确实是条件期望的一个版本. 零概率原子也可以取别的有限常数, 不改变可测性和积分.

例如四个等概率结果上, X 依次取 0, 2, 4, 10. 若观测只能分清前两个结果和后两个结果, 就在两组中分别取平均, 得到 1 和 7. 条件期望在前一组取 1, 在后一组取 7, 它的整体期望仍为 4. 前一节按情景取组内平均, 用的也是这个办法.

只有平凡信息 $\mathcal{G} = \{\emptyset, \Omega\}$ 时, 全空间只有一组, 所以条件期望为常数 $\mathbb{E}[X]$. 若 X 已经 $\mathcal{G}$ -可测, 则 X 自身满足定义, 因而 $\mathbb{E}[X | \mathcal{G}] = X$ a.s.

将 X 换成事件 A 的指示变量, 就得到给定信息后的事件概率:

$$\mathbb{P}(A | \mathcal{G}) = \mathbb{E}[\mathbf{1}_A | \mathcal{G}].$$

由下面的单调性, 可以选取值落在 $[0, 1]$ 内的版本. 若 $\mathcal{G}$ 由 B, B^c 生成, 且 $\mathbb{P}(B) > 0$, 它在 B 上的值正是原来的 $\mathbb{P}(A | B)$.

若已知的是随机变量 Y 的值, 相应信息就是 $\sigma(Y)$, 通常简记 $\mathbb{E}[X | Y] = \mathbb{E}[X | \sigma(Y)]$. 它随观测到的 Y 而取值, 如同有限分割中随所属组别取不同平均.

基本性质与均方投影 以下取实值随机变量, a, b 为实常数, 条件期望之间的等式均指几乎必然相等. 说 X 与 $\mathcal{G}$ 独立, 是指从 $\sigma(X)$ 和 $\mathcal{G}$ 中各取一个事件, 二者都独立.

命题 2.46 (条件期望的基本性质).

设 $X, Y \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数, 则有:

- **线性性:** $\mathbb{E}[aX + bY | \mathcal{G}] = a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]$.
- **单调性:** 如果 $X \leq Y$ a.s., 那么 $\mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[Y | \mathcal{G}]$ a.s.
- **保留期望:** $\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]$.
- **已知量可以提出:** 如果 Z 是有界的 $\mathcal{G}$ -可测随机变量, 那么 $\mathbb{E}[XZ | \mathcal{G}] = Z\mathbb{E}[X | \mathcal{G}]$.
- **塔性质:** 如果 $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$, 那么

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}].$$

- **独立性:** 如果 X 与 $\mathcal{G}$ 独立, 那么 $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X]$ a.s.

证明. 对两个条件期望作实线性组合, 所得变量仍 $\mathcal{G}$ -可测且可积. 在每个 $B \in \mathcal{G}$ 上积分, 由积分线性性可得它满足 $aX + bY$ 的条件期望定义, 再由唯一性得到第一项.

为证明单调性, 先取非负可积变量 W , 令 $M = \mathbb{E}[W | \mathcal{G}]$. 事件 $B = \{M < 0\}$ 属于 $\mathcal{G}$, 所以 $\mathbb{E}[M; B] = \mathbb{E}[W; B] \geq 0$. 但 $M \mathbf{1}_B \leq 0$, 只能几乎必然为零, 故 $\mathbb{P}(B) = 0$. 因而非负变量的条件期望非负. 将此用于 $Y - X$, 再用线性性, 就得到单调性. 在定义中取 $B = \Omega$, 则直接得到保留期望这一项.

要将已知的 Z 提出, 先取 $Z = \mathbf{1}_A$, 其中 $A \in \mathcal{G}$. 对每个 $B \in \mathcal{G}$, 有

$$\mathbb{E}[Z\mathbb{E}[X | \mathcal{G}]; B] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}]; A \cap B] = \mathbb{E}[XZ; B].$$

由唯一性即得结论. 作有限线性组合, 可推广到简单函数 Z . 对有界 $\mathcal{G}$ -可测的 Z , 选取一致有界的简单函数逐点逼近它. 两边的乘积分别由常数倍的 $|X|$ 和 $|\mathbb{E}[X | \mathcal{G}]|$ 控制, 在各 B 上使用控制收敛, 便得到一般的有界情形.

再令 $M = \mathbb{E}[X | \mathcal{G}]$, 考察 $\mathbb{E}[M | \mathcal{H}]$. 它 $\mathcal{H}$ -可测, 而每个 $B \in \mathcal{H}$ 也属于 $\mathcal{G}$, 因而

$$\mathbb{E}[\mathbb{E}[M | \mathcal{H}]; B] = \mathbb{E}[M; B] = \mathbb{E}[X; B].$$

所以它满足 $\mathbb{E}[X | \mathcal{H}]$ 的定义, 这就证明了塔性质.

最后, 若 X 与 $\mathcal{G}$ 独立, 则对每个 $B \in \mathcal{G}$, 有 $\mathbb{E}[X \mathbf{1}_B] = \mathbb{E}[X] \mathbb{P}(B)$. 常数 $\mathbb{E}[X]$ 是 $\mathcal{G}$ -可测的, 并满足这些积分等式, 因而就是 X 关于 $\mathcal{G}$ 的条件期望. $\square$

塔性质说明, 先根据较多的信息 $\mathcal{G}$ 取平均, 再根据其中较少的信息 $\mathcal{H}$ 取平均, 等于直接按 $\mathcal{H}$ 计算. 证明中正是利用 $\mathcal{H} \subseteq \mathcal{G}$, 才能在同一个 B 上连续使用两次定义.

条件期望的范数也可以估计. 为了处理 $|\mathbb{E}[X | \mathcal{G}]|^p$, 先将普通 Jensen 不等式推广到条件期望.

定理 2.47 (条件 Jensen 不等式).

令 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 为凸函数, 并假设 $X \in L^1$ 且 $\varphi(X) \in L^1$. 则

$$\varphi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\varphi(X) | \mathcal{G}] \quad \text{a.s.}$$

证明. 实线上处处有限的凸函数可以写成可列族支撑直线的上确界:

$$\varphi(x) = \sup_{j \geq 1} (a_j x + b_j).$$

例如在各有理点选取支撑直线, 由凸函数的连续性即可恢复整个函数. 对每个 j , 有 $a_j X + b_j \leq \varphi(X)$. 条件期望的单调性与线性性给出

$$a_j \mathbb{E}[X | \mathcal{G}] + b_j \leq \mathbb{E}[\varphi(X) | \mathcal{G}] \quad \text{a.s.}$$

将这可列个例外零测集合并, 再对 j 取上确界, 就得到所需不等式. 其左边又有任意一条支撑直线作为可积下界, 右边为可积上界, 因而 $\varphi(\mathbb{E}[X | \mathcal{G}])$ 也可积. $\square$

对 $1 \leq p < \infty$ 和 $X \in L^p$, 在定理中取 $\varphi(x) = |x|^p$, 得

$$|\mathbb{E}[X | \mathcal{G}]|^p \leq \mathbb{E}[|X|^p | \mathcal{G}] \quad \text{a.s.}$$

两边再取期望, 右边成为 $\mathbb{E}[|X|^p]$, 因而 $\|\mathbb{E}[X | \mathcal{G}]\|_p \leq \|X\|_p$. 若 $p = \infty$, 则从 $-M \leq X \leq M$ a.s. 出发, 由单调性得到 $-M \leq \mathbb{E}[X | \mathcal{G}] \leq M$ a.s. 对本质上界取下确界, 得到同样的范数不等式.

所以对 $1 \leq p \leq \infty$, 取条件期望不会增大 L^p 范数. 若先用另一个变量近似 X , 将这个不等式用于两变量的差, 就知取条件期望以后, 近似误差的范数也不会变大.

特别地, $X \in L^2$ 时, 条件期望仍在 L^2 中. 因而可以在 Hilbert 空间里比较它与其他 $\mathcal{G}$ -可测预测的均方误差.

命题 2.48 (条件期望的均方投影).

设实值 $X \in L^2$, 令 $M = \mathbb{E}[X | \mathcal{G}]$. 则 $M \in L^2(\Omega, \mathcal{G}, \mathbb{P})$, 且对任意 $Y \in L^2(\Omega, \mathcal{G}, \mathbb{P})$,

$$\|X - Y\|_2^2 = \|X - M\|_2^2 + \|M - Y\|_2^2.$$

因而在所有 $\mathcal{G}$ -可测的平方可积预测中, M 使均方误差最小. 任何达到这个最小值的预测都与 M 几乎必然相等.

证明. 条件 Jensen 已经给出 $M \in L^2$. 由条件期望定义, 每个 $B \in \mathcal{G}$ 都有 $\mathbb{E}[(X - M) \mathbf{1}_B] = 0$. 先作有限线性组合, 再用简单函数逼近, 得到 $\mathbb{E}[(X - M)Z] = 0$ 对所有有界 $\mathcal{G}$ -可测变量 Z 成立.

对一般 $Z \in L^2(\mathcal{G})$, 将它截断为有界变量 Z_n , 则 $Z_n \rightarrow Z$ 于 L^2 . 由 Cauchy-Schwarz,

$$|\mathbb{E}[(X - M)(Z_n - Z)]| \leq \|X - M\|_2 \|Z_n - Z\|_2 \rightarrow 0.$$

因而 $X - M$ 与每个 $Z \in L^2(\mathcal{G})$ 都正交. 在 $X - Y = (X - M) + (M - Y)$ 中展开平方范数, 由于 $M - Y \in L^2(\mathcal{G})$, 交叉项为零, 就得到命题中的等式. 右边第二项非负, 且恰在 $Y = M$ a.s. 时为零, 所以最小值与唯一性也随之成立. $\square$

$L^2(\mathcal{G})$ 本身完备, 作为子空间嵌入 $L^2(\mathcal{F})$ 时范数不变, 因而是闭子空间. 上述正交分解说明, 条件期望正是向这个闭子空间的投影. 若只允许常数预测, 就回到前一节以普通期望作为最佳常数近似的情形.

2.4.3 正则条件分布

除了预测平均值, 我们也可能要计算下一日上涨 10% 或跌破某个价位的概率. 对每个取值范围 A , 前面已经定义了 $\mathbb{P}(X \in A | \mathcal{G})$. 现在希望把这些条件概率放在一起, 使给定一次观测以后, 它们作为 A 的函数组成一个概率测度.

定义 2.49.

设 $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{E})$ 为随机元素, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. X 关于 $\mathcal{G}$ 的正则条件分布是 Markov 核

$$K: \Omega \times \mathcal{E} \rightarrow [0, 1],$$

满足对每个 $A \in \mathcal{E}$, $K(\cdot, A)$ 都是 $\mathbb{E}[\mathbf{1}_{\{X \in A\}} | \mathcal{G}]$ 的版本. 这里 Markov 核要求: 固定 ω 时, $K(\omega, \cdot)$ 是概率测度; 固定 A 时, $K(\cdot, A)$ 是 $\mathcal{G}$ -可测函数.

对固定的 A , $K(\cdot, A)$ 是 $\mathcal{G}$ -可测函数, 所以这一条件概率只依赖 $\mathcal{G}$ 中的信息. 对固定的 ω , 再要求 $K(\omega, \cdot)$ 是概率测度, 才能让不同取值范围的条件概率彼此满足可列可加性. 因此, 为各个 A 选择条件期望版本时, 这些版本还必须在同一个零测集之外相互兼容.

有了核, 就可以像对普通分布那样积分. 若 $f \geq 0$ 可测, 或者 $f(X)$ 可积, 则

$$\mathbb{E}[f(X) | \mathcal{G}](\omega) = \int_E f(x) K(\omega, dx) \quad \text{a.s.}$$

对指示函数, 这就是核的定义; 作有限线性组合, 得到简单函数情形. 再用非负简单函数递增逼近, 并在各个 $B \in \mathcal{G}$ 上使用单调收敛, 就得到非负情形, 允许取 $+\infty$. 这里非变量的条件期望由截断后的条件期望取递增极限定义.

若 $f(X)$ 实值可积, 先对 $|f|$ 使用上述公式, 可知内层绝对值积分几乎处处有限. 再分别计算正负部并相减, 即得实值公式; 将例外零测集上的值取为零, 就得到可积版本.

若已知的是 $Y: \Omega \rightarrow (S, \mathcal{S})$, 还可以尝试直接把观测值 y 用作核的参数. 当核满足 $\mathbb{P}(X \in A | \sigma(Y)) = K(Y, A)$ a.s. 时, 通常记

$$K(y, A) = \mathbb{P}(X \in A | Y = y).$$

这个记号通过核定义, 无须除以 $\mathbb{P}(Y = y)$, 因而也用于单点概率为零的连续观测. 下面的标准 Borel 条件保证可以作这样的选择.

定理 2.50 (标准 Borel 值域中的正则条件分布).

若 $(E, \mathcal{E})$ 是标准 Borel 空间, 则随机元素 X 关于任意子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$ 都存在正则条件分布. 若 Y 取值于标准 Borel 空间 $(S, \mathcal{S})$, 还可以选择 Markov 核 $K: S \times \mathcal{E} \rightarrow [0, 1]$, 使每个 $A \in \mathcal{E}$ 都满足

$$\mathbb{P}(X \in A | \sigma(Y)) = K(Y, A) \quad \text{a.s.}$$

任意两个这样的核, 除去一个 $\mathcal{L}(Y)$ -零测集后, 对每个剩下的 y 都给出相同的概率测度.

证明. 先设 X 实值. 对每个有理数 q , 选取条件期望的一个版本 $H_q = \mathbb{E}[\mathbf{1}_{\{X \leq q\}} | \mathcal{G}]$. 单调性给出 $0 \leq H_q \leq 1$, 并在 $q < r$ 时给出 $H_q \leq H_r$, 均 a.s. 成立. 对一致有界的单调随机变量列, 可以在每个 $B \in \mathcal{G}$ 上用控制收敛定理通过积分中的极限. 再核对条件期望的定义, 就得到条件期望也具有相应的单调极限. 因而对各个有理 q , 还有

$$\lim_{m \rightarrow \infty} H_{-m} = 0, \quad \lim_{m \rightarrow \infty} H_m = 1, \quad H_q = \inf_{r \in \mathbb{Q}, r > q} H_r$$

几乎必然成立. 这些要求只有可列多个, 将其例外集合并为一个 $\mathcal{G}$ -可测零测集 N , 就能在 N 外同时使用全部关系.

对 $\omega \notin N$, 令

$$F_\omega(x) = \inf_{q \in \mathbb{Q}, q > x} H_q(\omega).$$

它单调不减且右连续, 在负无穷和正无穷处分别趋于零和一, 所以由分布函数定理确定一个概率测度 $K(\omega, \cdot)$. 对 $\omega \in N$, 统一取 $K(\omega, \cdot) = \delta_0$. 在 N 外, 有理半直线上的核值等于相应的 H_q ; 在 N 上只改动了 $\mathcal{G}$ -可测零测集中的值, 所以这些核值仍可测, 并满足所需条件积分等式. 满足这两项要求的 Borel 集合组成 λ -系, 又包含所有有理半直线. 由 π - λ 定理, 两项要求对全部 Borel 集成立, 实值情形得证.

一般标准 Borel 空间与实线的某个 Borel 子集可测同构. 先将 X 经此同构看成实值变量, 使用刚才的构造. 所得条件测度几乎必然集中在这个 Borel 子集上. 在例外零测集上改取子集内一个固定点的 Dirac 测度, 再按逆同构前推, 就得到 E 上的正则条件分布.

若 $\mathcal{G} = \sigma(Y)$, 每个实值 $\sigma(Y)$ -可测函数都能写成 Y 的可测函数, 因而可以将上面的 H_q 写成 $h_q(Y)$. 在 S 上, 使这些可列关系失效的点组成 $\mathcal{L}(Y)$ -零测集. 在其外按同样方法构造分布函数, 在其中取固定点的 Dirac 测度, 就得到以 y 为参数的核.

最后, 标准 Borel 空间有可数的生成 π -系. 两个候选核在每个生成集上的值, 由条件期望唯一性几乎必然相等. 将这些可列个例外零测集合并, 在其外两个概率测度便在整体生成 π -系上一致. 再用概率测度唯一性, 可知它们在全部可测集上一致. $\square$

证明用到的是值域的可数生成结构及标准 Borel 同构, 原概率空间本身不必是标准 Borel 空间. 相关结果及测度分解的表述见 [Kal21, Theorem 8.5, Theorem 3.4] 或 [Dur19, Theorems 4.1.17–4.1.18].

核只在观测分布的零测集之外唯一. 若指定点 y 满足 $\mathbb{P}(Y = y) = 0$, 改变 $K(y, \cdot)$ 不会改变条件积分等式. 要在这个点也选出特定的条件分布, 可以再根据连续性等额外要求作选择.

有联合密度时, 这种选择可以具体算出. 设实值 (X, Y) 具有非负联合密度 $f_{X,Y}$, 先令 $f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx$. 由 Tonelli, f_Y 是边缘密度, 并且 Y 几乎必然落在 $0 < f_Y(y) < \infty$ 的集合中. 在这些点定义

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad 0 < f_Y(y) < \infty.$$

对 x 积分得一, 因而它定义概率测度 $K(y, \cdot)$. 在其余 y 上取一个固定概率测度, 就补成了核. 对 Borel 集 A, B ,

$$\int_B K(y, A) f_Y(y) dy = \int_B \int_A f_{X,Y}(x, y) dx dy = \mathbb{P}(X \in A, Y \in B).$$

所以这个核满足正则条件分布要求的积分等式.

在随机过程中, 用滤过 $(\mathcal{F}_t)$ 记下载至各时刻的信息. 对 $s < t$, 标准 Borel 状态空间上的正则条件分布可以同时给出所有 $\mathbb{P}(X_t \in A | \mathcal{F}_s)$. 若 X_t 可积, 对这个条件分布积分便得到 $\mathbb{E}[X_t | \mathcal{F}_s]$; 若还平方可积, 这个条件平均也是只使用 $\mathcal{F}_s$ 信息时的最佳均方预测.

Markov 性质进一步要求, 给定截至 s 的全部历史后所得到的条件分布, 只依赖当前状态 X_s . 用转移核写为

$$\mathbb{P}(X_t \in A | \mathcal{F}_s) = P_{s,t}(X_s, A) \quad \text{a.s.}$$

因此, 两段历史只要时刻 s 具有相同状态, 就用同一个转移核计算未来的取值概率. 状态中选出哪些变量, 决定了哪些历史信息能通过当前状态用于这项计算.

2.5 随机变量的收敛与极限定理

2.5.1 收敛概念

怎样比较随机变量的极限 用一系列 X_n 近似随机变量 X , 可以提出不同要求. 可以比较各自分布 $\mathcal{L}(X_n)$ 与 $\mathcal{L}(X)$, 也可以在同一概率空间中计算误差 $X_n - X$, 还可以固定一个样本点, 看数列 $X_n(\omega)$ 是否趋于 $X(\omega)$. 以下分别定义这些收敛方式, 再用它们研究样本平均.

概率测度的弱收敛 先按第2.2.1小节的前推测度表示分布, 直接比较实线上的概率测度 μ_n, μ .

一种比较办法是选定函数 f , 看这些分布给出的积分 $\int f d\mu_n$ 是否趋于 $\int f d\mu$. 这里选取有界连续函数: 连续性使相近位置上的函数值也相近, 有界性则保证所有积分有限, 并限制小概率部分对这次积分的影响.

定义 2.51.

对 $\mathbb{R}$ 上的概率测度 μ_n, μ , 若每个有界连续实函数 f 都满足

$$\int_{\mathbb{R}} f d\mu_n \rightarrow \int_{\mathbb{R}} f d\mu,$$

则称 μ_n 弱收敛到 μ , 记为 $\mu_n \Rightarrow \mu$.

定义是对每个固定的 f 分别要求积分收敛, 并未要求对所有测试函数一致收敛. 这里取极限的对象是概率测度, 而非 L^p 空间中的函数.

例 2.52.

令 $\mu_n = \delta_{1/n}$, $\mu = \delta_0$. 对每个有界连续 f , 有 $\int f d\mu_n = f(1/n) \rightarrow f(0) = \int f d\mu$, 所以 $\mu_n \Rightarrow \mu$. 但对 $A = \{0\}$, 始终有 $\mu_n(A) = 0$, 而 $\mu(A) = 1$. 这些测度集中在越来越接近零的位置, 却直到极限时才在零点上取得全部质量.

所以弱收敛并不要求所有 Borel 集合上的概率都收敛. 上例的极限质量恰好落在 A 的边界上, 这使集合内外的归属发生变化. 若集合边界的极限测度为零, 则可以得到集合概率收敛. 更一般的关系由 Portmanteau 定理给出.

定理 2.53 (Portmanteau 定理的一些形式).

对 $\mathbb{R}$ 上的概率测度 μ_n, μ , 以下条件等价:

1. $\mu_n \Rightarrow \mu$;
2. 对每个开集 G , $\liminf_n \mu_n(G) \geq \mu(G)$;
3. 对每个闭集 F , $\limsup_n \mu_n(F) \leq \mu(F)$;
4. 对每个满足 $\mu(\partial A) = 0$ 的 Borel 集 A , $\mu_n(A) \rightarrow \mu(A)$.

证明. 先用有界连续函数从上方逼近闭集的指示函数, 证明第一项推出第三项. 空集上的结论显然成立. 对非空闭集 F , 取

$$f_m(x) = \max\{1 - m d(x, F), 0\}.$$

f_m 有界连续, 且 $\mathbf{1}_F \leq f_m \downarrow \mathbf{1}_F$. 固定 m , 由弱收敛得到 $\limsup_n \mu_n(F) \leq \int f_m d\mu$. 再令 $m \rightarrow \infty$, 使用控制收敛, 即得闭集上的不等式. 开集与闭集互为补集, 各测度的总质量又都是一, 所以第二项与第三项等价. 对一般 A , 从 $A^\circ \subseteq A \subseteq \bar{A}$ 出发, 分别用开集下界和闭集上界夹住 $\mu_n(A)$. 若 $\mu(\partial A) = 0$, 两边的极限都是 $\mu(A)$, 就得到第四项.

再由第二项推出第一项. 先设 f 连续且 $0 \leq f \leq M$. 每个 $\{f > t\}$ 都是开集, 将积分写成尾积分, 再用 Fatou 与开集下界, 得

$$\begin{aligned} \liminf_n \int f d\mu_n &= \liminf_n \int_0^M \mu_n(f > t) dt \\ &\geq \int_0^M \mu(f > t) dt = \int f d\mu. \end{aligned}$$

对 $M - f$ 使用同一结果, 就得到 $\int f d\mu_n$ 的上极限不超过 $\int f d\mu$, 因而积分收敛. 一般有界连续实函数加上一个常数后即可化为非负情形.

最后证明第四项也推出第一项. 仍取 $0 \leq f \leq M$ 的连续函数. 由连续性, $\partial\{f > t\} \subseteq \{f = t\}$. 不同 t 的层集 $\{f = t\}$ 互不相交, 其中至多可数多个具有正的 μ -测度. 所以对几乎每个 t , 集合 $\{f > t\}$ 的边界为 μ -零测集, 第四项给出 $\mu_n(f > t) \rightarrow \mu(f > t)$. 各项概率均在零与一之间, 因而可在 $[0, M]$ 上使用控制收敛, 再由尾积分公式得到 $\int f d\mu_n \rightarrow \int f d\mu$. $\square$

满足 $\mu(\partial A) = 0$ 的集合称为 μ 的**连续集** (continuity set). 前面的 $\delta_{1/n}$ 例子中, $\{0\}$ 的边界就是它自身, 极限测度为一, 所以不属于连续集. 上面的证明也适用于欧氏空间 $\mathbb{R}^d$. 相关表述见 [Kal21, Theorem 5.25] 或 [Dur19, Theorem 3.2.11].

实线上的分布可以由分布函数比较. 记 F_n, F 分别为 μ_n, μ 的分布函数. 半直线 $(-\infty, x]$ 的边界只有点 x , 而 F 在 x 连续恰好等价于 $\mu(\{x\}) = 0$. 因而弱收敛给出

$$F_n(x) \rightarrow F(x)$$

在 F 的每个连续点成立.

反过来, 若这些连续点上的收敛已知, 取任意有界连续函数 f . 先选择 F 的连续点 $a < b$, 使 $\mu((a, b])$ 接近一. 由分布函数收敛, 对充分大的 n , $\mu_n((a, b])$ 也接近一. 再在 $[a, b]$ 上取足够细的分割, 各端点都选为 F 的连续点. 每个小区间的概率由分布函数之差计算, 因而收敛; f 在该紧区间上一致连续, 用阶梯函数近似它的误差可以任意小. 区间外的积分则由 f 的上界乘以尾概率估计. 将这几部分合起来, 得到 $\int f d\mu_n \rightarrow \int f d\mu$.

因此, $\mu_n \Rightarrow \mu$ 当且仅当 F_n 在 F 的所有连续点收敛到 F . 判别时只需检查这些点.

依分布收敛 将弱收敛用于随机变量的分布, 就得到依分布收敛. 因为只比较分布, 这些随机变量可以定义在不同概率空间中.

定义 2.54.

设实值随机变量 X_n 定义在 $(\Omega_n, \mathcal{F}_n, \mathbb{P}_n)$ 上, X 定义在 $(\Omega, \mathcal{F}, \mathbb{P})$ 上. 若

$$\mathcal{L}(X_n) \Rightarrow \mathcal{L}(X),$$

则称 X_n 依分布收敛到 X , 记为 $X_n \xrightarrow{d} X$.

例 2.55.

设 $X \sim \mathcal{N}(0, 1)$. 在同一概率空间中令所有 $X_n = X$, 则各项分布相同, 且每个样本上的差 $X_n - X$ 都为零.

也可以选择 $X, X_1, X_2, \dots$ 相互独立, 各自仍服从 $\mathcal{N}(0, 1)$. 同样有 $\mathcal{L}(X_n) = \mathcal{L}(X)$, 所以 $X_n \xrightarrow{d} X$. 但此时 $X_n - X \sim \mathcal{N}(0, 2)$. 对任意固定的 $\varepsilon > 0$, $\mathbb{P}(|X_n - X| > \varepsilon)$ 都是一个不随 n 改变的正数.

两种构造的边缘分布完全相同, 差值却不同. 下面直接用同一概率空间中的差来定义收敛, 第二种构造便不满足这项要求.

依概率收敛 以下讨论差值或逐样本收敛时, 默认 X_n, X 定义在同一 $(\Omega, \mathcal{F}, \mathbb{P})$ 上.

定义 2.56.

若每个 $\varepsilon > 0$ 都满足

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0,$$

则称 X_n 依概率收敛到 X , 记为 $X_n \xrightarrow{\mathbb{P}} X$.

对每个固定的误差阈值 ε , 误差超过它的概率都要趋于零. 这项定义使用已经选定的 X_n, X 的共同实现. 若极限为常数 c , 则 $X_n - c$ 的分布只由 X_n 的分布决定, 两种收敛恰好等价.

命题 2.57.

对任意常数 c ,

$$X_n \xrightarrow{d} c \iff X_n \xrightarrow{\mathbb{P}} c.$$

证明. 若分布趋于 δ_c , 对闭集 $\{x : |x - c| \geq \varepsilon\}$ 使用 Portmanteau, 得其概率上极限不超过零, 因而 $\mathbb{P}(|X_n - c| > \varepsilon) \rightarrow 0$. 反过来, 对有界连续 f 和任意 $\eta > 0$, 由 f 在 c 连续选取 $\delta > 0$, 使 $|x - c| \leq \delta$

时 $|f(x) - f(c)| \leq \eta$. 则

$$|\mathbb{E}[f(X_n)] - f(c)| \leq \eta + 2\|f\|_\infty \mathbb{P}(|X_n - c| > \delta).$$

先令 $n \rightarrow \infty$, 再令 $\eta \downarrow 0$, 就得到弱收敛的测试函数条件. $\square$

对一般的 X , 先计算 $|X_n - X|$ 的分布. 它是联合分布 $\mathcal{L}(X_n, X)$ 沿 $(x, y) \mapsto |x - y|$ 的前推. 将刚才的常数极限命题用于误差和常数零, 得到

$$X_n \xrightarrow{\mathbb{P}} X \iff \mathcal{L}(|X_n - X|) \Rightarrow \delta_0.$$

因此, 依概率收敛也可以通过误差分布来判断: 误差落在任意固定的零点邻域之外的概率都趋于零.

L^p 收敛 很大的误差即使只发生在小概率事件上, 也可能在平均时占有很大比重. 要同时计算误差的大小和发生概率, 可以使用 L^p 范数. 对 $1 \leq p < \infty$ 及 $X_n, X \in L^p$, 要求

$$\mathbb{E}[|X_n - X|^p] \rightarrow 0,$$

就是要求 $\|X_n - X\|_p \rightarrow 0$, 称为 L^p 收敛. $p = 2$ 时称为均方收敛.

无穷端点不用积分, 而要求 $\|X_n - X\|_\infty \rightarrow 0$. 这相当于删去一个共同零测集以后, 误差一致趋于零. 以下使用 p 阶积分时, 均取 $1 \leq p < \infty$.

命题 2.58.

对 $1 \leq p < \infty$, 若 $X_n \rightarrow X$ 于 L^p , 则 $X_n \rightarrow X$ 于概率.

证明. 对任意 $\varepsilon > 0$, 将 Markov 不等式用于非负误差 $|X_n - X|^p$, 得

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p} \rightarrow 0.$$

$\square$

L^∞ 收敛也推出依概率收敛. 当本质误差小于给定的 ε 后, 超过该阈值的概率就为零.

几乎必然收敛 前面每次固定 n , 计算第 n 个误差事件的概率或误差积分. 也可以固定样本点 ω , 沿着整个序列看下去, 问 $X_n(\omega)$ 是否真的趋于 $X(\omega)$.

定义 2.59.

若

$$\mathbb{P}\{\omega : X_n(\omega) \rightarrow X(\omega)\} = 1,$$

则称 X_n 几乎必然收敛到 X , 记为 $X_n \xrightarrow{\text{a.s.}} X$.

这个收敛事件是可测的. 可以把整个序列和候选极限一起放入序列空间:

$$\mathbf{X}(\omega) = ((X_k(\omega))_{k \geq 1}, X(\omega)) \in \mathbb{R}^\mathbb{N} \times \mathbb{R}.$$

各坐标都是可测函数, 所以 $\mathbf{X}$ 对乘积 σ -代数可测. 在值域中, 所有收敛到最后一个坐标的序列组成集合

$$C = \{((x_k)_{k \geq 1}, x) : x_k \rightarrow x\}.$$

将收敛定义中的精度依次取为 $1/m$, 有

$$C = \bigcap_{m=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{k \geq N} \left\{ ((x_j)_{j \geq 1}, x) : |x_k - x| < \frac{1}{m} \right\}.$$

每个最内层集合只由有限个坐标决定, 因而是 Borel 集; 再经过可列交和可列并, C 仍是 Borel 集. 所以它在 $\mathbf{X}$ 下的原像就是可测的收敛事件, 并且

$$X_n \xrightarrow{\text{a.s.}} X \iff \mathcal{L}(\mathbf{X})(C) = 1.$$

这时前推的是整个随机序列. 对同一条实现, 误差是否最终一直小于某个阈值, 可以由这个序列空间中的事件表达.

几种收敛方式之间的关系 在同一概率空间上, 这些收敛方式有以下关系:

$$X_n \xrightarrow{\text{a.s.}} X \implies X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{d} X, \quad X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{\mathbb{P}} X.$$

若 $X_n \rightarrow X$ a.s., 则对每个固定 $\varepsilon > 0$, $\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \rightarrow 0$ a.s. 这些指示函数都不超过可积的常数函数 1. 因此可以用控制收敛定理取期望, 从而得到依概率收敛. L^p 推出依概率收敛已经由 Markov 不等式证明.

要从依概率收敛得到依分布收敛, 固定有界连续函数 f . 先选足够大的 R , 使 $\mathbb{P}(|X| > R)$ 很小. f 在 $[-R-1, R+1]$ 上一致连续, 因而可以选 $0 < \delta < 1$, 使得在 $|X| \leq R$ 且 $|X_n - X| \leq \delta$ 时, $|f(X_n) - f(X)|$ 任意小. 在余下的事件上, 函数值之差不超过 $2\|f\|_\infty$, 这些事件的总概率至多为 $\mathbb{P}(|X| > R) + \mathbb{P}(|X_n - X| > \delta)$. 先令 $n \rightarrow \infty$, 使 $\mathbb{P}(|X_n - X| > \delta)$ 消失; 再把 R 取得足够大, 并把一致连续性给出的函数值误差取得足够小, 就得到 $\mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X)]$.

对于不同指数, 概率空间上的范数不等式还给出

$$X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{L^q} X, \quad 1 \leq q < p \leq \infty,$$

因为 $\|X_n - X\|_q \leq \|X_n - X\|_p$.

依概率收敛虽未要求整列几乎必然收敛, 却能抽取具有这种收敛的子列. 证明时, 我们会让子列上各次大误差的概率可求和, 再用下面的引理说明大误差几乎必然只出现有限次.

引理 2.60 (Borel–Cantelli).

对事件列 (A_n) , 若

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty,$$

则

$$\mathbb{P}(A_n \text{ i.o.}) = 0.$$

这里 i.o. 表示无穷多次发生, 即事件 $\bigcap_{m \geq 1} \bigcup_{n \geq m} A_n$.

证明. 对每个 m , 无穷多次发生的事件都包含在 $\bigcup_{n \geq m} A_n$ 中, 所以

$$\mathbb{P}(A_n \text{ i.o.}) \leq \mathbb{P}\left(\bigcup_{n \geq m} A_n\right) \leq \sum_{n \geq m} \mathbb{P}(A_n).$$

收敛级数的尾和趋于零, 令 $m \rightarrow \infty$ 即得结论. $\square$

注 2.61 (独立事件的反向结论).

若 (A_n) 相互独立且概率和发散, 则 $\mathbb{P}(A_n \text{ i.o.}) = 1$. 对任意固定 m 及 $N \geq m$, 独立性给出

$$\mathbb{P}\left(\bigcap_{n=m}^N A_n^c\right) = \prod_{n=m}^N (1 - \mathbb{P}(A_n)) \leq \exp\left(-\sum_{n=m}^N \mathbb{P}(A_n)\right).$$

令 $N \rightarrow \infty$, 从第 m 项起永不发生的概率为零. 再对 m 取可列并, 得只有有限次发生的概率为零. 仅凭概率和发散不能得到这个结论, 因为高度重叠的事件可以反复计算同一部分样本.

定理 2.62.

如果 $(X_n \xrightarrow{\mathbb{P}} X)$, 那么存在一个子列 $(X_{n_k})_{k \geq 1}$, 使得 $(X_{n_k} \xrightarrow{\text{a.s.}} X)$.

证明. 由 $(X_n \xrightarrow{\mathbb{P}} X)$, 可以递归选取子列 (X_{n_k}) , 使得

$$\mathbb{P}(|X_{n_k} - X| > 2^{-k}) < 2^{-k}.$$

令 $A_k = \{|X_{n_k} - X| > 2^{-k}\}$. 则 $\sum_k \mathbb{P}(A_k) < \infty$, 因而由 Borel–Cantelli 引理可知, 几乎必然只有有限多个 A_k 发生. 因而 $(X_{n_k} \xrightarrow{\text{a.s.}} X)$. $\square$

由此还能得到子列判别: $X_n \rightarrow X$ 于概率, 当且仅当每个子列都能再抽出几乎必然趋于 X 的子列. 正向只需对每个子列使用刚才的定理.

反向若不依概率收敛, 就存在 $\varepsilon, \eta > 0$ 和一个子列, 使所有 $\mathbb{P}(|X_{n_k} - X| > \varepsilon) \geq \eta$. 从中继续抽取子列, 这些概率仍不小于 η . 但按假设可以抽到几乎必然收敛的子列, 它必然依概率收敛, 于是得到矛盾.

这项判别涉及每个子列中的进一步子列, 而不是原列本身的逐点极限. 对有限 $1 \leq p < \infty$, L^p 收敛和几乎必然收敛也一般不能互相推出. 两个方向的差别可以分别算出.

例 2.63 (几乎必然消失的尖峰).

固定 $1 \leq p < \infty$, 在 $(0, 1)$ 上取 Lebesgue 概率测度, 令

$$X_n = n^{1/p} \mathbf{1}_{(0, 1/n)}.$$

固定任意 $\omega > 0$, 当 $n > 1/\omega$ 后, 这个点已在 $(0, 1/n)$ 之外, 所以其后的 $X_n(\omega)$ 都为零. 因而 X_n 逐点趋于零. 但每一项的 p 阶矩都是

$$\mathbb{E}[|X_n|^p] = n \cdot \frac{1}{n} = 1,$$

所以没有 L^p 收敛.

非零区间的长度缩小为 $1/n$, 函数的 p 次方却升高到 n , 两者相乘始终为一. 因而每个点最终取零, 与每一项的积分始终为一可以同时成立. 若反过来要求积分趋于零, 每个点上的数列也可能一直来回变化.

例 2.64 (打字机序列).

在 $[0, 1)$ 上取 Lebesgue 概率测度. 将正整数写为 $n = 2^m + k$, 其中 $m \geq 0$, $0 \leq k < 2^m$, 定义

$$X_n = \mathbf{1}_{[k/2^m, (k+1)/2^m)}.$$

在第 m 层, 指示函数依次扫过划分 $[0, 1)$ 的 2^m 个小区间. 对每个固定的 $1 \leq p < \infty$,

$$\mathbb{E}[|X_n|^p] = 2^{-m} \rightarrow 0,$$

所以 $X_n \rightarrow 0$ 于 L^p .

固定 $\omega \in [0, 1)$, 它在每一层恰好属于一个小区间, 因而每层恰有一项 $X_n(\omega) = 1$. 从 $m \geq 1$ 起, 每层也有取零的项. 因而零和一都出现无穷多次, 每个点上的数列都不收敛. 此例还始终满足 $\|X_n\|_\infty = 1$, 所以无穷端点没有同样的范数收敛.

若要从逐点极限得到积分极限, 可以补上控制收敛的条件. 设 $1 \leq p < \infty$, $X_n, X \in L^p$, 且 $X_n \rightarrow X$ a.s. 若有同一个 $Y \in L^1$, 使所有 $|X_n - X|^p \leq Y$ a.s., 就能取期望得到 $\mathbb{E}[|X_n - X|^p] \rightarrow 0$, 因而 $X_n \rightarrow X$ 于 L^p .

也可以不要求逐点上界, 只要求大取值部分的积分对整列函数都能同时变小. 可积变量族 (U_n) 称为一致可积 (uniformly integrable), 是指

$$\lim_{K \rightarrow \infty} \sup_n \mathbb{E}[|U_n| \mathbf{1}_{\{|U_n| > K\}}] = 0.$$

给定很小的误差以后, 选一个足够大的 K , 就能让所有变量在 $|U_n| > K$ 部分的绝对值积分都小于该误差.

若 (X_n) 一致可积且 $X_n \rightarrow X$ 于概率, 则有 $X \in L^1$ 和 $X_n \rightarrow X$ 于 L^1 , 这称为 Vitali 收敛结论. 证明仍用截断. 一致可积先给出 $\sup_n \mathbb{E}[|X_n|] < \infty$. 抽取几乎必然收敛子列并使用 Fatou, 得知 X 可积.

固定 K , 令 $T_K(x) = \max\{-K, \min\{x, K\}\}$. 截断后的两个变量都落在 $[-K, K]$ 内, 且截断不增大差值, 所以

$$\mathbb{E}[|T_K(X_n) - T_K(X)|] \leq \varepsilon + 2K\mathbb{P}(|X_n - X| > \varepsilon).$$

先令 $n \rightarrow \infty$, 再令 $\varepsilon \downarrow 0$, 截断后的误差积分趋于零. 原变量与截断之间的差, 对所有 X_n 由一致可积估计, 对 X 则由其可积性估计. 最后令 $K \rightarrow \infty$, 得到 $\mathbb{E}[|X_n - X|] \rightarrow 0$.

因此, 对 $X_n, X \in L^p$ 和 $1 \leq p < \infty$, 若已经依概率收敛, 并且误差族 $|X_n - X|^p$ 一致可积, 就得到 L^p 收敛. 各种收敛的基本区别列在下表中, 其中 p 阶矩使用的也是有限 p .

收敛方式	是否需要共同概率空间	控制的对象	典型记号	基本推出关系
依分布收敛	不需要	各自分布	$(X_n \xrightarrow{d} X)$	通常推出链中位置最弱
依概率收敛	需要	给定耦合下的误差概率	$(X_n \xrightarrow{\mathbb{P}} X)$	推出依分布
L^p 收敛	需要	给定耦合下误差的 p 阶矩	$(X_n \xrightarrow{L^p} X)$	推出依概率
几乎必然收敛	需要	几乎每条样本路径的尾部行为	$(X_n \xrightarrow{\text{a.s.}} X)$	推出依概率

2.5.2 极限定理

连续映射定理与 Slutsky 定理 已知 X_n 趋于 X , 再对它们使用同一个函数 g , 是极限计算中的常见步骤. 若 g 连续, 则依分布收敛可以通过复合测试函数来验证.

定理 2.65 (连续映射定理).

若 $X_n \xrightarrow{d} X$, 且 $g: \mathbb{R} \rightarrow \mathbb{R}$ 连续, 则

$$g(X_n) \xrightarrow{d} g(X).$$

证明. 对任意有界连续函数 f , 复合函数 $f \circ g$ 仍然有界连续. 由 $X_n \xrightarrow{d} X$, 有 $\mathbb{E}[f(g(X_n))] \rightarrow \mathbb{E}[f(g(X))]$, 这正是 $g(X_n) \xrightarrow{d} g(X)$ 的定义. $\square$

对欧氏空间之间的连续映射, 证明完全相同. 若原来是依概率收敛, 则每个子列都能抽到几乎必然收敛的进一步子列. 沿这个子列逐点使用 g 的连续性, 再用子列判别, 就得到 $g(X_n) \rightarrow g(X)$ 于概率.

依分布收敛时还可以放宽连续性条件. 设 g Borel 可测, 不连续点集为 D_g , 且 $\mathbb{P}(X \in D_g) = 0$. 对值域中的闭集 F , 有 $\overline{g^{-1}(F)} \subseteq g^{-1}(F) \cup D_g$. 先用 Portmanteau 估计 X_n 落在这个闭包中的概率上极限, 再由极限分布不在 D_g 上分配质量, 得到 $g(X_n)$ 的闭集不等式. 所以仍有 $g(X_n) \xrightarrow{d} g(X)$. 一般表述见 [Kal21, Theorem 5.27].

对两个变量作加法, 乘法或除法, 则应将连续映射用于它们的联合分布. Slutsky 定理说明: 若其中一个变量趋于常数, 只给出另一个的分布极限也已足够, 不要求两者独立.

定理 2.66 (Slutsky 定理).

设每一对 (X_n, Y_n) 在共同概率空间中定义, $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{\mathbb{P}} c$, 其中 c 为常数. 则

$$X_n + Y_n \xrightarrow{d} X + c, \quad X_n Y_n \xrightarrow{d} cX.$$

若 $c \neq 0$, 将商在 $\{Y_n = 0\}$ 上定义为任意可测有限值后, 还有

$$X_n/Y_n \xrightarrow{d} X/c.$$

不要求 X_n, Y_n 独立.

证明. 先证明联合分布收敛 $(X_n, Y_n) \xrightarrow{d} (X, c)$. 先由 $X_n \xrightarrow{d} X$ 证明 (X_n) 的分布构成一个紧族. 给定 $\eta > 0$, 先取 R 足够大, 使 $\mathbb{P}(|X| \geq R)$ 很小. 对闭集 $\{x : |x| \geq R\}$ 使用 Portmanteau, 可以控制所有充分大的 n 的尾概率. 剩下只有有限个早期项; 再把 R 适当增大, 就能同时使它们的尾概率也小于 η . 因而最终可取 R 使 $\sup_n \mathbb{P}(|X_n| > R) < \eta$.

固定有界连续函数 $h: \mathbb{R}^2 \rightarrow \mathbb{R}$. 它在 $[-R, R] \times [c-1, c+1]$ 上一致连续, 所以可以选 $0 < \delta < 1$, 使该矩形中 $|y - c| \leq \delta$ 时 $|h(x, y) - h(x, c)| \leq \eta$. 在其余事件上用 $2\|h\|_\infty$ 估计差值, 得

$$\mathbb{E}[|h(X_n, Y_n) - h(X_n, c)|] \leq \eta + 2\|h\|_\infty (\mathbb{P}(|X_n| > R) + \mathbb{P}(|Y_n - c| > \delta)).$$

先让 $n \rightarrow \infty$, 再让 $\eta \downarrow 0$, 可知左边趋于零. 同时, $x \mapsto h(x, c)$ 有界连续, 所以 $\mathbb{E}[h(X_n, c)] \rightarrow \mathbb{E}[h(X, c)]$. 合起来就得到所需的联合分布收敛.

将连续映射定理用于加法和乘法, 即得前两项. 对除法, 先将 $(x, y) \mapsto x/y$ 在 $y = 0$ 上定义为零. 这个 Borel 函数的不连续点只可能在 $y = 0$ 上, 而极限的第二坐标恒为 $c \neq 0$, 所以可用刚才的推广版本. 又因 $\mathbb{P}(Y_n = 0) \leq \mathbb{P}(|Y_n - c| > |c|/2) \rightarrow 0$, 在 $\{Y_n = 0\}$ 上改取其他可测有限值时, 任意有界测试函数的期望之差仍趋于零, 因而不改变分布极限. $\square$

相关步骤见 [Dur19, Exercises 3.2.12–3.2.14], 连续映射及倒数变换见 [Dur19, Theorem 3.2.10]. 在统计计算中, 标准化分母常含有未知的 $\sigma > 0$. 若估计量 $\hat{\sigma}_n \rightarrow \sigma$ 于概率, Slutsky 就允许用估计值代替这个分母. 下文的 Monte Carlo 例子会直接用到这项替换.

大数定律 设重复实验的结果 $X_1, X_2, \dots$ 独立同分布, 取样本平均

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

随着实验次数增加, 这个平均值是否接近理论期望? 有限方差时, 可以直接计算平均误差的平方, 得到下面的弱大数定律.

定理 2.67 (弱大数定律, 有限方差版本).

若 $X_1, X_2, \dots$ 独立同分布, $\mathbb{E}[X_1] = \mu$, $\text{Var}(X_1) = \sigma^2 < \infty$, 则

$$\bar{X}_n \xrightarrow{\mathbb{P}} \mu.$$

证明. 由期望线性性, $\mathbb{E}[\bar{X}_n] = \mu$. 展开误差平方, 不同项的交叉期望因独立且中心化而为零, 所以

$$\mathbb{E}[|\bar{X}_n - \mu|^2] = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{\sigma^2}{n} \rightarrow 0.$$

因而 $\bar{X}_n \rightarrow \mu$ 于 L^2 , 从而依概率收敛. 也可以对同一个平方误差使用 Chebyshev, 直接写成 $\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \sigma^2/(n\varepsilon^2)$. $\square$

注 2.68.

上面用方差计算证明了 L^2 收敛. 若只假设 $\mathbb{E}[|X_1|] < \infty$, 独立同分布的平均仍然收敛, 但要换一种证明. 下面的强大数定律给出几乎必然收敛, 也随之给出依概率收敛.

定理 2.69 (强大数定律).

设 $X_1, X_2, \dots$ 独立同分布, 并且 $\mathbb{E}[X_1] < \infty$. 那么

$$(\bar{X}_n \xrightarrow{\text{a.s.}} \mathbb{E}[X_1]).$$

只有一阶绝对矩有限时, 方差可能为无穷, 所以证明改从截断开始. 先截断过大的 X_k , 用可求和的尾概率及 Borel–Cantelli 说明, 几乎每条实现上只有有限多项被改变. 对中心化的截断变量使用独立随机级数的收敛判据和 Kronecker 引理, 再求截断均值的极限, 就得到强大数定律. 完整论证见 [Kal21, Theorem 5.23] 或 [Dur19, Theorem 2.4.1].

定理说明, 对几乎每条无限实验记录, 其平均值最终趋于理论期望. 平均值在途中仍可上下变化, 一阶可积性本身也没有给出统一的有限样本误差速度.

例 2.70 (经验频率).

独立重复同一种实验, 令 A_k 表示第 k 次实验中某事件发生, 且 $\mathbb{P}(A_k) = p$. 则 $X_k = \mathbf{1}_{A_k}$ 独立同分布, $\mathbb{E}[X_k] = p$. 前 n 次实验的平均

$$\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k}$$

就是事件的经验频率. 由强大数定律,

$$\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k} \xrightarrow{\text{a.s.}} p.$$

模型先给每次事件指定概率 p , 定理再证明独立重复所得的经验频率几乎必然趋于它. 这便把事先给定的理论概率与长期观察到的频率联系起来.

中心极限定理 大数定律给出 $\bar{X}_n \rightarrow \mu$, 但平均值每次离 μ 有多远, 仍然是随机的. 在独立同分布且方差有限时,

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{Std}(\bar{X}_n) = \frac{\sigma}{\sqrt{n}}.$$

所以均方根误差为 $\sigma/\sqrt{n}$. 直接观察 $\bar{X}_n - \mu$, 它会缩到零; 将它除以自身的标准差, 就能在相同尺度上比较不同样本量的误差分布.

定理 2.71 (Lindeberg–Lévy 中心极限定理).

若 $X_1, X_2, \dots$ 独立同分布, $\mathbb{E}[X_1] = \mu$, $0 < \text{Var}(X_1) = \sigma^2 < \infty$, 则

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} Z, \quad Z \sim \mathcal{N}(0, 1).$$

证明可用特征函数完成. 先将单项变量中心化并标准化为方差一, 其特征函数在零点附近有展开 $1 - t^2/2 + o(t^2)$. 对标准化的和, 独立性使特征函数写成相应的 n 次幂, 取极限得到 $e^{-t^2/2}$. 再用 Lévy 连续性定理, 就得到分布收敛. 这些工具及完整证明见 [Kal21, Theorem 6.10] 或 [Dur19, Theorem 3.4.1].

令 Φ 为标准正态分布函数. 它处处连续, 所以对每个固定 $x \in \mathbb{R}$,

$$\mathbb{P}\left(\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \leq x\right) \rightarrow \Phi(x).$$

例如, 要估计平均值落在均值附近某个范围内的概率, 先将范围的两端减去 μ , 再除以 $\sigma/\sqrt{n}$, 就可以用标准正态分布计算近似概率. 因而通常写成

$$\mathcal{L}(\bar{X}_n) \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

定理给出固定标准化阈值处的概率极限. 若要估计有限样本的分布近似误差, 还需相应的定量结果, 例如经典 Berry–Esseen 型 $n^{-1/2}$ 上界使用有限三阶绝对矩. 随样本量不断移向远端的阈值则属于尾部近似问题, 不能仅用固定阈值的收敛计算其相对误差, 通常要进一步研究尾部或大偏差.

例 2.72 (二项计数的正态近似).

固定 $0 < p < 1$, 令 X_k 独立且服从 $\text{Bernoulli}(p)$, $S_n = \sum_{k=1}^n X_k$. 则 $S_n \sim \text{Bin}(n, p)$, 单
项均值为 p , 方差为 $p(1-p)$. 强大数定律给出 $S_n/n \rightarrow p$ a.s., 中心极限定理则给出

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} Z, \quad Z \sim \mathcal{N}(0, 1).$$

于是以 np 为中心, 以 $\sqrt{np(1-p)}$ 为单位表示计数范围以后, 可以用正态分布近似固定标准
化区间的概率. 这里 p 固定; 若它非常接近零或一, 有限样本下的近似效果还与实际样本量有
关.

例 2.73 (Monte Carlo 定价).

这里先把风险中性测度 $\mathbb{Q}$ 当作定价模型已经给定的概率测度; 它为什么会由无套利与计
价资产产生, 将在第五章中说明. 假设在这个 $\mathbb{Q}$ 下, 所求价格是贴现支付 H 的期望

$$V = \mathbb{E}_{\mathbb{Q}}[H], \quad \mathbb{E}_{\mathbb{Q}}[|H|] < \infty.$$

按 H 在 $\mathbb{Q}$ 下的分布独立模拟 n 次, 得到 $H^{(1)}, \dots, H^{(n)}$, 再用平均值

$$\hat{V}_n = \frac{1}{n} \sum_{i=1}^n H^{(i)}$$

估计 V . 由强大数定律, 在模拟样本的概率空间中, $\hat{V}_n \rightarrow V$ a.s.

还要估计有限次模拟带来的误差. 若 $0 < \text{Var}_{\mathbb{Q}}(H) = \sigma^2 < \infty$, 则独立性给出 $\text{Var}(\hat{V}_n) =$
 σ^2/n , 所以模拟平均值的标准误差为 $\sigma/\sqrt{n}$. 将偏差 $\hat{V}_n - V$ 除以这个标准误差, 中心极限定
理给出

$$\frac{\sqrt{n}(\hat{V}_n - V)}{\sigma} \xrightarrow{d} Z, \quad Z \sim \mathcal{N}(0, 1).$$

因而可以用标准正态分布估计误差落在若干倍标准误差之内的概率.

实际模拟时, σ 通常也未知, 可以由同一组样本估计. 对 $n \geq 2$, 取样本方差

$$\hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (H^{(i)} - \hat{V}_n)^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{i=1}^n (H^{(i)})^2 - \hat{V}_n^2 \right).$$

有限二阶矩使 H 与 H^2 都可积, 分别应用强大数定律, 得到 $\hat{\sigma}_n^2 \rightarrow \sigma^2$ a.s., 从而 $\hat{\sigma}_n \rightarrow \sigma$ a.s.
由 Slutsky, 将未知分母换成估计值以后仍有

$$\frac{\sqrt{n}(\hat{V}_n - V)}{\hat{\sigma}_n} \xrightarrow{d} Z.$$

若某次样本的标准差为零, 可将这个比值暂取为零. 由于 $\hat{\sigma}_n \rightarrow \sigma > 0$, 这类事件的概率趋于
零, 所以不改变极限.

最终以 $\hat{V}_n$ 作为期望 V 的模拟估计, 以 $\hat{\sigma}_n/\sqrt{n}$ 估计这次抽样的标准误差.

2.5.3 通向随机过程的补充

进阶补充: 耦合与 Wasserstein 距离 前面计算 $X_n - X$ 时, 两个变量已经在同一概率空间中定
义. 若只固定它们各自的分布, 却允许重新选择如何一起取值, 就可以寻找使平均误差尽量小的联合
分布. 这样的选择称为耦合, 最优传输的系统讨论见 [Vil09].

定义 2.74.

若 $\mathbb{R}^2$ 上的概率测度 π 的两个边缘分别为 μ, ν , 就称 π 为二者的一个耦合. 所有耦合组成的集合记为 $\Pi(\mu, \nu)$.

至少可以选独立乘积 $\mu \otimes \nu$, 所以 $\Pi(\mu, \nu)$ 非空. 已有随机变量 X, Y 的联合分布 $\mathcal{L}(X, Y)$ 也是一个耦合, 对应它们原来在同一空间中的取值方式.

对 $1 \leq p < \infty$, 在每个耦合下计算 $|x - y|^p$ 的平均, 再在所有耦合中取下确界, 就能定义两个分布的 Wasserstein 距离.

定义 2.75.

设 $1 \leq p < \infty$, 并记

$$\text{Prob}_p(\mathbb{R}) = \left\{ \mu \mid \mu \text{ 是 } \mathbb{R} \text{ 上的 Borel 概率测度, } \int_{\mathbb{R}} |x|^p d\mu(x) < \infty \right\}.$$

对于 $\mu, \nu \in \text{Prob}_p(\mathbb{R})$, 定义

$$W_p(\mu, \nu) = \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathbb{R}^2} |x - y|^p d\pi(x, y) \right)^{1/p}.$$

可以把 π 看作将一处的概率质量移到另一处的方案. 移动得越远, $|x - y|^p$ 越大; 移动的质量越多, 对积分的贡献也越大. 两个边缘都有有限 p 阶矩时, 由 $|x - y|^p \leq 2^{p-1}(|x|^p + |y|^p)$, 每个耦合的成本都有限.

若 $X, Y \in L^p$ 已经在同一空间中定义, 它们的联合分布只是所有可选耦合中的一个, 所以

$$W_p(\mathcal{L}(X), \mathcal{L}(Y)) \leq \|X - Y\|_p.$$

右边按现有配对计算, 左边则可以换配对. 例如前面的独立标准正态变量, 两个边缘相同, 可以改为将相同取值配在一起, 使 Wasserstein 距离为零; 原来的独立配对却仍给出 $X_n - X \sim \mathcal{N}(0, 2)$.

这也说明怎样把分布近似进一步写成随机变量的误差估计. 例如 CLT 先给出标准化平均的正态分布极限; 若要在共同空间中让它接近某个正态变量 Z , 就要另外选择耦合, 再估计标准化以后的差. 仅比较未放大的 $\bar{X}_n - \mu$ 与 $\sigma Z/\sqrt{n}$, 两者本来都趋于零, 它们的差趋于零并没有反映相对于标准误差的近似好坏.

若一个边缘是常数分布, 则另一边无论取何值都只能与该常数配对, 因而没有上述选择.

命题 2.76.

设 $1 \leq p < \infty$, $Z \in L^p$, $c \in \mathbb{R}$, 则

$$W_p(\mathcal{L}(Z), \delta_c) = \|Z - c\|_p.$$

证明. 第二个边缘集中在 c , 使任何耦合都将全部质量放在 $\mathbb{R} \times \{c\}$ 上. 再指定第一个边缘, 耦合就唯一为 $\mathcal{L}(Z) \otimes \delta_c$. 因而

$$W_p^p(\mathcal{L}(Z), \delta_c) = \int |x - c|^p d\mathcal{L}(Z)(x) = \mathbb{E}[|Z - c|^p].$$

取 p 次根即得等式. □

将命题用于误差 $Z = X_n - X$ 和常数零, 对共同概率空间中的 $X_n, X \in L^p$ 得到

$$X_n \xrightarrow{L^p} X \iff W_p(\mathcal{L}(X_n - X), \delta_0) \longrightarrow 0.$$

左边的误差已按原来的联合实现计算, 右边只是把这个误差的分布与零比较. 若直接比较两个给定分布, 则 Wasserstein 收敛由下面的条件刻画.

定理 2.77.

固定 $1 \leq p < \infty$, 设 $\mu_n, \mu \in \text{Prob}_p(\mathbb{R})$. 则 $W_p(\mu_n, \mu) \rightarrow 0$ 当且仅当 $\mu_n \Rightarrow \mu$, 且

$$\int_{\mathbb{R}} |x|^p d\mu_n(x) \longrightarrow \int_{\mathbb{R}} |x|^p d\mu(x).$$

距离公理及这一刻画的完整证明见 [Vil09]. 矩条件的必要性可以直接计算. 对任意耦合, 由 Minkowski, 两个坐标的 L^p 范数之差的绝对值不超过它们差值的范数. 再对耦合取下确界, 得

$$\left| \left(\int |x|^p d\mu_n \right)^{1/p} - \left(\int |x|^p d\mu \right)^{1/p} \right| \leq W_p(\mu_n, \mu).$$

所以 Wasserstein 距离趋于零时, 这些矩也必须收敛. 反向则通过构造合适的耦合证明.

弱收敛只检验有界连续函数. 很少的概率移到很远处时, 对这类函数积分的影响可以趋于零, 但距离的 p 次方很大, 相应运输成本可能仍不小. 矩收敛正是对这部分取值追加的要求.

例 2.78.

在 $(0, 1)$ 上取 Lebesgue 概率测度, 令 $X_n = n\mathbf{1}_{(0, 1/n)}$. 则

$$\mathcal{L}(X_n) = \left(1 - \frac{1}{n}\right) \delta_0 + \frac{1}{n} \delta_n.$$

除了概率为 $1/n$ 的部分取值 n , 其余都取零, 所以 $\mathcal{L}(X_n) \Rightarrow \delta_0$. 但要把位于 n 的那部分概率也移到零, 需要移动距离 n , 对应的平均距离始终为 $(1/n)n = 1$. 因而

$$W_1(\mathcal{L}(X_n), \delta_0) = \mathbb{E}|X_n| = 1.$$

所以它弱收敛到 δ_0 , 却不按 W_1 收敛, 一阶绝对矩也没有趋于零.

从随机变量到路径空间 本节将整条随机序列放入序列空间, 从而把几乎必然收敛写成一个可测事件. 对随时间变化的随机过程, 也可以把一次实现看成一条函数:

$$\omega \longmapsto (t \mapsto X_t(\omega)).$$

选定函数空间及其可测结构, 并证明这个映射可测, 就能将过程作为路径空间中的随机元素研究. 它的分布仍由前推概率测度定义, 连续性, 跳跃和首次到达等问题则通过整条路径描述.

连续路径的版本通常放在 $C([0, T])$ 中, 采用一致拓扑. 右连续且有左极限的路径通常放在 $D([0, T])$ 中, 常用 Skorokhod J_1 拓扑. 讨论路径分布的弱收敛时, 必须指定所用拓扑, 因为哪些路径函数连续取决于这项选择.

在这样的空间中, 可以同时考察不同时刻的关系, 判断某个水平是否曾被达到, 或者一系列过程的整条路径如何趋近. 下一章从有限维分布和样本路径开始, 将前面的概率, 信息和极限方法用于这些随时间展开的问题.

第三章 随机过程基础

前一章研究随机变量的分布, 期望和收敛. 现在把随机变量按时间排列起来. 随机游走下一步会走到哪里, 第一笔订单什么时候到达, 一条路径是否曾经越过某个水平, 都不再只涉及某一个时刻的随机变量.

过程的关键在于不同时刻怎样联系. 即使每个时刻的边缘分布都已知, 仍然不知道两个时刻是否独立, 一次实现怎样随时间变化, 或观察到过去以后怎样判断未来. 因而除了联合分布和样本路径, 还要记录每个时刻已经获得的信息.

本章主要参考 [Bil95; Dur19; Kal21; Shr04b; Wil91]. 我们先建立过程律, 样本路径和滤过的语言, 再研究停时, Markov 性与鞅. Poisson 过程和 Brown 运动分别给出跳跃过程与连续过程的基本例子. 最后比较总变差和二次变差, 为第四章中的随机积分和 Itô 公式作准备.

3.1 从路径到信息

先用随机游走看几个层次不同的问题. 第十步在哪里, 只涉及 S_{10} 的分布; 第五步和第十步怎样共同取值, 要看联合分布; 前十步有没有越过某个水平, 则取决于整段路径. 有限维分布和过程律正是为了同时描述这些问题.

再把观察时点放在游走尚未结束的时候. 已经走过的部分可以使用, 后面的增量还没有发生. 滤过记录这种随时间增加的信息. 有了它, 才能区分什么时候能够决定下一期的系数, 首次到达一个位置是否能当场认出, 以及给定当前信息以后怎样计算未来的条件分布和条件平均. 可预测性, 停时, Markov 性和鞅都从这里出现.

进入连续时间以后, Poisson 过程用跳跃记录事件到达, Brown 运动则给出连续的随机波动. 它们的路径性质最终把问题带到变差和随机积分. 下图按这个顺序列出本章的主要概念:




图 3.1: 随机过程基础的首次阅读路线.

3.2 随机过程, 分布与样本路径

固定概率空间与随机变量族 下面先把所有随机对象放在同一个固定概率空间

$$(\Omega, \mathcal{F}, \mathbb{P})$$

上. 状态空间记为 $(E, \mathcal{E})$, 时间指标集记为 $\mathbb{T}$. 最常见的两种情况是离散时间 $\mathbb{T} = \mathbb{N}_0$ 和连续时间 $\mathbb{T} = [0, \infty)$.

定义 3.1 (随机过程).

一个取值于 $(E, \mathcal{E})$, 指标集为 $\mathbb{T}$ 的 **随机过程**是指一族随机元素

$$X = (X_t)_{t \in \mathbb{T}}, \quad X_t: \Omega \rightarrow E,$$

其中每个 X_t 都是 $\mathcal{F}/\mathcal{E}$ -可测的.

固定时刻 t 时, X_t 是一个随机变量或随机元素. 此时让 ω 变化, 比较的是同一时刻在不同样本上的取值. 固定样本点 ω 时,

$$t \mapsto X_t(\omega)$$

是关于时间的普通函数, 称为 X 在 ω 上的**样本路径**. 因而可以把同一个过程从两个方向来看:

- t 固定 : $\omega \mapsto X_t(\omega)$ 比较同一时刻不同样本的取值,
- ω 固定 : $t \mapsto X_t(\omega)$ 得到一次实现随时间变化的路径.

图3.2左边突出一条样本路径, 右边则固定 t_* , 比较几条可能路径在这个时刻分别处于什么状态.




图 3.2: 固定样本点与固定时刻观察同一随机过程. 三条折线表示可能的实现; 蓝线突出一条样本路径, 橙点表示固定时刻在不同实现上的取值.

例 3.2 (随机游走).

令 $\xi_1, \xi_2, \dots$ 为独立同分布随机变量, 满足

$$\mathbb{P}(\xi_k = 1) = p, \quad \mathbb{P}(\xi_k = -1) = 1 - p.$$

定义

$$S_0 = 0, \quad S_n = \sum_{k=1}^n \xi_k.$$

那么 $S = (S_n)_{n \geq 0}$ 是整数值随机过程. 固定 n 时, S_n 是随机变量; 固定 ω 时, $0, S_1(\omega), S_2(\omega), \dots$ 是一条上下移动的折线路径.

当 $p = 1/2$ 时称为简单对称随机游走. 它会同时成为后面 Markov 链, 鞅和首次到达问题的例子.

一条现实价格记录也是一条实现 图3.3把 AAPL 的复权收盘价按时间排列, 展示了一段已经发生的价格历史. 若把价格放在随机过程模型中, 这段记录就是一次实现, 对应固定 ω 后的路径 $t \mapsto X_t(\omega)$. 图中能看见这一段历史怎样变化, 却看不见其他历史有多大可能发生; 后一个问题需要由过程的分布回答. 因此, 画出一条价格路径与给出一个价格模型, 是两件不同的事.



图 3.3: AAPL 复权收盘价的一条实现路径 (2019–2021). 数据来源见引用文献 [Yaha; Yahc].

为什么单时点分布不够 下面两个过程在每个时刻都有相同的分布, 随时间变化的方式却截然不同. 设 $Z_0, Z_1, \dots$ 独立同分布于 $\mathcal{N}(0, 1)$, 另取 $Z \sim \mathcal{N}(0, 1)$, 定义

$$X_n = Z_n, \quad Y_n = Z.$$

过程 X 每一期重新抽取一个独立的正态值; 过程 Y 只在开始时抽取一次, 此后始终保持这个值. 单看任意一个时刻, 两者都是标准正态分布, 无法区分. 只要同时观察两个时刻, 区别就出现了: 前者的两个值独立, 后者的两个值必然相等.

因此, 要描述时间依赖, 不能停留在各时刻的边缘分布, 而要研究多个时刻的联合分布.

定义 3.3 (有限维分布).

对任意 $n \geq 1$ 和任意 $t_1, \dots, t_n \in \mathbb{T}$, 随机向量

$$(X_{t_1}, \dots, X_{t_n})$$

的联合分布称为过程 X 的一个**有限维分布**. 全部有限维分布组成的族记作

$$\{\mathcal{L}(X_{t_1}, \dots, X_{t_n}) : n \geq 1, t_1, \dots, t_n \in \mathbb{T}\}.$$

也可以把整条路径看成一次随机抽取的结果. 此时取值空间不再是 E , 而是由所有函数 $\mathbb{T} \rightarrow E$ 组成的空间 $E^{\mathbb{T}}$:

$$X: \Omega \longrightarrow E^{\mathbb{T}}, \quad X(\omega) = (X_t(\omega))_{t \in \mathbb{T}}.$$

要谈这个随机元素的分布, 先要在路径空间上指定可测集合. 这里采用由有限个坐标投影生成的柱 σ -代数. 它从“在若干指定时刻, 过程的取值落入某个可测集合”这类事件出发, 再通过可数次集合运算生成其他事件.

每个 X_t 的可测性保证上述路径映射可测, 因此可以像处理普通随机变量一样, 取前推测度

$$\mathcal{L}(X) = \mathbb{P} \circ X^{-1}.$$

这就是 X 的**过程分布**, 也称**过程律**. 有限维分布是它在有限组坐标上的边缘分布; 反过来, 这些边缘分布也决定了柱 σ -代数上的整个测度.

定理 3.4 (有限维分布决定柱 σ -代数上的过程律).

如果两个过程 X 和 Y 具有相同的全部有限维分布, 那么它们在 $E^{\mathbb{T}}$ 的柱 σ -代数上具有相同的过程律.

证明. 全部有限维分布相同, 意味着两个过程律在每个有限坐标柱集合上取值相同. 这些柱集合构成一个生成柱 σ -代数的 π -系统, 而两个过程律都是概率测度. 由 π - λ 定理, 它们在整个柱 σ -代数上相同. $\square$

上面的定理从一个已经存在的过程出发. 现在反过来问: 若我们只给出了各组时刻的联合分布, 什么条件能保证确实存在一个过程具有这些分布? 最基本的要求是投影一致性. 例如, 指定三个时刻的联合分布以后, 忘掉第三个坐标, 必须得到原先指定的前两个时刻的联合分布, 不能另得一个答案. Kolmogorov 延拓定理说明, 在适当的状态空间上, 这个要求已经足够.

定理中的状态空间须为标准 Borel 空间, 即与某个 Polish 空间的 Borel 可测空间可测同构; Polish 指可分且可由完备度量给出拓扑. 常用的 $\mathbb{R}^d$, 可数离散空间, 以及采用一致拓扑的连续路径空间 $C([0, T])$ 和采用通常 Skorokhod 拓扑的 $D([0, T])$, 都在这一范围内. 要注意, 延拓定理解决的是过程律的存在, 并不同时保证所构造的路径连续或右连续.

定理 3.5 (Kolmogorov 延拓定理).

设 $(E, \mathcal{E})$ 是标准 Borel 空间. 对每个有限子集 $J \subseteq \mathbb{T}$, 设给定 E^J 上的概率测度 μ_J . 如果每当 $J \subseteq K$ 时, μ_J 都等于 μ_K 经自然坐标投影 $E^K \rightarrow E^J$ 所得的前推测度, 那么存在某个概率空间及其上的过程, 使 (μ_J) 成为该过程的有限维分布族.

证明. 先引用可数乘积上的射影极限定理: 对每个可数的 $U \subseteq \mathbb{T}$, 一致的有限维分布族 $(\mu_J)_{J \subseteq U, |J| < \infty}$ 可以在 E^U 上延拓为概率测度 P_U . 这一存在性用到了标准 Borel 条件, 见 [Kal21, Theorem 8.21]; 唯一性则由柱集合上的 π - λ 定理得到. 特别地, 不同可数坐标集上的 P_U 也彼此投影一致.

从可数指标推广到任意指标, 关键在于: 乘积 σ -代数中的每个集合, 实际上只依赖至多可数个坐标. 因为生成它的柱集合只涉及有限个坐标, 而取补集和可数并不会引入不可数多个新坐标. 因此, 对每个可测集合 A , 都可找到可数的坐标集 U_A , 并写成 $A = \pi_U^{-1}(A_U)$, 其中 $A_U \in \mathcal{E}^U$. 令

$$P(A) = P_U(A_U).$$

这个定义不能依赖所选的表示. 若 A 也可以用另一组坐标 V 表示, 就把两组坐标都放进 $U \cup V$; 在这个可数乘积空间中使用投影一致性, 两种计算给出的概率相同.

同样, 对两两不交的 $A_1, A_2, \dots$, 取 $U = \bigcup_n U_{A_n}$, 便能把所有集合放在同一个可数乘积空间中处理. 此时 P 的可列可加性就是 P_U 的可列可加性. 所以 P 确实是 $E^{\mathbb{T}}$ 的乘积 σ -代数上的概率测度.

最后以 $(E^{\mathbb{T}}, \mathcal{E}^{\mathbb{T}}, P)$ 为概率空间, 取坐标过程 $X_t(x) = x_t$. 根据构造, 它在每个有限坐标集 J 上的分布正是 μ_J . 任意指标集与标准 Borel 状态空间的完整论证见 [Kal21, Theorem 8.23]; 实数序列空间上的直接紧矩形证明见 [Dur19, Theorem A.3.1]. $\square$

注 3.6.

延拓定理把测度构造在所有坐标函数组成的空间上, 尚未把路径限制为连续函数. 因此, “这些有限维分布能够同时实现”与“能够选到连续的实现”不能混为一谈. 后一个问题通常要利用增量的矩估计, 再应用 Kolmogorov 连续性定理寻找连续修正. 下面先说明这里的“修正”究竟允许改变什么.

修正, 不可区分与路径性质 对单个随机变量, 在一个零概率集合上改变取值, 通常不会影响我们的结论. 对随机过程则必须多问一句: 各时刻允许修改的是不是同一个零概率集合? 若每个时刻各有自己的例外集, 那么把不可数多个时刻合起来以后, 例外未必仍然可以忽略. 修正与不可区分的区别, 正是这个量词次序的区别.

定义 3.7 (修正与不可区分).

设 $X = (X_t)_{t \in \mathbb{T}}$ 和 $Y = (Y_t)_{t \in \mathbb{T}}$ 定义在同一概率空间上.

1. 如果对每个固定的 $t \in \mathbb{T}$ 都有

$$\mathbb{P}(X_t = Y_t) = 1,$$

则称 X 和 Y 互为修正.

2. 如果存在 $\Omega_0 \in \mathcal{F}$, 满足 $\mathbb{P}(\Omega_0) = 1$, 并且对每个 $\omega \in \Omega_0$ 和所有 $t \in \mathbb{T}$ 都有

$$X_t(\omega) = Y_t(\omega),$$

则称 X 和 Y 不可区分.

不可区分要求找出一个共同的满概率事件, 使两条路径在其中处处相等, 因此一定推出互为修正. 若 $\mathbb{T}$ 可数, 把每个时刻的零概率例外集取并, 就能得到这样一个共同的例外集, 所以反方向也成立. 连续时间的问题在于时刻不可数: 测度的可列可加性不能保证不可数个零概率集合的并仍是零概率集合. 下面的例子恰好利用了这一点.

例 3.8 (每个时刻相同, 整条路径却不同).

取 $\Omega = [0, 1]$ 及 Lebesgue 概率测度, 并令

$$X_t(\omega) = \mathbf{1}_{\{\omega=t\}}, \quad Y_t(\omega) = 0, \quad t \in [0, 1].$$

对每个固定 t , 单点集合 $\{t\}$ 的概率为 0, 因而 $X_t = Y_t$ a.s. 所以 X 与 Y 互为修正.

但是对每一个 ω , 都有 $X_\omega(\omega) = 1$, 因而不存在任何样本点使两条路径在所有时刻都相同. 所以二者并不可区分.

命题 3.9 (连续修正的唯一性).

如果连续时间过程 X 和 Y 互为修正, 并且二者的样本路径都几乎必然连续, 那么 X 和 Y 不可区分.

证明. 互为修正保证两个过程在每个有理时刻几乎必然相等. 有理时刻只有可数多个, 因此可以同时排除它们的零概率例外集, 再与两条路径都连续的满概率事件取交, 得到一个共同的满概率事件.

固定这个事件中的任意 ω . 两条连续函数在所有有理时刻相等, 而有理时刻稠密, 所以它们在所有时刻都相等. 这里正是连续性把“逐时刻相等”加强成了“整条路径相等”. $\square$

因此, 从有限维分布构造过程时, 可以先不要求路径连续, 再寻找一个连续修正; 一旦找到, 连续修正在不可区分的意义下就是唯一的. 但原过程未必已经连续, 不能把“存在连续修正”直接写成“原过程的路径连续”. 后文把路径连续性直接列入 Brown 运动的定义; 若先构造具有相应协方差的 Gauss 过程, 则还须完成寻找连续修正这一步.

3.3 时间与信息

前一节允许我们把整条路径作为一个随机元素来研究, 但预测和决策不能事先使用整条路径. 站在时刻 t , 我们只能依据当时已经获得的信息. 要判断一个量是否已经可知, 一个决定是否使用了未来信息, 以及一个随机时刻是否已经到来, 都必须先明确这些信息的范围.

滤过, 自然滤过与适应过程 仍用 σ -代数表示可用信息, 只是现在要给每个时刻各指定一个. 随着观察继续进行, 能够判断的事件越来越多, 于是得到下面这个递增的 σ -代数族.

定义 3.10 (滤过与滤过概率空间).

一个滤过是指一族子 σ -代数 $(\mathcal{F}_t)_{t \in \mathbb{T}}$, 满足

$$s \leq t \implies \mathcal{F}_s \subseteq \mathcal{F}_t \subseteq \mathcal{F}.$$

四元组

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in \mathbb{T}}, \mathbb{P})$$

称为滤过概率空间.

事件属于 $\mathcal{F}_t$, 表示到时刻 t 已经能根据所掌握的信息判断它是否发生. 包含关系 $\mathcal{F}_s \subseteq \mathcal{F}_t$ 则表示过去已经能判断的事, 到后来仍然能判断. 滤过不是过程记号旁边可有可无的附属物: 同一过程面对掌握不同信息的观察者, 可能有不同的条件期望, 因而有不同的鞅性质.

两次抛硬币给出一个有限的例子. 记 H 为正面, T 为反面, 样本空间是 $\Omega = \{HH, HT, TH, TT\}$. 观察第一次以后, 我们能够区分 $\{HH, HT\}$ 与 $\{TH, TT\}$, 却还不能区分 HH 与 HT . 观察第二次以后, 四种结果才可以区分. 图3.4中的每个框表示当时仍无法区分的一组结果; 信息增加, 就是这些分组逐渐细分.




图 3.4: 信息增长表现为可区分结果的细分. 每一列的 σ -代数由该列各框及它们的并组成, 包括空集. 样本空间始终是同一个 Ω .

定义 3.11 (自然滤过).

过程 X 生成的自然滤过为

$$\mathcal{F}_t^X = \sigma(X_s : s \leq t).$$

自然滤过是使截至 t 的全部观测 X_s 都可测的最小信息集, 因此只记录过程自身的历史. 实际模型可以使用更大的滤过. 例如, 即使 X 只记录价格, 观察者也可能同时知道成交量, 新闻和订单流.

连续时间中还常对自然滤过作通常增广: 补入零概率集合, 并使滤过右连续. 这样便于陈述后面的连续时间定理. 这里要区分两种做法: 补全和右连续化是明确的数学处理, 额外加入其他观测则是在改变模型允许使用的信息; 不能把两者都笼统地当作无关紧要的记号调整.

定义 3.12 (适应过程).

若对每个 $t \in \mathbb{T}$, 随机变量 X_t 都是 $\mathcal{F}_t$ -可测的, 则称 X 关于滤过 $(\mathcal{F}_t)$ 适应.

适应性说的是: 到了时刻 t , 当前值 X_t 已经可知. 每个过程自然都适应于自己的自然滤过. 但这还没有说明一个决定是否来得及实施. 例如, 第 n 期结束后确定的持仓可以是 $\mathcal{F}_n$ -可测的, 却不能倒过来赚取这一期已经发生的收益. 为表达这种先后关系, 需要可预测性.

可预测性: 行动必须先于结果**定义 3.13 (离散时间可预测过程).**

设 $(H_n)_{n \geq 1}$ 为离散时间过程. 如果每个 H_n 都是 $\mathcal{F}_{n-1}$ -可测的, 则称 H 为可预测过程.

这里的“可预测”不是说能够预报未来价格, 而是说第 n 期使用的系数, 在第 $n-1$ 期结束时已经能够确定. 若 H_n 表示区间 $(n-1, n]$ 内的持仓, 它可以依赖此前的全部观测, 却不能依赖这一区间尚未发生的价格变化. $\mathcal{F}_{n-1}$ 与 $\mathcal{F}_n$ 只相差一个时间下标, 经济含义却完全不同.

例 3.14 (离散时间交易增益).

设 S_n 是价格过程, H_n 是第 n 期开始前决定的持仓. 每期的增益等于持仓数量乘以随后发生的价格变化, 因此截至 n 的累计交易增益为

$$(H \cdot S)_n = \sum_{k=1}^n H_k(S_k - S_{k-1}).$$

要把这个和解释为事前能够实施的交易, 须要求 H_k 为 $\mathcal{F}_{k-1}$ -可测. 对比下面的选择:

$$H_k = \text{sgn}(S_k - S_{k-1}).$$

它让上涨时持有正头寸, 下跌时持有负头寸, 于是每一项都变成价格变化的绝对值. 但选择头寸时已经使用了本期涨跌; 在涨跌事先未知的情形下, 这个过程并不可预测. 计算出来的非负增益只是使用未来信息的结果, 并没有给出可实施的交易方法.

连续时间的可预测性 连续时间没有紧邻当前的“上一时刻”, 不能直接照搬 $\mathcal{F}_{n-1}$. 不过, 分段常数的规则仍然容易说明: 在时刻 s 根据已经知道的信息作出决定, 然后在 $(s, t]$ 内保持不变. 连续时间的可预测性就从这种规则出发定义, 而不是要求预先知道整条未来轨迹.

定义 3.15 (连续时间可预测 σ -代数).

在 $[0, \infty) \times \Omega$ 上, 由下列集合生成的 σ -代数称为可预测 σ -代数:

$$\{0\} \times A, \quad A \in \mathcal{F}_0,$$

以及

$$(s, t] \times A, \quad 0 \leq s < t, \quad A \in \mathcal{F}_s.$$

对这个 σ -代数可测的过程称为可预测过程.

集合 $(s, t] \times A$ 同时说明何时采用一条规则, 以及在什么情形下采用它. 由于 $A \in \mathcal{F}_s$, 到了 s 就已经知道这条规则是否启用; 随后才发生区间 $(s, t]$ 中的变化. 用这些集合生成 σ -代数, 便把简单的分段规则扩展到更一般的过程.

适应且左连续的过程是可预测的, 连续适应过程尤其如此. 这里没有矛盾: 连续过程的当前值可以由此前越来越近的观测取得, 并不意味着我们提前知道了它未来的值. 第4.3节将从简单可预测过程开始构造随机积分.

注 3.16 (渐进可测性).

适应性逐个时刻说明 X_s 在时刻 s 已经可知. 连续时间中若还要把时间变量一起积分或作其他联合运算, 则要考虑映射 $(s, \omega) \mapsto X_s(\omega)$ 的联合可测性.

过程称为**渐进可测**, 是指对每个 t , 映射在 $[0, t] \times \Omega$ 上的限制关于 $\mathcal{B}([0, t]) \otimes \mathcal{F}_t$ 可测. 也就是说, 截至 t 的整段轨迹作为时间和样本点的函数, 都只使用 $\mathcal{F}_t$ 中的信息. 适应且具有连续或右连续路径的过程是渐进可测的. 后面的积分构造会根据需要采用可预测性或渐进可测性, 并另外要求相应的可积条件.

停时, 首次到达与停止过程 许多问题没有预先指定结束日期, 而是约定发生某件事时就停止. 例如, 价格首次触及止损线, 第一笔订单到达, 或随机游走首次离开一个区间. 结束时刻因路径而异, 但规则应该允许我们在观察过程中判断是否该停, 而不是等看完未来以后再回头选一个时刻.

定义 3.17 (停时).

取值于 $\mathbb{T} \cup \{\infty\}$ 的随机变量 τ 称为关于 $(\mathcal{F}_t)$ 的**停时**, 如果对每个 $t \in \mathbb{T}$ 都有

$$\{\tau \leq t\} \in \mathcal{F}_t.$$

定义要求的是: 到了 t , 能够判断停止是否已经发生; 它不要求在开始时就知道将在哪一天停止. 允许 $\tau = \infty$, 则是为了容纳停止条件始终没有出现的路径. 在离散时间中, 这个条件等价于

$$\{\tau = n\} \in \mathcal{F}_n \quad \text{对每个 } n.$$

也就是说, 每一步走完以后, 我们能够当场判断是否恰好在这一步停止.

例 3.18 (首次到达时刻).

设 X 是适应过程, $B \in \mathcal{E}$, 并约定空集的下确界为 ∞ . 离散时间首次进入 B 的时刻为

$$\tau_B = \inf\{n \geq 0 : X_n \in B\}.$$

到了第 n 步, 检查前 n 步是否有一次落入 B , 就能判断是否已经到达, 因此

$$\{\tau_B \leq n\} = \bigcup_{k=0}^n \{X_k \in B\} \in \mathcal{F}_n.$$

这证明了 τ_B 是停时.

连续时间不能直接把这个有限并换成不可数并, 因为 σ -代数只保证对可数并封闭. 若 X 是具有连续路径的实值适应过程, 则对常数 a ,

$$\tau_a = \inf\{t \geq 0 : X_t \geq a\}$$

仍是停时. 此时是否在 t 以前到达, 等价于是否有 $\sup_{s \leq t} X_s \geq a$; 连续性又使这个上确界可以通过稠密的有理时刻计算, 必要时加入端点. 因此只需可数次观测, 就能证明相应事件属于 $\mathcal{F}_t$.

定义 3.19 (停时处的信息与停止过程).

对停时 τ , 定义

$$\mathcal{F}_\tau = \{A \in \mathcal{F} : A \cap \{\tau \leq t\} \in \mathcal{F}_t \text{ 对所有 } t\}.$$

$\mathcal{F}_\tau$ 表示停止时已经获得的信息. 过程 X 在 τ 处停止后得到

$$X_t^\tau = X_{t \wedge \tau},$$

称为停止过程.

$\mathcal{F}_\tau$ 的定义把随机时刻的问题改写成确定时刻的问题: 对于每个 t , 如果停止已经发生, 那么事件 A 是否发生也应该已经能够判断. 停止过程则更直观: 在 τ 以前照常运行, 从 τ 开始一直保持停止时的值.

离散时间中, 停止后的过程仍然适应. 连续时间中, 对这里使用的连续或右连续适应过程, 这一点也成立; 若只给出一般适应性而没有进一步的路径或联合可测性条件, 就不能直接略过证明.

注 3.20.

首次到达与最后一次到达有根本区别. 到达某个价位时, 我们能够知道它是不是第一次, 因为这只需查看过去; 通常却无法知道它是不是最后一次, 因为未来还可能再次到达. 因此“最后一次达到某个价位”通常不是停时. 停时并非任意一个随机选出的时间, 而是能够依照当时信息执行的停止规则.

3.4 Markov 过程: 当前状态能否代表过去

知道截至当前的全部历史以后, 我们原则上可以据此计算未来的条件分布. 但有时这段历史不必全部保留. 例如, 随机游走的下一步由当前位置加上一个新的独立增量得到; 已经知道当前位置, 再补上更早的行走记录, 并不会改变下一步的分布.

Markov 性把这种情形一般化: 给定当前状态以后, 过去的其他信息不再改变未来的条件分布. 这里重要的不是“过程没有过去”, 而是“当前状态已经包含预测未来所需的过去信息”. 先用转移核写出从一个状态走向另一些状态的概率, 再给出正式定义.

转移核与 Markov 性**定义 3.21 (转移核).**

设 $(E, \mathcal{E})$ 为状态空间. 一个从 E 到 E 的转移核是映射

$$K: E \times \mathcal{E} \rightarrow [0, 1],$$

满足:

1. 固定 $x \in E$ 时, $A \mapsto K(x, A)$ 是 E 上的概率测度;
2. 固定 $A \in \mathcal{E}$ 时, $x \mapsto K(x, A)$ 是可测函数.

$K(x, A)$ 表示当前状态为 x 时, 下一步落入集合 A 的条件概率.

定义 3.22 (离散时间 Markov 性).

适应过程 $X = (X_n)_{n \geq 0}$ 称为关于滤过 $(\mathcal{F}_n)$ 的 Markov 过程, 如果存在转移核 K_n , 使对所有 $A \in \mathcal{E}$,

$$\mathbb{P}(X_{n+1} \in A \mid \mathcal{F}_n) = K_n(X_n, A) \quad \text{a.s.}$$

如果 K_n 不依赖于 n , 则称过程时间齐次, 并把共同的核记为 K .

在自然滤过下, 上式就是

$$\mathbb{P}(X_{n+1} \in A \mid X_0, \dots, X_n) = \mathbb{P}(X_{n+1} \in A \mid X_n).$$

左边使用全部历史预测下一步, 右边只使用当前位置; Markov 性要求两者给出相同的答案. 它并没

有要求过去与未来独立. 未来当然可以依赖现在, 而现在也依赖过去; 被排除的是在已经给定现在以后, 更早历史仍提供额外的预测信息.

这也说明 Markov 性与状态的选择有关. 如果只记录一个不足以概括预测信息的量, 遗漏的信息就可能通过历史继续起作用. 把必要的量加入状态, 有时能够恢复 Markov 性; 但这需要证明, 不能仅凭把更多变量放在一起就宣布成立.

例 3.23 (随机游走的转移核).

对前面的随机游走,

$$K(x, \{x+1\}) = p, \quad K(x, \{x-1\}) = 1-p.$$

下一步只由当前位置和新的独立增量决定, 因而 S 是时间齐次 Markov 链. 但当 $p \neq 1/2$ 时它具有漂移, 所以 Markov 性并不自动推出鞅性.

Chapman–Kolmogorov 方程 令 $K^m(x, A)$ 表示从 x 出发经过 m 步以后落入 A 的概率. 约定 $K^0(x, A) = \mathbf{1}_A(x)$.

定理 3.24 (Chapman–Kolmogorov 方程).

对时间齐次 Markov 链,

$$K^{m+n}(x, A) = \int_E K^m(x, dy) K^n(y, A), \quad m, n \in \mathbb{N}_0.$$

证明. 先在第 m 步的状态上取条件. 由 Markov 性, 若此时位于 y , 再经过 n 步落入 A 的概率就是 $K^n(y, A)$, 不必继续知道到达 y 以前的历史. 而从 x 出发, 第 m 步状态的分布为 $K^m(x, dy)$. 对这个中间状态取平均, 也就是应用条件期望的塔性质, 便得到右边的积分. 当 $m=0$ 或 $n=0$ 时, 结论由 $K^0(x, A) = \mathbf{1}_A(x)$ 同样成立. $\square$

因此, 右边不是把两个概率直接相乘, 而是先固定中间状态相乘, 再把所有可能的中间状态加总. 在有限状态空间上, 积分成为有限求和, 整个方程就是转移矩阵的乘法.

例 3.25 (两状态市场环境).

为演示计算, 假设一个模型只区分活跃和低迷两种环境, 记状态空间为

$$E = \{B, S\},$$

并假定每期都使用同一个转移矩阵

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix}.$$

行对应当前环境, 列对应下一期环境. 例如, 当前活跃时, 下一期仍活跃的概率为 0.8, 转为低迷的概率为 0.2.

经过两期后的概率由矩阵乘法给出:

$$P^2 = \begin{pmatrix} 0.70 & 0.30 \\ 0.45 & 0.55 \end{pmatrix}.$$

第一行第一列包含两条互斥的路线: 先保持活跃, 再保持活跃; 或先转为低迷, 再回到活跃. 因此

$$0.8 \times 0.8 + 0.2 \times 0.3 = 0.70.$$

因此, 从活跃状态出发两期后仍处于活跃状态的概率为 0.70. 这个有限状态计算正是 Chapman–Kolmogorov 方程对中间状态求和的矩阵形式.

连续时间的想法相同，只是不再有一个固定长度的“下一步”。我们要从任意确定时刻 s 预测任意较晚时刻 t ，因此使用一族转移核 $P_{s,t}$ 。若过程时间齐次，经过多长时间才是关键，核便只依赖于 $t - s$ 。

定义 3.26 (连续时间 Markov 性).

设 $X = (X_t)_{t \geq 0}$ 是取值于 $(E, \mathcal{E})$ 且适应于 $(\mathcal{F}_t)_{t \geq 0}$ 的过程。如果对每个 $0 \leq s \leq t$ 都存在从 E 到 E 的转移核 $P_{s,t}$ ，使每个有界可测函数 f 都满足

$$\mathbb{E}[f(X_t) | \mathcal{F}_s] = P_{s,t}f(X_s) \quad \text{a.s.}, \quad P_{s,t}f(x) := \int_E f(y)P_{s,t}(x, dy),$$

则称 X 关于该滤过具有**连续时间 Markov 性**。若 $P_{s,t}$ 只依赖于时间差 $t - s$ ，即 $P_{s,t} = P_{t-s}$ ，则称过程时间齐次。

这里用有界可测函数 f 表述条件，与只写事件概率是等价的：取 $f = \mathbf{1}_A$ 就恢复概率形式。 $P_{s,t}f(X_s)$ 表示从当前状态 X_s 出发计算未来 $f(X_t)$ 的平均值。Markov 性说的是，一旦给定 X_s ，再利用 $\mathcal{F}_s$ 中的其他信息也不会改变这个平均值。

对时间齐次过程，设给定从各个状态出发的 Markov 家族 $(\mathbb{P}_x)_{x \in E}$ ，其中 $\mathbb{P}_x(X_0 = x) = 1$ ，并以 $\mathbb{E}_x$ 表示相应期望。把转移核作用在函数上，就得到

$$P_t f(x) = \mathbb{E}_x[f(X_t)], \quad P_{s+t} = P_s P_t.$$

半群等式仍是 Chapman–Kolmogorov 方程：先把未来 t 单位时间后的函数值取平均，再对前面 s 单位时间的变化取平均，与一次计算 $s + t$ 单位时间后的平均值相同。第 4.7 节将进一步研究这个平均值在极短时间内怎样变化，由此引入生成元，Kolmogorov 方程和 Feynman–Kac 公式。

注 3.27 (强 Markov 性把 Markov 思想带回停时).

上面的连续时间定义只对预先指定的时刻作了保证。但首次到达时刻是观察路径后才确定的，不能直接把定义中的 s 换成 τ 就算证明完毕。若在停时发生以后，给定停止时的状态，未来仍按照从该状态出发的转移规律演化，就称为**强 Markov 性**。

在通常使用的滤过下，标准 Markov 链，Poisson 过程和 Brown 运动都具有这一性质。它使我们能够在首次到达以后重新开始分析，例如研究下一次等待时间或反射后的路径。一般连续时间过程中，强 Markov 性仍须由额外假设或定理保证，不能仅凭普通 Markov 性直接断言。

3.5 鞅：条件平均下没有可预测漂移

鞅，下鞅与上鞅 Markov 性问的是：预测未来分布时，需要保留多少历史？鞅问的是另一件事：使用当前的全部信息以后，未来值的条件平均是否仍等于当前值？前者限制条件分布依赖什么，后者规定这个条件分布的均值。

因此，两者不能互相替代。一个 Markov 过程可以具有向上的平均漂移；一个鞅的未来波动幅度或分布形状也可以依赖历史，只要这种依赖没有使未来值的条件平均偏离当前值。

定义 3.28 (离散时间鞅).

设 $X = (X_n)_{n \geq 0}$ 适应于 $(\mathcal{F}_n)$ ，并且每个 X_n 都可积。

1. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n \quad \text{a.s.},$$

则称 X 为**鞅**。

2. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] \geq X_n \quad \text{a.s.},$$

则称 X 为**下鞅**。

3. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] \leq X_n \quad \text{a.s.},$$

则称 X 为**上鞅**。

定义 3.29 (连续时间鞅).

设 $X = (X_t)_{t \geq 0}$ 适应于 $(\mathcal{F}_t)_{t \geq 0}$, 并且每个 X_t 都可积. 如果对所有 $0 \leq s \leq t$ 都有

$$\mathbb{E}[X_t | \mathcal{F}_s] = X_s \quad \text{a.s.},$$

则称 X 为关于该滤过的**连续时间鞅**. 把等号分别改为 $\geq$ 和 $\leq$, 就得到连续时间下鞅和上鞅.

离散时间的定义只写了一步, 但反复使用条件期望的塔性质, 就得到对所有 $m \leq n$,

$$\mathbb{E}[X_n | \mathcal{F}_m] = X_m.$$

所以, 不论向前看一步还是多步, 只要使用的仍是时刻 m 的信息, 条件平均都停留在 X_m . 这也是把鞅比作“公平游戏”的原因.

鞅性只限制条件平均, 并不要求每条路径保持不变, 也不要求未来与过去独立. 条件期望同时依赖概率测度和滤过: 前者规定怎样加权各种结果, 后者规定取条件平均时已经知道哪些事件. 因而同一个坐标过程换了测度或信息结构以后, 鞅性也可能改变.

例 3.30 (有漂移与无漂移随机游走).

对随机游走 $S_n = \sum_{k=1}^n \xi_k$, 使用它的自然滤过. 到了第 n 步, S_n 已经知道; 新的独立增量的平均值为 $2p - 1$, 所以

$$\mathbb{E}[S_{n+1} | \mathcal{F}_n] = S_n + (2p - 1).$$

特别地,

$$p = \frac{1}{2} \implies S \text{ 是鞅}.$$

当 $p > 1/2$ 时, 下一步的条件平均高于当前位置, S 是下鞅; 当 $p < 1/2$ 时则低于当前位置, S 是上鞅.

每一步扣去已知的平均增量 $2p - 1$, 便得到

$$M_n = S_n - n(2p - 1).$$

这个过程对任意 p 都是鞅. 扣去的只是平均漂移, 并没有消除路径上的随机起伏.

命题 3.31 (可预测变换).

设 M 是离散时间鞅, $H = (H_n)_{n \geq 1}$ 是有界可预测过程. 定义

$$(H \cdot M)_n = \sum_{k=1}^n H_k (M_k - M_{k-1}).$$

那么 $(H \cdot M)_n$ 也是鞅.

证明. 有界性保证 $H_k(M_k - M_{k-1})$ 可积, 可预测性则保证在第 k 步开始前, 系数 H_k 已经知道. 因此它可以从关于 $\mathcal{F}_{k-1}$ 的条件期望中提出:

$$\begin{aligned} \mathbb{E}[H_k(M_k - M_{k-1}) | \mathcal{F}_{k-1}] &= H_k \mathbb{E}[M_k - M_{k-1} | \mathcal{F}_{k-1}] \\ &= 0. \end{aligned}$$

最后一项为零, 是因为 M 为鞅. 变换后过程的每一步增量恰好就是左边括号中的乘积, 所以它仍然适应, 可积, 且每一步增量的条件平均为零, 即仍为鞅. $\square$

证明的关键正是 H_k 在第 k 个增量出现以前已经确定. 因为 H_k 是 $\mathcal{F}_{k-1}$ -可测的, 才能把它从条件期望中提出. 若先看到 $M_k - M_{k-1}$ 再选择 H_k , 上面的等式便没有这个依据.

若把 H_k 看成第 k 期的持仓, 命题说明: 对鞅增量作有界的可预测加权以后, 累计增益仍是鞅. 这正是离散时间随机积分最基本的形式.

离散时间 Doob 分解 对有漂移的随机游走, 我们扣去了每一步的平均增量. 一般下鞅也可以这样处理, 只是每一步该扣多少, 可能依赖当时的历史. Doob 分解的做法是: 在第 k 步开始以前, 先计算这一增量的条件平均, 把它记入 A ; 实际增量减去这个平均以后, 剩下的部分就没有条件漂移.

定理 3.32 (离散时间 Doob 分解).

设 $X = (X_n)_{n \geq 0}$ 是可积下鞅. 定义

$$A_0 = 0, \quad A_n = \sum_{k=1}^n \mathbb{E}[X_k - X_{k-1} | \mathcal{F}_{k-1}],$$

并令

$$M_n = X_n - A_n.$$

那么 M 是鞅, A 是从 0 开始的可积可预测递增过程, 且

$$X_n = M_n + A_n.$$

在要求 $A_0 = 0$ 的条件下, 这个分解唯一.

证明. 下鞅性恰好保证每一步所扣的条件平均非负:

$$\mathbb{E}[X_k - X_{k-1} | \mathcal{F}_{k-1}] \geq 0.$$

因而这些量的累计 A 递增. 第 k 步增加多少, 在 $\mathcal{F}_{k-1}$ 下已经可知, 所以 A 可预测; 条件期望的可积性也保证每个 A_n 可积.

从 X 中扣去 A , 正好消除了每一步的条件平均:

$$\begin{aligned} \mathbb{E}[M_k - M_{k-1} | \mathcal{F}_{k-1}] &= \mathbb{E}[X_k - X_{k-1} | \mathcal{F}_{k-1}] \\ &\quad - (A_k - A_{k-1}) = 0. \end{aligned}$$

因此 M 是鞅.

再看唯一性. 若另有 $X = M' + A'$ 满足同样的要求, 则 $D = A - A' = M' - M$ 同时是可预测过程和鞅, 且 $D_0 = 0$. 由于 $D_k - D_{k-1}$ 在第 $k-1$ 步已经可知, 它的条件期望等于自身; 由于 D 是鞅, 同一个条件期望又必须为零. 所以每一步增量都为零, D 恒为零, 两个分解相同. $\square$

对上鞅应用同样的思路, 便得到

$$X_n = M_n - A_n,$$

其中 A 从 0 出发, 可预测且递增. 两种情形都把条件平均的累计与剩余波动分开了. 第 4.2 节中的半鞅分解将采用相似的思路, 用局部鞅处理随机波动, 用有限变差过程处理另一部分累计变化.

把鞅带到随机时刻 鞅在每个确定时刻保持期望, 但如果我们观察路径, 选择一个有利的时刻停止呢? 这时不能直接把定义中的时间下标替换成停时, 因为停止规则本身依赖过程.

有界停时的关键是: 是否继续承受下一步增量, 在这一步开始以前就已经决定. 因此, 停止仍是一种可预测地选取增量的方式. 无界停时则多出一个极限问题: 先在第 n 步强制停止, 再令 n 增大, 是否还能把期望传到极限? 后面所需的尾部条件正是为这一步服务.

定理 3.33 (有界停时的可选抽样).

设 $M = (M_n)_{n \geq 0}$ 是离散时间鞅, $\sigma \leq \tau$ 是两个有界停时. 那么

$$\mathbb{E}[M_\tau | \mathcal{F}_\sigma] = M_\sigma \quad \text{a.s.},$$

从而

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_\sigma].$$

对下鞅, 相应等号改为 $\geq$; 对上鞅改为 $\leq$.

证明. 取确定的 N 使 $\tau \leq N$. 由于只会选取 $M_0, \dots, M_N$ 中的值, M_σ 与 M_τ 都可积, 且 M_σ 为 $\mathcal{F}_\sigma$ -可测. 要证明条件期望等式, 只需对任意 $A \in \mathcal{F}_\sigma$ 验证相应积分相等.

先把两次停止之间的变化拆成单步增量:

$$M_\tau - M_\sigma = \sum_{k=1}^N \mathbf{1}_{\{\sigma < k \leq \tau\}} (M_k - M_{k-1}).$$

第 k 个增量是否计入, 只取决于第 $k-1$ 步时是否已经过了 σ , 以及是否尚未在 τ 停止. 这两件事当时都能判断. 严格地说, $\{\sigma < k\} = \{\sigma \leq k-1\}$, $\{\tau \geq k\} = \{\tau \leq k-1\}^c$, 而 $A \in \mathcal{F}_\sigma$ 又保证 $A \cap \{\sigma \leq k-1\} \in \mathcal{F}_{k-1}$. 所以 $A \cap \{\sigma < k \leq \tau\} \in \mathcal{F}_{k-1}$.

现在对第 k 个增量先取关于 $\mathcal{F}_{k-1}$ 的条件期望. 指示函数可以提出, 鞅增量的条件平均为零, 于是

$$\mathbb{E}[\mathbf{1}_A \mathbf{1}_{\{\sigma < k \leq \tau\}} (M_k - M_{k-1})] = 0.$$

有限求和得到 $\mathbb{E}[\mathbf{1}_A (M_\tau - M_\sigma)] = 0$. 这对每个 $A \in \mathcal{F}_\sigma$ 都成立, 因此 $\mathbb{E}[M_\tau | \mathcal{F}_\sigma] = M_\sigma$. 对下鞅或上鞅, 只需在同一位置保留相应方向的不等式. 更一般的离散可选抽样形式见 [Kal21, Theorem 9.12]. $\square$

注 3.34 (无界停时还要看尾部).

若 $\tau < \infty$ a.s., 则对几乎每条路径, $M_{\tau \wedge n}$ 最终都会等于 M_τ . 但逐路径收敛不保证期望收敛: 越来越少的路径可能承受越来越大的取值, 它们对期望的贡献不能只凭发生概率很小就忽略.

对离散时间鞅, 一组常用的充分条件是 $\tau < \infty$ a.s., 并且停止族

$$\{M_{\tau \wedge n} : n \geq 0\}$$

一致可积. 此时收敛可加强为 L^1 收敛, 所以能够从每个有界停时的等式传到极限, 得到

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_0].$$

另一组便于验证的充分条件是: 增量满足统一上界 $|M_n - M_{n-1}| \leq C$, 并且 $\mathbb{E}[\tau] < \infty$. 两者合起来给出可积控制 $|M_{\tau \wedge n}| \leq |M_0| + C\tau$, 因而可以使用控制收敛. 只知道增量有界, 或只知道停时几乎必然有限, 都不能代替这组条件.

非负性也不能自动保住等号. 若只知道 $M_n \geq 0$ 和 $\tau < \infty$ a.s., Fatou 引理一般只能推出

$$\mathbb{E}[M_\tau] \leq \mathbb{E}[M_0].$$

若停止族再一致可积, 才可恢复等号. 问题不在于停止规则是否合法, 而在于从截断停时走向无界停时时, 是否有足够的可积性允许交换极限与期望.

例 3.35 (赌徒破产与首次到达).

设 (S_n) 是简单对称随机游走, 从 $S_0 = i \in \{1, \dots, N-1\}$ 出发, 在首次到达 0 或 N 时停止:

$$\tau = \inf\{n \geq 0 : S_n \in \{0, N\}\}.$$

我们要计算先到达 N 而不是 0 的概率. 停止以后只剩两个可能值, 因此只要知道停止值的期望, 就能求出这个概率.

先对有界停时 $\tau \wedge m$ 应用可选抽样:

$$\mathbb{E}[S_{\tau \wedge m}] = i.$$

接着验证能否令 $m \rightarrow \infty$. 从区间内任意位置出发, 接下来连续 N 步向左的概率都是 2^{-N} , 且这必然使过程在这段时间内触及 0. 因而每经过 N 步, 仍未吸收的条件概率都有一个严格小于 1 的统一上界; 不断重复便知 τ 几乎必然有限.

又因为停止前不会越出区间, 始终有 $0 \leq S_{\tau \wedge m} \leq N$. 控制收敛因此给出

$$\mathbb{E}[S_\tau] = i.$$

最后, S_τ 只取 0 或 N , 所以其期望等于 N 乘以到达 N 的概率, 即

$$\mathbb{P}_i(S_\tau = N) = \frac{i}{N}.$$

这里不是直接对无界的 τ 使用定理, 而是先截断, 再明确验证极限所需的条件.

注 3.36.

翻倍下注之所以看起来能够保证获利, 是因为只看第一次赢时的结果: 这一笔收入可以覆盖此前损失. 但连续输时, 所需下注和已经承受的损失都在迅速增加. 对截断后的策略取极限, 不能忽略那些尚未赢过的路径; 它们正可能使停止族失去一致可积性. 因此“最终停止时赚钱”并不能推翻可选抽样, 反而说明必须检查定理的假设. 现实中的资金限额还会使策略在第一次赢以前就被迫结束.

3.6 计数过程与 Poisson 过程

有些随机现象天然按事件计数. 一次订单到达, 一次违约或一次设备故障都会使累计次数增加; 两次事件之间, 计数保持不变. 用 N_t 表示截至时刻 t 已经发生的事件数, 就得到计数过程的基本形状.

从累计次数到 Poisson 过程 计数取非负整数值并且不会减少. 本文还约定事件若恰在时刻 t 发生, N_t 已经包含这次事件, 因而采用右连续路径.

定义 3.37 (计数过程).

一个计数过程是过程 $N = (N_t)_{t \geq 0}$, 满足:

1. $N_0 = 0$;
2. 样本路径取非负整数值并且单调不减;
3. 样本路径右连续且有左极限.

如果每次跳跃的大小都为 1, 则称它是简单计数过程.

计数过程的定义只规定路径怎样记录累计次数, 尚未规定不同时间段内的事件怎样分布. Poisson 过程再加入独立且平稳的增量规律, 从而得到一类可以明确计算的计数模型.

定义 3.38 (Poisson 过程).

设 $\lambda > 0$. 计数过程 $N = (N_t)_{t \geq 0}$ 称为强度 λ 的 **Poisson 过程**, 如果:

1. $N_0 = 0$ a.s.;
2. 它具有独立增量;
3. 对任意 $0 \leq s < t$,

$$N_t - N_s \sim \text{Poisson}(\lambda(t - s)).$$

参数 λ 表示单位时间内的平均到达次数. 长度为 t 的区间内, 计数的分布及其前两阶矩为

$$N_t \sim \text{Poisson}(\lambda t), \quad \mathbb{E}[N_t] = \lambda t, \quad \text{Var}(N_t) = \lambda t.$$

这里不仅规定了平均次数, 还规定了方差必须等于平均值, 以及不同时段怎样相互依赖. 平稳增量说, 同样长的区间具有同样的计数分布; 独立增量说, 不相交区间内发生多少次互不影响. 一个递增的整数值过程并不会自动具有这些性质, 它们都是齐次 Poisson 模型增加的假设.

等待时间 定义第 n 次到达时刻和相邻到达之间的等待时间:

$$T_n = \inf\{t \geq 0 : N_t \geq n\}, \quad W_n = T_n - T_{n-1}, \quad T_0 = 0.$$

定理 3.39 (Poisson 到达与指数等待).

如果 N 是强度 λ 的 Poisson 过程, 那么 $W_1, W_2, \dots$ 独立同分布, 且

$$W_n \sim \text{Exp}(\lambda).$$

因而

$$\mathbb{P}(W_1 > t) = e^{-\lambda t}, \quad \mathbb{E}[W_1] = \frac{1}{\lambda}.$$

第 n 次到达时刻满足

$$T_n = W_1 + \dots + W_n \sim \text{Gamma}(n, \lambda),$$

这里采用 rate 参数化.

证明. 第一次到达晚于 t , 当且仅当截至 t 一次事件也没有发生, 因此

$$\mathbb{P}(T_1 > t) = \mathbb{P}(N_t = 0) = e^{-\lambda t}.$$

这就是强度为 λ 的指数分布的生存函数, 也说明第一次到达几乎必然有限.

对后续等待时间, 需要把过程重新开始的时刻放在随机的到达时刻, 而不只是确定时刻. 利用前文所述 Poisson 过程的强 Markov 性, 每次到达以后新增的计数过程, 都与截至该次到达的历史独立, 并且仍是强度 λ 的 Poisson 过程. 因而下一次等待又有同一个指数分布. 逐次应用便得到全部等待时间的独立同分布性. n 个独立的同参数指数变量之和具有 $\text{Gamma}(n, \lambda)$ 分布, 于是得到到达时刻的结论. $\square$

指数等待还满足无记忆性:

$$\mathbb{P}(W_1 > s + t \mid W_1 > s) = \mathbb{P}(W_1 > t).$$

已经等待了 s 而仍未发生到达以后, 从此刻起继续等待的时间仍服从原来的指数分布. 已经过的时间当然仍然是 s ; 无记忆性说的是它不改变剩余等待时间的条件分布.

叠加, 稀疏化与补偿

定理 3.40 (叠加与稀疏化).

1. 如果 $N^{(1)}, \dots, N^{(m)}$ 相互独立, 且分别是强度 $\lambda_1, \dots, \lambda_m$ 的 Poisson 过程, 那么

$$N_t = \sum_{j=1}^m N_t^{(j)}$$

是强度 $\lambda_1 + \dots + \lambda_m$ 的 Poisson 过程.

2. 如果把强度 λ 的 Poisson 过程中的每次到达独立地以概率 p 标记为第 I 类, 以概率 $1 - p$ 标记为第 II 类, 那么两类计数过程相互独立, 且强度分别为 $p\lambda$ 和 $(1 - p)\lambda$.

证明. 对叠加, 任意区间内的总到达数是独立 Poisson 随机变量之和, 所以仍为 Poisson 分布, 参数等于各参数之和. 不相交区间内的总计数仍然独立, 因而得到了所述 Poisson 过程.

对稀疏化, 取长度为 h 的区间. 给定总到达数为 n , 两类计数的联合概率生成函数是 $(pz + (1 - p)w)^n$. 再对 Poisson 总次数取平均, 得到

$$\exp(\lambda h(pz + (1 - p)w - 1)) = \exp(p\lambda h(z - 1)) \exp((1 - p)\lambda h(w - 1)).$$

右边分成两个 Poisson 概率生成函数的乘积, 所以两类计数独立, 参数分别为 $p\lambda h$ 与 $(1 - p)\lambda h$. 原过程在不相交区间上的独立增量, 加上各次标记的独立性, 又保证分出的两个过程具有所需的独立增量性质. $\square$

叠加把多个独立 Poisson 来源合成一个总计数, 强度相加. 稀疏化则把每次到达独立分类, 使总强度按固定概率 p 和 $1-p$ 分到两个独立过程. 给定总次数时, 两类数量当然彼此制约; 对随机的 Poisson 总次数一起平均以后, 联合生成函数才分解成两个独立 Poisson 因子. 第二项因此确实用了各次标记相互独立且采用固定概率.

无论怎样叠加或稀疏化, 强度仍然决定平均计数. 对原来的强度 λ 过程, $\mathbb{E}[N_t] = \lambda t$. 把这条确定的平均增长从实际计数中减掉, 就得到下面的补偿 Poisson 鞅.

命题 3.41 (补偿 Poisson 鞅).

令 N 是强度 λ 的 Poisson 过程, $(\mathcal{F}_t^N)$ 为其自然滤过. 则

$$M_t = N_t - \lambda t$$

是关于 $(\mathcal{F}_t^N)$ 的鞅.

证明. 对 $0 \leq s < t$, 由独立增量, $N_t - N_s$ 与 $\mathcal{F}_s^N$ 独立, 且期望为 $\lambda(t-s)$. 因而

$$\begin{aligned}\mathbb{E}[M_t | \mathcal{F}_s^N] &= N_s - \lambda t + \mathbb{E}[N_t - N_s | \mathcal{F}_s^N] \\ &= N_s - \lambda t + \lambda(t-s) = M_s.\end{aligned}$$

□

N_t 随到达次数增加, 当然不是平均不变的过程. 扣去 λt , 就是扣去模型预期截至 t 应当累计的次数. 没有事件到达时, $N_t - \lambda t$ 以斜率 $-\lambda$ 下降; 发生到达时, 它向上跳跃. 两种变化在条件平均下恰好抵消, 因此得到鞅.

这与 Doob 分解的思路相同: 把可预测的平均累计从实际过程里分出来. 更一般的点过程可以让条件强度依赖时间和历史; 在相应条件下, 将这种强度沿时间积分, 就得到应当扣除的补偿子.

3.7 Brown 运动

定义与 Gauss 增量 Poisson 过程在事件到达时跳跃, 其余时间保持不变. Brown 运动的路径没有跳跃, 却在任意短的时间尺度上仍有随机变化. 它用均值为零, 方差与区间长度成正比的独立 Gauss 增量, 给出了连续噪声的一个基本模型. 路径连续性也必须明确要求, 不能只从增量分布中略去.

定义 3.42 (标准 Brown 运动).

在滤过概率空间 $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$ 上, 实值过程 $W = (W_t)_{t \geq 0}$ 称为关于该滤过的 **标准 Brown 运动**, 如果:

1. $W_0 = 0$ a.s.;
2. W 适应于 $(\mathcal{F}_t)$;
3. 对任意 $0 \leq s < t$,

$$W_t - W_s \sim \mathcal{N}(0, t-s),$$

并且 $W_t - W_s$ 与 $\mathcal{F}_s$ 独立;

4. 样本路径几乎必然连续.

定义中的独立性是相对于 $\mathcal{F}_s$ 说的: 从 s 以后新发生的增量, 与时刻 s 已有的全部信息独立. 取自然滤过时, 这就是未来增量与过程自身的过去独立. 若把某个未来值提前放进滤过, 同一条坐标过程可能不再满足这个条件, 因此不能脱离滤过单独谈这里的 Brown 性.

把若干时刻按先后顺序排列, 每个 W_{t_k} 都是此前若干独立 Gauss 增量的和. 因而对任意 $t_1, \dots, t_n$,

$$(W_{t_1}, \dots, W_{t_n})$$

服从多元正态分布, 所以 Brown 运动是 Gauss 过程. 它满足

$$\mathbb{E}[W_t] = 0, \quad \text{Cov}(W_s, W_t) = \min(s, t).$$

例如 $0 \leq s \leq t$ 时,

$$W_t = W_s + (W_t - W_s),$$

而增量 $W_t - W_s$ 与 W_s 独立且均值为零, 所以 $\text{Cov}(W_s, W_t) = \text{Var}(W_s) = s$. 交换 s, t 的位置, 就得到 $\min(s, t)$ 的一般形式.

反过来, 若中心 Gauss 过程具有这一协方差, 两个不相交区间上的增量协方差为零. 这些增量联合服从 Gauss 分布, 因而相互独立. 再取它的连续修正, 并使用自然滤过或通常增广的自然滤过, 就得到标准 Brown 运动.

例 3.43 (增量与水平并不独立).

当 $0 < s < t$ 时, 增量 $W_t - W_s$ 与过去 $\mathcal{F}_s$ 独立, 但水平 W_t 与 W_s 并不独立, 因为

$$\text{Cov}(W_s, W_t) = s.$$

这里的独立性适用于不相交区间上的增量, 不适用于不同时刻的过程水平.

缩放, Markov 性与鞅性

命题 3.44 (Brown 缩放).

对任意常数 $c > 0$, 定义缩放后的滤过与过程

$$\tilde{\mathcal{F}}_t = \mathcal{F}_{ct}, \quad \tilde{W}_t = \frac{1}{\sqrt{c}} W_{ct}, \quad t \geq 0,$$

则 $\tilde{W}$ 是关于 $(\tilde{\mathcal{F}}_t)_{t \geq 0}$ 的标准 Brown 运动. 因而在过程律意义下,

$$(\tilde{W}_t)_{t \geq 0} \stackrel{d}{=} (W_t)_{t \geq 0}.$$

证明. 时间变换保留路径连续性, 并使 $\tilde{W}_t$ 适应于 $\mathcal{F}_{ct}$. 对 $s < t$, 缩放后的增量为 $(W_{ct} - W_{cs})/\sqrt{c}$, 它与 $\mathcal{F}_{cs}$ 独立, 均值为零, 方差为 $c(t-s)/c = t-s$. 连同初值为零, 这正好验证了相对于 $\tilde{\mathcal{F}}_t = \mathcal{F}_{ct}$ 的 Brown 运动定义. $\square$

Brown 运动把时间扩大 c 倍后, 若同时把空间除以 $\sqrt{c}$, 得到的过程仍具有同一个过程律. 这里相等的是随机过程的分布, 并不是把某条样本路径缩放以后会得到原来的那条路径. 平方根尺度直接来自增量方差: 长度为 $c(t-s)$ 的区间方差扩大 c 倍, 标准差因而扩大 $\sqrt{c}$ 倍.

命题 3.45 (Brown 运动的 Markov 性与基本鞅).

标准 Brown 运动是时间齐次 Markov 过程, 当 $t > 0$ 时其转移核为

$$P_t(x, A) = \int_A \frac{1}{\sqrt{2\pi t}} \exp\left(-\frac{(y-x)^2}{2t}\right) dy.$$

此外,

$$W_t \quad \text{和} \quad W_t^2 - t$$

都是鞅.

证明. 对 $0 \leq s < t$, 写成

$$W_t = W_s + (W_t - W_s).$$

后一项独立于 $\mathcal{F}_s$, 且服从 $\mathcal{N}(0, t-s)$, 所以给定当前状态 W_s 后, 未来分布不再依赖更早历史, 这给出 Markov 性. 同时

$$\mathbb{E}[W_t | \mathcal{F}_s] = W_s.$$

再利用 $\mathbb{E}[(W_t - W_s)^2] = t-s$ 和交叉项条件期望为 0, 得到

$$\mathbb{E}[W_t^2 - t | \mathcal{F}_s] = W_s^2 - s.$$

$\square$

反射原理与首次到达 设

$$\tau_a = \inf\{t \geq 0 : W_t = a\}, \quad a > 0.$$

连续性保证“达到或超过 a ”之前一定先命中 a .

定理 3.46 (反射原理).

对 $a > 0$ 和 $t > 0$,

$$\mathbb{P}\left(\sup_{0 \leq s \leq t} W_s \geq a\right) = 2\mathbb{P}(W_t \geq a) = 2\left(1 - \Phi\left(\frac{a}{\sqrt{t}}\right)\right),$$

其中 Φ 为标准正态分布函数. 等价地,

$$\mathbb{P}(\tau_a \leq t) = 2\left(1 - \Phi\left(\frac{a}{\sqrt{t}}\right)\right).$$

证明. 把截至 t 曾经命中 a 的路径分成两类: 终点在 a 以下, 或终点在 a 以上. 对第一类路径, 保留首次命中 a 以前的部分, 把命中以后的整段路径关于水平线 a 反射. 终点便从 a 以下变成 a 以上. 反射两次恢复原路径, 因此这是一个一一对应. 反过来, 终点高于 a 的路径由连续性必然已经命中过 a , 所以不会遗漏第二类中的路径.

一一对应本身还不足以说明两类路径等概率. 这里还要使用强 Markov 性: 从首次命中时刻起, 后续相对于 a 的增量重新具有 Brown 运动的规律; Brown 增量关于零对称, 所以把这些增量全部变号不改变概率律. 因而两类路径的概率相同.

W_t 在 a 处没有原子, 所以终点恰等于 a 不影响概率. 把两类相加, 便得到命中过 a 的概率是 $\mathbb{P}(W_t \geq a)$ 的两倍. 最后使用 $W_t \sim \mathcal{N}(0, t)$, 得到标准正态尾概率的表达式. $\square$

例 3.47 (触及障碍与到期终值).

取 $a > 0$ 和 $t > 0$. 事件

$$\left\{\sup_{0 \leq s \leq t} W_s \geq a\right\}$$

记录的是路径在 $[0, t]$ 内有没有达到过 a . 它与终值事件 $\{W_t \geq a\}$ 不同: 路径完全可能先越过 a , 到时刻 t 又回到 a 以下. 反射原理利用首次命中后的路径对称性, 得到这两个不同事件的概率关系

$$\mathbb{P}\left(\sup_{0 \leq s \leq t} W_s \geq a\right) = 2\mathbb{P}(W_t \geq a).$$

因而一个依赖整段路径的首次到达问题, 在 Brown 运动中可以化为终值的正态尾概率计算.

Brown 路径的规则与不规则 Brown 路径连续, 但它远比普通光滑曲线粗糙. 下面汇总后续会使用的若干路径性质. 其中总变差的计算方法是: 先沿分割把各段绝对增量相加, 再对所有分割取上确界. 下一节会正式写出定义, 并与平方增量和比较.

定理 3.48 (Brown 运动的路径性质).

对标准 Brown 运动, 下列性质几乎必然成立:

1. 路径在每个有限区间上一致连续;
2. 路径处处不可微;
3. 路径在每个非退化区间上具有无限总变差;
4. 对每个 $0 < \alpha < 1/2$ 和每个固定的 $T < \infty$, 存在依赖于路径的有限常数 $C_{\alpha, T}$, 使

$$|W_t - W_s| \leq C_{\alpha, T}|t - s|^\alpha, \quad 0 \leq s, t \leq T.$$

这称为路径在紧区间上 α -Hölder 连续; 一般不能把指数提高到 $1/2$;

5. 沿二进分割 $t_k^{(n)} = kT/2^n$,

$$\sum_{k=0}^{2^n-1} \left(W_{t_{k+1}^{(n)}} - W_{t_k^{(n)}} \right)^2 \rightarrow T \quad \text{a.s.}$$

这些结论说明了几种不同程度的正则性, 所需的论证也不同. 第一条直接来自连续函数在紧区间上一致连续. 对于第四条, Gauss 增量具有任意阶矩, 且 p 阶绝对矩随时间间隔按 $p/2$ 次方缩放; 把高阶矩估计代入 Kolmogorov 连续性准则, 可以得到每个 $\alpha < 1/2$ 的 Hölder 连续性. 处处不可微则不能仅从“增量通常具有平方根尺度”推出, 还需要更精细的局部振荡估计. 精确结果见 [Kal21, Theorem 14.5 and Proposition 14.10] 以及 [Dur19, Theorems 7.1.5–7.1.6].

第五条可以直接从独立增量的矩计算看出. 沿 $[0, T]$ 的第 n 层二进分割, 平方增量和的期望为 T , 方差为 $2T^2 2^{-n}$. 方差关于 n 的和有限, 所以 Chebyshev 不等式与 Borel–Cantelli 引理给出几乎必然收敛到 T . 定理 4.6 将详细展开这一步, 并处理一般确定性分割及整个时间区间上的一致依概率收敛. 下一节还会证明, 连续有限变差路径的平方增量和只能趋于零; 与这里的非零极限比较, 就能推出 Brown 路径的无限总变差. 对有理端点区间取可数交, 再利用区间包含关系, 可把结论同时用于所有非退化区间.

路径连续只说明网格变细以后, 每一个小区间上的增量都会变小; 它没有说明所有平方增量加起来也趋于零. 对长度为 Δt 的 Brown 增量,

$$\mathbb{E}[(W_{t+\Delta t} - W_t)^2] = \Delta t.$$

若用等长小区间铺满总长度 T , 每项虽然越来越小, 项数却同时增加, 平方增量和的期望始终为 T . 上面的路径性质进一步说明, 沿二进分割时这个随机和本身几乎必然趋于 T .

从随机游走到 Brown 运动 Brown 运动也可以从越来越细的随机游走中得到. 简单对称随机游走每步的方差为 1; 若在单位时间内安排 n 步, 未经缩放的总方差就会增长到 n . 因此, 在把每步时间缩短为 $1/n$ 的同时, 把空间步长缩小为 $1/\sqrt{n}$, 恰好能保留单位时间内的方差尺度.

具体地, 先在网格点定义

$$W_{k/n}^{(n)} = \frac{1}{\sqrt{n}} S_k, \quad k = 0, 1, \dots,$$

再在相邻网格点之间作线性插值, 得到连续的随机折线. 随着 n 增大, 步长和时间间隔同时缩小; 下面的定理说明这些随机折线的分布趋向 Brown 运动.

定理 3.49 (Donsker 不变性原理).

在任意固定 $T < \infty$ 上, 上述过程 $W^{(n)}$ 在路径空间 $C([0, T])$ 中依分布收敛到标准 Brown 运动, 其中 $C([0, T])$ 采用一致拓扑.

固定一个时刻, 普通中心极限定理已经能解释为什么会出现正态分布. Donsker 定理更进一步: 收敛的是整个随机函数在 $C([0, T])$ 中的分布, 而不只是某个时刻的取值分布. 它并没有断言在同一概率空间中, 每条随机游走路径都会逐路径收敛到某条 Brown 路径.

证明分成两部分. 第一部分对任意有限组时刻使用多维中心极限定理, 证明这些坐标的联合分布趋于 Brown 运动相应的有限维分布. 第二部分证明路径分布的紧性, 排除随机折线在观测时刻之间出现越来越剧烈的振荡. 紧性保证任意子序列还能抽出一个弱收敛的子序列; 有限维分布的收敛再迫使每个这样的子序列极限都具有 Brown 运动的有限维分布. 因而所有可能的极限都是同一个 Brown 运动律, 从而得到整个序列在 $C([0, T])$ 中的弱收敛.

线性插值随机游走的完整证明见 [Dur19, Theorem 8.1.4]; 更一般的函数型极限定理版本见 [Kal21, Theorem 22.9].

3.8 有限变差与二次变差: 为随机积分作准备

总变差 设 $x: [0, T] \rightarrow \mathbb{R}$ 是一条确定路径. 对分割

$$\pi = \{0 = t_0 < t_1 < \dots < t_m = T\},$$

定义沿分割的绝对增量和

$$V_T(x; \pi) = \sum_{k=0}^{m-1} |x(t_{k+1}) - x(t_k)|.$$

定义 3.50 (有限变差路径).

路径 x 在 $[0, T]$ 上的总变差为

$$V_T(x) = \sup_{\pi} V_T(x; \pi),$$

上确界取遍所有有限分割. 如果 $V_T(x) < \infty$, 则称 x 在 $[0, T]$ 上具有有限变差.

总变差把每次向上和向下的移动都按正值计入, 因此衡量的是累计移动量, 而不是起点到终点的净变化. 单调函数, 分段光滑函数, 以及绝对连续且导数可积的函数都有有限变差.

有限总变差可以直接控制 Stieltjes 和. 例如积分器具有有限变差时, 对连续被积函数可以据此构造经典 Riemann–Stieltjes 积分. Brown 路径几乎必然具有无限总变差, 所以这种路径估计不能作为后面随机积分的构造依据. 下一章改用 Brown 增量的概率结构和二阶矩来控制积分和.

二次变差 现在不把增量取绝对值, 而是取平方, 再沿同一个分割求和:

$$Q_T(x; \pi) = \sum_{k=0}^{m-1} (x(t_{k+1}) - x(t_k))^2.$$

与总变差的定义不同, 这里不对所有分割取上确界, 而是选取一系列网格大小趋于 0 的分割 (π_n) , 观察平方和是否收敛. 若收敛, 就把极限称为沿这列分割的二次变差.

对一般路径, 极限可能不存在, 也可能随分割列改变, 因此“沿哪一系列分割”不能无条件省去. 对随机过程还要说明收敛方式: 几乎必然收敛, 依概率收敛和 L^p 收敛是不同的结论. 下一章将在连续半鞅中给出不依赖所选确定性分割序列的规范二次变差; 这里先保留最直接的分割和定义.

命题 3.51 (连续有限变差路径的二次变差为零).

如果 x 在 $[0, T]$ 上连续且具有有限变差, 那么对任意网格大小趋于 0 的分割列,

$$Q_T(x; \pi_n) \rightarrow 0.$$

证明. 记分割上的最大增量为

$$\delta_n = \max_k |x(t_{k+1}) - x(t_k)|.$$

由 x 在紧区间上的一致连续性, $\delta_n \rightarrow 0$. 同时

$$Q_T(x; \pi_n) \leq \delta_n \sum_k |x(t_{k+1}) - x(t_k)| \leq \delta_n V_T(x) \rightarrow 0.$$

□

连续有限变差路径的平方增量和趋于零, Brown 运动沿二进分割却满足

$$[W]_T = T.$$

这里涉及三种不同的累加. 带符号的一阶增量相邻相消, 总和恒等于 $W_T - W_0$; 绝对增量之和衡量路径累计移动了多远; 平方增量之和则产生二次变差. 网格变细时单个增量和最大增量都会趋于零, 但三种累加的极限仍然完全不同.

普通链式法则的证明需要把各小区间的 Taylor 展开相加. 对连续有限变差路径, 二阶余项的累计可以消失; 对 Brown 路径, 平方增量却保留了非零极限. 因此二阶导数所乘的那一项不能丢掉. 这正是 Itô 公式与普通链式法则不同的原因.

为什么下一章需要随机积分 现在回到积分和. 在每个分割点 t_k , 先根据 $\mathcal{F}_{t_k}$ 中的信息确定系数 H_{t_k} , 再让它在随后的区间 $(t_k, t_{k+1}]$ 上保持不变. 对这样的简单可预测过程, 定义

$$\sum_{k=0}^{m-1} H_{t_k} (W_{t_{k+1}} - W_{t_k}).$$

每一项都先确定 H_{t_k} , 随后才发生 Brown 增量, 与前面的可预测性完全一致.

要把定义推广到一般的 H , 需要控制简单过程逼近以后积分和的误差. Brown 路径没有有限总变差, 因而前面的路径估计不适用; 但可预测性使系数在增量发生前已经确定, Brown 增量又具有零条件平均和可以明确计算的二阶矩. 第4.3节将这些性质整理成 Itô 等距, 再用 L^2 极限把积分从简单可预测过程延拓到更一般的被积过程.

有了积分以后, 二次变差说明函数变换为何出现二阶项, Markov 性则帮助把未来的条件期望写成关于当前时间和状态的函数, 并进一步联系到生成元和偏微分方程. 对于既有漂移又有随机波动的过程, 下一章还会引入局部鞅和半鞅: 有限变差部分可以沿路径积分, 局部鞅部分用随机积分处理, 带跳情形则再计入跳跃的贡献. 局部鞅, 半鞅, 协变差及相应积分的正式定义都在第四章中展开.

3.9 小结

到这里, 下一章构造随机积分所需的两项结构已经出现. 一方面, 可预测性要求积分系数在相应随机增量发生以前确定; 另一方面, Brown 路径虽然具有无限总变差, 但沿前面使用的二进分割, 平方增量和几乎必然收敛到时间长度. 第四章将利用这两点构造 Itô 积分, 再由非零二次变差得到 Itô 公式中的二阶修正.

第四章 随机分析基础

在第3.7节和第3.8节中, 我们已经看到一个关键差别: Brown 路径虽然连续, 却几乎必然具有无限总变差; 与此同时, 平方增量沿细分能够累积成非零极限. 因而经典有限变差路径所用的积分方法不够, 需要利用 Brown 增量本身的概率结构重新构造积分. 这就是下面要构造的 Itô 积分.

构造时会用到前一章的两项性质. 被积系数必须在相应随机增量发生以前确定, 而 Brown 增量的二阶矩可以精确计算. 积分建立以后, 同一个二次变差又会在函数变换中留下二阶项, 由此得到 Itô 公式.

以下固定有限期限 $T > 0$, 在满足通常条件的滤过概率空间

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{0 \leq t \leq T}, \mathbb{P})$$

上工作. 一维 Brown 运动记为 B , 多维 Brown 运动记为 W . 本章涉及的半鞅均取适应的 càdlàg 版本, 即右连续且有左极限; 被积过程还须满足相应的可预测性和可积性条件. 前半章先处理连续过程, 末尾再加入跳跃.

4.1 从变差到随机微分

从最简单的分段系数开始. 若系数在一段时间开始时已经确定, 再乘以后来的 Brown 增量, 积分就是有限个乘积之和. 要推广到一般被积过程, 关键是证明简单过程逐渐逼近时, 相应积分也趋于唯一的极限. Itô 等距正好把被积过程的 L^2 误差转成积分的 L^2 误差.

积分定义以后, 再对 $f(t, X_t)$ 作变量替换. Taylor 展开的一阶项产生积分, Brown 平方增量的累计使二阶项也留下来, 得到 Itô 公式. 这套公式随后用于求解和分析几何 Brown 运动, OU 过程和 CIR 型扩散.

在此基础上, Girsanov 定理研究更换概率权重后漂移怎样改变; 生成元和 Kolmogorov 方程研究扩散的条件期望怎样随时间演化; Feynman-Kac 再把带贴现和沿途累积项的期望写成偏微分方程. 图4.1按这个顺序列出本章主线.




图 4.1: 从二次变差到随机微分方程的阅读路线.

注 4.1 (本章使用的积分理论).

Brown 积分将在本章从简单可预测过程开始构造. 连续半鞅积分把局部鞅积分与有限变差路径上的 Stieltjes 积分合在一起. 对一般 càdlàg 半鞅, 本章使用已有的半鞅积分理论, 并在跳跃部分说明跳前值和跳跃修正怎样进入公式. Tanaka 公式, 粗糙路径和 Malliavin 微积分等其他理论不在本章展开.

4.2 路径变差, 二次变差与半鞅

先比较两种沿分割累加增量的办法. 若路径的绝对增量总和有一统一上界, 经典 Stieltjes 积分就能利用这个上界控制积分和. Brown 路径没有这种有限总变差, 但平方增量却有稳定的极限. 两种极限的差别决定了后面应怎样构造随机积分.

总变差: 普通积分能够处理的路径 给定区间 $[0, t]$ 的分割

$$\pi = \{0 = t_0 < t_1 < \cdots < t_n = t\}, \quad |\pi| = \max_k (t_k - t_{k-1}),$$

我们先逐条路径衡量它累计移动了多少.

定义 4.2 (总变差与有限变差).

对实值函数 $x: [0, T] \rightarrow \mathbb{R}$, 定义它在 $[0, t]$ 上的总变差为

$$\mathrm{TV}_t(x) = \sup_{\pi} \sum_{k=1}^n |x(t_k) - x(t_{k-1})|,$$

其中上确界取遍 $[0, t]$ 的所有有限分割. 若 $\mathrm{TV}_T(x) < \infty$, 则称 x 为有限变差函数.

若过程 A 的样本路径以概率 1 在每个有限区间上都具有有限变差, 则称 A 为有限变差过程.

连续有限变差函数可以写成两个单调连续函数之差, 因而能够通过相应的符号测度定义 Lebesgue–Stieltjes 积分. 对随机过程 A , 固定样本点以后也可以逐条路径这样积分. 一个常见的有限变差过程是

$$A_t = A_0 + \int_0^t a_s \, ds, \quad \int_0^T |a_s| \, ds < \infty.$$

即使 a_s 随样本变化, 固定 ω 后右边仍只是普通的时间积分. 有限变差路径并不都能写成这种绝对连续形式, 上面的定义还包括更一般的情形.

二次变差与协变差 有限变差给出了对一阶绝对增量和的统一控制. Brown 路径的总变差却几乎必然无限, 所以不能依靠这个估计构造所有需要的积分. 换成平方增量以后, 情形会发生变化: 单个增量趋于零, 平方和却可能留下一个有限的非零极限.

对连续过程 X 和 $[0, t]$ 的确定性分割 π , 令

$$Q_t^\pi(X) = \sum_{k=1}^n (X_{t_k} - X_{t_{k-1}})^2.$$

为了同时比较各个时刻, 可以先分割整个 $[0, T]$. 计算时刻 t 的平方和时, 保留已经完成的区间, 并把最后一个尚未完成的区间截断到 t . 下面的收敛要求将控制整个时间区间上的误差, 不只控制某个固定时刻.

定义 4.3 (二次变差).

若对任意确定性分割序列, 当 $|\pi_n| \rightarrow 0$ 时, $Q^{\pi_n}(X)$ 在紧时间区间上一致依概率收敛到一个递增过程, 并且极限不依赖于所取的分割序列, 则把该极限记作

$$[X]_t = \lim_{|\pi| \rightarrow 0} \sum_{t_k \leq t} (X_{t_k} - X_{t_{k-1}})^2,$$

称为 X 的二次变差. 这里“紧时间区间上一致依概率收敛”意为对每个 $t \leq T$, 误差在 $[0, t]$ 上的上确界依概率趋于 0.

这个定义比沿某一列分割取得极限更强: 对任意确定性的趋细分割序列, 都要得到同一个一致依概率极限. 连续半鞅具有这种二次变差. 一般连续过程则可能没有这样的极限, 或者只能沿特定分割列得到极限. 因而这里的 $[X]$ 已经包含对存在性和收敛方式的要求.

定义 4.4 (协变差).

若 $X, Y, X + Y, X - Y$ 的二次变差均存在, 定义

$$[X, Y]_t = \frac{1}{4}([X + Y]_t - [X - Y]_t).$$

对连续半鞅, 它也等于分割和

$$[X, Y]_t = \lim_{|\pi| \rightarrow 0} \sum_{t_k \leq t} (X_{t_k} - X_{t_{k-1}})(Y_{t_k} - Y_{t_{k-1}})$$

的一致依概率极限.

协变差把每个小区间内 X 与 Y 的增量相乘, 再沿时间累加. 它是双线性的, 并满足 $[X, X] = [X]$.

不要把它与固定时刻的协方差混在一起. $\text{Cov}(X_t, Y_t)$ 先把 t 固定, 再对两个随机变量的乘积取期望, 所以结果是一个确定的数. $[X, Y]_t$ 则由一条实现上的增量乘积累积而成, 本身仍是随 t 变化的随机过程. 两者定义不同, 在后面的 Itô 公式中出现的是协变差.

命题 4.5 (连续有限变差过程的二次变差).

若 A 连续且在 $[0, T]$ 上有限变差, 则

$$[A]_t = 0, \quad [A, X]_t = 0$$

对任意连续半鞅 X 成立.

证明. 先固定一条连续且有限变差的路径. 对任意趋细分割,

$$\sum_k |\Delta A_k|^2 \leq \max_k |\Delta A_k| \sum_k |\Delta A_k|.$$

紧区间上的一致连续性使最大增量趋于零, 后一个因子则不超过总变差, 因此平方和趋于零.

对交叉增量和, 同样逐条路径估计:

$$\left| \sum_k \Delta A_k \Delta X_k \right| \leq \max_k |\Delta X_k| \text{TV}_T(A).$$

X 的连续性使右边趋于零. 这两个估计也同时控制所有截断到 $t \leq T$ 的分割和, 因而给出所需的一致收敛, 从而 $[A] = 0$ 且 $[A, X] = 0$. $\square$

Brown 运动的二次变差

定理 4.6 (Brown 运动的二次变差).

对标准 Brown 运动 B ,

$$[B]_t = t, \quad 0 \leq t \leq T.$$

与此同时, 对每个 $t > 0$, Brown 路径在 $[0, t]$ 上的总变差几乎处处为无穷.

证明. 先计算固定时刻的误差, 再把估计推广到整个时间区间. 固定 t 和确定性分割 π . Brown 增量独立且满足 $\Delta B_k \sim \mathcal{N}(0, \Delta t_k)$, 因而

$$\mathbb{E} Q_t^\pi(B) = \sum_k \Delta t_k = t.$$

每个平方增量的方差由正态四阶矩给出: $\text{Var}((\Delta B_k)^2) = 2(\Delta t_k)^2$. 独立性允许把这些方差相加, 得到

$$\text{Var}(Q_t^\pi(B)) = 2 \sum_k (\Delta t_k)^2 \leq 2t|\pi| \rightarrow 0.$$

所以对每个固定 t , 平方增量和在 L^2 中收敛到 t .

定义要求的收敛还须同时控制所有时刻. 设整个 $[0, T]$ 的分割含 n 个区间, 记端点处的误差为

$$M_j = \sum_{k \leq j} ((\Delta B_k)^2 - \Delta t_k).$$

(M_j) 关于 j 是平方可积离散鞅. 此处用到 Doob 的 L^2 最大不等式:

$$\mathbb{E} \left[\max_{0 \leq j \leq n} |M_j|^2 \right] \leq 4\mathbb{E}|M_n|^2 = 4\text{Var}(Q_T^\pi(B)) \leq 8T|\pi|.$$

因此最大端点误差在 L^2 中趋于零. 至于分割端点之间的时刻, 只多出最后一个截断区间内的平方增量和相应时间长度. Brown 路径的一致连续性控制前者, $|\pi|$ 控制后者. 因此 $Q^\pi(B)$ 在 $[0, T]$ 上一致依概率收敛到 $s \mapsto s$.

为证明无限总变差, 固定 $t > 0$ 并改用 $[0, t]$ 的二进分割 π_n . 此时

$$\text{Var}(Q_t^{\pi_n}(B)) = 2t^2 2^{-n}.$$

这些方差的和有限, 所以由 Chebyshev 不等式与 Borel–Cantelli 引理, $Q_t^{\pi_n}(B) \rightarrow t$ 几乎必然成立. 另一方面, 若某条连续路径具有有限总变差, 前一命题的估计会给出

$$Q_t^{\pi_n}(B) \leq \max_k |\Delta B_k| \text{TV}_t(B) \rightarrow 0.$$

当 $t > 0$ 时, 这与刚得到的极限矛盾. 因而 Brown 路径在 $[0, t]$ 上具有有限总变差的概率为零. $\square$

这个极限可以从 Brown 增量的二阶矩看出尺度. 长度为 Δt 的增量服从 $\mathcal{N}(0, \Delta t)$, 因而标准差为 $\sqrt{\Delta t}$, 二阶矩为 Δt . 分割越细, 单个平方增量越小, 但所有时间间隔相加仍为总长度, 所以平方增量和能够留下有限的非零极限. 这里的 $\sqrt{\Delta t}$ 是分布尺度, 不是每条路径上的逐点界.

离散价格记录也可以做同样的平方和计算. 图4.2先计算相邻交易日的对数收益率 r_k , 再累加

$$Q_n = \sum_{k \leq n} r_k^2.$$

较大的正收益和负收益都会使曲线明显上升, 因为平方后不再区分涨跌方向. 图中记录的是这段历史在日线网格上的累计平方收益, 尚未进行网格趋细的极限操作. 它展示了二次变差估计实际累加的量, 也说明累计波动与累计收益是不同的计算.




图 4.2: AAPL 日线网格上的累计平方对数收益率 (2019–2021). 相邻日增量平方后逐步累加, 得到经验二次变差的离散近似. 数据来源见引用文献 [Yaha; Yahc].

连续局部鞅与半鞅 Brown 运动只是随机波动的一种情形. 更一般的过程可能在适当停止以后是鞅, 但放开停止时却缺少维持鞅等式所需的可积性. 局部鞅用一系列停时保留这些停止后的鞅性质.

实际方程还常包含另一类变化, 例如漂移, 利息或费用的累计, 它们在有限时间内可以具有有限变差. 半鞅把这两部分写在一起: $X = X_0 + M + A$, 其中 M 是局部鞅, A 是有限变差过程. 后面将分别对两部分定义积分, 再把结果相加.

定义 4.7 (局部鞅).

定义在 $[0, T]$ 上的适应 càdlàg 过程 M 称为局部鞅, 如果存在一系列递增停时 $\tau_n \leq T$, 满足 $\mathbb{P}(\tau_n = T) \rightarrow 1$, 并使停止过程 $M^{\tau_n} = (M_{t \wedge \tau_n})_{0 \leq t \leq T}$ 对每个 n 都是鞅. 这列停时称为局部化序列. 等价地, 可以把过程在 T 后停止, 再使用趋于无穷的局部化序列.

局部化允许停时随路径变化. 对每个 n , 停止后的过程都是鞅; 随着 n 增大, 在 T 以前被停止的路径越来越少. 但从 M^{τ_n} 回到 M 时, 还要把条件期望等式取极限. 若缺少足够的可积性, 这个极限步骤可能失败, 所以局部鞅未必是真鞅. 非负局部鞅是上鞅, 其期望也可能随时间下降.

定义 4.8 (半鞅).

适应的右连续有左极限过程 X 称为半鞅, 如果它可以写成

$$X_t = X_0 + M_t + A_t,$$

其中 $M_0 = A_0 = 0$, M 是局部鞅, A 是有限变差过程. 若 X, M, A 都连续, 则称 X 为连续半鞅.

Brown 运动, 适应的 càdlàg 有限变差过程, 以及后文标准条件下 SDE 的解, 都属于半鞅. 这个类之所以重要, 是因为对它们可以建立稳定的随机积分: 简单可预测过程的逼近能够传到积分结果, 而不因逼近方式不同产生任意的答案. 反过来, 这种积分稳定性也可以用来刻画半鞅, 这就是 Bichteler–Dellacherie 定理的思想. 本章先使用上述分解来构造和计算积分.

定理 4.9 (连续半鞅的二次变差只来自局部鞅部分).

若

$$X = X_0 + M + A, \quad Y = Y_0 + N + C$$

是连续半鞅分解, 其中 M, N 为连续局部鞅, A, C 为连续有限变差过程, 则

$$[X, Y] = [M, N], \quad [X] = [M].$$

特别地, 存在唯一从 0 出发的连续递增适应过程 $[M]$ 使 $M^2 - [M]$ 为局部鞅.

证明. 先使用连续局部鞅的括号构造: 存在从零出发的连续有限变差过程 $[M, N]$, 使 $MN - [M, N]$ 为局部鞅; 当 $M = N$ 时, $[M]$ 递增. 这一构造及其刻画见 [Kal21, Theorem 18.5]. 若有两个满足要求的候选过程, 它们的差同时是连续有限变差过程和局部鞅, 因而只能恒等于初值零. 这给出唯一性.

接着把 $X = X_0 + M + A$ 与 $Y = Y_0 + N + C$ 的交叉增量展开. 含有连续有限变差部分的项都消失, 因为对连续有限变差过程 A 和连续过程 X ,

$$\left| \sum_k \Delta A_k \Delta X_k \right| \leq \max_k |\Delta X_k| \text{Var}_{[0,t]}(A) \rightarrow 0.$$

其中 $\text{Var}_{[0,t]}(A)$ 表示路径的总变差, 并非概率意义的方差. 剩下的只有 M 与 N 的交叉增量和. 由括号的分割逼近 [Kal21, Proposition 18.17], 它收敛到 $[M, N]$, 所以 $[X, Y] = [M, N]$. 取 $Y = X$ 即得到 $[X] = [M]$. $\square$

对连续局部鞅, $M^2 - [M]$ 为局部鞅还说明 $[M]$ 正好补偿了平方过程中的条件漂移. 对连续 Itô 型过程, 这会直接变成系数的积分. 例如若

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dB_s, \quad Y_t = Y_0 + \int_0^t c_s ds + \int_0^t d_s dB_s,$$

则

$$[X]_t = \int_0^t b_s^2 ds, \quad [X, Y]_t = \int_0^t b_s d_s ds.$$

也就是说, 二次变差累计 b_s^2 , 协变差累计 $b_s d_s$. 时间积分中的 $a_s ds$ 与 $c_s ds$ 是连续有限变差部分, 对这些括号没有贡献.

上面的括号结论使用了连续性. 对带跳半鞅, 二次变差还要加上实际跳跃的平方:

$$[X]_t = [X^c]_t + \sum_{0 < s \leq t} (\Delta X_s)^2,$$

其中 X^c 是连续局部鞅部分. 第4.8节将在 Poisson 计数中直接算出这一项.

注 4.10 (半鞅之外的连续过程).

连续路径本身也不保证半鞅性. Hurst 指数不等于 $1/2$ 的分数 Brown 运动一般不是半鞅, 相应积分要改用 Young 积分, 粗糙路径或 Skorokhod 积分等其他构造, 计算规则也随所用积分理论改变.

4.3 从简单过程构造 Itô 积分

先定义分段常数的积分 先把时间分成有限个区间. 在左端点 t_k 已经知道 $\mathcal{F}_{t_k}$ 中的信息, 据此选定系数 ξ_k , 并让这个系数在 $(t_k, t_{k+1}]$ 上保持不变. 对随后发生的 Brown 增量, 这一段的积分定义为

$$\xi_k(B_{t_{k+1}} - B_{t_k}).$$

把各段相加即可得到有限和. 因为 ξ_k 在增量出现以前已经确定, 后面取条件期望时可以利用 Brown 增量相对于过去的独立性和零均值. 这样的分段系数组成简单可预测过程.

定义 4.11 (简单可预测过程).

给定确定性分割 $0 = t_0 < \cdots < t_n = T$, 若

$$H_t = \sum_{k=0}^{n-1} \xi_k \mathbf{1}_{(t_k, t_{k+1}]}(t),$$

其中 ξ_k 是 $\mathcal{F}_{t_k}$ -可测且平方可积的随机变量, 则称 H 为平方可积的简单可预测过程.

定义对 ξ_k 提出了两个不同的要求. $\mathcal{F}_{t_k}$ -可测性保证系数只使用区间开始时的信息, 因而仍可利用随后 Brown 增量的零条件平均. 这个增量与 ξ_k 独立且具有有限二阶矩, 所以 ξ_k 平方可积时, 它与增量的乘积也平方可积. 前一个条件决定怎样计算条件期望, 后一个条件使后面的等距和 L^2 极限有意义.

定义 4.12 (简单过程的 Itô 积分).

对上述 H , 定义

$$\int_0^t H_s dB_s = \sum_{k=0}^{n-1} \xi_k (B_{t \wedge t_{k+1}} - B_{t \wedge t_k}), \quad 0 \leq t \leq T.$$

式中的两个截断时刻处理了三种情况: 尚未开始的区间贡献为零, 已完成的区间贡献整个增量, 当前所在区间只累加到 t . 因此这个有限和已经定义了整个连续积分过程. 下一步将对被积过程作逼近, 在 $L^2(\mathbb{P})$ 中取得极限; 这与直接固定路径构造 Riemann-Stieltjes 积分采用了不同的控制方式.

Itô 等距与平方可积延拓 要把定义从简单过程推广出去, 必须知道被积过程的误差会造成多大的积分误差. Itô 等距给出了精确关系: 随机积分的二阶矩, 等于 H_s^2 先对时间积分, 再对概率取期望. 因此用

$$\mathbb{E} \int_0^T H_s^2 ds$$

衡量被积过程的大小. 两个简单过程若在这个量对应的范数下越来越接近, 它们的随机积分就在 $L^2(\mathbb{P})$ 中同样越来越接近. 于是可以先在简单过程中定义积分, 再利用 L^2 的完备性取极限.

定理 4.13 (Itô 等距).

对任意平方可积简单可预测过程 H ,

$$\mathbb{E} \left[\left(\int_0^T H_s dB_s \right)^2 \right] = \mathbb{E} \left[\int_0^T H_s^2 ds \right].$$

并且 $\mathbb{E}[\int_0^T H_s dB_s] = 0$.

证明. 记 $\Delta B_k = B_{t_{k+1}} - B_{t_k}$, 展开有限和的平方. 对角项可以先对 $\mathcal{F}_{t_k}$ 取条件期望. 此时 ξ_k 已知, 而新增量独立于过去, 二阶矩为 Δt_k , 所以

$$\mathbb{E}[\xi_k^2 (\Delta B_k)^2] = \mathbb{E}[\xi_k^2] \Delta t_k.$$

对交叉项取 $k < \ell$, 并对较晚的 $\mathcal{F}_{t_\ell}$ 取条件期望. 前一个增量及两个系数都已经可知, 只有 ΔB_ℓ 尚未发生, 它的条件平均为零, 因而交叉项的期望为零. 这里用的是条件平均为零, 并未要求各个加权增量彼此独立.

因此只剩对角项:

$$\mathbb{E} \left[\left(\sum_k \xi_k \Delta B_k \right)^2 \right] = \sum_k \mathbb{E}[\xi_k^2] \Delta t_k = \mathbb{E} \int_0^T H_s^2 ds.$$

不展开平方, 直接对每项作同样的条件期望计算, 就得到积分均值为零. $\square$

令

$$\mathcal{H}^2 = \left\{ H \text{ 可预测} : \mathbb{E} \int_0^T H_s^2 ds < \infty \right\}, \quad \|H\|_{\mathcal{H}^2}^2 = \mathbb{E} \int_0^T H_s^2 ds.$$

若两个过程只在一个 $dt \otimes \mathbb{P}$ 零测集上不同, 它们的 $\mathcal{H}^2$ 距离为零, 因而把它们视为同一个元素. 对这一等价关系取商以后, $\mathcal{H}^2$ 成为 Hilbert 空间. 简单可预测过程在其中稠密, 而 Itô 等距说明: 被积过程之间的 $\mathcal{H}^2$ 距离, 正好等于相应随机积分之间的 L^2 距离. 因此积分可以唯一延拓到整个 $\mathcal{H}^2$.

定理 4.14 (L^2 延拓).

对每个 $H \in \mathcal{H}^2$, 存在简单可预测过程 $H^{(n)}$ 使 $\|H^{(n)} - H\|_{\mathcal{H}^2} \rightarrow 0$. 定义

$$\int_0^T H_s dB_s = L^2(\mathbb{P})\text{-}\lim_{n \rightarrow \infty} \int_0^T H_s^{(n)} dB_s.$$

该极限与逼近序列无关, 仍满足 Itô 等距. 积分过程

$$I_t = \int_0^t H_s dB_s$$

具有连续平方可积鞅版本, 并且

$$[I]_t = \int_0^t H_s^2 ds.$$

证明. 可预测 σ -代数由前一章给出的时间区间与已知事件生成. 对这些生成集合的指示函数作简单函数逼近, 再截断系数, 就得到简单可预测过程在 $\mathcal{H}^2$ 中的稠密性. 取 $H^{(n)} \rightarrow H$. 由 Itô 等距,

$$\mathbb{E} \left| \int_0^T (H_s^{(n)} - H_s^{(m)}) dB_s \right|^2 = \|H^{(n)} - H^{(m)}\|_{\mathcal{H}^2}^2.$$

右边趋于零, 所以积分在完备空间 $L^2(\mathbb{P})$ 中有极限. 对两列不同逼近也应用这个等式, 就知道它们得到同一结果.

为了同时得到所有时刻的积分, 记相应简单积分为 $I^{(n)}$. 它们是连续平方可积鞅, Doob 最大不等式给出

$$\mathbb{E} \sup_{t \leq T} |I_t^{(n)} - I_t^{(m)}|^2 \leq 4 \|H^{(n)} - H^{(m)}\|_{\mathcal{H}^2}^2.$$

因而能够选出一个几乎必然一致收敛的子列, 其极限路径连续. 条件期望在 L^2 中连续, 所以简单积分的鞅等式也传到极限, 得到 I 的鞅性.

最后验证括号. 对简单过程, 使用 Brown 运动的平方鞅逐段计算可知, $(I_t^{(n)})^2 - \int_0^t (H_s^{(n)})^2 ds$ 是鞅. 上面的最大矩估计使平方项在 L^1 中收敛; Cauchy-Schwarz 不等式又使累计平方积分在 L^1 中收敛到 $\int_0^t H_s^2 ds$. 因此 $I_t^2 - \int_0^t H_s^2 ds$ 仍为鞅. 由连续局部鞅括号的唯一性, $[I]_t = \int_0^t H_s^2 ds$. $\square$

若可预测过程 H 只满足

$$\int_0^T H_s^2 ds < \infty \quad \text{a.s.},$$

则每条路径上的累计平方有限, 但它的期望未必有限, 所以 H 不一定属于全局的 $\mathcal{H}^2$. 此时先在累计平方达到 n 时停止, 并把停时截在 T . 停止后的平方积分有确定上界 n , 可以使用已经构造好的平方可积积分.

不同 n 的积分在它们共同尚未停止的区间上一致, 因而可以逐段拼成一个连续过程. 由于原来的累计平方几乎必然有限, 对每条路径而言, 足够大的 n 最终不会再在 T 以前触发停止. 这样定义的随机积分是连续局部鞅. 若还要得到真鞅, 则需另外证明解除这些停止以后仍有足够的可积性.

对连续半鞅积分 对一般连续局部鞅 M , Brown 积分中的时间 ds 要换成括号测度 $d[M]_s$, 再作相应的平方可积延拓和局部化. 有限变差过程则仍按每条路径作 Stieltjes 积分. 因而若 $X = X_0 + M + A$ 是连续半鞅, 定义

$$\int_0^t H_s dX_s = \int_0^t H_s dM_s + \int_0^t H_s dA_s.$$

例如, 可预测的 H 若沿路径满足 $\int_0^T H_s^2 d[M]_s < \infty$ 和 $\int_0^T |H_s| dTV_s(A) < \infty$, 便可以通过局部化定义这两项. 前一项由局部鞅的二次变差控制, 后一项由有限变差的总变差控制.

注 4.15 (一般半鞅积分的引用范围).

一般 càdlàg 半鞅积分还允许跳跃. 对每个适应的 càdlàg 半鞅 X , 以 $L(X)$ 记对它可积的可预测过程类, 并写作

$$H \in L(X) \quad \mapsto \quad (H \cdot X)_t := \int_0^t H_u dX_u.$$

这里 $L(X)$ 表示可积过程的集合, 与第3.2节中表示过程律的 $\mathcal{L}(X)$ 不同. 本章对 Brown 积分完成构造, 对一般半鞅积分使用已有理论.

积分由 X 本身决定, 不随半鞅分解的选择而改变. 若 $X = X_0 + M + A$ 且右边两项有定义, 就有

$$H \cdot X = H \cdot M + H \cdot A.$$

在跳跃时刻, 积分的跳跃满足

$$\Delta(H \cdot X)_t = H_t \Delta X_t.$$

因此乘上本次跳跃的必须是事先确定的系数. 若用适应的 càdlàg 过程 $\bar{H}$ 记录每次调整后的头寸, 实际参与本次价格跳跃的持仓应写为 $H_t = \bar{H}_{t-}$. 这样, 跳跃发生后才作出的调整就不会被倒算成本次跳跃以前的持仓.

原则 4.16 (随机微分是积分等式的简写).

表达式

$$dX_t = a_t dt + b_t dB_t, \quad X_0 = x,$$

表示在相应可积条件下成立的积分等式

$$X_t = x + \int_0^t a_s ds + \int_0^t b_s dB_s, \quad 0 \leq t \leq T.$$

时间积分与随机积分分别说明两类增量怎样累积. 由于 Brown 路径不可微, 不能再把 dB_t 除以 dt , 当作普通函数的导数来解释这个方程.

同样, 常用的助记规则

$$(dB_t)^2 = dt, \quad dt dB_t = 0, \quad (dt)^2 = 0$$

记录的是分割和的极限: Brown 平方增量累积成时间, 连续有限变差的平方增量和及其与 Brown 增量的交叉和则趋于零. 第一个式子没有断言每个小区间都满足 $(\Delta B)^2 = \Delta t$. 它之所以能用于计算, 是因为相应的二次变差结论已经成立.

4.4 Itô 公式, 乘积公式与随机指数

有了积分, 就可以研究过程经过函数变换后怎样变化. 例如, 从 X 转向 X^2 , e^X , 或在 $X > 0$ 时转向 $\log X$, 都需要相应的链式法则.

普通链式法则在把小区间的展开相加后, 只留下了一阶项. 对 Brown 型路径, 平方增量的累计也有非零极限, 因而二阶项必须保留. Itô 公式给出的正是这个修正后的变量替换法则.

一维 Itô 公式 考虑 Itô 过程

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dB_s,$$

其中 a, b 渐进可测, 并且 $\int_0^T (|a_s| + b_s^2) ds < \infty$ 几乎必然成立. 对这里的 Brown 积分, 渐进可测系数可以用在 $ds \otimes \mathbb{P}$ 意义下相等的可预测代表处理, 再按上一节的局部化构造积分.

定理 4.17 (一维 Itô 公式).

若 $f \in C^{1,2}([0, T] \times \mathbb{R})$, 则

$$\begin{aligned} f(t, X_t) = f(0, X_0) &+ \int_0^t \left(\partial_s f(s, X_s) + a_s \partial_x f(s, X_s) + \frac{1}{2} b_s^2 \partial_{xx} f(s, X_s) \right) ds \\ &+ \int_0^t b_s \partial_x f(s, X_s) dB_s, \end{aligned}$$

只要各项通过局部化或可积性条件得到良好定义.

证明. 使用连续半鞅的代换公式 [Kal21, Theorem 18.18]. 空间变量的一阶变化给出 $\partial_x f dX$, 二阶变化给出 $\frac{1}{2} \partial_{xx} f d[X]$. 时间坐标是连续有限变差函数, 因而只贡献普通的 $\partial_t f dt$, 不贡献二次变差或交叉变差. 再代入 $dX_t = a_t dt + b_t dB_t$ 和 $d[X]_t = b_t^2 dt$, 就得到所述积分等式. 时间与一维 Brown 运动的版本, 以及多维 Brown 运动的版本, 分别见 [Dur19, Theorem 7.6.5, Theorem 7.6.7].

代换公式中二阶项的来源也可以从 Taylor 展开理解. 若在短区间内暂时把系数视为近似不变, 就写成

$$\Delta X \approx a \Delta t + b \Delta B.$$

将展开沿分割相加时, 一阶项形成时间积分和随机积分; 二阶项中的 Brown 平方增量和留下二次变差, 而时间平方项与时间和 Brown 的交叉项消失. 所以 $\frac{1}{2} f_{xx} (\Delta X)^2$ 最后贡献 $\frac{1}{2} f_{xx} b^2 dt$.

这个短区间近似说明了公式的来由, 完整证明还须处理一般系数和余项. 可先局部化到紧集, 再控制 Taylor 余项, 平方增量和以及随机积分的收敛. Kallenberg 的证明先用乘积公式建立多项式情形, 再同时逼近 f , f' 和 f'' , 利用有限变差积分的估计及随机积分的收敛通过极限, 见 [Kal21, proof of Theorem 18.18]. $\square$

公式中的三个时间项各有来源: $\partial_t f$ 来自函数本身随时间改变, $a \partial_x f$ 来自过程的漂移, $\frac{1}{2} b^2 \partial_{xx} f$ 来自波动经过函数曲率后的累计影响. 最后一项 $b \partial_x f dB$ 则保留了变换后的随机波动.

完整例一: Brown 运动的平方 取 $X_t = B_t$ 和 $f(x) = x^2$. 一阶导数给出 $2B_s dB_s$, 二阶导数与二次变差则给出 $\frac{1}{2} \times 2 ds$. 因此

$$B_t^2 = 2 \int_0^t B_s dB_s + t.$$

整理后,

$$\int_0^t B_s dB_s = \frac{1}{2}(B_t^2 - t).$$

若照搬普通积分得到 $B_t^2/2$, 就漏掉了累计平方增量贡献的 $-t/2$.

这里还可以直接使用平方可积理论: $\mathbb{E} \int_0^t B_s^2 ds = t^2/2 < \infty$, 所以积分是真鞅, 均值为零. 于是等式同时验证了 $\mathbb{E}[B_t^2] = t$ 和 $B_t^2 - t$ 的鞅性.

完整例二: 指数与随机指数 Brown 运动的均值虽然不变, 对它取指数以后却会出现正漂移. 取 $f(x) = e^{\lambda x}$, $\lambda \in \mathbb{R}$, Itô 公式给出

$$e^{\lambda B_t} = 1 + \lambda \int_0^t e^{\lambda B_s} dB_s + \frac{\lambda^2}{2} \int_0^t e^{\lambda B_s} ds.$$

最后一项来自指数函数的二阶导数. 若希望消除这一漂移, 就应在指数中加入一个随时间减少的项:

$$Z_t = \exp\left(\lambda B_t - \frac{1}{2}\lambda^2 t\right).$$

对 $f(t, x) = \exp(\lambda x - \lambda^2 t/2)$ 再用 Itô 公式, 时间偏导恰好抵消二阶修正, 得到

$$Z_t = 1 + \int_0^t \lambda Z_s dB_s, \quad dZ_t = \lambda Z_t dB_t.$$

这个例子中还可以直接验证真鞅性. 给定 $\mathcal{F}_s$, Z_t/Z_s 只含新的 Gauss 增量; 其指数矩恰好抵消 $\exp(-\lambda^2(t-s)/2)$. 因而条件期望为 1, 即 $\mathbb{E}[Z_t | \mathcal{F}_s] = Z_s$, 特别地 $\mathbb{E}Z_t = 1$.

同样的二阶抵消适用于连续局部鞅. 若 $M_0 = 0$, 定义 **Doléans 随机指数**

$$\mathcal{E}(M)_t = \exp\left(M_t - \frac{1}{2}[M]_t\right).$$

Itô 公式给出

$$\mathcal{E}(M)_t = 1 + \int_0^t \mathcal{E}(M)_s dM_s.$$

因此 $\mathcal{E}(M)$ 严格为正, 并且是局部鞅. 常系数 Brown 例子中可以直接算出它的条件期望等于当前值; 对一般连续局部鞅, 局部鞅性本身还不能保证这个期望等式在解除局部化以后仍成立.

完整例三: 几何 Brown 运动与对数修正 给定常数 $\mu, \sigma \in \mathbb{R}$ 和 $S_0 > 0$, 考虑

$$S_t = S_0 + \int_0^t \mu S_s ds + \int_0^t \sigma S_s dB_s.$$

漂移和噪声都与当前值成正比, 因此可以尝试指数形式. 前一个例子说明, 指数中的时间系数还须扣去二阶修正, 于是取

$$S_t = S_0 \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma B_t\right).$$

直接应用 Itô 公式, 三项分别为

$$\left(\mu - \frac{1}{2}\sigma^2\right) S_t dt, \quad \sigma S_t dB_t, \quad \frac{1}{2}\sigma^2 S_t dt.$$

两个时间项合起来正是 $\mu S_t dt$, 所以这个过程确实解原积分方程. 指数表示也同时给出 $S_t > 0$.

正性允许我们在正半轴上对 $\log S_t$ 使用 Itô 公式. 由于对数函数的二阶导数为负, 得到

$$d \log S_t = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dB_t,$$

从而

$$\log \frac{S_t}{S_0} = \left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma B_t.$$

这里 μ 是原方程中相对于当前值的漂移率, $\mu - \sigma^2/2$ 是对数过程的漂移率. 两者相差 $\sigma^2/2$, 是波动经过对数函数的曲率以后产生的结果, 不需要再加入一个经济假设.

多维 Itô 公式 对多个过程的函数作 Taylor 展开时, 二阶项不仅有各坐标增量的平方, 还有不同坐标增量的乘积. 因此, 多维 Itô 公式既需要二次变差, 也需要协变差. 即使驱动噪声的各坐标独立, 不同状态变量也可能同时使用同一个噪声坐标, 从而产生非零的交叉项.

定义 4.18 (m 维标准 Brown 运动).

在固定滤过概率空间上, $\mathbb{R}^m$ -值过程 $W = (W^1, \dots, W^m)$ 称为关于该滤过的 m 维标准 Brown 运动, 如果 $W_0 = 0$ a.s., W 适应且路径几乎必然连续, 并且对每个 $0 \leq s < t$, 向量增量 $W_t - W_s$ 与 $\mathcal{F}_s$ 独立且满足

$$W_t - W_s \sim \mathcal{N}(0, (t-s)I_m).$$

这个定义给出相互独立的一维 Brown 坐标. 对 $j, k \in \{1, \dots, m\}$,

$$[W^j, W^k]_t = \delta_{jk}t, \quad dW_t^j dW_t^k = \delta_{jk} dt.$$

其中 δ_{jk} 是 Kronecker delta, 第二式是第一式的微分助记法: 同一噪声坐标贡献时间, 不同独立坐标的交叉变差为零.

现在令 d 维过程 X 由这些噪声驱动:

$$dX_t^i = b_i(t, X_t) dt + \sum_{j=1}^m \sigma_{ij}(t, X_t) dW_t^j, \quad i = 1, \dots, d.$$

第 i 行的系数说明 X^i 怎样使用各个噪声坐标. 计算 X^i 与 X^k 的协变差时, 同一噪声坐标上的两个系数相乘, 再对所有噪声坐标求和, 得到 $a = \sigma\sigma^\top$, 即

$$d[X^i, X^k]_t = a_{ik}(t, X_t) dt.$$

定理 4.19 (多维 Itô 公式).

若 $f \in C^{1,2}([0, T] \times \mathbb{R}^d)$, 则

$$\begin{aligned} df(t, X_t) = & \left(\partial_t f + \sum_{i=1}^d b_i \partial_i f + \frac{1}{2} \sum_{i,k=1}^d a_{ik} \partial_{ik} f \right) (t, X_t) dt \\ & + \sum_{j=1}^m \left(\sum_{i=1}^d \sigma_{ij} \partial_i f \right) (t, X_t) dW_t^j. \end{aligned}$$

证明. 在多维连续半鞅代换公式中, 一阶项为各个 $\partial_i f dX^i$ 之和, 二阶项为 $\frac{1}{2} \sum_{i,k} \partial_{ik} f d[X^i, X^k]$. 代入上面的漂移, 噪声和协变差表达式, 再按 dt 与各个 dW^j 分组, 就得到所述公式. 时间坐标仍是有限变差坐标, 只贡献 $\partial_t f dt$. $\square$

二阶项是函数 Hessian 与瞬时协变差矩阵的配对. 只要 a_{ik} 非零, 相应的混合二阶导数就参与修正. 因而实际计算应看 X 的协变差矩阵, 不能仅凭驱动 Brown 坐标独立就删去所有混合项.

乘积公式与分部积分 乘积的单步变化满足精确恒等式 $\Delta(XY) = X\Delta Y + Y\Delta X + \Delta X\Delta Y$, 其中右边的 X, Y 取区间左端点值. 普通分部积分中, 最后一类交叉增量和趋于零; 对连续半鞅, 它可能留下协变差. 后面把密度过程乘上价格过程, 或把贴现因子乘上未来收益时, 都会用到这一计算.

命题 4.20 (连续半鞅乘积公式).

若 X, Y 为连续半鞅, 则

$$X_t Y_t = X_0 Y_0 + \int_0^t X_s dY_s + \int_0^t Y_s dX_s + [X, Y]_t.$$

形式上可写成

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + d[X, Y]_t.$$

证明. 先对平方过程建立公式, 再用极化恒等式把平方公式改写为一般的乘积公式. 在分割逼近中, 两个一阶和分别收敛到随机积分, 交叉增量和收敛到 $[X, Y]$. 局部鞅部分使用括号构造与随机积分的收敛, 连续有限变差部分使用逐路径的 Lebesgue-Stieltjes 分部积分. 完整论证见 [Kal21, Theorem 18.16]. $\square$

若其中一个过程连续且有限变差, 交叉项就为零, 公式恢复为熟悉的分部积分形式. 这正是后面处理只含时间积分的贴现因子时所用的情形.

4.5 随机微分方程: 解的含义与基本模型

第4.3节和第4.4节从已经给定的过程出发, 研究怎样积分和作函数变换. 随机微分方程则先指定漂移和噪声系数, 再寻找满足这条规则的过程.

例如, 系数可以规定离某个中心越远, 回复漂移越强; 也可以规定当前值越大, 噪声幅度越大. 这些系数依赖尚未求出的 X_t , 所以写下方程还没有构造出解. 我们需要证明某个连续适应过程确实满足相应的积分等式, 并说明在初值和噪声固定以后, 解是否还有选择余地.

先写积分形式 考虑 d 维状态, m 维 Brown 噪声的方程

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t, \quad X_0 = \xi.$$

其中 $b: [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$, $\sigma: [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^{d \times m}$ 均为 Borel 可测函数.

定义 4.21 (SDE 的解).

一个连续适应过程 X 是上述 SDE 的解, 如果对每个 $t \leq T$, 几乎处处有

$$X_t = \xi + \int_0^t b(s, X_s) ds + \int_0^t \sigma(s, X_s) dW_s,$$

且两个积分均良好定义. 所谓满足 SDE, 始终是指满足这条积分等式.

强解, 弱解与两类唯一性 SDE 的存在性有两种不同问法. 一种已经给定初值和驱动 Brown 运动, 要求用它们生成解; 另一种允许连概率空间和 Brown 运动一起构造, 只要求最终满足方程及规定的初始分布. 这一区别产生了强解和弱解的名称.

定义 4.22 (强解与弱解).

强解问题预先给定概率空间, 滤过, Brown 运动 W 和初值 ξ , 并要求 X_t 适应于

$$\mathcal{G}_t = \sigma(\xi, W_s : 0 \leq s \leq t)$$

的完备化滤过. 因此, 截至 t 的解由初值及截至 t 的 Brown 路径可测地决定. 即使工作空间另有更大的滤过, 强解仍要求这一表示, 不借用额外的随机性来决定解.

弱解问题只给定系数和初始分布, 允许把概率空间, 滤过, Brown 运动与 X 一起构造, 使它们满足积分等式和规定的分布条件.

这里的强弱与路径是否光滑无关, 弱解同样必须满足前面的积分等式. 与两种存在性相对应, 唯一性也要说明比较的是路径本身还是路径的分布.

定义 4.23 (路径唯一性与分布唯一性).

若定义在同一滤过概率空间, 由同一个 W 驱动且具有同一初值的任意两个解 X, Y 都不可区分, 则称该 SDE 具有**路径唯一性**.

若任意两个具有规定初始分布的弱解, 作为路径空间随机元素具有相同分布, 则称该 SDE 具有**分布唯一性或依分布唯一性**.

路径唯一性把两条候选解放在同一个初值和同一个噪声实现下比较; 分布唯一性允许两次构造使用不同的概率空间, 只比较最后得到的路径概率律.

Yamada–Watanabe 定理把这些概念联系起来: 在标准 Brown 驱动的 SDE 框架中, 弱存在性加路径唯一性推出强存在性, 并给出分布唯一性. 弱存在性先保证至少能够造出一组满足方程的过程; 路径唯一性进一步保证, 初值和 Brown 噪声一旦确定, 解就不能再有额外的随机选择. 定理的实质是把这一事实严格转化为解关于初值和噪声的可测函数表示, 见 [Kal21, Theorem 32.14].

全局 Lipschitz 与线性增长条件 接下来需要条件来保证解存在且唯一. 全局 Lipschitz 条件控制系数对状态变化的敏感程度, 使我们能够估计候选解之间的差距. 线性增长条件则控制系数在远处的增长, 帮助排除有限时间内的爆炸. 两者结合, 得到下面常用的存在唯一性定理.

定理 4.24 (强解的存在唯一性).

假设存在常数 $L, K < \infty$, 使对所有 $t \in [0, T]$ 和 $x, y \in \mathbb{R}^d$,

$$|b(t, x) - b(t, y)| + \|\sigma(t, x) - \sigma(t, y)\| \leq L|x - y|,$$

且

$$|b(t, x)|^2 + \|\sigma(t, x)\|^2 \leq K(1 + |x|^2).$$

若 ξ 是 $\mathcal{F}_0$ -可测且 $\xi \in L^2$, 则 SDE 在 $[0, T]$ 上存在唯一强解, 并且

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |X_t|^2 \right] < \infty.$$

证明. 先考虑有界的 Lipschitz 系数. 从 $X_t^{(0)} = \xi$ 出发作 Picard 迭代, 每一步把上一条近似过程代入系数:

$$X_t^{(n+1)} = \xi + \int_0^t b(s, X_s^{(n)}) ds + \int_0^t \sigma(s, X_s^{(n)}) dW_s.$$

因为上一轮近似适应, 下一轮仍然只使用截至当前的噪声. Lipschitz 条件把系数之差控制在对应的过程差之内; 对时间积分使用 Cauchy–Schwarz 不等式, 对随机积分使用 Itô 等距与最大不等式, 可以估计 $\mathbb{E}[\sup_{s \leq t} |X_s^{(n+1)} - X_s^{(n)}|^2]$, 并把它控制为上一轮同类误差的时间积分. 反复迭代得到阶乘型上界, 所以 Picard 序列在 $\mathbb{E}[\sup_{t \leq T} |\cdot|^2]^{1/2}$ 对应的范数下收敛. 同样的估计允许在时间积分和随机积分中通过极限, 因而极限过程满足 SDE.

对同一初值和同一 Brown 运动驱动的两个解, 差的估计具有相同形式, 但初始差为零. Gronwall 不等式因此给出两解不可区分, 即路径唯一性.

对一般线性增长系数, 先在大球外截断, 应用上述构造. 不同截断的解在离开较小球以前相同, 因而可以按退出时刻拼接. 线性增长条件与 Gronwall 不等式给出独立于截断半径的估计

$$\mathbb{E} \sup_{t \leq T} |X_t|^2 \leq C_T(1 + \mathbb{E}|\xi|^2).$$

这个估计使在 T 以前离开半径越来越大的球的概率趋于零, 从而排除有限时间爆炸, 并给出结论中的最大矩界. 有界系数下的迭代构造和随后使用的估计见 [Kal21, Theorem 32.3, Proposition 32.6]. $\square$

若只要求局部 Lipschitz, 上述构造仍可在退出有界区域以前进行. 要把解延续到整个有限期限, 则须另外排除爆炸, 例如使用适当的 Lyapunov 估计.

几何 Brown 运动 第4.4节已经通过代入验证了

$$dS_t = \mu S_t dt + \sigma S_t dB_t, \quad S_0 > 0,$$

具有解

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma B_t \right).$$

现在可以进一步说明为什么没有另一个解: 系数 $b(x) = \mu x$ 和 $\sigma(x) = \sigma x$ 满足全局 Lipschitz 与线性增长条件, 所以上面的存在唯一性定理适用. 因而显式公式给出的就是唯一强解.

解始终为正, 则来自指数表示本身. 这一性质要由具体方程说明, 一般的存在唯一性定理并不规定解的取值范围. 接下来把漂移改为均值回复, 再把常数噪声改为平方根噪声, 就能看到系数怎样改变路径和边界行为.

Ornstein-Uhlenbeck 过程 令 $\kappa > 0, \theta \in \mathbb{R}, \sigma \geq 0$, 考虑

$$dX_t = \kappa(\theta - X_t) dt + \sigma dB_t.$$

当 X_t 高于 θ 时漂移向下, 低于 θ 时漂移向上, 偏离越大, 回复漂移也越大. 但 Brown 噪声仍然不断加入新的变化, 所以均值回复不等于每条路径最终停在 θ .

这是线性方程, 可以沿用积分因子法. 对 $e^{\kappa t} X_t$ 使用乘积公式, $e^{\kappa t}$ 的导数恰好抵消原漂移中的 $-\kappa X_t$. 由于积分因子连续且有限变差, 没有协变差修正, 得到

$$d(e^{\kappa t} X_t) = \kappa \theta e^{\kappa t} dt + \sigma e^{\kappa t} dB_t.$$

积分后整理为

$$X_t = \theta + (X_0 - \theta)e^{-\kappa t} + \sigma \int_0^t e^{-\kappa(t-s)} dB_s.$$

初值相对于中心的偏离按指数衰减. 每次较早的噪声冲击也乘上同样的衰减因子, 因而影响随时间减弱; 较新的冲击则保留更大的权重.

把起点从 0 移到 s , 给定 $\mathcal{F}_s$ 后, 后续随机积分均值为零, 所以

$$\mathbb{E}[X_t | \mathcal{F}_s] = \theta + (X_s - \theta)e^{-\kappa(t-s)}.$$

随机积分具有确定性的指数核. 对核的平方使用 Itô 等距, 得到条件方差

$$\text{Var}(X_t | \mathcal{F}_s) = \frac{\sigma^2}{2\kappa} \left(1 - e^{-2\kappa(t-s)} \right).$$

因此预测均值趋近 θ , 而预测方差趋近 $\sigma^2/(2\kappa)$, 并不会一般地趋于零.

若初值服从 $\mathcal{N}(\theta, \sigma^2/(2\kappa))$ 且独立于 Brown 运动的未来增量, 初值方差随时间衰减的部分恰好由新噪声补回, 因而每个时刻仍服从同一个正态分布. 这就是 OU 过程的不变分布.

CIR 型平方根扩散与零点行为 CIR 型过程仍使用回复漂移, 但把常数噪声幅度换成 $\sigma\sqrt{X_t}$. 令 $\kappa, \theta, \sigma > 0$, 考虑

$$dX_t = \kappa(\theta - X_t) dt + \sigma\sqrt{X_t} dB_t, \quad X_0 \geq 0.$$

靠近零时, 噪声幅度随平方根减小, 漂移则趋近正值 $\kappa\theta$. 两者怎样共同作用, 决定了过程能否真正到达零点.

这里不能直接应用前面的全局 Lipschitz 定理, 因为平方根函数在零附近不满足该条件. 一维 SDE 的专门比较与唯一性理论仍能证明存在唯一非负强解. 以下使用这一结论, 再区分非负与严格为正.

Feller 条件给出相应的零点行为:

1. 若 $2\kappa\theta \geq \sigma^2$ 且 $X_0 > 0$, 则过程几乎必然不会到达 0, 解始终严格为正;
2. 若 $0 < 2\kappa\theta < \sigma^2$, 则过程可以到达 0, 但标准非负解不会进入负半轴, 并在正漂移作用下瞬时离开边界;
3. 若把参数范围扩展到 $\theta = 0$, 则漂移和噪声在 0 处同时为零, 此时 0 成为吸收边界.

连续方程的非负性还不会自动传给离散算法. 普通 Euler 步把本步系数固定后加上一个 Gauss 增量, 这个增量可能使近似值越过零点, 即使真解没有这种行为. 因此数值计算需要使用保正格式或精确转移方法, 把近似值的取值范围与原方程相协调.

4.6 Girsanov 定理: 在有限期限内改变概率权重

第4.5节中的 Brown 性和漂移都相对于给定测度而言. 若改变样本路径的概率权重, 条件期望随之改变, 同一个过程的漂移也可能不同. Girsanov 定理说明怎样选择权重, 使原 Brown 运动加上一项时间积分以后, 成为新测度下的 Brown 运动.

要完成这件事, 首先需要真正的概率密度. 严格为正还不够, 它的期望必须等于 1. 随机指数提供候选密度, Novikov 条件则给出一条保证其期望保持为 1 的充分条件. 在此基础上, Girsanov 定理再确定新测度下的噪声和漂移.

密度过程与 Novikov 条件 令 ϑ 为可预测过程, 满足 $\int_0^T \vartheta_s^2 ds < \infty$ 几乎必然成立, 并取

$$Z_t = \mathcal{E} \left(- \int_0^t \vartheta_s dB_s \right)_t = \exp \left(- \int_0^t \vartheta_s dB_s - \frac{1}{2} \int_0^t \vartheta_s^2 ds \right).$$

指数中的第二项消除了函数变换产生的漂移, 因此 Z 是从 1 出发的正局部鞅, 也就是上鞅. 这只能先保证 $\mathbb{E}_{\mathbb{P}} Z_T \leq 1$. 若要用 Z_T 重新分配全部概率, 还须有 $\mathbb{E}_{\mathbb{P}} Z_T = 1$.

定理 4.25 (Novikov 充分条件).

若

$$\mathbb{E}_{\mathbb{P}} \left[\exp \left(\frac{1}{2} \int_0^T \vartheta_s^2 ds \right) \right] < \infty,$$

则 Z 是 $[0, T]$ 上的一致可积鞅, 特别地 $\mathbb{E}_{\mathbb{P}}[Z_T] = 1$.

证明. 应用连续局部鞅的 Novikov 判据 [Kal21, Theorem 19.24]. 把过程停止在 T , 记

$$M_t = - \int_0^{t \wedge T} \vartheta_s dB_s, \quad [M]_{\infty} = \int_0^T \vartheta_s^2 ds.$$

判据要求 $\mathbb{E} \exp([M]_{\infty}/2) < \infty$, 这正是这里的假设. 因而随机指数 $\mathcal{E}(M)$ 一致可积, 且期望保持为初值 1. 限制回 $[0, T]$ 就得到 Z 的结论, 并有 $Z_t = \mathbb{E}_{\mathbb{P}}[Z_T | \mathcal{F}_t]$. $\square$

Novikov 条件的作用是用累计平方的指数矩控制解除局部化时的尾部, 保住随机指数的期望. 它是充分条件, 不满足它并不能据此判定 Z 不是真鞅, 还可以使用其他方法证明. 但若已经知道 $\mathbb{E} Z_T < 1$, 那么 $Z_T d\mathbb{P}$ 的总质量确实小于 1, 不能把它直接当作新的概率测度.

Girsanov 定理及符号检查 得到密度过程后, 就可以判断原 Brown 运动加上怎样的漂移修正, 才会在新测度下成为 Brown 运动. 下文用 ϑ 表示漂移调整, 新测度下的 Brown 运动记为 $B^{\mathbb{Q}}$.

定理 4.26 (一维 Girsanov 定理).

假设上文定义的 Z 为真鞅, 并在 $\mathcal{F}_T$ 上定义

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = Z_T.$$

则 $\mathbb{Q}$ 与 $\mathbb{P}$ 在 $\mathcal{F}_T$ 上等价, 且

$$B_t^{\mathbb{Q}} = B_t + \int_0^t \vartheta_s ds$$

是 $\mathbb{Q}$ 下的标准 Brown 运动.

证明. Z_T 严格为正且期望为 1, 所以它定义了与 $\mathbb{P}$ 等价的概率测度 $\mathbb{Q}$. 接着使用由 Bayes 公式和随机分部积分得到的局部鞅变换: 连续 $\mathbb{P}$ -局部鞅 M 在扣去 $Z^{-1} \cdot [M, Z]$ 后, 成为 $\mathbb{Q}$ -局部鞅, 见 [Kal21, Theorem 19.20, Corollary 19.26].

对当前的随机指数, $dZ_t = -\vartheta_t Z_t dB_t$, 因而 $d[B, Z]_t = -\vartheta_t Z_t dt$. 取 $M = B$, 变换后的局部鞅正是 $B_t + \int_0^t \vartheta_s ds = B_t^{\mathbb{Q}}$. 加上的时间积分连续且有限变差, 所以二次变差仍为 t . 由连续局部鞅的 Brown 刻画, $B^{\mathbb{Q}}$ 是 $\mathbb{Q}$ 下的标准 Brown 运动.

引用中的另一种常见记号是 $Z = \mathcal{E}(V \cdot B)$, 对应 $\tilde{B} = B - \int V ds$. 本文取 $V = -\vartheta$, 因而 Brown 运动的修正项带正号. $\square$

终端密度也决定了此前各时刻的密度. 因为 Z 是真鞅, 对 $t \leq T$,

$$Z_t = \mathbb{E}_{\mathbb{P}}[Z_T | \mathcal{F}_t] = \left. \frac{d\mathbb{Q}}{d\mathbb{P}} \right|_{\mathcal{F}_t}.$$

只使用 $\mathcal{F}_t$ 中的信息时, 看不到终端密度的全部变化, 所以要对它取条件期望. 这解释了为什么需要整个密度过程, 而不只是一个终端随机变量.

漂移的改变可以直接代入计算. 假设在 $\mathbb{P}$ 下

$$dX_t = b_t dt + \sigma_t dB_t.$$

由 $dB_t = dB_t^{\mathbb{Q}} - \vartheta_t dt$, 同一个 X 在 $\mathbb{Q}$ 下满足

$$dX_t = (b_t - \sigma_t \vartheta_t) dt + \sigma_t dB_t^{\mathbb{Q}}.$$

噪声系数没有改变, 漂移减少了 $\sigma_t \vartheta_t$. 因而当 $\sigma_t \neq 0$ 时, 消去 b_t 所需的选择是 $\vartheta_t = b_t / \sigma_t$. 这个代数选择还须满足可预测性, 路径平方可积性及密度真鞅条件, 才真正对应一个概率测度变换.

例 4.27 (带常漂移的 Brown 运动).

在 $\mathbb{P}$ 下令 $X_t = B_t + \mu t$, 并取

$$Z_t = \exp \left(-\mu B_t - \frac{1}{2} \mu^2 t \right).$$

此时 $\vartheta_t = \mu$ 是常数, 有限期限上的 Novikov 条件成立. 因而在由 Z_T 定义的 $\mathbb{Q}$ 下, $B_t^{\mathbb{Q}} = B_t + \mu t = X_t$ 是标准 Brown 运动. 在 $\mathbb{P}$ 下 X_t 的均值为 μt , 在 $\mathbb{Q}$ 下则为零. 这两个平均值可以不同, 因为它们使用不同的概率权重.

原则 4.28 (改变测度与保留路径).

测度变换保留同一可测空间上的坐标值 $X_t(\omega)$, 改变的是计算概率和期望时的权重. 因此同一条实现没有被移动, 过程的分布和漂移却可以改变. 在这里的有限期限内, $\mathbb{P}$ 与 $\mathbb{Q}$ 等价还保证两者具有相同的零概率事件, 但并不要求一般事件的概率相同.

多维情形使用向量 ϑ , 随机指数中的平方换成 $\|\vartheta_t\|^2$, 并有 $W_t^{\mathbb{Q}} = W_t + \int_0^t \vartheta_s ds$. 代回 SDE 后, 漂移的改变量为 $-\sigma_t \vartheta_t$. 因此能够消去的漂移方向必须位于扩散矩阵 σ_t 的值域中; 没有噪声作用的方向, 不能靠这种 Brown 测度变换任意调整漂移.

4.7 生成元, Kolmogorov 方程与 Feynman–Kac

即使已经知道过程满足哪个 SDE, 未来函数的期望仍可能不容易直接算出. 若过程具有 Markov 性, 给定时刻 t 的状态 x 后, 这个期望可以写成确定函数 $u(t, x)$, 不必再把此前整条历史作为自变量.

我们将用 Itô 公式研究 $u(s, X_s)$ 随时间怎样变化. 生成元给出状态变化对条件平均的瞬时贡献; 若 u 表示同一个终端结果的未来期望, 它沿过程的变化应当是鞅, 相应的漂移为零, 这就产生 Kolmogorov 后向方程. 再加入贴现或沿途累计的收益, 同一个论证便得到 Feynman–Kac 公式.

从 Itô 公式读出生成元 考虑时变 Markov 扩散

$$dX_s = b(s, X_s) ds + \sigma(s, X_s) dW_s, \quad a = \sigma \sigma^T.$$

对空间函数 $f \in C^2(\mathbb{R}^d)$, Itô 公式中的时间积分系数为

$$(\mathcal{L}_t f)(x) = \sum_{i=1}^d b_i(t, x) \partial_i f(x) + \frac{1}{2} \sum_{i,k=1}^d a_{ik}(t, x) \partial_{ik} f(x).$$

这定义了时刻 t 的生成元. 第一项计算漂移怎样改变 f , 第二项计算波动通过 f 的曲率怎样改变平均值. 在允许取期望和短时间极限的条件下, $\mathcal{L}_t f(x)$ 就是从 (t, x) 出发时, $f(X)$ 的条件平均每单位时间的初始变化率.

扣除这部分累计变化以后, Itô 公式只留下随机积分:

$$f(X_t) - f(X_0) - \int_0^t (\mathcal{L}_s f)(X_s) ds.$$

它在相应可积条件下是局部鞅, 并在足够的可积性下成为真鞅. 也可以反过来, 要求一组测试函数都满足这种鞅性质, 用以描述过程的分布; 这就是扩散鞅问题的出发点.

若函数还显式依赖时间, 则除状态变化以外, 还要加入函数自身的时间变化. 因而作用于 $u(t, x)$ 的算子是 $\partial_t + \mathcal{L}_t$.

Kolmogorov 后向方程 固定终点 T 和终端函数 g , 以 (t, x) 为起点的过程记作 $X_s^{t,x}$, 定义

$$u(t, x) = \mathbb{E}[g(X_T^{t,x})].$$

这个函数给出从不同起始时刻, 不同起始状态出发时, 同一个终端结果的平均值. 可以直接从现在计算这个平均值, 也可以先让过程运行一小段时间, 再对新状态下的剩余期望取平均. Markov 性和塔性质保证两种计算相同. 后向方程把这种时间一致性写成一个微分关系.

定理 4.29 (Kolmogorov 后向方程).

假设 SDE 具有非爆炸 Markov 解, 系数具有足够正则性, 且上述期望定义的 u 属于 $C^{1,2}$ 并满足使随机积分成为真鞅的增长条件, 则

$$\partial_t u(t, x) + \mathcal{L}_t u(t, x) = 0, \quad 0 \leq t < T,$$

并具有终端条件

$$u(T, x) = g(x).$$

证明. Markov 性与塔性质给出

$$u(t, x) = \mathbb{E}[u(t+h, X_{t+h}^{t,x})],$$

其中 $h > 0$ 足够小. 对 $u(s, X_s^{t,x})$ 在 $[t, t+h]$ 上使用 Itô 公式. 随机积分在假设下是真鞅, 取期望后为零, 因而

$$0 = \mathbb{E} \int_t^{t+h} (\partial_s u + \mathcal{L}_s u)(s, X_s^{t,x}) ds.$$

除以 h 再令 $h \downarrow 0$, 正则性与增长条件允许把极限移入期望, 得到 $(\partial_t u + \mathcal{L}_t u)(t, x) = 0$. 当起始时刻就是 T 时, 没有剩余演化时间, 所以 $u(T, x) = g(x)$.

反方向同样来自 Itô 公式. 若经典解满足 PDE, 则 $u(s, X_s^{t,x})$ 的漂移为零. 在相应可积性下它是真鞅, 因而其期望从 t 到 T 保持不变: $u(t, x) = \mathbb{E}[u(T, X_T^{t,x})] = \mathbb{E}[g(X_T^{t,x})]$. 这也说明为什么 PDE 解的增长条件会影响期望表示. $\square$

对一维 Brown 运动, 生成元为 $\mathcal{L} = \frac{1}{2} \partial_{xx}$, 因而

$$u(t, x) = \mathbb{E}[g(x + B_{T-t})]$$

在 g 的增长和正则性足以支持经典解时满足

$$\partial_t u + \frac{1}{2} \partial_{xx} u = 0, \quad u(T, x) = g(x).$$

终端函数已经给定, 我们从 T 向较早的起始时刻求 u , 所以称为后向热方程. 距离终点的时间越长, 期望就把 g 与方差越大的 Gauss 分布作平均.

前向方程问的是另一件事: 固定初始分布以后, 概率质量怎样随时间移动? 若边缘分布有密度 $p(t, x)$, 相应方程形式上为

$$\partial_t p = \mathcal{L}_t^* p,$$

其中

$$\mathcal{L}_t^* p = - \sum_i \partial_i (b_i p) + \frac{1}{2} \sum_{i,k} \partial_{ik} (a_{ik} p).$$

这个伴随算子来自把作用在测试函数上的导数通过分部积分移到密度上. 前向方程从初始密度求后续密度; 后向方程从终端函数求此前的条件期望. 两者对应不同的未知函数与初终值条件.

带权期望的 Feynman–Kac 公式 只给终端函数 $g(X_T)$ 时, 后向方程计算的是终点结果的条件期望. 还可以在到达 T 以前不断累积一项 $h(s, X_s) ds$, 同时用 c 对未来各时刻作指数权重. 定义

$$D_{t,s} = \exp \left(- \int_t^s c(r, X_r^{t,x}) dr \right).$$

若 c 表示短期利率, $D_{t,s}$ 就是从 s 折回 t 的路径贴现因子; 若 $c \geq 0$ 表示杀死率, 同一个指数可以解释为存活权重. 对一般实值 c , 这里只把它看作期望中的指数权重.

Feynman–Kac 把终端项和沿途累积项放进同一个期望. 证明时, 在中间时刻 s 将 PDE 解 $u(s, X_s)$ 乘以权重 $D_{t,s}$, 再加上从 t 到 s 已经累计的加权 h 项. 对这个过程使用 Itô 公式和乘积公式, PDE 恰好使所有 ds 漂移项相消.

定理 4.30 (Feynman–Kac 公式).

假设对每个 (t, x) , 扩散 $X^{t,x}$ 在 $[t, T]$ 上存在且不爆炸, 并且沿其路径有

$$\int_t^T (|c(s, X_s^{t,x})| + |h(s, X_s^{t,x})|) ds < \infty \quad \text{a.s.}$$

若 $u \in C^{1,2}$ 解终值问题

$$\begin{cases} \partial_t u + \mathcal{L}_t u - cu + h = 0, & 0 \leq t < T, \\ u(T, x) = g(x), \end{cases}$$

并且

$$\mathbb{E} \left[D_{t,T} |g(X_T^{t,x})| + \int_t^T D_{t,s} |h(s, X_s^{t,x})| ds \right] < \infty,$$

同时

$$\int_t^\cdot D_{t,s} (\nabla u \sigma)(s, X_s^{t,x}) dW_s$$

是 $[t, T]$ 上的真鞅, 则

$$u(t, x) = \mathbb{E} \left[D_{t,T} g(X_T^{t,x}) + \int_t^T D_{t,s} h(s, X_s^{t,x}) ds \right].$$

证明. 固定起点 (t, x) , 考虑随 s 变化的过程

$$D_{t,s} u(s, X_s^{t,x}) + \int_t^s D_{t,r} h(r, X_r^{t,x}) dr.$$

第一项表示时刻 s 尚未实现部分的加权价值, 第二项记录从 t 到 s 已经累积的 h . 对第一项使用乘积公式. $D_{t,s}$ 连续且有限变差, 满足 $dD_{t,s} = -c(s, X_s^{t,x})D_{t,s}ds$, 所以它与 $u(s, X_s^{t,x})$ 的协变差为零.

Itô 公式给出 $\partial_s u + \mathcal{L}_s u$, $D_{t,s}$ 的变化给出 $-cu$, 第二项随时间增加时给出 h . 因而总漂移为

$$D_{t,s}(\partial_s u + \mathcal{L}_s u - cu + h)(s, X_s^{t,x}) ds = 0.$$

剩下的随机积分正是定理中假设为真鞅的那一项. 因此整个过程的期望保持不变. 在 $s = t$ 时它等于 $u(t, x)$; 在 $s = T$ 时, 代入 $u(T, \cdot) = g$ 就得到所述期望表示. $\square$

定理先从一个满足 $C^{1,2}$, 可积性和真鞅条件的 PDE 解出发, 证明它必定等于右边的带权期望. 因而在这些条件下, 两个经典解若都满足同样的表示条件, 就由同一个期望确定. 若反过来先定义右边的期望, 还要另行证明所得函数具有足够正则性并满足 PDE. 在经典光滑性不足时, 通常要改用弱解或黏性解等 PDE 理论.

相关标准版本见 [Kal21, Theorem 34.1], 其中处理有界终端函数, 有界非负权重和时齐 Feller 扩散的无源情形; Brown 运动与有界势函数的版本见 [Dur19, Theorem 9.4.1–9.4.5]. 上面的写法允许时变系数和额外的 h 项, 证明中因此多出对应的时间积分.

在金融语境中, g 可以表示到期现金流, $h(s, X_s)ds$ 表示持有期间连续发生的现金流, c 则可以取相应贴现率. Feynman–Kac 于是把这些现金流的贴现期望与终值 PDE 联系起来; 具体定价模型中, 所用测度和贴现过程再由相应的无套利论证确定.

4.8 Poisson 随机测度与跳跃

连续扩散没有跳跃, 而违约, 财报跳空或订单到达等变化可能集中在某些时刻. 第3.6节已经用计数过程描述到达次数, 现在把它放进随机积分和二次变差的计算中.

若 N 相对于当前滤过是强度 $\lambda > 0$ 的 Poisson 过程, 则

$$\tilde{N}_t = N_t - \lambda t$$

是鞅. N 的每次跳跃大小为 1, 平方仍为 1; 扣除连续函数 λt 不改变这些跳跃. 因而

$$[N]_t = [\tilde{N}]_t = N_t, \quad \langle \tilde{N} \rangle_t = \lambda t.$$

第一种括号累计实际发生的跳跃平方. 第二种称为可预测二次变差: 它从零出发, 可预测且递增, 并使 $\tilde{N}^2 - \langle \tilde{N} \rangle$ 成为局部鞅. 这里它就是实际平方累计 N 的补偿过程 λt .

在一段没有到达的时间里, $[\tilde{N}]$ 保持不变, 而 $\langle \tilde{N} \rangle$ 仍按模型强度增加. 前者记录已经发生多少, 后者记录可预测的平均累计. 这个例子也说明, 有限变差过程的二次变差为零需要连续性: N 虽然在有限区间上有有限变差, 却有非零的跳跃平方和.

若每次到达还带有大小, 类别等标记, 只记录总次数就不够了. 以 E 为标记空间, Poisson 随机测度 $N(dt, dz)$ 同时记录到达时间和标记. 例如, $N((s, t] \times A)$ 统计这段时间内标记落入 A 的到达次数. 对有限强度的 A , 其 Poisson 参数为 $(t - s)\nu(A)$.

相对于当前滤过, 设补偿测度为 $\nu(dz)dt$, 写作

$$\tilde{N}(dt, dz) = N(dt, dz) - \nu(dz)dt.$$

设 H 是可预测的带标记被积函数, 即它对可预测 σ -代数与标记 σ -代数的乘积可测. 若下面等式右端的积分有限, 则有

$$\mathbb{E} \left[\left(\int_0^T \int_E H(s, z) \tilde{N}(ds, dz) \right)^2 \right] = \mathbb{E} \int_0^T \int_E |H(s, z)|^2 \nu(dz) ds.$$

减去补偿测度以后, 简单积分的增量具有零条件平均. Poisson 计数的方差等于其平均值, 因而二阶矩正好得到右边对时间和标记强度的积分. 这给出了与 Brown 积分类似的 L^2 等距. 从简单被积函数出发, 再按这个等距作平方可积延拓, 就得到补偿 Poisson 随机测度积分; 与 Brown 积分不同, 所得积分过程本身可以跳跃.

同时包含连续噪声与跳跃的 SDE 可以写成

$$dX_t = b(t, X_{t-})dt + \sigma(t, X_{t-})dB_t + \int_E \gamma(t, X_{t-}, z) \tilde{N}(dt, dz).$$

γ 根据跳前状态和标记决定跳跃幅度. 使用 X_{t-} , 意味着在跳跃发生以前, 已为每个可能标记 z 确定幅度规则 $\gamma(t, X_{t-}, z)$; 到达的标记再决定实际采用哪一个幅度. 第3.3节中的可预测性要求的是这项规则依据跳前信息, 而不要求预先知道本次会出现哪个标记. 跳跃积分还须满足相应的可积性条件.

函数经过一次有限跳跃后的变化, 应当直接计算为 $f(X_s) - f(X_{s-})$, 不能只保留一个局部导数近似. 因此对一般一维半鞅和 $f \in C^2(\mathbb{R})$, Itô 公式为

$$f(X_t) = f(X_0) + \int_0^t f'(X_{s-}) dX_s + \frac{1}{2} \int_0^t f''(X_{s-}) d[X^c]_s + \sum_{0 < s \leq t} (f(X_s) - f(X_{s-}) - f'(X_{s-}) \Delta X_s).$$

第一项积分已经计入跳跃的一阶贡献 $f'(X_{s-}) \Delta X_s$, 所以最后的求和只补上实际函数变化与一阶贡献的差. 连续的二阶修正则仍由 $[X^c]$ 给出. 这样每次跳跃和连续波动都恰好计入一次.

公式并不要求有限区间内只有有限次跳跃. 局部化以后, 小跳的一阶 Taylor 余项可以由跳幅平方控制, 而半鞅在有限区间上的跳幅平方和有限, 所以这些余项能够累计. 若模型具有无限活动跳跃, 补偿积分本身还要通过相应的截断与极限构造.

补偿的选择还会影响方程中的漂移项. 因而同一个跳跃模型若改用另一种小跳补偿约定, 相应的漂移也必须一起改写.

4.9 连续扩散的计算次序

用一个矩计算把前面的工具连起来. 沿用本章的滤过概率空间和 Brown 运动, 取常数 μ, σ 及确定初值 $S_0 > 0$, 考虑乘法扩散 $dS_t = \mu S_t dt + \sigma S_t dB_t$. 我们要计算任意实数 p 对应的 $\mathbb{E}[S_t^p]$.

这条 SDE 表示前面已经写出的时间积分与 Brown 积分之和. 系数满足全局 Lipschitz 和线性增长条件, 因而存在唯一强解; 显式指数解又保证严格正性. 所以即使 p 为负, 也可以在正半轴上对 $f(x) = x^p$ 应用局部化后的 Itô 公式.

先从噪声系数读出 $d[S]_t = \sigma^2 S_t^2 dt$. 再把 $f'(x) = px^{p-1}$ 与 $f''(x) = p(p-1)x^{p-2}$ 代入, 得到

$$d(S_t^p) = \left(p\mu + \frac{1}{2}p(p-1)\sigma^2 \right) S_t^p dt + p\sigma S_t^p dB_t.$$

一阶导数把原漂移变成 $p\mu$, 曲率与二次变差共同给出 $\frac{1}{2}p(p-1)\sigma^2$. 这两个贡献在任何取期望以前就已经出现.

下一步才能去掉随机积分. 由指数解和 Gauss 变量的指数矩, S 在有限期限内具有所需的正负阶矩, 特别地 $\mathbb{E} \int_0^T S_s^{2p} ds < \infty$. 因而被积过程 $p\sigma S_s^p$ 平方可积, 随机积分是真鞅且期望为零.

将微分式还原为积分式并取期望, $m_p(t) = \mathbb{E}[S_t^p]$ 满足一个常系数线性积分方程, 其系数为 $p\mu + \frac{1}{2}p(p-1)\sigma^2$. 解出这个方程便得

$$\mathbb{E}[S_t^p] = S_0^p \exp \left(\left[p\mu + \frac{1}{2}p(p-1)\sigma^2 \right] t \right).$$

当 $p = 1$ 时曲率项消失, 得到原过程的均值增长; 当 $p = 2$ 时, 波动贡献保留在二阶矩中. 对负数 p , 公式仍成立的依据是解的正性和相应的矩可积性.

4.10 小结

本章从简单可预测过程的有限和出发, 用 Itô 等距构造随机积分, 再由二次变差得到 Itô 公式. SDE 把漂移和随机积分放入同一积分方程; Girsanov 改变计算概率时使用的权重; 生成元和 Feynman-Kac 则把扩散的条件期望与 PDE 联系起来. 带跳过程最后说明, 实际跳跃还要以跳前系数和跳跃修正项进入同一套半鞅计算.

下一章将在这些随机分析工具之上加入可交易资产, 自融资条件和无套利关系.

第五章 从随机过程到金融交易

假设一份合约约定：到期时股票涨得越多，卖方需要支付的钱也越多。卖方今天应该收取多少元期权费，又该怎样安排股票和现金，才能在到期时履行这项约定？这个问题把前面学过的随机过程变成了具体的交易问题：股票价格描述可能发生的变化，滤过记录交易者已经知道什么，持仓决定哪些变化会影响账户，自融资条件则要求每次调仓都有钱可用。

我们先只考虑今天和到期日，直接算出一笔复制交易。随后允许中途调仓，再把交易日期推广到连续时间。随机积分将在这里出现：它累加的是事先确定的持仓在后续价格变化中产生的收益。章末再加入买卖报价，实际成交，融资和结算，核对模型中的财富变化怎样落到一份现金账上。

本章的数值均用于说明计算。金额通常显示到小数点后两位，概率和持股数量至多显示三位；后续计算仍使用未舍入的数值。Brown 运动记为 W ，字母 B 留给现金账户或其他严格为正的计价资产。离散与连续时间的标准理论见 [HP81; Shr04a; Shr04b]。

5.1 一期二叉市场与期权复制

先设一股股票今天卖 100 元。我们只研究今天到某个约定到期日之间的一段期间，并且只在今天建仓，中间不再买卖。这就是一期，或称一时期。用 0 表示今天，用 1 表示到期日；这里的 1 表示下一个交易时点，不预先指定它是一日还是一年。

再把到期股价简化为两种可能：涨到 120 元，或跌到 90 元。只有两种后续结果，所以称为二叉。树上的节点表示某个时点已经到达的情形，分支表示从当前情形到下一时点的可能变化。




图 5.1：一期股价树。左端是建仓时点，右端是到期时点；股价单位为元/股。

这棵树还没有说明交易者怎样存钱或借钱。为此再加入一个现金账户：今天存入 1 元，到期变成 1.02 元；今天借入 1 元，到期也须偿还 1.02 元。因而现金的一期增长倍数为 $R = 1.02$ ，对应这一整期的利率为 2%。

下面的复制定价先采用无摩擦交易约定：股票可以买入，也可以卖空；数量可以任意细分；存款和借款使用相同利率；买卖按同一模型价格完成，暂不计税费，价差，违约和数量限制。股票，现金账户以及这些交易规则合在一起，才构成我们要研究的市場。

例 5.1 (先看合约，再安排备付资金)。

考虑一份执行价格为 $K = 105$ 元的欧式看涨期权，每份对应一股股票。

看涨期权的买方取得这样一项权利：到期时可以按 105 元买入一股股票，也可以放弃购买。105 元就是执行价格。“欧式”规定这项购买权只能在到期日行使。

如果到期股价为 120 元，买方可以按 105 元取得一股市值为 120 元的股票，这项权利值

$$120 - 105 = 15$$

元。如果到期股价只有 90 元，买方可以直接在市场上按 90 元购买，没有必要按 105 元行权，所以会放弃这项权利。

若采用实物交割，行权时买方支付 105 元并收到一股股票。在上述无摩擦约定下，收到股票后立即按 120 元卖出，净收款为 15 元。为了直接核对现金账，本例约定采用差额现金结算：

到期由卖方向买方支付

$$X_1 = (S_1 - K)^+, \quad x^+ = \max\{x, 0\}.$$

因而两种状态的到期支付为

$$X_u = 15, \quad X_d = 0.$$

这是合约的到期支付, 尚未扣除买方今天支付的期权费.

现在替卖方安排备付资金. 我们希望今天买入一些股票, 再配上存款或借款, 使组合到期时在两种状态下分别剩下 15 元和 0 元. 这样的组合称为期权的**复制组合**.

设今天买入 Δ 股, 并在现金账户中留下 β 元. $\beta < 0$ 表示借款. 到期现金金额为 1.02β , 所以必须同时满足

$$120\Delta + 1.02\beta = 15,$$

$$90\Delta + 1.02\beta = 0.$$

两式相减, 现金部分消去:

$$30\Delta = 15, \quad \Delta = \frac{1}{2}.$$

这一步先确定股票数量. 两种状态的股价相差 30 元, 而期权支付相差 15 元, 所以半股恰好产生所需的支付差别.

再把半股代回下跌状态的等式:

$$\frac{1}{2} \times 90 + 1.02\beta = 0.$$

因而

$$\beta = -\frac{45}{1.02} \approx -44.12.$$

也就是说, 今天借入约 44.12 元, 到期偿还的本金和利息合计恰为 45 元.

买入半股需要 50 元, 借款提供其中的 $45/1.02$ 元, 所以还需要投入

$$V_0 = 50 - \frac{45}{1.02} = \frac{100}{17} \approx 5.88$$

元. 到期再逐项核对:

$$\begin{aligned} \text{上涨时: } & \frac{1}{2} \times 120 - 45 = 15, \\ \text{下跌时: } & \frac{1}{2} \times 90 - 45 = 0. \end{aligned}$$

无论出现哪种结果, 卖出股票并偿还借款后, 剩余现金都恰好支付期权义务. 因此卖方收到约 5.88 元期权费后, 可以用这笔钱加上借款建立复制组合.

刚才的计算没有预测上涨的概率. 我们只要求同一组初始持仓在两种结果中都匹配支付. 下面把这笔交易写成一般形式, 再解释为什么复制成本也是无套利价格.

5.1.1 状态, 价格倍数与一般复制公式

用

$$\Omega = \{\omega_u, \omega_d\}$$

表示两个可能结果. ω_u 和 ω_d 是状态, 分别给较高和较低的到期价格命名. 现实概率记为

$$\mathbb{P}(\omega_u) = p, \quad \mathbb{P}(\omega_d) = 1 - p, \quad 0 < p < 1.$$

这个条件保证模型中的两种结果都确实可能发生. 下面的复制计算只需要这一点, 无须知道 p 的具体数值.

沿用前面的滤过概率空间记号. 一期模型的信息为

$$\mathcal{F}_0 = \{\emptyset, \Omega\}, \quad \mathcal{F}_1 = 2^\Omega.$$

今天尚不能区分两种终态, 所以今天选择的持仓必须对两种结果相同. 到期以后, 才知道实际发生的是哪一种.

把股票的两种增长倍数记为 α_u 和 α_d :

$$S_1(\omega_u) = \alpha_u S_0, \quad S_1(\omega_d) = \alpha_d S_0, \quad S_0 > 0, \quad 0 < \alpha_d < \alpha_u.$$

这里 ω_u 是一个结果, α_u 是一个数. 例如刚才的上涨状态满足

$$S_1(\omega_u) = 1.20 \times 100 = 120.$$

增长倍数 1.20 对应收益率 20%, 并不表示上涨概率为 1.20. 同样, $\alpha_d = 0.90$ 对应收益率 -10%.

现金账户取

$$B_0 = 1, \quad B_1 = R, \quad R > 0.$$

因此 α_u, α_d, R 都是同一期间的增长倍数, 可以直接比较. 一般模型只要求 $\alpha_d < \alpha_u$, 不要求两者一定分处 1 的两侧; “上涨支”和“下跌支”在这里分别指较高价格的一支和较低价格的一支.

现在给定任意一份两状态现金流:

$$X_1(\omega_u) = X_u, \quad X_1(\omega_d) = X_d.$$

X_u, X_d 都是到期时的货币金额. 持有 Δ 股股票和 β 单位现金账户, 复制条件为

$$\Delta \alpha_u S_0 + \beta R = X_u,$$

$$\Delta \alpha_d S_0 + \beta R = X_d.$$

由于 $B_0 = 1$, β 在今天也等于现金金额. 两式相减, 再代回其中一式, 得到

$$\Delta = \frac{X_u - X_d}{S_0(\alpha_u - \alpha_d)}, \quad \beta = \frac{\alpha_u X_d - \alpha_d X_u}{R(\alpha_u - \alpha_d)}.$$

$\alpha_u \neq \alpha_d$ 保证这组解唯一. 股票复制两个支付之间的差别, 现金账户再把两种状态的支付共同移到正确水平.

将持仓成本相加并整理:

$$\begin{aligned} V_0 &= \Delta S_0 + \beta \\ &= \frac{1}{R} \left(\frac{R - \alpha_d}{\alpha_u - \alpha_d} X_u + \frac{\alpha_u - R}{\alpha_u - \alpha_d} X_d \right). \end{aligned}$$

如果

$$\alpha_d < R < \alpha_u,$$

括号中的两个系数都严格为正, 并且相加等于 1. 于是令

$$q = \frac{R - \alpha_d}{\alpha_u - \alpha_d}, \quad 1 - q = \frac{\alpha_u - R}{\alpha_u - \alpha_d},$$

就能把同一个复制成本写成

$$V_0 = \frac{1}{R} (q X_u + (1 - q) X_d).$$

在前面的看涨期权例子中,

$$q = \frac{1.02 - 0.90}{1.20 - 0.90} = 0.4,$$

所以

$$V_0 = \frac{0.4 \times 15 + 0.6 \times 0}{1.02} \approx 5.88.$$

这里的 q 是从股票价格, 现金增长倍数和复制成本中算出来的. 我们没有先假定现实中上涨的概率为 40%.

5.1.2 无套利为什么要求现金增长倍数位于两支之间

在本模型中, 套利指这样一笔交易: 初始净投入为零, 到期在两种可能结果中都不亏损, 并且至少在一种正概率结果中盈利.

命题 5.2 (二叉市场的无套利条件).

在上述一期市场及交易约定下, 市场无套利当且仅当

$$\alpha_d < R < \alpha_u.$$

证明. 先证明必要性.

如果 $R \leq \alpha_d$, 今天借入 S_0 元并买入一股股票. 借款收入与买股支出相抵, 初始净投入为零. 到期卖出股票并偿还借款, 剩余

$$S_1 - RS_0 = \begin{cases} (\alpha_u - R)S_0, & \omega_u, \\ (\alpha_d - R)S_0, & \omega_d. \end{cases}$$

两种状态都非负, 且上涨状态严格为正, 构成套利.

如果 $R \geq \alpha_u$, 则反过来卖空一股股票, 把收到的 S_0 元存入现金账户. 初始净投入仍为零. 到期用现金买回股票归还, 剩余

$$RS_0 - S_1.$$

两种状态都非负, 且下跌状态严格为正, 也构成套利. 因而无套利要求 $\alpha_d < R < \alpha_u$.

再证明充分性. 在这个严格不等式下, 定义

$$\mathbb{Q}^B(\omega_u) = q, \quad \mathbb{Q}^B(\omega_d) = 1 - q, \quad q = \frac{R - \alpha_d}{\alpha_u - \alpha_d}.$$

因为 $p, q \in (0, 1)$, 两个测度赋予相同的事件零概率, 即 $\mathbb{Q}^B \sim \mathbb{P}$. 而

$$q\alpha_u + (1 - q)\alpha_d = R,$$

所以

$$\mathbb{E}^{\mathbb{Q}^B} \left[\frac{S_1}{B_1} \right] = S_0 = \frac{S_0}{B_0}.$$

股票的贴现价格满足一期鞅等式.

任意股票与现金组合的贴现终值期望因此等于其初始成本:

$$\mathbb{E}^{\mathbb{Q}^B} \left[\frac{\Delta S_1 + \beta R}{R} \right] = \Delta S_0 + \beta.$$

如果一个零初始成本组合构成套利, 它的贴现终值在 $\mathbb{Q}^B$ 下也非负, 且以正概率严格为正, 期望便应严格为正. 这与上式的零期望矛盾. $\square$

上标 B 表示以现金账户为计价资产. 测度 $\mathbb{Q}^B$ 使贴现股票价格成为鞅, 称为这里的**风险中性测度**. 于是一般复制公式可以写成

$$V_0 = \frac{1}{R} \mathbb{E}^{\mathbb{Q}^B} [X_1].$$

这是一种表达复制成本的方法. 它没有把现实中的股票收益率改成现金利率.

命题 5.3 (复制, 完备性与风险中性概率).

当 $\alpha_d < R < \alpha_u$ 时, 每个有限值的两状态现金流都能由股票和现金账户唯一复制. 因而市场完备, 复制成本是合约的唯一无套利价格, 而

$$q = \frac{R - \alpha_d}{\alpha_u - \alpha_d}$$

是以 B 为计价资产的唯一风险中性上涨概率.

证明. 联立复制方程所得的唯一解已经证明了复制能力.

若合约价格高于复制成本, 卖出合约并买入复制组合, 会在今天收到一笔正价差. 再把这笔价差全部存入现金账户, 初始净投入便为零. 到期时复制组合恰好支付合约义务, 现金账户中的价差及其增长全部留下, 构成套利.

若合约价格低于复制成本, 则买入合约并卖空复制组合, 同样把收到的价差存入现金账户. 到期合约支付抵消复制组合的空头义务, 仍会留下严格为正的现金. 因而无套利价格只能等于复制成本.

最后, 任何使贴现股票成为鞅的上涨权重都必须满足

$$q\alpha_u + (1 - q)\alpha_d = R.$$

由于两种增长倍数不同, 这个方程唯一确定 q . □

整个复制计算都没有使用现实概率 p . 原因在于我们逐个终态匹配支付, 哪一支更常出现并不改变匹配关系. p 用于计算现实中的平均收益和风险, q 用于把由可交易资产确定的复制成本写成期望. 下一步允许中途调整持仓以后, 仍然遵守同一时间顺序: 先根据已知信息决定持仓, 再承担随后发生的价格变化.

5.2 多期离散时间: 鞅, 自融资与基本定理

一期模型只在今天建仓一次. 多期市场允许交易者在中间日期看到新价格以后, 重新安排股票和现金. 这时除了问“应该持有多少”, 还要问“调仓的钱从哪里来”.

例 5.4 (一次不追加资金的调仓).

今天有 1,000 元, 股票价格为每股 100 元. 买入 6 股花费 600 元, 其余 400 元存入现金账户. 假设现金账户在这一期增长 1%.

到下一交易日, 股票价格变成每股 110 元, 期间没有股息. 调仓前有

$$6 \times 110 = 660$$

元股票, 以及

$$400 \times 1.01 = 404$$

元现金, 合计财富为

$$V_1 = 660 + 404 = 1,064.$$

现在决定下一期持有 8 股. 多买的 2 股需要 220 元, 从已有现金中支付后, 现金剩下

$$404 - 2 \times 110 = 184.$$

调仓后的组合价值为

$$8 \times 110 + 184 = 1,064.$$

调仓改变了股票和现金的比例, 没有改变账户当时的总财富, 也没有要求从外部再投入资金. 这就是**自融资**.

还要区分现金金额与现金账户单位数. 若 $B_0 = 1$, $B_1 = 1.01$, 初始 400 元对应 400 单位现金账户. 调仓后的 184 元则对应

$$\psi_2 = \frac{184}{1.01}$$

单位账户. B_1 是每单位账户的价值, ψ_2 是单位数, 两者相乘才是现金金额.

再单独考虑有股息的情形. 若同一天旧持仓还取得每股 2 元股息, 应收到的是

$$6 \times 2 = 12$$

元. 在相同的除息股价 110 元下, 调仓前财富变成 1,076 元, 买入两股后现金剩下 196 元. 这次股息属于此前持有的 6 股, 刚买入的两股不参与已经支付的股息.

这个例子说明了记账顺序: 先让旧持仓经历本期的价格变化, 收取本期分配和现金利息, 然后用得到的财富安排下一期持仓. 下面把这个顺序写成一般定义.

交易日期为

$$\mathbb{T} = \{0, 1, \dots, T\}.$$

市场有一项严格为正的现金或货币市场账户 B , 以及 d 只风险资产. 令 S_t 为各资产在当期现金分配支付后的除息价格向量, ΔD_t 为本期每单位资产另行支付的现金向量.

用 θ_t 表示在 $(t-1, t]$ 期间持有的风险资产数量, 用 ψ_t 表示这期间持有的现金账户单位数. 两者必须在时刻 $t-1$ 已经确定:

$$\phi_t = (\psi_t, \theta_t) \text{ 为 } \mathcal{F}_{t-1}\text{-可测, } t = 1, \dots, T.$$

这就是离散时间持仓的可预测性. 在日期 t 得知的新价格, 可以用于选择 θ_{t+1} , 不能倒过来决定已经承担本期收益的 θ_t .

定义 5.5 (离散时间自融资策略).

初始财富为

$$V_0 = \psi_1 B_0 + \theta_1 \cdot S_0.$$

对 $t = 1, \dots, T$, 将本期旧持仓按除息价格计值, 再加上它收到的本期现金分配, 得到

$$V_t = \psi_t B_t + \theta_t \cdot (S_t + \Delta D_t).$$

如果在每个中间日期 $t = 1, \dots, T-1$, 下一期持仓的购买成本恰好等于这笔已有财富:

$$\psi_{t+1} B_t + \theta_{t+1} \cdot S_t = V_t,$$

就称策略 ϕ 是自融资的.

左边使用新持仓和当前除息价格, 表示调仓需要多少钱; 右边使用旧持仓, 表示本期结束后实际有多少钱. 两边相等, 就说明调仓没有追加资金或提走资金. 股票增持所需的钱从现金账户支付, 减持收到的钱回到现金账户.

5.2.1 贴现以后, 现金账户怎样消去

将财富除以 B_t , 就是在用现金账户的单位数衡量财富:

$$\tilde{V}_t = \frac{V_t}{B_t}.$$

一笔在日期 k 收到的分配 ΔD_k , 当时可以换成 $\Delta D_k/B_k$ 单位现金账户. 因而截至日期 t , 每单位风险资产的贴现价格与历次分配合计为

$$\tilde{G}_t = \frac{S_t}{B_t} + \sum_{k=1}^t \frac{\Delta D_k}{B_k}.$$

这称为贴现累计收益过程. 各笔分配按各自支付时点的 B_k 换算; 收到以后继续存入现金账户, 所持账户单位数不再改变.

自融资条件给出本期期初的价值等式

$$V_{t-1} = \psi_t B_{t-1} + \theta_t \cdot S_{t-1}.$$

将它与本期期末财富分别贴现后相减:

$$\begin{aligned} \tilde{V}_t - \tilde{V}_{t-1} &= \left(\psi_t + \theta_t \cdot \frac{S_t + \Delta D_t}{B_t} \right) - \left(\psi_t + \theta_t \cdot \frac{S_{t-1}}{B_{t-1}} \right) \\ &= \theta_t \cdot \left(\frac{S_t}{B_t} - \frac{S_{t-1}}{B_{t-1}} + \frac{\Delta D_t}{B_t} \right) \\ &= \theta_t \cdot (\tilde{G}_t - \tilde{G}_{t-1}). \end{aligned}$$

现金持仓 ψ_t 消去, 因为以现金账户自身为单位衡量时, 本期持有的账户单位数没有增长. 对各期求和, 得到

$$\tilde{V}_t = \tilde{V}_0 + \sum_{k=1}^t \theta_k \cdot (\tilde{G}_k - \tilde{G}_{k-1}).$$

每一项都是期初已经确定的持仓, 乘以随后发生的贴现累计收益增量. 这与第3.3节中的交易增益具有相同的时间顺序. 股息必须包含在增量中: 除息时价格有所下降, 但持有人同时收到现金, 只记录价格变化会漏掉这部分收入.

命题 5.6 (贴现收益鞅推出无套利).

假设存在 $\mathbb{Q}^B \sim \mathbb{P}$, 使每只风险资产的贴现累计收益过程 $\tilde{G}$ 都是 $\mathbb{Q}^B$ -鞅. 对给定的有限初始财富, 每个有界的可预测自融资策略的贴现财富 $\tilde{V}$ 也是 $\mathbb{Q}^B$ -鞅.

更一般地, 同一结论适用于其交易增益积分确为真鞅的策略. 市场不存在由这类策略构成的套利.

证明. 由自融资恒等式,

$$\begin{aligned} \mathbb{E}^{\mathbb{Q}^B} [\tilde{V}_t - \tilde{V}_{t-1} \mid \mathcal{F}_{t-1}] &= \mathbb{E}^{\mathbb{Q}^B} [\theta_t \cdot (\tilde{G}_t - \tilde{G}_{t-1}) \mid \mathcal{F}_{t-1}] \\ &= \theta_t \cdot \mathbb{E}^{\mathbb{Q}^B} [\tilde{G}_t - \tilde{G}_{t-1} \mid \mathcal{F}_{t-1}] \\ &= 0. \end{aligned}$$

持仓 θ_t 在期初已知, 所以可以提出条件期望. 持仓有界, 收益增量可积, 保证了这里的乘积也可积.

若零初始财富策略构成套利, 则其终端财富在 $\mathbb{P}$ 下非负, 且以正概率严格为正. 测度等价使这些性质在 $\mathbb{Q}^B$ 下仍然成立. 又因为 $B_T > 0$, 贴现终值应有严格正的期望, 但鞅性要求

$$\mathbb{E}^{\mathbb{Q}^B} [\tilde{V}_T] = \tilde{V}_0 = 0.$$

矛盾. □

上面的论证从一个鞅测度出发, 推出没有套利. 在有限树上, 反过来也成立.

命题 5.7 (有限树上的金融市场基本定理).

考虑有限时间, 有限状态树上的无摩擦市场, 节点上允许双向交易. 假设树具有单一根节点, 因而 $\mathcal{F}_0 = \{\emptyset, \Omega\}$, 且全部模型内终端状态均有严格正的现实概率. 则:

1. 市场无套利, 当且仅当存在至少一个 $\mathbb{Q}^B \sim \mathbb{P}$, 使全部贴现累计收益过程成为 $\mathbb{Q}^B$ -鞅.
2. 在无套利成立以后, 市场对全部有限值的 $\mathcal{F}_T$ -可测终端现金流完备, 当且仅当这样的 $\mathbb{Q}^B$ 唯一.

第一项说明, 在有限树上没有套利, 就能给各条路径赋予严格正的定价权重, 使可交易资产的贴现累计收益成为鞅. 第二项进一步区分了“有相容的定价权重”和“定价权重只有一组”. 当股票和现金足以复制每一种终端现金流时, 所有支付的价格都已由复制决定, 鞅测度也就唯一.

若市场不完备, 可能存在多个与现有资产价格相容的 $\mathbb{Q}^B$. 对可复制支付, 它们给出的贴现期望仍然相同, 因为复制成本已经唯一. 对不可复制支付, 现有资产没有确定全部定价权重, 仅凭无套利便可能得到一组相容价格.

注 5.8 (从有限树到连续时间).

在无限状态或连续时间中, 还可能出现一系列策略: 每一项都不构成套利, 但它们逐渐接近一种损失风险趋于零而仍保留正收益机会的交易. 推广基本定理时, 必须控制这样的极限, 例如使用“无免费午餐且风险趋于消失”条件.

对局部有界的半鞅价格, 相应结论涉及等价局部鞅测度; 对一般半鞅, 还须采用更一般的表述. 有限树上的无套利条件和鞅测度结论不能逐字搬到连续时间.

5.3 停时与美式合约: Snell 包络

第5.1节和 第5.2节研究了怎样选择持仓. 现在再允许期权持有人选择行权日期. 这个决定只能使用当时已经知道的信息, 所以行权规则应当是停时.

欧式期权只允许在到期日行权; 美式期权则允许在到期前行权. 下面用离散时间模型描述这种选择, 在模型列出的日期比较立即行权与继续持有. 这里讨论的是向合约对手方行使权利的时间. 欧式期权的持有人仍可能在到期前将期权卖给别人, 卖出合约与行权是两笔不同的交易.

例 5.9 (用两期树算出美式看跌期权的继续价值).

考虑交易日期 0, 1, 2, 总期限为两期. 股票今天为 100 元, 每一期从当前价格出发, 都可能乘以 1.20 或 0.80. 现金账户每期增长 5%, 即

$$S_0 = 100, \quad \alpha_u = 1.20, \quad \alpha_d = 0.80, \quad R = 1.05.$$

R 是每一期的增长倍数, 这里没有把它换算成年利率.

这次考虑执行价为 $K = 100$ 元的看跌期权. 持有人有权按 100 元卖出一股股票. 若采用现金结算, 在允许的行权日期 t 立即行权, 收到


$$H_t = (100 - S_t)^+.$$

合约允许在 0, 1, 2 三个日期行权; 一旦行权, 合约终止.

因为每个节点都有 $0.80 < 1.05 < 1.20$, 每期的风险中性上涨权重为

$$q = \frac{1.05 - 0.80}{1.20 - 0.80} = \frac{5}{8} = 0.625, \quad 1 - q = \frac{3}{8}.$$

从一个节点计算下一期现金流的价格时, 先按这两个权重求和, 再除以 R .



图中的 H_t 是合约尚未行权时, 在该节点立即行权可取得的金额. 两条先涨后跌与先跌后涨的路径都到达股价 96, 因而图中合并了这个终价; 持有人是否已经提前行权, 仍取决于实际经过的历史.

从最后一期开始计算. 到期后没有等待机会, 所以三个终价对应的期权支付分别为

$$(100 - 144)^+ = 0, \quad (100 - 96)^+ = 4, \quad (100 - 64)^+ = 36.$$

再回到日期 1 的上节点. 此时股价为 120, 立即行权得不到钱. 若等待到期, 下一期会收到 0 或 4 元, 这项未来权利在日期 1 的价值为

$$\frac{q \times 0 + (1 - q) \times 4}{R} = \frac{1.5}{1.05} = \frac{10}{7} \approx 1.43.$$

因此上节点的期权价值为

$$V_1^u = \max \left\{ 0, \frac{10}{7} \right\} = \frac{10}{7},$$

应继续持有.

在日期 1 的下节点, 股价为 80, 立即行权可以收到 20 元. 若继续等待, 下一期支付为 4 或 36 元, 继续价值为

$$\frac{q \times 4 + (1 - q) \times 36}{R} = \frac{16}{1.05} = \frac{320}{21} \approx 15.24.$$

因而

$$V_1^d = \max \left\{ 20, \frac{320}{21} \right\} = 20.$$

在这个节点, 现在收到 20 元比保留价值约 15.24 元的权利更合算, 应立即行权. 两个数都已经是日期 1 的货币金额, 可以直接比较.

最后回到今天. 立即行权支付为零. 若保留合约, 下一期会得到上节点价值 10/7, 或下节点的最优行权金额 20. 所以

$$\begin{aligned} V_0 &= \max \left\{ 0, \frac{\frac{5}{8} \cdot \frac{10}{7} + \frac{3}{8} \cdot 20}{1.05} \right\} \\ &= \frac{1175}{147} \approx 7.99. \end{aligned}$$

今天的继续价值已经包含明天的最优选择: 到下节点时行权, 到上节点时继续等到到期.

为看清提前行权权利值多少, 再计算同一棵树上只能在日期 2 行权的欧式看跌期权:

$$V_0^{\text{Eur}} = \frac{q^2 \times 0 + 2q(1 - q) \times 4 + (1 - q)^2 \times 36}{R^2} = \frac{925}{147} \approx 6.29.$$

美式期权多出的约 1.70 元, 来自它允许持有人在下节点提前取得 20 元, 而不必继续持有那项只值约 15.24 元的到期权利.

上面的倒推使用定价权重 q , 因为我们比较的是立即行权的现金与继续持有合约的复制价值. 它不要求现实中上涨概率恰为 5/8. 若研究买入这份期权的现实平均损益, 则要用现实概率, 并把买入时支付的期权费计入.

现在将逐节点的比较写成一般形式. 仍取有限日期 $0, 1, \dots, T$, 固定定价测度 $\mathbb{Q}^B$. 令适应过程 H_t 表示日期 t 立即行权的现金支付, 并令

$$\tilde{H}_t = \frac{H_t}{B_t}.$$

假设每个 $\tilde{H}_t$ 都在 $\mathbb{Q}^B$ 下可积. 用 $\mathcal{T}_{t,T}$ 表示取值于 $\{t, t+1, \dots, T\}$ 的所有停时. 从日期 t 开始允许选择行权时间, 最优贴现行权价值为

$$Y_t = \text{ess sup}_{\tau \in \mathcal{T}_{t,T}} \mathbb{E}^{\mathbb{Q}^B} [\tilde{H}_\tau | \mathcal{F}_t].$$

每一种行权规则给出的条件期望都会随当前信息变化, 所以这里的上确界也是随机变量. 本质上确界是几乎必然支配所有候选值的最小随机变量. 在有限状态树上, 它就是在各个节点算出的最优值.

定义 5.10 (Snell 包络).

支配 $\tilde{H}$ 的最小 $\mathbb{Q}^B$ -上鞅称为支付过程的 **Snell 包络**. 在有限离散时间中, 它由以下倒推构造:

$$Y_T = \tilde{H}_T, \quad Y_t = \max \left\{ \tilde{H}_t, \mathbb{E}^{\mathbb{Q}^B} [Y_{t+1} | \mathcal{F}_t] \right\}.$$

这个递推保留了刚才例子的两个选择. 第一项是在当前日期立即行权, 第二项是把权利保留到下一期, 并从下一期起继续作最优选择. 因为已经用 B 贴现, 第二项外面不必再写一次现金折现因子.

证明. 有限次条件期望和取最大值保持这里所需的可积性. 递推直接给出

$$Y_t \geq \tilde{H}_t, \quad Y_t \geq \mathbb{E}^{\mathbb{Q}^B}[Y_{t+1} | \mathcal{F}_t],$$

所以 Y 是支配支付的上鞅.

若另一上鞅 U 也支配 $\tilde{H}$, 则 $U_T \geq \tilde{H}_T = Y_T$. 假设已经知道 $U_{t+1} \geq Y_{t+1}$, 那么

$$U_t \geq \tilde{H}_t, \quad U_t \geq \mathbb{E}^{\mathbb{Q}^B}[U_{t+1} | \mathcal{F}_t] \geq \mathbb{E}^{\mathbb{Q}^B}[Y_{t+1} | \mathcal{F}_t].$$

因而 $U_t \geq Y_t$. 向前反推便证明了最小性.

定义首次达到立即行权价值的日期

$$\tau_t^* = \inf\{s \in \{t, \dots, T\} : Y_s = \tilde{H}_s\}.$$

由于两个过程都适应, τ_t^* 是停时; 又因为到期时 $Y_T = \tilde{H}_T$, 它不会超过 T .

在首次接触以前, 立即行权项严格小于 Y_s , 所以递推必须选择继续价值:

$$Y_s = \mathbb{E}^{\mathbb{Q}^B}[Y_{s+1} | \mathcal{F}_s].$$

因而从 t 开始, 将 Y 停在 τ_t^* 后得到一个鞅. 由有限期限上的可选停止及接触时的等式,

$$Y_t = \mathbb{E}^{\mathbb{Q}^B}[Y_{\tau_t^*} | \mathcal{F}_t] = \mathbb{E}^{\mathbb{Q}^B}[\tilde{H}_{\tau_t^*} | \mathcal{F}_t].$$

对任意其他允许的停时 τ , 上鞅性和支配关系给出

$$\mathbb{E}^{\mathbb{Q}^B}[\tilde{H}_\tau | \mathcal{F}_t] \leq \mathbb{E}^{\mathbb{Q}^B}[Y_\tau | \mathcal{F}_t] \leq Y_t.$$

因此 τ_t^* 取得最优停止值, 递推与本质上确界表达式相同. $\square$

首次接触给出了最早的最优行权时间; 立即行权与继续价值相等时, 已经可以停止. 在完备的有限市场中, 换回货币单位就得到美式合约价格

$$V_t = B_t Y_t.$$

对应的货币递推是

$$V_t = \max \left\{ H_t, B_t \mathbb{E}^{\mathbb{Q}^B} \left[\frac{V_{t+1}}{B_{t+1}} \middle| \mathcal{F}_t \right] \right\}.$$

若每期现金增长倍数为确定的 R , 第二项就成为下一期最优价值的条件期望除以 R , 恰好回到两期例子的算法.

5.4 连续时间的持仓收益与自融资

离散时间的自融资增益为

$$\sum_{k=1}^t \theta_k \cdot (\tilde{G}_k - \tilde{G}_{k-1}).$$

这里每一项都先确定持仓, 再计入后续收益. 若把交易日期排得越来越密, 我们仍希望累加同样的量, 只是有限求和要换成随机积分.

例如, 在一段时间 $(t_k, t_{k+1}]$ 内保持持股数量不变, 这段时间的股票收益就是

$$\theta_{t_k} (S_{t_{k+1}} - S_{t_k}).$$

即使股价走出了非常不规则的 Brown 路径, 这笔分段持仓的账仍然清楚. 连续时间理论所做的, 是在适当的可积性条件下把这种交易增益推广到更一般的持仓过程. 半鞅提供了进行这种推广的价格过程类.

5.4.1 持仓, 分红与自融资等式

在前面的滤过概率空间上, 设 B 是严格为正, 连续且有限变差的现金账户. 设 S 是适应的 càdlàg d 维除息价格半鞅. 用 D 记录每单位风险资产累计支付的现金; 本节取 $D_0 = 0$, 并假设 D 适应, 连续且有限变差.

与离散时间一样, 分配应在收到时换成现金账户单位. 因而

$$\tilde{G}_t = \frac{S_t}{B_t} + \int_{(0,t]} \frac{1}{B_u} dD_u.$$

第二项是对有限变差过程的 Stieltjes 积分. 若一小笔分配在日期 u 收到, 它买到的账户单位数就是这笔现金除以当时的 B_u .

沿用 $L(X)$ 表示对半鞅 X 可积的可预测过程类. 用可预测过程 ψ 和 θ 分别表示现金账户与风险资产持仓, 要求

$$\psi \in L(B), \quad \theta^i \in L(S^i) \cap L(D^i), \quad i = 1, \dots, d.$$

下面的贴现积分也取其相应的可积版本.

价格如果在时刻 u 跳跃, 承担这次跳跃盈亏的数量必须在跳跃发生前就已确定. 因此积分使用可预测持仓 θ_u . 若用适应的 càdlàg 过程 $\bar{\theta}$ 记录观察价格并完成调整后的库存, 那么参与时刻 u 价格跳跃的应是跳前库存 $\bar{\theta}_{u-}$.

组合在时刻 t 的价值为

$$V_t = \psi_t B_t + \theta_t^\top S_t.$$

自融资要求财富变化完全来自实际持有资产的收益:

$$V_t = V_0 + \int_0^t \psi_u dB_u + \int_0^t \theta_u^\top dS_u + \int_0^t \theta_u^\top dD_u.$$

三个积分分别记录现金账户增长, 除息价格变化和收到的现金分配. 买入股票时现金减少, 卖出股票时现金增加; 这些调仓收付只在组合内部转移资金, 不另算一项财富收益.

由于 B^{-1} 连续且有限变差, 它与半鞅财富的协变差为零. 对 V/B 使用分部积分:

$$d\left(\frac{V_t}{B_t}\right) = \frac{1}{B_t} dV_t + V_{t-} d(B_t^{-1}).$$

代入自融资等式, 再用 $V = \psi B + \theta^\top S$ 消去现金持仓, 得到

$$\tilde{V}_t = \tilde{V}_0 + \int_0^t \theta_u^\top d\tilde{G}_u, \quad \tilde{V}_t = \frac{V_t}{B_t}.$$

这正是离散时间贴现收益求和的连续版本.

定义 5.11 (连续时间自融资增益).

在上述可预测性和可积性条件下,

$$(\theta \cdot \tilde{G})_t = \int_0^t \theta_u^\top d\tilde{G}_u$$

称为持仓 θ 的贴现自融资交易增益.

用现金账户自身作计价单位以后, 一单位现金账户始终值 1. 因而贴现财富的变化只需记录风险资产的贴现累计收益. 这并没有漏掉融资利息; 利息已经包含在计价单位 B 的增长中.

若存在 $\mathbb{Q}^B \sim \mathbb{P}$ 使 $\tilde{G}$ 为局部鞅, 且可预测持仓 θ 局部有界, 则贴现交易增益也是局部鞅. 对更一般的持仓, 还须检查相应的局部鞅积分条件. 要进一步写成

$$\tilde{V}_t = \mathbb{E}^{\mathbb{Q}^B}[\tilde{V}_T | \mathcal{F}_t],$$

还须证明 $\tilde{V}$ 是真鞅. 平方可积性, 或局部化后的一致可积性, 都是常用的充分条件.

连续时间还需要限制可采用的策略. 例如要求贴现财富有统一的常数下界, 可以排除靠不断扩大潜在亏损维持的翻倍策略. 在局部鞅测度下, 有统一下界的局部鞅财富是上鞅, 从零初始财富出发便不能产生非负且有正概率严格为正的终值. 自融资说明钱从哪里来, 这种可容许性条件则限制交易者可以承担怎样的财富路径.

5.4.2 为什么要改变计算路径的权重

一期模型把复制成本写成了风险中性贴现期望. 连续时间也希望得到这样的表达: 不再逐条路径列出复制结果, 而是在一个合适的测度下计算到期支付的贴现条件期望.

例 5.12 (几何 Brown 运动中的测度变换).

设不支付股息的股票在现实测度下满足

$$dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}, \quad S_0 > 0,$$

其中 μ 和 $\sigma > 0$ 为常数. 时间以年计, μ 描述现实中的瞬时相对价格漂移, σ 描述年化相对波动率. 现金账户按常数连续复利利率 r 增长:

$$B_t = e^{rt}.$$

漂移项与随机波动项都乘以当前价格, 所以这里描述的是相对价格变化. 由前面的随机微分方程计算,

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t^{\mathbb{P}} \right).$$

因而股价严格为正且连续. 对数价格的漂移为 $\mu - \sigma^2/2$, 与相对价格漂移 μ 不同; 对数价格增量具有平稳独立的 Gauss 分布.

现在固定有限期限 T . 我们要找一个与 $\mathbb{P}$ 等价的测度, 使 S/B 成为鞅. 为此, 令

$$\vartheta = \frac{\mu - r}{\sigma}, \quad Z_t = \exp \left(-\vartheta W_t^{\mathbb{P}} - \frac{1}{2} \vartheta^2 t \right).$$

$\mu - r$ 是股票相对漂移与现金增长率之差, 除以 σ 后得到 Girsanov 变换所需的修正系数. ϑ 为常数且期限有限, 所以 Novikov 条件成立, Z 是期望等于 1 的真鞅. 因而可以定义

$$\left. \frac{d\mathbb{Q}^B}{d\mathbb{P}} \right|_{\mathcal{F}_t} = Z_t.$$

Z_t 严格为正, 所以 $\mathbb{Q}^B \sim \mathbb{P}$.

由第 4.6 节,

$$W_t^{\mathbb{Q}^B} = W_t^{\mathbb{P}} + \vartheta t$$

在新测度下是 Brown 运动. 将

$$dW_t^{\mathbb{P}} = dW_t^{\mathbb{Q}^B} - \vartheta dt$$

代回股价方程, 漂移系数变为

$$\mu - \sigma \vartheta = r.$$

因此同一个价格过程在 $\mathbb{Q}^B$ 下写成

$$dS_t = r S_t dt + \sigma S_t dW_t^{\mathbb{Q}^B}.$$

其贴现价格为常数系数的指数鞅, 因而确实是 $\mathbb{Q}^B$ -真鞅.

这个计算没有改变任何一个样本点上的股票路径. 改变的是计算平均值时赋予各条路径的权重. 同一条路径在现实测度下由 $W^{\mathbb{P}}$ 表示, 在新测度下则由相应的 $W^{\mathbb{Q}^B}$ 表示; 两个 Brown 运动的关系保证股票本身仍是原来的过程.

测度存在还不等于已经证明市场完备. 若全部信息恰好来自这一维 Brown 运动的通常增广滤过, 且可交易资产就是这只非退化股票和现金账户, 鞅表示定理才给出相应的复制能力.

例如, 对平方可积的贴现终端支付 $\tilde{X}$, 有

$$M_t = \mathbb{E}^{\mathbb{Q}^B} [\tilde{X} | \mathcal{F}_t] = M_0 + \int_0^t h_u dW_u^{\mathbb{Q}^B}.$$

而

$$d(S_t/B_t) = \sigma(S_t/B_t) dW_t^{\mathbb{Q}^B}.$$

因为 $\sigma S_t/B_t > 0$, 取

$$\theta_t = \frac{h_t}{\sigma S_t/B_t}$$

就能用股票的贴现收益复制上面的鞅增量. 现金持仓再由价值等式确定. 如果滤过还包含不可由这只股票交易的额外风险, 这一步便未必能表示全部终端支付, 鞅测度也未必唯一.

5.5 一个完整例子：欧式看涨期权的复制与定价

沿用上一节的无股息几何 Brown 运动市场, 现在具体复制一份到期支付为

$$(S_T - K)^+, \quad K > 0$$

的现金结算欧式看涨期权. 每份合约对应一股股票. 我们要求出初始资金, 以及此后每一时刻的股票数量和现金余额. 期权卖方可以持有这个组合, 用它在到期时支付合约义务.

这与第5.1节的任务相同. 一期模型逐个终态匹配支付, 连续时间模型则先让组合与期权价值在每个时刻承受相同的变化, 再核对它们到期时是否相等. 下面展开标准 Black-Scholes 模型的完整计算 [Shr04b].

5.5.1 市场模型与复制条件

固定有限到期日 T . 股票与现金账户满足

$$dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}, \quad B_t = e^{rt},$$

其中 $S_0 > 0$, $r, \mu \in \mathbb{R}$, $\sigma > 0$. 滤过取 $W^{\mathbb{P}}$ 自然滤过的通常增广. 沿用前述无摩擦交易约定, 并允许连续调仓. 股票不支付股息, 期权仅在 T 支付一次现金.

设期权在日期 t , 股价为 s 时的候选价值为 $c(t, s)$. 对 $t < T$, $s > 0$, 先寻找一个 $C^{1,2}$ 函数, 并要求到期满足

$$c(T, s) = (s - K)^+.$$

终端支付有折点, 但我们只在到期以前对光滑的候选价值使用 Itô 公式, 最后再取到期极限.

令 θ_t 为复制组合的股票数量, ψ_t 为现金账户单位数. 现金金额为

$$C_t = \psi_t B_t.$$

组合必须同时满足价值等式与自融资等式:

$$V_t = \theta_t S_t + C_t, \quad dV_t = \theta_t dS_t + rC_t dt.$$

前式说明当前持仓值多少钱, 后式说明这些钱怎样变化. 只在每个时刻分别凑出一个价值为 $c(t, S_t)$ 的组合, 还不够; 调整持仓时也必须由已有资金支付.

5.5.2 先匹配随机波动, 再匹配漂移

由第4.4节的 Itô 公式,

$$dc(t, S_t) = \left(c_t + \mu S_t c_s + \frac{1}{2} \sigma^2 S_t^2 c_{ss} \right) dt + \sigma S_t c_s dW_t^{\mathbb{P}}.$$

这里 c_t, c_s, c_{ss} 分别表示时间偏导, 股价一阶偏导和股价二阶偏导, 均在 (t, S_t) 处取值.

复制组合的变化为

$$dV_t = (\theta_t \mu S_t + rC_t) dt + \theta_t \sigma S_t dW_t^{\mathbb{P}}.$$

先比较 Brown 项. 现金账户只能产生有限变差的利息收入, 无法弥补一个未被匹配的 Brown 波动项. 因而必须有

$$\theta_t \sigma S_t = \sigma S_t c_s.$$

由于 $\sigma S_t > 0$, 股票数量被唯一确定为

$$\theta_t = c_s(t, S_t).$$

这个偏导称为期权的 **Delta**. 在复制交易中, 它的直接含义就是每份期权需要持有多少股股票. 要求组合市值等于期权价值, 又得到现金余额

$$C_t = c(t, S_t) - S_t c_s(t, S_t).$$

股票数量与现金余额现在都由候选价值确定了, 还须检查漂移是否相等:

$$c_t + \mu S_t c_s + \frac{1}{2} \sigma^2 S_t^2 c_{ss} = \mu S_t c_s + r(c - S_t c_s).$$

两边的 $\mu S_t c_s$ 相消, 整理得

$$c_t + \frac{1}{2} \sigma^2 S_t^2 c_{ss} + r S_t c_s - r c = 0, \quad c(T, s) = (s - K)^+. \quad (5.1)$$

现实漂移 μ 消失, 是因为复制组合与期权已经持有相同的股票风险, 对应的股票漂移也随之相消. 剩下的关系由波动率, 现金利率和到期支付决定. 我们没有假定现实股票只能按 r 增长, 也不需要先猜一个现实平均涨幅才能计算复制成本.

5.5.3 把候选价格写成风险中性期望

上一节已经构造了现金账户对应的测度 $\mathbb{Q}^B$. 在这个测度下,

$$dS_t = r S_t dt + \sigma S_t dW_t^{\mathbb{Q}^B},$$

生成元为

$$\mathcal{L}f(s) = r s f'(s) + \frac{1}{2} \sigma^2 s^2 f''(s).$$

将它和贴现率 r 代入 Feynman-Kac 方程, 得到的就是式 (5.1). 对应的候选价值为

$$c(t, S_t) = \mathbb{E}^{\mathbb{Q}^B} \left[e^{-r(T-t)} (S_T - K)^+ \mid \mathcal{F}_t \right]. \quad (5.2)$$

支付满足

$$0 \leq (S_T - K)^+ \leq S_T,$$

几何 Brown 运动在有限期限上又具有所需的矩, 所以这个期望有限. 接下来先算出它的显式形式, 再直接验证光滑性, 定价方程和复制策略.

给定当前股价 $S_t = s$, 令剩余期限为 $\tau = T - t > 0$. 风险中性条件分布为

$$S_T = s \exp \left((r - \frac{1}{2} \sigma^2) \tau + \sigma \sqrt{\tau} Z \right), \quad Z \sim \mathcal{N}(0, 1).$$

这里的新增量独立于 $\mathcal{F}_t$. 用 Φ 和 φ 分别表示标准正态分布函数与密度, 并令

$$d_1 = \frac{\log(s/K) + (r + \frac{1}{2} \sigma^2) \tau}{\sigma \sqrt{\tau}}, \quad d_2 = d_1 - \sigma \sqrt{\tau}.$$

从股价的指数表示可知,

$$S_T > K \iff Z > -d_2.$$

现在只在发生行权的事件上比较股票价值与执行价:

$$(S_T - K)^+ = S_T \mathbf{1}_{\{S_T > K\}} - K \mathbf{1}_{\{S_T > K\}}.$$

第二项中的 K 为常数, 所以它的贴现条件期望为

$$K e^{-r\tau} \mathbb{Q}^B(S_T > K \mid S_t = s) = K e^{-r\tau} \Phi(d_2).$$

第一项还要考虑行权时股票究竟涨到了多少. 令 $a = \sigma\sqrt{\tau}$, 使用配方恒等式

$$e^{az-a^2/2}\varphi(z) = \varphi(z-a),$$

便有

$$\begin{aligned} e^{-r\tau}\mathbb{E}^{\mathbb{Q}^B}[S_T\mathbf{1}_{\{S_T>K\}} \mid S_t=s] &= s \int_{-d_2}^{\infty} e^{az-a^2/2}\varphi(z) dz \\ &= s \int_{-d_2}^{\infty} \varphi(z-a) dz \\ &= s\Phi(d_1). \end{aligned}$$

两部分相减得到

$$c(t, s) = s\Phi(d_1) - Ke^{-r(T-t)}\Phi(d_2). \quad (5.3)$$

$\Phi(d_2)$ 是定价测度下到期股价高于执行价的条件概率. $\Phi(d_1)$ 则来自带股票价值的截断积分; 它还将出现在复制持股数量中. 两者在公式里承担不同作用.

5.5.4 验证股票与现金持仓确实能够复制

对显式价格求导. 恒等式

$$s\varphi(d_1) = Ke^{-r\tau}\varphi(d_2)$$

使求导时来自 d_1, d_2 的额外项相消, 得到

$$c_s(t, s) = \Phi(d_1).$$

因此复制持仓为

$$\theta_t = \Phi(d_1(t, S_t)), \quad C_t = -Ke^{-r(T-t)}\Phi(d_2(t, S_t)), \quad \psi_t = \frac{C_t}{B_t}.$$

现金余额为负, 表示组合需要借款来购买一部分股票.

进一步求导:

$$c_{ss} = \frac{\varphi(d_1)}{s\sigma\sqrt{\tau}}, \quad c_t = -\frac{s\sigma\varphi(d_1)}{2\sqrt{\tau}} - rKe^{-r\tau}\Phi(d_2).$$

于是

$$c_t + \frac{1}{2}\sigma^2 s^2 c_{ss} = -rKe^{-r\tau}\Phi(d_2),$$

而

$$rsc_s - rc = rKe^{-r\tau}\Phi(d_2).$$

两者相加为零, 验证了式 (5.1). 再对 $V_t = c(t, S_t)$ 使用 Itô 公式, 就确实得到

$$dV_t = \theta_t dS_t + rC_t dt.$$

因此这些持仓的调整满足自融资, 并非仅仅在各时刻有相同市值.

还要让策略一直延续到到期. 对 $t < T$, 两个持仓过程连续且适应, 所以可预测. 股票数量满足

$$0 \leq \theta_t \leq 1,$$

现金余额满足

$$|C_t| \leq Ke^{r|T|}.$$

结合股票在有限期限上的二阶矩, 随机积分与现金利息积分均可延续到 T . 显式价格又满足

$$\lim_{t \uparrow T} c(t, S_t) = (S_T - K)^+,$$

所以到期财富恰好等于合约支付.

由式 (5.2),

$$e^{-rt}c(t, S_t) = \mathbb{E}^{\mathbb{Q}^B}[e^{-rT}(S_T - K)^+ \mid \mathcal{F}_t],$$

故贴现价值是真鞅. 组合价值非负, 也满足通常的财富下界要求. 至此, 初始成本, 自融资过程和到期支付三项都已核对.

5.5.5 把初始复制写成一笔交易

取

$$S_0 = 100, \quad K = 100, \quad T = 1 \text{ 年}, \quad r = 5\%, \quad \sigma = 20\%.$$

当前股价与执行价均为每股 100 元, 合约一年后到期. r 是连续复利年率, σ 是年化相对波动率. 现实漂移 μ 已从复制方程中消去, 所以这里不需要为它指定数值.

此时

$$d_1 = \frac{0 + (0.05 + \frac{1}{2} \times 0.20^2) \times 1}{0.20} = 0.35, \quad d_2 = 0.15.$$

初始持仓为

项目	数值
股票数量 $\theta_0 = \Phi(0.35)$	0.637 股
股票市值 $\theta_0 S_0$	63.68 元
现金余额 $C_0 = -100e^{-0.05}\Phi(0.15)$	-53.23 元
组合净值 $V_0 = c(0, 100)$	10.45 元

这笔交易的资金来源很具体: 投入约 10.45 元, 再借入约 53.23 元, 合计买入价值约 63.68 元的股票. 股票数量约为 0.637 股. 股票市值减去借款, 才是复制组合的净值.

以后股价和剩余期限改变, Delta 也会改变. 增持股票要支付现金, 减持股票会收到现金, 借款余额还会计息. 因而现金账户必须同时记录利息与调仓收付, 不能把它写成初始借款一直滚存.

5.5.6 只在有限日期调仓时, 现金怎样变化

现在不再连续调仓, 而只在

$$0 = t_0 < t_1 < \cdots < t_n < T$$

交易. 用 θ_k, C_k 表示日期 t_k 调仓后的股票数量与现金金额. 两次交易之间股票数量不变, 现金先按利率增长. 到 t_{k+1} 再按当时价格买卖股票, 得到

$$C_{k+1} = C_k e^{r(t_{k+1}-t_k)} - (\theta_{k+1} - \theta_k) S_{t_{k+1}} - \text{fee}_{k+1}.$$

其中 fee_{k+1} 是这次实际支付的交易费. 增持时第二项是支出, 减持时它是收入. 这条现金递推没有外部注资; 若有费用, 费用就作为账户的实际支出扣除.

例 5.13 (九个月后减持, 再持有到期).

仍从上一小节的精确初始持仓出发:

$$\theta_0 = \Phi(0.35), \quad C_0 = -100e^{-0.05}\Phi(0.15).$$

前九个月不调仓, 到 $t_1 = 3/4$ 年时才重新计算 Delta. 假设此时股价仍为每股 100 元, 本例暂取交易费为零. 我们要根据剩余期限调整股票数量, 再核对已有资金是否足以支付到期义务.

距离到期还剩 $1/4$ 年. 虽然股价与建仓时相同, 剩余期限已经缩短, 新的 Delta 因而也不同. 代入公式:

$$d_1 = \frac{\log(100/100) + (0.05 + \frac{1}{2} \times 0.20^2) \times \frac{1}{4}}{0.20\sqrt{1/4}} = 0.175.$$

新目标持股数量为

$$\theta_1 = \Phi(0.175) \approx 0.569.$$

先算调仓前的现金. 旧借款已经计息九个月:

$$C_0 e^{rt_1} = -100e^{-0.05/4}\Phi(0.15) \approx -55.27.$$

再把持股数量从约 0.637 股降到约 0.569 股. 卖出的数量为

$$\theta_0 - \theta_1 \approx 0.067$$

股, 按每股 100 元卖出, 收到

$$(\theta_0 - \theta_1) \times 100 \approx 6.74$$

元. 这笔钱用于减少借款, 所以调仓后的现金余额为

$$\begin{aligned} C_1 &= C_0 e^{rt_1} + (\theta_0 - \theta_1) \times 100 \\ &\approx -48.53. \end{aligned}$$

此时股票市值约为 56.95 元, 债务约为 48.53 元, 账户净值为

$$V_{t_1} = 100\theta_1 + C_1 \approx 8.42.$$

这个 8.42 元是九个月实际持仓形成的结果. 同一时点的理论期权价格约为 4.61 元, 两者已经不同. 我们只用新的 Delta 决定持有多少股票, 调仓所用的钱仍来自原有账户. 若直接把现金改成 $c(t_1, 100) - 100\theta_1$, 就会把此前没有连续调仓造成的差额从账上抹去.

此后不再交易, 并假设到期股价为每股 110 元. 剩余三个月内, 债务继续计息, 到期现金余额为

$$C_1 e^{r/4} \approx -49.14.$$

按到期股价卖出全部股票, 收到

$$110\theta_1 \approx 62.64$$

元. 偿还债务后, 组合剩余

$$V_T = 110\theta_1 + C_1 e^{r/4} \approx 13.50.$$

看涨期权应支付 $110 - 100 = 10$ 元, 因而履行义务后还剩约

$$V_T - 10 \approx 3.50$$

元. 这就是这条价格路径上的离散对冲误差. 正值表示组合资金有余, 负值则表示不足以支付期权义务. 本例中的差额来自间隔调仓, 不能据此认定其他价格路径也会留下盈余.

连续复制要求持仓随 Delta 不断调整. 离散策略在两次交易之间保持旧数量, 因而通常无法继续逐路径匹配期权. 若最后一次调仓后一直持有到期, 暂以 S_T 计算股票价值且没有额外退出费, 对冲误差一般写为

$$\varepsilon_T = \theta_n S_T + C_n e^{r(T-t_n)} - (S_T - K)^+.$$

真正卖出股票时, 则应把 $\theta_n S_T$ 换成实际净出售所得. 调仓费用, 买卖价差和成交价格偏离也都通过同一份现金账进入最终结果.

第8.5节的完整 SMA 例子 (第199页) 使用另一种持仓规则, 但账户的更新顺序相同: 根据当时的信息决定动作, 成交后更新股票和现金, 再按实际发生的费用计算净财富.

5.6 点过程示例: 订单到达与价格变化

前面直接用随机过程描述价格. 若还关心市场中的订单, 就可以先记录某类订单何时到达, 再研究它们与价格变化之间的关系.

例如, 令 N_t 统计从观察开始到时刻 t 到达的市场化买单次数. 这里的一次事件是一笔订单, 不是一股股票: 一笔购买 100 股的订单和一笔购买 1,000 股的订单, 在计数中都各记一次. 要研究数量的影响, 还须给每次到达附上股数等标记.

5.6.1 到达率怎样变成可计算的概率

先假设 N 相对于当前滤过是强度为 $\lambda > 0$ 的 Poisson 过程, 如第3.6节所述. 对长度为 h 的后续区间,

$$N_{t+h} - N_t \sim \text{Poisson}(\lambda h),$$

且这个增量独立于 $\mathcal{F}_t$.

例 5.14 (每分钟两笔买单).

以分钟为时间单位, 假设市场化买单的到达率为

$$\lambda = 2 \text{ 次/分钟.}$$

观察未来 30 秒, 即 $h = 0.5$ 分钟. 这段时间的平均订单次数为

$$\mathbb{E}[N_{t+h} - N_t] = \lambda h = 1.$$

这表示平均到达一次, 不表示必定到达一次.

由参数为 1 的 Poisson 分布,

$$\mathbb{P}(N_{t+h} - N_t = 0) = e^{-1} \approx 0.368,$$

$$\mathbb{P}(N_{t+h} - N_t = 1) = e^{-1} \approx 0.368,$$

$$\mathbb{P}(N_{t+h} - N_t \geq 1) = 1 - e^{-1} \approx 0.632.$$

因而未来半分钟至少出现一笔这种买单的概率约为 63.2%, 恰好出现一笔的概率约为 36.8%.

当 h 趋于零时, 精确概率可以展开为

$$\mathbb{P}(N_{t+h} - N_t = 1 \mid \mathcal{F}_t) = e^{-\lambda h} \lambda h = \lambda h + o(h),$$

$$\mathbb{P}(N_{t+h} - N_t \geq 2 \mid \mathcal{F}_t) = o(h).$$

因此 λh 是短区间内一次到达概率的首阶近似. 上例中 $\lambda h = 1$, 不能把这个短时间近似当成精确概率; 它仍然精确地表示平均次数.

真实的订单到达速度可能随已有信息变化. 此时可以用非负可预测过程 λ_t 代替常数 λ , 假设对每个 $t \leq T$,

$$\int_0^t \lambda_s \, ds < \infty \quad \text{a.s.},$$

并要求

$$M_t = N_t - \int_0^t \lambda_s \, ds$$

为局部鞅. 积分是计数过程的累计补偿量: 根据过去信息能够预先解释的到达变化先记在这一项中, 扣除以后得到局部鞅.

λ_t 必须可预测, 因为本次订单到达以前采用的强度不能使用本次尚未出现的订单. 这样的条件强度模型允许到达率依赖历史, 不再要求独立或平稳增量.

5.6.2 订单次数与价格响应是两项不同的设定

买单, 卖单, 限价单提交和撤单对订单簿的作用不同, 应分别计数. 例如令 N_t^+, N_t^- 记录市场化买单与卖单次数, 相应强度为 λ_t^+, λ_t^- , 则

$$M_t^\pm = N_t^\pm - \int_0^t \lambda_s^\pm \, ds$$

是对应的补偿过程. 每次事件还可以携带方向, 股数和成交场所等标记.

令 T_k 为事件到达时刻, Z_k 为第 k 次事件的标记, 并在有限期限内考虑有限次到达. 一个中间价候选模型可以写成

$$m_t = m_0 + \int_0^t \eta_s \, dW_s + \sum_{k: T_k \leq t} g(Z_k).$$

这里 W 是当前滤过下的 Brown 运动, η 可预测且满足

$$\int_0^t \eta_s^2 \, ds < \infty \quad \text{a.s.}$$

连续积分记录没有逐笔列出的连续价格变化，求和项记录各次事件对应的价格跳动。

如果中间价以元/股计量，时间以分钟计量，那么 $g(Z_k)$ 的单位是元/股， η 的单位是元/股除以分钟的平方根。这里的 η 是绝对价格波动系数，与几何 Brown 运动模型中乘在股价前的相对波动率 σ 不同。

例 5.15 (把次数与单次价格变化分别代入).

继续使用每分钟平均两笔买单的计数模型。为单独看清订单项，暂把连续波动项设为零，并约定模型中每笔这种买单对应的中间价变化为 0.01 元/股。从 $m_0 = 100$ 元/股开始，

$$m_t = 100 + 0.01N_t.$$

这里 $\lambda = 2$ 决定订单有多频繁，0.01 决定每次已记录事件对应多大的价格变化。

未来半分钟平均到达一次，所以模型中的平均中间价为

$$\mathbb{E}[m_{0.5}] = 100 + 0.01 \times 1 = 100.01.$$

若实际到达了三笔，则该次观察中的模型中间价为

$$m_{0.5} = 100 + 0.01 \times 3 = 100.03.$$

平均次数用于计算平均值，实际次数用于计算这一条已发生路径上的结果。

上例把每笔订单的价格响应设成同一个数，因而没有区分大小订单。加入股数等标记以后， g 才能随订单大小变化。到达强度 λ_t 与响应函数 g 应分别估计：前者描述何时出现多少次事件，后者描述一次事件伴随怎样的价格变化。

如果这些关系来自观察数据， g 首先刻画条件关联。同一条消息可能同时引来买单并推高价格，涨价本身也可能吸引后续买单，相同股数的订单在不同盘口深度下还可能对应不同变化。要把 g 解释成额外增加一笔订单的因果效应，需要进一步区分这些作用。

若订单到达具有聚集，自激或日内季节性，可以采用 Hawkes 过程或其他带标记点过程。无论如何描述到达，中间价都还不是整笔订单的成交均价。要计算一笔交易实际收付多少现金，还必须查看买卖两侧能承接多少数量。

5.7 从报价到成交：一笔往返交易的现金账

模型中的自融资等式通常让买卖都按同一个价格完成。实际记账还要区分交易者看到的报价和真正成交的价格。本节固定一笔买入 100 股，持有五天再全部卖出的交易，逐项算出买股支出，借款，利息和最终现金。

我们也会在同一次退出附近比较三个量：尚未卖出时按中间价计算的持仓损益，按最优买价估计的清算损益，以及实际卖出后的净损益。

5.7.1 买入时，钱付给哪一侧

初始盘口为

$$b_0 = 100.00, \quad a_0 = 100.10, \quad m_0 = \frac{a_0 + b_0}{2} = 100.05.$$

b_0 是最优买价，即当前有人愿意买入的最高报价。 a_0 是最优卖价，即当前有人愿意卖出的最低报价。 m_0 是两者的中间价。

交易者要立刻买股票，需要与愿意卖出的人交易，所以先碰到卖价 a_0 。但屏幕上的最优卖价不一定有足够数量。假设这笔 100 股买单实际分两档成交：

卖盘档位	本笔成交股数	成交价格 (元/股)
第一档	80	100.10
第二档	20	100.20

买入价款为

$$80 \times 100.10 + 20 \times 100.20 = 10,012.$$

令总股数为 $n = 100$, 实际买入均价为 x , 则

$$x = \frac{10,012}{100} = 100.12.$$

最初看到的 100.10 只适用于第一档的数量, 整笔订单不能都按这个价格记账.

另付入场费 2 元. 假设买入价款的一半由借款支付, 借款本金为

$$L = \frac{10,012}{2} = 5,006.$$

其余买股价款和入场费由自有资金支付, 所以实际投入

$$V_0 = 10,012 + 2 - 5,006 = 5,008.$$

这笔资金中, 5,006 元补足股票价款, 另 2 元支付入场费用.

持有期间没有股息和其他税费. 融资使用年化单利 8%, 按一年 365 天计息. 主例先约定借款占用五天, 并在第五天完成结清. 利息为

$$I = 5,006 \times 0.08 \times \frac{5}{365} \approx 5.49.$$

本金在开始时提供买股资金, 结束时需要归还; 这五天减少财富的融资费用是利息 I , 不是本金本身.

5.7.2 同一笔持仓的三个损益数

五天后的最优报价为

$$b_5 = 100.95, \quad a_5 = 101.05, \quad m_5 = 101.00.$$

先保持股票不动, 仅按中间价估值. 当前持仓市值为 $100 \times 101.00 = 10,100$ 元. 相对于实际买入价款, 价格增值为 88 元. 扣除已经发生的入场费与融资利息, 得到**标记损益**

$$\begin{aligned} \Pi^{\text{mark}} &= n(m_5 - x) - 2 - I \\ &= 100(101.00 - 100.12) - 2 - I \\ &\approx 80.51. \end{aligned}$$

此时股票尚未卖出, 没有实际退出价, 也没有发生退出费. 中间价用于估值, 不表示已有买方承诺按这个价格接下全部股票.

再估计现在卖出能得到多少. 交易者要立即卖股票, 应与当前愿意买入的人交易, 所以使用最优买价 $b_5 = 100.95$. 若暂假设这档能接下全部 100 股, 且退出费为 2 元, 则按**最优报价估计的清算损益**为

$$\begin{aligned} \Pi^{\text{quote}} &= n(b_5 - x) - 2 - 2 - I \\ &= 100(100.95 - 100.12) - 2 - 2 - I \\ &\approx 73.51. \end{aligned}$$

从中间价换成最优买价, 持仓估值减少 5 元; 再计入将发生的退出费 2 元, 所以比标记损益少了 7 元.

最后实际提交卖单. 假设成交记录为

买盘档位	本笔成交股数	成交价格 (元/股)
第一档	40	100.95
第二档	60	100.90

卖出总价款为

$$40 \times 100.95 + 60 \times 100.90 = 10,092.$$

令实际卖出均价为 y , 则

$$y = \frac{10,092}{100} = 100.92.$$

退出费仍为 2 元. 因而实际成交净损益为

$$\begin{aligned}\Pi^{\text{exec}} &= n(y - x) - 2 - 2 - I \\ &= 100(100.92 - 100.12) - 2 - 2 - I \\ &\approx 70.51.\end{aligned}$$

实际卖出均价比最优买价低 0.03 元, 乘以 100 股, 比刚才的清算估计又少了 3 元.
三个数分别回答不同的问题:

口径	使用的退出侧价格与费用	损益 (元)
标记损益	中间价 101.00, 尚不扣未发生的退出费	80.51
报价清算估计	假设全部按最优买价 100.95 卖出, 计退出费	73.51
成交净损益	使用实际卖出均价 100.92, 计实际退出费	70.51

5.7.3 从自有资金再核对一次

例 5.16 (偿还借款以后, 最终现金剩多少).

仍按五天融资的主例计算. 初始自有资金为

$$V_0 = 10,012 + 2 - 5,006 = 5,008.$$

卖出全部股票收到 10,092 元. 从这笔钱中支付退出费, 归还借款本金并支付五天利息, 最终现金为

$$\begin{aligned}V_5 &= 10,092 - 2 - 5,006 - I \\ &\approx 5,078.51.\end{aligned}$$

相对于最初投入的自有资金, 财富增加

$$V_5 - V_0 \approx 70.51,$$

与成交净损益相同.

入场费已经包含在初始自有资金中, 不从最终现金再扣一次. 借款本金开始时帮助买股, 结束时归还, 也不作为额外亏损重复扣除.

这次核对只用了实际现金收付. 初始投入提供了买股自有部分和入场费; 借款提供另一部分买股价款; 卖股收入用于支付退出费, 偿还本金和利息. 全部收付结束后剩余多少, 与用买卖均价计算出的净损益一致.

5.7.4 成交确认与现金到账之间还有结算

卖出成交以后, 成交价格与应收金额已经确定, 但资金不一定立即到账. 在结算完成以前, 卖款可能仍是一笔应收款. 这会影响何时能够归还借款.

单独改变主例的一个条件: 假设卖出后还要等一天收到资金, 并且借款因此多占用一天. 新增利息为

$$5,006 \times 0.08 \times \frac{1}{365} \approx 1.10.$$

这时应直接按六天融资重算净损益:

$$100(100.92 - 100.12) - 2 - 2 - 5,006 \times 0.08 \times \frac{6}{365} \approx 69.42.$$

这是另一个结算情形, 不再使用五天主例的最终现金 5,078.51 元. 成交均价没有变化, 改变的是收到卖出款并偿还借款的日期.

图5.2将这些步骤分开. 报价用于决定是否下单, 成交确认给出实际价格和数量, 清算确定应收应付, 结算完成以后才得到相应的已到账现金.




图 5.2: 从观察报价到已结算现金的交易顺序.

由此也能看清模型价格与交易记录怎样配合. 价格过程可以用于形成持仓和估计价值; 账户中真正增加或减少的现金, 则应按成交数量, 成交价格, 融资期间与结算日期逐笔记录.

5.8 从模型现金流到具体市场制度

从一期复制到连续对冲, 同一个问题始终贯穿其中: 先投入一笔资金, 此后按已知信息买卖资产, 最终能支付什么现金? 一期模型用两个线性方程回答, 多期模型逐期更新持仓和财富, 连续时间则用随机积分记录持仓收益. Black-Scholes 计算把初始价格与整个复制过程连接起来, 往返交易的现金账又把模型价格进一步落实为实际收付.

下一章转向这些交易依赖的具体市场安排. 股票附带哪些权利, 期货与期权按什么规则结算, 债券何时支付利息和本金, 融资怎样计息, 订单怎样进入盘口并成交, 都会决定本章中的价格, 分配和现金账户在实际市场上应当怎样填写.

第二部分

随机过程与金融市场

第六章 金融市场基础


第五章已经用抽象的股票价格、现金账户和持仓写出了复制与自融资关系。现在把这些符号放回市场中：一股股票究竟代表什么，一份合约何时收付现金，一笔订单最后又按什么价格成交。

做金融计算时，经常要先分清三件事。第一，持有者究竟享有哪些权利，承担哪些义务；第二，这些权利和义务在什么时点产生现金流；第三，真正交易时需要占用多少资金，能成交多少数量，按什么价格成交。把这三件事说清以后，才能分别计算资产价格，合约价值和投资者账户最终的损益。

本章先从股票、价格和持有回报开始，再研究衍生品，事件合约，指数与 ETF，债券和美元融资。有了这些现金流以后，再讨论贴现与无套利，最后进入订单簿和实际成交。背景材料主要参考 [Hul22; Shr04a; Shr04b; TS11]。

本章中的数值算例除明确引用实际制度或市场规则者外，都只为说明计算而设定。实际交易的现金收支还取决于税费，保证金，结算和交付规则，下文会在相应计算中具体说明。

下面的图列出阅读顺序。



从资产权利到现金流比较，再到交易现场的价格形成

图 6.1: 金融市场基础的阅读路线

先从最熟悉的股票开始。我们先说明一股股票包含哪些权利，新股发行和已有股份转让时钱分别流向哪里，再把这些收支写成价格，收益和账户财富。

6.1 资产头寸，价格与策略回报

买入一股股票时，投资者先付出买价，随后持有一股相应类别的股份。持有期间可能收到股息，卖出时再取得出售款；若买入资金来自借款，账户还会产生利息和还款义务。这些收支合起来，才是这笔持仓的结果。

本节先把股票代表的权利，发行和交易时的钱流向说清，再用 S_t 记录每单位价格。随后把价格变化，现金分配，持有数量和融资放进同一份财富计算。

6.1.1 从资产名称到具体持仓

同一个资产名称并不能唯一确定投资者实际持有什么。同一家公司的 A 类股和 B 类股可能具有不同投票权；即使持有同样数量的股票，用自有资金买入与借款买入，账户现金流也不同。因而开始计算以前，至少要确认股份或合约类别，持有数量，以及是否有与这笔头寸直接相关的借款，保证金或费用。

设投资者在券商账户中持有某上市公司 100 股普通股。若每股价格变动一美元，100 股持仓的市值就变动 100 美元；股份类别决定投资者享有哪些股息，表决等股东权利；若账户还有借款，还要另外记录融资现金流。后面分别用持有数量，每单位价格和现金账户记录这些部分。

本章主要研究单位和交易规则较为标准化的金融资产，尤其是证券。

定义 6.1.

在本文中，**证券** (security) 指按相应市场制度发行并可持有或转让的资产，其金融权利以相对标准化的单位表示。股票和债券是典型的证券；基金份额及部分其他金融工具在相应制度下也属于证券。

证券持有人取得的是证券本身规定的权利。买入股票以后, 股东拥有股份, 并按股份类别享有相应的分配和治理权; 公司的机器, 专利和银行存款仍由公司持有。买入债券则取得合同约定的付款请求权。因而分析每单位证券值多少钱时, 先看这一单位到底承诺或分配什么。

6.1.2 从持有权利到价值与价格

一项持仓今后能带来什么, 取决于它规定的权利。股票可能支付股息并最终某个价格卖出, 债券会按合同支付票息和本金, 期权则只在相应条件满足时产生支付。若资产还带来实际使用服务, 这部分利益与现金流分开说明即可。

价值是对这些未来利益今天值多少钱的判断。预测的现金流, 等待期限和要求回报率不同, 得到的估值自然会不同。第7.1节将具体计算这些差异。

市场价格则是当前有人愿意按相应交易条件买卖的价格。投资者若真的按这个价格建仓, 以后收到的现金, 卖出所得和期间成本才共同形成实际损益。因而本节接下来先看证券怎样发行和转让, 再把成交价格写成随时间变化的过程。

6.1.3 资产与交易市场

股票

定义 6.2.

股票 (stock) 是股份公司发行并代表股东权益的一类证券。股东通常享有公司未来分配和清算剩余财产的经济索取权, 并按照股份类别和适用规则享有投票, 参与治理及转让股份等权利。

不同股份类别可以把分红权和投票权作不同安排, 所以讨论每股盈利, 每股分红或控制权以前, 先确认研究的是哪一类股份。

股票第一次发行和发行后的转手, 钱的去向不同。

一级市场与二级市场

定义 6.3.

一级市场 (primary market), 也称发行市场, 是新发行证券被出售和分配给投资者的市场。
二级市场 (secondary market) 是已发行证券在市场参与者之间继续转让和交易的市场。

公司发行新股时, 投资者取得新股份, 相应认购资金最终进入发行融资。首次向公众发行股票通常称为**首次公开募股** (Initial Public Offering, IPO)。一笔 IPO 也可能同时包含原股东出售的存量股份: 新股部分的资金进入公司, 存量股份部分的出售款则归卖出股份的原股东。

发行完成以后, 普通交易所买卖大多发生在二级市场。买方把钱付给卖方, 卖方把已有股份转给买方, 公司不会因为每一笔二级市场成交再次收到这笔买入款。

二级市场的流动性也会影响新证券的发行条件。如果投资者预期认购以后较容易转手, 初次认购时通常更愿意持有这种证券; 如果以后很难退出, 发行人往往需要提供更有吸引力的条件才能完成融资。

交易动机与流动性 持有人卖出股票的原因很多。他可能改变了对公司的判断, 也可能只是需要现金, 降低组合暴露或满足保证金要求。买方和卖方即使对公司未来看法相近, 只要资金需求和现有持仓不同, 仍可能愿意在同一价格成交。

能转让也不等于任何数量都能立刻按屏幕价格卖出。若某个价位只有少量买单, 大额卖单要么等待新的买方, 要么继续向更低价位成交。

定义 6.4.

一项资产或一个市场具有较高的**流动性**, 是指参与者能够在较短时间内完成足够数量的交易, 而不必作出过大的价格让步, 交易本身也不会造成过大的价格变化。

因此看流动性时, 不只数市场里有多少参与者, 还要看各个价格附近实际愿意买卖多少。同样, 某位投资者缺现金属于他的账户约束, 与整个市场是否有足够对手方是两件事。

报价, 成交与市场价格 在限价订单簿中, 报价先说明有人愿意以什么价格, 买卖多少数量. 最高买入报价记为 b_t , 称为**最优买价** (best bid); 最低卖出报价记为 a_t , 称为**最优卖价** (best ask). 买卖价差为 $a_t - b_t$, 中间价为

$$m_t := \frac{a_t + b_t}{2}.$$

真正提交订单以后, 才产生实际成交. 一笔立即买入通常先吃掉卖价一侧的数量; 若最优卖价数量不够, 剩余部分继续向更高报价成交. 因而中间价, 最优报价, 最近成交价和一整笔新订单的平均成交价都可能不同.

若成交数量为 q , 每单位实际成交价为 x , 忽略费用时整笔交易金额就是 qx . 这里的 x 是每单位价格, qx 才是账户中实际收付的总金额.

注 6.5.

每一笔已完成交易同时有买方和卖方, 成交数量在两边完全相同. 所谓主动买入较多, 指买方不断接受已有卖价, 消耗卖盘; 卖盘被消耗以后, 后来的立即买单可能只能在更高价位完成. 主动卖出则以相反方式消耗买盘.

成交以后还要完成结算. 例如股票卖出成交时价格已经确定, 但现金和证券可能在随后才正式交收. 因此观察报价, 确认成交和取得已结算现金是连续的几个时点, 后文的订单簿和现金账会分别记录它们.

6.1.4 价格与收益率

价格与市场预期 股票今天为什么在某个价格成交, 与买卖双方怎样看未来有关. 买方会比较当前支付的价格与以后可能取得的股息和出售价值, 卖方则比较继续持有和现在退出哪个更合适. 对公司股票而言, 这些判断最终会落到未来盈利, 再投资, 风险和股东所得上.

新消息影响价格时, 市场比较的是新结果与原先已经反映的预期. 例如公司盈利增长 20%, 但此前市场按更高增长定价, 公布结果以后价格仍可能下跌; 反过来, 一家公司仍在亏损, 只要实际亏损明显小于此前预期, 价格也可能上涨.

仅凭一个市场价格, 无法反推出所有参与者分别采用了什么预测. 同一个价格既可能对应较高增长和较高要求回报率, 也可能对应较低增长和较低要求回报率. 因而基本面研究常从现价反推市场隐含的增长或估值倍数, 再与经营资料比较.

从价格记录到价格过程 数学模型先选定一种具体价格来记录. 对股票可以取每股中间价, 收盘价或模型中的无摩擦价格, 然后用 S_t 表示时刻 t 的每股价格. 若 $S_t = 200$, 就表示一股按所选口径计价为 200 单位货币或其他计价资产.

简单模型常把买价和卖价合成同一个 S_t , 从而先研究持有收益和定价. 真正计算订单成交时, 再回到上一段的买价, 卖价, 数量和实际均价.

未来价格尚未实现时, 每个 S_t 是随机变量; 把各时刻放在一起, 就得到价格过程 (S_t) . 接下来先从这个过程计算持有一单位资产的收益.

现金流, 收益与收益率 先考虑用自有资金买入一单位资产并一直持有的情形. 持有者的收益不仅来自出售价格与买入价格的差额, 也来自期间收到的现金, 例如股票股息或债券票息.

以 D_t 表示这一单位截至 t 已累计支付的现金流, 并令 $G_t := S_t + D_t$. 若在 s 时刻按 $S_s > 0$ 全额买入, 持有到 t , 暂不计交易费用, 税和融资成本, 则损益为

$$G_t - G_s = S_t - S_s + D_t - D_s.$$

右边分别是价格变化和本次持有期间收到的现金. D_s 以前已经支付的分配不属于这段持有期, 所以要从累计分配中扣去.

例 6.6 (除息).

假设股票除息前价格为 \$100, 每股支付 \$1 股息, 除息后以 \$99 交易. 价格本身确实下降了 1%, 但原股东同时收到每股 \$1 现金. 在忽略税费和其他市场变化的这个例子中, 股东持有的股票与现金合计没有减少, 因而总持有收益为零.

损益回答赚了多少钱. 为了比较不同初始投入, 再把损益除以投入资金, 就得到收益率.

定义 6.7.

在一单位, 全额支付, 买入并持有的上述假设下, 令 $S_s > 0$. 从 s 到 t 的简单价格收益率为

$$R_{s,t}^P := \frac{S_t - S_s}{S_s}.$$

加入持有期间收到的现金流, 得到总收益率

$$R_{s,t} := \frac{S_t - S_s + D_t - D_s}{S_s}.$$

因此, 长期比较股票表现时, 应分清原始价格 (raw price), 复权价格 (adjusted price) 与总回报 (total return) 分别记录了什么. 只看原始价格变化, 可能遗漏股东已经取得的现金分配.

这里的 D_t 只是现金分配的累计, 没有假定收到以后自动买入更多资产. 若把股息重新投入, 持有数量就会改变, 后续收益也会基于新的持仓产生. 这时应当研究包含再投资的总回报财富过程 (total-return wealth process).

对数价格变化与对数收益率 连续多期的增长要相乘. 若两期简单收益率分别为 R_1, R_2 , 初始 \$1 在两期后变成 $(1 + R_1)(1 + R_2)$; 直接相加收益率会遗漏复利项. 对数把这种乘法转换为加法, 因而经常用于描述跨期变化.

定义 6.8.

若 $S_s, S_t > 0$, 且比较的是同一组交易条件下的价格, 从 s 到 t 的对数价格变化定义为

$$r_{s,t} := \log \frac{S_t}{S_s}.$$

金融文献中也常称其为对数价格收益率.

因为 $r_{s,t} = \log(1 + R_{s,t}^P)$, 对 $s < u < t$ 有

$$r_{s,t} = r_{s,u} + r_{u,t}.$$

所以一段较长时间的对数变化, 可以由各小段直接相加. 等价地, $S_t = S_s e^{r_{s,t}}$, 其中 $r_{s,t}$ 表示整个区间的累计连续复利变化; 若要写成单位时间的连续复利率, 还须除以 $t - s$.

当变化较小时, $\log(1 + x) \approx x$, 简单价格收益率与对数价格收益率数值接近. 但这两个量仍有不同定义, 尤其在跨期累计时不能互换计算方法.

这里取对数的是价格之比. 若持有期间还有股息, 或者持仓因交易和再投资而改变, 就要对相应的财富过程研究复利增长. 此外, 对数要求所用数值严格为正, 对可能达到零或变成负数的价格不能直接套用这个定义.

6.1.5 策略, 头寸与财富

头寸与损益 同一段价格变化落到投资者账户里有多大金额, 取决于实际持有多少单位.

定义 6.9.

时刻 t 的数量头寸记为 θ_t , 表示投资者当时净持有的单位数. $\theta_t > 0$ 为多头, $\theta_t < 0$ 为空头, $\theta_t = 0$ 表示没有净持仓.

若从 s 到 t 始终持有固定数量 θ , 暂不计费用, 税和融资成本, 则总损益就是每单位收益乘以数量:

$$P\&L_{s,t} = \theta(S_t - S_s + D_t - D_s).$$

这里能够把 θ 提到括号外, 是因为整个期间数量没有变化. 若中途成交改变了持仓, 就要按每一段实际持有的数量分别计算.

一次买入后固定持有并最终卖出的现金账也很直接：期间收到的现金分配和最后的净卖出款是流入，最初的买入价款，交易费用和融资利息是流出。一笔费用若已经包含在买入或卖出的净金额中，就不再扣第二次。

策略不断交易时，更方便直接跟踪整个账户。记

$$V_t^h = C_t^h + MV_t^h(\theta_t^h),$$

其中 C_t^h 是现金减去已经计入的融资负债后的净额， θ_t^h 是成交以后实际持有的头寸， MV_t^h 是未平仓持仓按当前估值口径计算的价值。对普通现货，

$$MV_t^h(\theta_t^h) = (\theta_t^h)^\top S_t.$$

借款取得的现金与相应负债要同时入账；把现金记进去却漏掉债务，会把融资误认为盈利。

若投资者在策略运行期间还从外部追加或取走资金，记累计净注资为 A_t^h ，流入取正。那么策略本身从 0 到 H 产生的金融损益为

$$\Pi_{0:H}^{\text{financial}}(h) = V_H^h - V_0^h - (A_H^h - A_0^h).$$

已经计入 V_t^h 的股息，费用或融资收支都不再在这个式子外重复加减。

若还要把损益换成百分比，就先选定分母。以正数 K_0^h 表示所采用的初始自有资金或其他明确的资金占用量，定义

$$R_{0:H}^{\text{financial}}(h) = \frac{\Pi_{0:H}^{\text{financial}}(h)}{K_0^h}.$$

同样 70 美元损益，若最初只占用 500 美元自有资金和若占用 1000 美元，报出的收益率自然不同。因而策略收益率必须和所用分母一起读。

订单本身还不是持仓。从 θ_s 调整到 θ_t ，要等相应买卖真正成交以后，账户头寸才发生变化。后面的订单簿部分会继续计算这段调整实际花了多少钱。

保证金与杠杆 用借款或衍生品可以让市场暴露大于最初投入的自有资金。经纪商或清算机构通常还要求账户保留一定担保资产，用来覆盖持仓亏损和履约风险。

定义 6.10.

保证金 (margin) 是建立或维持某些头寸时，投资者须提交或保留的现金或合格资产。

先看实际借款的股票融资。假设投资者用 50 美元自有资金加 50 美元借款，买入价值 100 美元的股票，暂不计利息和费用。股票上涨 10%，持仓赚 10 美元，相对于 50 美元自有资金就是 20%；股票下跌 10%，也会损失自有资金的 20%。股票本身仍只涨跌 10%，放大的是账户相对于自有资金的结果。

定义 6.11.

杠杆 (leverage) 描述市场暴露相对于净财富的放大程度。在简单的单资产现货账户中，若 $V_t > 0$ ，可以写成

$$L_t = \frac{|\theta_t S_t|}{V_t}.$$

亏损会减少账户权益。当权益或保证金低于维持头寸所要求的水平时，经纪商可能要求补充现金或抵押物，这就是**追加保证金** (margin call)；若要求没有得到满足，头寸可能被平仓。因而有杠杆的持仓不仅关心最终价格，中途是否跌到保证金门槛同样会影响结果。

期货中的初始保证金与上面的 50 美元股票借款不是同一件事。期货交易存入的是履约担保，并没有因为只存一部分保证金就同时借入其余名义金额。期货盈亏怎样进入账户，下一节会用逐日结算的完整数字计算。

投资组合与财富 同时持有 n 项资产时, 将数量和价格分别写成向量

$$\theta_t = (\theta_t^1, \dots, \theta_t^n), \quad S_t = (S_t^1, \dots, S_t^n).$$

若 C_t 已经把现金和融资负债按净额记录, 简单现货组合的净财富为

$$V_t = C_t + \theta_t \cdot S_t.$$

保证金账户中的资产仍属于账户财富, 只是用途受到限制. 例如把 10 美元从自由现金转到保证金账户, 一边减少 10 美元, 另一边增加 10 美元, 净财富本身不变; 后续交易盈亏, 利息和手续费才会改变总额.

不同持仓还可以相互对冲. 因而多资产或衍生品账户除了看名义金额, 还要看各头寸对同一市场变化的方向和敏感度. 前一章的自融资公式则负责记录调仓时现金怎样在这些持仓之间转移.

6.1.6 价格, 分配与财富

到这里已经有三个不同的过程. S_t 记录所选市场价格, D_t 记录每单位资产截至当时已经支付的现金, V_t^h 则记录某个具体策略在实际持仓, 融资和交易以后拥有多少净财富.

同一只股票可以有完全相同的 S_t 和 D_t , 两个投资者却因为持股数量, 借款和买卖时点不同而得到不同的 V_t^h . 后续金融模型正是用滤过规定什么时候能够调整持仓, 再用自融资关系把这些调整和财富变化联系起来.

下一节先不直接买卖原资产, 而是签订一份规定未来如何收付的合约. 远期, 期货和期权由此把价格变化转换成不同形状的现金流.

6.2 衍生品与或有现金流

在第6.1节中, 我们直接持有股票: 股价每变动一美元, 固定数量持仓的市值就相应变化. 衍生品则由合约条款规定标的价格或状态怎样决定未来收付. 航空公司可以预先约定三个月后的燃油买价; 股票持有人也可以支付权利金, 换取将来按约定价格卖出股票的权利. 两种合约都针对未来价格的不确定性, 但规定的现金流完全不同.

本节先把这些规则写成支付函数, 再计算保证金, 结算和权利金怎样进入账户. 通用背景参考 [Hul22; Opt; US 15].

定义 6.12.

金融合约 (financial contract) 规定交易各方在未来什么时间或条件下应交付什么资产, 支付多少现金, 或可以行使什么权利.

定义 6.13.

衍生品 (derivative) 是价值或未来现金流依赖于某项资产, 市场变量或未来事件的金融合约. 用来确定其价值或支付的参考对象称为**标的** (underlying).

标的可以是股票, 商品, 汇率, 利率, 股票指数或波动率. 持有衍生品时不必同时持有标的. 合约根据约定的标的价格, 市场变量或事件状态, 确定相应的现金收付或交割义务.

定义 6.14.

或有现金流 (contingent cash flow) 是金额或是否发生取决于未来市场情况或事件的现金流.

例如合约可以规定, 三个月后的股票价格超过 100 美元时, 按超过 100 美元的部分支付. 若到期支付只由 S_T 决定, 记为

$$X = \Phi(S_T),$$

其中 Φ 就是今天已经写进合约的支付函数. 远期的 Φ 是一条直线, 期权的 Φ 则带有折点.

6.2.1 线性衍生品与期货

远期合约 航空公司可以先与交易对手约定未来的购买条件, 把尚不确定的采购价格固定下来. 这就是远期合约的基本用途.

定义 6.15.

远期合约 (forward contract) 是双方现在约定, 在未来时刻 T 按事先确定的价格 K 买卖一定数量标的资产的合约.

假设今天约定三个月后以 100 美元买入一股股票. 到期若股票市价为 120 美元, 多头仍只支付 100 美元, 相对于当时市价有 20 美元的正差额. 若股票只值 80 美元, 多头也仍须支付 100 美元, 相对于市价多付 20 美元. 远期双方都必须按约履行, 多头不能只在有利时才成交.

定义 6.16.

实物交割 (physical delivery) 是实际交付约定的标的资产, 同时支付相应价款. **现金结算** (cash settlement) 是按合约规则计算应付差额, 以现金结清, 不交付标的资产.

对一单位远期多头, 到期的净经济支付为

$$S_T - K.$$

现金结算时, 正值表示多头收钱, 负值表示多头付钱. 实物交割时, 则是支付 K 并取得价值为 S_T 的资产; 不能把净值 $S_T - K$ 误当成购买资产时实际需要支付的价款. 空头的净支付相反, 为 $K - S_T$.

到期的 $S_T - K$ 称为合约的**到期支付** (payoff). 若还要算持有这份合约的最终利润, 再把最初为合约支付的价格, 期间费用和融资收支加入现金账.

新签远期通常把交割价 K 选到使合约初始价值为零, 这个 K 称为该期限的**远期价格** (forward price). 签约以后 K 固定不变, 市场条件却会继续变化, 因而这份旧远期的价值可以转为正数或负数. 所以“今天新远期采用什么交割价”和“以前签下的远期今天值多少钱”是两个不同计算.

期货与实际对冲 远期可以逐笔商定条款, 期货则把数量单位, 到期和交割等条件标准化, 让参与者在统一市场中交易.

定义 6.17.

期货合约 (futures contract) 是按交易所规定的标准化条款交易, 由相应期货价格和结算价格的变化产生盈亏的衍生品合约.

与通常的远期相比, 期货还使用中央清算, 保证金和定期盈亏结算. 因而同样一段价格变化, 两者收到或支付现金的时点可能不同. 后面比较远期与期货价格时, 会再用到这个区别.

定义 6.18.

名义金额 (notional amount) 是合约中用于计算现金流或表示价格暴露规模的参考金额. **保证金** (margin) 是为履约而存入的资金或合格抵押品.

例如, 一份合约可以对应 \$100,000 的名义暴露, 建仓时却只要求存入其中一部分金额作为保证金. 这不表示交易者已经买下价值 \$100,000 的标的, 也不表示其余部分必然是一笔借款. 保证金用于承担合约亏损, 盈亏仍按整个合约数量和乘数计算.

定义 6.19.

在这里的期货结算语境中, **逐日盯市** (daily marking to market) 是按每日官方结算价计算持仓盈亏, 并通过相应结算款增加或减少账户资金的安排.

CME 的说明以每日官方结算价确定这项盈亏收付 [CMEc]. 已连续持有的头寸, 本日盈亏相对于上一结算价计算; 建仓当天则从实际开仓价算到当日结算价. 若持有 n 张多头, 每点乘数为 m , 用 F_d 表示第 d 日结算价, 则

$$\Delta \Pi_d = nm(F_d - F_{d-1}).$$

首日把 F_0 取为开仓价. 空头的盈亏符号相反.

例 6.20 (连续两天的期货结算与追加保证金).

投资者买入 2 张线性期货, 每张每点为 \$10, 开仓价为 1,000 点. 本例设每张初始保证金为 \$2,000, 维持保证金为 \$1,500, 因而一开始存入 \$4,000, 合计维持要求为 \$3,000. 账户低于维持要求时须补回 \$4,000 的初始保证金总额. 两天内不改变持仓, 不计费用和利息, 也不安排其他现金收支.

建仓时的名义金额为

$$2 \times 10 \times 1,000 = \$20,000.$$

投资者没有支付 \$20,000 购买标的, 而是以 \$4,000 保证金承担这两张合约的盈亏.

第一日结算价为 1,030, 多头盈利

$$\Delta\Pi_1 = 2 \times 10 \times (1,030 - 1,000) = \$600.$$

结算后保证金余额为 $4,000 + 600 = \$4,600$.

第二日结算价降至 940. 本日从上一结算价 1,030 开始计算, 所以

$$\Delta\Pi_2 = 2 \times 10 \times (940 - 1,030) = -\$1,800.$$

结算后, 补款前的余额为 $4,600 - 1,800 = \$2,800$.

时点	结算价	当日盈亏	补款前余额	追加资金	补款后余额
第一日	1,030	+600	4,600	0	4,600
第二日	940	-1,800	2,800	1,200	4,000

表中除价格以点计外, 金额均为美元. 第二日余额低于 \$3,000 的维持要求, 按本例约定须补回 \$4,000, 因此追加 $4,000 - 2,800 = \$1,200$. 不能只补与维持要求相差的 \$200, 因为本例的补款目标是初始保证金水平.

两天累计盈亏为

$$\Pi_{0:2} = 600 - 1,800 = -\$1,200 = 2 \times 10 \times (940 - 1,000).$$

追加保证金是投入资金, 不会使亏损消失, 也不是另一笔交易亏损. 补款后账户有 \$4,000, 投资者累计投入了 \$5,200, 差额仍为亏损 \$1,200. 若随后恰按 940 平仓且无费用, 就没有新的价格盈亏, 不能再扣一次从开仓算起的 \$1,200.

表格按每日官方结算价列出现金盈亏, 所以第二日从上一日结算价 1030 而不是最初开仓价重新计算当天亏损. 风险检查则可以发生得更频繁. CME 的清算安排同时包含日内风险管理和日终结算, 必要时还会有额外的日内保证金或变动保证金要求 [CMEa]. 因而“按每日结算价收付盈亏”和“日内什么时候检查账户是否还能维持头寸”是两套时间安排.

这也解释了为什么期货要关心中间路径. 账户若在价格后来恢复以前已经跌破保证金要求, 交易者可能必须先补款或减仓.

例 6.21 (航空公司的燃油对冲).

假设航空公司担心三个月后的燃油采购成本上涨, 可以提前建立数量和期限相匹配的期货多头. 它仍按原有供应体系向燃油供应商采购, 不必为了使用期货, 就改由交易所取得实际所需的燃油.

临近采购时, 可以用同一合约的反向交易结束原持仓, 称为**平仓** (close out). 期货累计盈亏与供应商的采购款分别计算, 再合起来看净成本. 若 Π_T^{fut} 以盈利为正, 暂不计额外费用和融资成本, 则

$$\text{对冲后的净采购成本} = \text{实际采购支出} - \Pi_T^{\text{fut}} \approx \text{事先希望锁定的采购成本}.$$

燃油涨价时, 采购支出增加, 期货多头的盈利可以抵消其中一部分. 燃油降价时, 采购变便宜, 期货亏损则抵消部分节省. 对冲的目的在于让合计成本较稳定, 不要求期货账户在每种情况下都盈利.

等式后的近似取决于匹配程度. 实际采购的航空燃油与合约标的可能在品种, 地点和时间上不同, 两种价格不会始终同步. 即使方向大致一致, 变化幅度也可能不同.

定义 6.22.

基差风险 (basis risk) 是被对冲价格与所用衍生品价格不能完全同步变化, 因而在对冲后仍保留的风险.

因此, 企业还要研究残余价格差异和保证金资金需要. 期货可以减小采购成本的不确定性, 却未必同时消除基差与持有期间的现金压力.

例 6.23 (基差作为交易对象).

价格差异不仅可能是对冲留下的风险, 也可能是交易者主动研究的目标. 在**国债基差交易** (Treasury cash-futures basis trade) 中, 交易者可能买入可交割现券, 同时卖出国债期货, 关注两者相对于交割安排和持有成本是否存在价格差异 [AS23; BKM23].

多头现券和空头期货可以抵消一部分共同的利率方向风险, 但交易仍有 repo 融资, 期货保证金和流动性需要. 相对价格尚未按预期收敛以前, 资金压力就可能迫使其减仓. 后面的美债与 repo 内容会继续解释这种看似对冲充分的持仓为什么仍有路径风险.

永续合约 普通期货有固定到期日. **永续合约** (perpetual futures 或 perpetual swap, 简称 perp) 通常没有固定到期日, 因而头寸可以长期维持. 为了让多空头寸长期存在, 合约还要规定保证金, 资金费以及价格盈亏怎样结算 [Ang+22; He+24].

下面以一单位, 同币种结算的线性永续多头为例, 分开记录账户中的各项变化. 记实际开仓价为盈亏基准 P^{basis} , 标记价格为 M_t .

第一步是持续重估持仓. 按标记价格计算的未实现盈亏为

$$U_t = M_t - P^{\text{basis}}.$$

只要标记价格变化, U_t 就随之变化. 这一步是在给当前头寸估值, 尚未说明现金已经结算进余额.

第二步是用当前权益检查保证金风险. 若账户余额为 B_t , 简化账户的权益为

$$E_t = B_t + U_t.$$

因此即使余额暂时没有现金变动, 标记价格下跌仍会立刻减少权益. 风险系统可以把这个权益与维持保证金要求比较, 在周期结算或资金费时点以前就触发补充担保或强平. Bybit 的相关规则就是使用标记价格作强平判断 [Bybb].

第三步是在规定时点收付资金费. 永续没有普通期货的最终到期交割, 通常用资金费调节长期持有多头和空头的成本. 当永续价格相对参考现货价格偏高时, 常见安排是多头向空头支付; 偏低时方向可以反过来 [Ang+22; He+24]. 若以 $f_k > 0$ 表示本次费率下多头付款, N_{t_k} 为计费名义金额, 则把多头本次资金费的净现金流记为

$$\Delta A_{t_k}^{\text{fund}} = -f_k N_{t_k}.$$

资金费只结算这一项费用, 价格盈亏另按合约的结算规则处理.

第四步是某些产品按规定时点结算价格盈亏. 例如 Bybit 的 USDC 永续会把周期内未实现盈亏计入账户余额, 并以结算时的标记价格重置后续盈亏基准 [Byba]. 因而周期盈亏结算与资金费即使发生在附近时点, 也分别按自己的规则计算.

例 6.24 (标记价下降以后, 先变的是权益).

假定投资者持有一单位线性永续多头, 实际开仓价为 \$1,000, 投入 \$100 保证金, 账户没有其他持仓, 抵押品价值不变. 暂不计手续费, 资金费和其他收支, 本段价格变化中也尚未进行周期盈亏结算.

标记价格降到 \$960 时,

$$U_t = 960 - 1,000 = -\$40, \quad E_t = 100 - 40 = \$60.$$

此时账户余额仍是 100 美元, 但按当前标记价计算的权益已经只有 60 美元.

再设本例的维持保证金等于当前标记名义金额的 5%, 权益不高于维持要求时触发风险处置. 标记价为 960 美元时, 维持要求是 $960 \times 5\% = 48$ 美元, 权益 60 美元仍高于它. 若继续下跌, 触发标记价格 M^* 满足

$$100 + (M^* - 1,000) = 0.05M^*, \quad M^* = \frac{900}{0.95} \approx \$947.37.$$

因而在本例规则下, 标记价降到约 947.37 美元时就达到风险门槛. 947.37 美元是风险系统使用的标记价格条件, 强平订单真正成交的价格还要由当时订单簿决定.

现在回到标记价 960 美元这一时点. 若产品在这里进行周期盈亏结算, 就把 40 美元浮亏从未实现项转入余额: B_t 从 100 变成 60, 新盈亏基准改为 960, U_t 从 -40 重置为 0. 结算前权益是 $100 - 40 = 60$, 结算后仍是 $60 + 0 = 60$. 这一步只是把同一笔亏损从一个账户项目移到另一个项目, 没有新增第二笔 40 美元亏损.

随后价格若继续从 960 美元下跌, 新的未实现盈亏从 960 这一重置基准开始计算. 已经结算进余额的 40 美元不能再从原始 1000 美元开仓价重复计算一次.

由这份账户可以看出, **持续按标记价重估, 实时检查保证金, 资金费收付和价格盈亏现金结算**是四件不同的事. 风险检查可以很频繁, 并不意味着每一次标记价变化都立刻形成现金收付; 反过来, 按每日或其他周期结算现金盈亏, 也不表示结算间隔内不检查风险 [Byba; CMEa].

若最终以实际成交价 P_t^{perp} 全部平仓, 开仓成交价为 P_0^{perp} , 并把期间资金费的累计净收付记为 A_t^{fund} , 则在暂不计其他费用和资金时间价值时, 总损益为

$$\Pi_t = (P_t^{\text{perp}} - P_0^{\text{perp}}) + A_t^{\text{fund}}.$$

期间若已经把部分价格盈亏结算进余额, 就把各段已结算盈亏与最后一段未结算盈亏相加, 最终仍得到开平仓价格之差. 从账户流水计算时, 已经进入余额的价格盈亏和资金费也各自只计一次.

算力期货 期货可以按价格指数现金结算, 不一定交付实物. 若要把算力租赁成本写成这样的合约, 第一步就是先定义一个双方都能观察的价格基准.

例 6.25 (算力期货).

假设一家公司半年后需要大量 H100 或 B200 算力. GPU 型号, 集群规模, 网络结构, 数据中心位置, 租赁期限和服务质量都会影响最终租价, 因而不能简单把“算力价格”当成一个统一数字.

一种设计是先规定可比较的服务规格, 收集符合规格的租赁报价, 再计算每 GPU-hour 的价格指数. 期货可以围绕这个指数现金结算, 公司仍然在实际采购市场租用所需算力.

如果半年后公司的实际需求换成另一种 GPU 或不同集群配置, 企业真正支付的采购成本就可能与原指数走势不同, 这就是基差风险. 此外, 只有市场上有足够报价和成交数量, 企业才真正能够用这份合约建立所需对冲.

股指期货 股票指数是按规则计算的数值. 所谓“买入 S&P 500”, 通常是买入跟踪它的交易所交易基金 (exchange-traded fund, ETF), 指数基金或其他产品, 并没有取得一个可以直接交付的指数数值. 但合约可以把这个数值用作现金结算依据.

定义 6.26.

股指期货 (stock index futures) 是以股票指数为标的, 按合约规定的指数结算水平和乘数计算盈亏的期货合约.

指数本身不能像股票或商品那样交付, 所以股指期货通常采用现金结算. 设 $F_{0,T}$ 是建仓期货价格, I_T^{settle} 是到期结算指数, 每点乘数为 m . 对一张一直持有至到期的多头, 忽略费用以及中间结算款的利息影响, 累计损益为

$$m(I_T^{\text{settle}} - F_{0,T}).$$

这是各次价格差额结算相加后的结果, 与前面的两日期货例子相同. 多张合约再乘以张数, 空头则改变符号. 到期时通常只需完成最后一段结算, 不能把这项累计损益再支付一次.

例 6.27 (利用股指期货降低市场风险).

假设基金持有几百只股票, 仍看好这些公司的长期前景, 但担心接下来几个月市场因经济或利率变化而共同下跌. 它可以出售股票, 也可以保留原持仓并卖出适当数量的股指期货.

若股票组合与指数一同下跌, 空头期货的盈利就能抵消部分股票损失. 合约数量应根据组合对该指数变化的敏感程度确定, 组合与指数表现不同的部分则仍然保留. 因此, 卖出股指期货可以是降低整体风险, 不必表示基金已经看坏每一家持股公司.

要判断这样的对冲是否合适, 还须知道指数由什么组成, 与持仓有多大差异. 后面的市场指数, ETF 和被动投资内容将继续讨论 S&P 500, Nasdaq-100 等指数的构造.

远期和期货价格就是未来价格吗 合约围绕未来价格产生盈亏, 不等于今天的合约报价就是未来现货价格的平均预测. 对能够持有和复制的标的, 今天买入现货并持有到交割日的成本, 已经会约束远期价格.

先考虑一个简单的无套利模型. 资产现价为 $S_0 > 0$, 可以自由买卖和卖空, 持有期间没有股息或其他现金流, 没有交易成本, 并能按同一个确定的连续复利率 r 借贷. 对初始价值为零的新远期, 交割价满足

$$F_{0,T} = S_0 e^{rT}.$$

可以直接看出两边为什么必须相等. 若远期交割价更高, 就借入 S_0 买进现货, 同时卖出远期. 到期交付现货收到远期价款, 偿还 $S_0 e^{rT}$, 留下确定的正差额. 若远期交割价更低, 就卖空现货并将所得贷出, 同时买入远期; 到期按较低交割价取得资产还券, 同样留下正差额. 在这些交易均能实施的假设下, 无套利排除了两种偏离.

因此, 正利率使这一模型的远期价高于现货, 零利率使两者相等, 负利率使远期价低于现货. 这些方向来自融资成本, 本身没有预测到期现货一定上涨或下跌.

若资产支付股息, 现货持有人取得了远期持有人尚未取得的期间现金, 价格关系就要调整. 商品还可能有仓储, 保险和损耗成本, 持有库存也可能为经营提供便利, 称为**便利收益** (convenience yield). 这些收入与成本共同进入**持有成本** (cost of carry) 的分析, 具体关系仍取决于实际可实施的持有和交割方式 [Hul22].

期货还多了中途盈亏结算. 在确定利率等简单条件下, 同期限期货与远期价格可以相同. 利率随机时, 提前收到的盈利可以再投资, 提前支付的亏损则可能需要融资, 现金流时点与利率的关系会使两种价格不同.

现实世界的终价均值记为 $\mathbb{E}^{\mathbb{P}}[S_T]$. 它描述在所采用现实概率判断下, 未来价格平均是多少; $F_{0,T}$ 描述今天新远期的交割报价; S_0 则是现在的现货价格. 只有进一步比较远期报价与现实世界的终价均值, 才进入预期收益和风险补偿问题.

后面的风险中性定价会把价格写成相应测度下的折现期望. 那个期望服务于无套利定价, 与现实测度 $\mathbb{P}$ 下的预测均值仍须区分.

6.2.2 期权与非线性现金流

期权 远期要求按约履行. 若约定未来按 \$100 买入股票, 不能仅因届时股票跌到 \$50 就放弃义务. 期权买方取得的则是选择: 有利时按约行使, 不利时可以放弃.

定义 6.28.

期权 (option) 是赋予买方选择权的衍生品合约. 买方可以按照约定的时间和条件买入或卖出标的, 获得相应现金结算, 或放弃行权. 卖方承担与买方权利相对应的履约义务.

合约须写明**执行价格** (strike price) K , **到期日** (expiration date 或 maturity) T , 标的单位数和行权规则. 按规则使用权利称为**行权** (exercise). 合约单位数决定每单位支付和权利金要乘多少倍; 因而只看每单位报价, 还不能知道整张合约实际需要收付多少钱.

定义 6.29.

看涨期权 (call option) 赋予买方按 K 买入标的或获得相应现金结算的权利. **看跌期权** (put option) 赋予买方按 K 卖出标的或获得相应现金结算的权利.

定义 6.30.

欧式期权 (European option) 只能在到期日 T 行权. **美式期权** (American option) 可以在到期日或以前符合合约规定的时刻行权.

European 和 American 在这里是行权规则的名称, 与在哪里交易无关. 先看一单位欧式期权的到期结果. 看涨期权在 $S_T > K$ 时具有正的行权价值, 在 $S_T \leq K$ 时没有正的行权价值, 所以支付为

$$(S_T - K)^+ = \max(S_T - K, 0).$$

看跌期权反过来, 在市场价格低于约定卖价时提供保护, 支付为

$$(K - S_T)^+ = \max(K - S_T, 0).$$

现金结算时, 它们可以直接表示净结算金额; 实物交割时, 它们表示交付和收款合起来的净经济价值.

定义 6.31.

买方为取得期权而支付的价格称为**权利金** (option premium).

到期支付没有减去买入权利的成本. 例如支付为零且最初付了 \$5, 就损失 \$5; 到期收到 \$10 而最初付了 \$7, 忽略费用和资金时间价值, 净利润才是 \$3. 因而“到期值得行权”与“买入期权已经回本”是不同判断.

例 6.32 (欧式看涨期权的支付, 盈亏与回本价格).

假设买入一张以美元现金结算的欧式看涨期权, 执行价为 \$100, 每单位权利金为 \$5, 每张合约包含 100 个标的单位. 买方全额支付权利金并持有到期, 本例不计费用, 税和资金时间价值.

建仓支出为

$$100 \times 5 = \$500.$$

整张合约的到期支付和净盈亏分别为

$$X_T = 100(S_T - 100)^+, \quad \Pi_T = 100(S_T - 100)^+ - 500.$$

三种到期结果如下, 金额均为美元:

到期情况	标的价格 S_T	合约支付 X_T	净盈亏 Π_T
低于执行价	80	0	-500
高于执行价但未回本	103	300	-200
超过回本价格	120	2,000	1,500

第一种情况下, 期权没有到期支付, 权利金全部损失. 第二种情况下, 每单位具有 \$3 的正支付, 整张收到 \$300, 但此前支付了 \$500, 所以仍亏 \$200. 第三种情况下, 收到 $100 \times 20 = \$2,000$, 扣除权利金后赚 \$1,500.

盈亏平衡要求

$$100(S_T - 100) - 500 = 0, \quad S_T = \$105.$$

所以本例的到期回本价格为执行价加每单位权利金, 即 $100 + 5 = 105$. 合约到期出现正支付只需要超过 100, 净盈利则需要超过 105.

这个例子采用现金结算. 若改为实物行权, 正的净经济支付不意味着只支付差额就能拿到标的: 买方仍须按执行价支付全部交割价款, 并取得相应数量的资产. 比较实际账户收支时, 必须把交割方式一并写清楚.

从线性暴露到非线性现金流 远期多头的支付为 $S_T - K$. 标的价格每增加一美元, 一单位远期的支付就增加一美元, 因而是线性暴露. 看涨期权在执行价以下支付为零, 超过执行价以后才随价格增加, 整个支付函数有一个折点.

这使期权不能只靠终价均值来分析. 对可积终价, 远期平均支付由 $\mathbb{E}[S_T] - K$ 决定; 看涨期权的 $\mathbb{E}[(S_T - K)^+]$ 则还取决于价格有多大可能超过 K , 以及超过多少.

例 6.33 (相同均值, 不同平均支付).

用两个假设分布说明这一点. 第一种分布中, 到期价格必为 100; 第二种分布中, 到期价格以各 1/2 的概率等于 80 或 120. 两者的均值都是 100.

取 $K = 100$, 一单位远期多头在第一种分布中的平均支付为零, 在第二种分布中也为 $(-20 + 20)/2 = 0$. 看涨期权在第一种分布中支付为零, 第二种分布中的平均支付却为

$$\frac{1}{2}(80 - 100)^+ + \frac{1}{2}(120 - 100)^+ = 10.$$

因此, 相同的终价均值可以对应不同的期权平均支付. 这里比较的是指定分布下的支付, 尚未计入权利金和贴现, 也没有据此确定市场期权价格.

到期支付与到期前的期权价值也要分开. 支付函数在执行价处有折点, 到期前价值则还取决于剩余时间以及未来价格的分布. 在足够光滑的定价模型中, 记价值为 V , 保持其他输入不变, 对标的价格的一阶敏感度为

$$\Delta = \frac{\partial V}{\partial S},$$

称为 Delta. 它说明标的发生小幅变化时, 期权价值大致改变多少. Delta 随标的价格变化的速度为

$$\Gamma = \frac{\partial^2 V}{\partial S^2},$$

称为 Gamma. 因而今天按某个 Delta 建立的对冲, 标的移动以后未必仍然合适.

未来分布的波动和尾部也会影响期权价值. 用股票或期货抵消主要方向风险以后, 仍可能留下波动率及其他风险. 后面的定价与动态对冲将逐步说明这些敏感度, 这里先保留它们各自回答的问题 [Hul22].

买方的权利与卖方的义务 选择权属于买方, 对应的履约义务由卖方承担. 对全额支付权利金并单独持有的普通看涨期权买方, 忽略费用和融资, 最多损失这笔权利金; 标的上涨时, 到期支付可以继续增加. 实物行权后取得的股票则是新的持仓, 其后续风险要另外计算.

没有对应对冲的看涨期权卖方相反. 收入最多是最初收取的权利金, 但若标的价格没有上界, 履约损失也没有有限上界. 初始收到一笔现金, 不表示这笔现金已经成为没有后续义务的利润 [Opt; US 15].

因此, 分析期权风险时, 要看买方还是卖方, 看涨还是看跌, 执行价, 到期日和合约单位数, 还要看它与已有持仓怎样配合. 同一张期权单独持有时的风险, 与加入股票或其他期权以后的组合风险, 可能明显不同.

6.2.3 合约怎样进入已有持仓

做市商与报价 客户买入期权时, 对手方常常是先提供双边报价, 再管理自身库存的做市商.

定义 6.34.

做市商 (market maker) 是按相应市场制度持续或经常提供买卖报价, 并通过暂时承担库存和价格风险提供流动性的交易者或机构.

期权的买价 (bid) 是做市商愿意买入的报价, 卖价 (ask) 是愿意卖出的报价, 两者之差为买卖价差.

例 6.35 (期权做市).

假设期权每单位报价为

$$\text{Bid} = 4.90, \quad \text{Ask} = 5.10.$$

报价有效且数量足够时, 客户立即买入通常支付 5.10, 立即卖出通常收到 4.90. 若报价完全不变, 买入后立刻卖出, 每单位先损失价差 0.20, 整张合约再乘以合约单位数.

做市商卖出一份看涨期权以后会增加负 Delta. 若整个账户仍有净负 Delta, 可以买入股票或期货使方向敏感度接近目标水平; 若账户中的其他期权已经抵消了这部分 Delta, 所需外部对冲就相应减少. 标的继续变化时, Gamma 又会使 Delta 改变, 因而对冲数量也会随之调整 [Hul22].

同一合约放进不同组合会得到不同风险 衍生品既可以增加风险, 也可以用来对冲原有风险. 航空公司未来需要采购燃油时, 期货多头可以抵消一部分燃油涨价带来的额外支出; 股票持有人担心下跌时, 则可以购买看跌期权, 为组合的到期价值设定一个下限.

例 6.36 (股票加看跌期权).

投资者以 \$100 买入一股股票, 同时支付 \$3 买入一单位执行价为 \$95 的欧式看跌期权, 两者持有到同一到期日. 本例没有股息, 费用, 税和融资成本, 并忽略资金时间价值. 总初始投入为 $100 + 3 = \$103$.

到期时, 股票与看跌期权合计价值为

$$S_T + (95 - S_T)^+ = \max(S_T, 95),$$

所以净盈亏为

$$\Pi_T = \max(S_T, 95) - 103.$$

若股价跌到 \$80, 股票值 80 美元, 看跌期权支付 15 美元, 合计仍为 95 美元, 净亏 8 美元. 若股价涨到 \$120, 看跌期权支付为零, 股票值 120 美元, 净赚 17 美元. 因而在这些到期条件下, 最大亏损为 8 美元: 股票买价与执行价相差 5 美元, 再加 3 美元权利金.

看跌期权把到期时低于 95 美元的股票价值补到 95 美元, 代价是无论涨跌都先支付 3 美元权利金. 因此分析一份衍生品时, 不能只看它单独的支付函数, 还要把它和账户中原有的资产, 融资及其他合约一起计算.

从终端支付到整个价格过程 普通欧式期权到期只支付

$$X = \Phi(S_T).$$

若贴现因子确定, 并已知定价测度下 S_T 的分布, 时刻 0 的价格可以写成一个终端期望. 但动态对冲, 保证金和提前行权都涉及到期以前发生的事情, 此时就要研究整个价格过程

$$(S_t)_{0 \leq t \leq T}.$$

两日期货算例已经给出一个简单例子: 开仓与最终结算价之差能够还原累计价格盈亏, 但第二日之前账户是否跌破维持保证金, 必须知道中间的结算路径. 永续的资金费与风险检查也同样沿时间发生.

有些合约的支付本身就依赖整条路径.

例 6.37 (路径依赖).

亚洲期权 (Asian option) 可以按一段时间的平均价格计算支付, 障碍期权 (barrier option) 则可能取决于价格是否曾经触及某个水平. 两条路径即使具有相同终价, 平均价格或是否触及障碍仍可能不同, 因而支付也不同. 这类合约可以写成

$$X = \Phi((S_t)_{0 \leq t \leq T}).$$

美式期权还允许持有人选择行权时点. 每次决定都只能使用当时已经知道的信息, 因而形成最优停时问题; 第5.3节的 Snell 包络正是把“立即行权还是继续等待”逐期比较.

下一节把支付条件从资产价格改成事件是否发生, 研究预测市场中的事件合约.

6.3 预测市场与市场隐含概率

在第6.2节中, 我们已经用支付函数描述期权到期时如何收付. 一组不同行权价的欧式期权还能告诉我们市场如何给不同终价范围定价: 在相应无套利与光滑性条件下, Breeden–Litzenberger 关系可以从期权价格随行权价的变化中提取风险中性终端分布信息 [BL78; Hul22].

如果关心的不是终价范围, 而是某项审批是否通过这样的具体事件, 可以把支付条件直接写成这个事件是否发生. 预测市场交易的就是这类合约.

6.3.1 先看事件合约怎样支付

定义 6.38 (预测市场与事件合约).

预测市场 (prediction market) 是围绕未来事件或可验证结果交易合约的市场, 其中的合约称为事件合约 (event contracts). 本节研究最简单的二元合约: 按规则确认事件 A 发生时支付一单位结算货币, 否则支付零. 若在 T 判定并支付, 则

$$X_T^A = \mathbf{1}_A.$$

CFTC 介绍事件合约时, 也用 yes-no 问题和固定支付来说明这种结构 [Com]. 因而研究一份合约时, 要先确定事件 A 的具体定义: 截止哪一天观察, 用什么数据或裁决确认结果, 何时结算. 这些条款确定以后, $\mathbf{1}_A$ 才有明确含义.

例如, “某项监管批准是否在规定日期以前发生”与“某家公司股价是否在规定日期以前超过某个水平”分别对应两个不同事件. 前者只在审批条件满足时支付, 后者只看股价路径是否满足约定条件.

注 6.39.

CFTC 在 2022 年曾将 Polymarket 提供的若干事件型二元期权认定为其辖区下的 swaps, 并就未注册交易设施相关问题作出处罚 [Com22].

6.3.2 从盘口算到一笔交易的收益

事件合约也有买价, 卖价和实际成交价. 假设单位面值合约的最优买价为 0.57, 最优卖价为 0.63, 最近成交价为 0.61. 中间价是

$$\frac{0.57 + 0.63}{2} = 0.60.$$

若卖价仍有效且数量足够, 立即买入的成本是 0.63, 而不是中间价 0.60 或上一笔成交价 0.61.

再假设 0.63 一档足以买入 100 份, 每份事件发生时支付 1, 不发生时支付 0, 暂不计贴现和费用. 总买入成本为

$$100 \times 0.63 = 63.$$

事件发生时收到 100, 净赚 37; 不发生时收到 0, 净亏 63. 若研究者自己估计事件发生概率为 p , 这笔交易的期望净损益为

$$\mathbb{E}[\Pi_T] = 37p - 63(1 - p) = 100p - 63.$$

因此在这些交易条件下, 毛期望为正要求 $p > 0.63$. 若卖价一档不能容纳全部 100 份, 就应按各档实际成交数量和价格计算平均买入成本, 再重算同一公式.

6.3.3 从合约价格到市场隐含概率

上一算例直接使用卖价计算买入成本. 若要把事件合约价格与概率放在同一个尺度上比较, 还要处理从今天到结算日之间的时间价值.

以 $D(t, T) > 0$ 表示时刻 t 买入一份确定在 T 支付一单位同种货币的零息无风险支付所需价格. 若单位事件合约的模型价格为 C_t^A , 定义

$$\hat{p}_t^{\text{mkt}}(A) = \frac{C_t^A}{D(t, T)}.$$

若事件发生时支付固定金额 $a > 0$, 则相应归一化为 $C_t^A/[aD(t, T)]$.

定义 6.40 (市场隐含概率).

本节把事件合约价格除以相同到期日, 相同结算货币的确定支付价格, 再按合约面值归一化所得的数, 称为**市场隐含概率** (market-implied probability).

在无摩擦模型中, 单位事件支付满足 $0 \leq \mathbf{1}_A \leq 1$, 所以相应无套利价格满足 $0 \leq C_t^A \leq D(t, T)$, 归一化后落在 $[0, 1]$ 内.

它的概率含义可以由定价核直接看出. 若正的随机定价核 $m_{t,T}$ 对相应支付给出一致定价, 且条件期望存在, 则

$$C_t^A = \mathbb{E}_{\mathbb{P}}[m_{t,T} \mathbf{1}_A \mid \mathcal{F}_t], \quad D(t, T) = \mathbb{E}_{\mathbb{P}}[m_{t,T} \mid \mathcal{F}_t].$$

分子只保留事件发生状态中的定价权重, 分母汇总所有状态的定价权重. 两者相除以后, 正好把这些权重归一化成一个条件概率.

等价地, 若以到期日为 T 的零息债券为计价资产, 对应的 T 远期测度记为 $\mathbb{Q}^T$, 则

$$C_t^A = D(t, T) \mathbb{Q}^T(A \mid \mathcal{F}_t),$$

所以

$$\hat{p}_t^{\text{mkt}}(A) = \mathbb{Q}^T(A \mid \mathcal{F}_t).$$

在确定利率模型中, 确定贴现因子还可以直接提出现金账户定价测度下的期望. 若利率随机, 则未来贴现量本身也是随机变量, 应保留相应计价资产和测度的区别, 不能先把随机贴现项移出期望再沿用原测度的概率解释.

真实盘口通常同时有买价和卖价. 此时可以分别将两边报价除以 $D(t, T)$, 得到可执行买卖价格对应的两侧数值; 上一算例中的实际买入判断仍应使用卖价成本. 定价测度下的概率是否接近现实世界中的事件概率, 还取决于不同状态怎样被市场定价, 以及哪些参与者在交易这份合约 [Man06; WZ04].

6.3.4 从事件概率到公司情景

到这里已经有三个不同的量. 现实世界中的事件 A 有一个实际发生规律; 研究者可以根据资料形成自己的概率估计 p ; 市场价格归一化以后, 在前述定价模型中得到的是 $\mathbb{Q}^T(A \mid \mathcal{F}_t)$. 比较研究判断与市场时, 先把三者分别记清即可.

公司 Bull, Base, Bear 情景还包含事件发生以后公司的经营结果. 例如监管批准只决定某项产品能否按规定进入市场, 批准以后还有销量, 价格, 成本和竞争等变量. 因而事件 A 可以影响公司情景, 却通常不是整个公司情景本身.

实际研究时, 一份事件合约首先给出两项可以直接记录的信息: 条款明确的事件定义, 以及这份合约当前的买卖报价. 下一步再研究这个事件通过什么业务渠道改变公司收入, 成本或项目时点.

6.3.5 怎样把事件合约用于公司研究

先记录事件条款, 判定日期, 结算日期以及所引用报价的时间和种类. 这样以后回看研究时, 能够还原当时研究的具体事件和交易价格.

然后把事件接到公司的经营模型中. 若 A 表示某项审批在规定日期以前通过, 它可能首先改变产品可销售的起始日期. 起始日期变化以后, 再按照原来的患者数, 采用率, 单价和成本假设重算对应期间收入与利润. 若新资料还同时支持这些经营变量改变, 则分别更新相应假设.

当事件合约价格变化时, 研究者可以重新比较自己的概率判断与市场隐含概率. 公司事件图 (Company Event Graph) 则记录事件 A 通过哪些业务关系影响收入, 成本和估值. 几家公司暴露于同一政策或供应链事件时, 市场图 (Market Graph) 可以把同一个外部事件与各家公司各自的传导路径连接起来.

6.3.6 结算规则与交易者信息

同一句日常语言可以对应不同的结算事件. 一份合约可能要求事件在某日期以前发生, 另一份还会指定采用哪个数据源, 首次发布值还是修订值, 或由哪一个机构作最终裁决. 因而比较两份报价以前, 先把它们实际对应的事件集合 A 对齐.

交易者掌握的信息也可能不同. CFTC 在 2026 年关于预测市场的执法提示中讨论了非公开信息误用, 欺诈, wash sales 及其他禁止交易行为, 并列举 KalshiEX 上候选人本人参与交易以及 YouTube 频道内部人员相关的案例 [Com26]. 这些案例说明, 研究异常报价或成交时, 还应查清参与者是否与结算事件存在直接关系.

一笔大单或报价突变则只是一条市场记录. 将它与公开消息, 盘口深度, 跨市场价格和后续成交放在同一时间线上, 才能继续判断当时发生了什么.

6.3.7 预测市场作为随机过程

固定事件 A 和到期日 T 后, 市场会随着新信息不断更新这份支付的价格. 在前面的单一无摩擦价格模型中,

$$\hat{p}_t^{\text{mkt}}(A) = \mathbb{Q}^T(A | \mathcal{F}_t).$$

因此对 $t \leq u \leq T$, 条件期望的塔性质直接给出

$$\mathbb{E}^{\mathbb{Q}^T}[\hat{p}_u^{\text{mkt}}(A) | \mathcal{F}_t] = \hat{p}_t^{\text{mkt}}(A).$$

所以归一化后的模型价格在 $\mathbb{Q}^T$ 下是取值于 $[0, 1]$ 的鞅. 新消息可以使它立即上升或下降; 鞅条件只要求给定当前信息以后, 未来这个归一化价格的条件期望等于当前值.

实际盘口则同时记录买价, 卖价, 数量和成交. 可以分别研究这些序列怎样随消息和订单流变化, 而上面的鞅等式对应的是无摩擦模型中的单一价格.

事件合约把事件结果写成零或一的支付. 下一节的股票指数则先把许多资产按一套规则汇总成一个数, 再由基金和衍生品把这个指数与可交易持仓联系起来.

6.4 指数, ETF 和被动投资

股指期货已经把指数水平用作结算依据. 本节进一步拆开指数和实际持仓: 指数规定选哪些证券, 怎样分配权重和怎样计算表现; 基金则真正持有资产并发行份额; ETF 又让这些基金份额在交易所买卖, 并通过创建赎回与基金资产联系起来.

先从一篮子股票的收益和方差开始, 再依次研究指数权重, 指数基金和 ETF. 相关背景主要参考 [Gas10; Mar52; Nas; SP 26; SP a; SP b; US e; US f].

6.4.1 从单只股票到股票篮子

若全部资金都投在一家公司, 它的产品失败, 工厂事故或管理问题就会影响大部分投资财富. 同时持有多家公司, 可以减少其中一家对组合的影响, 因为这些经营问题未必同时发生.

定义 6.41.

分散化 (diversification) 是通过同时持有多项不完全同步变化的资产, 降低单个资产或局部风险对组合的影响.

效果不能只用持仓家数判断. 设各资产在同一期间的简单总收益率为 $R_1, \dots, R_n$, 有有限二阶矩. 取固定的期初多头资金权重 $w_i \geq 0$, 且 $\sum_i w_i = 1$. 不考虑期中再平衡和额外组合费用时,

$$R_p = \sum_{i=1}^n w_i R_i.$$

将这个加权后的方差展开, 得到

$$\text{Var}(R_p) = \sum_i w_i^2 \text{Var}(R_i) + 2 \sum_{i < j} w_i w_j \text{Cov}(R_i, R_j).$$

第一项是各资产方差乘以权重平方后的总和, 第二项是资产两两协方差的加权总和. 增加持仓数量可以降低单项权重, 但若这些资产经常同向变化, 协方差项仍可能很大. 这就是为什么买入很多高度相似的股票, 可能没有分散掉真正关心的风险 [Mar52].

定义 6.42.

特有风险 (idiosyncratic risk) 主要来自某家公司或资产自身. **系统性风险** (systematic risk) 会同时影响大量资产, 因而难以仅靠增加同类持仓的数量消除.

一家公司的新产品失败更接近特有风险, 经济衰退或整体融资条件收紧则可能同时影响许多公司. 两种区分还要结合所研究的组合: 半导体行业的共同冲击, 对半导体股票组合十分集中, 放进全球多资产组合以后则只影响其中一部分.

注 6.43.

这里的 systematic risk 是资产定价中共同风险的含义. systemic risk 则讨论金融体系的传染或失灵, 两个词不能因中文接近而混用.

分散化并不要求使用指数. 投资者自行选择 100 家公司, 或主动基金建立广泛持仓, 也可以减少单一公司的影响. 指数进一步规定选择哪些资产, 按多少权重计算, 以后怎样维护, 使不同人能够按同一套规则观察和比较一个篮子的表现.

6.4.2 指数怎样选择和计算一个篮子

定义 6.44.

市场指数 (market index) 是按照规定的成分选择, 加权, 维护与收益计算方法, 汇总一组资产市场表现的指标.

规则先决定哪些资产合格, 再决定纳入哪些, 各占多少. 以后遇到拆股, 增发, 回购或成分替换, 还要按规定更新. 股息是否计入收益, 也属于指数定义, 不能在比较表现时临时改变.

先看一个价格指数的基本计算:

$$I_t = \frac{\sum_{i=1}^n P_{i,t} Q_{i,t}}{D_t}.$$

$P_{i,t}$ 是价格, $Q_{i,t}$ 是计算采用的指数股数或相应权重参数, 分子是这些数量按当前价格计算的总值. 指数除数 D_t 把总值换成指数点数, 并按方法规定处理某些非市场涨跌引起的变化.

各项在分子中所占比例就是当时的权重:

$$w_{i,t} = \frac{P_{i,t} Q_{i,t}}{\sum_j P_{j,t} Q_{j,t}}.$$

所以给出 $Q_{i,t}$ 还没有固定以后每天的权重. 价格变化也会改变各项占比. 不同加权方法的主要区别, 就在于怎样设定这些指数股数, 以及在什么时点重新调整.

公司行动需要按其经济内容处理. 股票拆分时, 每股价格下降而股数按相反比例增加. 普通市值加权指数的相应总市值不变, 通常不必为这件事改变除数. 价格加权指数按相同名义股数计算, 拆分会直接减少价格之和, 就通常要调整除数, 避免把单位改变误算成市场损失.

增发, 回购, 特别股息和成分替换也各有规定. 指数提供商通过调整股数, 权重因子或除数, 将这些变化与市场价格收益区分开. 具体采用哪一步, 应以指数方法文件为准 [SP a].

权重规则与再平衡

定义 6.45.

市值加权指数 (market-capitalization-weighted index) 按可计入的市场价值分配权重. 若公司 i 的相应市值为 M_i , 最简单的权重为

$$w_i = \frac{M_i}{\sum_j M_j}.$$

许多指数采用自由流通调整市值, 按方法规定只计入相应的可流通股份. 这样计算的权重, 不一定等于公司全部股份总市值所占比例.

市值加权便于跟踪的一点是, 单纯价格变化通常不要求为维持比例再做同方向买卖. 当成分和计入股数不变, 某只股票上涨后, 指数中的市值占比提高, 原本按相同比例持有的组合也会因这笔股票升值而提高其权重. 基金不必仅因涨价就追加购买.

增发, 回购, 流通比例变化, 并购, 分拆和成分调整则会改变其他输入. 加上投资者申赎, 基金仍有实际交易需要, 所以市值加权并非永远不调仓.

定义 6.46.

价格加权指数 (price-weighted index) 按成分证券的每股价格决定相对影响, 可以理解为用相同名义股数汇总各证券价格, 再通过除数换成指数点数.

假设只有两只股票, A 为 \$300, B 为 \$100. 两者都涨 1% 时, 价格分别增加 \$3 和 \$1, 前者对价格之和的贡献更大. 这取决于每股报价, 与两家公司总市值谁更大不同. 拆股改变每股报价尺度, 因而价格加权指数特别需要相应维护.

定义 6.47.

等权指数 (equal-weighted index) 在规定的再平衡时点, 按其计算方法使各成分公司或证券恢复相同或近似相同的目标权重.

等权描述重设目标的办法, 不表示每个时刻都等权. 价格继续涨跌以后, 上涨较快的持仓会占更大比例, 这称为**权重漂移** (weight drift). 在下次再平衡以前, 权重可以偏离等权目标.

例如, 两项持仓初始各为 \$100. 一项涨到 \$120, 另一项仍为 \$100, 总值为 \$220, 权重成为 $120/220$ 与 $100/220$, 约为 54.55% 和 45.45%. 若此时无成本恢复等权, 每项应为 \$110, 就要卖出第一项 \$10, 用所得买入第二项 \$10. 这是调整已有资金的分配, 再平衡当下并没有凭空增加财富.

与市值加权相比, 定期恢复等权通常带来更多这类买卖, 并提高较小成分的相对权重. 实际成本还取决于流动性和执行方法. 此外, 一个行业若包含较多公司, 公司等权后仍可能占据较高行业权重; 公司等权并不等于行业等权.

几个真实指数 指数名称可以提示大致范围, 具体成分还要按方法文件选择. 以下保留所引用版本的条件, 以说明资格, 加权和维护如何共同起作用.

例 6.48 (S&P 500).

S&P 500 旨在表示美国大型股票市场. 纳入公司须满足身份, 上市地点, 规模, 自由流通市值和流动性等资格, 指数委员会再按方法进行选择和维持.

以所引 2026 年 8 月的 S&P U.S. Indices 方法文件为例, 新进入 S&P 500 的公司总市值门槛为 \$22.7 billion, 最近一个季度的 GAAP 持续经营净利润须为正, 最近四个季度合计也须为正. 这里 GAAP 指美国公认会计原则, 使用的是按这些规则报告的利润, 而非公司另行剔除部分费用后的调整后利润; 两者的区别见第 7.1 节. 对 Equity REIT, 文件允许依据 GAAP 持续经营净利润和/或已报告的 FFO 判断财务可行性 [SP b]. 这些数值属于该版本的方法条件, 不能当成永远不变的入选门槛.

这里的 500 指公司数. 一家公司若有多个合格股份类别同时入选, 实际证券行数可以超过 500. 纳入以后, 主要按自由流通调整市值加权.

因此, S&P 500 不能简单理解成把所有美国股票按总市值排列后取前 500 行. 公司资格, 股份类别和委员会维护都参与最终结果.

例 6.49 (Nasdaq Composite 和 Nasdaq-100).

Nasdaq 既是交易市场及相关基础设施的名称, 也出现在多个指数名称中. **Nasdaq Composite** 广泛覆盖 Nasdaq Stock Market 上市的合资格普通类型证券, 与其中上市股票的整体表现更接近.

Nasdaq-100 采用另一套选择方法. 所引 2026 年方法文件将其设计为度量 Nasdaq 上市的 100 家大型非金融公司, 并使用修正市值加权 [Nas]. 科技权重较高, 不表示只允许科技公司; 消费, 通信, 医药等非金融公司也可以入选.

年度重构包含资格与排名缓冲, 减少边缘公司仅因短期排名变化而反复进出. 该 2026 年版本还允许满足其他适用条件, 且按 Full Market Capitalization 足以进入当前成分前 40 的证券, 通过 Fast Entry 或 3 月, 6 月, 9 月的季度调整加入, 而不要求同时删除另一家公司. 因而某些时点的公司数可以暂时超过 100.

这些例子说明, 名称中的公司数量, 实际证券数量和特定时点的持仓行数, 未必完全相同. 要复算指数, 必须使用相应时期的具体方法和成分资料.

S&P 500 Equal Weight 的季度调整 S&P 500 Equal Weight 使用与 S&P 500 相同的公司集合, 但在季度再平衡时让每家公司恢复相同目标权重. 若约有 500 家公司, 每家公司目标约为 0.2%. 一家公司若有多个入选股份类别, 仍先在公司层面取得一份等权目标, 再按这些股份类别的自由流通市值分配.

再平衡之间, 权重会随着价格自动漂移. 某家公司从 100 涨到 120 而其他条件不变, 它在组合中的份额自然增大; 指数不需要为了这次上涨再买入该股票. 到下一次季度调整时, 才按规则把已经漂移的权重重新拉回目标附近.

2026 年 6 月的调整同时包含权重重设和成分变化. 这一轮用 6 月 10 日收盘价作为重算指数股数的参考价. S&P Dow Jones Indices 在 6 月 5 日公告, Marvell 和 Flex 加入, Pool 和 Campbell's 删除, 变化于 6 月 22 日开盘前生效 [SP 26]. 6 月 19 日为 Juneteenth 休市日, 因而 6 月 18 日是生效前最后一个正常交易日. 从 6 月 10 日参考价到正式生效之间价格仍会变化, 所以实际生效时观察到的权重可以与 0.2% 略有差异.

若要分析这轮调整怎样改变行业权重, 就把所有该行业成分在调整前后的权重分别相加. 例如新增 Marvell 和 Flex 会增加 Information Technology 中的两家公司, 同时一些此前上涨较快的科技成分会因恢复等权而减重; 行业净变化取决于这些调整的合计.

若进一步分解等权指数相对于市值加权指数的后续收益, 可以设置两个对照组合. 第一份按实际季度规则调整, 第二份保留调整前已经漂移的等权组合, 不作本轮再平衡. 在相同后续价格和股息路径下,

$$R^{\text{EW,actual}} - R^{\text{EW,no rebalance}}$$

给出本轮实际调整相对于继续持有旧组合的收益差. 再计算

$$R^{\text{EW,no rebalance}} - R^{\text{Market Cap}},$$

则把本轮调整以前已经存在的权重差异保留下来. 两项相加正好得到实际等权指数与市值加权指数的总收益差.

这里第一项若采用实际季度调整, 就同时包含本轮成分加入删除和权重重设; 若只想研究纯再平衡效果, 则应保持原成分不变, 另做只调整权重的对照. 指数层面的精确复算使用指数提供商的成分和方法数据; ETF 实际持仓则还会受到基金自己的复制和申赎安排影响.

指数怎样概括市场表现 说“今天美国股市上涨了 1%”时, 实际上已经选择了某个基准. S&P 500, Nasdaq Composite, Nasdaq-100, Dow Jones 和 S&P 500 Equal Weight 因为成分与权重不同, 同一天可以给出不同收益.

指数的总收益是各成分收益按相应权重汇总后的结果. 若要知道上涨由哪些行业或公司贡献, 就继续把各成分的权重与收益分组相加. 对高集中度指数, 少数大权重公司的变化就可能占据相当部分的指数涨跌.

价格指数, 总收益指数与净总收益指数 相同成分和权重, 还可能因股息处理不同而产生不同指数收益.

定义 6.50.

价格指数 (price index) 主要计算成分资产的价格变化. **总收益指数** (total return index) 按规则将现金股息再投资, 把这部分分配加入收益. **净总收益指数** (net total return index) 则先按规定假设扣除股息预提税, 再计算相应再投资收益.

例如, 股票由 \$100 降到 \$98, 同时支付 \$4 股息. 价格确实下跌 2%, 但在不计其他因素时, 原股东的总收益为

$$\frac{98 + 4 - 100}{100} = 2\%.$$

价格变化与持有结果之所以不同, 是因为一部分利益已经以现金分配出去. 多期总收益指数进一步规定这笔现金何时及怎样再投资.

净总收益指数按照指数方法统一扣除假定的股息预提税. 因而将基金收益与某个指数比较时, 先选与基金分配处理相匹配的价格指数, 总收益指数或净总收益指数, 再使用相同期间和币种计算差额.

6.4.3 从指数到基金和 ETF

把指数规则变成可持有的组合 指数给出的是一套成分, 权重和收益计算方法. 投资者若希望取得接近这种表现, 可以自己按规则持有股票篮子, 购买指数基金, 或使用股指期货和指数期权等衍生品.

购买指数基金时, 投资者持有的是基金份额, 由基金按照目标指数建立相应的资产组合.

指数基金与跟踪误差

定义 6.51.

投资基金 (investment fund) 将投资者资金集中起来, 按基金规定的投资目标持有和管理资产; 投资者通过基金份额取得相应经济权益. **指数基金** (index fund) 则以跟踪某个指定指数的表现为主要投资目标.

最直接的跟踪办法是按指数成分和权重买入全部证券, 即完整复制. 成分过多或部分证券难以交易时, 可以抽样建立近似组合; 某些产品也使用衍生品取得相应收益. 投资者持有的是基金份额, 由基金按自身文件和安排完成这些交易.

即使基金以跟踪指数为目标, 实际收益也未必与指数完全相同. 管理费, 交易成本, 税, 现金持有, 公司行动处理和复制方式都会造成偏离, 证券借贷收入等则可能抵消其中一部分. 比较时先统一期间和收益口径, 再计算下面两个量.

定义 6.52.

一段期间基金收益减去指数收益, 称为**跟踪差异** (tracking difference):

$$TD_{0,T} = R_{0,T}^{\text{fund}} - R_{0,T}^{\text{index}}.$$

定义 6.53.

各期基金相对指数收益之差的标准差, 称为这里采用的**跟踪误差** (tracking error):

$$TE = \text{sd} \left(r_t^{\text{fund}} - r_t^{\text{index}} \right).$$

跟踪差异回答最后领先或落后多少, 跟踪误差回答各期偏离有多不稳定. 假如每期都稳定落后相同幅度, 跟踪误差可以很小甚至为零, 但投资者仍然持续落后. 报告跟踪误差还应说明日度, 周度或月度频率, 以及如何年化.

ETF 指数基金可以采用不同的申赎和交易方式. ETF 说明的是基金份额怎样交易, 不单独决定基金是否跟踪指数.

定义 6.54.

交易所交易基金 (exchange-traded fund, ETF) 的份额可以在交易所二级市场买卖, 并通常允许授权参与者按规定以资产篮子或现金进行大额份额创建和赎回 [Gas10; US f].

因此, “指数基金”说的是投资目标, “ETF”说的是基金份额怎样组织, 交易和申赎. 跟踪 Nasdaq-100 的 ETF 同时是指数基金和 ETF; 主动 ETF 则同样采用 ETF 结构, 但不以复制某个指数为目标.

在美国市场中, commodity trust, commodity pool 和 exchange-traded note 等产品也常与 ETF 一起列入更广义的 exchange-traded products, 其法律结构和持有人权利与注册 ETF 并不相同 [US e; US f].

ETF 的净值, 市场价格与创建赎回 ETF 份额一边代表基金净资产中的相应份额, 一边又能在交易所连续买卖. 若基金资产价值为 A_t , 负债为 L_t , 已发行份额为 $N_t > 0$, 每份**基金净值** (net asset value, NAV) 为

$$\text{NAV}_t = \frac{A_t - L_t}{N_t}.$$

官方 NAV 通常按基金规定在交易日结束后计算, 盘中 ETF 则已经有新的买卖报价. 参与者还可以根据底层证券实时报价估算一篮子份额当前大约值多少; 部分产品也公布盘中指示价值 IIV [Gas10; US f].

定义 6.55.

授权参与者 (authorized participant, AP) 是与 ETF 基金签订相应协议, 可以按规定直接进行大额份额创建和赎回的机构.

普通二级市场交易只把已经存在的 ETF 份额从卖方转给买方. AP 则还有另一条路径: 用规定篮子或现金向基金换取新份额, 或把份额交回基金换回篮子或现金. 当 ETF 与同一时点可交易篮子之间的价差超过转换和交易成本时, 两条路径之间就可能出现价差交易.

例 6.56 (创建和赎回怎样比较两边价格).

假设一个创建单位为 50,000 份 ETF, 对应篮子可以按总额 \$5,000,000 买入或卖出, 即每份对应 \$100 的篮子价值. 整笔篮子和 ETF 都能够按所列价格成交, 每轮交易, 融资以及创建或赎回成本合计 \$10,000.

若 ETF 每份可以按 \$101 卖出, AP 先以 \$5,000,000 买入规定篮子, 用篮子创建 50,000 份 ETF 后再卖出, 可收

$$50,000 \times 101 = \$5,050,000.$$

扣除篮子成本和全部 \$10,000 费用, 净价差为

$$5,050,000 - 5,000,000 - 10,000 = \$40,000.$$

基金收到篮子并发行新份额.

若 ETF 每份可以按 \$99 买入, AP 先用 \$4,950,000 买入 50,000 份 ETF, 再将这些份额赎回成篮子并按 \$5,000,000 卖出. 扣除同样成本, 净价差也是

$$5,000,000 - 4,950,000 - 10,000 = \$40,000.$$

这次基金收回份额并交付资产, 已发行份额减少.

本例中每份篮子价值为 100 美元, 单边总成本相当于每份 $10,000/50,000 = 0.20$ 美元. 因而 ETF 与可执行篮子价格只有在价差足以覆盖交易, 融资和申赎成本时, 上述转换才留下正收益. 真实市场中还要把两边买卖价差和实际可成交数量放进同一现金账.

官方 NAV 与盘中 ETF 报价还可能使用不同时间的底层价格. 底层市场关闭或报价陈旧时, 盘中 ETF 价格甚至可能先反映新的市场信息. 因而 AP 实际比较的是当时能成交的 ETF 与篮子价格, 不是机械地把盘中价格与上一份官方 NAV 作差.

6.4.4 被动管理与价格形成

定义 6.57.

被动管理 (passive management) 以跟踪事先指定的基准为主要目标, 按相应规则控制基金收益相对于基准的偏离。

被动管理说的是基金怎样相对于基准投资。投资者仍可以主动决定什么时候买卖这只基金; 反过来, 一个按固定算法选股, 目标却是战胜基准的多因子基金, 仍属于主动管理。

基准本身已经规定市场范围, 成分选择, 权重与再平衡办法。指数基金接受这套规则, 主要任务是把自己的资产组合维持在足够接近基准的位置, 并控制前面的 tracking difference 与 tracking error。

基金交易怎样进入底层市场 市值加权基金中, 一只股票单纯上涨以后, 基金原有持仓的市值也同步增加, 权重会自然上升, 不需要仅为了维持市值权重继续追买。真正改变证券数量的交易主要来自资金净流入流出, 成分变化, 股数调整, 再平衡以及基金自身现金管理。

ETF 份额在二级市场成交时, 买方可以直接接手卖方已有份额, 因而这笔成交未必产生底层股票订单。若随后出现净创建或赎回, AP 和基金才按相应机制交换篮子或现金; AP 现有库存又会决定其中多少需要立即进入底层市场。

因此研究指数资金怎样影响市场时, 可以按顺序检查: 指数规则要求目标持仓调整多少, 基金实际发生多少净申赎, AP 现有库存能满足多少申赎需求, 最终还有多少数量需要在底层证券中成交。如果多项成分调整在同一个时点生效, 相应的实际订单也可能集中在相近时间出现。

6.4.5 从指数走向债券

本节介绍的股票指数基金通过持有一篮子股票分享企业的剩余价值。下一节换成债权合同: 债券直接规定本金, 票息和支付日期, 还规定债权在资本结构中的请求顺序。

因此债券定价首先从一串约定现金流开始。市场利率决定这些不同日期的支付怎样折回今天, 信用风险则改变最终能收到多少。下一节就从这两项计算进入债券和利率。

6.5 债券, 美债与利率

公司可以通过发行股票让投资者取得股东权益, 也可以借入资金并约定以后还本付息。后一种关系标准化成可交易证券以后, 就形成债券。

债券分析先从合约现金流开始: 发行人什么时候付息, 什么时候还本金, 违约时债权人按什么顺序取得回收。市场价格则把这些未来支付折到今天。本节随后再研究收益率, 利率敏感度, 美债融资和信用风险。

固定收益, 美债市场以及国债基差交易的背景主要参考 [AS23; BK21; BKM23; CME24; TS11; US b; US c; US d]。

定义 6.58.

债券 (bond) 是发行人为融资而发行的债务证券。持有人依照合约享有未来收取本金, 利息或其他约定支付的权利。

发行时, 投资者提供资金, 发行人承担还款义务。债券进入二级市场以后, 买方通常把钱付给原持有人, 接手这项请求权, 并非再次向发行人提供同额资金。

普通股分享企业扣除其他请求权后的剩余利益, 债券则先约定付款规则。对没有违约或提前赎回的普通固定息债券, 票息和到期本金可以事先列出。但浮息债券的票息取决于参考利率, TIPS 的支付随通胀调整, 可赎回债券可能提前结束, 可转债还包含与股票有关的选择。合同能够先规定计算方法, 未必已经确定以后每笔金额。

普通债券约定的本金称为**面值** (face value 或 par value), 最终还款日称为**到期日** (maturity)。定期利息称为**票息** (coupon)。对固定息债券, **票面利率** (coupon rate) 通常按一年票息占面值的比例表示; 若一年付息多次, 每次金额还要按相应频率计算。

还款能力不足时, 谁先受偿会改变各债权人的回收。因而清偿顺位和担保安排也是债券权利的一部分。债券契约中的限制条款 (covenants) 可以约束继续举债或转移资产等行为, 减少发行人损害债权人利益的空间。分析具体债券时, 这些条款应与现金流一起阅读。

6.5.1 货币的时间价值与零息债券

今天取得 \$100 与十年后取得 \$100, 可供使用的时间不同. 今天的资金可以消费, 支付债务或投入其他资产; 等待十年就放弃了期间这些用途. 未来物价变化也会影响届时的购买力.

已知利率和借贷条件, 就能计算今天的一笔资金到未来会变成多少. 假设可以按一年 5% 的确定利率投资, 今天的 \$100 到一年后成为 \$105. 反过来, 要在一年后取得 \$100, 今天需要

$$\frac{100}{1.05} \approx 95.24.$$

向后累计是复利, 把未来金额换算为今天的金额是贴现. 这个数来自所假定的投资机会, 不能仅凭有通胀就直接指定贴现率.

名义利率以货币金额计量, 实际回报还要考虑物价. 即使按约收到本金和利息, 若实际通胀超过名义收益, 购买力仍可能下降. 因而名义支付有保证与实际购买力不变, 是两个不同要求.

定义 6.59.

零息债券 (zero-coupon bond) 在存续期间不付票息, 到期一次支付约定金额.

先取无违约模型, 用 $P(t, T) > 0$ 表示在时刻 t 购买一份于 T 确定支付一单位货币的零息债券所需的价格, 并有 $P(T, T) = 1$. 它直接回答未来那一单位货币今天值多少, 因而也称为相应期限的曲线贴现因子.

固定今天的 t , 改变付款日 T , 就得到贴现曲线 $T \mapsto P(t, T)$. 一年后和十年后的支付分别使用各自期限的价格, 无须先把所有支付压成同一个利率.

例如, 一张债券在 $T_1, \dots, T_n$ 付票息 $C_1, \dots, C_n$, 最后还支付本金 F . 若这些支付确定, 没有违约和嵌入期权, 并使用同一套无套利贴现价格, 债券全价为

$$B_t = \sum_{i=1}^n C_i P(t, T_i) + F P(t, T_n).$$

此处 B_t 是这张债券的价格. 每项现金流都可以用相应数量的零息债券复制, 所以把各项成本相加. 到期票息和本金虽然同日支付, 金额仍须都计入.

当前可知的 $P(t, T)$ 与沿未来短率路径计算的 $\exp(-\int_t^T r_s ds)$ 不同. 随机利率下, 后一个数要等路径实现才能确定. 在相应定价测度和可积性条件下, 当前债券价格才可以写成这种随机贴现量的条件期望, 后文会继续说明.

注 6.60 (实际使用哪一条曲线).

美债和隔夜指数掉期 (overnight indexed swap, OIS) 等工具可以用来建立不同基准曲线. OIS 交换固定利率支付与按隔夜参考利率累计的浮动支付, 其报价因而提供相应期限的利率信息. 选择哪条曲线, 要看所研究现金流的币种, 抵押和结算条件. 美债收益率与抵押衍生品的贴现率未必相同, 不能仅因都用美元计价就混用.

6.5.2 债券价格, YTM 与市场报价

一张面值 \$1000 的债券每年付 \$50, 票面利率就是 5%. 固定息合约的这项约定不随二级市场价格改变. 但新投资者若以 \$900 买入, 就只付了 \$900 来取得剩余支付, 实际回报不能再用品面利率概括.

到期收益率 (Yield to Maturity, YTM) 把当前价格与约定的剩余现金流联系起来. 它是使这些现金流的贴现值恰好等于买入全价的统一内部收益率. 暂不处理实际日计数和非标准结算, 以年为时间单位并采用每年复利 m 次的约定, 则 y 满足

$$B_t = \sum_{i=1}^n \frac{C_i}{(1 + y/m)^{m(T_i - t)}} + \frac{F}{(1 + y/m)^{m(T_n - t)}}, \quad 1 + y/m > 0.$$

B_t 在这里是全价. 与上一节对每笔现金流分别使用 $P(t, T_i)$ 不同, 计算 YTM 时用同一个 y 折现所有剩余支付, 再求出使现值恰好等于市场全价的那个 y . 它方便用一个数概括一张债券的当前报价, 并不表示整条期限曲线处处都等于这个利率.

沿用面值 \$1000, 年票息 \$50, 买价 \$900 的例子, 再明确假设只剩一年, 到期一次收到最后票息和本金, 没有违约及其他费用. 此时

$$900 = \frac{1050}{1+y}, \quad y = \frac{1050}{900} - 1 \approx 16.67\%.$$

票面利率仍为 5%, 每年票息相对买价为 $50/900 \approx 5.56\%$, 一年持有至到期的收益却还包含本金从买价回到面值的差额. 这三个百分比分别计算不同的东西.

对固定的非负未来支付, 上式每项现值都随 y 增加而下降, 所以价格与 YTM 反向变化. 未来支付没有增加, 若投资者要求更高收益, 能接受的今天买价就会降低.

YTM 是使当前全价等于剩余约定现金流现值的内部收益率. 对有中间票息的债券, 若还想把同一个 y 解释为整段持有期间实现的复合收益率, 就需要将收到的票息按相应速度再投资. 提前出售, 违约或赎回则会直接改变原来用来求 YTM 的现金流.

实际报价还要区分**净价** (clean price) 与**全价** (dirty price). 在通常的固定息债券报价安排中, 买方在两个付息日之间购买债券, 以后会按规则取得整笔下一期票息. 结算时因此另外向卖方支付按日计数算出的**应计利息** (accrued interest):

$$\text{Dirty Price} = \text{Clean Price} + \text{Accrued Interest}.$$

这项支付在买卖双方之间分配本期持有对应的票息, 不改变发行人的原付息日. 具体除息和日计数仍按债券规则处理.

若屏幕上的 99.5 是每 \$100 面值的净价, 实际价款就要在 99.5 上加相应应计利息, 再按购买面值换算. 计算 YTM 和持有回报时, 应使用与实际现金支出相符的全价, 交易费用则另行计入.

6.5.3 即期利率, 远期利率与期限结构

零息债券价格可以换算成不同的利率表示. 对 $t < T$ 和 $P(t, T) > 0$, 采用连续复利, 定义**即期利率**或**零息利率**

$$P(t, T) = e^{-y(t, T)(T-t)}, \quad y(t, T) = -\frac{\log P(t, T)}{T-t}.$$

它把今天付出 $P(t, T)$, 到 T 收到一单位的增长, 换成年化连续复利率. 不同期限有不同价格, 所以也可以有不同的 $y(t, T)$.

还可以比较相邻到期日的零息债券价格. 若今天就锁定未来 T 附近一个极短时间段的借贷条件, 相应的连续复利率由 $\log P(t, T)$ 随到期日 T 的变化率决定. 若该函数可微, 定义**瞬时远期利率**

$$f(t, T) := -\frac{\partial}{\partial T} \log P(t, T).$$

结合 $P(t, t) = 1$, 积分还原为

$$P(t, T) = \exp \left(- \int_t^T f(t, u) du \right).$$

若右端极限存在, 当前瞬时短率为 $r_t = f(t, t)$. 因而 $y(t, T)$ 汇总今天到 T 的整段增长, $f(t, T)$ 描述今天价格所隐含的未来局部交换条件, r_t 则取最短端.

瞬时远期利率 $f(t, T)$ 是从今天的零息债券价格曲线求出来的. 若要问现实世界中未来时刻 T 附近的短率平均会是多少, 则还要指定短率的概率模型. 因而远期曲线首先是一条由当前价格定义的曲线; 把它进一步解释成未来短率预期时, 才需要处理期限溢价, 测度与凸性等因素.

注 6.61 (三种收益率曲线).

平价收益率曲线 (par yield curve) 问每个期限的票息应设为多少, 才使相应债券按面值定价. **零息收益率曲线** (zero-coupon curve) 或**即期曲线** (spot curve) 汇总 $y(t, T)$. **远期曲线** (forward curve) 汇总 $f(t, T)$. 它们可以由同一组贴现价格联系起来, 但纵轴上的利率含义不同.

例如, 美国财政部公布的 Treasury Par Yield Curve 采用平价收益率口径, 并非直接给出零息利率或远期利率. 从票息债券市场估计零息价格以后, 才能按相应方法进一步构造另外两条曲线 [US b].

期限结构模型常把较长期收益率分成未来短率的平均预期和**期限溢价** (term premium). 期限溢价反映投资者为承担较长期利率风险所要求的额外补偿, 可以随时间变化, 也可能为负.

因此观察到曲线倒挂时, 可以进一步研究究竟是未来短率预期下降, 期限溢价变化, 还是两者共同作用. 这一步需要采用具体的期限结构分解模型.

久期, 凸性与每基点价值 固定现金流以后, 可以研究收益率稍有变化时价格怎样改变. 以 $B(y) > 0$ 表示采用给定复利约定的债券全价, 定义**修正久期** (modified duration)

$$D_{\text{mod}} := -\frac{1}{B} \frac{\partial B}{\partial y}.$$

它是价格相对变化对收益率的一阶敏感度, 前面的负号使普通固定支付债券的久期为正. Taylor 展开给出

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y.$$

收益率须以小数代入. 例如, 债券全价为 100, 修正久期为 8, 收益率上升 10 个基点, 即 $\Delta y = 0.001$, 则

$$\frac{\Delta B}{B} \approx -8 \times 0.001 = -0.8\%,$$

所以价格的一阶变化约为 -0.80 . 这里保持现金流不变, 只计算收益率在当前点附近移动 10 个基点时的局部敏感度.

继续保留二阶项, 定义**凸性** (convexity) 为 $\text{Convexity} = B^{-1} \partial^2 B / \partial y^2$, 就有

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y + \frac{1}{2} \text{Convexity} (\Delta y)^2.$$

普通固定正现金流债券在相应收益率范围内具有正凸性. 变动幅度增大时, 一阶近似的误差更值得检查; 若存在赎回等期权, 还要考虑现金流本身是否随利率改变.

每基点价值 (DV01 或 PV01) 将相对敏感度换成货币金额. 一个基点为 $0.01\% = 10^{-4}$, 在这里的单一收益率近似下, 普通多头的绝对金额约为 $B D_{\text{mod}} 10^{-4}$. 上例每基点约为 $100 \times 8 \times 10^{-4} = 0.08$. 收益率上升时, 价格变化的符号为负; 报告持仓 DV01 时应同时说明采用的符号约定.

麦考利久期 (Macaulay duration) 则把各付款时间按其现金流现值占总价的比例加权平均. 在前面每年复利 m 次的固定支付模型中,

$$D_{\text{mod}} = \frac{D_{\text{Mac}}}{1 + y/m}.$$

零息债券只在到期支付, 所以麦考利久期恰好等于剩余期限. 有票息时, 一部分价值更早回到持有人手中, 同样到期日也可以有不同久期.

以上比较只改变一个收益率. 真实曲线可能短端上升而长端下降, 或在某些期限变化更大. 要研究这种风险, 还须分别计算不同期限点变化的影响, 不能只用一个总久期概括全部曲线变动.

6.5.4 美债

定义 6.62.

美国国债 (U.S. Treasury Securities) 是美国财政部为联邦政府融资发行的债务证券.

不同种类提供不同现金流. Treasury Bills 位于短端, 主要以到期支付为收益来源; Treasury Notes 和 Treasury Bonds 提供较长期的固定票息与本金; TIPS 使本金随通胀调整; 浮息票据 (Floating Rate Notes, FRNs) 则让票息随参考利率改变 [US d].

一只票息债券中包含多笔支付, 美债市场还允许把符合条件的支付拆开交易.

例 6.63 (STRIPS).

STRIPS 可以将合格 Treasury Note, Treasury Bond 或 TIPS 的各次利息和本金拆成独立交易的零息证券。例如, 一张还剩十年, 每半年付息一次的 Treasury Bond, 包含二十笔票息和一笔到期本金, 可以分为二十一个支付组成部分。最后票息与本金在同一天支付, 所以二十一个组成部分不表示二十一个不同日期 [US c].

名义美债的固定支付拆开后, 与前面用于贴现计算的单次确定现金流十分接近。TIPS 拆出的支付仍保留相应通胀调整, 零息并不使其金额变成固定名义数。

美债的作用还超过收取票息和本金。下面先看它作为其他美元资产的价格比较基准, 再看金融机构怎样用它融资。

美元固定收益市场的基准资产 评价公司债时, 常先与相近期限的美债或其他合适基准比较, 再研究额外的信用, 流动性和融资条件需要多少补偿。美债自身的价格除了反映美国政府支付, 还反映了较高的市场流动性和抵押融资用途。因而公司债相对美债的利差也受这些因素影响, 不能全部归于信用风险。

财政部公布的官方平价曲线使用市场指示性买方报价拟合。固定期限美债利率 (Constant Maturity Treasury rates) 是从这条曲线读出的标准期限点, 并不等同于某一只具体债券的成交 YTM。若要逐笔贴现现金流, 则需进一步构造相应的零息贴现曲线 [US b].

普通名义美债承诺美元金额。即使发行人足额支付, 长期通胀仍可能降低购买力。TIPS (Treasury Inflation-Protected Securities) 则通过调整本金来改变这项风险: 票面利率先固定, 票息按调整后的本金计算。

通缩期间, TIPS 本金可以向下调整, 到期偿还本金有原始面值下限。这个下限保护的是合约到期本金, 不保证二级市场买价或提前出售价格。投资者仍可能因买入价格, 利率和退出时间承受亏损 [US d].

同期限名义美债与 TIPS 的收益率差常被用来观察**通胀补偿** (inflation compensation)。它除了包含预期通胀, 还受到通胀风险补偿, 相对流动性与供需影响。因而这个差额适合用来研究市场定价中的通胀因素, 不应直接当成对未来通胀的纯粹平均预测。

美债作为抵押品 持有美债的机构需要现金时, 可以出售债券, 也可以用它安排短期融资。出借人若取得易于估值和出售的抵押品, 借款人不还款时就多了一条回收途径。美债因其信用与市场流动性, 广泛用于这类交易。

典型安排是**回购协议** (repurchase agreement, repo): 一方先出售证券取得现金, 同时约定以后按规定价款买回。从现金使用和到期偿还看, 它接近以证券担保的短期借款, 具体权利仍由回购合同确定。

若抵押品市值为 $V_0 > 0$, 出借现金为 C_0 , 可以定义抵押折扣

$$h = 1 - \frac{C_0}{V_0}.$$

于是 $C_0 = (1 - h)V_0$ 。正的 haircut 让出借现金低于抵押品当前价值, 为后续价格下跌与处置成本留出缓冲。对融资买入同一笔债券的交易者, 其余条件相同时, 折扣越小, 需要补足的自有资金越少。

haircut 同时决定融资能够覆盖现券价值的多少。抵押品价格下跌或 haircut 提高以后, 同一批美债能融到的现金会减少, 借款人就需要补充现金, 增加抵押品或缩小头寸。

Treasury repo 分布在不同交易和清算安排中, haircut 也不是统一常数。某些双边交易曾采用零 haircut, 并配合净额和其他风险管理方式。因而计算一笔 repo 实际占用多少自有资金时, 使用的是该交易本身约定的抵押市值与现金金额。

国债基差交易 国债基差交易同时使用现券, 期货和 repo。**现券美债** (cash Treasury) 是已经发行并可买卖的债券, **国债期货** (Treasury futures) 则规定未来的交割安排和期间盈亏结算。两者可能具有相近的利率暴露, 但取得和维持它们所需的现金不同。

一份可实物交割的国债期货通常允许空头从合格债券篮子中选择交割券。不同券的票息和期限不同, 合约按**转换因子** (conversion factor, CF) 调整相应交割价款。理解期货报价与某只现券的关系, 因而先要查交割规则, 不能把两边的报价直接相减 [CME24].

在价格单位已经对齐时,一只候选券的原始基差常写为

$$b_t^{\text{raw}} = P_t^{\text{cash, clean}} - CF F_t^{\text{fut}}.$$

这里使用现券净价减去经转换因子调整的期货价. 因而期货相对变贵时, 这个差额会变小, 甚至为负.

不同资料可能采用相反符号. 例如 Federal Reserve 讨论的 option-adjusted basis net of carry (OABNOC) 采用收益口径, 正值对应期货相对现券偏贵, 有利于研究做多现券并做空期货的 long basis trade[Gli+24]. 所以看到正基差以前, 应先确认它实际在减什么, 是否已经扣除了持有成本和交割期权价值.

原始基差尚未计算全部现金. 买现券需要付全价并承担融资, 持有期间收到票息, 交割时还有应计利息和时间选择. 空头可以选择交割券, 也会改变期货与某一只固定现券之间的关系. 把这些因素放在同一期限上比较以后, 才能判断价差是否足以补偿成本与风险.

当交易者认为期货偏贵时, 可以买入适合交割的现券, 同时卖出相应期货. 为减少现券占用的自有资金, 再用买到的美债做 repo, 融入大部分购买款. 现券上涨时的收益与期货空头的损失可以抵消一部分共同利率风险, 交易主要依赖相对价格与持有成本的变化.

对冲了方向风险, 不表示两个账户的收付会自动同步. 期货空头需要按规则结算变动保证金; 现券融资到期需要续作; repo 对手方还可能要求补抵押, 调整折扣或提高利率. 即使最后交割会使相对价格受到很强约束, 中间仍然需要真实现金.

例如, 期货先相对上涨, 空头就须支付变动保证金. 现券相对下跌, 又可能减少能够取得的融资. 若此时 repo 不能按原条件续作, 交易者可能只能卖出现券筹钱, 同时买回期货退出对冲. 许多交易者一起这样做, 会增加现券卖压与期货买盘, 使尚未退出者面对的相对价格继续恶化.

OFR, Federal Reserve 和 BIS 的研究都讨论了 repo 续作, 期货保证金与高杠杆减仓之间的联系 [AS23; BK21; BKM23]. 此外, 交割券选择改变或模型估计错误, 也可能使原以为能取得的价差并不存在.

国债基差交易把现券价格, 期货价格和 repo 融资放在同一现金账中. 下面先回到另一类债券定价问题: 发行人本身可能无法完整支付约定现金流. 这会引出信用利差, 违约强度和 CDS.

6.5.5 信用风险, 信用利差与 CDS

两只债券约定相近的支付时间, 发行人的还款能力却可能不同. 现金流稳定的企业与接近破产的企业即使写下同样的承诺, 投资者愿意付出的价格也会不同. 这就是**信用风险**进入债券价格的直接方式.

公司债收益率与选定基准之间的差额称为利差 (spread). 其中既可能包含预期违约损失和信用风险补偿, 也会受到相对流动性与供需影响.

不同利差选择的基准不同. G-spread 将债券 YTM 与政府债曲线比较, I-spread 改用掉期曲线. Z-spread 则在逐笔零息贴现率上加同一个利差, 使全部现金流现值等于市场价格. 若债券含有嵌入期权, OAS 进一步在相应期权模型中调整这部分价值.

因而比较两张债券时, 先选同一种利差定义, 再研究差异中有多少来自信用条件.

进一步计算信用支付时, 可以用**违约时间**

$$\tau: \Omega \rightarrow [0, \infty]$$

表示何时违约, $\tau = \infty$ 表示不发生违约. 在采用的信息下, 通常要求违约时间为停时, 即到了当时能够判断是否已经违约. 对 $T > t$, $\mathbb{P}(\tau > T | \mathcal{F}_t)$ 是当前信息下存续到 T 的条件概率.

违约后未必全部损失. **回收率** (recovery rate) 要先指定相对于什么金额计算, 例如面值, 违约前市值或某项无风险支付价值. 固定这项基数后, 在回收比例为 $0 \leq R \leq 1$ 的简化约定下, **违约损失率** (Loss Given Default, LGD) 为 $1 - R$. 不同回收约定会产生不同的定价公式.

若模型允许用**违约强度** (hazard rate) λ_t 描述违约在短时间内发生的条件概率, 那么在尚未违约的前提下可以写成

$$\mathbb{P}(t < \tau \leq t + h | \tau > t, \mathcal{F}_t) = \lambda_t h + o(h), \quad h \downarrow 0.$$

λ_t 的单位是每单位时间, 并不是一个脱离期限就能使用的违约概率. 只有当违约时间在该模型中具有这种强度表示时, 上式才成立.

这样, 研究需要回答的具体问题就是: 债务人可能何时停止付款, 此前支付多少, 违约时还能回收多少. 这些判断决定实际现金流, 再由相应定价方法计算价值.

持有债券的投资者还可以另外购买信用保护, 把一部分违约损失交给另一方承担.

定义 6.64.

信用违约互换 (Credit Default Swap, CDS) 约定由信用保护买方按规则支付费用, 参考主体或债务发生指定信用事件时, 保护卖方向买方提供约定的保护支付.

这便于将信用风险与现券持有分开. 保护买方也可能没有持有相应债券, 所以 CDS 既能对冲现有风险, 也能用于单独交易信用变化. 它与普通保险在法律和合约安排上不同, 实际保护仍取决于信用事件定义和结算方式.

CDS 将信用保护单独做成合约. 其报价会受到预期损失, 信用风险补偿, 回收假设和市场流动性等共同影响. 下面用一个常数强度模型说明平价 CDS 利差怎样与风险中性违约强度相连.

平价 CDS 利差 (par CDS spread) s_{CDS} 是使合约初始价值为零的持续费率. 它平衡买方以后支付的费用与卖方可能承担的损失. 看一个简化计算: 单位名义金额, 常数回收率 R , 定价测度下常数强度 $\lambda^{\mathbb{Q}}$, 确定常数利率 r , 费用连续支付至违约或到期, 违约时立即赔付, 且没有交易对手违约. 平价条件为

$$s_{\text{CDS}} \int_0^T e^{-(r+\lambda^{\mathbb{Q}})u} du = (1-R)\lambda^{\mathbb{Q}} \int_0^T e^{-(r+\lambda^{\mathbb{Q}})u} du.$$

左边按存续概率计算费率支付, 右边按违约到达与损失比例计算保护支付. 两边含有同一个正积分因子, 约去后得到 $s_{\text{CDS}} = (1-R)\lambda^{\mathbb{Q}}$. 这个等式在上述简化模型中精确成立; 用于概括较一般合约时, 常写作近似关系

$$s_{\text{CDS}} \approx (1-R)\lambda^{\mathbb{Q}}.$$

实际离散缴费, 应计费用和回收约定都可能使简单表达需要调整.

这里的 $\mathbb{Q}$ 是所选无套利定价模型的测度, 因而反推出的是**风险中性违约强度**. 现实发生概率用 $\mathbb{P}$ 描述, 不必具有同一强度. 即使在常数强度模型内, 期限 T 的违约概率也是 $1 - e^{-\lambda^{\mathbb{Q}}T}$, 不能把每年的强度直接当成任意期限的概率.

市场合约还可能采用标准化固定票息, 并用交易开始时的**前端支付** (upfront payment) 补足与市值之间的差额. 因而平价利差便于比较信用定价, 实际要付的固定费用与前端金额仍须按合约分别计算.

6.5.6 从期限结构到随机过程

利率模型需要同时处理当前观察时间与未来付款时间, 因而使用整族价格

$$P(t, T), \quad 0 \leq t \leq T.$$

固定到期日 T , 让 t 向前走, 观察的是同一张债券从今天直到到期怎样变价. 固定今天 t , 改变 T , 观察的则是同一时刻各个未来期限的贴现价格. 前者是一条随时间演化的价格过程, 后者是一整条当前曲线.

这两个方向不能混同. 今天的十年利率与明天的十年利率, 还对应了不同的实际到期日; 今天买入一张十年债券, 明天持有的是剩余期限已经缩短的同一只债券. 期限结构模型需要把这些关系一致地处理.

短率模型先规定 r_t 怎样演化, 再推导各到期日的债券价格, Vasicek 和 CIR 属于这类思路. HJM 则直接研究远期曲线随观察时间怎样变化. 两种办法选择不同的建模起点, 最后仍须与同一市场中的现金流和无套利关系相容.

到这里, 债券的支付, 贴现和利率敏感度已经连在一起. 美债还把投资账户与抵押融资连接起来, 公司债和 CDS 则要求进一步研究违约后的收付.

下一节回到短端资金的实际来源: 一家银行为什么要借隔夜资金, 持有美债的机构怎样取得现金, 美联储准备金和不同隔夜参考利率又分别参与哪一步.

6.6 美联储, 美元体系与短端资金市场

长期债券要面对多年利率和通胀变化. 把期限缩短到隔夜以后, 今天借出的资金约定在下一个工作日收回, 但借款人仍须按时还款并完成结算. 借款人能否及时取得现金, 出借人能够获得什么保障, 都会影响这笔隔夜资金的利率.

银行可能因为客户向另一家银行付款而需要准备金. 证券交易商可能已经持有美债, 却需要现金支付其他交易. 企业或货币市场基金则可能暂时持有闲置现金, 希望取得短期收益. 隔夜市场让需要现金的机构与愿意短期出借资金的机构相互交易; 借款人的信用, 是否提供抵押以及谁有资格参与, 又会使不同交易形成不同利率.

本节先从商业银行存款和跨行付款开始, 看准备金为什么会在银行之间流动; 再加入财政部 TGA, 说明银行体系准备金总量怎样变化. 随后转到短期资金市场, 分别看 fed funds, repo, SOFR 以及美联储管理利率怎样形成不同的隔夜资金价格. 最后把这些具体市场压缩成模型中的瞬时短率 r_t .

这些安排有各自的历史来源, 相关说明主要参考 Federal Reserve, New York Fed, FDIC, SEC, BIS 及教材和论文 [Ald+20; Alt; Boab; Boac; Boad; Boae; DD83; Fed; Fedd; Fedf; Fedg; Fedi; Hul22; HPW19; MT; TS11; US g].

6.6.1 银行付款为什么需要中央银行

美联储体系

定义 6.65.

美联储 (Federal Reserve System, Fed) 是美国的中央银行体系. 它制定和实施货币政策, 提供中央银行结算和流动性服务, 监管部分金融机构, 并承担维护金融稳定等职责.

早期美国银行之间的资金调动受到地区分割等限制. 恐慌时, 客户突然希望把存款换成现金或转往更安全的机构, 支付需求会集中增加. 没有统一中央银行支持时, 清算所, 财政部和私人银行家只能临时协调资金.

1907 年恐慌从纽约信托公司和短期融资市场扩散, 推动了货币改革 [MT]. 1913 年联邦储备法建立美联储体系, 为提供更有弹性的货币和银行流动性安排奠定基础 [Boad; Fedi].

理解它的作用, 可以先把商业银行与银行间结算分开. 商业银行能向客户发放贷款并开立存款, 客户在不同银行之间支付时, 银行还要转移彼此接受的结算资产. 美联储提供的准备金账户和支付安排, 就用于完成这一层的收付.

组织上, 美联储包括位于 Washington, D.C. 的理事会 (Board of Governors), 十二家地区联邦储备银行, 以及负责相应公开市场政策决定的联邦公开市场委员会 (Federal Open Market Committee, FOMC). 全国性决策与地区机构并存, 体现了建立体系时对权力集中和地区参与的安排.

纽约联邦储备银行承担重要市场操作和参考利率发布工作. 后面讨论隔夜借贷, repo 和政策实施时, 会具体看到它怎样参与, 不必先把所有工具名称记成一张清单.

同样叫美元, 谁承担付款义务 一张美元纸币, 银行账户中的美元存款和银行持有的准备金都以美元计量, 但它们并非都是同一家机构的负债.

定义 6.66.

美联储票据 (Federal Reserve Note) 是美联储体系发行进入流通的美元纸币, 在美联储资产负债表上列为负债.

Federal Reserve Note 用于现金支付. 前面的 Treasury Note 则是财政部发行的中期国债, 尽管英文都有 Note, 发行人和合约功能不同.

银行还可以在符合资格时持有美联储账户余额.

定义 6.67.

本节所称**准备金**主要指金融机构在美联储持有的**准备金余额** (reserve balances), 用于银行间支付结算和流动性管理. 更广义的银行准备金概念还可能包括其他相应项目, 下文不将这些不同口径混用.

纸币和准备金余额都在中央银行负债端, 但持有人和使用方式不同. 公众可以直接持有纸币, 准备金账户则限于符合条件的机构.

普通客户的商业银行存款是另一项关系. 若客户账户有 \$10,000, 客户持有的是要求该银行按约支付的资产, 银行则欠客户 \$10,000. 这笔存款并不等于客户直接在美联储拥有同额准备金.

对象	对谁是资产	对谁是负债	主要用途
美元纸币	持有人	美联储	现金支付
银行存款	储户	商业银行	支付, 储蓄
准备金余额	商业银行等机构	美联储	银行间结算, 流动性管理

正常情况下, 客户可以把账户里的 \$100 提取成现金, 或转到另一家银行, 所以日常使用中这些差别不显眼. 但一旦研究流动性和违约, 就必须知道由谁付款, 需要经过哪个账户. 同为美元计价, 并没有消除发行人和法律请求权的区别.

贷款, 跨行付款与挤兑 假设银行向客户发放金额 L 的贷款, 并把款项记入客户账户. 银行同时增加一项对借款人的债权和一项对客户的存款负债:

银行资产	银行负债
+ 贷款 L	+ 存款 L

这一步说明贷款可以创造银行自己的存款, 没有说明银行同时创造了美联储准备金.

现在让借款人把这笔钱支付给另一家银行的客户. 在两家银行通过准备金完成结算的简化例子中, 放贷银行的客户存款减少 L , 准备金资产也减少 L , 原来的贷款资产仍留在账上. 收款银行的准备金增加 L , 同时为收款客户增加存款 L .

这次转账改变了准备金在银行之间的分布, 并没有因此增加银行体系的准备金总量. 对放贷银行而言, 准备金却已经真实流出. 若新贷款形成的付款持续流向其他银行, 放贷银行就要吸收存款, 借入批发资金, 做 repo, 出售资产或在符合条件时向央行借款, 才能继续完成结算.

挤兑会把这种流动性压力集中到很短时间. 存款人希望立即取款, 银行的长期贷款却未必能立即按账面价值卖出. 一家银行即使按正常期限持有和回收资产时足以偿付, 也可能因被迫低价出售资产而遭受损失. Diamond-Dybvig 模型讨论了这种期限转换与挤兑的关系 [DD83].

这些问题由不同制度分别处理. 贴现窗口向符合条件的存款机构提供抵押借款, 帮助弥补短期流动性缺口. 1933 年建立的 FDIC 及存款保险安排减少了受保护储户抢先提款的动机 [Feda]. 资本和审慎监管则要求银行有能力吸收资产损失, 处理的是偿付能力问题, 不能由临时借款替代.

2020 年, 美联储将法定准备金率降为零 [Boag]. 这取消的是特定的法定比例要求. 客户跨行付款仍需要结算, 银行仍须安排能够支付的准备金和其他流动性, 所以零法定比例不等于零准备金需求.

6.6.2 TGA 收支怎样改变准备金

客户从一家银行转到另一家银行, 主要改变准备金分布. 资金转入财政部在美联储的账户时, 则可能改变银行体系准备金总量.

定义 6.68.

美国财政部一般账户 (Treasury General Account, TGA) 是财政部在美联储的主要运营账户, 用于结算相应的财政收入, 发债融资和政府支出.

假设客户用银行存款缴纳一笔税款. 银行扣减客户存款, 美联储扣减该银行的准备金账户, 同时增加财政部的 TGA 余额. 在其他项目不变时, 银行体系准备金减少, TGA 增加. 财政部以后从 TGA 向银行客户付款, 则反向减少 TGA, 增加收款银行准备金及客户存款.

这可以用资产负债表核对. 将美联储资产负债表简化为

$$A_t^{\text{Fed}} = N_t + R_t + G_t + Q_t + O_t,$$

其中 A_t^{Fed} 为资产, 右边分别为流通纸币 N_t , 准备金 R_t , TGA 余额 G_t , 逆回购等负债 Q_t , 以及其余负债和资本 O_t . 两个时点相减, 得到

$$\Delta R_t = \Delta A_t^{\text{Fed}} - \Delta N_t - \Delta G_t - \Delta Q_t - \Delta O_t.$$

若资产, 纸币及其他项目短期近似不变, 才进一步有

$$\Delta R_t \approx -\Delta G_t - \Delta Q_t.$$

这保留了一个重要条件: TGA 变化时, 其他负债也可能变化. 例如在纯粹的教学记账中, 若 TGA 增加 100, 逆回购负债同时减少 100, 其余项目不变, 两项对准备金的影响恰好抵消. 所以不能只看到 TGA 上升就断言准备金必定同额下降, 还要看资金来自哪里及其他操作.

税款, 国债结算和政府集中支出会改变 TGA 与银行准备金之间的资金流动, 因而可能影响短端资金供求. 债务上限僵局结束后若财政部集中补充 TGA, 这种影响也可能持续一段时间. 相关会计项目与市场影响见 [Boac; HPW19].

资产负债表告诉我们余额必须怎样对应, 却没有单独给出利率会升多少. 同样数量的准备金流出, 在原本充足或已经偏紧的环境中可能有不同影响, 还取决于准备金分布和机构能否相互调动资金. 研究短率时, 应先算清这些收付, 再估计市场如何响应.

6.6.3 短期美元资金可以放在哪里

现在换到出借人的位置. 一家机构持有大额暂时不用的美元, 不能假设全部金额都受零售存款保险保护, 又希望取得短期利息. 它要比较到期由谁还款, 能否提前取用, 有无抵押, 自己是否具备参与资格.

银行存款与无抵押借贷主要依靠债务人履约. Repo 另外提供证券作为抵押, T-bill 直接对应财政部支付, 货币市场基金则让投资者通过基金份额持有一篮子短期资产. 符合条件的机构还可以直接使用相应央行账户或工具. 因而不能脱离期限, 用途和参与资格, 把这些工具简单排成一套固定的风险顺序.

工具	直接债务人或持有方式	典型用途	利息或收益怎样形成
未保险存款, fed funds	银行等借款机构	存放现金或无抵押隔夜融资	存款报价或市场成交利率
Prime MMF 份额	基金份额	短期现金管理	基金所持私人及政府短期资产的收益
Government MMF 份额	基金份额	短期现金管理	政府证券, repo 等持仓收益
Treasury repo	回购交易对手	以国债担保借入或出借现金	回购价与初始现金之间的利息差
T-bill	美国财政部债务	直接持有短期政府支付	买入价与到期支付共同决定收益率
准备金余额	合格机构持有的美联储账户余额	银行间结算, 流动性管理	IORB
ON RRP	合格交易对手与美联储进行隔夜逆回购	合格机构隔夜投资	ON RRP offering rate

下面从银行间借贷开始, 逐项看这些选择怎样形成实际利率.

无抵押隔夜借贷: Fed funds 与 EFFR 某家机构需要准备金完成付款, 另一家有可出借的余额, 两者可以进行隔夜融资. 这类交易把准备金从一处调到另一处, 不等于私人市场凭借借贷增加了准备金总量.

定义 6.69.

联邦基金市场 (Federal Funds Market) 是符合条件的机构围绕美联储账户余额进行无抵押隔夜融资的市场. 其中各笔交易约定的利率称为联邦基金利率.

出借人没有同时拿到一篮子美债, 所以需要判断借款机构的信用与支付能力. 双方自身的资产负债表成本和其他资金去处, 也会影响愿意接受的利率.

定义 6.70.

有效联邦基金利率 (Effective Federal Funds Rate, EFR) 是纽约联储根据相应实际隔夜交易计算的成交量加权中位数.

纽约联储按相应成交量计算 EFR, 所以它是市场实际隔夜无抵押融资的统计量. FOMC 另行设定联邦基金利率目标区间, 再通过 IORB, ON RRP 和其他实施工具改变市场参与者的资金选择, 使实际成交利率运行在政策希望的范围附近 [Fed; Fede].

因此 EFR 同时反映政策实施环境和当日 fed funds 市场中的真实借贷条件.

货币市场基金与短期现金管理 企业, 保险公司和其他投资者也有暂时不用的美元, 但未必能直接参加每个银行间市场. 货币市场基金把这些资金集中起来, 由基金配置一篮子短期资产.

定义 6.71.

货币市场基金 (Money Market Fund, MMF) 主要投资短期限, 高流动性债务工具, 常用于短期现金管理.

投资者交入现金后取得基金份额, 基金再买入证券或出借短期资金. 收益和风险来自实际持有的资产, 所以先要知道它是哪一类基金.

政府型基金主要配置现金, 美国政府证券和相应政府证券支持的 repo. Prime 基金还可以投资银行存单, 商业票据等私人短期信用工具. 免税型基金主要持有短期市政债务. 这些范围对应不同债务人, 不能仅因都叫货币市场基金就假定风险相同.

MMF 份额是基金投资, 与受 FDIC 保险规则覆盖的合格银行存款属于不同法律和资产结构 [US g]. Prime, Government 和免税型基金所持资产不同, 因而基金收益也来自不同的短期债务与 repo 组合.

组合报告中的“现金”因此可能实际包含银行存款, T-bill, MMF 份额或 repo 等不同工具. 它们都能承担短期资金管理功能, 但利息来源和变成支付现金的方式不同.

Repo 与抵押融资 持有债券而暂时缺现金的机构, 可以与有现金的一方做 repo. 借款人取得现金继续使用, 出借人则在合同安排下取得证券作为保护.

定义 6.72.

回购协议 (Repurchase Agreement, Repo) 先出售证券取得现金, 并同时约定以后按规定价款买回. 从资金收付看, 它具有证券担保融资的经济作用.

例如, 今天交出美债取得 \$100, 次日付 \$100.01 买回, 多付的 \$0.01 就是融资利息. 若初始现金为 $C_0 > 0$, 回购价款为 C_1 , 计息期间占一年的比例为 $\delta > 0$, 简单年化利率为

$$r^{\text{repo}} = \frac{C_1/C_0 - 1}{\delta}.$$

若进一步作教学假设, 这笔交易跨一个自然日并采用 $\delta = 1/360$, 则利率为 $0.0001 \times 360 = 3.6\%$. 隔夜到下一个工作日可能跨多个自然日, 实际年化须按合同日计数计算, 不能总把期间当成一天.

同一笔交易, 从交出证券取得现金的一方看是 repo; 从出借现金并取得证券的一方看则是 reverse repo. 两个名称只是站在交易双方的不同角度描述同一笔资金和证券交换.

出借现金未必等于抵押品全部市值. 设市值 $V_0 > 0$, 则

$$h = 1 - \frac{C_0}{V_0}$$

表示这里采用的 haircut. 若上述 \$100 现金对应 \$102 抵押品, 这一教学例子的折扣为 $1 - 100/102 \approx 1.96\%$. 多出的抵押价值用于缓冲价格下跌与处置成本, 不等于出借人没有剩余风险.

repo 的抵押品还会影响利率. 某只特定美债若很难借到, 持有现金的一方可能愿意接受较低的现金收益来换取这只证券, 这称为该券处于特殊状态 (trading special). 因而即使期限同为隔夜, 不同抵押品的 repo 利率也可以不同 [Fedf].

SOFR 与不同期限的利息计算

定义 6.73.

有担保隔夜融资利率 (Secured Overnight Financing Rate, SOFR) 是纽约联储根据相应美债 repo 隔夜成交计算并发布的参考利率, 用于衡量以美债担保取得隔夜现金的成本.

SOFR 的发展与伦敦银行间同业拆借利率 (London Interbank Offered Rate, LIBOR) 的问题有关. LIBOR 曾用于大量贷款和衍生品, 但相关基础交易稀薄及操纵风险使报价可靠性受到质疑. Alternative Reference Rates Committee (ARRC) 在 2017 年选择 SOFR 作为美元 LIBOR 的推荐替代利率 [Alt].

SOFR 先由市场中的美债 repo 成交产生, 纽约联储再按规定方法汇总三方 repo, GCF Repo 和部分经 FICC 清算的双边 Treasury repo, 并对相应特殊券交易作筛选后计算成交量加权中位数 [Fedg]. EFFR 和 SOFR 因此都是成交统计: EFFR 来自无抵押 fed funds, SOFR 来自美债担保的隔夜 repo.

若一笔三个月贷款使用隔夜 SOFR, 还需要把每天的隔夜利率累计成整段利息. 简单逐日复合的增长因子为

$$\prod_i (1 + \text{SOFR}_{t_i} \Delta_i),$$

其中 Δ_i 是该次利率对应的计息年数比例. 这种**复合 SOFR** 要等相应每日利率逐步实现以后才能全部确定.

前瞻期限 SOFR (forward-looking Term SOFR) 则根据相关衍生品价格在期初形成一个规定期限的参考利率 [CMEb]. 因而隔夜 SOFR, 事后累计得到的复合 SOFR 和期初即可观察的 Term SOFR 分别对应不同的计息安排; 合同通过观察日, 非营业日处理和日计数进一步规定最终利息.

IORB 与 ON RRP 怎样影响市场选择 美联储不必为每笔私人借贷直接指定利率. 它可以改变机构在中央银行取得的收益, 从而改变这些机构向别人出借资金时愿意接受的条件. 这在充裕准备金的实施框架中尤其重要.

定义 6.74.

准备金余额利率 (Interest on Reserve Balances, IORB) 是美联储向符合条件机构的准备金余额支付的管理利率.

准备金付息权限经历了法律变化. 2006 年的授权原计划在 2011 年生效, 2008 年危机期间提前到当年 10 月实施 [Boae]. 随后资产负债表扩张和大量准备金持有, 使准备金报酬成为影响短期资金选择的重要工具.

一家有资格取得 IORB 的银行, 可以比较把余额留在美联储的收益与借给另一机构的收益. 出借还承担信用和其他成本, 所以 IORB 成为它的重要机会成本. 管理利率改变, 银行愿意接受的其他短期利率也会受到影响.

但并非每个出借人都能取得 IORB. 某些政府支持企业和 Federal Home Loan Banks 没有这种付息资格, 仍可能接受低于 IORB 的联邦基金利率. 能够在两边配置资金的机构也有自己的资产负债表成本, 因而不保证差额被完全消除. EFFR 低于 IORB 并不与这种机会成本解释矛盾.

定义 6.75.

隔夜逆回购工具 (Overnight Reverse Repurchase Agreement Facility, ON RRP) 为符合条件的交易对手提供与美联储进行隔夜投资的安排, 报酬按规定的 ON RRP offering rate 计算.

符合条件的货币市场基金和政府支持企业等, 可以把它与市场中的 repo 或其他短期去处比较. 对不能取得 IORB 的部分非银行投资者, ON RRP 提供了另一种面对中央银行的资金选择, 从而帮

助减轻货币市场利率的下行压力 [Boaf; Fedf]. 它同样有资格和操作条件, 不是所有现金持有人都能无限制参加。

现在可以把几个短端利率放在一起比较. FOMC 设定联邦基金目标区间; 美联储按 IORB 向合格准备金持有者付息; 合格 ON RRP 交易对手把资金隔夜交给美联储时按 ON RRP offering rate 取得利息; EFFR 统计无抵押 fed funds 成交; SOFR 统计美债担保 repo 成交. 机构会在这些资金去处之间比较收益和成本, 所以各利率会相互影响, 但每个数对应的交易和参与者仍然不同。

6.6.4 离岸美元与链上美元

离岸美元与全球美元融资 美元债权和债务也大量存在于美国境外. 存放在境外银行的美元存款, 传统上称为欧洲美元或离岸美元存款 (Eurodollar). 这里的 Euro 不限定欧洲, 计价货币也没有变成欧元。

与美国境内存款一样, 境外银行的美元存款首先是该银行对客户的负债. 银行能否支付, 取决于整体资产, 资金来源和结算安排, 不等于每笔存款背后都为储户单独存放了同额美联储准备金。

承诺美元支付的银行需要安排美元来源. 它可以吸收美元存款, 向其他机构借款, 做 repo 或发行美元债务, 也可以通过外汇掉期 (FX swap) 临时取得美元. 例如一家欧洲机构主要持有欧元, 却需要三个月美元, 可以现在交出欧元取得美元, 同时约定到期反向交换. 两次汇率事先约定, 才使它比较这段融资的成本。

令 S_t 为一单位外币的即期美元价, $F_t(T)$ 为同样报价方式的远期价, Δ 为相应年数比例. 若两种货币在同一期限均可按给定简单利率借贷, 汇兑无摩擦, 并允许双向套利, 抵补利率平价为

$$\frac{F_t(T)}{S_t} = \frac{1 + r_t^{\$} \Delta}{1 + r_t^f \Delta}.$$

可以从一单位外币比较两条路径. 今天换成 S_t 美元并投资, 到期有 $S_t(1 + r_t^{\$} \Delta)$ 美元. 先投资外币, 再按已经锁定的远期价兑换, 则有 $(1 + r_t^f \Delta)F_t(T)$ 美元. 两边相等就得到上式, 并没有使用对未来即期汇率的预测。

实际借贷, 信用和资产负债表条件不同, 通过外汇掉期取得美元的成本可能偏离这种简单关系, 常用 cross-currency basis 描述 [Ald+20]. 比较其扩大或缩小时, 还应先确认报价方向及把基差加在哪一边的利率上。

2008 年和 2020 年的美元融资压力说明, 境外机构有大量美元付款义务, 不代表压力时能立即取得足够美元. 中央银行之间的安排可以提供额外渠道。

定义 6.76.

央行美元流动性互换 (central bank U.S. dollar liquidity swap) 是美联储与外国央行的货币交换安排. 美联储提供美元, 外国央行提供相应本币并约定以后反向交换, 再由外国央行按自己的操作向辖区机构提供美元。

美联储直接面对的是外国央行, 而不是每家境外商业银行. 外国央行负责转贷并承担借款机构的信用风险, 央行之间则按互换合同处理反向交换等义务 [Boa20b; Boab]. 这使美元流动性支持能够经由外国央行到达境外机构, 也说明美元短端压力不能只在美国国内银行体系中寻找原因。

法币储备型稳定币与链上美元 美元计价还可以通过链上代币延伸. 这里仅讨论与传统短端资产直接相连的法币储备型安排, 不概括所有稳定币设计。

定义 6.77.

法币储备型美元稳定币 (fiat-backed USD stablecoin) 由私人主体发行, 以美元计价, 并依靠储备资产和相应赎回安排力求将每单位代币的价值维持在接近 \$1 的水平。

发行人可以在传统金融体系持有银行存款, 短期美债或美债担保逆回购, 同时在链上发行代币. 因而链上转移虽然采用另一种记录方式, 支撑赎回的资产仍可能依赖银行, 证券与短期融资市场。

持有人取得的具体权利, 包括是否能够直接赎回和按什么条件赎回, 要看条款. 一枚私人发行的美元代币不会仅因以美元计价, 就成为一单位美联储准备金或受相同保障的银行存款。

若储备资产发生损失, 变现时缺少流动性, 或赎回渠道受阻, 代币在二级市场上就可能跌至明显低于一美元的水平, 形成脱锚 (depeg). 分析这种风险时, 应具体检查储备资产, 发行人的付款责任

和赎回步骤, 而不只观察代币平时是否接近一美元.

6.6.5 从美元资金市场到短期利率模型

前面这些市场里并不存在一个所有机构都能按相同条件借入和贷出的统一美元利率. 管理利率改变资金选择, EFFR 和 SOFR 汇总不同市场的成交, T-bill, 银行融资和外汇掉期又有各自条件. 要研究具体价差, 应保留这些区别, 并说明准备金, 抵押品或资金限制怎样进入相应交易.

若先研究最基本的连续贴现, 可以作一个更简单的假设: 存在瞬时短率 r_t , 资金能够按它连续滚动. 取 r 渐进可测, 并在每个有限期限满足 $\int_0^T |r_s| ds < \infty$ a.s. 定义初值为一的货币市场账户 (money-market account)

$$B_t = \exp \left(\int_0^t r_s ds \right).$$

逐条路径使用普通微积分, 得到

$$dB_t = r_t B_t dt, \quad B_0 = 1.$$

即使 r_t 随机, B 仍是严格为正的连续有限变差过程. 常数利率时它退化为 $B_t = e^{rt}$. 这里的货币市场账户是模型中的滚动账户, 不等于前面持有短期证券篮子的货币市场基金.

这里的 r_t 是模型中货币市场账户在时刻 t 的瞬时增长率. EFFR, SOFR 等实际利率则来自具有具体交易期限和统计方法的市场数据. 建模时可以用这些数据估计或校准短率过程, 但 r_t 本身由所选择的货币市场账户模型定义.

它与上一节的零息债券价格有明确联系. 若选择 B 作为计价资产, 并在相应定价测度 $\mathbb{Q}^B$ 下使 $P(\cdot, T)/B$ 成为真鞅, 利用到期支付 $P(T, T) = 1$, 就有

$$P(t, T) = \mathbb{E}^{\mathbb{Q}^B} \left[\frac{B_t}{B_T} \mid \mathcal{F}_t \right] = \mathbb{E}^{\mathbb{Q}^B} \left[\exp \left(- \int_t^T r_s ds \right) \mid \mathcal{F}_t \right].$$

因此, 当前债券价格等于沿未来短率路径形成的贴现因子的条件期望; 计算时并没有预先知道未来整条短率路径. 要写出这个条件期望等式, 还需要相应的真鞅和可积性条件, 见第5.4节.

若零息曲线在到期方向足够光滑并满足短端一致性, 还可写为

$$r_t = - \frac{\partial}{\partial T} \log P(t, T) \Big|_{T=t}.$$

因此短率既是滚动现金账户的瞬时增长率, 也是当前零息曲线在最短期限处的瞬时远期利率.

实际市场中的贴现曲线, 浮息现金流预测曲线, 机构自身融资成本和跨币种融资可以继续分别建模. 为了单独研究无套利关系, 下一节先保留一个统一的可交易计价资产. 现在已经能够把不同日期的支付换算到同一时刻; 接下来就问: 在确实能够双向交易和复制的条件下, 两组相同未来现金流为什么应有相同的今天价格?

6.7 贴现与无套利

前两节已经给出零息债券价格 $P(t, T)$, 短率 r_t 和货币市场账户 B_t . 现在用这些对象回答两个问题. 第一, 不同日期的现金怎样换算到同一个时点; 第二, 两种策略若产生完全相同的现金流, 它们今天能否有不同价格.

第一个问题由贴现处理. 第二个问题若允许买入较便宜的一边, 卖出较贵的一边, 并用同一账户完成融资, 就会导向套利和复制定价.

本节先无摩擦模型中推导这些关系, 再加入买卖价差和借贷利差. 标准理论参考 [Coc05; DS94; Duf01; HK79; HP81; Hul22; Shr04a; Shr04b].

6.7.1 贴现和计价资产

一只在 T 确定支付一单位货币的无违约零息债券, 今天的价格为 $P(t, T)$. 要在同一天取得确定金额 x , 可以持有 x 单位该债券, 成本就是

$$xP(t, T).$$

这里利用的是支付数量可以按相同比例放大的交易关系. 若允许相应借款和卖空, 负的 x 也可以表示到期付款义务.

确定常数利率 r 下, 连续复利给出

$$P(t, T) = e^{-r(T-t)},$$

所以未来的 x 折为今天的 $xe^{-r(T-t)}$. 随机利率下, 当前零息债券价格仍然可以用于这笔确定支付, 但不能把尚未知的未来短率路径直接当成已经锁定的投资利率.

另一个有用的做法是改变计量单位. 与其总问资产值多少美元, 也可以问它值多少单位某项可交易资产.

定义 6.78 (计价资产).

在给定期限内, 取严格为正, 可交易的自融资价值过程 N , 并将分配留在该投资中再投资, 或假设它没有另行支付的分配. 以 N 作为计价资产 (numéraire) 时, 资产价格 S_t 的相对价格为

$$\hat{S}_t = \frac{S_t}{N_t}.$$

严格正值保证可以作除法. 可交易和自融资则保证所选单位对应一种能够持有的投资, 而不只是任意正数序列. 相对价格的变化比较两项投资的价值, 选择计价资产本身尚未保证这个比值是鞅.

常用的计价资产是货币市场账户. 若短率 r 适应并满足所需可测性, 且在有限期限上路径绝对可积, 定义

$$B_t = \exp\left(\int_0^t r_s ds\right), \quad B_0 = 1.$$

它表示资金按每一时刻的短率连续滚动. 用它计量股票, 得到贴现价格

$$\tilde{S}_t = \frac{S_t}{B_t}.$$

同一段时间中, 股票即使按货币价格上涨, 相对于现金账户的价值 S_t/B_t 仍可能下降. 后面的定价测度正是用来研究这种以某个可交易计价资产为单位的相对价格.

6.7.2 套利和无套利

取交易期限 $[0, T]$, 以 V_t^ϕ 表示策略 ϕ 的净财富, 其中包括现金, 资产和融资负债. 策略遵守当时的信息限制, 并且自融资: 初始建仓以后, 调仓和中间收付都在同一组合内完成, 不从外部追加或取走资金.

还须先规定哪些策略可允许. 在有限模型中, 这包含交易方向和数量等条件; 在连续时间中, 通常还限制财富的下界, 排除靠无限借款维持的翻倍下注. 自融资说明钱从哪里来, 可允许性说明允许采用什么持仓和承担什么风险, 两者不能互相替代.

定义 6.79 (套利和无套利).

可允许的自融资策略 ϕ 若满足

$$V_0^\phi = 0, \quad V_T^\phi \geq 0 \quad \text{a.s.}, \quad \mathbb{P}(V_T^\phi > 0) > 0,$$

就称为套利 (arbitrage). 若不存在这样的策略, 则市场满足无套利 (no-arbitrage).

零初始净财富可以包含相互抵消的资产和借款, 并非不进行任何交易. 终端条件要求偿清相应义务以后仍然几乎必然不亏, 而且有正概率盈利. 中间财富是否可能下降以及需要多少资金缓冲, 仍由前面的可允许条件控制.

另一种常见写法把初始成本记为 $c_0 \leq 0$, 终端支付记为 $X_T \geq 0$, 并要求 $c_0 < 0$ 或 $\mathbb{P}(X_T > 0) > 0$ 至少一项成立. 它还包括今天已经净收一笔钱, 到期收付恰好抵消的交易. 若这笔初始收入可以投入严格为正的现金账户, 到期便保留正财富, 从而转成上面的零净投入形式.

预期收益较高的风险投资不必是套利, 因为它仍可能亏损. 无套利检查的是在规定交易条件下, 能否用零净投入取得这种终端不亏的机会. 改变卖空, 融资或持仓规则以后, 可实施的策略集合也会改变, 应在新的条件下重新判断.

6.7.3 一价定律

以下比较都在同一市场模型内进行. 两边的币种, 单位和交割日已经对齐, 中间分配, 税费, 融资及其他现金流若存在, 都已经计入各自的自融资财富过程. 还假设命题中用到的买入, 卖空和现金账户交易确实属于可允许策略.

在这组共同条件下, 若两个组合到期逐状态给出同样的净财富, 它们的初始价值也必须相同.

命题 6.80 (一价定律).

假设市场无套利, 组合 A, B 均可按所需数量双向交易, 且由它们与现金账户组成的比较策略可允许并自融资. 若

$$V_T^A = V_T^B \quad \text{a.s.},$$

则

$$V_0^A = V_0^B.$$

证明. 若 $V_0^A < V_0^B$, 买入 A 并卖空 B , 初始净收入为 $V_0^B - V_0^A > 0$. 将全部收入投入严格为正的现金账户 N , 这三项合起来的初始净投入为零. 到期时 $V_T^A - V_T^B = 0$, 剩余财富为

$$(V_0^B - V_0^A) \frac{N_T}{N_0} > 0.$$

由假设, 整个策略可允许且自融资, 所以构成套利, 与无套利矛盾. 交换 A, B 可同样排除 $V_0^A > V_0^B$. $\square$

证明只用到两组合的到期财富几乎处处相等, 无须计算各状态的具体概率. 如果某个方向的卖空或融资不在允许的策略集合中, 相应的反向套利证明就不能使用; 带摩擦部分将据此得到上下不同的价格边界.

6.7.4 复制定价

定义 6.81 (复制).

给定仅在 T 支付的现金流 X_T , 若由可交易资产组成的可允许自融资策略 θ 满足

$$V_T^\theta = X_T \quad \text{a.s.},$$

就称该策略复制 (replicate) 了这一支付. 策略的初始财富 $V_0^\theta = v$ 是复制成本.

命题 6.82 (复制价格).

在上述市场条件下, 假设目标合约和复制策略能够双向交易, 所需比较策略可允许并自融资. 若 $V_T^\theta = X_T$ a.s. 且 $V_0^\theta = v$, 则目标合约的唯一无套利价格为 v .

证明. 若合约价格高于 v , 卖出合约并买入复制策略; 若低于 v , 买入合约并反向建立复制策略. 两种情况下, 到期支付相互抵消, 初始都留下正差额. 将差额投入正值现金账户, 便得到一价定律证明中的套利. $\square$

下面在无摩擦, 可双向交易和融资的假设下计算两个例子. 关键都在于用已有资产凑出同一笔未来收付, 而非先预测未来价格.

远期交割价格 设现货价格为 S_0 , 持有期间无股息或其他持有成本, 零息债券价格为 $P(0, T) > 0$. 买入一单位现货, 同时借入 S_0 , 初始净投入为零. 若通过出售零息债券锁定到期还款, 需要出售 $S_0/P(0, T)$ 单位, 到期偿还

$$\frac{S_0}{P(0, T)}.$$

因此这组持仓的到期净值是 $S_T - S_0/P(0, T)$. 它与按该金额交割的一单位远期多头相同, 从而零初始价值的远期交割价为

$$F_{0,T} = \frac{S_0}{P(0, T)}.$$

这里锁定的是到期借款金额. 随机利率下, 每天滚动借入短期资金并不保证最后恰好欠这个数, 因而不能随意把两种融资办法互换.

更一般地, 交割价为 K 的远期多头可由一单位现货加上到期支付 K 的负债复制, 当前价值为 $S_0 - KP(0, T)$. 让这个价值为零, 就得到上面的 $F_{0,T}$. 确定常数利率下,

$$F_{0,T} = S_0 e^{rT}.$$

欧式看涨看跌平价 对同一无股息标的, 同一执行价 $K > 0$ 和到期日 T , 比较两组持仓. 第一组买入看涨期权和 K 单位零息债券, 第二组买入看跌期权和一单位股票. 到期恒有

$$(S_T - K)^+ + K = (K - S_T)^+ + S_T = \max(S_T, K).$$

股价高于 K 时, 两边都等于 S_T ; 不高于 K 时, 两边都等于 K . 因而一价定律给出

$$c_0 + KP(0, T) = p_0 + S_0, \quad c_0 - p_0 = S_0 - KP(0, T).$$

这是**看涨看跌平价**. 它只规定两个期权价格之间必须满足的关系, 尚未分别算出 c_0 和 p_0 . 若有股息或提前行权权利, 就要重新检查中间收付与可采用的交易, 不再直接使用上述两组终端支付的比较.

6.7.5 状态价格和风险中性概率

在一时期有限状态市场中, 可以把各种终态分别计价. 设可能结果为 $\omega_1, \dots, \omega_n$, 各自在现实测度下都有正概率. 一个支付由各状态下的金额确定:

$$X_T = (X_1, \dots, X_n).$$

这个向量用于逐项计算支付成本, 不仅是列出未来情况的名称.

先假设每一种只在单个状态付款的基本支付都可以交易或复制, 并允许按数量作线性组合.

定义 6.83 (状态价格).

一份在状态 ω_i 支付一单位货币, 在其余状态支付零的基本证券, 其当前价格 π_i 称为该状态的状态价格 (state price).

分别持有 X_i 单位第 i 种基本证券, 到期就得到目标支付. 因而

$$V_0 = \sum_{i=1}^n \pi_i X_i.$$

在这里的双向交易假设下, 无套利要求 $\pi_i > 0$. 若某项价格为零或负, 买入就能在一个正概率状态得到正支付, 在其他状态不亏, 与无套利矛盾.

各买一单位基本证券, 不论发生哪种结果都收一单位货币, 所以

$$P(0, T) = \sum_{i=1}^n \pi_i.$$

将状态价格除以这笔确定支付的价格, 定义

$$q_i = \frac{\pi_i}{P(0, T)}, \quad q_i > 0, \quad \sum_{i=1}^n q_i = 1.$$

它们构成概率分布, 记相应测度为 $\mathbb{Q}^T$. 价格因而可以改写成

$$V_0 = P(0, T) \sum_{i=1}^n q_i X_i = P(0, T) \mathbb{E}^{\mathbb{Q}^T}[X_T].$$

这里的顺序是先由可交易的状态支付得到状态价格 π_i , 再除以确定支付价格 $P(0, T)$ 得到 q_i . 因而 q_i 是由市场价格关系确定的定价概率.

定义 6.84 (计价资产对应的定价测度).

上述 $\mathbb{Q}^T$ 对应到期日为 T 的零息债券计价, 称为 **T -forward 测度**. 现金账户计价所对应的测度则通常称为**风险中性测度**, 下文记为 $\mathbb{Q}^B$. 它们都用于将价格关系写成相应的期望, 但所用计价资产和概率权重应一并说明.

对无股息股票, 同样有

$$S_0 = P(0, T) \mathbb{E}^{\mathbb{Q}^T}[S_T].$$

而 $\mathbb{E}^{\mathbb{P}}[S_T]$ 描述现实概率判断下的平均终价. 例如, 确定利率下预期获得正风险溢价的股票, 现实平均终价可以高于同额资金投资零息债券的终值. 定价公式仍然成立, 因为它使用了不同权重. 两种测度在特殊情形下也可能相同, 应区分的是定义和用途, 并非要求它们永远不相等.

若基本状态支付并非都可复制, 有限市场的无套利仍可对应一组严格正的定价权重, 使现有可交易支付按上式定价, 但这组权重未必唯一. 它们对可复制支付给出相同成本, 对不可复制支付则可能给出不同数值. 因而不能在不完备市场中任选一组权重, 就把所有新合约都宣布为已经有唯一市场价格.

6.7.6 随机贴现因子

同一组价格也可以保留现实概率 $\mathbb{P}$, 把不同结果的定价权重放在一个随机乘数中. 在前面的有限模型里, 若 $p_i = \mathbb{P}(\omega_i) > 0$, 取 $M_{0,T}(\omega_i) = \pi_i/p_i$, 则

$$\mathbb{E}^{\mathbb{P}}[M_{0,T} X_T] = \sum_i p_i \frac{\pi_i}{p_i} X_i = \sum_i \pi_i X_i.$$

这没有改变价格, 只是把状态价格拆成现实概率与另一个权重的乘积.

定义 6.85 (随机贴现因子).

相对于给定市场和被定价的支付类, 若严格为正且可积的随机变量 $M_{0,T}$ 满足

$$V_0 = \mathbb{E}^{\mathbb{P}}[M_{0,T} X_T],$$

就称其为相应的**随机贴现因子** (stochastic discount factor), 也称定价核或 state-price density. 对每项使用该式的支付, 还要求 $\mathbb{E}^{\mathbb{P}}[|M_{0,T} X_T|] < \infty$.

任意正随机变量并不会自动给出现有资产的正确价格, 定义中的定价等式是必要条件. 对确定支付 $X_T = x$, 它给出

$$V_0 = x \mathbb{E}^{\mathbb{P}}[M_{0,T}] = x P(0, T).$$

因此随机贴现因子的均值等于一单位确定终端支付的贴现价格. 它在不同状态中的高低, 则表示一单位现金流若出现在这些状态中, 市场分别赋予多大的定价权重.

例如, 在相应资产定价模型中, 投资者资金最紧缺时收到的现金可能更有价值, 对应较高的定价权重. 这不是仅凭发生概率能够表达的差别. 在 $M_{0,T}$ 与 X_T 都平方可积时, 还可直接展开为

$$V_0 = P(0, T) \mathbb{E}^{\mathbb{P}}[X_T] + \text{Cov}_{\mathbb{P}}(M_{0,T}, X_T).$$

相同现实平均支付, 与定价权重的共同变化不同, 当前价格也可以不同.

在时刻 t 使用同样思路, 写成

$$V_t = \mathbb{E}^{\mathbb{P}}[M_{t,T} X_T | \mathcal{F}_t].$$

它与换测度方法可以严格对应. 设 Z_t^B 是 $\mathbb{Q}^B$ 相对于 $\mathbb{P}$ 的严格正密度过程, 并且无中间分配的目标价值满足所需真鞅与可积条件. 取

$$M_{t,T} = \frac{B_t}{B_T} \frac{Z_T^B}{Z_t^B},$$

由条件期望的换测度公式得到

$$\frac{V_t}{B_t} = \mathbb{E}^{\mathbb{Q}^B} \left[\frac{X_T}{B_T} \mid \mathcal{F}_t \right].$$

这里既有沿未来短率累计的 B_t/B_T , 也有改变概率权重的密度比. 随机利率下, B_T 通常不能从这个期望中提出.

若改用 T 到期零息债券计价, 相应关系为 $V_t = P(t, T)\mathbb{E}^{\mathbb{Q}^T}[X_T | \mathcal{F}_t]$. 两式可以给出同一个价值, 但使用的测度不同. 确定利率等特殊情形下它们可以相同, 一般则须保留上标以说明采用哪种计价资产.

事件合约也是同一个计算. 对支付 $\mathbf{1}_A$,

$$C_0^A = \mathbb{E}^{\mathbb{P}}[M_{0,T}\mathbf{1}_A].$$

这个金额是事件发生时的定价权重总和. 再除以 $P(0, T) = \mathbb{E}^{\mathbb{P}}[M_{0,T}]$, 才得到相应的归一化定价概率. 它与现实概率 $\mathbb{P}(A)$ 的关系, 取决于 $M_{0,T}$ 是否随事件结果改变, 以及所用报价是否符合这个定价模型.

6.7.7 带摩擦的套利边界与套利限制

无摩擦远期价格为 $F_{0,T} = S_0/P(0, T)$. 一旦买入和卖出使用不同价格, 借钱与存钱又采用不同利率, 前面的两个套利方向便会有不同成本.

设现货买价为 S_0^{bid} , 卖价为 S_0^{ask} , 借款与存款的确定连续复利率分别为 $r_{\text{borrow}} \geq r_{\text{lend}}$. 假设标的无分配和其他持有成本, 可以卖空, 卖空所得可全部投资, 两种利率都能锁到 T . 先令远期没有买卖价差, 可以按同一个零初始价值交割价 $F_{0,T}$ 买入或卖出.

买现货时要付卖价并承担借款成本. 若远期交割价高于 $S_0^{\text{ask}}e^{r_{\text{borrow}}T}$, 就可借钱买现货, 卖出远期, 到期用交割款还清借款后留有正差额. 这给出上界.

反向交易只能按买价卖出现货, 所得按存款利率增长. 若远期价低于 $S_0^{\text{bid}}e^{r_{\text{lend}}T}$, 就可卖空现货并投资所得, 买入远期, 到期按较低价取得标的还券. 这给出下界. 因而

$$\underbrace{S_0^{\text{bid}}e^{r_{\text{lend}}T}}_{F_{0,T}^{\text{lower}}} \leq F_{0,T} \leq \underbrace{S_0^{\text{ask}}e^{r_{\text{borrow}}T}}_{F_{0,T}^{\text{upper}}}.$$

价差和借贷利差让两个方向的复制成本分开, 区间内的价格差未必足以支付交易成本. 能够事先锁定的手续费或借券费用, 也可按到期金额分别加入对应方向的成本.

远期本身若也有买卖价差, 就要用能实际卖出的远期买价检验上界, 用能实际买入的远期卖价检验下界, 不能拿一个不可成交的中间报价同时执行两边交易.

上面的区间仍假设现货, 卖空和融资条件能够锁定到 T . 若现券只能依靠短期 repo 不断续作, 或期货账户会在途中收付变动保证金, 终端价差尚未收敛以前就可能出现额外现金需求. 一旦资金或券源不能续接, 原来的套利组合便无法维持到期. 这类对利用价格差的约束通常称为**套利限制**(limits to arbitrage)[SV97].

因此带摩擦后的无套利计算仍然从可执行现金流出发: 买入一边实际要付什么价格, 卖出另一边实际能收多少, 融资能否锁定, 中途是否需要补现金. 下一节进入订单簿以后, 买卖价和可成交数量会直接给出这些执行成本.

6.7.8 通往鞅和金融市场基本定理

一时期定价按终态匹配支付, 多期和连续时间还允许根据新信息调整持仓. 因而价格之间的一致性必须在整个交易过程中维持, 不能只检查几项静态合约.

第5.2节已给出有限状态树上的基本定理: 在相应无摩擦, 双向交易的有限模型中, 无套利等价于等价鞅测度存在; 市场完备则对应测度唯一. 连续时间中还要控制一系列策略在极限中趋近套利的问题. 对局部有界的半鞅贴现价格及标准可允许策略, 相应的无免费午餐且风险趋于消失条件与等价局部鞅测度相联系 [DS94]. 更一般半鞅需要相应的一般化表述.

资产若另有分配, 应对累计收益而非单独除息价格应用这一思路. 设 S 是除息价格, D 是累计每单位现金分配, B 是严格为正的连续有限变差现金账户, 并满足相应积分条件. 贴现累计收益为

$$\frac{S_t}{B_t} + \int_{(0,t]} \frac{1}{B_u} dD_u.$$

价格与分配使用同一计价单位, 才能表示持有资产的全部模型收益. 在合适的等价定价测度下, 这一过程具有局部鞅性质, 见第5.4节.

在适当的可允许性条件下, 局部鞅性质已经能够排除相应的套利, 但还不足以把价格写成条件期望等式. 例如, 有固定下界的局部鞅财富是超鞅, 所以其期望不会超过初始财富; 从零初始财富出发, 就不可能得到几乎必然非负且以正概率严格为正的终端财富. 若还要把当前价值写成终值的条件期望, 则须进一步证明财富过程是真鞅, 常用的充分条件包括相应的平方可积性或一致可积性; 仅仅每个时点分别可积还不够.

对期间没有分配且贴现价格为真鞅的资产, 才得到

$$\frac{S_t}{B_t} = \mathbb{E}^{\mathbb{Q}^B} \left[\frac{S_T}{B_T} \mid \mathcal{F}_t \right].$$

这与前面随机贴现因子的表达相同: 给定当前信息, 在相应计价资产和测度下计算未来支付.

确定现金流可以直接用当前贴现曲线相加. 支付依赖未来股价, 利率或整条路径时, 就需要相应的联合动态, 才能计算条件期望和复制持仓. Black-Scholes, 利率和波动率模型各自选择不同的动态假设, 但都须回到同样的现金流与自融资关系.

下一节把视角转向实际成交. 即使已经知道模型价格, 一笔指定数量的订单按什么价格完成, 还要看报价, 排队和其他参与者的交易.

6.8 交易, 订单簿与市场微观结构

第6.7节比较了合约支付与复制成本. 实际买卖时, 还要问整笔数量能按什么价格成交. 屏幕上有一档卖价, 不表示这一档足以卖给我们所需的全部数量; 愿意等候的限价单, 也未必能在希望的时点成交.

定义 6.86 (市场微观结构).

市场微观结构 (market microstructure) 研究参与者怎样在具体交易规则下提交订单和报价, 这些订单怎样成交, 以及信息, 库存, 流动性和交易制度怎样影响价格与成本.

本节按一张订单真实经历的顺序展开, 参考 [FPR23; Har02; Has07; Mad00; OHa95]. 先说明订单怎样进入场所, 怎样排队和成交, 再计算扫单成本. 有了这些成交记录以后, 才讨论价差, 订单流, 库存和价格响应.

沿用最优买价 b_t , 最优卖价 a_t 和中间价 $m_t = (a_t + b_t)/2$. 成交价则由具体订单与当时可用数量共同决定.

6.8.1 从一张订单进入市场开始

投资者先向经纪商或交易系统发送订单. 经纪商可能检查资金, 持仓和风险条件, 再决定把订单送往哪个场所; 直接接入市场的机构则可以省去其中部分环节. 交易场所接受订单以后, 才按照自己的撮合规则立即成交, 进入队列等待, 或返回未执行部分.

因此一张订单从发出到结束, 至少要区分已经发送, 已被场所接受和已经成交等状态. 只有确认成交的数量才进入实际持仓; 仍在传输, 已被拒绝或仍在队列中等待的数量都不能算作持仓.

交易场所与参与者

定义 6.87 (交易场所).

交易场所 (trading venue) 是按既定规则接收并执行交易指令的市场组织或系统. 公开限价订单簿, 另类交易系统, 暗池及经纪商或交易商的内部执行安排, 都可能提供不同形式的交易场所.

同一证券可以在多个场所交易. 一处的最优价格, 未必是所有可访问场所中的最优价格. 即使报价相同, 可成交数量, 费用, 排队规则和到达速度也可能不同.

经纪商接收并安排客户订单, 做市商和其他挂单者提供可执行报价, 套利或相对价值交易者则同时比较不同资产与场所. 场所负责按规则处理这些订单. 这些名称说明所做的工作, 并不把参与者永久分成互不重叠的几类: 普通投资者也可以挂单提供流动性, 做市商也可能主动买入别人挂出的数量.

订单包含什么

定义 6.88 (订单).

订单 (order) 是按指定方向, 数量和执行条件请求买入或卖出资产的指令. 它可以被拒绝, 全部或部分成交, 也可以按规则保留未成交余量等待.

订单至少要指定证券, 买卖方向和数量; 限价单还要给出价格限制, 订单也可以规定有效期, 是否允许部分成交以及是否展示. 在采用时间优先的场所中, 被场所接受的时间还会决定同价订单的排队位置.

后面的计算因此一律使用场所确认后的订单状态和实际成交回报. 目标数量决定想交易多少, 成交回报才告诉我们实际买到了多少以及价格是多少.

6.8.2 市场单, 限价单与订单簿**定义 6.89 (市场单, 限价单与撤单).**

市场单 (market order) 请求尽快按可用的对手方报价执行, 实际价格由当时的数量和市场规则决定.

限价单 (limit order) 规定最差可接受价格: 买入成交不高于限价, 卖出成交不低于限价.

撤单 (cancellation) 请求取消尚未成交的剩余数量, 不撤回此前已经确认的成交.

限价单也可以立即成交. 若买入限价 $\ell \geq a_t$, 就能在相应报价仍有效且订单条件允许时接受现有卖盘; 卖出限价 $\ell \leq b_t$ 时同理. 这称为**可成交限价单 (marketable limit order)**. 超过可接受价格的余量, 则按有效期和其他规则继续等待或取消.

因此, 限价单是否提供流动性, 要看它到达时是留在簿上等待, 还是主动接受别人的报价. 市场单优先争取尽快成交, 为了完成更多数量可能一路接受更差的对手价; 限价单则守住最差可接受价格, 代价是可能只完成一部分或一直没有成交. 市场中断或价格保护也可能使市场单无法全部完成.

撤单消息也要经过传输和处理. 在它生效以前, 原单仍可能成交. 修改价格或增加数量, 在许多采用时间优先的规则中会丢失原排队位置, 但具体处理仍取决于场所及订单类型. 计算剩余订单时, 应使用确认后的结果, 不把已经发送的撤改请求当成已经生效.

订单簿与各档数量**定义 6.90 (限价订单簿与深度).**

限价订单簿 (limit order book) 按方向, 限价和优先次序组织尚未成交的订单. 同一价位上剩余可交易的数量称为该价位的**深度 (depth)**. 使用公开行情时, 下文的数量专指当前能够看到的显示深度.

将同价买单的剩余数量相加, 记为 $Q_t^b(p)$; 同价卖单的剩余数量相加, 记为 $Q_t^a(p)$. 在两侧非空且最优档位存在时,

$$b_t = \max\{p : Q_t^b(p) > 0\}, \quad a_t = \min\{p : Q_t^a(p) > 0\}.$$

最高买价是卖方立即卖出首先遇到的价格, 最低卖价是买方立即买入首先遇到的价格. 若某一侧为空, 就没有这一侧的最优报价, 相应中间价也不能照常计算.

按成交优先方向, 买价由高到低记为 $p_{1,t}^b, p_{2,t}^b, \dots$, 卖价由低到高记为 $p_{1,t}^a, p_{2,t}^a, \dots$. 因而 $p_{1,t}^b = b_t$, $p_{1,t}^a = a_t$. 各档显示数量分别记为 $Q_{k,t}^b, Q_{k,t}^a$, 后面的扫单和价差计算会直接用到这些数量.

这里的 $Q_{k,t}^a, Q_{k,t}^b$ 是当时公开显示的数量. 隐藏数量和其他场所并不包含在这张订单簿快照中; 若用快照模拟一笔立即执行的订单, 还要明确在撮合期间是否把新单和撤单冻结不变. 下面的 550 股算例采用这一静态快照假设.

撮合优先规则**原则 6.91 (价格优先与时间优先).**

在采用价格优先, 同价时间优先的连续订单簿中, 买单按更高限价优先, 卖单按更低限价优先. 同价且具有相同优先类别的订单, 较早被场所接受的先成交.

因此, 即使 100.01 的卖单比 100.02 的卖单提交得更晚, 它也排在前面, 因为买方先取得更低的卖价. 只有两张订单处在同一价格且具有相同优先类别时, 才比较它们被场所接受的先后时间.

以下排队例子采用这套规则. 它不是所有交易场所的共同算法: 某些衍生品采用按数量比例等方式分配, 开收盘集合竞价另有统一撮合安排, 隐藏或特殊订单也可能有不同优先类别 [Gou+13]. 计算自己前面还有多少数量时, 必须使用对应规则.

6.8.3 一次撮合与交易成本

在上述连续撮合规则中, 主动买单先接受最低卖价, 用完这一档数量才继续向上; 主动卖单则从最高买价向下执行. 因而一张大订单可以产生多笔不同价格的成交.

定义 6.92 (成交均价与滑点).

若订单全部成交, 数量 $Q > 0$ 分成 n 笔, 第 k 笔价格与数量为 p_k, q_k , 且 $\sum_k q_k = Q$, 成交均价为

$$\bar{p}(Q) = \frac{\sum_{k=1}^n p_k q_k}{Q}.$$

选定基准价格 p^* , 按正数表示买贵或卖便宜的约定, 每单位滑点为

$$\text{Slip}_{\text{buy}} = \bar{p}(Q) - p^*, \quad \text{Slip}_{\text{sell}} = p^* - \bar{p}(Q).$$

均价乘以成交数量, 才是总买入支出或卖出收入. 若只部分成交, 分母应改为实际已成交数量, 未完成部分另行记录.

滑点取决于基准. 与到达前最优对手价相比, 可以看到扫过后续档位增加了多少支出; 与当时中间价相比, 还包含最初跨越半个价差的成本. 用更早的决策价格, 则把等待和传输期间的价格变化也算在里面. 因而报告滑点必须同时说明基准时点和价格种类.

例 6.93 (一张市场买单怎样扫过订单簿).

以下采用价格优先的连续撮合, 订单允许部分成交. 暂不计费用, 隐藏流动性, 其他场所和撮合期间的新单及撤单, 将给定显示数量视为可执行. 初始订单簿为

方向	价格	显示数量
卖出	100.04	500
卖出	100.03	200
卖出	100.02	300
买入	100.01	400
买入	100.00	600
买入	99.99	800

因而

$$b_t = 100.01, \quad a_t = 100.02, \quad m_t = 100.015.$$

买入 550 股的市场单先取得 100.02 的 300 股, 再取得 100.03 的 200 股, 最后从 100.04 这一档取得 50 股. 总支出为

$$300 \times 100.02 + 200 \times 100.03 + 50 \times 100.04 = 55,014.$$

所以

$$\bar{p}(550) = \frac{55,014}{550} \approx 100.02545.$$

与所有股票都按初始最优卖价买入相比, 多付

$$55,014 - 550 \times 100.02 = 3.00,$$

即每股约 0.00545. 若与初始中间价比较, 则多付

$$55,014 - 550 \times 100.015 = 5.75.$$

两种成本相差 $550 \times 0.005 = 2.75$, 正是这 550 股跨越最初半个价差的金额.

成交以后, 前两档卖单用尽, 100.04 还剩 450 股, 新最优卖价为 100.04. 买侧没有变化, 因而此刻显示价差扩大为 $100.04 - 100.01 = 0.03$.

再回到同一初始订单簿, 将市场单改成限价 100.03 的 550 股买单. 它只能取得前 500 股, 支出 $300 \times 100.02 + 200 \times 100.03 = 50,012$, 已成交部分的均价为 100.024. 剩余 50 股不接受 100.04; 是继续挂单还是取消, 由有效期和其他订单条件决定.

成交方向与有符号订单流 每笔成交买卖数量相等. 所谓买方发起, 是买方主动接受已有卖单; 卖方发起则相反. 统计主动方向, 才能讨论哪一侧正在更积极地消耗报价, 而不是把买卖成交总量说成不相等.

定义 6.94 (成交方向).

第 i 笔成交数量为 $v_i > 0$, 取

$$\varepsilon_i = \begin{cases} +1, & \text{买方主动发起,} \\ -1, & \text{卖方主动发起.} \end{cases}$$

有符号成交量为 $q_i = \varepsilon_i v_i$.

对一段时间求和,

$$Q_{t,t+\Delta}^{\text{trade}} = \sum_{i: t_i \in (t, t+\Delta]} \varepsilon_i v_i.$$

正值表示这段时间内买方主动成交的数量大于卖方主动成交的数量. 前面的 550 股市场买单虽然在三个价位分别生成成交回报, 三笔的主动方向都为买入, 所以有符号成交量合计仍为 550.

有的数据直接报告主动方, 有的只能根据成交相对买价, 卖价和中间价的位置推断. 价差内部成交和报价时间不同步, 都可能使这种分类出错 [LR91]. 对无法可靠分类的成交, 应保留不确定性, 而不让算法强行制造准确方向.

成交不平衡只统计已经发生的交易; 订单簿不平衡则比较此刻尚未成交的买卖数量. 例如只看最优档位, 在两侧总显示量为正时定义

$$J_t = \frac{Q_{1,t}^b - Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a}.$$

前例买侧 400 股, 卖侧 300 股, 所以 $J_t = 1/7$.

同一组最优报价和数量还可以构造队列加权的微价格 (microprice):

$$\mu_t = \frac{a_t Q_{1,t}^b + b_t Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a} = m_t + \frac{a_t - b_t}{2} J_t.$$

买侧显示数量较大时, μ_t 位于中间价靠近卖价的一侧; 卖侧较大时则靠近买价. 前例给出 $\mu_t \approx 100.01571$, 略高于中间价 100.015. 这个数是由当前最优队列构造的状态量, 后面可以检验它与短期价格变化之间的统计关系.

报价价差, 有效价差与实现价差 只看买卖报价距离, 还不知道实际成交是在价差内部, 最优档位, 还是更远的价格. 对第 i 笔成交, 用 a_i, b_i 表示匹配的成交前最优报价, 定义**报价价差**

$$QS_i = a_i - b_i.$$

它以每单位价格计量, 尚未考虑这笔交易实际付出了什么.

若成交价为 p_i , 时刻为 t_i , 成交前中间价为 $m_{t_i^-}$, 则**有效价差** (effective spread) 为

$$ES_i = 2\varepsilon_i(p_i - m_{t_i^-}).$$

买得高于中间价或卖得低于中间价时, 结果为正. 系数 2 把一次交易的价格让步换成全价差的等效尺度, 并不表示已经实际完成一买一卖. 前例最初按 100.02 买入, 若成交前中间价仍为 100.015, 有效价差就是 $2 \times 0.005 = 0.01$.

再固定观察时距 $h > 0$, 用后来中间价重新比较该笔成交, 定义**实现价差** (realized spread)

$$RS_i(h) = 2\varepsilon_i(p_i - m_{t_i+h}),$$

以及这段时间的有符号中间价变化

$$PI_i(h) = 2\varepsilon_i(m_{t_i+h} - m_{t_i^-}).$$

在成交价与原中间价之间加减同一个 m_{t_i+h} , 立即得到

$$ES_i = RS_i(h) + PI_i(h).$$

例如买方主动成交以后, 中间价继续上涨, 则 $PI_i(h) > 0$, 所以实现价差低于成交时的有效价差. 从当时卖出的流动性提供者看, 按 $t_i + h$ 的中间价重新衡量这笔卖出, 原先相对于旧中间价取得的价差收入有一部分被随后上涨抵消.

等式 $ES_i = RS_i(h) + PI_i(h)$ 只是把成交相对旧中间价的让步, 分成观察时点仍保留的部分和期间中间价变化. 若要算做市商实际利润, 还要把对冲, 费用, 返佣, 融资和其他库存一起加入现金账 [HS97].

6.8.4 流动性的多个维度

一笔交易是否容易完成, 要同时看价格, 数量与等待时间. **紧度**比较买卖价差有多窄, **深度**比较附近价位能承接多少. **即时性**则问能否马上成交, 或需要付出多大价格让步才能不再等待.

假设市场 A 价差为 0.01, 但最优档位只有 100 股; 市场 B 价差为 0.05, 附近却能承接 100,000 股. 在其他条件可比时, 50 股订单可能更喜欢 A. 50,000 股订单则必须查看 A 的更深档位, 不能仅凭它的最优价差更窄就作同一判断.

大单完成以后, 还可以观察盘口多久恢复. 新订单能多快补回深度, 价差是否很快收窄, 属于**韧性**. 不断增大订单规模时, 均价和总成本怎样改变, 则关系到**交易容量**. 一个能够低成本交易小额资金的办法, 未必可以原样放大.

成交活跃也不保证容易成交. 大量主动卖单扫过不断撤退的买盘时, 成交量可以很高, 但卖方需要接受越来越差的价格. 所以数量统计要与报价和执行结果一起看.

6.8.5 买卖价差为什么存在

挂出买价和卖价的人把可执行报价留在市场中; 在报价撤回或失效以前, 对手方可以主动与之成交. 成交会改变报价者的库存头寸, 而资产价值还可能在平仓以前变化. 因而买卖价差可能要补偿订单处理成本, 库存风险以及与更知情交易者成交造成的损失.

下面先看信息差异怎样产生价差, 再看库存怎样推动报价中心移动.

信息交易与流动性交易

定义 6.95 (信息交易与流动性交易).

订单利用了当前报价尚未充分反映的信息时, 称为**信息交易** (informed trading). 微观结构模型中, 由现金需求, 对冲, 指数调仓等其他需要产生的订单, 常称为**流动性交易**或**噪声交易**.

噪声在这里是相对于所研究的价值信息而言, 并不表示交易动机不合理. 基金为支付赎回卖出股票, 可能没有看坏公司, 只是需要现金. 同一次执行又可能利用短期信息选择时机, 所以两类动机在现实中也会混合.

逆向选择 挂单者先报出愿意买卖的价格, 对手方再决定是否接受. 若对手方更早知道好消息, 就更愿意按尚未更新的卖价买入; 若更早知道坏消息, 就更愿意按旧买价卖出. 是否与挂单成交, 由主动交易的一方决定. 因而当对手方掌握更有利的信息时, 挂单者的订单反而更容易在对自己不利的情境下成交, 这就是**逆向选择** (adverse selection).

在 Glosten-Milgrom 类型的一期简化模型中, 令 V 为可积的未来结算价值, 利率取零, 或将 V 预先折算到报价时点. 做市商报价前的信息为 $\mathcal{F}_t$, 每次交易一单位. 竞争性, 风险中性的做市商忽略库存和处理成本, 并要求在成交方向已知的条件下预期利润为零, 则

$$a_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = +1, \mathcal{F}_t], \quad b_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = -1, \mathcal{F}_t].$$

做市商设定卖价时, 按有人主动买入这一条件计算未来价值的平均值; 设定买价时, 则按有人主动卖出这一条件计算. 如果主动买入更可能意味着好消息, 两个条件期望就会不同, 从而形成正的买卖价差 [GM85].

期望按照模型规定的价值与订单联合分布计算. V 是模型中的未知终值, 不是从一张盘口直接观测到的公司真实价值. 这个模型解释信息差异如何产生价差, 实际价差中还会有其他成本和库存因素.

库存风险 客户连续卖出, 做市商就会逐渐买入更多库存; 客户连续买入, 则会消耗做市商库存, 甚至形成空头. 即使对价值的判断不变, 已经承担的风险不同, 愿意继续报价的条件也可能改变.

一种局部线性报价规则用 $\hat{v}_t$ 表示参考价格, H_t 表示净库存, 正数为多头, 令

$$c_t = \hat{v}_t - \kappa_t H_t, \quad \kappa_t > 0.$$

在其他条件不变时, 每多持有一单位, 报价中心降低 κ_t . 若拟报的全价差为 $s_t \geq 0$, 自身两侧报价可以设为

$$b_t = c_t - \frac{s_t}{2}, \quad a_t = c_t + \frac{s_t}{2}.$$

多头库存较大时, 做市商可以降低买价, 减少继续买入库存的机会; 同时降低卖价, 提高把现有库存卖给买方的机会. 空头较大时方向相反. 这条线性规则把库存变化怎样推动报价移动写成了一个可计算假设, 相关库存模型见 [HS81].

这里的 b_t, a_t 是该做市商按照这条线性规则产生的报价, 未必恰好成为全市场最优价. 参数 κ_t 决定库存每增加一单位时报价中心移动多少, s_t 决定它希望保留多宽的买卖价差. 做市商也可以改变挂单数量或用其他资产对冲库存.

真正的账户利润要把客户成交, 后续平仓或对冲, 费用和融资一起计算. 报价价差提供的是成交时的价格差, 库存持有期间的价格变化则可能把这部分收入扩大或抵消.

6.8.6 订单流与价格冲击

550 股例子中的均价上升, 来自现有卖单被消耗. 真实市场还会根据订单修改报价. 其他人看到连续主动买入, 可能认为有新信息, 也可能认为只是暂时的交易需求. 不同解释会影响是否补回原价附近的数量.

Kyle lambda Kyle 模型把知情者的订单选择与做市商从总订单中学习放在一起 [Kyl85]. 先看其中一次拍卖. 令 V 为未来价值, 采用零利率或已贴现的价值单位; 知情交易者提交带符号订单 X , 其他交易者的订单为 U . 做市商只看到

$$Y = X + U,$$

无法直接分辨其中多少来自信息. 在竞争性, 风险中性且无其他成本的模型中, 它按条件平均价值报价:

$$p = \mathbb{E}[V \mid Y].$$

在标准 Gauss 线性设定中, 取已中心化的 Y , 即 $\mathbb{E}[Y] = 0$, 并有 $\text{Var}(Y) > 0$. 若 V, Y 联合 Gauss, 条件期望具有线性形式

$$p = p_0 + \lambda Y, \quad p_0 = \mathbb{E}[V], \quad \lambda = \frac{\text{Cov}(V, Y)}{\text{Var}(Y)}.$$

在完整 Kyle 均衡中, X 本身还由知情者面对这条价格规则的选择决定, 因而 λ 需要与其订单策略一起求解, 并非任意指定的冲击常数.

定义 6.96 (Kyle lambda).

上述线性均衡中的价格斜率 λ 称为 **Kyle lambda**. 在固定模型和数量单位下, 净订单流增加一单位时, 报价改变 λ 单位价格.

λ 越大, 同样数量的净订单对应的价格变化越大. 当 $\lambda > 0$ 时, $1/\lambda$ 表示在这条线性关系中让报价改变一单位价格所对应的订单流数量. 它与买卖价差衡量的是不同方向: 一个研究数量变化与价格响应, 一个研究同一时刻买卖报价的间隔.

成交不平衡与经验价格冲击 在给定长度的时间窗口内, 可以用回归比较有符号成交量与中间价变化:

$$\Delta m_{t,t+\Delta} = \alpha_{\Delta} + \beta_{\Delta} Q_{t,t+\Delta}^{\text{trade}} + \eta_{t,\Delta}.$$

β_{Δ} 是在指定数据和窗口长度下得到的经验斜率. Kyle 模型中的 λ 则来自知情者订单选择和做市商定价共同形成的均衡, 所以二者只有在额外模型条件成立时才可以作结构上的对应.

只使用已经成交的数量, 会遗漏订单簿中尚未成交队列的变化. 例如买侧大量撤单以后, 即使还没有大额卖单成交, 下一笔卖单面对的最优买价和深度也已经改变. **订单流不平衡** (order flow imbalance, OFI) 因而进一步把限价单新增, 撤单以及最优报价处的队列变化一起计入短时统计 [CKS14].

至于订单与价格变化谁先发生, 是否同时受同一消息驱动, 要依靠更细的事件时间记录或相应结构模型判断. 在转到这些事件时间记录以前, 还可以先比较成交后的价格响应会不会随着观察时距拉长而消退.

暂时冲击与永久冲击 前例的卖盘被扫空后, 若新卖单很快回到原价附近, 价差和中间价就可能部分恢复. 这种随后消退的价格影响称为**暂时冲击**. 若订单使市场持续提高对资产价值的判断, 补回的盘口可能出现在更高价格, 则包含较持久的信息影响, 通常称为**永久冲击**.

一种观察方法是固定成交后的时距 h , 在相应一阶矩存在时计算

$$R(h) = \mathbb{E} \left[\varepsilon_i (m_{t_i+h} - m_{t_i}^-) \right].$$

买入后上涨或卖出后下跌都记为正, 因而 $R(h)$ 汇总沿主动方向的平均价格响应. 若响应先大后小, 可以在给定模型中研究消退部分; 若较长窗口后仍保留, 则需要解释其持续来源.

实际数据中, 从 t_i 到 $t_i + h$ 之间还会到达新消息和新订单, 同一母订单也可能继续拆成后续子单. 因而用 $R(h)$ 分解短暂与持久响应时, 观察窗口和所采用的事件模型本身就是估计的一部分.

6.8.7 时间尺度与点过程

日线只留下开盘, 高低, 收盘和成交量, 不能重建一天中订单怎样先后到达. 订单簿的更新发生在不规则时刻, 活跃时很密集, 安静时则等待较久.

定义 6.97 (日历时间, 事件时间与成交时间).

日历时间 (calendar time) 用秒或毫秒等物理单位计时. **事件时间** (event time) 按预先选定的提交, 撤销, 修改, 成交或报价事件依次编号. **成交时间** (transaction time) 只按实际成交的次序推进.

令 τ_n 为第 n 个所选事件的实际到达时刻, 在有限区间事件数有限的模型中,

$$N(t) = \sum_{n \geq 1} \mathbf{1}_{\{\tau_n \leq t\}}$$

统计截至 t 发生多少次, 相邻等待时间为

$$W_n = \tau_n - \tau_{n-1}.$$

每次事件后的平均变化与每秒平均变化不同, 因为每秒包含的事件数也会变. 使用数据时先确定时钟, 才能比较速率和响应.

对第 i 类事件分别建立计数 $N_i(t)$, 可以区分主动买卖, 挂单与撤单. 严格地说, 若非负可预测过程 $\lambda_i(t)$ 局部可积, 并且

$$N_i(t) - \int_0^t \lambda_i(s) ds$$

是局部鞅, 就称 λ_i 为相应事件计数的条件强度. 其中 $\int_0^t \lambda_i(s) ds$ 是根据此前信息形成的累计补偿量; 用实际计数 $N_i(t)$ 减去它以后, 剩下的是局部鞅.

在简单点过程, 无固定时刻跳跃并有适当小时间正则性的情况下, 可以将这种强度直观读成

$$\mathbb{P}(N_i(t + \Delta t) - N_i(t) = 1 \mid \mathcal{F}_{t-}) = \lambda_i(t)\Delta t + o(\Delta t).$$

这是局部概率展开, 不能对任意带有成批到达或定时跳跃的计数记录直接套用.

常数强度 Poisson 过程提供最简单的基准. 若数据显示开收盘季节性, 事件聚集或不同类型相互影响, 可以让强度随此前事件及当时可见的队列变化, 或采用 Hawkes 过程等模型 [BMM15; CST10].

例如, 一笔主动卖出后若更容易继续出现卖单, 可以在卖出事件对应的条件强度中体现自激; 若同时提高买侧撤单的强度, 则表现为两类事件之间的交叉激发. Hawkes 模型用这些条件强度的动态关系描述事件到达的统计依赖.

数据的可见范围 要研究什么, 决定需要哪些记录. 成交与最优报价数据能比较执行价和价差, 多档快照还能观察深度, 逐消息数据则进一步显示订单加入, 修改和撤销. 自己的经纪商记录还可以区分发送, 接受, 成交回报等时点.

这些时间并不必然相同. 市场中已经发生的成交, 可能过一会儿才到研究者系统; 多条更新还可能乱序到达. 一张 550 股订单也可能像前例那样生成多笔成交, 不能仅凭三条成交记录断言来了三个独立交易者. 粗时间戳下, 多条消息看似同时发生, 实际顺序仍可能影响排队和可见信息.

同一证券还可能分散在多个场所交易. 若研究者只拿到其中一个公开订单簿, 记录的就是该场所可见队列. 合并多处公开行情时, 还要按照各自时间戳处理传播延迟和更新顺序; 合并后的记录仍不包含未展示的数量. 暗池等非公开场所则可能只在成交以后留下可观察记录.

流动性枯竭与交易中断 挂单者也会更新风险判断. 新消息到达, 波动扩大或库存接近限额时, 它可以缩小数量, 拉开报价或撤单. 这使后续相同规模的主动订单需要扫过更多档位, 价格变化又可能促使更多挂单者减少风险.

因此, 原来适合小订单的盘口, 可以在短时间内变得难以承接稍大交易. 深度变化并非只发生在价格变化之后, 撤单本身也会改变下一笔订单面对的价格条件.

极短时间内的大幅异常下跌及可能随后出现的快速部分恢复, 通常称为**闪崩** (flash crash). 大额执行, 单边订单, 流动性撤退, 跨市场联系和算法风控之间的相互作用, 都可能参与其中, 见 [Kir+17].

交易暂停, 临时集合竞价和价格限制可以按规则中断或改变连续撮合, 给参与者重新报价的时间. 但未满足的买卖需求可能仍然存在. 重新开市以后以什么价格成交, 要由那时的订单和信息决定.

6.8.8 从订单簿走向交易执行

同样的限价, 排在前面与后面具有不同的成交机会. 先研究一个所有数量可见, 同价先进先出的理想队列. 设本单在 t_0 被接受, 价格为 p , 数量为 $q > 0$, 前方已有数量 $A_{t_0}(p)$. 本单此后不撤销, 不改价, 后来的同价订单都排在它后面.

令 $D_t(p)$ 累计从 t_0 开始在这一价位发生的主动成交数量, 加上最初排在本单前方而后来撤销的数量. 后方订单的撤销不计入, 因为它没有让本单前进. 在这些假设下, 本单截至 t 的成交数量为

$$F_t^{\text{fill}} = \min \left\{ q, (D_t(p) - A_{t_0}(p))^+ \right\}.$$

只有前方数量被移除以后, 新的主动成交才会轮到本单. 因而在离散成交事件下,

$$\tau_{\text{first}} = \inf \{ t \geq t_0 : D_t(p) > A_{t_0}(p) \},$$

$$\tau_{\text{full}} = \inf\{t \geq t_0 : D_t(p) \geq A_{t_0}(p) + q\},$$

并约定空集合的下确界为 ∞ . 恰好移除全部前方订单, 只表示轮到本单站在最前, 尚不等于本单已经成交, 所以首次成交使用严格不等号.

例如, 在价格 100.02 提交 100 股卖单, 前方有 300 股. 前方撤销 100 股后, $D = 100$, 本单仍未成交. 随后该价位被主动买入 250 股, 前方剩余 200 股先成交, 本单成交 50 股, 此时 $D = 350$. 再成交 50 股, $D = 400$, 本单全部完成. 若 100 股撤单原本在本单后面, 就不能计入这项推进量.

实际快照通常不知道撤单属于哪个排队位置, 隐藏和冰山数量也可能改变顺序. 因而以上公式给出的是明确队列假设下的成交计算, 现实排队位置还须由逐消息记录或估计取得.

成交快也不必更有利. 一张买入限价单可能正因为卖压突然增加而迅速成交, 随后价格继续下跌. 等候限价省下部分立即跨价差的成本, 同时承担未成交和逆向选择; 市场化成交则用价格让步减少等待. 选择取决于交易有多急, 价格风险有多大, 以及还剩多少数量.

大额母订单还可以分批执行. 若总数量 $Q > 0$ 分为同方向的子单, 全部完成时

$$\sum_{k=1}^n q_k = Q, \quad \bar{P}^{\text{exec}} = \frac{1}{Q} \sum_{k=1}^n q_k P_k^{\text{exec}}.$$

分批可以等待新流动性, 少扫一些远档, 但等待期间价格可能朝不利方向变化, 连续子单也可能让别人察觉交易需求.

用决策时的基准 P^{decision} 比较实际全部成交, 实施差额可以写为 [Per88]

$$\text{IS} = \varepsilon Q \left(\bar{P}^{\text{exec}} - P^{\text{decision}} \right) + \text{费用},$$

其中买入取 $\varepsilon = 1$, 卖出取 -1 , 正数表示相对于基准付出了成本. 前面的 550 股买单若以原中间价 100.015 为决策基准, 且没有费用, 实施差额就是 5.75. 这已经包含从该基准到实际均价的全部价差, 不再另扣同一笔点差或扫单滑点.

若订单未完成, 还应报告剩余数量, 并按明确的评价时点研究未成交的机会成本. 只展示已经成交的一小部分均价, 可能把难以完成的部分从结果中删掉.

实施差额把决策价格与最终执行现金流之间的全部价格变化记在同一个指标中. 因而等待期间的市场变化也会进入这个成本. 执行模型要在更快成交时付出的价格让步, 继续等待期间的价格风险以及未成交数量之间作权衡 [AC01].

第七章 基本面分析

第六章已经介绍了股票赋予持有人的权利以及市场怎样交易。要判断一只股票值多少钱，还要回到公司本身：产品卖给谁，收入怎样增长，经营赚到的钱又有多少需要继续投入。再扣除利息和税，处理优先于普通股的其他请求权，并考虑股数变化，才能算出最终归属于普通股股东的每股盈利或现金。

第7.1节先从一个完整的 DCF 例子入手，把经营预测一步步算成现金流，再折现得到每股价值。随后介绍 Morningstar 的长期估值方法，并用 LLY 说明 DCF 与盈利倍数法为什么可能相差很大。银行、地产和多业务公司的算例则说明，估值方法要适应具体业务的盈利方式和资本需要。

未来的销量、价格和竞争格局都有多种可能。第7.3节把主要差别分成若干情景，分别计算盈利与股价，再与今天的买入价比较。最后的第7.4节讨论怎样保存每项判断的依据，使新财报或竞争消息出现以后，能够找到受影响的假设，修改相应预测，再重算估值与回报。

7.1 从资产头寸到可识别价值

在第6.1节中，我们已经区分了资产赋予的权利，市场价格和最终投资回报。基本面估值接着追踪公司怎样产生收入和现金，这些现金先要满足哪些请求权，最后有多少归普通股股东所有。在开始估值以前，先分清财报和估值中常见的几种利润指标。

GAAP 与 non-GAAP: 利润按什么规则计算 GAAP 是 Generally Accepted Accounting Principles 的缩写，即公认会计原则。本文讨论美国公司时指 US GAAP，它规定收入、费用、资产和负债等怎样确认与计量 [Fin]。GAAP 净利润扣除了按这些规则应确认的费用，包括利息和所得税；收入与费用的确认时点却不一定等于现金收付时点，所以净利润也不等于当期收到的现金。

公司还可能在 GAAP 数字上加回或剔除某些项目，得到 **non-GAAP** 指标，如调整后净利润或调整后 EPS。常见调整包括并购相关摊销、股权激励和重组费用，也可能剔除一次性收益。阅读时看调节表：从哪项 GAAP 数字出发，每一项加减了多少，所得税影响怎样处理。同名的调整后利润未必采用相同调整，也不能一概把被剔除的费用当成不再发生的费用 [US i]。

EBIT, EBITA 与 EBITDA: 哪些费用还没有扣 这三个指标都先不扣利息和所得税，区别在于怎样处理折旧与摊销。折旧 (depreciation) 通常把机器、厂房等有形资产的成本分配到使用期间；摊销 (amortization) 在这里主要指对有限使用寿命无形资产的类似分摊，例如购入的专利。两者合称 D&A。买设备或专利时已经发生的支出，可以在随后几年逐步计入费用，因而当年的折旧摊销通常不伴随同额的当年现金流出。

指标与英文全称	中文含义及费用处理
EBIT: earnings before interest and taxes	息税前利润。已扣折旧和摊销，尚未扣利息与所得税
EBITA: earnings before interest, taxes and amortization	息税摊销前利润。在 EBIT 上加回摊销，仍扣折旧
EBITDA: earnings before interest, taxes, depreciation and amortization	息税折旧摊销前利润。在 EBIT 上加回折旧与摊销

例如，某公司的 EBIT 为 200，其中已经扣了折旧 20 和摊销 10，则 EBITA 为 210，EBITDA 为 230。若再假设利息支出 20，所得税率 25%，没有其他损益和税会差异，净利润就是 $(200 - 20)(1 - 25\%) = 135$ 。这些数描述同一份经营结果，差别来自计算到哪一步。

EBIT 也不一定等于报表上的营业利润：从净利润加回利息和所得税时，可能仍包含投资收益等非经营项目。后面的 DCF 使用经营口径的 EBIT，将这类非经营损益另行处理。公司披露的 EBIT 与 EBITDA 作为业绩指标时通常属于 non-GAAP 指标；若还剔除股权激励等其他费用，就应继续说明 Adjusted EBITDA 等调整后口径 [US i]。

从 EBIT 换成 EBITDA, 只是少扣了两类费用, 并没有多收到现金. 设备仍要更新, 公司仍要缴税, 存货和应收款也会占用资金. 后面计算自由现金流时, 会把这些收支逐项算进去. 在进入这些估值计算以前, 还要先分清所估的是整个经营资产, 还是普通股股东的权益.

先确定所估的是哪一项经济利益 企业价值 (enterprise value, EV) 衡量整套经营资产对所有资本提供者合计值多少. 普通股价值只计算普通股股东享有的部分, 因而还要把未计入经营价值的非经营资产加进来, 再扣除债务, 优先权利, 少数股东权益和其他优先于普通股的请求权. 每股收益 (earnings per share, EPS), P/E, P/B 和 P/TBV 本来就在股权层面; EV/EBIT 与 EV/EBITDA 则从经营资产层面出发.

这一区别决定了现金流与折现率怎样配对. FCFF 在付利息以前衡量经营现金, 对应经营资产价值; FCFE 已经处理利息和净借款, 对应股权价值. 由 FCFF 算出经营价值以后, 加上未计入其中的非经营资产, 再扣除债务和其他优先请求权, 得到普通股价值. 若一开始已经得到股权价值, 就不再扣同一笔债务. SOTP 也按同一原则处理: 每个分部先注明算的是经营价值还是股权价值, 汇总时再处理尚未计入分部估值的集团现金, 债务和其他请求权.

按业务怎样赚钱来选择方法 方法不必先按行业标签固定. 先看最有把握预测的经济对象是什么, 再选能直接给它定价的方法.

经营对象	常用方法	主要预测依据
成熟经营业务	DCF, 正常化盈利与可比倍数	收入, 利润率, 维护与增长资本, 营运资金, 税和资本结构
成长或商业化业务	经营驱动到未来 EPS/FCFF, 再用 DCF 或未来倍数	收费, 数量, 留存, 单位贡献, 再投资, 稀释及增长持续期
临床项目, IP 或有限项目	风险调整净现值 (rNPV), 项目现金流或条件价值	资金到节点, 成败后的现金权利, 开发时点和项目之间的重叠
银行等金融机构	剩余收益, P/B, P/TBV 及其他股权方法	资产质量, 融资成本, 监管资本, 可分配盈利及普通股资本回报
物业与 REIT	NOI 资本化, NAV 或物业 DCF	可持续租金, 空置, 运营费用, 更新投入, 债务及其他物业权利

同一家公司也可以同时包含这些不同对象. 已商业化的产品可以按经营盈利研究, 尚在临床的项目可以按项目权利研究, 若几项业务共用研发和销售渠道, 难以分别估计投入和收入, 就把它放在一起估值.

证据决定结果写成一个数还是一组条件 将数字代入公式以后, 算术通常很快. 真正困难的是收入增速, 利润率, 资本效率, 临床进展, 倍数和资本成本为什么取这些数. 经营证据能够支持一条主要路径时, 可以把它展开为可复算估值; 若关键变量有几种都有依据的取值, 就分别计算, 看结果相差多少.

市场价格也可以反过来帮助研究. 例如由现价求出它隐含的长期增长率或未来 P/E, 再问公司经营能否支持这些条件. 这种反算把价格变成一个需要解释的问题, 而不是拿现价来调参数直到模型重新得到现价.

多种方法怎样一起使用 可以把 DCF 作为主要估值方法, 也可以用它检查盈利最终能转成多少现金; 可以用 P/E 为未来盈利估算市场价格, 也可以反过来检查某个 DCF 结果隐含了多高的市盈率. 只有当几种方法估的是同一对象, 同一日期和币种, 并采用一致的情景与股东权利口径时, 才适合把结果合在一起. 即使如此, 权重也应取决于各方法关键输入有多可靠, 而不是一律各占一半.

若两个结果相差很大, 先追查它们在哪一步开始分叉: 盈利分母是否相同, 一边是否包含研发和资本投入, 估值日期是否相同, 终期增长持续多久, 债务和现金是否处理了两次, 使用的资本成本又是否针对同一组现金. 这些问题解决以后, 可以选更适合的主方法, 将另一种保留为诊断; 若两种方法依据不同资料, 各有可信之处, 也可以说明权重的理由, 取加权结果.

普通股是下面各算例的共同终点. 我们会先把公司经营算成现金, 盈利或资产价值, 再沿资本结构和稀释股数换成每股价值. 先看其中步骤最多的一种方法: DCF.

7.2 常用估值方法: 从经营预测到每股价值

下面先完整计算一份通用 DCF, 再讨论 Morningstar 怎样把竞争优势与长期资本回报放入更长的预测. 随后的 LLY 案例用同一家公司展示未来 P/E 条件价格, 今日 DCF 现值和资本成本敏感性为什么会得到不同数字. 除 LLY 复盘外, 以下算例的总金额均以百万美元计, 股数以百万股计, 每股金额以美元计.

7.2.1 DCF 怎样计算: 一个完整例子

DCF 先回答一个最简单的问题: 未来收到的钱折到今天值多少. 若一年后确定收到 100, 相应要求回报率为 10%, 今天与它等价的金额是

$$\frac{100}{1.10} = 90.91.$$

若同样的 100 要到第二年末才收到, 就要折现两期. 因而每笔现金何时收到, 决定它要经过多少期折现.

对非金融企业, 一种常用做法是先预测企业自由现金流 FCFF. 从 EBIT 出发, 扣经营税得到税后经营利润; 折旧摊销已经减少会计利润却没有在当期等额流出现金, 因而加回; 资本开支和经营营运资本增加会真正占用现金, 所以扣除:

$$FCFF_t = EBIT_t(1 - \tau) + D\&A_t - Capex_t - \Delta NWC_t.$$

这里 τ 为经营税率, $EBIT(1 - \tau)$ 称为税后经营利润 (net operating profit after tax, NOPAT); D&A 为折旧摊销, Capex 为资本开支, ΔNWC 为经营营运资本增加 [Dam12]. 应收和存货增加通常增加营运资本占用, 应付增加则减少净占用.

设一家企业第一年收入 1000, EBIT 利润率始终为 20%, 税率始终为 25%. 再假设收入, 折旧摊销, 资本开支和营运资本新增都每年增长 10%:

项目	第 1 年	第 2 年	第 3 年
收入	1000	1100	1210
EBIT	200	220	242
税后经营利润	150.0	165.0	181.5
加: 折旧摊销	30.0	33.0	36.3
减: 资本开支	60.0	66.0	72.6
减: 经营营运资本增加	20.0	22.0	24.2
FCFF	100.0	110.0	121.0

例如第一年

$$150 + 30 - 60 - 20 = 100,$$

第二年为 $165 + 33 - 66 - 22 = 110$, 第三年为 $181.5 + 36.3 - 72.6 - 24.2 = 121$. 后两年的现金流也就随经营预测一起算出来了.

FCFF 在付利息之前计算, 是经营活动产生的, 可供股东和债权人共同分配的现金. 本例给定股权市场价值权重 80%, 债务市场价值权重 20%, 股权成本 11%, 税前债务成本 8%, 税率 25%. 假设利息税盾按这个税率适用, 则

$$k = WACC = 0.8 \times 11\% + 0.2 \times 8\% \times (1 - 25\%) = 10\%.$$

这里的成本输入已经给定, 权重按相应资本的市场价值. 因为正在折现 FCFF, 所以使用全部经营资本的 WACC, 而不是普通股单独的 k_e .

三笔显式现金分别在第一, 二, 三年末取得, 因而现值为

$$\frac{100}{1.10} = 90.91, \quad \frac{110}{1.10^2} = 90.91, \quad \frac{121}{1.10^3} = 90.91.$$

三年显式 FCFF 的现值合计约 272.73.

企业在第三年以后仍然经营, 所以还要给第四年及以后现金一个价值. 假设从第四年起已经进入稳定阶段, FCFF 长期按 $g = 2\%$ 增长, 则第四年 FCFF 为

$$\text{FCFF}_4 = 121 \times 1.02 = 123.42.$$

在 $g < k$ 下, 第三年末的终值为

$$\text{TV}_3 = \frac{\text{FCFF}_4}{k - g} = \frac{123.42}{0.10 - 0.02} = 1542.75.$$

这个 1542.75 位于第三年末, 还要从第三年末折回今天:

$$\frac{1542.75}{1.10^3} \approx 1159.09.$$

因此当前经营企业价值为

$$\text{EV}_0 = 272.73 + 1159.09 \approx 1431.82.$$

最后从经营价值走到普通股. 假设公司还有未计入经营价值的可分配现金 80, 当前有息债务价值 300, 没有其他优先请求权, 稀释股数 20, 则

$$V_0^{\text{eq}} = 1431.82 + 80 - 300 = 1211.82, \quad v_0 = \frac{1211.82}{20} = 60.59.$$

本例中终值现值约占经营价值的 81%. 因而第三年以后为什么能够增长 2%, 需要多少再投资, 以及稳定阶段的资本成本是多少, 比把前三年多算几个小数位更影响结果. 稳定阶段应来自业务真正进入较稳定的经营状态, 而不是因为预测表恰好在第三年结束.

若改为直接预测 FCFE, 现金已经扣除利息并计入净借款, 就应使用股权资本成本 k_e , 得到的是股权价值, 不再从结果中重复扣同一债务. 同理, 经营所需现金, 资本开支, 股权激励和稀释都应在与其经济作用一致的位置处理一次.

7.2.2 Morningstar 的三阶段框架: 竞争优势怎样逐渐减弱

Morningstar 的公开估值方法把长期经营分成三个阶段. 第一阶段逐年预测企业财务, 常见长度为五年或十年. 第二阶段预测竞争优势怎样逐渐减弱, 重点研究新增投入资本的回报怎样向资本成本靠近. 第三阶段进入稳定经营, 新投资不再持续创造超过资本成本的经济利润 [Mor26].

这里使用 RONIC (return on new invested capital) 衡量新增经营资本带来的新增税后经营利润. 它与全部历史资本的平均 ROIC 不是同一个量. 例如追加资本 100, 下一完整年度增加税后经营利润 15, RONIC 就是 15%. 若相应资本成本为 10%, 这 100 新增资本一年创造 5 的经济利润. 若竞争逐渐使同样投入只能增加 10 的税后利润, RONIC 便降到 10%, 新投资仍获得正常资本回报, 但不再产生超额经济利润.

新增资本的回报下降时, 既有业务可能仍在依靠原来的优势赚钱. 因此要分别预测旧业务的收入和利润怎样变化, 新投入又能带来多少新增利润. 护城河的价值就体现在这些经营差异及其持续时间长中.

Morningstar 还将公允价值估计与不确定性结合使用 [Mor24b]. 不确定性越高, 市价与公允价值之间需要更大的折价或溢价, 才会进入相应的高星级或低星级区间. 星级因此同时取决于公允价值, 当前市价和不确定性. 这套框架仍然使用 DCF 的基本现值算法, 重点在于预测竞争优势能够维持多久, 以及新投资的回报怎样逐渐接近资本成本.

7.2.3 同一家公司为什么会有不同估值数字: LLY 研究复盘

下面用 2026 年 9 月 11–12 日对 Eli Lilly (LLY) 的研究算例, 比较两种估值思路: 一种先预测 2029 年每股盈利, 再乘以 P/E; 另一种预测未来各年的现金流, 折回今天相加 [本笔记 26]. 收入, 盈利, 研发和倍数都采用当时的研究假设. 以下总金额和股数以 B 为单位, 1B 为十亿; 每股金额以美元计. 计算沿用原研究精度, 展示最多保留三位小数.

2029 年的盈利与 P/E 条件价格 先按研究假设预测 2029 年收入为 130.056B 美元, 扣除经营费用和内部研发后, 经营利润为 69.605B. 接着扣净利息 1.484B, 按 19% 计算所得税, 再扣本例设定的外部研发投入 4.552B. 这里把外部研发放在税后扣除, 表示本例没有给它计入当期税收抵扣. 最后除以稀释股数 0.894B, 就得到每股调整后盈利:

$$EPS_{2029}^* \approx \frac{(69.605 - 1.484)(1 - 19\%) - 4.552}{0.894} \approx 56.628.$$

这是本研究按上述收入, 利润率, 税和研发假设算出的调整后 EPS. 若要把它与 GAAP EPS 或公司披露的 non-GAAP EPS 比较, 就要逐项说明哪些费用或收入作了调整. 这里使用的 2029 年数字都来自本例研究假设.

若假定 2029 年 9 月 12 日市场按 2029 年全年这项盈利给 26 倍 P/E, 条件价格为

$$EPS_{2029}^* \times 26 \approx 1472.339 \text{ 美元/股}.$$

相同盈利在 18, 26 和 30 倍下分别得到:

2029 P/E	2029-09-12 条件价格
18	1019.31
26	1472.34
30	1698.85

为什么给 18 倍, 26 倍或 30 倍? 这取决于对 2029 年以后经营情况的判断: 盈利还能增长多久, 药品实际售价会不会下降, 新产品能否接替旧产品, 竞争会有多激烈, 以及持续研发还需要投入多少资金.

比较倍数时, 还要先看 EPS 扣除了哪些费用. 比如, 若不扣这 4.552B 外部研发, EPS 就会提高到 61.720. 如果仍认为每股值 1472.34 美元, 对应倍数应为

$$\frac{1472.339}{61.720} \approx 23.855,$$

这是因为费用扣得少了, 算出的 EPS 变高了; 在估值不变的情况下, P/E 就应相应降低. 不能只改变盈利的算法, 却原样保留 26 倍.

2026 年 9 月 11 日的 DCF 现值 DCF 直接计算这些经营现金今天值多少. 这份模型把截至 2080 年的显式预测现金流逐年折现, 相加得到 709.294B; 预测期之后的现金用终值表示, 折回今天为 35.838B. 两部分相加, 得到经营资产价值:

$$709.294 + 35.838 \approx 745.132 \text{ B 美元}.$$

经营资产的价值还不全归普通股股东. 本例再处理净债务等调整, 共扣除 47.678B, 得到普通股价值:

$$745.132 - 47.678 = 697.454 \text{ B 美元}.$$

除以 0.894B 股, 得

$$\frac{697.454}{0.894} \approx 780.150 \text{ 美元/股}.$$

780.15 美元估计的是 2026 年 9 月 11 日的价值, 1472.34 美元则是 2029 年 9 月 12 日按 26 倍 P/E 计算的价格. 比较两者以前, 先要处理这三年的时间差和期间股息.

以 P/E 算例的买入日 2026 年 9 月 12 日为准, 假设要求年回报为 10%. 按实际天数除以 365.25 计算年数, 将 2029 年 9 月 12 日的 1472.34 美元折回买入日, 得到 1106.118 美元; 期间各笔股息分别按预计支付日期折现, 合计 20.368 美元. 因而

$$1106.118 + 20.368 = 1126.486 \text{ 美元/股}.$$

如果未来卖出价和各笔股息都按本例假设实现, 那么今天以 1126.49 美元买入, 持有到设定期限就能取得要求的 10% 年回报. 换句话说, 这一步是在给定未来卖出价和股息以后, 反求今天最多可以付多少. DCF 则直接从公司的经营现金流出, 按资本成本折回估值日. 即使把 P/E 方法也换算到相同买入日, 两种方法的结果仍相差很大. 下面继续看折现率和长期研发假设怎样造成这种差异.

WACC 为什么会显著改变长久期 DCF 上述 780.15 美元采用原研究设定的 8.907% WACC. 这是当时研究采用的资本成本假设. 先保持经营预测不变, 可以单独看资本成本对结果的影响.

保持同一份经营现金流预测, 分别用以下三个固定 WACC 折现, 得到的每股价值是:

WACC	当前 DCF 价值/股
8.00%	941.65
8.907%	780.15
10.00%	640.78

这些经营现金中有很大大一部分要在较远的将来收到. 折现率提高后, 每年的分母都增大; 经过的年份越多, 现值受影响越明显. 因而仅把 WACC 从约 8.91% 改为 8%, 这份模型的每股估值就由 780.15 美元升到 941.65 美元. 研究 DCF 与 P/E 的差异时, 除了盈利和研发假设, 也要检查折现率究竟怎样影响了远期现金.

资本成本可以逐年变化 前面的入门例子始终使用同一个 WACC. 如果公司未来的经营风险和融资方式大致不变, 这样简化很方便. 但从新业务投入走向成熟经营时, 收入的稳定程度, 资本需要和融资条件往往都在变化, 资本成本也应随相应阶段调整 [Dam16].

例如, 模型一方面假设新业务以后会形成稳定客户和持续收入, 另一方面却永远沿用初创阶段的高 WACC, 就可能把成熟以后的现金流压得过低. 更合适的做法是逐年设定 $WACC_t$: 哪一年开始改变, 改变多少, 都与当年的业务风险和资本结构对应. 这些是估值时对未来各阶段的假设, 随后有新资料再作修订.

在年度网格上, 第 t 年 FCFF 折回今天的分母应累计经过此前每一年的资本成本:

$$PV(FCFF_t) = \frac{FCFF_t}{\prod_{j=1}^t (1 + WACC_j)}.$$

分母中的每一项对应一年. 即使后期采用较低的 WACC, 前期较高的资本成本也仍在累计分母中; 若只用最后一年的率作 t 次方, 就会把前面各年的率一并换掉.

另取三笔 FCFF 各为 100 的现金演示这项算法. 给定

$$WACC_1 = 12\%, \quad WACC_2 = 10\%, \quad WACC_3 = 8\%.$$

则三笔现值分别为

$$\frac{100}{1.12} = 89.29, \quad \frac{100}{1.12 \times 1.10} = 81.17, \quad \frac{100}{1.12 \times 1.10 \times 1.08} = 75.16,$$

合计 245.61. 若三年全程固定使用 12%, 同样三笔现金现值合计 240.18. 后两年的资本成本下降提高了后两笔现金的价值, 第一年的 12% 仍用于这三笔现金各自的累计折现.

若在第 T 年以后真正进入稳定阶段, 假设稳定阶段资本成本高于长期增长率 g , 终值便按该阶段的现金, 增长和资本成本计算:

$$TV_T = \frac{FCFF_{T+1}}{WACC_{\text{steady}} - g},$$

再用从今天到 T 的累计折现因子 $\prod_{j=1}^T (1 + WACC_j)$ 折回今天. 若业务到 T 时仍未稳定, 就继续逐期预测, 而不是提前套入永续公式.

资本成本的变化方向取决于业务本身. 客户和产品更加分散, 收入更加稳定, 可能使资本成本下降; 产品集中, 专利临近到期或融资恶化, 则可能使它上升. 因此逐年预测的重点是让资本成本与经营假设相互吻合, 而不是画出一条固定下降的曲线.

一家公司的不同业务也可能处于不同阶段. 如果能够分别预测各业务的 FCFF, 就可以用各自的 $WACC_{i,t}$ 逐年折现后加总; 若几项业务共用研发和渠道, 无法可靠分摊现金流, 则把相关业务放

在一起估值。这些资本成本用于折现相应业务的 FCFF。若改为直接折现普通股现金流，则应使用股权资本成本 k_e ；它反映债权人优先受偿以后普通股承担的剩余风险，也会受到公司债务安排影响。

研发失败的概率应先进入预期现金流。例如按获批与失败两条路径计算概率加权现金以后，相同的失败风险已经影响了分子；再因此额外调高 WACC，就可能重复扣减价值。资本成本主要反映资本提供者承担相应系统性风险所要求的回报，不宜把所有经营上的担心都塞进这个数 [Dam16]。

研发费用与未来创新要放在同一现金路径中 LLY 案例还有一项重要的长期现金问题。商业化药物产生当前收入和现金，已在研项目可能在以后接替旧产品，持续研发又为更远期的产品组合提供新的候选项目。若模型假定公司长期投入研发，现金流中要扣除这些研发资源；同时也要研究这些资源在经过失败，开发时滞和产品寿命以后可能产生什么收入。

在这份研究中，资本成本同样取 8.907%，但重新预测后续研发带来的产品收入和投入后，每股现值由 699.73 美元变为 780.15 美元。修改后的预测分别考虑已经识别的药物项目，正在临床开发的项目，以及未来研发可能带来的新项目怎样接替旧产品。各年需要投入多少研发费用，以后可能获得多少收入，都进入对应年份的现金流。反过来，若永远扣研发费用却把相应未来产出固定为零，也会把经营路径写成另一种极端假设。

P/E 也要按同样原则处理。如果 2029 年的 EPS 和所采用的倍数已经建立在公司能够持续更新产品组合的判断上，就不能又在 $\text{EPS} \times \text{P/E}$ 之外额外加一份研发平台价值。DCF 把更多远期现金假设逐年写出来；P/E 则把对增长持续期，风险和资本需求的部分判断包含在倍数中。实际研究时，哪一组输入更有依据，就更适合把相应方法作为主要估值方法；另一种方法可以用来检查长期假设是否彼此一致。

7.2.4 可比公司法：每一倍在乘什么

可比估值借助其他公司的市场价格，研究投资者目前愿意为每单位盈利或经营成果支付多少。它适合有可比较业务和正常化盈利的公司。CFA Institute 区分按市场可比公司选择倍数，与从增长、风险和回报假设推导合理倍数这两种做法 [CFAb]。行业中位数可以是调查起点，但还不是对目标公司的定价理由。

先看 P/E。它把普通股价格与归属于普通股的每股盈利比较，因而要使用扣除利息及相应税费后的盈利。如果采用今天股价除以下一年预测 EPS 的前瞻 P/E，可比公司和目标公司都应使用同一预测期限。把过去十二个月的倍数乘下一年度盈利，会同时改变比较基础和估值。

另设一家公司，下一年度正常化普通股净利润为 120，稀释股数为 20，因而 EPS 为 6。暂取前瞻 P/E 为 18 倍进行当前估值，则

$$v_0^{P/E} = \frac{120}{20} \times 18 = 108.$$

18 倍是本例的假设。要在真实研究中采用它，应解释可比公司的增长，盈利风险和资本回报为什么接近，再处理剩余差异。一次性资产出售不能当成每年都有的盈利，周期高峰利润也应先判断能维持多久。盈利仍为负或主要来自不稳定项目时，P/E 通常不能提供同样清楚的比较。

EV/EBITDA 则先在企业层面计算，不把企业倍数乘在普通股净利润上。假设同一公司的下一年度 EBITDA 为 200，采用 10 倍，额外现金 80，有息债务 400，没有其他请求权，则

$$\text{EV}_0 = 200 \times 10 = 2000, \quad v_0^{\text{EV/EBITDA}} = \frac{2000 + 80 - 400}{20} = 84.$$

EBITDA 没有扣折旧摊销，也没有扣资本开支，税和营运资本投入。两家公司即使 EBITDA 相同，一家需要不断更新设备，另一家新增收入几乎不占用资产，留给资本提供者的现金也可能不同。比较倍数时还应对齐租赁，利润正常化和债务的处理，而不把加回折旧直接理解为无需再投资。

本例的 108 与 84 为什么不同，可以反算检查。每股 108 对应普通股价值 2160，加债务 400 并减额外现金 80，得企业价值 2480，相对于 EBITDA 200 是 12.4 倍。因而 18 倍 P/E 与 10 倍 EV/EBITDA 从一开始就没有表达相同估值水平。要决定采用哪种判断，应回到利润转成现金的能力和可比证据，把两个价格平均成 96 并没有解决分歧。

7.2.5 分部估值：各项业务分别算，共同负担只扣一次

不同业务的增长，风险和资本需要差异很大时，一个全公司倍数可能掩盖主要差别。分部加总估值 (SOTP) 先分别估值，再把总部成本，集团融资和其他资产归并。每个分部可以使用适合其经营的办法，但相加以前要确认得到的是经营企业价值还是股权价值。

一个公开实例是 Morgan Stanley 在 2024 年 5 月 16 日的 Project Lean 交易顾问材料. 其中同时采用整体无杠杆 DCF, 分部估值和 P/E 可比分析; Networks 以无杠杆现金流和 WACC 估值, Renewables 则使用股权现金流与股权资本成本, 汇总时再处理口径转换. 该文件是具体交易的顾问材料, 并明确说明并非证券研究部门报告 [Mor24a]. 它恰好展示了 SOTP 的核心做法: 不同业务可以用不同方法, 但相加以前要先把价值对象和资本口径对齐.

考虑另一家有两项业务的公司. 业务 A 的预测 EBITDA 为 80, 采用 10 倍; 业务 B 的预测 EBIT 为 40, 采用 15 倍. 假设两项都是按同一估值时点计算的全部经营企业价值:

$$EV_A = 80 \times 10 = 800, \quad EV_B = 40 \times 15 = 600.$$

两项盈利均未分摊总部费用. 再假设总部每年需要 12 的税后经营现金支出, 长期不增长, 按 10% 贴现, 其现值为 $12/0.10 = 120$. 集团另有未包含在分部估值中的现金 100, 全部有息债务 400, 已估计的少数股东权益价值 80, 稀释股数 30, 无其他调整, 则

$$\begin{aligned} V_0^{\text{eq}} &= 800 + 600 - 120 + 100 - 400 - 80 = 900, \\ v_0 &= 900/30 = 30. \end{aligned}$$

分部按 100% 的业务估值, 所以还要扣除属于少数股东的部分. 总部费用若已经进入分部盈利, 就不再资本化扣一次. 债务 400 已经包含应处理的集团及子公司有息债务, 也不在各层反复相减.

若某个分部直接用 FCFE 得到股权价值, 就不能把它当成尚未扣债的 EV 混入上式. 可以先把其他分部也换算成股权价值再相加, 最后只处理尚未计入的集团负担; 也可以将各项统一到企业价值. 采用哪一种都可以, 关键是每项资产和请求权只出现一次.

7.2.6 银行: 先研究资本要求允许分配多少

银行的存款和融资参与日常经营, 利息支出也是获取资金的重要成本. 把工业企业的 EBITDA 和净债务办法直接搬来, 容易先忽略融资对盈利的作用, 又把经营所需负债重复当成外部负担. 金融企业因此常从普通股盈利, 可分配现金与权益资本入手 [Asw].

贷款增长会占用资本, 信用损失又会削弱已有资本. 账面净利润未必都能立刻分给股东, 实际可分配金额还受持续经营和监管资本要求约束. 监管资本与会计股东权益也并非完全相同, 实际模型需要检查资产质量, 监管扣除和能够释放给股东的资本.

剩余收益 (residual income) 定义为净利润减去股东投入资本的机会成本. 它不是现金科目, 用途是判断公司是否创造了超过股东要求回报的盈利. 在会计与股利预测一致的条件下, 股权价值可以写为当前账面权益加未来剩余收益的现值 [CFAc].

设 BV_t 为普通股账面权益, NI_t 为归属普通股的净利润, d_t 为股利. 先假设没有新股发行或回购, 股数固定, 并满足**干净盈余关系**

$$BV_t = BV_{t-1} + NI_t - d_t.$$

若存在绕过净利润的其他综合收益等权益变化, 须先作一致调整. 用固定股权资本成本 k_e 评价这组股利预测, 将 $d_t = NI_t - (BV_t - BV_{t-1})$ 代入股利现值, 账面权益项作望远镜求和. 在相关级数收敛且 $BV_n/(1+k_e)^n \rightarrow 0$ 时, 得到

$$RI_t = NI_t - k_e BV_{t-1}, \quad V_0^{\text{eq}} = BV_0 + \sum_{t=1}^{\infty} \frac{RI_t}{(1+k_e)^t}.$$

这说明账面权益为什么不是天然的估值下限. 若未来盈利长期不足以补偿股权资本成本, 剩余收益现值可以为负, 模型价值便低于账面值.

进一步假设 ROE 恒定, 账面权益每年增长 g , 留存后的盈利可以分配, 并有 $0 \leq g < k_e$ 和 $g \leq \text{ROE}$. 此时 $RI_t = (\text{ROE} - k_e)BV_0(1+g)^{t-1}$, 等比求和给出模型支持的 P/B:

$$\frac{V_0^{\text{eq}}}{BV_0} = 1 + \frac{\text{ROE} - k_e}{k_e - g} = \frac{\text{ROE} - g}{k_e - g}.$$

这项稳定关系适合帮助解释倍数, 不要求真实银行以后始终维持相同 ROE. 转型, 信用周期和资本缺口明显时, 应逐年预测盈利与必要留存.

取教学数字 $BV_0 = 1000$, ROE 为 12%, $k_e = 10\%$, $g = 5\%$, 并假设相应资本积累足以满足本例的经营和监管需要. 第一年的净利润为 120, 留存 50, 可分配 70. 因而

$$\frac{V_0^{\text{eq}}}{BV_0} = \frac{0.12 - 0.05}{0.10 - 0.05} = 1.4, \quad V_0^{\text{eq}} = 1400.$$

若股数为 50, 每股价值为 $1400/50 = 28$. 直接折现以 5% 增长的首年股利 70, 也给出 $70/(0.10 - 0.05) = 1400$, 两种写法相符.

若只把持续 ROE 改为 8%, 保留其余假设, 合理 P/B 就变成 $(0.08 - 0.05)/(0.10 - 0.05) = 0.6$. 低于一倍账面价值可以是对低资本回报的合理定价, 不单独构成便宜的证据. 这里已经直接估计普通股价值, 不再像工业企业 EV 换算那样扣一次银行存款和债务.

7.2.7 地产与 REIT: 从物业租金算到每股净资产价值

对已经稳定出租的物业, 可以先用可持续租金和运营费用估计净经营收益 (net operating income, NOI). 现金 NOI 从实际可取得的物业收入出发, 扣除空置损失和物业经营费用, 不先扣债务利息与折旧. 房地产估值可以据此资本化, 再扣负债得到每股净资产价值 NAVPS[CFAa].

资本化率应与所用 NOI 的时期和定义一致. 比如, 下一年度 NOI 相同的两栋楼, 若租约, 位置, 空置风险或以后更新投入不同, 价格也可能不同. 因而资本化率需从可比物业和长期经营条件研究, 不是把股权资本成本直接换一个名称.

设一组物业下一年度稳定租金等收入为 80, 空置损失 5, 物业经营费用 25, 则现金 NOI 为 50. 暂取与这些物业条件相容的资本化率 5%, 估计物业价值为

$$\text{NOI}_1 = 80 - 5 - 25 = 50, \quad V_0^{\text{property}} = \frac{50}{0.05} = 1000.$$

假设公司另有额外现金 40, 债务 400, 并需立即支付 20 补足一项欠修工程. 这笔特殊支出尚未包含在上述 NOI, 资本化率所比较的物业条件或其他负债中. 无其他待计入的资产, 总部现金负担和请求权, 稀释股数 20, 则

$$\text{NAV}_0 = 1000 + 40 - 400 - 20 = 620, \quad \text{NAVPS}_0 = 620/20 = 31.$$

这里先重估物业, 再得到普通股净资产价值, 并未把财报中的历史成本净资产直接当成市场价值. 特殊工程 20 只扣一次, 如果所采用的物业价值已经按欠修情况打过折, 就应相应调整计算.

NOI 通常还不是全部可分配现金. 维护更新, 租户装修和租赁佣金等资本支出, 要在完整物业估值中得到处理. 直接资本化时, 可比物业的价格及资本化率可能已经反映通常的后续支出, 不再为同一成本另扣完整现值; 使用逐年 DCF 时, 则要明确列出这些现金支出. 开发期, 大量租约集中到期或空置率将明显变化的物业, 更需要逐年预测, 不能直接把某一年的收入永久资本化.

REIT 分析还会使用 FFO (funds from operations) 和 AFFO (adjusted funds from operations) 比较经营表现及相应倍数. 使用这些经调整指标前, 仍须核对具体加减项, 尤其是持续维护和租赁投入是否已扣. 一个高于会计净利润的调整数字, 并不因此全部成为股东能够提走的现金.

怎样理解不同方法的结果 以上方法分别从经营现金, 盈利, 分部业务, 银行资本和物业收入出发, 最后都要算到股东所得. 结果不一致时, 先核对各自在估哪一年的价值, 使用哪一年的盈利, 是否都已处理债务和稀释, 再比较长期增长与资本需求的假设. 这样才能找到差异的来源, 决定主要依据哪一种方法.

下一节第 7.3 节将同一套估值计算用于不同经营情景. 比如销量比预期高或低, 竞争更强或更弱, 分别会得到怎样的盈利, 股价和投资回报.

7.3 Risk-Reward 框架与情景分析

第 7.1 节已经从经营现金, 盈利, 资产和资本要求算到了每股价值. 但未来未必只沿一条路径发展. Risk-Reward 因此把几种主要可能分别列出来: 先写清各自的经营条件, 用前面的估值方法算出结果, 再比较在同一买入价下各自能赚多少或亏多少.

本节以买入并持有一股普通股为例. 当前价格记为 $S_0 > 0$, 共同研究期限为 T , 情景 s 在该期限的代表价格记为 $S_s(T)$. 若持有期间还有股息等现金, 后面再加入总收益. Morgan Stanley 的一些公开材料也采用上行, 中心和下行情景并列的 Risk-Reward 展示 [Mor22].

为什么一个目标价不够 若只给 Base 价格, 价格收益为

$$\frac{S_{\text{Base}}(T) - S_0}{S_0}.$$

它只说明中心经营判断成立时会发生什么. 例如下面两家公司现价都为 100, Base 也都为 120:

	Bull Case	Base Case	Bear Case
A	160	120	90
B	130	120	50

两者的 Base 上涨空间都是 20%, 但 A 在所列情景中有更大的上行和较小的下行, B 的 Bear 损失则明显更大. 要说明这项差别, 就必须把端点背后的经营条件写出来.

定义 7.1 (Scenario).

一个情景 (Scenario) 是一组能够共同成立的经营, 财务和市场定价假设. 对指定期限 T , 先按这一组假设推算业务活动, 盈利或现金流, 再用已经选定的估值方法算出该情景的代表价格 $S_s(T)$.

Base Case 采用当前证据最支持的中心经营路径. Bull Case 明确哪些有利变化会带来明显上行, Bear Case 则明确哪些不利变化会造成主要下行. 为了直接比较价格, 三种情景采用相同的持有人权利和期限.

情景是对复杂未来的离散近似 一条真实未来路径可以同时包含需求, 价格, 竞争, 利率, 资本投入和估值倍数的变化. 情景分析把这些路径按最重要的经济差别分组, 再用少数代表结果近似.

设 A_s 表示第 s 类未来路径, 各类彼此不交并覆盖当前采用的近似模型. 若进一步给每类真实世界主观概率 p_s , 则

$$p_s = \mathbb{P}(A_s) \geq 0, \quad \sum_s p_s = 1.$$

可以只列条件情景而暂时不给概率; 一旦要计算概率加权结果, 分类就应先组成这样的分割.

在每个 A_s 内选代表价格 $S_s(T)$, 相当于用简单随机变量

$$\tilde{S}_T = \sum_s S_s(T) \mathbf{1}_{A_s}$$

近似真实终价. 因而

$$\mathbb{E}[\tilde{S}_T] = \sum_s p_s S_s(T).$$

若代表价格本身取为 $\mathbb{E}[S_T | A_s]$, 这个加权平均恰好保留 $\mathbb{E}[S_T]$; 若代表价只是研究者选取的典型值, 上式计算的就是这份离散近似的期望. Base 只是其中一类的代表值, 不等于概率加权后的期望; Bear 也只是所列的一种不利情景, 不等于数学上的价格下界.

从经营驱动算到情景价格 设定不同情景时, 先说明销量, 单价或成本会怎样变化, 再据此计算财务结果. 经营驱动分析 (Driver Tree) 就是逐步算清楚: 公司卖出多少, 每单位取得多少收入, 为此付出多少成本和资本, 最后形成多少盈利与现金.

支付网络例如可以从支付金额, 交易笔数, 跨境占比, 收费率和客户激励开始. 若支付金额增加, 但客户激励增长使净收入率下降, 收入未必同步增加. 先将数量和净收费率的变化算入收入, 再处理费用与利润, 就得到这一情景的 EPS 或 FCFF.

上一节已经说明怎样从这些结果选择 DCF, P/E, SOTP 或其他适用方法. 在 Risk-Reward 中沿用同一方法, 只把真正随情景变化的输入改掉. 例如用未来 P/E 表示普通股价格时,

$$S_s(T) = \text{EPS}_s(T) \times M_s.$$

其中 $\text{EPS}_s(T)$ 来自该情景的经营和资本路径, M_s 则表示在同一期限上对这项盈利采用的市场倍数. 需求转弱可以先压低 EPS; 若增长持续期和资本回报也明显变差, 再根据这些条件调整倍数. 这样就能看出价格变化分别来自盈利和资本化水平的哪一部分.

端点偏斜与概率加权 R/D 先沿用一单位现货多头的简单策略: 买入价格 $S_0 > 0$, 期限共同为 T , 暂不计费用, 融资和期间现金分配. 对一般策略 h , 则先按实际持仓和现金流算出从 0 到 T 的净损益, 记为 $\Pi_{0:T}^{\text{financial}}(h)$; 再除以有经济含义的资本基数 K_0^h , 得到各情景回报, 再作下面的比较.

只看 Bull 和 Bear 两个端点, 可以计算上行空间

$$U_{\text{Bull}} = \frac{S_{\text{Bull}}(T) - S_0}{S_0},$$

以及下行幅度

$$L_{\text{Bear}} = \frac{S_0 - S_{\text{Bear}}(T)}{S_0}.$$

当 $L_{\text{Bear}} > 0$ 时, 比例 $U_{\text{Bull}}/L_{\text{Bear}}$ 比较了选定端点的潜在盈利和亏损. 它没有使用概率, 也没有计入中心情景. 因而比例相同的两项投资, 仍可能有完全不同的预期结果. 这是本文用于讨论情景形状指标, 并非声称 Morgan Stanley 的页面都采用这一固定公式.

若进一步接受各情景的主观概率 p_s , 令

$$\rho_s = \frac{S_s(T) - S_0}{S_0},$$

并把正收益与负收益分别按概率加权:

$$R_{\mathbb{P}} = \sum_s p_s (\rho_s)^+, \quad D_{\mathbb{P}} = \sum_s p_s (-\rho_s)^+.$$

这里 $x^+ = \max(x, 0)$. $R_{\mathbb{P}}$ 累计盈利情景对平均回报的贡献, $D_{\mathbb{P}}$ 把亏损幅度取正后累计. 一个叫作 Base 的情景若仍然盈利, 也要计入 $R_{\mathbb{P}}$; 分类依据是收益的正负, 不只是 Bull 或 Bear 的名称.

这份情景近似给出的期限内金融期望收益率为

$$\mu_{\text{fin}, T} = \sum_s p_s \rho_s = R_{\mathbb{P}} - D_{\mathbb{P}}.$$

$D_{\mathbb{P}}$ 是概率加权的亏损幅度, 不是最大可能亏损, 也不是亏损发生时的条件平均损失. 这些量回答不同问题, 不能互相替代.

计算结果取决于所用输入, 因而还要判断: 哪些经营证据支持各情景, 代表价格为什么合理, 主观概率又依据什么. 当前买入价也同样重要. 再好的公司, 如果市场价格已经接近 Bull 情景, 从当前价格继续持有的上行空间也可能不大; 一家公司即使经营普通, 若现价已经反映很悲观的假设, 从这个价格出发的回报结构反而可能更有利.

因此, 经营前景相同的公司, 买入价格越高, 留给投资者的回报就越少. 下面固定同一个买入价, 分别计算各情景的盈利和亏损, 再看概率加权后的结果.

一个虚构的三情景例子 设一家虚构公司的现价为 $S_0 = 100$, 研究期限为一年. 暂不计期间现金分配和费用, 并假设一年后市场会按各情景对应的市盈率给预测盈利定价. 这项假设使每股盈利乘以倍数的结果可以在本例中用作代表性终价.

情景	p_s	EPS_s	M_s	核心假设
Bull	0.25	12	13	需求强于预期, 利润率扩张, 市场愿意给更高倍数.
Base	0.50	10	12	经营大致符合中心判断, 估值倍数保持正常.
Bear	0.25	7	10	需求转弱, 经营杠杆反向作用, 估值倍数压缩.

先在每一行情景内计算终价, 不急于把情景混合:

$$S_{\text{Bull}}(T) = 12 \times 13 = 156, \quad S_{\text{Base}}(T) = 10 \times 12 = 120, \quad S_{\text{Bear}}(T) = 7 \times 10 = 70.$$

由现价 100 出发, 选定端点的上行和下行分别为

$$U_{\text{Bull}} = \frac{156 - 100}{100} = 56\%, \quad L_{\text{Bear}} = \frac{100 - 70}{100} = 30\%.$$

二者之比为

$$\frac{U_{\text{Bull}}}{L_{\text{Bear}}} \approx 1.87.$$

到这里尚未使用表中的概率. 这个比例只比较 Bull 的 56% 盈利与 Bear 的 30% 亏损, 没有计算平均收益.

再接受表中的主观概率. 三个情景收益率依次为 56%, 20% 和 -30%. Bull 和 Base 都盈利, 因而概率加权上行为

$$R_{\mathbb{P}} = 0.25 \times 56\% + 0.50 \times 20\% = 24\%.$$

只有 Bear 亏损, 所以

$$D_{\mathbb{P}} = 0.25 \times 30\% = 7.5\%.$$

相减得到一年内的情景加权期望收益率:

$$\mu_{\text{fin}, T} = R_{\mathbb{P}} - D_{\mathbb{P}} = 16.5\%.$$

中心情景的收益是 20%, 加权期望却是 16.5%, 这直接说明 Base 不能替代期望. 同样, 7.5% 是亏损对平均回报的贡献, 不是说进入 Bear 时只亏 7.5%; 该情景的亏损仍是 30%.

按给定参数, 上面的回报已经算出. 实际研究还要说明这些输入的依据: 哪些经营条件支持 EPS 取 12, 10 或 7, 什么增长与资本回报支持 13, 12 或 10 倍, 以及什么证据支持 0.25, 0.50, 0.25 的主观概率. 改动其中一项以后, 可以沿相同公式立即看见它怎样改变加权结果.

期权隐含概率与真实世界情景概率 期权价格还提供另一种关于未来终价的信息. 在适用的无套利模型中, 若利率为确定常数且支付满足相应可积条件, 欧式看涨期权价格为

$$C_0(K, T) = e^{-rT} \mathbb{E}_{\mathbb{Q}} [(S_T - K)^+].$$

这里的 $\mathbb{Q}$ 是定价使用的风险中性测度. 在足够光滑的理想条件下, 期权价格随行权价的变化还能恢复风险中性终价密度; Breeden-Litzenberger 关系给出了经典表达 [BL78; Hul22].

Risk-Reward 中的 p_s 表示研究者在真实世界测度 $\mathbb{P}$ 下对各经营情景发生概率的判断. 定价测度 $\mathbb{Q}$ 则重新给不同结果分配权重, 使资产价格能够写成折现期望; 这些权重还反映市场对风险状态的定价. 因而两种概率可以拿来比较, 但定义和用途不同, 不能把一个数直接当成另一个使用.

此外, 期权按终价和行权价划分支付, 基本面情景则按需求, 竞争, 产品和盈利条件组织. 要利用期权信息, 可以先把某些终价范围与基本面情景联系起来, 再比较市场定价所隐含的分布与自己的经营判断. 分歧由此可以落到未来盈利, 波动或尾部定价的具体位置.

为什么还需要保存研究来由 Risk-Reward 把经营假设压缩成少数情景价格与概率. 新财报或竞争消息到来以后, 还要知道原来的 EPS, 倍数和概率分别依据什么, 才能判断应修改哪一项. 下一节的 Agentic R-D-G 专门保存这条证据到经营驱动, 再到估值和情景结果的关系.

7.4 Agentic R/D Graph: 把研究判断组织成可更新的图

第7.3节最终得到一组经营条件, 情景价格以及必要时的概率. 如果只保存这些最终数字, 以后很难追查某个数字为什么改变. Agentic R-D-G 因此还保存数字之间的推理关系: 新资料先改变哪项经营驱动, 这项变化怎样进入财务预测, 又怎样继续影响估值和情景结果.

先看支付平台的一次证据更新 假设研究者原来用支付金额 100 和扣除客户激励后的净收入率 2% 估计收入:

$$100 \times 2\% = 2.$$

后来支付金额升到 110. 若其他条件不变, 收入会升到

$$110 \times 2\% = 2.2.$$

随后公司披露客户激励增加, 净收入率降为 1.8%. 此时应把已经更新的支付金额 110 保留下来, 只替换净收入率, 重新计算

$$110 \times 1.8\% = 1.98.$$

所以业务量确实增长, 但更低的净收入率把这项增长抵消掉了. 正确更新不是把整条研究结论一起撤回, 而是保留仍成立的 110, 修改已经失效的 2%, 再沿原来的收入关系重算.

新信息	直接改变什么	随后怎样计算
支付金额增至 110	支付量假设	与当时净收入率相乘, 重算收入
客户激励使净收入率降至 1.8%	净收入率假设	保留支付量 110, 得到收入 1.98, 再向利润传导
监管讨论升温但尚无具体条款	增加一个待核实事件	等条款, 业务范围和生效时间明确后再连接经营驱动

收入下修以后, 沿原来的费用和利润预测继续算下去, 就能得到新的 EPS 与情景价格.

从一次计算扩展成研究图 如果只保存收入 1.98, 以后就看不出这个数同时使用了支付金额 110 和净收入率 1.8%. 因而研究图至少要把原始证据, 经营驱动, 财务结果和估值判断分别留下, 再说明它们之间为什么相连.

定义 7.2 (Agentic R-D-G).

本笔记把这种研究组织方式称为 **Agentic R-D-G**, 也写作 Agentic R/D Graph. R 表示潜在回报, D 表示潜在下行, G 表示研究图. 图将证据, 事件, 经营驱动, 财务预测, 估值和情景联系起来, 并保留资料的时间与适用范围. Agent 用于协助检索, 更新和复查这些关系.

图中的不同内容承担不同作用:

内容	支付平台例子	连接到下一步时要说明什么
证据	财报披露支付金额 110, 客户激励上升	来源, 日期以及直接观察到的事实
经营驱动	支付金额 110, 净收入率 1.8%	哪项证据改变哪一个输入, 何时生效
财务预测	净收入 1.98, 随后的成本与利润	驱动怎样通过公式或业务机制传到财务结果
估值与情景	EPS, FCF, 倍数, Bull/Base/Bear 价格	财务变化怎样改变价值, 哪个情景受到影响
概率判断	各情景的主观概率	为什么新资料改变了发生可能性, 而不只是情景内的金额

连线因而不是简单的相关标记. “客户激励增加 → 净收入率下降” 要说明费用怎样进入合同或收入确认; “净收入率下降 → 收入减少” 则由当前计算式直接支持. 若一项关系有时滞或只影响某个业务, 也应记录这些条件. 新资料若推翻一条关系, 就继续检查依赖这条关系的预测, 找出需要重算的结果.

这与随机过程中的信息时间顺序相同. 研究者在 2026 年作出的预测只能依据当时已经取得的资料. 后来出现的事实可以用来检验和更新旧判断, 不能倒过来放进旧预测, 再把修订后的结果当成当时已经知道的结论.

公司事件, 预测市场与跨公司联系 对单家公司, 研究图首先回答一个实际问题: 某项事件怎样传到这家公司的经营结果? 例如竞争者降价, 可能使目标公司跟随降价, 也可能提高客户激励或造成份额流失. 要沿具体业务机制找到首先变化的量, 再向收入, 成本和资本投入传导.

在预测市场中, 可以观察一份具体事件合约的当前价格. 使用 Polymarket 或 Kalshi 等资料时, 先读清具体结算事件和期限. 如果这份合约直接对应研究中的外部事件, 它可以用来观察市场怎样给该事件定价; 至于事件最终怎样改变公司的销量, 成本和盈利, 仍要根据公司的实际暴露和应对方式继续分析.

跨公司研究时, 可以把受到同一个外部因素影响的公司放在一起看. 例如几家企业都依赖 AI 资本开支时, 同一客户削减预算可能同时减少它们的订单; 多家公司都依赖短期融资时, 融资成本上升也可能同时挤压现金流. 这些共同暴露会使表面上分散的持仓在同一环境下同时受损, 因而形成组合中的集中风险.

同一事件对不同公司的作用不必相同. 一个供应商可能因原材料涨价受损, 另一个上游生产商却获益; 同一政策也可能只覆盖某些地区和产品. 记录跨公司联系时, 因而要分别说明同一事件怎样影响每家公司的收入和成本.

新证据怎样更新情景 一次更新可以有三种不同结果. 第一种是改变情景内部的经营数值, 如净收入率从 2% 降到 1.8%. 第二种是改变不同情景的主观概率, 例如新的合同数据使竞争恶化路径明显更常见. 第三种是只增加一个待回答的问题, 如监管草案尚未说明适用范围.

更新时先处理第一处真正变化的经营量. 降价先进入单价, 客户流失先进入数量, 新工厂先进入资本开支和未来产能. 再计算它如何改变收入, 利润和现金. 若同一证据还能改变情景概率, 则单独写出这一步的理由, 不把盈利下修幅度直接当成概率变化幅度.

原则 7.3 (先解释变化, 再修改数字).

调整预测时, 写清新证据改变了哪项假设, 影响通过什么经营活动发生, 何时开始, 持续多久, 以及哪些事实会使这项解释不再成立. 能说明方向而暂时不能估计幅度时, 就保留这个差别, 不为使模型完整而随意填数.

将这些理由与计算一起保存, 以后就能从变化后的估值追溯到最初改变的那项假设.

把估值与回报留下可复算的输入 一次研究至少要分别保存两类会随时间更新的信息. 第一类是经营与估值假设, 例如支付金额 110, 净收入率 1.8%, 各情景的 EPS 和倍数. 第二类是用于比较的当前市场价格以及各笔现金流发生的日期. 新财报可能改变第一类; 如果只有市场价格变化, 公司经营判断可以保持不变, 只需用新价格重算当前回报.

对每个情景保存期限 T , 代表价格 $S_s(T)$, 经营假设, 期间现金分配与成本以及主要证据; 计算加权回报时, 再保存所用的概率. 当前买入价另记录时间和来源. 以后结果变化时, 可以分清究竟是公司经营变了, 估值假设变了, 还是仅仅买入价格变了.

沿用一单位现货多头, 以正的 S_0 为资本基数. 情景 s 的价格收益率为

$$r_s = \frac{S_s(T) - S_0}{S_0}.$$

若持有期间还有净现金收益率 c_s , 例如股息减去相应持有成本, 则总情景金融收益率为

$$\rho_s = r_s + c_s.$$

c_s 与 r_s 使用同一货币, 期限和资本基数. 已经进入终值或其他现金账的同一笔现金不再加入一次.

给定互不重叠且覆盖所用近似的情景概率 p_s , 概率加权上行和原始金融下行为

$$R_{\text{fin},T} = \sum_s p_s(\rho_s)^+, \quad D_{\text{raw},T} = \sum_s p_s(-\rho_s)^+.$$

这里先在每个情景内将价格变化和净现金合成完整收益, 再按正负拆分, 所以同一情景中的股息和价格损失不会被当成两个独立结果.

有时还要研究亏损为什么发生. 若有证据将情景 s 的亏损分成暂时性与较难恢复的部分, 取

$$\lambda_{s,\text{temp}} \geq 0, \quad \lambda_{s,\text{perm}} \geq 0, \quad \lambda_{s,\text{temp}} + \lambda_{s,\text{perm}} = 1.$$

则

$$D_{\text{temp},T} = \sum_s p_s (-\rho_s)^+ \lambda_{s,\text{temp}}, \quad D_{\text{perm},T} = \sum_s p_s (-\rho_s)^+ \lambda_{s,\text{perm}}.$$

二者只是对同一期限 T 下原亏损的分类, 因而始终满足

$$D_{\text{temp},T} + D_{\text{perm},T} = D_{\text{raw},T}.$$

分类本身不会把 T 时刻已经发生的亏损变小. 若还要研究以后是否恢复, 就另设 $T' > T$, 将恢复时点, 后续现金和融资条件放进新的期限计算.

期限 T 的金融期望收益率为

$$\mu_{\text{fin},T} = R_{\text{fin},T} - D_{\text{raw},T} = \sum_s p_s \rho_s.$$

当 $D_{\text{raw},T} > 0$ 时, 本节使用

$$R/D_{\text{fin},T} = \frac{R_{\text{fin},T}}{D_{\text{raw},T}}$$

比较这组离散情景中的概率加权盈利和亏损. 若所列情景全部不亏, 分母为零, 这个比率在当前定义下记为不可计算; 其他收益和情景结果仍照常列出.

同一项经济影响只进入一次 研究图还有一个实际用途: 看清某项成本已经在哪个计算位置出现. 支付平台的客户激励若已经通过更低的净收入率减少收入, 就不能又把同一金额作为独立费用再扣一次. 相反, 一项技术既增加收入又需要额外算力成本时, 这是真实的两条经济后果, 应分别计算.

多份资料也可能只是支持同一个事实. 三份行业报告都引用同一次原材料涨价, 可以提高对涨价事实的把握, 却不会把一份成本变成三份成本. 若同一新证据既改变某情景的盈利, 又让该情景更可能发生, 则分别写清盈利幅度和概率判断各自的推理, 再进入上面的计算.

Agent 怎样帮助维护研究 公司和资料增多以后, 最费力的往往是找到旧结论用了哪项证据, 新资料影响哪些下游判断. Agent 可以检索原始来源, 比较新旧披露, 沿研究图找出依赖同一假设的收入, EPS, FCF 和情景价格, 并重算已经明确的算术.

判断本身仍回到经济关系. 新需求数据是否改变业务量, 新监管条款影响价格还是准入, 某项研发失败是否只影响一个项目还是共同技术平台, 都要根据内容判断. 若一条旧关系被推翻, 更新时还要撤销此前由它产生的下游调整, 而不只是从今天起停止继续传播.

实际更新一项研究时, 可以按这个顺序处理: 先保存新资料及日期, 判断它直接说明了什么事件, 找到最先受影响的经营变量, 重算财务结果, 再更新估值和情景. 同时保留所用输入, 公式和证据, 这样以后回看时, 既能解释支付平台收入为什么从 2.2 改成 1.98, 也能看出支付金额从 100 增到 110 这一事实仍然成立.

读者可以从一项估值沿连线回到经营驱动和证据, 也可以从一条新消息向后找到需要重算的结果. 这样, 新信息到来时只修改真正失效的部分, 保留仍然成立的证据和计算.

第八章 趋势交易与技术指标：从路径变换到可交易策略

趋势规则先用历史价格计算指标，再规定看到什么信号时怎样调整下一段持仓。例如价格高于均线时，可以在下一交易时点立即买入，也可以等到价格高出均线达到某个阈值才进场。两种规则使用同一条均线，交易结果却会不同。

本章沿用第五章中的交易时钟：先取得当时可用的数据，计算指标和目标持仓；订单成交以后，实际持仓才开始承担后续价格变化。因而比较趋势规则时，指标公式，成交时点，持仓数量和成本要放在同一计算中。

SMA 和 EMA 用不同权重平滑历史价格，MACD 比较两个指数平滑尺度，Bollinger Bands 和 ATR 提供价格变化的尺度，RSI 比较近期上涨与下跌幅度，VWAP 则按成交量汇总实际成交价格。后文先逐项定义这些量，再用两组完整现金账户比较不同进出场规则。

8.1 从指标到账本

图8.1把整套研究分成两部分。前半段从价格记录得到指标，信号和目标持仓，再通过订单成交形成实际交易；后半段用真实持仓和成本计算损益，最后把已经固定的规则放到样本外数据中检验。




图 8.1: 趋势交易的一条最小阅读路线。

在进入指标公式以前，先把几个常被混在一起的问题分开：一段历史价格是否呈现趋势，过去是否真的改变未来收益分布，以及把这种关系变成交易以后能否留下净收益。

8.2 历史走势，预测关系与交易结果

假设某指数六个月上涨了 12%。这首先是对已经实现路径的描述：在这六个月中，价格总体向上。本章把这种已经观察到的形状称为**路径趋势**。

若进一步研究过去是否包含下一期信息，问题就变成**统计依赖**：给定截至今日的历史以后，下一期收益的条件分布是否发生变化。例如 AR(1) 模型会明确给出这种条件均值变化，独立增量随机游走则不会。

还可以用**潜在状态**解释这种依赖。一个未直接观察到的状态可能同时影响漂移，波动率或流动性，历史数据帮助我们更新对当前状态的判断。这里的状态是模型中的变量，要通过相应的转移规律和观测分布进入预测。

即使历史数据真的含有预测信息，也还没有得到交易结果。指标形成信号以后，还要把信号转换成具体持仓，让订单实际成交，再扣除交易和融资成本，才得到**策略净收益**。因而从“这段历史看起来在上涨”到“这一规则值得交易”，中间还隔着预测，持仓和实际现金收支三层计算。

下面先固定真实交易时钟，这样后面的每一种指标都能在同一时间顺序下使用。

8.3 离散交易时钟，信息集与可预测持仓

先定义所使用的价格记录 取决策时点 $t = 0, 1, \dots, T$ ，用 S_t 表示当时已经取得的指定价格记录， V_t 表示同步可得的成交量。先固定它们来自哪里，按什么单位计量，再计算指标。收盘价，最新成交价和中间价可以分别作为输入，但不必等于整笔订单能够成交的价格。

日线数据尤其要说明是否调整拆股和现金分配。原始收盘价，拆股调整价和包含分配再投资的总回报序列，计算出的均线和收益不一定相同。跨市场使用数据时，日期也必须按交易日历与时区理解，不能把不同地方的同名日期当成同一信息时点。

图8.2展示了单位变化的影响. 将 AAPL 在 2020 年 4:1 拆分前后的名义报价直接拼接, 会出现约 75% 的下降. 这主要是每股单位改变, 并非股东财富发生同样损失. 20 日均线却会把这个断点当作价格变化, 直到旧观测逐渐移出窗口. 拆分调整消除了这一问题, 股息和总回报的处理仍须另外说明.




图 8.2: AAPL 2020 年 4:1 拆分前后的价格序列与 20 日 SMA. 灰色为按拆分比例复原的当时名义报价, 蓝色为拆分调整后的收盘价. 数据与拆分事件来源见引用文献 [Yaha].

期货还有合约换月带来的价格拼接问题. 合成连续序列可以用于计算信号, 实际盈亏却要回到当时持有的具体合约与换月成交, 详见第8.12.1小节.

若相关价格均严格为正, 定义

$$X_t = \log S_t, \quad \ell_t = X_t - X_{t-1} = \log \frac{S_t}{S_{t-1}}.$$

S_t 是价格, X_t 是对数价格, ℓ_t 是对数价格变化. 它们适合不同计算, 不统一简称为收益率. 后文的 r_t 则按具体问题表示简单收益, 总收益或超额收益. 多资产收益按资金权重相加时, 使用相应的简单收益, 不把对数变化当成可以精确加权的组合收益.

若窗口内报价达到零或变成负数, 上述对数就不可用. 可以按合约乘数计算价格差的货币损益, 或以明确资本基数定义收益. 给整条报价任意加一个常数虽然能使数值为正, 却会改变价格比率及信号, 不能据此修复经济计算.

指标, 决策与成交的时间顺序 令 $\mathcal{F}_t$ 包含截至时刻 t 已经取得的信息. 若指标由这些数据计算,

$$I_t = f_t(S_0, V_0, \dots, S_t, V_t),$$

则 I_t 为 $\mathcal{F}_t$ -可测. 用它决定下一段目标持仓时, 可以写成

$$q_{t+1}^* = g_t(I_0, \dots, I_t), \quad q_{t+1}^* \text{ 是 } \mathcal{F}_t\text{-可测的}.$$

因此目标持仓在下一段价格变化发生以前已经确定, 与第5.2节中的可预测持仓相同.

目标持仓是交易决定, 实际持仓则由成交回报确定. 若订单在 $t+1$ 才成交, 就用成交价 P_{t+1}^{exec} 和实际成交数量更新 q_{t+1} , 新持仓从这个成交以后开始承担价格变化.

例 8.1 (收盘信号怎样用于下一次交易).

若 S_t 只有正式收盘后才完整可得, 就在收盘后计算 I_t , 再于下一交易日开盘或更晚时点执行. 若策略使用收盘集合竞价成交, 则指标只能使用订单截止时间以前已经取得的数据.

另一种规则可以直接用 I_{t-1} 安排第 t 日交易. 两种时钟对应两套不同成交价格, 回测时分别计算即可.

止损也使用相同顺序. 首次满足触发条件的时刻可以作为停时; 触发以后再提交退出订单. 若随后跳空或缺少买单, 最终卖价就由实际成交决定, 而不是由触发阈值决定.

策略收益的条件期望恒等式 设 r_{t+1} 是已明确含义的下一期简单收益, 总收益或超额收益, H_t 是事前确定的无量纲权重, 为 $\mathcal{F}_t$ -可测. 假设 H_t , r_{t+1} 和乘积 $H_t r_{t+1}$ 均可积. 先在当前信息下取条件期望, 再取期望, 得到

$$\mathbb{E}_{\mathbb{P}}[H_t r_{t+1}] = \mathbb{E}_{\mathbb{P}}[H_t \mathbb{E}_{\mathbb{P}}(r_{t+1} | \mathcal{F}_t)]. \quad (8.1)$$

因为 H_t 已在 $\mathcal{F}_t$ 中确定, 可以从内层条件期望提出; 再使用塔性质, 就得到式 (8.1). 因而可预测持仓的平均毛收益由两部分共同决定: 下一期条件均值怎样变化, 以及规则在这些状态下持有多少.

例如若

$$r_{t+1} = \mu + \varepsilon_{t+1}, \quad \mathbb{E}_{\mathbb{P}}(\varepsilon_{t+1} | \mathcal{F}_t) = 0,$$

则

$$\mathbb{E}_{\mathbb{P}}[H_t r_{t+1}] = \mu \mathbb{E}_{\mathbb{P}}[H_t].$$

历史信息没有改变噪声项的条件均值时, 策略仍可能因为平均保持多头而取得正的平均毛收益. 因而检验择时贡献时, 可以将它与具有相近平均方向暴露的常数持仓或买入持有基准比较.

8.4 滤波的统一语言: 平滑, 时滞与尺度

要把上面的可预测权重 H_t 具体写成交易规则, 常见的第一步是先处理截至当前的历史观测. 本节把按一定规则重新组合历史观测统称为滤波. 以下以 Y_t 表示输入, 可以取价格, 对数价格, 收益或成交量, 但每次计算都要固定所用序列.

平滑把权重分散到当前值和过去多个观测上, 所以单个最新观测对结果的影响会变小, 曲线通常也少一些短期起伏. 随着新数据进入, 旧观测逐步移出窗口, 或在平均值中所占权重逐渐降低, 因此平滑曲线的转向往往晚于原始数据. 差分强调变化, 标准化则改变比较尺度. 这些操作的效果可以直接从权重和公式看出, 不必先赋予它们预测含义.

简单移动平均 长度为 n 的简单移动平均 (simple moving average, SMA) 为

$$M_t^{(n)} = \frac{1}{n} \sum_{j=0}^{n-1} Y_{t-j}, \quad t \geq n-1.$$

这里明确包含当前观测, 对最近 n 个值等权平均. 一个值超过窗口以后, 权重立即归零. 前 $n-1$ 个时点若没有足够历史, 可以暂不输出; 若改用短窗口, 得到的是另一种启动方式.

对线性路径 $Y_t = a + bt$, 均线可以精确算成

$$M_t^{(n)} = a + b \left(t - \frac{n-1}{2} \right).$$

因此当前值与均线之差恰为 $b(n-1)/2$, 相当于在这条线性路径上落后 $(n-1)/2$ 期. 这个平均年龄来自窗口内 $0, 1, \dots, n-1$ 的均值.

实际路径并非直线, 不会总有一个固定的转向延迟. 但同样的权重原理仍在起作用: 窗口更长, 更多旧观测参与平均, 一次新变化对均线的影响就更小.

指数移动平均, 半衰期和有效窗口 取 $0 < \alpha \leq 1$, 指数移动平均 (exponential moving average, EMA) 为

$$E_t^{(\alpha)} = \alpha Y_t + (1 - \alpha) E_{t-1}^{(\alpha)}.$$

当前观测的权重为 α , 上一期 EMA 整体的权重为 $1 - \alpha$. 继续递推展开可得

$$E_t^{(\alpha)} = \alpha \sum_{j=0}^{t-1} (1 - \alpha)^j Y_{t-j} + (1 - \alpha)^t E_0^{(\alpha)}.$$

因此旧观测不会在某一日突然退出, 而是逐期衰减. 在无限历史表示下, 年龄 j 的权重为 $\alpha(1 - \alpha)^j$. 常用跨度 n 对应

$$\alpha = \frac{2}{n + 1},$$

Wilder 平滑则使用 $\alpha = 1/n$. 报告一个 n 以前, 应先说明采用哪种关系.

对 $0 < \alpha < 1$, 权重减为一半所需的年龄为

$$h_{1/2} = \frac{\log(1/2)}{\log(1 - \alpha)}.$$

它可以不是整数. 当 $\alpha = 1$ 时, $E_t = Y_t$, 已经没有历史记忆, 不再代入含 $\log(1 - \alpha)$ 的公式.

无限历史权重的平均年龄为 $(1 - \alpha)/\alpha$. 令它等于 SMA 的 $(n - 1)/2$, 得到

$$n_{\text{eff}} = \frac{2 - \alpha}{\alpha} = \frac{2}{\alpha} - 1.$$

同一个结果也可由方差等价得到: 对独立同方差观测, EMA 权重平方和为 $\alpha/(2 - \alpha)$, SMA 则为 $1/n$. 这解释了常用跨度公式, 也说明两者即使当前权重不同, 仍可具有相同的平均年龄和这项噪声方差. 有限样本的初始化影响尚未消退时, 这种比较只是近似.

初始化同样属于定义. 可以取 $E_0 = Y_0$, 或在已经取得前 n 个值以后用它们的均值开始递推, 也可以使用归一化权重. 第二种方法不能在那些观测尚未出现时提前生成指标. 回测应说明预热期和初始化, 因为初始值的影响会按 $(1 - \alpha)^t$ 保留下来.

图8.3在同一段 SPY 价格上比较 20 日 SMA 与跨度 20 的 EMA. 两者都混合了新旧价格, 转向只能随着新观测进入而逐步显现.

EMA 的当期权重更大, 但也保留了更长的衰减尾部; SMA 则在窗口边缘直接移除旧值. 因此, 两条线面对一次跳变和持续变化时可以有不同反应, 不能一概说同跨度 EMA 在每次转向都更早, 或在所有尺度上都保留更多噪声.

下图是价格减去各自滤波值的差, 正值表示价格在相应均线上方. 纵轴仍为价格差, 时间上的滞后要沿上图的时间轴观察.




图 8.3: SPY 在 2021-01-04–2022-12-30 的拆分与现金分配调整收盘价, 20 日 SMA 和跨度为 20 的 EMA. 黑色为价格, 蓝色为 SMA, 暖橙色虚线为 EMA; 下图给出价格与两种滤波值之差, 零线以上表示价格高于相应滤波值. 数据来源见引用文献 [Yahb; Yahc].

价格水平, 收益口径与稳定性 价格均线与原价格使用相同单位. 资产价格为 10 和 1000 时, 同样偏离均线 \$1 所代表的相对幅度显然不同. 因而若要跨价格尺度比较, 可以在 $M_t^{(n)} \neq 0$ 时计算

$$d_t = \frac{S_t - M_t^{(n)}}{M_t^{(n)}}.$$

也可以在价格严格为正时使用对数差, 或直接研究定义清楚的收益序列.

这些选择改变了问题. 相对距离比较百分比偏离, 收益研究相邻时点的增长, 绝对距离则仍适合某些按价格单位规定的交易规则. 无论选哪一种, 都还可能出现时变波动, 跳跃和历史依赖. 换成收益不会自行保证平稳, 需要根据后续计算使用的假设检验.

8.5 从滤波器到趋势规则

滤波器算出的是历史数据的概括. 规则还要决定怎样比较这个数, 以及比较后持有多少. 下面先列出几种方向信号, 具体的多空范围, 等号处理和成交时点将在完整例子中规定.

价格—均线规则 价格高于或低于其 SMA, 可以写成信号

$$z_t^{\text{PM}} = \text{sign}(S_t - M_t^{(n)}).$$

这里取通常的 $\text{sign}(0) = 0$. 再用 $q_{t+1}^* = g(z_t^{\text{PM}})$ 决定目标数量. 同一个负信号可以被解释为卖空, 减仓或空仓, 取决于 g 的定义. 均线若包含当前值, 当前变化也会同时推动均线, 因而比较的是包含这一更新后的距离.

快慢均线交叉 取 $\alpha_f > \alpha_s$, 快线给当前观测更大权重. 比较两条 EMA 可得

$$z_t^{\text{cross}} = \text{sign}(E_t^{(\alpha_f)} - E_t^{(\alpha_s)}).$$

两个平均都削弱部分较快变化, 相减以后强调它们对不同时间尺度的反应差异. 由于输入相同, 两条线不能当作两份独立证据; 同一个价格冲击会同时进入两者, 只是权重不同.

时间序列动量 对严格为正的价格, 可以直接比较现在与 k 期以前:

$$m_t^{(k)} = X_t - X_{t-k} = \log \frac{S_t}{S_{t-k}}, \quad z_t^{\text{mom}} = \text{sign}(m_t^{(k)}).$$

这等于窗口内对数变化的累计. 报价不适合取对数时, 应使用相应合约的算术损益或明确的收益序列, 而不任意平移价格. 后面还可以按事前波动率缩放持仓, 但那是在调整承担多少风险, 与方向信号怎样形成是两步.

突破与 Donchian 式区间 突破规则问当前观测是否超出此前区间. 因而先用不包含当前值的历史定义

$$U_{t-1}^{(n)} = \max_{1 \leq j \leq n} S_{t-j}, \quad L_{t-1}^{(n)} = \min_{1 \leq j \leq n} S_{t-j}.$$

若使用每根价格柱的最高价 H_t 与最低价 L_t , 通常的 Donchian 上下轨则为

$$U_{t-1, \text{std}}^{(n)} = \max_{1 \leq j \leq n} H_{t-j}, \quad L_{t-1, \text{std}}^{(n)} = \min_{1 \leq j \leq n} L_{t-j}.$$

收盘价区间与最高最低价通道使用不同输入, 应分别计算. 在第一种定义下, 向上突破是 $S_t > U_{t-1}^{(n)}$, 向下突破是 $S_t < L_{t-1}^{(n)}$.

若把 S_t 先放进上轨窗口, 再要求它严格大于这个窗口的最大值, 条件就永远不成立. 正确的时间索引保证我们比较当前与过去, 至于突破后继续上涨还是很快退回区间, 仍是后续收益的问题.

收益移动平均的连续仓位分解 有一种特别容易分析的规则: 直接用过去收益均值作为连续权重. 假设 r_t 弱平稳且有有限二阶矩, 均值为 μ , 自协方差为 $\gamma(i) = \text{Cov}(r_{t-i}, r_t)$. 定义

$$m_{t-1}^{(N)} = \frac{1}{N} \sum_{i=1}^N r_{t-i}.$$

若单位资本的一期毛收益确实取为 $m_{t-1}^{(N)} r_t$, 则

$$\mathbb{E}[m_{t-1}^{(N)} r_t] = \mu^2 + \frac{1}{N} \sum_{i=1}^N \gamma(i). \quad (8.2)$$

证明只需展开有限求和, 对每项使用 $\mathbb{E}[r_{t-i} r_t] = \mu^2 + \gamma(i)$, 然后除以 N . 这一分解见 [FSY19].

第一项来自平均方向暴露, 第二项才使用收益的时间相关性. 即使收益独立, 只要均值非零, 这条连续权重规则仍有 μ^2 的期望毛收益. 这与前面的条件期望恒等式一致, 不需要时变的预测信息.

但把权重改成均值的符号, 或加入缓冲区, 波动率缩放及杠杆上限, 就不能再把乘积按同样方式展开. 式 (8.2) 的结论属于这里明确定义的连续权重, 不直接适用于常见的零一持仓规则.

同一类趋势规则还要规定哪些选择 “均线”或“动量”只说明信号的大致来源. 一套可以复算的策略还要规定输入序列, 信号到仓位的映射, 收益口径, 风险分配和成交成本. 这些选择分别改变不同的计算环节:

环节	一种写法	另一种写法	改变的内容
输入	价格与价格均线比较	过去收益的均值或累计和	指标单位和历史权重不同
仓位映射	$\{-1, 0, 1\}$ 阈值仓位	随信号幅度变化的连续仓位	同一信号产生不同头寸大小
收益口径	资产总收益	相对现金账户的超额收益	现金与融资部分的处理不同
比较基准	空仓	买入持有或常数方向暴露	回答绝对盈利还是择时增值
风险分配	等名义或等权	逆波动率或目标波动率	每个资产承担的风险不同
成本口径	毛收益	使用实际成交并扣费用的净收益	交易频率和市场深度进入结果

例如, 一类 EMA 动量规则会同时计算多组快慢均线差, 再用当时估计的波动尺度作归一化, 最后通过非线性函数合成 [Baz+15]. 这样得到的是一套多尺度连续信号, 与单一快慢均线的符号交叉不是同一个仓位规则.

方向信号怎样变成实际持仓 图8.1给出整项研究从数据到样本外检验的路线. 下面把其中的一笔交易单独放大: 原始路径先形成指标和信号, 信号映射为目标持仓, 订单成交以后才形成实际持仓和现金收支.




图 8.4: 从市场路径到含成本策略损益.

$z_t = 1$ 可以只表达方向为正, 并没有规定买一股还是买一百股. 目标数量还可能取决于已有持仓, 波动率和能够承担的风险; 成交数量又取决于实际订单.

先用全部成交的简单例子算清楚. 之后再在章末处理部分成交和未完成订单, 避免一开始就把目标持仓当成账户已经持有的数量.

一个不偷看未来的完整小例 考虑只持有一单位多头或空仓的规则. 每日收盘后计算

$$M_t^{(3)} = \frac{C_{t-2} + C_{t-1} + C_t}{3}.$$

若 $C_t > M_t^{(3)}$, 下一日目标为一单位; 若小于或等于均线, 目标为零. 目标在下一开盘 O_{t+1} 执行, 调整后的数量 q_{t+1} 承担直到 O_{t+2} 的价格变化.

本例假设所需数量都能按该开盘价完全成交, 所以 $q_{t+1} = q_{t+1}^*$. 单边成本为成交名义金额的 $\kappa = 0.1\%$, 不计利息, 分配及其他费用. 初始持仓 $q_2 = 0$, 可用现金为 200. 以下价格均为教学假设, 前两日收盘为 $C_0 = 100$, $C_1 = 101$. 表中均线仅为展示而保留两位小数, 判断使用未舍入值:

决策日 t	收盘 C_t	三日 SMA	$C_t - M_t^{(3)}$	q_{t+1}^*	下一开盘 O_{t+1}
2	103.00	101.33	1.67	1	103.20
3	102.00	102.00	0.00	0	101.80
4	104.00	103.00	1.00	1	104.30
5	105.00	103.67	1.33	1	105.10
6	104.00	104.33	-0.33	0	104.40

每行先在下一开盘调仓并支付费用, 再由新持仓承担后一段价格变化:

$$\Delta \Pi_{t+1} = q_{t+1}(O_{t+2} - O_{t+1}) - \kappa O_{t+1} |q_{t+1} - q_t|.$$

最后一行在 O_7 卖出并变为空仓, 本行只剩退出成本. 后面没有持仓, 因而不需要 O_8 就能结束这次计算:

决策 t	持仓 q_{t+1}	区间开盘	下一开盘	毛损益	成本	净损益
2	1	103.20	101.80	-1.40	0.1032	-1.5032
3	0	101.80	104.30	0.00	0.1018	-0.1018
4	1	104.30	105.10	0.80	0.1043	0.6957
5	1	105.10	104.40	-0.70	0.0000	-0.7000
6	0	104.40	—	0.00	0.1044	-0.1044
合计				-1.30	0.4137	-1.7137

也可以从现金核对结果. 以 B_t^{cash} 表示开盘调仓后的现金, 初始 $B_2^{\text{cash}} = 200$, 则

$$B_{t+1}^{\text{cash}} = B_t^{\text{cash}} - (q_{t+1} - q_t)O_{t+1} - \kappa O_{t+1}|q_{t+1} - q_t|.$$

在 O_3 买入后剩 96.6968, 在 O_4 卖出后为 198.3950. O_5 再买入后剩 93.9907, O_6 不交易, 现金不变. 最后在 O_7 卖出并扣费, 剩余 198.2863. 全部平仓后比初始现金少 1.7137, 恰好等于表中的净亏损.

这段收盘价从 100 附近最终升到 104 附近, 账户却净亏 1.7137. 原因可以逐笔看到: 第一次在 103.20 买入后下一开盘跌到 101.80; 后面再次买入又经历下跌, 四次成交还产生 0.4137 的费用. 规则的收益因此由实际持有的开盘到开盘区间决定, 而不是由收盘序列的起点和终点决定.

这个例子已经把后文统一使用的交易时钟固定下来. 接下来只改变指标怎样概括历史数据, 成交与现金计算仍按同一顺序理解.

8.6 常见指标: 公式, 单位与窗口

同一段历史可以按不同方式压缩. MACD 比较两个指数平滑尺度, Bollinger Bands 把当前价格放到滚动均值和标准差的尺度中, RSI 比较平滑后的上涨与下跌幅度, ATR 汇总价格柱与跳空形成的范围, VWAP 则按成交量计算一段成交的平均价格.

下面分别给出公式, 初始化和单位. 这些定义确定以后, 再由交易规则决定如何使用指标值.

MACD: 两个指数滤波器之差 给定快速, 慢速和信号跨度 $n_f < n_s$ 与 n_{sig} , 令

$$\text{MACD}_t = E_t^{(\alpha_f)}(S) - E_t^{(\alpha_s)}(S),$$

$$\text{Signal}_t = E_t^{(\alpha_{\text{sig}})}(\text{MACD}),$$

$$\text{Hist}_t = \text{MACD}_t - \text{Signal}_t,$$

通常取 $\alpha_j = 2/(n_j + 1)$, 常见跨度为 (12, 26, 9). 这些参数规定观察多长的历史, 并不是对所有市场都有特殊意义的常数.

MACD 先用快 EMA 减去慢 EMA, Signal 再平滑这条差值序列, Hist 则计算 MACD 与 Signal 之间的差. 柱状图中的 Hist 因此仍由价格滤波结果产生, 与成交量无关.

这三个量都保留原价格单位. 若要跨价格尺度比较, 可以再除以价格或其他明确尺度得到无量纲版本. 快线, 慢线和 Signal 各自都有 EMA 初始化和预热过程, 复算时使用相同约定.

Bollinger Bands 与滚动标准化分数 这里明确采用窗口总体方差口径. 令

$$M_t^{(n)} = \frac{1}{n} \sum_{j=0}^{n-1} S_{t-j},$$

$$\hat{\sigma}_{t,n}^2 = \frac{1}{n} \sum_{j=0}^{n-1} (S_{t-j} - M_t^{(n)})^2,$$

$$B_{t,\pm} = M_t^{(n)} \pm k\hat{\sigma}_{t,n}.$$

当 $\hat{\sigma}_{t,n} > 0$ 时, 滚动分数为

$$z_t^{(n)} = \frac{S_t - M_t^{(n)}}{\hat{\sigma}_{t,n}}.$$

本节方差分母取 n , 与使用 $n-1$ 的结果不同. 窗口价格完全相同时, 标准差为零, 标准化分数没有定义; 交易规则应规定此时不计算该信号或如何沿用此前决定, 而不是让除零结果决定持仓.

这里的 $k\hat{\sigma}_{t,n}$ 是同一滚动价格窗口中的离散程度尺度. 它与“已知均值和方差的正态总体中未来观测落在若干标准差内”的概率问题不是同一个设置: 当前价格已经进入窗口均值与方差的计算, 而价格序列也没有在定义中被假定为独立同分布正态. 因而 $k=2$ 在这里规定的是两倍滚动标准差的带宽, 不对应固定的 95

交易规则随后可以使用 $z_t^{(n)}$ 或上下轨. 例如顺势规则可以在向上越带时进入, 逆势规则可以采用相反映射; 指标本身只提供当前价格相对于滚动中心和尺度的位置.

RSI: 上涨与下跌幅度的 Wilder 平滑比 令 $\Delta S_t = S_t - S_{t-1}$, 并定义

$$G_t = \max(\Delta S_t, 0), \quad L_t = \max(-\Delta S_t, 0).$$

对长度 n , 先用前 n 个变化初始化

$$\bar{G}_n = \frac{1}{n} \sum_{j=1}^n G_j, \quad \bar{L}_n = \frac{1}{n} \sum_{j=1}^n L_j,$$

之后使用 Wilder 平滑

$$\bar{G}_t = \frac{(n-1)\bar{G}_{t-1} + G_t}{n},$$

$$\bar{L}_t = \frac{(n-1)\bar{L}_{t-1} + L_t}{n}.$$

为避免先计算比值造成零分母, 可以直接写成

$$\text{RSI}_t = 100 \frac{\bar{G}_t}{\bar{G}_t + \bar{L}_t}.$$

若平滑后的下降幅度为零而上涨幅度为正, RSI 取 100; 反过来取 0. 两者同时为零时, 公式分母为零, 本节另外约定 RSI 为 50. 沿用前值等其他约定会产生不同结果, 复算时不能混用.

RSI 可以直接读作平滑后上涨幅度在上涨与下跌总幅度中的百分比. 例如 RSI 为 80, 表示按当前 Wilder 平滑状态, 上涨幅度占两类幅度之和的 80

若把 RSI 用于交易, 还要规定阈值怎样映射到持仓. “RSI 高于 70 时保持多头”和“RSI 从 70 上方跌回以后退出”使用同一个指标, 却是两条不同规则.

真实波幅与 ATR 令 H_t, L_t, C_t 分别为第 t 个价格柱的最高, 最低和收盘价. 真实波幅为

$$\text{TR}_t = \max \{H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|\}.$$

只用 $H_t - L_t$ 会漏掉整根价格柱相对于前收盘的跳空. 加入另外两项后, 即使本期内部波动很小, 跨期缺口也会进入 TR.

计算首个 TR 需要窗口前的收盘价 C_0 , 因而先由 H_1, L_1, C_0 得到 TR_1 . 累积到 n 个有效值后初始化

$$\text{ATR}_n = \frac{1}{n} \sum_{j=1}^n \text{TR}_j,$$

随后对 $t \geq n+1$ 使用

$$\text{ATR}_t = \frac{(n-1)\text{ATR}_{t-1} + \text{TR}_t}{n}.$$

这就是 $\alpha = 1/n$ 的 Wilder 平滑. 本节在预热期不输出 ATR, 缺少前收盘的首根价格柱记为缺失, 不悄悄用柱内高低差替代并加入初始平均.

ATR 仍以价格单位计量, 数值越大表示近期价格柱与跨期跳空形成的范围越大. 在正价格下还可以用 ATR 除以价格得到相对尺度. 拆股等单位变化若未经调整, 会先形成异常 TR, 再通过 Wilder 平滑影响随后多期 ATR.

VWAP：成交量加权的窗口均价 VWAP 直接使用成交记录。固定交易窗口 W 和纳入规则，令 $\mathcal{E}_t(W)$ 是截至 t 已收到的合格成交。对成交价 p_i 和数量 v_i ，定义

$$\text{VWAP}_t = \frac{\sum_{i \in \mathcal{E}_t(W)} p_i v_i}{\sum_{i \in \mathcal{E}_t(W)} v_i},$$

分母要求为正。分子是这些成交的总金额，分母是总成交量，所以 VWAP 就是这批成交每单位的量加权平均价格。窗口按交易日还是某段执行时段重置，都属于定义的一部分。

执行分析中，可以将自己的买入均价与同一窗口 VWAP 比较；卖出则方向相反。若自己的订单也进入市场成交数据，它也会按成交量进入 VWAP 的计算。

只有价格柱和柱成交量时，可以构造柱级近似，但柱内最高，最低和收盘价没有保存各价格实际成交了多少。逐笔筛选，消息到达时间和柱级近似见第8.12.3小节。

指标的单位与输入比较

指标	使用的历史信息	输出单位或范围	常见用途
SMA / EMA	价格或其他输入序列的加权历史	与输入相同	平滑水平，比较不同记忆长度
MACD	两个 EMA 及 MACD 自身的 EMA	价格单位	比较快慢滤波尺度及其差值变化
Bollinger / z	滚动均值与滚动标准差	带宽为价格单位， z 无量纲	衡量当前值相对窗口中心的标准化位置
RSI	上涨与下跌幅度的 Wilder 平滑	[0, 100]	比较近期正负价格变化幅度
ATR	柱内范围及相对前收盘的跳空	价格单位	估计近期价格范围尺度
VWAP	指定窗口内逐笔成交价和成交量	价格单位	描述市场实际成交的量加权平均水平

8.7 随机过程怎样给趋势规则提供基准

可以在不同的概率模型下分析同一条趋势规则。这样能够看出，哪些图形即使在历史不提供额外预测信息时也会自然出现，又有哪些策略收益确实依赖特定的时间相关性。

第3.5节提供零条件平均增量的基准，第4.5节则说明怎样在连续时间描述漂移和噪声。下面只用这些模型明确假设的后果，是否适合真实数据仍要另行比较。

随机游走与 GBM：图形会自然出现 先令对数价格满足

$$X_t = X_{t-1} + \mu + \varepsilon_t, \quad \mathbb{E}[\varepsilon_t \mid \mathcal{F}_{t-1}] = 0.$$

取独立同分布的增量就得到熟悉的随机游走。即使如此，一次实现仍会有较长的上涨段，均线交叉和突破。图形是历史增量累积的结果，并不与下一步噪声不可预测相矛盾。

这里直接规定的是对数增量的条件均值。在独立同分布且相应指数矩存在时，下一期简单价格收益的条件分布也不会因过去图形改变。不能仅凭对数噪声条件均值为零，就在没有其他条件时对所有非线性收益作同样断言。

连续时间的对应基准是常数系数几何 Brown 运动：

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t,$$

其中 $S_0 > 0$, W 为当前滤过下的 Brown 运动。此处 μ 是价格相对变化的漂移，对数漂移为 $\mu - \sigma^2/2$ ，与上一个离散对数方程中的参数含义应分开。

在这个常数系数 GBM 中，给定当前价格以后，后续增量的分布由时间长度、 μ 和 σ 决定，更早的价格形状不再额外进入条件分布。因而它可以作为没有额外趋势状态时的连续时间基准。

AR(1) 收益：延续与反转的最小模型 令收益满足平稳 AR(1)

$$r_t - \bar{r} = \phi(r_{t-1} - \bar{r}) + \varepsilon_t, \quad |\phi| < 1,$$

且 $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0$. 于是

$$\mathbb{E}[r_t | \mathcal{F}_{t-1}] = \bar{r} + \phi(r_{t-1} - \bar{r}).$$

$\phi > 0$ 时, 上一期高于均值会使本期条件均值也高于长期均值, 出现短期延续; $\phi < 0$ 时, 条件均值向相反方向偏离. 这次预测信息直接来自方程中的滞后项, 不必从图形外观猜测.

但相关性大小还要与交易成本比较. 很小的 ϕ 即使能够统计上辨认, 对应的预期收益也可能不足以覆盖换手. 数据频率改变以后, 收益的相关性可能改变; 从一段样本估计的参数, 也需要在后续时期重新检验.

漂移, 潜在状态, 异方差与跳跃 还可以研究漂移是否随一个未直接观察的持久因素改变. 若不同情况下的平均收益确实不同, 历史观测就可能帮助判断目前更接近哪一种情况. 但要完成这种预测, 还须说明各情况怎样演变, 观测怎样产生, 以及参数怎样估计, 不能仅给上涨阶段取一个名称就算建立了模型.

即使方向信号不变, 波动率变化也会改变同一名义持仓承担的风险, 因而影响合适的持仓规模. 公告或流动性变化造成的大幅跳跃, 还可能使过去窗口计算出的平均值迅速失去代表性.

不同机制也可能产生相似的指标形态. 快线高于慢线, 既可能因为价格持续上行, 也可能只是一次大幅跳升造成. 要区分这两种情况, 就要继续查看事件, 成交和更细的价格记录, 并说明哪些后续结果会推翻当前解释.

这些模型把不同机制写成可以推导和检验的假设. 接下来先不判断哪一种机制最符合真实数据, 而转向交易规则本身: 同一信号出现以后, 是否立即改变持仓.

8.8 怎样减少反复交易：缓冲区与进出场规则

价格刚超过均线就买入, 刚退回均线下方就卖出, 会对阈值附近的小幅波动作出很多次反应. 一种改变办法是把入场和出场条件分开: 空仓时要求价格明显高于均线才买, 已持有时则等到明显低于均线才卖. 两个阈值之间不交易, 保留原持仓.

这与把均线窗口加长不同. 加长窗口会改变指标本身; 缓冲区可以保留同一条指标, 只改变持仓怎样响应它. 代价也很直接: 小变化被忽略时, 真正的新趋势或反转在开始阶段也可能被忽略.

两条事先写清楚的规则 仍用每日收盘后的三日 SMA, 但这里另设一段假设价格. 以价格单位表示偏离

$$x_t = C_t - M_t^{(3)}, \quad M_t^{(3)} = \frac{C_{t-2} + C_{t-1} + C_t}{3}.$$

两条规则都只做多一单位或空仓, 初始持仓均为零. 收盘后计算, 下一开盘成交, 假设所需数量都完全成交. 用 q_{t+1} 表示在 O_{t+1} 调整后持有的数量, 它只承担此后的开盘到开盘变化.

零阈值规则在偏离为正时持有, 其余时候空仓:

$$q_{t+1}^{(0)} = \begin{cases} 1, & x_t > 0, \\ 0, & x_t \leq 0. \end{cases}$$

缓冲规则取 $b = 0.50$, 在达到正阈值时持有, 达到负阈值时空仓, 中间沿用上一持仓:

$$q_{t+1}^{(b)} = \begin{cases} 1, & x_t \geq b, \\ 0, & x_t \leq -b, \\ q_t^{(b)}, & -b < x_t < b. \end{cases}$$

所以等于 $+0.50$ 时进入或维持多头, 等于 -0.50 时退出或保持空仓. $x_t = 0$ 时, 零阈值规则取空仓, 缓冲规则保持已有持仓. 初值为 $q_0^{(0)} = q_0^{(b)} = 0$.

同一路径上的逐笔比较 假定 $C_{-2} = C_{-1} = 100$, 两个账户初始现金均为 200. 为便于核算, 本例每成交一单位收取固定成本 0.10, 买卖都收, 不计利息, 分配或其他费用. 这些价格和费用只是示例假设. 表中 $\Delta q_{t+1} = q_{t+1} - q_t$ 是下一开盘实际成交的带符号数量, 正数买入, 负数卖出.

t	C_t	$M_t^{(3)}$	x_t	O_{t+1}	$q_{t+1}^{(0)}$	$\Delta q_{t+1}^{(0)}$	$q_{t+1}^{(b)}$	$\Delta q_{t+1}^{(b)}$
0	100.30	100.10	0.20	100.40	1	1	0	0
1	99.70	100.00	-0.30	99.60	0	-1	0	0
2	100.30	100.10	0.20	100.40	1	1	0	0
3	99.70	99.90	-0.20	99.60	0	-1	0	0
4	100.30	100.10	0.20	100.40	1	1	0	0
5	103.00	101.00	2.00	103.10	1	0	1	1
6	103.30	102.20	1.10	103.40	1	0	1	0
7	102.70	103.00	-0.30	102.60	0	-1	1	0
8	99.70	101.90	-2.20	99.60	0	0	0	-1

每行的 C_t 和均线在决定时已经知道, O_{t+1} 是随后才发生的成交价格. 因而价格从收盘到下一开盘的变化, 不会被新建立的持仓提前赚取.

零阈值规则先完成两次小幅往返, 都在 100.40 买入, 99.60 卖出; 第三次在 100.40 买入, 最后于 102.60 卖出. 毛损益为

$$\Pi_{\text{gross}}^{(0)} = (99.60 - 100.40) + (99.60 - 100.40) + (102.60 - 100.40) = 0.60.$$

缓冲规则只在 $O_6 = 103.10$ 买入, 到 $O_9 = 99.60$ 才卖出, 所以

$$\Pi_{\text{gross}}^{(b)} = 99.60 - 103.10 = -3.50.$$

成本按实际成交数量计算:

$$C^{(j)} = 0.10 \sum_{t=0}^8 |\Delta q_{t+1}^{(j)}|, \quad j \in \{0, b\}.$$

零阈值规则有六次一单位成交, 缓冲规则有两次, 得到

规则	毛损益	成交成本	净损益	期末现金
零阈值	0.60	0.60	0.00	200.00
缓冲区	-3.50	0.20	-3.70	196.30

期末取 O_9 的交易完成以后, 两个账户都已空仓. 零阈值规则在 O_8 的卖出费和缓冲规则在 O_9 的卖出费均已计入. 最后一行只有退出或保持空仓, 不需要再给出 O_{10} .

省下的交易与付出的等待成本 最初两次阈值附近的往返中, 零阈值规则每次以 100.40 买入, 99.60 卖出, 每轮价格损失 0.80, 再支付 0.20 交易成本. 缓冲规则始终空仓, 因而一共省下 2.00. 这种在阈值附近反复进出的情形通常称为 **whipsaw**.

真正上涨开始以后, 两条规则的差别反过来. 零阈值规则已在 100.40 买入, 缓冲规则直到 103.10 才进入, 因等待少取得 2.70. 后来偏离降到 -0.30 时, 零阈值规则已在 102.60 退出, 缓冲规则仍继续持有, 直到 99.60 才退出, 又多承受 3.00 下跌.

缓冲规则前面省下 2.00, 后面因晚入少赚 2.70, 因晚出多亏 3.00, 三项合计使它相对零阈值规则落后

$$2.00 - 2.70 - 3.00 = -3.70.$$

这正好与两个账户的期末净损益差一致。

入场和出场阈值也可以设得不对称。例如空仓时要求较强确认, 已持仓后采用更近的退出条件, 可以减少晚出的损失, 但也可能进一步推迟入场。无论怎样改阈值, 都应沿用同一成交时钟和现金账户重新计算结果。

缓冲区还带来一个重要变化: 规则有记忆。当当前偏离为 0.20 时, 原来空仓就继续空仓, 原来持有就继续持有。只知道当前指标已经不足以确定动作, 还需要此前持仓。下一节继续看, 即使不考虑持仓记忆, 同一个指标值又会遗漏哪些价格历史。

8.9 指标相同, 状态可以不同

上一节中, 当前信号相同, 先前持仓不同, 就可能采取不同动作。还有另一种信息损失: 不同的价格路径本身也会给出相同指标。

考虑

$$A = (97, 98, 99, 101, 105),$$

$$B = (103, 99, 96, 97, 105).$$

两段五日收盘价的总和都是 500, 当前价格都是 105, 所以五日 SMA 均为 100, 相对偏离均为 5%。只按这一偏离计算的无记忆信号会给出相同结果。

但第一段逐步上行, 第二段先下跌再大幅回升。它们包含不同的逐日变化, 也可能对应不同的成交与消息。五个收盘价本身没有说明回升是否来自隔夜跳空, 更没有直接证明某个持久因素存在。

若一个经过说明的模型让这两段历史对应不同的潜在情况, 下一期条件分布就可能不同。在独立增量模型中, 过去路径的这种差别又未必有预测作用。是否值得保留更多历史细节, 因而取决于它们是否帮助回答后续问题。

增加 ATR, 成交量或更高频数据可以补充信息, 也会增加估计和选择参数的机会。应检验新增信息实际改善了什么, 而不把指标数量当成对市场理解的深度。

8.10 从漂亮回测到可信检验

把成本放进同一份损益 净损益从实际持仓产生的价格和分配收益中扣除交易与融资成本。若直接使用实际成交均价计算买卖现金流, 买卖价差, 扫单和执行期间的价格变化已经体现在成交价中, 不再把同一价格差另外扣一次。若输入本身是总回报序列, 其中已经包含的现金分配也不再重复相加。

因此回测最重要的是保持一套一致账法: 先说明价格和分配怎样进入毛收益, 再列出尚未包含其中的手续费, 融资和其他实际成本。

每次调仓只向一个方向成交时, 单位数量的换手为

$$\text{UnitTurnover} = \sum_t |q_{t+1} - q_t|.$$

若同一统计区间内先买后卖, 不能只看区间末的净数量变化, 应把各次成交分别计入。对单位数求和得到的是交易数量, 还不是相对于资本的无量纲换手率。

对正成交价格 and 正净资产, 若一次调仓从 q_t 改为 q_{t+1} , 成交价为 S_t^{exec} , 调仓前净资产为 $A_{t-} > 0$, 一种名义换手率定义为

$$\text{Turnover}^{\text{notional}} = \sum_t \frac{S_t^{\text{exec}} |q_{t+1} - q_t|}{A_{t-}}.$$

合约还须按乘数换算, 跨币种金额按当时汇率换成同一货币。对可能出现非正报价或其他特殊计价的合约, 应另外说明名义规模的定义, 不机械套用正价格公式。

换手帮助估计交易成本, 但同样名义金额在不同深度和不同方向上未必付出相同代价。因而成交量之外, 还要看订单相对市场有多大。

第8.8节的两条规则交易量分别为六单位和两单位, 对应成本 0.60 与 0.20。这项差别直接来自持仓规则。但较少成本没有弥补晚买晚卖的价格损失, 所以应同时报告毛损益与成本, 不只展示换手下降。

实际策略还会因为合约换月或组合风险缩放而调仓。这些交易与方向信号触发的买卖应分开记录, 才能知道成本从哪里来; 相关的换手和成本比较见 [BK20]。

波动放大时, 点差和滑点也可能变差. 把整个样本的平均成本回填每一天, 会掩盖最需要退出时的交易困难. 资金规模增加后, 同一权重规则需要更大的订单, 执行结果也可能改变. 关于报价深度和订单规模, 见第6.8节与第6.8.8小节.

波动率缩放, 杠杆和路径风险 波动变化除了会影响执行成本, 也会改变同样名义持仓承担的风险. 因而方向确定以后, 还可以按预计波动决定承担多少. 常见规则是

$$|w_{t+1}^*| \propto \frac{\sigma^{\text{target}}}{\hat{\sigma}_t},$$

其中 $\hat{\sigma}_t$ 只使用截至 t 的信息, 并要求为正. 波动估计较高时减少名义权重, 较低时增加, 再受持仓和杠杆上限限制. 估计为零或缺失时应另有处理, 不能让倒数产生无限仓位.

权重还不是合约张数. 实际数量要结合账户资本, 价格, 乘数和汇率换算, 然后取允许的交易单位. 风险缩放也会独自产生调仓, 即使方向信号一直没有改变.

例如, 令 $r_{i,t+1}$ 表示资产相对于同一现金账户的一期简单超额收益, $z_{i,t}$ 为方向, $w_{i,t} \geq 0$ 为对应的绝对名义权重. 在同一资本基数及相应融资假设下, 组合超额毛收益可以写为

$$R_{t+1}^{\text{port}} = \sum_{i=1}^d w_{i,t} z_{i,t} r_{i,t+1}.$$

这里的表现同时取决于方向, 风险分配和资产之间的共同变化. 若改用总收益, 还须计入现金或融资部分, 不能把超额收益公式直接当成完整账户收益.

要判断方向信号贡献了多少, 可以比较未缩放规则, 同类缩放的被动基准, 以及实际平均杠杆, 参见 [KTW16]. 只看最终组合的 Sharpe 比率, 无法把这些来源区分开.

波动率缩放使用的是截至当前的估计值, 所以实际未来波动仍可能高于或低于目标. 这项差异会进入后续真实持仓收益.

图8.5则给出一个真实历史中的阈值穿越例子. 两个面板使用相同的 20 日和 100 日 SMA: 2017 年快线始终高于慢线, 而 2015–2016 年两条线的方向关系翻转了 8 次. 若采用最简单的交叉规则, 后一窗口会产生更多目标持仓变化; 若加入前面定义的缓冲区, 则应按新的阈值重新计算成交次数.



图 8.5: SPY 拆分与现金分配调整收盘价在两个历史窗口中的 20 日与 100 日 SMA. 上图对应 2017 年, 下图对应 2015—2016 年; 红点标记快线与慢线方向关系的翻转; 每个面板下方的蓝色条带表示 20 日 SMA 高于 100 日 SMA, 灰色表示该判断不成立. 数据来源见引用文献 [Yahb; Yahc].

样本外, 走步验证与参数冻结 先固定要研究的规则, 包括价格定义, 观察和成交时钟, 信号与持仓公式, 成本和评价方法. 参数只在训练期选择, 然后冻结, 用后续数据检验. 走步验证可以按时间推进, 在每次重新训练时只使用那以前已经取得的资料.

报告结果时, 同时给出毛收益, 各项成本, 换手和风险表现, 并保留表现不好的市场与参数. 缓冲区如果只是少交易, 就应看见相应成本减少; 若声称改善了进出场, 还要在毛结果和各类转向中看见支持.

如果反复查看测试结果再调整阈值, 原来的测试期实际上也参与了规则选择, 因而最后仍需保留真正没有用于开发的数据. 判断参数是否稳健, 也不能只看最优参数附近是否还有几个盈利点; 更重要的是, 在一段合理参数范围内, 能否用相同的机制解释规则的表现, 扣除成本后结果是否仍大致一致.

数据偏差与多重检验 历史可投资集合应包含当时存在而后来退出的证券, 不能只从今天仍上市的名单回测过去. 指数成分, 财报和修订记录也须按当时可得版本使用, 否则规则会得到真实交易者当时不知道的信息.

时间对齐同样会改变结果. 不同市场的收盘发生在不同时间, 日线中的 20 期与分钟线中的 20 期不是同一记忆长度. 原始价格, 拆股调整价和总回报数据也应与实际分配计算一致, 不能一边使用含分红再投资的序列, 一边再加同一笔分红.

如果看过全部数据以后才挑资产, 起点, 窗口, 缓冲宽度或止损, 就已经进行了规则选择. 尝试越多, 越容易出现一个偶然较好的结果. 对最终赢家报告一个仿佛它事先固定的普通 p 值, 没有计入这次选择. 应披露尝试范围, 使用适当的多重比较处理和独立样本外检验, 并保留候选规则之间的依赖, 参见 [STW99].

即使结果稳健, 还要与相同风险尺度的常数方向或买入持有基准比较, 分辨平均暴露与时变预测的贡献 [Hua+20]. 统计上可以辨认的差异, 最后也仍须足以覆盖合理成本.

8.11 趋势研究与基本面估值怎样配合

基本面研究从公司未来经营和股东所得估计价值，趋势规则则从已经观察到的价格历史规定什么时候改变持仓。两者合在一起时，可以让估值决定哪些资产值得进入候选集或什么价格具有吸引力，再让趋势规则决定实际进出场时点。

还可以把职责进一步分开：估值与 Risk-Reward 提供不同情景下的潜在收益和下行，趋势或执行规则规定何时建立和退出，风险预算决定数量。一旦这些模块组合成新的交易规则，就按组合后的实际持仓，成本和基准重新计算其历史与样本外表现。

8.12 实现补充：数据，活动订单与现金记录

前面的例子假定每次都全部成交。实际复算还会遇到合约换月，未完成订单和延迟到达的成交记录。下面分别说明这些情况怎样影响所用价格，待交易数量和现金余额，以免把图上的目标持仓误当成真实账户。

8.12.1 期货与远期的合约和换月记录

连续期货曲线通常由不同到期合约拼接而成。计算信号时可以使用这条曲线，计算盈亏时却要知当时实际持有哪一张合约，何时卖出旧合约并买入新合约。

因此，每段交易记录都应保留实际合约名称，到期日，乘数，报价与结算币种。换月规则必须只使用当时已知的信息。若用成交量或持仓量选合约，就不能先看完整历史，再把后来确定的最活跃合约回填到此前决策。

合成曲线还要说明是直接拼接，差额调整还是比例调整。这些处理会改变历史价格和指标，却不代表投资者能按调整后的历史数值成交。实际收益应从具体合约价差，乘数，换月成交及明确资本基数计算。

抵押品收益，变动保证金，汇率变化和换月费用也分别记录。变动保证金若已经把一段价格盈亏计入现金，后面就不能再把同一段价差当成额外利润。合成曲线用于观察和发出信号，合约与现金记录用于核对实际结果。

8.12.2 活动订单与部分成交

部分成交以后，新订单数量不能只用“目标持仓减去当前持仓”计算，因为此前已经发出的剩余订单仍可能继续成交。

令 q_t 为已经成交的当前持仓， L_t 为尚可能成交的订单余量之和，买单取正，卖单取负。如果这些订单全部成交，持仓就会变成 $q_t + L_t$ 。面对下一目标 q_{t+1}^* ，尚缺的净调整为

$$\Delta q_t = q_{t+1}^* - q_t - L_t.$$

这个量用于安排后续订单，实际损益仍按已经成交的持仓计算。

例如，目标原为 100 股，已买到 30 股，还有 70 股买单尚未成交。若目标降为 80 股，需要把剩余买单减少 20 股。若选择先撤销原单再重新下单，就要根据撤单确认时的实际成交数量计算新单；不能一边让原来的 70 股继续有效，一边再按 $80 - 30 = 50$ 股发送新买单。

订单状态本身也随消息更新。新单尚未收到接受或拒绝回报时，它可能仍在传输或处理；撤单请求尚未确认时，原单仍可能成交。部分成交会同时增加已确认持仓并减少该订单的剩余数量。若目标已经反向，还要先按场所规则处理原活动订单，再决定是否发送新的反向订单。

交易单位，券源，保证金，限价和排队会继续影响最终成交数量。这些撮合和执行机制见第6.8节，第6.8.8小节以及 [AC01; Har02; Has07]。

成交真正确认以后，就按前面已经建立的现金账更新账户。对普通现货，买入 $\Delta q > 0$ 单位，成交价为 p^{exec} 时，现金减少 $p^{\text{exec}} \Delta q$ 再加相应费用；卖出则取得相反方向的价款。若成交和结算不在同一时刻，成交先改变持仓并产生应收应付，结算日再把相应金额转入或转出现金。

期货则不在开仓时支付全部名义本金。保证金划转和以后变动保证金的实际收付分别进入账户；已经通过变动保证金结算的价格盈亏不再作为一笔未实现持仓价值重复加入。

完整的逐事件财富记账已在第6.1.5小节和第5.7节建立。本节只需要在每次成交后更新确认持仓，并确保活动订单的剩余数量与现金记录同步。

8.12.3 VWAP 的成交筛选与到达时间

上一小节处理订单何时改变实际持仓；对 VWAP 这类由成交记录计算的指标，还要再区分成交何时发生与记录何时进入信息集。一笔成交实际发生的时间 τ_i ，与系统收到记录的时间 a_i 可能不同。

在 t 时决策, 只能使用此前已经收到的消息. 因而对指定交易窗口 W , 合格成交集合定义为

$$\mathcal{E}_t(W) = \{i : a_i \leq t, \tau_i \in W, e_i(t) = 1\}.$$

$e_i(t)$ 表示根据当时已收到的成交条件, 撤销和更正消息, 这笔记录是否符合预先规定的纳入条件. 是采用综合市场还是单一场所, 是否纳入竞价, 场外成交和碎股, 都会影响加权结果.

按此集合计算前面的 VWAP, 并要求总成交量为正. 若只有价格柱, 可以用典型价 $TP_j = (H_j + L_j + C_j)/3$ 近似每柱成交价格, 得到

$$\widetilde{\text{VWAP}}_t = \frac{\sum_{j \leq t} TP_j V_j}{\sum_{j \leq t} V_j}.$$

求和仅使用指定窗口内已经可用的价格柱, 分母同样须为正. 这通常不等于逐笔 VWAP, 因为最高, 最低和收盘价没有保留柱内各价格实际成交了多少.

价格柱本身也应使用一致的成交筛选方式生成. 后来才到达的更正可以修订事后统计, 却不能回填成当时交易者已经知道的数据. 复算信号时保留这一区别, 才能让指标的可测性与实际信息取得时间一致.

8.13 小结

本章把趋势策略拆成一条可以复算的链: 历史数据先形成指标, 指标通过规则得到目标持仓, 成交以后形成实际持仓, 最后由实际价格变化和费用得到现金结果. 三日 SMA 算例与缓冲区双账户算例分别说明了交易时钟和持仓记忆怎样改变最终损益.

随机游走, GBM 和 AR(1) 给出了不同的条件分布基准, 样本外检验则负责判断选定规则在后续数据中的表现. 下一章转向制度史, 讨论交易, 融资和清算规则本身怎样随历史发生变化.

附录 A 金融市场制度史：危机如何塑造今日结构

现代金融市场中的中央银行，存款保险，证券披露，交易所自律，中央清算和熔断机制，并不是在同一时期一次设计完成的。它们分别在融资，付款，交易或处置出现问题以后逐步形成。

本章从十七世纪荷兰和英国的股份，结算与政府借款开始，再进入美国证券和银行体系。叙述始终追踪三类关系：投资者怎样筹资和持有资产，交易怎样完成付款与交收，出现损失以后谁必须立即提供现金。

这也使价格暴跌与金融危机可以分开分析。一项资产价格大跌首先造成持有人财富损失；若同一批持有人还依赖短期融资，价格下降又会触发补保证金，赎回或被迫出售，压力才进一步传向其他机构和市场。Mishkin and White [MW02] 对美国股灾的比较同样强调，系统性影响取决于损失怎样通过金融关系继续传播。

下面先列出几项后来形成的重要制度，再按时间说明它们分别回应了什么问题：

今天的结构	促成变化的历史问题	后来形成的制度安排
央行货币与最后贷款人	英国十九世纪恐慌，美国 1907 年恐慌	把私人银行家与清算所临时承担的部分流动性功能，转入可重复且有法定授权的公共机制
存款保险与银行处置	美国 1930–1933 年银行危机，1980 年代储贷危机，2023 年地区银行危机	区分流动性支持，损失吸收，破产处置与存款人保护
联邦证券披露与交易所监督	1929 年股灾和大萧条	私人交易所继续运营，但在联邦法律，美国证券交易委员会 (SEC) 监督和自律组织框架下承担公共义务
全国市场与现代清算结算	1968–1970 年代证券后台处理危机 (paperwork crisis)，1975 年证券法修正	竞争性交易场所通过行情，路由，托管和清算基础设施连接起来
熔断，保证金与跨市场监测	1987 年股灾，2010 年闪电崩盘 (flash crash)，2021 年 meme stock 事件	把现货，期货，期权，经纪商和清算机构看成同一个动态系统
宏观审慎与非银监管	1998 年 Long-Term Capital Management (LTCM)，2007–2009 年危机，2020 年抢夺现金 (dash for cash)	监管对象从单家银行扩展到融资网络，中央对手方，基金杠杆和核心市场功能
数字私人货币的储备与赎回规则	2022 年加密资产动荡及稳定币挤兑风险	技术形式可以改变，面值承诺，储备透明度，托管和挤兑问题仍然存在

A.1 荷兰前史：股份怎样让长期投资可以转手

远洋贸易需要先支付船只，人员和货物的成本，经营结果却可能多年以后才揭晓。如果每次航行分别集资，投资者就要等待航程结束才能收回资金。1602 年成立的荷兰东印度公司 (Vereenigde Oostindische Compagnie, VOC) 把多次航行纳入持续经营的公司，可转让股份又让持有人能够在公司继续使用资本时自行退出。

关键是把两件事分开：投资者想收回资金，不要求公司立即变卖船只或终止经营，可以把股份卖给另一位投资者。公司保留经营所需资本，买卖双方则转移对未来利益的请求权。股份逐渐还能支持信用交易和抵押融资，二级市场与配套金融活动由此一起发展 [GJ04]。

这些股份最初登记在公司账簿中。VOC 能够形成长期资本，也与国家特许，殖民贸易垄断和强制权力相连；股东取得的商业利益包含这些政治和殖民制度所产生的收益。

股份能够转手以后，市场还需要可靠完成付款。当时流通硬币成色不一，私人信用和远距离支付又增加结算成本。1609 年成立的阿姆斯特丹汇兑银行 (Bank of Amsterdam) 让商人通过账户余额转账完成大额支付，减少了每次搬运和检验硬币的需要。

这套银行货币的可信度又取决于银行资产。后期隐蔽贷款增加，财政支持不足并伴随信心下降，汇兑银行逐渐失去原来的结算地位 [FSW20]。股份交易和银行账户由此分别解决长期资本转让与日常结算两个不同问题。

1636–1637 年的郁金香投机使用了另一类合约。参与者交易的是未来交付花球的承诺，这些承诺还能继续转手，但当时没有后来期货市场的集中保证金，逐日结算和统一履约安排。报价快速上涨后交易骤减，原有承诺的履行便成为核心问题。现有研究认为，这一事件对荷兰整体经济的冲击远小于通俗叙事中的系统性灾难形象 [MT17]。

1720 年的投机则横跨伦敦、巴黎和阿姆斯特丹。英国南海公司和法国密西西比公司把政府债务转换，政治特许与股票融资连在一起，其他贸易和保险公司证券也同时受到追捧。

Frehen, Goetzmann, and Rouwenhorst [FGR09] 对不同证券价格的比较显示，投资者确实在重新评价大西洋贸易和股份制保险等新的经营机会，而不同公司涨幅也不相同。因而这一时期既有真实的商业创新，也有融资扩张和对更高转售价的预期；这三类因素都可能推动股票价格。

股份可以转让以后，长期投资者无需等公司结束经营就能退出；银行货币又让买卖双方更容易完成结算；证券融资则允许参与者用较少自有资金持有更多股份。这些安排让市场能够汇集更多资本，也使一家公司的经营损失可能沿借贷关系继续传给其他人。

A.2 英国前史：政府借款与最后贷款人的形成

1694 年，英国政府为对法战争筹资，投资者认购一家新银行的股份，银行再把资金贷给政府。这家私人持股机构就是英格兰银行。它后来承担的中央银行职责，并不是成立当天已经完整具备，而是在政府融资，银行业务和历次危机中逐渐形成 [Ban24]。

证券交易也先由私人组织起来。1698 年前后，伦敦经纪人在咖啡馆发布股票和商品报价；到 1801 年，经纪人与交易商才建立受正式规则管理的交易所 [Lon]。集中报价和会员惯例使交易更易完成，政府随后逐步承认并监督这些安排。

1720 年的南海泡沫将证券市场与公共债务紧密联系。南海公司参与政府债务转换，又以政治特许和未来贸易前景吸引股票投资。其中的 *asiento* 奴隶贸易权依赖国家强制和殖民扩张，涉及对被奴役者的买卖，不能仅写成一项普通商业创新 [UK 25]。股价因而同时受政府信用，公司筹资和对特许利益的预期影响，转售投机又进一步推动上涨。

Bubble Act 在繁荣期间就已通过。南海公司还希望借它限制竞争公司的筹资，所以不能把这部法律讲成泡沫破裂以后才制定的现代投资者保护措施。对史料的研究也表明，它对后来公司组织的限制没有通俗叙事所说的那样全面 [Har94]。这次事件使政府债务，公司治理和政治关系难以再彼此分开研究。

十九世纪的恐慌提出了另一个紧迫问题。持有人都想把票据和存款换成现金，银行却不可能立即收回全部贷款。1844 年 Bank Charter Act 强化了英格兰银行的纸币发行地位，1847、1857 和 1866 年的流动性危机仍然发生。1866 年大型票据经纪商 Overend Gurney 倒闭时，英格兰银行没有救助这家被判断为资不抵债的机构，却向其他市场参与者供给资金，防止它的失败引起更广泛的付款中断。

后来所称的 Bagehot 原则，概括了这种区别：恐慌中向有良好抵押品的借款人充分供给流动性，同时以较高利率减少没有必要的借款和对救助的依赖。历史贷款账簿显示，英格兰银行十九世纪中期的做法大体符合这条后来总结的路线，具体危机与贷款仍有差异 [Ans+17]。

临时贷款解决的是今天付不出现金。若资产即使正常回收也不足以偿债，增加一笔贷款只会同时增加现金和负债，并没有填上原来的损失。但在恐慌当天，资产能够回收多少往往最难判断，流动性不足与偿付能力不足也会互相加重：为筹现金低价卖出，可能使原本只是缺钱的机构真的遭受资本损失。

同一种“资产尚未到期，现金却必须马上补足”的机制在现代抵押融资中也会出现。因而这里跨到 2022 年的英国 LDI 事件作一次对照。政府财政声明引起长期国债急剧重定价后，部分采用杠杆的负债驱动投资 (liability-driven investment, LDI) 策略需要追加抵押品和保证金。为筹现金而出卖国债，又进一步压低抵押品价格，引起新的追加要求和出售。英格兰银行随后通过临时，定向的国债购买缓解这一循环 [Ale+23; Ban22]。

1866 年主要通过票据和银行信用传导，2022 年则通过衍生品保证金与国债抵押传导。融资工

具和抵押安排已经不同，共同的问题仍是如何在集中求现时提供暂时流动性，并在随后处理实际资产损失。

A.3 从 Buttonwood 到 1907 年：私人组织怎样交易与救急

美国证券市场先有经纪人的协议，后有持续的联邦监督。1792 年，二十四名纽约经纪人与商人签署 Buttonwood Agreement，约定彼此优先交易并设最低佣金。1817 年建立的 New York Stock & Exchange Board 进一步规定会员和交易时段，按固定时间逐只证券集中撮合，即 call market[Newb]。

这些规则既保护会员收入，也帮助交易完成。会员知道与谁交易，遇到违约有共同处理办法，报价也能在同一地方比较。但它首先服务成员，无法仅凭会员协议保护所有外部投资者，更不能为全国金融体系提供紧急资金。

银行同样依赖局部协调。单一银行制 (unit banking) 限制跨地区分支，使银行不易分散当地风险；州与联邦监管分开，货币又难以随季节性需求及时增加。纽约清算所能帮助成员银行结算，在压力时发行清算凭证并相互支持，却没有完整覆盖信托公司和全国支付需要 [Cal09; Fedh]。

1907 年 10 月，United Copper 股票逼仓失败，与之有关的中介信誉受损，提款随后扩散到纽约信托公司。Knickerbocker Trust 停止支付以后，更多持有人要求取得现金。银行、信托公司和证券融资市场同时受到压力，可随时收回的经纪贷款 call money 利率急升。经纪会员如果无法继续融资，交易所也难以维持正常交易。

J. P. Morgan 利用私人关系收集银行与信托公司的财务资料，判断哪些机构还有可回收资产，哪些已经承担无法弥补的损失。他再召集银行家共同出资，支持交易所及被认为仍能存续的机构。个人信誉在这里帮助互不信任的出资者采取共同行动，但实际现金并非只来自他一个人。

纽约清算所同时发行贷款凭证，成员银行协调限制存款兑付；财政部则把政府资金存入银行。信托公司没有参加同样的兑付限制，更显出私人会员安排覆盖不全。这些行动连同海外黄金流入等因素，逐步缓和恐慌 [MT]。

1907 年的处置主要依靠私人银行家，清算所和财政部临时协调。随后美国开始把其中部分职能制度化：1908 年 Aldrich–Vreeland Act 安排紧急货币并设立 National Monetary Commission，1913 年 Federal Reserve Act 建立包含十二家地区储备银行的美联储体系 [Fedi]。

Morgan 当时承担的工作后来没有全部交给一家机构。中央银行流动性，存款保护，失败机构处置和证券监督逐渐形成不同的法定安排。下表将 1907 年的临时做法与后来承担相近任务的机构对应起来：

1907 年的私人功能	今天主要由谁承担	后来仍须完成的任务
召集银行共同出资	Fed, Treasury, FDIC, 市场监管者和私人机构按权限协调	危机中的共同判断仍需要具体人员和可信关系
为有抵押品者供给现金	Fed 贴现窗口，回购 (repo) 工具及紧急流动性设施	央行贷款不能自动修复负资本
判断机构是否可救	银行监管者，FDIC 处置机制，Treasury 和法院	资产在压力下的真实价值仍有不确定性
保护交易所融资和市场功能	Fed 市场操作，SEC 监督，交易所规则和清算机构	私营做市商和交易商资产负债表仍是第一道缓冲
用个人信誉稳定预期	有法律授权，披露和问责的公共承诺	公共承诺本身也可能产生道德风险和政治争议

美联储使银行间结算与紧急流动性供给能够在法定安排下重复进行，不再每次都从头寻找私人出资联盟。证券监督，存款保护和失败机构的损失处理，则还需要其他法律与机构。

召集私人机构共同解决问题的做法也没有消失。1998 年，纽约联储召集十四家私人机构为 Long-Term Capital Management (LTCM) 安排资本重组 [McD98]。公共机构参与协调与公共资金承担损失是两件事，后面将继续说明这次重组。

A.4 1913–1935 年：央行怎样在危机中改变

1913 年的法律建立了能够提供弹性货币的机构，还没有解决各类危机发生时该怎样行动。十二家地区储备银行，Washington 的理事会和后来形成的 FOMC，兼顾地区参与和全国决策。这种安排有助于取得政治支持，也意味着不同地区可能对风险大小以及是否提供流动性支持作出不同判断 [Fedi; GM13]。

第一次世界大战很快扩大了美联储的工作。财政部发行 Liberty Bonds 筹集战争资金，美联储协助销售与支付，银行和经纪商向家庭推广债券。数以千万计的家庭由此接触政府证券，公共债务市场不再只面对少数专业投资者。这种普及同时包含投资机会，公民动员和销售压力 [Gar]。

1920 年代，大众证券参与与新技术前景和保证金融资结合。股票上涨时，借款放大持有收益；价格下跌以后，同一融资安排却会使投资者需要更快取得现金。1929 年 10 月崩盘后，纽约联储通过公开市场操作增加银行准备金，支持证券融资与支付继续进行 [RKG]。

但 1930–1933 年的银行危机仍不断加深。银行倒闭和提款压力削弱存款与信贷，通缩增加既有名义债务的实际负担，企业和家庭又进一步缩减支出。国际金本位限制政策选择，美联储内部判断和行动也未能有效阻止恶化 [GM13]。因而大萧条不能仅用 1929 年股价跌了多少解释，还要追踪银行，债务与货币收缩怎样互相加强。

1933 年的改革分别处理发行信息和银行风险。Securities Act 要求新证券发行承担联邦披露责任，让投资者能够取得规定信息。同年的 Banking Act 建立 FDIC，并设置商业银行与证券业务之间的隔离。存款保险降低受保护储户抢先提款的需要，业务限制则试图减少某些利益冲突和风险传递。

1934 年 Securities Exchange Act 建立 SEC，对交易所，经纪交易商和二级市场施加持续的联邦监督。1935 年 Banking Act 强化 Board of Governors 与 FOMC 的中央决策，改善全国货币政策的协调。到 1940 年，Investment Company Act 和 Investment Advisers Act 又进一步规定基金与投资顾问的责任 [Ric+a; Ric+b; US j]。

这些改革分工明确。联邦证券披露主要改善发行与交易信息，FDIC 存款保险减少受保护储户抢先提款的动机，银行业务和资本规则约束机构经营，1935 年的调整则提高全国货币政策决策的集中程度。

制度改变以后，市场参与者也会调整行为。存款保险降低了储户直接监控银行风险的动力，某些受限制的融资活动则可能转移到其他机构。后面的储贷危机和影子银行融资会继续展示这种制度变化与行为反应之间的关系。

A.5 1934–2006 年：私人交易所，全国市场与后台基础设施

1934 年以后，美国交易所继续由私人机构经营，同时进入联邦证券法下的自律组织 (self-regulatory organization, SRO) 体系。注册全国性证券交易所自行制定和执行会员规则，SEC 则依法监督这些规则和交易所履职 [KR11; US j]。交易所由此同时承担市场运营与法定自律职责。

此后市场规模不断扩大。战争时期 Treasury 市场随政府融资增长；1951 年 Treasury–Fed Accord 结束战时对政府债券利率的固定支持安排，重新区分财政部债务管理与货币政策 [HL]。战后家庭又越来越多地通过共同基金，保险和雇主养老金持有证券，经纪、托管与清算需要处理的交易数量随之增加。

成交增加以后，瓶颈首先出现在交易之后的后台。一笔交易即使已经谈妥价格，仍要完成确认，证券交付和款项结算。

1960 年代末，经纪商仍大量依靠纸质记录确认交易和交付股票证书。成交量上升以后，后台比对和结算速度跟不上交易，未完成事项不断积压，一些经纪商因此陷入资金和运营困难，交易所还曾缩短交易时间来处理积压 [US 68]。

改革首先改变证券保管和结算方式。1973 年成立的 Depository Trust Company (DTC) 集中保管证券，以账簿方式转移持有权益；1976 年成立的 National Securities Clearing Corporation (NSCC) 进一步集中交易比对，净额和结算义务 [Dep]。证券因而不需要为每笔成交都搬运纸质证书并逐笔全额付款。

交易前的报价系统也在电子化。Nasdaq 于 1971 年上线电子报价网络，使 OTC 参与者更容易比较报价，但当时成交协商仍大量依靠电话 [US 71]。因而电子报价先于后来普遍出现的自动限价订单簿撮合。

1975 年的改革又改变佣金和场所竞争。SEC Rule 19b-3 自 5 月 1 日起结束面向公众的固定佣金表；6 月 4 日通过的 Securities Acts Amendments of 1975 要求 SEC 推进全国市场和全国清算结算体系，并加强对 SRO 的监督 [US 75]。随后竞争性交易场所逐渐通过合并行情，接入和订单路由

相互连接，而证券托管和清算则继续集中化。

交易所自身的所有权也发生变化。2006 年 NYSE 与电子交易平台 Archipelago 合并并完成去会员化 (demutualization)，从会员拥有的非营利交易所转为上市控股集团中的营利性公司。SEC 批准交易时要求进一步区分市场运营与自律监管职能 [US 06]。

按截至 2026 年 9 月 2 日的资料，SEC 全国性证券交易所名录仍列有 New York Stock Exchange LLC[US h]，NYSE 属于公开上市的 Intercontinental Exchange (ICE) 集团 [Newa]。私人所有，场所竞争，联邦监督和集中清算因此同时存在于现代美国证券市场结构中。

A.6 1970—1999 年：利率错配，跨市场交易与高杠杆

上一节沿交易所和后台基础设施的发展讲到 2006 年的去会员化，并交代了今天的所有权与监管结构。现在把时间回溯到二十世纪后半段，改看融资和杠杆怎样放大并传播损失。接下来的几次事件分别说明三种机制：短期融资成本上升怎样损害长期固定收益资产持有者的收益与偿付能力，同时卖出现货与期货怎样造成跨市场压力，以及一家高杠杆非银行机构怎样通过对手方关系影响主要交易商。

储贷机构 (savings and loan institutions, S&Ls) 大量用短期存款支持长期固定利率住房贷款。利率上升以后，留住或补充存款所需的利息提高，旧贷款的收益却不能同步增加。资产价值和经营收入都受到压力，机构的经济资本已经恶化。

立即关闭失败机构，又会暴露存款保险基金不足和处置成本。宽松会计与监管宽容使部分机构继续营业，存款保险帮助它们继续吸收资金，扩大的投资权限还使一些机构承担更多高风险资产。原来的损失没有因为暂不确认而消失，反而可能在继续经营中扩大。

1989 年 Financial Institutions Reform, Recovery, and Enforcement Act (FIRREA) 废除已经资不抵债的 FSLIC，建立 Resolution Trust Corporation (RTC) 处置失败储贷机构，并将相应存款保险责任移交 FDIC。1991 年 FDIC Improvement Act (FDICIA) 又加强及时纠正措施 (prompt corrective action) 和最低成本处置 (least-cost resolution) 等要求 [Fedb; Fedc]。

处置之所以拖延，并不只是因为没人发现问题。一旦正式确认损失，就必须决定谁来出钱，谁负责关闭机构，谁承担相应的职业和政治后果。如果各方都希望把这个决定留给别人或以后再做，已经失去偿付能力的机构仍可能继续获得资金并扩大损失。

前面的储贷危机一直讲到 1989 和 1991 年的处置改革。同一时期，证券市场的另一类压力在 1987 年 10 月股灾中集中出现。组合保险试图在价格下跌时减少风险资产，程序交易与股指期货使调整可以更快完成。但许多参与者同时卖出，会增加其他市场和中介承受的压力。现货与期货互相影响，做市商要融资维持库存，清算机构也要求足够保证金。

美联储迅速公开表示提供流动性，后来的跨市场协调，熔断和清算保障又针对这些付款与交易问题加强 [Car]。熔断并不设定股票应该值多少，它让极端波动时的连续交易暂缓，给订单，风险计算和资金安排争取时间。

1998 年的 LTCM 则说明，机构规模不是衡量外部影响的唯一办法。它与多家主要交易商建立大量衍生品和融资关系，又持有高杠杆的相对价值交易。若各对手方同时抢先退出，相同资产可能被集中出售，抵押品下跌又迫使其他人补充保证金。

纽约联储召集私人对手方安排资本重组，没有直接动用公共资金买下 LTCM[McD98]。协调的目的在于减少多家对手方同时清仓造成的损失，实际重组资金由私人机构承担。这个案例说明，基金的影响不限于自身的资产规模。当它与许多主要交易商都有业务往来，又与其他机构持有大量相似头寸时，被迫平仓就可能把压力传给这些机构和相关市场。

1999 年 Gramm-Leach-Bliley Act 又取消 Glass-Steagall 的部分业务隔离，使银行，证券和保险业务更容易进入同一集团。监管随之更依赖集团资本，内部风险管理和机构间协调 [BBW]。后来的危机还涉及独立投资银行，影子银行融资和住房贷款质量，不能只用这一次法律变化解释。

这些事件共同说明，既有规则改变以后，参与者会重新选择在哪里借钱，怎样持有资产和承担风险。研究下一场危机时，需要重新查看实际负债与交易关系，而不能只沿用上一场危机涉及的机构名单。

A.7 2000—2010 年：从科技股损失到融资体系危机

互联网确实降低了搜索和通信成本，但这并没有告诉投资者每家新企业最终能赚多少钱。公司如何收费，竞争是否会压低利润，技术优势能维持多久，在繁荣期间都存在很大不确定性。新技术带来的机会可以真实存在，投资者仍可能为这些机会支付过高价格。

Pastor and Veronesi [PV05] 研究投资者逐渐了解新技术生产率时的价格变化。Ofek and Richardson [OR01] 则强调投资者意见不同，悲观者受到卖空限制，以及锁定期结束后更多股票可以出售。前者讨论怎样学习新技术价值，后者讨论不同判断能否通过实际买卖进入价格。两类分析都比在事后把所有买方视为同样盲目更具体。

2000–2002 年科技股下跌造成巨大财富损失，却没有像大萧条或 2008 年那样演变成同等程度的银行支付与融资危机。随后 Enron 和 WorldCom 等会计丑闻又暴露了另一项问题：投资者依赖的财务报告和外部审计可能因管理层行为与利益冲突而失效。

2002 年 Sarbanes–Oxley Act 建立 Public Company Accounting Oversight Board (PCAOB)，加强审计独立性，管理层财务报告责任和内部控制要求 [US 02]。这些具体措施更直接回应会计与治理失败，不能仅用科技股估值过高概括它们的起因。

2007–2009 年的住房损失则沿着更广泛的借贷和融资关系传播。抵押贷款被证券化以后，相关资产分散到多类机构手中，其中一些机构又依靠 repo 和其他短期批发融资不断续借。货币市场基金，信用衍生品和主要交易商之间的交易关系，又把更多机构的资产负债表连接在一起。

住房价格下降和贷款损失使复杂证券更难估值，出借人也难以判断对手方究竟亏了多少。它们缩短融资，提高抵押折扣或拒绝续作，借款人就须补现金或卖资产。集中出售压低其他持有人抵押品的价格，引起更多减仓。传统存款保险和贴现窗口没有完整覆盖这些影子银行融资，许多短期债权人因此会像储户一样抢先撤回资金。

Financial Crisis Inquiry Commission 多数报告把监管失误，公司治理与风险管理缺陷，过度借贷和不透明衍生品等列为重要原因，同时收录不同委员的反对意见 [Fin11]。多条原因可以同时成立，争论在于各自有多重要，以及不同政策本可怎样改变结果。以下制度回应主要针对已经显现的融资收缩和监管遗漏。

美联储的紧急支持因而不只面向传统银行。它建立贷款设施，与外国央行交换美元流动性，支持商业票据和资产支持证券融资，并进行大规模资产购买。这些工具分别向难以续借的机构或交易失灵的机构提供流动性，试图避免许多参与者为了筹现金而同时收缩融资和出售资产。

历史上，严重危机中也出现过央行扩展工具的做法，跨国比较见 [MW14]。更值得比较的是资金经过什么渠道到达哪些机构，要求什么抵押或损失保护，以及工具何时退出。临时恢复融资以后，还要调整相应激励，避免私人机构因此过度依赖紧急支持。

2010 年 Dodd–Frank Act 建立 Financial Stability Oversight Council (FSOC) 和 Office of Financial Research (OFR)，并加强系统重要机构监督，处置及压力测试等安排。改革希望把银行，证券，保险和非银融资一起观察，不再仅由每个监管者检查自己管辖的一小部分。FSOC 主要协调不同机构，并没有成为直接监管所有金融公司的单一监管者 [US a]。

场外衍生品还分别增加报告，清算和平台交易要求。以 CFTC 所辖互换为例，监管报告包括已清算和未清算交易；强制中央清算针对被认定须清算且不适用例外的互换；平台交易要求又只覆盖其中满足 made available to trade 等规定且不适用相关例外的交易 [Com12; Com13; US 10]。因而不能把改革概括成所有场外衍生品都必须在同一种交易所撮合和清算。

中央对手方 (central counterparty, CCP) 介入交易双方之间以后，可以集中进行净额，保证金和违约管理。原来分散在许多双边关系中的部分付款义务因此集中到 CCP，相应地需要初始保证金，变动保证金，违约基金以及自身的流动性和处置安排。

A.8 2010–2026 年：更快的交易与银行之外的融资

交易技术和金融机构的组织形式不断变化，付款与融资义务却没有消失。数字通信让提款与卖出决定传播得更快，基金和衍生品把杠杆带到银行体系之外，零佣金经纪和社交媒体又改变了零售订单的来源。接下来的几次事件分别展示这些变化怎样影响交易，融资和结算。

2010 年闪崩：卖出和撤单互相加快。2010 年 5 月 6 日，股指期货的大额自动卖出遇到已经紧张的流动性。高频参与者继续交易并调整库存，其他流动性提供者撤单，现货与期货之间的联系又把压力传到更多证券。许多价格在几分钟内急剧偏离，随后快速恢复 [Sta10]。

卖出程序可以继续发送订单，但另一侧可成交数量正在减少，同样一笔数量因而需要接受更远的价格。联合调查讨论的是自动执行，市场碎片化与流动性撤退的共同作用，不只是某个程序单独运行得太快。

后续的 limit up–limit down，熔断和跨市场数据建设，分别尝试限制异常成交，暂缓连续交易并改善监测。原来可以由人召集协调的处置，面对毫秒级订单变化时已经来不及逐笔完成。

2020 年求现：为什么连美债也难卖。COVID-19 冲击初期，共同基金，外国官方机构，对冲基

金和其他持有人同时需要美元现金，因而大量卖出资产，其中也包括信用和流动性通常较好的美债。交易商自身的资产负债表和融资能力有限，无法无限接下这些卖单，于是买卖价差扩大，现券与期货的相对价格失常，Treasury 与 agency MBS 市场交易明显恶化 [Boa20a]。Agency MBS 指由联邦机构或政府支持企业担保的抵押贷款证券。

部分高杠杆国债基差交易也需要平仓，但卖出并不只来自这一类基金。集体求现使安全资产也承受交易压力：最终支付受到信任，不等于今天有足够中介资金按接近原价接走全部数量。

美联储先以大规模购买，回购操作和紧急工具支持市场。2021 年建立的常设回购便利 (standing repo facility, SRF)，则把一项隔夜后备融资安排变成常设工具 [Fed21]。持有合格证券的对手方因而有规定条件下的额外现金来源，不必每次等到危机再临时设计同类操作。

此后的改革与政策讨论仍关注交易商的库存承接能力，杠杆基金活动，交易数据以及让更多参与者直接互相成交的 all-to-all trading。Treasury 中央清算也是其中一项改革。按截至 2026 年 9 月 2 日公布的时间表，符合范围的 Treasury 现券交易合规日期为 2026 年 12 月 31 日，repo 的相应日期为 2027 年 6 月 30 日 [US k]。因而在本章采用的观察日，这两个合规日期都仍在未来。

2021 年 meme stocks：手机上的买入与清算资金。 GameStop 等股票吸引社交媒体和大量零售交易，同时存在高卖空余额，活跃期权和剧烈价格变化。一些经纪商随后限制继续买入。其中一项直接压力来自清算机构提高保证金：客户已经成交的交易尚待结算，价格剧烈变化使经纪商需要为这些义务提供更多资金 [US 21]。

零佣金的交易界面并不会显示经纪商为待结算交易准备了多少清算资金。经纪商还可能通过 payment for order flow (PFOF) 取得收入，将客户订单交给场外批发做市商执行。因而客户看见的显性佣金为零，并不能说明最终成交价格或订单路由没有成本。SEC 的工作人员报告同时讨论零售界面设计，路由激励，卖空，期权和清算，没有把事件只归因于一个交易方向。

这场波动使交易与结算之间的时间差受到更广关注。2024 年 5 月 28 日，大多数适用的美国证券交易从 T+2 转为 T+1 [US 23b]。更早交收缩短了待结算风险持续的时间，有助于降低相应担保资金需要。这属于更广的结算改革，不能将其全部归因于 GameStop 一项事件。

加密资产与稳定币：记录公开以后，还要看谁能付款。 无抵押加密资产，稳定币，中心化交易平台和去中心化金融 (decentralized finance, DeFi) 并不提供同一种权利。用户可能直接控制私钥，也可能只是对平台有提取资产的请求；某种代币可能承诺赎回，也可能没有相同承诺。分析失败时，要先分清哪笔资产由谁保管，哪项付款由谁负责。

2022 年的 TerraUSD 失败说明，规则能够在链上观察，不代表维持币值和按面值退出所需的条件始终存在 [Fin22]。FTX 则暴露中心化平台的托管，负债和关联方风险。底层资产使用区块链，并没有使平台内部客户资产与自身经营风险自动隔离 [Com24]。

TerraUSD 与 FTX 暴露的是不同结构中的问题。前者依靠算法和相关代币机制维持稳定，后者则是中心化平台的托管，负债和关联方治理问题。储备支持型稳定币又要另外研究储备资产，保管和赎回条款。

FSB 在 2023 年的全球框架中按活动与风险组织监管建议，强调客户资产保护，利益冲突，跨境协作和稳定币治理 [Fin23]。美国 2025 年签署 GENIUS Act，建立支付型稳定币的联邦监管框架 [The25; US 25]。按截至 2026 年 9 月 2 日的资料，法律已经颁布，配套最终规则仍在制定，尚未全面实施 [Off26]。

法律可以规定发行人保留什么资产和履行什么责任，实际赎回仍需要资金。如果持有人集中要求退出，储备需要变现，处置损失和等待时间就会影响继续持有的意愿。2026 年的美联储研究将稳定币，代币化货币市场基金和其他近似货币产品放在一起，继续比较流动性转换，阈值和传染问题 [Ana+26]。

这与阿姆斯特丹汇兑银行的历史有可比较之处：账户或代币得到广泛接受以后，使用者更依赖发行和保管机构保持兑付能力。纸簿，中央数据库和分布式账本改变记录与转移方式，但仍要说明储备在哪里，谁能提取，压力时怎样付款。

2023 年地区银行危机：久期损失遇到集中提款。 Silicon Valley Bank (SVB) 的存款客户集中在科技和风险投资领域，大量金额不在通常存款保险范围内。银行把快速增加的存款投入更长期限的证券，没有充分管理相应利率风险。利率上升后，这些证券已经产生未实现损失，未出售只影响损失怎样进入账面，不会消除其经济影响。

资本筹集计划引起客户对偿付能力的担心，社交网络让相似客户迅速交换信息，线上银行又让它们能够集中提款。银行需要现金时，先前的长期投资已经不容易按原成本变现。美联储事后审查同时指出管理失败和监管没有及时升级处理的问题 [Boa23]。

监管者使用系统性风险例外 (systemic risk exception) 保护 SVB 和 Signature Bank 的全部存款人。美联储另设 Bank Term Funding Program (BTFP), 允许合格机构用按面值估值的合格高质量证券取得期限融资, 减少因立即筹款而低价出售证券的需要 [Boaa; US 23a].

两项措施分别作用于存款人和银行融资。存款保护没有救回股东价值, 抵押借款也没有让证券的经济损失消失。BTFP 是临时工具, 自 2024 年 3 月 11 日起不再发放新贷款。

事后 FDIC 比较了维持有限保险, 全面保险, 以及提高企业支付账户定向保障等方案 [Fed23]. 更广保护可以减少抢先提款, 也会改变存款人监督银行的动机及保险定价。报告讨论这些选择, 并不等于所有存款从此都适用同一种永久保障。

ETF 与私人信贷: 非银行机构怎样承受资金压力。不同非银行金融机构的融资和赎回结构差异很大, 不能把它们当成同一种机构分析。ETF 持有人可以在交易所转让份额, 授权参与者还可以通过创建赎回在基金份额与规定资产篮子或现金之间转换。在正常市场中, 这套机制有助于 ETF 价格接近资产价值; 市场承压时, 实际买卖篮子和份额的成本却可能明显增加。

债券报价稀疏, 净值采用较旧估值时, ETF 的实时成交价还可能先反映新的信息。所以折价既可能包含交易与赎回压力, 也可能反映净值更新滞后。应比较同一时点可交易的篮子与份额, 不能只根据折价就确定哪一边错误 [US 19; US 20].

私人信贷 (private credit) 则把部分企业融资放在银行之外的基金, business development companies (BDCs) 和保险关联载体中。BDC 是向企业提供贷款或股权资本的受监管投资公司。不同载体对投资者退出的承诺不同, 资金压力也因此不同。

长期不按净值向投资者赎回的封闭式安排, 可以让管理人不必为每天的退出请求出售贷款, 但借款人仍可能违约, 杠杆仍须偿还, 估值和与银行或保险机构的联系也仍需研究。只在规定窗口提供周期性赎回的半流动性安排, 又需要在这些时点准备现金。

本章所用 2024 年和 2026 年研究记录了私人信贷的扩张以及数据覆盖仍不完整的情况 [Boa26; CH24]. 研究其资金压力时, 关键变量包括借款人的偿付情况, 基金自身杠杆, 投资者赎回安排以及它与银行和保险机构之间的融资联系。

从这些案例可以看到, 数字化主要缩短了反应时间, 新产品则改变了资产和负债放在哪里。若许多持有人同时求现, 或同类抵押品下跌使多笔杠杆交易一起减仓, 早期银行史中的挤兑和被迫出售仍会以新的交易方式出现。

A.9 泡沫与危机留下了什么

下面按事件并列整理损失怎样扩大和后来采取了什么措施。同一时期的改革未必有同一个原因: 证券集中保管回应后台交收困难, 电子报价和佣金竞争则还各有自己的发展过程。

事件	主要传导机制	对现行结构的遗产
1636–1637 年郁金香投机	未标准化远期请求权，供给信息不透明，缺少保证金和集中履约机制；价格崩塌但系统性影响有限	提醒我们区分资产泡沫与金融系统危机，并检查交付，保证金和合同执行
1720 年跨国股票泡沫	政府债务转换，政治特许，新贸易和保险叙事，跨市场投机相互强化	公共债务，公司治理，发行规则和政治关系必须联合分析
1866 年 Overend Gurney 危机	大型票据中介倒闭，流动性需求扩散到整个伦敦货币市场	为后来由 Bagehot 总结的最后贷款人路线提供关键实践；实际操作仍随危机与贷款对象而异
1907 年美国恐慌	信托公司多在清算所会员边界之外，挤兑进入 call money 与 NYSE 融资	催化 Aldrich–Vreeland 应急货币，National Monetary Commission 与后来 Fed 对部分流动性和协调职能的制度化
1929–1933 年危机	股价崩跌与银行恐慌，通缩，信贷收缩和政策失误结合	FDIC, SEC, 联邦披露，银行业务边界与更集中的 Fed 决策结构
1968–1976 年后台危机与同期市场结构改革	成交增长超过纸质确认，股票证书和经纪商资本处理能力；会员制佣金与碎片化行情限制竞争	DTC 与 NSCC 属于后台危机的直接制度路径；Nasdaq, national market system 与竞争性佣金属于同期但不同的报价，竞争和法律改革路径
1987 年股灾	现货，期货，组合保险，做市与保证金跨市场反馈	现代熔断，跨市场监测，清算保障和 Fed 对市场功能的公开流动性承诺
1980 年代储贷危机	利率错配，存款保险道德风险，监管宽容和损失延迟确认	RTC, FIRREA, FDICIA, prompt corrective action 与更明确的处置成本约束

续下页

事件	主要传导机制	对现行结构的遗产
1998 年 LTCM	高杠杆, 相似交易和多家交易商对手方形成火售网络	系统重要性开始更多按网络 and 共同头寸理解, 公共召集与私人损失吸收并用
2000–2002 年科技股与会计危机	技术不确定性, 异质信念和融资热潮之后叠加独立的审计与治理失败	科技股崩跌深化估值教训; Enron 与 WorldCom 等公司丑闻更直接催化 PCAOB, 审计独立和内部控制改革
2007–2009 年全球金融危机	抵押贷款证券化, repo 与短期批发融资, 不透明衍生品和高杠杆影子银行	FSOC, OFR, 压力测试, 处置框架及特定场外衍生品中央清算; 风险被重组并部分集中, 没有消失
2010 年 flash crash	自动执行, 跨市场反馈与流动性同步撤退	limit up–limit down, 更新熔断与更细粒度市场数据
2020 年 dash for cash	多类持有人共同求现, 基金赎回, 保证金, 部分 basis trade 去杠杆与交易商承接能力约束共同作用	SRF, Treasury 市场数据与仍在实施的中央清算改革, 更重视 NBF1 流动性和杠杆
2021 年 meme stocks	社交媒体驱动的零售参与, 期权, short interest, 场外执行和清算保证金集中相遇	对零售路由, PFOF, 数字参与设计和清算基础设施的持续审查; T+1 属于更广泛的结算改革
2022 年 crypto 动荡	算法稳定币挤兑与中心化平台的治理, 托管和关联方风险以不同方式暴露	按功能区分 unbacked crypto, payment stablecoins, 平台和 DeFi; 稳定币法律框架进入实施期
2022 年英国 LDI 压力	财政消息引发国债重定价, 杠杆化久期对冲的追加保证金和被迫售债放大跌势	NBF1 流动性缓冲, 压力测试与英格兰银行临时定向国债购买
2023 年美国地区银行	未保险存款集中, 久期风险, 管理与监管缺陷, 线上提款和社交网络加速挤兑	BTFP 的临时经验, 存款保险边界争论和对利率风险, 抵押品准备及流动性监督的重估

表中的制度变化与损失传播方式更直接相关. 若价格下跌主要由持有人自行吸收, 交易, 付款和信贷仍可以继续; 若压力进一步使银行无法付款, 经纪商无法交收或抵押融资中断, 改革往往就会转向流动性, 清算和损失处置机制.

因此 1960 年代末的 paperwork crisis 即使没有先发生大型资产泡沫, 仍然推动了证券托管和清算基础设施的重大改革.

A.10 为什么平时难改, 危机时却能迅速行动

这些事件中反复出现一种情形: 风险已经显露, 各方却迟迟没有改变做法; 等到支付和融资同时受到威胁, 公共部门与私人机构又能迅速集中资金和人员. 1985 年 San Francisco Fed 对美国金融改革的回顾, 就注意到许多重大改革由危机推动 [Fed85].

这种反差可以从权力和成本怎样分配来理解. 州与联邦银行监管, 国会委员会, 证券监管者和交易所各自负责一部分事务. 一家机构发现问题, 未必有权改变其他机构的规则. 跨市场改革需要同时取得多个决定, 平时较容易被其中某一方拖住.

改革的代价又往往立即落到具体的人身上. 增加资本, 减少杠杆或加强披露, 会影响机构利润和可提供的信贷. 避免未来危机的好处则分散给社会, 而且没有发生的损失很难清楚归功于某项政策. 因而承担眼前成本的人有动力反对, 未来受益者却不容易形成同样集中的支持.

私人协调在平时确实也有用. 清算所, 交易商联系和合同安排能迅速处理局部问题, 不必每次等待立法. 但当所有人同时求现, 原本互相支持的成员也都需要现金, 私人安排覆盖之外的机构更难得到帮助. 1907 年信托公司的处境说明, 一套平时运行良好的会员制度未必足以应付全市场提款.

储贷危机则显示另一种拖延. 继续按旧价值记账, 又能依靠保险存款或其他资金维持, 就能把立即确认损失的决策推到以后. 关闭机构需要承认保险基金不足, 安排处置并承担政治责任. 即使有关人员知道情况不好, 他们也可能各自希望不要由自己首先作出这个决定.

危机改变了这种成本比较. 银行停止付款, 企业发不出工资或美债无法顺利交易时, 不行动的损失突然变得具体. 原先意见分散的机构可能因此接受同一个紧急目标, 财政资源, 央行资产负债表和私人运营能力才更容易被共同调动.

这些现象并非美国独有. 荷兰的国家特许和英国央行职能的形成, 都包含私人组织与公共权力重新分工. 美国的特点在于, 对集中金融权力的警惕, 州与联邦并存的监管, 强大的私人资本市场,

与财政部和美联储的资源同时存在。平时协调可能缓慢，危机时可动用的能力却很大。

能够集中资源，仍然需要正确诊断。1930–1933 年的政策失败与储贷处置的拖延说明，有机构和权限不等于会及时采取合适行动。2008 年后银行监管加强，也没有使货币基金，对冲基金和美债融资市场的压力一并消失；2023 年的存款保护又重新提出保障范围与市场纪律的问题。

因此，评价处置不能只看到市场恢复交易。还应追踪损失由股东，债权人，保险基金还是公共部门承担，临时支持是否退出，新规则是否让相同融资转移到了其他地方。跨时期研究强调的也是法律，监管和政治安排如何共同改变参与者的选择，而非某个机构一经设立即能保证稳定 [Cal09; KR11]。

A.11 回到随机过程：制度变化怎样影响条件分布

同样的抵押品价格和持仓，在不同融资制度下可以产生不同的后续交易。有稳定期限融资的投资者可以继续持有，需要立即补足保证金的投资者则可能出售。可以把这种制度差异直接放进状态变量中。

取标准 Borel 可测空间 $(X, \mathcal{E}_X)$ 和 $(Z, \mathcal{E}_Z)$ 。令 $X_t \in X$ 表示价格，融资，保证金等市场变量， $Z_t \in Z$ 表示清算方式，交易资格和可用流动性支持等制度条件，并记

$$Y_t = (X_t, Z_t).$$

以下明确作一项 Markov 状态假设：给定当前 Y_t 以后，更早历史不再改变 Y_{t+1} 的条件分布。若 Y_t 对完整信息滤过 $\mathcal{F}_t$ 可测，这项假设可以写成存在可测概率核 Q_t ，使每个可测集合 C 满足

$$\Pr(Y_{t+1} \in C \mid \mathcal{F}_t) = Q_t(Y_t, C) \quad \text{a.s.}$$

这里的 Markov 等式正是“当前所选状态已经足够”的数学假设；后面的推导都在这一假设下进行。

核 $Q_t((x, z), \cdot)$ 同时描述下一期的市场状态和制度状态。若只关心 X_{t+1} 是否落在 B ，而不限制 Z_{t+1} 的取值，就把第二个坐标的所有可能值一起计入。因而对 $B \in \mathcal{E}_X$ 定义

$$K_{t,z}(x, B) := Q_t((x, z), B \times Z).$$

这就是对下一期制度状态作边缘化，并没有假定制度状态保持不变。代入上面的 Markov 假设，得到

$$\Pr(X_{t+1} \in B \mid \mathcal{F}_t) = K_{t,Z_t}(X_t, B) \quad \text{a.s.}$$

因此，即使两个时期观察到的市场状态都是 $X_t = x$ ，只要当时的制度状态 Z_t 不同，对下一期市场变量就可以使用不同的一步预测核。

保留下标 t ，是因为转移核还可能随日历时间变化，例如受到法规生效日期或交易时段的影响。只有当这些影响已经由所选状态充分概括，并且各时点可以使用同一个转移规律时，才能把核写可不显含 t 的形式。时间齐次也不等于平稳：即使始终使用同一个核，若初始分布不是相应不变分布，各时点分布仍可能变化。

现在考虑观察者只有部分信息。令 $\mathcal{G}_t \subseteq \mathcal{F}_t$ 为观察滤过，先假设 X_t 对 $\mathcal{G}_t$ 可测，但 Z_t 不能完全观察。法规文本本身可以公开，但某家机构是否实际具备融资资格，某项支持能否取得，或政策支持会在什么条件下启动，仍可能需要推断。这里所谓隐藏变量，指模型中这些未被完全观察的条件，并不表示所有法律本身都不可见。

标准 Borel 假设使我们可以选取 Z_t 给定 $\mathcal{G}_t$ 的正则条件分布，

$$\pi_t(dz) := \Pr(Z_t \in dz \mid \mathcal{G}_t).$$

它是随当前观测改变的的概率分布。由条件期望的塔性质，

$$\begin{aligned} \Pr(X_{t+1} \in B \mid \mathcal{G}_t) &= \mathbb{E}[\Pr(X_{t+1} \in B \mid \mathcal{F}_t) \mid \mathcal{G}_t] \\ &= \mathbb{E}[K_{t,Z_t}(X_t, B) \mid \mathcal{G}_t] \\ &= \int_Z K_{t,z}(X_t, B) \pi_t(dz) \quad \text{a.s.} \end{aligned}$$

最后一步利用 X_t 已在观察信息中确定，只需对尚未确定的 Z_t 加权。各项被积值都在零与一之间，因而这里的条件期望和积分是有界的。

这个公式把部分观察下的预测写成混合分布: 对每一种可能的制度状态 z , 先用 $K_{t,z}$ 计算下一期市场变量的分布, 再按当前后验 π_t 加权. 相同的当前 X_t 若伴随不同的 π_t , 就可以得到不同的进一步预测.

若 X_t 本身也没有完全观察, 则对 (X_t, Z_t) 的联合条件分布积分即可. 这属于部分观察问题. 另一种不同情况是完整知道所选状态以后, 更早历史仍然影响下一期; 此时前面假定的 Markov 核 Q_t 本身就不成立, 需要重新选择状态或改用含历史的模型.

制度随危机和立法改变时, 这种变化可以体现在 Z_t 的转移以及时间下标 t 上. 因而核是否时间齐次, 以及哪些制度变量应进入状态, 都成为可以通过历史分段和数据检验的模型选择.

跨时期比较时, 制度变化至少会通过两条渠道改变我们观察到的市场结果. 第一, 资产对应的权利和信息条件可能改变: 披露规定影响投资者能取得哪些信息, 存款保护, 托管和赎回安排则会改变未来支付以及损失由谁承担. 第二, 融资条件可能改变: 保证金, haircut 和赎回规则会影响同样的价格冲击发生以后, 哪些参与者必须立即补现金或卖出资产.

因此 1934 年的证券监督, 1975 年的佣金与全国市场改革, 2008 年后的衍生品清算等都可以视为 Z_t 的变化. 在跨时期回测中, 可以据此分段估计参数, 加入制度状态, 或检验转移核是否发生改变, 参见第 8.10 节.

本章从股份转让, 银行结算一路追到现代中央清算和数字货币, 核心变化始终围绕同几个问题: 谁承诺付款, 谁提供短期现金, 交易怎样完成交收, 损失最终由谁承担. 这些制度条件与价格路径一起, 构成研究长期金融数据时需要保留的历史状态.

参考文献

- [Ald+20] Iñaki Aldasoro et al. *Global Banks' Dollar Funding Needs and Central Bank Swap Lines*. Bank for International Settlements. July 16, 2020. URL: <https://www.bis.org/publ/bisbull27.htm> (visited on 08/17/2026).
- [Ale+23] Paul Alexander et al. *Financial Stability Buy/Sell Tools: A Gilt Market Case Study*. Bank of England. Nov. 20, 2023. URL: <https://www.bankofengland.co.uk/quarterly-bulletin/2023/2023/financial-stability-buy-sell-tools-a-gilt-market-case-study> (visited on 09/02/2026).
- [AC01] Robert Almgren and Neil Chriss. “Optimal Execution of Portfolio Transactions”. In: *Journal of Risk* 3.2 (2001), pp. 5–39. DOI: 10.21314/JOR.2001.041.
- [Alt] Alternative Reference Rates Committee. *Transition from LIBOR*. Federal Reserve Bank of New York. URL: <https://www.newyorkfed.org/arrc/sofr-transition> (visited on 08/17/2026).
- [Ana+26] Kenekchukwu Anadu et al. *A Framework for Understanding the Vulnerabilities of New Money-Like Products*. Finance and Economics Discussion Series 2026-002. Board of Governors of the Federal Reserve System, 2026. DOI: 10.17016/FEDS.2026.002. URL: <https://www.federalreserve.gov/econres/feds/a-framework-for-understanding-the-vulnerabilities-of-new-money-like-products.htm> (visited on 09/02/2026).
- [Ang+22] Guillermo Angeris et al. *A Primer on Perpetuals*. Sept. 7, 2022. arXiv: 2209.03307. (Visited on 08/17/2026).
- [Ans+17] Mike Anson et al. *The Bank of England as Lender of Last Resort: New Historical Evidence from Daily Transactional Data*. Staff Working Paper 691. Bank of England, 2017. URL: <https://www.bankofengland.co.uk/working-paper/2017/the-bank-of-england-as-lender-of-last-resort-new-historical-evidence-from-daily-transactional-data> (visited on 09/02/2026).
- [Asw] Aswath Damodaran. *Valuing Financial Service Firms*. URL: <https://pages.stern.nyu.edu/~adamodar/pdfiles/eqnotes/finsvc.pdf> (visited on 09/12/2026).
- [AS23] Fernando Avalos and Vladyslav Sushko. *Margin Leverage and Vulnerabilities in U.S. Treasury Futures*. Bank for International Settlements. Sept. 18, 2023. URL: https://www.bis.org/publ/qtrpdf/r_qt2309w.htm (visited on 08/17/2026).
- [BMM15] Emmanuel Bacry, Iacopo Mastromatteo, and Jean-François Muzy. “Hawkes Processes in Finance”. In: *Market Microstructure and Liquidity* 1.1 (2015), p. 1550005. DOI: 10.1142/S2382626615500057.
- [BK20] Nick Baltas and Robert Kosowski. “Demystifying Time-Series Momentum Strategies: Volatility Estimators, Trading Rules and Pairwise Correlations”. In: *Market Momentum: Theory and Practice*. Ed. by Stephen Satchell and Andrew Grant. John Wiley & Sons, Nov. 16, 2020, pp. 30–67. ISBN: 9781119599364. DOI: 10.1002/9781119599364.ch3. URL: <https://onlinelibrary.wiley.com/doi/10.1002/9781119599364.ch3> (visited on 09/02/2026).
- [Ban22] Bank of England. *Financial Stability Report: December 2022*. Bank of England, 2022. URL: <https://www.bankofengland.co.uk/financial-stability-report/2022/december-2022> (visited on 09/02/2026).
- [Ban24] Bank of England. *History*. Dec. 9, 2024. URL: <https://www.bankofengland.co.uk/about/history> (visited on 09/02/2026).
- [BK21] Daniel Barth and R. Jay Kahn. *Hedge Funds and the Treasury Cash-Futures Disconnect*. Office of Financial Research. Apr. 1, 2021. URL: <https://www.financialresearch.gov/working-papers/2021/04/01/hedge-funds-and-the-treasury-cash-futures-disconnect/> (visited on 08/17/2026).
- [BKM23] Daniel Barth, R. Jay Kahn, and Robert Mann. *Recent Developments in Hedge Funds' Treasury Futures and Repo Positions: Is the Basis Trade “Back”?* Board of Governors of the Federal Reserve System. Aug. 30, 2023. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/recent-developments-in-hedge-funds-treasury-futures-and-repo-positions-20230830.html> (visited on 08/17/2026).

- [BBW] James R. Barth, R. Dan Brumbaugh, and James A. Wilcox. *Gramm–Leach–Bliley Act of 1999*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/gramm-leach-bliley-act> (visited on 09/02/2026).
- [Baz+15] Jamil Baz et al. *Dissecting Investment Strategies in the Cross Section and Time Series*. Working Paper 2695101. SSRN, 2015. DOI: 10.2139/ssrn.2695101. URL: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2695101 (visited on 09/02/2026).
- [Bil95] Patrick Billingsley. *Probability and Measure*. 3rd ed. Wiley, 1995.
- [Boa20a] Board of Governors of the Federal Reserve System. *A Retrospective on the March 2020 Turmoil in Treasury and Mortgage-Backed Securities Markets*. 2020. URL: <https://www.federalreserve.gov/publications/2020-november-financial-stability-report-borrowing.htm> (visited on 09/02/2026).
- [Boa20b] Board of Governors of the Federal Reserve System. *Swap Lines FAQs*. Mar. 19, 2020. URL: <https://www.federalreserve.gov/newsevents/pressreleases/swap-lines-faqs.htm> (visited on 08/17/2026).
- [Boa23] Board of Governors of the Federal Reserve System. *Review of the Federal Reserve’s Supervision and Regulation of Silicon Valley Bank*. Board of Governors of the Federal Reserve System, 2023. URL: <https://www.federalreserve.gov/publications/2023-April-SVB-Executive-Summary.htm> (visited on 09/02/2026).
- [Boa26] Board of Governors of the Federal Reserve System. *Financial Stability Report: Funding Risks*. Board of Governors of the Federal Reserve System, May 2026. URL: <https://www.federalreserve.gov/publications/2026-may-financial-stability-report-funding-risks.htm> (visited on 09/02/2026).
- [Boaa] Board of Governors of the Federal Reserve System. *Bank Term Funding Program*. URL: <https://www.federalreserve.gov/financial-stability/bank-term-funding-program.htm> (visited on 09/02/2026).
- [Boab] Board of Governors of the Federal Reserve System. *Central Bank Liquidity Swaps*. URL: <https://www.federalreserve.gov/monetarypolicy/central-bank-liquidity-swaps.htm> (visited on 08/17/2026).
- [Boac] Board of Governors of the Federal Reserve System. *Factors Affecting Reserve Balances, H.4.1*. URL: <https://www.federalreserve.gov/releases/h41/> (visited on 08/17/2026).
- [Boad] Board of Governors of the Federal Reserve System. *Federal Reserve Act*. URL: <https://www.federalreserve.gov/aboutthefed/fract.htm> (visited on 08/17/2026).
- [Boae] Board of Governors of the Federal Reserve System. *Interest on Reserve Balances*. URL: <https://www.federalreserve.gov/monetarypolicy/reserve-balances.htm> (visited on 08/17/2026).
- [Boaf] Board of Governors of the Federal Reserve System. *Overnight Reverse Repurchase Agreement Operations*. URL: <https://www.federalreserve.gov/monetarypolicy/overnight-reverse-repurchase-agreements.htm> (visited on 08/17/2026).
- [Boag] Board of Governors of the Federal Reserve System. *Reserve Requirements*. URL: <https://www.federalreserve.gov/monetarypolicy/reservereq.htm> (visited on 08/17/2026).
- [Bog07] Vladimir I. Bogachev. *Measure Theory*. Springer, 2007.
- [BL78] Douglas T. Breeden and Robert H. Litzenberger. “Prices of State-Contingent Claims Implicit in Option Prices”. In: *The Journal of Business* 51.4 (1978), pp. 621–651. DOI: 10.1086/296025.
- [Byba] Bybit. *USDC Perpetual Session Settlement Mechanism*. URL: <https://www.bybit.com/en/help-center/article/USDC-Perpetual-Session-Settlement-Mechanism> (visited on 09/12/2026).
- [Bybb] Bybit. *Why Was My Position Liquidated When the Candlestick Did Not Touch My Liquidation Price?* URL: <https://www.bybit.com/en/help-center/article/Why-Was-My-Position-Still-Liquidated> (visited on 09/12/2026).
- [CH24] Fang Cai and Sharjil Haque. *Private Credit: Characteristics and Risks*. Board of Governors of the Federal Reserve System. Feb. 23, 2024. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/private-credit-characteristics-and-risks-20240223.html> (visited on 09/02/2026).

- [Cal09] Charles W. Calomiris. *Banking Crises and the Rules of the Game*. Working Paper 15403. National Bureau of Economic Research, 2009. DOI: [10.3386/w15403](https://doi.org/10.3386/w15403). URL: <https://www.nber.org/papers/w15403> (visited on 09/02/2026).
- [Car] Mark Carlson. *Stock Market Crash of 1987*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/stock-market-crash-of-1987> (visited on 09/02/2026).
- [CFAa] CFA Institute. *Investments in Real Estate through Publicly Traded Securities*. URL: <https://www.cfainstitute.org/insights/professional-learning/refreshers-readings/2026/investments-real-estate-publicly-traded-securities> (visited on 09/12/2026).
- [CFAb] CFA Institute. *Market-Based Valuation: Price and Enterprise Value Multiples*. URL: <https://www.cfainstitute.org/insights/professional-learning/refreshers-readings/2026/market-based-valuation-price-enterprise-value-multiples> (visited on 09/12/2026).
- [CFAc] CFA Institute. *Residual Income Valuation*. URL: <https://www.cfainstitute.org/insights/professional-learning/refreshers-readings/2026/residual-income-valuation> (visited on 09/12/2026).
- [Che+26] Xin Cheng et al. *DSpark: Confidence-Scheduled Speculative Decoding with Semi-Autoregressive Generation*. July 6, 2026. arXiv: 2607.05147. URL: <https://arxiv.org/abs/2607.05147> (visited on 08/17/2026).
- [CME24] CME Group. *Calculating U.S. Treasury Futures Conversion Factors*. Jan. 19, 2024. URL: <https://www.cmegroup.com/articles/2024/calculating-us-treasury-futures-conversion-factors.html> (visited on 08/17/2026).
- [CMEa] CME Group. *CME Clearing: Principles for Financial Market Infrastructures Disclosure*. URL: <https://www.cmegroup.com/clearing/risk-management/files/cme-clearing-principles-for-financial-market-infrastructures-disclosure.pdf> (visited on 09/12/2026).
- [CMEb] CME Group. *CME Term SOFR Reference Rates*. URL: <https://www.cmegroup.com/market-data/cme-group-benchmark-administration/term-sofr.html> (visited on 08/17/2026).
- [CMEc] CME Group. *Mark-to-Market*. URL: <https://www.cmegroup.com/education/courses/introduction-to-futures/mark-to-market> (visited on 09/12/2026).
- [Coc05] John H. Cochrane. *Asset Pricing*. Revised. Princeton University Press, 2005.
- [Com12] Commodity Futures Trading Commission. *Clearing Requirement Determination Under Section 2(h) of the Commodity Exchange Act*. Final Rule. Commodity Futures Trading Commission, Dec. 13, 2012. URL: <https://www.cftc.gov/sites/default/files/idc/groups/public/@lrfederalregister/documents/file/2012-29211a.pdf> (visited on 09/02/2026).
- [Com13] Commodity Futures Trading Commission. *Process for a Designated Contract Market or Swap Execution Facility To Make a Swap Available to Trade*. Final Rule. Commodity Futures Trading Commission, June 4, 2013. URL: <https://www.cftc.gov/LawRegulation/FederalRegister/FinalRules/2013-12250.html> (visited on 09/02/2026).
- [Com22] Commodity Futures Trading Commission. *CFTC Orders Event-Based Binary Options Markets Operator to Pay \$1.4 Million Penalty*. Jan. 3, 2022. URL: <https://www.cftc.gov/PressRoom/PressReleases/8478-22> (visited on 08/17/2026).
- [Com24] Commodity Futures Trading Commission. *CFTC Obtains \$12.7 Billion Judgment against FTX and Alameda*. Aug. 8, 2024. URL: <https://www.cftc.gov/PressRoom/PressReleases/8938-24> (visited on 09/02/2026).
- [Com26] Commodity Futures Trading Commission. *CFTC Enforcement Division Issues Prediction Markets Advisory*. Feb. 25, 2026. URL: <https://www.cftc.gov/PressRoom/PressReleases/9185-26> (visited on 08/17/2026).
- [Com] Commodity Futures Trading Commission. *Understanding Prediction Markets and Event Contracts*. URL: <https://www.cftc.gov/LearnandProtect/PredictionMarkets> (visited on 08/17/2026).
- [CKS14] Rama Cont, Arseniy Kukanov, and Sasha Stoikov. “The Price Impact of Order Book Events”. In: *Journal of Financial Econometrics* 12.1 (2014), pp. 47–88. DOI: [10.1093/jjfinec/nbt003](https://doi.org/10.1093/jjfinec/nbt003).
- [CST10] Rama Cont, Sasha Stoikov, and Rishi Talreja. “A Stochastic Model for Order Book Dynamics”. In: *Operations Research* 58.3 (2010), pp. 549–563. DOI: [10.1287/opre.1090.0780](https://doi.org/10.1287/opre.1090.0780).

- [Dam12] Aswath Damodaran. *Investment Valuation: Tools and Techniques for Determining the Value of Any Asset*. 3rd ed. Wiley, 2012.
- [Dam16] Aswath Damodaran. *The Cost of Capital: The Swiss Army Knife of Finance*. Apr. 2016. URL: <https://pages.stern.nyu.edu/adamodar/pdfiles/papers/costofcapital.pdf> (visited on 09/13/2026).
- [DS94] Freddy Delbaen and Walter Schachermayer. “A General Version of the Fundamental Theorem of Asset Pricing”. In: *Mathematische Annalen* 300.1 (1994), pp. 463–520. DOI: [10.1007/BF01450498](https://doi.org/10.1007/BF01450498).
- [Dep] Depository Trust & Clearing Corporation. *The 1970s: Immobilization, Book Entry and Netting*. URL: <https://www.dtcc.com/annuals/history/1970s/> (visited on 09/02/2026).
- [DD83] Douglas W. Diamond and Philip H. Dybvig. “Bank Runs, Deposit Insurance, and Liquidity”. In: *Journal of Political Economy* 91.3 (1983), pp. 401–419. DOI: [10.1086/261155](https://doi.org/10.1086/261155).
- [Duf01] Darrell Duffie. *Dynamic Asset Pricing Theory*. 3rd ed. Princeton University Press, 2001.
- [Dur19] Rick Durrett. *Probability: Theory and Examples*. 5th ed. Cambridge University Press, 2019.
- [Fed23] Federal Deposit Insurance Corporation. *Options for Deposit Insurance Reform*. Federal Deposit Insurance Corporation, 2023. URL: <https://www.fdic.gov/analysis/options-deposit-insurance-reform> (visited on 09/02/2026).
- [Feda] Federal Deposit Insurance Corporation. *1930–1939*. URL: <https://www.fdic.gov/history/1930-1939> (visited on 08/17/2026).
- [Fedb] Federal Deposit Insurance Corporation. *1980–1989*. URL: <https://www.fdic.gov/history/1980-1989> (visited on 09/02/2026).
- [Fedc] Federal Deposit Insurance Corporation. *1990–1999*. URL: <https://www.fdic.gov/history/1990-1999> (visited on 09/02/2026).
- [Fed21] Federal Reserve Bank of New York. *Statement Regarding Repurchase Agreements*. July 28, 2021. URL: https://www.newyorkfed.org/markets/opolicy/operating_policy_210728 (visited on 09/02/2026).
- [Fedd] Federal Reserve Bank of New York. *Effective Federal Funds Rate*. URL: <https://www.newyorkfed.org/markets/reference-rates/effr> (visited on 08/17/2026).
- [Fede] Federal Reserve Bank of New York. *Monetary Policy Implementation*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation> (visited on 08/17/2026).
- [Fedf] Federal Reserve Bank of New York. *Repo and Reverse Repo Agreements*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation/repo-reverse-repo-agreements> (visited on 08/17/2026).
- [Fedg] Federal Reserve Bank of New York. *Secured Overnight Financing Rate Data*. URL: <https://www.newyorkfed.org/markets/reference-rates/sofr> (visited on 08/17/2026).
- [Fed85] Federal Reserve Bank of San Francisco. *U.S. Financial Reform: Historical Perspective*. Weekly Letter. Federal Reserve Bank of San Francisco, Mar. 22, 1985. URL: https://fraser.stlouisfed.org/files/docs/historical/frbsf/frbsf_let/frbsf_let_19850322.pdf (visited on 09/02/2026).
- [Fedh] Federal Reserve History. *Before the Fed: The Historical Precedents of the Federal Reserve System*. URL: <https://www.federalreservehistory.org/essays/before-the-fed> (visited on 09/02/2026).
- [Fedi] Federal Reserve History. *Federal Reserve Act Signed into Law*. URL: <https://www.federalreservehistory.org/essays/federal-reserve-act-signed> (visited on 08/17/2026).
- [FSY19] Fernando F. Ferreira, A. Christian Silva, and Ju-Yi Yen. *Detailed Study of a Moving Average Trading Rule*. 2019. arXiv: [1907.00212](https://arxiv.org/abs/1907.00212) [q-fin.ST]. URL: <https://arxiv.org/abs/1907.00212>.
- [Fin] Financial Accounting Standards Board. *Standards*. URL: <https://fasb.org/Page/PageContent?PageId=%2Fstaticpages%2Fstandards.html> (visited on 09/13/2026).

- [Fin11] Financial Crisis Inquiry Commission. *The Financial Crisis Inquiry Report*. U.S. Government Printing Office, 2011. URL: <https://www.govinfo.gov/content/pkg/GPO-FCIC/pdf/GPO-FCIC.pdf> (visited on 09/02/2026).
- [Fin23] Financial Stability Board. *Global Regulatory Framework for Crypto-Asset Activities*. Financial Stability Board, 2023. URL: <https://www.fsb.org/2023/07/fsb-finalises-global-regulatory-framework-for-crypto-asset-activities/> (visited on 09/02/2026).
- [Fin22] Financial Stability Oversight Council. *Report on Digital Asset Financial Stability Risks and Regulation*. U.S. Department of the Treasury, 2022. URL: <https://home.treasury.gov/system/files/261/FSOC-Digital-Assets-Report-2022.pdf> (visited on 09/02/2026).
- [Fol99] Gerald B. Folland. *Real Analysis: Modern Techniques and Their Applications*. 2nd ed. Wiley, 1999.
- [FPR23] Thierry Foucault, Marco Pagano, and Ailsa Röell. *Market Liquidity: Theory, Evidence, and Policy*. 2nd ed. Oxford University Press, 2023. DOI: [10.1093/oso/9780197542064.001.0001](https://doi.org/10.1093/oso/9780197542064.001.0001).
- [FGR09] Rik G. P. Frehen, William N. Goetzmann, and K. Geert Rouwenhorst. *New Evidence on the First Financial Bubble*. Working Paper 15332. National Bureau of Economic Research, 2009. DOI: [10.3386/w15332](https://doi.org/10.3386/w15332). URL: <https://www.nber.org/papers/w15332> (visited on 09/02/2026).
- [FSW20] Jon Frost, Hyun Song Shin, and Peter Wierts. *An Early Stablecoin? The Bank of Amsterdam and the Governance of Money*. Working Paper 696. De Nederlandsche Bank, 2020. URL: <https://www.dnb.nl/publicaties/publicaties-onderzoek/working-paper-2020/696-an-early-stablecoin-the-bank-of-amsterdam-and-the-governance-of-money/> (visited on 09/02/2026).
- [Gar] Kenneth D. Garbade. *Liberty Bonds*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/liberty-bonds> (visited on 09/02/2026).
- [Gas10] Gary L. Gastineau. *The Exchange-Traded Funds Manual*. 2nd ed. Wiley, 2010.
- [GJ04] Oscar Gelderblom and Joost Jonker. “Completing a Financial Revolution: The Finance of the Dutch East India Trade and the Rise of the Amsterdam Capital Market, 1595–1612”. In: *The Journal of Economic History* 64.3 (2004), pp. 641–672. DOI: [10.1017/S002205070400292X](https://doi.org/10.1017/S002205070400292X).
- [Gli+24] Jonathan Glicoes et al. *Quantifying Treasury Cash-Futures Basis Trades*. Board of Governors of the Federal Reserve System. Mar. 8, 2024. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/quantifying-treasury-cash-futures-basis-trades-20240308.html> (visited on 08/17/2026).
- [GM85] Lawrence R. Glosten and Paul R. Milgrom. “Bid, Ask and Transaction Prices in a Specialist Market with Heterogeneously Informed Traders”. In: *Journal of Financial Economics* 14.1 (1985), pp. 71–100. DOI: [10.1016/0304-405X\(85\)90044-3](https://doi.org/10.1016/0304-405X(85)90044-3).
- [GM13] Gary B. Gorton and Andrew Metrick. *The Federal Reserve and Financial Regulation: The First Hundred Years*. Working Paper 19292. National Bureau of Economic Research, 2013. DOI: [10.3386/w19292](https://doi.org/10.3386/w19292). URL: <https://www.nber.org/papers/w19292> (visited on 09/02/2026).
- [Gou+13] Martin D. Gould et al. “Limit Order Books”. In: *Quantitative Finance* 13.11 (2013), pp. 1709–1742. DOI: [10.1080/14697688.2013.803148](https://doi.org/10.1080/14697688.2013.803148).
- [Har02] Larry Harris. *Trading and Exchanges: Market Microstructure for Practitioners*. Oxford University Press, 2002. DOI: [10.1093/oso/9780195144703.001.0001](https://doi.org/10.1093/oso/9780195144703.001.0001).
- [Har94] Ron Harris. “The Bubble Act: Its Passage and Its Effects on Business Organization”. In: *The Journal of Economic History* 54.3 (1994), pp. 610–627. DOI: [10.1017/S0022050700015059](https://doi.org/10.1017/S0022050700015059).
- [HK79] J. Michael Harrison and David M. Kreps. “Martingales and Arbitrage in Multiperiod Securities Markets”. In: *Journal of Economic Theory* 20.3 (1979), pp. 381–408. DOI: [10.1016/0022-0531\(79\)90043-7](https://doi.org/10.1016/0022-0531(79)90043-7).
- [HP81] J. Michael Harrison and Stanley R. Pliska. “Martingales and Stochastic Integrals in the Theory of Continuous Trading”. In: *Stochastic Processes and their Applications* 11.3 (1981), pp. 215–260. DOI: [10.1016/0304-4149\(81\)90026-0](https://doi.org/10.1016/0304-4149(81)90026-0).
- [Has07] Joel Hasbrouck. *Empirical Market Microstructure: The Institutions, Economics, and Econometrics of Securities Trading*. Oxford University Press, 2007. DOI: [10.1093/oso/9780195301649.001.0001](https://doi.org/10.1093/oso/9780195301649.001.0001).

- [He+24] Songrun He et al. *Fundamentals of Perpetual Futures*. Aug. 21, 2024. arXiv: [2212.06888](https://arxiv.org/abs/2212.06888). (Visited on 08/17/2026).
- [HL] Robert L. Hetzel and Ralph F. Leach. *The Treasury–Federal Reserve Accord*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/treasury-fed-accord> (visited on 09/02/2026).
- [HS81] Thomas Ho and Hans R. Stoll. “Optimal Dealer Pricing under Transactions and Return Uncertainty”. In: *Journal of Financial Economics* 9.1 (1981), pp. 47–73. DOI: [10.1016/0304-405X\(81\)90020-9](https://doi.org/10.1016/0304-405X(81)90020-9).
- [Hua+20] Dashan Huang et al. “Time Series Momentum: Is It There?” In: *Journal of Financial Economics* 135.3 (2020), pp. 774–794. DOI: [10.1016/j.jfineco.2019.08.004](https://doi.org/10.1016/j.jfineco.2019.08.004).
- [HS97] Roger D. Huang and Hans R. Stoll. “The Components of the Bid-Ask Spread: A General Approach”. In: *The Review of Financial Studies* 10.4 (1997), pp. 995–1034. DOI: [10.1093/rfs/10.4.995](https://doi.org/10.1093/rfs/10.4.995).
- [Hul22] John C. Hull. *Options, Futures, and Other Derivatives*. 11th ed. Pearson, 2022.
- [HPW19] Jeffrey Huther, Luke Pettit, and Mark Wilkinson. *Fiscal Flow Volatility and Reserves*. Board of Governors of the Federal Reserve System. Dec. 16, 2019. DOI: [10.17016/2380-7172.2470](https://doi.org/10.17016/2380-7172.2470). URL: <https://www.federalreserve.gov/econres/notes/feds-notes/fiscal-flow-volatility-and-reserves-20191216.html> (visited on 08/17/2026).
- [Kal21] Olav Kallenberg. *Foundations of Modern Probability*. 3rd ed. Springer, 2021.
- [KTW16] Abby Y. Kim, Yiuman Tse, and John K. Wald. “Time Series Momentum and Volatility Scaling”. In: *Journal of Financial Markets* 30 (2016), pp. 103–124. DOI: [10.1016/j.finmar.2016.05.003](https://doi.org/10.1016/j.finmar.2016.05.003). URL: <https://www.sciencedirect.com/science/article/pii/S1386418116301379> (visited on 09/02/2026).
- [Kir+17] Andrei Kirilenko et al. “The Flash Crash: High-Frequency Trading in an Electronic Market”. In: *The Journal of Finance* 72.3 (2017), pp. 967–998. DOI: [10.1111/jofi.12498](https://doi.org/10.1111/jofi.12498).
- [KR11] Alejandro Komai and Gary Richardson. *A Brief History of Regulations Regarding Financial Markets in the United States: 1789 to 2009*. Working Paper 17443. National Bureau of Economic Research, 2011. DOI: [10.3386/w17443](https://doi.org/10.3386/w17443). URL: <https://www.nber.org/papers/w17443> (visited on 09/02/2026).
- [Kyl85] Albert S. Kyle. “Continuous Auctions and Insider Trading”. In: *Econometrica* 53.6 (1985), pp. 1315–1335. DOI: [10.2307/1913210](https://doi.org/10.2307/1913210).
- [LR91] Charles M. C. Lee and Mark J. Ready. “Inferring Trade Direction from Intraday Data”. In: *The Journal of Finance* 46.2 (1991), pp. 733–746. DOI: [10.1111/j.1540-6261.1991.tb02683.x](https://doi.org/10.1111/j.1540-6261.1991.tb02683.x).
- [Lon] London Stock Exchange Group. *The History of LSEG*. URL: <https://www.lseg.com/en/about-us/history> (visited on 09/02/2026).
- [Mad00] Ananth Madhavan. “Market Microstructure: A Survey”. In: *Journal of Financial Markets* 3.3 (2000), pp. 205–258. DOI: [10.1016/S1386-4181\(00\)00007-0](https://doi.org/10.1016/S1386-4181(00)00007-0).
- [Man06] Charles F. Manski. “Interpreting the Predictions of Prediction Markets”. In: *Economics Letters* 91.3 (2006), pp. 425–429. DOI: [10.1016/j.econlet.2006.01.004](https://doi.org/10.1016/j.econlet.2006.01.004).
- [Mar52] Harry Markowitz. “Portfolio Selection”. In: *The Journal of Finance* 7.1 (1952), pp. 77–91. DOI: [10.2307/2975974](https://doi.org/10.2307/2975974).
- [MT17] James E. McClure and David Chandler Thomas. “Explaining the Timing of Tulipmania’s Boom and Bust: Historical Context, Sequestered Capital and Market Signals”. In: *Financial History Review* 24.2 (2017), pp. 121–141. DOI: [10.1017/S0968565017000154](https://doi.org/10.1017/S0968565017000154).
- [McD98] William J. McDonough. *Statement on the Long-Term Capital Management Rescue*. Federal Reserve Bank of New York. Oct. 1, 1998. URL: <https://www.newyorkfed.org/newsevents/speeches/1998/mcd981001.html> (visited on 09/02/2026).
- [MW02] Frederic S. Mishkin and Eugene N. White. *U.S. Stock Market Crashes and Their Aftermath: Implications for Monetary Policy*. Working Paper 8992. National Bureau of Economic Research, 2002. DOI: [10.3386/w8992](https://doi.org/10.3386/w8992). URL: <https://www.nber.org/papers/w8992> (visited on 09/02/2026).

- [MW14] Frederic S. Mishkin and Eugene N. White. *Unprecedented Actions: The Federal Reserve's Response to the Global Financial Crisis in Historical Perspective*. Working Paper 20737. National Bureau of Economic Research, 2014. DOI: [10.3386/w20737](https://doi.org/10.3386/w20737). URL: <https://www.nber.org/papers/w20737> (visited on 09/02/2026).
- [MT] Jon R. Moen and Ellis W. Tallman. *The Panic of 1907*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/panic-of-1907> (visited on 08/17/2026).
- [Mor22] Morgan Stanley. *Vintage Values 2023*. Morgan Stanley Wealth Management. Aug. 24, 2022. URL: <https://www.morganstanley.com/content/dam/msdotcom/what-we-do/wealth-management-images/uit/vintage-values-research-report.pdf> (visited on 08/17/2026).
- [Mor24a] Morgan Stanley. *Project Lean: Discussion Materials, May 16, 2024, Exhibit (c)(16)*. May 16, 2024. URL: <https://www.sec.gov/Archives/edgar/data/1360587/000119312524165806/d842696dex99c16.htm> (visited on 09/12/2026).
- [Mor24b] Morningstar. *Morningstar Equity Analyst Note: Research Methodology for Valuing Companies*. Sept. 10, 2024. URL: <https://developer.morningstar.com/content/hidden-from-navigation/morningstar-stock-analyst-note.pdf> (visited on 09/12/2026).
- [Mor26] Morningstar. *Economic Moat Ratings: How to Measure a Company's Competitive Advantage*. Mar. 11, 2026. URL: <https://www.morningstar.com/business/insights/blog/equity-economic-moat-ratings> (visited on 09/12/2026).
- [Nas] Nasdaq. *Nasdaq-100 Index Methodology*. URL: https://indexes.nasdaqomx.com/docs/Methodology_NDX.pdf (visited on 08/17/2026).
- [Newa] New York Stock Exchange. *Listing at NYSE*. URL: <https://www.nyse.com/listings> (visited on 09/02/2026).
- [Newb] New York Stock Exchange. *The History of the New York Stock Exchange*. URL: <https://www.nyse.com/history-of-nyse> (visited on 09/02/2026).
- [OH95] Maureen O'Hara. *Market Microstructure Theory*. Blackwell Publishers, 1995.
- [OR01] Eli Ofek and Matthew Richardson. *DotCom Mania: The Rise and Fall of Internet Stock Prices*. Working Paper 8630. National Bureau of Economic Research, 2001. DOI: [10.3386/w8630](https://doi.org/10.3386/w8630). URL: <https://www.nber.org/papers/w8630> (visited on 09/02/2026).
- [Off26] Office of the Comptroller of the Currency. *Comptroller Gould Discusses Digital Asset Innovation, GENIUS Next Steps*. Aug. 19, 2026. URL: <https://www.occ.treas.gov/news-issuances/news-releases/2026/nr-occ-2026-69.html> (visited on 09/02/2026).
- [Opt] Options Clearing Corporation. *Characteristics and Risks of Standardized Options*. URL: <https://www.theocc.com/company-information/documents-and-archives/options-disclosure-document> (visited on 08/17/2026).
- [PV05] Lubos Pastor and Pietro Veronesi. *Technological Revolutions and Stock Prices*. Working Paper 11876. National Bureau of Economic Research, 2005. DOI: [10.3386/w11876](https://doi.org/10.3386/w11876). URL: <https://www.nber.org/papers/w11876> (visited on 09/02/2026).
- [Per88] André F. Perold. "The Implementation Shortfall: Paper versus Reality". In: *The Journal of Portfolio Management* 14.3 (1988), pp. 4–9. DOI: [10.3905/jpm.1988.409150](https://doi.org/10.3905/jpm.1988.409150).
- [Ric+a] Gary Richardson et al. *Banking Act of 1933 (Glass-Steagall)*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/glass-steagall-act> (visited on 09/02/2026).
- [Ric+b] Gary Richardson et al. *Banking Act of 1935*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/banking-act-of-1935> (visited on 09/02/2026).
- [RKG] Gary Richardson, Alejandro Komai, and Michael Gou. *Stock Market Crash of 1929*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/stock-market-crash-of-1929> (visited on 09/02/2026).
- [SP 26] S&P Dow Jones Indices. *Marvell Technology and Flex Set to Join S&P 500; Others to Join S&P MidCap 400 and S&P SmallCap 600*. June 5, 2026. URL: <https://press.spglobal.com/2026-06-05-Marvell-Technology-and-Flex-Set-to-Join-S-P-500-Others-to-Join-S-P-MidCap-400-and-S-P-SmallCap-600> (visited on 08/17/2026).

- [SP a] S&P Dow Jones Indices. *Index Mathematics Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-index-math.pdf> (visited on 08/17/2026).
- [SP b] S&P Dow Jones Indices. *S&P U.S. Indices Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-sp-us-indices.pdf> (visited on 08/17/2026).
- [SV97] Andrei Shleifer and Robert W. Vishny. “The Limits of Arbitrage”. In: *The Journal of Finance* 52.1 (1997), pp. 35–55. DOI: [10.1111/j.1540-6261.1997.tb03807.x](https://doi.org/10.1111/j.1540-6261.1997.tb03807.x).
- [Shr04a] Steven E. Shreve. *Stochastic Calculus for Finance I: The Binomial Asset Pricing Model*. Springer, 2004.
- [Shr04b] Steven E. Shreve. *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer, 2004.
- [Sta10] Staffs of the U.S. Securities and Exchange Commission and the Commodity Futures Trading Commission. *Findings Regarding the Market Events of May 6, 2010*. U.S. Securities, Exchange Commission, and Commodity Futures Trading Commission, 2010. URL: <https://www.sec.gov/news/studies/2010/marketevents-report.pdf> (visited on 09/02/2026).
- [STW99] Ryan Sullivan, Allan Timmermann, and Halbert White. “Data-Snooping, Technical Trading Rule Performance, and the Bootstrap”. In: *The Journal of Finance* 54.5 (1999), pp. 1647–1691. DOI: [10.1111/0022-1082.00163](https://doi.org/10.1111/0022-1082.00163).
- [The25] The White House. *The President Signed into Law S. 1582*. July 18, 2025. URL: <https://www.whitehouse.gov/briefings-statements/2025/07/the-president-signed-into-law-s-1582/> (visited on 09/02/2026).
- [TS11] Bruce Tuckman and Angel Serrat. *Fixed Income Securities: Tools for Today’s Markets*. 3rd ed. Wiley, 2011.
- [US 10] U.S. Congress. *Dodd–Frank Wall Street Reform and Consumer Protection Act, Public Law 111-203*. July 21, 2010. URL: <https://www.govinfo.gov/app/details/PLAW-111publ203> (visited on 09/02/2026).
- [US 25] U.S. Congress. *Guiding and Establishing National Innovation for U.S. Stablecoins Act, Public Law 119-27*. July 18, 2025. URL: <https://www.govinfo.gov/app/details/PLAW-119publ27> (visited on 09/02/2026).
- [US a] U.S. Department of the Treasury. *About the Financial Stability Oversight Council*. URL: <https://home.treasury.gov/policy-issues/financial-markets-financial-institutions-and-fiscal-service/fsoc/about-fsoc> (visited on 09/02/2026).
- [US b] U.S. Department of the Treasury. *Daily Treasury Rates*. URL: https://home.treasury.gov/resource-center/data-chart-center/interest-rates/TextView?type=daily_treasury_yield_curve (visited on 08/17/2026).
- [US c] U.S. Department of the Treasury. *STRIPS*. URL: <https://www.treasurydirect.gov/marketable-securities/strips/> (visited on 08/17/2026).
- [US d] U.S. Department of the Treasury. *Treasury Marketable Securities*. URL: <https://www.treasurydirect.gov/marketable-securities/> (visited on 08/17/2026).
- [US 23a] U.S. Department of the Treasury and Board of Governors of the Federal Reserve System and Federal Deposit Insurance Corporation. *Joint Statement by the Department of the Treasury, Federal Reserve, and FDIC*. Mar. 12, 2023. URL: <https://www.fdic.gov/news/press-releases/2023/pr23017.html> (visited on 09/02/2026).
- [US 68] U.S. Securities and Exchange Commission. *Thirty-Fourth Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1968. URL: https://www.sec.gov/about/annual_report/1968.pdf (visited on 09/02/2026).
- [US 71] U.S. Securities and Exchange Commission. *Thirty-Seventh Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1971. URL: <https://www.sec.gov/file/1971pdf> (visited on 09/02/2026).
- [US 75] U.S. Securities and Exchange Commission. *Forty-First Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1975. URL: https://www.sec.gov/about/annual_report/1975.pdf (visited on 09/02/2026).

- [US 02] U.S. Securities and Exchange Commission. *SEC Accomplishments: Fiscal Year 2002*. 2002. URL: <https://www.sec.gov/news/extra/initisfy2002.htm> (visited on 09/02/2026).
- [US 06] U.S. Securities and Exchange Commission. *Approval of SRO Rule Changes Necessary to Effectuate Merger of NYSE and Archipelago Holdings*. Feb. 27, 2006. URL: <https://www.sec.gov/news/press/2006-29.htm> (visited on 09/02/2026).
- [US 15] U.S. Securities and Exchange Commission. *Investor Bulletin: An Introduction to Options*. Mar. 18, 2015. URL: <https://www.investor.gov/introduction-investing/general-resources/news-alerts/alerts-bulletins/investor-bulletins-63> (visited on 08/17/2026).
- [US 19] U.S. Securities and Exchange Commission. *Exchange-Traded Funds, Rule 6c-11*. Sept. 25, 2019. URL: <https://www.sec.gov/rules/final/2019/33-10695.pdf> (visited on 09/02/2026).
- [US 21] U.S. Securities and Exchange Commission. *Staff Report on Equity and Options Market Structure Conditions in Early 2021*. U.S. Securities and Exchange Commission, 2021. URL: <https://www.sec.gov/files/staff-report-equity-options-market-structure-conditions-early-2021.pdf> (visited on 09/02/2026).
- [US 23b] U.S. Securities and Exchange Commission. *SEC Finalizes Rules to Reduce Risks in Clearance and Settlement*. Feb. 15, 2023. URL: <https://www.sec.gov/newsroom/press-releases/2023-29> (visited on 09/02/2026).
- [US e] U.S. Securities and Exchange Commission. *Exchange-Traded Funds (ETFs)*. Investor.gov. URL: <https://www.investor.gov/introduction-investing/investing-basics/glossary/exchange-traded-funds-etfs> (visited on 08/17/2026).
- [US f] U.S. Securities and Exchange Commission. *Investor Bulletin: Exchange-Traded Funds (ETFs)*. URL: <https://www.sec.gov/investor/pubs/sec-guide-to-etfs.pdf> (visited on 08/17/2026).
- [US g] U.S. Securities and Exchange Commission. *Money Market Funds*. URL: <https://www.investor.gov/introduction-investing/investing-basics/investment-products/mutual-funds-and-exchange-traded-5> (visited on 08/17/2026).
- [US h] U.S. Securities and Exchange Commission. *National Securities Exchanges*. URL: <https://www.sec.gov/about/divisions-offices/division-trading-markets/national-securities-exchanges> (visited on 09/02/2026).
- [US i] U.S. Securities and Exchange Commission. *Non-GAAP Financial Measures: Compliance and Disclosure Interpretations*. Questions 100.01–100.05, 102.11, 103.01–103.02. URL: <https://www.sec.gov/rules-regulations/staff-guidance/corporation-finance-interpretations/non-gaap-financial-measures> (visited on 09/13/2026).
- [US j] U.S. Securities and Exchange Commission. *Securities Laws and Regulations*. URL: <https://www.sec.gov/rules-regulations/statutes-regulations> (visited on 09/02/2026).
- [US k] U.S. Securities and Exchange Commission. *Treasury Clearing Implementation*. URL: <https://www.sec.gov/featured-topics/treasury-clearing-implementation> (visited on 09/02/2026).
- [US 20] U.S. Securities and Exchange Commission Research Staff. *U.S. Credit Markets Interconnectedness and the Effects of the COVID-19 Economic Shock*. U.S. Securities and Exchange Commission, Oct. 5, 2020. URL: https://www.sec.gov/files/us-credit-markets_covid-19_report.pdf (visited on 09/02/2026).
- [UK 25] UK Parliament. *Research into Historic Links to Transatlantic Chattel Slavery*. UK Parliament, 2025. URL: https://data.parliament.uk/DepositedPapers/Files/DEP2025-0405/Research_into_Historic_Links_to_Transatlantic_Chattel_Slavery_Report.pdf (visited on 09/02/2026).
- [Vil09] Cédric Villani. *Optimal Transport: Old and New*. Springer, 2009.
- [Wil91] David Williams. *Probability with Martingales*. Cambridge University Press, 1991.
- [WZ04] Justin Wolfers and Eric Zitzewitz. “Prediction Markets”. In: *Journal of Economic Perspectives* 18.2 (2004), pp. 107–126. DOI: [10.1257/0895330041371321](https://doi.org/10.1257/0895330041371321).
- [Yaha] Yahoo Finance. *Apple Inc. (AAPL) Historical Prices and Data*. URL: <https://finance.yahoo.com/quote/AAPL/history/> (visited on 09/02/2026).

- [Yahb] Yahoo Finance. *SPDR S&P 500 ETF Trust (SPY) Historical Prices and Data*. URL: <https://finance.yahoo.com/quote/SPY/history/> (visited on 09/02/2026).
- [Yahc] Yahoo Help. *What Is the Adjusted Close?* URL: <https://help.yahoo.com/kb/adjusted-close-sln28256.html> (visited on 09/02/2026).
- [本笔记 26] 本笔记作者. *LLY 未来经营情景与现金流估值研究算例*. 2026 年 9 月 11–12 日研究记录. 未来经营、研发及估值参数为作者当时假设, 非发行人或晨星预测. 包含未来盈利定价与现金流折现复算. Sept. 2026.