

# 随机过程与金融市场

本地 TeX 版

---

Ou Liu

2026-08-16

# 编写声明

本文本地 TeX 版基于作者在 BananaSpace 更新的《随机过程与金融市场》笔记整理而成. 主要内容, 判断和写作风格由 Ou Liu 负责. GPT/Codex 参与了本地版本的格式转换, 结构整理, 语言润色, 参考文献补充, 排版实现以及部分章节的编辑建议. 经由 GPT/Codex 生成或改写的内容均由作者审阅后纳入本文.

GPT/Codex 不作为独立事实来源或者数学与金融内容的权威背书. 涉及数学命题, 金融制度事实和市场机制的内容, 仍应以文中引用, 原始资料以及作者后续修订为准.

# 目录

|                                     |           |
|-------------------------------------|-----------|
| 编写声明                                | ii        |
| <b>第一章 引言</b>                       | <b>1</b>  |
| 1.1 为什么是随机过程                        | 1         |
| 1.2 为什么前面还要学习测度论                    | 1         |
| 1.3 金融市场作为一个长期例子                    | 1         |
| 1.4 模型不是市场                          | 2         |
| 1.5 本文的路线                           | 2         |
| <b>第一部分 随机过程的数学基础</b>               | <b>3</b>  |
| <b>第二章 测度论基础</b>                    | <b>4</b>  |
| 2.1 可测空间, 测度, Lebesgue 积分           | 6         |
| 2.2 符号测度, Hahn 分解与 Radon-Nikodym 导数 | 18        |
| <b>第三章 概率论基础</b>                    | <b>29</b> |
| 3.1 概率空间与随机变量                       | 30        |
| 3.2 随机变量的分布                         | 32        |
| 3.3 期望与矩                            | 40        |
| 3.4 独立性, 条件概率与条件期望                  | 43        |
| 3.5 随机变量的收敛与极限定理                    | 49        |
| <b>第四章 随机过程基础</b>                   | <b>59</b> |
| 4.1 随机过程、分布与样本路径                    | 59        |
| 4.2 时间与信息                           | 59        |
| 4.3 两种条件结构: Markov 性与鞅              | 59        |
| 4.4 两类基础噪声: Poisson 过程与布朗运动         | 59        |
| 4.5 从随机过程走向随机分析                     | 59        |
| <b>第五章 随机分析基础</b>                   | <b>60</b> |
| 5.1 二次变差与半鞅                         | 60        |
| 5.2 随机积分                            | 60        |
| 5.3 Itô 公式与随机微分规则                   | 60        |
| 5.4 随机微分方程                          | 60        |
| 5.5 测度变换                            | 60        |
| 5.6 生成元、Feynman-Kac 与金融接口           | 60        |
| <b>第二部分 随机过程与金融市场</b>               | <b>61</b> |
| <b>第六章 金融市场基础</b>                   | <b>62</b> |
| 6.1 资产, 价格与收益                       | 63        |
| 6.2 衍生品与或有现金流                       | 69        |
| 6.3 预测市场与市场隐含概率                     | 79        |
| 6.4 指数, ETF 和被动投资                   | 83        |
| 6.5 债券, 美债与利率                       | 92        |
| 6.6 美联储, 美元体系与短端资金市场                | 100       |
| 6.7 贴现与无套利                          | 108       |

---

|                                                |            |
|------------------------------------------------|------------|
| 6.8 交易、订单簿与市场微观结构 . . . . .                    | 114        |
| <b>第七章 基本面分析</b>                               | <b>126</b> |
| 7.1 Risk-Reward 框架与情景分析 . . . . .              | 126        |
| 7.2 Agentic R/D Graph: 把研究判断组织成可更新的图 . . . . . | 131        |
| <b>参考文献</b>                                    | <b>140</b> |

# 第一章 引言

本文是一份学习随机过程时逐步整理的笔记。

它不打算按照某一套标准教材完整地铺开随机过程理论，而更像是一份边学边整理的阅读记录。这里会按主题需要逐步补充内容；证明也会按需要选择展开。主要目标是尽量用比较轻松和直观的方式，把这些对象到底在研究什么弄明白。

此外，本文会随手参考各种教材，讲义，论文以及其他资料。出处尽量补齐，但不保证构成一份完整书目。

## 1.1 为什么是随机过程

概率论最基本的研究对象是随机变量。一个随机变量可以用来描述某一次随机实验中我们关心的某个数值，比如一次抛硬币的结果，某一天的股票价格，或者一段时间内发生了多少次事件。

但现实中的很多随机系统不会只发生一次。

股票价格会不断变化，订单会不断进入市场，电话会不断打进客服中心，粒子会不断运动，一个系统的状态也会随着时间不断演化。

如果我们只固定在某一个时刻观察，当然仍然可以得到一个随机变量。但如果我们希望研究整个系统随着时间究竟是怎样变化的，那就自然需要同时考虑一整族随机变量  $(X_t)_{t \in T}$ 。这就是所谓的随机过程。

粗略来说，随机变量研究的是“一次观测得到什么”，而随机过程进一步研究的是“这些随机观测随着时间怎样组织在一起”。

更有意思的问题也从这里开始出现：不同时间上的随机变量之间有什么关系，过去的信息能够告诉我们多少关于未来的事情，一条随机路径是否连续，一个过程长期以后会不会进入某种稳定状态，以及大量随机扰动叠加以后最终会产生怎样的宏观规律。

## 1.2 为什么前面还要学习测度论

如果只是做一些有限样本空间上的初等概率计算，完全没有必要先学这么多测度论。

问题在于，一旦开始研究随机过程，样本空间很快就可能变成“所有可能的无限序列”，“所有可能的价格路径”，甚至“所有可能的连续函数”这样巨大而且无限维的空间。

此时一个样本点  $\omega$  本身就可能代表一整条完整的随机路径，而我们需要讨论的事件也会涉及无穷次集合运算，极限以及各种函数空间。

因此现代概率论最终自然建立在测度论之上。

实际上前面介绍的很多测度论概念，到了概率论里面都只是换了一套语言：测度变成概率，可测集变成事件，可测函数变成随机变量，前推测度变成分布，而 Lebesgue 积分则变成期望。

$L^p$  空间也会在这里发挥非常直接的作用。随机变量的矩，方差，均方收敛以及大量极限定理，都依赖于 Lebesgue 积分和  $L^p$  空间提供的结构。

因此前面的测度论并不是为了故意把概率论讲复杂，而是为了等我们遇到无限维随机对象的时候，手里至少还有一套不会立刻散架的语言。

## 1.3 金融市场作为一个长期例子

本文主要还是为了学习随机过程本身，不过股票市场是很方便反复观察的随机系统之一，后面会比较频繁地拿金融市场作为例子。

比如可以令  $S_t$  表示时刻  $t$  的股票价格。对于固定的  $t$ ， $S_t$  只是一个随机变量；而整族  $(S_t)_{t \in T}$  则构成一个随机过程。

截至时刻  $t$  已知的全部市场信息可以组织成一条滤过 (filtration, 也称滤链)  $(\mathcal{F}_t)$ ；未来价格在当前信息下的条件分布，可以通过条件概率和条件期望进行描述；而“第一次跌破某个价格的时刻”则自然会引出停时。

再往后，随机过程在金融市场中的应用远远不只“预测股价”。

期权定价会引出布朗运动，鞅以及随机微分方程；波动率本身可以被建模成随机过程；订单流可以使用计数过程或者点过程进行研究；流动性，市场冲击以及交易执行也都具有明显的动态结构。

甚至很多传统的技术指标也可以重新放进这个框架里面理解。均线，指数移动平均 (exponen-

tial moving average, EMA), MACD, 布林带 (Bollinger Band) 或者成交量加权平均价格 (volume-weighted average price, VWAP), 形式上都可以看成对于价格, 成交量或者订单流等随机过程进行某种平滑, 差分或者局部统计以后得到的函数.

不过, 这并不意味着某个指标因此就自动具有预测能力. 随机过程理论首先帮助我们回答的是: 这个指标究竟从原始市场路径中提取了什么信息, 以及在什么样的随机机制下这种信息可能具有意义.

至于这些信息究竟能不能稳定预测未来, 那是另外一个经验和市场结构上的问题.

## 1.4 模型不是市场

这里还需要提前强调一件事情.

随机过程模型只是对于现实系统某些结构的抽象, 而不是现实系统本身.

比如我们可以假设股票价格服从几何布朗运动, 可以假设波动率服从某种随机波动率模型, 也可以假设订单流满足某种点过程. 这些模型在特定的定价, 风险管理或者交易执行问题中可能非常有用.

但是一个模型在某个问题上有效, 并不意味着真实市场真的按照这个随机过程生成.

因此本文在金融市场部分更加关心的是: 某个随机过程模型到底保留了市场的什么结构, 它能够解决什么问题, 以及它在哪些地方开始失效.

换句话说, 我们会尽量把“这个模型很好用”和“这个模型就是真实世界”这两件事情分开.

## 1.5 本文的路线

本文大致分为两部分.

1. 第一部分主要介绍随机过程所需要的数学基础. 我们会从测度和概率论开始, 然后进入随机过程本身, 介绍样本路径, 有限维分布, 滤过, 停时, 马尔可夫过程, 泊松过程, 布朗运动以及鞅等基本对象.
2. 第二部分则主要讨论随机过程在金融市场中的应用. 这里会涉及资产价格与收益率过程, 衍生品定价与 Black-Scholes 模型, 随机波动率, 订单流, 流动性, 市场冲击和交易执行, 以及随机过程与技术分析之间可能存在的联系.

这只是目前的学习路线. 之后如果遇到新的随机过程例子或者新的金融应用, 也可以继续补充到相应位置.

# 第一部分

## 随机过程的数学基础


## 第二章 测度论基础

这一节先搭起测度论最基础的骨架：哪些集合可以测量，以及这些集合的“大小”应该满足什么条件。

本章以及后面两节的测度论背景主要参考 [Bog07; Fol99].

我们所测量的对象通常可以视为某个集合  $X$  的子集. 比如要测量方块的体积, 就是在给  $\mathbb{R}^3$  的一个子集“方块”赋予大小. 粗略来说, 我们需要从幂集  $\mathcal{P}(X)$  中挑出一族允许测量的子集.

那问题就在于, 我们到底需要哪些集合可以被测量呢? 先考虑  $\mathbb{R}^2$  中最朴素的情况. 对于一个矩形, 我们很容易定义它的面积, 比如  $R = [a, b] \times [c, d]$ , 那它的面积就是  $(b-a)(d-c)$ . 但是我们不想测矩形. 如果现在想测量一个圆盘  $D$  的大小, 一个自然的想法就是先把平面切成很多小方块, 然后用这些小方块去逼近这个圆盘.



$A_n$ : 由有限多个小方块拼成的近似

如果这些方块足够小, 那我们可以把圆盘逼近得越来越精确. 为了避免边界问题, 先把  $D$  理解成开圆盘. 于是可以构造一系列集合  $A_1 \subseteq A_2 \subseteq \dots$ , 其中每个  $A_n$  都只是有限个小矩形的并, 但是随着划分越来越细, 我们希望最后能够有

$$D = \bigcup_{n=1}^{\infty} A_n.$$

这时候问题就出现了, 虽然每一个  $A_n$  都只是有限个我们已经会测量的矩形拼起来的, 但是为了得到  $D$ , 我们却需要把这样的过程无限地做下去. 所以如果我们希望圆盘也是可以测量的, 那自然就需要要求如果  $A_1, A_2, \dots$  都可以测量, 那么它们的可列并  $\bigcup_{n=1}^{\infty} A_n$  也应该可以测量. 这也就是为什么我们不只要求有限并, 而是要求对于可列并封闭.

类似地, 如果一个集合  $A$  可以测量, 那把它从整个空间  $X$  中挖掉以后剩下的部分  $A^c = X \setminus A$  自然也是可以测量的. 而有了补集和可列并以后, 根据 De Morgan 律, 可列交其实也就自动有了:

$$\bigcap_{n=1}^{\infty} A_n = \left( \bigcup_{n=1}^{\infty} A_n^c \right)^c.$$

因此我们想找的就是  $\mathcal{P}(X)$  中的一族集合  $\mathcal{F}$ , 它至少应该满足:

1.  $X \in \mathcal{F}$ ;
2. 如果  $A \in \mathcal{F}$ , 那么  $A^c \in \mathcal{F}$ ;
3. 如果  $A_1, A_2, \dots \in \mathcal{F}$ , 那么  $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ .

满足这些条件的集合族  $\mathcal{F} \subseteq \mathcal{P}(X)$ , 就称为  $X$  上的一个  $\sigma$ -代数.

粗略地说,  $\sigma$ -代数就是在规定“哪些集合是我们允许测量的”, 而这些集合还需要对于我们在逼近过程中自然会出现的操作保持封闭.

接下来我们开始给这些集合赋予“大小”. 也就是说, 对于每一个  $A \in \mathcal{F}$ , 我们希望能够给它一个数  $\mu(A)$ , 并且这个赋值至少应该符合我们对于“大小”最基本的直觉:

1. 空集应该没有大小, 即  $\mu(\emptyset) = 0$ ;



2. 如果  $A_1, A_2, \dots$  彼此不相交, 那么把它们拼起来以后的大小也应该等于它们各自大小的总和:

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

这样的函数  $\mu: \mathcal{F} \rightarrow [0, \infty]$  就称为一个测度, 而  $(X, \mathcal{F}, \mu)$  就称为一个测度空间.

到这里也就已经离概率论非常近了. 概率论中我们同样是在给一些“事件”赋予大小. 一次实验所有可能发生的结果组成一个集合  $\Omega$ , 而一个事件  $A$  就是  $\Omega$  的一个可测子集. 比如掷一次骰子的时候, 我们可以取  $\Omega = \{1, 2, 3, 4, 5, 6\}$ , 那么“掷出偶数”这个事件就是集合  $A = \{2, 4, 6\}$ . 所谓  $\mathbb{P}(A)$ , 就是在给这个事件  $A$  赋予一个大小, 只不过这个大小现在被解释成了“事件发生的概率”.


既然事件之间同样可以取并, 取交, 取补集, 而且我们同样希望对于互不相交的事件有可列可加性, 那概率本身就是一种测度. 唯一额外要求的只是整个样本空间  $\Omega$  必然发生, 所以  $\mathbb{P}(\Omega) = 1$ . 因此一个概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$ , 就是一个总测度为 1 的特殊测度空间. 换句话说, 测度论研究的是一般意义上的“大小”, 而概率论把这个大小解释成概率, 并额外把整个空间的大小归一化成了 1.

不过, 我们研究概率论并不只是为了给事件赋予概率. 很多时候我们关心的是随机变量, 以及随机变量的期望, 方差等等. 而随机变量就是定义在概率空间上的可测函数, 所以接下来还需要知道什么样的函数是“可以被测量的”, 以及应该怎样对这样的函数进行积分. 这就会自然引出可测映射和 Lebesgue 积分.

从积分的角度来看, 我们其实又可以重新理解一遍为什么前面需要  $\sigma$ -代数.

我们以前学 Riemann 积分的时候, 大概是在定义域上进行划分. 比如对于  $f: [a, b] \rightarrow \mathbb{R}$ , 我们把  $[a, b]$  切成很多很小的区间, 然后在每一个区间上取一个函数值作为高度, 用很多细长的矩形去逼近函数下面的面积. 粗略地说, Riemann 积分是在“竖着切”.

而 Lebesgue 积分的想法某种程度上反了过来. 与其问“每一小段  $x$  上面的  $f(x)$  有多高”, 我们可以按照函数值去看, 被  $f$  映到某一段高度里面的那些  $x$  组成了多大的集合. 也就是说, 我们开始关心类似  $f^{-1}([a, b])$  这样的集合到底有多大.



但是这样一来就会出现一个很关键的问题. 如果我们想知道落在某一段函数值中的  $x$  组成的原像具有多大测度, 那首先就必须保证这个原像是一个我们能够测量的集合. 比如对于  $f: X \rightarrow \mathbb{R}$ , 如果我们想讨论“ $f(x) \leq a$  的那些  $x$  有多大”, 实际上就是在讨论集合  $f^{-1}((-\infty, a])$ . 所以我们自然希望这样的原像属于  $X$  上的  $\sigma$ -代数  $\mathcal{F}$ .

这也就是可测映射的基本想法. 如果  $(X, \mathcal{F})$  和  $(Y, \mathcal{G})$  都是可测空间, 那我们要求一个函数  $f: X \rightarrow Y$  满足: 对于每一个  $B \in \mathcal{G}$ , 都有  $f^{-1}(B) \in \mathcal{F}$ . 换句话说,  $Y$  中所有我们能够“辨认”的集合, 拉回到  $X$  以后仍然必须是可测量的.

所以  $\sigma$ -代数在这里又出现了一次. 前面我们需要它, 是因为我们想要测量复杂的集合; 现在我们需要它, 是因为我们想要测量一个函数到底把多少东西送到了某一段取值里面.

有了这个条件以后, 我们就可以开始定义 Lebesgue 积分. 最简单的情况是一个非负简单函数  $s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$ , 其中  $a_i \geq 0$ , 每一个  $A_i$  都是可测集, 并且可以通过细分把这些  $A_i$  看成两两不交. 那么它的积分自然可以定义成

$$\int_X s d\mu = \sum_{i=1}^n a_i \mu(A_i).$$

这里的意思其实很直接, 函数在  $A_i$  上的高度是  $a_i$ , 而  $A_i$  的“大小”是  $\mu(A_i)$ , 所以这一层贡献的大小就是  $a_i\mu(A_i)$ .

对于一般的非负可测函数  $f$ , 我们再用越来越精细的简单函数从下面去逼近它, 最后把这些简单函数积分的上确界定义成  $f$  的 Lebesgue 积分. 从这个角度来看, Lebesgue 积分就是把“测量集合”这件事进一步延伸到了“测量函数”.

而这也正好回到概率论. 一个随机变量  $X: \Omega \rightarrow \mathbb{R}$  就是一个可测函数; 当  $X$  可积时, 它的期望就是关于概率测度  $\mathbb{P}$  的 Lebesgue 积分:

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

因此我们前面引入测度空间并不是单纯为了重新包装概率的定义. 后面概率论里随机变量, 分布, 期望, 方差乃至随机过程的大量内容, 都会建立在“可测映射 + Lebesgue 积分”这套结构上.

## 2.1 可测空间, 测度, Lebesgue 积分

### 2.1.1 可测空间与 $\sigma$ -代数

前面已经解释过为什么会需要  $\sigma$ -代数, 现在来看正式定义. 这里我们先换一种方式, 从集合之间的运算看这个对象.

假设  $A, B \subseteq X$  都是我们已经能够测量的集合. 那如果我们还想测量  $A \cup B$ , 一个比较自然的办法就是把它拆成两部分: 一部分是  $A$  和  $B$  的交  $A \cap B$ , 另一部分是只属于其中一个集合的地方, 也就是它们的对称差

$$A \Delta B = (A \setminus B) \cup (B \setminus A).$$

这两部分彼此不交, 而且刚好拼成整个  $A \cup B$ , 也就是

$$A \cup B = (A \Delta B) \sqcup (A \cap B).$$

所以如果  $\mu$  是我们想要的测度, 自然应该有  $\mu(A \cup B) = \mu(A \Delta B) + \mu(A \cap B)$ . 也就是说, 为了让“测量集合”对这种基本的分解保持稳定, 如果  $A$  和  $B$  都是可测的, 那我们至少也希望  $A \cap B$  和  $A \Delta B$  仍然可测.

下面先看一个偏代数、但以后偶尔有用的等价视角. 在  $\mathcal{P}(X)$  上, 我们可以把对称差  $\Delta$  看成某种“加法”, 把交  $\cap$  看成某种“乘法”. 比如  $A \Delta A = \emptyset$ , 所以每个元素都是自己的“加法逆元”, 而  $A \cap A = A$ , 所以这个乘法还是幂等的. 在这两个运算下,  $\mathcal{P}(X)$  构成一个布尔环 (Boolean ring).

因此我们也可以先采用下面这个等价定义来理解  $\sigma$ -代数.

#### 定义 2.1.

$\sigma$ -代数是指集合族  $\mathcal{F} \subseteq \mathcal{P}(X)$ , 其满足:

1.  $X \in \mathcal{F}$ ;
2. 对于任意  $A, B \in \mathcal{F}$ , 都有  $A \Delta B \in \mathcal{F}$ ;
3. 对于任意  $A_1, A_2, \dots \in \mathcal{F}$ , 都有

$$\bigcap_{n=1}^{\infty} A_n \in \mathcal{F}.$$

这和通常使用补集和可列并给出的定义等价. 首先因为  $X \in \mathcal{F}$ , 对于  $A \in \mathcal{F}$  有  $A^c = X \Delta A \in \mathcal{F}$ , 所以补集自动存在. 有了补集和可列交以后, 根据 De Morgan 律又有  $\bigcup_{n=1}^{\infty} A_n = (\bigcap_{n=1}^{\infty} A_n^c)^c \in \mathcal{F}$ , 所以可列并也自动存在.

反过来, 如果按照通常的方式要求对于补集和可列并封闭, 那么交可以由 De Morgan 律得到, 而对称差也可以写成  $A \Delta B = (A \cap B^c) \cup (B \cap A^c)$ , 所以两种定义描述的是同一个东西.

#### 定义 2.2.

可测空间是指二元组  $(X, \mathcal{F})$ , 其中  $X$  为集合,  $\mathcal{F}$  为  $X$  上的  $\sigma$ -代数.

那么我们就可以把  $X$  理解为我们真正关心的空间. 在强调概率的时候我们常常使用  $\Omega$  来表示  $X$ , 并称之为样本空间, 而  $\mathcal{F}$  则规定  $X$  的哪些子集是我们可以“测量”的. 在概率论中我们也称  $\mathcal{F}$  为事件域, 称其中的元素为事件.

**例 2.3.**

对于任意集合  $X$ , 总有两个最自然的  $\sigma$ -代数, 即  $\{\emptyset, X\}$  以及  $\mathcal{P}(X)$ . 当  $X = \emptyset$  时二者恰好相同.

如果考虑拓扑空间  $(X, \tau)$ , 那我们已经有了—族很自然的子集, 也就是开集. 既然拓扑本身就在描述这个空间中哪些集合在局部结构上是“自然”的, 那我们希望这些开集至少都是可以测量的.

不过一个拓扑  $\tau$  本身一般并不是  $\sigma$ -代数. 它对于任意并封闭, 对有限交封闭, 但是并不要求对于补集封闭. 所以我们需要在  $\tau$  的基础上继续补充一些集合, 直到得到一个完整的  $\sigma$ -代数.

**定义 2.4.**

由集合族  $\mathcal{A} \subseteq \mathcal{P}(X)$  生成的  $\sigma$ -代数是指

$$\sigma(\mathcal{A}) = \bigcap_{\substack{\mathcal{F} \supseteq \mathcal{A} \\ \mathcal{F} \text{ is a } \sigma\text{-algebra}}} \mathcal{F}.$$

也就是说,  $\sigma(\mathcal{A})$  是所有包含  $\mathcal{A}$  的  $\sigma$ -代数之交.

这里  $\sigma(\mathcal{A})$  的确是一个  $\sigma$ -代数, 因为任意一族  $\sigma$ -代数的交仍然是一个  $\sigma$ -代数. 而且由定义有  $\mathcal{A} \subseteq \sigma(\mathcal{A})$ , 并且对于任意包含  $\mathcal{A}$  的  $\sigma$ -代数  $\mathcal{F}$ , 都有  $\sigma(\mathcal{A}) \subseteq \mathcal{F}$ . 所以  $\sigma(\mathcal{A})$  正是包含  $\mathcal{A}$  的最小  $\sigma$ -代数.

**定义 2.5.**

拓扑空间  $(X, \tau)$  的 Borel  $\sigma$ -代数是指

$$\mathcal{B}(X) = \sigma(\tau),$$

其中的元素称为 **Borel 集**.

比如在  $\mathbb{R}$  上取通常的拓扑, 那所有开区间  $(a, b)$  都是 Borel 集. 因为 Borel  $\sigma$ -代数对于补集和可列运算封闭, 所以闭区间, 半开区间, 单点集以及很多更复杂的集合也自然都是 Borel 集. 事实上,

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(a, b) \mid a < b\}),$$

而且我们甚至不需要所有开区间, 比如

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, a] \mid a \in \mathbb{R}\}).$$

所以如果一个空间本身已经带有拓扑, Borel  $\sigma$ -代数可以看作最自然的一种可测结构: 拓扑告诉我们哪些集合在空间结构上是自然的, 而 Borel  $\sigma$ -代数则把这些集合扩张成—族对于可数集合运算稳定的可测集合.

很多时候我们已经知道一个  $\sigma$ -代数是由—族非常简单的集合生成的, 那自然会希望以后验证某个性质的时候也只需要在这些简单集合上检查, 而不用真的把整个  $\sigma$ -代数里面所有集合都处理一遍.  $\pi$ - $\lambda$  定理正是处理这类问题的工具.

**定义 2.6.**

$\pi$ -系是指对于有限交封闭的集合族  $\mathcal{P} \subseteq \mathcal{P}(X)$ .

**定义 2.7.**

$\lambda$ -系, 也称为 Dynkin 系, 是指集合族  $\mathcal{D} \subseteq \mathcal{P}(X)$ , 其满足:

1.  $X \in \mathcal{D}$ ;
2. 对于  $A, B \in \mathcal{D}$ , 如果  $A \subseteq B$ , 则  $B \setminus A \in \mathcal{D}$ ;

3. 对于两两不交的  $A_1, A_2, \dots \in \mathcal{D}$ , 有

$$\bigsqcup_{n=1}^{\infty} A_n \in \mathcal{D}.$$

$\lambda$ -系比  $\sigma$ -代数弱不少, 因为它只要求对于彼此不交的可列并封闭. 不过一旦一个集合族既是  $\pi$ -系又是  $\lambda$ -系, 它实际上就是一个  $\sigma$ -代数.

**定理 2.8 ( $\pi$ - $\lambda$  定理).**

令  $\mathcal{P}$  为  $X$  上的一个  $\pi$ -系,  $\mathcal{D}$  为一个包含  $\mathcal{P}$  的  $\lambda$ -系. 如果  $\mathcal{P} \subseteq \mathcal{D}$ , 则有

$$\sigma(\mathcal{P}) \subseteq \mathcal{D}.$$

证明. 证明较长, 这里暂不展开. □

$\pi$ - $\lambda$  定理告诉我们, 如果一族生成元对于有限交已经足够稳定, 那么要把某个性质从这些生成元推广到整个  $\sigma$ -代数, 很多时候只需要证明满足这个性质的集合构成一个  $\lambda$ -系即可.

**推论 2.9.**

令  $\mu, \nu$  为  $(X, \mathcal{F})$  上的有限测度,  $\mathcal{P}$  为满足  $\sigma(\mathcal{P}) = \mathcal{F}$  的  $\pi$ -系. 如果  $\mu(X) = \nu(X)$ , 并且对于任意  $A \in \mathcal{P}$  都有  $\mu(A) = \nu(A)$ , 则有

$$\mu = \nu.$$

比如在  $\mathbb{R}$  上, 因为半直线族  $\{(-\infty, a] \mid a \in \mathbb{R}\}$  生成整个  $\mathcal{B}(\mathbb{R})$ , 所以后面要证明两个概率分布相同的时候, 很多时候只需要比较这些半直线的概率即可. 这也就是为什么分布函数能够唯一确定一个概率分布.

正如拓扑空间之间存在连续映射一样, 可测空间之间也存在可测映射.

**定义 2.10.**

令  $(X, \mathcal{F})$  以及  $(Y, \mathcal{G})$  为可测空间. 称映射  $f: X \rightarrow Y$  为**可测映射**, 是指其满足对于任意  $A \in \mathcal{G}$ , 都有

$$f^{-1}(A) \in \mathcal{F}.$$

这很像连续映射定义的翻版. 连续映射要求开集的原像仍然是开集, 而可测映射要求可测集的原像仍然是可测集. 如果使用一点范畴语言, 也可以考虑范畴 **Meas**: 它的对象是可测空间, 态射是可测映射. 不熟悉这套语言也没有关系, 这里主要只是强调可测映射是可测空间之间合适的结构保持映射.

**注 2.11.**

稍后我们将会发现, 随机变量就是概率空间到  $\mathbb{R}$  的可测映射.

## 2.1.2 测度

有了可测空间  $(X, \mathcal{F})$  以后, 我们只是规定了哪些集合可以被测量, 但还没有真正告诉这些集合应该有多大. 所以下一步自然就是在  $\mathcal{F}$  上定义一个函数, 给每一个可测集赋予一个非负的“大小”.

当然这个赋值不能是随便的. 首先空集什么都没有, 所以它的大小自然应该是 0. 更重要的是, 如果我们把一个集合拆成若干个彼此不相交的部分, 那整个集合的大小应该等于这些部分大小的和. 而由于前面的  $\sigma$ -代数允许我们处理可列次的集合运算, 这里自然也希望这个加法可以一直延伸到可列多个集合.

**定义 2.12.**

令  $(X, \mathcal{F})$  为可测空间. 称函数  $\mu: \mathcal{F} \rightarrow [0, \infty]$  为  $X$  上的一个 **测度**, 是指其满足:

1.  $\mu(\emptyset) = 0$ ;
2. 对于任意一列两两不交的可测集  $A_1, A_2, \dots \in \mathcal{F}$ , 都有

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

测度空间是指三元组  $(X, \mathcal{F}, \mu)$ , 其中  $(X, \mathcal{F})$  为可测空间,  $\mu$  为  $\mathcal{F}$  上的测度.

第二个条件通常称为可列可加性或者  $\sigma$ -可加性.

- 从可列可加性马上就可以得到有限可加性. 比如如果  $A \cap B = \emptyset$ , 那么有  $\mu(A \sqcup B) = \mu(A) + \mu(B)$ .
- 如果  $A \subseteq B$ , 那么  $B = A \sqcup (B \setminus A)$ , 所以  $\mu(B) = \mu(A) + \mu(B \setminus A)$ , 从而有  $\mu(A) \leq \mu(B)$ . 这称为测度的单调性.
- 如果进一步有  $\mu(A) < \infty$ , 那么由同一个分解还可以得到  $\mu(B \setminus A) = \mu(B) - \mu(A)$ . 这里之所以需要有限性, 是因为扩展实数中不能随便处理  $\infty - \infty$ .
- 对于一般的两个可测集  $A, B$ , 前面的对称差分解给出

$$\mu(A \cup B) = \mu(A \Delta B) + \mu(A \cap B).$$

- 将  $A$  和  $B$  分别拆开以后还可以得到熟悉的包含排除公式

$$\mu(A \cup B) + \mu(A \cap B) = \mu(A) + \mu(B).$$

还有一种后面会反复遇到的集合, 就是大小为 0 的集合.

**定义 2.13.**

令  $(X, \mathcal{F}, \mu)$  为测度空间. 称可测集  $N \in \mathcal{F}$  为**零测集**, 是指其满足

$$\mu(N) = 0.$$

零测集虽然不一定真的是空集, 但是从测度的角度来看它已经和空集非常接近. 比如在  $\mathbb{R}$  上取 Lebesgue 测度时, 每个单点集都是零测集, 因而任何可数集也都是零测集.

不过这里还有一个小问题. 如果  $N$  是零测集而  $A \subseteq N$ , 那按照我们的直觉  $A$  当然也应该具有大小 0, 但是  $A$  却未必属于原来的  $\sigma$ -代数  $\mathcal{F}$ , 所以  $\mu(A)$  甚至可能没有定义. 于是我们还需要区分测度空间是否完备.

**定义 2.14.**

令  $(X, \mathcal{F}, \mu)$  为测度空间. 称其为**完备测度空间**, 是指对于任意零测集  $N \in \mathcal{F}$  以及任意子集  $A \subseteq N$ , 都有  $A \in \mathcal{F}$ .

也就是说, 在完备测度空间中, 零测集的所有子集都会被自动补进可测集合里面. 后面我们会看到, Lebesgue 测度是完备的, 而只定义在 Borel  $\sigma$ -代数上的 Lebesgue 测度并不完备.

有了零测集以后, 我们也可以正式定义一个后面会经常出现的说法.

**定义 2.15.**

令  $(X, \mathcal{F}, \mu)$  为测度空间. 称一个关于  $x \in X$  的性质**几乎处处成立**, 是指存在零测集  $N$ , 使得这个性质对于所有  $x \in X \setminus N$  都成立. 常记作  $\mu$ -a.e., 或者在没有歧义的时候直接写作 a.e.

比如  $f = g$  a.e. 就是说它们可以在一个零测集上不相同, 但是除此以外完全一样. 对于 Lebesgue 积分而言, 这种零测集上的差别通常是看不见的.

测度之所以允许取值为  $\infty$ , 也是因为我们并不希望只研究有限大小的空间. 比如  $\mathbb{R}$  上通常的长度显然满足  $\mu(\mathbb{R}) = \infty$ , 但这并不妨碍它成为一个很自然的测度.

**定义 2.16.**

令  $(X, \mathcal{F}, \mu)$  为测度空间.

- 称  $\mu$  为一个**有限测度**, 是指其满足  $\mu(X) < \infty$ .
- 称  $\mu$  为一个 **$\sigma$ -有限测度**, 是指存在一列可测集  $A_1, A_2, \dots \in \mathcal{F}$ , 满足

$$X = \bigcup_{n=1}^{\infty} A_n, \quad \mu(A_n) < \infty.$$

显然有限测度一定是  $\sigma$ -有限测度, 但是反过来并不成立.  $\sigma$ -有限大概就是说, 虽然整个空间可能有无限大的测度, 但是仍然可以被可列多个有限测度的部分覆盖.

比如  $\mathbb{R}$  上的 Lebesgue 测度并不是有限测度, 但是它是  $\sigma$ -有限的, 因为  $\mathbb{R} = \bigcup_{n=1}^{\infty} [-n, n]$  而每个  $[-n, n]$  都只有有限测度.

这个条件看起来只是一个很弱的技术要求, 但是实际上非常常见. 后面我们遇到 Radon - Nikodym 定理, Fubini 定理等结果的时候都会再次看到它.

概率测度当然是一个很特殊的有限测度, 因为对于概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$  总有  $\mathbb{P}(\Omega) = 1$ .

如果空间  $X$  本身还带有拓扑, 那我们通常还会希望测度和这个拓扑之间能够比较好地配合. 这就会引出 Radon 测度.

**定义 2.17.**

令  $X$  为局部紧 Hausdorff 空间,  $\mu$  为定义在  $\mathcal{B}(X)$  上的 Borel 测度. 称  $\mu$  为 **Radon 测度**, 是指其满足:

1. 在紧集上有限;
2. 对于任意 Borel 集  $A$ , 有内正则性

$$\mu(A) = \sup\{\mu(K) \mid K \subseteq A, K \text{ compact}\};$$

3. 对于任意 Borel 集  $A$ , 有外正则性

$$\mu(A) = \inf\{\mu(U) \mid A \subseteq U, U \text{ open}\}.$$

这个定义大概是在说, 一个集合的测度既可以从里面用紧集逐渐逼近, 也可以从外面用开集逐渐逼近. 所以 Radon 测度描述的主要不是“整个空间有多大”, 而是测度和拓扑之间是否配合得足够好.

需要注意的是, 不同文献对于 Radon 测度在一般拓扑空间上的定义会有一点区别. 对我们后面主要会遇到的  $\mathbb{R}^n$  之类的空间来说, 大概把它理解成“局部有限并且正则的 Borel 测度”就够了.  $\mathbb{R}^n$  上 Lebesgue 测度限制到 Borel  $\sigma$ -代数以后就是最重要的 Radon 测度之一.

**例 2.18.**

在任意集合  $X$  上都可以定义计数测度

$$\mu(A) = \#A,$$

其中有限集取它的元素个数, 无限集则令  $\mu(A) = \infty$ . 这大概是最简单的非平凡测度.

**例 2.19.**

固定一个点  $x \in X$ , 可以定义 Dirac 测度  $\delta_x$  为

$$\delta_x(A) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

也就是说, 整个测度都集中在一个点  $x$  上.



而在概率论里面, 概率  $\mathbb{P}$  本身就是一个测度, 只不过额外满足  $\mathbb{P}(\Omega) = 1$ . 所以概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$  可以看成是一个总测度为 1 的测度空间.

### Lebesgue 测度

接下来我们真正关心的一个重要例子就是  $\mathbb{R}^d$  上的 Lebesgue 测度. 它希望严格实现我们前面一直使用的“长度”, “面积”和“体积”这些直觉.

按照我们一开始的想法, 要测量一个复杂的集合, 一个很自然的方法就是先从我们已经知道怎么计算大小的简单集合开始, 然后用这些简单集合去覆盖它. 在  $\mathbb{R}^d$  中, 最方便的简单集合就是半开矩形.

#### 定义 2.20 (体积函数).

半开矩形是指形如

$$[a, b) = \prod_{i=1}^d [\alpha_i, \beta_i)$$

的集合, 其中  $a = (\alpha_1, \dots, \alpha_d)$ ,  $b = (\beta_1, \dots, \beta_d) \in \mathbb{R}^d$ , 并且对于所有  $i = 1, \dots, d$  都有  $\alpha_i \leq \beta_i$ .

半开矩形  $[a, b)$  的体积定义为

$$\lambda([a, b)) = \prod_{i=1}^d (\beta_i - \alpha_i).$$

如果存在某个  $i$  使得  $\alpha_i = \beta_i$ , 那么  $[a, b) = \emptyset$ , 此时自然有  $\lambda([a, b)) = 0$ .

#### 注 2.21.

原则上我们也可以从开矩形或者闭矩形出发, 但是半开矩形  $[a, b)$  在集合运算上具有更好的性质. 所有半开矩形构成一个半环, 特别是两个半开矩形之差总可以写成有限多个彼此不交的半开矩形之并.

不过这里其实出现了一个更加一般的问题. 我们现在只在这些非常简单的矩形上知道“大小”是什么, 但是最终却希望在一个很大的  $\sigma$ -代数上定义测度. 那是否存在一种一般的方法, 可以把简单集合上的测度自动扩张到它们所生成的  $\sigma$ -代数上呢?

答案就是 Carathéodory 扩张定理.

首先, 半开矩形本身只构成一个半环, 所以我们可以考虑由有限多个彼此不交的半开矩形之并所构成的集合代数  $\mathcal{A}$ . 对于  $A = \bigsqcup_{i=1}^n I_i \in \mathcal{A}$ , 自然定义  $\lambda_0(A) = \sum_{i=1}^n \lambda(I_i)$ . 这样我们就把矩形上的体积扩张到了一个集合代数上.

#### 定义 2.22 (预测度).

令  $\mathcal{A}$  为  $X$  上的一个集合代数. 称函数  $\mu_0: \mathcal{A} \rightarrow [0, \infty]$  为一个预测度, 是指其满足  $\mu_0(\emptyset) = 0$ , 并且对于任意两两不交的  $A_1, A_2, \dots \in \mathcal{A}$ , 如果  $\bigsqcup_{n=1}^{\infty} A_n \in \mathcal{A}$ , 则有

$$\mu_0\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu_0(A_n).$$

这里和真正的测度相比已经非常接近了, 唯一的问题只是  $\mathcal{A}$  还不是一个  $\sigma$ -代数. Carathéodory 扩张定理告诉我们, 一个预测度可以继续扩张成真正的测度.

#### 定理 2.23 (Carathéodory 扩张定理).

令  $\mathcal{A}$  为  $X$  上的一个集合代数,  $\mu_0$  为  $\mathcal{A}$  上的预测度. 则存在定义在  $\sigma(\mathcal{A})$  上的测度  $\mu$ , 使得

$$\mu|_{\mathcal{A}} = \mu_0.$$

如果进一步  $\mu_0$  是  $\sigma$ -有限的, 则这样的扩张唯一.

证明. 证明较长, 这里不展开; 下面只保留与 Lebesgue 测度构造有关的思路.  $\square$

所以大概来说, 我们根本不需要一开始就在所有复杂集合上定义测度. 只需要先在一批足够简单, 而且能够生成我们想要的  $\sigma$ -代数的集合上把大小定义好, 后面的扩张就可以交给 Carathéodory.

这个扩张的具体做法其实也和我们一开始“拿小方块覆盖复杂图形”的想法一致. 第一步是先不管一个集合到底是否真的可测, 直接给所有子集定义一个外部的大小.

### 定义 2.24 (Lebesgue 外测度).

Lebesgue 外测度是指函数  $\theta: \mathcal{P}(\mathbb{R}^d) \rightarrow [0, \infty]$ , 其中对于任意  $A \subseteq \mathbb{R}^d$  定义

$$\theta(A) = \inf \left\{ \sum_{n=1}^{\infty} \lambda(I_n) \mid A \subseteq \bigcup_{n=1}^{\infty} I_n, I_n \text{ 为半开矩形} \right\}.$$

也就是说, 我们用可列多个已经知道体积的半开矩形去覆盖  $A$ , 然后在所有覆盖方法的总体积中取下确界. 这基本上就是把一开始“用很多小方块去逼近一个复杂图形”的想法严格化了.

Lebesgue 外测度满足  $\theta(\emptyset) = 0$ , 单调性, 以及可列次可加性

$$\theta \left( \bigcup_{n=1}^{\infty} A_n \right) \leq \sum_{n=1}^{\infty} \theta(A_n).$$

这里需要特别注意,  $\theta$  现在还只是一个外测度, 并不是定义在整个  $\mathcal{P}(\mathbb{R}^d)$  上的测度. 一般情况下上面的不等式并不能变成等号, 所以我们还需要从所有集合里面挑出那些真正表现良好的集合.

### 定义 2.25 (Carathéodory 可测集).

令  $\theta$  为  $\mathbb{R}^d$  上的 Lebesgue 外测度. 称集合  $E \subseteq \mathbb{R}^d$  为  $\theta$ -可测集, 是指其满足对于任意  $A \subseteq \mathbb{R}^d$  都有

$$\theta(A) = \theta(A \cap E) + \theta(A \setminus E).$$

这个条件大概是在说,  $E$  可以把任意集合  $A$  干净地切成“在  $E$  里面”和“在  $E$  外面”两部分, 而这个切割并不会凭空增加或者损失大小.

令

$$\mathcal{L}(\mathbb{R}^d) = \left\{ E \subseteq \mathbb{R}^d \mid \forall A \subseteq \mathbb{R}^d, \theta(A) = \theta(A \cap E) + \theta(A \setminus E) \right\}.$$

Carathéodory 的结果告诉我们,  $\mathcal{L}(\mathbb{R}^d)$  是一个  $\sigma$ -代数, 而且  $\theta$  限制到它上面以后就具有真正的可列可加性.

### 定义 2.26 (Lebesgue 测度).

$\mathbb{R}^d$  上的 Lebesgue  $\sigma$ -代数是指  $\mathcal{L}(\mathbb{R}^d)$ , 其中的元素称为 Lebesgue 可测集.

$\mathbb{R}^d$  上的 Lebesgue 测度是指测度

$$\lambda_d = \theta|_{\mathcal{L}(\mathbb{R}^d)}.$$

于是我们最终得到了测度空间  $(\mathbb{R}^d, \mathcal{L}(\mathbb{R}^d), \lambda_d)$ . 整个过程大概就是

矩形上的体积  $\rightarrow$  预测度  $\rightarrow$  外测度  $\rightarrow$  Carathéodory 可测集  $\rightarrow$  Lebesgue 测度.

这里还有一个值得注意的地方.  $\mathbb{R}^d$  上的 Borel  $\sigma$ -代数满足

$$\mathcal{B}(\mathbb{R}^d) \subsetneq \mathcal{L}(\mathbb{R}^d).$$

也就是说, 所有 Borel 集都是 Lebesgue 可测的, 但是还存在不是 Borel 集的 Lebesgue 可测集.

两者之间的差别基本上就来自我们前面说的零测集. 将 Lebesgue 测度先限制在  $\mathcal{B}(\mathbb{R}^d)$  上, 再把所有 Borel 零测集的任意子集都补进来, 得到的正好就是  $\mathcal{L}(\mathbb{R}^d)$ . 所以 Lebesgue  $\sigma$ -代数也可以理解成 Borel  $\sigma$ -代数关于 Lebesgue 测度的测度完备化.

特别地, Lebesgue 测度是完备测度. 而它限制在 Borel  $\sigma$ -代数上的版本虽然是 Radon 测度, 却并不是完备的.



### 2.1.3 Lebesgue 积分

现在, 我们来介绍 Lebesgue 积分. 下设  $(X, \mathcal{F}, \mu)$  是一个测度空间.

Lebesgue 积分的想法其实和我们前面说的一样. Riemann 积分大概是在定义域上竖着切, 而 Lebesgue 积分更接近按照函数值横着切. 所以最简单的情况自然就是函数只取有限多个值, 这样每一个高度下面对应一个可测集, 我们拿“高度  $\times$  这一块集合的测度”再全部加起来就行.

#### 定义 2.27 (非负简单函数及其积分).

非负简单函数是指可测集的指示函数的非负有限线性组合, 即形如  $s = \sum_{i=1}^n a_i 1_{E_i}$  的函数, 其中  $a_i \geq 0$ ,  $E_i \in \mathcal{F}$ .

非负简单函数  $s$  的 Lebesgue 积分是指

$$\int_X s \, d\mu = \sum_{i=1}^n a_i \mu(E_i),$$

其中约定  $0 \cdot \infty = 0$ . 将这些集合进一步拆成两两不交的部分以后, 由测度的可加性可以验证这个值只和  $s$  本身有关, 和它具体如何写成指示函数的线性组合无关.

对于一般的非负函数, 我们当然不太可能直接把它精确地写成有限多个指示函数的线性组合. 那一个很自然的办法就是拿越来越精细的简单函数从下面去逼近它.

#### 定义 2.28 (非负可测函数及其积分).

非负可测函数是指可测函数  $f: X \rightarrow [0, \infty]$ .

非负可测函数  $f$  的 Lebesgue 积分是指

$$\int_X f \, d\mu = \sup \left\{ \int_X s \, d\mu \mid s \text{ 是非负简单函数且 } s \leq f \right\}.$$

这个积分允许取值  $+\infty$ .

这个定义的直觉很直接: 我们把所有能够放在  $f$  下面的简单函数都拿出来, 看它们的积分最多能够逼近到哪里, 然后把这个上确界定义成  $f$  的积分.

对于一般实值函数, 只需要把正负两部分拆开.

#### 定义 2.29 (Lebesgue 可积函数及其积分).

令  $f: X \rightarrow \mathbb{R}$  为可测函数, 并记  $f_+ = \max\{f, 0\}$ ,  $f_- = \max\{-f, 0\}$ . 则  $f_+$  和  $f_-$  都是非负可测函数, 并且  $f = f_+ - f_-$ ,  $|f| = f_+ + f_-$ .

称  $f$  为 **Lebesgue 可积函数**, 或简称**可积函数**, 是指  $f_+$  和  $f_-$  都具有有限的 Lebesgue 积分. 此时定义

$$\int_X f \, d\mu = \int_X f_+ \, d\mu - \int_X f_- \, d\mu.$$

因此  $f$  可积也就等价于  $\int_X |f| \, d\mu < \infty$ . 上面几个定义在重合的地方是一致的.

我们之后还会经常只在某个可测集上积分, 所以对于  $A \in \mathcal{F}$  约定

$$\int_A f \, d\mu := \int_X f 1_A \, d\mu.$$

特别地,  $\int_A 1 \, d\mu = \mu(A)$ . 所以从这个角度来看, 测度本身其实也可以看成指示函数的积分.

#### 定义 2.30 (可积向量值函数及其积分).

令  $V$  为有限维  $\mathbb{R}$ -向量空间, 并赋予通常的 Borel  $\sigma$ -代数,  $f: X \rightarrow V$  为可测函数. 取  $V$  的一组基  $v_1, \dots, v_n$ , 并写成  $f = \sum_{i=1}^n f_i v_i$ .

称  $f$  为可积函数, 是指每个  $f_i$  都在实值可积函数定义的意义下可积. 此时定义

$$\int_X f \, d\mu = \sum_{i=1}^n \left( \int_X f_i \, d\mu \right) v_i.$$

由积分的线性性可以验证这个定义和基的选取无关.

特别地,  $\mathbb{C}$  可以被看成二维实向量空间, 所以复值函数的积分也包括在这里面.

### 一些例子

最典型的情况是  $\mathbb{R}^n$  上的 Lebesgue 测度. 比如在一个有界矩形上, 如果  $f$  是 Riemann 可积函数, 那么它也是 Lebesgue 可积的, 并且两种积分给出的值相同. 不过对于广义 Riemann 积分就不能直接这么说, 因为广义 Riemann 积分可能依靠正负抵消而收敛, 但对应函数并不 Lebesgue 可积.

另一个很简单的例子是计数测度. 比如取  $X = \mathbb{N}$ ,  $\mu$  为计数测度, 那么

$$\int_X f \, d\mu = \sum_{n=1}^{\infty} f(n)$$

在有意义的时候就是普通的级数. 所以 Lebesgue 积分同时包含了我们以前认为有些不同的“积分”和“求和”.

### 基本性质与收敛定理

与前文相同, 下设  $(X, \mathcal{F}, \mu)$  为测度空间.

#### 命题 2.31 (单调性).

令  $f, g$  为非负可测函数或者实值可积函数. 如果  $f \leq g$  a.e., 则有

$$\int f \leq \int g.$$

特别地, 如果  $f = g$  a.e., 则有  $\int f = \int g$ .

证明. 依次按照简单函数积分, 非负可测函数积分和实值可积函数积分的定义验证即可.  $\square$

#### 命题 2.32 (数乘).

令  $f$  为非负可测函数且  $a \geq 0$ , 或者令  $f$  为实值可积函数且  $a \in \mathbb{R}$ . 则有

$$\int af = a \int f.$$

证明. 依次按照简单函数积分, 非负可测函数积分和实值可积函数积分的定义验证即可.  $\square$

接下来需要说明一个我们在定义 Lebesgue 积分的时候其实已经默认使用的事实, 也就是非负可测函数确实都可以由简单函数从下面不断逼近.

#### 引理 2.33 (简单函数逼近).

令  $f: X \rightarrow [0, \infty]$  为可测函数. 对于正整数  $n$ , 定义

$$\varphi_n(x) = \begin{cases} 2^{-n} \lfloor 2^n f(x) \rfloor, & f(x) < n, \\ n, & f(x) \geq n. \end{cases}$$

则每个  $\varphi_n$  都是非负简单函数, 并且  $\varphi_1 \leq \varphi_2 \leq \cdots \leq f$ , 且  $\varphi_n(x) \rightarrow f(x)$ .

证明. 每个  $\varphi_n$  只取有限多个值, 而这些取值对应的原像都可以由  $f$  的区间原像写出, 所以  $\varphi_n$  是可测简单函数. 当  $f(x) < n$  时有  $0 \leq f(x) - \varphi_n(x) < 2^{-n}$ , 而如果  $f(x) = \infty$ , 那么  $\varphi_n(x) = n \rightarrow \infty$ . 其余性质直接验证即可.  $\square$

这其实也就是我们前面说 Lebesgue 积分是在“横着切”的一个比较严格的版本. 我们把函数的值域按照越来越细的网格切开, 得到一系列阶梯状的简单函数, 然后让它们从下面逐渐贴近原来的函数.

**定理 2.34 (单调收敛定理).**

令  $f, f_1, f_2, \dots$  为非负可测函数. 如果  $f_n \leq f_{n+1}$ , 并且  $f_n \rightarrow f$  逐点成立, 则有

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 由单调性,  $(\int f_n)$  单调递增且  $\int f_n \leq \int f$ , 所以  $\lim_n \int f_n \leq \int f$ .

反过来, 任取非负简单函数  $\phi \leq f$  以及  $\alpha \in (0, 1)$ , 令  $E_n = \{x \in X \mid f_n(x) \geq \alpha\phi(x)\}$ . 则  $E_n$  递增且  $\bigcup_n E_n = X$ , 因而

$$\int f_n \geq \int_{E_n} f_n \geq \alpha \int_{E_n} \phi.$$

对简单函数  $\phi$  而言,  $A \mapsto \int_A \phi d\mu$  是一个测度, 所以由测度对于递增集合列的连续性有  $\int_{E_n} \phi \rightarrow \int \phi$ . 因而  $\lim_n \int f_n \geq \alpha \int \phi$ . 最后令  $\alpha \rightarrow 1^-$ , 再对所有满足  $0 \leq \phi \leq f$  的简单函数取上确界即可.  $\square$

结合简单函数逼近引理和单调收敛定理, 每一个非负可测函数都可以由一系列递增的简单函数逼近, 而且这些简单函数的积分也同时趋于原函数的积分.

**命题 2.35 (可列加性).**

令  $f_1, f_2, \dots$  为非负可测函数. 则有

$$\int_X \sum_{k=1}^{\infty} f_k d\mu = \sum_{k=1}^{\infty} \int_X f_k d\mu.$$

证明. 先考虑两个函数. 分别取递增简单函数序列  $\phi_n \uparrow f_1$  和  $\psi_n \uparrow f_2$ , 那么  $\phi_n + \psi_n \uparrow f_1 + f_2$ . 由简单函数积分的加性以及单调收敛定理,

$$\int (f_1 + f_2) = \lim_n \int (\phi_n + \psi_n) = \int f_1 + \int f_2.$$

有限多个函数的情况由归纳得到. 最后令  $S_n = \sum_{k=1}^n f_k$ , 则  $S_n \uparrow \sum_{k=1}^{\infty} f_k$ , 再使用一次单调收敛定理即可.  $\square$

**引理 2.36 (Fatou 引理).**

令  $f_1, f_2, \dots$  为非负可测函数. 则有

$$\int \liminf_{n \rightarrow \infty} f_n \leq \liminf_{n \rightarrow \infty} \int f_n.$$

证明. 令  $g_k = \inf_{n \geq k} f_n$ , 则  $g_k$  是非负可测函数, 并且  $g_k \uparrow \liminf_n f_n$ . 由单调收敛定理,

$$\int \liminf_n f_n = \lim_{k \rightarrow \infty} \int g_k.$$

对任意  $j \geq k$  有  $g_k \leq f_j$ , 所以  $\int g_k \leq \inf_{j \geq k} \int f_j$ . 令  $k \rightarrow \infty$  即得结论.  $\square$

**定理 2.37 (控制收敛定理).**

令  $f, f_1, f_2, \dots$  为可测函数. 如果  $f_n \rightarrow f$  a.e., 并且存在可积函数  $g$  使得对于所有  $n$  都有  $|f_n| \leq g$  a.e., 则  $f$  可积, 并且

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 由  $f_n \rightarrow f$  a.e. 以及  $|f_n| \leq g$  a.e., 可以得到  $|f| \leq g$  a.e., 所以  $f$  可积.

对非负函数  $g + f_n$  和  $g - f_n$  分别使用 Fatou 引理, 得到

$$\begin{aligned} \int g + \int f &\leq \int g + \liminf_{n \rightarrow \infty} \int f_n, \\ \int g - \int f &\leq \int g - \limsup_{n \rightarrow \infty} \int f_n. \end{aligned}$$

因为  $\int g < \infty$ , 可以把它消掉, 从而有

$$\int f \leq \liminf_n \int f_n \leq \limsup_n \int f_n \leq \int f.$$

所以  $\int f_n \rightarrow \int f$ . □

**乘积测度与 Fubini 定理**

接下来我们考虑乘积空间. 令  $(X, \mathcal{F})$  和  $(Y, \mathcal{G})$  为两个可测空间. 从范畴语言看, 我们希望它们在 **Meas** 中也有对应的积.

**定义 2.38 (乘积可测空间).**

可测空间  $(X, \mathcal{F})$  和  $(Y, \mathcal{G})$  的乘积可测空间是指

$$(X \times Y, \mathcal{F} \otimes \mathcal{G}),$$

其中

$$\mathcal{F} \otimes \mathcal{G} = \sigma\{A \times B \mid A \in \mathcal{F}, B \in \mathcal{G}\}.$$

等价地,  $\mathcal{F} \otimes \mathcal{G}$  是使两个投影  $\pi_X: X \times Y \rightarrow X$  和  $\pi_Y: X \times Y \rightarrow Y$  同时可测的最小  $\sigma$ -代数. 因此  $(X \times Y, \mathcal{F} \otimes \mathcal{G})$  正是  $(X, \mathcal{F})$  和  $(Y, \mathcal{G})$  在 **Meas** 中的积.

现在再分别给两个空间放上测度  $\mu$  和  $\nu$ . 如果我们已经知道  $A$  和  $B$  的大小, 那矩形  $A \times B$  的大小自然应该是  $\mu(A)\nu(B)$ , 而 Carathéodory 扩张定理正好可以把这个赋值扩张到整个乘积  $\sigma$ -代数.

**定义 2.39 (乘积测度).**

令  $(X, \mathcal{F}, \mu)$  和  $(Y, \mathcal{G}, \nu)$  为  $\sigma$ -有限测度空间. 乘积测度  $\mu \otimes \nu$  是指定义在  $\mathcal{F} \otimes \mathcal{G}$  上唯一满足

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B)$$

的测度.

需要注意的是, 乘积可测空间确实是 **Meas** 中的范畴积, 但是乘积测度本身一般并不是某个测度空间范畴中的范畴积. 特别是在概率论中,  $\mu \otimes \nu$  对应的是具有边缘分布  $\mu, \nu$  的独立联合分布.

比如  $\mathbb{R}^2 = \mathbb{R} \times \mathbb{R}$  上的二维 Lebesgue 测度, 就可以理解成一维 Lebesgue 测度和自身的乘积.

有了乘积测度以后, 自然就会问一个很熟悉的问题: 如果  $f(x, y)$  定义在  $X \times Y$  上, 那我们能不能先对  $y$  积分, 再对  $x$  积分, 或者反过来?

对于非负函数, 答案由 Tonelli 定理给出.

**定理 2.40 (Tonelli 定理).**

令  $(X, \mathcal{F}, \mu)$  和  $(Y, \mathcal{G}, \nu)$  为  $\sigma$ -有限测度空间,  $f: X \times Y \rightarrow [0, \infty]$  为  $\mathcal{F} \otimes \mathcal{G}$ -可测函数. 则有

$$\begin{aligned} \int_{X \times Y} f \, d(\mu \otimes \nu) &= \int_X \left( \int_Y f(x, y) \, d\nu(y) \right) d\mu(x) \\ &= \int_Y \left( \int_X f(x, y) \, d\mu(x) \right) d\nu(y), \end{aligned}$$

其中允许积分取值  $+\infty$ .

所以对于非负函数来说事情非常简单. 即使我们还不知道积分是不是有限的, 也可以直接交换积分顺序.

而如果函数同时可能取正值和负值, 那就必须稍微小心一点. 因为如果正负两部分都积分到无穷, 就会重新碰到  $\infty - \infty$  的问题. 所以对于一般实值函数, 我们通常要求绝对可积.

**定理 2.41 (Fubini 定理).**

令  $(X, \mathcal{F}, \mu)$  和  $(Y, \mathcal{G}, \nu)$  为  $\sigma$ -有限测度空间,  $f: X \times Y \rightarrow \mathbb{R}$  为可测函数. 如果

$$\int_{X \times Y} |f| \, d(\mu \otimes \nu) < \infty,$$

则对于  $\mu$ -a.e.  $x \in X$ , 函数  $y \mapsto f(x, y)$  在  $Y$  上可积; 对于  $\nu$ -a.e.  $y \in Y$ , 函数  $x \mapsto f(x, y)$  在  $X$  上可积, 并且

$$\begin{aligned} \int_{X \times Y} f \, d(\mu \otimes \nu) &= \int_X \left( \int_Y f(x, y) \, d\nu(y) \right) d\mu(x) \\ &= \int_Y \left( \int_X f(x, y) \, d\mu(x) \right) d\nu(y). \end{aligned}$$

所以 Tonelli 和 Fubini 其实是在处理同一件事情, 只是使用条件稍有不同. 如果函数非负, 那么优先考虑 Tonelli; 如果函数可能有正有负, 那就先检查  $|f|$  是否可积, 然后使用 Fubini.

**注 2.42.**

这两个定理的证明这里暂不展开. 对后面的概率论来说, 目前最需要记住的是在什么条件下可以交换积分顺序.

**前推测度与积分**

最后还有一个之后在概率论里面同样非常常用的东西, 就是把一个测度沿着可测映射搬到另一个空间上.

**定义 2.43 (前推测度).**

令  $(X, \mathcal{F}, \mu)$  为测度空间,  $(Y, \mathcal{G})$  为可测空间,  $F: X \rightarrow Y$  为可测映射.  $\mu$  沿  $F$  的**前推测度**是指测度  $F_*\mu$ , 其中

$$(F_*\mu)(A) = \mu(F^{-1}(A)), \quad A \in \mathcal{G}.$$

也就是说, 一个集合  $A \subseteq Y$  在前推测度下有多大, 就回到  $X$  里面去看有多少东西会被  $F$  映进  $A$ .

**命题 2.44 (前推测度下的积分).**

令  $(X, \mathcal{F}, \mu)$  为测度空间,  $(Y, \mathcal{G})$  为可测空间,  $F: X \rightarrow Y$  为可测映射, 并令  $\nu = F_*\mu$ . 如果  $g$  是  $Y$  上的非负可测函数或者可积函数, 则有

$$\int_X (g \circ F) \, d\mu = \int_Y g \, d\nu.$$

这个公式到了概率论里面就尤其自然. 如果  $\xi: \Omega \rightarrow \mathbb{R}$  是一个随机变量, 那么它的分布其实就是概率测度  $\mathbb{P}$  沿  $\xi$  的前推

$$\mathbb{P}_\xi = \xi_*\mathbb{P}.$$

因此对于合适的函数  $g$ ,

$$\mathbb{E}[g(\xi)] = \int_{\Omega} g(\xi) d\mathbb{P} = \int_{\mathbb{R}} g(x) d\mathbb{P}_\xi(x).$$

所以知道随机变量的分布以后, 在计算这种期望的时候其实就不需要再关心它原本是在哪个概率空间上实现的了, 直接对于它的分布积分即可. 这也正好说明了为什么概率论很多时候真正关心的是随机变量的分布, 而不是它具体在哪个样本空间上实现.

## 2.2 符号测度, Hahn 分解与 Radon-Nikodym 导数

### 2.2.1 符号测度与 Radon-Nikodym 定理

前面我们一直要求测度只能取非负值. 不过很多时候也希望考虑两个测度之差, 或者更加一般地允许集合带有正负两种“质量”. 这就会引出符号测度.

#### 定义 2.45.

令  $(X, \mathcal{F})$  为可测空间. 符号测度是指定义在  $\mathcal{F}$  上的函数

$$\nu: \mathcal{F} \rightarrow [-\infty, \infty],$$

其满足:

1.  $\nu(\emptyset) = 0$ ;
2. 对于任意一列两两不交的  $A_1, A_2, \dots \in \mathcal{F}$ , 都有

$$\nu\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \nu(A_n);$$

3.  $\nu$  不同时取  $+\infty$  与  $-\infty$ , 从而避免出现没有意义的  $\infty - \infty$ .

符号测度已经不能再单纯理解成“大小”, 因为一个集合现在可以具有负测度. 不过一个很自然的想法是, 能不能把整个空间切成两块, 其中一块只会产生非负测度, 另一块只会产生非正测度.

#### 定义 2.46.

令  $\nu$  为  $(X, \mathcal{F})$  上的符号测度.

- 称可测集  $P \in \mathcal{F}$  为  $\nu$  的正集, 是指对于任意可测集  $A \subseteq P$ , 都有  $\nu(A) \geq 0$ .
- 称可测集  $N \in \mathcal{F}$  为  $\nu$  的负集, 是指对于任意可测集  $A \subseteq N$ , 都有  $\nu(A) \leq 0$ .

#### 定理 2.47 (Hahn 分解定理).

令  $\nu$  为  $(X, \mathcal{F})$  上的符号测度. 则存在互不相交的可测集  $P, N$ , 使得

$$X = P \sqcup N,$$

其中  $P$  为  $\nu$  的正集,  $N$  为  $\nu$  的负集.

证明. 这里不展开. □

Hahn 分解说明, 虽然一个符号测度可以同时具有正负两部分, 但是总可以把空间切成“只产生正值”和“只产生负值”的两个区域.

有了 Hahn 分解以后, 我们可以进一步把符号测度本身也拆开.

**定理 2.48 (Jordan 分解定理).**

令  $\nu$  为  $(X, \mathcal{F})$  上的符号测度. 则存在唯一的两个非负测度  $\nu^+, \nu^-$ , 使得

$$\nu = \nu^+ - \nu^-,$$

并且存在一个 Hahn 分解  $X = P \sqcup N$ , 使得  $\nu^+$  集中在  $P$  上,  $\nu^-$  集中在  $N$  上.

其中  $\nu^+$  和  $\nu^-$  分别称为  $\nu$  的正变差与负变差.

事实上, 如果  $X = P \sqcup N$  是  $\nu$  的一个 Hahn 分解, 那么对于任意  $A \in \mathcal{F}$  可以直接写成

$$\nu^+(A) = \nu(A \cap P), \quad \nu^-(A) = -\nu(A \cap N).$$

所以 Hahn 分解是在拆空间, 而 Jordan 分解则是在此基础上把符号测度本身拆成两个真正的测度.

**定义 2.49.**

令  $\nu$  为  $(X, \mathcal{F})$  上的符号测度,  $\nu^+, \nu^-$  为其正变差与负变差.  $\nu$  的全变差测度是指

$$|\nu| = \nu^+ + \nu^-.$$

于是一个符号测度自然对应三个非负测度  $\nu^+, \nu^-$  和  $|\nu|$ . 其中前两个分别记录它的正负部分, 而  $|\nu|$  则忽略正负号以后记录它总共具有多少“质量”.

**奇异与绝对连续**

为了描述不同测度之间的关系, 我们先固定一个很直观的说法.

**定义 2.50.**

令  $\mu$  为  $(X, \mathcal{F})$  上的测度,  $A \in \mathcal{F}$ . 称  $\mu$  集中在  $A$  上, 是指其满足

$$\mu(X \setminus A) = 0.$$

也就是说, 从  $\mu$  的角度来看,  $A$  以外的部分全部都可以忽略.

**定义 2.51.**

令  $\mu, \nu$  为  $(X, \mathcal{F})$  上的测度.

- 称  $\mu$  与  $\nu$  互相奇异, 是指存在互不相交的可测集  $A, B \in \mathcal{F}$ , 使得  $\mu$  集中在  $A$  上,  $\nu$  集中在  $B$  上. 常记作

$$\mu \perp \nu.$$

- 称  $\nu$  关于  $\mu$  绝对连续, 是指对于任意  $A \in \mathcal{F}$ , 如果  $\mu(A) = 0$ , 则有  $\nu(A) = 0$ . 常记作

$$\nu \ll \mu.$$

这两个概念描述的是两种不同的关系.  $\mu \perp \nu$  表示两个测度的质量可以分别集中在互不重叠的地方, 而  $\nu \ll \mu$  则表示  $\nu$  不会在  $\mu$  完全看不见的地方凭空出现质量.

**注 2.52.**

需要注意的是, 绝对连续是有方向的.  $\nu \ll \mu$  并不意味着  $\mu \ll \nu$ . 但是互相奇异是对称的,  $\mu \perp \nu$  与  $\nu \perp \mu$  是同一件事情.

从这个定义来看, Jordan 分解中的  $\nu^+$  与  $\nu^-$  正好满足

$$\nu^+ \perp \nu^-.$$

比如在  $\mathbb{R}$  上, Dirac 测度  $\delta_0$  与 Lebesgue 测度  $\lambda$  互相奇异.  $\delta_0$  完全集中在  $\{0\}$  上, 而 Lebesgue 测度认为  $\{0\}$  是零测集, 所以可以把两者分别集中在  $\{0\}$  和  $\mathbb{R} \setminus \{0\}$  上.

另一方面, 令  $f$  为非负可测函数, 并定义测度

$$\nu(A) = \int_A f \, d\mu.$$



那么由定义有  $\nu \ll \mu$ , 因为只要  $\mu(A) = 0$ , 就有  $\int_A f d\mu = 0$ .

这种形式的测度可以理解成在原来的测度  $\mu$  上乘上了一个“密度”  $f$ . 在  $f$  较大的地方,  $\nu$  相对于  $\mu$  分配了更多质量; 在  $f = 0$  的地方,  $\nu$  则完全没有质量.

那一个很自然的问题就是反过来是否成立: 如果我们只知道  $\nu \ll \mu$ , 是否一定存在一个非负可测函数  $f$ , 使得

$$\nu(A) = \int_A f d\mu$$

对于所有  $A \in \mathcal{F}$  都成立?

答案就是 Radon-Nikodym 定理.

### Radon-Nikodym 定理

#### 定理 2.53 (Radon-Nikodym 定理).

令  $\mu, \nu$  为  $(X, \mathcal{F})$  上的  $\sigma$ -有限测度. 如果  $\nu \ll \mu$ , 则存在非负可测函数  $f: X \rightarrow [0, \infty]$ , 使得对于任意  $A \in \mathcal{F}$ , 都有

$$\nu(A) = \int_A f d\mu.$$

并且这样的  $f$  在  $\mu$ -a.e. 的意义下唯一.

我们把这个函数记作

$$f = \frac{d\nu}{d\mu},$$

称为  $\nu$  关于  $\mu$  的 **Radon-Nikodym 导数**.

这个记号和导数非常像. 粗略来说,  $\frac{d\nu}{d\mu}$  描述的就是“单位  $\mu$  对应多少  $\nu$ ”, 也就是两个测度之间局部的密度比.

证明. 我们先考虑  $\mu, \nu$  都是有限测度的情况.

对于非负可测函数  $f$ , 记

$$(f \cdot \mu)(A) := \int_A f d\mu.$$

现在考虑

$$\mathcal{H} = \{f \geq 0 \mid f \text{ 关于 } \mathcal{F} \text{ 可测且 } f \cdot \mu \leq \nu\}.$$

这里  $f \cdot \mu \leq \nu$  是指对于任意  $A \in \mathcal{F}$  都有  $(f \cdot \mu)(A) \leq \nu(A)$ .

定义

$$\alpha = \sup_{f \in \mathcal{H}} \int_X f d\mu.$$

因为  $f \cdot \mu \leq \nu$ , 所以  $\int_X f d\mu \leq \nu(X) < \infty$ , 从而  $\alpha < \infty$ .

取  $f_n \in \mathcal{H}$  使得  $\int_X f_n d\mu \rightarrow \alpha$ . 如果  $f, g \in \mathcal{H}$ , 那么将  $X$  按照  $f \geq g$  与  $f < g$  分开以后容易验证  $\max\{f, g\} \in \mathcal{H}$ . 因此令

$$g_n = \max\{f_1, \dots, f_n\},$$

则  $g_n \in \mathcal{H}$  且对某个非负可测函数  $g$ , 有  $g_n \uparrow g$ .

由单调收敛定理,

$$\int_X g d\mu = \lim_{n \rightarrow \infty} \int_X g_n d\mu = \alpha.$$

对任意  $A \in \mathcal{F}$  再使用一次单调收敛定理, 有

$$\int_A g d\mu = \lim_{n \rightarrow \infty} \int_A g_n d\mu \leq \nu(A),$$

所以  $g \in \mathcal{H}$ .

现在令

$$\lambda = \nu - g \cdot \mu.$$



因为  $g \in \mathcal{H}$ , 所以  $\lambda$  是一个非负有限测度. 而且由于  $\nu \ll \mu$  以及  $g \cdot \mu \ll \mu$ , 还有  $\lambda \ll \mu$ .

我们只需要证明  $\lambda = 0$ . 假设反之  $\lambda(X) > 0$ . 因为  $\mu(X) < \infty$ , 可以取足够小的  $\varepsilon > 0$ , 使得

$$\lambda(X) - \varepsilon\mu(X) > 0.$$

考虑符号测度

$$\rho = \lambda - \varepsilon\mu.$$

由 Hahn 分解定理, 可以找到  $\rho$  的正集  $P$  满足  $\rho(P) > 0$ . 因为  $\lambda \ll \mu$ , 此时必然有  $\mu(P) > 0$ , 而且对于任意可测集  $A \subseteq P$  都有

$$\lambda(A) \geq \varepsilon\mu(A).$$

因此对于任意  $A \in \mathcal{F}$ ,

$$\begin{aligned} \int_A (g + \varepsilon 1_P) d\mu &= \int_A g d\mu + \varepsilon\mu(A \cap P) \\ &\leq \int_A g d\mu + \lambda(A \cap P) \\ &\leq \nu(A). \end{aligned}$$

所以  $g + \varepsilon 1_P \in \mathcal{H}$ . 但是

$$\int_X (g + \varepsilon 1_P) d\mu = \alpha + \varepsilon\mu(P) > \alpha,$$

这和  $\alpha$  的定义矛盾. 因此只能有  $\lambda = 0$ , 从而

$$\nu = g \cdot \mu.$$

最后来看唯一性. 令  $f, g$  都满足  $f \cdot \mu = g \cdot \mu = \nu$ . 在集合  $\{f > g\}$  上有

$$\int_{\{f > g\}} f d\mu = \int_{\{f > g\}} g d\mu,$$

由于两边都是  $\nu(\{f > g\})$ , 这里的积分是有限的. 对每个  $n \geq 1$ , 在  $E_n = \{f \geq g + 1/n\}$  上有

$$\int_{E_n} f d\mu \geq \int_{E_n} g d\mu + \frac{1}{n}\mu(E_n).$$

又由上面的等式可知两边积分相等, 因而  $\mu(E_n) = 0$ . 因为  $\{f > g\} = \bigcup_{n \geq 1} E_n$ , 所以  $\mu(\{f > g\}) = 0$ . 同理有  $\mu(\{g > f\}) = 0$ , 因此  $f = g$  a.e.

一般的  $\sigma$ -有限情形只需要把  $X$  拆成可列多个彼此不交的可测集, 使得  $\mu$  和  $\nu$  在每一块上都有有限, 分别应用上面的有限测度情形以后再把得到的密度拼起来即可.  $\square$

所以 Radon-Nikodym 定理大概是在说, 一个关于  $\mu$  绝对连续的测度  $\nu$  本质上就是  $\mu$  乘上某个密度函数. 更准确地说,

$$\nu(A) = \int_A \frac{d\nu}{d\mu} d\mu.$$

这个结果在概率论里面尤其重要. 如果随机变量  $\xi$  的分布  $\mathbb{P}_\xi$  关于 Lebesgue 测度  $\lambda$  绝对连续, 那么

$$p_\xi = \frac{d\mathbb{P}_\xi}{d\lambda}$$

就是我们平常所说的概率密度函数.

于是对于任意 Borel 集  $A \subseteq \mathbb{R}$ ,

$$\mathbb{P}(\xi \in A) = \mathbb{P}_\xi(A) = \int_A p_\xi(x) dx.$$

所以严格来说, 概率密度并不是概率本身, 而是概率测度相对于 Lebesgue 测度的 Radon-Nikodym 导数.

## Lebesgue 分解

既然我们已经有了“绝对连续”和“互相奇异”两种关系, 那一个自然的问题就是: 给定两个测度  $\mu, \nu$ , 是否可以把  $\nu$  拆成一部分关于  $\mu$  绝对连续, 另一部分与  $\mu$  互相奇异?

答案仍然是肯定的.

### 定理 2.54 (Lebesgue 分解定理).

令  $\mu, \nu$  为  $(X, \mathcal{F})$  上的  $\sigma$ -有限测度. 则存在唯一的两个测度  $\nu_{ac}, \nu_s$ , 使得

$$\nu = \nu_{ac} + \nu_s,$$

并且

$$\nu_{ac} \ll \mu, \quad \nu_s \perp \mu.$$

证明. 令

$$\rho = \mu + \nu.$$

则  $\mu \ll \rho$  且  $\nu \ll \rho$ . 由 Radon-Nikodym 定理, 存在非负可测函数  $f, g$ , 使得

$$\mu = f \cdot \rho, \quad \nu = g \cdot \rho.$$

由  $\rho = \mu + \nu$  可知

$$f + g = 1 \quad \rho\text{-a.e.}$$

令  $A = \{f > 0\}$ , 并定义

$$\nu_{ac}(E) = \nu(E \cap A), \quad \nu_s(E) = \nu(E \cap A^c).$$

由定义可见  $\nu = \nu_{ac} + \nu_s$ .

如果  $\mu(E) = 0$ , 那么  $\int_E f d\rho = 0$ , 所以  $f = 0$  在  $E$  上  $\rho$ -a.e. 成立. 因而  $\rho(E \cap A) = 0$ , 从而  $\nu_{ac}(E) = 0$ . 所以  $\nu_{ac} \ll \mu$ .

另一方面,

$$\mu(A^c) = \int_{A^c} f d\rho = 0,$$

而  $\nu_s$  完全集中在  $A^c$  上, 所以  $\nu_s \perp \mu$ .

唯一性可以这样看. 假设还有另一个分解  $\nu = \alpha + \sigma$ , 其中  $\alpha \ll \mu$  且  $\sigma \perp \mu$ . 取  $\mu$ -零测集  $N, M$ , 使得  $\nu_s$  集中在  $N$  上,  $\sigma$  集中在  $M$  上. 对任意可测集  $E$ , 绝对连续性给出  $\nu_{ac}(E \cap (N \cup M)) = \alpha(E \cap (N \cup M)) = 0$ , 而奇异部分在  $(N \cup M)^c$  上为 0. 因此  $\nu_{ac}(E) = \alpha(E)$ , 从而奇异部分也相同.  $\square$

由 Radon-Nikodym 定理, 其中绝对连续的部分还可以写成

$$\nu_{ac}(A) = \int_A \frac{d\nu_{ac}}{d\mu} d\mu.$$

所以从  $\mu$  的角度来看, 一个测度  $\nu$  大概可以拆成两部分: 一部分可以通过相对于  $\mu$  的密度函数描述, 另一部分则集中在  $\mu$  完全看不见的地方.

放到概率分布里面也是一样. 相对于 Lebesgue 测度来说, 一个概率分布可以具有绝对连续部分, 也可以具有奇异部分. 离散的原子质量属于奇异部分的一种, 不过奇异部分并不一定是离散的, 比如还存在奇异连续分布.

### 2.2.2 $L^p$ 空间

下面转入一个相对独立但后面概率论会反复用到的主题:  $L^p$  空间.

前面我们已经定义了 Lebesgue 积分. 积分理论并不只有 Lebesgue 积分一种, 如果单纯只是想给某个函数算积分, 那么很多时候 Riemann 积分或者其他积分理论也完全够用.

不过分析学真正麻烦的地方往往并不是“这个函数能不能积分”, 而是我们经常需要研究一整族函数, 比较它们之间的大小和距离, 然后不断地取极限.

比如对于可积函数  $f$ ,  $\int_X |f| d\mu$  可以用来衡量它整体有多大. 如果我们更加在意函数出现较大取值的部分, 那自然可以进一步考虑

$$\left( \int_X |f|^p d\mu \right)^{1/p}.$$

这里最后再开  $p$  次根也很自然, 因为  $|f|^p$  将函数值本身的尺度做了  $p$  次方, 最后开根以后又重新回到了原来的尺度.

这正是有限维向量空间中  $p$ -范数的推广. 比如对于  $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ , 我们有

$$\|x\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

如果把  $\{1, \dots, n\}$  赋予计数测度, 那么这里的求和本身就是 Lebesgue 积分. 从这个角度来看,  $L^p$  范数就是把有限维向量的  $p$ -范数推广到了一般测度空间上的函数.

不过这里重要的不只是成功定义出了一个范数.

比如在有界区间上, 如果只考虑 Riemann 可积函数, 然后同样使用  $L^p$  范数衡量函数之间的距离, 得到的函数空间一般并不完备: 一系列 Riemann 可积函数完全可能在  $L^p$  意义下成为 Cauchy 列, 但是它的极限却已经不再是 Riemann 可积函数.

而 Lebesgue 理论的一个巨大优点就在于, 当我们把 a.e. 相等的函数视为同一个函数以后, 对于  $1 \leq p \leq \infty$ , 所得到的  $L^p$  空间都是 Banach 空间. 也就是说, 在  $L^p$  范数下取 Cauchy 极限并不会离开这个空间.

这件事情对于分析学尤其重要, 因为分析学里面大量操作都需要不断取极限. 如果每次取完极限以后都需要担心结果已经离开了原来的函数空间, 那么很多理论都会变得非常难用.

因此 Lebesgue 积分之所以在现代分析中被如此广泛地采用, 并不只是因为它“能够积分更多函数”, 更重要的是它和极限以及函数空间的结构配合得非常好. 特别地, 它使得  $L^p$  空间成为 Banach 空间, 而  $L^2$  还会进一步成为 Hilbert 空间.

到了概率论里面, 这套结构又有了解释. 如果  $(\Omega, \mathcal{F}, \mathbb{P})$  是概率空间, 那么随机变量本身就是  $\Omega$  上的可测函数. 当  $1 \leq p < \infty$  时,

$$\|X\|_p^p = \mathbb{E}[|X|^p].$$

所以概率论里面所谓“随机变量具有有限的  $p$  阶绝对矩”, 就是在说它属于  $L^p(\Omega, \mathbb{P})$ .

而  $p = \infty$  的情况需要单独理解:  $X \in L^\infty$  表示  $X$  本质有界, 也就是存在有限常数  $M$  使得  $|X| \leq M$   $\mathbb{P}$ -a.e.; 在概率语言中称为几乎必然 (almost surely, a.s.).

而当我们研究随机变量序列的时候,  $\|X_n - X\|_p \rightarrow 0$  又会自然给出所谓的  $L^p$  收敛. 所以后面的矩, 方差, 均方收敛以及很多随机过程中的估计, 都会反复使用同一套  $L^p$  结构.

下设  $(X, \mathcal{F}, \mu)$  为测度空间, 并记  $\mathbb{K} = \mathbb{R}$  或  $\mathbb{C}$ .

## $L^p$ 范数与 $L^p$ 空间

### 定义 2.55 ( $L^p$ 范数).

令  $f: X \rightarrow \mathbb{K}$  为可测函数.

- 当  $1 \leq p < \infty$  时,  $f$  的  $L^p$  范数是指

$$\|f\|_p = \left( \int_X |f|^p d\mu \right)^{1/p}.$$

- 当  $p = \infty$  时,  $f$  的  $L^\infty$  范数是指

$$\|f\|_\infty = \operatorname{ess\,sup}_{x \in X} |f(x)| = \inf\{a \geq 0 \mid |f| \leq a \text{ a.e.}\}.$$

这里需要稍微注意一下, 对一般可测函数来说, 上面的量可能取  $+\infty$ ; 限制在有限值的函数类上以后, 它也仍然只是一个半范数. 取 a.e. 等价类以后才会成为真正的范数. 因为  $\|f\|_p = 0$  只能推出  $f = 0$  a.e., 而不能保证  $f$  逐点处处等于 0.

解决办法也很直接: 既然零测集上的区别对于积分来说本来就是看不见的, 那我们就把 a.e. 相等的函数视为同一个函数.

**定义 2.56 ( $L^p$  空间).**

令  $1 \leq p \leq \infty$ .  $L^p(X, \mu; \mathbb{R})$  是指所有满足  $\|f\|_p < \infty$  的可测函数关于 a.e. 相等得到的商空间.

无歧义时, 也直接记作  $L^p(X)$  或  $L^p$ .

所以严格来说,  $L^p$  中的元素并不是一个具体函数, 而是一整个 a.e. 相等的函数等价类. 不过实际使用的时候, 我们一般还是直接拿其中一个代表元当作“这个函数”来写.

对于概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$ , 当  $1 \leq p < \infty$  时, 这个定义可以直接翻译成

$$X \in L^p(\Omega, \mathbb{P}) \iff \mathbb{E}[|X|^p] < \infty.$$

而  $X \in L^\infty(\Omega, \mathbb{P})$  则表示  $X$  本质有界.

特别地,  $L^1$  中的随机变量具有有限的一阶绝对矩, 因而期望存在;  $L^2$  中的随机变量具有有限二阶矩, 因而可以进一步讨论方差和协方差.

令  $X = \mathbb{Z}_{>0}$  并取计数测度. 当  $1 \leq p < \infty$  时, 就得到一个很重要的特例  $\ell^p$  空间:

$$\ell^p = \left\{ (x_n)_{n \geq 1} \mid \sum_{n=1}^{\infty} |x_n|^p < \infty \right\},$$

其范数为

$$\|x\|_p = \left( \sum_{n=1}^{\infty} |x_n|^p \right)^{1/p}.$$

而  $p = \infty$  时,

$$\ell^\infty = \left\{ (x_n)_{n \geq 1} \mid \sup_{n \geq 1} |x_n| < \infty \right\}, \quad \|x\|_\infty = \sup_{n \geq 1} |x_n|.$$

所以 Lebesgue 积分和无穷求和本身就是同一个测度论框架下的两种情况,  $L^p$  和  $\ell^p$  之间的关系也是如此.

### $L^p$ 收敛

既然  $L^p$  上已经有了一个范数, 那么我们也就可以直接使用这个范数来定义函数之间的收敛.

**定义 2.57.**

令  $f, f_1, f_2, \dots \in L^p(X)$ . 称  $f_n$  在  $L^p$  意义下收敛到  $f$ , 是指  $\|f_n - f\|_p \rightarrow 0$ . 常记作

$$(f_n \xrightarrow{L^p} f).$$

在概率空间上, 当  $1 \leq p < \infty$  时, 这也就是

$$(X_n \xrightarrow{L^p} X) \iff \mathbb{E}[|X_n - X|^p] \rightarrow 0.$$

当  $p = \infty$  时, 它表示  $X_n - X$  的本质确界趋于 0, 也就是在忽略零概率集合以后的一致收敛.

所以当  $1 \leq p < \infty$  时,  $L^p$  收敛描述的并不是每一个样本点上的逐点行为, 而是随机变量之间整体误差的  $p$  阶矩趋于 0. 而  $L^\infty$  收敛则是本质上一致意义下的误差趋于 0.

特别地,  $L^1$  收敛也常被称为平均收敛, 而  $L^2$  收敛则常被称为均方收敛. 后面我们还会看到几乎处处收敛, 依概率收敛, 依分布收敛等等不同的收敛概念, 它们之间并不是同一回事.

### 基本不等式

$L^p$  空间最基本的两个不等式是 Hölder 不等式和 Minkowski 不等式.

**定义 2.58.**

令  $1 \leq p, q \leq \infty$ . 称  $p, q$  为一对共轭指数, 是指其满足

$$\frac{1}{p} + \frac{1}{q} = 1.$$

**定理 2.59 (Hölder 不等式).**

令  $p, q$  为一对共轭指数,  $f \in L^p(X)$ ,  $g \in L^q(X)$ . 则  $fg \in L^1(X)$ , 并且

$$\|fg\|_1 \leq \|f\|_p \|g\|_q.$$

证明. 当  $1 < p, q < \infty$  时, 如果  $\|f\|_p$  或  $\|g\|_q$  为 0, 结论显然. 否则将二者归一化以后, 由 Young 不等式

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q}$$

有

$$\frac{|f(x)g(x)|}{\|f\|_p \|g\|_q} \leq \frac{1}{p} \frac{|f(x)|^p}{\|f\|_p^p} + \frac{1}{q} \frac{|g(x)|^q}{\|g\|_q^q}.$$

两边积分即可.

$p = 1, q = \infty$  以及  $p = \infty, q = 1$  的情况直接由  $|fg| \leq \|g\|_\infty |f|$  得到. □

放到概率空间里面, Hölder 不等式就是

$$\mathbb{E}[|XY|] \leq \|X\|_p \|Y\|_q.$$

所以以后我们在证明两个随机变量的乘积可积, 或者估计各种矩的时候, 本质上经常只是在使用 Hölder 不等式.

特别地, 当  $p = q = 2$  时得到

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2]} \sqrt{\mathbb{E}[Y^2]},$$

这就是 Cauchy-Schwarz 不等式.

**定理 2.60 (Minkowski 不等式).**

令  $1 \leq p \leq \infty$ ,  $f, g \in L^p(X)$ . 则有

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p.$$

证明.  $p = 1$  和  $p = \infty$  的情况直接验证即可.

设  $1 < p < \infty$ , 并令  $q$  为  $p$  的共轭指数. 首先由  $|f + g|^p \leq 2^{p-1}(|f|^p + |g|^p)$  可知  $f + g \in L^p(X)$ , 所以下面的表达式都是有限的.

由

$$|f + g|^p \leq (|f| + |g|)|f + g|^{p-1}$$

以及 Hölder 不等式,

$$\begin{aligned} \int_X |f + g|^p d\mu &\leq (\|f\|_p + \|g\|_p) \| |f + g|^{p-1} \|_q \\ &= (\|f\|_p + \|g\|_p) \|f + g\|_p^{p-1}. \end{aligned}$$

消去  $\|f + g\|_p^{p-1}$  即得结论. □

Minkowski 不等式也就说明了为什么在  $p \geq 1$  的时候  $\|\cdot\|_p$  真的是一个范数. 放到概率论里面, 它可以理解成随机变量整体  $p$  阶大小的三角不等式.

## 完备性

前面已经提到, Lebesgue 理论真正重要的一个地方就在于  $L^p$  在这个范数下是完备的. 现在我们正式说明这件事情.

### 定理 2.61 (Riesz–Fisher 定理).

令  $1 \leq p \leq \infty$ . 则  $L^p(X, \mu)$  关于  $\|\cdot\|_p$  是一个 Banach 空间.

证明. 这里只证明  $1 \leq p < \infty$  的情况.  $p = \infty$  的情况可以直接利用本质上一致收敛处理.

由 Banach 空间的标准判别法, 只需要证明: 如果

$$\sum_{k=1}^{\infty} \|f_k\|_p < \infty,$$

那么级数  $\sum_k f_k$  在  $L^p$  中收敛.

令

$$G_n = \sum_{k=1}^n |f_k|, \quad G = \sum_{k=1}^{\infty} |f_k|.$$

由 Minkowski 不等式,  $\|G_n\|_p \leq \sum_{k=1}^n \|f_k\|_p \leq B$  对某个有限的  $B$  成立. 再由单调收敛定理,

$$\int_X G^p d\mu = \lim_{n \rightarrow \infty} \int_X G_n^p d\mu \leq B^p.$$

所以  $G \in L^p$ , 特别地  $G < \infty$  a.e. 因而  $\sum_k f_k$  a.e. 绝对收敛, 记其和为  $F$ .

令  $F_n = \sum_{k=1}^n f_k$ . 因为  $F_n \rightarrow F$  a.e., 并且  $|F - F_n| \leq 2G$ , 所以  $|F - F_n|^p \leq 2^p G^p$ . 由控制收敛定理,

$$\|F - F_n\|_p^p = \int_X |F - F_n|^p d\mu \rightarrow 0.$$

因而  $F_n \rightarrow F$  在  $L^p$  中成立. □

对于概率论来说, 这意味着一个在  $L^p$  意义下的 Cauchy 随机变量序列不会离开  $L^p$ : 它一定存在某个仍然具有有限  $p$  阶矩的随机变量作为极限.

## $L^2$ 空间

在所有  $L^p$  空间里面,  $p = 2$  的情况尤其特殊, 因为它的范数来自一个真正的内积.

### 定义 2.62.

$L^2(X, \mu)$  上的内积是指

$$\langle f, g \rangle = \int_X f \bar{g} d\mu$$

在复值情形下的定义. 对于实值函数则直接去掉共轭.

由 Cauchy–Schwarz 不等式, 这个积分总是有限的, 并且  $\|f\|_2 = \sqrt{\langle f, f \rangle}$ .

### 定理 2.63.

$L^2(X, \mu)$  关于上述内积是一个 Hilbert 空间.

对于概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$ , 这个内积就是

$$\langle X, Y \rangle = \mathbb{E}[X \bar{Y}].$$

很多概率论里面看起来很特殊的概念, 都可以放进 Hilbert 空间语言中统一理解. 比如对于实值随机变量,

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \|X - \mathbb{E}[X]\|_2^2,$$

而协方差就是

$$\text{Cov}(X, Y) = \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

所以  $\text{Cov}(X, Y) = 0$  就是说中心化以后的两个随机变量在  $L^2$  中正交.

这也是为什么  $L^2$  在概率论和随机过程中会特别常见. 我们不只是可以讨论随机变量整体有多大, 还可以直接利用 Hilbert 空间里面的正交, 投影等几何结构.

### 不同 $L^p$ 空间之间的关系

一般测度空间上, 对于  $p < q$ ,  $L^p$  和  $L^q$  并不存在统一的包含关系. 不过概率空间本身是有限测度空间, 所以情况会简单很多.

#### 命题 2.64.

令  $(X, \mathcal{F}, \mu)$  为有限测度空间,  $1 \leq p < q \leq \infty$ . 如果  $f \in L^q(X)$ , 则  $f \in L^p(X)$ , 并且

$$\|f\|_p \leq \mu(X)^{1/p-1/q} \|f\|_q.$$

特别地, 对于概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$ , 因为  $\mathbb{P}(\Omega) = 1$ , 所以上式直接变成

$$L^q(\Omega) \subseteq L^p(\Omega), \quad \|X\|_p \leq \|X\|_q.$$

所以在概率论里面, 高阶矩有限会自动推出低阶矩有限. 比如

$$X \in L^2 \implies X \in L^1,$$

也就是说, 只要随机变量具有有限二阶矩, 那么它的期望就一定存在.

更一般地, 如果  $\mathbb{E}[|X|^q] < \infty$ , 那么所有更低阶的绝对矩也都会有限.

如果我们同时知道一个函数的两个不同阶矩, 那中间的阶数还可以通过插值控制.

#### 定理 2.65 (插值不等式).

令  $1 \leq p < q < r \leq \infty$ ,  $f \in L^p(X) \cap L^r(X)$ . 如果  $\lambda \in (0, 1)$  满足

$$\frac{1}{q} = \frac{\lambda}{p} + \frac{1-\lambda}{r},$$

则  $f \in L^q(X)$ , 并且

$$\|f\|_q \leq \|f\|_p^\lambda \|f\|_r^{1-\lambda}.$$

证明. 当  $r < \infty$  时, 写成

$$|f|^q = |f|^{\lambda q} |f|^{(1-\lambda)q},$$

再使用 Hölder 不等式即可.

$r = \infty$  的情况直接由  $|f|^q \leq \|f\|_\infty^{q-p} |f|^p$  得到. □

在概率论里面, 这个不等式可以直接理解成不同阶矩之间的插值. 如果我们已经控制了某个随机变量的  $p$  阶矩和  $r$  阶矩, 那么介于它们之间的  $q$  阶矩也会自动得到控制. 后面研究随机过程的矩估计时会经常遇到这种操作.

### 简单函数逼近

简单函数不只是用来定义 Lebesgue 积分, 它们还可以逼近一般的  $L^p$  函数.

#### 命题 2.66.

令  $1 \leq p < \infty$ . 则具有有限测度支撑的简单函数在  $L^p(X, \mu)$  中稠密.

证明. 令  $f \in L^p$ . 对于  $n \geq 1$ , 先将  $f$  截断在

$$\left\{ \frac{1}{n} \leq |f| \leq n \right\}$$

上, 再对函数值作简单函数逼近, 可以得到简单函数  $f_n$ , 满足  $f_n \rightarrow f$  a.e. 且  $|f_n| \leq |f|$ .

另一方面, 因为

$$\mu\left(\left\{|f| \geq \frac{1}{n}\right\}\right) \leq n^p \int_X |f|^p d\mu < \infty,$$

所以每个  $f_n$  都可以取成具有有限测度支撑.

最后由  $|f_n - f|^p \leq 2^p |f|^p$  以及控制收敛定理, 得到  $\|f_n - f\|_p \rightarrow 0$ . □

对于概率论来说, 这个结论大概是在说: 很多关于一般随机变量的问题, 我们都可以先对只取有限多个值的随机变量处理, 然后再通过  $L^p$  逼近推广到一般情况.

#### 注 2.67.

在常见的  $\sigma$ -有限测度空间上, 当  $1 < p < \infty$  时,  $L^p$  的连续对偶可以识别成  $L^q$ , 其中  $p, q$  为共轭指数. 这个结果的证明会再次使用前面的 Radon-Nikodym 定理, 不过这已经比较偏向泛函分析, 这里暂时不展开.



### 第三章 概率论基础

前面我们花了不少篇幅介绍测度论, 现在终于可以开始讲概率了.

这一章的概率论基础主要参考 [Bil95; Dur19; Kal21; Wil91].

从现代观点看, 概率空间就是总质量为 1 的测度空间. 我们把可测集称为“事件”, 将测度称为“概率”, 就已经得到了概率论的基本语言.

很多我们熟悉的概率公式并不是什么全新的结论. 比如事件的并, 交, 补集, 可列可加性等等, 都是前面测度论里面集合运算和测度性质的重新解释.

但是概率论有意思的地方不只是给集合赋一个 0 到 1 之间的数.

实际进行一次随机实验的时候, 最原始的结果往往会带有很多我们并不关心的信息. 比如连续抛十次硬币, 一个完整的实验结果可能是

$$(H, T, H, H, T, T, H, T, H, H),$$

但很多时候我们关心的可能只是“一共出现了多少次正面”. 于是相比于直接研究原来的样本点  $\omega$ , 我们通常更愿意通过某个函数把它投影到一个更加方便处理的空间里面. 这个函数就是随机变量.

随机变量这个名字多少有些误导. 它并不是一个“会随机变化的变量”, 而是概率空间上的一个可测函数

$$X: \Omega \rightarrow \mathbb{R}.$$

随机性来自输入的样本点  $\omega$ , 而  $X$  本身只是把每一个可能的实验结果转换成一个数.

这件事情也解释了为什么我们前面需要花时间讲可测映射. 如果我们想讨论“ $X$  落在集合  $A$  中”的概率, 实际上就是在讨论事件  $X^{-1}(A)$ . 因此只有当  $X$  是可测的, 这些原像才仍然属于事件域, 从而概率

$$\mathbb{P}(X \in A)$$

才有定义.

更进一步, 随机变量还会把概率测度推到自己的取值空间上, 形成所谓的分布. 下一节会系统展开这个概念. 在这里先记住一个直觉: 分布记录的是观测值在取值空间中怎样散布, 而不是原始样本空间的全部结构.

另一方面, 我们前面定义的 Lebesgue 积分到了这里也会变成期望. 如果  $X$  是可积随机变量, 那么

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P}.$$

同样, 期望就是关于概率测度的 Lebesgue 积分. 类似地, 当  $1 \leq p < \infty$  时,  $L^p$  空间也会直接对应随机变量的不同阶绝对矩:

$$X \in L^p(\Omega, \mathbb{P}) \iff \mathbb{E}[|X|^p] < \infty.$$

而  $L^\infty$  则对应随机变量本质有界.

因此到这里, 前面的测度论可以翻译成概率论的语言:

$$\begin{aligned} \text{测度空间} &\longrightarrow \text{概率空间}, \\ \text{可测集} &\longrightarrow \text{事件}, \\ \text{测度} &\longrightarrow \text{概率}, \\ \text{可测映射} &\longrightarrow \text{随机变量}, \\ \text{前推测度} &\longrightarrow \text{分布}, \\ \text{Lebesgue 积分} &\longrightarrow \text{期望}. \end{aligned}$$

但概率论并不只是给测度论换一套名字. 当我们同时考虑多个事件和多个随机变量时, 新的问题就会出现: 它们是否独立, 知道一部分信息以后概率应该怎样改变, 一个随机变量的条件期望是什么, 以及一系列随机变量到底以什么方式趋于另一个随机变量.

把这一章的概念依赖关系压缩成一张图, 大致可以写成下面这样:




图 3.1: 概率论基础的概念依赖关系

而再往后, 当我们给一族随机变量加上时间指标以后, 也就进入了本文真正想学习的对象 — 随机过程.

### 3.1 概率空间与随机变量

这一节先把概率空间的三个组成部分钉牢, 再看随机变量如何从中提取信息.

粗略来说, 概率空间描述了一个“带有随机性的系统”: 样本空间收集这个系统所有可能出现的完整结果, 事件域规定哪些结果集合可以讨论, 概率测度则描述不同事件发生的可能性.

#### 3.1.1 概率空间

现在我们来正式定义概率空间.

##### 定义 3.1.

概率空间是指三元组  $(\Omega, \mathcal{F}, \mathbb{P})$ , 其中:

- $\Omega$  为集合, 也称为样本空间;
- $\mathcal{F}$  为  $\Omega$  上的  $\sigma$ -代数, 也称为事件域, 其中的元素称为事件;
- $\mathbb{P}$  为定义在  $\mathcal{F}$  上的概率测度, 也就是满足  $\mathbb{P}(\Omega) = 1$  的测度.

概率论里面所谓的“概率”, 就是总质量被归一化成 1 的测度.

需要注意的是, 并不是  $\Omega$  的所有子集都一定是事件. 只有属于事件域  $\mathcal{F}$  的子集才称为事件. 对于  $A \subseteq \Omega$  但  $A \notin \mathcal{F}$ ,  $\mathbb{P}(A)$  本身就没有定义.

不难发现,  $\Omega$  和  $\emptyset$  都属于  $\mathcal{F}$ , 因此它们都是事件. 我们称  $\Omega$  为必然事件, 称  $\emptyset$  为不可能事件.

这里还需要稍微区分一下“必然发生”和“概率为 1”. 如果事件  $A$  满足  $\mathbb{P}(A) = 1$ , 那么我们通常说  $A$  几乎必然发生. 这是因为它的补集  $A^c$  虽然满足  $\mathbb{P}(A^c) = 0$ , 但却未必真的是空集. 类似地,  $\mathbb{P}(A) = 0$  也只能说明  $A$  是一个零概率事件, 并不意味着  $A = \emptyset$ . 它在模型中仍然可以存在, 只是几乎必然不会发生. 这件事情在连续型概率空间里面尤其常见.

接下来我们来看两个最基本的例子.

##### 例 3.2 (古典概型).

令  $\Omega$  为非空有限集, 并取  $\mathcal{F} = \mathcal{P}(\Omega)$ , 那么可以定义

$$\mathbb{P}(A) := \frac{\#A}{\#\Omega}.$$

由定义可见,  $(\Omega, \mathcal{F}, \mathbb{P})$  构成概率空间.

这里每一个样本点都具有相同的概率, 因而事件的概率就是“有利结果占所有可能结果的比例”. 这就是最经典的等可能模型.

### 例 3.3 (几何概型).

令  $\Omega \subseteq \mathbb{R}^d$  为 Lebesgue 可测集, 并满足  $0 < \lambda_d(\Omega) < \infty$ . 取

$$\mathcal{F} = \{A \cap \Omega \mid A \in \mathcal{L}(\mathbb{R}^d)\},$$

并定义

$$\mathbb{P}(A) := \frac{\lambda_d(A)}{\lambda_d(\Omega)}, \quad A \in \mathcal{F}.$$

那么  $(\Omega, \mathcal{F}, \mathbb{P})$  构成概率空间.

这可以看作古典概型的连续版本. 古典概型使用元素个数  $\#A$  衡量一个事件占整个样本空间的比例, 而几何概型则改用 Lebesgue 测度衡量一个区域所占的比例.

比如在区间  $[0, 1]$  中均匀随机取一点, 那么取到  $[a, b] \subseteq [0, 1]$  中的概率就是  $b - a$ . 另一方面, 对于任意  $x \in [0, 1]$  都有  $\mathbb{P}(\{x\}) = 0$ , 但  $x$  仍然是样本空间中完全合法的一个结果. 这也再次说明了概率为 0 并不意味着这个结果不可能出现.

### 3.1.2 随机变量

很多时候, 概率空间本身可能极其复杂, 而且其中绝大部分信息并不是我们关心的.

比如如果我们试图把股票市场建模成一个概率空间, 那么一种比较自然的想法是把一个样本点  $\omega \in \Omega$  理解成市场的一次完整实现, 甚至直接理解成一整条可能的市场历史.

如果暂时只研究某一只股票每天的价格, 那么可以粗略地取  $\Omega = \mathbb{R}_+^{\mathbb{N}}$ . 此时一个样本点  $\omega = (s_0, s_1, s_2, \dots)$  就代表这只股票的一整条可能价格路径.

真实股票市场还会包含更多状态变量. 如果试图描述整个市场, 那么一个  $\omega$  可能还需要包含成交量, 订单簿, 利率, 新闻, 其他资产价格以及许多额外信息. 于是原始的样本空间会非常庞大.

与之对应, 事件域  $\mathcal{F}$  则描述我们能够讨论并赋予概率的事件. 比如“明天股价高于今天”, “未来一个月最大回撤超过 10%”, 或者“某个时刻以前股价曾经突破 200”都可以被视为事件.

如果我们只观察价格, 那么一种自然的做法就是令事件域由所有价格观测生成:

$$\mathcal{F} = \sigma(S_t : t \in \mathbb{N}),$$

其中  $S_t(\omega) = s_t$  表示从完整路径  $\omega$  中读出时刻  $t$  的价格.

不过实际研究的时候, 我们通常并不想直接处理整个  $\omega$ . 一整个市场世界里面的信息实在太多, 我们关心的往往只是从中提取出来的一些数值, 比如某只股票的价格, 收益率, 成交量, 甚至 MACD 之类的指标.

所以我们希望通过一个函数  $X: \Omega \rightarrow \mathbb{R}$  把复杂的样本结果  $\omega$  转换成一个想研究的数值. 这就是随机变量最基本的想法.

#### 定义 3.4.

令  $(\Omega, \mathcal{F}, \mathbb{P})$  为概率空间. **随机变量**是指可测映射

$$X: (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

“随机变量”这个名字多少有些误导. 随机变量  $X$  本身只是一个确定的可测函数, 具有随机性的是样本点  $\omega$ . 当随机系统最终实现为某个  $\omega$  时, 我们实际观测到的数值就是  $X(\omega)$ .

从这个角度来看, 随机变量可以理解成对于原概率空间的一次**观测**或者**信息提取**: 我们主动丢掉原空间中大量并不关心的信息, 只保留某一个希望研究的量.

这里要求  $X$  可测也不是一个纯粹的技术条件. 比如如果我们想讨论“ $X \leq a$ ”发生的概率, 那么实际上是在讨论事件  $\{X \leq a\} = X^{-1}((-\infty, a])$ . 只有当这个原像属于  $\mathcal{F}$  时,  $\mathbb{P}(X \leq a)$  才真正有定义.

而由于  $\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, a] \mid a \in \mathbb{R}\}$ , 所以要验证一个函数  $X: \Omega \rightarrow \mathbb{R}$  是随机变量, 实际上只需要验证对于任意  $a \in \mathbb{R}$  都有  $\{X \leq a\} \in \mathcal{F}$ .

回到刚才的股票例子, 时刻  $t$  的价格  $S_t: \Omega \rightarrow \mathbb{R}_+$  就是一个随机变量. 如果  $S_{t-1} > 0$ , 收益率

$$R_t = \frac{S_t - S_{t-1}}{S_{t-1}}$$

也只是价格随机变量经过确定变换以后得到的函数, 因而仍然是一个随机变量. 类似地, MACD 之类的技术指标也是对历史价格进行某种确定变换以后得到的数值, 所以在合适的可测性条件下, 它们同样可以被视为随机变量.

### 随机变量所携带的信息

既然随机变量可以理解成对于原概率空间的一次观测, 那自然还可以问: 仅仅知道  $X$  的值以后, 我们究竟获得了多少关于原样本点  $\omega$  的信息?

#### 定义 3.5.

令  $X: \Omega \rightarrow \mathbb{R}$  为随机变量. 由  $X$  生成的  $\sigma$ -代数是指

$$\sigma(X) := \{X^{-1}(A) \mid A \in \mathcal{B}(\mathbb{R})\}.$$

$\sigma(X)$  可以理解成“仅仅通过观察  $X$  能够分辨出来的全部事件”. 由可测性有  $\sigma(X) \subseteq \mathcal{F}$ , 所以从信息的角度来看, 随机变量实际上是在主动丢弃原概率空间中的一部分信息.

两个样本点  $\omega_1, \omega_2$  即使在原来的样本空间中完全不同, 只要  $X(\omega_1) = X(\omega_2)$ , 那么仅仅通过观察  $X$  就无法再把它区分开来.

比如对于股票价格随机变量  $S_t$ ,  $\sigma(S_t)$  描述的就是仅仅观察时刻  $t$  的价格以后能够获得的信息. 而如果我们观察截至时刻  $t$  的全部历史价格, 那么自然会得到  $\sigma(S_0, \dots, S_t)$ . 后面我们还会把这种“随着时间不断增加的信息”系统地整理成所谓的滤过 (filtration, 也称滤链).

### 事件与随机变量

事件本身也可以被编码成一个非常简单的随机变量.

#### 定义 3.6.

令  $A \in \mathcal{F}$  为事件.  $A$  的示性随机变量是指

$$\mathbf{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

所以一个事件可以被编码成一个只取 0 和 1 的随机变量. 后面我们还会看到  $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$ , 也就是说事件的概率就是其示性随机变量的期望.

### 随机向量与随机过程

随机变量也不一定非要只记录一个数. 如果  $X = (X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$  是可测映射, 那么称  $X$  为一个随机向量.

更一般地, 如果  $(E, \mathcal{E})$  是任意可测空间, 那么也可以考虑可测映射  $X: \Omega \rightarrow E$ , 这种对象通常称为一个随机元素. 所以实值随机变量只是最基本的一种情况.

而如果我们不再只看某一个固定时刻的  $S_t$ , 而是同时考虑整族  $\{S_t\}_{t \in T}$ , 那么我们就已经开始研究一个随机过程了.

之后所谓随机过程, 可以先理解成把“一个随机变量”推广成“一族带有时间参数的随机变量”. 新的困难也就在这里: 当我们同时研究很多随机变量以后, 除了每一个随机变量自身的分布以外, 还需要研究它们之间的依赖关系, 以及这些关系如何随着时间发生变化.

## 3.2 随机变量的分布

回忆上一节中, 我们将随机变量定义为从概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$  到  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  的可测函数.

另一方面, 在前面的测度论中, 对于测度  $\mathbb{P}$  以及可测映射  $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$ , 我们已经定义了其前推测度

$$X_*\mathbb{P} := \mathbb{P}(X^{-1}(-)).$$

到了概率论里面, 当  $X$  是一个随机变量或者更一般的随机元素时, 我们通常把这个前推测度称为  $X$  的分布.

这里并没有引入新的测度论结构. 所谓随机变量的分布, 就是把原来定义在样本空间  $\Omega$  上的概率测度, 通过随机变量  $X$  前推到它的值域以后得到的概率测度.

### 3.2.1 分布作为前推测度

根据前面的讨论, 我们可以直接得到下面的定义.

#### 定义 3.7.

令  $(\Omega, \mathcal{F}, \mathbb{P})$  为概率空间,  $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$  为随机元素. 称前推测度  $X_*\mathbb{P}$  为  $X$  在概率测度  $\mathbb{P}$  下的分布, 记作  $\mathcal{L}(X)$  或  $\mu_X$ .

也就是说, 对于任意  $A \in \mathcal{G}$ , 有

$$(X_*\mathbb{P})(A) = \mathbb{P}(X \in A).$$

更一般地, 令  $\mu$  为  $(E, \mathcal{G})$  上的概率测度. 如果  $X_*\mathbb{P} = \mu$ , 则称  $X$  服从分布  $\mu$ , 记作  $X \sim \mu$ .

所以分布本身只是值域  $(E, \mathcal{G})$  上的一个概率测度. 但是同一个概率测度完全可以通过许多不同的概率空间和随机变量得到, 这就引出了所谓的实现.

#### 定义 3.8.

令  $\mu$  为可测空间  $(E, \mathcal{G})$  上的概率测度. 称概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$  以及随机元素  $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$  为分布  $\mu$  的一个实现, 是指其满足  $X_*\mathbb{P} = \mu$ .

有时也直接称随机变量  $X$  为分布  $\mu$  的一个实现.

所以分布与它的实现是两件不同的事情.

分布  $\mu$  只记录值域上的概率规律, 而不会记录它究竟来自哪个样本空间, 也不会记录随机变量具体是怎样从这个样本空间中提取出来的. 因此同一个分布通常具有许多完全不同的实现.

事实上, 每一个概率分布都有一个最直接的实现.

#### 例 3.9 (典范实现).

令  $\mu$  为  $(E, \mathcal{G})$  上的概率测度. 直接取概率空间  $(E, \mathcal{G}, \mu)$ , 并令  $X = \text{id}_E$ , 那么

$$X_*\mu = (\text{id}_E)_*\mu = \mu.$$

因此恒等随机元素  $\text{id}_E$  本身就是分布  $\mu$  的一个实现.

从这个角度来看, 概率测度本身就可以被看成恒等随机元素的分布. 一般随机变量的分布, 就是把原来的概率测度通过某个观测  $X$  前推到另一个空间以后得到的概率测度.

这也说明了为什么概率论里面很多时候我们关心的是分布, 而不是某一个具体的实现.

#### 定义 3.10.

令  $(\Omega, \mathcal{F}, \mathbb{P})$  和  $(\Omega', \mathcal{F}', \mathbb{Q})$  为概率空间,  $X: \Omega \rightarrow E$  和  $Y: \Omega' \rightarrow E$  为取值于同一可测空间  $(E, \mathcal{G})$  的随机元素.

称  $X$  与  $Y$  同分布, 是指其满足

$$X_*\mathbb{P} = Y_*\mathbb{Q}.$$

通常记作  $X \stackrel{d}{=} Y$ .

所以“同分布”并不是说  $X$  和  $Y$  是同一个函数, 甚至也不要求它们定义在同一个概率空间上. 它只是在说, 当我们把它们各自所在概率空间上的概率测度前推到值域以后, 最终得到了完全相同的概率规律.

不过如果同时研究多个随机变量, 只知道每个随机变量各自的分布还不等于知道它们放在一起

以后的联合分布. 换句话说, 边缘分布本身并不决定随机变量之间的依赖结构. 这也是后面讨论独立性, 条件概率和随机过程时需要额外关心联合分布的原因.

### 分布函数

对于一般的随机元素  $X: \Omega \rightarrow (E, \mathcal{G})$ , 它的分布  $X_*\mathbb{P}$  已经是我们能够得到的最一般描述. 如果  $E$  只是一个任意可测空间, 通常并不存在一个像“分布函数”一样自然的普通函数能够完整记录这个分布.

不过当值域为  $\mathbb{R}^n$  时情况会好很多. 对于  $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ , 记

$$(-\infty, x] := \prod_{i=1}^n (-\infty, x_i].$$

我们可以直接记录分布在这些左下矩形上积累了多少概率质量.

#### 定义 3.11.

令  $X = (X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$  为随机向量.  $X$  的分布函数 (cumulative distribution function, CDF) 是指函数  $F_X: \mathbb{R}^n \rightarrow [0, 1]$ , 其中

$$F_X(x_1, \dots, x_n) := \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

如果记  $\mu_X = X_*\mathbb{P}$ , 那么也可以写成  $F_X(x) = \mu_X((-\infty, x])$ . 当  $n > 1$  时,  $F_X$  也常称为  $X$  的联合分布函数.

当  $n = 1$  时, 这当然就退化成为  $F_X(x) = \mathbb{P}(X \leq x)$ .

### 分布函数与分布

$\mathbb{R}^n$  上的分布函数实际上可以完整确定随机向量的分布.

比如对于二维随机向量  $(X, Y)$ , 如果已经知道  $F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ , 那么矩形  $(a, b] \times (c, d]$  的概率就是

$$\begin{aligned} \mathbb{P}(a < X \leq b, c < Y \leq d) &= F_{X,Y}(b, d) - F_{X,Y}(a, d) \\ &\quad - F_{X,Y}(b, c) + F_{X,Y}(a, c). \end{aligned}$$

高维情况只是继续对每一个坐标做这样的差分.

对于矩形  $R = \prod_{i=1}^n (a_i, b_i]$ , 记

$$\Delta_R F := \sum_{\varepsilon \in \{0,1\}^n} (-1)^{n-|\varepsilon|} F(c_\varepsilon),$$

其中  $c_\varepsilon$  的第  $i$  个坐标在  $\varepsilon_i = 1$  时取  $b_i$ , 在  $\varepsilon_i = 0$  时取  $a_i$ .

如果  $F$  真的是某个随机向量的分布函数, 那么  $\Delta_R F$  恰好就是这个矩形的概率, 因此必然满足  $\Delta_R F \geq 0$ .

#### 定义 3.12.

称函数  $F: \mathbb{R}^n \rightarrow [0, 1]$  为一个  $n$  维分布函数, 是指其满足:

1. 对于任意半开矩形  $R = \prod_{i=1}^n (a_i, b_i]$ , 都有  $\Delta_R F \geq 0$ ;
2. 如果  $x^{(k)} \downarrow x$  逐坐标成立, 则  $F(x^{(k)}) \rightarrow F(x)$ ;
3. 如果任意一个坐标趋于  $-\infty$ , 则  $F(x_1, \dots, x_n) \rightarrow 0$ ;
4. 当所有坐标同时趋于  $+\infty$  时,  $F(x_1, \dots, x_n) \rightarrow 1$ .

第一条通常称为  $F$  的  $n$ -递增性. 当  $n = 1$  时, 它恰好就是普通的单调不减. 但是在高维情况下, 单独要求  $F$  对每一个坐标单调不减是不够的, 我们还必须保证每一个矩形对应的“概率”都是非负的.



**定理 3.13.**

令  $F: \mathbb{R}^n \rightarrow [0, 1]$  为函数. 则  $F$  是某个  $\mathbb{R}^n$  值随机向量的分布函数, 当且仅当  $F$  是一个  $n$  维分布函数.

此外, 此时存在唯一的 Borel 概率测度  $\mu_F$ , 满足对于任意  $x \in \mathbb{R}^n$  都有

$$\mu_F((-\infty, x]) = F(x).$$

证明. 如果  $F$  来自某个概率测度, 上面的性质都可以直接由测度的性质得到.

反过来, 可以先在半开矩形上令  $\mu_F(R) := \Delta_R F$ .  $n$ -递增性保证这些矩形增量非负. 然后把这个赋值扩展到由有限个不交半开矩形组成的代数上; 右连续性和边界条件保证它给出一个概率预测度. 再利用 Carathéodory 扩张定理得到  $\mathcal{B}(\mathbb{R}^n)$  上的概率测度.

唯一性则可以由  $\pi$ - $\lambda$  定理得到, 因为左下矩形  $(-\infty, x]$  生成整个  $\mathcal{B}(\mathbb{R}^n)$ .  $\square$

因此对于  $\mathbb{R}^n$  上的概率分布, 分布函数和概率测度实际上携带完全相同的信息.

**推论 3.14.**

令  $F$  为任意  $n$  维分布函数. 则存在概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$  以及随机向量  $X: \Omega \rightarrow \mathbb{R}^n$ , 使得  $F_X = F$ .

证明. 令  $\mu_F$  为  $F$  对应的 Borel 概率测度. 直接取概率空间  $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mu_F)$  以及恒等随机向量  $X = \text{id}_{\mathbb{R}^n}$  即可.  $\square$

对于随机向量  $X = (X_1, \dots, X_n)$ , 各个坐标随机变量的分布称为**边缘分布**. 比如二维情况下, 可以通过  $F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y)$  从联合分布函数中恢复  $X$  的边缘分布函数.

**3.2.2 一些常见的分布**

接下来我们来看一些常见的概率分布.

下面我们不按公式列表来记这些分布. 相比于公式本身, 我们更加关心这些分布是在什么样的随机机制下自然出现的, 以及不同分布之间到底有什么关系.

**离散分布****定义 3.15.**

令  $X$  为随机变量. 称  $X$  具有**离散分布**, 是指存在有限或者可数集  $S \subseteq \mathbb{R}$ , 使得  $\mathbb{P}(X \in S) = 1$ .

此时函数  $p_X(x) := \mathbb{P}(X = x)$  称为  $X$  的**概率质量函数** (probability mass function, PMF).

于是对于任意 Borel 集  $A$ , 都有  $\mathbb{P}(X \in A) = \sum_{x \in A} p_X(x)$ . 所以离散分布本质上只需要告诉我们, 每一个可能取值上放了多少概率质量.

**例 3.16 (单点分布).**

令  $a \in \mathbb{R}$ . 如果随机变量  $X$  满足  $\mathbb{P}(X = a) = 1$ , 那么称  $X$  服从位于  $a$  的**单点分布**. 它的分布就是 Dirac 测度  $\delta_a$ , 也就是说

$$\delta_a(A) = \begin{cases} 1, & a \in A, \\ 0, & a \notin A. \end{cases}$$

这是最简单的概率分布: 所有概率质量全部集中在一个点上.

**例 3.17 (Bernoulli 分布).**

令  $p \in [0, 1]$ . 如果随机变量  $X$  只取 0 和 1 两个值, 并满足  $\mathbb{P}(X = 1) = p$ ,  $\mathbb{P}(X = 0) = 1 - p$ , 那么称  $X$  服从参数为  $p$  的**Bernoulli 分布**, 记作  $X \sim \text{Bernoulli}(p)$ .

Bernoulli 分布就是一次“成功或者失败”实验最直接的数学描述. 比如抛一次硬币时, 可

以令正面对应 1, 反面对应 0.

### 例 3.18 (二项分布).

令  $n \in \mathbb{N}$ ,  $p \in [0, 1]$ . 如果进行  $n$  次相互独立且成功概率均为  $p$  的 Bernoulli 实验, 并令  $X$  表示其中成功的总次数, 那么

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

此时称  $X$  服从参数为  $(n, p)$  的**二项分布**, 记作  $X \sim \text{Bin}(n, p)$ .

换句话说, Bernoulli 分布描述一次实验, 而二项分布描述重复  $n$  次相同实验以后成功的总次数.

等到后面正式定义独立性以后, 这也可以写成: 如果  $X_1, \dots, X_n$  相互独立并且都服从  $\text{Bernoulli}(p)$ , 那么  $X_1 + \dots + X_n \sim \text{Bin}(n, p)$ .

### 例 3.19 (几何分布).

令  $p \in (0, 1]$ . 不断进行相互独立且成功概率均为  $p$  的 Bernoulli 实验, 并令  $T$  表示直到第一次成功为止一共进行了多少次实验. 那么

$$\mathbb{P}(T = k) = (1-p)^{k-1} p, \quad k = 1, 2, \dots$$

此时称  $T$  服从参数为  $p$  的**几何分布**, 记作  $T \sim \text{Geom}(p)$ .

所以几何分布研究的不是“成功了多少次”, 而是“要等多少次实验才第一次成功”.

这里采用的是取值从 1 开始的约定. 也有一些地方将第一次成功以前失败的次数记为几何分布, 那时其取值会从 0 开始.

### 例 3.20 (Poisson 分布).

令  $\lambda > 0$ . 如果随机变量  $X$  取值于  $\mathbb{N}_0 = \{0, 1, 2, \dots\}$ , 并满足

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k \in \mathbb{N}_0,$$

那么称  $X$  服从参数为  $\lambda$  的**Poisson 分布**, 记作  $X \sim \text{Pois}(\lambda)$ .

Poisson 分布通常用来描述某一段固定时间或者固定区域内“一共发生了多少次事件”.

一个比较自然的理解是, 将这一段时间切成  $n$  个非常小的区间, 每一个小区间内发生一次事件的概率约为  $\lambda/n$ , 并暂时假设这些小区间之间彼此独立. 那么总事件数近似服从  $\text{Bin}(n, \lambda/n)$ .

对固定的  $k$ , 当  $n \rightarrow \infty$  时,

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda} \frac{\lambda^k}{k!}.$$

所以 Poisson 分布可以粗略理解成“大量极小概率 Bernoulli 事件的计数极限”.

这段直觉已经用到了独立性, 稳定发生率以及极短时间内不会同时发生很多次事件之类的假设. 后面介绍泊松过程时会重新正式处理这些条件.

## 绝对连续分布

离散分布将全部概率质量集中在至多可数多个点上. 另一种非常重要的情况, 则是分布关于 Lebesgue 测度绝对连续.



**定义 3.21.**

令  $X: \Omega \rightarrow \mathbb{R}^n$  为随机向量,  $\mu_X = X_*\mathbb{P}$  为其分布. 称  $X$  具有**绝对连续分布**, 是指

$$\mu_X \ll \lambda_n,$$

其中  $\lambda_n$  为  $\mathbb{R}^n$  上的 Lebesgue 测度.

此时由 Radon - Nikodym 定理, 存在非负可测函数  $f_X: \mathbb{R}^n \rightarrow [0, \infty)$ , 使得对于任意  $A \in \mathcal{B}(\mathbb{R}^n)$  都有

$$\mathbb{P}(X \in A) = \int_A f_X(x) dx.$$

称  $f_X$  为  $X$  的**概率密度函数** (probability density function, PDF).

所以概率密度就是随机变量分布关于 Lebesgue 测度的 Radon-Nikodym 导数, 也就是

$$f_X = \frac{d\mu_X}{d\lambda_n}.$$

特别地, 在一维情况下,  $F_X(x) = \int_{-\infty}^x f_X(t) dt$ .

这里需要再次强调,  $f_X(x)$  并不是“ $X = x$  的概率”. 对于绝对连续随机变量, 任意单点的概率都等于 0; 真正具有概率意义的是密度在某个区域上的积分.

此外, 分布函数连续也并不等价于分布绝对连续. 确实存在分布函数处处连续, 但是分布却关于 Lebesgue 测度奇异的情况. 所以“存在概率密度”的条件是  $\mu_X \ll \lambda_n$ .

**例 3.22 (均匀分布).**

令  $a < b$ . 如果随机变量  $X$  的概率密度为

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x),$$

那么称  $X$  服从区间  $[a, b]$  上的**均匀分布**, 记作  $X \sim \text{Unif}(a, b)$ .

可以把它看作古典等可能模型的连续版本. 每一个单独的点虽然概率都为 0, 但是长度相同的区间具有相同的概率.

**例 3.23 (指数分布).**

令  $\lambda > 0$ . 如果随机变量  $T$  的概率密度为

$$f_T(t) = \lambda e^{-\lambda t} \mathbf{1}_{[0,\infty)}(t),$$

那么称  $T$  服从参数为  $\lambda$  的**指数分布**, 记作  $T \sim \text{Exp}(\lambda)$ .

指数分布通常描述连续时间中“等待下一次事件发生需要多久”.

因此它和几何分布具有非常自然的类比: 几何分布记录离散时间中要经过多少次实验才第一次成功, 而指数分布记录连续时间中要等待多久才第一次发生事件.

更进一步, 几何分布和指数分布都具有所谓的**无记忆性**. 比如对于指数分布, 当  $s, t \geq 0$  时有

$$\mathbb{P}(T > s+t \mid T > s) = \mathbb{P}(T > t).$$

也就是说, 已经等了多久并不会改变从现在开始还需要继续等待多久的概率规律.

**例 3.24 (Gamma 分布).**

令  $\alpha > 0, \lambda > 0$ . 如果随机变量  $T$  的概率密度为

$$f_T(t) = \frac{\lambda^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\lambda t} \mathbf{1}_{[0,\infty)}(t),$$

那么称  $T$  服从形状参数为  $\alpha$ , 率参数为  $\lambda$  的 **Gamma 分布**, 记作  $T \sim \text{Gamma}(\alpha, \lambda)$ .

这里采用的是率参数 (rate parameter) 约定. 另一种常见记法使用尺度参数 (scale parameter)  $\theta = 1/\lambda$ .

Gamma 分布和 Poisson 分布之间有一个非常自然的关系.

在后面泊松过程的设定中, 假设事件以恒定速率  $\lambda$  发生, 并令  $N(t)$  表示时间  $t$  以前发生的事件次数. 那么会有  $N(t) \sim \text{Pois}(\lambda t)$ .

现在反过来, 令  $T_k$  表示第  $k$  次事件发生所需要的时间. 那么  $\{T_k > t\} = \{N(t) \leq k-1\}$ , 因此

$$\mathbb{P}(T_k \leq t) = 1 - \sum_{j=0}^{k-1} e^{-\lambda t} \frac{(\lambda t)^j}{j!}.$$

对  $t$  求导以后得到

$$f_{T_k}(t) = \frac{\lambda^k}{(k-1)!} t^{k-1} e^{-\lambda t} \mathbf{1}_{[0, \infty)}(t).$$

由于  $\Gamma(k) = (k-1)!$ , 这恰好就是  $\text{Gamma}(k, \lambda)$  的概率密度.

所以 Poisson 分布和 Gamma 分布并不是简单的“离散版本”和“连续版本”. 它们实际上是在同一个随机机制里面回答两个相反的问题: 固定时间  $t$  时, 问发生了多少次事件, 得到 Poisson 分布; 固定事件次数  $k$  时, 问等到第  $k$  次事件需要多久, 得到 Gamma 分布.

特别地, 当  $k=1$  时, Gamma 分布就退化指数分布. 所以指数分布也就是等待第一次 Poisson 事件发生所需要时间的分布.

### 例 3.25 (正态分布).

令  $\mu \in \mathbb{R}$ ,  $\sigma > 0$ . 如果随机变量  $X$  的概率密度为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right),$$


那么称  $X$  服从参数为  $(\mu, \sigma^2)$  的 **正态分布** (normal distribution), 也称高斯分布 (Gaussian distribution), 记作

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

当  $\mu=0$ ,  $\sigma=1$  时, 称其为**标准正态分布**, 记作  $\mathcal{N}(0, 1)$ .

从概率密度的图像来看, 正态分布关于  $x=\mu$  对称. 参数  $\mu$  控制整个分布在实轴上的位置, 而  $\sigma$  控制分布展开的尺度:  $\sigma$  越大, 概率质量铺得越开;  $\sigma$  越小, 概率质量则越集中在  $\mu$  附近.

比如下面画出了  $\mu=0$  时正态分布概率密度的大致形状, 并标出了距离均值  $\sigma$ ,  $2\sigma$ ,  $3\sigma$  的位置.



后面定义期望和方差以后我们会看到,  $\mu$  恰好就是  $X$  的期望, 而  $\sigma^2$  恰好就是其方差, 因此  $\sigma$  就是标准差.

对于正态分布, 大约有 68.27% 的概率质量落在  $(\mu-\sigma, \mu+\sigma)$  内, 95.45% 落在  $(\mu-2\sigma, \mu+2\sigma)$  内, 而 99.73% 落在  $(\mu-3\sigma, \mu+3\sigma)$  内.

因而在正态模型下, 落在  $\mu \pm 3\sigma$  以外的概率约为 0.27%, 这也就是常说的“3 $\sigma$  法则”.

正态分布还有一个非常方便的性质: 它在线性变换下仍然保持为正态分布. 如果  $X \sim \mathcal{N}(\mu, \sigma^2)$ , 那么对于  $a \neq 0$  和  $b \in \mathbb{R}$ , 有

$$aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

特别地,

$$\frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1),$$

这个过程通常称为**标准化**.

此外, 如果  $X$  和  $Y$  相互独立, 并分别满足  $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$  和  $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$ , 那么

$$X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

正态分布之所以如此常见, 并不只是因为这条钟形曲线比较好处理. 更重要的原因是, 大量相对独立的小随机扰动叠加以后, 在相当一般的条件下都会趋近于正态分布.

这就是后面中心极限定理真正要说明的事情.

### 注 3.26 (多元正态分布).

正态分布也可以推广到随机向量.


令  $\mu \in \mathbb{R}^n$ ,  $\Sigma$  为正定的  $n \times n$  矩阵. 对应的  $n$  元正态分布记作  $\mathcal{N}(\mu, \Sigma)$ , 其概率密度为

$$f(x) = \frac{1}{(2\pi)^{n/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

后面定义随机向量的期望和协方差以后会看到,  $\mu$  就是均值向量, 而  $\Sigma$  就是协方差矩阵.

从几何上来看, 一维正态分布中“离均值多少个标准差”的概念, 到高维以后会变成由  $\Sigma$  决定的椭球结构.

比如下面画出了一个二维正态分布的等密度区域. 椭圆的中心就是均值  $\mu$ , 而椭圆的方向以及沿各个方向展开的程度则由协方差矩阵  $\Sigma$  决定.



更具体地说, 正态密度的等值面满足

$$(x - \mu)^\top \Sigma^{-1}(x - \mu) = c,$$

因而在二维中就是椭圆, 在更高维中则是椭球.

更一般的多元正态分布还允许  $\Sigma$  只是半正定. 此时分布可能退化到某个低维仿射子空间上, 因而不具有关于整个  $\mathbb{R}^n$  上 Lebesgue 测度的概率密度.

### 注 3.27.

上面的几个分布与其说是一堆需要记忆的公式, 不如说是在回答几类非常自然的问题:

Bernoulli 分布问一次实验是否成功; Binomial 分布问  $n$  次实验一共成功多少次; Geometric 分布问要做多少次实验才第一次成功; Poisson 分布问一段固定时间内发生多少次事件; Exponential 分布问等待第一次事件需要多久; Gamma 分布问等待第  $k$  次事件需要多久; Normal 分布则描述大量小随机扰动叠加以后出现的典型极限形状.

更值得记住的不是每一条公式本身, 而是这些分布背后分别在描述什么样的随机机制.

### 3.3 期望与矩

#### 3.3.1 期望与矩的基本语言

前面我们主要研究了随机变量的分布, 也就是一个随机变量可能取哪些值, 以及这些值按照怎样的概率规律出现.

不过一个完整的分布通常包含很多信息. 实际研究时, 我们经常希望先用几个数字概括这个分布的主要特征: 一个随机变量大概位于什么位置, 围绕这个位置波动得有多厉害, 或者分布究竟有多偏. 这些信息很多都可以通过随机变量的矩来描述, 而其中最基本的是期望.

在前面的测度论中, 我们已经定义了可测函数关于测度的 Lebesgue 积分, 所以到了概率论里面并不需要重新发明一种新的“平均值”.

##### 定义 3.28.

令  $(\Omega, \mathcal{F}, \mathbb{P})$  为概率空间,  $X: \Omega \rightarrow \mathbb{R}$  为随机变量. 如果  $X \in L^1(\Omega, \mathbb{P})$ , 则  $X$  的期望(expectation) 是指

$$\mathbb{E}[X] := \int_{\Omega} X \, d\mathbb{P}.$$

这里定义的是有限期望. 对于非负随机变量  $X \geq 0$ , 也常允许扩展值期望

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P} \in [0, \infty],$$

所以它可以等于  $+\infty$ . 对于一般实值随机变量, 可以先写  $X = X^+ - X^-$ ; 只要  $\mathbb{E}[X^+]$  和  $\mathbb{E}[X^-]$  不同时为  $+\infty$ , 扩展值意义下的期望就有定义. 而有限期望正好对应  $X \in L^1$ .

期望就是概率测度下的 Lebesgue 积分. 把它理解成“平均值”没有问题, 不过这个平均并不是简单地把所有可能取值加起来再除以个数, 而是按照概率测度对不同结果进行加权.

比如如果  $X$  只取可数多个值  $x_1, x_2, \dots$ , 那么在期望存在时有  $\mathbb{E}[X] = \sum_i x_i \mathbb{P}(X = x_i)$ ; 如果  $X$  具有概率密度  $f_X$ , 那么  $\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x) \, dx$ . 初等概率论里面所谓“离散情况求和, 连续情况积分”并不是两套不同的期望定义, 而只是同一个 Lebesgue 积分在不同分布下的表现形式.

回忆前面, 实值随机变量  $X$  的分布就是前推测度  $\mu_X = X_*\mathbb{P}$ . 因此前推测度的积分公式直接告诉我们, 如果  $g: \mathbb{R} \rightarrow \mathbb{R}$  为可测函数并且  $g(X)$  可积, 那么

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \, d\mu_X(x).$$

所以只要研究的是  $X$  的函数, 它的期望只依赖于  $X$  的分布, 而与  $X$  究竟在哪个概率空间上实现没有关系. 特别地, 如果  $X \stackrel{d}{=} Y$ , 那么只要相关期望存在, 对于任意合适的  $g$  都有  $\mathbb{E}[g(X)] = \mathbb{E}[g(Y)]$ .

因为期望就是 Lebesgue 积分, 前面关于积分的大量性质也可以直接搬过来. 对于  $X, Y \in L^1$  和  $a, b \in \mathbb{R}$ , 有  $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$ . 如果  $X \leq Y$  几乎必然 (almost surely, a.s.), 则  $\mathbb{E}[X] \leq \mathbb{E}[Y]$ . 对于事件  $A$  的示性随机变量, 有  $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$ , 所以概率本身也可以被理解成一种最简单的期望. 由  $|\mathbb{E}[X]| \leq \mathbb{E}[|X|] = \|X\|_1$ , 期望还是  $L^1(\Omega, \mathbb{P})$  上的连续线性泛函.

前面介绍  $L^p$  空间时已经看到, 当  $1 \leq p < \infty$  时有  $\|X\|_p^p = \mathbb{E}[|X|^p]$ . 所以从  $L^p$  的角度来看, “随机变量具有有限的  $p$  阶绝对矩”就是在说  $X \in L^p(\Omega, \mathbb{P})$ .

##### 定义 3.29.

令  $X$  为实值随机变量,  $k \in \mathbb{N}$ . 如果  $X \in L^k$ , 则称  $\mathbb{E}[|X|^k] = \|X\|_k^k$  为  $X$  的  $k$  阶绝对矩; 相应地,  $\mathbb{E}[X^k]$  称为  $X$  的  $k$  阶矩, 也称为  $k$  阶原点矩.

这里需要注意的是, 真正和  $L^k$  范数直接对应的是绝对矩. 当  $k$  为偶数时  $X^k = |X|^k$ , 因此  $\mathbb{E}[X^k] = \|X\|_k^k$ ; 而当  $k$  为奇数时,  $X^k$  会保留正负号, 所以一般不能直接使用  $L^k$  范数表示.

类似地,  $\mathbb{E}[|X - \mathbb{E}[X]|^k] = \|X - \mathbb{E}[X]\|_k^k$  称为  $k$  阶绝对中心矩, 而  $\mathbb{E}[(X - \mathbb{E}[X])^k]$  则称为  $k$  阶中心矩. 绝对矩衡量取值大小; 普通矩在奇数阶还会保留正负方向, 因而可能发生抵消. 阶数越高, 越大的取值获得的权重也就越大.

又因为概率空间满足  $\mathbb{P}(\Omega) = 1$ , 对于  $1 \leq p < q$  有  $L^q \subseteq L^p$ , 所以高阶绝对矩有限会自动推出所有更低阶绝对矩有限.

### 3.3.2 二阶结构与尾部控制

#### $L^2$ 空间, 协方差与方差

在所有的  $L^p$  空间里面,  $L^2$  对概率论尤其重要, 因为它是一个希尔伯特 (Hilbert) 空间. 对于实值随机变量  $X, Y \in L^2(\Omega, \mathbb{P})$ , 其内积就是  $\langle X, Y \rangle = \mathbb{E}[XY]$ .

不过如果直接使用这个内积, 随机变量自身的平均位置也会混在其中. 如果关心的是随机变量围绕各自平均位置的共同波动, 一个自然的办法就是先将它们中心化. 记  $X^\circ = X - \mathbb{E}[X]$ , 那么  $\langle X^\circ, 1 \rangle = 0$ , 也就是说中心化后的随机变量与常数函数正交.

更加准确地说,  $\mathbb{E}[X]1$  就是  $X$  向常数函数子空间的正交投影. 因此期望还有一个很自然的几何解释: 在所有常数  $c \in \mathbb{R}$  中,  $\mathbb{E}[X]$  恰好使得  $\|X - c\|_2$  最小. 换句话说, 如果只能使用一个常数来逼近随机变量  $X$ , 那么在均方误差意义下最好的选择就是它的期望.

#### 定义 3.30.

令  $X, Y \in L^2(\Omega, \mathbb{P})$ .  $X$  与  $Y$  的协方差是指

$$\text{Cov}(X, Y) := \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

协方差就是两个随机变量中心化以后在  $L^2$  中的内积. 对于实值随机变量, 这也就是  $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$ , 展开以后得到

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

如果协方差为正, 大致表示二者相对于各自平均值的偏离倾向于同向; 如果为负, 则倾向于反向. 如果  $\text{Cov}(X, Y) = 0$ , 那么中心化后的两个随机变量在  $L^2$  中正交, 此时称  $X$  与  $Y$  不相关. 需要注意的是, 不相关只是在二阶的线性结构下正交, 一般并不能推出独立.

有了协方差以后, 方差只是令两个随机变量相同得到的特殊情况.

#### 定义 3.31.

令  $X \in L^2(\Omega, \mathbb{P})$ .  $X$  的方差是指

$$\text{Var}(X) := \text{Cov}(X, X) = \|X - \mathbb{E}[X]\|_2^2.$$

从 Hilbert 空间的角度来看, 方差就是中心化随机变量的长度平方. 因此  $\text{Var}(X) \geq 0$ , 并且  $\text{Var}(X) = 0$  当且仅当  $X = \mathbb{E}[X]$  a.s. 展开以后还有  $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$ .

#### 定义 3.32.

令  $X \in L^2(\Omega, \mathbb{P})$ .  $X$  的标准差是指

$$\text{Std}(X) := \sqrt{\text{Var}(X)} = \|X - \mathbb{E}[X]\|_2.$$

如果方差是中心化随机变量的长度平方, 标准差就是它的  $L^2$  长度. 这也解释了为什么要对方差开平方: 方差的量纲被平方了, 而标准差又回到了和原随机变量相同的尺度.

协方差仍然受到随机变量尺度的影响. 比如把  $X$  放大 100 倍, 协方差也会放大 100 倍. 所以如果希望得到一个与尺度无关的量, 自然应该进一步标准化.

#### 定义 3.33.

令  $X, Y \in L^2(\Omega, \mathbb{P})$ , 并假设二者方差均非零.  $X$  与  $Y$  的相关系数是指

$$\rho(X, Y) := \frac{\text{Cov}(X, Y)}{\text{Std}(X)\text{Std}(Y)}.$$

如果令  $\tilde{X} = (X - \mathbb{E}[X])/\text{Std}(X)$ ,  $\tilde{Y} = (Y - \mathbb{E}[Y])/\text{Std}(Y)$ , 那么  $\rho(X, Y) = \langle \tilde{X}, \tilde{Y} \rangle$ . 又因为  $\|\tilde{X}\|_2 = \|\tilde{Y}\|_2 = 1$ , 所以相关系数其实就是  $L^2$  中两个单位向量之间的内积, 也就是所谓的“夹角余弦”. 因此由 Cauchy-Schwarz 不等式自然有  $|\rho(X, Y)| \leq 1$ .

因此期望, 协方差, 方差, 标准差和相关系数并不是几条互不相关的公式, 它们都来自同一个  $L^2$  Hilbert 空间结构.



## 尾部与尾部风险

前面介绍的期望, 方差以及各种矩, 都试图使用少量数字来概括一个完整的概率分布. 但是在很多问题里面, 尤其是在金融市场中, 我们关心的并不只是随机变量通常位于哪里, 而是它跑到非常极端的位置时究竟会发生什么.

分布中远离主要概率质量的部分通常称为分布的**尾部** (tail). 对于实值随机变量  $X$ , 当  $x$  很大时,  $\mathbb{P}(X > x)$  描述右尾,  $\mathbb{P}(X < -x)$  描述左尾; 如果只关心偏离原点有多远, 也经常考察  $\mathbb{P}(|X| > x)$ .

因此所谓“尾部有多重”, 本质上是在问: 随着阈值越来越远, 极端事件的概率究竟以多快的速度趋于 0.

### 定义 3.34.

令  $X$  为实值随机变量,  $F_X$  为其分布函数.  $X$  的**右尾函数**, 也称**生存函数**, 是指

$$\bar{F}_X(x) := \mathbb{P}(X > x) = 1 - F_X(x).$$

分布函数是在问“走到  $x$  为止已经积累了多少概率”, 而尾函数则是在问“走过  $x$  以后还剩下多少概率”. 尾部下降得越快, 极端取值通常越少; 下降得越慢, 极端事件就越常见. 因此我们会非正式地说一个分布具有**轻尾**或者**重尾**. 严格来说重尾有多种不同定义, 这里我们暂时只用一个宽松含义: 尾部概率下降得相对较慢.

尾部和矩之间的关系非常直接. 对于非负随机变量  $X$ , 有

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt,$$

两边允许同时为  $+\infty$ . 这是因为逐点都有  $X(\omega) = \int_0^\infty \mathbf{1}_{\{X(\omega) > t\}} dt$ , 再使用 Tonelli 定理交换积分即可.

更加一般地, 对于  $p > 0$  有

$$\mathbb{E}[|X|^p] = p \int_0^\infty t^{p-1} \mathbb{P}(|X| > t) dt.$$

这个公式说明了为什么高阶矩越来越重视尾部. 当  $p$  增大时,  $t^{p-1}$  会越来越强烈地放大那些极端的大取值. 因此如果分布的尾部下降得太慢, 某些高阶矩就可能直接发散. 从这个角度来看,  $X \in L^p$  也可以理解成它的尾部下降得足够快, 使得这个加权尾部积分仍然有限.

比如正态分布的尾部下降得非常快, 所以它具有任意阶的绝对矩. 而如果一个随机变量具有类似  $\mathbb{P}(|X| > x) \sim Cx^{-\alpha}$  的幂律尾部, 那么只有  $p < \alpha$  的绝对矩有限, 当  $p \geq \alpha$  时相应的矩会发散.

因此“期望和方差是多少”并不能完整描述一个分布. 两个分布完全可以具有相同的期望和方差, 但其中一个在极端区域放置了更多概率质量. 如果只看前两阶矩, 这种差异就很容易被忽略.

反过来, 如果我们已经知道一些矩, 也可以利用它们控制尾部概率.

### 定理 3.35 (Markov 不等式).

令  $X \geq 0$  为可积随机变量,  $a > 0$ . 则

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

证明. 因为  $X \geq a \mathbf{1}_{\{X \geq a\}}$ , 取期望即可. □

更加一般地, 如果  $X \in L^p$ , 那么对  $|X|^p$  使用 Markov 不等式就得到

$$\mathbb{P}(|X| \geq a) \leq \frac{\mathbb{E}[|X|^p]}{a^p} = \frac{\|X\|_p^p}{a^p}.$$

矩和尾部之间存在一种很自然的双向关系: 尾部下降得有多快决定了哪些矩能够存在; 而控制住某个高阶矩以后, 又可以反过来限制极端事件的概率.

**定理 3.36 (Chebyshev 不等式).**

令  $X \in L^2(\Omega, \mathbb{P})$ ,  $a > 0$ . 则

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

Chebyshev 不等式是把 Markov 不等式应用到中心化随机变量的平方上. 因而方差不只是一个  $L^2$  长度平方, 它还能够控制随机变量偏离平均位置很远的概率.

Markov 和 Chebyshev 不等式只使用了很少的信息, 所以实际给出的界往往非常粗糙; 它们更加重要的地方在于告诉我们一个基本思想: **控制矩可以转化成控制尾部概率**. 后面的大数定律以及很多随机过程中的概率估计都会不断用到这一点.

尾部在金融市场里面尤其重要. 对于投资来说, 真正麻烦的事情很多时候不是“正常情况下会发生什么”, 而是“如果事情明显偏离原来的预期, 到底可能坏到什么程度”.

比如令  $V$  表示某个未来时点资产的价值. 理论上我们想知道的是  $V$  的完整概率分布, 但现实中的基本面研究通常很难准确给出这样一个分布. 一种自然的做法就是先将可能结果划分成若干具有经济意义的情景, 例如乐观情景 (Bull), 基准情景 (Base), 悲观情景 (Bear) 和尾部情景 (Tail), 然后再分别给出这些情景发生的概率以及相应估值.

从概率论的角度来看, 情景分析可以看作对原分布的一种**粗粒化**. 如果事件  $A_i$  构成对于可能结果的分区, 并为每个区域选择一个代表性价值  $V_i$ , 那么可以构造近似随机变量

$$\tilde{V} = \sum_i V_i \mathbf{1}_{A_i}, \quad \mathbb{E}[\tilde{V}] = \sum_i \mathbb{P}(A_i) V_i.$$

平常写的  $\sum_i p_i V_i$  就是在计算这个粗粒化分布的期望. Bull, Base, Bear, Tail 并不是概率论中的标准划分, 而只是根据研究目的对于原本连续而复杂的分布进行的一种人为压缩.

这里的尾部情景也最好不要简单理解成“比悲观情景再悲观一点”. 如果从概率论的尾部来看, Tail 想强调的是那些发生概率比较低, 但结果明显偏离通常区域, 并且一旦发生就可能造成巨大损失的事件.

因此金融里面所谓的尾部风险 (tail risk) 同时在问两件事: 掉进尾部的概率有多大, 以及一旦真的掉进去以后究竟可能有多糟. 这也是为什么仅仅知道期望和方差通常还远远不够.

后面讨论条件期望以后我们还会看到, 如果每个情景中的代表值  $V_i$  直接取成该情景下  $V$  的条件期望, 那么这种情景分解对于总期望甚至可以成为严格的等式, 而不再只是一个近似. 再往金融部分继续走, 对尾部的研究还会自然引出风险价值 (Value at Risk, VaR), 预期短缺 (Expected Shortfall, ES) 以及更加一般的尾部风险度量.

## 3.4 独立性, 条件概率与条件期望

### 3.4.1 独立性与条件概率

#### 事件与随机变量的独立性

前面我们主要是在研究单个随机变量以及它自身的分布. 但是一旦同时考虑多个事件或者多个随机变量, 一个很自然的问题就是: 它们之间究竟有没有关系?

比如令  $A$  表示“未来一个月股票上涨”,  $B$  表示“下一次财报超出市场预期”. 如果知道  $B$  已经发生以后, 我们对于  $A$  发生概率的判断完全没有变化, 那么直觉上就可以认为  $B$  并没有为  $A$  提供什么额外的信息. 这就是所谓的独立性.

**定义 3.37.**

令  $A, B \in \mathcal{F}$  为事件. 称  $A$  与  $B$  **相互独立**, 是指其满足

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

独立性表达的并不是“两个事件看起来没有关系”, 而是一个事件是否发生, 不会为另一个事件提供额外的概率信息. 如果  $\mathbb{P}(B) > 0$ , 那么上面的条件等价于  $\mathbb{P}(A | B) = \mathbb{P}(A)$ .

当同时考虑很多事件时, 还需要区分两两独立和共同独立.

**定义 3.38.**

令  $(A_i)_{i \in I}$  为一族事件. 称它们**相互独立**, 是指对于任意不同的  $i_1, \dots, i_n \in I$  都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

如果只要求任意两个事件相互独立, 则称它们**两两独立**. 两两独立一般并不能推出整族事件相互独立, 因为若干个事件放在一起以后仍然可能出现额外的依赖结构.

对于随机变量来说, 独立性还可以从信息的角度重新理解. 前面已经看到, 随机变量  $X$  所携带的信息可以由  $\sigma(X)$  描述, 所以一族随机变量相互独立, 就是它们各自携带的信息之间互不提供额外信息.

**定义 3.39.**

令  $(X_i)_{i \in I}$  为定义在同一概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$  上的一族随机元素. 称它们**相互独立**, 是指任意有限子族都满足下面第一条. 在实值情形中, 第一条还等价于后两条:

1. 对于任意不同的  $i_1, \dots, i_n \in I$  以及任意  $A_{i_k} \in \sigma(X_{i_k})$ , 都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

2. 对于实值随机变量  $X_1, \dots, X_n$ , 等价地, 任意 Borel 集  $B_1, \dots, B_n \subseteq \mathbb{R}$  都满足

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i).$$

3. 如果记  $X = (X_1, \dots, X_n)$ , 那么从分布的角度来看, 独立性又等价于联合分布分解成各个边缘分布的乘积:

$$\mu_X = \mu_{X_1} \otimes \cdots \otimes \mu_{X_n}.$$

因此独立性也可以理解成: 联合分布里面没有超出各个边缘分布之外的额外依赖结构.

特别地, 如果  $X, Y \in L^2$  相互独立, 那么  $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ , 因而  $\text{Cov}(X, Y) = 0$ . 所以独立会推出不相关, 但是反过来一般并不成立. 只有在某些特殊情况里面, 比如  $(X, Y)$  联合正态时, 不相关才会推出独立.

**条件概率与 Bayes 公式**

不过现实中的很多事件并不独立. 如果知道一件事情以后, 我们对于另一件事情的概率判断发生了改变, 那么自然就需要描述这种改变.

**定义 3.40.**

令  $A, B \in \mathcal{F}$ , 并满足  $\mathbb{P}(B) > 0$ .  $A$  在给定  $B$  发生条件下的**条件概率**是指

$$\mathbb{P}(A | B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

这个定义很好理解. 既然已经知道  $B$  发生, 原来的样本空间就被限制到了  $B$  中; 此时  $A$  能够发生的部分只剩下  $A \cap B$ , 再除以  $\mathbb{P}(B)$ , 就是把  $B$  中剩余的概率重新归一化成 1.

固定  $B$  以后,  $A \mapsto \mathbb{P}(A | B)$  本身又是一个概率测度. 因此条件概率可以理解成: 获得一部分新信息以后, 重新归一化得到的概率规律.

由定义立刻得到  $\mathbb{P}(A \cap B) = \mathbb{P}(A | B)\mathbb{P}(B)$ . 交换  $A, B$  的位置以后, 就得到 Bayes 公式.



**定理 3.41 (Bayes 公式).**

令  $A, B \in \mathcal{F}$ , 并满足  $\mathbb{P}(A), \mathbb{P}(B) > 0$ . 则

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}.$$

Bayes 公式描述的是: 看到新的证据  $B$  以后, 怎样把原来对于事件  $A$  的概率判断更新为  $\mathbb{P}(A | B)$ .  $\mathbb{P}(A)$  是看到信息  $B$  以前的判断, 而  $\mathbb{P}(A | B)$  则是在知道  $B$  以后得到的新判断.

如果  $(B_i)$  构成  $\Omega$  的一个可列分割, 并且  $\mathbb{P}(B_i) > 0$ , 那么还有

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A | B_i)\mathbb{P}(B_i),$$

这就是**全概率公式**.

它和前面 Bull, Base, Bear, Tail 的情景分析已经很接近. 如果这些情景对应一组互不相交并覆盖全部可能结果的事件  $B_i$ , 那么总体概率就可以通过“各情景自身的概率”和“每个情景内部的条件概率”重新拼回来. 而 Bayes 公式做的事情则正好反过来: 当我们得到新的财报, 行业或者宏观信息以后, 原来分配给 Bull, Base, Bear, Tail 的概率也应该随之发生变化.

**例 3.42 (DSpark 中的条件概率).**

一个比较现代的条件概率例子来自 DeepSeek 提出的 DSpark 系统 [Che+26]. 它属于投机解码 (speculative decoding) 一类方法: 成本较低的草稿模型 (draft model) 先生成一段候选文本, 再由成本较高的目标模型 (target model) 进行验证.

DSpark 的重点在于, 后续词元 (token) 能否被接受并不是孤立事件. 如果前面的候选前缀已经通过验证, 那么后面的候选也就失去了继续验证的意义. 因此它需要估计一种沿着前缀逐步条件化的接受概率.

令  $A_k$  表示“第  $k$  个草稿词元最终被目标模型接受”这一事件. DSpark 会估计条件接受概率

$$c_k \approx \mathbb{P}(A_k | A_1 \cap \cdots \cap A_{k-1}).$$

也就是说,  $c_k$  描述的是在前面的草稿词元已经全部通过验证的条件下, 当前词元继续被接受的概率.

因此由条件概率的乘法公式, 前  $k$  个词元全部通过验证的概率大约为

$$a_k := \prod_{i=1}^k c_i \approx \mathbb{P}(A_1 \cap \cdots \cap A_k).$$

DSpark 将  $a_k$  称为前缀存活概率 (prefix survival probability).

最后, 调度器会结合这些前缀存活概率和当前硬件负载, 判断这段草稿中有多少部分值得交给目标模型验证.

**3.4.2 条件期望****定义与存在性**

目前为止, 条件概率所描述的是“已经知道某一个事件  $B$  发生以后”, 我们应该怎样更新对于其他事件的概率判断. 但是到了随机过程里面, 我们拥有的信息通常远远不只是某一个事件.

比如截至时刻  $t$ , 我们可能已经观察到了整个股票价格历史, 以及成交量, 新闻, 订单流等等. 这些已经获得的信息更加自然地应该由一个子  $\sigma$ -代数  $\mathcal{G} \subseteq \mathcal{F}$  来描述.

于是问题变成: 给定随机变量  $X$ , 如果现在只允许使用  $\mathcal{G}$  中的信息, 我们应该怎样描述  $X$ ?

为了方便, 对于随机变量  $X$  和事件  $B \in \mathcal{F}$ , 记

$$\mathbb{E}[X; B] := \mathbb{E}[X\mathbf{1}_B] = \int_B X \, d\mathbb{P}.$$

现在固定  $X \in L^1(\Omega, \mathbb{P})$  以及子  $\sigma$ -代数  $\mathcal{G} \subseteq \mathcal{F}$ . 我们希望找到一个随机变量  $Y$ , 使它满足两件事:

1.  $Y$  是  $\mathcal{G}$ -可测的;
2. 对于任意  $B \in \mathcal{G}$ , 都有  $\mathbb{E}[Y; B] = \mathbb{E}[X; B]$ .

这里第一条要求  $Y$  只能使用  $\mathcal{G}$  中已经能够观察到的信息; 第二条则要求虽然  $Y$  丢掉了  $X$  中一部分暂时无法观察的信息, 但是在任何  $\mathcal{G}$  能够分辨出来的事件上, 它都保留  $X$  原来的平均值.

我们先验证唯一性, 再用 Radon-Nikodym 定理解决存在性.

**命题 3.43 (唯一性).**

令  $X \in L^1(\Omega, \mathbb{P})$ ,  $\mathcal{G} \subseteq \mathcal{F}$  为子  $\sigma$ -代数. 假设  $Y, Z \in L^1(\Omega, \mathbb{P})$  都是  $\mathcal{G}$ -可测的, 并且对于任意  $B \in \mathcal{G}$  都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B] = \mathbb{E}[Z; B].$$

则  $Y = Z$  a.s.

证明. 令  $W = Y - Z$ . 因为  $W$  为  $\mathcal{G}$ -可测, 所以  $B_+ = \{W > 0\}$  和  $B_- = \{W < 0\}$  都属于  $\mathcal{G}$ .

由假设有  $\mathbb{E}[W; B_+] = 0$ , 而  $W \mathbf{1}_{B_+} \geq 0$ , 所以  $W \mathbf{1}_{B_+} = 0$  a.s. 由于  $W > 0$  在  $B_+$  上成立, 这推出  $\mathbb{P}(B_+) = 0$ . 对  $B_-$  同理, 因而  $W = 0$  a.s.  $\square$

剩下的问题只是这样的  $Y$  是否一定存在, 而答案正好由前面介绍过的 Radon-Nikodym 定理给出.

**定理 3.44 (条件期望的存在性).**

令  $X \in L^1(\Omega, \mathbb{P})$ ,  $\mathcal{G} \subseteq \mathcal{F}$  为子  $\sigma$ -代数. 则存在  $\mathcal{G}$ -可测随机变量  $Y \in L^1(\Omega, \mathbb{P})$ , 使得对于任意  $B \in \mathcal{G}$  都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

证明. 写  $X = X^+ - X^-$ . 因为  $X \in L^1$ , 所以可以在  $(\Omega, \mathcal{G})$  上定义两个有限测度

$$\nu^+(B) := \mathbb{E}[X^+; B], \quad \nu^-(B) := \mathbb{E}[X^-; B].$$

由定义可见  $\nu^+, \nu^- \ll \mathbb{P}|_{\mathcal{G}}$ . 因此由 Radon-Nikodym 定理存在非负  $\mathcal{G}$ -可测函数  $Y^+, Y^-$ , 使得对于任意  $B \in \mathcal{G}$  都有

$$\nu^\pm(B) = \int_B Y^\pm d\mathbb{P}.$$

又因为  $\mathbb{E}[Y^\pm] = \nu^\pm(\Omega) = \mathbb{E}[X^\pm] < \infty$ , 所以  $Y = Y^+ - Y^-$  属于  $L^1$ . 对任意  $B \in \mathcal{G}$ ,

$$\int_B Y d\mathbb{P} = \nu^+(B) - \nu^-(B) = \mathbb{E}[X; B],$$

也就是  $\mathbb{E}[Y; B] = \mathbb{E}[X; B]$ .  $\square$

于是我们可以正式给这个几乎必然唯一的对象一个名字.

**定义 3.45.**

令  $X \in L^1(\Omega, \mathbb{P})$ ,  $\mathcal{G} \subseteq \mathcal{F}$  为子  $\sigma$ -代数. 称随机变量  $Y \in L^1(\Omega, \mathbb{P})$  为  $X$  关于  $\mathcal{G}$  的条件期望, 是指其满足:

1.  $Y$  是  $\mathcal{G}$ -可测的;
2. 对于任意  $B \in \mathcal{G}$ , 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

这样的  $Y$  存在且在 a.s. 意义下唯一, 记作

$$Y = \mathbb{E}[X | \mathcal{G}].$$

所以  $\mathbb{E}[X | \mathcal{G}]$  并不是一个数, 而仍然是一个随机变量.  $\mathcal{G}$  可以理解成我们目前能够观察到的信息, 而条件期望则是把  $X$  压缩到这些信息上以后, 仍然保留所有  $\mathcal{G}$ -可见平均值的随机变量.

如果  $B$  是满足  $\mathbb{P}(B) > 0$  的事件, 我们也记

$$\mathbb{E}[X | B] := \frac{\mathbb{E}[X \mathbf{1}_B]}{\mathbb{P}(B)}.$$

条件期望的这个定义在  $\mathcal{G}$  由一个分割生成时尤其直观. 假设非空集合  $B_1, \dots, B_n$  两两不交并且并为  $\Omega$ , 并令  $\mathcal{G} = \sigma(B_1, \dots, B_n)$ . 此时每个  $B_i$  都是  $\mathcal{G}$  的一个原子:  $\mathcal{G}$  中的任意集合都只能由若干个  $B_i$  拼出来, 因而  $\mathcal{G}$  根本无法继续区分同一个  $B_i$  中的样本点.

所以任何  $\mathcal{G}$ -可测实值随机变量都必须在每个  $B_i$  上取常值. 如果  $\mathbb{P}(B_i) > 0$ , 那么条件期望在这个原子上的值只能是

$$\mathbb{E}[X | \mathcal{G}](\omega) = \mathbb{E}[X | B_i], \quad \omega \in B_i,$$

也就是说

$$\mathbb{E}[X | \mathcal{G}] = \sum_{i=1}^n \mathbb{E}[X | B_i] \mathbf{1}_{B_i} \quad \text{a.s.}$$

如果某个  $B_i$  的概率为 0, 那么条件期望在这个原子上取什么值都不会产生影响, 这也正是条件期望只能在 a.s. 意义下唯一的一个最简单例子.

在有限分割下, 条件期望就是把  $X$  在每一个当前能够辨认的原子里面取一次平均. 这和前面的 Bull, Base, Bear, Tail 情景分析也很接近: 如果  $\mathcal{G}$  只能告诉我们当前落在哪一个情景中, 那么条件期望就在每个情景内部取对应的平均值.

两个极端情况也立即可以看出来. 如果  $\mathcal{G} = \{\emptyset, \Omega\}$ , 那么整个  $\Omega$  就只有一个原子, 所以  $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X]$  a.s.; 如果  $\mathcal{G} = \mathcal{F}$ , 或者更一般地  $X$  本身已经是  $\mathcal{G}$ -可测的, 那么  $\mathbb{E}[X | \mathcal{G}] = X$  a.s.

### 基本性质与均方投影

条件期望具有下面这些基本性质.

#### 命题 3.46 (条件期望的基本性质).

令  $X, Y \in L^1(\Omega, \mathbb{P})$ ,  $\mathcal{G} \subseteq \mathcal{F}$  为子  $\sigma$ -代数. 在相应表达式有意义时, 有:

- 线性性:  $\mathbb{E}[aX + bY | \mathcal{G}] = a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]$ .
- 单调性: 如果  $X \leq Y$  a.s., 那么  $\mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[Y | \mathcal{G}]$  a.s.
- 保留期望:  $\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]$ .
- 已知量可以提出: 如果  $Z$  是有界的  $\mathcal{G}$ -可测随机变量, 那么  $\mathbb{E}[XZ | \mathcal{G}] = Z\mathbb{E}[X | \mathcal{G}]$ .
- 塔性质: 如果  $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$ , 那么

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}].$$

- 独立性: 如果  $X$  与  $\mathcal{G}$  独立, 那么  $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X]$  a.s.

塔性质可以理解为: 先利用较丰富的信息  $\mathcal{G}$  对  $X$  进行一次压缩, 再继续忘掉信息直到只剩  $\mathcal{H}$ , 和一开始直接只保留  $\mathcal{H}$  的结果一样.

普通 Jensen 不等式也有完全对应的条件版本.

#### 定理 3.47 (条件 Jensen 不等式).

令  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  为凸函数, 并假设  $X \in L^1$  且  $\varphi(X) \in L^1$ . 则

$$\varphi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\varphi(X) | \mathcal{G}] \quad \text{a.s.}$$

比如当  $X \in L^p$  且  $p \geq 1$  时, 取  $\varphi(x) = |x|^p$ , 就有  $|\mathbb{E}[X | \mathcal{G}]|^p \leq \mathbb{E}[|X|^p | \mathcal{G}]$ . 再取一次普通期望便得到  $\|\mathbb{E}[X | \mathcal{G}]\|_p \leq \|X\|_p$ . 所以条件期望在  $L^p$  中实际上也是一种不会把随机变量放大的压缩.

条件概率本身也可以重新包含进条件期望. 对于事件  $A \in \mathcal{F}$ , 定义

$$\mathbb{P}(A | \mathcal{G}) := \mathbb{E}[\mathbf{1}_A | \mathcal{G}].$$

于是  $\mathbb{P}(A) = \mathbb{E}[\mathbf{1}_A]$  和  $\mathbb{P}(A | \mathcal{G}) = \mathbb{E}[\mathbf{1}_A | \mathcal{G}]$  正好完全平行. 类似地, 对于随机变量  $Y$ , 我们通常把  $\mathbb{E}[X | \sigma(Y)]$  简写成  $\mathbb{E}[X | Y]$ ; 所以所谓“给定  $Y$ ”, 真正给定的其实是  $Y$  所生成的信息  $\sigma(Y)$ .

所以独立性, 条件概率和条件期望实际上可以放进同一个信息视角里面:

- 独立表示获得这部分信息以后无需更新;
- 条件概率描述获得信息以后如何更新事件发生的概率;
- 条件期望则描述获得信息以后如何更新对于随机变量平均值的判断.

最后, 当  $X \in L^2(\Omega, \mathbb{P})$  时, 条件期望还有一个很漂亮的几何解释. 所有  $\mathcal{G}$ -可测的平方可积随机变量组成闭子空间  $L^2(\Omega, \mathcal{G}, \mathbb{P})$ , 而  $\mathbb{E}[X | \mathcal{G}]$  恰好就是  $X$  向这个闭子空间的正交投影. 因此在所有只能使用  $\mathcal{G}$  中信息构造出来的平方可积随机变量  $Y$  中,  $\mathbb{E}[X | \mathcal{G}]$  使  $\|X - Y\|_2$  最小.

所以到了  $L^2$  中, 我们才可以很准确地说: 条件期望是在只允许使用信息  $\mathcal{G}$  的情况下, 对于  $X$  的最佳均方预测. 普通期望  $\mathbb{E}[X]$  无非是把允许使用的信息进一步缩小到常数函数以后得到的特殊情况.

到了随机过程里面, 随着时间增加的信息会被一条滤链  $(\mathcal{F}_t)_{t \in T}$  记录下来. 因而  $\mathbb{E}[X_{t+s} | \mathcal{F}_t]$  表示的就是在已经知道截至时刻  $t$  的全部信息以后, 对未来随机变量  $X_{t+s}$  作出的条件平均预测. 后面的马尔可夫过程和鞅都会不断回到这个观点.

### 3.4.3 正则条件分布

条件期望只告诉我们给定信息以后随机变量的条件平均值, 但很多时候我们真正想知道的是整个条件分布.

比如  $\mathbb{E}[S_{t+1} | \mathcal{F}_t]$  只告诉我们在当前信息下下一时刻股票价格的平均值; 如果还想知道上涨 10% 的概率, 跌破某个价格的概率或者整个未来价格的分布, 那么一个条件期望显然不够. 这就引出了正则条件分布.

#### 定义 3.48.

令  $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{E})$  为随机元素,  $\mathcal{G} \subseteq \mathcal{F}$  为子  $\sigma$ -代数.  $X$  关于  $\mathcal{G}$  的正则条件分布是指一个从  $(\Omega, \mathcal{G})$  到  $(E, \mathcal{E})$  的 Markov 核

$$K: \Omega \times \mathcal{E} \rightarrow [0, 1],$$

使得对于任意  $A \in \mathcal{E}$ ,  $K(\cdot, A)$  是  $\mathbb{P}(X \in A | \mathcal{G})$  的一个版本.

所谓 Markov 核就是一种积分核:

- 固定  $\omega$  时,  $A \mapsto K(\omega, A)$  是  $(E, \mathcal{E})$  上的概率测度;
- 固定  $A$  时,  $\omega \mapsto K(\omega, A)$  则是  $\mathcal{G}$ -可测函数.

因此我们可以把  $K(\omega, dx)$  理解成在当前信息状态  $\omega$  下对于  $X$  得到的一整个概率分布.

条件期望可以重新从这个分布中积分出来. 对于合适的可测函数  $f$ ,

$$\mathbb{E}[f(X) | \mathcal{G}](\omega) = \int_E f(x) K(\omega, dx) \quad \text{a.s.}$$

所以条件期望只是条件分布的一个积分结果, 而正则条件分布保存的是给定  $\mathcal{G}$  以后关于  $X$  的整个概率规律.

特别地, 如果  $Y: \Omega \rightarrow (S, \mathcal{S})$ , 那么所谓“给定  $Y$ ”实际上就是给定  $\sigma(Y)$ . 在合适的条件下, 可以找到 Markov 核  $K: S \times \mathcal{E} \rightarrow [0, 1]$ , 使得  $\mathbb{P}(X \in A | Y) = K(Y, A)$  a.s. 于是通常会简写成

$$K(y, A) = \mathbb{P}(X \in A | Y = y).$$

这也是为什么即使对于连续随机变量有  $\mathbb{P}(Y = y) = 0$ , 我们仍然能够讨论“给定  $Y = y$  时  $X$  的分布”. 不过这里需要稍微小心: 正则条件分布通常只在  $\mu_Y$ -几乎处处 (almost everywhere, a.e.) 的  $y$  上唯一, 所以对于满足  $\mu_Y(\{y\}) = 0$  的某个具体  $y$ , 如果没有额外的连续性或者其他结构,  $K(y, \cdot)$  并不一定有唯一的标准取法.

如果  $X, Y$  取值于标准 Borel 空间, 比如  $\mathbb{R}^m, \mathbb{R}^n$ , 那么我们通常都能够得到这样的正则条件分布. 如果  $(X, Y)$  进一步具有联合密度, 那么熟悉的条件密度就是它的特殊情形:

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad f_Y(y) > 0.$$

所以初等概率论中的“条件密度”并不是另外一个独立概念, 而是正则条件分布在具有密度时的一种表示.

正则条件分布到了随机过程里面尤其自然. 对于  $s < t$ , 我们真正关心的往往不是  $\mathbb{E}[X_t | \mathcal{F}_s]$  这一个平均数, 而是未来状态在当前全部信息下的整个条件分布  $\mathbb{P}(X_t \in A | \mathcal{F}_s)$ .

而马尔可夫过程的特殊之处就在于: 这个依赖于全部过去信息的条件分布, 只需要当前状态  $X_s$  就能够确定. 也就是说存在转移核  $P_{s,t}$ , 使得

$$\mathbb{P}(X_t \in A | \mathcal{F}_s) = P_{s,t}(X_s, A) \quad \text{a.s.}$$

所以“未来只依赖现在”这句常见的口号, 更准确地说是在讲: 给定全部过去得到的未来正则条件分布, 只依赖于当前状态.

## 3.5 随机变量的收敛与极限定理

### 3.5.1 收敛概念

#### 从前推测度到随机变量的收敛

前面已经把随机变量的分布定义为它诱导的前推概率测度, 并记作  $\mathcal{L}(X) = X_*\mathbb{P}$ . 因此当我们有一列随机变量  $X_1, X_2, \dots$ , 并希望讨论收敛过程 ( $X_n \rightarrow X$ ) 时, 一个很自然的想法就是研究这些随机变量所诱导的前推测度怎样变化.

这里先约定一个小记号: 当我们把“收敛”本身当作一个过程或者命题来讨论时, 会把箭头连同两端对象一起放在括号中, 例如  $(X_n \rightarrow X)$ . 括号不表示额外结构, 只是强调我们现在讨论的是整个收敛过程.

本节大致会先回答“随机变量究竟以什么意义收敛”, 再讨论这些收敛经过连续函数和常见代数运算以后怎样变化, 最后用大数定律和中心极限定理说明样本平均会收敛到哪里, 以及它在什么尺度上继续保留随机波动.

#### 概率测度的弱收敛

我们先暂时忘掉随机变量, 直接考虑一列  $\mathbb{R}$  上的概率测度  $\mu_n$  和另一个概率测度  $\mu$ .

“弱收敛”这个名字并不是概率论凭空发明的. 在拓扑空间中, 连续函数可以看成探测空间结构的自然观测; 在泛函分析中, Banach 空间里的弱收敛也是类似的思想: 不直接要求范数意义下的强收敛, 而是要求所有连续线性泛函作用以后得到的数值都收敛.

概率测度的情形与此类似. 每个概率测度  $\mu$  都给出一个作用在有界连续函数上的线性泛函

$$f \mapsto \int_{\mathbb{R}} f d\mu.$$

于是比较概率测度时, 可以不直接比较所有集合上的取值, 而是比较这些测度对于连续观测  $f$  给出的积分. 这就是概率测度弱收敛的基本想法.

一个直接但过强的要求是  $\mu_n(A) \rightarrow \mu(A)$  对所有 Borel 集  $A$  都成立. 一个非常小的位置移动, 就可能使某些集合上的概率突然发生变化. 因此概率论中通常改用连续函数来观察这些测度.

#### 定义 3.49.

设  $\mu_n, \mu$  为  $\mathbb{R}$  上的概率测度. 如果对于任意有界连续函数  $f: \mathbb{R} \rightarrow \mathbb{R}$  都有

$$\int_{\mathbb{R}} f d\mu_n \rightarrow \int_{\mathbb{R}} f d\mu,$$

则称  $\mu_n$  弱收敛到  $\mu$ , 记作  $(\mu_n \Rightarrow \mu)$ .

这个定义可以理解成: 如果所有有界连续观测的期望都渐近地无法区分  $\mu_n$  和  $\mu$ , 那么在当前拓扑允许的连续观测下, 这两个概率测度已经越来越接近. 需要注意的是, 这里的“弱”与  $L^p$  空间中随机变量等价类的弱收敛精神相近, 但对象不同: 本节讨论的是概率测度在连续测试函数下的收敛.

弱收敛虽然不保证所有 Borel 集上的概率都收敛, 但只要集合的边界不承载极限测度的质量, 就仍然可以得到集合概率的收敛.



**定理 3.50 (Portmanteau 定理的一些形式).**

对  $\mathbb{R}$  上的概率测度  $\mu_n, \mu$ , 以下条件等价:

1.  $(\mu_n \Rightarrow \mu)$ ;
2. 对任意开集  $G$ , 有  $\liminf_n \mu_n(G) \geq \mu(G)$ ;
3. 对任意闭集  $F$ , 有  $\limsup_n \mu_n(F) \leq \mu(F)$ ;
4. 对任意满足  $\mu(\partial A) = 0$  的 Borel 集  $A$ , 有  $\mu_n(A) \rightarrow \mu(A)$ .

满足  $\mu(\partial A) = 0$  的集合称为  $\mu$  的连续集 (continuity set).

**例 3.51.**

令  $\mu_n = \delta_{1/n}$ ,  $\mu = \delta_0$ . 显然有  $(\mu_n \Rightarrow \mu)$ , 但是对于  $A = \{0\}$ , 始终有  $\mu_n(A) = 0$ , 而  $\mu(A) = 1$ .

这里没有任何矛盾, 因为  $\partial A = \{0\}$ , 从而  $\mu(\partial A) = 1$ . 所以  $\{0\}$  并不是  $\mu$  的连续集.

这也解释了为什么在实数上利用分布函数描述弱收敛时, 只要求在极限分布函数的连续点上收敛. 如果  $F_n(x) = \mu_n((-\infty, x])$ ,  $F(x) = \mu((-\infty, x])$ , 那么  $(\mu_n \Rightarrow \mu)$  当且仅当对于  $F$  的每一个连续点  $x$ , 都有  $F_n(x) \rightarrow F(x)$ .

**依分布收敛**

现在重新回到随机变量. 因为依分布收敛只比较随机变量各自的分布, 所以这些随机变量甚至不需要定义在同一个概率空间上.

**定义 3.52.**

设

$$X_n: (\Omega_n, \mathcal{F}_n) \rightarrow \mathbb{R}, \quad X: (\Omega, \mathcal{F}) \rightarrow \mathbb{R},$$

并分别在空间上给定概率测度  $\mathbb{P}_n$  和  $\mathbb{P}$ . 如果  $(\mathcal{L}(X_n) \Rightarrow \mathcal{L}(X))$ , 则称  $X_n$  依分布收敛到  $X$ , 记作  $(X_n \xrightarrow{d} X)$ .

所以依分布收敛本质上就是随机变量所诱导的前推概率测度的弱收敛. 它只看到分布, 完全看不到随机变量在某个共同概率空间中是怎样对应的.

**例 3.53.**

设  $X \sim \mathcal{N}(0, 1)$ . 如果直接令  $X_n = X$ , 那么每一个样本上  $X_n$  都和  $X$  完全相同.

但我们也可以令  $X, X_1, X_2, \dots$  相互独立, 并且全部服从  $\mathcal{N}(0, 1)$ . 此时对于所有  $n$  仍然有  $\mathcal{L}(X_n) = \mathcal{L}(X)$ , 所以  $(X_n \xrightarrow{d} X)$ .

然而这时  $X_n - X \sim \mathcal{N}(0, 2)$ , 因此对于任意固定的  $\varepsilon > 0$ ,  $\mathbb{P}(|X_n - X| > \varepsilon)$  始终是同一个严格正的常数, 并不会趋于 0. 所以这一实现中  $X_n$  甚至不依概率收敛到  $X$ .

这件事非常重要: 各自的分布并不能决定给定联合实现下两个随机变量之间的误差.

**依概率收敛**

从这里开始, 除非另有说明, 我们都假设  $X_n$  和  $X$  定义在同一个概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$  上.

**定义 3.54.**

如果对于任意  $\varepsilon > 0$  都有

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0,$$

则称  $X_n$  依概率收敛到  $X$ , 记作  $(X_n \xrightarrow{\mathbb{P}} X)$ .

依概率收敛的意思就是: 当  $n$  越来越大时,  $X_n$  与  $X$  出现明显误差的概率越来越小. 这里还会用到一个非常常见的特殊情况.

**命题 3.55.**

对任意常数  $c$ , 有

$$(X_n \xrightarrow{d} c) \iff (X_n \xrightarrow{\mathbb{P}} c).$$

所以虽然一般来说依分布收敛比依概率收敛弱, 但当极限退化成一个确定常数时, 两者恰好重合.

这里已经不能只看  $\mathcal{L}(X_n)$  和  $\mathcal{L}(X)$ , 因为  $X_n - X$  依赖于两个随机变量之间的联合关系. 当前概率空间给出了联合分布  $\mathcal{L}(X_n, X) = (X_n, X)_* \mathbb{P}$ ; 再通过映射  $(x, y) \mapsto |x - y|$  前推, 就得到误差  $|X_n - X|$  的分布.

把上面的命题用于误差变量  $|X_n - X|$ , 就得到

$$(X_n \xrightarrow{\mathbb{P}} X) \iff (\mathcal{L}(|X_n - X|) \Rightarrow \delta_0).$$

换句话说, 依概率收敛就是误差的概率质量越来越集中到 0.

 **$L^p$  收敛**

依概率收敛只要求大误差发生的概率越来越小, 却不太在意那些极少发生的误差究竟有多大. 如果我们还想控制误差本身的大小, 就会自然回到前面已经学习过的  $L^p$  空间. 对于  $1 \leq p < \infty$ , 若  $X_n, X \in L^p(\Omega, \mathcal{F}, \mathbb{P})$  且

$$\mathbb{E}|X_n - X|^p \rightarrow 0,$$

则称  $X_n$  在  $L^p$  中收敛到  $X$ , 记作  $(X_n \xrightarrow{L^p} X)$ .

因为  $\|X_n - X\|_{L^p} = (\mathbb{E}|X_n - X|^p)^{1/p}$ , 所以这就是  $L^p$  空间本身的范数收敛. 特别地,  $p = 2$  时称为均方收敛. 这种收敛在随机过程中尤其常见, 因为  $L^2$  是 Hilbert 空间.

$p = \infty$  时也可以讨论  $L^\infty$  范数收敛, 它对应本质上一致意义下的误差趋于 0. 不过为了和“有限  $p$  阶矩”的语言保持一致, 下面主要讨论  $1 \leq p < \infty$  的情形.

借助前推测度下的积分公式, 也可以把  $L^p$  收敛理解为: 误差分布不仅要向 0 集中, 其  $p$  阶尾部也要同时受到控制.

**命题 3.56.**

如果  $(X_n \xrightarrow{L^p} X)$ , 那么  $(X_n \xrightarrow{\mathbb{P}} X)$ .

证明. 对任意  $\varepsilon > 0$ , 根据 Markov 不等式,

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}|X_n - X|^p}{\varepsilon^p} \rightarrow 0.$$

□

**几乎必然收敛**

依概率收敛每次固定一个  $n$ , 看第  $n$  个误差事件有多大. 但我们还可以固定一个样本  $\omega$ , 然后观察整条数列  $X_1(\omega), X_2(\omega), \dots$  最终是否真的收敛.

**定义 3.57.**

如果

$$\mathbb{P}(\{\omega : (X_n(\omega) \rightarrow X(\omega))\}) = 1,$$

则称  $X_n$  几乎必然收敛到  $X$ , 记作  $(X_n \xrightarrow{\text{a.s.}} X)$ .

如果还想用前推测度的语言来理解它, 那么这一次不能只保留某一个  $X_n$ , 甚至不能只保留一对  $(X_n, X)$ , 而要把整个随机序列一起保留下来.

考虑

$$\mathbf{X}(\omega) = ((X_k(\omega))_{k \geq 1}, X(\omega)) \in \mathbb{R}^{\mathbb{N}} \times \mathbb{R}.$$



在乘积  $\sigma$ -代数下这是一个可测映射. 如果记

$$C = \{((x_k)_{k \geq 1}, x) : (x_k \rightarrow x)\},$$

它可以写成

$$C = \bigcap_{m=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{k \geq N} \left\{ ((x_j)_{j \geq 1}, x) : |x_k - x| < \frac{1}{m} \right\},$$

所以  $C$  是乘积空间中的 Borel 集. 那么

$$(X_n \xrightarrow{\text{a.s.}} X) \iff \mathcal{L}(\mathbf{X})(C) = 1.$$

所以几乎必然收敛依然可以写成一个前推测度的性质, 只不过我们现在前推的是整条随机序列. 这已经非常接近后面随机过程中的路径分布了.

### 几种收敛方式之间的关系

现在可以把前面的结果放在一起. 最基本的关系是

$$(X_n \xrightarrow{\text{a.s.}} X) \implies (X_n \xrightarrow{\mathbb{P}} X) \implies (X_n \xrightarrow{d} X), \quad (X_n \xrightarrow{L^p} X) \implies (X_n \xrightarrow{\mathbb{P}} X).$$

此外, 在概率空间上如果  $p > q \geq 1$ , 那么由不同  $L^p$  空间之间的包含关系可知

$$(X_n \xrightarrow{L^p} X) \implies (X_n \xrightarrow{L^q} X).$$

这些箭头一般都不能直接反过来. 不过依概率收敛仍然能够抽出几乎必然收敛的子列. 这里自然会用到 Borel–Cantelli 引理.

#### 引理 3.58 (Borel–Cantelli).

令  $A_1, A_2, \dots$  为事件. 如果

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty,$$

那么

$$\mathbb{P}(A_n \text{ i.o.}) = 0.$$

这里 i.o. 是 infinitely often 的缩写, 表示“无穷多次发生”. 也就是说, 概率总和有限的事件几乎必然只会发生有限多次.

#### 注 3.59.

Borel–Cantelli 引理还有一个常见的反向版本: 如果  $(A_n)$  相互独立并且  $\sum_n \mathbb{P}(A_n) = \infty$ , 那么  $\mathbb{P}(A_n \text{ i.o.}) = 1$ . 这里的独立性是额外条件, 不能省略.

#### 定理 3.60.

如果  $(X_n \xrightarrow{\mathbb{P}} X)$ , 那么存在一个子列  $(X_{n_k})_{k \geq 1}$ , 使得  $(X_{n_k} \xrightarrow{\text{a.s.}} X)$ .

证明. 由  $(X_n \xrightarrow{\mathbb{P}} X)$ , 可以递归选取子列  $(X_{n_k})$ , 使得

$$\mathbb{P}(|X_{n_k} - X| > 2^{-k}) < 2^{-k}.$$

令  $A_k = \{|X_{n_k} - X| > 2^{-k}\}$ . 则  $\sum_k \mathbb{P}(A_k) < \infty$ , 因而由 Borel–Cantelli 引理可知, 几乎必然只有有限多个  $A_k$  发生. 这正说明  $(X_{n_k} \xrightarrow{\text{a.s.}} X)$ .  $\square$

事实上还可以进一步证明:  $(X_n \xrightarrow{\mathbb{P}} X)$  当且仅当每一个子列都存在进一步子列几乎必然收敛到  $X$ .

另外,  $L^p$  收敛和几乎必然收敛之间一般不存在包含关系.

**例 3.61.**

固定  $p \geq 1$ , 在  $(0, 1)$  上定义

$$X_n = n^{1/p} \mathbf{1}_{(0, 1/n)}.$$

对任意固定的  $\omega > 0$ , 当  $n$  足够大时都有  $X_n(\omega) = 0$ , 所以  $(X_n \xrightarrow{\text{a.s.}} 0)$ . 但是

$$\mathbb{E}|X_n|^p = n \cdot \frac{1}{n} = 1,$$

因而  $X_n$  并不在  $L^p$  中收敛到 0.

这就是我们在 Lebesgue 积分中已经见过的尖峰现象: 虽然每一点最终都趋于 0, 但是越来越高的尖峰同时被压缩到越来越小的区域里, 使得  $p$  阶矩并没有消失.

反方向也不成立.

**例 3.62 (打字机序列).**

在  $[0, 1)$  上取 Lebesgue 概率测度. 对于  $n = 2^m + k$ , 其中  $m \geq 0$  和  $0 \leq k < 2^m$  均为整数, 定义

$$X_n = \mathbf{1}_{[k/2^m, (k+1)/2^m)}.$$

对任意  $p \geq 1$ , 都有  $\mathbb{E}|X_n|^p = 2^{-m} \rightarrow 0$ , 所以  $(X_n \xrightarrow{L^p} 0)$ .

但是对于每一个固定的  $\omega \in [0, 1)$ , 在每一个层级  $m$  中都会恰好有一个  $X_n(\omega) = 1$ , 同时其余很多项等于 0. 所以  $X_n(\omega)$  会无穷多次取到 1 和 0, 并不收敛.

一个常用充分条件来自控制收敛定理: 如果除了  $(X_n \xrightarrow{\text{a.s.}} X)$  以外, 还存在某个  $Y \in L^1$  使得  $|X_n - X|^p \leq Y$  几乎处处成立, 那么  $\mathbb{E}|X_n - X|^p \rightarrow 0$ , 也就是  $(X_n \xrightarrow{L^p} X)$ .

更一般地, 如果  $(X_n)$  一致可积 (uniformly integrable) 且  $(X_n \xrightarrow{\mathbb{P}} X)$ , 那么 Vitali 定理给出  $\mathbb{E}|X_n - X| \rightarrow 0$ ; 对一般的  $L^p$  收敛, 可以对误差族  $\{|X_n - X|^p\}$  要求一致可积. 这一层先作为可选补充, 这里暂不展开.

可以把这几种收敛暂时整理成下面这张表:

| 收敛方式     | 是否需要共同概率空间 | 控制的对象           | 典型记号                                | 基本推出关系     |
|----------|------------|-----------------|-------------------------------------|------------|
| 依分布收敛    | 不需要        | 各自分布            | $(X_n \xrightarrow{d} X)$           | 通常推出链中位置最弱 |
| 依概率收敛    | 需要         | 给定耦合下的误差概率      | $(X_n \xrightarrow{\mathbb{P}} X)$  | 推出依分布      |
| $L^p$ 收敛 | 需要         | 给定耦合下误差的 $p$ 阶矩 | $(X_n \xrightarrow{L^p} X)$         | 推出依概率      |
| 几乎必然收敛   | 需要         | 几乎每条样本路径的尾部行为   | $(X_n \xrightarrow{\text{a.s.}} X)$ | 推出依概率      |

这里的“最弱”只是在通常推出关系中的位置. 依分布收敛仍然可以在某些问题里保留最关键的信息, 比如中心极限定理描述的首先就是分布极限.

## 3.5.2 极限定理

### 连续映射定理与 Slutsky 定理

定义各种收敛以后, 还需要知道这些极限经过常见运算以后会发生什么.

**定理 3.63 (连续映射定理).**

如果  $(X_n \xrightarrow{d} X)$ , 并且  $g: \mathbb{R} \rightarrow \mathbb{R}$  连续, 那么

$$(g(X_n) \xrightarrow{d} g(X)).$$

类似地, 如果  $(X_n \xrightarrow{\mathbb{P}} X)$ , 那么也有  $(g(X_n) \xrightarrow{\mathbb{P}} g(X))$ . 更一般地, 依分布收敛时并不真的要求  $g$  处处连续; 只要  $g$  是 Borel 可测映射, 且其不连续点集合  $D_g$  满足  $\mathbb{P}(X \in D_g) = 0$ , 仍然有  $(g(X_n) \xrightarrow{d} g(X))$ .

**定理 3.64 (Slutsky 定理).**

如果  $(X_n \xrightarrow{d} X)$ ,  $(Y_n \xrightarrow{\mathbb{P}} c)$ , 其中  $c$  为常数, 那么

$$(X_n + Y_n \xrightarrow{d} X + c), \quad (X_n Y_n \xrightarrow{d} cX).$$

如果  $c \neq 0$ , 并且商  $X_n/Y_n$  已经定义好 (例如  $\mathbb{P}(Y_n = 0) = 0$ , 或者在  $\{Y_n = 0\}$  上任意定义), 还有  $(X_n/Y_n \xrightarrow{d} X/c)$ .

这里并不要求  $X_n$  和  $Y_n$  独立.

这些结果以后在统计估计中会反复出现. 例如一个极限定理中如果含有未知参数  $\sigma$ , 而我们能够构造相合估计量  $(\hat{\sigma}_n \xrightarrow{\mathbb{P}} \sigma)$ , 那么 Slutsky 定理通常允许我们在标准化分母中把  $\sigma$  换成  $\hat{\sigma}_n$ , 而不会改变最终的极限分布.

**大数定律**

前面的内容解决了“随机变量到底以什么意义收敛”. 接下来就可以研究概率论中最经典的问题之一: 如果不断重复同一种随机实验, 样本平均最后会发生什么?

设  $X_1, X_2, \dots$  独立同分布, 并定义

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

如果  $\mathbb{E}[X_1] = \mu$ , 那么直觉上大量随机波动相互平均以后,  $\bar{X}_n$  应该越来越靠近  $\mu$ . 这就是大数定律.

**定理 3.65 (弱大数定律, 有限方差版本).**

设  $X_1, X_2, \dots$  独立同分布, 并满足  $\mathbb{E}[X_1] = \mu$ ,  $\text{Var}(X_1) = \sigma^2 < \infty$ . 那么

$$(\bar{X}_n \xrightarrow{\mathbb{P}} \mu).$$

事实上, 在当前假设下可以直接得到更强的  $L^2$  收敛. 因为独立性给出  $\text{Var}(\bar{X}_n) = \sigma^2/n$ , 而  $\mathbb{E}[\bar{X}_n] = \mu$ , 所以

$$\|\bar{X}_n - \mu\|_{L^2}^2 = \mathbb{E}|\bar{X}_n - \mu|^2 = \frac{\sigma^2}{n} \rightarrow 0.$$

因此  $(\bar{X}_n \xrightarrow{L^2} \mu)$ , 再利用  $L^2$  收敛推出依概率收敛, 就得到上面的弱大数定律.

**注 3.66.**

这里给出的是最容易利用方差计算证明的版本, 并不是弱大数定律最一般的形式. 对独立同分布随机变量而言, 只要  $\mathbb{E}|X_1| < \infty$ , 弱大数定律同样成立.

下面的强大数定律虽然结论更强, 看起来假设却反而更弱, 并不是出现了什么反常现象; 这里只是为了得到一个最直接的证明, 先陈述了一个假设更强的弱大数定律版本.

**定理 3.67 (强大数定律).**

设  $X_1, X_2, \dots$  独立同分布, 并且  $\mathbb{E}|X_1| < \infty$ . 那么

$$(\bar{X}_n \xrightarrow{\text{a.s.}} \mathbb{E}[X_1]).$$

也就是说, 对于几乎每一条无限长的样本序列, 它的经验平均最终都会趋向理论期望.

**例 3.68.**

假设不断独立重复同一种实验. 令  $A_k$  表示第  $k$  次实验中某个事件发生, 并假设  $\mathbb{P}(A_k) = p$ . 定义  $X_k = \mathbf{1}_{A_k}$ , 那么  $X_k$  独立同分布, 且  $\mathbb{E}[X_k] = p$ .

此时

$$\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k}$$

正是这个事件在前  $n$  次实验中出现的经验频率. 强大数定律给出

$$\left( \frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k} \xrightarrow{\text{a.s.}} p \right).$$

所以在独立同分布重复实验的框架下, 大数定律建立了经验频率和理论概率之间的数学联系. 这并不是说概率必须被定义成长期频率, 而只是说这种模型中的长期经验频率会几乎必然地趋向概率.

**中心极限定理**

大数定律告诉我们  $(\bar{X}_n \xrightarrow{\mathbb{P}} \mu)$ , 在强大数定律的条件下甚至有  $(\bar{X}_n \xrightarrow{\text{a.s.}} \mu)$ , 但还没有告诉我们样本平均究竟以怎样的尺度围绕  $\mu$  波动.

如果  $\text{Var}(X_1) = \sigma^2 < \infty$ , 那么  $\text{Var}(\bar{X}_n) = \sigma^2/n$ , 所以  $\text{Std}(\bar{X}_n) = \sigma/\sqrt{n}$ . 这说明样本平均的典型误差尺度不是  $1/n$ , 而是  $1/\sqrt{n}$ .

因此如果直接看  $\bar{X}_n - \mu$ , 它会逐渐缩到 0; 但如果同时把它放大  $\sqrt{n}$  倍, 就有可能留下一个不会退化成常数的极限分布.

**定理 3.69 (Lindeberg-Lévy 中心极限定理).**

设  $X_1, X_2, \dots$  独立同分布, 并满足  $\mathbb{E}[X_1] = \mu$ ,  $0 < \text{Var}(X_1) = \sigma^2 < \infty$ . 令  $Z \sim \mathcal{N}(0, 1)$ , 那么

$$\left( \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} Z \right).$$

所以大数定律和中心极限定理回答的是两个不同的问题. 大数定律告诉我们样本平均最终会走向哪里, 答案是  $\mu$ ; 中心极限定理则进一步描述在  $1/\sqrt{n}$  的尺度上, 样本平均围绕  $\mu$  还剩下怎样的随机波动, 答案是正态极限.

更具体地说, 如果记  $\Phi$  为标准正态分布函数, 那么中心极限定理说的是

$$\mathbb{P}\left(\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \leq x\right) \rightarrow \Phi(x)$$

在每一个  $x \in \mathbb{R}$  上成立.

因此当  $n$  很大时, 在分布近似的意义下可以写成

$$\mathcal{L}(\bar{X}_n) \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

这里需要停一下, 避免把渐近分布误读成逐样本近似. 中心极限定理首先告诉我们的只是对前推测度的弱极限. 它并没有自动在原概率空间上构造出某个  $Z \sim \mathcal{N}(0, 1)$ , 使得  $\bar{X}_n - \mu$  在逐样本或者  $L^p$  意义下接近  $\sigma Z/\sqrt{n}$ . 而且有限方差版本的中心极限定理本身并不给出有限样本误差率; 如果需要 Berry-Esseen 型的  $n^{-1/2}$  误差界, 还要额外加入有限三阶绝对矩等条件.

**例 3.70.**

设  $0 < p < 1$ ,  $X_k \sim \text{Bernoulli}(p)$  独立同分布, 并令  $S_n = X_1 + \cdots + X_n$ . 那么  $S_n \sim \text{Bin}(n, p)$ , 且  $\mathbb{E}[X_k] = p$ ,  $\text{Var}(X_k) = p(1-p)$ .

强大数定律告诉我们  $(S_n/n \xrightarrow{\text{a.s.}} p)$ . 若  $Z \sim \mathcal{N}(0, 1)$ , 中心极限定理进一步给出

$$\left( \frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} Z \right).$$

因此当  $n$  足够大时, 二项分布可以在适当区域内利用正态分布近似.

**例 3.71 (Monte Carlo 定价).**

在选定风险中性定价测度  $\mathbb{Q}$  的模型中, 假设某个衍生品的贴现到期支付可以写成  $\mathbb{Q}$ -可积随机变量  $H$ . 这个模型及所选定定价测度下的价格为

$$V = \mathbb{E}_{\mathbb{Q}}[H].$$

如果我们在  $\mathbb{Q}$  下模拟  $H$  的独立同分布副本  $H^{(1)}, \dots, H^{(n)}$ , 并用

$$\hat{V}_n = \frac{1}{n} \sum_{i=1}^n H^{(i)}$$

估计  $V$ , 那么大数定律给出  $(\hat{V}_n \xrightarrow{\text{a.s.}} V)$ .

如果进一步有  $0 < \text{Var}_{\mathbb{Q}}(H) = \sigma^2 < \infty$ , 若  $Z \sim \mathcal{N}(0, 1)$ , 中心极限定理给出

$$\left( \frac{\sqrt{n}(\hat{V}_n - V)}{\sigma} \xrightarrow{d} Z \right).$$

实际计算中  $\sigma$  通常未知, 于是会使用样本标准差  $\hat{\sigma}_n$ . 只要  $(\hat{\sigma}_n \xrightarrow{\mathbb{P}} \sigma)$ , Slutsky 定理就允许我们写成

$$\left( \frac{\sqrt{n}(\hat{V}_n - V)}{\hat{\sigma}_n} \xrightarrow{d} Z \right).$$

所以 Monte Carlo 定价里常说的标准误差具有  $1/\sqrt{n}$  尺度, 本质上正是大数定律, 中心极限定理和 Slutsky 定理合在一起的结果.

**注 3.72.**

中心极限定理并不是在说现实中的随机变量天然服从正态分布. 这里陈述的 Lindeberg-Lévy 版本依赖独立性、同分布和有限方差等条件, 而真实金融市场中的收益率往往具有时间依赖、波动率聚集、厚尾、跳跃和状态切换等结构.

即使某一种中心极限定理能够用于聚合收益率, 它首先描述的也是适当尺度下的典型渐近波动, 并不会自动保证极端尾部也能被正态分布准确描述. 极端风险通常还需要另外研究厚尾、大偏差或者极值行为.

**3.5.3 通向随机过程的补充****进阶补充: 耦合与 Wasserstein 距离**

前面已经反复遇到同一个问题: 两个随机变量各自的分布并不能决定它们之间的误差, 因为还必须知道它们怎样被联合实现. 这一节可以先看作一个可选进阶, 目的只是统一“分布接近”和“给定耦合下误差接近”这两种视角; 最优传输和 Wasserstein 距离的系统背景可参考 [Vil09].

**定义 3.73.**

设  $\mu, \nu$  为  $\mathbb{R}$  上的概率测度. 如果  $\pi$  是  $\mathbb{R}^2$  上的概率测度, 并且它的两个边缘分布分别为  $\mu$  和  $\nu$ , 则称  $\pi$  为  $\mu$  和  $\nu$  的一个**耦合**. 所有这样的耦合构成的集合记作  $\Pi(\mu, \nu)$ .

如果  $X$  和  $Y$  已经定义在同一个概率空间上, 那么它们的联合分布  $\mathcal{L}(X, Y)$  自然就是  $\mathcal{L}(X)$  和  $\mathcal{L}(Y)$  的一个耦合, 但它通常并不是唯一的.

Wasserstein 距离做的事情就是允许我们在所有耦合中寻找运输成本最小的一个.

**定义 3.74.**

设  $p \geq 1$ , 并记

$$\mathcal{P}_p(\mathbb{R}) = \left\{ \mu \in \mathcal{P}(\mathbb{R}) : \int_{\mathbb{R}} |x|^p d\mu(x) < \infty \right\}.$$

对于  $\mu, \nu \in \mathcal{P}_p(\mathbb{R})$ , 定义

$$W_p(\mu, \nu) = \left( \inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathbb{R}^2} |x - y|^p d\pi(x, y) \right)^{1/p}.$$

可以把  $\mu$  想成原来的质量分布,  $\nu$  想成目标质量分布, 而  $\pi$  描述质量从哪里搬到哪里. Wasserstein 距离就是所有合法搬运方案中最小的  $p$  阶运输成本.

如果  $X, Y \in L^p$  已经定义在同一个概率空间上, 当前概率空间给出的联合分布  $\mathcal{L}(X, Y)$  只是所有可能耦合中的一个, 所以立刻得到

$$W_p(\mathcal{L}(X), \mathcal{L}(Y)) \leq \|X - Y\|_{L^p}.$$

需要特别注意的是, 这个不等式一般不能反过来理解. 即使

$$W_p(\mathcal{L}(X_n), \mathcal{L}(X)) \rightarrow 0,$$

也不一定有当前这个给定耦合下的  $\|X_n - X\|_{L^p} \rightarrow 0$ . 前面独立正态随机变量的例子就是极端情况: 边缘分布完全相同, 但给定耦合下的误差并不趋于 0.

如果当前这个耦合恰好就是最优耦合, 那么可以取得等号. 有一种情况等号一定自动成立: 其中一个分布是 Dirac 测度.

**命题 3.75.**

设  $Z \in L^p$ ,  $c \in \mathbb{R}$ . 那么

$$W_p(\mathcal{L}(Z), \delta_c) = \|Z - c\|_{L^p}.$$

这是因为  $\delta_c$  的全部质量都集中在  $c$ , 所以  $\mathcal{L}(Z)$  和  $\delta_c$  之间只有一个可能的耦合, 即  $\mathcal{L}(Z) \otimes \delta_c$ . 因而

$$W_p^p(\mathcal{L}(Z), \delta_c) = \int |x - c|^p d\mathcal{L}(Z)(x) = \mathbb{E}|Z - c|^p.$$

特别地, 取  $Z = X_n - X$  和  $c = 0$ , 就得到

$$(X_n \xrightarrow{L^p} X) \iff W_p(\mathcal{L}(X_n - X), \delta_0) \rightarrow 0.$$

不过 Wasserstein 距离真正重要的地方并不只是重新书写  $L^p$  范数, 而是它确实在  $\mathcal{P}_p(\mathbb{R})$  上定义了一个距离.

**定理 3.76.**

设  $\mu_n, \mu \in \mathcal{P}_p(\mathbb{R})$ . 那么  $W_p(\mu_n, \mu) \rightarrow 0$  当且仅当  $(\mu_n \Rightarrow \mu)$ , 并且

$$\int_{\mathbb{R}} |x|^p d\mu_n(x) \rightarrow \int_{\mathbb{R}} |x|^p d\mu(x).$$



所以可以粗略理解成

Wasserstein 收敛 = 弱收敛 +  $p$  阶绝对矩收敛.

这里的  $p$  阶绝对矩收敛可以直观理解成一种尾部控制: 概率质量不仅要在弱收敛意义下移动到正确位置, 跑到远处的少量质量也不能带来残留的  $p$  阶成本.

### 例 3.77.

在  $(0, 1)$  上定义  $X_n = n\mathbf{1}_{(0, 1/n)}$ . 那么

$$\mathcal{L}(X_n) = \left(1 - \frac{1}{n}\right) \delta_0 + \frac{1}{n} \delta_n.$$

显然  $(\mathcal{L}(X_n) \Rightarrow \delta_0)$ , 因为那一小部分远离 0 的概率质量只有  $1/n$ . 但是

$$W_1(\mathcal{L}(X_n), \delta_0) = \mathbb{E}|X_n| = 1$$

所以这里存在弱收敛, 却不存在  $W_1$  收敛. 弱收敛只看到那部分质量越来越少, 而 Wasserstein 距离还会计算它已经跑到了多远的位置.

### 从随机变量到路径空间

到这里, 我们已经从单个随机变量的分布出发, 逐渐遇到了联合分布、耦合以及整条随机序列的路径结构. 这条线会直接延伸到随机过程.

一个随机过程  $(X_t)_{t \in [0, T]}$  首先是一族随机变量. 但如果我们希望一次性研究整条样本路径, 就会考虑映射

$$\omega \mapsto (t \mapsto X_t(\omega)).$$

在选择合适的路径空间并验证相应可测性以后, 一个随机过程就可以被看成取值于函数空间的随机变量. 常见选择包括: 样本路径几乎必然连续的过程, 在选定连续版本后通常放在  $C([0, T])$  中, 并采用一致拓扑; 具有右连续左极限路径的过程通常放在  $D([0, T])$  中; 而真正讨论路径空间上的弱收敛时, 还需要同时指定拓扑. 对  $D([0, T])$  来说, 常见选择是斯科罗霍德 (Skorokhod)  $J_1$  拓扑.

这时随机过程的分布就不再只是某个固定时刻的  $\mathcal{L}(X_t)$ , 而是整个路径空间上的前推概率测度.

从前推测度的角度看, 这一节其实一直在追问同一个问题: **我们究竟把原概率空间上的哪些信息前推到了新的状态空间中?** 如果只前推单个随机变量, 得到的是它的分布; 如果保留两个随机变量的联合分布, 得到的是一个给定耦合; 如果把整个随机序列或者随机过程一起前推, 得到的就是序列空间或者路径空间上的概率测度.

后面进入随机过程以后, 这条主线还会继续发挥作用.



## 第四章 随机过程基础

本章目前为结构占位，正文将在后续逐节补充。

概率论主要研究随机变量以及随机变量列；随机过程则给随机变量加入时间或其他指标，开始同时研究有限维分布、信息随时间的增长和整条样本路径。

这一章的任务是把“许多带指标的随机变量”组织成一个动态系统，为后面的随机积分和随机微分方程准备概率结构：

随机变量族  $\rightarrow$  信息与样本路径  $\rightarrow$  Markov、Poisson、布朗运动与鞅。

这里暂时只建立对象、信息和条件结构，不定义随机积分，也不提前展开金融定价。随机积分、Itô 公式和随机微分方程统一留到下一章。

### 4.1 随机过程、分布与样本路径

本节将从指标集上的随机变量族出发，定义随机过程和样本路径，再区分有限维分布、过程在序列空间或函数空间上的分布，以及单条路径的性质。随后处理相容性、Kolmogorov 延拓思想、版本、修正、不可区分性、随机连续性和路径正则性等问题。

这一节要回答的核心问题是：只知道每一组有限时刻上的联合分布，能够在多大程度上确定整个随机过程；而当我们谈论“连续路径”时，又是在原过程、某个修正还是路径空间分布的哪个层面上说话。

### 4.2 时间与信息

本节将把时间以前能够观察到的信息组织成滤链，介绍自然滤链、通常条件、适应过程、渐进可测过程和可预测过程。停时、首次到达时刻、停止过程以及停时处的信息也放在这里统一处理。

这部分的重点不是堆叠可测性名词，而是说明每一种条件分别限制了什么：一个量是否只使用当前信息，一个交易规则能否在行动以前确定，以及一个随机时刻能否在它真正发生时被识别出来。

### 4.3 两种条件结构：Markov 性与鞅

Markov 性和鞅都在利用条件分布或条件期望压缩过去的信息，但它们保留下来的内容不同。本节将并列介绍 Markov 性、转移核、Chapman–Kolmogorov 方程、转移半群和强 Markov 性，以及鞅、下鞅、上鞅、离散时间 Doob 分解、可选抽样和鞅收敛。

这种并列安排有助于区分两个经常被混在一起的想法：“当前状态足以描述未来分布”与“当前值是未来值在现有信息下的条件期望”并不是同一件事情。

### 4.4 两类基础噪声：Poisson 过程与布朗运动

本节将用 Poisson 过程和布朗运动介绍连续时间模型中的两类基本随机扰动：离散到达与连续波动。Poisson 部分包括计数过程、等待时间、独立平稳增量、叠加、稀疏化和补偿过程；布朗运动部分包括 Gaussian 过程视角、缩放性、反射原理、路径性质、Markov 性和鞅性。

两类过程最后会放在同一张比较图中：一个通过跳跃累积事件，另一个通过连续但高度不规则的路径累积波动。二者都会自然引出补偿、二次变差和后续的随机积分。

### 4.5 从随机过程走向随机分析

本节作为下一章的接口，区分有限变差路径与无限变差路径，解释为什么布朗路径不能直接套用普通微积分或经典 Riemann–Stieltjes 积分，并第一次引入二次变差和半鞅的基本动机。

最后还会简要区分有限维分布收敛与路径空间收敛，说明为什么研究整个随机过程的极限除了逐点分布以外还需要紧性和拓扑。这些内容只建立问题，不在本章提前完成随机分析的技术构造。

## 第五章 随机分析基础

本章目前为结构占位，正文将在随机过程基础完成后继续补充。

随机过程基础告诉我们怎样描述一个动态随机系统，随机分析则进一步讨论怎样对这些过程进行积分、微分和变换。这一章将以二次变差和随机积分为起点，逐步建立连续时间随机模型所需要的计算语言。

这里建立的工具会成为随机过程进入连续时间金融模型的主要接口：

半鞅与二次变差  $\rightarrow$  随机积分与 Itô 公式  $\rightarrow$  随机微分方程与测度变换.

本章只负责数学工具本身。无套利、风险中性定价、随机波动率、利率模型和交易执行中的经济含义，仍然留到后面的金融应用部分。

### 5.1 二次变差与半鞅

本节将从总变差、二次变差和协变差开始，比较有限变差过程、连续局部鞅和布朗运动的路径结构，再引入局部鞅与半鞅。半鞅分解会作为后续随机积分的对象边界，而不是一开始就当作抽象定义硬塞进来。

这里还会说明连续部分与跳跃部分怎样共同进入二次变差，以及为什么二次变差正是普通微积分在随机路径上需要增加的新信息。

### 5.2 随机积分

本节先对简单可预测过程定义 Itô 积分，再利用 Itô 等距把积分延拓到  $L^2$  被积过程，随后进入局部鞅和半鞅积分。积分的可预测性要求、局部化方法和积分过程的鞅性质都在这里统一说明。

Poisson 随机测度和补偿随机测度作为跳跃情形的进阶补充放在本节末尾，从而使后面的随机微分方程既能覆盖连续扩散，也保留通向跳跃模型的接口。

### 5.3 Itô 公式与随机微分规则

本节将从一维 Itô 公式进入多维形式，并由此得到乘积公式、分部积分、随机指数和常用变量变换。重点是解释二阶项从哪里出现，以及随机微分记号究竟是积分等式的哪一种简写。

Tanaka 公式与局部时放在可选进阶中，用于说明非光滑函数和路径在某一点附近停留的方式怎样进入随机分析。

### 5.4 随机微分方程

本节将随机微分方程写回积分形式，区分强解、弱解、路径唯一性和分布唯一性，再介绍常见 Lipschitz 与线性增长条件下的存在唯一性结论。线性 SDE、几何布朗运动、Ornstein–Uhlenbeck 过程和 CIR 型过程将作为贯穿本节的基本例子。

跳跃扩散只作为连续理论的扩展接口出现；具体资产价格、随机波动率和利率模型留到金融应用部分再按问题展开。

### 5.5 测度变换

本节从 Radon–Nikodym 导数构成的密度过程出发，介绍指数鞅、Novikov 条件和 Girsanov 定理。需要反复强调的是，所谓“改变漂移”并不是在同一个概率规律下直接修改一条路径，而是在等价测度之间重新分配路径的概率权重。

这里建立的只是概率论和随机分析意义下的测度变换。为什么金融定价中会选择某个等价鞅测度，以及这种选择与无套利有什么关系，仍由后面的金融数学部分回答。

### 5.6 生成元、Feynman–Kac 与金融接口

本节将从 Markov 过程和 SDE 的生成元出发，连接 Kolmogorov 前向方程、后向方程与 Feynman–Kac 公式，并简要介绍鞅问题视角。这条路线把随机路径上的条件期望转换成偏微分方程，也解释了概率方法和解析方法为什么会在同一个定价问题中相遇。

## 第二部分

### 随机过程与金融市场

## 第六章 金融市场基础

在真正讨论随机过程怎样应用到金融市场以前, 我们最好先花一点时间认识金融市场本身。

毕竟后面会不断出现价格  $S_t$ , 利率  $r_t$ , 零息债券价格或由它得到的贴现因子  $P(t, T)$ , 头寸  $\theta_t$ , 以及各种期权, 债券和交易策略. 如果连这些对象在现实市场里面究竟代表什么都没有讲清楚, 直接把它们写成随机变量或者随机过程, 最后很容易变成只会操作公式, 却不知道公式到底在描述什么。

这一部分并不打算完整介绍金融学, 更不会试图把整个现代金融市场从头到尾讲一遍. 金融数学和市场工具的背景材料主要参考 [Hul22; Shr04a; Shr04b; TS11]. 我们只关心后面随机过程和金融数学会反复用到的几个基本对象: 资产怎样发行和交易, 价格和收益怎样形成, 不同时间的现金流怎样比较, 利率和债券怎样给时间以及信用风险定价, 衍生品怎样把未来状态重新做成可以交易的合约, 以及订单和流动性最终怎样参与价格形成。

这里还有一条从一开始就需要记住的原则。

### 注 6.1.

Market  $\neq$  Model of Market.

真实金融市场和我们用来描述它的数学模型并不是同一个东西。

市场本身包含企业经营, 利率, 政策, 资金需求, 仓位, 订单流, 流动性, 交易制度以及不同参与者对于未来的预期; 而一个数学模型只能根据当前想研究的问题, 从这些复杂关系里面选择一部分结构保留下来。

所以后面出现的价格过程, 利率过程, 布朗运动, 风险中性测度以及各种随机模型, 都应该被理解成对于金融市场的抽象, 而不是金融市场本身的运动定律。

我们会先从最基础的资产和股票开始. 股票本身是一部分企业权益, 但这些权益又能够被发行, 转让和交易, 于是自然产生一级市场, 二级市场, 流动性以及市场价格. 而因为股票代表的是对于企业未来剩余价值的索取权, 股票市场又天然成为一个预期市场。

从现金流权利的确定性看, 本章先从不确定性较高的剩余索取权出发, 再转向支付规则更明确的债权工具. 这是一条教学路线, 不是给所有资产做绝对风险排序; 债券仍然承担期限, 利率, 流动性和信用风险。

在直接资产之后, 我们会先看衍生品怎样把已有资产, 指数, 利率或者其他状态重新做成合约现金流. 这一章不是把衍生品当成某种低风险资产类别, 而是把它们看成重新切割, 转移和组合风险的工具。

沿着或有现金流继续往前, 预测市场会把未来事件本身做成可以交易的合约. 这一步不仅帮助我们理解事件合约和市场隐含概率, 也会为后面 Agentic R-D-G 中的 Event Graph 和 Market Graph 提供现实来源。

股指期货则会自然引出指数这个有些特殊的对象. 指数, ETF 和被动投资把许多股票放进同一个规则化的资产篮子中, 一方面降低单个企业事件对于组合的影响, 另一方面仍然保留股票作为剩余索取权的系统性风险. 这一步处在衍生品和债券之间: 指数可以成为期货和期权的结算标的, ETF 又把指数规则转化为可以在二级市场交易的基金份额。

接下来再进入债券和利率. 债券把“今天给别人一笔钱, 换取未来的一组支付”做成了可以交易的证券, 于是货币的时间价值, 贴现, 期限结构, 美债, 信用利差以及 CDS 都会自然出现. 再往后, 我们还需要理解美联储和美元资金市场怎样形成短端资金价格, 以及美债为什么同时是债券市场的基准资产和整个抵押融资体系的重要基础。

在这些资产与合约铺好以后, 贴现与无套利会把不同时间和不同状态的现金流放进统一的定价语言. 最后, 订单, 订单簿和市场微观结构会把价格形成重新拉回真实交易现场: 报价怎样进入市场, 订单怎样撮合, 流动性为什么会变化, 以及订单流怎样影响成交价格和执行成本。

这样一来, 本章就从金融权利和现金流出发, 依次经过衍生品, 预测市场, 指数与 ETF, 债券, 短端美元资金市场和无套利定价, 最后回到这些资产真正被交易时的市场机制。

因此这一部分真正想建立的并不是一张金融术语表, 而是一条从现实市场逐渐走向数学模型的路线. 这条路线同时包含一条资产与现金流主轴, 以及一条把价格、利率和事件状态重新写成合约的横向支线:




图 6.1: 金融市场基础的主轴与横向工具支线

等这些现实对象大致清楚以后，我们再回过头来看随机过程，那些原本看起来抽象的符号就会有更加明确的市场含义。

## 6.1 资产, 价格与收益

沿着上一节的路线，先从最基础的金融对象开始。

金融市场首先需要有可以被交易的东西。股票，债券，商品，货币以及各种衍生品所代表的权利当然并不相同，不过在这一章中，我们暂时把这些能够由市场参与者建立头寸的交易对象统称为资产。

### 定义 6.2.

在本文中，**资产**是指市场参与者可以对其建立头寸，并能够以某种计价单位表示其市场价值或者未来现金流的交易对象。

这里的定义只是为了方便后面的金融建模，并不是对于法律或者会计意义上“资产”的完整定义。比如一份衍生品合约对于一方可能具有正价值，对于另一方却可能具有负价值；一笔债券对于投资者是一项金融资产，对于发行人却对应一项负债。

在这些资产里面，股票和债券还属于我们之后会反复遇到的一类对象：证券。

### 定义 6.3.

在本文中，**证券** (security) 是指将某种金融权利或者未来现金流以相对标准化的形式表示出来，并能够按照相应市场制度发行，持有或者转让的一类金融资产。

股票和债券是最典型的证券。基金份额以及一部分其他金融工具在相应制度下也可以属于证券。

证券首先是一项金融权利，而不是它背后的实物本身。比如持有一家公司的股票，并不意味着投资者按照持股比例直接拥有公司的厂房或者银行账户；持有一张公司债券，也不是直接拥有公司某一项具体资产，而是持有发行人按照合同约定进行未来支付的权利。

同时，“证券”在不同国家和不同法律制度中还具有更加具体的监管定义。我们这里并不试图解决所有法律分类问题，而只是把它作为后面讨论股票，债券，基金以及证券交易市场时使用的基本金融概念。

对于后面的数学模型而言，我们首先关心的是这些对象具有怎样的价格和现金流，投资者能够怎样建立或者改变头寸，以及这些量怎样随着时间变化。

### 6.1.1 资产与交易市场

#### 股票

我们先从最熟悉的证券之一——股票一开始。

**定义 6.4.**

**股票** (stock) 是指股份公司发行并代表股东权益的一类证券。

持有一家公司的股票, 意味着持有相应的一束股东权利。这些权利通常包括对于公司未来分配和清算剩余财产的经济索取权, 按照股票类别参与投票和公司治理的权利, 以及在相应市场和法律制度下转让股份的权利。

这里需要注意, 股东持有的是股票以及股票所附带的权利, 而不是按照持股比例直接拥有公司的每一台机器, 每一项专利或者银行账户中相同比例的现金。

同时, 经济权益和公司控制权也不一定按照完全相同的比例分配。不同类别股票可以把经济权益和投票权拆开配置, 使一家公司在公开交易股份以外仍然保留不同层次的控制权安排。

所以股票实际上可以被理解成一束股东权利, 而公司又可以通过不同的股票类别, 在一定程度上重新组合经济权益和控制权。

股票有意思的地方在于, 这份对于公司的权益本身又可以继续转让。所以股票一旦被发行出去, 它就不再只是公司融资时交给投资者的一张凭证, 而同时成为了一项可以继续在其他投资者之间交易的证券。

### 一级市场与二级市场

股份以及类似股份的交易在更早以前就已经存在, 不过现代公开股票市场一个很重要的历史起点是 1602 年成立的荷兰东印度公司 (Vereenigde Oostindische Compagnie, VOC)。这里暂时只需要记住: 股份募集资本以后, 这些权利还可以继续在投资者之间转让。

这里已经可以看到现代证券市场最基本的两层结构: 投资者既可以把资本交给发行人换取新发行的证券, 也可以把自己已经取得的证券继续转让给其他投资者。

**定义 6.5.**

**一级市场** (primary market), 也称发行市场, 是指新发行的证券被出售和分配给投资者的市场; **二级市场** (secondary market) 是指已经发行的证券在不同市场参与者之间继续进行转让和交易的市场。

一级市场最核心的功能是融资。比如一家公司决定新发行一批股票, 投资者支付资金认购这些股票, 公司得到资本, 投资者则取得相应的股份。现实中可能存在投资银行和承销商等中介, 所以一级市场并不意味着投资者直接向公司柜台购买股票; 重要的是这部分证券是不是正在被发行。

一家公司第一次向公众发行股票并进入公开资本市场的过程通常称为**首次公开募股** (Initial Public Offering, IPO)。IPO 通常放在一级市场的框架下讨论, 不过一笔 IPO 既可能包含公司新发行的股份, 也可能包含原有股东出售的存量股份。前者募集的资金进入公司, 后者对应的资金则流向出售股份的原股东。

股票完成发行以后, 原来的股东又可以把股份卖给其他投资者, 这就进入了二级市场。我们平时在证券交易所买卖某家上市公司的股票, 绝大多数时候进行的都是二级市场交易: 买方支付的钱通常交给另一个愿意卖出股票的市场参与者, 而不是上市公司本身。

非常粗糙地说, 一级市场主要解决公司怎样获得资本, 二级市场主要解决投资者怎样重新转让已经取得的证券。不过二者并不是完全割裂的: 如果一项证券发行以后几乎无法再次卖出, 投资者在一级市场第一次认购的时候也会更加谨慎。一个活跃的二级市场会反过来提高证券在一级市场中的吸引力。

### 交易动机与流动性

二级市场之所以存在, 一个很简单的原因就是投资者并没有义务永久持有自己已经买下的资产。

一个人可能因为对于公司的判断发生变化而卖出股票, 也可能只是突然需要现金, 想购买另一项资产, 调整投资组合, 降低风险, 偿还债务或者满足保证金要求。做市商和衍生品交易者还可能纯粹因为对冲需要进行买卖。

所以一笔交易并不意味着买方一定“看多”, 而卖方一定“看空”。即使两个人对于一家公司的长期发展具有完全相同的判断, 也完全可能因为资金需求, 持仓结构, 风险承受能力, 投资期限以及杠杆约束不同而发生交易。

但是股票能够转让, 并不意味着我们什么时候想买或者想卖, 都一定能够按照自己满意的价格完成交易。

假设市场里面只有很少几个交易者。当我们急着卖出一只股票时, 可能恰好没有人在我们能够



接受的价格附近愿意买入。此时我们只能继续等待，或者主动降低价格寻找新的买家。反过来，如果市场中长期存在大量愿意在相近价格附近交易的参与者，通常就更加容易找到合适的交易对手。

#### 定义 6.6.

称一项资产或者一个市场具有较高的**流动性**，是指市场参与者能够在较短时间内完成足够数量的交易，而不需要作出过大的价格让步，也不会因为交易本身造成过大的价格变化。

所以从最直观的角度来看，流动性可以先理解成“在自己能够接受的价格附近找到交易对手并完成交易有多容易”。

不过参与者数量本身当然并不等于流动性。如果市场中的大量参与者突然同时希望卖出，当前价格附近却没有足够的人愿意接手，那么即使市场中有成千上万名交易者，流动性仍然可能在很短时间内迅速恶化。

这里还需要区分市场本身的流动性和投资者自己的资金流动性。比如一个投资者仍然认为 Apple (AAPL) 的长期发展很好，但突然需要大量现金偿还债务或者投入其他地方，那么他仍然可能不得不卖出股票。如果对于现金的需求足够迫切，他甚至可能接受比自己原本认为合理的价值更低的成交价格。

所以一个人愿意在什么价格买入或者卖出资产，从来都不是一个只由“这家公司究竟值多少钱”决定的问题。信息，预期，资金需求，其他投资机会，风险偏好，仓位，杠杆，投资期限以及流动性约束都会改变一个人愿意接受的交易价格。

### 报价，成交与市场价格

为了把价格是怎样形成的这件事情说得稍微准确一点，我们还需要区分报价和真正发生的成交。

在最简单的限价订单簿中，市场参与者可以声明自己愿意按照什么价格买入或者卖出一定数量的资产。令  $b_t$  表示时刻  $t$  最高的买入报价，称为**最优买价** (best bid)；令  $a_t$  表示最低的卖出报价，称为**最优卖价** (best ask)。二者之差  $a_t - b_t$  称为**买卖价差** (bid-ask spread)，而  $m_t := (a_t + b_t)/2$  称为**中间价** (mid price)。市场还会记录最近一笔实际完成交易的成交价格；一笔新的订单真正能够得到的执行价格又可能不同于以上任何一个数字。

所以现实市场中所谓的“当前价格”其实并不天然对应唯一的数字。

#### 注 6.7.

每一笔已经完成的交易都同时存在买方和卖方，而且成交数量必然相等。所以价格上涨并不是因为成交意义上的“买入的股票比卖出的股票更多”。

真正可能失衡的是主动买卖意愿，以及当前价格附近能够吸收这些订单的流动性。当大量主动买单不断消耗当前卖价附近提供的股票时，后来的买方如果仍然希望立即成交，就需要接受更高的卖价；反过来也一样。

所以一笔成交并不意味着买方和卖方对于一家公司的价值形成了完全一致的判断。卖方可能认为按照当前价格出售已经足够划算，买方却认为即使按照同一个价格买入，未来仍然具有足够的潜在收益。

这笔成交真正能够说明的只有一件事情：双方订单在当时的市场规则下形成了可执行匹配，并按照这个价格交换了股票和现金。

于是市场价格可以被理解成大量不同的信息，判断，需求和约束最终通过实际交易表现出来的结果。

## 6.1.2 价格与收益率

### 价格与市场预期

在大多数正常情况下，股票持有者并没有义务立即出售自己的股份。如果一个投资者目前并不缺少现金，也没有更加值得配置的资产，同时仍然认为所持公司的未来发展良好，那么继续持有本身就是一个完全合理的选择。

这时如果新的投资者希望从现有持有人手中取得股票，就需要给出一个足以让其中一部分人愿意放弃这部分未来权益的价格。价格越高，原本愿意继续持有的人中，通常就会有更多人认为“现在卖掉已经足够划算”。

而买方之所以愿意支付这个价格，当然也是因为他认为即使按照现在的价格买入，这家公司未来仍然值得。



于是股票价格天然开始包含市场对于未来的判断。

股票本身代表的是对于企业未来剩余价值的索取权, 所以一个投资者今天愿意为它支付多少钱, 不可能只取决于公司过去已经发生了什么. 他还必须考虑公司未来能够赚多少钱, 盈利能够持续多久, 企业还需要投入多少资本, 最终有多少价值能够归属于股东, 以及为了等待这些未来结果并承担相应风险, 自己需要获得多高的回报。

从这个意义上来说, 可以先把股票市场理解成一个**预期市场**。

这里所谓的“预期市场”并不是说市场能够准确预测未来, 更不是说当前价格一定等于某个真正的公允价值. 它只是说今天的价格已经受到市场参与者对于未来各种可能状态的判断影响。

真正推动股票价格变化的, 往往并不只是“公司变好了还是变坏了”, 而是新的信息相对于此前已经反映在价格中的预期究竟更好还是更坏. 一家公司盈利增长 20% 并不意味着股票一定上涨, 因为市场此前可能已经按照增长 30% 进行定价; 反过来, 一家仍然亏损的公司只要实际结果明显好于此前预期, 股票同样完全可能上涨。

不过价格包含预期, 并不意味着一个价格能够唯一还原出一套市场预期. 同一个价格可能来自更高的盈利预期和更高的要求回报率, 也可能来自更低的盈利预期和更低的贴现率; 流动性, 风险溢价, 仓位和资金约束同样会参与价格形成。

因此市场价格更像是大量信息, 预期以及现实约束在这一时刻通过交易压缩出来的结果, 而不是市场对于未来完整概率分布的一份直接报告。

## 价格

有了这些背景以后, 我们终于可以正式引入数学模型中的价格。

令  $S_t$  表示一单位资产在时刻  $t$  的市场价格. 比如如果一单位资产当前大约能够按照 200 单位计价货币交换, 那么可以粗略记作  $S_t = 200$ 。

这里已经进行了一次建模简化. 现实市场同时存在买价, 卖价, 中间价, 最近成交价以及真正能够得到的执行价格; 在最简单的金融模型里面, 我们暂时把这些差异压缩成一个统一的价格  $S_t$ . 后面研究市场微观结构和交易执行时, 这种简化就不再足够。

价格还永远是相对于某种计价单位而言的. 200 单位计价货币是在说“用哪种东西来度量价格”. 后面讨论贴现和无套利时, 我们还会把这种计价基准进一步抽象成计价资产 (numéraire)。

站在未来尚未发生的时刻来看,  $S_t$  是一个随机变量; 当时间不断变化以后,  $(S_t)_{t \in T}$  就形成了资产的价格随机过程. 所以后面真正需要研究的, 就是这个价格过程在我们选择的模型中具有怎样的时间和概率结构。

## 现金流, 收益与收益率

价格变化是持有资产产生收益的重要来源, 但并不是唯一来源. 股票可能支付股息, 债券可能支付票息, 其他资产也可能在持有期间产生现金流。

令  $D_t$  表示截至时刻  $t$  一单位资产累计向持有者支付的现金流, 并令  $G_t := S_t + D_t$ . 那么从时刻  $s$  到  $t$  始终持有一单位资产产生的持有期收益就是

$$G_t - G_s = S_t - S_s + D_t - D_s.$$

### 例 6.8 (除息).

假设一只股票在除息以前的价格为 \$100, 随后每股支付 \$1 股息, 并在除息以后以 \$99 交易. 如果只观察股票价格, 它似乎下跌了 1%; 但原来的股东同时取得了每股 \$1 的现金流。

在忽略税费以及其他市场变化的理想情况下, 投资者的总持有收益并没有因为除息本身发生变化。

为了比较不同价格尺度的资产, 我们通常还需要把收益除以最初投入的资金。

### 定义 6.9.

令  $S_s > 0$ . 资产从时刻  $s$  到  $t$  的**简单价格收益率**是指

$$R_{s,t}^P := \frac{S_t - S_s}{S_s}.$$

如果进一步把持有期间收到的现金流计算进去, 则相应的总收益率是指

$$R_{s,t} := \frac{S_t - S_s + D_t - D_s}{S_s}.$$

“收益”描述的是实际赚了多少钱, 而“收益率”描述的是相对于最初投入的资金赚了多少钱. 对于股票来说, 价格上涨和股息都可能构成投资者收益的一部分, 因此长期研究时还需要注意原始价格 (raw price), 复权价格 (adjusted price) 和总回报 (total return) 之间的区别.

这里定义的  $D_t$  只是把资产支付出来的现金流累计起来. 如果投资者收到股息以后立即重新投入, 那么财富又会按照新的头寸继续增长, 此时更加自然的对象是总回报财富过程 (total-return wealth process).

### 对数收益率

除了简单收益率以外, 金融市场里面还经常使用对数收益率.

#### 定义 6.10.

如果  $S_s, S_t > 0$ , 则资产从时刻  $s$  到  $t$  的对数价格收益率是指

$$r_{s,t} := \log \frac{S_t}{S_s}.$$

使用对数收益率最自然的原因, 其实是金融市场本身就是一个复利世界. 如果连续两期的简单收益率分别为  $R_1, R_2$ , 那么 \$1 最后并不是变成  $1 + R_1 + R_2$ , 而是变成  $(1 + R_1)(1 + R_2)$ . 财富增长本身具有乘法结构, 而对数恰好把这种乘法结构变成加法.

由于  $r_{s,t} = \log(1 + R_{s,t}^P)$ , 如果  $s < u < t$ , 就有

$$r_{s,t} = r_{s,u} + r_{u,t}.$$

同时  $S_t = S_s e^{r_{s,t}}$ , 所以  $r_{s,t}$  可以理解成区间  $[s, t]$  对应的累计连续复利收益. 如果要换成单位时间的连续复利收益率, 还需要进一步除以  $t - s$ .

当收益率比较小时, 由  $\log(1 + x) \approx x$ , 简单收益率和对数收益率在数值上通常很接近.

当然,  $\log(S_t/S_s)$  仍然只是价格本身的对数收益率. 如果持有期间存在股息等现金流, 真正研究投资者财富的复利增长时, 应该考虑相应的 total-return wealth process. 对数收益率同时要求价格严格为正, 所以对于可能达到零甚至取负值的金融变量, 这个定义也不再适用.

### 6.1.3 头寸, 投资组合与财富

#### 头寸与损益

知道一项资产怎样涨跌, 仍然不能告诉我们一个投资者究竟赚了多少钱, 因为最终结果还取决于他究竟持有多少资产.

#### 定义 6.11.

一项资产在时刻  $t$  的头寸是指投资者在这一时刻净持有的资产数量, 记作  $\theta_t$ .

当  $\theta_t > 0$  时称为多头头寸; 当  $\theta_t < 0$  时称为空头头寸; 当  $\theta_t = 0$  时则表示没有净头寸.

所以多头和空头首先只是头寸方向的描述. 从数学上来看, 这相当于允许资产持有量成为一个有符号的数量. 多头通常从价格上涨中获利, 空头通常从价格下降中获利, 但头寸方向并不一定代表投资者对于资产的主观看法. 做市商或者衍生品交易者完全可能只是为了对冲某种风险而建立空头头寸.

如果从  $s$  到  $t$  始终持有固定头寸  $\theta$ , 那么这一段时间产生的损益为

$$\text{P\&L}_{s,t} = \theta(S_t - S_s + D_t - D_s).$$

所以资产本身取得了多少收益, 和投资者实际赚了多少钱属于两个不同层次的问题. 前者描述资产本身怎样变化, 后者还取决于投资者究竟承担了多大的头寸.

交易本身则可以理解成对于头寸的调整. 如果头寸从  $\theta_s$  变成  $\theta_t$ , 那么净头寸变化就是  $\theta_t - \theta_s$ . 后面讨论交易执行时, 真正的问题往往不再只是“要不要买”, 而是怎样把当前头寸沿着一条合适的路径逐渐调整到目标头寸.

### 保证金与杠杆

不过现实市场中, 建立一个头寸并不一定意味着投资者必须立即拿出与头寸市场价值完全相等的自有资金. 很多交易允许投资者通过融资或者提交抵押物来建立更大的市场暴露, 这就引出了保证金.

#### 定义 6.12.

**保证金 (margin)** 是指为了建立或者维持某些交易头寸, 投资者需要向经纪商, 清算机构或者其他交易对手提交或者保留的一部分现金或合格资产.

保证金的主要作用是为潜在损失和履约风险提供缓冲. 它本身不是一项新的市场头寸, 也不一定等于这笔交易实际发生的融资金额.

例如, 假设投资者想建立价值为 \$100 的股票多头头寸, 但只投入 \$50 自有资金, 剩余 \$50 由经纪商融资. 那么投资者虽然只有 \$50 的初始净财富投入, 却承担了 \$100 股票头寸的价格变化.

如果股票上涨 10%, 头寸价值增加 \$10; 相对于最初 \$50 的自有资金而言, 投资者的收益率就是 20%. 反过来, 如果股票下跌 10%, \$10 的亏损同样相当于自有资金的 20%.

所以融资并没有改变股票本身的收益率, 而是改变了资产价格变化对于投资者财富的放大程度.

#### 定义 6.13.

**杠杆 (leverage)** 是指投资者所承担的市场风险暴露相对于自身净财富的放大程度.

在最简单的单资产情形下, 如果资产头寸的市场价值为  $|\theta_t S_t|$ , 投资者净财富为  $V_t > 0$ , 那么可以粗略地用

$$L_t = \frac{|\theta_t S_t|}{V_t}$$

描述这一头寸相对于净财富的杠杆程度.

这里的定义只是最简单的描述. 对于包含多项资产, 空头以及衍生品的组合而言, 单纯把名义头寸相加往往不能准确表示实际风险, 后面还需要结合 Delta, duration 或者其他风险暴露来理解杠杆.

保证金制度还有一个重要特点: 随着市场价格变化, 投资者自身在头寸中的净权益也会变化. 当资产价格朝不利方向移动以后, 原来的保证金可能已经不足以覆盖规定的风险缓冲.

#### 定义 6.14.

当账户中的保证金或者净权益下降到规定水平以下, 交易机构要求投资者补充资金或者抵押物, 这种要求称为**追加保证金 (margin call)**.

如果投资者没有及时满足要求, 部分头寸可能被强制平仓.

因此杠杆真正危险的地方不只是“亏损被放大”. 即使投资者认为资产长期最终会重新上涨, 他也可能因为中途价格波动导致保证金不足, 在恢复以前就被迫退出头寸.

#### 注 6.15.

不同市场中的“margin”并不完全是一回事.

股票保证金账户中, margin 往往和经纪商融资直接联系在一起. 投资者用部分自有资金建立股票头寸, 其余部分由经纪商提供贷款.

但是期货保证金通常不应该理解成“购买期货所支付的首付”. 建立期货合约时并没有按照合约名义价值借入剩余资金. Initial margin 更接近一种履约担保, 此后合约还会按照市场价格进行逐日盯市, 盈亏不断通过 variation margin 在账户之间结算.

因此

$$\text{Margin} \neq \text{Down Payment} \neq \text{Loss}.$$

保证金是一种交易制度和风险管理机制; 它怎样运作, 必须结合具体市场来看.

这也说明为什么同一个金融工具既可以用于降低风险,也可以用于放大风险. 一项期货或者期权头寸如果用来抵消原有资产风险,可以降低整个组合的净风险暴露;但如果投资者在没有相应基础头寸的情况下利用保证金建立很大的方向性头寸,同一种工具又可能产生很高的杠杆.

### 投资组合与财富

现实中的投资者通常会同时持有很多资产. 如果市场中存在  $n$  项资产,可以把投资者在时刻  $t$  的资产头寸写成

$$\theta_t = (\theta_t^1, \dots, \theta_t^n),$$

相应的价格向量记作

$$S_t = (S_t^1, \dots, S_t^n).$$

如果再令  $C_t$  表示现金头寸,那么在最简单的情况下,

$$V_t = C_t + \sum_{i=1}^n \theta_t^i S_t^i = C_t + \theta_t \cdot S_t$$

就是投资组合在时刻  $t$  的市场价值.

这里的  $C_t$  也不一定必须为正. 如果投资者通过借款为其他资产头寸融资,那么相应的现金或者融资账户可以表现为负头寸. 如果一部分现金被提交为保证金,则还需要在具体模型中区分可自由使用的现金和受到限制的抵押资产.

#### 注 6.16.

提交保证金本身通常并不意味着投资者立刻损失了同样数量的财富.

如果 \$10 现金只是从自由现金账户转入保证金账户,那么它主要发生的是资产用途上的变化: 这 \$10 暂时不能自由使用,但仍然属于投资者资产的一部分. 真正改变净财富的是随后产生的交易损益,融资成本,手续费以及违约等经济事件.

因此在研究财富过程时,最好把“资金被占用”和“财富发生损失”区分开来.

所谓对冲,从这个角度来看就是配置若干个不同方向的头寸,让某些市场变化对于整个组合造成的影响相互抵消. 如果这些头寸本身还会随着时间不断调整,那么还需要区分市场变化本身产生的投资损益和投资者从外部额外投入或者取出的资金. 后面讨论动态交易策略时,我们会用自融资条件 (self-financing condition) 来正式处理这个问题.

股票让我们看到不确定价格,现金流和财富过程. 下一节转向衍生品,看这些风险怎样被重新写成合约现金流.

## 6.2 衍生品与或有现金流

前面讨论股票,价格和头寸时,我们基本上都默认投资者是在直接买卖资产本身. 如果认为一只股票会上涨,最直接的办法是买入股票;如果已经持有股票并且担心价格下跌,最直接的办法则是卖掉一部分.

但现实市场显然不只有这一种做法.

市场参与者还可以彼此约定,在未来某个时间或者某些条件满足以后怎样进行交易,由谁向谁支付多少现金,或者由谁承担某项权利和义务. 这种约定本身也可以具有市场价值,甚至进一步成为可以转让和交易的金融对象.

在第二部分的风险主线上,衍生品需要单独说明一下: 它们不是从股票走向低风险资产时的下一档资产类别,而是一种横向工具. 同一份期货或者期权既可以放大风险,也可以转移和限制已有风险. 因此这一节重点看的是衍生品怎样把未来状态重新写成合约现金流.

衍生品和期权部分的通用背景主要参考 [Hul22; Opt; US 15].

在介绍衍生品以前,我们最好先说明这里所谓的合约究竟是什么.

#### 定义 6.17.

在本文中,金融合约 (financial contract) 是指交易双方或者多方之间,对于未来权利,义务或者现金流所作出的具有约束力的约定.

一份金融合约通常会规定在什么时间或者什么条件下,由谁向谁交付什么资产或者支付



多少现金.

这个定义只是为了后面的金融建模, 并不是对于法律意义上 contract 的完整定义. 现实中的金融合约还会受到具体司法制度, 交易所规则, 清算安排以及违约处理机制的约束. 从建模的角度来看, 我们首先关心的是: 合约建立以后, 不同未来状态会对应怎样的权利, 义务和现金流.

假设一家航空公司知道自己三个月以后需要购买大量燃油. 它真正担心的并不是今天的燃油价格, 而是三个月以后燃油突然变贵. 如果等到三个月以后再去市场上买, 那时价格究竟是多少现在并不知道. 于是一个很自然的想法就是: 能不能今天先通过一份合约, 把三个月以后的交易价格约定下来?

这就已经非常接近衍生品了.

#### 定义 6.18.

**衍生品** (derivative) 是指其价值或者未来现金流依赖于某项资产, 市场变量或者未来事件状态的金融合约.

用来决定衍生品价值或者现金流的参考对象通常称为**标的** (underlying).

所谓“衍生”, 并不是说它一定只是某项资产价格乘上一个系数. 股票和商品可以作为标的, 汇率和利率可以作为标的, 股票指数甚至波动率也可以成为衍生品的参考对象. 真正重要的是, 我们不再只是直接交易原来的资产, 而是围绕它未来可能出现的状态另外建立一份合约.

因此衍生品最自然的理解方式, 是把未来状态和未来现金流重新联系起来.

#### 定义 6.19.

**或有现金流** (contingent cash flow) 是指其金额或者是否发生取决于未来某些市场状态或者事件的现金流.

比如一份合约可能规定: 如果三个月以后某只股票价格超过 \$100, 就按照某种规则支付一笔钱; 如果没有超过 \$100, 就不支付. 站在今天来看, 这笔未来现金流显然还没有确定.

如果合约在时刻  $T$  的最终支付只取决于标的资产价格  $S_T$ , 后面我们经常会把它简单写成

$$X = \Phi(S_T).$$

不过现在不用急着把这个表达式看得太数学化. 它真正表达的只是

未来发生什么  $\rightarrow$  合约支付什么.

金融市场做的很多事情, 就是把这样的映射本身做成可以交易的金融合约.

## 6.2.1 线性衍生品与期货

### 远期合约

刚才航空公司的问题可以先用最简单的远期合约来理解.

#### 定义 6.20.

**远期合约** (forward contract) 是指交易双方现在约定, 在未来某个时刻  $T$  按照事先确定的价格  $K$  买卖一定数量标的资产的合约.

假设我们现在约定三个月以后按照 \$100 买入一股股票. 如果三个月以后股票价格已经变成 \$120, 那么按照 \$100 买入显然对多头有利; 如果到时候股票只有 \$80, 多头仍然需要按照 \$100 买入, 相对于当时的市场价格就处于不利位置.

衍生品到期时究竟怎样完成合约, 还需要区分两种最常见的结算方式.

#### 定义 6.21.

**实物交割** (physical delivery) 是指合约到期以后, 交易双方按照约定实际交付标的资产并支付相应价款.

**现金结算** (cash settlement) 是指并不实际交付标的资产, 而是根据合约规定计算应付金

额, 直接以现金结清双方之间的差额.

以后我们把合约在到期时产生的净支付称为**到期支付** (payoff). 合约今天的市场价值和投资者最终的盈亏 (P&L) 是另外两层对象.

只考虑一单位标的时, 远期多头在到期时按照  $K$  买入价值为  $S_T$  的标的, 因而它的净经济价值为

$$S_T - K.$$

如果采用现金结算, 这一数值可以直接表现为结算金额; 如果采用实物交割, 多头则支付  $K$  并收到价值为  $S_T$  的标的. 远期空头的到期支付刚好相反, 为  $K - S_T$ .

这里还需要区分两个以后很容易混在一起的概念. 对于一份刚刚建立的远期合约, 交割价格  $K$  通常会被设定在使合约初始价值为零的位置. 这个使新远期合约初始价值为零的交割价格, 通常称为该期限下的**远期价格** (forward price).

之后市场发生变化时, 原来约定的  $K$  不会跟着改变, 但这份已经存在的远期合约本身却可能变得具有正价值或者负价值.

所以以后需要始终区分:

新的远期合约对应的远期价格      和      已经存在的远期合约的当前价值.

两者并不是同一个东西.

## 期货与实际对冲

远期的经济逻辑很简单, 但如果每家公司都分别寻找交易对手, 自己约定数量, 到期时间, 交割方式以及信用安排, 交易会非常麻烦. 从最直观的经济功能来看, 期货可以先被理解成把这类未来价格交易标准化以后形成的市场.

### 定义 6.22.

**期货合约** (futures contract) 是指按照交易所规定的标准化条款交易, 并根据未来标的价格或者相应结算价格产生盈亏的一类衍生品合约.

从最直观的经济关系来看, 期货和远期很相似: 都是在今天建立一个关于未来价格的头寸. 不过期货并不只是把远期合约搬到交易所交易. 中央清算, 保证金制度以及逐日盯市都会改变合约的交易方式和现金流发生的时间. 因此在最简单的模型中, 同期限的期货和远期价格可以十分接近; 但在更加一般的市场环境下, 两者并不必然完全相同.

### 定义 6.23.

**名义金额** (notional amount) 是衍生品合约中用于确定现金流或者风险规模的参考金额.

一份期货合约可能代表 \$100,000 的标的风险暴露, 但这并不意味着投资者建立头寸时需要支付 \$100,000. 他通常需要提交的是保证金.

### 定义 6.24.

**保证金** (margin) 是指交易者为了保证衍生品合约履约而存入的资金或者合格抵押品. 保证金不是购买标的资产的首付款, 也不意味着投资者只承担保证金规模的风险.

### 定义 6.25.

**逐日盯市** (marking to market) 是指市场按照每日结算价格重新计算已有期货头寸的损益, 并将相应金额计入或者扣除保证金账户的结算机制.

这也是为什么期货很容易形成杠杆. 投资者可能只占用相对于名义金额较小的一部分保证金, 却承担整个合约规模对应的价格变化. 而且即使一个投资者最后对于价格方向的判断是正确的, 也不意味着中间价格怎样变化无所谓. 如果价格在到达最终目标以前先大幅向不利方向移动, 投资者可能因为保证金不足而被要求补充资金, 甚至在价格恢复以前就被迫退出头寸.

所以金融市场中的风险很多时候不仅取决于终点, 还取决于中间走过了怎样的路径.



**例 6.26 (航空公司的燃油对冲).**

假设一家航空公司担心三个月以后燃油价格上涨, 它可以提前建立与未来采购风险相匹配的期货多头.

但这并不意味着航空公司准备等期货到期以后通过交易所完成实际燃油采购. 现实中的实物采购和金融对冲通常是两条分开的链条. 航空公司仍然按照原来的供应体系向炼油商或者燃油供应商购买真正需要的航空燃油; 与此同时, 它在期货市场建立金融头寸, 用期货上的损益来抵消一部分实际采购价格的变化.

临近实际采购时, 公司通常可以通过建立相反方向的期货交易把原来的头寸平仓 (close out), 然后继续通过正常供应渠道购买燃油.

如果把期货头寸的累计损益记为  $\Pi_T^{\text{fut}}$ , 并约定盈利为正、亏损为负, 那么对冲后的净采购成本可以粗略写成

$$\text{对冲后的净采购成本} = \text{实际采购支出} - \Pi_T^{\text{fut}} \approx \text{事先希望锁定的采购成本}.$$

如果油价意外上涨, 实际采购支出会增加, 但期货多头通常会产生正的损益; 如果油价下降, 实际采购变得便宜, 期货头寸则可能亏损. 因此期货真正帮助企业稳定的, 是最终承担的净采购成本, 而不是强迫企业改变原来的物流和供应链.

当然, 上面的“ $\approx$ ”非常重要. 航空公司实际购买的航空燃油和期货合约所追踪的标的未必完全相同, 采购地点, 品种, 时间以及市场价格变化之间也不可能永远严格同步.

**定义 6.27.**

**基差风险 (basis risk)** 是指实际需要对冲的价格与所使用衍生品的价格不能完全同步变化, 因而在建立对冲以后仍然留下的风险.

所以对冲并不意味着把风险精确消成零. 很多时候, 衍生品只是把原来无法接受的一种风险换成一个规模更小或者更加容易管理的剩余风险.

**例 6.28 (基差作为交易对象).**

基差并不只是需要被动承受的风险, 它本身也可以成为交易对象.

美国国债市场中的**国债基差交易** (Treasury cash-futures basis trade) 就是典型例子. 交易者可能买入可交割现券, 同时卖出国债期货, 押注现券和期货之间的相对价格关系会按照交割机制和持有成本约束收敛 [AS23; BKM23].

这里押注的不是“美国国债整体上涨还是下跌”, 而是两种高度相关工具之间的相对价格. 但它仍然会承担 repo 融资, 期货保证金, 流动性和中途去杠杆风险. 完整机制放到下一节的美债与 repo 背景中再展开.

**永续合约**

上面的例子仍然属于有固定到期日的期货. 在加密货币市场中, 还非常常见一种看起来像期货, 但取消了固定到期日的合约: **永续合约** (perpetual futures 或 perpetual swap, 常简称 perp). 这类合约的理论背景和市场机制可以参考 [Ang+22; He+24].

**定义 6.29.**

**永续合约**是指一种以某个标的资产价格或者价格指数为参考, 允许交易者持续持有多头或空头价格暴露, 但通常没有固定到期日的保证金衍生品合约.

下面只讨论最常见的一单位线性永续合约. 现实中还可能存在反向合约或者 quanto 合约, 其保证金计价和盈亏函数会更加复杂, 不能直接套用下面的线性盈亏公式.

如果只看价格方向, 永续合约和期货很像: 多头希望标的价格上涨, 空头希望标的价格下跌. 但普通期货有一个到期日  $T$ , 临近到期时会通过交割或者现金结算把期货价格和结算价格联系起来. 永续合约没有这个强制收敛时刻, 所以它需要另一套机制来影响合约价格和现货指数之间的偏离.

这套机制通常称为**资金费率** (funding rate). 在离散时间  $t_1, t_2, \dots$  上, 交易所会根据永续合约价格相对于参考现货指数的偏离, 以及利率等约定项, 计算一个资金费率. 如果永续合约价格明显高

于现货指数, 通常会出现正的资金费率, 多头向空头支付资金费用; 如果永续合约价格明显低于现货指数, 资金费率可能为负, 空头向多头支付资金费用。

粗略地说, 如果一单位名义金额的资金费率为  $f_k$ , 且  $f_k > 0$  约定为多头支付, 那么在第  $k$  个资金费率结算时点附近, 多头的有符号资金收入可以写成

$$\Delta A_{t_k}^{\text{fund}} \approx -f_k \times \text{名义金额}.$$

这里  $\Delta A_{t_k}^{\text{fund}} > 0$  表示多头收到资金费用,  $\Delta A_{t_k}^{\text{fund}} < 0$  表示多头支付资金费用. 真实交易所会有更加具体的指数构造, 费率上限, 结算频率以及保证金规则, 但核心思想是:

价格偏离  $\rightarrow$  资金费用  $\rightarrow$  持仓成本变化  $\rightarrow$  套利或方向性交易激励  $\rightarrow$  价格锚定.

因此永续合约不能简单理解成“没有到期日的期货”. 普通期货主要通过到期结算来建立期货价格和标的价格之间的关系; 永续合约则通过连续或者周期性的资金费用, 把持有某一方向头寸的成本变成合约结构的一部分. 这使得永续合约的现金流不再只是某个到期时刻的一次支付, 而是会沿着整条持仓路径不断发生.

这也是永续合约特别适合作为随机过程例子的原因. 一个交易者持有永续合约时, 他的盈亏不只取决于未来某个时刻的标的价格, 还取决于中间路径上的永续合约价格和指数价格之间的基差, 资金费率的随机变化, 保证金余额和强平边界, 以及市场流动性, 订单簿深度和价格跳跃.

如果用  $P_t^{\text{perp}}$  表示线性永续合约的市场价格,  $I_t$  表示参考指数价格,  $A_t^{\text{fund}}$  表示截至时刻  $t$  的有符号累计资金收入, 那么一单位多头的简化损益可以粗略写成

$$\Pi_t = (P_t^{\text{perp}} - P_0^{\text{perp}}) + A_t^{\text{fund}}.$$

这里的  $A_t^{\text{fund}}$  本身已经是沿时间积累出来的随机过程. 所以永续合约把价格过程, 基差过程, 资金费率过程和保证金路径共同纳入同一个动态系统中.

当然, 资金费率机制并不意味着永续合约价格一定会始终贴住现货价格. 资金费用改变的是持仓成本和交易激励, 真正的价格回归还需要交易者愿意并能够同时交易现货和永续合约. 如果市场单边情绪很强, 杠杆需求集中, 融资或抵押品约束收紧, 交易所风险上升, 或者流动性突然变差, 永续合约价格仍然可能长期偏离指数价格, 资金费率也可能成为持仓成本和市场拥挤程度的直接信号. 因此在实际市场里, 永续合约同时是一个方向性杠杆工具, 一个观察市场多空需求和杠杆拥挤的窗口, 也是一个天然带有路径依赖现金流的衍生品例子.

### 算力期货

期货最容易让人联想到原油, 小麦或者黄金这些传统商品, 但期货并不要求标的一定是一件最后能够装上卡车或者轮船运走的实物.

#### 例 6.30 (算力期货).

一个正在形成中的例子就是算力期货. 这里讨论的重点不是某个合约当前是否已经形成成熟流动性, 而是算力价格怎样开始被标准化并尝试进入衍生品市场.

这类合约即使被设计出来, 也仍然需要经历报价, 成交量和持仓量逐渐形成的过程.

随着 AI 训练和推理需要大量 GPU, 对一些 AI 公司和云服务商来说, 算力本身已经成为一项重要经营成本. 假设一家公司知道自己半年以后需要大量 H100 或者 B200 算力, 那么它面对的问题其实和航空公司未来需要燃油非常类似: 未来确定存在资源需求, 但未来价格现在并不知道.

不过算力又和石油不完全一样. 所谓“一单位算力”并不是一桶规格统一的东西. GPU 型号, 集群规模, 网络结构, 数据中心位置, 租赁期限以及服务质量都可能影响真正的采购成本. 所以想让算力进入标准化的衍生品市场, 首先必须回答: 到底用什么价格代表“算力价格”?

一种方法是收集 GPU 租赁市场中的报价, 对不同交易条件进行标准化, 再构造以每 GPU-hour 租赁成本表示的价格指数. 市场有了这样一个相对稳定的价格基准以后, 才能够进一步围绕这个指数设计标准化期货合约.

整个过程大致是

现实资源  $\rightarrow$  价格基准  $\rightarrow$  标准合约  $\rightarrow$  形成流动性  $\rightarrow$  真正可用的对冲工具.

最后两步尤其不能省略。一份合约被设计出来甚至正式上市, 并不自动意味着它已经成为一个有效的对冲工具。只有当市场逐渐形成足够的成交量, 持仓量和连续报价以后, 企业才可能在不承担过高交易成本的情况下建立和退出头寸。

算力期货还会面对一种比较特殊的基差风险: 技术迭代。一家企业半年以后真正需要的可能已经不是 H100, 而是 B200, 下一代加速器或者完全不同的 GPU 集群结构。即使一份期货能够很好地跟踪 H100 的租赁价格, 它也未必能够很好地对冲企业未来真正需要购买的**有效算力成本**。

这个例子反而很好地说明了期货市场真正做的事情: 它不一定负责把某种实物交到交易者手里, 更重要的是把现实经营中原本难以单独交易的价格风险抽取出来, 找到一个可观察的价格基准, 再把这种风险做成标准化的金融头寸。

## 股指期货

算力期货已经告诉我们, 期货的标的的不一定是一件能够直接交割的实物。股指期货还可以把这件事情再往前推进一步。

S&P 500 本身甚至不是一项可以被直接买入或者卖出的资产, 而只是按照既定规则计算出来的指数数值。投资者平时所谓的“买入 S&P 500”, 实际上通常是在买入跟踪这个指数的交易所交易基金 (exchange-traded fund, ETF), 指数基金或者其他金融产品。但市场仍然可以围绕这个指数的未来水平建立期货合约。

### 定义 6.31.

**股指期货** (stock index futures) 是指以某个股票指数作为标的, 根据指数未来水平确定合约价值和结算金额的一类期货合约。

这里显然不可能进行普通意义上的实物交割。我们不可能要求空头在期货到期以后交付“5000 点 S&P 500”, 所以这类合约通常使用现金结算。

如果用  $F_{0,T}$  表示建立头寸时的期货价格,  $I_T^{\text{settle}}$  表示到期时用于结算的指数水平,  $m$  表示每一个指数点对应的合约金额, 那么忽略逐日结算产生的资金时间差异以后, 多头的累计损益可以粗略写成

$$m(I_T^{\text{settle}} - F_{0,T}).$$

### 例 6.32 (利用股指期货降低市场风险).

假设一家基金持有几百只股票。基金经理可能仍然看好这些公司的长期前景, 但担心接下来几个月整个股票市场因为经济衰退, 利率变化或者其他系统性事件一起下跌。

一种办法当然是把这些股票全部卖掉, 但这样既会产生交易成本, 也会改变原来的持仓结构。另一种办法是继续持有股票, 同时卖出一定数量的股指期货, 从而降低组合对于整个市场方向变化的敏感程度。

当然, 如果基金组合和期货所追踪的指数并不完全一致, 对冲结果也不会精确抵消。对冲所需要的合约数量还取决于组合对于该指数变化究竟有多敏感。

这里再次可以看到, 空头并不等于“看空自己持有的一切”。一个基金经理完全可以长期看好自己的股票, 同时为了降低短期系统性风险而卖出股指期货。

而股指期货也给我们留下了一个后续需要回答的问题: 所谓 S&P 500, Nasdaq-100 或者其他市场指数, 到底是怎样构造出来的? 这个问题会自然引向市场指数, ETF 和被动投资。

## 远期和期货价格就是未来价格吗

既然期货允许我们在今天建立关于未来价格的头寸, 一个非常自然的直觉就是: **期货价格是不是市场对于未来现货价格的预测?**

并不能简单这么理解。

下面先从远期价格开始考虑。这是一段无套利关系预览; 贴现和无套利的正式语言会在后面再展开。假设一项今天价格为  $S_0$  的资产可以自由买卖和卖空, 市场中没有交易成本, 资产在持有期间不支付股息或者其他现金流, 投资者可以按照同一个确定利率  $r$  借入和贷出资金, 并且采用连续复利。如果一份新建立的远期合约以  $T$  为到期日, 并且交割价格被设定在使合约初始价值为零的位置,



那么无套利关系给出

$$F_{0,T} = S_0 e^{rT}.$$

这里的  $F_{0,T}$  首先应该理解成这份新远期合约的合理交割价格。它之所以高于  $S_0$ ，并不是因为市场认为资产未来一定会上涨，而是因为投资者今天完全可以借钱买入现货，然后一直持有到时刻  $T$ 。如果远期交割价格和这一套操作的最终成本相差过大，投资者就可能通过同时交易现货，融资资产和远期合约构造套利。

所以  $F_{0,T}$  和  $S_0$  之间首先存在的是一个**无套利和持有成本**关系。如果资产会支付股息，直接持有现货能够获得相应现金流，远期多头却不能获得同样的中间支付，因而远期价格需要相应调整。对于商品，持有实物还可能产生仓储、保险和损耗成本；与此同时，拥有库存本身又可能给生产和经营带来便利，这种价值通常称为**便利收益** (convenience yield)。这些因素可以统一放进**持有成本** (cost of carry) 中理解。

期货还需要再多一步。在利率确定等简单条件下，同期限的期货价格和远期价格可以视为相同。但是期货会逐日盯市，远期则主要在到期时结算。如果利率本身随机变化，两种合约现金流发生的时间不同，因而价格也未必完全一致。

那么市场对于未来价格的现实判断在哪里？这就需要比较另一个对象：

$$\mathbb{E}^{\mathbb{P}}[S_T],$$

其中  $\mathbb{P}$  表示描述现实世界价格变化的概率测度。

于是三个对象应该明确区分：

$$S_0, \quad F_{0,T}, \quad \mathbb{E}^{\mathbb{P}}[S_T].$$

它们彼此有关，但不是同一个东西。只有当我们比较  $F_{0,T}$  和  $\mathbb{E}^{\mathbb{P}}[S_T]$  时，才开始涉及现实概率下的价格预期以及市场对于风险的补偿。

#### 注 6.33.

不能把期货价格直接理解成“市场预测未来现货价格是多少”。

对于可以交易和复制的资产，远期或者期货价格首先是一种受到现货价格，融资成本，资产现金流以及其他持有成本约束的相对价格。等到后面介绍风险中性定价以后，我们会看到它还可以和风险中性测度下的预期联系起来，但风险中性预期和现实概率测度  $\mathbb{P}$  下对于未来价格的平均预测并不是同一件事情。

### 6.2.2 期权与非线性现金流

#### 期权

远期和期货有一个很明显的特点：一旦建立合约，双方都承担相应的合约义务。如果我们约定未来按照 \$100 买入股票，那么无论到时候股票是 \$150 还是 \$50，原来的约定原则上都在那里。

但有时候投资者想要的是另一种东西：如果未来状态对自己有利，就使用这项权利；如果不利，就可以放弃。

这就是期权。

#### 定义 6.34.

**期权** (option) 是指给予买方在约定时间内或者到期时，按照事先规定的条件买入，卖出某项标的，或者获得相应现金结算的权利，而不是义务的一类衍生品合约。

与此同时，期权卖方承担与这项权利相对应的合约义务。

一份期权至少需要规定几个最基本的条件：**执行价格** (strike price)，也就是期权合约事先规定的买卖价格，后面通常记作  $K$ ；**到期日** (expiration date 或 maturity)，也就是这项权利存在到什么时候，后面通常记作  $T$ ；以及**行权规则**。如果期权持有人按照合约规定使用这项权利，这种行为称为**行权** (exercise)。

根据这项权利究竟是买入还是卖出标的，最基本的期权可以分成看涨期权和看跌期权。

**定义 6.35.**

**看涨期权** (call option) 是指给予买方按照执行价格  $K$  买入标的, 或者获得相应现金结算的权利的期权.

**看跌期权** (put option) 是指给予买方按照执行价格  $K$  卖出标的, 或者获得相应现金结算的权利的期权.

期权还需要规定什么时候允许行权.

**定义 6.36.**

**欧式期权** (European option) 是指只能在到期日  $T$  行权的期权.

**美式期权** (American option) 是指允许持有人在到期日或以前符合合约规定的时刻行权的期权.

这里的 European 和 American 只是行权规则的名称, 并不是说它们分别只能在欧洲或者美国交易.

我们先看最简单的欧式期权.

假设一份欧式看涨期权的执行价格为  $K$ . 到期时如果  $S_T > K$ , 按照较低的  $K$  买入自然具有价值; 如果  $S_T \leq K$ , 买方就没有必要行权. 因此它在到期时的到期支付为

$$(S_T - K)^+ = \max(S_T - K, 0).$$

类似地, 一份欧式看跌期权在到期时的到期支付为

$$(K - S_T)^+ = \max(K - S_T, 0).$$

不过这种“只有对自己有利时才行权”的权利当然不会免费出现.

**定义 6.37.**

期权买方为了获得相应权利而支付给期权卖方的价格称为**权利金** (option premium).

所以这里还需要特别区分到期支付和盈亏. 到期支付描述的是合约本身在到期状态下产生多少支付, 而盈亏还需要把投资者最初支付或者收到的权利金考虑进去.

比如一份看涨期权到期时满足  $(S_T - K)^+ = 0$ , 只能说明它最终没有产生正的到期支付. 如果投资者最初支付了 \$5 的权利金, 那么他仍然损失了这 \$5. 反过来, 如果期权到期支付 \$10, 最初支付了 \$7 的权利金, 那么在暂时忽略资金时间价值, 交易费用和税务影响以后, 最简单的名义利润才是 \$3.

因此以后看到到期支付图时, 最好先问清楚: 这里画的是期权本身的到期支付, 还是把权利金也考虑进去以后的完整盈亏?

**从线性暴露到非线性现金流**

远期和期权之间还有一个更加本质的区别. 远期多头的到期支付为  $S_T - K$ , 所以  $S_T$  增加一美元, 到期支付也增加一美元. 它提供的是一种线性的价格暴露.

看涨期权的到期支付  $(S_T - K)^+$  则不一样. 当  $S_T < K$  时, 到期支付为零; 只有超过  $K$  以后, 到期支付才开始随着标的价格增加. 所以期权首先引入的是一种**非线性现金流**.

**例 6.38 (相同均值, 不同分布).**

假设两个未来价格分布具有相同的均值, 其中一个非常集中, 另一个却允许价格大幅向上或者向下波动.

对于  $S_T - K$  这样的线性到期支付, 两个分布的平均支付可能完全相同; 对于  $(S_T - K)^+$  这样的非线性到期支付, 两者却可能产生明显不同的期望支付.

所以期权会让我们开始关心未来价格分布的波动程度和尾部形状, 而不仅仅是平均价格本身.

但这里不能简单地说“期权就是一个二阶变量”. 看涨期权的到期支付  $(S_T - K)^+$  本身仍然只是一个分段线性函数. 真正的二阶性质是在研究**期权价值怎样随着标的价格变化时出现的**.

如果期权价值记作  $V$ , 那么它对标的价格的一阶敏感度称为 Delta, 也就是期权的方向敏感度:

$$\Delta = \frac{\partial V}{\partial S},$$

而 Delta 本身还会随着标的价格变化, 这种曲率由 Gamma, 也就是二阶敏感度描述:

$$\Gamma = \frac{\partial^2 V}{\partial S^2}.$$

这里暂时只需要知道这些量描述的是期权价值对于市场状态变化的敏感程度, 后面讨论期权定价和动态对冲时再正式介绍它们.

所以更加准确地说, 期权首先引入了非线性的现金流结构; 当我们研究这种非线性头寸怎样随着市场状态变化时, 二阶风险才会自然出现.

也正因为如此, 期权价格会对波动率产生明显敏感度. 如果进一步通过股票或者期货把主要的方向性风险对冲掉, 市场参与者甚至可以在一定程度上把波动率风险相对独立地拿出来管理和交易. 不过一张普通期权本身仍然不是一份纯粹的波动率合约.

### 买方的权利与卖方的义务

期权还有一个和普通资产非常不同的地方. 买方拥有权利, 就意味着另一边需要有人承担相应的义务.

对于看涨期权买方来说, 如果标的价格大幅下跌, 最坏的情况通常只是期权最终失效并损失已经支付的权利金; 如果标的价格大幅上涨, 到期支付却可以继续增加. 一个没有相应对冲头寸的看涨期权卖方则恰好相反: 他最初获得的权利金是有限的, 但如果标的价格持续上涨, 潜在损失却可能不断增加.

因此单独说“在做期权”几乎没有提供多少风险信息. 至少还需要知道这是看涨还是看跌, 是多头还是空头, 执行价格  $K$  在哪里, 到期时间  $T$  多长, 名义规模多大, 以及这份期权和投资者原来已经持有的头寸之间是什么关系.

这再次提醒我们:

$$\text{Position Risk} \neq \text{Portfolio Risk}.$$

## 6.2.3 交易结构与风险理解

### 做市商

这里又会产生一个很自然的问题: 如果我们买入一张看涨期权, 那么另一边究竟是谁在卖给我们? 是不是一定存在另一个投资者和我们的判断完全相反?

并不一定. 现实市场中, 相当一部分交易的另一边可能是做市商.

#### 定义 6.39.

**做市商 (market maker)** 是指按照相应市场制度持续或者经常提供买入和卖出报价, 并通过暂时承担库存和价格风险为市场提供流动性的交易者或者机构.

做市商通常会同时给出两个价格.

#### 定义 6.40.

**买价 (bid)** 是市场参与者愿意买入的报价; **卖价 (ask)** 是市场参与者愿意卖出的报价. ask 与 bid 之间的差额称为**买卖价差 (bid-ask spread)**.

#### 例 6.41 (期权做市).

比如某只期权当前可能存在

$$\text{Bid} = 4.90, \quad \text{Ask} = 5.10.$$

投资者希望立即卖出时, 通常需要按照 Bid 一侧成交; 希望立即买入时, 则通常按照 Ask 一侧成交.

做市商的重要作用之一, 就是让市场参与者不必每次都等到另一个最终投资者恰好在同一时刻产生完全相反的需求.



但做市商也不是凭空提供流动性. 假设做市商刚刚向客户卖出了一批看涨期权. 在其他条件不变时, 卖出看涨期权会给做市商带来负的 Delta 暴露. 如果它希望降低这部分方向风险, 就可能买入一定数量的标的股票或者相应期货.

不过做市商真正管理的是**整个投资组合的净风险**, 而不是机械地为每一张客户订单立即建立一笔完全对应的股票交易. 它可能已经持有其他执行价格, 其他到期日或者方向相反的期权头寸; 也可能选择使用股指期货, 其他期权或者相关资产进行对冲.

因此

客户买入看涨期权  $\nRightarrow$  做市商一定按固定数量买入现货.

更加准确的传导过程是

客户订单  $\rightarrow$  做市商净风险变化  $\rightarrow$  必要时重新对冲  
 $\rightarrow$  可能产生标的或期货订单.

而 Gamma 的存在意味着 Delta 本身还会随着价格变化, 所以一次对冲通常也不是永久有效的. 标的价格继续移动以后, 做市商可能还需要继续调整自己的对冲头寸.

#### 注 6.42.

做市商并不是日常语言中所谓的“庄家”. 它不能随意决定市场价格, 也不是因为站在客户交易的另一边就天然能够赚钱.

做市商需要面对库存风险, 跳价风险, 对冲误差, 流动性枯竭以及交易对手与清算机制带来的其他约束. Bid-ask spread 中的一部分收益, 正是在补偿它提供即时流动性并暂时承担这些风险.

同一只股票可以同时存在大量不同执行价格  $K$  和不同到期时间  $T$  的期权. 如果每一个  $(K, T)$  合约都必须等到两个最终投资者恰好产生完全相反的需求才能成交, 很多合约几乎不可能拥有持续流动性. 做市商在中间承接这些不完全同步的需求, 再把不同合约产生的风险放进一个整体账户里面统一管理, 因而成为衍生品市场非常重要的参与者.

### 衍生品并不天然意味着高风险

到这里可以回过头重新回答一个很容易产生误解的问题: 期货和期权是不是天然就是比股票更加危险的东西?

并不是.

如果一个投资者原本没有相应风险暴露, 却利用很少的保证金建立巨大的方向性期货头寸, 那么他当然是在主动增加风险. 如果他大量裸卖期权, 也可能承担非常不对称的尾部损失.

但同一类工具也可能被用于降低既有风险. 如果一家航空公司本来就面对未来燃油价格上涨的风险, 建立期货头寸反而可能降低它的经营风险; 如果一家基金持有大量股票, 卖出股指期货可能是在减少整个组合对于市场共同下跌的敏感程度; 如果一个股票投资者买入看跌期权, 则可能是在支付一笔确定的权利金, 换取对于极端下跌状态的保护.

#### 注 6.43.

**衍生品是一种重新切割, 转移和组合风险的工具.**

它可以创造新的风险暴露, 可以借助杠杆放大风险, 也可以抵消已经存在的风险或者限制某些极端状态下的损失. 因此判断一项衍生品交易是否危险时, 不能只看这张合约本身, 而应该把它放回投资者完整的头寸和资产负债表中观察.

### 衍生品为什么会需要随机过程

到目前为止, 我们举的大部分期权例子最终都写成

$$X = \Phi(S_T).$$

这很容易让人产生一种错觉: 如果一份欧式期权最后只依赖  $S_T$ , 那么是不是只需要研究终点分布, 根本不需要整个随机过程?

并不是, 但这里需要分清两个层次.

如果已经额外给定贴现方式, 并且知道某个定价测度下  $S_T$  的终端边缘分布, 那么一份欧式终端支付在时刻 0 的静态价格确实可以压缩成一个终端期望. 这说明并不是所有关于欧式支付的问题都必须直接写出整条路径.

但是现实中的衍生品定价通常不只问这个静态价格. 为了描述它在到期以前的价值怎样变化, 研究投资者应该怎样进行动态对冲, 或者处理路径依赖支付和提前行权问题, 我们仍然需要为整个价格过程

$$(S_t)_{0 \leq t \leq T}$$

建立模型.

对于普通欧式期权来说, 最终到期支付本身只依赖终值  $S_T$ , 但动态价值过程和复制对冲仍然依赖价格过程的概率结构. 另外还有一些衍生品, 连到期支付本身都直接依赖整条路径.

#### 例 6.44 (路径依赖).

亚洲期权 (Asian option) 的支付可以取决于一段时间内的平均价格, 障碍期权 (barrier option) 则可能取决于标的价格曾经有没有碰到某个规定水平.

两条价格路径即使最后具有完全相同的  $S_T$ , 中间走法不同, 合约最终支付也可能完全不同. 这时更加一般的表示就是

$$X = \Phi((S_t)_{0 \leq t \leq T}).$$

还有一类问题稍微不同. 前面已经定义过, 欧式期权只能在规定到期日行权, 而美式期权允许持有人在到期日或以前符合规则的時刻行权. 于是对于美式期权来说, 我们不仅需要知道价格过程怎样变化, 还需要不断面对“现在行权, 还是继续等待”的决策.

这正是一个最优停时 (optimal stopping) 问题, 因而会自然和后面随机过程基础中将要介绍的停时联系起来.

所以随机过程模型在衍生品定价中变得不可避免, 主要有两个层次的原因. 第一, 动态价值过程和复制对冲需要描述市场变量怎样随时间变化. 第二, 对于某些衍生品来说, 合约最终支付或者行权决策本身直接依赖整个随机路径.

#### 注 6.45.

在数学模型中, 我们以后经常会把一份衍生品压缩成

$$X = \Phi(S_T)$$

或者更加一般的路径函数.

这种写法非常方便, 但现实中的期货和期权首先仍然是具有具体合约条款, 保证金制度, 清算规则, 流动性以及市场交易机制的金融合约.

因此到期支付函数是我们为了研究当前问题而保留下来的结构, 而不是现实合约的全部.

到这里, 我们已经看到了一种非常重要的风险处理方式: 通过新的金融合约重新切割和转移已有风险. 这也留下了两个自然的接口.

第一个接口是事件本身. 如果一份合约的支付可以取决于股票价格, 利率或者指数, 那么它当然也可以进一步取决于某个未来事件是否发生. 下一节先沿着这条线, 讨论预测市场怎样把事件做成或有现金流, 以及为什么它会自然给出所谓的市场隐含概率.

第二个接口来自股指期货: 一个不能直接持有的指数, 为什么能够成为期货, 期权和长期投资产品共同围绕的对象? 这个问题会在预测市场之后, 由指数, ETF 和被动投资继续处理.

## 6.3 预测市场与市场隐含概率

上一节把衍生品理解成一种将未来状态重新写成或有现金流的金融合约. 如果一份合约的支付不再主要取决于某项资产的价格, 而是取决于某个未来事件是否发生, 我们就已经非常接近预测市场.

不过本文引入预测市场, 并不是因为想把它当成某种能够准确预言未来的神谕机, 而是来自一个更加具体的问题:

怎样从当前市场价格中反解出市场究竟在 price in 什么?

这个问题后来也成为 Agentic R-D-G 中图结构的一项重要来源。

### 6.3.1 从价格反解市场预期

股票价格显然包含市场对于未来的判断。如果一家公司公布财报以后股价上涨，我们可能会说市场提高了对于收入增长的预期；如果股价下跌，也可能解释成利润率不及预期，资本开支过高，监管风险上升，估值倍数下降，或者只是此前仓位过于拥挤。

问题在于，价格是许多不同因素共同作用以后形成的压缩结果：

$$\{\text{未来现金流, 贴现率, 风险溢价, 仓位, 流动性, 订单流, ...}\} \\ \longrightarrow \text{当前价格.}$$

这个映射通常是多对一的。许多完全不同的事件组合和市场叙事，都可能产生相似的价格变化。因此从价格反过来恢复市场叙事，本质上是一个识别不足的反问题。

一个自然的想法是利用期权。现货价格主要给出一个已经高度压缩的方向性结果，而不同执行价格和到期时间的期权还能够提供隐含波动率，偏度，尾部风险和非线性暴露等更加丰富的信息。经典的 Breeden-Litzenberger 关系说明，在理想条件下可以从欧式期权价格曲面对风险中性终端分布提取信息 [BL78; Hul22]。

但是期权曲面仍然主要回答“市场怎样给不同价格状态定价”，而不是“市场认为哪个具体事件会导致这些状态”。隐含波动率上升，可能来自财报风险，监管决定，宏观数据，流动性下降，做市商仓位变化，或者几种因素共同作用。即使我们观察到明显的偏度变化，仍然不能仅凭期权价格确定市场究竟在担心哪件事情。

所以期权减少了信息压缩，却没有消除解释的不唯一性。

### 6.3.2 从文本生成解释为什么仍然困难

另一种可能的方法是先阅读公司的财报，Call Transcript 和其他经营资料，从中抽取若干候选事件  $E_1, \dots, E_m$ ，再由 Agent 生成这些事件可能造成的价格影响，最后寻找能够解释一段价格路径的事件组合：

$$\{\text{财报, Call Transcript, 行业与政策信息}\} \xrightarrow{\text{Agent}} \{E_1, \dots, E_m\} \xrightarrow{\text{解释价格路径}} \text{候选市场叙事.}$$

这种方法的问题并不是 Agent 无法生成解释，而是它通常能够生成太多解释。候选事件之间可能互相重叠，同一条证据可能支持多种叙事，多个事件也可能同时发生。如果只是要求解释能够符合已经观察到的价格变化，Agent 很容易在事后构造出一套看起来相当合理的故事。

因此真正缺少的并不是更多叙事，而是一组来自公司文本之外，具有明确事件边界和外部市场约束的参照物。预测市场正是在这里进入研究框架。

### 6.3.3 把事件做成或有现金流

**定义 6.46 (预测市场与事件合约).**

**预测市场** (prediction market) 是围绕未来事件或者可验证结果建立交易合约的市场。这些合约也常被称为**事件合约** (event contracts)。

如果事件  $A$  在规定期限内按照结算规则被判定为发生，一份二元事件合约支付 1；否则支付 0。它在结算时刻  $T$  的支付可以写成

$$X_T^A = \mathbf{1}_A.$$

CFTC 对 event contracts 的介绍中也采用了类似的直观语言：许多事件合约围绕 yes-no 问题设计，通常具有固定支付和到期或结算时点 [Com]。从金融合约的角度来看，事件合约只是衍生品的一种特别直接的形式：它把一个自然语言中的未来问题，转换成一份具有明确支付规则的或有现金流。

与股票或者普通期权相比，事件合约最重要的新增信息不是价格本身，而是它为价格附加了一个相对明确的语义标签：

这个价格究竟对应哪一个事件？

例如，“某项监管批准是否会在时刻  $T$  以前发生”和“某家公司股价是否会在时刻  $T$  以前超过某个水平”是两个不同的事件。即使它们可能彼此相关，也不能被当成同一个概率对象。

预测市场并没有彻底解决价格反演问题, 但它把原本混在资产价格中的一部分叙事, 拆成了可以分别观察的事件命题.

**注 6.47.**

将预测市场看成事件型或有现金流, 是一种金融建模上的理解方式. 一份事件合约在法律上究竟属于衍生品, 博彩合约, 还是其他受监管产品, 仍然取决于具体司法辖区和市场制度.

在美国监管语境中, CFTC 曾将 Polymarket 提供的若干 event-based binary options 认定为其辖区下的 swaps, 并在 2022 年对其未注册交易设施相关问题作出处罚 [Com22].

### 6.3.4 市场隐含概率

假设一份事件  $A$  的合约在时刻  $t$  价格为  $C_t^A$ , 到期发生时支付 1, 不发生时支付 0. 如果暂时忽略利率, 交易费用, 买卖价差, 风险厌恶和交易约束, 人们经常会把  $C_t^A$  直接读成一个概率.

更一般地, 如果从  $t$  到  $T$  的贴现因子为  $D(t, T)$ , 可以定义一个经过贴现归一化的市场价格对象

$$\hat{p}_t^{\text{mkt}}(A) = \frac{C_t^A}{D(t, T)}.$$

**定义 6.48 (市场隐含概率).**

本文把由事件合约价格经过合约面值和贴现归一化以后得到的概率状数值称为**市场隐含概率** (market-implied probability).

它表示市场在特定合约条款, 参与者结构和交易条件下对事件  $A$  给出的价格对象, 而自动等于事件的真实概率.

在足够理想的模型中, 这个价格可以被解释成某种定价测度下的条件概率. 如果把从  $t$  到  $T$  的贴现和风险调整统一记入随机定价核  $m_{t,T}$ , 则有形式表达

$$C_t^A = \mathbb{E}_{\mathbb{P}} [m_{t,T} \mathbf{1}_A \mid \mathcal{F}_t].$$

在更加简化的无摩擦模型中, 也可以写成

$$C_t^A = D(t, T) \mathbb{Q}(A \mid \mathcal{F}_t),$$

其中  $\mathbb{Q}$  是相应的定价测度.

这已经说明, “价格在数值上像概率” 并不意味着它就是现实世界的客观概率. 预测市场价格还会受到风险偏好, 资金约束, 手续费, 参与限制, 买卖价差, 流动性和结算规则影响. 关于 prediction-market price 应当怎样解释为概率, 文献中本来也有很多细节和争论 [Man06; WZ04].

### 6.3.5 四类不能混用的对象

为了避免把预测市场写成神谕, 至少需要区分下面几层对象.

事件  $A$  的真实条件概率可以形式化地写成

$$p_t^*(A) = \mathbb{P}(A \mid \mathcal{F}_t),$$

但真实的数据生成机制通常并不为研究者所知.

根据公司证据和基本面研究得到的主观估计, 可以记成

$$\hat{p}_t^{\text{fund}}(A).$$

预测市场在自身合约规则下给出的价格对象是

$$\hat{p}_t^{\text{mkt}}(A).$$

而公司估值中 Bull, Base, Bear 等情景的权重, 则可以另外记成

$$\pi_t^{(i)}(s), \quad s \in \{\text{Bull, Base, Bear, Tail}\}.$$



这四者不能未经论证地互相替换。一个监管事件  $A$  即使发生, 也未必自动使公司进入 Bull 情景; 它可能只改变收入路径, 利润率, 资本开支或者贴现率中的某一项。反过来, 公司进入 Bear 情景也可能由许多事件共同造成, 而不是由某一份事件合约单独决定。

预测市场还会提供另一组完全不同的信息:

$$\mathcal{L}_t^A = \{\text{bid, ask, spread, depth, volume, open interest, recency}\}.$$

这些是盘口和市场质量信息。它们可以帮助判断价格是否具有足够的交易支持, 也可以反映市场对于某个问题投入了多少注意力, 但流动性和成交量本身并不是概率。

#### 例 6.49.

假设某份事件合约的最优买价为 0.57, 最优卖价为 0.63, 最近成交价为 0.61。

此时把它简单写成“市场概率为 61%”会隐藏很多信息。0.61 可能只是已经过时的最近成交价; 0.60 是不可直接成交的中间价; 真正立即买入需要支付 0.63, 而立即卖出只能得到 0.57。

如果 0.63 的卖价上只有很少数量, 一笔稍大的买单还会继续吃掉更高价格的挂单。所以盘口顶部的价格也不必然代表较大规模资金可以成交的概率水平。

#### 注 6.50 (价格, 注意力与流动性).

市场中存在一份关于事件  $A$  的合约, 首先说明有人愿意围绕  $A$  建立一个可以交易的问题。

盘口较大或者成交活跃, 可以说明这个问题获得了较多市场注意力; 一个较窄的买卖价差和较深的盘口, 可以提高报价作为市场信号的可读性。

但市场注意力不等于事件概率, 流动性不等于预测准确度, 市场价格也不等于真实概率。

### 6.3.6 从事件合约到 Event Graph

预测市场真正改变研究方法的地方, 是它为事件图提供了一组外部的, 带有问题定义和市场状态的校准信号。整个接口可以粗略写成

$$\begin{aligned} \text{财报与 Call Transcript} &\xrightarrow{\text{Agent 提取}} \text{公司事件与传导路径,} \\ \text{Prediction Market} &\xrightarrow{\text{问题, 价格与盘口}} \text{市场注意力与候选概率对象,} \\ \text{两类信息} &\xrightarrow{\text{校准与路由}} \text{Company Event Graph.} \end{aligned}$$

Agent 仍然需要判断事件之间是否存在上下游关系, 某个事件怎样影响公司的需求, 定价, 利润率, 资本开支或者融资条件, 以及这些传导边有没有独立证据。预测市场不能单独激活这些因果关系。它首先能够提供的是一个外部的现实锚点: 市场上确实有人在围绕这个事件下注, 并且当前盘口给出了怎样的价格和注意力状态。

所以预测市场在图中的用途通常可以分成三层: 事件是否获得外部市场注意, 合约是否足够干净而能够形成候选市场概率对象, 以及概率或盘口变化是否值得触发进一步研究。

单家公司的局部 Event Graph 之后还可以沿着共同事件, 上下游关系和资产暴露彼此粘接, 形成更加全局的 Market Graph。后文介绍 Agentic R-D-G 时会进一步说明, 这种图怎样用于观察市场季风与风险堆积, 以及怎样作为语境输入反过来校准单家公司的基本面研究。

这里需要保留的边界是: 预测市场提供信号, Event Graph 保存传导, Market Graph 组织语境; 它们都不直接生产估值结论。

### 6.3.7 结算规则, 信息优势与监管问题

预测市场中的数字必须连同合约问题一起阅读。同一个自然语言事件, 只要结算期限, 条件分母, 数据来源或者裁决机构不同, 就可能对应完全不同的合约。因此在使用一个市场价格以前, 至少需要知道它对应的是最后成交价, 买卖价中点还是一侧报价, 并检查合约的结算规则, 期限, 条件性, 流动性和报价时效。

预测市场还存在一个不能回避的问题: 交易者可能拥有其他参与者不知道的信息。某些事件直接涉及企业内部人员, 政策制定者, 交易对手, 候选人, 内容发布者, 或者与事件高度接近的参与者。

而不同预测市场所处的监管制度, 信息披露义务, 市场监察能力和参与者限制又可能与传统证券市场明显不同. 因此非公开信息交易, 利益冲突和市场操纵都应被视为需要单独审计的风险.

CFTC 在 2026 年关于 prediction markets 的 enforcement advisory 中, 就专门提到 event contracts 中可能出现的非公开信息误用, 欺诈, wash sales 和其他禁止交易行为, 并列举了 KalshiEX 上与候选人本人交易, 以及与 YouTube 频道内部人员相关的案例 [Com26]. 这说明所谓预测市场信号, 有时可能并不是单纯的群体智慧, 而是混合了信息优势, 监管边界和交易制度的市场价格.

但一笔大额订单或者一次概率跳升仍然不能单独证明存在内幕交易. 它也可能来自公开新闻, 做市商库存调整, 跨市场套利, 低流动性冲击, 结算规则理解差异, 操纵行为或者陈旧报价.

#### 注 6.51 (预测市场不是神谕).

异常盘口可以形成“可能存在知情交易”的观察假设, 但不能仅凭市场运动指认内幕交易或违法行为.

预测市场信号适合用于注意力识别, 研究路由, 观察和校准; 更强的事实判断仍然需要预测市场以外的独立证据.

同样地, 没有找到相关预测市场也不能被解释成事件不重要或者不会发生. 它可能只是说明该事件不适合标准化, 缺少足够交易需求, 受到平台规则限制, 或者尚未被市场组织成一份合约.

### 6.3.8 预测市场作为随机过程

预测市场价格并不是一份静态民意调查. 对于固定事件  $A$ , 市场隐含概率, 买卖价差, 盘口深度和成交活动都会随时间变化. 因此更加完整的研究对象是

$$(\hat{p}_t^{\text{mkt}}(A), \mathcal{L}_t^A)_{0 \leq t \leq T}.$$

新的公开信息到来时, 价格可能跳跃; 市场参与者意见分歧扩大时, 价差和成交量可能发生变化; 临近结算时, 时间和规则不确定性又会以不同方式进入价格.

所以预测市场为后面的随机过程提供了一个很自然的例子: 事件合约价格构成价格过程, 订单到达构成点过程, 盘口深度构成流动性过程, 而市场能够使用的信息则形成相应的滤链.

更重要的是, 我们关心的不只是事件最后是否发生, 还关心市场对于事件的判断怎样随着信息到达而不断更新. 预测市场因此并没有替我们回答未来是什么. 它真正提供的是一条可以被观察, 被质疑并被校准的市场信念过程.

到这里, 我们已经看到两个从衍生品延伸出来的方向. 预测市场把未来事件本身做成可以交易的现金流; 股指期货和指数期权则提示我们, 一个不能直接持有的指数也可以成为大量金融合约围绕的对象. 下一节就转向指数, ETF 和被动投资.

## 6.4 指数, ETF 和被动投资

前面讨论股指期货时, 我们已经提前遇到了一个有些奇怪的标的: 指数.

S&P 500 本身不是一家公司, 也不是一项能够直接交割的资产. 它首先是一套规则以及按照这套规则计算出来的数值. 但市场参与者不仅可以围绕这个数值交易期货和期权, 还经常会说自己在“买入 S&P 500”, “持有 Nasdaq-100”, 甚至长期定投整个市场.

所以这里其实混在了一起几个不同的问题: 为什么要把很多股票放进同一个组合? 指数究竟怎样构造出来? 一个不能直接持有的指数为什么又能够成为投资对象? ETF 和指数是什么关系? 所谓被动投资又究竟被动在哪里?

指数构造, 指数数学, ETF 结构和被动投资的背景主要参考 [Gas10; Mar52; Nas; SP 26; SP a; SP b; US d; US e].

### 6.4.1 从单只股票到股票篮子

假设一个投资者把全部资金都放进一家公司. 那么这家公司的产品失败, 工厂事故, 管理层问题或者其他只属于这家公司的事件, 都可能直接影响投资者几乎全部财富.

如果投资者同时持有很多不同公司, 情况就会发生变化. 一家公司突然出现经营问题, 并不意味着另外几百家公司也会同时出现完全相同的问题. 因此当许多不完全同步变化的资产被放进同一个投资组合以后, 一部分原本属于单个公司的风险就可能被分散.



**定义 6.52.**

**分散化** (diversification) 是指通过同时持有多项不完全同步变化的资产, 降低单个资产或者局部风险来源对于整个投资组合的影响.

这里真正重要的并不是“买了多少只股票”, 而是这些股票究竟会不会一起变化.

假设一个投资组合中资产收益率分别为  $R_1, \dots, R_n$ , 权重为  $w_1, \dots, w_n$ , 并满足  $\sum_i w_i = 1$ . 组合收益率为

$$R_p = \sum_{i=1}^n w_i R_i,$$

组合收益率的方差满足

$$\text{Var}(R_p) = \sum_i w_i^2 \text{Var}(R_i) + 2 \sum_{i < j} w_i w_j \text{Cov}(R_i, R_j).$$

第一项来自每项资产自己的波动, 第二项则告诉我们不同资产之间怎样共同变化. 如果很多资产的协方差都很高, 单纯增加持仓数量并不会让风险自动消失.

**定义 6.53.**

**特有风险** (idiosyncratic risk) 是指主要来自某一家公司, 某一项资产或者少数特定对象自身的风险.

**系统性风险** (systematic risk) 是指大量资产共同暴露, 因而很难单纯通过增加同类持仓数量消除的风险来源.

一家公司的新产品失败更接近特有风险; 经济衰退, 整体融资条件突然收紧或者市场风险偏好发生巨大变化, 则更接近系统性风险.

**注 6.54.**

这里的 systematic risk, 指的是资产定价意义下大量资产共同暴露的风险, 不要和金融体系发生传染或者失灵意义上的 systemic risk 混在一起.

而且“特有”和“系统性”也不是某种风险永恒不变的标签. 一个只影响半导体行业的冲击, 对半导体股票组合来说可能是共同风险; 放进一个全球多资产组合以后, 它又可能只是局部风险.

不过分散化本身并不要求指数. 一个投资者完全可以自己选择 100 家公司, 主动基金也可以建立高度分散的组合.

指数真正解决的是另一个问题:

如何用公开, 可重复, 可维护的规则表示一个资产篮子?

这才是指数出现的地方.

## 6.4.2 指数怎样构造市场表示

**定义 6.55.**

**市场指数** (market index) 是指按照预先规定的样本范围, 成分选择, 加权, 维护以及收益计算规则, 将一组资产的市场表现压缩成一个或者少数几个数值的市场指标.

所以设计一个指数至少需要回答几个问题: 哪些资产具有进入资格? 最终选择哪些资产? 每项资产占多大权重? 公司行动怎样处理? 什么时候重新调整成分和权重? 股息等现金流又要不要计入指数收益?

一个简单的股票指数可以写成

$$I_t = \frac{\sum_{i=1}^n P_{i,t} Q_{i,t}}{D_t},$$

其中  $P_{i,t}$  是第  $i$  项证券的价格,  $Q_{i,t}$  是指数计算中分配给它的指数股数或者相应权重参数,  $D_t$  是指数除数 (index divisor).

相应地, 一项证券在指数中的实际权重为

$$w_{i,t} = \frac{P_{i,t}Q_{i,t}}{\sum_j P_{j,t}Q_{j,t}}.$$

所以  $Q_{i,t}$  本身不是权重. 权重是价格和指数股数共同作用以后得到的结果. 不同指数真正不同的地方, 很大程度上就在于怎样确定这些指数股数, 以及之后什么时候重新调整它们.

指数提供商还需要处理拆股, 增发, 回购, 成分更换, 特别股息等公司行动. 这些事件有些代表真实投资收益或者资产变化, 有些却只是股份结构发生了机械变化.

#### 注 6.56.

指数除数并不是遇到任何公司行动都会调整.

对普通市值加权指数来说, 股票拆股时每股价格下降, 股数同时按照相反方向增加, 公司市值没有变化, 因而通常不需要调整除数. 对价格加权指数则不一样. 由于每家公司在指数计算中使用相同的名义股数, 拆股只会直接降低每股价格, 因此通常需要调整除数来避免指数点位产生没有经济含义的机械跳跃.

所以指数提供商真正做的是利用指数股数, 权重调整因子和指数除数等工具, 把公司行动和真实市场收益区分开来. 究竟调整哪一个参数, 要看具体指数的方法文件.

### 权重规则与再平衡

最常见的一类股票指数是市值加权.

#### 定义 6.57.

**市值加权指数** (market-capitalization-weighted index) 是指资产在指数中的权重主要由其市场价值决定的一类指数.

如果只考虑最简单的情形, 公司  $i$  的权重大致为

$$w_i = \frac{M_i}{\sum_j M_j},$$

其中  $M_i$  表示公司的可计入市场价值.

很多现实指数还会进一步按照自由流通股份调整市值, 因为一家公司理论上存在的股份并不一定全部能够由普通市场参与者自由买卖.

市值加权有一个非常适合大规模指数跟踪的特点. 如果成分集合, 股数和其他指数参数都不发生变化, 某只股票单纯因为价格上涨而市值增加, 一个原本已经按照市值比例持有它的组合不需要额外买入, 这项头寸自己的市场价值已经自动上升.

所以市值加权具有很强的自我调整性质. 当然, 这并不意味着市值加权基金永远不需要交易. 增发, 回购, 自由流通比例变化, 并购, 分拆, 指数成分调整以及基金自己的申购赎回仍然会产生真实交易.

另一种历史悠久的方法是价格加权.

#### 定义 6.58.

**价格加权指数** (price-weighted index) 是指成分证券对于指数的影响主要由其每股市场价格决定的一类指数.

假设指数中暂时只有两只股票,  $A$  的价格为 \$300,  $B$  的价格为 \$100. 如果两只股票都上涨 1%, 那么  $A$  上涨 \$3,  $B$  只上涨 \$1, 所以  $A$  对指数点数变化的影响更大.

这和两家公司的总市值谁更大没有直接关系. 这也解释了为什么价格加权指数会特别在意拆股等改变每股价格刻度的公司行动.

第三种很直观的方法就是等权.

#### 定义 6.59.

**等权指数** (equal-weighted index) 是指在规定的再平衡时点, 让各成分公司或者证券重新具有相同或者近似相同目标权重的一类指数.

这里需要特别注意“在规定的再平衡时点”这几个字。等权指数并不是每一秒都让所有成分保持严格相同权重。一次再平衡以后，股票继续涨跌，上涨较快的公司权重会逐渐增加，下跌较多的公司权重则会逐渐下降。

这种现象可以称为**权重漂移** (weight drift)。所以更加准确地说，一个现实的等权指数通常是定期恢复等权的动态组合，而不是一个始终保持  $w_i = 1/N$  的静态组合。

如果一个行业拥有很多成分公司，它在等权指数中的行业总权重也可能很高。因此个股等权并不意味着行业等权，更不意味着每种风险来源也被平均分配。

另外，等权指数通常还意味着更高的再平衡需求。上涨较多的公司需要在下一轮重置时降低权重，相对落后的公司则需要提高权重。所以相对于市值加权，等权策略往往还会带来更高的换手率和交易成本，同时自然增加对较小成分公司的相对暴露。

### 几个真实指数

有了这些基本规则以后，再看几个平时经常听到的指数，就会发现它们实际上是完全不同的市场表示方法。

#### 例 6.60 (S&P 500).

S&P 500 的目标是表示美国大型股票市场，但它并不是每天把所有美国上市公司按照市值从大到小排列，然后机械地取前 500 名。

一家公司首先需要满足美国公司身份，上市地点，市场规模，自由流通市值和流动性等资格要求。对新加入公司还存在盈利要求。按照截至 2026 年 8 月使用的 S&P U.S. Indices 方法文件，新进入 S&P 500 的公司总市值门槛为 \$22.7 billion，最近一个季度的 GAAP 持续经营净利润需要为正，最近四个季度合计也需要为正 [SP b]。这类门槛会随方法文件更新，所以这里记录的是当前版本下的规则状态，不是一个永远固定的常数。

但满足这些条件并不意味着自动进入指数。S&P 500 由指数委员会持续维护，并不存在一个每季度重新进行市值排名以后机械取前 500 名的完整重构过程。

这里的“500”更准确地说是 500 家公司。某些公司可能同时存在多个符合条件的上市股份类别，因而指数中的证券行数量可以超过 500。

公司进入指数以后，S&P 500 主要按照自由流通调整市值加权。

所以 S&P 500 更准确的说法不是“美国市值最大的 500 只股票”，而是按照 S&P 方法选择和维持的一组美国大型上市公司。

Nasdaq 则很适合说明另一种常见混淆。

#### 例 6.61 (Nasdaq Composite 和 Nasdaq-100).

Nasdaq 首先是一个证券交易市场以及相关金融基础设施的名称，并不是某一个唯一的指数。

**Nasdaq Composite** 是一个范围很广的指数，大体覆盖 Nasdaq Stock Market 上市的合格普通类型证券，因而更接近“Nasdaq 上市股票整体表现如何”。

**Nasdaq-100** 则是另一套规则。按照 2026 年的方法文件 [Nas]，它设计上用于度量 Nasdaq 上市的 100 家大型非金融公司，并采用修正市值加权。

所以 Nasdaq-100 并不是“100 家科技公司”。科技企业在其中占比很高，但消费，通信，医药和其他非金融企业同样可以进入。

它的年度重构也不是简单把市值前 100 名一刀切下来。规则中存在缓冲机制，以避免排名处于边缘的公司因为短期市值波动频繁进出指数。

此外，2026 年现行方法还允许某些满足条件并进入现有成分市值前列的公司通过 Fast Entry 或 3 月，6 月，9 月季度调整加入指数，而不要求同步删除另一家公司。因此指数在某些时点可以暂时超过 100 家公司。

所以一个指数真正是什么，不能只看名字。真正决定它行为的是背后的 methodology。

### S&P 500 Equal Weight: 等权不是静态状态

S&P 500 Equal Weight 很适合把前面的概念放进一个真实市场里看。它使用和 S&P 500 相同的公司集合，但不会按照公司的自由流通市值决定权重，而是在季度再平衡时让每家公司重新获得近似相同的目标权重。

如果指数包含约 500 家公司, 每家公司的目标权重大致就是 1/500, 也就是约 0.2%.

这里说的是**公司权重**, 而不是每一条上市证券行的权重. 如果一家成分公司有多个股份类别同时进入指数, 这家公司总共获得一份等权目标, 再按照不同股份类别的自由流通市值分配到各证券行.

#### 注 6.62.

S&P 500 Equal Weight 中的 “Equal Weight” 不意味着任何时刻每家公司都严格保持 0.2% 左右.

它只是按照季度规则周期性恢复等权. 在两次再平衡之间, 公司价格继续变化, 因而权重也会继续漂移.

所以理解一个指数不能只看加权规则, 还必须同时看再平衡规则.

2026 年 6 月这一轮季度再平衡可以作为一个具体例子. 2026 年第二季度, 一些 AI, 半导体, 存储以及其他硬件相关股票经历了一轮很强的行情. 3 月季度重置以后, 这些涨幅较大的公司价格继续向上时, 因而即使是在 S&P 500 Equal Weight 中, 它们的实际权重也会随着价格上涨自然向上漂移.

所以不能把 Equal Weight 想成 “整个季度都只有 0.2% 的半导体股票”. 它同样会在两次再平衡之间逐渐增加对赢家的实际暴露.

2026 年 6 月这一轮季度重置使用 6 月 10 日的收盘价格作为重新计算指数股数的价格参考. 需要特别注意, 6 月 10 日只是用于计算下一轮目标指数股数的参考日, 并不是说指数在这一天已经完成了调仓.

按照 S&P Dow Jones Indices 在 2026 年 6 月 5 日发布的公告 [SP 26], 当季 S&P 500 的成分变化在 2026 年 6 月 22 日开盘前生效: Marvell 和 Flex 加入, Pool 和 Campbell's 被删除. 因为 2026 年 6 月 19 日是 Juneteenth, 美国主要股票市场休市, 所以这一轮调整的交易执行窗口也和普通季度稍有不同.

这次再平衡会把此前因为价格上涨而明显偏离目标等权的公司重新向相同公司权重拉回. 但是这里不能简单推出 “科技行业权重因此下降”.

一方面, 若干此前上涨较快的科技和硬件公司确实会因为重新恢复公司等权而降低个股权重; 另一方面, 这一轮成分变化本身又新增了 Marvell 和 Flex 两家 Information Technology 公司. 整个科技板块最终的总权重变化还取决于其他成分的价格漂移以及新增公司的影响.

所以只观察几只科技股票的个股权重变化, 不能直接推导整个行业暴露发生了什么变化.

类似地, 如果在某个后续窗口中观察到 Equal Weight 相对于普通 S&P 500 跑赢或者跑输, 也不能不加分解地解释成 “季度再平衡成功躲过了半导体回调” 或者 “季度再平衡拖累了收益”. 两个指数的相对收益本来就同时受到观察窗口, 收益口径, mega-cap 集中度, 行业配置, 公司规模倾斜, 再平衡前的权重漂移以及再平衡以后不同股票表现的影响.

如果真正想识别 6 月季度调整贡献了多少收益, 更合理的办法是先说明自己想识别的是**整套季度调整还是在成分不变时单纯恢复等权的影响**. 前者会同时包含 Marvell, Flex 加入以及 Pool, Campbell's 删除; 后者则需要构造一个保持原成分集合不变的额外反事实.

例如对于整套季度调整, 可以构造一个反事实组合: 假设 6 月不进行季度重置, 而是继续持有 6 月再平衡以前已经发生权重漂移的 Equal Weight 组合. 于是可以比较

$$R^{\text{EW,actual}} - R^{\text{EW,no rebalance}},$$

把它理解成对于这轮季度调整本身贡献的一种近似观察.

另一个比较是

$$R^{\text{EW,no rebalance}} - R^{\text{Market Cap}}$$

则更多保留了原本存在的公司规模, 行业以及集中度差异.

所以 2026 年 6 月这个案例真正值得学习的并不是 “Equal Weight 更好”, 而是一个现实指数的收益来自权重规则, 权重漂移, 再平衡以及之后市场路径的共同作用. 单纯比较两个指数最后谁涨得更多, 并不足以识别其中任何一个机制的因果贡献.

这里还需要再加一层区分. 实际跟踪 S&P 500 Equal Weight 的 ETF 或基金会拥有自己的真实持仓. 基金持仓和指数权重通常非常接近, 但并不是同一个对象. 基金还会受到现金, 费用, 申购赎回, 交易时间以及跟踪误差的影响.

所以如果以后拿某只 Equal Weight ETF 的历史持仓研究 Equal Weight, 必须明确说明这些数据是基金持仓的观察, 而不是直接把它当成指数提供商公布的精确指数权重。

### 市场不是指数

到这里已经可以更加准确地理解“今天美国股市上涨了 1%”这种说法。真正上涨 1% 的往往只是某一个具体指数。

S&P 500, Nasdaq Composite, Nasdaq-100, Dow Jones 和 S&P 500 Equal Weight 完全可能在同一天给出明显不同的市场表现, 因为它们选择的资产范围, 成分, 权重和维护规则本来就不同。

#### 注 6.63.

一个真实股票市场在时刻  $t$  可以包含成千上万项价格

$$S_t^1, \dots, S_t^n.$$

指数则通过一套选择, 加权和和维护规则, 把这个高维市场状态压缩成一个数值  $I_t$ .  
所以

$$\text{Market} \neq \text{Index}.$$

指数是一种观察和表示市场的方法, 而不是市场本身。

### 价格指数, 总收益指数与净总收益指数

即使指数选择了完全相同的公司和权重, 我们还需要决定到底怎样处理股息。

#### 定义 6.64.

**价格指数** (price index) 主要反映成分资产市场价格本身的变化。

**总收益指数** (total return index) 则进一步按照指数规则假设现金股息重新投资, 从而把股息纳入指数收益。

**净总收益指数** (net total return index) 还会进一步按照规定的税率假设扣除相应股息预提税。

比如一只股票从 \$100 跌到 \$98, 同时支付 \$4 股息。单纯价格收益率是  $-2\%$ , 但如果把股息也计算进去, 在暂时忽略其他因素时总收益率为

$$\frac{98 + 4 - 100}{100} = 2\%.$$

所以比较基金和指数的长期表现时, 必须先确认使用的是价格收益, 总收益还是净总收益。否则看起来在比较同一个 benchmark, 实际上计算的根本不是同一个量。

### 6.4.3 从指数到基金和 ETF

#### 指数本身不能直接持有

指数本身仍然只是一套规则和由此计算出来的数值, 所以投资者不能像买一家公司股票那样直接“持有十股 S&P 500”。

但这并不意味着投资者只能通过持有全部底层证券才能获得指数敞口。

上一节已经看到, 股指期货可以提供近似线性的指数暴露; 指数期权可以提供非线性的指数暴露; 市场中还存在其他能够交换指数收益的衍生品。

如果投资者希望长期持有一个接近指数本身收益的现货型组合, 一种最常见的方法则是指数基金。

#### 指数基金与跟踪误差

#### 定义 6.65.

**投资基金** (investment fund) 是指将投资者资金集中起来, 按照规定的投资目标和管理方式持有一组资产, 并通过基金份额把相应经济权益分配给投资者的一种资产管理结构。



**定义 6.66.**

**指数基金** (index fund) 是指以跟踪某个指定指数的表现为主要目标的投资基金。

最直接的做法当然是按照指数成分和权重完整买入所有底层证券, 也就是完整复制. 如果成分很多或者部分证券不容易交易, 基金也可以通过抽样等方法建立一个近似组合. 某些产品还可以借助衍生品获得指数敞口.

所以指数基金真正追求的是基金收益尽量接近目标指数收益, 而不是让基金和指数成为同一个东西.

**定义 6.67.**

本文把某一期间基金收益与指数收益之差定义为**跟踪差异** (tracking difference):

$$TD_{0,T} = R_{0,T}^{\text{fund}} - R_{0,T}^{\text{index}}.$$

如果进一步研究一系列期间超额收益的波动程度, 可以定义相应的**跟踪误差** (tracking error):

$$TE = \text{sd} \left( r_t^{\text{fund}} - r_t^{\text{index}} \right).$$

Tracking difference 关心一段时期以后基金究竟领先或者落后基准多少; tracking error 关心这种偏离在各期有多不稳定. 实际报告 tracking error 时, 还需要说明使用日度, 周度还是月度收益以及是否进行年化.

管理费, 交易成本, 税收, 现金拖累, 复制误差, 公司行动处理以及证券借贷收入等因素, 都可能使基金最终表现偏离指数.

**例 6.68.**

S&P 500 是一个指数.

市场上可以同时存在许多目标都是跟踪 S&P 500 的基金. 这些基金由不同机构管理, 拥有不同费用, 规模, 交易结构和具体执行方法, 但都可以使用同一个 S&P 500 作为 benchmark. 所以

$$\text{Index} \neq \text{Index Fund}.$$

**ETF**

基金本身还可以采用不同的组织和交易方式. ETF 就是其中非常重要的一种.

**定义 6.69.**

**交易所交易基金** (exchange-traded fund, ETF) 是指基金份额能够在交易所二级市场买卖, 并通常通过授权参与者的大额创建和赎回机制调节份额供给的一类投资基金.

ETF 首先是一种基金产品结构和交易形式, 并不是“指数”的另一个名字. 单纯“在交易所交易”还不足以刻画 ETF, 因为封闭式基金等产品也可以在交易所交易; ETF 的关键额外结构是基金份额可以通过创建和赎回机制, 在一级市场与底层资产篮子或者现金之间进行大额转换.

一个 ETF 可以跟踪股票指数, 也可以持有债券, 商品或者其他资产; 可以采用被动管理, 也可以采用主动管理. 反过来, 指数基金也不一定必须采用 ETF 结构. 它可以是普通共同基金, 也可以是 ETF.

所以这里最好始终保持

$$\text{Index} \neq \text{Index Fund} \neq \text{ETF}.$$

这里的  $\neq$  只是说这些词不能互相替换, 不是说它们构成互斥分类. 一只跟踪指数的 ETF 可以同时是指数基金和 ETF; 一只主动管理 ETF 则是 ETF, 但不是指数基金.

**例 6.70.**

一只跟踪 Nasdaq-100 的 ETF, 并不等于 Nasdaq-100 本身.

投资者买入的是基金份额. 基金通过自己的资产和管理机制尝试获得接近 Nasdaq-100 的



投资表现.

Nasdaq-100 是指数; Nasdaq Composite 是另一套更加广泛的指数; Nasdaq Stock Market 又是证券交易市场本身. 这些对象彼此联系, 但处在完全不同的层次.

这样一来, 原来分散在许多公司里的股票篮子就经过了几次转换:

股票篮子 → 可以表示的指数 → 可以跟踪的基金 → 可以盘中交易的基金份额.

衍生品则提供了另一条路径. 股指期货和指数期权不需要持有全部成分证券, 而是直接把指数水平写进合约现金流. 所以同一个指数既可以成为基金的跟踪基准, 也可以成为衍生品的结算标的.

### ETF 的净值和市场价格

ETF 自己持有资产, 所以可以计算基金的净资产价值.

#### 定义 6.71.

**基金净值** (net asset value, NAV) 是指基金资产价值扣除负债以后, 按照基金份额数量计算得到的每份净资产价值.

如果基金资产价值为  $A_t$ , 负债为  $L_t$ , 份额数量为  $N_t$ , 那么

$$NAV_t = \frac{A_t - L_t}{N_t}.$$

这里需要注意时间. ETF 份额在交易时段中可以像股票一样持续成交, 所以它具有不断变化的盘中市场价格. 但基金的官方 NAV 通常是在每个交易日结束以后根据规定方法计算一次.

因此盘中真正同时存在的更接近三个不同的量: ETF 的实时市场价格, 根据底层资产当前报价估算的盘中参考价值, 以及交易日结束以后正式计算的官方 NAV. 它们彼此相关, 但不是同一个数字.

如果 ETF 市场价格相对于底层资产价值出现明显偏离, 市场中的创建和赎回机制会提供重要的套利力量.

#### 定义 6.72.

**授权参与者** (authorized participant, AP) 是指和 ETF 基金签订相应协议, 能够按照规定直接进行大额基金份额创建和赎回的机构.

普通投资者通常只是在二级市场买卖 ETF 份额, 并不能直接拿一股 ETF 向基金要求赎回底层证券.

#### 例 6.73 (ETF 的创建与套利).

假设一只 ETF 的盘中市场价格明显高于其底层资产篮子的可交易价值, 而且价差已经足以覆盖交易, 融资和创建成本.

AP, 或者能够通过 AP 完成创建的套利机构, 就可能买入规定的资产篮子, 创建新的 ETF 份额, 再把 ETF 份额在二级市场中卖出.

如果 ETF 明显折价, 相反方向的赎回和套利也可能发生.

这些交易会给 ETF 市场价格和底层资产价值之间建立一股收敛力量.

不过这里同样不存在没有摩擦的恒等式. 交易成本, 融资成本, 税收, 做空约束以及底层资产本身的流动性都会形成一个现实中的无套利区间. 很小的价格差异并不会自动值得交易.

当市场剧烈波动或者底层资产缺乏可靠即时价格时, ETF 的市场价格也可能暂时明显偏离官方 NAV 或者盘中估算价值.

这里还需要避免另一种机械理解: 二级市场中每发生一笔 ETF 交易, 并不意味着基金必须同步买卖一篮子底层资产. 买方和卖方完全可能只是在交换已经存在的 ETF 份额. 只有当二级市场供求最终通过创建赎回传导到一级市场, 或者基金因为指数调整和现金管理需要交易时, 才可能进一步产生相应的底层资产订单. 即使发生创建和赎回, AP 也可能使用库存, 借券, 现金篮子或者其他执行安排完成操作, 并不必然对应一笔同步而完整的底层篮子买卖.

### 6.4.4 被动管理与价格形成

这里还需要拆开两个经常被一起使用的概念。

#### 定义 6.74.

**被动管理** (passive management) 是指基金以跟踪某个预先指定的基准为主要目标, 而不是持续依靠主观证券选择主动偏离并试图战胜该基准的一类管理方式。

被动管理描述的是**基金相对于 benchmark 怎样行动**, 并不自动描述持有这只基金的投资者本人。

一个投资者完全可以长期持有主动管理基金而几乎从不交易; 也可以每天择时买卖指数 ETF。后一种情况下, 他使用的是被动管理产品, 但自己的投资策略显然可以非常主动。

同样, “按照公式交易”也不等于被动管理。一个系统化多因子基金即使所有交易都由固定算法决定, 如果它的目标就是主动偏离 benchmark 并获得超额收益, 仍然属于一种主动策略。

所以这里所谓被动, 始终是**相对于一个已经选择好的基准而言**。

#### 注 6.75.

被动管理并没有消灭投资决策, 而是改变了决策发生的位置。

基金不再持续主动判断每家公司应该超配还是低配, 但 benchmark 本身仍然包含样本范围, 成分筛选, 权重规则, 缓冲机制, 再平衡频率以及治理方式。S&P 500 甚至还包含指数委员会的维护判断。

所以投资者选择一个被动指数基金, 实际上是在主动决定自己愿意服从哪一套指数规则。

### 被动资金仍然参与价格形成

一个市值加权指数基金通常不会因为基金经理认为某家公司高估, 就主动把这家公司从 6% 减到 3%。在这个意义上, 被动资金对于证券之间的相对估值判断确实更加有限。

但这并不意味着被动资金站在市场价格形成之外。基金的申购和赎回, 指数成分变化, 定期再平衡以及投资者自身的资金配置都会产生真实订单。这些订单和主动投资者, 做市商, 套利者以及其他市场参与者的订单一起进入市场。

所以更加准确的关系是

信息, 判断, 约束与资金流 → 全部市场订单 → 边际成交价格。

市场价格形成以后, 市值加权指数又会利用这些价格计算公司市值和指数权重; 指数权重再决定大量指数基金应该怎样持仓。于是市场和指数之间逐渐形成一个反馈关系:

Market → Index → Fund Position → Market.

#### 注 6.76.

指数最初只是市场的一种表示方法, 但当大量真实资金开始按照指数规则行动以后, 指数本身也会成为市场机制的一部分。

这并不意味着指数决定企业长期价值, 也不意味着一次指数纳入必然造成永久价格上涨。它只是意味着一套原本用于描述市场的规则, 可以通过真实资金流重新进入被描述的市场。

### 6.4.5 从指数走向债券

到这里我们已经看到, 把一只股票扩展成一个高度分散的股票组合以后, 单个企业对于整个组合的影响通常能够明显下降。

但分散化并没有把股票变成没有风险的资产。经济衰退, 利率变化, 融资条件和整体风险偏好的变化仍然可能让大量公司一起下跌。而且无论我们持有一只股票还是五百家公司的股票组合, 股东主要持有的仍然是企业的**剩余索取权**。

所以接下来从股票走向债券, 并不是从“有风险资产”简单走向“低风险资产”, 而是从一种金融权利走向另一种金融权利。

股票主要代表对于企业剩余现金流和剩余价值的索取权; 普通债券则会把本金, 利息, 支付顺序以及到期时间更多地写进合同。投资者因此放弃一部分不受上限约束的企业上行, 换取更加明确并且通常拥有更高偿付顺序的合同请求权。

但合同写清楚现金流,并不意味着这些现金流一定能够实现。违约,利率,通胀,再投资和流动性风险仍然存在。

所以下一节真正需要讨论的不是“怎样把风险继续降到零”,而是当金融权利从企业剩余索取权变成合同请求权以后,风险怎样逐渐转化成信用风险,期限风险以及利率风险。

这会把我们带到债券,美债以及利率。

## 6.5 债券,美债与利率

回到融资关系这条主线,前面介绍股票时,一个主体获得资金的办法是出售一部分权益。不过如果一个主体需要资金,还有另一种更加直接的办法:借钱。

最简单的借款关系就是投资者今天先把一笔钱交给借款人,借款人承诺按照事先约定的规则在未来还钱。当这种债权关系被标准化并做成能够继续交易的证券以后,我们就得到了债券。

固定收益,美债市场以及国债基差交易的背景主要参考 [AS23; BK21; BKM23; CME24; TS11; US a; US b; US c]。

### 定义 6.77.

**债券 (bond)** 是指发行人为筹集资金而发行的一类债务证券。债券持有人向发行人提供资金,并取得按照债券合约规定在未来收取本金,利息或者其他支付的权利。

所以债券和股票代表的是两种很不一样的融资关系。股东取得的是对于企业剩余价值的一部分索取权;债券持有人取得的则主要是一组事先约定好的债权支付规则。从支付结构看,这一步把权益资产中很大一部分经营结果不确定性先收束成了合约支付规则。

这里说的是“支付规则”,而不一定是完全确定的现金流。对于最普通的固定利率债券,只要发行人没有违约或者提前赎回,未来票息和本金通常可以事先确定;但是浮动利率债券的票息可以随着参考利率变化,TIPS 的支付会受到通胀影响,可赎回债券可能提前结束,可转换债券的最终经济结果还可能和股票价格发生关系。

所以

债券规定支付规则  $\neq$  所有未来现金流都已经确定。

一张普通债券通常会规定几个最基本的东西:最终需要偿还的本金称为**面值** (face value 或 par value),最终偿还的时刻称为**到期日** (maturity),在到期以前定期支付的利息称为**票息** (coupon),票息与面值之间的比例则称为**票面利率** (coupon rate)。

债券之间还可能具有不同的清偿顺位。如果发行人最终无法偿还全部债务,不同债权人能够按照什么顺序获得偿付会直接影响债券价值。债券契约还可能包含各种 covenant,限制发行人继续举债,转移资产或者进行其他可能损害债权人利益的行为。这些制度细节以后遇到具体信用债时再展开。

### 6.5.1 货币的时间价值与零息债券

如果有人今天向我们借 \$100,却只承诺十年以后还回 \$100,大多数人通常不会愿意接受。

一个很直接的原因是通胀。如果未来物价上涨,那么十年后的 \$100 所能够购买的东西可能远少于今天的 \$100。不过即使完全没有通胀,今天的钱和未来的钱仍然不是同一个经济对象:今天拿在手里的资金可以立即消费,也可以投入其他资产获得收益;把它借给别人,就意味着在这段时间里面放弃了这些其他用途。

所以利率首先可以理解成**跨时间交换资金的价格**。如果今天的 \$100 一年以后按照 5% 的利率增长为 \$105,那么反过来看,一年以后确定得到的 \$100 今天就只值大约  $100/1.05$ 。从今天走向未来叫复利,从未来折回今天叫贴现,两者是同一个过程的两个方向。

通胀当然会参与利率的形成。从非常粗略的角度来看,名义利率中包含了实际利率和对于未来通胀的补偿。不过这并不意味着债券收益率一定高于最终实现的通胀率;现实中完全可能出现负的实际利率。

为了把这种跨时间交换进一步数学化,最简单的对象其实并不是一张复杂的票息债券,而是零息债券。

**定义 6.78.**

**零息债券** (zero-coupon bond) 是指在到期以前不支付票息, 而只在到期时支付约定金额的债券.

在最简单的无违约模型中, 令  $P(t, T)$  表示时刻  $t$  一项在时刻  $T$  确定支付 1 单位计价货币的零息债券价格. 固定当前时刻  $t$  和到期日  $T$  后, 也常把它称为从  $t$  到  $T$  的**曲线贴现因子**. 特别地,  $P(T, T) = 1$ .

所以  $P(t, T)$  回答的其实就是:

时刻  $T$  的一块钱, 在时刻  $t$  值多少钱?

固定今天的时刻  $t$ , 让到期日  $T$  不断变化, 就会得到整条  $T \mapsto P(t, T)$ . 这条曲线比单独一个“市场利率”更基础, 因为不同时间收到的现金流原则上应该使用各自对应的贴现因子.

这里的贴现因子是当前价格曲线上的一个对象. 如果以后看到沿某条未来利率路径累计出来的  $\exp(-\int_t^T r_s ds)$ , 那是另一个随机贴现因子; 二者在具体模型和测度选择下才会发生关系.

例如一张固定息债券在  $T_1, \dots, T_n$  支付固定票息  $C_1, \dots, C_n$ , 并在  $T_n$  额外偿还本金  $F$ . 如果暂时不考虑违约, 提前赎回和其他嵌入期权, 那么其价格原则上应该写成

$$B_t = \sum_{i=1}^n C_i P(t, T_i) + F P(t, T_n).$$

也就是说, 一张票息债券可以被看成许多不同期限的零息现金流叠加在一起.

**注 6.79.**

这里的  $P(t, T)$  已经是一个金融模型中的抽象对象.

真实市场里面并不存在一条脱离交易制度, 抵押方式和资产选择以后仍然唯一存在的“无风险贴现曲线”. 根据我们研究的问题不同, 现实中可能使用美债, OIS 以及其他工具来建立不同的基准曲线.

因此这条曲线仍然是为当前问题选择的模型对象, 而不是现实市场中脱离制度与工具以后唯一存在的实体.

**6.5.2 债券价格, YTM 与市场报价**

有了贴现曲线以后, 我们再回过头来看日常市场里面更加常见的债券收益率.

首先需要特别区分**票面利率**和**收益率**. 假设一张面值 \$1000 的固定息债券每年支付 \$50, 那么它的票面利率就是 5%. 这个数字是债券合约的一部分, 并不会因为二级市场价格每天变化而自动改变.

但是债券本身可以继续交易. 如果这张债券在市场上只需要 \$900 就可以买到, 新投资者显然不是花 \$1000 去获得这些未来现金流. 所以他的投资回报不能再简单地由 5% 这个票面利率描述.

市场中经常使用的一个量是**到期收益率** (Yield to Maturity, YTM). 它并不是债券价格背后最基本的对象, 而是给定今天的债券价格和未来现金流以后, 反解出来的一个统一内部收益率.

比如在忽略日计数和结算细节, 并把  $B_t$  理解成全价 (dirty price) 的简化约定下, 若每年复利  $m$  次, YTM  $y$  大概就是满足

$$B_t = \sum_{i=1}^n \frac{C_i}{(1 + y/m)^{m(T_i - t)}} + \frac{F}{(1 + y/m)^{m(T_n - t)}}$$

的那个  $y$ .

这里真正发生的是: 原本每一个  $T_i$  都应该具有自己的贴现因子  $P(t, T_i)$ , 而 YTM 强行用一个统一的数字  $y$  把整条期限结构压缩成了一个数.

因此

YTM = 债券价格的一种摘要,

而不是债券定价最底层的对象.



这也解释了为什么固定现金流债券的价格和收益率通常反向变化. 如果市场中其他相近债券已经能够提供更高的收益率, 原来按照较低条件支付现金流的债券就需要降低价格才能重新具有吸引力.

#### 注 6.80.

YTM 并不是投资者未来必然能够实现的收益率.

如果投资者提前出售债券, 发行人发生违约或者提前赎回, 又或者中间收到的票息无法按照相同的收益率继续投资, 最终实现的持有期收益率就可能和最初观察到的 YTM 不同.

债券实际交易时还有一个非常基础的报价问题. 合同票息仍然是在票息支付日支付; 但在两个票息日之间, 报价和结算制度会按照日计数规则把本期票息在买卖双方之间分配, 这部分约定金额称为应计利息 (accrued interest). 因此固定息债券通常需要区分**净价** (clean price) 和**全价** (dirty price), 二者满足

$$\text{Dirty Price} = \text{Clean Price} + \text{Accrued Interest}.$$

市场屏幕上看到的债券报价经常是 clean price, 而实际结算时需要支付的金额还会包含相应的 accrued interest. 所以以后看到“债券报价是 99.5”时, 也不能自动认为真正交割一百美元面值债券只需要支付 \$99.5.

### 6.5.3 即期利率, 远期利率与期限结构

从  $P(t, T)$  出发, 我们终于可以更加准确地讨论所谓的“利率”.

如果采用连续复利约定, 可以定义从时刻  $t$  到  $T$  的**即期利率**或者**零息利率**  $y(t, T)$ , 使得

$$P(t, T) = e^{-y(t, T)(T-t)}, \quad y(t, T) = -\frac{\log P(t, T)}{T-t}.$$

所以  $y(t, T)$  描述的是: 在时刻  $t$ , 一笔从现在一直锁定到  $T$  的零息投资对应怎样的年化连续复利收益率.

进一步, 如果  $T \mapsto P(t, T)$  足够光滑, 可以定义**瞬时远期利率**

$$f(t, T) := -\frac{\partial}{\partial T} \log P(t, T),$$

于是  $P(t, T) = \exp(-\int_t^T f(t, u) du)$ . 特别地, 瞬时短期利率可以写成  $r_t = f(t, t)$ .

于是我们平常口语中统称为“利率”的东西, 实际上已经至少分成了三个层次:  $r_t$  对应短期利率,  $y(t, T)$  对应从今天直到某个期限的即期利率, 而  $f(t, T)$  对应当前价格体系隐含的不同未来区间之间的远期利率.

这里的远期利率是当前债券价格体系隐含的交换比率, 并不自动等于真实世界中未来短端利率的条件期望. 期限溢价, 测度选择以及凸性调整等因素, 都可能让

$$f(t, T) \neq \mathbb{E}_{\mathbb{P}}[r_T | \mathcal{F}_t].$$

现实市场里面因此也不存在唯一的一条“收益率曲线”.

#### 注 6.81.

至少需要区分三种经常出现的曲线.

**平价收益率曲线** (par yield curve) 描述不同期限的平价票息债券需要具有怎样的票面利率.

**零息收益率曲线** (zero-coupon curve) 或**即期曲线** (spot curve) 描述  $T \mapsto y(t, T)$ .

**远期曲线** (forward curve) 则描述  $T \mapsto f(t, T)$ .

它们彼此相关, 但不是同一个对象. 在无套利定价里面, 更基础的通常是零息债券价格  $P(t, T)$  以及由它确定的贴现曲线.

比如美国财政部日常公布的官方美债平价收益率曲线 (Treasury Par Yield Curve) 就是一条平价收益率曲线, 而不是直接观察得到的零息收益率曲线. 另一方面, 也可以利用市场上的票息债券价格进一步估计零息曲线和远期曲线.

长期和短期债券的收益率当然也没有理由完全相同。

把钱借出去三个月和锁定三十年是两件很不一样的事情。对于长期名义债券来说，投资者需要面对未来短期利率、通胀、经济环境以及资金机会成本的大量不确定性。

从一种常见的期限结构分解来看，长期收益率可以粗略写成“未来短期利率的平均预期 + term premium”。但这里的期限溢价 (term premium) 并不是市场屏幕上能够直接观察到的量，而是需要通过期限结构模型进一步分解出来的估计量，并且它甚至可能为负。

所以收益率曲线倒挂也不能简单翻译成“市场确定认为未来会降息”。更加准确地说，它可能同时来自未来短期利率路径的预期，term premium 的变化，以及债券供求和市场结构等其他因素。也就是说，

Yield Curve  $\neq$  唯一的市场预测。

债券期限越长，还有一个通常越重要的问题：对利率变化的敏感度。

如果暂时把债券价格看成某个收益率  $y$  的函数  $B(y)$ ，可以定义修正久期 (modified duration)

$$D_{\text{mod}} := -\frac{1}{B} \frac{\partial B}{\partial y}.$$

于是对于较小的收益率变化，有一阶近似

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y.$$

所以久期 (duration) 可以理解成债券价格对于利率变化的一阶敏感度。如果继续保留二阶项，就会出现凸性 (convexity)：

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y + \frac{1}{2} \text{Convexity}(\Delta y)^2.$$

实际风险管理里面还经常使用每基点价值 (DV01 或 PV01)，表示收益率变化一个基点 (basis point)，也就是 0.01% 时，债券或者整个头寸的价值大约变化多少。在最简单的局部近似下，其绝对值大约为  $BD_{\text{mod}} \times 10^{-4}$ 。

因此到期时间和利率风险也不是同一个概念。两张同样三十年到期的债券，如果票息结构不同，久期完全可能不同。对于零息债券来说，麦考利久期 (Macaulay duration) 才恰好等于其剩余到期时间。

现实中的整条期限结构并不会永远平行移动，所以单一久期仍然只是一个局部压缩。更细致的风险管理还可以进一步研究不同期限点各自的利率暴露。

#### 6.5.4 美债

在美元债券市场里面，最重要的一组债券就是美国国债。

##### 定义 6.82.

**美国国债** (U.S. Treasury Securities) 是指美国财政部为了给联邦政府融资而发行的一系列债务证券。

常见的可交易美债主要包括短期国债 (Treasury Bills)，中期国债 (Treasury Notes)，长期国债 (Treasury Bonds)，通胀保值债券 (TIPS) 以及浮息票据 (Floating Rate Notes, FRNs)。其中 Bills 主要位于短端，Notes 和 Bonds 提供更长期限的固定票息现金流，TIPS 把本金与通胀联系起来，FRNs 的票息则会随参考利率变化。

我们并不需要在这里逐一记住它们所有的发行制度；更重要的是理解美债在金融市场里面承担的几个不同角色。

这里还有一种非常适合连接数学模型和真实市场的工具——STRIPS。

##### 例 6.83 (STRIPS).

美债市场中的 STRIPS 可以把符合条件的 Treasury Note, Treasury Bond 或 TIPS 的本金和每一笔利息支付拆开，使这些现金流分别成为独立交易的零息证券。



比如一张还剩十年到期, 每半年付息一次的 Treasury Bond, 原本包含二十笔票息和最后一笔本金. 拆分以后就可以得到二十一个具有不同支付日或者支付性质的零息证券.

因此 STRIPS 可以被看成真实美债市场中和我们前面抽象的零息债券非常接近的一类工具. 接下来回到美债在金融市场里面承担的角色. 这里至少需要分成两个层次来看.

### 美元固定收益市场的基准资产

美债构成了美元固定收益市场最重要的基准之一. 投资者在评价一张十年公司债时, 通常不会直接拿它去和某个隔夜利率比较, 而会首先寻找相近期限的基准曲线, 再问承担额外信用和流动性风险究竟需要多少补偿.

不过美债收益率并不等于某个脱离市场结构以后仍然存在的抽象无风险利率. 美债自身具有极高的流动性, 安全资产属性以及抵押品价值, 这些特殊用途本身就可能使投资者愿意接受更低的收益率. 所以后面模型里面出现的无风险利率 (risk-free rate) 不能机械地理解成“屏幕上的十年美债收益率”.

美国财政部日常公布的美债收益率曲线 (Treasury yield curve) 本身也需要稍微注意. 官方曲线是一条平价收益率曲线, 利用市场中的指示性买方报价拟合得到; 相应的固定期限美债利率 (Constant Maturity Treasury rates) 也是从这条曲线上读取或者插值得到的标准化期限点, 并不意味着市场里面恰好存在一只债券以这个到期收益率 (YTM) 成交. 如果真正要做无套利定价, 我们往往还需要进一步建立适合当前问题的零息曲线 (zero curve).

长期名义美债还有一个特别重要的风险来源—通胀. 普通 Treasury Note 或 Treasury Bond 承诺的是名义美元支付, 所以即使美国政府最后按照合同足额偿付, 长期通胀仍然可能明显侵蚀这些现金流的实际购买力.

TIPS (Treasury Inflation-Protected Securities) 就是在处理这一问题. TIPS 的票面利率在发行时确定, 但是其本金会随着通胀指标调整, 而票息又按照调整后的本金计算, 所以实际票息支付也会随着通胀变化. 通缩期间本金可以向下调整, 不过如果持有到期, 最终偿还本金不会低于发行时的原始面值; 这并不保证二级市场买入价格本身不会亏损.

因此同期限普通美债和 TIPS 的收益率差经常被用来观察通胀补偿 (inflation compensation). 但这个差值并不能简单等同于真实的预期通胀, 因为其中还可能混入通胀风险溢价, TIPS 流动性溢价以及市场供求等因素.

### 美债作为抵押品

美债也是现代美元金融体系中最重要的高质量抵押品之一.

如果一家金融机构需要现金, 直接无抵押地借钱给它当然会让出借人承担很大的交易对手风险. 但是如果机构同时提供一项信用质量高, 市场价格透明而且能够迅速出售的资产作为抵押, 出借人面对的风险就会明显降低.

美债恰好具有这些特点. 所以金融机构持有美债以后, 并不意味着相应资金完全被“锁死”在债券里面; 美债还可以被拿出来作为抵押品获得融资.

最典型的制度就是后面会详细介绍的回购协议 (repurchase agreement, repo). 法律形式上, repo 是一方出售证券取得现金, 同时约定未来按照约定价格把证券买回来; 从经济效果来看, 它非常接近一笔以证券作为抵押的短期融资.

为了控制抵押品价格变化和交易对手风险, repo 可以使用 haircut 或 margin, 也就是抵押物价值需要高于实际取得的融资额. 如果抵押品市值为  $V_0$ , 实际取得的现金为  $C_0$ , 可以粗略写成

$$h = 1 - \frac{C_0}{V_0}.$$

较低的 haircut 会让同一笔现券头寸占用更少自有资金, 但也意味着抵押品价格, 融资利率和展期条件发生变化时, 交易者更容易被迫补充资金或者缩减头寸.

现实中的 Treasury repo 分成多个不同市场层次, haircut 的具体做法并不统一: 有些市场长期使用正 haircut, 另一些双边交易中也大量存在零 haircut, 并通过净额结算, 组合保证金以及其他机制管理风险.

所以美债同时具有资产和抵押品两层价值. 银行, 券商, 做市商, 对冲基金以及清算体系中的大量交易都需要高质量抵押品, 而美债正是整个体系中最重要抵押资产之一.

## 国债基差交易

从这个角度看, 前面在衍生品节提到的国债基差交易就不再只是一个期货例子, 而是现金美债, 国债期货和 repo 融资共同构成的相对价值交易。

**现券美债** (cash Treasury) 是已经发行并在现券市场交易的国债; **国债期货** (Treasury futures) 则是围绕未来交割或者结算建立的标准化合约。二者都暴露于相近的美债利率风险, 但并不是同一种工具。

一份国债期货通常对应一篮子符合条件的可交割债券, 而不是只对应某一只指定现券。期货空头可以在规则允许的范围内选择实际交割的债券; 不同债券的票息和期限差异, 又需要通过 **conversion factor** 调整。CME 对 conversion factor 的说明可以看作理解这类合约交割制度的基础材料 [CME24]。

对于一只候选交割券, 市场上常见的原始基差可以示意性地写成

$$b_t^{\text{raw}} = P_t^{\text{cash, clean}} - CF F_t^{\text{fut}},$$

其中 CF 是 conversion factor。这里的符号约定是“现券价格减去调整后的期货价格”; 如果国债期货相对于现券偏贵, 这个  $b_t^{\text{raw}}$  反而可能变小甚至为负。Federal Reserve 讨论 option-adjusted basis net of carry (OABNOC) 时使用的是收益口径, 其中正 basis 表示期货相对现券偏贵, 适合做多现券并做空期货的 long basis trade [Gli+24]。所以不同资料里的 basis 符号并不总是同向, 阅读时必须先看清楚定义。

真正用于比较的净基差还需要进一步处理应计利息, 持有期间票息, repo 融资成本, 交割时间以及空头拥有的交割选择权。因此某只现券和期货的原始报价不能直接相减以后就叫作无风险利润。

所谓 basis, 本质上是在比较持有并融资一只可交割现券的经济成本, 和通过期货取得相近交割暴露的经济成本。

一种典型结构是: 当交易者认为国债期货相对于可交割现券偏贵时, 买入现券, 同时卖出相应国债期货。为了避免占用全部现券购买资金, 交易者再把买入的美债放进 repo 市场, 用这项美债作为抵押借回大部分现金。于是头寸大致可以写成

$$\begin{aligned} &+ \text{cash Treasury,} \\ &- \text{Treasury futures,} \\ &\text{repo-financed cash position.} \end{aligned}$$

现券多头和期货空头会抵消相当一部分共同的利率方向风险。交易者主要押注的不是“美债整体上涨还是下跌”, 而是两种高度相关的价格关系会向交割规则和持有成本约束允许的水平收敛。

问题在于, 价差越小, 交易越需要依赖杠杆才能得到足够可观的收益。而交易能不能等到收敛, 取决于中间路径。

现券需要持续获得 repo 融资; 期货空头需要每日结算变动保证金; repo 出借人还可能提高 haircut, 提高融资利率, 要求补充抵押品或者拒绝展期。这些现金流并不会因为“现券和期货长期来看应该收敛”就自动彼此抵消。

如果压力期间基差先向不利方向偏离, 现金流压力可能从不同腿上出现: 若期货价格相对上升, 期货空头需要支付变动保证金; 若现券价格相对下跌, repo 出借人可能要求补充抵押品或者提高 haircut; 若融资市场本身变紧, 交易者还可能无法按原条件展期 repo。为了取得现金, 他可能被迫卖出现券并买回期货空头。如果许多高杠杆交易者同时这样做, 去杠杆本身又可能继续压低现券相对价格, 推动基差进一步偏离。OFR, Federal Reserve 和 BIS 的相关研究都把 repo rollover, futures margin 和高杠杆去杠杆视为这类交易的重要脆弱性来源 [AS23; BK21; BKM23]。

$$\begin{aligned} &\text{adverse basis move} \longrightarrow \text{margin and funding calls} \longrightarrow \text{forced deleveraging} \\ &\longrightarrow \text{further adverse basis move.} \end{aligned}$$

所以国债基差交易并不是“因为有交割机制, 所以没有风险”的套利。它至少承担融资展期风险, repo 利率和 haircut 风险, 期货保证金流动性风险, 现券市场流动性风险, 交割券切换和模型误差, 以及被迫在收敛以前退出的路径风险。

这也是固定收益市场一个很重要的教训:

最终可能收敛  $\neq$  中间一定能够活下来。

这些问题已经开始进入美元资金市场本身。后面一节再正式讨论 repo, SOFR, 银行准备金以及美联储。

### 6.5.5 信用风险, 信用利差与 CDS

有了基准债券以后, 我们就可以进一步问: 为什么同期限的公司债通常需要提供更高的收益率? 这里不是继续降低风险, 而是在基准期限结构上逐层加回发行人的信用风险。

最明显的区别是**信用风险**。美国政府, 一家现金流稳定的大型企业和一家已经接近破产的企业, 最终按照合同偿还债务的能力不可能完全相同。

从非常粗略的角度来看, 一只公司债的收益率可以理解成基准收益率再加上一部分利差 (spread)。但这部分利差不能简单理解成“违约概率”。它还可能包含预期信用损失, 信用风险溢价, 流动性, 供求以及其他因素。

而且所谓“利差”本身也不是唯一的一种数字。

#### 注 6.84.

实际债券分析中必须同时说明利差的基准和计算方式。

G-spread 通常把债券 YTM 和插值得到的政府债收益率进行比较; I-spread 使用 swap curve 作为基准; Z-spread 则寻找一个统一利差加到整条 zero curve 上, 使折现后的现金流等于当前价格; 对于具有嵌入期权的债券, 还经常使用 OAS 来进一步处理期权价值。

所以“这只债券的信用利差是多少”如果不说明算法和基准, 本身并不是一个完全确定的问题。

为了进一步数学化信用风险, 可以把发行人违约本身看成一个随机事件。

令

$$\tau: \Omega \rightarrow [0, \infty]$$

表示发行人发生违约的时间, 称为**违约时间**。那么站在时刻  $t$ , 我们可以考虑  $\mathbb{P}(\tau > T | \mathcal{F}_t)$ , 也就是在当前信息下发行人能够存续到  $T$  的条件概率。

违约以后债权人通常也不是一定什么都拿不回来。这里需要先约定**回收率** (recovery rate) 的口径: 它可以是相对于面值, 违约前市值, 或某个无风险债券价值的回收比例。在固定了暴露口径和回收约定以后, 若回收比例记为  $R$ , 相应的**违约损失率** (Loss Given Default, LGD) 可以写成  $\text{LGD} = 1 - R$ 。

在最简单的强度模型里面, 还可以使用**违约强度** (hazard rate)  $\lambda_t$  描述已经存续到时刻  $t$  的条件下, 接下来一个很短时间里面发生违约的瞬时概率强度。直觉上可以写成

$$\lambda_t \approx \lim_{h \downarrow 0} \frac{\mathbb{P}(t < \tau \leq t + h | \tau > t, \mathcal{F}_t)}{h},$$

只要相应模型允许这样定义。

于是信用风险就从一句模糊的“这个公司可能还不起钱”变成了随机违约时间, 存续概率 (survival probability), 回收率和违约强度等可以进一步建模的对象。

这时候一个非常自然的问题就是: 如果投资者愿意持有某个主体的债券, 但是不愿意承担全部信用风险, 能不能另外找一个交易对手承担这部分风险?

这就引出了信用违约互换 (Credit Default Swap, CDS)。

#### 定义 6.85.

**信用违约互换** (Credit Default Swap, CDS) 是一种信用衍生品。CDS 的信用保护买方 (protection buyer) 按照合约向信用保护卖方 (protection seller) 支付费用; 如果参考主体或者参考债务发生约定的信用事件 (credit event), 保护卖方则按照合约承担相应的保护支付 (protection payment)。

从经济直觉来看, CDS 很像是在给一项信用风险买保险。不过 CDS 本身并不是普通保险合同, 保护买方也不一定真的持有相应债券。所以它既可以被用于对冲已经存在的信用风险, 也可以被直接用来建立对于某个主体信用状况的多头或者空头暴露。

相比于一张现金债券, CDS 把信用保护本身单独做成了合约, 所以它的价格通常能够更加集中地反映参考主体的信用风险。但“更加集中”并不意味着它只反映违约概率: 回收率, 风险溢价, 流

动性, 融资成本 (funding cost) 以及保护卖方自身的交易对手风险同样可能进入 CDS 定价.

理论里面经常使用**平价 CDS 利差** (par CDS spread)  $s_{\text{CDS}}$ , 也就是让 CDS 合约初始价值为零的持续利差 (running spread). 在一个非常简化的常数回收率和常数违约强度模型里, 可以得到类似

$$s_{\text{CDS}} \approx (1 - R)\lambda^{\mathbb{Q}}$$

这样的关系.

这里的  $\mathbb{Q}$  是后面无套利定价中会正式引入的风险中性测度. 所以从 CDS 价格反推出的  $\lambda^{\mathbb{Q}}$  首先是**风险中性违约强度**, 而不是现实世界中发行人真正的物理违约频率.

换句话说,

CDS 利差  $\neq$  现实世界违约概率.

从 CDS 利差得到所谓的“市场隐含违约概率”, 中间已经加入了回收率, 贴现, 风险溢价以及概率测度等一整套模型假设.

现实 CDS 的报价还会比这个理论形式稍微复杂. 为了标准化和清算, CDS 合约可以使用固定票息, 再在交易开始时通过前端支付 (upfront payment) 调整合约的初始市场价值. 所以 CDS 利差是非常重要的信用市场指标, 但并不意味着所有实际 CDS 合约都直接按照当时的平价利差作为固定票息.

### 6.5.6 从期限结构到随机过程

到这里, 利率市场真正基础的数学对象其实已经不再只是某一个“利率” $r$ , 而是整族零息债券价格

$$P(t, T), \quad 0 \leq t \leq T.$$

这个对象有一个很有意思的双重时间结构.

固定到期日  $T$  时,  $t \mapsto P(t, T)$  描述的是同一张在  $T$  到期的零息债券随着现实时间前进怎样变化, 因而是一条债券价格过程.

而固定当前时刻  $t$  时,  $T \mapsto P(t, T)$  描述的是市场在这一时刻对于所有未来期限的定价, 因而是一整条贴现曲线.

如果进一步把市场状态写出来, 真正的随机对象其实可以看成

$$P(t, T, \omega).$$

所以利率随机过程和股票价格随机过程有一点很不一样: 股票模型最简单的时候可能只需要研究一个随时间变化的  $S_t$ , 而利率市场天然就需要同时处理“当前时间  $t$ ”和“到期时间  $T$ ”两个维度.

后面的利率模型就是在寻找不同方式来压缩这种复杂性.

比如短期利率模型会选择一个低维状态  $r_t$ , 再从它推导不同期限的债券价格; Vasicek 和 CIR 都属于这一类思路. 另一类方法则会更加直接地研究整条远期利率曲线怎样随时间变化, HJM 框架就是典型例子.

也就是说, 我们可以选择

完整利率市场  $\rightsquigarrow$  短期利率状态,

也可以选择

完整利率市场  $\rightsquigarrow$  远期曲线状态.

它们仍然是在根据不同研究目的, 对真实市场进行不同方式的状态压缩.

到这里, 债券市场最基础的结构已经大致建立起来了.

这一节的主线可以压缩成这样: 某个主体需要今天的资金, 于是发行债券, 用未来的一组支付规则交换投资者今天的资本;  $P(t, T)$  给不同时间的货币建立交换关系, 并进一步形成完整的期限结构; 不同期限又具有不同的利率和风险暴露; 美债同时承担美元债券市场的重要基准资产和高质量抵押品角色; 信用债又在基准期限结构之上加入发行人的信用风险, CDS 则进一步把这部分风险单独做成可以交易的合约.



不过我们到这里仍然留下了一个重要问题：

所谓美元短期利率在现实世界中究竟是怎样形成的？

银行之间为什么需要隔夜资金，美债为什么能够被拿去换取现金，repo，银行准备金，SOFR 和美联储又是什么关系？

## 6.6 美联储，美元体系与短端资金市场

前面讨论债券期限结构时，我们已经看到期限本身就是债券定价的重要因素之一。把资金借出去三十年，和只借出去几个月，面对的不是完全相同的不确定性。期限越长，未来利率，通胀，资金机会成本以及其他市场环境发生变化的空间通常就越大。

不过我们也可以反过来问一个更加基础的问题：

如果不断缩短一笔借款的期限，最后会走到哪里？

在现实金融市场里面，一个很自然的答案就是隔夜。今天借出一笔美元，下一个工作日就收回来。相比几十年的长期债券，这里已经很少有时间让长期通胀，经济周期或者远期利率变化逐渐累积，所以各种隔夜融资利率构成了美元利率体系最短的一端。

但是“隔夜”并不自动意味着“无风险”。如果只是把钱无抵押地借给另一个金融机构，我们仍然需要考虑对方第二天能不能还钱；如果使用抵押品，又会涉及抵押品本身的价值，流动性以及具体的交易制度。

更麻烦的是，美国的美元制度不是一套从零设计出来的干净系统。它更像一套运行了一百多年，不断因为事故而打补丁的老代码：1907 年银行恐慌暴露了没有中央银行时的流动性缺口，1913 年《联邦储备法》建立了美联储，1930 年代的银行危机推动了联邦存款保险，2008 年以后大规模资产购买和充裕准备金让 IORB, ON RRP 这样的工具变得核心，而 LIBOR 的缺陷又促成了 SOFR 这类更依赖真实成交的参考利率。本节的制度性说明主要参考 Federal Reserve, New York Fed, FDIC, SEC, BIS 以及相关教材和论文 [Ald+20; Alt; Boaa; Boab; Boac; Boad; DD83; Feda; Fedb; Fedd; Fede; Fedf; Hul22; HPW19; MT; TS11; US f]。

所以阅读本节时，需要始终区分三个层次：第一层是制度和资产负债表，包括准备金，TGA, IORB, ON RRP 和 swap lines；第二层是市场工具和参考利率，包括银行存款，fed funds, MMF, T-bill, repo, EFR 和 SOFR；第三层才是金融模型中的瞬时短期利率  $r_t$ 。

前两层产生真实市场中的资金流，交易和数据。第三层则把这些复杂结构压缩成一个可以用于贴现和定价的随机过程。在适当条件下，

$$r_t = - \left. \frac{\partial}{\partial T} \log P(t, T) \right|_{T=t}.$$

这条公式非常漂亮，但它背后的现实世界一点也不漂亮。

### 6.6.1 先有事故，后有制度

#### 美联储体系

在进入短端美元市场以前，先看整个美元银行体系最核心的机构之一：美联储。

#### 定义 6.86.

**美联储** (Federal Reserve System, Fed) 是指美国的中央银行体系。它主要承担美国货币政策的制定和实施，为银行体系提供中央结算和流动性基础设施，监管其中一部分金融机构，并承担维护金融体系稳定等职能。

美联储并不是从天上掉下来的一套完美制度。十九世纪末和二十世纪初的美国银行体系地域分割严重，货币和准备金很难在地区之间顺畅调动。一旦发生恐慌，资金需求会突然集中到现金和最安全的银行上，而当时的金融体系只能依靠清算所，财政部以及少数私人银行家临时组织救助。

1907 年恐慌就是这种旧系统的压力测试。它从纽约信托公司和短期融资市场开始扩散，并推动了后来建立中央银行的货币改革运动 [MT]。1913 年《联邦储备法》随后建立了联邦储备体系，目标之一正是提供更加安全，有弹性且稳定的货币和金融系统 [Boac; Fedf]。

所以美联储更合适的理解是：它位于美元银行体系的中央银行层。商业银行可以在自己的资产负债表上发放贷款，创造存款并处理客户支付，但不同银行之间仍然需要一种彼此都接受的最终结算资产，以及一套完成银行间支付的中央基础设施。美联储就在这一层的中心。

从组织上看, 美联储体系由位于 Washington, D.C. 的理事会 (Board of Governors), 十二家地区性联邦储备银行 (Federal Reserve Banks), 以及联邦公开市场委员会 (Federal Open Market Committee, FOMC) 共同构成.

纽约联邦储备银行在市场操作中尤其重要. 后面介绍 EFRR, SOFR, repo, ON RRP 以及其他货币政策实施工具时, 都会不断遇到它.

这套组织结构本身也像一个历史补丁: 它既要有全国性的中央银行权力, 又要保留地区储备银行和银行体系参与, 还要在政治上避免让所有权力集中到 Wall Street 或 Washington 某一侧. 因此, 美联储从一开始就不是一个纯粹工程式设计出来的单体机构, 而是一套带有历史妥协的分布式中央银行系统.

现代美元的不同层次

有了美联储以后, 我们终于可以问一个更加基础的问题:

我们平时所说的“美元”, 到底是什么?

答案比“美国发行的钱”稍微复杂一点. 同样被称为美元的东西, 可能来自不同发行人的资产负债表.

定义 6.87.

**美联储票据** (Federal Reserve Note) 是指由美联储体系发行进入流通的美元纸币. 从资产负债表来看, 美联储票据是美联储的负债.

这里的“Note”不要和前面介绍的 Treasury Note 混淆. Treasury Note 是美国财政部为了融资而发行的一类中期国债; Federal Reserve Note 则是美元纸币, 承担现金支付功能.

不过美联储票据并不是美联储唯一一种具有美元性质的负债. 商业银行以及其他符合条件的金融机构还可以在美联储持有准备金余额.

定义 6.88.

**银行准备金** (bank reserves) 是指商业银行为了支付结算和流动性管理而持有的高度流动性资产. 在本文讨论美元资金市场时, 如果没有特别说明, “准备金”主要是指金融机构存放在美联储的 **准备金余额** (reserve balances).

所以从中央银行这一层来看, 美元已经可以表现成两种很不一样的东西: 一种是公众能够直接持有的美元纸币, 另一种是主要存在于金融机构之间的准备金余额. 二者都是美联储的负债, 只是持有人和用途不同.

而普通人在银行账户里面看到的 \$100 又是另一回事. 比如一个人在某家商业银行的账户里面有 \$10,000, 那么这 \$10,000 对储户来说是一项资产; 但从这家银行的资产负债表来看, 它实际上是一笔银行对储户承担的负债.

从资产负债表来看, 几种平时都会被我们称作“美元”的对象可以简单整理成:

| 对象    | 对谁是资产   | 对谁是负债 | 主要用途         |
|-------|---------|-------|--------------|
| 美元纸币  | 持有人     | 美联储   | 现金支付         |
| 银行存款  | 储户      | 商业银行  | 支付, 储蓄       |
| 准备金余额 | 商业银行等机构 | 美联储   | 银行间结算, 流动性管理 |

所以这里有一个重要原则: **共享同一个美元计价单位, 并不意味着这些资产具有同一个发行人, 同一种法律请求权或者完全相同的风险.**

日常生活里面之所以几乎感觉不到这种区别, 是因为美元纸币, 商业银行存款以及银行间支付体系在正常情况下能够维持非常稳定的面值转换关系. 银行账户里面的 \$100 通常既可以取成 \$100 现金, 也可以按照 \$100 转到另一家银行.

换句话说, 我们日常使用的“一美元”看起来像是同一种东西, 背后实际上可能对应不同机构资产负债表上的不同请求权.



## 银行存款, 准备金与挤兑

商业银行创造存款这件事, 可以先从一个极简记账看起. 如果银行发放一笔金额为  $L$  的贷款, 它可以同时在资产端增加贷款, 在负债端为借款人增加存款:

| 银行资产     | 银行负债     |
|----------|----------|
| + 贷款 $L$ | + 存款 $L$ |

这就是常说的“贷款创造存款”.

不过这句话很容易被误解. 银行能够创造的是**自己的存款负债**, 而不是凭空创造美联储准备金. 如果借款人随后把钱转给另一家银行的客户, 原来的贷款仍然留在放贷银行的资产端, 但存款已经跑到另一家银行. 这时付款银行需要把相应结算资产转给收款银行, 最核心的结算资产之一就是准备金.

因此:

贷款创造存款  $\nRightarrow$  单家银行没有融资和流动性约束.

如果一家银行不断扩张贷款, 而由此产生的存款又不断流向其他银行, 它仍然需要通过吸收存款, 批发融资, repo, 出售资产或者向央行借款等方式补充流动性.

银行体系为什么需要这些层层补丁, 根源之一在于存款的期限和流动性转换. 储户希望存款随时能够按面值支付或取出, 而银行资产端持有的贷款通常期限更长, 流动性更差. 如果大量储户同时要求提款, 即使一家银行长期来看未必资不抵债, 也可能被迫在很差的价格下出售资产. Diamond-Dybvig 模型正是分析银行挤兑和存款保险的经典理论框架之一 [DD83].

美国后来逐步加上的补丁也就沿着这几个压力点展开: 贴现窗口让合格存款机构可以用资产作抵押向美联储借款; 1933 年建立的 FDIC 存款保险降低了受保险存款人的挤兑动机 [Fedal]; 资本, 流动性和审慎监管试图降低银行本身出问题的概率; 而准备金和央行结算体系则维持银行之间的最终支付.

2020 年以后, 美国法定准备金率被降为 0, 但这不表示准备金失去作用 [Boaf]. 准备金仍然是银行间支付结算, 流动性管理以及货币政策实施的核心资产. 这就像把旧系统里面某个参数调成了零, 但底层运行时环境仍然离不开那套结算基础设施.

### 6.6.2 TGA 与准备金管道

银行准备金的总量当然也不会永远保持不变. 美联储的负债端还有另一个会直接影响准备金的重要账户.

#### 定义 6.89.

**美国财政部一般账户** (Treasury General Account, TGA) 是指美国财政部在美联储持有的主要运营账户. 美国政府的许多财政收入, 融资收入以及财政支出最终都会通过这个账户进行结算.

美联储不仅是中央银行, 也是美国财政部的财政代理人. 税款和发债收入可以流入 TGA, 政府支出, 国债付息和到期偿还则可以从 TGA 流出. 这听起来像财政部自己的现金管理问题, 但因为 TGA 位于美联储负债端, 它会直接改变银行体系中的准备金.

把美联储资产负债表极度简化为

$$A_t^{\text{Fed}} = N_t + R_t + G_t + Q_t + O_t,$$

其中  $A_t^{\text{Fed}}$  表示美联储资产,  $N_t$  表示流通中纸币,  $R_t$  表示准备金,  $G_t$  表示 TGA,  $Q_t$  表示逆回购等负债,  $O_t$  汇总其他负债和资本. 于是

$$\Delta R_t = \Delta A_t^{\text{Fed}} - \Delta N_t - \Delta G_t - \Delta Q_t - \Delta O_t.$$

如果短期内其他项目近似不变, 就可以粗略记成

$$\Delta R_t \approx -\Delta G_t - \Delta Q_t.$$

这是一条会计关系, 不是行为定律. 它只是提醒我们: 当税款或者国债认购资金从商业银行体系流入 TGA 时, 银行体系中的准备金通常会下降; 当财政部从 TGA 花钱时, 准备金又会回到银行体系.

因此 TGA 本身不是一个市场利率, 却可以通过准备金供给影响 fed funds, repo 和其他隔夜利率. 纳税日, 大规模美债结算, 财政集中支出, 以及债务上限僵局结束以后财政部重新补充 TGA, 都可能让短端美元资金突然变紧或变松 [Boab; HPW19].

这已经很像随机过程问题了: 准备金  $R_t$  不是平滑地匀速变化, 而是会受到日历效应, 财政流量, 政策操作和市场压力共同驱动. 后面如果要写短端利率模型, 这些变量就可能变成状态变量, 跳跃项或者外生冲击.

### 6.6.3 沿风险梯子走过美元短端

下面从一个特定视角看短端美元资产: 一个持有大额美元现金, 无法完全依靠零售存款保险, 又希望短期停放资金的机构, 可以把钱放在哪里?

这个排序不是严格的数学全序. 不同投资者的准入资格, 抵押品质量, 法律结构, 期限, 流动性和监管约束都会改变具体风险. 但它可以帮助我们从小风险的私人无抵押美元, 逐步走向抵押融资, 短期国债和央行负债.

| 工具                 | 直接债务人或结构  | 主要保护            | 主要剩余风险          |
|--------------------|-----------|-----------------|-----------------|
| 未保险银行存款, fed funds | 商业银行或存款机构 | 银行资本和流动性        | 信用, 挤兑和无抵押风险    |
| Prime MMF 份额       | 基金份额      | 分散化和短期限资产       | 组合信用, 赎回和基金结构风险 |
| Government MMF 份额  | 基金份额      | 政府证券, 政府 repo 等 | 流动性, 操作和非保证净值风险 |
| Treasury repo      | 私人交易对手    | 国债抵押品, haircut  | 对手方, 抵押品和法律操作风险 |
| T-bill             | 美国财政部     | 主权信用和深度市场       | 利率, 结算和极端制度事件风险 |
| 准备金, ON RRP        | 联储银行      | 央行负债或央行交易对手     | 准入限制和操作规则       |

### 无抵押私人美元: Fed funds 与 EFFR

Fed funds 市场最初服务于一个非常实际的问题: 有些银行在日终准备金不足, 另一些银行有多余准备金, 于是它们进行隔夜, 无抵押的美元借贷.

#### 定义 6.90.

**联邦基金市场** (Federal Funds Market) 是符合条件的金融机构围绕其美联储账户准备金余额进行无抵押隔夜美元借贷的市场之一. 在这个市场中形成的利率通常统称为联邦基金利率.

这里的关键是**无抵押**. 借款人不需要像 repo 那样同时交出一批美债作为抵押品, 所以出借人除了考虑期限以外, 还要考虑交易对手信用风险和资产负债表约束.

#### 定义 6.91.

**有效联邦基金利率** (Effective Federal Funds Rate, EFFR) 是指 New York Fed 根据实际发生的隔夜联邦基金交易计算并公布的参考利率. EFFR 是成交量加权中位数, 因而首先是一个从真实市场成交中统计出来的利率, 不是 FOMC 直接规定的政策数字.

这一区别很重要. FOMC 给出的是联邦基金利率目标区间, EFFR 则是市场交易的统计结果. 美联储真正需要做的是通过政策工具影响市场参与者的机会成本, 让实际成交利率尽量运行在目标区间附近 [Fedb; Fedc].

如果把某类无抵押隔夜利率写成一个示意性分解, 可以想成

$$y_t^{\text{unsec}} = m_t + s_t^{\text{credit}} + s_t^{\text{liquidity}} + s_t^{\text{balance sheet}} + \varepsilon_t.$$

这里  $m_t$  是政策锚, 其余项分别表示信用风险, 流动性, 资产负债表约束以及统计噪声. 这不是一条严格恒等式, 只是提醒我们: 现实市场利率通常不是单纯的“政策利率”.

### 货币市场基金与短期现金管理

美元短端市场当然不只有银行. 现实中大量企业, 基金, 保险公司和个人都会持有暂时不需要使用的美元. 这些资金通常既不希望承担太大的价格波动, 又不愿意完全放弃短期利息, 所以会寻找短期限, 高流动性的现金管理工具.

#### 定义 6.92.

**货币市场基金** (Money Market Fund, MMF) 是主要投资于短期限, 高流动性债务工具的投资基金, 常被用于短期现金管理.

货币市场基金做的事情可以粗略理解为: 投资者把暂时不用的现金交给基金, 基金再把这些资金配置到各种短期金融工具里面. 但 MMF 不是银行账户. 投资者持有的是基金份额, 基金背后持有的是一篮子短期资产.

不同类型 MMF 的投资范围也不同. 政府型货币市场基金主要投资现金, 美国政府证券以及以政府证券支持的 repo; 优质型货币市场基金还可能持有银行存单, 商业票据等私人短期信用工具; 免税型货币市场基金则主要投资短期市政债务.

#### 注 6.93.

货币市场基金份额不是银行存款, 也不自动受到 FDIC 存款保险保障. 虽然许多货币市场基金希望提供非常稳定的现金管理体验, 但它们仍然属于基金投资, 具体风险取决于基金真正持有什么资产以及赎回机制怎样设计.

所以所谓“现金”实际上没有想象中简单. 一个投资组合里面的现金可能进一步表现成银行存款, T-bill, MMF 份额或者 repo. 这些工具都能承担现金管理功能, 但对应的发行人, 信用结构, 流动性和收益并不完全相同 [US f].

### Repo 与抵押融资

上一节已经介绍过, 美债除了是一类债券以外, 还有一个和普通投资资产很不一样的功能: 它可以被广泛用作高质量抵押品. 现在这件事情终于可以和美元短端资金市场连接起来.

#### 定义 6.94.

**回购协议** (Repurchase Agreement, Repo) 是指一方先出售证券取得现金, 同时约定在未来按照事先约定的价格重新买回这些证券的交易. 从经济效果来看, repo 非常接近一笔以证券作为抵押的短期融资.

比如一方今天交出美债并取得 \$100, 同时约定第二天支付 \$100.01 把美债买回来, 那么多出来的 \$0.01 就是这笔短期融资的利息. 如果初始现金为  $C_0$ , 到期回购金额为  $C_1$ , 计息年化比例为  $\delta$ , 则简单 repo rate 可以写成

$$r^{\text{repo}} = \frac{C_1/C_0 - 1}{\delta}.$$

同一份合约可以从两个方向看. 对于交出证券, 取得现金并承诺以后买回的一方, 这是 repo; 对于提供现金并暂时取得证券的一方, 同一笔交易则称为 reverse repo.

有抵押并不意味着没有风险. Repo 仍然会面对交易对手风险, 抵押品价格变化, 市场流动性以及结算风险, 所以现实交易还会利用 haircut, margin, 净额结算等方式进行风险管理. 如果抵押品市值为  $V_0$ , 初始现金为  $C_0$ , 常见的 haircut 可以写成

$$h = 1 - \frac{C_0}{V_0}.$$

还有一个细节很重要: repo 利率不只是在给现金融资定价, 抵押品本身也会参与价格形成. 如果某一只具体美债在市场上特别难以取得, 那么“暂时拿到这只美债”本身就会有额外价值. 现

金提供者可能愿意接受异常低的 repo 回报来取得这只证券, 这种现象通常称为该券处于特殊状态 (trading special).

### SOFR 与 LIBOR 之后的参考利率

有了美债 repo 市场以后, 我们可以引入现代美元金融市场里面最重要的参考利率之一: SOFR.

#### 定义 6.95.

**有担保隔夜融资利率** (Secured Overnight Financing Rate, SOFR) 是 New York Fed 根据大量美债 repo 隔夜实际成交数据计算并公布的参考利率. 它衡量的是以美国国债为抵押借入隔夜现金的大致成本.

SOFR 的重要性和 LIBOR 的历史问题有关. LIBOR 曾经广泛用于贷款, 债券和衍生品合约, 但它并不充分锚定在真实市场成交上, 并且在金融危机后暴露出操纵风险和底层交易稀薄等问题. ARRC 因此在 2017 年选择 SOFR 作为美元 LIBOR 的推荐替代利率 [Alt].

SOFR 不是美联储直接规定出来的政策利率, 也不是某一笔具体 repo 的成交利率. Repo 市场先发生大量真实融资交易, New York Fed 再利用三方 repo, GCF Repo 以及部分经 FICC 清算的双边 Treasury repo 数据, 并过滤一部分可能反映特殊券稀缺性的交易, 计算出成交量加权中位数 [Fede]. 因此可以粗略理解成

美债 repo 市场  $\rightarrow$  真实成交  $\rightarrow$  SOFR.

这和前面的 EFFR 很相似: EFFR 是从联邦基金市场的无抵押隔夜交易中统计出来的, SOFR 则是从美债 repo 这种有抵押的隔夜融资交易中统计出来的. 两者都属于美元隔夜参考利率, 但观察的不是同一个现实市场.

另外需要注意, SOFR 本身只描述隔夜. 如果一份贷款或者衍生品持续一个月, 三个月甚至更久, 不能直接把今天的 SOFR 当成整个期限的利率. 一种常见做法是把期间每天实际出现的隔夜 SOFR 按照相应计息天数逐日复合. 如果每天对应的 SOFR 为  $\text{SOFR}_{t_i}$ , 时间长度为  $\Delta_i$ , 那么累计增长因子大概具有

$$\prod_i (1 + \text{SOFR}_{t_i} \Delta_i)$$

这样的形式.

所以至少还需要区分**隔夜 SOFR** (overnight SOFR), **复合 SOFR** (compounded SOFR), 以及从衍生品价格中构造出来的**前瞻期限 SOFR** (forward-looking Term SOFR) [CME].

即使大家都在说 “SOFR”, 仍然值得问一句: 究竟是在说今天实际形成的隔夜参考利率, 一段时间内复合出来的利率, 还是市场价格隐含的未来期限利率?

### IORB 与 ON RRP

现在回到美联储怎样影响最短端资金价格. 在当前的充裕准备金框架中, 其中一个非常重要的工具是 IORB.

#### 定义 6.96.

**准备金余额利率** (Interest on Reserve Balances, IORB) 是美联储对符合条件的机构持有的准备金余额支付的利率.

IORB 本身也是历史补丁. 2006 年法律授权美联储对准备金支付利息, 原计划 2011 年生效; 2008 年金融危机期间, 这项权限被提前到 2008 年 10 月生效 [Boad]. 危机后美联储资产负债表大幅扩张, 银行体系持有大量准备金, 旧式的 “稀缺准备金” 利率控制方式不再足够. IORB 于是成为美联储影响银行短期资金机会成本的核心工具.

直觉上, 如果一家银行把准备金留在美联储就能够取得一定收益, 那么别人希望向它借隔夜资金时, 银行自然会比较: 继续把钱留在美联储, 还是按某个更低收益率借给对方. 所以 IORB 会成为银行配置短期资金的重要机会成本.

但 IORB 不是全市场不可突破的硬下限. 联邦基金市场的资金提供者并不全部能够获得 IORB. 比如某些政府支持企业和 Federal Home Loan Banks 不能像合格银行那样直接通过准备金余额取得 IORB, 因而仍然可能愿意按照低于 IORB 的利率提供隔夜资金. 这也是为什么 EFFR 可能低于 IORB.



对于很多非银行现金投资者来说, 另一个重要工具是 ON RRP.

#### 定义 6.97.

**隔夜逆回购工具** (Overnight Reverse Repurchase Agreement Facility, ON RRP) 是美联储向符合条件的交易对手提供的一种隔夜投资工具. 货币市场基金, 政府支持企业等合格机构可以通过这项工具把隔夜资金配置给美联储, 并按照美联储规定的 ON RRP offering rate 取得收益.

ON RRP 的历史动机也来自准入差异. 很多非银行现金投资者不能直接持有能够取得 IORB 的准备金余额. 当市场利率过低时, ON RRP 给它们提供了另一种直接面对美联储配置隔夜资金的选择, 从而帮助限制隔夜利率的下行压力, 并为更广泛的货币市场利率提供下方支撑 [Boae; Fedd].

因此这几个对象虽然经常同时出现, 角色却完全不同:

FOMC 目标区间 → 政策目标,  
IORB / ON RRP → 政策实施工具,  
EFFR / SOFR → 市场参考利率.

政策传导并不是简单地令

$$\text{EFFR}_t = i_t^{\text{IORB}} = \text{SOFR}_t.$$

更准确的说法是: IORB 和 ON RRP 提供政策锚, 准备金和抵押品供给决定市场环境, 真实交易再在不同市场中形成 EFFR, SOFR 以及其他参考利率.

### 6.6.4 美元体系的边界: 离岸美元与链上美元

#### 离岸美元与全球美元融资

到这里, 我们介绍的主要还是美国本土的美元体系. 但是美元当然并不只存在于美国境内.

全球大量银行, 企业和金融机构都会持有美元资产和美元负债. 其中相当一部分甚至直接存在于美国境外金融机构的资产负债表上. 传统上, 存放在美国境外银行中的美元存款经常被称为**欧洲美元**或者**离岸美元存款** (Eurodollar). 这里的“Euro”并不是说这些美元一定在欧洲, 更不是说它们和欧元有什么关系; 它最初只是用来描述存在于美国境外银行体系中的美元存款, 后来逐渐泛化为离岸美元体系的一部分.

这件事情和前面介绍商业银行存款时的逻辑类似. 如果一家位于美国境外的银行接受了一笔美元存款, 那么这笔存款首先仍然是这家银行对于储户承担的一项美元计价负债. 它并不意味着每一美元存款背后都机械地躺着一美元美联储准备金.

所以美元体系远远不只是“美联储发行多少美元”这么简单. 商业银行在美国境内和境外都可以通过自己的资产负债表产生大量美元计价的债权和债务关系.

不过离岸银行既然承诺按美元支付, 最终仍然需要解决一个现实问题: **真正需要支付美元的时候, 去哪里取得美元资金?**

常见办法包括吸收美元存款, 从其他金融机构借入美元, 进行 repo, 发行美元债务, 以及通过外汇掉期 (FX swap) 临时取得美元. 假设一家欧洲金融机构手里主要持有欧元, 但未来三个月临时需要美元. 它可以先用欧元换取美元, 同时约定三个月以后再按事先确定的价格把美元换回欧元. 从经济效果来看, 这就让它在一段时间内取得了美元融资.

如果用  $S_t$  表示一单位外币的即期美元价格,  $F_t(T)$  表示同一报价方式下的远期价格, 那么在没信用, 流动性和资产负债表摩擦时, 抵补利率平价会给出类似

$$\frac{F_t(T)}{S_t} = \frac{1 + r_t^{\$} \Delta}{1 + r_t^f \Delta}$$

的关系. 现实中的偏离通常可以用 cross-currency basis 描述. Basis 扩大时, 往往说明通过外汇掉期取得美元的成本已经偏离了由两种利率机械推导出的水平 [Ald+20].

2008 年金融危机和 2020 年全球美元紧张都说明, 离岸美元体系的私人负债可以远大于当地机构随时能够取得的央行美元. 于是现代美元流动性互换安排就像美元体系边界上的补丁: 当境外美元融资市场出现压力时, 美联储可以通过外国央行把美元流动性输送到其辖区内的金融体系.



**定义 6.98.**

**央行美元流动性互换** (central bank U.S. dollar liquidity swap) 是指美联储和外国央行之间的货币互换安排. 美联储向外国央行提供美元, 外国央行提供等值本币并约定未来反向交换; 外国央行再决定怎样把美元贷给本辖区机构.

这里要注意, 美联储的直接交易对手是外国央行, 不是境外商业银行. 外国央行负责向本辖区机构转贷美元, 并承担这些机构的信用风险; 美联储则通过央行之间的合约安排降低外汇风险和私人机构信用风险 [Boa20; Boaa].

所以美联储虽然首先是美国的中央银行, 但由于美元本身具有全球融资货币地位, 美元流动性问题从来都不只是一件美国国内银行业的问题.

**法币储备型稳定币与链上美元**

近年来, 美元体系还出现了一个新的延伸: 美元稳定币. 这里不打算完整讨论所有稳定币机制, 只看最容易和传统美元短端市场连接起来的**法币储备型稳定币**.

**定义 6.99.**

**法币储备型美元稳定币** (fiat-backed USD stablecoin) 是指由私人主体发行, 以美元作为计价基准, 并通过储备资产和赎回机制试图让每单位代币维持接近 \$1 价值的链上数字资产.

一枚稳定币不是一单位美联储准备金, 也不是普通商业银行存款. 更合适的理解是: 发行人在传统金融体系中持有一篮子美元资产, 同时在区块链上发行相应的美元计价请求权. 这些储备资产可能包括银行存款, 短期美债, 美债担保逆回购等高流动性短期美元资产.

所以所谓“链上美元”并不是一个完全脱离传统美元市场的新世界. 它背后的资产负债表最终仍然可能回到

银行存款,      短期美债,      回购协议.

这也再次说明: 使用美元作为计价单位, 并不意味着它本身就是美联储货币. 如果储备资产, 赎回机制, 市场流动性或者投资者信任出现问题, 稳定币价格就可能偏离 \$1, 也就是所谓的脱锚 (depeg).

**6.6.5 从美元资金市场到短期利率模型**

到了这里, 我们终于可以重新回到本节开头的问题:

**现实中这么复杂的美元资金体系, 为什么到了金融数学里面经常只剩下一个  $r_t$ ?**

前面实际上已经见到了很多不同的利率. FOMC 的目标区间是政策目标; IORB 和 ON RRP offering rate 是美联储主动设置的政策工具; EFFR 是从联邦基金市场实际成交中统计出来的无抵押隔夜参考利率; SOFR 是从美债 repo 市场实际成交中得到的有抵押隔夜参考利率; 而 T-bill, 银行融资, repo, 离岸美元和外汇掉期又各有自己的资金价格.

所以现实里面是一整套

美元资金曲线族,

而不是一个唯一的“美元利率”.

一种更贴近现实的写法, 是把第  $k$  类观测利率表示为

$$y_t^{(k)} = m_t + \beta_k^\top X_t + s_{t,\text{credit}}^{(k)} + s_{t,\text{liquidity}}^{(k)} + \varepsilon_t^{(k)}.$$

这里  $m_t$  可以理解为政策锚, 而状态向量  $X_t$  可能包括

$$X_t = \left( R_t, G_t, Q_t, \chi_t^{\text{collateral}}, b_t^{\text{FX}}, \dots \right),$$

其中  $R_t$  表示准备金条件,  $G_t$  表示 TGA,  $Q_t$  表示 ON RRP 使用量,  $\chi_t^{\text{collateral}}$  表示抵押品稀缺程度,  $b_t^{\text{FX}}$  表示离岸美元 basis.

但为了研究最基本的跨时间贴现和无套利关系, 金融数学通常会先做一次非常强的抽象: 假设存在一个瞬时短期利率过程

$$(r_t)_{t \geq 0},$$

并进一步定义一个按照这个短期利率连续滚动的**货币市场账户** (money-market account)

$$B_t = \exp\left(\int_0^t r_s ds\right).$$

因此它满足

$$dB_t = r_t B_t dt.$$

直觉上,  $B_t$  表示这样一个理想化账户: 每一个瞬间都能够按照当时的短期无风险利率把资金继续滚动下去. 如果  $r_t = r$  为常数, 那么自然得到  $B_t = e^{rt}$ .

不过这里一定要注意, 这个  $r_t$  并不是简单把某一个现实市场报价换了一个符号. EFR 和 SOFR 都是有限期限交易经过统计以后得到的参考利率;  $r_t$  则是金融模型中为了描述瞬时贴现而引入的状态变量. 二者在定义上不同, 但实证或者建模时可以把某个隔夜利率作为代理变量, 校准目标或者观测方程.

更加复杂的利率模型则会重新把现实差异加回来. 比如现代利率市场会区分用于贴现的曲线, 用于预测浮动现金流的曲线, 交易机构自身的融资成本, 抵押品报酬利率, 以及跨币种 basis 和抵押品稀缺性等价差.

因此所谓“无风险利率”从现实市场走到数学模型的过程中, 本身就已经经历了一次很强的建模压缩. 把整个美元资金体系写成一个  $r_t$ , 并不是发现了现实世界里面唯一真正存在的无风险利率, 而是为了研究跨时间贴现和无套利定价, 主动选择保留下来的一个模型状态.

到了这里, 从债券市场开始逐渐出现的

$$P(t, T), \quad r_t, \quad B_t$$

也终于连接到了一起. 其中  $P(t, T)$  描述时刻  $T$  的一单位货币在时刻  $t$  的价格;  $r_t$  描述模型中最短端的瞬时资金价格;  $B_t$  描述资金按照这些短期利率不断滚动以后形成的价值过程.

后续进入贴现与无套利时, 真正需要解决的问题就是:

既然不同时间的资金已经可以通过这些对象进行比较, 那么两个具有相同未来现金流的交易策略, 今天为什么应该具有相同的价格?

## 6.7 贴现与无套利

前面几节里, 我们已经分别遇到了股票价格, 衍生品现金流, 预测市场事件合约, 指数和 ETF, 以及零息债券价格  $P(t, T)$ , 短期利率  $r_t$  和货币市场账户  $B_t$ . 这些对象看起来分散, 但真正进入金融数学以后, 它们会被放进同一套语言: **不同时间和不同状态的现金流应该怎样定价?**

贴现回答的是时间问题. 今天的一单位货币和一年以后确定收到的一单位货币不能直接相加, 中间需要一条跨时间比较的规则.

无套利回答的是一致性问题. 如果两套交易方式在未来每一种可能状态下都给出相同现金流, 那么它们今天不应该有两个不同价格. 否则投资者就可以买便宜的一边, 卖贵的一边, 把差价锁住.

本节主要参考无套利定价和资产定价理论中的标准处理 [Coc05; DS94; Duf01; HK79; HP81; Hul22; Shr04a; Shr04b]. 这里不会证明一般形式的基本定理, 而是先把后面不断会用到的直觉和符号准备好.

### 6.7.1 贴现和计价资产

先从最简单的确定现金流开始.

如果时刻  $t$  市场中一只无违约零息债券的价格为  $P(t, T)$ , 并且它在时刻  $T$  确定支付一单位计价货币, 那么  $P(t, T)$  就是把时刻  $T$  的确定一单位现金流折回时刻  $t$  的价格. 如果  $T$  时刻确定支付  $x$  单位货币, 那么在这条贴现曲线下, 它在时刻  $t$  的价值就是

$$xP(t, T).$$

当利率为确定常数  $r$  且采用连续复利时, 这个贴现因子退化为

$$P(t, T) = e^{-r(T-t)}.$$

于是未来的  $x$  单位货币今天值

$$xe^{-r(T-t)}.$$

这正是债券那一节已经出现过的时间价值. 但从现在开始, 我们更关心的是另一个视角: 贴现不仅是把未来金额折算成现在金额, 也是在选择一个用来度量其他资产价格的基准.

**定义 6.100 (计价资产).**

给定一个严格为正的资产价格过程  $(N_t)_{t \geq 0}$ . 如果我们用  $N_t$  作为计价单位, 那么资产  $S_t$  的贴现价格或相对价格定义为

$$\hat{S}_t = \frac{S_t}{N_t}.$$

这里  $N$  称为一个**计价资产** (numéraire).

最常见的计价资产是货币市场账户. 如果模型中存在短期利率过程  $r_t$ , 并且

$$B_t = \exp \left( \int_0^t r_s ds \right),$$

那么  $B_t$  可以理解成资金不断按照短端利率滚动以后形成的账户价值. 用  $B_t$  计价时, 资产价格变成

$$\tilde{S}_t = \frac{S_t}{B_t}.$$

这一步看似只是换单位, 但它会在后面变得非常重要. 很多无套利定价命题并不是直接说原始价格  $S_t$  应该怎样变化, 而是说经过合适计价资产归一化以后, 价格过程应该具有某种鞅性质.

**注 6.101 (贴现不是只有一条曲线).**

现实市场中, “用哪条曲线贴现” 本身就是一个市场和制度问题. 美债曲线, OIS 曲线, 抵押品报酬利率, 机构自身融资成本和跨币种 basis 都可能对应不同问题下的现金流比较方式.

所以数学模型里的  $B_t$  或  $P(t, T)$  应该理解成一种经过抽象后的定价基准, 而不是现实世界里唯一真正存在的无风险利率.

## 6.7.2 套利和无套利

现在可以更准确地说什么叫套利.

考虑一个从时刻 0 交易到时刻  $T$  的市场. 一组交易策略会产生一个初始价值  $V_0$  和一个终端财富  $V_T$ . 如果存在一组策略使得

$$V_0 \leq 0, \quad V_T \geq 0 \quad \text{a.s.}, \quad \mathbb{P}(V_T > 0) > 0,$$

那么它就是套利.

**定义 6.102 (套利和无套利).**

一组交易策略称为**套利** (arbitrage), 如果它不需要正的初始投入, 未来在几乎所有状态下都不会亏钱, 并且在正概率状态下能够严格赚钱.

如果市场中不存在这样的可允许交易策略, 就说这个市场满足**无套利** (no-arbitrage).

这里的关键不是“赚钱”. 投资者承担风险以后当然可能赚钱. 套利真正排除的是另一种东西:

$$\text{不花钱} + \text{不承担下行风险} + \text{还有机会赚钱}.$$

也就是说, 套利是一张不亏钱的免费彩票.

在更严肃的连续时间模型中, 还需要限制所谓“可允许策略”. 否则可以写出一些靠无限杠杆, 无限翻倍或者财富过程无限向下穿透的病态策略. 所以无套利从来不是脱离交易策略集合的抽象口号; 它总是相对于给定市场, 给定资产, 以及给定允许交易规则而言.

## 6.7.3 一价定律

无套利最直接的后果是一价定律.

**命题 6.103 (一价定律).**

假设市场满足无套利. 如果两个交易组合  $A$  和  $B$  在时刻  $T$  的终端现金流几乎处处相同, 即

$$V_T^A = V_T^B \quad \text{a.s.},$$

那么它们在时刻 0 的价格必须相同:

$$V_0^A = V_0^B.$$

证明. 假设  $V_0^A < V_0^B$ . 那么可以在时刻 0 买入便宜的组合  $A$ , 同时卖空昂贵的组合  $B$ . 初始时刻获得正现金流  $V_0^B - V_0^A > 0$ . 把这笔现金流投入货币市场账户, 到时刻  $T$ , 两个组合的现金流完全抵消:

$$V_T^A - V_T^B = 0.$$

但货币市场账户已经把初始差额变成严格为正的终端财富. 因而这给出一组初始净投入为零、终端财富严格为正的套利. 这与无套利矛盾. 反向不等式同理.  $\square$

一价定律看起来朴素, 但它是金融数学里面非常强的约束. 衍生品定价的很多公式, 本质上都不是直接预测未来价格, 而是在寻找另一组已经可以交易的资产, 使它们在未来产生同样现金流. 一旦找到了这种复制关系, 价格就被无套利锁定.

**6.7.4 复制定价**

设某个衍生品在时刻  $T$  的到期支付为  $X_T$ . 如果存在一组交易策略  $\theta$ , 它从时刻 0 开始的成本为  $v$ , 并且终端财富满足

$$V_T^\theta = X_T \quad \text{a.s.},$$

那么  $\theta$  就复制了这个衍生品.

**定义 6.104 (复制).**

如果一组由市场中可交易资产构成的策略能够在到期时产生和某个目标现金流完全相同的支付, 就说这组策略**复制** (replicate) 了这个现金流.

无套利立刻给出: 被复制的现金流价格必须等于复制组合的成本. 否则买便宜的、卖贵的, 就会回到一价定律的套利构造.

**命题 6.105 (复制价格).**

在无套利市场中, 如果现金流  $X_T$  可以由成本为  $v$  的交易策略复制, 那么任何具有到期支付  $X_T$  的合约在时刻 0 的无套利价格都必须等于  $v$ .

远期价格就是最简单的例子. 假设资产当前价格为  $S_0$ , 持有期间不支付股息, 并且市场中存在到期日为  $T$  的零息债券  $P(0, T)$ . 如果今天借入  $S_0$  买入一单位现货, 那么到期时需要偿还的金额为

$$\frac{S_0}{P(0, T)}.$$

因此使远期合约初始价值为零的交割价格应该满足

$$F_{0,T} = \frac{S_0}{P(0, T)}.$$

当  $P(0, T) = e^{-rT}$  时, 这就变成前面见过的

$$F_{0,T} = S_0 e^{rT}.$$

这里没有用到“市场认为未来现货价格平均会是多少”. 它只用了现货, 融资和远期之间的复制关系.

欧式看涨和看跌期权之间也有类似关系. 在无股息的简单模型中, 同一标的, 同一执行价格  $K$ , 同一到期日  $T$  的欧式看涨期权和看跌期权满足

$$c_0 - p_0 = S_0 - KP(0, T),$$

其中  $c_0$  和  $p_0$  分别是看涨和看跌期权价格. 这是看涨看跌平价. 它来自两个到期现金流完全相同的组合: 一边是看涨期权加上  $K$  单位到期现金, 另一边是看跌期权加上一单位股票.

所以复制定价的精神可以概括为:

$$\text{相同未来现金流} \implies \text{相同当前价格}.$$

### 6.7.5 状态价格和风险中性概率

复制定价还可以换一种角度理解. 考虑一个一时期有限状态模型. 从时刻 0 到时刻  $T$ , 世界最终会落入有限多个状态

$$\omega_1, \dots, \omega_n.$$

一个到期现金流可以写成向量

$$X_T = (X_1, \dots, X_n),$$

其中  $X_i$  表示状态  $\omega_i$  发生时的支付.

如果市场中存在一组价格

$$\pi_1, \dots, \pi_n,$$

使得任意可定价现金流  $X_T$  的价格都可以写成

$$V_0 = \sum_{i=1}^n \pi_i X_i,$$

那么  $\pi_i$  就称为状态  $\omega_i$  的状态价格.

#### 定义 6.106 (状态价格).

**状态价格 (state price)** 是指一份在某个特定未来状态支付一单位货币, 而在其他状态支付零的基本证券在今天的价格.

状态价格不是现实概率. 它已经同时包含了概率, 贴现和风险补偿. 如果所有状态价格都为正, 并且一单位确定到期现金流的价格为

$$P(0, T) = \sum_{i=1}^n \pi_i,$$

那么可以把状态价格归一化为

$$q_i = \frac{\pi_i}{P(0, T)}.$$

于是

$$q_i > 0, \quad \sum_{i=1}^n q_i = 1.$$

这组  $q_i$  在形式上就是一个概率分布. 在它之下, 价格公式变成

$$V_0 = P(0, T) \sum_{i=1}^n q_i X_i = P(0, T) \mathbb{E}^Q[X_T].$$



**定义 6.107 (风险中性概率).**

由状态价格经过贴现归一化以后得到的概率测度称为**风险中性概率**或**风险中性测度**. 在这个测度下, 可交易资产的贴现价格具有“平均不变”的定价形式.

这里最容易误解的一点是:

$$\mathbb{Q} \neq \mathbb{P}.$$

现实概率测度  $\mathbb{P}$  描述我们认为世界实际上怎样随机变化; 风险中性测度  $\mathbb{Q}$  描述市场价格在无套利约束下怎样给未来状态现金流定价.

如果一只股票在现实世界里有风险溢价, 那么通常

$$\mathbb{E}^{\mathbb{P}}[S_T]$$

会高于简单滚动无风险资产得到的未来金额. 但在风险中性测度下, 无股息可交易资产的价格满足

$$S_0 = P(0, T)\mathbb{E}^{\mathbb{Q}}[S_T].$$

这不是说投资者真的认为股票没有风险溢价, 而是说风险溢价已经被吸收到从  $\mathbb{P}$  到  $\mathbb{Q}$  的测度变换之中.

所以风险中性定价并不是“假装世界没有风险”. 它是在无套利市场中, 把风险补偿和贴现折进一个方便计算的概率测度里.

**6.7.6 随机贴现因子**

还有一种更一般的写法, 是不急着把风险调整改写成新的概率测度. 给定现实概率测度  $\mathbb{P}$ , 可以寻找一个随机变量  $M_{0,T}$ , 使任意可定价的到期现金流  $X_T$  满足

$$V_0 = \mathbb{E}^{\mathbb{P}}[M_{0,T}X_T].$$

这里的  $M_{0,T}$  称为随机贴现因子, 定价核或者 state-price density.

**定义 6.108 (随机贴现因子).**

**随机贴现因子** (stochastic discount factor) 是一个严格为正且可积的随机变量, 它作为随机权重把未来随机现金流转换成当前价格. 它同时包含跨时间贴现和跨状态风险调整.

如果只考虑确定现金流, 例如  $X_T = x$ , 那么

$$V_0 = x\mathbb{E}^{\mathbb{P}}[M_{0,T}] = xP(0, T).$$

这里退化为普通贴现因子的是进入价格的期望权重  $\mathbb{E}^{\mathbb{P}}[M_{0,T}]$ , 而不是随机变量  $M_{0,T}$  本身. 但对于随机现金流, 它还会在不同状态上给出不同权重. 那些投资者更不愿意承受的状态, 通常会具有更高的边际价值, 相应状态中的现金流也会更贵.

用条件期望写, 从时刻  $t$  到时刻  $T$  的一般定价关系可以表示成

$$V_t = \mathbb{E}_t^{\mathbb{P}}[M_{t,T}X_T].$$

如果选用货币市场账户  $B_t$  作为计价资产, 并且存在合适的风险中性测度  $\mathbb{Q}$ , 同一关系也常写作

$$\frac{V_t}{B_t} = \mathbb{E}_t^{\mathbb{Q}}\left[\frac{X_T}{B_T}\right].$$

这正是后面风险中性定价会反复使用的形式. 它也解释了为什么预测市场那一节要小心区分事件概率和事件合约价格. 如果事件  $A$  的到期支付是  $\mathbf{1}_A$ , 那么它今天的价格更一般地应该写成

$$C_0^A = \mathbb{E}^{\mathbb{P}}[M_{0,T}\mathbf{1}_A],$$

而不是简单等同于  $\mathbb{P}(A)$ . 只有在贴现, 风险溢价, 流动性和合约摩擦都已经被处理以后, 我们才可能从价格中读出某种市场隐含概率.

### 6.7.7 带摩擦的套利边界与套利限制

到目前为止, 我们写下的公式都像是精确等式. 但真实市场里, 这些等式通常会变成区间.

以远期和现货为例. 在无交易成本, 无 bid-ask, 无保证金约束, 可以自由融资和卖空的模型中, 无套利给出

$$F_{0,T} = \frac{S_0}{P(0,T)}.$$

如果先加入可以事前写进交易策略的摩擦, 例如确定的买卖价差, 手续费, 借贷利差, 做空成本和税收, 精确等式通常会放宽为形式化的无套利边界:

$$F_{0,T}^{\text{lower}} \leq F_{0,T} \leq F_{0,T}^{\text{upper}}.$$

只要价格仍然落在这个区间里, 它可能已经偏离了最干净的理论中点, 但不一定存在可执行套利. 只有当偏离大到足以覆盖这些可执行成本时, 才可能在相应模型中构造套利.

保证金追加, 基差继续扩大, 融资突然收紧, 流动性枯竭, 强制平仓和平台风险则属于另一个层次. 它们通常不能简单塞进一组确定的上下界, 而是限制交易者能否建立头寸并持有到理论关系收敛. 这类问题通常称为**套利限制** (limits to arbitrage) [SV97].

#### 原则 6.109 (套利边界和套利限制).

理论无套利关系常常给出一个没有摩擦时的价格等式. 可事前计入并能够锁定的交易摩擦可能把等式放宽成无套利边界; 融资约束, 保证金, 流动性和路径风险则可能阻止交易者把价格拉回这组边界附近. 两者有关, 但不是同一个概念.

这也解释了为什么做市商大量卖出期货, 或者某一侧订单流突然变得很重时, 期货价格可以相对现货出现偏移. 这并不自动说明市场已经出现了免费午餐. 可能只是说明某些参与者的库存约束, 风险限额, 对冲需求或者融资成本暂时改变了价格所在的位置.

如果期货相对现货显著偏贵, 典型 cash-and-carry 方向是买入现货并卖出期货; 如果期货显著便宜, 反向交易则需要卖空现货并买入期货. 但这些交易都需要资产借贷, 融资, 保证金, 交易容量和持有到收敛的能力. 一旦中间基差继续向不利方向扩大, 交易者可能在最终收敛以前就被追加保证金或者风控线迫出局.

PERP 更能说明这一点. 永续合约没有到期交割, 所以它不能依靠“到期时交割现货”强制收敛. 它通常依赖资金费率把合约价格和参考指数之间的偏离转化为多空双方之间的定期现金流. 当 PERP 明显高于现货指数时, 多头往往需要向空头支付 funding, 从而吸引

$$\text{long spot} + \text{short perp}$$

这类交易. 当 PERP 明显低于现货指数时, 方向则反过来.

但这仍然不是无风险套利. 资金费率会变化, 基差可能继续扩大, 保证金可能被耗尽, 参考指数可能有构造问题, 交易所也可能出现风控, 强平和流动性问题. 所以 PERP 里的所谓套利, 更准确地说通常是带有路径风险和平台风险的相对价值交易.

#### 注 6.110 (做市商和套利).

做市商的基本业务不是无风险套利. 它们通过买卖报价向市场出售即时流动性, 价差和返佣可能形成毛收入; 对冲和库存管理则用于控制库存风险, 逆向选择风险和价格风险, 同时往往会产生新的交易与融资成本.

当跨市场价格出现明显偏离时, 做市商当然可能参与套利或者相对价值交易. 但这只是它们活动的一部分, 并不意味着做市本身就是没有风险的套利机器.

ETF 创建赎回和国债基差交易也是同一个道理. ETF 市场价格和底层篮子价值之间存在套利力量, 但 AP 需要承担交易成本, 底层资产流动性, 创建赎回流程和融资成本. 国债现券和期货之间有交割机制和基差收敛逻辑, 但高杠杆交易者可能在 repo 展期, haircut 上调, 期货保证金追加和强制去杠杆的中间路径中被迫退出.

因此, 无套利不是说市场价格永远贴着某条理论公式不动. 更准确地说, 无套利是在问:

给定交易规则, 融资条件, 摩擦和风险约束,  
是否存在一组不花钱, 不会亏, 且有机会赚钱的可执行策略?

如果答案是否定的, 市场就仍然可以被视为满足相应意义下的无套利. 即使价格表面上已经偏离了某个理想模型中的中点.

### 6.7.8 通往鞅和金融市场基本定理

最后把这一节和后面的随机过程连接起来.

在离散时间或者连续时间模型中, 资产价格本身会随时间变化. 交易者可以动态调整头寸. 于是无套利不再只是比较两个终端现金流, 还要约束整个价格过程.

非常粗略地说, 金融市场基本定理告诉我们: 在合适技术条件下, 无套利和某种等价鞅测度的存在密切相关. 如果用货币市场账户  $B_t$  作为计价资产, 并用  $D_t$  表示资产截至时刻  $t$  已经支付的累计现金流, 那么在风险中性测度  $\mathbb{Q}$  下, 贴现累计收益过程

$$\frac{S_t}{B_t} + \int_{(0,t]} \frac{1}{B_u} dD_u$$

在合适技术条件下是局部鞅. 当它进一步满足可积性并成为真鞅时, 才可以写成条件期望等式. 特别地, 对于期间没有现金流的资产, 这时有

$$\frac{S_t}{B_t} = \mathbb{E}_t^{\mathbb{Q}} \left[ \frac{S_T}{B_T} \right].$$

#### 注 6.111 (完备市场和不完备市场).

无套利通常保证价格不会乱到产生免费午餐. 但它不一定保证每一个未来现金流都有唯一价格.

如果每个相关现金流都可以由可交易资产复制, 市场称为完备, 定价测度通常唯一. 如果市场不完备, 可能存在多个与无套利相容的定价测度, 某些现金流只能得到无套利价格区间.

这也是为什么随机过程会真正进入金融市场. 如果只讨论确定现金流, 贴现曲线已经足够. 但一旦现金流取决于未来状态, 取决于路径, 或者取决于交易者能否连续调整头寸, 我们就需要描述资产价格, 利率, 波动率, 订单流和流动性怎样随时间随机演化.

后面的金融市场应用部分中, 风险中性定价, Black-Scholes 模型, 利率模型和波动率模型都会不断回到这里:

贴现 + 无套利 + 随机过程  $\rightarrow$  动态定价模型.

## 6.8 交易、订单簿与市场微观结构

上一节讨论贴现和无套利时, 我们把资产价格写成一个统一的过程  $S_t$ , 并关心不同资产和现金流之间应该满足怎样的价格关系. 这种抽象对于定价非常有用, 但它暂时省略了一个更加贴近交易现场的问题:

一笔订单进入市场以后, 究竟怎样变成报价, 成交和价格变化?

从“这项资产在模型中值多少”到“这笔订单最后按照什么价格成交”之间, 还隔着交易场所, 订单类型, 排队顺序, 买卖价差, 订单簿深度, 通信延迟, 其他参与者的行动以及市场本身的制度安排.

市场微观结构研究的正是这一层问题 [FPR23; Har02; Has07; Mad00; OHa95].

#### 定义 6.112 (市场微观结构).

**市场微观结构** (market microstructure) 研究市场参与者的潜在买卖意愿怎样在给定交易制度下转化为订单, 报价, 成交量和市场价格, 以及交易规则, 信息差异, 库存约束和流动性怎样影响这一过程.

在“资产, 价格与收益”一节中, 我们已经区分了最优买价  $b_t$ , 最优卖价  $a_t$ , 中间价  $m_t = (a_t + b_t)/2$  和最近成交价. 这里不会重新讨论股票价格为什么包含市场预期, 而是沿着一张订单实际经过的路径, 把这些报价和成交放回真实交易制度中.

**原则 6.113 (成交价不是价值测量).**

一笔成交的价格, 是买方和卖方在某个时刻, 某个场所和某套交易规则下实际完成交换的价格.

它可能包含关于资产未来价值的信息, 但也会受到交易紧迫性, 订单规模, 当前库存, 融资约束和订单簿状态影响. 因此

成交价格  $\neq$  被直接测量出来的唯一真实价值.

一笔成交只能说明双方的订单在当时的市场规则下形成了可执行匹配, 不能机械地说明双方已经形成完全相同的价值判断.

**6.8.1 从一张订单进入市场开始**

在一个典型的电子证券市场中, 一张订单可能经历下面这条路径:

投资者或交易策略  $\rightarrow$  经纪商与交易前检查  
 $\rightarrow$  订单路由  $\rightarrow$  交易场所  $\rightarrow$  撮合引擎  
 $\rightarrow$  成交, 留簿, 撤销或者拒绝.

这只是一条示意路径. 有些机构可以直接接入交易场所, 有些订单会由经纪商内部执行, 还有些订单会被发送到不公开展示完整订单簿的场所. 但无论具体路径怎样, 都需要先区分

作出投资决策  $\neq$  提交订单  $\neq$  订单已经成交.

订单首先只是一项交易指令. 它只有在通过相应检查, 到达一个可以执行交易的场所, 并且遇到满足条件的对手方以后, 才可能产生实际成交.

**交易场所与参与者****定义 6.114 (交易场所).**

**交易场所** (trading venue) 是按照一组既定规则接收和执行交易指令的市场组织或者交易系统.

交易所的公开限价订单簿, 另类交易系统, 暗池, 以及由交易商或者经纪商提供的内部执行系统, 都可能构成不同形式的交易场所.

同一项证券可能同时在多个场所交易. 因此一个场所自己的最优报价, 和投资者通过多个场所能够观察到的整体最优报价, 并不一定完全相同. 不同场所还可能具有不同的费用, 速度, 优先规则, 隐藏流动性和参与者结构.

参与交易的人也不只有最终投资者. 经纪商负责接收和路由客户订单; 做市商和其他流动性提供者提交可以被别人执行的报价; 套利者或者相对价值交易者连接不同资产和不同场所之间的价格; 交易场所则按照自己的规则组织订单和成交.

这些角色不是互相排斥的永久身份. 普通投资者提交一张等待成交的限价单时, 也可能暂时成为流动性提供者; 做市商有时同样会主动执行别人留下的报价; 套利者也可能承担库存, 基差, 融资和执行风险.

**订单包含什么**

固定一项资产以后, 可以把一张经过简化的订单写成

$$o = (s, q, \ell, \tau, \kappa),$$

其中  $s$  表示买入或者卖出方向,  $q > 0$  表示数量,  $\ell$  表示价格限制,  $\tau$  表示订单被交易场所接受的时间, 而  $\kappa$  汇总有效期, 展示方式和其他执行条件. 现实订单还可能包含路由, 是否允许部分成交, 是否只在特定时段生效等更多字段.

**定义 6.115 (订单).**

**订单** (order) 是市场参与者按照给定方向, 数量和执行条件, 请求买入或者卖出某项资产的指令.

一张订单可以被拒绝, 立即成交, 部分成交, 或者以未成交余额进入订单簿等待.

实际系统通常还会检查交易权限, 可用资金, 持仓和风险限额, 价格保护区间以及市场当前是否开放. 所以即使交易者已经按下“买入”或者“卖出”, 订单也不一定已经到达公开市场, 更不一定会按照屏幕上最后看到的价格成交.

**6.8.2 市场单, 限价单与订单簿****定义 6.116 (市场单, 限价单与撤单).**

**市场单** (market order) 以尽快成交为主要目标, 接受按照当时可用的对手方报价逐级执行. 它提高了成交的即时性, 但不会保证一个精确的执行价格.

**限价单** (limit order) 指定交易者能够接受的最差价格. 买入限价单不会按照高于限价的价格成交; 卖出限价单不会按照低于限价的价格成交.

**撤单** (cancellation) 是在订单尚未完全成交以前, 请求删除其剩余数量的指令. 已经发生的成交不能通过撤单倒回.

如果当前最优卖价为  $a_t$ , 那么限价为  $\ell$  的买单在  $\ell \geq a_t$  时已经可以立即和卖盘成交. 类似地, 限价卖单在  $\ell \leq b_t$  时已经可以立即和买盘成交. 这种订单通常称为**可成交限价单** (marketable limit order).

因此市场单和限价单并不分别对应两类永远主动或者永远被动的交易者. 一张价格足够积极的限价单也可以立即穿过价差; 一张原本留在订单簿中的限价单, 则可能在后来被新的对手方订单击中.

市场单主要承担**价格不确定性**: 它通常能够较快成交, 却可能逐级扫过多个价位. 限价单主要承担**成交不确定性**: 它限制了最差价格, 却可能只得到部分成交或者完全不成交.

撤单本身也需要传输和处理时间. 如果成交先于撤单生效, 相应成交仍然成立. 在很多市场中, 修改价格或者增加数量还会被视为撤销旧订单并提交新订单, 从而失去原来的时间优先位置.

**订单簿作为市场状态****定义 6.117 (限价订单簿与深度).**

**限价订单簿** (limit order book) 是交易场所按照买卖方向, 限价和优先顺序组织尚未成交限价单的记录.

某个价位上尚未成交的订单数量称为这个价位的**订单簿深度** (depth).

令  $\mathcal{O}_t$  表示时刻  $t$  仍然留在订单簿中的订单集合. 可以定义

$$Q_t^b(p) = \sum_{\substack{o \in \mathcal{O}_t \\ s(o)=\text{buy} \\ \ell(o)=p}} q_t^{\text{rem}}(o), \quad Q_t^a(p) = \sum_{\substack{o \in \mathcal{O}_t \\ s(o)=\text{sell} \\ \ell(o)=p}} q_t^{\text{rem}}(o),$$

其中  $q_t^{\text{rem}}(o)$  是订单  $o$  的剩余数量.  $Q_t^b(p)$  和  $Q_t^a(p)$  分别表示价位  $p$  上的买方深度和卖方深度. 于是前面已经出现的最优报价可以写成

$$b_t = \max\{p : Q_t^b(p) > 0\}, \quad a_t = \min\{p : Q_t^a(p) > 0\}.$$

这里没有重新定义 bid 和 ask, 只是把它们放回订单簿中:  $b_t$  是最高的非空买入价位,  $a_t$  是最低的非空卖出价位.

如果把买方报价从高到低排列, 卖方报价从低到高排列, 还可以写成

$$p_{1,t}^b > p_{2,t}^b > \cdots, \quad p_{1,t}^a < p_{2,t}^a < \cdots,$$



其中  $p_{1,t}^b = b_t$ ,  $p_{1,t}^a = a_t$ . 令  $Q_{k,t}^b$  和  $Q_{k,t}^a$  分别表示相应价格档位当前显示的买入和卖出数量, 那么订单簿状态可以粗略写成

$$\mathcal{L}_t = \left( (p_{k,t}^b, Q_{k,t}^b)_{k \geq 1}, (p_{k,t}^a, Q_{k,t}^a)_{k \geq 1} \right).$$

**注 6.118 (订单簿不是完整供需曲线).**

屏幕上显示的订单簿只是一张当前快照. 订单可以被撤销或者修改, 市场还可能隐藏订单, 冰山订单, 多个交易场所以及没有进入公开订单簿的流动性.

因此显示深度并不是一条稳定不动的市场供给或者需求曲线. 当价格开始变化时, 原本显示的订单可能消失, 新的订单也可能迅速出现.

## 撮合优先规则

**原则 6.119 (价格优先与时间优先).**

在采用价格优先和时间优先的连续限价订单簿中, 更有利于对手方的价格先执行.

对于买单, 更高的买入限价优先; 对于卖单, 更低的卖出限价优先. 当多张订单具有相同限价时, 较早被交易所接受的订单先执行.

价格优先意味着后来到达的卖价 100.01 会排在较早到达的卖价 100.02 前面. 只有当价格相同时, 时间顺序才决定谁先成交.

但价格和时间优先并不是所有市场唯一可能采用的规则. 某些衍生品市场会按照数量比例分配成交, 开盘和收盘集合竞价也使用不同的撮合过程. 隐藏订单和特殊订单类型还可能具有自己的优先级 [Gou+13].

### 6.8.3 一次撮合与交易成本

一张主动买单进入以后, 撮合引擎会从最低卖价开始消耗卖方订单; 一张主动卖单则从最高买价开始消耗买方订单. 订单数量较大时, 一次订单可以产生多笔不同价格的成交.

**定义 6.120 (成交均价与滑点).**

假设一张数量为  $Q$  的订单产生价格和数量分别为  $(p_k, q_k)$  的  $n$  笔成交, 其中  $\sum_{k=1}^n q_k = Q$ . 这张订单的成交均价定义为

$$\bar{p}(Q) = \frac{\sum_{k=1}^n p_k q_k}{Q}.$$

给定订单提交以前选定的基准价格  $p^*$ , 可以按照“正数表示执行更差”的方向定义滑点:

$$\text{Slip}_{\text{buy}} = \bar{p}(Q) - p^*, \quad \text{Slip}_{\text{sell}} = p^* - \bar{p}(Q).$$

滑点没有脱离基准价格的唯一含义. 如果  $p^*$  选择订单到达前的最优对手价, 它主要衡量订单扫过多个价位造成的额外成本; 如果选择到达时的中间价, 其中还包含跨越半个买卖价差的成本; 如果选择更早的决策价格, 等待和路由期间的市场变化也会进入结果.

**例 6.121 (一张市场买单怎样扫过订单簿).**

为了单独看清撮合机制, 以下忽略隐藏流动性, 其他交易场所以及撮合期间到达或撤销的

新订单, 并假设订单允许部分成交. 假设某只股票当前可见的部分订单簿为

| 方向 | 价格     | 显示数量 |
|----|--------|------|
| 卖出 | 100.04 | 500  |
| 卖出 | 100.03 | 200  |
| 卖出 | 100.02 | 300  |
| 买入 | 100.01 | 400  |
| 买入 | 100.00 | 600  |
| 买入 | 99.99  | 800  |

此时

$$b_t = 100.01, \quad a_t = 100.02, \quad m_t = 100.015.$$

如果一张买入 550 股的市场单到达, 撮合顺序是

300 股 按照 100.02 成交,  
200 股 按照 100.03 成交,  
50 股 按照 100.04 成交.

因而成交均价为

$$\bar{p}(550) = \frac{300 \times 100.02 + 200 \times 100.03 + 50 \times 100.04}{550} \approx 100.02545.$$

如果以订单到达前的最优卖价 100.02 为基准, 每股滑点约为 0.00545, 总额约为 3.00 单位计价货币.

撮合完成以后, 100.02 和 100.03 的卖单已经耗尽, 100.04 还剩 450 股, 因而新的最优卖价变成 100.04.

如果原订单是允许部分成交、限价为 100.03 的 550 股买单, 它只能成交前 500 股. 剩余 50 股不会继续支付 100.04; 它是留在订单簿等待还是立即取消, 取决于订单的有效期和交易场所规则.

这个例子中最后一笔成交价从 100.02 走到 100.04, 首先说明的是一张主动买单耗尽了当前显示的卖方深度. 它并不单独证明资产的基本价值刚刚提高了 0.02. 新的卖单可能很快补回, 而这张买单也可能来自信息判断, 对冲, 指数调仓或者必须立即完成的资金需求.

### 成交方向与有符号订单流

每一笔成交都同时存在买方和卖方, 所以所谓“买方发起”或者“卖方发起”并不是在说成交中只有一边存在. 它描述的是哪一方主动跨过价差, 接受了订单簿中已经存在的报价.

#### 定义 6.122 (成交方向).

对第  $i$  笔成交, 令  $v_i > 0$  表示成交数量, 并定义成交符号

$$\varepsilon_i = \begin{cases} +1, & \text{买方主动发起成交,} \\ -1, & \text{卖方主动发起成交.} \end{cases}$$

相应的有符号成交量为  $q_i = \varepsilon_i v_i$ .

于是一个时间区间内的有符号成交订单流可以写成

$$Q_{t,t+\Delta}^{\text{trade}} = \sum_{i: t_i \in (t, t+\Delta]} \varepsilon_i v_i.$$

$Q_{t,t+\Delta}^{\text{trade}} > 0$  表示这段时间内主动买入成交量较多, 并不表示成交意义上的买入数量超过卖出数量.

有些交易数据会直接记录主动方, 有些数据则只能根据成交价相对于 bid, ask 和 mid 的位置进行推断. 成交发生在价差内部, 或者成交和报价的时间戳没有完全同步时, 这种推断可能出错 [LR91].

还需要区分三个相近但不同的概念: 成交不平衡只统计已经完成的主动买卖成交; 订单流不平衡还可以把限价订单的加入, 撤销和被成交考虑进去; 订单簿不平衡则描述某个时刻买卖两侧显示深度的差异.

例如最优报价上的队列不平衡可以写成

$$J_t = \frac{Q_{1,t}^b - Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a}.$$

$J_t > 0$  只表示当前最优买价上的显示数量较多. 它并不保证下一笔价格变化一定向上, 因为显示订单可以撤销, 更深档位和其他交易场所中的流动性也没有出现在这个数字里.

### 报价价差, 有效价差与实现价差

最优报价给出的

$$QS_i = a_i - b_i$$

称为**报价价差** (quoted spread). 但成交不一定恰好发生在最优 bid 或 ask, 所以报价价差不一定等于投资者真正付出的交易成本.

令第  $i$  笔成交发生在时刻  $t_i$ ,  $p_i$  表示成交价格,  $m_{t_i^-}$  表示成交前一刻的中间价,  $\varepsilon_i$  表示成交方向. 定义

$$ES_i = 2\varepsilon_i(p_i - m_{t_i^-}),$$

称为**有效价差** (effective spread). 系数 2 把一侧成交相对于 mid 的价格让步写成往返交易口径.

再选定一个日历时间长度  $h > 0$ , 定义

$$RS_i(h) = 2\varepsilon_i(p_i - m_{t_i+h})$$

为**实现价差** (realized spread), 同时定义成交后的有符号价格变化

$$PI_i(h) = 2\varepsilon_i(m_{t_i+h} - m_{t_i^-}).$$

于是存在恒等式

$$ES_i = RS_i(h) + PI_i(h).$$

这个分解把成交时相对于中间价支付的成本, 和随后同方向发生的报价变化分开了. 但实现价差仍然不等于做市商的实际利润: 它依赖观察窗口  $h$ , 而且没有自动扣除对冲, 手续费, 返佣, 库存, 融资和其他头寸产生的成本 [HS97].

#### 6.8.4 流动性不是一个数

前面已经把流动性粗略解释成“能否在较短时间内完成足够数量的交易, 而不需要作出过大的价格让步”. 现在可以把这个概念拆得更细一些.

##### 原则 6.123 (流动性的多个维度).

一个市场是否具有流动性, 不能只由成交量, 买卖价差或者任何单独一个指标决定. 流动性至少涉及紧度, 深度, 即时性, 韧性和交易容量等不同维度.

**紧度**关心买卖报价之间有多近, 通常由报价价差或者有效价差描述.

**深度**关心当前价格附近能够吸收多少数量, 通常由订单簿各档数量或者价格冲击斜率描述.

**即时性**关心交易者需要等待多久, 或者需要作出多大价格让步才能立即完成交易.

**韧性**关心一笔大额订单或者一次冲击以后, 订单簿, 价差和市场深度能够多快恢复.

**交易容量**则关心订单规模不断增大时, 平均成交价格 and 总执行成本怎样恶化.

假设市场 A 的报价价差只有 0.01, 但最优报价上只有 100 股; 市场 B 的报价价差是 0.05, 但附近能够吸收 100,000 股. 对于一笔 50 股订单, 市场 A 可能更加流动; 对于一笔 50,000 股订单, 只看最优价差却可能得到完全错误的结论.

成交量和换手率同样不能单独代表流动性. 很高的成交量可能来自市场双方稳定提供报价, 也可能来自恐慌期间的大量主动卖单不断扫过正在撤退的买盘. 后一种市场看起来非常活跃, 实际执行成本却可能正在快速上升.

还可以根据最优买卖两侧的数量构造**微价格** (microprice)

$$\mu_t = \frac{a_t Q_{1,t}^b + b_t Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a}.$$

当买方队列更大时,  $\mu_t$  会更接近卖价; 当卖方队列更大时, 它会更接近买价. 微价格可以作为短期订单簿压力的一种统计摘要, 但它仍然不是公允价值, 也不能脱离具体市场和时间尺度被当成稳定预测公式.

### 6.8.5 买卖价差为什么存在

买卖价差有时被简单理解成做市商按照 bid 买入, 再按照 ask 卖出以后得到的利润. 问题在于, 做市商不能保证先在一边成交以后, 立刻在另一边成交相同数量. 两边订单到达的时间和规模并不相同, 信息和价格也可能在持有库存期间发生变化.

价差通常同时反映几类因素: 处理订单和维持交易系统需要成本; 最小报价单位, 交易费用 and 市场竞争会影响报价; 流动性提供者需要暂时承担库存风险; 而且和自己成交的交易者可能拥有更加及时的信息.

#### 信息交易与流动性交易

##### 定义 6.124 (信息交易与流动性交易).

如果交易者的订单和当前价格尚未充分反映的信息相关, 就称这类交易为**信息交易** (informed trading).

如果交易主要来自现金需求, 指数调仓, 对冲, 风险限额或者其他并不以预测资产价值为核心的原因, 在微观结构模型中常把它称为**噪声交易**或者**流动性交易**.

这里的“噪声”并不是说交易者愚蠢或者不理性. 它只是表示这笔订单相对于当前研究的价值信息而言, 没有同样强的方向性信息.

同一个交易者也可能同时具有多种动机. 一笔基金赎回产生的卖单可能主要来自流动性需求, 但负责执行的人仍然可能根据短期市场状态选择交易时机. 所以信息交易者和流动性交易者首先是模型角色, 不是能够根据账户名称识别的永久身份.

#### 逆向选择

假设流动性提供者根据现有信息给出 bid 和 ask. 如果某些交易者比它更早知道影响资产价值的信息, 这些交易者就会选择只在旧报价对自己有利时成交.

当好消息尚未进入报价时, 信息交易者更愿意按照旧 ask 买入; 当坏消息尚未进入报价时, 他们更愿意按照旧 bid 卖出. 流动性提供者因此更容易在报价已经过时成交, 这就是**逆向选择** (adverse selection).

在 Glosten-Milgrom 类型的简化模型中, 令  $V$  表示模型中的未来结算价值,  $\mathcal{F}_t$  表示做市商报价以前拥有的信息. 如果竞争性, 风险中性的做市商忽略库存和处理成本, 并按照条件期望实现零预期利润, 那么报价可以直观地写成

$$a_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = +1, \mathcal{F}_t],$$

以及

$$b_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = -1, \mathcal{F}_t].$$

如果主动买入更可能携带好消息, 主动卖出更可能携带坏消息, 那么信息不对称本身就能够产生正的买卖价差 [GM85].

这里的  $V$  是模型为了研究信息结构引入的潜在变量, 并不是现实中能够被直接观察的“真正价格”. 这个模型也不是说现实中的全部价差都来自逆向选择.

### 库存风险

做市商还需要管理已经积累的头寸. 如果客户连续向做市商卖出, 做市商会不断增加多头库存; 如果客户连续买入, 做市商则可能积累空头库存.

一个很粗的局部表达是

$$c_t = \hat{v}_t - \kappa_t H_t,$$

其中  $\hat{v}_t$  是做市商根据当前信息形成的参考价格,  $H_t$  是库存, 并约定  $H_t > 0$  表示多头库存,  $\kappa_t > 0$  表示库存约束的强弱. 报价可以围绕这个中心写成

$$b_t = c_t - \frac{s_t}{2}, \quad a_t = c_t + \frac{s_t}{2}.$$

当做市商多头库存过多时, 降低报价中心会使继续买入变得不那么有吸引力, 同时提高把库存卖出去的机会. 它也可以减少某一侧报价数量, 或者通过其他市场和相关资产进行对冲 [HS81].

这只是库存模型的直觉表达, 不是所有订单簿都必须满足的报价公式. 现实报价还会受到其他做市商, 普通限价订单交易者, 费用规则和风险限额影响.

#### 注 6.125 (做市不是无风险套利).

做市商出售的是即时成交能力, 同时承担库存, 逆向选择, 跳价, 对冲, 融资和操作风险.

报价价差只是两侧报价之间的差异, 不是已经锁定的利润. 做市商可能在一侧成交以后迟迟找不到另一侧订单, 也可能在重新对冲以前遭遇不利价格变化.

### 6.8.6 订单流与价格冲击

订单流之所以重要, 并不只是因为一张大订单能够机械地扫过订单簿. 订单还可能携带信息. 其他参与者观察到成交方向, 数量和速度以后, 会重新判断自己面对的是暂时资金需求, 还是尚未充分进入价格的新信息.

#### Kyle lambda

Kyle 模型把信息交易, 噪声交易和价格冲击放进了同一个序贯拍卖框架 [Kyl85]. 为了先看清核心机制, 这里抽取其中一次拍卖的线性定价表示.

令  $V$  表示模型中的未来价值, 信息交易者提交订单  $X$ , 噪声交易者提交订单  $U$ . 做市商只能观察到总订单流

$$Y = X + U,$$

却不能直接知道其中哪一部分来自信息. 于是竞争性做市商按照观察到的  $Y$  更新价格:

$$p = \mathbb{E}[V | Y].$$

在线性均衡中, 这条定价规则可以写成

$$p = p_0 + \lambda Y.$$

其中  $p_0 = \mathbb{E}[V]$  是做市商观察本次总订单流以前的先验价格.

#### 定义 6.126 (Kyle lambda).

系数  $\lambda$  称为 **Kyle lambda**. 它表示在给定模型, 单位和时间尺度下, 有符号净订单流增加一单位时价格改变多少.

$\lambda$  越大, 同样数量的订单流对应的价格变化越大;  $1/\lambda$  因而可以被理解成一种市场深度.



Kyle lambda 不等于买卖价差. 一个描述订单流和价格变化之间的斜率, 另一个描述同时存在的买卖报价之间的距离.

它也不是能够从一个模型直接搬到所有市场的常数. 现实中的经验  $\lambda$  会随着资产, 样本, 单位, 时间尺度, 波动率, 市场深度和交易制度变化.

### 成交不平衡与经验价格冲击

在交易数据中, 人们有时使用局部关系

$$\Delta m_{t,t+\Delta} = \alpha_{\Delta} + \beta_{\Delta} Q_{t,t+\Delta}^{\text{trade}} + \eta_{t,\Delta}$$

估计有符号成交量和中间价变化之间的关系. 这里的  $\beta_{\Delta}$  只是给定样本和时间窗口中的简约形式斜率, 没有额外识别假设时并不等于结构模型中的 Kyle lambda.

上式中的  $Q_{t,t+\Delta}^{\text{trade}}$  只统计已经发生的成交. 经验研究中所谓的订单流不平衡 (order flow imbalance, OFI) 还可以把最优报价的移动、限价订单加入和撤单造成的队列变化纳入, 而不是把这些事件统称为成交量. 在很短的时间尺度上, 最优报价附近的供需变化通常比单独使用成交量更加接近订单簿真正承受的压力 [CKS14].

但回归关系本身不能自动证明因果方向. 信息交易者可能因为预见到未来价格变化而先行交易; 其他参与者也可能同时撤单或者重新报价. 所以“订单流和价格变化相关”不能被机械翻译成“这一笔交易凭空创造了同样数量的资产价值”.

### 暂时冲击与永久冲击

一张主动订单首先可能机械地消耗当前订单簿. 如果后续限价订单很快补回, 价差和中间价可能部分恢复. 这部分通常称为**暂时冲击**.

如果订单透露了市场此前不知道的信息, 其他参与者可能持续修改自己的判断和报价. 即使订单簿重新变厚, 价格也未必回到交易以前的位置. 这部分通常称为**永久冲击**或者**信息冲击**.

设第  $i$  笔成交发生在  $t_i$ , 交易前中间价为  $m_{t_i^-}$ . 可以考察给定时距  $h$  下的有符号价格响应

$$R(h) = \mathbb{E} \left[ \varepsilon_i \left( m_{t_i+h} - m_{t_i^-} \right) \right].$$

如果  $R(h)$  随  $h$  增加逐渐回落, 可以把其中的回落部分理解成暂时成分; 如果它在较长时间以后仍然保留, 则可能包含更加持久的信息成分.

不过现实数据中的分解不会像语言上这么干净. 在等待  $h$  的过程中, 新消息和新订单仍然不断到达; 拆单策略还会使订单流本身具有持续性. 因此所谓“永久”始终是相对于某个模型和观察窗口而言, 并不表示我们已经识别出一笔交易对于资产真实价值直到永远的因果影响.

### 6.8.7 时间尺度, 点过程与市场状态

日线数据通常把一天压缩成开盘价, 最高价, 最低价, 收盘价和成交量. 但在订单簿内部, 市场不是每隔一秒整齐地向前走一步. 订单到达, 撤销和成交发生在不规则时刻, 而市场活跃程度本身也会不断变化.

#### 定义 6.127 (日历时间, 事件时间与成交时间).

**日历时间** (calendar time) 使用秒, 毫秒或者其他物理时间单位记录市场状态.

**事件时间** (event time) 按照订单提交, 撤销, 修改, 成交或者报价变化的先后顺序为事件编号.

**成交时间** (transaction time) 只保留实际成交, 按照第 1, 2, ... 笔成交推进时钟.

令  $\tau_n$  表示第  $n$  个订单簿事件的日历时间, 并令

$$N(t) = \sum_{n \geq 1} \mathbf{1}_{\{\tau_n \leq t\}}$$

表示截至时刻  $t$  已经发生的事件数量. 相邻事件之间的等待时间为

$$W_n = \tau_n - \tau_{n-1}.$$

一分钟在安静市场中可能只包含几个事件，在剧烈波动时却可能包含成千上万个事件。所以“每个事件以后价格平均变化多少”和“每秒价格平均变化多少”回答的是不同问题。

可以分别令  $N_i(t)$  统计第  $i$  类事件，例如买入限价单，卖出限价单，主动买单，主动卖单，买方撤单和卖方撤单。给定事件发生以前的信息  $\mathcal{F}_{t-}$ ，第  $i$  类事件的条件强度  $\lambda_i(t)$  可以通过

$$\mathbb{P}(N_i(t + \Delta t) - N_i(t) = 1 \mid \mathcal{F}_{t-}) = \lambda_i(t)\Delta t + o(\Delta t)$$

理解。它描述的是在当前市场历史和订单簿状态下，下一小段时间内某类事件发生的瞬时速率。

最简单的起点是把订单事件建模成 Poisson 过程。但真实市场通常具有开盘和收盘季节性，事件会成群出现，不同类型的订单也会相互影响。因此一个更现实的模型可能让强度依赖当前订单簿状态

$$\lambda_i(t) = f_i(\mathcal{L}_{t-}),$$

或者使用 Hawkes 过程描述事件之间的自激发和交叉激发 [BMM15; CST10]。

例如一笔主动卖单以后，短时间内可能出现更多主动卖单，也可能引起买方限价单撤销或者新的买方报价进入。但统计上的事件聚集不自动证明经济因果：共同新闻，拆单策略和没有被模型观察到的市场状态都可能产生类似现象。

### 数据看到的只是市场的一部分

成交与报价数据记录成交和最优报价；订单簿快照记录若干档深度；逐消息数据进一步记录订单提交，修改和撤销。经纪商自己的订单数据还可能包含发送时间，确认时间，排队估计和实际执行结果。

即使数据足够详细，仍然需要小心时间戳精度，时钟同步，消息延迟和乱序问题。同一个进入订单可能产生多笔成交和多条订单簿更新；多个事件也可能共享同一个粗粒度时间戳。

单一场所的订单簿也不等于整个市场的订单簿。同一资产可能同时在多个交易所，另类交易系统，暗池和经纪商内部系统中交易。合并行情可以提供重要线索，却仍然不能自动还原一个没有延迟，没有隐藏流动性的“全市场真实订单簿”。

#### 注 6.128 (碎片化与暗池)。

市场碎片化可以让不同场所围绕费用，速度和服务竞争，但也会把流动性分散到不同地方。

暗池和其他非公开场所可能帮助大额订单减少交易前信息泄露，却通常不保证执行，也会降低研究者能够观察到的交易前信息。

因此“最好的显示价格”和“最好的实际执行结果”不是同一个概念；单一场所的显示深度也不是全部可交易流动性。

### 流动性枯竭与交易中斷

显示在订单簿中的流动性是一种有条件的交易意愿，不是无论市场怎样变化都必须留在原地的资本承诺。新的信息到来，波动上升或者库存风险逼近限额时，交易者可以撤单，减少数量或者把报价移得更远。

于是市场可能形成反馈：

订单失衡或价格冲击  $\rightarrow$  库存与风险限额收紧  
 $\rightarrow$  撤单，深度下降和价差扩大  
 $\rightarrow$  后续订单产生更大价格冲击。

如果这一过程在很短时间内造成异常剧烈的价格运动，并可能伴随快速的部分反转，通常会被称为**闪崩** (flash crash)。闪崩不应该被预先压缩成一个单一原因。大额自动执行，单边订单流，流动性撤出，跨市场传导，风控行为和交易算法之间的反馈都可能共同参与 [Kir+17]。

交易中斷，临时集合竞价和价格限制是市场面对极端状态时可能采用的制度工具。它们可以暂时停止连续撮合，让报价和风险系统重新评估市场状态，却不会消除原来的买卖失衡，也不会保证重开以后价格回到某个预先确定的价值。

### 6.8.8 从订单簿走向交易执行

一张限价单被放进订单簿以后, 只知道它的价格仍然不够. 在价格优先, 时间优先的市场中, 同一价格上排在它前面的订单会先获得执行.

假设我们在时刻  $t_0$  提交一张价格为  $p$ , 数量为  $q$  的限价单, 并令  $A_{t_0}(p)$  表示当时排在它前面的可见数量. 在一个理想化的先进先出队列中, 令  $D_t(p)$  表示从  $t_0$  到  $t$  从队列前端有效消耗的累计数量. 那么首次成交时间可以粗略写成

$$\tau_{\text{first}} = \inf\{t \geq t_0 : D_t(p) > A_{t_0}(p)\},$$

完全成交时间则可以写成

$$\tau_{\text{full}} = \inf\{t \geq t_0 : D_t(p) \geq A_{t_0}(p) + q\}.$$

但普通订单簿快照通常不能准确识别每一笔撤单原来位于队列的哪里. 隐藏数量, 冰山订单, 优先规则和消息延迟也会使真实排队位置难以观察. 因此现实中的排队位置和执行概率经常只能估计.

一张限价单很快成交也不一定是好事. 它可能恰好在新的卖压到来时买到股票, 随后中间价继续下降. 此时订单取得了执行, 却同时遭遇逆向选择.

所以市场单和限价单之间不存在脱离情境的固定优劣:

市场单: 较高成交确定性 + 价差与滑点,

限价单: 价格保护 + 排队, 未成交和逆向选择风险.

如果一张母订单的规模为  $Q$ , 交易者还可以把它拆成若干子订单

$$q_1, \dots, q_n, \quad \sum_{k=1}^n q_k = Q.$$

拆单可以避免一次性扫过过多订单簿深度, 并等待新的流动性补充; 但执行得更慢也会延长价格风险暴露, 增加信号失效和交易意图泄露的可能.

如果全部订单已经完成, 平均执行价格为

$$\bar{P}^{\text{exec}} = \frac{1}{Q} \sum_{k=1}^n q_k P_k^{\text{exec}},$$

那么相对于决策价格  $P^{\text{decision}}$  的实施差额可以粗略写成 [Per88]

$$\text{IS} = \varepsilon Q (\bar{P}^{\text{exec}} - P^{\text{decision}}) + \text{费用},$$

其中  $\varepsilon = +1$  表示买入,  $\varepsilon = -1$  表示卖出. 如果订单没有完成, 还需要把剩余数量的机会成本放进来.

实施差额是一个结果指标, 不能被机械地全部解释成市场冲击. 在执行期间发生的公共信息, 市场整体变化和其他参与者的交易同样会影响价格.

怎样在市场冲击, 价格风险和未完成风险之间作出权衡, 正是后面交易执行模型需要处理的问题 [AC01].

### 6.8.9 通往订单流和市场冲击模型

现在可以把订单簿写成一个随事件变化的随机状态过程. 令

$$X_t = (b_t, a_t, Q_{1,t}^b, Q_{1,t}^a, Q_{2,t}^b, Q_{2,t}^a, \dots)$$

表示时刻  $t$  的订单簿状态. 第  $n$  个事件还可以携带标记

$$Z_n = (\text{类型}, \text{方向}, \text{价格}, \text{数量}, \text{场所}).$$

订单簿在事件到来时按照

$$X_{\tau_n} = \Phi(X_{\tau_n-}, Z_n)$$

发生跳变. 沿着事件时刻把这些跳变累加, 还可以直接写成

$$X_t = X_0 + \sum_{\tau_n \leq t} [\Phi(X_{\tau_n-}, Z_n) - X_{\tau_n-}].$$

这给出了标记点过程和订单簿状态过程之间最直接的接口. 它也说明最简单模型中的单一价格  $S_t$  究竟压缩掉了多少信息: 买价, 卖价, 价差, 多档深度, 订单流, 排队位置和交易制度都没有出现在一个标量价格中.

从这里继续往前, 会出现三组自然的随机过程问题:

订单到达与撤销  $\rightarrow$  事件强度和聚集性,  
 订单流与订单簿状态  $\rightarrow$  价格响应和市场冲击,  
 随机成交与剩余头寸  $\rightarrow$  交易执行和随机控制.

这时金融市场中的价格过程就不再只是从外部给定的  $S_t$ . 在更细的时间尺度上, 价格, 订单流, 流动性和交易者行动会共同演化:

订单事件  $\rightarrow$  订单簿状态  $\rightarrow$  成交与库存  $\rightarrow$  价格响应  $\rightarrow$  执行成本.

市场微观结构并没有把市场变成一台可以被完全还原的机械装置. 它只是提醒我们: 模型中的价格过程不是凭空出现的, 而是大量订单, 信息和约束在具体交易制度中相互作用以后形成的可观察投影.

## 第七章 基本面分析

前面的金融市场基础章节主要在回答：市场里有哪些可以交易的权利，它们怎样形成价格，又怎样通过利率，期限，抵押品和美元资金体系连接在一起。这些内容更像是在搭建市场对象的地图。

但真正进入股票研究或者交易体系时，我们还需要另一层语言：一家公司怎样赚钱，哪些经营变量决定未来利润，这些判断怎样变成估值，以及当前价格相对可能结果到底处在什么位置。这一层问题已经不只是市场制度，而是**基本面分析**。

在很多基本面量化问题中，最困难的第一步往往不是计算本身，而是把事件，语境和叙事翻译成合适的变量和值。例如“竞争格局恶化”本身还不是一个模型输入；它必须进一步变成价格压力，市占率变化，客户留存率，利润率压缩或者估值倍数下调等可讨论的量。如果这一步翻译得不好，后面再复杂的公式也只是在精致地处理一个坏输入。

本章先从 Risk-Reward 框架开始。原因很简单：它既保留了基本面研究中关于商业模式，驱动因素和估值的内容，又把这些判断压缩成 Bull, Base, Bear 等情景，从而自然接到概率论里关于状态空间，随机变量和分布的语言。

相比直接从价格序列出发的某些量化分析方式，或者主要依赖价格趋势和交易信号的趋势交易，Risk-Reward 以及我们自创的 Agentic R-D-G (Agentic R/D Graph) 可以说是本文作者更拿手，也更愿意作为主线展开的分析方式。它们并不是拒绝量化，而是把量化的入口前移：先把事件，语境，经营驱动，风险路径和情景价格组织成可以被持续更新的结构，然后再讨论概率，分布，风险暴露和交易决策。

这里的目标不是建立一套自动下单公式，也不是把个股研究变成看起来精确的数学模型。更准确地说，我们是在学习怎样把现实中的商业判断整理成可以讨论，可以比较，也可以进一步接入风险管理和组合决策的对象。

### 7.1 Risk-Reward 框架与情景分析

前面几节先把资产，衍生品，债券和短端美元资金市场这些对象讲了一遍。这些对象进入交易体系以后，还会遇到一个非常朴素的问题：如果判断是对的，大概还有多少上行空间；如果判断是错的，又要承受多大的下行损失。

只看单个投资机会时，这个问题可以先压缩成一张 Risk-Reward 图。不过真正重要的并不是图本身，也不是在图上随手写出 Bull Case, Base Case 和 Bear Case 三个价格。三个情景价格背后应该有对商业模式，经营驱动，财务结果和估值方法的判断。Risk-Reward 图只是把这些判断压缩成一种更容易比较的形式。

Morgan Stanley 的一些公开材料会用 Risk-Reward 页面组织个股情景分析，并把上行情景，中心情景，下行情景以及期权隐含概率等信息放在同一处展示 [Mor22]。本文并不试图复刻某家机构的研究模板。我们关心的是：这种框架为什么比单点目标价更接近真实投资决策，以及它怎样和前面已经介绍的随机变量，分布和风险中性定价联系起来。

为了避免和债券章节中的零息债券价格  $P(t, T)$  混淆，本节用  $S_0$  表示当前股票价格，用  $S_s(T)$  表示共同研究期限  $T$  下情景  $s$  的代表性终值。如果分红，回购或其他现金分配在研究期内很重要，则应把下面的价格收益改成包含这些现金分配的总收益。

#### 7.1.1 为什么不能只看目标价

股票研究最后经常会收敛成一个目标价。假设股票当前价格为  $S_0$ ，研究者认为期限  $T$  下的中心情景终值为  $S_{\text{Base}}(T)$ ，那么最直接的潜在上涨空间就是

$$\frac{S_{\text{Base}}(T) - S_0}{S_0}.$$

这个数字当然有用，但它只告诉我们中心情景相对现价在哪里，没有告诉我们判断失误时下方是什么形状，也没有告诉我们如果事情发展得比预期更好时上方有多厚。

例如两家公司当前价格同为 100，中心情景也同样是 120。如果把上行和下行情景放进去，它们可能完全不是同一种机会：



|   | Bull Case | Base Case | Bear Case |
|---|-----------|-----------|-----------|
| A | 160       | 120       | 90        |
| B | 130       | 120       | 50        |

只看 Base Case, 二者看起来都还有 20% 的上涨空间. 但公司 A 的上行更厚, 下行更浅; 公司 B 的中心情景虽然也高于现价, 但一旦核心假设失败, 损失可能很深.

### 命题 7.1.

单点目标价不是投资结论. 它只回答了中心情景下大概值多少钱, 还没有回答上行来自哪里, 下行会怎样发生, 以及当前价格在这些可能结果之间处于什么位置.

因此 Risk-Reward Framework 不是把目标价旁边再随便放两个数字. 它真正做的是把一个投资判断从单点估值扩展成情景分布的粗略轮廓.

### 定义 7.2 (Scenario).

一个 Scenario 是一组彼此一致的经营, 财务和估值假设. 这些假设共同描述一种可能的未来经济状态, 并最终产生相应的情景价格.

Base Case 表示当前信息下最具代表性的中心经营世界; Bull Case 说明哪些关键变量可能明显好于中心判断; Bear Case 则说明哪些核心假设可能失效, 以及这种失效怎样破坏企业价值.

## 7.1.2 情景作为状态空间的粗粒化

从概率论的角度看, 未来真正可能出现的世界当然不止三种. 我们可以把所有可能的未来状态组织成概率空间  $(\Omega, \mathcal{F}, \mathbb{P})$ . 每个样本点  $\omega \in \Omega$  代表一条足够完整的未来路径: 宏观环境, 利率, 行业需求, 公司竞争地位, 利润率, 估值倍数和市场情绪都包含在其中.

完整地研究  $\Omega$  几乎不可能. 情景分析做的是一次粗粒化: 它把复杂未来状态压缩成少数几个对当前决策最重要的类别. 例如可以定义一个可测映射

$$Y: \Omega \longrightarrow \{\text{Bear}, \text{Base}, \text{Bull}\}.$$

这里  $Y(\omega)$  不是未来价格本身, 而是告诉我们未来状态  $\omega$  被归入哪一类经济情景. 于是

$$A_s = \{\omega \in \Omega : Y(\omega) = s\}, \quad s \in \{\text{Bear}, \text{Base}, \text{Bull}\},$$

其中  $A_s \in \mathcal{F}$ . 如果这些事件互不相交且并为  $\Omega$ , 它们就给出了对未来状态空间的一组粗略划分.

由于  $\mathbb{P}$  是真实世界概率测度, 我们当然可以记  $p_s = \mathbb{P}(A_s)$ . 若三个情景构成划分, 则有

$$\sum_s p_s = 1.$$

但实务里的 Risk-Reward 图通常不一定显式给出这些主观概率. 它首先给出的是每个情景下的经济机制和情景价格.

设情景  $s$  下得到的代表性终值为  $S_s(T)$ . 那么一张三情景图可以理解成用简单随机变量

$$\tilde{S}_T = \sum_s S_s(T) \mathbf{1}_{A_s}$$

近似一个复杂得多的未来终值  $S_T$ . 这个近似肯定会丢掉大量信息, 但它迫使研究者回答几个更有决策意义的问题: 中心情景是什么, 哪些变量会把公司推向上行情景, 哪些变量又会把公司拖入下行情景.

### 注 7.3.

Base Case 不等于数学意义上的期望值. 一般没有理由认为  $S_{\text{Base}}(T) = \mathbb{E}[S_T]$ . 它更像是当前信息下最具代表性的中心经济情景, 而期望值还需要情景概率以及情景内部更细的分布

信息.

#### 注 7.4.

Bear Case 只是研究者选定的下行情景, 不是数学意义上的下界或最坏情况. 三点离散化会隐藏每个情景桶内部的分散程度, 极端尾部, 以及到达终值以前的路径风险.

这也解释了为什么 Risk-Reward 图不能只看三个价格. 真正有意义的是三组内部一致的经济世界:

Assumptions → Forecast → Valuation → Scenario Price.

### 7.1.3 从商业驱动到情景价格

为了让 Bull, Base 和 Bear 不是拍脑袋写出的数字, 每个情景都应该从企业的关键经营驱动开始.

#### 定义 7.5 (Driver Tree).

Driver Tree 指的是把企业经营活动逐层连接到收入, 利润率, 净利润, 每股收益和自由现金流的传导结构. 它试图回答的不是“明年利润会增长多少”, 而是“利润为什么会这样变化”.

不同商业模式的 Driver Tree 完全不同. 支付网络公司可能更关心支付金额, 跨境交易量, 交易笔数, 单笔业务的收费率和客户激励; 零售企业可能更关心客流, 客单价, 同店销售和毛利率; 银行则可能更关心贷款增长, 净息差, 信用损失, 费用率和资本回报率. 这些变量本身未必直接等于财务报表项目, 但会沿着经营链条传到 Revenue, Margin, EPS 或 FCF.

#### 例 7.6 (支付网络).

对支付网络公司来说, 最上游的问题不是先猜下一年收入增长率, 而是先问有多少支付活动经过网络, 跨境交易占比怎样变化, 每笔或每单位支付金额能够收取多少收入, 以及为了维持客户关系需要支付多少激励. 这些判断再进入收入, 费用, 利润率和每股收益预测.

这样做的好处是, 风险不再只是一个抽象的“股价可能下跌”. 如果 Bear Case 来自需求下降, 它应当沿着

Volume ↓ → Revenue ↓ → Margin ↓ → EPS ↓

这样的路径传导. 如果 Bear Case 来自竞争恶化, 传导路径可能是价格下降, 客户激励上升, 利润率压缩, 最后再引起估值倍数下调.

因此一份有用的情景分析至少要说明: 哪几个关键 Driver 在不同情景下发生了变化, 这些变化怎样传到财务结果, 以及财务结果变化以后为什么应该对应不同估值.

### 7.1.4 估值方法服务于商业模式

做完经营和财务预测以后, 下一步才是把这些结果转成价格. 这里需要避免一种机械想法: 不存在一种对所有企业都最正确的估值公式. 估值方法应该服从商业模式和情景本身, 而不是让所有公司硬套同一条公式.

| 估值锚                 | 更自然的使用场景                              |
|---------------------|---------------------------------------|
| P/E                 | 盈利相对稳定, 资本结构不太扭曲, 每股收益能较好代表股东经济结果的公司. |
| EV/EBIT 或 EV/EBITDA | 需要先估计经营资产价值, 再单独处理净债务和资本结构差异的公司.      |
| DCF                 | 现金流路径和资本成本是核心问题, 且需要显式展开长期假设的公司.      |
| SOTP                | 多块业务具有明显不同增长, 利润率和风险结构, 不能用单一倍数概括的公司. |
| P/B 或 P/TBV         | 银行等资产负债表本身就是商业模式核心的金融机构.              |

估值方法的基本工具可以参考公司金融和估值教材 [Dam12]. 在 Risk-Reward Framework 中, 这些工具的任务不是给出一个看似精确的唯一答案, 而是把不同情景下的基本面假设转成可比较的情景价格.

例如对使用  $P/E$  估值的公司, 最简单的价格关系是

$$S_s(T) = \text{EPS}_s \times M_s,$$

其中  $M_s$  是情景  $s$  下的合理市盈率. Bear Case 中经常不只是  $\text{EPS}_s$  下降, 还可能因为增长放缓, 风险上升或竞争优势受损, 导致  $M_s$  一起下降. 这就是盈利下修和估值压缩同时发生的情形.

同一家公司的不同情景甚至可以使用不同估值锚. 一家银行在正常环境下可能主要看未来盈利和资本回报率; 但在严重信用压力情景中, 市场可能先关心有形账面价值是否足够可靠. 这不是前后不一致, 而是因为不同情景下真正约束企业价值的经济条件已经变了.

### 7.1.5 端点偏斜与概率加权 R/D

设当前价格为  $S_0$ , 上行情景终值为  $S_{\text{Bull}}(T)$ , 下行情景终值为  $S_{\text{Bear}}(T)$ . 为了记号方便, 可以定义端点上行空间

$$U_{\text{Bull}} = \frac{S_{\text{Bull}}(T) - S_0}{S_0},$$

以及端点下行幅度

$$L_{\text{Bear}} = \frac{S_0 - S_{\text{Bear}}(T)}{S_0}.$$

当  $L_{\text{Bear}} > 0$  时,  $U_{\text{Bull}}/L_{\text{Bear}}$  可以作为一个非常粗糙的端点偏斜指标.

#### 注 7.7.

这里的  $U_{\text{Bull}}/L_{\text{Bear}}$  是本文为了讨论 Risk-Reward 形状引入的压缩记号, 不是 Morgan Stanley 报告中的固定公式, 也不是完整的期望收益, 也不是可以机械下单的评分公式. 它只是在当前研究假设下, 描述上行空间和下行损失是否对称的一种压缩记号.

如果研究者进一步愿意给情景分配真实世界主观概率  $p_s$ , 也可以令

$$\rho_s = \frac{S_s(T) - S_0}{S_0},$$

并定义概率加权的上行与下行:

$$R_{\mathbb{P}} = \sum_s p_s(\rho_s)^+, \quad D_{\mathbb{P}} = \sum_s p_s(-\rho_s)^+.$$

令  $\tilde{\rho}_T = (\tilde{S}_T - S_0)/S_0$ , 于是粗粒化后的期望收益可以写成

$$\mathbb{E}_{\mathbb{P}}[\tilde{\rho}_T] = R_{\mathbb{P}} - D_{\mathbb{P}}.$$

不过这里的难点也正好暴露出来: 真正困难的不是把几个数代入公式, 而是怎样把现实事件翻译成情景, 再把情景翻译成合理的概率和价格。

这一区分非常重要. 一家非常优秀的公司, 如果当前价格已经接近 Bull Case, 剩余上行可能并不吸引人. 一家普通公司, 如果当前价格已经接近一个相当悲观的 Bear Case, 而 Base 和 Bull 仍然有充分空间, 反而可能形成更好的 Risk-Reward.

所以 Business Quality 不等于 Investment Attractiveness. 前者是在问公司本身好不好, 后者是在问当前价格下, 这组可能结果是否值得承担。

### 7.1.6 一个虚构的三情景例子

为了避免真实公司案例随着时间迅速过期, 这里使用一个完全虚构的例子. 设公司当前价格为  $S_0 = 100$ , 研究期限为一年. 研究者认为三种情景可以粗略整理为:

| 情景   | $p_s$ | $EPS_s$ | $M_s$ | 核心假设                      |
|------|-------|---------|-------|---------------------------|
| Bull | 0.25  | 12      | 13    | 需求强于预期, 利润率扩张, 市场愿意给更高倍数. |
| Base | 0.50  | 10      | 12    | 经营大致符合中心判断, 估值倍数保持正常.     |
| Bear | 0.25  | 7       | 10    | 需求转弱, 经营杠杆反向作用, 估值倍数压缩.   |

于是三个情景终值分别为

$$S_{\text{Bull}}(T) = 12 \times 13 = 156, \quad S_{\text{Base}}(T) = 10 \times 12 = 120, \quad S_{\text{Bear}}(T) = 7 \times 10 = 70.$$

端点上行和下行分别是

$$U_{\text{Bull}} = \frac{156 - 100}{100} = 56\%, \quad L_{\text{Bear}} = \frac{100 - 70}{100} = 30\%.$$

因此端点偏斜为

$$\frac{U_{\text{Bull}}}{L_{\text{Bear}}} \approx 1.87.$$

如果进一步接受表中的主观概率, 三个情景收益率分别为 56%, 20% 和 -30%. 于是

$$R_{\mathbb{P}} = 0.25 \times 56\% + 0.50 \times 20\% = 24\%,$$

而

$$D_{\mathbb{P}} = 0.25 \times 30\% = 7.5\%.$$

所以粗粒化后的概率加权期望收益为

$$R_{\mathbb{P}} - D_{\mathbb{P}} = 16.5\%.$$

这些数字本身当然仍然只是模型输出. 真正需要审查的是: EPS 为什么能到 12 或跌到 7, 合理倍数为什么会从 12 倍扩张到 13 倍或压缩到 10 倍, 以及 0.25, 0.50, 0.25 这组概率是否真的反映当前证据。

### 7.1.7 期权隐含概率不是主观真实概率

有些 Risk-Reward 页面还会把情景价格和期权市场信息放在一起. 直观地说, 期权价格包含了市场对未来价格分布的定价信息. 但这里一定要分清两件事: 期权隐含概率不是分析师对 Bull, Base 和 Bear 的主观概率.

在无套利定价框架中, 在确定常数利率, 无套利和 payoff 适当可积等简化假设下, 欧式看涨期权价格可以写成风险中性测度  $\mathbb{Q}$  下 payoff 的折现期望:

$$C_0(K, T) = e^{-rT} \mathbb{E}_{\mathbb{Q}} [(S_T - K)^+].$$

在足够光滑的理想条件下, 不同行权价的期权价格甚至可以反推出风险中性密度的信息; 经典的 Breeden-Litzenberger 关系正是这种思想的表达 [BL78; Hul22].

但是  $\mathbb{Q}$  不是现实世界概率测度  $\mathbb{P}$ 。二者之间的差异和风险溢价, 投资者风险偏好, 供求压力以及市场微观结构有关。因此 Options-Implied Probability 更适合被理解为当前期权市场价格所隐含的定价分布信息, 而不是“市场真的认为某个基本面情景会以这个概率发生”。

这对交易体系很有用。分析师主观情景告诉我们基本面世界可能怎样展开; 期权市场告诉我们某些终端价格区域或尾部状态在市场定价中有多贵或多便宜。两者放在一起看, 可以帮助我们区分: 自己究竟是在表达基本面分歧, 波动率分歧, 还是市场对尾部风险定价的分歧。

### 7.1.8 作为交易体系的接口

Risk-Reward Framework 最适合被理解成一个接口。在它的上游, 是商业模式研究, Driver Tree, 财务预测和估值; 在它的下游, 才是仓位大小, 流动性, 相关性, 组合风险和具体执行。

$$\begin{aligned} \text{Business} &\longrightarrow \text{Drivers} \longrightarrow \text{Forecast} \longrightarrow \text{Valuation} \\ &\longrightarrow \text{Scenarios} \longrightarrow \text{Risk-Reward} \longrightarrow \text{Research Input}. \end{aligned}$$

这也说明它不是一个孤立的数学公式。如果上游 Driver 判断是空的, 那么 Bull, Base 和 Bear 只是三个装饰性的数字。如果下游没有组合和执行纪律, 那么看起来漂亮的端点偏斜也无法自动变成好的交易。

不过作为学习随机过程和金融市场之间的桥梁, 这个框架仍然很有用。它把一个复杂的未来路径空间压缩成少数几个经济情景, 把每个情景转换成可以比较的价格, 再让我们观察当前价格处在这些情景之间的什么位置。换句话说, 它把现实市场中的基本面叙事, 翻译成了一个粗糙但可讨论的随机对象。

不过到这里为止, Risk-Reward 图仍然是一种相对静态的压缩。它展示了当前研究者怎样理解几个主要情景, 但还没有完整保存: 这些情景来自哪些证据, 哪些事件通过什么机制改变了经营变量, 同一项风险有没有被重复计算, 以及新的信息到来时究竟应该修改哪一个环节。

这正是下一节要讨论的 Agentic R-D-G。

## 7.2 Agentic R/D Graph: 把研究判断组织成可更新的图

上一节把一个投资机会压缩成 Bull, Base, Bear 等少数情景, 再用这些情景价格和概率讨论上行与下行。这种压缩非常有用, 因为它让不同机会可以被放在同一张图上比较。

但它也会隐藏一个问题: 这些情景究竟是怎样从现实信息中长出来的?

如果只保留最后的几个情景价格, 过一段时间以后, 我们很容易已经忘记某个数字来自哪条证据, 某个风险通过什么机制影响公司, 以及一条新信息究竟应该修改情景价格, 情景概率, 还是只应该成为一个观察项。

所以这一节反过来做一件事: 把压缩后的情景重新展开成一张可以追踪证据, 经营驱动, 传导路径和研究边界的图。

### 定义 7.8 (Agentic R-D-G).

本文把作者自创的这种研究形式称为 Agentic R-D-G, 也写作 Agentic R/D Graph. 其中  $R$  表示潜在回报,  $D$  表示潜在下行或风险,  $G$  表示研究图。

它把预测市场信号, 市场事件, 语境, 公司局部反应, 经营驱动, 情景输入和风险路径组织成一组带有来源, 时间, 状态和责任边界的图, 使 Agent 可以持续读取, 更新, 回放和审查研究过程。

Agentic R-D-G 不是自动买卖信号, 也不是图评分公式。图的任务是保存传导结构和输入来源; 最终估值, 情景概率, R/D, 组合判断和交易执行仍然由各自的研究与决策环节负责。

因此 Agentic R-D-G 并不等于单独一张 Event Graph。为了把它和本文的随机过程主线接起来, 先给出一个粗略记号。把截至时刻  $t$  的市场状态看成一个概率空间  $(\Omega_t, \mathcal{F}_t, \mathbb{P})$ , 其中  $\mathcal{F}_t$  表示此时能够被区分和使用的信息。普通价格  $S_t$  是从这个空间读出的一个数值随机变量; Market Graph 则可以暂时记成一个图值随机变量

$$M_t: \Omega_t \longrightarrow \mathfrak{G}_{\text{mkt}}.$$

对某个市场状态  $\omega$ ,  $M_t(\omega)$  不是市场本身, 而是一张保留了事件, 传导, 市场注意力, 风险堆积和资产暴露的图。



在研究结构上, 单家公司和单个事件层面的研究可以看成局部 Event Graph; Market Graph 则可以从许多局部图沿着共同事件, 上下游关系, 行业主题和资产暴露粘接而成来理解. 这种说法只是数学上的图像, 不是说实际研究流程每次都会先重建一个全局母图. 若要从  $M_t$  中读出市场季风, 风险堆积或者公司研究语境, 还需要交给明确的读出器或者研究归属环节.

### 7.2.1 从静态情景到可更新的研究状态

Risk-Reward 图首先给出的是未来状态空间的一次粗粒化:

$$\Omega \longrightarrow \{\text{Bull, Base, Bear, Tail}\}.$$

它回答的是: 在几个具有代表性的未来世界中, 企业可能分别值多少钱.

Agentic R-D-G 进一步追问: 哪些市场事件和外部信号会把公司推向这些世界, 这些事件通过哪些中间变量发生作用, 当前证据又支持其中哪几条路径. 换句话说, 它关心三件事: 哪些事件改变哪些经营变量, 这些变化应该进入情景价格, 情景概率还是观察清单, 以及新证据到来以后哪些判断需要重新审查. 下面先区分公司事件图, 预测市场信号和市场图, 再讨论事件如何进入变量.

预测市场信号则最好单独看待:

$$\Delta Q_t \longrightarrow \{\text{market attention, market probability objects}\} \longrightarrow \text{路由/语境/校准}.$$

它可以帮助我们识别外部市场正在注意什么, 以及某个合约在自身结算规则下给出了怎样的价格对象; 但它不能自己激活公司传导边, 也不能直接生成公司情景概率.

与此同时, Market Graph 可以按研究问题被读出为公司研究所需的局部语境. 这里要强调的是: 全局图并不是可以任意吸收的背景知识, 而是只能以经过路由和允许用途约束的方式进入单家公司研究.

### 7.2.2 Prediction Market, Market Graph 与 Company Event Graph

这里需要先区分三层对象.

第一层是 Company Event Graph, 也就是落到某一家公司  $i$  以后, 围绕这家公司自身商业模式, Driver Tree, 上下游事件, 财务变量和情景对象展开的局部事件图. 它是最底层的研究节点, 由 Agent 根据公司证据, 上下游事实和传导机制判断来构造. Prediction Market 中相关上下游事件的盘口, 赔率, 成交量和市场关注度可以作为市场注意力或者候选概率对象进入路由和语境, 但不能单独证明事件发生, 也不能单独证明某条公司传导边已经被激活.

第二层是 Prediction Market 或更一般的预测市场信号. Polymarket, Kalshi 等市场把某些未来事件本身做成可以交易的合约, 因此能够提供两类信息: 一类是市场注意力, 也就是市场当前愿意围绕哪些事件下注; 另一类是市场目前的押注状态, 例如赔率, 盘口大小, 流动性和价格变化. 不过预测市场价格首先是关于某个合约自身结算规则的价格, 不是公司情景概率, 也不是估值结论.

例如某个预测市场可能给出事件  $A$  在其结算规则下的价格

$$q_t^{A, \text{mkt}},$$

但这并不等于某家公司 Bull, Base 或 Bear 情景的概率. 它至多说明: 市场上确实存在一类关于  $A$  的外部注意力或概率对象, 可以用来校准研究问题的优先级, 或者作为候选证据交给既有的概率归属环节. 至于它能不能影响公司情景概率, 仍然要看合约结算规则, 期限, 条件性, 流动性, 以及公司基本面传导证据是否足够干净.

第三层是 Market Graph. 它不是某一家公司内部的事件图, 也不是预先高高在上的母图. 更合适的理解是: Market Graph 是对于市场这个样本空间的一个相对保留更多信息的图值随机变量. 对某个市场状态  $\omega \in \Omega_t$ , 可以把  $M_t(\omega)$  理解成一张记录了事件, 传导, 市场注意力, 资金条件和资产暴露的全局图.

在直觉上, 这种全局图可以由局部图粘接出来. 如果  $G_t^{(i)}(\omega)$  表示公司  $i$  在同一市场状态下的局部 Event Graph, 那么可以粗略写成

$$M_t(\omega) \simeq \text{Glue}_t(\{G_t^{(i)}(\omega)\}_{i \in I_t}, \mathcal{R}_t(\omega), Q_t(\omega)).$$

这里  $\mathcal{R}_t$  表示公司之间共享的事件, 上下游关系, 共同因子和资产暴露;  $Q_t$  表示预测市场提供的市场注意力, 带有结算规则和期限的赔率, 盘口大小和市场概率对象. 这个记号只是一个概念类比, 不

是说本文已经在严格意义上构造了一个层论对象. 在工程实现里, 被接受的图谱状态和本轮研究图还需要通过版本, 来源和用途边界分开保存.

Market Graph 的作用主要有两个, 但它们都需要通过明确的读出或路由发生. 一方面, 它可以交给专门的市场季风读出器, 帮助我们观察市场的季风, 也就是当前哪些事件, 主题, 资金条件和风险暴露正在共同起作用, 以及风险是否在多个局部图之间堆积. 另一方面, 它可以被投影成语境输入, 反过来为某一家公司的基本面研究提供对照语境: 某条公司局部风险是否只是个体噪声, 还是已经和更大的行业, 政策, 资金或市场注意力结构连在一起.

### 注 7.9.

Company Event Graph 提供的是以单家公司为中心组织的传导路径. Prediction Market 提供的是市场注意力, 押注状态和候选市场概率对象. Market Graph 可以理解成市场状态空间上的图值读出, 也可以在概念上由许多局部图粘接出来. 但它需要通过明确读出器或路由, 才能进入市场季风, 风险堆积或公司研究语境.

三者都不是估值模型本身, 也都不能直接生产公司情景概率, R/D, 仓位或订单.

## 7.2.3 最困难的翻译: 从事件和语境到变量

在很多基本量量化问题中, 最困难的第一步往往不是计算, 而是把事件或者语境翻译成合适的变量和值.

假设出现了一条“竞争进一步加剧”的消息. 这句话本身还不能直接进入估值模型. 对于不同公司, 它可能意味着完全不同的东西: 价格下降, 客户激励上升, 市场份额流失, 获客成本提高, 资本开支增加, 或者只是短期市场情绪变差.

可以用下面的记号表示这种翻译:

$$(e, c) \xrightarrow{\Theta_t} \Delta x.$$

其中  $e$  表示事件,  $c$  表示事件发生时的商业和市场语境,  $x$  表示最终受到影响的经营或估值变量, 而  $\Theta_t$  表示截至时刻  $t$  研究者对于传导机制的判断.

这个记号并不意味着  $\Theta_t$  是一个已经知道的机械函数. 恰恰相反, 识别  $\Theta_t$  通常是整个研究过程中最困难, 也最需要商业理解的一步.

同一条事件在不同语境中可能产生不同结果. 例如降价既可能意味着竞争恶化, 也可能意味着公司主动用价格换取规模; 资本开支上升既可能压低近期自由现金流, 也可能为未来产能和增长创造条件. 只有把事件放回商业模式, 时间跨度和当前价格之中, 我们才知道应该观察哪个变量.

### 命题 7.10.

事件和叙事不能直接变成数字.

在进入情景价格或者概率以前, 必须先说明事件改变了什么状态变量, 通过什么机制发生, 大概具有怎样的方向, 时滞和持续时间, 以及什么证据会否定这条传导路径.

## 7.2.4 节点, 边与证据状态

为了避免把研究图画成一张漂亮但无法审查的思维导图, 图中的节点需要保留基本的认识论状态.

为了记号简单, 下面若没有特别说明,  $G_t$  都指某家公司局部的 Company Event Graph. 设时刻  $t$  的公司局部图为一个带标签的有向图

$$G_t^{(i)} = (V_t, E_t, \tau_V, \tau_E, x_t, \mathcal{L}_t),$$

其中  $V_t$  是节点集合,  $E_t$  是传导边集合,  $\tau_V, \tau_E$  记录节点和边的类型,  $x_t$  记录当前状态,  $\mathcal{L}_t$  则保存证据谱系, 允许用途和禁止用途. 节点可以大致分成下面几层:

| 层次        | 典型内容                                               | 主要问题                      |
|-----------|----------------------------------------------------|---------------------------|
| 证据节点      | 财报, 电话会, 行业数据, 政策文件, 市场价格, 预测市场信号                  | 谁在什么时间说了什么, 这是事实, 主张还是推断? |
| 事件与语境节点   | 需求变化, 政策变化, 竞争动作, 融资环境变化                           | 什么状态发生了变化, 变化从何时开始?       |
| Driver 节点 | Volume, Price, Take Rate, Margin, Capex, Retention | 事件首先改变企业经营链条中的哪个变量?       |
| 公司反应节点    | 提价, 降价, 扩产, 回购, 削减成本, 调整渠道                         | 公司会怎样响应外部变化?              |
| 经济终端节点    | Revenue, EPS, FCF, Multiple, Scenario Probability  | 这条路径最终应该交给哪个经济变量的负责人?     |

证据节点还应该区分不同状态. 一个节点可以是已经观察到的事实, 也可以是根据事实作出的推断, 尚未被证据激活的理论路径, 或者暂时无法判断的未解决问题.

这种区分非常重要. “管理层声称需求仍然强劲” 首先只是一个有来源的 claim; 只有当订单, 收入, 客户行为或者其他独立证据与之相符时, 它才可能进一步支持需求状态的判断.

Driver Tree 和 Company Event Graph 在这里承担不同任务. Driver Tree 更像一张相对稳定的经营骨架, 说明企业通常怎样从业务活动走向收入和利润. Company Event Graph 则是附着在骨架上的动态证据层, 说明当前究竟发生了什么, 以及哪些路径已经被证据激活.

例如对支付网络公司, Driver Tree 中可能长期存在

Payment Volume → Revenue → Operating Profit → EPS.

如果出现竞争加剧和客户激励上升的事件, 当前的活动路径可能变成

Competition ↑ → Client Incentives ↑  
→ Net Take Rate ↓  
→ Revenue and Margin ↓  
→ EPS<sub>Bear</sub> ↓.

不过最后一条边只表示这项证据应该进入 Bear 情景的盈利变量. 它本身并不能决定 EPS<sub>Bear</sub> 究竟应该是多少.

一条完整的传导边至少应该说明: 传导机制是什么, 方向为正, 负还是混合, 可能存在多长时滞, 影响是一次性的还是持续的, 当前有哪些支持和反对证据, 以及这条边处于活动, 理论还是未解决状态. 也就是说, 一条边不只是普通箭头, 而应至少带有类似

$e = (\text{mechanism, sign, lag, persistence, status, 归属路径})$

这样的标签.

7.2.5 Owner Route 与 Single Count

一张研究图很容易产生一种虚假的丰富感: 同一个风险在多个地方反复出现, 于是看起来好像有很多条独立的坏消息.

例如竞争恶化可能同时出现在行业分析, Driver Tree, Bear Case, 风险清单和组合风险说明中. 如果每出现一次就再扣一次价值, 或者再提高一次 Bear 概率, 同一件事情就被重复计算了.

定义 7.11 (Owner Route).

Owner Route 是一条经济影响的唯一主要归属路径. 这里的 owner 指负责作出某类经济判断的归属环节, leg 指一个已经标准化的经济影响单元.

图中的每个重要经济或风险影响单元都应该被交给一个明确的判断环节, 例如情景价格, 情景概率, 损失分类, carry, 无法可靠量化的风险登记, 未来观察触发器或者仅作参考.

图负责把证据送到这个归属环节, 但不代替归属环节作出数值判断.

常见的归属路径可以整理为:

| 归属路径                 | 适合处理的问题              | 不应自动变成           |
|----------------------|----------------------|------------------|
| scenario_level       | 改变某个情景中的盈利, 现金流或估值水平 | 第二次概率调整或额外风险扣减   |
| scenario_probability | 改变不同情景之间的概率分配        | 直接改变情景价格         |
| loss_or_carry        | 区分损失机制或记录一次性的 carry  | 已经进入价格的第二份收益或损失的 |
| censored_register    | 记录重要但暂时无法可靠量化的风险     | 为了完整而强行制造一个数字    |
| watch_trigger        | 指定未来需要重新观察的事件        | 当前概率, 当前结论或自动阻塞  |
| context_only         | 保存组合或市场环境背景          | 通用的第二份 $D$       |

**命题 7.12 (Single Count).**

同一个标准化经济影响单元只能拥有一条主要经济路径.

多个来源可以共同支持同一个影响单元, 同一个根事件也可以通过不同机制产生多个真正不同的影响单元; 但证据数量, 路径数量和图中的出现次数都不能自动制造额外的收益或风险.

可以把这个原则写成一个函数

$$\omega_t: L_t \longrightarrow \mathcal{O},$$

其中  $L_t$  是时刻  $t$  的标准化经济影响单元集合,  $\mathcal{O}$  是经济归属环节集合. 要求  $\omega_t$  是函数, 就是要求每个标准化经济影响单元在当前研究结构中只有一个主要归属. 如果同一个根事件真的产生了两个机制完全不同的影响, 就应该先把它拆成两个不同的影响单元, 而不是让同一个影响单元同时进入多个经济路线.

例如同一项技术采用可能一方面提高产品收入, 另一方面增加外部算力成本. 只要两条路径的机制和经济变量确实不同, 它们可以分别进入收入和利润率. 但如果三份报告都在描述同一次成本上升, 这只是对同一个成本影响单元的交叉验证, 不能被算成三份下行风险.

**7.2.6 Scenario Packet, Price State 与 Replay**

Company Event Graph 本身不是最终研究结论. 它首先把证据送到正确的归属环节, 再由这些归属环节形成几个可以长期保存和重新计算的对象.

**定义 7.13 (Scenario Packet).**

Scenario Packet 是一组经过审查的情景对象.

它保存 Bull, Base, Bear 和 Tail 的代表性价格或估值, 情景概率, 核心假设, 主要证据, 可证伪条件, 研究置信度, 有效期限以及需要重新审查的触发条件.

Scenario Packet 保存的是“在什么世界中为什么会得到什么结果”, 而不只是几个彼此孤立的价格.

**定义 7.14 (Price State).**

Price State 记录截至某个时点的市场价格, 价格在当前情景结构中的相对位置, 研究所使用的价格时间戳, 以及维持研究, 重新审查或判定信息失效的边界.

Price State 是研究状态, 不是限价单, 目标仓位或者执行指令.

由于市场价格会变, 即使 Scenario Packet 没有改变, 同一组情景相对于现价的 R/D 也可能明显变化. 因此基本面情景和当前价格状态需要分别保存.

### 定义 7.15 (Replay Bundle).

Replay Bundle 是用于重新计算 R/D 和 EV 的输入包.

它保存已经接受的情景价格与概率, 损失分类, 暂时性损失的折减参数, 研究期内只计算一次的附加收益或成本, 研究期限, 公司在组合中的角色, 组合风险档位和最低收益要求, 以及对应的 Price State. 同时, 它还记录这些输入的来源, 版本, 复核状态, 有效期限, 刷新条件, 以及允许和禁止的下游用途. 这样以后重新计算时, 才能知道每个输入为什么可用, 又会在什么条件下失效.

它冻结的是可重放的输入和判断来源, 不是一个可以被以后无条件继承的最终 R/D 数字.

于是可以把一套研究状态粗略写成

$$\text{RDView}_t = \Psi(\Pi_t, P_t, a),$$

其中  $\Pi_t$  表示时刻  $t$  可用的 Scenario Packet,  $P_t$  表示当时的 Price State,  $a$  表示明确的计算约定和用途. 这里的  $\text{RDView}_t$  是一种临时视图: 它可以服务于研究验证或者组合比较, 但不应该脱离原始情景和版本关系, 变成永久有效的单一分数.

这和上一节的最小教学模型并不矛盾. 上一节的  $R_{\mathbb{P}}$  和  $D_{\mathbb{P}}$  只是为了说明概率加权上行和下行的基本思想. 真实研究里还会有更复杂的情景价格生成, 损失机制分类, carry, 置信度, 有效期和下游使用边界. Agentic R-D-G 的任务不是替代这些判断, 而是让这些判断的来源和归属更容易被复查.

例如, 一条证据经过归属路径进入情景  $s$  的经营变量以后, 可以抽象地写成

$$x_s = F_s(d_s), \quad S_s(T) = \mathcal{V}_s(x_s; \theta_s).$$

这里  $d_s$  是情景  $s$  下被接受的经营驱动输入,  $F_s$  是从经营驱动到财务变量的预测环节,  $\mathcal{V}_s$  是从财务变量到情景价格的估值环节. 图可以说明  $d_s$  来自哪里, 也可以说明哪些证据应该进入  $F_s$  或  $\mathcal{V}_s$ ; 但  $F_s$  和  $\mathcal{V}_s$  本身仍然是基本面判断.

在作者的完整 R/D 体系中, 下行还会进一步区分为暂时性损失和永久性损失. 设

$$r_s = \frac{S_s(T) - S_0}{S_0},$$

则可以写出

$$R = \sum_s p_s(r_s)^+,$$

$$D_{\text{temp}} = \sum_s p_s(-r_s)^+ \lambda_{s,\text{temp}}, \quad D_{\text{perm}} = \sum_s p_s(-r_s)^+ \lambda_{s,\text{perm}},$$

其中每个下行情景满足  $\lambda_{s,\text{temp}} + \lambda_{s,\text{perm}} = 1$ . 若  $\alpha \in [0, 1]$  表示当前资本性质和研究期限下对暂时性损失的折减程度,  $C$  表示同一研究期限内只计入一次的 carry, 则

$$D_{\text{clean}} = \alpha D_{\text{temp}} + D_{\text{perm}}, \quad \text{EV} = R - D_{\text{clean}} + C.$$

当  $D_{\text{clean}} > 0$  时, 还可以读出

$$\text{R/D} = \frac{R}{D_{\text{clean}}}.$$

### 注 7.16.

这一组公式是本文作者体系中的一种实现方式, 不是一般金融学定理. 它的目的不是把投资判断变成机械公式, 而是把情景价格, 情景概率, 损失机制和 carry 分开放置, 使每个输入都能被追踪和重新审查.



### 7.2.7 一个极简支付平台例子

继续使用支付网络或支付平台的例子。假设我们观察到三条信息：

| 信息       | 可能传导                        | Owner Route                                                 | 处置                               |
|----------|-----------------------------|-------------------------------------------------------------|----------------------------------|
| 支付金额继续增长 | Volume 上升, Revenue 上升       | <code>scenario_level</code>                                 | 进入 Bull/Base 的收入和 EPS 假设         |
| 客户激励上升   | Net Take Rate 下降, Margin 下降 | <code>scenario_level</code>                                 | 进入 Bear 的利润率假设, 不再额外加一次 <i>D</i> |
| 监管讨论升温   | 可能影响定价或业务范围, 但证据尚不充分        | <code>censored_register</code> 或 <code>watch_trigger</code> | 保留为需要观察的风险, 不强行制造精确概率            |

#### 例 7.17.

在这个例子里, 同一项客户激励上升的风险如果已经通过利润率下降进入 Bear 情景价格, 就不应该再作为独立风险额外提高 Bear 概率, 或者再给 R/D 加上一份通用折扣。

反过来, 如果监管讨论目前只有标题和市场传闻, 它可以成为观察触发器或无法量化风险登记, 但不应该为了让图看起来完整, 就被强行转成一个具体的损失数字。

这个例子很小, 但它说明了 R-D-G 的核心用途: 不是让图替我们给出答案, 而是让我们知道每条信息应该进入哪里, 哪些地方已经计入, 哪些地方仍然只是待观察的风险。这些被接受的处置随后才会进入 Scenario Packet, Price State 或 Replay Bundle, 供之后重新计算临时的 R/D 视图。

### 7.2.8 为什么是 Agentic

所谓 Agentic, 并不是让 Agent 自己在图上随意添加节点, 再根据节点数量自动得出结论。

真正需要 Agent 的原因更加实际。如果只研究一家公司, 人类当然可以手工维护一张事件表, 偶尔更新几条假设。但如果同时跟踪许多公司, 再把它们和宏观事件, 政策变化, 行业主题, 预测市场信号以及组合暴露连接起来, 图的规模很快就会变得难以手工维护。

更麻烦的是, 这里需要维护的不是一张普通关系图, 而是一张带有来源, 时间, 状态, 经济归属路径, 单次计数, 版本关系和重新审查条件的研究图。它不只要求能画出来, 还要求事后能够审计: 某个判断来自哪里, 什么时候进入图, 经过哪些中间路径, 有没有被重复计数, 以及哪些下游对象应该因为新信息而重新检查。

固定程序在这里当然也有用, 比如做格式校验, 重复检查和确定性的表格转换。但固定程序很难可靠处理语境: 一条新闻究竟是同一事件的新证据, 还是一个新的事件; 一条预测市场价格究竟只是市场注意力, 还是可以作为干净的概率对象交给某个归属环节; 一条风险究竟已经进入情景价格, 还是仍然停留在观察清单。这些都需要语义判断。

#### 原则 7.18.

Agentic R-D-G 中的 Agent 首先是维护者和审计者, 不是替代经济判断的自动打分器。

它的核心任务是帮助维护大规模研究图的可追溯性, 检查证据来源, 版本关系, 归属路径, 单次计数和下游复查对象, 并把需要重新判断的变量交还给相应的研究归属环节。

它真正有用的地方在于: 图中的节点和边具有稳定标识, 证据带有来源和时间, 路径带有状态和归属路径, 而研究对象带有版本, 有效期和更新条件。于是 Agent 可以知道一条新信息究竟影响哪里, 而不需要每次从头重写整篇研究报告。

不过这里需要区分三件事情。第一, 图谱只是研究状态的表示, 不是市场运动定律。第二, 单次研究只能读取经过来源, 版本, 允许用途和禁止用途约束的局部语境, 不能把全局图当作任意背景知识吸收。第三, 如果新证据真的需要改变已经接受的市场图谱状态, 也不能直接把新闻写进  $M_t$ 。更稳妥的做法是先把新证据固定下来, 再判断它是旧事件的新证据, 新的候选事件, 还是需要退役或替换的事件状态。在普通研究中, 这种刷新通常只是本轮研究范围内的临时校准; 它可以帮助分析, 但

不等于改动已经接受的市场图。只有在单独的图谱维护任务中, 经过来源核验, 版本审查和下游影响检查, 并将全部变更作为完整版本发布以后, 变化才进入下一版正式图谱。

这不是一条市场运动定律, 也不是自动传播公式。它只是说明更新应该从新证据开始, 识别受影响的节点和边, 再沿着图找到需要重新审查的下游对象。如果  $\Delta V_{t+1}^{(i)}$  表示公司  $i$  的局部图中被新信息直接改变的节点集合, 那么需要复查的对象可以粗略写成

$$\mathcal{D}_{t+1}^{(i)} \subseteq \text{Desc}_{G_t^{(i)}}(\Delta V_{t+1}^{(i)}) \cup \text{RouteChange}_{t+1}^{(i)}.$$

这里  $\text{RouteChange}_{t+1}^{(i)}$  提醒我们: 如果某个事件被退役, 替换或改变绑定, 还要检查旧路径和新路径的并集, 避免只沿旧图的后继对象走一遍而漏掉撤回影响。  $\mathcal{D}_{t+1}^{(i)}$  只是需要复查的对象集合, 并不意味着数值会沿着图自动传播。正确顺序仍然是: 核验证据, 改变节点状态, 激活或关闭边, 标记受影响的下游对象, 再由对应归属环节重做判断。

例如一条新的行业需求数据可能只改变 Volume 路径; 一项监管政策可能同时影响定价, 成本和市场准入; 一份新的财报则可能直接否定某条原本活动的边。

Agent 在这里适合完成几件事情: 追踪证据来源, 寻找受影响的下游路径, 检查同一风险是否被重复计算, 发现已经过期或仍未解决的节点, 以及把需要重新判断的变量交还给正确的归属环节。

但是 Agent 不应该因为图中某个节点具有更高中心性, 被更多来源提到, 或者连接了更多路径, 就自动提高它的经济权重。图的拓扑结构首先代表研究结构, 不天然等于概率, 价值或者风险大小。

### 7.2.9 与实际研究流程的对应

把上述抽象落到实际研究中, 可以用一条受约束的流程来理解。下面不是工程操作手册, 只是保留和本节概念有关的顺序: 一次完整研究并不是让 Agent 自由读取所有材料, 然后凭直觉生成一张大图。它首先冻结一份经过预处理的数据集, 再把证据, 未解决问题, 来源和允许用途分配给具体的分析切片。如果本轮研究需要图谱语境, 已经接受的 Event Graph 或 Market Graph 谱系会先被投影成有版本的图谱语境, 再绑定到对应分析切片中。

用很粗略的流程表示, 实际研究更接近

原始证据 → 核验并固定本轮数据 → 按问题提取语境  
 → 分析与反方检验 → 必要时核对预测市场  
 → 更新本轮公司图 → 形成情景输入  
 → 重新计算 → 验证。

如果写成局部记号, 其中一条路径可以是

$\mathcal{E}_t^{(i)}, K_t^{(i)} \rightarrow \text{分析与对峙} \rightarrow \text{预测市场处置}$   
 $\rightarrow G_{t,\text{run}}^{(i)} \rightarrow \text{归属交接}$   
 $\rightarrow \Pi_t^{(i)} \rightarrow \text{RDView}_t^{(i)}.$

这里  $\mathcal{E}_t^{(i)}$  表示公司证据,  $K_t^{(i)}$  表示从已接受市场图谱中按当前问题读出的局部语境,  $G_{t,\text{run}}^{(i)}$  是分析, 对峙和预测市场处置以后形成的本轮公司图,  $\Pi_t^{(i)}$  表示公司  $i$  的情景输入包。这个顺序强调: 本轮公司图组织已经接受的证据和归属交接, 但不在分析之前自动生成经营 Driver 或经济输入。

这里的图谱范围判断包括: 本轮是否只需要读取既有语境, 是否需要做研究范围内的影子刷新, 还是需要单独进入图谱维护任务。如果确实需要刷新, 也要先冻结增量数据, 再进入图谱语境验收和最终绑定。

图谱语境不是一团可以任意吸收的背景知识。每一条被保留的图谱语境都应说明: 它来自哪一版已接受图谱, 面向哪个研究问题, 可以用到什么程度, 以及哪些用途仍然被排除。如果一条语境没有明确服务的判断, 或者只能作为背景, 就应该明确写成背景, 缺口, 重复项或本轮研究范围之外, 而不是悄悄进入估值。

Prediction Market 在这条流程中也不是固定的图谱卫生检查。只有当分析和对峙以后确实出现新的或变化的事件型外部市场问题, 而且这个问题有明确消费者时, 才会进行额外的预测市场搜索。如果没有这样的事件问题, 正确做法是保留已有图谱谱系, 并记录没有搜索的处置, 而不是为了满足形式而搜一堆公司关键词。

最后, 情景一致性, 情景价格, 回放输入包和验证负责守住经济判断的边界. 图谱可以把证据送到相应归属环节, 但不能自己创造情景价格, 不能自己决定公司情景概率, 也不能把某次保存下来的 R/D 或 EV 数字变成永久权威. 真正持久保存的是可重放的输入, 版本关系和使用边界; R/D 与 EV 更像是在给定 Price State 和 Scenario Packet 以后临时计算出来的视图.

### 7.2.10 边界与随机过程接口

Agentic R-D-G 的下游需要保留两道明确边界.

第一道是研究与组合管理的边界. 研究层提供 Scenario Packet, Price State 和 Replay Bundle. 组合层可以在当前组合状态和当前价格下重新计算临时的 R/D 与 EV 视图, 然后结合组合角色, 集中度, 流动性和风险暴露作出判断.

尤其需要注意, 原始 Market Graph 不是组合管理输入. 只有当专门的市场环境或组合风险汇总环节在本轮范围内时, 它们才可以消费带有来源和用途边界的图谱语境, 并输出组合层可以读取的市场语境. 图谱维护本身不解释组合结论, 也不触发仓位或交易动作.

但是组合层不能为了得到一个组合答案, 反过来修改研究层的情景价格, 情景概率或者损失分类. 图分数也不能机械转换成目标仓位, Kelly 比例, 固定档位或者自动填满某个仓位上限.

第二道是组合判断与执行的边界. 即使研究和组合判断已经完成, 它们仍然不是订单. Price State 中的某个区间不是限价单; Watch Trigger 不是自动交易条件; Scenario Packet 中的 Bull 或 Bear 价格也不是应当立即买入或卖出的价格.

#### 注 7.19.

Prediction Market 不生产公司情景概率; Market Graph 不生产估值; Company Event Graph 不生产 R/D; Scenario Packet 不生产目标仓位; Replay Bundle 不生产订单.

各环节只能消费经过允许的输出生, 不能用全局语境改写局部证据, 也不能用市场盘口替代基本面判断.

回到本节开头的记号, 价格  $S_t$ , 指数水平或者几个情景标签都是从市场样本空间中读出的低维随机变量. 相比之下,  $M_t$  是一个更高信息保留的图值读出. 公司 Event Graph  $G_t^{(i)}$  可以看成全局市场状态在公司  $i$  上的局部观测; 把许多  $G_t^{(i)}$  粘接成  $M_t$  则像是把局部截面粘成一个整体对象.

如果进一步给所有可能的图配置适当的可测结构, 就可以把  $(M_t)_{t \geq 0}$  和  $(G_t^{(i)})_{t \geq 0}$  看成图值随机过程. 但本文暂时不需要把它完全形式化, 也不能把图中的边直接理解成转移概率或者 Markov 核. 这里真正重要的直觉是: 研究结论不是一个永远固定的目标价, 而是一个随着信息流不断更新, 并且能够被审计和回放的状态.

简言之, Risk-Reward 负责压缩未来, Company Event Graph 负责解释公司传导, Prediction Market 提供市场注意力和合约价格对象, Market Graph 则帮助观察市场季风, 风险堆积, 并作为语境回流到公司研究. 前者让结果可以比较, 后者让结果可以解释, 更新和审查.

## 参考文献

- [Ald+20] Iñaki Aldasoro et al. *Global Banks' Dollar Funding Needs and Central Bank Swap Lines*. Bank for International Settlements. July 16, 2020. URL: <https://www.bis.org/publ/bisbull27.htm> (visited on 08/17/2026).
- [AC01] Robert Almgren and Neil Chriss. “Optimal Execution of Portfolio Transactions”. In: *Journal of Risk* 3.2 (2001), pp. 5–39. DOI: [10.21314/JOR.2001.041](https://doi.org/10.21314/JOR.2001.041).
- [Alt] Alternative Reference Rates Committee. *Transition from LIBOR*. Federal Reserve Bank of New York. URL: <https://www.newyorkfed.org/arrc/sofr-transition> (visited on 08/17/2026).
- [Ang+22] Guillermo Angeris et al. *A Primer on Perpetuals*. Sept. 7, 2022. arXiv: [2209.03307](https://arxiv.org/abs/2209.03307). (Visited on 08/17/2026).
- [AS23] Fernando Avalos and Vladyslav Sushko. *Margin Leverage and Vulnerabilities in U.S. Treasury Futures*. Bank for International Settlements. Sept. 18, 2023. URL: [https://www.bis.org/publ/qtrpdf/r\\_qt2309w.htm](https://www.bis.org/publ/qtrpdf/r_qt2309w.htm) (visited on 08/17/2026).
- [BMM15] Emmanuel Bacry, Iacopo Mastromatteo, and Jean-François Muzy. “Hawkes Processes in Finance”. In: *Market Microstructure and Liquidity* 1.1 (2015), p. 1550005. DOI: [10.1142/S2382626615500057](https://doi.org/10.1142/S2382626615500057).
- [BK21] Daniel Barth and R. Jay Kahn. *Hedge Funds and the Treasury Cash-Futures Disconnect*. Office of Financial Research. Apr. 1, 2021. URL: <https://www.financialresearch.gov/working-papers/2021/04/01/hedge-funds-and-the-treasury-cash-futures-disconnect/> (visited on 08/17/2026).
- [BKM23] Daniel Barth, R. Jay Kahn, and Robert Mann. *Recent Developments in Hedge Funds' Treasury Futures and Repo Positions: Is the Basis Trade “Back”?* Board of Governors of the Federal Reserve System. Aug. 30, 2023. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/recent-developments-in-hedge-funds-treasury-futures-and-repo-positions-20230830.html> (visited on 08/17/2026).
- [Bil95] Patrick Billingsley. *Probability and Measure*. 3rd ed. Wiley, 1995.
- [Boa20] Board of Governors of the Federal Reserve System. *Swap Lines FAQs*. Mar. 19, 2020. URL: <https://www.federalreserve.gov/newsevents/pressreleases/swap-lines-faqs.htm> (visited on 08/17/2026).
- [Boaa] Board of Governors of the Federal Reserve System. *Central Bank Liquidity Swaps*. URL: <https://www.federalreserve.gov/monetarypolicy/central-bank-liquidity-swaps.htm> (visited on 08/17/2026).
- [Boab] Board of Governors of the Federal Reserve System. *Factors Affecting Reserve Balances, H.4.1*. URL: <https://www.federalreserve.gov/releases/h41/> (visited on 08/17/2026).
- [Boac] Board of Governors of the Federal Reserve System. *Federal Reserve Act*. URL: <https://www.federalreserve.gov/aboutthefed/fract.htm> (visited on 08/17/2026).
- [Boad] Board of Governors of the Federal Reserve System. *Interest on Reserve Balances*. URL: <https://www.federalreserve.gov/monetarypolicy/reserve-balances.htm> (visited on 08/17/2026).
- [Boae] Board of Governors of the Federal Reserve System. *Overnight Reverse Repurchase Agreement Operations*. URL: <https://www.federalreserve.gov/monetarypolicy/overnight-reverse-repurchase-agreements.htm> (visited on 08/17/2026).
- [Boaf] Board of Governors of the Federal Reserve System. *Reserve Requirements*. URL: <https://www.federalreserve.gov/monetarypolicy/reservereq.htm> (visited on 08/17/2026).
- [Bog07] Vladimir I. Bogachev. *Measure Theory*. Springer, 2007.
- [BL78] Douglas T. Breeden and Robert H. Litzenberger. “Prices of State-Contingent Claims Implicit in Option Prices”. In: *The Journal of Business* 51.4 (1978), pp. 621–651. DOI: [10.1086/296025](https://doi.org/10.1086/296025).
- [Che+26] Xin Cheng et al. *DSpark: Confidence-Scheduled Speculative Decoding with Semi-Autoregressive Generation*. July 6, 2026. arXiv: [2607.05147](https://arxiv.org/abs/2607.05147). URL: <https://arxiv.org/abs/2607.05147> (visited on 08/17/2026).

- [CME24] CME Group. *Calculating U.S. Treasury Futures Conversion Factors*. Jan. 19, 2024. URL: <https://www.cmegroup.com/articles/2024/calculating-us-treasury-futures-conversion-factors.html> (visited on 08/17/2026).
- [CME] CME Group. *CME Term SOFR Reference Rates*. URL: <https://www.cmegroup.com/market-data/cme-group-benchmark-administration/term-sofr.html> (visited on 08/17/2026).
- [Coc05] John H. Cochrane. *Asset Pricing*. Revised. Princeton University Press, 2005.
- [Com22] Commodity Futures Trading Commission. *CFTC Orders Event-Based Binary Options Markets Operator to Pay \$1.4 Million Penalty*. Jan. 3, 2022. URL: <https://www.cftc.gov/PressRoom/PressReleases/8478-22> (visited on 08/17/2026).
- [Com26] Commodity Futures Trading Commission. *CFTC Enforcement Division Issues Prediction Markets Advisory*. Feb. 25, 2026. URL: <https://www.cftc.gov/PressRoom/PressReleases/9185-26> (visited on 08/17/2026).
- [Com] Commodity Futures Trading Commission. *Understanding Prediction Markets and Event Contracts*. URL: <https://www.cftc.gov/LearnandProtect/PredictionMarkets> (visited on 08/17/2026).
- [CKS14] Rama Cont, Arseniy Kukanov, and Sasha Stoikov. “The Price Impact of Order Book Events”. In: *Journal of Financial Econometrics* 12.1 (2014), pp. 47–88. DOI: [10.1093/jffinec/nbt003](https://doi.org/10.1093/jffinec/nbt003).
- [CST10] Rama Cont, Sasha Stoikov, and Rishi Talreja. “A Stochastic Model for Order Book Dynamics”. In: *Operations Research* 58.3 (2010), pp. 549–563. DOI: [10.1287/opre.1090.0780](https://doi.org/10.1287/opre.1090.0780).
- [Dam12] Aswath Damodaran. *Investment Valuation: Tools and Techniques for Determining the Value of Any Asset*. 3rd ed. Wiley, 2012.
- [DS94] Freddy Delbaen and Walter Schachermayer. “A General Version of the Fundamental Theorem of Asset Pricing”. In: *Mathematische Annalen* 300.1 (1994), pp. 463–520. DOI: [10.1007/BF01450498](https://doi.org/10.1007/BF01450498).
- [DD83] Douglas W. Diamond and Philip H. Dybvig. “Bank Runs, Deposit Insurance, and Liquidity”. In: *Journal of Political Economy* 91.3 (1983), pp. 401–419. DOI: [10.1086/261155](https://doi.org/10.1086/261155).
- [Duf01] Darrell Duffie. *Dynamic Asset Pricing Theory*. 3rd ed. Princeton University Press, 2001.
- [Dur19] Rick Durrett. *Probability: Theory and Examples*. 5th ed. Cambridge University Press, 2019.
- [Feda] Federal Deposit Insurance Corporation. *1930–1939*. URL: <https://www.fdic.gov/history/1930-1939> (visited on 08/17/2026).
- [Fedb] Federal Reserve Bank of New York. *Effective Federal Funds Rate*. URL: <https://www.newyorkfed.org/markets/reference-rates/effr> (visited on 08/17/2026).
- [Fedc] Federal Reserve Bank of New York. *Monetary Policy Implementation*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation> (visited on 08/17/2026).
- [Fedd] Federal Reserve Bank of New York. *Repo and Reverse Repo Agreements*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation/repo-reverse-repo-agreements> (visited on 08/17/2026).
- [Fede] Federal Reserve Bank of New York. *Secured Overnight Financing Rate Data*. URL: <https://www.newyorkfed.org/markets/reference-rates/sofr> (visited on 08/17/2026).
- [Fedf] Federal Reserve History. *Federal Reserve Act Signed into Law*. URL: <https://www.federalreservehistory.org/essays/federal-reserve-act-signed> (visited on 08/17/2026).
- [Fol99] Gerald B. Folland. *Real Analysis: Modern Techniques and Their Applications*. 2nd ed. Wiley, 1999.
- [FPR23] Thierry Foucault, Marco Pagano, and Ailsa Röell. *Market Liquidity: Theory, Evidence, and Policy*. 2nd ed. Oxford University Press, 2023. DOI: [10.1093/oso/9780197542064.001.0001](https://doi.org/10.1093/oso/9780197542064.001.0001).
- [Gas10] Gary L. Gastineau. *The Exchange-Traded Funds Manual*. 2nd ed. Wiley, 2010.
- [Gli+24] Jonathan Glicoes et al. *Quantifying Treasury Cash-Futures Basis Trades*. Board of Governors of the Federal Reserve System. Mar. 8, 2024. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/quantifying-treasury-cash-futures-basis-trades-20240308.html> (visited on 08/17/2026).



- [GM85] Lawrence R. Glosten and Paul R. Milgrom. “Bid, Ask and Transaction Prices in a Specialist Market with Heterogeneously Informed Traders”. In: *Journal of Financial Economics* 14.1 (1985), pp. 71–100. DOI: [10.1016/0304-405X\(85\)90044-3](https://doi.org/10.1016/0304-405X(85)90044-3).
- [Gou+13] Martin D. Gould et al. “Limit Order Books”. In: *Quantitative Finance* 13.11 (2013), pp. 1709–1742. DOI: [10.1080/14697688.2013.803148](https://doi.org/10.1080/14697688.2013.803148).
- [Har02] Larry Harris. *Trading and Exchanges: Market Microstructure for Practitioners*. Oxford University Press, 2002. DOI: [10.1093/oso/9780195144703.001.0001](https://doi.org/10.1093/oso/9780195144703.001.0001).
- [HK79] J. Michael Harrison and David M. Kreps. “Martingales and Arbitrage in Multiperiod Securities Markets”. In: *Journal of Economic Theory* 20.3 (1979), pp. 381–408. DOI: [10.1016/0022-0531\(79\)90043-7](https://doi.org/10.1016/0022-0531(79)90043-7).
- [HP81] J. Michael Harrison and Stanley R. Pliska. “Martingales and Stochastic Integrals in the Theory of Continuous Trading”. In: *Stochastic Processes and their Applications* 11.3 (1981), pp. 215–260. DOI: [10.1016/0304-4149\(81\)90026-0](https://doi.org/10.1016/0304-4149(81)90026-0).
- [Has07] Joel Hasbrouck. *Empirical Market Microstructure: The Institutions, Economics, and Econometrics of Securities Trading*. Oxford University Press, 2007. DOI: [10.1093/oso/9780195301649.001.0001](https://doi.org/10.1093/oso/9780195301649.001.0001).
- [He+24] Songrun He et al. *Fundamentals of Perpetual Futures*. Aug. 21, 2024. arXiv: [2212.06888](https://arxiv.org/abs/2212.06888). (Visited on 08/17/2026).
- [HS81] Thomas Ho and Hans R. Stoll. “Optimal Dealer Pricing under Transactions and Return Uncertainty”. In: *Journal of Financial Economics* 9.1 (1981), pp. 47–73. DOI: [10.1016/0304-405X\(81\)90020-9](https://doi.org/10.1016/0304-405X(81)90020-9).
- [HS97] Roger D. Huang and Hans R. Stoll. “The Components of the Bid-Ask Spread: A General Approach”. In: *The Review of Financial Studies* 10.4 (1997), pp. 995–1034. DOI: [10.1093/rfs/10.4.995](https://doi.org/10.1093/rfs/10.4.995).
- [Hul22] John C. Hull. *Options, Futures, and Other Derivatives*. 11th ed. Pearson, 2022.
- [HPW19] Jeffrey Huther, Luke Pettit, and Mark Wilkinson. *Fiscal Flow Volatility and Reserves*. Board of Governors of the Federal Reserve System. Dec. 16, 2019. DOI: [10.17016/2380-7172.2470](https://doi.org/10.17016/2380-7172.2470). URL: <https://www.federalreserve.gov/econres/notes/feds-notes/fiscal-flow-volatility-and-reserves-20191216.html> (visited on 08/17/2026).
- [Kal21] Olav Kallenberg. *Foundations of Modern Probability*. 3rd ed. Springer, 2021.
- [Kir+17] Andrei Kirilenko et al. “The Flash Crash: High-Frequency Trading in an Electronic Market”. In: *The Journal of Finance* 72.3 (2017), pp. 967–998. DOI: [10.1111/jofi.12498](https://doi.org/10.1111/jofi.12498).
- [Kyl85] Albert S. Kyle. “Continuous Auctions and Insider Trading”. In: *Econometrica* 53.6 (1985), pp. 1315–1335. DOI: [10.2307/1913210](https://doi.org/10.2307/1913210).
- [LR91] Charles M. C. Lee and Mark J. Ready. “Inferring Trade Direction from Intraday Data”. In: *The Journal of Finance* 46.2 (1991), pp. 733–746. DOI: [10.1111/j.1540-6261.1991.tb02683.x](https://doi.org/10.1111/j.1540-6261.1991.tb02683.x).
- [Mad00] Ananth Madhavan. “Market Microstructure: A Survey”. In: *Journal of Financial Markets* 3.3 (2000), pp. 205–258. DOI: [10.1016/S1386-4181\(00\)00007-0](https://doi.org/10.1016/S1386-4181(00)00007-0).
- [Man06] Charles F. Manski. “Interpreting the Predictions of Prediction Markets”. In: *Economics Letters* 91.3 (2006), pp. 425–429. DOI: [10.1016/j.econlet.2006.01.004](https://doi.org/10.1016/j.econlet.2006.01.004).
- [Mar52] Harry Markowitz. “Portfolio Selection”. In: *The Journal of Finance* 7.1 (1952), pp. 77–91. DOI: [10.2307/2975974](https://doi.org/10.2307/2975974).
- [MT] Jon R. Moen and Ellis W. Tallman. *The Panic of 1907*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/panic-of-1907> (visited on 08/17/2026).
- [Mor22] Morgan Stanley. *Vintage Values 2023*. Morgan Stanley Wealth Management. Aug. 24, 2022. URL: <https://www.morganstanley.com/content/dam/msdotcom/what-we-do/wealth-management-images/uit/vintage-values-research-report.pdf> (visited on 08/17/2026).
- [Nas] Nasdaq. *Nasdaq-100 Index Methodology*. URL: [https://indexes.nasdaqomx.com/docs/Methodology\\_NDX.pdf](https://indexes.nasdaqomx.com/docs/Methodology_NDX.pdf) (visited on 08/17/2026).
- [OH95] Maureen O’Hara. *Market Microstructure Theory*. Blackwell Publishers, 1995.

- [Opt] Options Clearing Corporation. *Characteristics and Risks of Standardized Options*. URL: <https://www.theocc.com/company-information/documents-and-archives/options-disclosure-document> (visited on 08/17/2026).
- [Per88] André F. Perold. “The Implementation Shortfall: Paper versus Reality”. In: *The Journal of Portfolio Management* 14.3 (1988), pp. 4–9. DOI: [10.3905/jpm.1988.409150](https://doi.org/10.3905/jpm.1988.409150).
- [SP 26] S&P Dow Jones Indices. *Marvell Technology and Flex Set to Join S&P 500; Others to Join S&P MidCap 400 and S&P SmallCap 600*. June 5, 2026. URL: <https://press.spglobal.com/2026-06-05-Marvell-Technology-and-Flex-Set-to-Join-S-P-500-Others-to-Join-S-P-MidCap-400-and-S-P-SmallCap-600> (visited on 08/17/2026).
- [SP a] S&P Dow Jones Indices. *Index Mathematics Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-index-math.pdf> (visited on 08/17/2026).
- [SP b] S&P Dow Jones Indices. *S&P U.S. Indices Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-sp-us-indices.pdf> (visited on 08/17/2026).
- [SV97] Andrei Shleifer and Robert W. Vishny. “The Limits of Arbitrage”. In: *The Journal of Finance* 52.1 (1997), pp. 35–55. DOI: [10.1111/j.1540-6261.1997.tb03807.x](https://doi.org/10.1111/j.1540-6261.1997.tb03807.x).
- [Shr04a] Steven E. Shreve. *Stochastic Calculus for Finance I: The Binomial Asset Pricing Model*. Springer, 2004.
- [Shr04b] Steven E. Shreve. *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer, 2004.
- [TS11] Bruce Tuckman and Angel Serrat. *Fixed Income Securities: Tools for Today’s Markets*. 3rd ed. Wiley, 2011.
- [US a] U.S. Department of the Treasury. *Daily Treasury Rates*. URL: [https://home.treasury.gov/resource-center/data-chart-center/interest-rates/TextView?type=daily\\_treasury\\_yield\\_curve](https://home.treasury.gov/resource-center/data-chart-center/interest-rates/TextView?type=daily_treasury_yield_curve) (visited on 08/17/2026).
- [US b] U.S. Department of the Treasury. *STRIPS*. URL: <https://www.treasurydirect.gov/market/able-securities/strips/> (visited on 08/17/2026).
- [US c] U.S. Department of the Treasury. *Treasury Marketable Securities*. URL: <https://www.treasurydirect.gov/marketable-securities/> (visited on 08/17/2026).
- [US 15] U.S. Securities and Exchange Commission. *Investor Bulletin: An Introduction to Options*. Mar. 18, 2015. URL: <https://www.investor.gov/introduction-investing/general-resources/news-alerts/alerts-bulletins/investor-bulletins-63> (visited on 08/17/2026).
- [US d] U.S. Securities and Exchange Commission. *Exchange-Traded Funds (ETFs)*. Investor.gov. URL: <https://www.investor.gov/introduction-investing/investing-basics/glossary/exchange-traded-funds-etfs> (visited on 08/17/2026).
- [US e] U.S. Securities and Exchange Commission. *Investor Bulletin: Exchange-Traded Funds (ETFs)*. URL: <https://www.sec.gov/investor/pubs/sec-guide-to-etfs.pdf> (visited on 08/17/2026).
- [US f] U.S. Securities and Exchange Commission. *Money Market Funds*. URL: <https://www.investor.gov/introduction-investing/investing-basics/investment-products/mutual-funds-and-exchange-traded-5> (visited on 08/17/2026).
- [Vil09] Cédric Villani. *Optimal Transport: Old and New*. Springer, 2009.
- [Wil91] David Williams. *Probability with Martingales*. Cambridge University Press, 1991.
- [WZ04] Justin Wolfers and Eric Zitzewitz. “Prediction Markets”. In: *Journal of Economic Perspectives* 18.2 (2004), pp. 107–126. DOI: [10.1257/0895330041371321](https://doi.org/10.1257/0895330041371321).