

随机过程与金融市场

Ou Liu

2026-08-16

编写声明

本文由 Ou Liu 基于 BananaSpace 上的 随机过程与金融市场笔记整理修订而成. 作者负责内容取舍, 数学核验, 参考文献整理和最终表述.

文中涉及数学命题, 金融制度事实和市场机制时, 以正文给出的条件, 引用资料和后续修订为准.

目录

编写声明	ii
第一章 引言	1
1.1 为什么是随机过程	1
1.2 为什么需要测度论	1
1.3 金融市场作为贯穿的例子	1
1.4 模型要回答具体问题	2
1.5 阅读路线	2
第一部分 随机过程的数学基础	3
第二章 测度论基础	4
2.1 可测空间, 测度, Lebesgue 积分	5
2.2 符号测度, Hahn 分解与 Radon–Nikodym 导数	19
第三章 概率论基础	31
3.1 概率空间与随机变量	32
3.2 随机变量的分布	34
3.3 期望与矩	42
3.4 独立性, 条件概率与条件期望	46
3.5 随机变量的收敛与极限定理	54
第四章 随机过程基础	65
4.1 从路径到信息	65
4.2 随机过程, 分布与样本路径	65
4.3 时间与信息	69
4.4 Markov 过程: 当前状态能否代表过去	72
4.5 鞅: 条件平均下没有可预测漂移	74
4.6 计数过程与 Poisson 过程	78
4.7 Brown 运动	80
4.8 有限变差与二次变差: 为随机积分作准备	84
4.9 小结	85
第五章 随机分析基础	86
5.1 从变差到随机微分	86
5.2 路径变差, 二次变差与半鞅	86
5.3 从简单过程构造 Itô 积分	91
5.4 Itô 公式, 乘积公式与随机指数	94
5.5 随机微分方程: 解的含义与基本模型	97
5.6 Girsanov 定理: 在有限期限内改变概率权重	100
5.7 生成元, Kolmogorov 方程与 Feynman–Kac	102
5.8 Poisson 随机测度与跳跃	104
5.9 连续扩散的计算次序	106
5.10 小结	106
第六章 从随机过程到金融交易	107
6.1 一时期二叉市场: 从状态到复制	107
6.2 多期离散时间: 鞅, 自融资与基本定理	110

6.3	停时与美式合约: Snell 包络	111
6.4	连续时间桥: 半鞅与随机积分增益	112
6.5	一个完整例子: 欧式看涨期权的复制与定价	114
6.6	点过程示例: 订单到达与因果边界	117
6.7	从报价到可实现损益: 同一策略的现金账	118
6.8	把模型放回真实市场	119
第二部分	随机过程与金融市场	121
第七章	金融市场基础	122
7.1	资产头寸, 价格与策略回报	122
7.2	衍生品与或有现金流	129
7.3	预测市场与市场隐含概率	139
7.4	指数, ETF 和被动投资	142
7.5	债券, 美债与利率	149
7.6	美联储, 美元体系与短端资金市场	156
7.7	贴现与无套利	163
7.8	交易, 订单簿与市场微观结构	169
第八章	基本面分析	179
8.1	从资产头寸到可识别价值	179
8.2	常用估值方法: 从经营预测到每股价值	182
8.3	Risk-Reward 框架与情景分析	186
8.4	Agentic R/D Graph: 把研究判断组织成可更新的图	190
第九章	趋势交易与技术指标: 从路径变换到可交易策略	197
9.1	从指标到账本	197
9.2	看到上涨以后, 还要回答什么	197
9.3	离散交易时钟, 信息集与可预测持仓	198
9.4	滤波的统一语言: 平滑, 时滞与尺度	199
9.5	从滤波器到趋势规则	201
9.6	常见指标: 准确公式与有限含义	204
9.7	随机过程怎样给趋势规则提供基准	206
9.8	怎样减少反复交易: 缓冲区与进出场规则	207
9.9	指标相同, 状态可以不同	209
9.10	从漂亮回测到可信检验	209
9.11	趋势研究与基本面估值怎样配合	212
9.12	实现补充: 数据, 活动订单与现金记录	212
9.13	小结	213
附录 A	金融市场制度史: 危机如何塑造今日结构	215
A.1	荷兰前史: 股份怎样让长期投资可以转手	215
A.2	英国前史: 政府借款与最后贷款人的形成	216
A.3	从 Buttonwood 到 1907 年: 私人组织怎样交易与救急	217
A.4	1913–1935 年: 央行怎样在危机中改变	218
A.5	私人交易所怎样受到公共监督	218
A.6	1970–1999 年: 利率错配, 跨市场交易与高杠杆	219
A.7	2000–2010 年: 从科技股损失到融资体系危机	220
A.8	2010–2026 年: 更快的交易与银行之外的融资	221
A.9	泡沫与危机留下了什么	223
A.10	为什么平时难改, 危机时却能迅速行动	224
A.11	回到随机过程: 制度变化怎样影响条件分布	225

第一章 引言

这份笔记面向具有实分析, 线性代数和基本概率知识的高年级本科生与研究生. 从测度和积分出发, 逐步研究随机变量怎样随时间共同变化, 信息怎样限制预测与行动, 以及这些问题在金融市场中怎样出现.

定义与证明用于回答具体问题. 为什么单个时刻的分布不足以描述一个过程, 为什么持仓必须在价格变化以前确定, 为什么某些极限可以与期望交换, 都会在相应位置展开. 内容主要参考教材, 讲义和论文, 出处随正文列出.

1.1 为什么是随机过程

一个时刻的价格, 一段时间内的到达次数, 都可以用随机变量描述. 若研究价格怎样变化或订单怎样陆续到达, 就要把不同时刻放在同一概率空间中, 同时考虑一族随机变量 $(X_t)_{t \in T}$. 这就是**随机过程**.

新增的内容不仅是时间下标, 更是不同时刻之间的关系. 例如, 一个序列的每一项都服从标准正态分布, 各项可以彼此独立, 也可以始终等于同一个随机变量. 两者的单时点分布完全相同, 观察过去以后对未来的判断却很不一样.

因此, 一方面要研究有限多个时刻的联合分布, 另一方面要研究一次完整实现所形成的样本路径. 路径是否连续, 首次达到某个水平需要多久, 长期分布是否趋于稳定, 都不能仅由一个时刻的分布回答.

信息也随时间进入问题. 已经观察到什么, 决定了能够怎样预测和选择行动. 后面的滤过, 条件期望, 停时和鞅, 将分别把这些要求写成可以推导的数学条件.

1.2 为什么需要测度论

在有限样本空间中, 可以逐项指定概率. 对无限序列或连续路径, 这样的办法不再适用. 我们需要先规定哪些路径集合是事件, 再构造与已知有限维分布相容的概率, 并研究极限是否仍保留相应性质.

在典范路径空间中, 一个样本点 ω 就是一条完整路径. 坐标映射读出它在某个时刻的取值, 首次到达时间和其他路径函数则使用更长一段历史. 这些函数是否可测, 取决于路径空间上采用的 σ -代数, 不能只凭形式上能够写出就略去检查.

测度论让这些问题使用同一套定义. 概率是总质量为一的测度, 随机变量是可测映射, 分布是前推测度, 期望是关于概率测度的 Lebesgue 积分. 这几项联系会在进入过程理论以前逐一建立.

收敛定理和 L^p 空间则处理另一类反复出现的工作: 用较简单的随机变量逼近目标, 判断极限能否移入期望, 并控制逼近误差. 方差与均方收敛使用二阶积分, 随机积分的构造也会依赖类似估计. 因而前面的测度论不只是补充术语, 后面的存在性与极限证明都会实际用到它.

1.3 金融市场作为贯穿的例子

金融市场把价格变化, 信息和行动放在一起, 适合反复使用前面的数学. 令 S_t 表示股票价格, 单独的 S_t 是随机变量, 整族 $(S_t)_{t \in T}$ 则描述价格过程.

用滤过 (filtration, 也称滤链) $(\mathcal{F}_t)$ 记录各时刻已经可用的信息, 就可以讨论未来价格的条件分布. 交易者依据这些信息确定持仓, 再承担后续涨跌; 首次跌破某个水平等行动规则, 则要求相应时点能凭当时信息辨认, 从而引出停时.

定价与预测还会提出不同问题. 期权复制需要匹配持仓和合约价值的随机变化, 因而用到 Brown 运动, 鞅和随机微分方程. 利率模型要同时比较不同付款期限, 订单流模型研究不规则到达, 执行模型则还要考虑等待期间的价格风险与实际成交成本.

技术指标也可以从这一角度理解. 均线和指数移动平均 (exponential moving average, EMA) 汇总历史水平, MACD 比较快慢平滑结果, Bollinger Bands 加入局部离散尺度, 成交量加权平均价格 (volume-weighted average price, VWAP) 汇总所选成交. 先算清指标保留了哪些历史信息, 再规定它怎样影响下一期持仓, 才能计算一条策略的收益.

这也给经验检验留下明确问题: 过去信息是否改变未来条件分布, 这种差异能否在实际成交后取得, 又是否足以支付成本. 这些答案依赖数据和交易条件, 不由指标公式单独决定.

1.4 模型要回答具体问题

选用几何 Brown 运动, 就先规定了连续的正价格路径和相应的增量规律. 在这些假设下可以推导复制策略, 但若研究跳空以后怎样平仓, 连续路径就省略了直接影响结果的变化. 同样, 一个不计买卖价差的模型可以比较理想复制成本, 却还不能给出大额订单的实际成交均价.

因此, 使用模型时先明确要计算什么, 再检查假设是否保留了决定答案的因素. 波动率需要随时变化时, 增加相应过程; 成交取决于排队和撤单时, 就继续研究订单记录与到达规律. 模型复杂程度应由问题决定, 不必把所有细节放进每一次计算.

推导所得结论始终带着这些条件. 与数据比较时, 既要核对参数, 也要判断交易规则, 融资方式或参与者行为是否已经改变了原来的问题.

1.5 阅读路线

前半部先建立测度, 积分和概率的基本结果, 再研究有限维分布与样本路径. 滤过和停时确定信息与行动时点, Markov 过程和 Poisson 过程给出具体模型, Brown 运动与鞅进一步用于随机积分和随机微分方程. 构造和证明紧接相应定义与定理, 所用条件在推导中说明.

第六章随后把价格, 持仓和现金放进同一自融资计算. 其中第6.5节从一份欧式看涨期权出发, 通过 Itô 公式匹配随机变化, 推出定价方程和持仓, 再用测度变换得到相同价格的期望表示. 最后核对现金账户, 比较连续复制与离散交易.

金融市场基础解释这些计算对应的实际权利与收付, 包括股票, 衍生品, 事件合约, 指数基金, 债券, 美元短端融资和订单执行. 基本面分析继续研究公司经营怎样产生每股利益, 情景分析比较不同预测的投资结果. 趋势交易章从指标一直计算到成交与净损益, 数据和订单记录的细节可在章末实现补充中查阅. 制度史则说明交易和融资条件为什么会随时期改变.

已有概率论基础的读法. 若已熟悉概率空间, 随机变量及分布, 期望与独立性, 条件期望, 各类收敛及基本极限定理, 可以直接从第四章阅读. 所需积分或 Radon-Nikodym 结果, 再回到第二章和第三章核对.

若数学基础较好而金融背景较少, 可以先读第七章, 再返回第六章. 前者说明交易究竟收付什么, 后者说明这些收付怎样接受随机过程和无套利条件的分析.

第一部分


随机过程的数学基础

第二章 测度论基础

测度论先解决两个相互联系的问题: 哪些子集可以赋予大小, 这些大小在集合运算和极限下应满足什么关系. 后面将总大小取为一, 就得到概率; 再对可测函数积分, 就得到期望. 本章主要参考 [Bog07; Fol99].

先保留面积这一具体例子. 矩形 $R = [a, b] \times [c, d]$ 的面积为 $(b - a)(d - c)$, 有限个不交矩形的面积可以相加. 圆盘却不能由有限个矩形精确拼成, 需要让划分不断细化.

下图每次把网格边长减半, 保留闭包完全位于开圆盘 D 内的小方块. 这样的有限近似说明, 从矩形推广到一般集合时, 为什么仅有有限次集合运算还不够.



为使网格组成不重叠的划分, 将每个小方块取为半开矩形, 并只选取闭包包含于 D 的方块. 记第 n 次得到的有限并为 A_n . 细化时, 原来被选中的方块会由更小的方块完整覆盖, 所以 $A_n \subseteq A_{n+1}$. 对任意 $x \in D$, 它到圆盘外的距离为正, 网格足够细时, 包含它的方块闭包也在 D 内. 因而

$$D = \bigcup_{n=1}^{\infty} A_n.$$

这给出了精确的集合逼近, 尚未预先假定圆盘面积是多少. 若每个 A_n 都可测, 而又要测量其极限集合, 所选集合族就应对可列并封闭.

补集同样必要: 已经能判断点是否落在 A , 就应能判断是否落在 $X \setminus A$. 有了补集和可列并, De Morgan 律又给出可列交:

$$\bigcap_{n=1}^{\infty} A_n = \left(\bigcup_{n=1}^{\infty} A_n^c \right)^c.$$

因此选取 $\mathcal{F} \subseteq \mathcal{P}(X)$, 要求

1. $X \in \mathcal{F}$;
2. $A \in \mathcal{F}$ 时, $A^c \in \mathcal{F}$;
3. $A_1, A_2, \dots \in \mathcal{F}$ 时, $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$.

这样的集合族称为 X 上的 σ -代数. 它规定可以测量的集合, 并保证从可列逼近和相应集合运算得到的结果仍在同一范围内.

在 $\mathcal{F}$ 上赋予大小, 要与不交分解相容. 函数 $\mu: \mathcal{F} \rightarrow [0, \infty]$ 若满足 $\mu(\emptyset) = 0$, 并对任意两两不交的 $A_1, A_2, \dots \in \mathcal{F}$ 满足

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n),$$

就称为测度, $(X, \mathcal{F}, \mu)$ 称为测度空间.

可列可加性不仅用于相加, 也控制极限. 对前面的递增集合列, 将每次新增的部分分别列出, 它们两两不交, 因而圆盘的测度等于这些有限近似测度的极限. 后面将从定义证明这种连续性.


概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 只是总测度满足 $\mathbb{P}(\Omega) = 1$ 的特例. 可测子集此时称为事件, 并, 交和补分别组合事件的发生条件. 样本点也可以是一整条路径, 这些测度公理并不要求样本空间有限或能够逐项列出.

接下来要将集合的测量用于函数. 随机变量的期望与方差都需要积分, 而积分首先要知道函数的取值区间对应哪些可测集合. 这使可测映射与积分自然联系起来.


两种熟悉的积分逼近, 可以说明为什么需要测量函数的原像.

Riemann 积分先划分定义域. 对 $f: [a, b] \rightarrow \mathbb{R}$, 将 $[a, b]$ 分成小区间, 每段选取一个函数值作为高度, 再乘该段长度并相加. 对非负函数, 这相当于用一系列竖矩形逼近图像下的面积.

Lebesgue 积分先按函数值分组. 固定一段高度, 把取值落入这一段的所有点收在一起, 即使它们在定义域中分散成许多部分, 也可以使用同一近似高度. 下图右侧的两段横轴区域合起来就是 $f^{-1}([a, b])$. 计算这部分贡献, 需要知道整个原像的测度, 而不要求它本身是一个区间.



Riemann: 先划分 x 所在的区间
每段取一个高度, 再乘该段的长度



Lebesgue: 先按函数值分组
轴上两段合起来是 $f^{-1}([a, b])$

要对这些原像使用测度, 它们必须属于 $\mathcal{F}$. 对实值函数, 例如要测量取值不超过 a 的部分, 就要求 $f^{-1}((-\infty, a]) \in \mathcal{F}$. 后面会证明, 检查这一族半直线已经足以保证所有 Borel 集合的原像可测.

一般地, 从 $(X, \mathcal{F})$ 到 $(Y, \mathcal{G})$ 的可测映射满足: 每个 $B \in \mathcal{G}$ 都有 $f^{-1}(B) \in \mathcal{F}$. 因而目标空间中规定的取值条件, 能在原空间中成为可测事件.

先令 $s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$ 为非负简单函数, 系数 a_i 是非负实数. 将可测集细分为两两不交的部分以后, 每部分上函数都取一个确定高度, 定义

$$\int_X s d\mu = \sum_{i=1}^n a_i \mu(A_i),$$

并约定 $0 \cdot \infty = 0$. 每项就是高度乘以对应集合的大小. 用共同细分比较两种表示, 可以验证结果只依赖函数本身.

一般非负可测函数的积分, 定义为所有不超过它的非负简单函数积分的上确界, 允许结果为 $+\infty$. 随后证明简单函数可以递增逼近它, 积分也随之收敛. 有正负值时, 再分别积分正部与负部, 并排除两者同时为无穷的相减.

在概率空间中, 可积随机变量 $X: \Omega \rightarrow \mathbb{R}$ 的期望正是

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

因此, 后面关于期望和极限的论证, 可以直接使用本章建立的可测性与积分收敛结果. 下一节将把上述构造和性质逐项写清楚.

2.1 可测空间, 测度, Lebesgue 积分

2.1.1 可测空间与 σ -代数

章首先从补集与可列并定义 σ -代数. 这里换用对称差和交给出等价表述, 使集合运算中的代数关系也能直接使用.

对 $A, B \subseteq X$, 对称差为

$$A \Delta B = (A \setminus B) \cup (B \setminus A).$$

它与交集互不相交, 且

$$A \cup B = (A \Delta B) \sqcup (A \cap B).$$

因此, 对这些集合可测的任何测度都有 $\mu(A \cup B) = \mu(A \triangle B) + \mu(A \cap B)$. 把并集改写成不交部分, 可以直接使用可加性, 而不必从可能为无穷的测度中作减法.

以对称差为加法, 交为乘法, $\mathcal{P}(X)$ 构成布尔环 (Boolean ring). 空集是加法零元, $A \triangle A = \emptyset$, 每个元素都是自己的加法逆元; $A \cap A = A$ 则说明乘法幂等. 全空间 X 是乘法单位. 在此基础上再加入可列运算, 可以采用下面的 σ -代数定义.

定义 2.1.

σ -代数是指集合族 $\mathcal{F} \subseteq \mathcal{P}(X)$, 其满足:

1. $X \in \mathcal{F}$;
2. 对于任意 $A, B \in \mathcal{F}$, 都有 $A \triangle B \in \mathcal{F}$;
3. 对于任意 $A_1, A_2, \dots \in \mathcal{F}$, 都有

$$\bigcap_{n=1}^{\infty} A_n \in \mathcal{F}.$$

这和通常使用补集和可列并给出的定义等价. 首先因为 $X \in \mathcal{F}$, 对于 $A \in \mathcal{F}$ 有 $A^c = X \triangle A \in \mathcal{F}$, 所以补集自动存在. 有了补集和可列交以后, 根据 De Morgan 律又有 $\bigcup_{n=1}^{\infty} A_n = (\bigcap_{n=1}^{\infty} A_n^c)^c \in \mathcal{F}$, 所以可列并也自动存在.

反过来, 如果按照通常的方式要求对于补集和可列并封闭, 那么交可以由 De Morgan 律得到, 而对称差也可以写成 $A \triangle B = (A \cap B^c) \cup (B \cap A^c)$, 所以两种定义描述的是同一个东西.

定义 2.2.

可测空间是指二元组 $(X, \mathcal{F})$, 其中 X 为集合, $\mathcal{F}$ 为 X 上的 σ -代数.

这里的 X 是所研究的空间. 在概率论中常用 Ω 表示 X , 并称为样本空间; $\mathcal{F}$ 规定其中哪些子集可以“测量”, 此时称为事件域, 其中的元素称为事件.

例 2.3.

对于任意集合 X , 总有两个最自然的 σ -代数, 即 $\{\emptyset, X\}$ 以及 $\mathcal{P}(X)$. 当 $X = \emptyset$ 时二者恰好相同.

有拓扑时, 通常先要求开集可测, 再加入测度论需要的集合运算. 拓扑本身对任意并和有限交封闭, 不必对补集封闭, 所以还需要生成 σ -代数.

定义 2.4.

由集合族 $\mathcal{A} \subseteq \mathcal{P}(X)$ 生成的 σ -代数为

$$\sigma(\mathcal{A}) = \bigcap_{\substack{\mathcal{F} \supseteq \mathcal{A} \\ \mathcal{F} \text{ is a } \sigma\text{-algebra}}} \mathcal{F}.$$

参与求交的集合族非空, 因为 $\mathcal{P}(X)$ 包含 $\mathcal{A}$. 每个参与者都对补集和可列并封闭, 它们的交也保留这些性质. 所以 $\sigma(\mathcal{A})$ 确实是 σ -代数, 并且包含在任何一个含有 $\mathcal{A}$ 的 σ -代数中. 这证明了其最小性.

定义 2.5.

拓扑空间 (X, τ) 的 Borel σ -代数为

$$\mathcal{B}(X) = \sigma(\tau),$$

其中的集合称为 Borel 集.

在通常拓扑的 $\mathbb{R}$ 上, 每个开集都能写成可列个开区间之并, 例如使用有理端点的可列基. 因而

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(a, b) \mid a < b\}).$$

闭集, 半开区间和单点集随补集与可列运算一并纳入. 还可以只用左半直线生成:

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, a] \mid a \in \mathbb{R}\}).$$

一方面这些半直线本来就是 Borel 集; 另一方面, 由 $(-\infty, b) = \bigcup_{n \geq 1} (-\infty, b - 1/n]$ 再作集合差, 可以得到任意开区间 (a, b) , 所以两边相等.

这种较小的生成族特别适合检验测度和映射. 但一个性质在生成元上成立, 还需要证明它能随适当的集合运算保留, 才能推广到整个 σ -代数. 接下来的 π - λ 定理给出常用的检验办法.

定义 2.6.

集合族 $\mathcal{P} \subseteq \mathcal{P}(X)$ 若对二元交封闭, 即 $A, B \in \mathcal{P}$ 时 $A \cap B \in \mathcal{P}$, 就称为 π -系. 因而它也对非空有限交封闭, 这里不另要求 $X \in \mathcal{P}$.

定义 2.7.

λ -系, 也称为 Dynkin 系, 是指集合族 $\mathcal{D} \subseteq \mathcal{P}(X)$, 其满足:

1. $X \in \mathcal{D}$;
2. 对于 $A, B \in \mathcal{D}$, 如果 $A \subseteq B$, 则 $B \setminus A \in \mathcal{D}$;
3. 对于两两不交的 $A_1, A_2, \dots \in \mathcal{D}$, 有

$$\bigsqcup_{n=1}^{\infty} A_n \in \mathcal{D}.$$

λ -系中的差集只对包含关系提出要求, 可列并也只要求各项不交. 若它还对交封闭, 就可以先取得补集, 再把任意可列并依次去掉前面的重叠部分, 化成不交可列并. 因而同时为 π -系和 λ -系的集合族就是 σ -代数. 下面证明的关键, 是对两个集合先后固定一个, 使最小 λ -系也获得对交的封闭性.

定理 2.8 (π - λ 定理).

令 $\mathcal{P}$ 为 X 上的一个 π -系, $\mathcal{D}$ 为一个包含 $\mathcal{P}$ 的 λ -系. 如果 $\mathcal{P} \subseteq \mathcal{D}$, 则有

$$\sigma(\mathcal{P}) \subseteq \mathcal{D}.$$

证明. 记 $\lambda(\mathcal{P})$ 为包含 $\mathcal{P}$ 的最小 λ -系. 固定 $A \in \mathcal{P}$, 并令

$$\mathcal{D}_A = \{B \subseteq X : A \cap B \in \lambda(\mathcal{P})\}.$$

由 λ -系对相对补与不交可列并封闭, $\mathcal{D}_A$ 也是 λ -系. 又因为 $\mathcal{P}$ 是 π -系, 对 $B \in \mathcal{P}$ 有 $A \cap B \in \mathcal{P}$, 所以 $\mathcal{P} \subseteq \mathcal{D}_A$. 最小性给出 $\lambda(\mathcal{P}) \subseteq \mathcal{D}_A$.

现在固定 $B \in \lambda(\mathcal{P})$, 并令

$$\mathcal{E}_B = \{A \subseteq X : A \cap B \in \lambda(\mathcal{P})\}.$$

同理, $\mathcal{E}_B$ 是 λ -系; 上一步说明它包含 $\mathcal{P}$, 故它也包含 $\lambda(\mathcal{P})$. 因此 $\lambda(\mathcal{P})$ 对有限交封闭. 一个同时为 π -系和 λ -系的集合族对补集与任意可列并封闭, 因而是 σ -代数. 所以

$$\sigma(\mathcal{P}) = \lambda(\mathcal{P}) \subseteq \mathcal{D}.$$

这一两次固定集合的证明也见 [Kal21, Theorem 1.1]. □

使用这一结果时, 可以把满足所需性质的集合收成一族, 检查它是否为 λ -系. 如果已经包含生成 σ -代数的 π -系, 就完成了推广. 有限测度的唯一性正是一个直接例子.

推论 2.9.

令 μ, ν 为 $(X, \mathcal{F})$ 上的有限测度, $\mathcal{P}$ 为满足 $\sigma(\mathcal{P}) = \mathcal{F}$ 的 π -系. 若 $\mu(X) = \nu(X)$, 且每个

$A \in \mathcal{P}$ 都有 $\mu(A) = \nu(A)$, 则

$$\mu = \nu.$$

证明. 令 $\mathcal{D} = \{A \in \mathcal{F} : \mu(A) = \nu(A)\}$. 总质量相等保证 $X \in \mathcal{D}$. 若 $A \subseteq B$ 且二者在 $\mathcal{D}$ 中, 有限性允许相减, 因而两测度在 $B \setminus A$ 上仍相等. 可列可加性又保证 $\mathcal{D}$ 对不交可列并封闭. 所以 $\mathcal{D}$ 是包含 $\mathcal{P}$ 的 λ -系, 由定理包含整个 $\mathcal{F}$. $\square$

半直线族 $\{(-\infty, a] : a \in \mathbb{R}\}$ 是生成 $\mathcal{B}(\mathbb{R})$ 的 π -系. 两个概率测度的总质量已经都是一, 因而只需比较这些半直线的概率, 就能判断它们是否相同. 后面的分布函数唯一性正来自这里.

集合可以测量以后, 还要判断函数的取值条件是否对应可测集合.

定义 2.10.

对可测空间 $(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$, 若 $f: X \rightarrow Y$ 满足每个 $A \in \mathcal{G}$ 都有

$$f^{-1}(A) \in \mathcal{F},$$

就称 f 为可测映射.

检验时不必总遍历整个 $\mathcal{G}$. 集合族 $\{A \subseteq Y : f^{-1}(A) \in \mathcal{F}\}$ 本身是 σ -代数, 因为原像保持补集和可列并. 所以只要它包含 $\mathcal{G}$ 的生成族, 就包含整个 $\mathcal{G}$. 特别地, 实值函数可以通过所有 $\{f \leq a\}$ 的可测性来检验.

同样的原像性质保证可测映射的复合仍可测, 恒等映射也可测, 从而形成范畴 $\mathbf{Meas}$. 连续映射相对于两边的 Borel σ -代数是可测的: 先检查开集原像, 再使用生成族即可.

注 2.11.

实值随机变量就是从概率空间到 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 的可测映射. 所以函数的取值条件能够成为事件, 是给它讨论分布和期望的前提.

2.1.2 测度

现在在 $(X, \mathcal{F})$ 上赋予测度. 除了有限不交分解, 还要求可列不交分解能够直接相加, 才能处理前面圆盘逼近一类极限.

定义 2.12.

函数 $\mu: \mathcal{F} \rightarrow [0, \infty]$ 称为测度, 若满足:

1. $\mu(\emptyset) = 0$;
2. 对每列两两不交的 $A_1, A_2, \dots \in \mathcal{F}$,

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

三元组 $(X, \mathcal{F}, \mu)$ 称为测度空间. 第二项是可列可加性, 也称 σ -可加性. 它包括有限可加性, 因为可以把有限列之后的集合全取为空集.

若 $A \subseteq B$, 分解 $B = A \sqcup (B \setminus A)$ 给出 $\mu(B) = \mu(A) + \mu(B \setminus A)$, 从而 $\mu(A) \leq \mu(B)$. 这就是单调性. 只有在 $\mu(A) < \infty$ 时, 才能继续写成 $\mu(B \setminus A) = \mu(B) - \mu(A)$, 避免未定义的 $\infty - \infty$.

一般两个集合则可按交与对称差分解:

$$\mu(A \cup B) = \mu(A \Delta B) + \mu(A \cap B).$$

分别拆开 A 与 B , 还得到

$$\mu(A \cup B) + \mu(A \cap B) = \mu(A) + \mu(B).$$

保持这种加法形式, 即使部分测度为无穷也仍有意义.

对任意可测集列, 依次从每项中去掉此前已经出现的部分, 可得可列次可加性 $\mu(\bigcup_n A_n) \leq \sum_n \mu(A_n)$. 特别地, 可列个零测集的并仍是零测集.

可列可加性还给出**从下连续性**. 若 $A_n \uparrow A$, 令 $A_0 = \emptyset$, 则新增部分 $A_n \setminus A_{n-1}$ 两两不交, 因而

$$\mu(A) = \sum_{n=1}^{\infty} \mu(A_n \setminus A_{n-1}) = \lim_{n \rightarrow \infty} \mu(A_n).$$

这里不要求 $\mu(A)$ 有限. 后面扩张唯一性和单调收敛的证明, 都会用到这项由可加性直接推出的极限性质.

还有一种后面会反复遇到的集合, 就是大小为 0 的集合.

定义 2.13.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称可测集 $N \in \mathcal{F}$ 为**零测集**, 是指其满足

$$\mu(N) = 0.$$

零测集可以非空, 甚至包含很多点. 对 $\mathbb{R}$ 上的 Lebesgue 测度, 每个单点测度为零, 可列次可加性使任何可数集也为零测集. 集合中有点与测度为正, 是不同的判断.

若 $A \subseteq N$ 且 $\mu(N) = 0$, 在 A 已经可测时, 单调性必给出 $\mu(A) = 0$. 唯一可能缺少的是可测性本身: 原来的 $\mathcal{F}$ 未必包含 N 的每个子集. 完备性正用于补足这一点.

定义 2.14.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称其为**完备测度空间**, 是指对于任意零测集 $N \in \mathcal{F}$ 以及任意子集 $A \subseteq N$, 都有 $A \in \mathcal{F}$.

完备空间把这些子集一并纳入, 并赋予零测度. 后面的完整 Lebesgue 测度采用这种做法, 仅限制在 Borel 集合上的版本则没有包含全部零测集子集.

积分经常只关心零测集以外的取值, 因而使用下面的表述.

定义 2.15.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称一个关于 $x \in X$ 的性质**几乎处处成立**, 是指存在零测集 N , 使得这个性质对于所有 $x \in X \setminus N$ 都成立. 常记作 μ -a.e., 或者在没有歧义的时候直接写作 a.e.

$f = g$ a.e. 表示两者只可能在某个可测零测集上不同. 若两者均可测且积分有相应定义, 这种差异不改变积分. 在不完备空间中, 任意修改零测集上的取值却可能破坏可测性, 所以不能略去前一个条件.

测度还可以取 ∞ , 例如整条实线的长度. 后面许多定理不要求全空间有限, 只要求能够分成可列个有限测度的部分.

定义 2.16.

令 $(X, \mathcal{F}, \mu)$ 为测度空间.

- 称 μ 为一个**有限测度**, 是指其满足 $\mu(X) < \infty$.
- 称 μ 为一个 **σ -有限测度**, 是指存在一列可测集 $A_1, A_2, \dots \in \mathcal{F}$, 满足

$$X = \bigcup_{n=1}^{\infty} A_n, \quad \mu(A_n) < \infty.$$

有限测度当然是 σ -有限的, 反向却不成立. 实线满足 $\mathbb{R} = \bigcup_{n=1}^{\infty} [-n, n]$, 每个区间长度有限, 全空间长度仍为无穷. σ -有限性允许先在有限测度部分证明结果, 再沿递增覆盖取极限; 测度扩张的唯一性和后面的 Fubini 定理都会使用这种做法.

概率测度的总质量为一, 已经满足更强的有限性. 若另有拓扑, 还会关心测度能否通过紧集和开集逼近, 这与总质量有限是另一项要求.

定义 2.17.

令 X 为局部紧 Hausdorff 空间, μ 为定义在 $\mathcal{B}(X)$ 上的 Borel 测度. 称 μ 为 **Radon 测度**, 是指其满足:

1. 在紧集上有限;
2. 对于任意 Borel 集 A , 有内正则性

$$\mu(A) = \sup\{\mu(K) \mid K \subseteq A, K \text{ compact}\};$$

3. 对于任意 Borel 集 A , 有外正则性

$$\mu(A) = \inf\{\mu(U) \mid A \subseteq U, U \text{ open}\}.$$

内正则性从集合内部取紧集逼近测度, 外正则性从外部取开集逼近. 这让拓扑逼近也能控制测度. 本文采用上述 Radon 约定; 一般拓扑空间上的不同文献可能采用略有差异的定义. 对这里主要使用的 $\mathbb{R}^n$, 它对应局部有限且正则的 Borel 测度. Lebesgue 测度限制到 Borel σ -代数就是重要例子.

例 2.18 (计数测度).

在 $(X, \mathcal{P}(X))$ 上定义

$$\mu(A) = \#A,$$

有限集取元素个数, 无限集取 ∞ . 不交集合的元素分别计数, 因而满足可列可加性. 它也可以限制到任意给定的 σ -代数上使用.

例 2.19 (Dirac 测度).

在可测空间 $(X, \mathcal{F})$ 中固定 $x \in X$, 定义

$$\delta_x(A) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

对不交集合列, 至多一项包含 x , 所以这同样给出测度, 且 $\delta_x(X) = 1$. 在允许测量单点的空间中, 可以直接说全部质量集中于 x .

面积, 计数和集中于一点的概率使用同一套公理, 但测量结果完全不同. 固定可测空间以后, 仍然需要指明采用哪一个测度.

Lebesgue 测度 现在在 $\mathbb{R}^d$, $d \geq 1$, 上构造 Lebesgue 测度. 从矩形的边长乘积开始, 先确认不同分解和可列覆盖与这个体积相容, 再把定义扩张到更大的集合族. 这样得到的长度, 面积和体积, 就能够与可列极限一起使用.

以下矩形端点均为有限实数, 因而矩形有界. 采用半开而非闭区间, 便于把相邻部分拼接为不交划分.

定义 2.20 (体积函数).

半开矩形是指形如

$$[a, b) = \prod_{i=1}^d [\alpha_i, \beta_i)$$

的集合, 其中 $a = (\alpha_1, \dots, \alpha_d)$, $b = (\beta_1, \dots, \beta_d) \in \mathbb{R}^d$, 并且对于所有 $i = 1, \dots, d$ 都有 $\alpha_i \leq \beta_i$.

半开矩形 $[a, b)$ 的体积定义为

$$\lambda([a, b)) = \prod_{i=1}^d (\beta_i - \alpha_i).$$

如果存在某个 i 使得 $\alpha_i = \beta_i$, 那么 $[a, b) = \emptyset$, 此时自然有 $\lambda([a, b)) = 0$.

注 2.21.

原则上我们也可以从开矩形或者闭矩形出发, 但是半开矩形 $[a, b)$ 在集合运算上具有更好的性质. 所有半开矩形构成一个半环, 特别是两个半开矩形之差总可以写成有限多个彼此不交的半开矩形之并.

将有限个半开矩形合起来, 可以得到对有限并和集合差封闭的集合族. 非空且对这两种运算封闭的集合族称为**集合环**; 若还包含全空间 X , 才是 X 上的**集合代数**.

令 $\mathcal{A}$ 为有限个有界半开矩形的并所构成的集合环. 每个成员都可以细分成不交矩形, 但仍然有界, 所以 $\mathbb{R}^d \notin \mathcal{A}$. 对 $A = \bigsqcup_{i=1}^n I_i \in \mathcal{A}$, 定义 $\lambda_0(A) = \sum_{i=1}^n \lambda(I_i)$. 把两种矩形分解的全部端点放在同一网格上细分, 可以验证这个值与分解无关, 并且有限可加.

仅有有限可加性还不足以扩张. 需要保证一个环内集合若由可列个不交环内集合组成, 体积也能按这一分解相加.

定义 2.22 (预测度).

令 $\mathcal{A}$ 为 X 上的集合环. 函数 $\mu_0: \mathcal{A} \rightarrow [0, \infty]$ 称为**预测度**, 若 $\mu_0(\emptyset) = 0$, 且对两两不交的 $A_n \in \mathcal{A}$, 只要它们的并仍在 $\mathcal{A}$ 中, 就有

$$\mu_0\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu_0(A_n).$$

矩形体积的这项性质可以用紧性验证. 若 $A = \bigsqcup_n A_n \in \mathcal{A}$, 有限可加性先给出 $\sum_{n=1}^N \lambda_0(A_n) \leq \lambda_0(A)$. 对反向不等式, 在 A 的有限个矩形内取紧矩形, 使损失的总体积小于 ε ; 再将每个 A_n 的有限矩形分解稍向外扩大为开矩形, 使总体积增加小于 $\varepsilon 2^{-n}$. 这些开矩形覆盖所取紧集, 因而有有限子覆盖. 对有限个矩形作共同细分比较体积, 得到

$$\lambda_0(A) - \varepsilon \leq \sum_{n=1}^{\infty} \lambda_0(A_n) + \varepsilon.$$

令 $\varepsilon \downarrow 0$, 与前一个方向合并, 就证明了 λ_0 是预测度. 这里对开矩形和紧矩形的体积仍只使用边长乘积及有限划分, 没有预先使用待构造的 Lebesgue 积分.

定理 2.23 (Carathéodory 扩张定理).

令 $\mathcal{A}$ 为 X 上的集合环, 并假设存在 $E_m \in \mathcal{A}$ 使 $X = \bigcup_m E_m$. 若 μ_0 是 $\mathcal{A}$ 上的预测度, 则存在 $\sigma(\mathcal{A})$ 上的测度 μ 满足

$$\mu|_{\mathcal{A}} = \mu_0.$$

若可以选取上述覆盖使每个 $\mu_0(E_m) < \infty$, 即预测度 σ -有限, 则扩张唯一.

证明. 对任意 $E \subseteq X$ 定义

$$\mu^*(E) = \inf \left\{ \sum_{n=1}^{\infty} \mu_0(A_n) : E \subseteq \bigcup_{n=1}^{\infty} A_n, A_n \in \mathcal{A} \right\}.$$

空集可由空集覆盖, 故 $\mu^*(\emptyset) = 0$. 覆盖较大集合也覆盖其子集, 给出单调性; 将各集合的近似最优覆盖合并, 并将误差分配为 $\varepsilon 2^{-n}$, 给出可列次可加性. 因而 μ^* 是外测度.

先验证它没有改变环内原来的数值. 用 $A \in \mathcal{A}$ 自身覆盖, 得到 $\mu^*(A) \leq \mu_0(A)$. 对任意覆盖 $A \subseteq \bigcup_n A_n$, 依次令 $B_n = A \cap (A_n \setminus \bigcup_{k < n} A_k)$. 这些集合属于环, 两两不交且并为 A . 预测度的可列可加性给出 $\mu_0(A) = \sum_n \mu_0(B_n) \leq \sum_n \mu_0(A_n)$. 对覆盖取下确界, 得 $\mu^*(A) = \mu_0(A)$.

再定义

$$\mathcal{M} = \{C \subseteq X : \mu^*(E) = \mu^*(E \cap C) + \mu^*(E \setminus C) \text{ 对所有 } E \subseteq X\}.$$

对 $C \in \mathcal{A}$, 将任意覆盖中的每个 A_n 拆为 $A_n \cap C$ 和 $A_n \setminus C$. 环的封闭性与有限可加性说明, 拆分总成本不变, 因而 $\mu^*(E \cap C) + \mu^*(E \setminus C) \leq \mu^*(E)$. 反向不等式来自外测度的次可加性, 所以 $\mathcal{A} \subseteq \mathcal{M}$.

判据对补集对称, 接连作两次切分又说明 $\mathcal{M}$ 对有限集合运算封闭. 若 $C_n \in \mathcal{M}$ 两两不交, 记 $C = \bigcup_n C_n$. 有限次切分及单调性给出

$$\mu^*(E) \geq \sum_{k=1}^n \mu^*(E \cap C_k) + \mu^*(E \setminus C).$$

令 $n \rightarrow \infty$, 再用 $\mu^*(E \cap C) \leq \sum_k \mu^*(E \cap C_k)$, 得到 C 的可测判据. 任意可列并可以先去掉重叠部分, 因而 $\mathcal{M}$ 是 σ -代数. 在上式取 $E = C$, 并结合次可加性, 又得到 $\mu^*|_{\mathcal{M}}$ 的可列可加性. 由于 $\sigma(\mathcal{A}) \subseteq \mathcal{M}$, 将该测度限制到 $\sigma(\mathcal{A})$ 即得扩张.

最后假设 μ_0 σ -有限. 令 $B_m = E_1 \cup \cdots \cup E_m$, 则 $B_m \uparrow X$ 且 $\mu_0(B_m) < \infty$. 两个扩张在 B_m 上都是有限测度, 在生成迹 σ -代数的 π -系 $\{A \cap B_m : A \in \mathcal{A}\}$ 上一致, 总质量也都等于 $\mu_0(B_m)$. 由 π - λ 定理, 它们在 $\sigma(\mathcal{A})|_{B_m}$ 上一致. 再对任意 $E \in \sigma(\mathcal{A})$ 使用 $E \cap B_m \uparrow E$ 的测度连续性, 得到全局唯一性. 外测度构造参见 [Kal21, Theorem 2.5], σ -有限唯一性参见 [Kal21, Lemma 1.18] 或 [Dur19, Theorem A.1.3]. $\square$

若起点是集合代数, 可以用 X 自身覆盖全空间, 所以通常的代数版本包含在这个表述中. 对有限矩形环, 则使用 $[-m, m)^d \uparrow \mathbb{R}^d$, 每块体积有限. 有理端点开矩形构成可列拓扑基, 而每个这样的开矩形都是可列个环内半开矩形的并, 因而 $\sigma(\mathcal{A}) = \mathcal{B}(\mathbb{R}^d)$, 得到唯一的 Borel 扩张.

环内集合各自都是有限个矩形的并, 所以外测度定义中的环内覆盖也可以拆成可列矩形覆盖. 于是上面的构造在此具体成为下面的 Lebesgue 外测度.

定义 2.24 (Lebesgue 外测度).

Lebesgue 外测度是指函数 $\theta: \mathcal{P}(\mathbb{R}^d) \rightarrow [0, \infty]$, 其中对于任意 $A \subseteq \mathbb{R}^d$ 定义

$$\theta(A) = \inf \left\{ \sum_{n=1}^{\infty} \lambda(I_n) \mid A \subseteq \bigcup_{n=1}^{\infty} I_n, I_n \text{ 为半开矩形} \right\}.$$

覆盖不要求矩形两两不交, 相交部分只会使该次总体积增加. 对全部覆盖取下确界, 就能得到从外部覆盖 A 所需的最小体积尺度. 前面已经证明, 对原来的矩形和有限并, 这个下确界仍等于其体积.

外测度满足 $\theta(\emptyset) = 0$, 单调性及可列次可加性

$$\theta\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \theta(A_n).$$

即使各 A_n 不交, 对任意子集也未必有可加性, 所以 θ 尚不是幂集上的测度. 接下来选出能够对任意集合作无损切分的集合; 在这一范围内, 外测度才成为测度.

定义 2.25 (Carathéodory 可测集).

令 θ 为 $\mathbb{R}^d$ 上的 Lebesgue 外测度. 称集合 $E \subseteq \mathbb{R}^d$ 为 θ -可测集, 是指其满足对于任意 $A \subseteq \mathbb{R}^d$ 都有

$$\theta(A) = \theta(A \cap E) + \theta(A \setminus E).$$

次可加性已经保证 $\theta(A) \leq \theta(A \cap E) + \theta(A \setminus E)$. 判据还要求反向不等式, 即不论用什么 A 检验, 按 E 内外切开都不改变总外测度. 前面扩张证明已经说明, 满足这一条件的集合组成 σ -代数, 外测度在其上可列可加.

令

$$\mathcal{L}(\mathbb{R}^d) = \left\{ E \subseteq \mathbb{R}^d \mid \forall A \subseteq \mathbb{R}^d, \theta(A) = \theta(A \cap E) + \theta(A \setminus E) \right\}.$$

Carathéodory 的结果表明, $\mathcal{L}(\mathbb{R}^d)$ 是一个 σ -代数, 而且 θ 限制到它上面后具有可列可加性.

定义 2.26 (Lebesgue 测度).

$\mathbb{R}^d$ 上的 **Lebesgue σ -代数**是指 $\mathcal{L}(\mathbb{R}^d)$, 其中的元素称为 **Lebesgue 可测集**.
 $\mathbb{R}^d$ 上的 **Lebesgue 测度**是指测度

$$\lambda_d = \theta|_{\mathcal{L}(\mathbb{R}^d)}.$$

于是我们最终得到了测度空间 $(\mathbb{R}^d, \mathcal{L}(\mathbb{R}^d), \lambda_d)$. 整个过程可概括为

矩形上的体积 $\rightarrow$ 预测度 $\rightarrow$ 外测度 $\rightarrow$ Carathéodory 可测集 $\rightarrow$ Lebesgue 测度.

对 $d \geq 1$, 有严格包含

$$\mathcal{B}(\mathbb{R}^d) \subsetneq \mathcal{L}(\mathbb{R}^d).$$

外测度为零的集合及其所有子集都满足 Carathéodory 判据, 所以完整 Lebesgue 测度是完备的. 这已经超出了仅由开集生成的 Borel 集合.

准确地说, 每个 Lebesgue 可测集都与某个 Borel 集只相差一个包含在 Borel 零测集内的集合. 有限测度部分可以通过外测度定义选取体积任意接近的 Borel 覆盖, 再对覆盖取交得到这个结论; 全空间则沿 $[-m, m]^d$ 的覆盖拼接. 因而把 Borel 测度中的所有零测集子集补入, 恰好得到 $\mathcal{L}(\mathbb{R}^d)$.

所以这里有同一体积测量的两个版本: 限制在 $\mathcal{B}(\mathbb{R}^d)$ 上的是 Radon 测度, 但不完备; 定义在 $\mathcal{L}(\mathbb{R}^d)$ 上的是它的完备化. 后面形成乘积测度时, 还要保留这一区别.

2.1.3 Lebesgue 积分

固定测度空间 $(X, \mathcal{F}, \mu)$. 章首按函数值分组的做法, 先对只取有限多个值的函数给出积分. 每个取值对应的集合可测, 就可以计算该高度所覆盖的测度.

定义 2.27 (非负简单函数及其积分).

非负简单函数是 $s = \sum_{i=1}^n a_i 1_{E_i}$, 其中 a_i 为非负实数, $E_i \in \mathcal{F}$. 定义

$$\int_X s \, d\mu = \sum_{i=1}^n a_i \mu(E_i),$$

并约定 $0 \cdot \infty = 0$.

这里不要求所写的 E_i 已经互不相交. 对两种表示同时细分, 可将空间分成有限个部分, 每部分上的函数值固定. 测度的有限可加性使两种求和得到同一个数, 因而定义与表示方式无关.

一般非负函数未必只有有限个取值, 于是用所有位于它下方的简单函数比较.

定义 2.28 (非负可测函数及其积分).

对可测函数 $f: X \rightarrow [0, \infty]$, 定义

$$\int_X f \, d\mu = \sup \left\{ \int_X s \, d\mu \mid s \text{ 是非负简单函数且 } s \leq f \right\}.$$

结果允许为 $+\infty$.

零函数总在比较范围内, 所以上确界有定义. 此时还没有使用任何交换极限与积分的结论; 稍后将构造一列递增简单函数, 再证明其积分确实趋于这个上确界.

实值函数需要分别处理正负贡献. 若两边都积成无穷, 相减没有定义, 这就是绝对可积条件进入下一定义的原因.

定义 2.29 (Lebesgue 可积函数及其积分).

令 $f: X \rightarrow \mathbb{R}$ 为可测函数, 并记 $f_+ = \max\{f, 0\}$, $f_- = \max\{-f, 0\}$. 则 f_+ 和 f_- 都是非负可测函数, 并且 $f = f_+ - f_-$, $|f| = f_+ + f_-$.

称 f 为 **Lebesgue 可积函数**, 或简称**可积函数**, 是指 f_+ 和 f_- 都具有有限的 Lebesgue

积分. 此时定义

$$\int_X f \, d\mu = \int_X f_+ \, d\mu - \int_X f_- \, d\mu.$$

因此 f 可积也就等价于 $\int_X |f| \, d\mu < \infty$. 上面几个定义在重合的地方是一致的. 我们之后还会经常只在某个可测集上积分, 所以对于 $A \in \mathcal{F}$ 约定

$$\int_A f \, d\mu := \int_X f 1_A \, d\mu.$$

特别地, $\int_A 1 \, d\mu = \mu(A)$. 因而测度也可以看成指示函数的积分.

定义 2.30 (可积向量值函数及其积分).

令 V 为有限维实向量空间, 赋予通常的 Borel σ -代数, $f: X \rightarrow V$ 可测. 选一组基 $v_1, \dots, v_n$, 写为 $f = \sum_{i=1}^n f_i v_i$. 若所有实值坐标 f_i 均可积, 称 f 可积, 并定义

$$\int_X f \, d\mu = \sum_{i=1}^n \left(\int_X f_i \, d\mu \right) v_i.$$

换基只对坐标作有限线性组合. 下文的积分线性性因而同时保证可积性与所得向量都不依赖选基. 复数是二维实向量, 复值积分也就等于分别积分实部和虚部.

一些例子 在有界矩形上, Riemann 可积函数对完整 Lebesgue 测度也可积, 且两种积分相等. 因而原来可以用 Riemann 积分计算的面积不会改变, Lebesgue 方法扩展的是能够处理的函数和极限.

广义 Riemann 积分则要另行判断. 它可以依赖正负抵消而收敛, 此时绝对值积分可能为无穷, 函数便不属于这里定义的 Lebesgue 可积类.

对 $X = \mathbb{N}$ 上的计数测度,

$$\int_X f \, d\mu = \sum_{n=1}^{\infty} f(n).$$

非负函数允许两边同为 $+\infty$; 实值函数可积则恰好要求级数绝对收敛. 所以求和与积分使用同一套定义, 原来关于非负级数或绝对收敛级数的交换问题, 也能放在后面的积分定理中处理.

基本性质与收敛定理 与前文相同, 下设 $(X, \mathcal{F}, \mu)$ 为测度空间.

命题 2.31 (单调性).

令 f, g 同为非负可测函数, 或同为实值可积函数. 若 $f \leq g$ a.e., 则

$$\int f \leq \int g.$$

特别地, $f = g$ a.e. 时积分相等.

证明. 先取非负情形, 令可测零测集 N 包含所有可能违反不等式的点. 对任意非负简单函数 $s \leq f$, 有 $s 1_{X \setminus N} \leq g$. 从每个简单函数取值集合中删去 N 不改变其测度, 所以 $\int s = \int s 1_{X \setminus N} \leq \int g$. 对 s 取上确界, 得到结论. 实值可积情形使用 $f_+ \leq g_+$ 和 $f_- \geq g_-$ a.e., 对两部应用非负情形后作有限数相减即可. 相等情形交换 f, g 再用一次单调性. $\square$

命题 2.32 (数乘).

若 f 非负可测且 $a \geq 0$, 或 f 实值可积且 $a \in \mathbb{R}$, 则

$$\int af = a \int f.$$

非负情形沿用 $0 \cdot \infty = 0$ 的约定.

证明. 对非负简单函数, 直接把系数乘以 a 即得等式. $a > 0$ 时, $s \leq af$ 与 $s/a \leq f$ 给出两边所用简单函数的一一对应, 对其积分取上确界就得到非负情形. $a = 0$ 时按约定两边均为零. 对实值可积函数分别使用正负部; $a < 0$ 时正负部互换, 再由积分定义相减. $\square$

积分的上确界定义并未预先选择某一系列逼近. 现在构造一系列适用于任意非负可测函数的简单函数: 先截断高度, 再在保留范围内向下取整. 截断保证取值有限, 逐步加细网格则控制误差.

引理 2.33 (简单函数逼近).

令 $f: X \rightarrow [0, \infty]$ 可测. 对正整数 n 定义

$$\varphi_n(x) = \begin{cases} 2^{-n} \lfloor 2^n f(x) \rfloor, & f(x) < n, \\ n, & f(x) \geq n. \end{cases}$$

则各 φ_n 都是非负简单函数, 且 $\varphi_1 \leq \varphi_2 \leq \dots \leq f$, 逐点有 $\varphi_n \rightarrow f$.

证明. 每个取值的原像由 f 的区间原像或 $\{f \geq n\}$ 给出, 所以可测, 取值数也有限. 在 $f(x) < n$ 时, 细化二进网格不会降低向下取整值; 在 $f(x) \geq n$ 时, 下一步的取值仍至少为 n . 因而 $\varphi_n \leq \varphi_{n+1} \leq f$. 若 $f(x) < \infty$, 则从 $n > f(x)$ 开始有 $0 \leq f(x) - \varphi_n(x) < 2^{-n}$. 若 $f(x) = \infty$, 则 $\varphi_n(x) = n \rightarrow \infty$. $\square$

这使章首按函数值分组的想法成为一系列明确的函数. 要证明其积分也收敛, 还要使用下面的单调收敛定理. 其证明先选一个固定简单函数作比较, 略微降低它的高度, 让 f_n 逐点最终超过这个较低高度.

定理 2.34 (单调收敛定理).

令 $f, f_1, f_2, \dots$ 为非负可测函数. 如果 $f_n \leq f_{n+1}$, 并且 $f_n \rightarrow f$ 逐点成立, 则有

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 由单调性, $(\int f_n)$ 单调递增且 $\int f_n \leq \int f$, 所以 $\lim_n \int f_n \leq \int f$.

反过来, 任取非负简单函数 $\phi \leq f$ 以及 $\alpha \in (0, 1)$, 令 $E_n = \{x \in X \mid f_n(x) \geq \alpha \phi(x)\}$. 则 E_n 递增且 $\bigcup_n E_n = X$, 因而

$$\int f_n \geq \int_{E_n} f_n \geq \alpha \int_{E_n} \phi.$$

对简单函数 ϕ 而言, $A \mapsto \int_A \phi d\mu$ 是一个测度, 所以由测度对于递增集合列的连续性有 $\int_{E_n} \phi \rightarrow \int \phi$. 因而 $\lim_n \int f_n \geq \alpha \int \phi$. 最后令 $\alpha \rightarrow 1^-$, 再对所有满足 $0 \leq \phi \leq f$ 的简单函数取上确界即可. $\square$

简单函数逼近引理与单调收敛定理合起来, 才说明前面的上确界可以沿一系列 $\varphi_n \uparrow f$ 取得极限. 这个过程不要求积分有限. 非负函数还可以逐项相加: 先证明有限加性, 再把部分和作为递增列, 就得到可列加性.

命题 2.35 (可列加性).

令 $f_1, f_2, \dots$ 为非负可测函数. 则有

$$\int_X \sum_{k=1}^{\infty} f_k d\mu = \sum_{k=1}^{\infty} \int_X f_k d\mu.$$

证明. 先考虑两个函数. 分别取递增简单函数序列 $\phi_n \uparrow f_1$ 和 $\psi_n \uparrow f_2$, 那么 $\phi_n + \psi_n \uparrow f_1 + f_2$. 由简单函数积分的加性以及单调收敛定理,

$$\int (f_1 + f_2) = \lim_n \int (\phi_n + \psi_n) = \int f_1 + \int f_2.$$

有限多个函数的情况由归纳得到. 最后令 $S_n = \sum_{k=1}^n f_k$, 则 $S_n \uparrow \sum_{k=1}^{\infty} f_k$, 再使用一次单调收敛定理即可. $\square$

实值可积函数的有限加性也由此得到. 先用 $|f + g| \leq |f| + |g|$ 确认和可积, 再把正负部的等式移成两边均为非负函数的有限和, 分别积分并相减. 连同数乘性质, 这给出了积分的线性性, 也完成了前面向量值积分不依赖选基的验证.

如果非负函数列不单调, 仍可以从每段尾部取下确界, 构造递增列. 这正是 Fatou 引理的证明办法.

引理 2.36 (Fatou 引理).

令 $f_1, f_2, \dots$ 为非负可测函数. 则有

$$\int \liminf_{n \rightarrow \infty} f_n \leq \liminf_{n \rightarrow \infty} \int f_n.$$

证明. 令 $g_k = \inf_{n \geq k} f_n$, 则 g_k 是非负可测函数, 并且 $g_k \uparrow \liminf_n f_n$. 由单调收敛定理,

$$\int \liminf_n f_n = \lim_{k \rightarrow \infty} \int g_k.$$

对任意 $j \geq k$ 有 $g_k \leq f_j$, 所以 $\int g_k \leq \inf_{j \geq k} \int f_j$. 令 $k \rightarrow \infty$ 即得结论. $\square$

Fatou 只给出一个方向, 极限函数的积分可以严格变小. 例如在 $(0, 1)$ 上, $f_n(x) = n1_{(0, 1/n)}(x)$ 逐点趋于零, 各自积分却都为 1. 质量集中到越来越窄的区间, 说明仅有逐点收敛还不足以交换积分. 下面用同一个可积函数限制全部 f_n .

定理 2.37 (控制收敛定理).

令 $f, f_1, f_2, \dots$ 为实值可测函数. 若 $f_n \rightarrow f$ a.e., 且存在可积函数 g 使所有 n 都有 $|f_n| \leq g$ a.e., 则 f 可积, 并且

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 将所有例外零测集合并, 在这一共同零测集上把函数改为零, 并可将控制函数取为非负. 可测性与积分不受影响, 以下不等式便可逐点使用. 取极限得到 $|f| \leq g$, 所以 f 与各 f_n 都可积.

对 $g + f_n$ 与 $g - f_n$ 分别使用 Fatou 引理和积分线性性, 得

$$\begin{aligned} \int g + \int f &\leq \int g + \liminf_{n \rightarrow \infty} \int f_n, \\ \int g - \int f &\leq \int g - \limsup_{n \rightarrow \infty} \int f_n. \end{aligned}$$

因为 $\int g < \infty$, 可以消去它, 得到

$$\int f \leq \liminf_n \int f_n \leq \limsup_n \int f_n \leq \int f.$$

两端相等, 故积分收敛. $\square$

证明中的可积控制保证减去 $\int g$ 是合法的有限数运算. 再将定理用于 $|f_n - f| \leq 2g$, 还得到 $\int |f_n - f| d\mu \rightarrow 0$. 复值或有限维向量值情形可以逐坐标使用实值结果.

乘积测度与 Fubini 定理 同时使用两个变量, 先要确定乘积空间中哪些集合可测. 矩形 $A \times B$ 表示第一个变量属于 A , 同时第二个变量属于 B , 因而作为最初的生成集合.

定义 2.38 (乘积可测空间).

$(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$ 的乘积可测空间为

$$(X \times Y, \mathcal{F} \otimes \mathcal{G}),$$

其中

$$\mathcal{F} \otimes \mathcal{G} = \sigma\{A \times B : A \in \mathcal{F}, B \in \mathcal{G}\}.$$

这是使两个投影 $\pi_X: X \times Y \rightarrow X$ 与 $\pi_Y: X \times Y \rightarrow Y$ 都可测的最小 σ -代数. 一个映射到乘积空间可测, 等价于两个坐标映射可测, 所以它确实给出 Meas 中的积.

给定两边测度以后, 还要另行规定联合的测度. 乘积测度选择矩形大小等于两边大小之积, 这一条件加上 σ -有限性确定唯一扩张.

定义 2.39 (乘积测度).

设 $(X, \mathcal{F}, \mu)$ 与 $(Y, \mathcal{G}, \nu)$ 都 σ -有限. 乘积测度 $\mu \otimes \nu$ 是 $\mathcal{F} \otimes \mathcal{G}$ 上唯一满足

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B)$$

的测度, 其中约定 $0 \cdot \infty = 0$.

可以先在矩形及其有限不交并上构造相应预测度, 再作 Carathéodory 扩张. 两边的有限测度覆盖给出乘积空间的有限测度矩形覆盖, 因而也保证这里的唯一性.

乘积可测空间的范畴性质, 并不直接规定其上的联合测度. 特别地, 当 μ, ν 是概率测度时, $\mu \otimes \nu$ 给出独立联合分布; 相同的两个边缘分布还可以有其他相依的联合分布.

对 Lebesgue 测度要同时说明定义域: 一维 Borel Lebesgue 测度的乘积, 等于 $\mathcal{B}(\mathbb{R}^2) = \mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R})$ 上的二维 Borel Lebesgue 测度. 若从完备的一维 λ_1 出发, $\lambda_1 \otimes \lambda_1$ 定义在 $\mathcal{L}(\mathbb{R}) \otimes \mathcal{L}(\mathbb{R})$ 上, 仍不完备; 再完备化以后, 才得到完整的 $(\mathbb{R}^2, \mathcal{L}(\mathbb{R}^2), \lambda_2)$.

下面的积分定理先在乘积 σ -代数上陈述. 它们分别说明, 非负性或绝对可积性怎样保证逐次积分与乘积积分一致.

定理 2.40 (Tonelli 定理).

设 $(X, \mathcal{F}, \mu)$ 和 $(Y, \mathcal{G}, \nu)$ 为 σ -有限测度空间, $f: X \times Y \rightarrow [0, \infty]$ 为 $\mathcal{F} \otimes \mathcal{G}$ -可测函数. 则各截面可测, 两个内层积分分别是外层变量的非负可测函数, 且

$$\begin{aligned} \int_{X \times Y} f \, d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) \, d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) \, d\mu(x) \right) d\nu(y). \end{aligned}$$

所有积分均允许为 $+\infty$.

证明. 截面映射 $y \mapsto (x, y)$ 和 $x \mapsto (x, y)$ 对乘积 σ -代数可测, 因而 f 的各截面可测. 先设两个测度都有限, 从矩形指示函数 $f = \mathbf{1}_{A \times B}$ 开始. 两次积分均等于 $\mu(A)\nu(B)$, 内层积分也显然可测.

将其指示函数满足结论的乘积可测集合收集起来, 得到一个 λ -系. 对补集, 用 $\nu(Y) - \nu(E_x)$ 和 $\mu(X) - \mu(E_y)$ 计算截面测度, 这里的有限性保证减法有定义. 对不交可列并, 截面测度按项相加, 再用单调收敛交换非负求和与外层积分. 这一 λ -系包含所有矩形, 所以 π - λ 定理将结论推广到任意乘积可测集合.

非负有限线性组合给出简单函数情形. 对一般非负 f , 取简单函数 $f_n \uparrow f$, 先在各截面使用单调收敛, 得到内层积分的可测性及递增极限, 再在两个外层空间和乘积空间分别使用单调收敛, 即得等式.

对 σ -有限空间, 取 $X_n \uparrow X, Y_n \uparrow Y$, 且 $\mu(X_n), \nu(Y_n) < \infty$. 先在有限测度矩形 $X_n \times Y_n$ 上应用已证结论, 将截面积分在相应集合外延为零. 再令 $n \rightarrow \infty$, 对所有非负积分使用单调收敛, 得到全空间结论. $\square$

非负性使整个证明只使用递增极限, 即使结果无穷也无须相减. 实值函数则需要排除正负两部同时积成无穷, 最常用的保证是绝对可积.

定理 2.41 (Fubini 定理).

设 $(X, \mathcal{F}, \mu)$ 和 $(Y, \mathcal{G}, \nu)$ 为 σ -有限测度空间, $f: X \times Y \rightarrow \mathbb{R}$ 为 $\mathcal{F} \otimes \mathcal{G}$ -可测函数, 且

$$\int_{X \times Y} |f| d(\mu \otimes \nu) < \infty.$$

则对 μ -a.e. x , 截面 $y \mapsto f(x, y)$ 可积; 对 ν -a.e. y , 截面 $x \mapsto f(x, y)$ 可积. 将截面不可积的相应例外零测集上的内层积分统一取为零, 得到可测的可积版本, 并有

$$\begin{aligned} \int_{X \times Y} f d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) d\mu(x) \right) d\nu(y). \end{aligned}$$

证明. 对 $|f|$ 应用 Tonelli. 其乘积积分有限, 所以 $x \mapsto \int_Y |f(x, y)| d\nu(y)$ 几乎处处有限, 另一方向同理. 这给出几乎每个截面的绝对可积性. 将例外集上的内层积分取零后, 有

$$\left| \int_Y f(x, y) d\nu(y) \right| \leq \int_Y |f(x, y)| d\nu(y)$$

几乎处处成立, 所以内层积分关于外层变量可积. 最后分别对 f_+ 与 f_- 使用 Tonelli, 再相减. 两部的乘积积分都有限, 因而相减合法, 得到两种积分次序的等式. 相关证明参见 [Kal21, Theorem 1.29] 或 [Dur19, Theorem 1.7.2]. $\square$

使用时, 非负函数可以直接用 Tonelli 计算, 结果可以无穷. 有正负值时, 先对 $|f|$ 使用 Tonelli 检查是否有限, 再用 Fubini 交换次序. 几乎处处的截面结论不能改成每个截面都可积, 但例外零测集不会改变外层积分.

前推测度与积分 若只观察 $F(x)$ 的取值, 可以把原空间的测度记录到取值空间中. 目标集合的大小, 就按原空间中被映入它的那部分计算.

定义 2.42 (前推测度).

设 $(X, \mathcal{F}, \mu)$ 为测度空间, $(Y, \mathcal{G})$ 为可测空间, $F: X \rightarrow Y$ 可测. 定义**前推测度**

$$(F_*\mu)(A) = \mu(F^{-1}(A)), \quad A \in \mathcal{G}.$$

可测性保证右边有定义. 不交集合的原像仍不交, 原像又保持可列并, 所以 $F_*\mu$ 确实可列可加. 这里不要求 F 单射或满射, 也不需要它可微.

命题 2.43 (前推测度下的积分).

设 $F: (X, \mathcal{F}, \mu) \rightarrow (Y, \mathcal{G})$ 可测, $\nu = F_*\mu$. 若 g 在 Y 上非负可测或关于 ν 可积, 则

$$\int_X (g \circ F) d\mu = \int_Y g d\nu.$$

可积情形中, $g \circ F$ 也关于 μ 可积.

证明. 先取 $g = 1_A$, 则 $g \circ F = 1_{F^{-1}(A)}$, 等式就是前推测度的定义. 非负有限线性组合给出简单函数情形. 再取简单函数 $g_n \uparrow g$, 在两边使用单调收敛, 得到任意非负可测函数的结论. 对实值可积 g , 先将非负结论用于 $|g|$, 确认 $g \circ F$ 可积, 再对正负部分分别应用并相减. 有限维向量值情形逐坐标处理. $\square$

随机变量 $\xi: \Omega \rightarrow \mathbb{R}$ 的分布正是

$$\mathbb{P}_\xi = \xi_* \mathbb{P}.$$

所以对非负 Borel 函数 g , 或关于 $\mathbb{P}_\xi$ 可积的 g , 有

$$\mathbb{E}[g(\xi)] = \int_{\Omega} g(\xi) d\mathbb{P} = \int_{\mathbb{R}} g(x) d\mathbb{P}_\xi(x).$$

左边在样本空间上计算, 右边只使用取值及其分布, 两者得到同一个数. 这说明为什么知道分布就足以计算这类期望. 但若比较两个随机变量的相依关系或研究一个过程的历史信息, 各自单独的分布仍不够, 还须保留联合分布和相应滤过.

2.2 符号测度, Hahn 分解与 Radon–Nikodym 导数

2.2.1 符号测度与 Radon–Nikodym 定理

两个有限测度的差仍然可列可加, 但可以在不同集合上取不同符号. 对可积函数 h , 赋值 $A \mapsto \int_A h d\mu$ 也有同样性质. 若要研究这些正负贡献, 就需要将测度的取值范围扩大, 同时保证加减仍有意义.

定义 2.44.

在可测空间 $(X, \mathcal{F})$ 上, 函数

$$\nu: \mathcal{F} \rightarrow [-\infty, \infty]$$

称为**符号测度**, 若满足:

1. $\nu(\emptyset) = 0$;
2. 对任意两两不交的 $A_1, A_2, \dots \in \mathcal{F}$,

$$\nu\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \nu(A_n);$$

3. 在全部可测集上, ν 至多取 $+\infty$ 与 $-\infty$ 中的一种, 不允许两种无限值同时出现.

可列可加性要求右边是有定义的和, 对不交集重新编号也须给出相同结果. 限制无限值正是为了避免把正负两项无穷贡献相消. 因而不能对两个任意无限测度逐集作差, 就直接得到符号测度.

一个集合的总值为正, 里面仍可能有负贡献, 所以只检查 $\nu(P) \geq 0$ 不足以把 P 称为正的部分. 真正需要的是: P 内每个可测子集都取非负值. 负的部分也作同样要求. Hahn 分解将证明, 整个空间确实能够这样分开.

定义 2.45.

令 ν 为 $(X, \mathcal{F})$ 上的符号测度.

- 称可测集 $P \in \mathcal{F}$ 为 ν 的**正集**, 是指对于任意可测集 $A \subseteq P$, 都有 $\nu(A) \geq 0$.
- 称可测集 $N \in \mathcal{F}$ 为 ν 的**负集**, 是指对于任意可测集 $A \subseteq N$, 都有 $\nu(A) \leq 0$.

定理 2.46 (Hahn 分解定理).

设 ν 为 $(X, \mathcal{F})$ 上的符号测度. 则存在互不相交的可测集 P, N , 满足

$$X = P \sqcup N,$$

其中 P 是正集, N 是负集.

证明. 先假设 ν 不取 $-\infty$, 但允许取 $+\infty$. 若原测度取过 $-\infty$, 定义保证它不取 $+\infty$, 可以对 $-\nu$ 使用以下证明, 最后交换正负集.

先证明: 每个满足 $\nu(A) < 0$ 的可测集, 都包含一个测度仍严格为负的负集. 此时 $\nu(A)$ 有限, 而 A 的每个可测子集也取有限值; 否则某个子集取 $+\infty$, 它与补足部分相加就不可能得到有限的 $\nu(A)$.

从 $A_0 = A$ 开始, 令

$$s_n = \sup\{\nu(E) : E \in \mathcal{F}, E \subseteq A_{n-1}\}.$$

空集保证 $s_n \geq 0$. 若 $s_n = 0$, 剩余的 A_{n-1} 已是负集, 构造结束. 否则选择 $E_n \subseteq A_{n-1}$, 使 $\nu(E_n) > \min\{1, s_n/2\}$, 并令 $A_n = A_{n-1} \setminus E_n$. 这里允许 $s_n = +\infty$, 此时只需选取测度大于1的子集.

若构造一直继续, 所有 E_n 两两不交且具有正的有限测度. 它们的并仍在 A 内, 测度有限, 所以 $\sum_n \nu(E_n) = \nu(\bigcup_n E_n) < \infty$, 特别有 $\nu(E_n) \rightarrow 0$. 令 $N_A = A \setminus \bigcup_n E_n$. 若其中仍有可测子集 B 满足 $\nu(B) > 0$, 则每个 $s_n \geq \nu(B)$, 所选 $\nu(E_n)$ 就有同一个严格正的下界, 与趋于零矛盾. 因而 N_A 是负集, 并且

$$\nu(N_A) = \nu(A) - \sum_n \nu(E_n) \leq \nu(A) < 0.$$

有限步结束时同一减法也成立, 所以引理得证.

接着把尽可能多的负贡献收在一起. 负集的可列并仍是负集: 对并集内的任意可测子集, 依次按它第一次落入哪个负集分成不交部分, 各部分测度非正, 可列可加后仍非正. 定义

$$\beta = \inf\{\nu(N) : N \text{ 是可测负集}\}.$$

空集给出 $\beta \leq 0$. 而 β 不可能等于 $-\infty$: 否则可取负集 N_n 满足 $\nu(N_n) < -n$, 它们的并 N 仍为负集, 且 $\nu(N) \leq \nu(N_n) < -n$ 对每个 n 成立, 迫使 $\nu(N) = -\infty$, 与当前选定的符号矛盾.

因而 β 有限. 取负集 N_n 使 $\nu(N_n) \rightarrow \beta$, 再令 $N = \bigcup_n N_n$. 因为 $N \setminus N_n$ 也是负集, 有 $\beta \leq \nu(N) \leq \nu(N_n)$, 所以 $\nu(N) = \beta$. 若 $P = X \setminus N$ 不是正集, 就存在 $A \subseteq P$ 满足 $\nu(A) < 0$. 由引理可在 A 内取得负集 N_A 且 $\nu(N_A) < 0$. 于是 $N \sqcup N_A$ 是负集, 但

$$\nu(N \sqcup N_A) = \beta + \nu(N_A) < \beta,$$

与下确界矛盾. 这里相加的两个数均有限, 所以严格不等式有意义. 因此 P 为正集, 得到所需分解. 相关论证参见 [Kal21, Theorem 2.8] 或 [Dur19, Theorem A.4.5]. $\square$

Hahn 分解划分的是空间. 正集和负集都可以含有零贡献, 所以这项划分未必唯一. 但分别记录两边的贡献, 可以得到唯一的两个非负测度. 以下说测度集中在某集合上, 是指它在该集合的补集上为零.

定理 2.47 (Jordan 分解定理).

设 ν 为 $(X, \mathcal{F})$ 上的符号测度. 则存在唯一的两个非负测度 ν^+, ν^- , 满足

$$\nu = \nu^+ - \nu^-,$$

并分别集中在某个 Hahn 分解 $X = P \sqcup N$ 的 P 与 N 上. 二者至少有一个是有限测度, 因而这个差在每个可测集上都有定义. ν^+ 与 ν^- 分别称为正变差和负变差.

证明. 给定 Hahn 分解 $X = P \sqcup N$, 定义

$$\nu^+(A) = \nu(A \cap P), \quad \nu^-(A) = -\nu(A \cap N).$$

正集与负集的定义保证二者非负; 符号测度的可列可加性保证它们都是测度. 对每个 $A \in \mathcal{F}$,

$$\nu(A) = \nu(A \cap P) + \nu(A \cap N) = \nu^+(A) - \nu^-(A).$$

且 ν^+ 与 ν^- 分别集中在互不相交的 P 与 N 上. 若两者的总质量都为无穷, 就有 $\nu(P) = +\infty$ 和 $\nu(N) = -\infty$, 与符号测度的定义矛盾, 所以至少一项总质量有限.

若还有 $\nu = \alpha - \beta$ 且 $\alpha \perp \beta$, 取互不相交的集中集 C, D , 使 α 集中在 C 上, β 集中在 D 上. 令

$$R = X \setminus (C \cup D), \quad C' = C \cup R.$$

由于 $\alpha(R) = \beta(R) = 0$, 把 R 并入 C 不改变集中性. 对任意可测集 $E \subseteq C'$ 有 $\beta(E) = 0$, 因而 $\nu(E) = \alpha(E) \geq 0$; 对任意可测集 $E \subseteq D$ 有 $\alpha(E) = 0$, 因而 $\nu(E) = -\beta(E) \leq 0$. 所以 $X = C' \sqcup D$ 也是一个 Hahn 分解.

将它与定义 ν^+, ν^- 时使用的 Hahn 分解 $X = P \sqcup N$ 比较. 交集 $P \cap D$ 同时是正集与负集, 故它的每个可测子集都有 ν -测度 0; $N \cap C'$ 也具有同一性质. 因此对任意 $A \in \mathcal{F}$,

$$\begin{aligned}\alpha(A) &= \alpha(A \cap C') = \nu(A \cap C') = \nu(A \cap C' \cap P) = \nu(A \cap P) = \nu^+(A), \\ \beta(A) &= \beta(A \cap D) = -\nu(A \cap D) = -\nu(A \cap D \cap N) = -\nu(A \cap N) = \nu^-(A).\end{aligned}$$

于是 $\alpha = \nu^+$ 且 $\beta = \nu^-$, 分解唯一. □

唯一性证明比较了两个分割的交叉部分. 同时属于一个正集与另一个负集的地方, 每个可测子集的测度都为零, 移动这些部分不会改变正负变差. 这也解释了为什么分割可以不同, 两个变差测度却仍唯一.

定义 2.48.

符号测度 ν 的全变差测度为

$$|\nu| = \nu^+ + \nu^-.$$

$\nu(A)$ 将正负贡献相消, $|\nu|(A)$ 则把两边的大小相加, 因而 $|\nu(A)| \leq |\nu|(A)$. 后者可以衡量实际存在多少正负变化, 而不让相消掩盖它们.

例如, 在 $[0, 1]$ 上令 $\nu(A) = \int_A (2x - 1) dx$. 可以取 $N = [0, 1/2)$, $P = [1/2, 1]$, 得到

$$\nu^+([0, 1]) = \frac{1}{4}, \quad \nu^-([0, 1]) = \frac{1}{4}, \quad \nu([0, 1]) = 0, \quad |\nu|([0, 1]) = \frac{1}{2}.$$

整个区间的符号测度为零, 却不表示其中每个子集都没有贡献. 这一点与非负测度的零测集不同.

奇异与绝对连续 Jordan 分解将两个非负测度放在互不相交的部分. 现在一般地比较 $(X, \mathcal{F})$ 上的两个非负测度, 看它们是否集中于不同地方, 或能否通过密度相互表示.

定义 2.49.

测度 μ 集中在可测集 A 上, 是指

$$\mu(X \setminus A) = 0.$$

这只要求补集测度为零, 不要求 A 有拓扑意义上的闭性, 也不要求 A 中每个非空子集都有正测度.

定义 2.50.

设 μ, ν 为同一可测空间上的测度.

- 若存在互不相交的可测集, 分别集中 μ 和 ν 的全部质量, 则称二者**互相奇异**, 记为 $\mu \perp \nu$.
- 若每个 μ -零测集也是 ν -零测集, 即 $\mu(A) = 0$ 蕴含 $\nu(A) = 0$, 则称 ν 关于 μ **绝对连续**, 记为 $\nu \ll \mu$.

互相奇异是对称关系. 绝对连续有方向: 它要求 ν 不在 μ -零测集上分配质量, 没有要求 μ 对 ν 也满足同样条件. 等价地, $\nu \perp \mu$ 可以表述为: ν 集中在某个 μ -零测集上.

Jordan 分解中的两项正满足

$$\nu^+ \perp \nu^-.$$

在 $\mathbb{R}$ 的共同可测空间上, δ_0 与 Lebesgue 测度 λ 也是互相奇异的: 前者集中于 $\{0\}$, 后者在该点为零, 可以集中于其补集.

密度给出另一种关系. 取非负可测函数 f , 定义

$$\nu(A) = \int_A f d\mu.$$

非负积分的可列加性保证这确实是测度. 若 $\mu(A) = 0$, 积分也为零, 所以 $\nu \ll \mu$. 密度较大的区域相对于 μ 取得更多质量, 密度为零的区域则不取得质量.

反过来, 只知道 $\nu \ll \mu$, 在什么条件下就能找到这样的 f ? Radon–Nikodym 定理给出答案. 证明将先找一个在每个集合上都不超过 ν 的密度, 再说明任何尚未表示的剩余质量都能用来把密度提高.

Radon–Nikodym 定理

定理 2.51 (Radon–Nikodym 定理).

设 μ, ν 为 $(X, \mathcal{F})$ 上的 σ -有限测度, 且 $\nu \ll \mu$. 则存在非负可测函数 $f: X \rightarrow [0, \infty]$, 使每个 $A \in \mathcal{F}$ 满足

$$\nu(A) = \int_A f \, d\mu.$$

这样的 f 在 μ -a.e. 意义下唯一.

证明. 先设两测度都有限. 对非负可测 f 记

$$(f \cdot \mu)(A) := \int_A f \, d\mu,$$

并考虑所有不会在任何可测集上超过 ν 的密度:

$$\mathcal{H} = \{f \geq 0 : f \text{ 可测且 } f \cdot \mu \leq \nu\}.$$

这里的不等式逐个可测集成立, 不只比较全空间的总质量. 零函数属于 $\mathcal{H}$, 且所有候选都满足 $\int_X f \, d\mu \leq \nu(X)$, 所以

$$\alpha = \sup_{f \in \mathcal{H}} \int_X f \, d\mu < \infty.$$

选择 $f_n \in \mathcal{H}$ 使其积分趋于 α . 两个候选函数的最大值仍是候选: 在 $\{f \geq g\}$ 使用 f 的上界, 在补集使用 g 的上界, 再对这两个不交部分相加即可. 因而可以将原序列换为

$$g_n = \max\{f_1, \dots, f_n\} \uparrow g.$$

对全空间和任意可测集分别使用单调收敛, 得到

$$\int_X g \, d\mu = \alpha, \quad \int_A g \, d\mu = \lim_n \int_A g_n \, d\mu \leq \nu(A).$$

所以 g 本身也是候选, 并取得了最大总质量.

剩余部分

$$\lambda = \nu - g \cdot \mu$$

是非负有限测度, 且 $0 \leq \lambda \leq \nu$ 保证 $\lambda \ll \mu$. 这里两项均为有限测度, 差没有无限值相减的问题. 若 $\lambda(X) > 0$, 则 $\mu(X) > 0$, 可以取足够小的 $\varepsilon > 0$, 使

$$\rho := \lambda - \varepsilon\mu, \quad \rho(X) > 0.$$

对有限符号测度 ρ 作 Hahn 分解. 负集的贡献非正, 因而正集 P 必满足 $\rho(P) > 0$. 绝对连续性又给出 $\mu(P) > 0$, 否则 $\lambda(P) = 0$ 也会使 $\rho(P) = 0$. 正集的定义保证每个可测 $E \subseteq P$ 都有 $\lambda(E) \geq \varepsilon\mu(E)$.

因而对任意 $A \in \mathcal{F}$,

$$\begin{aligned} \int_A (g + \varepsilon 1_P) \, d\mu &= \int_A g \, d\mu + \varepsilon\mu(A \cap P) \\ &\leq \int_A g \, d\mu + \lambda(A \cap P) \\ &\leq \int_A g \, d\mu + \lambda(A) = \nu(A). \end{aligned}$$

新函数仍在 $\mathcal{H}$ 中, 总积分却为

$$\alpha + \varepsilon\mu(P) > \alpha,$$

与最大性矛盾. 所以 $\lambda = 0$, 即 $\nu = g \cdot \mu$.

再证明有限情形的唯一性. 若 $f \cdot \mu = g \cdot \mu = \nu$, 则两函数的总积分均为有限的 $\nu(X)$. 因而 $\{f = \infty\} \cup \{g = \infty\}$ 是可测的 μ -零测集. 将两函数在这个共同零测集上都改为零, 不改变其积分表示, 以下便可使用处处有限的版本. 令 $E_n = \{f \geq g + 1/n\}$, 则

$$\int_{E_n} f d\mu \geq \int_{E_n} g d\mu + \frac{1}{n}\mu(E_n).$$

两个积分都等于有限的 $\nu(E_n)$, 故 $\mu(E_n) = 0$. 此时确有 $E_n \uparrow \{f > g\}$, 所以 $\mu(\{f > g\}) = 0$. 交换 f, g 得另一方向, 从而原来的两密度也 μ -a.e. 相等.

最后设两测度只 σ -有限. 分别取有限测度覆盖, 将其前 n 项的并相交, 得到共同递增覆盖 $C_n \uparrow X$, 且 $\mu(C_n), \nu(C_n) < \infty$. 令 $C_0 = \emptyset, D_n = C_n \setminus C_{n-1}$. 在每个不交块 D_n 上应用有限情形, 得到密度 f_n , 再令 f 在 D_n 上等于 f_n . 可测性和非负积分的可列加性给出

$$\int_A f d\mu = \sum_n \int_{A \cap D_n} f_n d\mu = \sum_n \nu(A \cap D_n) = \nu(A).$$

任意两个密度在每块上由有限情形几乎处处相等, 可列个例外零测集的并仍为零测集, 因而全局也唯一到 μ -a.e. $\square$

将定理中的密度记为

$$f = \frac{d\nu}{d\mu},$$

称为 **Radon-Nikodym 导数**. 这个记号由积分关系定义:

$$\nu(A) = \int_A \frac{d\nu}{d\mu} d\mu.$$

它可以用在没有距离和微分运算的可测空间上, 不要求先通过缩小邻域求一个普通导数极限. 在本定理的 σ -有限假设下, 密度在每个共同有限测度块上都可积, 因而还可以选成 μ -a.e. 有限的版本.

密度一旦确定, 对非负可测函数 h 也有 $\int h d\nu = \int h f d\mu$. 先对指示函数使用定义, 再经简单函数和单调收敛即可证明; 可积的实值情形再按正负部处理. 所以密度不只重写集合的测度, 也直接转换积分.

例如, 在 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上, 用 λ 表示 Lebesgue 测度的 Borel 限制. 若随机变量 ξ 的分布 $\mathbb{P}_\xi \ll \lambda$, 则

$$p_\xi = \frac{d\mathbb{P}_\xi}{d\lambda}$$

就是概率密度, 对任意 Borel 集 A 满足

$$\mathbb{P}(\xi \in A) = \mathbb{P}_\xi(A) = \int_A p_\xi(x) dx.$$

密度非负且全空间积分为一, 单个点上的取值仍只确定到零测集上的修改. 并非每个分布都对 Lebesgue 测度绝对连续, 下一定理将说明不具备密度的部分怎样保留下来.

Lebesgue 分解 给定参考测度 μ , 另一个测度 ν 可能既有可用密度表示的部分, 又把质量放在某个 μ -零测集上. Lebesgue 分解将这两项分开. 证明先用 $\rho = \mu + \nu$ 同时支配两者, 使它们都具有相对于同一测度的密度, 再检查其中代表 μ 的密度在哪里为零.

定理 2.52 (Lebesgue 分解定理).

设 μ, ν 为 $(X, \mathcal{F})$ 上的 σ -有限测度. 则存在唯一的两个测度 ν_{ac}, ν_s , 使

$$\nu = \nu_{ac} + \nu_s, \quad \nu_{ac} \ll \mu, \quad \nu_s \perp \mu.$$

证明. 取共同的有限测度覆盖, 可见 $\rho = \mu + \nu$ 仍 σ -有限. 又有 $\mu \ll \rho$ 和 $\nu \ll \rho$, 所以 Radon-Nikodym 定理给出

$$\mu = f \cdot \rho, \quad \nu = g \cdot \rho.$$

因为 $f + g$ 与常数一都表示 ρ 关于自身的密度, 唯一性给出 $f + g = 1$ ρ -a.e. 可在共同零测集上调整, 使 f, g 处处非负且和为一.

令 $A = \{f > 0\}$, 定义

$$\nu_{ac}(E) = \nu(E \cap A), \quad \nu_s(E) = \nu(E \cap A^c).$$

两者都是 ν 的限制, 相加得到 ν . 若 $\mu(E) = 0$, 则 $\int_E f d\rho = 0$, 非负性使 $f = 0$ 在 E 上 ρ -a.e. 成立. 因而 $\rho(E \cap A) = 0$, 再由 $\nu \ll \rho$ 得到 $\nu_{ac}(E) = 0$. 这证明 $\nu_{ac} \ll \mu$. 另一方面,

$$\mu(A^c) = \int_{A^c} f d\rho = 0,$$

而 ν_s 集中于 A^c , 所以 $\nu_s \perp \mu$.

对唯一性, 假设另有 $\nu = \alpha + \sigma$, 其中 $\alpha \ll \mu$, $\sigma \perp \mu$. 取可测的 μ -零测集 N, M , 分别集中 ν_s 与 σ , 并令 $H = N \cup M$. 两个绝对连续部分在 H 上都为零, 两个奇异部分在 H^c 上都为零. 因而对任意 $E \in \mathcal{F}$,

$$\nu_{ac}(E) = \nu(E \cap H^c) = \alpha(E),$$

$$\nu_s(E) = \nu(E \cap H) = \sigma(E).$$

这是直接比较在 H 内外的限制, 即使某些值无穷也成立, 不需要由 $\nu - \nu_{ac}$ 作减法恢复奇异部分. $\square$

由于 $\nu_{ac} \leq \nu$, 它仍 σ -有限, 可以再次应用 Radon-Nikodym 定理, 写成

$$\nu_{ac}(E) = \int_E \frac{d\nu_{ac}}{d\mu} d\mu.$$

另一项则集中在 μ -零测集上, 无法由关于 μ 的非负密度产生, 除非它本来就是零测度.

对概率分布, 可以相对于 Lebesgue 测度作同样分解. 离散原子质量属于奇异部分, 但奇异部分不必离散, 还可以有奇异连续分布. 所以没有原子与具有 Lebesgue 密度, 也不是同一个条件.

2.2.2 L^p 空间

积分还可以用来衡量函数误差. 差值在大部分地方很小, 但在小集合上很大时, 不同问题可能要求不同的控制方式. 对有限 $p \geq 1$, 考虑

$$\left(\int_X |f|^p d\mu \right)^{1/p}.$$

先取绝对值避免正负相消, 再取 p 次方提高大幅取值的相对贡献, 最后开根使数乘满足一次齐次性. 对有限集合的计数测度, 这就是熟悉的向量范数

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

除了能量化误差, 我们还希望 Cauchy 逼近确实有极限. 对 $1 \leq p < \infty$, 有界区间上的 Riemann 可积函数类在这种误差下并不一般完备. 例如在 $[0, 1]$ 上令 $f(x) = x^{-1/(2p)}$ 对 $x > 0$ 成立, 并取 $f(0) = 0$. 每个截断 $\min\{n, f\}$ 都 Riemann 可积, 又因为 $|f|^p = x^{-1/2}$ 在 $(0, 1]$ 上可积, 截断在 L^p 中趋于 f . 极限本质无界, 没有与之几乎处处相等的有界 Riemann 可积代表元.

使用 Lebesgue 可测函数并按几乎处处相等取商以后, $1 \leq p \leq \infty$ 的 L^p 都将成为 Banach 空间. 因而证明近似构成 Cauchy 列, 就能得到仍属于同一空间的极限. $p = \infty$ 使用本质一致的误差, 与上述有限 p 的积分误差分别处理.

在概率空间中, 有限 p 的这项大小就是绝对矩:

$$\|X\|_p^p = \mathbb{E}[|X|^p], \quad 1 \leq p < \infty.$$

$p = \infty$ 则要求几乎必然有一个有限常数界. L^2 还具有内积, 可以把平方误差, 正交和投影放在一起研究, 后面的条件期望会使用这一点.

以下固定测度空间 $(X, \mathcal{F}, \mu)$, 取标量域 $\mathbb{K} = \mathbb{R}$ 或 $\mathbb{C}$.

L^p 范数与 L^p 空间**定义 2.53** (L^p 范数).

对可测函数 $f: X \rightarrow \mathbb{K}$, 定义

$$\|f\|_p = \left(\int_X |f|^p d\mu \right)^{1/p}, \quad 1 \leq p < \infty.$$

在端点 $p = \infty$, 定义

$$\|f\|_\infty = \operatorname{ess\,sup}_{x \in X} |f(x)| = \inf\{a \geq 0 : |f| \leq a \text{ a.e.}\}.$$

没有有限本质上界时, 后一个下确界取为 $+\infty$.

若 $\|f\|_\infty < \infty$, 可以选择一列可用上界趋于该下确界. 将相应例外零测集合并以后, 得到 $|f| \leq \|f\|_\infty$ a.e. 因而本质上确界本身也能作为几乎处处的界.

这些量对一般函数可以无穷. 限制到上述量有限的函数后, 数乘齐次性直接成立, 三角不等式将在下面证明; 正定性却只成立到几乎处处: $\|f\|_p = 0$ 等价于 $f = 0$ a.e. 要得到真正的范数, 就按这个等价关系取商.

定义 2.54 (L^p 空间).

对 $1 \leq p \leq \infty$, $L^p(X, \mu; \mathbb{K})$ 是满足 $\|f\|_p < \infty$ 的可测函数, 关于 μ -a.e. 相等所形成的等价类空间. 无歧义时记为 $L^p(X)$ 或 L^p .

实际计算通常仍写一个代表函数. 换成与它几乎处处相等的可测版本, 不改变范数或所属等价类. 在尚未取商的函数类上, 同样的表达只构成半范数.

对概率测度,

$$X \in L^p(\Omega, \mathbb{P}) \iff \mathbb{E}[|X|^p] < \infty, \quad 1 \leq p < \infty.$$

L^1 要求绝对可积, L^2 要求有限二阶绝对矩, L^∞ 则要求本质有界. 后面将分别用它们控制期望, 平方误差和本质一致误差.

正整数上采用计数测度时, 就得到序列空间

$$\ell^p = \left\{ (x_n)_{n \geq 1} : \sum_{n=1}^{\infty} |x_n|^p < \infty \right\}, \quad \|x\|_p = \left(\sum_{n=1}^{\infty} |x_n|^p \right)^{1/p}, \quad 1 \leq p < \infty.$$

计数测度没有非空零测集, 所以这里的几乎处处相等就是每项相等. 同理,

$$\ell^\infty = \left\{ (x_n)_{n \geq 1} : \sup_{n \geq 1} |x_n| < \infty \right\}, \quad \|x\|_\infty = \sup_{n \geq 1} |x_n|.$$

连续空间上的积分与离散空间上的求和, 因而都可以使用同一组 L^p 不等式和完备性结果.

 L^p 收敛**定义 2.55.**

对 $f, f_1, f_2, \dots \in L^p(X)$, 若 $\|f_n - f\|_p \rightarrow 0$, 称 f_n 在 L^p 意义下收敛到 f , 记为

$$f_n \xrightarrow{L^p} f.$$

在概率空间中, 有限 p 的条件就是

$$X_n \xrightarrow{L^p} X \iff \mathbb{E}[|X_n - X|^p] \rightarrow 0.$$

它控制整项误差的绝对矩, 并不要求原序列在每个样本点收敛, 也不一般保证整列几乎处处收敛. L^1 常称平均收敛, L^2 称均方收敛.

L^∞ 收敛则更直接控制最坏的本质误差. 对一系列代表函数, 将每个 $|f_n - f| \leq \|f_n - f\|_\infty$ 的例外集合并, 可以在同一个零测集之外得到一致收敛. 这里使用的是可列个例外集的并, 不是为每个点随意忽略不同的误差.

几乎处处, 依概率和依分布收敛将在概率论部分分别讨论. 比较它们与 L^p 收敛时, 要看控制的是单条实现, 超过误差阈值的概率, 还是误差的积分.

基本不等式 Hölder 不等式控制乘积的积分, Minkowski 不等式控制和的范数. 前者把两个不同阶的可积性联系起来, 后者将成为 L^p 的三角不等式.

定义 2.56.

若 $1 \leq p, q \leq \infty$ 满足

$$\frac{1}{p} + \frac{1}{q} = 1,$$

则称为一对共轭指数, 约定 $1/\infty = 0$.

定理 2.57 (Hölder 不等式).

若 p, q 共轭, $f \in L^p(X)$, $g \in L^q(X)$, 则 $fg \in L^1(X)$, 且

$$\|fg\|_1 \leq \|f\|_p \|g\|_q.$$

证明. 先设 $1 < p, q < \infty$. 任一范数为零时, 相应函数几乎处处为零, 结论成立. 否则分别除以各自范数, 将问题化为两个单位范数函数. 对非负实数使用 Young 不等式

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q},$$

得到

$$\frac{|fg|}{\|f\|_p \|g\|_q} \leq \frac{1}{p} \frac{|f|^p}{\|f\|_p^p} + \frac{1}{q} \frac{|g|^q}{\|g\|_q^q}.$$

右边积分为 $1/p + 1/q = 1$, 同时证明乘积可积和所需上界.

若 $p = 1, q = \infty$, 则 $|fg| \leq \|g\|_\infty |f|$ a.e., 积分即得结论. 若 $p = \infty, q = 1$, 交换两者的作用, 使用 $|fg| \leq \|f\|_\infty |g|$ a.e. 后积分. $\square$

在概率空间中, 它给出

$$\mathbb{E}[|XY|] \leq \|X\|_p \|Y\|_q.$$

要计算随机变量乘积的期望, 可以先用这个不等式确认绝对可积, 再进行其他等式运算. 取 $p = q = 2$, 并使用积分绝对值不超过绝对值积分, 就得到 Cauchy-Schwarz 不等式:

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2]} \sqrt{\mathbb{E}[Y^2]}.$$

定理 2.58 (Minkowski 不等式).

设 $1 \leq p \leq \infty$, $f, g \in L^p(X)$. 则 $f + g \in L^p(X)$, 且

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p.$$

证明. $p = 1$ 时对 $|f + g| \leq |f| + |g|$ 积分. $p = \infty$ 时, 在共同例外零测集之外有 $|f + g| \leq \|f\|_\infty + \|g\|_\infty$, 所以也成立.

设 $1 < p < \infty$, $q = p/(p - 1)$. 先由凸性得到 $|f + g|^p \leq 2^{p-1}(|f|^p + |g|^p)$, 确认 $f + g \in L^p$, 避免在尚未知有限性时消去无穷值. 若 $\|f + g\|_p = 0$, 所需不等式已成立, 以下设它严格为正.

将一个因子分开, 再对两项使用 Hölder:

$$\begin{aligned}\|f + g\|_p^p &= \int_X |f + g|^p d\mu \\ &\leq \int_X (|f| + |g|)|f + g|^{p-1} d\mu \\ &\leq (\|f\|_p + \|g\|_p) \| |f + g|^{p-1} \|_q \\ &= (\|f\|_p + \|g\|_p) \|f + g\|_p^{p-1}.\end{aligned}$$

最后一项使用 $(p-1)q = p$. 此时 $\|f + g\|_p^{p-1}$ 有限且非零, 除去它便得到结论. $\square$

连同数乘齐次性和取商后的正定性, Minkowski 证明了 L^p 确实是赋范向量空间. 将总误差拆成几项时, 它允许用各项范数之和控制总范数; 这一用途同时包括有限 p 与本质上确界端点.

完备性 Cauchy 列只说明各项彼此越来越接近, 没有预先给出极限函数. 证明完备性时, 可以先处理范数可求和的级数: 各项绝对值之和同时控制逐点收敛与积分, 再从一般 Cauchy 列抽取快速接近的子列归结到这种级数.

定理 2.59 (Riesz-Fisher 定理).

对任意测度空间 $(X, \mathcal{F}, \mu)$ 及 $1 \leq p \leq \infty$, $L^p(X, \mu)$ 关于 $\|\cdot\|_p$ 是 Banach 空间.

证明. 先设 $1 \leq p < \infty$, 并取一列满足

$$B := \sum_{k=1}^{\infty} \|f_k\|_p < \infty$$

的函数. 选定可测代表元, 令

$$G_n = \sum_{k=1}^n |f_k|, \quad G = \sum_{k=1}^{\infty} |f_k|.$$

Minkowski 给出 $\|G_n\|_p \leq B$. 又因 $G_n^p \uparrow G^p$, 单调收敛给出

$$\int_X G^p d\mu = \lim_n \int_X G_n^p d\mu \leq B^p.$$

因而 $G < \infty$ a.e., 级数 $\sum_k f_k$ 在该集合上绝对收敛. 将其和记为 F , 并在例外可测零测集上取零, 得到可测函数. 由 $|F| \leq G$ a.e. 可知 $F \in L^p$.

记 $F_n = \sum_{k=1}^n f_k$. 有 $F_n \rightarrow F$ a.e. 且 $|F - F_n|^p \leq 2^p G^p$ a.e., 所以控制收敛给出

$$\|F - F_n\|_p^p = \int_X |F - F_n|^p d\mu \rightarrow 0.$$

这证明范数绝对可求和的级数在有限 p 时收敛.

对 $p = \infty$, 若 $\sum_k \|f_k\|_{\infty} < \infty$, 将每项不等式 $|f_k| \leq \|f_k\|_{\infty}$ 的例外零测集合并为 N . 在 $X \setminus N$ 上, 级数被一个可求和的常数级数控制, 因而绝对且一致收敛. 在 N 上将和定义为零, 得到本质有界的可测函数 F , 并有

$$\left\| F - \sum_{k=1}^n f_k \right\|_{\infty} \leq \sum_{k>n} \|f_k\|_{\infty} \rightarrow 0.$$

最后对任意 L^p -Cauchy 列 (h_n) , 选取子列使 $\|h_{n_{k+1}} - h_{n_k}\|_p \leq 2^{-k}$. 则

$$h_{n_1} + \sum_{k=1}^{\infty} (h_{n_{k+1}} - h_{n_k})$$

的各项范数之和有限, 由已证结果在 L^p 中收敛. 部分和正是原子列, 所以该子列有极限. 再用原列的 Cauchy 性质和三角不等式, 得到整列趋于同一极限. $\square$

因此, 在概率空间中作 L^p -Cauchy 逼近, 极限仍属于同一个 L^p 空间. 有限 p 时保留相应绝对矩的有限性, $p = \infty$ 时保留本质有界性. 这项完备性不要求底层测度空间本身完备, 也不要求它 σ -有限.

L^2 空间 $p = 2$ 时, 范数还能由内积得到, 因而误差之间可以使用正交与投影来比较.

定义 2.60.

对 $f, g \in L^2(X, \mu)$, 定义

$$\langle f, g \rangle = \int_X f \bar{g} d\mu.$$

采用第一个变量线性, 第二个变量共轭线性的约定. 实值情形直接去掉共轭.

定理 2.61.

$L^2(X, \mu)$ 关于上述内积是 Hilbert 空间.

证明. Cauchy-Schwarz 保证乘积可积, 所以内积有定义且不依赖代表元. 积分线性性给出相应线性和共轭对称性, 取商后正定性也成立. 又有 $\langle f, f \rangle = \|f\|_2^2$, 所以诱导范数就是 L^2 范数. Riesz-Fisher 定理保证该范数完备, 因而这是 Hilbert 空间. $\square$

在概率空间中,

$$\langle X, Y \rangle = \mathbb{E}[X \bar{Y}].$$

若 $X \in L^2$, 对 X 和常数一使用 Cauchy-Schwarz, 就知 $\mathbb{E}[|X|] < \infty$. 因而对实值 $X, Y \in L^2$, 可以合法地中心化, 并写出

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \|X - \mathbb{E}[X]\|_2^2,$$

$$\text{Cov}(X, Y) = \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

方差是中心化后的平方范数, 协方差为零则是中心化后的正交. 后面把条件期望看成对较少信息所作的最佳平方误差预测时, 还会用到同一种 Hilbert 空间投影.

不同 L^p 空间之间的关系 提高指数会更严格地控制大幅取值, 但在无限测度空间中, 较小取值分布在多大区域也会影响可积性. 因而对任意测度空间, 不能仅凭 $p < q$ 指定一个统一包含方向. 全空间测度有限时, 则可以把常数一放入 Hölder 不等式, 得到明确结论.

命题 2.62.

设 $\mu(X) < \infty$, $1 \leq p < q \leq \infty$. 若 $f \in L^q(X)$, 则 $f \in L^p(X)$, 且

$$\|f\|_p \leq \mu(X)^{1/p-1/q} \|f\|_q.$$

证明. $\mu(X) = 0$ 时所有范数均为零, 结论成立. 对 $q < \infty$, 对 $|f|^p$ 和常数一使用共轭指数 q/p 与 $q/(q-p)$, 得

$$\int_X |f|^p d\mu \leq \left(\int_X |f|^q d\mu \right)^{p/q} \mu(X)^{1-p/q}.$$

右边有限, 取 p 次根即得结论. 若 $q = \infty$, 直接对 $|f|^p \leq \|f\|_\infty^p$ a.e. 积分, 再取 p 次根. $\square$

概率空间的总质量为一, 所以

$$L^q(\Omega) \subseteq L^p(\Omega), \quad \|X\|_p \leq \|X\|_q.$$

在这里, 有限高阶绝对矩确实控制较低阶绝对矩, 本质有界性也控制每个有限阶绝对矩. 特别地,

$$X \in L^2 \implies X \in L^1,$$

从而有限二阶矩保证期望存在. 这一结论使用了概率测度有限, 不能不加条件地移到任意无限测度空间.

不要求总测度有限, 若已经同时控制两个指数的范数, 也能控制中间指数. 将 $|f|^q$ 分成两个因子, 并让 Hölder 分别使用已知的 p 次与 r 次积分, 就得到插值.

定理 2.63 (插值不等式).

设 $1 \leq p < q < r \leq \infty$, $f \in L^p(X) \cap L^r(X)$. 若 $\lambda \in (0, 1)$ 满足

$$\frac{1}{q} = \frac{\lambda}{p} + \frac{1-\lambda}{r},$$

则 $f \in L^q(X)$, 且

$$\|f\|_q \leq \|f\|_p^\lambda \|f\|_r^{1-\lambda}.$$

证明. 先设 $r < \infty$. 两个数 $p/(\lambda q)$ 与 $r/((1-\lambda)q)$ 大于一, 其倒数之和为一. 对

$$|f|^q = |f|^{\lambda q} |f|^{(1-\lambda)q}$$

使用这对 Hölder 指数, 得到

$$\int_X |f|^q d\mu \leq \|f\|_p^{\lambda q} \|f\|_r^{(1-\lambda)q}.$$

取 q 次根即得结论.

若 $r = \infty$, 指数关系变为 $\lambda = p/q$. 由

$$|f|^q \leq \|f\|_\infty^{q-p} |f|^p \quad \text{a.e.}$$

积分并取 q 次根, 得到所需的两个范数幂次. □

在概率论中, 有限 p, r 的情形用两个绝对矩控制中间绝对矩. $r = \infty$ 时则用一个有限阶矩与一个本质上界控制中间范数. 后面研究随机过程的误差与矩估计时, 可以按已经掌握的两端信息选择这种分解.

简单函数逼近 积分定义中的简单函数逼近, 还可以升级为范数逼近. 对无限测度空间, 要同时保证近似函数只在有限测度部分非零; 可积性本身就会提供所需的集合.

命题 2.64.

对 $1 \leq p < \infty$, 具有有限测度支撑的简单函数在 $L^p(X, \mu)$ 中稠密. 这里的有限测度支撑, 指在某个有限测度可测集之外取零, 不涉及拓扑支撑的闭包.

证明. 取 $f \in L^p$, 先保留

$$E_n = \left\{ \frac{1}{n} \leq |f| \leq n \right\}$$

上的取值, 在补集取零. 实值情形将保留下来的绝对值按步长 2^{-n} 向下取整, 并保留原符号; 复值情形则分别将实部和虚部按同样步长向零取整. 这样得到有限取值的可测简单函数 f_n , 满足 $|f_n| \leq |f|$, 且对每个有限非零的 $f(x)$, 最终 $x \in E_n$, 取整误差也趋于零. 在 $f = 0$ 处始终为零, 所以 $f_n \rightarrow f$ a.e.

由 $|f|^p \geq n^{-p}$ 在 $\{|f| \geq 1/n\}$ 上成立, 有

$$\mu \left(\left\{ |f| \geq \frac{1}{n} \right\} \right) \leq n^p \int_X |f|^p d\mu < \infty.$$

因而每个 E_n 测度有限, 每个 f_n 都具有所要求的支撑. 最后用

$$|f_n - f|^p \leq 2^p |f|^p$$

和控制收敛, 得到 $\|f_n - f\|_p \rightarrow 0$. □

这个证明不要求全空间 σ -有限, 因为所需有限测度部分直接由 f 的可积性得到. 在概率论中, 它允许先对有限取值随机变量证明适合按范数取极限的结论, 再推广到一般 L^p 随机变量.

有限测度支撑的要求不能直接推广到 L^∞ 的一般无限测度空间. 例如实线上的常数一属于 L^∞ , 任何只在有限 Lebesgue 测度集合上非零的函数, 与它的本质上确界距离都至少为一. 本质有界函数仍可通过对整个值域分组作简单函数的一致逼近, 但支撑可能必须保留在无限测度集合上.

注 2.65 (积分给出的线性泛函).

对共轭指数 p, q , 每个 $g \in L^q$ 都定义连续线性泛函

$$\Lambda_g(f) = \int_X fg \, d\mu,$$

因为 Hölder 给出 $|\Lambda_g(f)| \leq \|g\|_q \|f\|_p$. 在 σ -有限空间上, 若 $1 < p < \infty$, 每个 L^p 的连续线性泛函都能这样表示, 且对应 g 在几乎处处意义下唯一, 泛函范数等于 $\|g\|_q$. 反向表示的证明先用泛函作用于有限测度集合的指示函数, 构造绝对连续的符号测度 (复值情形为复测度), 再由 Radon–Nikodym 定理取得密度, 最后用简单函数稠密性推广到整个 L^p . 因而本节的密度表示与范数逼近在对偶问题中会再次一起使用.

第三章 概率论基础

第二章已建立可测空间, 测度, 前推测度和 Lebesgue 积分. 将总测度取为一, 就得到概率空间, 其中的可测集称为事件. 事件的并, 交, 补及概率的可列可加性, 都沿用前面的集合与测度运算.

本章主要参考 [Bil95; Dur19; Kal21; Wil91]. 从完整实验结果出发, 先说明怎样选取要研究的观测量, 再讨论这些量的分布, 期望, 相互关系和极限.

例如连续抛十次硬币, 一次完整结果可以是

$$(H, T, H, H, T, T, H, T, H, H).$$

若只关心正面总数, 就把这条记录送到数值 6. 其他排列也可能得到 6, 因而计数保留了正面次数, 没有保留出现顺序.

这样的观测由函数

$$X: \Omega \rightarrow \mathbb{R}$$

表示. 样本点 ω 给定以后, $X(\omega)$ 也随之确定; 概率来自我们怎样给可能的样本结果赋予权重.

要讨论取值落在 Borel 集 A 中的概率, 就要测量原像 $X^{-1}(A)$. 可测性保证它属于事件域, 从而

$$\mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A))$$

有定义. 随机变量因此既是一种观测方式, 也把取值空间中的问题转回了原概率空间上的事件.

把所有取值集合的概率记录到取值空间, 就得到 X 的分布, 即前推测度 $X_*\mathbb{P}$. 分布足以回答只依赖这个观测量的概率问题, 却不一定保留样本中的其他信息. 正面总数的分布, 例如没有同时说明每一次抛币的先后关系.

完整市场历史也可以这样使用. 一天的盘口和成交记录是一项复杂结果, 收盘收益率, 最大回撤和总成交量则分别读取这项结果的不同部分. 要联合研究这些量, 就须保留它们来自同一历史的关系, 不能只给出各自的分布.

若 X 可积, 其期望定义为

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P}.$$

前推测度的积分公式还允许直接对 X 的分布计算同一个数. 对 $1 \leq p < \infty$,

$$X \in L^p(\Omega, \mathbb{P}) \iff \mathbb{E}[|X|^p] < \infty,$$

而 L^∞ 对应本质有界. 前面关于积分收敛和范数的定理, 因而可以直接控制随机变量的平均误差与各阶矩.

接下来还要研究多项观测怎样相互影响. 独立性规定联合概率怎样分解, 条件概率和条件期望则描述新增信息以后怎样调整判断. 随机变量列的收敛问题, 还要求分清逐条实现的变化与分布或积分的变化.

图3.1列出这些内容的联系. 先把样本, 观测与分布区分清楚, 再研究信息和极限, 后面就能够同时处理一整族随时间变化的随机变量.




图 3.1: 从样本和事件走向随机过程

进入随机过程以后, 单个时刻的分布只是起点. 不同时刻的联合规律, 随时间积累的信息以及整条样本路径的性质, 将成为进一步研究的内容.

3.1 概率空间与随机变量

描述一个随机系统, 要先说明哪些结果可能出现, 哪些关于结果的问题可以赋予概率, 以及这些概率是多少. 概率空间把这三件事放在一起; 随机变量再从完整结果中读出我们关心的数值.

3.1.1 概率空间

定义 3.1.

概率空间是三元组 $(\Omega, \mathcal{F}, \mathbb{P})$, 其中 Ω 为样本空间, $\mathcal{F}$ 是其上的 σ -代数, 称为事件域, $\mathbb{P}$ 是满足 $\mathbb{P}(\Omega) = 1$ 的测度. $\mathcal{F}$ 的元素称为事件.

样本空间列出可能结果, 事件域规定哪些结果集合能够赋予概率, 最后才由 $\mathbb{P}$ 给出概率值. 对不属于 $\mathcal{F}$ 的子集, 这个模型没有定义其概率. 同一个样本空间也可以采用不同事件域或概率测度, 因而只写出 Ω 还没有完成概率模型.

全空间 Ω 是必然事件, 空集是不可能事件. 对一般事件 A , $\mathbb{P}(A) = 1$ 表示它几乎必然发生 (almost surely, a.s.): 补集的概率为零, 但补集未必为空. 同理, 零概率也不要求事件没有样本点.

下面两个例子分别用计数与体积归一化构造概率. 它们的等可能性来自模型的具体选择, 不由样本空间的有限或连续形式自动决定.

例 3.2 (古典概型).

对非空有限集 Ω , 取 $\mathcal{F} = \mathcal{P}(\Omega)$, 定义

$$\mathbb{P}(A) = \frac{\#A}{\#\Omega}.$$

不交集合的元素数相加, 全空间归一化为一, 所以这确实是概率测度. 每个样本点的概率都是 $1/\#\Omega$, 事件概率因而等于其中结果数所占的比例.

使用这种计算, 要先有样本点等可能的依据. 有限空间上的一般概率也可以给不同样本点不同权重, 只要求权重非负且总和为一.

例 3.3 (几何概型).

设 $\Omega \subseteq \mathbb{R}^d$ 为 Lebesgue 可测集, 且 $0 < \lambda_d(\Omega) < \infty$. 在迹 σ -代数

$$\mathcal{F} = \{A \cap \Omega : A \in \mathcal{L}(\mathbb{R}^d)\}$$

上定义

$$\mathbb{P}(A) = \frac{\lambda_d(A)}{\lambda_d(\Omega)}, \quad A \in \mathcal{F}.$$

这是将限制到 Ω 的 Lebesgue 测度归一化, 可列可加性因此保留, 总质量成为一.

它按长度, 面积或体积的比例分配概率. 例如在 $[0, 1]$ 上均匀取点, 对 $[a, b] \subseteq [0, 1]$ 有 $\mathbb{P}([a, b]) = b - a$. 每个单点的概率却都是零, 尽管一次实现最终仍会落在某个点上.

这与全区间概率为一不矛盾: 区间是不可数个单点的并, 测度公理只保证可列可加性, 不允许把这个不可数并按单点概率直接相加.

3.1.2 随机变量

一个样本点可以包含整个实验的结果, 也可以是一整条可能的市场历史. 固定样本点以后, 这条历史中各时刻的价格便都确定, 随机性来自不同历史如何被赋予概率.

先只记录一只股票的每日价格, 并在这个例子中假设价格严格为正. 取

$$\Omega = (0, \infty)^{\mathbb{N}_0}, \quad \mathbb{N}_0 = \{0, 1, 2, \dots\}.$$

样本点 $\omega = (s_0, s_1, s_2, \dots)$ 是完整路径, 坐标函数 $S_t(\omega) = s_t$ 只读出第 t 日的价格. 取

$$\mathcal{F} = \sigma(S_t : t \in \mathbb{N}_0),$$

即由各时点的 Borel 取值条件生成的 σ -代数. 这先规定了路径和事件, 还须另外选择概率测度 $\mathbb{P}$, 才能描述路径有怎样的联合规律.

在离散观察时点下, 明日价格高于今日, 一个月内最大回撤超过 10%, 或截至某日价格曾超过 200, 都可以通过有限个坐标的不等式和最大值构成事件. 若还研究成交量, 订单簿或新闻, 就要在样本记录与事件域中保留相应信息.

完整路径的事件域包含关于未来的事件, 不表示交易者今天已经知道它们是否发生. 当前可用信息会在下面另用较小的 σ -代数表示.

价格, 收益率或技术指标都是从完整样本中取得的数值. 一般地, 用一个可测函数读出所研究的量, 就得到随机变量.

定义 3.4.

令 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间. **随机变量**是指可测映射

$$X: (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

随机变量 X 指整个函数, 实现值 $X(\omega)$ 才是一次观察所得的数. 同一个函数可以用于全部样本, 但不同样本给出不同值.

可测性保证这些值能够接受概率计算. 例如 $\{X \leq a\} = X^{-1}((-\infty, a])$ 必须属于 $\mathcal{F}$. 由于半直线 $(-\infty, a]$ 生成 $\mathcal{B}(\mathbb{R})$, 检查所有这样的原像已经足够. 原因是所有原像可测的目标集合本身组成 σ -代数, 包含生成族以后就包含全部 Borel 集.

在上述路径空间中, S_t 按定义可测. 严格正价格下, 对 $t \geq 1$ 定义

$$R_t = \frac{S_t - S_{t-1}}{S_{t-1}}.$$

它由两个可测坐标通过连续函数得到, 因而仍可测. 若另一个模型允许分母为零, 就须先规定所研究的收益如何定义, 再检查相应函数.

均线或 MACD 等指标也可以由历史坐标经可测运算得到. 可测性说明它们能够作为随机变量研究, 至于历史指标是否有助于预测下一段收益, 则取决于这些变量的联合分布.

随机变量所携带的信息 知道 X 的值, 就能判断它是否落在任意 Borel 集合中. 这些取值条件在原空间上的原像, 正好描述仅凭这次观测能够判断的事件.

定义 3.5.

随机变量 X 生成的 σ -代数

$$\sigma(X) = \{X^{-1}(A) : A \in \mathcal{B}(\mathbb{R})\}.$$

原像保持补集和可列并, 所以这里列出的集合族已经是 σ -代数, 无需再作一次生成. 它是使 X 可测的最小 σ -代数, 并由原来的可测性得到 $\sigma(X) \subseteq \mathcal{F}$.

若 $X(\omega_1) = X(\omega_2)$, 每个 $\sigma(X)$ 中的事件都同时包含或同时不包含这两个样本点. 仅看 X 无法区分它们. 包含关系也可以成为等号, 所以观测可能遗漏信息, 却不要求每个随机变量都严格减少事件域.

当前价格 S_t 相同的两条路径, 过去走势仍可能不同. 因而只看当前价格的 $\sigma(S_t)$, 与看完历史的 $\sigma(S_0, \dots, S_t)$ 是不同的信息选择. 后者随 t 增加而扩大, 构成价格的自然滤过. 它只使用截至 t 的坐标, 与前面包含所有未来价格事件的 $\mathcal{F}$ 应分开.

事件与随机变量**定义 3.6.**

事件 $A \in \mathcal{F}$ 的示性随机变量为

$$\mathbf{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

它只记录事件是否发生. 取值原像只会是 A, A^c , 空集或全空间, 因而可测. 反过来, $\mathbf{1}_A$ 可测也保证 $A = \{\mathbf{1}_A = 1\}$ 是事件. 积分的定义直接给出 $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$, 将事件概率包含在期望计算中.

随机向量与随机过程 可测映射 $X = (X_1, \dots, X_n): \Omega \rightarrow (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ 称为**随机向量**. 它可测当且仅当每个坐标 X_i 可测. 一个方向由坐标投影可测得到; 另一个方向对矩形使用

$$\left\{ X \in \prod_{i=1}^n B_i \right\} = \bigcap_{i=1}^n \{X_i \in B_i\}, \quad B_i \in \mathcal{B}(\mathbb{R}),$$

再由 Borel 矩形生成 $\mathcal{B}(\mathbb{R}^n)$ 即可.

取值空间也可以是一般可测空间 $(E, \mathcal{E})$, 这样的可测映射称为**随机元素**. 例如, 在合适的可测空间上, 整条路径也可以作为一个随机元素研究.

若固定同一概率空间并同时考虑一族 $(S_t)_{t \in T}$, 就得到随机过程. 每个时刻可测, 还没有说明不同时刻怎样关联或路径有什么正则性. 下一节先建立分布的语言, 后面再用联合分布和信息滤过处理这些问题.

3.2 随机变量的分布

随机变量说明怎样从样本取得数值, 分布则记录这些数值落入各集合的概率. 两者通过前推测度联系: 对可测映射 $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$,

$$(X_*\mathbb{P})(A) = \mathbb{P}(X^{-1}(A)), \quad A \in \mathcal{G}.$$

右边在原样本空间计算, 左边把结果作为取值空间上的测度保存. 原像保持不交可列并, 且 $X^{-1}(E) = \Omega$, 所以前推后仍是概率测度.

只研究这个观测量时, 可以直接使用它在 $(E, \mathcal{G})$ 上的分布, 不必保留样本中的其他细节. 但若问题还涉及另一个观测或此前信息, 单个分布就未必足够.

3.2.1 分布作为前推测度

根据前面的讨论, 我们可以直接得到下面的定义.

定义 3.7.

令 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$ 为随机元素. 称前推测度 $X_*\mathbb{P}$ 为 X 在概率测度 $\mathbb{P}$ 下的 **分布**, 记作 $\mathcal{L}(X)$ 或 μ_X .

因而对于任意 $A \in \mathcal{G}$, 有

$$(X_*\mathbb{P})(A) = \mathbb{P}(X \in A).$$

更一般地, 令 μ 为 $(E, \mathcal{G})$ 上的概率测度. 如果 $X_*\mathbb{P} = \mu$, 则称 X **服从分布** μ , 记作 $X \sim \mu$.

给定取值空间上的概率测度以后, 还可以反过来寻找具有这个分布的随机元素. 原样本空间和观测函数未必唯一, 这些具体选择称为实现.

定义 3.8.

若概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 与随机元素 $X: \Omega \rightarrow (E, \mathcal{G})$ 满足 $X_*\mathbb{P} = \mu$, 就称它们给出了分布 μ 的一个**实现**. 语境清楚时也直接称 X 为该分布的实现.

例 3.9 (典范实现).

对任意 $(E, \mathcal{G})$ 上的概率测度 μ , 取概率空间 $(E, \mathcal{G}, \mu)$, 并令 $X = \text{id}_E$. 恒等映射的原像不改变集合, 所以

$$X_*\mu = (\text{id}_E)_*\mu = \mu.$$

因而每个概率测度至少都有这个直接实现.

这个构造足以证明单个分布能够实现. 若还要求多个随机变量独立, 相等或满足其他关系, 则需要安排它们怎样放在同一概率空间中. 同一个单变量分布可以参与许多不同的联合构造.

定义 3.10.

设 $X: (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (E, \mathcal{G})$ 与 $Y: (\Omega', \mathcal{F}', \mathbb{Q}) \rightarrow (E, \mathcal{G})$ 为随机元素. 若

$$X_*\mathbb{P} = Y_*\mathbb{Q},$$

则称它们**同分布**, 记为 $X \stackrel{d}{=} Y$.

同分布比较的是所有取值事件的概率. 两个函数不必相等, 甚至可以定义在不同空间中. 只有先把它们放到共同概率空间, 才能进一步讨论 $X = Y$ 的概率, 或者二者差多少.

各自的分布也不能确定联合分布. 例如在 $[0, 1]$ 的均匀概率空间中, 恒等变量 U 与 $1 - U$ 都均匀分布. 随机向量 (U, U) 的两个坐标始终相等, $(U, 1 - U)$ 的两个坐标之和始终为一. 各坐标的分布一样, 坐标之间的关系却不同.

后面的独立性和条件概率正是研究这种联合关系. 随机过程中, 每个时刻的分布同样需要与跨时刻的联系一起给出.

分布函数 一般可测空间未必带有顺序, 直接用概率测度描述分布最合适. 在 $\mathbb{R}^n$ 中, 坐标顺序则给出一族特别方便的集合:

$$(-\infty, x] = \prod_{i=1}^n (-\infty, x_i], \quad x = (x_1, \dots, x_n).$$

只要记录这些左下矩形上的概率, 就能恢复整个 Borel 分布.

定义 3.11.

随机向量 $X = (X_1, \dots, X_n)$ 的**分布函数** (cumulative distribution function, CDF) 为

$$F_X(x_1, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

若 $\mu_X = X_*\mathbb{P}$, 就有 $F_X(x) = \mu_X((-\infty, x])$. 一维时只剩 $F_X(x) = \mathbb{P}(X \leq x)$; 多维时也称联合分布函数, 因为这里同时要求所有坐标满足各自的不等式.

分布函数与分布 先从左下矩形算出有界矩形的概率. 二维情况下, 在 $F_{X,Y}(b, d)$ 中减去左边和下边的部分, 再补回被减去两次的交叠部分, 得到

$$\begin{aligned} \mathbb{P}(a < X \leq b, c < Y \leq d) &= F_{X,Y}(b, d) - F_{X,Y}(a, d) \\ &\quad - F_{X,Y}(b, c) + F_{X,Y}(a, c). \end{aligned}$$

高维时对各坐标依次作差. 对有限实端点 $a_i < b_i$ 构成的有界半开矩形 $R = \prod_{i=1}^n (a_i, b_i]$, 定义

$$\Delta_R F = \sum_{\varepsilon \in \{0,1\}^n} (-1)^{n-|\varepsilon|} F(c_\varepsilon),$$

其中 $|\varepsilon| = \sum_i \varepsilon_i$, c_ε 的第 i 坐标按 $\varepsilon_i = 1$ 或 0 分别取 b_i 或 a_i . 若 F 来自一个分布, 这项差分就是矩形概率, 必须非负.

定义 3.12.

函数 $F: \mathbb{R}^n \rightarrow [0, 1]$ 称为 n 维分布函数, 若满足:

1. 每个有界半开矩形 $R = \prod_{i=1}^n (a_i, b_i]$ 都有 $\Delta_R F \geq 0$;
2. 若 $x^{(k)} \downarrow x$ 逐坐标成立, 则 $F(x^{(k)}) \rightarrow F(x)$;
3. 固定其余坐标, 让任意一个坐标趋于 $-\infty$, 函数值趋于零;
4. 所有坐标同时趋于 $+\infty$ 时, 函数值趋于 1.

第一项称为 n -递增性. 一维时它就是单调不减, 多维时却要求各坐标的混合差分非负, 比分别沿坐标单调更强. 第二项是与右闭矩形对应的右连续性, 最后两项则规定全概率在无穷远边界的行为. 下面证明这些条件也足以构造一个概率测度.

定理 3.13.

函数 $F: \mathbb{R}^n \rightarrow [0, 1]$ 是某个随机向量的分布函数, 当且仅当它满足上述 n 维分布函数条件. 此时存在唯一的 Borel 概率测度 μ_F , 使每个 $x \in \mathbb{R}^n$ 满足

$$\mu_F((-\infty, x]) = F(x).$$

证明. 若 F 来自概率测度, 矩形差分就是非负的矩形概率. 对 $x^{(k)} \downarrow x$, 相应左下矩形递减到 $(-\infty, x]$, 概率测度的从上连续性给出右连续性. 令一个坐标趋于负无穷或所有坐标趋于正无穷, 再分别使用集合的递减或递增极限, 得到两项边界条件.

反过来, 先令 $\mathcal{A}$ 为有限个有界半开矩形的不交并所构成的集合环. 它对有限并和集合差封闭, 但不包含 $\mathbb{R}^n$, 所以不是全空间上的集合代数. 对矩形定义 $\mu_0(R) = \Delta_R F$, 对有限不交并按项相加. 将不同矩形分解放到共同端点网格上, 各坐标差分逐项相消, 证明数值与分解无关且有限可加. n -递增性保证非负性.

边界条件还给出所需的有限质量控制. 固定某坐标的两个端点, 将其他坐标的矩形下端点依次送到负无穷, $\Delta_R F \geq 0$ 就推出 F 对该坐标单调不减. 因而对固定上端点 b , 当 $m \rightarrow \infty$ 时,

$$\mu_0\left(\prod_{i=1}^n (-m, b_i]\right) \rightarrow F(b).$$

展开差分后, 除 $F(b)$ 外的每项都至少有一个坐标等于 $-m$; 用坐标单调性将其余坐标向上放到固定的 b_i , 再用负无穷边界, 可知这些项趋于零. 每个环内集合 A 都包含在某个固定上端点的此类矩形中, 有限可加性及单调性因此给出 $0 \leq \mu_0(A) \leq 1$. 这还没有给全空间赋值, 只是对所有有界环内集合的统一上界.

接着证明 μ_0 是预测度. 只需先证: 若 $A_j \in \mathcal{A}$ 且 $A_j \downarrow \emptyset$, 则 $\mu_0(A_j) \downarrow 0$. 对一个矩形 $R = \prod_i (a_i, b_i]$, 将下端点略向右移为 $a_i + \delta$, 得到 R_δ ; 当 $\delta \downarrow 0$ 时, 右连续性给出 $\mu_0(R_\delta) \rightarrow \mu_0(R)$,

而 $\overline{R_\delta} \subseteq R$ 是紧集. 对有限矩形并分别这样处理, 可以为每个 A_j 找到 $B_j \in \mathcal{A}$, 使 $K_j = \overline{B_j} \subseteq A_j$ 为紧集, 且

$$\mu_0(A_j \setminus B_j) < \varepsilon 2^{-j}.$$

因 $\bigcap_j K_j \subseteq \bigcap_j A_j = \emptyset$, 紧性保证存在有限的 N , 使 $\bigcap_{j=1}^N K_j = \emptyset$. 又因 $A_N \subseteq A_j$ 对 $j \leq N$ 成立, 有

$$A_N \subseteq \bigcup_{j=1}^N (A_j \setminus K_j) \subseteq \bigcup_{j=1}^N (A_j \setminus B_j).$$

仅对最后这些环内集合使用有限次可加性, 得到 $\mu_0(A_N) < \varepsilon$. 因而所需从上连续性成立, 这里没有对尚未测量的紧集直接使用 μ_0 .

若 $A = \bigsqcup_j E_j$ 且 $A, E_j \in \mathcal{A}$, 则余集 $A \setminus \bigcup_{j=1}^N E_j$ 在环内递减到空集. 将有限可加性中的余项送到零, 得 $\mu_0(A) = \sum_j \mu_0(E_j)$, 所以 μ_0 是预测度. 有界盒 $(-m, m]^n$ 可列覆盖全空间, 各盒测度有限, 而 $\sigma(\mathcal{A}) = \mathcal{B}(\mathbb{R}^n)$. 由集合环版 Carathéodory 扩张定理, 得到唯一的 Borel 测度扩张 μ_F .

对固定 x , 使用 $\prod_i (-m, x_i] \uparrow (-\infty, x]$ 和前面的差分极限, 得

$$\mu_F((-\infty, x]) = F(x).$$

再令所有上端点一起趋于正无穷,

$$\mu_F(\mathbb{R}^n) = \lim_{m \rightarrow \infty} F(m, \dots, m) = 1.$$

因而扩张确为概率测度. 在它上面取恒等随机向量, 就实现了 F . 唯一性也可由 π - λ 定理直接得到: 两个候选概率测度总质量都为一, 并在生成 Borel σ -代数的左下矩形 π -系上一致. $\square$

因此, 在 $\mathbb{R}^n$ 上可以用分布函数代替逐个记录所有 Borel 集合的概率. 若要实现这个分布, 直接把构造出的概率测度放在取值空间上即可.

推论 3.14.

令 F 为任意 n 维分布函数. 则存在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 以及随机向量 $X: \Omega \rightarrow \mathbb{R}^n$, 使得 $F_X = F$.

证明. 令 μ_F 为 F 对应的 Borel 概率测度. 直接取概率空间 $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mu_F)$ 以及恒等随机向量 $X = \text{id}_{\mathbb{R}^n}$ 即可. $\square$

随机向量各坐标的分布称为**边缘分布**. 从联合分布取得一个边缘, 就是不再限制其他坐标. 二维时, 事件 $\{X \leq x, Y \leq y\}$ 随 $y \uparrow \infty$ 增大到 $\{X \leq x\}$, 所以

$$F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y).$$

联合分布能够确定边缘分布, 反过来一般不行, 因为取极限时已经丢掉了两个坐标怎样共同取值的信息.

3.2.2 一些常见的分布

下面按计数, 等待和连续取值介绍常用分布. 独立性将在后文正式定义, 这里先用独立实验的概率乘法说明二项和几何等公式的来源, 再看连续时间中的对应关系.

离散分布

定义 3.15.

随机变量 X 若存在有限或可数集 $S \subseteq \mathbb{R}$, 使 $\mathbb{P}(X \in S) = 1$, 就称其具有**离散分布**. 函数 $p_X(x) = \mathbb{P}(X = x)$ 称为**概率质量函数** (probability mass function, PMF).

单点两两不交, 所以对任意 Borel 集 A ,

$$\mathbb{P}(X \in A) = \sum_{x \in A \cap S} p_X(x), \quad \sum_{x \in S} p_X(x) = 1.$$

只需给出可数个非负质量, 就能恢复任意取值事件的概率. S 以外允许还有模型中的取值, 但它们合起来的概率为零.

例 3.16 (单点分布).

令 $a \in \mathbb{R}$. 如果随机变量 X 满足 $\mathbb{P}(X = a) = 1$, 那么称 X 服从位于 a 的**单点分布**. 它的分布就是 Dirac 测度 δ_a , 即

$$\delta_a(A) = \begin{cases} 1, & a \in A, \\ 0, & a \notin A. \end{cases}$$

这是最简单的概率分布: 所有概率质量全部集中在一个点上.

例 3.17 (Bernoulli 分布).

令 $p \in [0, 1]$. 如果随机变量 X 只取 0 和 1 两个值, 并满足 $\mathbb{P}(X = 1) = p$, $\mathbb{P}(X = 0) = 1 - p$, 那么称 X 服从参数为 p 的**Bernoulli 分布**, 记作 $X \sim \text{Bernoulli}(p)$.

Bernoulli 分布就是一次“成功或者失败”实验最直接的数学描述. 比如抛一次硬币时, 可以令正面对应 1, 反面对应 0.

例 3.18 (二项分布).

取非负整数 n 和 $p \in [0, 1]$, 进行 n 次相互独立, 成功概率均为 p 的 Bernoulli 实验. 令 X 为成功总次数, 则

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

称为**二项分布**, 记作 $X \sim \text{Bin}(n, p)$.

对 $0 < p < 1$, 一个指定的成功位置组合含 k 次成功与 $n - k$ 次失败, 概率由独立性相乘得到 $p^k (1-p)^{n-k}$. 这样的组合有 $\binom{n}{k}$ 个且互不相交, 相加便得公式. $p = 0$ 或 1 分别给出始终失败或始终成功, 公式按端点处 $0^0 = 1$ 的组合约定理解; $n = 0$ 时总次数为零.

用示性变量记各次结果, 就是 $X = X_1 + \dots + X_n$, 其中各 X_i 独立且服从 $\text{Bernoulli}(p)$. 二项分布因此固定实验次数, 再统计成功多少次.

例 3.19 (几何分布).

取 $p \in (0, 1]$, 重复相互独立且成功概率为 p 的 Bernoulli 实验, 直到第一次成功. 所用次数 T 满足

$$\mathbb{P}(T = k) = (1-p)^{k-1} p, \quad k = 1, 2, \dots,$$

称为**几何分布**, 记作 $T \sim \text{Geom}(p)$.

$T = k$ 要求前 $k - 1$ 次全失败, 第 k 次成功, 所以概率是上述乘积. $p = 1$ 时直接取 $T = 1$ a.s. 对任意 $p > 0$, 连续 m 次仍未成功的概率为 $(1-p)^m$, 随 $m \rightarrow \infty$ 趋于零, 因而首次成功几乎必然会到来.

本例把成功的那次也计入, 所以从 1 开始取值. 若改为统计成功前的失败次数, 得到的是 $T - 1$, 从 0 开始. 两种约定只差一, 使用其均值或其他公式时必须一致.

例 3.20 (Poisson 分布).

对 $\lambda > 0$, 定义

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k \in \mathbb{N}_0 = \{0, 1, 2, \dots\}.$$

这些数非负, 总和由指数级数等于一, 因而给出**Poisson 分布**, 记作 $X \sim \text{Pois}(\lambda)$.

它可以从稀少事件的计数极限得到. 设一次固定观察期分成 n 个独立小试验, 每次发生事件的概率为 λ/n , 先只记录是否发生. 当 n 足够大使该概率不超过一时, 总数服从 $\text{Bin}(n, \lambda/n)$.

对固定 k ,

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda} \frac{\lambda^k}{k!}.$$

其中 $n(n-1)\cdots(n-k+1)/n^k \rightarrow 1$, 而 $(1 - \lambda/n)^n \rightarrow e^{-\lambda}$, 直接给出这个极限.

参数 λ 对应整段观察的计数规模. 用它描述连续时间事件, 还要说明各小段如何独立, 发生率是否稳定以及多次同时到达怎样处理. 后面的 Poisson 过程会明确这些假设, 并将长度为 t 的观察期参数写成发生率乘以 t .

绝对连续分布 离散分布按点累加概率. 另一类分布按区域体积和密度计算, 由 Radon–Nikodym 定理给出其准确条件.

定义 3.21.

设随机向量 $X: \Omega \rightarrow \mathbb{R}^n$ 的分布为 μ_X . 在共同的 Borel σ -代数上, 以 λ_n 表示 Lebesgue 测度的限制. 若

$$\mu_X \ll \lambda_n,$$

就称 X 具有**绝对连续分布**. 此时存在非负 Borel 可测函数 f_X , 对所有 Borel 集 A 满足

$$\mathbb{P}(X \in A) = \int_A f_X(x) dx.$$

f_X 称为**概率密度函数** (probability density function, PDF).

这里

$$f_X = \frac{d\mu_X}{d\lambda_n}, \quad \int_{\mathbb{R}^n} f_X(x) dx = 1.$$

积分有限使密度几乎处处有限, 可在例外零测集上改为零, 选取处处有限的版本. 反过来, 任意非负可测函数若积分为一, 按上述积分公式就定义一个概率分布.

一维时,

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

单点是 Lebesgue 零测集, 所以 $\mathbb{P}(X = x) = 0$; 密度在点上的数值并不是该点概率. 不同密度版本可以在零测集上不同, 却给出完全相同的分布.

分布函数连续只表示没有点质量, 还不足以保证对 Lebesgue 测度绝对连续. 奇异连续分布就是没有原子却仍集中在 Lebesgue 零测集上的例子. 因而离散与有密度也没有穷尽所有概率分布.

例 3.22 (均匀分布).

令 $a < b$. 如果随机变量 X 的概率密度为

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x),$$

那么称 X 服从区间 $[a, b]$ 上的**均匀分布**, 记作 $X \sim \text{Unif}(a, b)$.

可以把它看作古典等可能模型的连续版本. 每一个单独的点虽然概率都为 0, 但是长度相同的区间具有相同的概率.

例 3.23 (指数分布).

取率参数 $\lambda > 0$. 密度

$$f_T(t) = \lambda e^{-\lambda t} \mathbf{1}_{[0,\infty)}(t)$$

定义指数分布, 记作 $T \sim \text{Exp}(\lambda)$. 对 $t \geq 0$ 积分, 得到

$$\mathbb{P}(T > t) = \int_t^\infty \lambda e^{-\lambda u} du = e^{-\lambda t}.$$

因而总概率为一, 且对 $s, t \geq 0$,

$$\mathbb{P}(T > s + t \mid T > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(T > t).$$

条件事件的概率严格为正, 所以这里可直接用概率比计算.

这称为**无记忆性**: 已经等待但尚未到达, 不改变剩余等待时间的分布. 几何分布的尾概率 $(1-p)^m$ 也给出离散时间的相应性质, 只在条件事件概率为正时使用. 指数分布因此适合恒定发生率的 Poisson 等待, 并非任意连续等待时间都应服从这一分布.

例 3.24 (Gamma 分布).

对任意形状参数 $\alpha > 0$ 与率参数 $\lambda > 0$, 密度

$$f_T(t) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\lambda t}, & t > 0, \\ 0, & t \leq 0 \end{cases}$$

定义 **Gamma 分布**, 记作 $T \sim \text{Gamma}(\alpha, \lambda)$. 这里

$$\Gamma(\alpha) = \int_0^\infty u^{\alpha-1} e^{-u} du.$$

用 $u = \lambda t$ 换元, 可见密度积分为一. 当 $0 < \alpha < 1$ 时, 密度在零点右侧无界, 但仍可积; 零点本身取何值不改变分布, 上面统一取零.

本节采用率参数, 另一种常见约定采用尺度参数 $\theta = 1/\lambda$. 比较不同资料时, 先确认第二个参数是率还是尺度.

整数形状的 Gamma 分布可以由 Poisson 到达直接得到. 在率为 λ 的 Poisson 过程中, 令 $N(t)$ 为截至 t 的事件数, 有 $N(t) \sim \text{Pois}(\lambda t)$. 对**正整数** k , 令 T_k 为从零时刻等到第 k 次到达的时间. 对 $t \geq 0$,

$$\{T_k > t\} = \{N(t) \leq k-1\},$$

所以

$$\mathbb{P}(T_k \leq t) = 1 - \sum_{j=0}^{k-1} e^{-\lambda t} \frac{(\lambda t)^j}{j!}.$$

在 $t > 0$ 求导, 相邻幂次的项相消, 剩下

$$f_{T_k}(t) = \frac{\lambda^k}{(k-1)!} t^{k-1} e^{-\lambda t}, \quad t > 0.$$

结合 $\Gamma(k) = (k-1)!$, 得到 $T_k \sim \text{Gamma}(k, \lambda)$.

在同一个 Poisson 过程中, 固定时间统计次数得到 Poisson 分布, 固定正整数次数研究等待得到整数形状 Gamma 分布. $k=1$ 时就是指数分布. 一般非整数 $\alpha > 0$ 的 Gamma 分布仍由前面的密度定义, 不具有等待第 α 次事件这种解释.

例 3.25 (正态分布).

取 $\mu \in \mathbb{R}, \sigma > 0$. 密度

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$


定义**正态分布** (normal distribution), 也称 Gauss 分布, 记为

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

$\mu = 0, \sigma = 1$ 时称为**标准正态分布** $\mathcal{N}(0, 1)$.

密度关于 μ 对称. μ 平移分布的位置, σ 改变横向尺度, 前面的 $1/\sigma$ 同时调整高度, 使总面积仍为一. 因而较大的 σ 将概率摊在更宽范围, 并降低峰值.

下图展示正态曲线的形状, 横向标出距 μ 一, 二, 三个 σ 的位置. 纵向作了便于观察的缩放且未标数值刻度, 图上高度不直接表示上式的密度数值.



正态族在仿射变换下保持同样形式. 若 $a \neq 0, b \in \mathbb{R}$, 变量替换给出 $aX + b$ 的密度为 $|a|^{-1}f_X((x-b)/a)$, 代入原式即得

$$aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

特别地,

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1),$$

称为**标准化**. 若 $a = 0$, 则得到位于 b 的**单点分布**, 不再具有上面要求正方差的密度.

用下一节的期望定义, 标准正态密度的对称性给出 $\mathbb{E}[Z] = 0$, 对 $z^2 e^{-z^2/2}$ 分部积分给出 $\mathbb{E}[Z^2] = 1$. 因而 X 的期望为 μ , 方差为 σ^2 , 标准差为 σ .

对 $c \geq 0$, 区间概率可以化为标准正态积分:

$$\mathbb{P}(|X - \mu| < c\sigma) = \frac{1}{\sqrt{2\pi}} \int_{-c}^c e^{-z^2/2} dz.$$

取 $c = 1, 2, 3$, 分别约为 68.27%, 95.45% 和 99.73%. 因而正态模型中落在 $\mu \pm 3\sigma$ 之外的概率约为 0.27%. 这些数字来自正态密度, 不能只凭其他分布也有均值和标准差就直接使用.

若 X, Y 独立, 分别服从 $\mathcal{N}(\mu_1, \sigma_1^2)$ 与 $\mathcal{N}(\mu_2, \sigma_2^2)$, 则其联合密度是两个密度的乘积. 将乘积沿 $u + (z - u) = z$ 积分, 完成平方可得

$$f_{X+Y}(z) = \int_{\mathbb{R}} f_X(u) f_Y(z-u) du = \frac{\exp\left(-\frac{(z-\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right)}{\sqrt{2\pi(\sigma_1^2+\sigma_2^2)}}.$$

所以

$$X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

这里的独立性使联合密度能够相乘, 只知道两个边缘都正态还不够.

正态分布还有更广的极限意义: 满足适当条件的许多小扰动之和, 在中心化并按其波动尺度归一化以后, 可以趋于正态分布. 后面的中心极限定理将说明准确的条件与收敛方式.


注 3.26 (多元正态分布).

取 $\mu \in \mathbb{R}^n$, 实对称正定矩阵 Σ . 非退化的 n 元正态分布 $\mathcal{N}(\mu, \Sigma)$ 具有密度

$$f(x) = \frac{1}{(2\pi)^{n/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

μ 是均值向量, Σ 是协方差矩阵. 二次型比较的是偏离均值以后, 按不同方向的尺度和相关性调整的距离.

下图画出二维情形的等密度轮廓. 椭圆中心为 μ , 方向及各方向上的伸展程度由 Σ 决定, 图中色阶仅用来区分由内到外的区域.



正密度的等值面由

$$(x - \mu)^\top \Sigma^{-1}(x - \mu) = c$$

给出. 对 $c > 0$, 二维时是椭圆, 高维时是椭球面; $c = 0$ 时缩为均值点.

更一般地, 可以取独立标准正态坐标组成的向量 Z , 并令 $X = \mu + AZ$, 则协方差为 $AA^\top$. 这样也定义了协方差只半正定的多元正态分布. 若 $\Sigma = AA^\top$ 的秩小于 n , 分布集中于 $\mu + \text{range}(A)$ 这个低维仿射子空间, 不具有相对于整个 $\mathbb{R}^n$ 的 Lebesgue 密度, 也不能把不可逆的 Σ 代入前面的密度公式.

注 3.27.

相同实验可以产生不同观测分布. Bernoulli 记录一次结果, 固定独立重复次数并求和得到二项分布, 等到首次成功则得到几何分布. 对 Poisson 过程, 固定时间统计次数得到 Poisson 分布, 固定正整数次数研究等待则得到整数形状 Gamma 分布, 首次等待为指数分布. 一般 Gamma 形状仍不限于整数, 正态分布则还与归一化求和的极限相联系. 使用这些模型时, 应先对应实验与观测方式, 再决定采用哪组参数.

3.3 期望与矩

3.3.1 期望与矩的基本语言

分布给出全部取值事件的概率. 期望和矩则从中提取较少的数, 用来比较平均位置, 波动和极端取值的影响. 它们便于计算, 但保留的信息少于完整分布.

期望按概率对取值加权, 因而直接采用前面的 Lebesgue 积分.

定义 3.28.

在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上, 若实值随机变量 $X \in L^1$, 定义其**期望** (expectation) 为

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P}.$$

这里的可积性保证得到有限实数. 对非负随机变量, 也使用扩展期望

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P} \in [0, \infty],$$

允许结果为 $+\infty$.

一般实值 X 写成 $X^+ - X^-$ 后, 只有当两部的期望不同时为无穷, 才能定义扩展意义的相减. 若两者都有限, 就等价于 $\mathbb{E}[|X|] < \infty$, 即 $X \in L^1$. 正负两边都为无穷时, 不能通过选择某种抵消次序制造一个有限期望.

计算时可以直接在取值空间上积分. 若 $\mu_X = X_*\mathbb{P}$, 对 Borel 可测 g , 在 $g \geq 0$ 或 $g(X)$ 可积的条件下,

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \, d\mu_X(x).$$

这是前推测度的积分公式, 非负情形允许无穷值. 因而同分布变量对同一合适函数 g 有相同的期望, 不需要它们在同一概率空间实现.

离散与有密度的两种计算都是这个公式的特例. 若互不相同的 x_i 承载全部概率, 则

$$\mathbb{E}[X] = \sum_i x_i \mathbb{P}(X = x_i).$$

若存在密度 f_X , 则

$$\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x) \, dx.$$

两式都按前面规定检查期望是否存在. 有限结果等可能时, 第一式才简化为普通算术平均.

积分性质给出: 对 $X, Y \in L^1$ 和 $a, b \in \mathbb{R}$,

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y].$$

这不要求 X, Y 独立. 同样, $X \leq Y$ a.s. 时期望按同一方向比较, 而指示函数满足 $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$.

最后, $|\mathbb{E}[X]| \leq \mathbb{E}[|X|] = \|X\|_1$, 所以期望是 L^1 上的连续线性泛函. 特别地, $X_n \rightarrow X$ 于 L^1 时, $|\mathbb{E}[X_n] - \mathbb{E}[X]| \leq \mathbb{E}[|X_n - X|] \rightarrow 0$. 这里使期望收敛的是对绝对误差的控制, 仅有逐点收敛仍须另加条件.

定义 3.29.

设 $k \geq 1$ 为整数, $X \in L^k$ 为实值随机变量. $\mathbb{E}[|X|^k] = \|X\|_k^k$ 称为 k 阶绝对矩, $\mathbb{E}[X^k]$ 称为 k 阶矩或 k 阶原点矩.

偶数阶时 $X^k = |X|^k$, 两种矩相同. 奇数阶保留正负号, 可以发生抵消, 因而普通矩不能代替绝对矩来衡量取值大小. 绝对矩还可以对任意实数 $p > 0$ 定义; 其中 $p \geq 1$ 且有限时, 与前面的 L^p 范数直接对应.

若 $X \in L^k$, 概率空间有限保证 $X \in L^1$, 所以均值有限, 中心化后仍在 L^k . 相应定义

$$\mathbb{E}[|X - \mathbb{E}[X]|^k] = \|X - \mathbb{E}[X]\|_k^k$$

为绝对中心矩, $\mathbb{E}[(X - \mathbb{E}[X])^k]$ 为中心矩. 前者控制偏离均值的大小, 后者在奇数阶还比较两个方向的贡献.

对 $1 \leq p < q \leq \infty$, 前面的有限测度空间不等式给出 $\|X\|_p \leq \|X\|_q$, 因为 $\mathbb{P}(\Omega) = 1$. 所以控制高阶绝对矩可以同时控制较低阶, 本质有界则保证所有有限阶绝对矩存在. 接下来先看二阶矩怎样形成几何解释.

3.3.2 二阶结构与尾部控制

L^2 空间, 协方差与方差 本小节取实值 L^2 随机变量, 内积为 $\langle X, Y \rangle = \mathbb{E}[XY]$. Cauchy-Schwarz 保证乘积可积, 也保证各变量具有有限期望.

减去均值以后, $X^\circ = X - \mathbb{E}[X]$ 满足 $\langle X^\circ, \mathbf{1} \rangle = 0$. 因而 X 分成常数均值和与常数正交的偏差. 对任意常数 c , 展开平方得到

$$\mathbb{E}[(X - c)^2] = \mathbb{E}[(X - \mathbb{E}[X])^2] + (\mathbb{E}[X] - c)^2,$$

交叉项因中心化后的期望为零而消失. 第二项在且仅在 $c = \mathbb{E}[X]$ 时为零, 所以均值是用常数逼近 X 的唯一最佳均方选择, 也就是向常数函数子空间的正交投影.

定义 3.30.

对实值 $X, Y \in L^2$, 定义协方差

$$\text{Cov}(X, Y) = \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

它把平均位置先去掉, 再计算两个偏差乘积的平均. 展开并使用期望线性性,

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

同向偏离产生正乘积, 反向偏离产生负乘积, 协方差比较这些带幅度的贡献. 协方差为零称为**不相关**, 即中心化后的两个变量正交.

正交仍可能容纳很强的非线性关系. 例如 U 在 $[-1, 1]$ 上均匀分布, 令 $Y = U^2$. 对称性使 $\mathbb{E}[U] = \mathbb{E}[U^3] = 0$, 所以 $\text{Cov}(U, Y) = 0$, 但 Y 完全由 U 决定. 具体地, 事件 $\{Y \leq 1/4\}$ 与 $\{|U| \leq 1/2\}$ 相同, 它们的交集概率为 $1/2$, 与两个独立事件应有的概率乘积 $1/4$ 不同.

将协方差中的两个变量取为同一个, 就得到方差.

定义 3.31.

对实值 $X \in L^2$, 定义方差

$$\text{Var}(X) = \text{Cov}(X, X) = \|X - \mathbb{E}[X]\|_2^2.$$

平方范数非负, 为零当且仅当偏差几乎处处为零, 所以零方差恰好表示 $X = \mathbb{E}[X]$ a.s. 展开平方还得到

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

前面的最佳常数逼近公式因而说明, 方差就是能够达到的最小常数预测均方误差.

定义 3.32.

$X \in L^2$ 的标准差为

$$\text{Std}(X) = \sqrt{\text{Var}(X)} = \|X - \mathbb{E}[X]\|_2.$$

标准差将平方量纲恢复到原变量的尺度. 若将 X 放大 100 倍, 标准差放大 100 倍, 方差则放大 10,000 倍. 协方差对每个变量分别一次齐次, 也会受所用单位影响.

定义 3.33.

对实值 $X, Y \in L^2$, 若两者方差均严格为正, 定义相关系数

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\text{Std}(X) \text{Std}(Y)}.$$

令 $\tilde{X} = (X - \mathbb{E}[X]) / \text{Std}(X)$, 对 Y 同样标准化. 两个变量都成为 L^2 单位向量, 且 $\rho(X, Y) = \langle \tilde{X}, \tilde{Y} \rangle$. Cauchy-Schwarz 于是给出 $|\rho(X, Y)| \leq 1$. 正的单位缩放不改变这个系数; 把一个变量乘以负数则会反转其符号.

方差为零的变量没有上述相关系数, 因为分母为零. 对非退化变量, 相关系数描述标准化偏差的线性关系, 仍不能替代完整联合分布.

尾部与尾部风险 均值和方差没有单独给出极端事件的概率. 要研究超出某个范围的取值, 可以直接观察 $\mathbb{P}(X > x)$, $\mathbb{P}(X < -x)$ 或 $\mathbb{P}(|X| > x)$ 随阈值怎样下降. 远离主要概率质量的这些部分称为分布的**尾部** (tail).

定义 3.34.

实值随机变量 X 的右尾函数或生存函数为

$$\bar{F}_X(x) = \mathbb{P}(X > x) = 1 - F_X(x).$$

分布函数累计不超过阈值的概率, 尾函数则保留超过阈值的概率. 这里严格使用 $>$, 因为有原子时 $\mathbb{P}(X \geq x)$ 还会包含阈值点的质量. 轻尾和重尾有多种正式约定, 下文不选其中一种作总定义, 而直接使用具体的尾概率或渐近式.

尾概率与矩可以相互联系. 对非负 X , 逐点有

$$X(\omega) = \int_0^\infty \mathbf{1}_{\{X(\omega) > t\}} dt.$$

被积函数在概率空间与半轴的乘积上可测且非负, 对它应用 Tonelli, 得到

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt.$$

两边可以同为 $+\infty$, 所以这个等式也能用来判断期望是否有限.

对任意实值 X 和 $p > 0$, 同样使用逐点等式 $|X|^p = \int_0^\infty pt^{p-1} \mathbf{1}_{\{|X| > t\}} dt$, 再用 Tonelli, 得

$$\mathbb{E}[|X|^p] = p \int_0^\infty t^{p-1} \mathbb{P}(|X| > t) dt.$$

因此, 高阶绝对矩要求远端概率在更大的权重 t^{p-1} 下仍可积. 对 $p \geq 1$, 这正是 L^p 可积性的尾积分表达.

例如正态密度的指数衰减能够压过任意固定幂次, 因而各个正阶绝对矩都有限. 若更具体地假设 $\mathbb{P}(|X| > x) \sim Cx^{-\alpha}$, 其中 $C > 0, \alpha > 0$, 则大阈值处的积分与 $\int_1^\infty t^{p-1-\alpha} dt$ 同敛散. 小阈值部分因尾概率不超过一而总是有限, 所以绝对矩恰在 $0 < p < \alpha$ 时有限, $p \geq \alpha$ 时发散.

即使前两阶矩相同, 较远处的概率仍可不同. 例如各以一半概率取 ± 1 的变量, 与以 0.9 概率取 0, 各以 0.05 概率取 $\pm\sqrt{10}$ 的变量, 均值都为零, 方差都为一, 后者却有 0.1 的概率满足 $|X| > 2$. 只报告均值与方差没有保留这项差别.

反过来, 已知一个矩时, 也能对尾概率给出普遍上界.

定理 3.35 (Markov 不等式).

若 $X \geq 0$ 可积, $a > 0$, 则

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

证明. 逐点有 $X \geq a \mathbf{1}_{\{X \geq a\}}$. 取期望得到 $\mathbb{E}[X] \geq a \mathbb{P}(X \geq a)$, 再除以 $a > 0$. $\square$

对 $1 \leq p < \infty$ 和 $X \in L^p$, 将不等式用于非负变量 $|X|^p$ 和阈值 a^p , 得到

$$\mathbb{P}(|X| \geq a) \leq \frac{\mathbb{E}[|X|^p]}{a^p} = \frac{\|X\|_p^p}{a^p}.$$

前面的尾积分给出矩的精确表示, 这里则从一个有限矩得到概率上界. 两种结论用途不同: 尾概率的大阈值上界不必精确到足以恢复全部矩.

定理 3.36 (Chebyshev 不等式).

若实值 $X \in L^2$ 且 $a > 0$, 则

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

证明. 将 Markov 不等式用于非负可积变量 $(X - \mathbb{E}[X])^2$ 和阈值 a^2 . 该变量的期望就是方差, 而至少为 a^2 的事件恰好是 $\{|X - \mathbb{E}[X]| \geq a\}$. $\square$

若标准差为 $\sigma > 0$, 取 $a = k\sigma$ 就得到不超过 $1/k^2$ 的界. 它适用于任意有限方差分布, 因而通常比正态密度算出的概率宽松得多. 后面的大数定律和过程估计, 会反复用这种办法把积分误差转成超出阈值的概率.

金融研究常将可能结果分成若干经营情景, 以便分别分析收入, 成本或融资条件. 设 V 是某个未来时点的价值, 乐观 (Bull), 基准 (Base), 悲观 (Bear) 和尾部 (Tail) 是研究者为具体问题选取的分类, 并不是概率论规定的四种标准状态.

要把分类用于加权计算, 先要求有限个事件 $A_1, \dots, A_m$ 两两不交且覆盖全空间, 再给每项选一个有限代表值 V_i . 由此得到简单随机变量

$$\tilde{V} = \sum_{i=1}^m V_i \mathbf{1}_{A_i}, \quad \mathbb{E}[\tilde{V}] = \sum_{i=1}^m \mathbb{P}(A_i) V_i.$$

这个等式精确计算的是所选近似变量的期望. 每个情景内部可能仍有广泛取值, 任意选一个代表值并不会让它自动等于原来的 $\mathbb{E}[V]$.

若 $V \in L^1$, 可以进一步比较

$$|\mathbb{E}[V] - \mathbb{E}[\tilde{V}]| \leq \mathbb{E}[|V - \tilde{V}|].$$

它说明近似期望的误差由各情景内没有保留的取值差异控制. 若希望总期望严格相同, 对每个正概率情景取

$$V_i = \frac{\mathbb{E}[V \mathbf{1}_{A_i}]}{\mathbb{P}(A_i)}.$$

零概率情景的代表值可以任取有限数, 例如取零. 此时按分区相加就有

$$\mathbb{E}[\tilde{V}] = \sum_i \mathbb{E}[V \mathbf{1}_{A_i}] = \mathbb{E}[V].$$

这正是后面有限信息条件期望的一个例子. 但它只保住总期望, 没有同时保住全部方差和情景内部的尾部.

尾部风险需要把发生概率与发生后的损失幅度一起研究. 将一个区域叫作 Tail, 仍要说明其中可能有多大损失, 以及什么事实支持所用概率. 后续的风险价值 (Value at Risk, VaR), 预期短缺 (Expected Shortfall, ES) 等度量, 将进一步指定从损失分布中提取什么信息.

3.4 独立性, 条件概率与条件期望

3.4.1 独立性与条件概率

事件与随机变量的独立性 联合分布记录多个观测怎样同时出现. 其中一种特殊情形是, 得知一个事件发生, 并不改变另一个事件的概率. 例如把未来一个月股票上涨记为 A , 下次财报超出预期记为 B , 可以比较给定 B 前后对 A 的判断. 是否相同要由联合概率决定, 不能只根据两件事的名称判断.

独立性的定义直接使用概率乘法, 因而即使某个事件概率为零, 仍然有意义.

定义 3.37.

令 $A, B \in \mathcal{F}$ 为事件. 称 A 与 B **相互独立**, 是指其满足

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

当 $\mathbb{P}(B) > 0$ 时, 除以 $\mathbb{P}(B)$ 就得到后面条件概率意义下的 $\mathbb{P}(A | B) = \mathbb{P}(A)$. 如果 $\mathbb{P}(B^c) > 0$, 对补事件也有相同结论. 因而独立性同时处理知道 B 发生和知道它不发生这两种信息.

对多项事件, 只检查每一对还不够, 需要检查任意有限子族的交.

定义 3.38.

令 $(A_i)_{i \in I}$ 为一族事件. 称它们**相互独立**, 是指对于任意不同的 $i_1, \dots, i_n \in I$ 都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

只检查任意两个事件, 得到的是**两两独立**. 例如独立抛两次公平硬币, 令 A 为第一次正面, B 为第二次正面, C 为两次结果相同. 三个事件的概率都为 $1/2$, 任意两者交的概率都为 $1/4$, 但

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

知道前两次结果以后, 是否相同已被确定, 这项依赖没有被两两比较排除.

随机变量的独立性需要比较它们能够辨认的全部事件. 用 $\sigma(X_i)$ 表示第 i 个观测的信息, 对来自不同这些 σ -代数的事件应用同一乘法条件, 就得到随机变量的独立性.

定义 3.39.

令 $(X_i)_{i \in I}$ 为定义在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的一族随机元素. 称它们**相互独立**, 是指任意有限子族都满足下面第一条. 在实值情形中, 第一条还等价于后两条:

1. 对于任意不同的 $i_1, \dots, i_n \in I$ 以及任意 $A_{i_k} \in \sigma(X_{i_k})$, 都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

2. 对于实值随机变量 $X_1, \dots, X_n$, 等价地, 任意 Borel 集 $B_1, \dots, B_n \subseteq \mathbb{R}$ 都满足

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i).$$

3. 如果记 $X = (X_1, \dots, X_n)$, 那么从分布的角度来看, 独立性又等价于联合分布分解成各个边缘分布的乘积:

$$\mu_X = \mu_{X_1} \otimes \cdots \otimes \mu_{X_n}.$$

因此独立性也可以理解成: 联合分布里面没有超出各个边缘分布之外的额外依赖结构.

前两种表述等价, 因为 $\sigma(X_i)$ 的事件正是相应 Borel 集合的原像. 第二种表述又说明联合分布与乘积分布在所有矩形上一致. 矩形构成生成乘积 σ -代数的 π -系, 两个测度的总质量都为一, 所以 π - λ 定理给出第三种表述; 反向只需在矩形上取值.

独立性还允许分开计算乘积期望. 若实值 $X, Y \in L^1$ 独立, 对联合乘积分布使用 Tonelli, 有

$$\mathbb{E}[|XY|] = \mathbb{E}[|X|]\mathbb{E}[|Y|] < \infty.$$

再用 Fubini 得到 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. 特别地, 独立的 L^2 变量协方差为零.

不相关一般只排除二阶线性联系, 前面的 U 与 U^2 就仍有确定的函数关系. 联合正态是一个特殊情形: 两个非退化坐标不相关时, 协方差矩阵为对角形式, 联合密度分解为两个边缘密度的乘积, 从而独立. 若其中一个方差为零, 它几乎必然为常数, 结论也成立.

条件概率与 Bayes 公式 知道事件 B 发生以后, 只保留 B 中的结果, 再把这些结果的总概率归一化为一. 这给出对单个正概率事件条件化的定义.

定义 3.40.

对 $A, B \in \mathcal{F}$ 且 $\mathbb{P}(B) > 0$, 定义**条件概率**

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

固定 B 后, $A \mapsto \mathbb{P}(A | B)$ 可列可加, 在全空间上取一, 因而仍是概率测度. 它把质量全部放在 B 内, 又保留了原来各部分之间的相对权重. 分母为零时, 这个比值没有定义, 后面的正则条件分布会采用不同办法处理连续观测.

定理 3.41 (Bayes 公式).

若 $\mathbb{P}(A), \mathbb{P}(B) > 0$, 则

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}.$$

证明. 同一个交事件满足 $\mathbb{P}(A | B)\mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B | A)\mathbb{P}(A)$. 除以正数 $\mathbb{P}(B)$ 即得结论. $\square$

公式用 $\mathbb{P}(B | A)$ 衡量在 A 成立时见到证据 B 有多常见, 再结合原来的 $\mathbb{P}(A)$ 调整权重. 更新所需的条件概率来自同一联合模型, 不是见到证据后任意改变原先数字.

若有限或可数个可测集 (B_i) 两两不交并覆盖 Ω , 则 $A = \bigsqcup_i (A \cap B_i)$. 可列可加性给出**全概率公式**

$$\mathbb{P}(A) = \sum_{i: \mathbb{P}(B_i) > 0} \mathbb{P}(A | B_i)\mathbb{P}(B_i).$$

零概率的分块对 A 没有贡献, 可以略去, 无须为它写下一个未定义的条件概率.

情景分析可以采用这项分解. 各情景先组成不交且完整的分区, 总体概率再由情景权重和情景内部的条件概率相加. 收到新财报或行业信息后, Bayes 公式则比较该证据在各情景中出现的可能性, 由此得到更新后的权重.

例 3.42 (DSpark 中的条件概率).

DeepSeek 的 DSpark 系统使用投机解码 (speculative decoding): 草稿模型先生成候选文本, 目标模型再验证候选, 以减少昂贵模型逐步生成的工作 [Che+26]. 一段草稿能继续保留多长, 取决于前缀是否已经通过, 因而各位置需要使用沿前缀条件化的概率.

令 A_k 为第 k 个草稿词元最终被接受的事件. 系统估计

$$c_k \approx \mathbb{P}(A_k | A_1 \cap \cdots \cap A_{k-1}),$$

第一个位置将空前缀理解为全空间. 在此前前缀的概率为正时, 反复使用条件概率定义, 得到精确的乘法关系

$$\mathbb{P}\left(\bigcap_{i=1}^k A_i\right) = \prod_{i=1}^k \mathbb{P}\left(A_i \mid \bigcap_{j<i} A_j\right).$$

它没有假设各位置独立, 每个因子已经包含前面的接受条件.

将这些因子换成估计值, 得到前缀存活概率 (prefix survival probability) 的估计

$$a_k = \prod_{i=1}^k c_i \approx \mathbb{P}(A_1 \cap \cdots \cap A_k).$$

若某个前缀本身概率为零, 更长前缀的概率也已为零, 不再通过除以零来定义后续条件概率. 调度器结合估计的前缀存活概率和硬件负载安排验证工作. 这个例子中的概率乘法来自条件化, 实际估计误差则来自各 c_i 与相应条件概率之间的差异.

3.4.2 条件期望

定义与存在性 已知信息通常不止一个事件. 观察完截至某时刻的价格和成交量以后, 可以判断许多事件是否发生, 这些可辨认事件组成一个子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$.

给定可积的 X , 希望用只依赖 $\mathcal{G}$ 的变量描述它的条件平均. 若 $\mathcal{G}$ 无法区分两个结果, 所作预测就不能使用这两个结果之间尚未观察到的差别.

对可积随机变量及事件 B , 沿用记号

$$\mathbb{E}[X; B] = \mathbb{E}[X\mathbf{1}_B] = \int_B X \, d\mathbb{P}.$$

我们寻找可积的 Y , 要求它 $\mathcal{G}$ -可测, 并在每个 $B \in \mathcal{G}$ 上保留原积分:

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

可测性规定能使用哪些信息, 积分等式规定在这些信息能够分出的每一部分里, 预测没有改变总的平均贡献. 只保留全空间期望还不够, 因为那样无法限制各个可辨认事件中的预测.

先比较两个候选, 再通过 Radon–Nikodym 定理构造它.

命题 3.43 (唯一性).

令 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 假设 $Y, Z \in L^1(\Omega, \mathbb{P})$ 都是 $\mathcal{G}$ -可测的, 并且对于任意 $B \in \mathcal{G}$ 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B] = \mathbb{E}[Z; B].$$

则 $Y = Z$ a.s.

证明. 令 $W = Y - Z$. 因为 W 为 $\mathcal{G}$ -可测, 所以 $B_+ = \{W > 0\}$ 和 $B_- = \{W < 0\}$ 都属于 $\mathcal{G}$.

由假设有 $\mathbb{E}[W; B_+] = 0$, 而 $W\mathbf{1}_{B_+} \geq 0$, 所以 $W\mathbf{1}_{B_+} = 0$ a.s. 由于 $W > 0$ 在 B_+ 上成立, 这推出 $\mathbb{P}(B_+) = 0$. 对 B_- 同理, 因而 $W = 0$ a.s. $\square$

存在性利用一个直接联系: $B \mapsto \mathbb{E}[X; B]$ 在较小的事件域 $\mathcal{G}$ 上仍然可列可加. 分别处理正负部, 就能对这个事件域上的有限测度使用密度定理.

定理 3.44 (条件期望的存在性).

若实值 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数, 则存在 $\mathcal{G}$ -可测的 $Y \in L^1$, 使每个 $B \in \mathcal{G}$ 满足

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

证明. 在 $(\Omega, \mathcal{G})$ 上定义非负有限测度

$$\nu_+(B) = \mathbb{E}[X^+; B], \quad \nu_-(B) = \mathbb{E}[X^-; B].$$

概率为零的集合上两项积分都为零, 因而 $\nu_+, \nu_- \ll \mathbb{P}|_{\mathcal{G}}$. Radon–Nikodym 定理给出非负 $\mathcal{G}$ -可测密度 U, V , 满足

$$\nu_+(B) = \int_B U \, d\mathbb{P}, \quad \nu_-(B) = \int_B V \, d\mathbb{P}.$$

它们的总积分分别为有限的 $\mathbb{E}[X^+]$ 与 $\mathbb{E}[X^-]$, 所以都几乎处处有限. 在共同的 $\mathcal{G}$ -可测例外零测集上将两者改零, 就能处处定义实值函数 $Y = U - V$. 又有 $|Y| \leq U + V$, 故 $Y \in L^1$. 对任意 $B \in \mathcal{G}$, 两项积分均有限, 因而可相减得到

$$\int_B Y \, d\mathbb{P} = \nu_+(B) - \nu_-(B) = \mathbb{E}[X; B].$$

这就是所需函数. $\square$

结合前面的唯一性, 可以把这个确定到几乎必然相等的变量定义为条件期望.

定义 3.45.

令 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 称随机变量 $Y \in L^1(\Omega, \mathbb{P})$ 为 X 关于 $\mathcal{G}$ 的**条件期望**, 是指其满足:

1. Y 是 $\mathcal{G}$ -可测的;
2. 对于任意 $B \in \mathcal{G}$, 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

这样的 Y 存在且在 a.s. 意义下唯一, 记作

$$Y = \mathbb{E}[X | \mathcal{G}].$$

条件期望本身是随机变量, 因为不同观测会给出不同条件平均. 条件在一个正概率事件上时, 则得到一个数, 记为

$$\mathbb{E}[X | B] = \frac{\mathbb{E}[X \mathbf{1}_B]}{\mathbb{P}(B)}, \quad \mathbb{P}(B) > 0.$$

这两种写法在有限分割中直接联系起来.

设非空可测集 $B_1, \dots, B_n$ 两两不交并覆盖 Ω , 取 $\mathcal{G} = \sigma(B_1, \dots, B_n)$. 这个 σ -代数的每个事件都是若干 B_i 的并, 因而各 B_i 是它不能再细分的**原子**. $\mathcal{G}$ -可测实值函数必须在每个原子上取常数, 否则某条实数半直线的原像就会把该原子分开.

若条件期望在 B_i 上取值 c_i , 定义要求 $c_i \mathbb{P}(B_i) = \mathbb{E}[X \mathbf{1}_{B_i}]$. 因此在正概率原子上, 常数只能取相应平均值. 取零概率原子上的常数为零, 得到一个版本

$$\mathbb{E}[X | \mathcal{G}] = \sum_{i: \mathbb{P}(B_i) > 0} \mathbb{E}[X | B_i] \mathbf{1}_{B_i}.$$

对这些原子的任意并积分, 两边都与 X 相同, 所以这确实满足完整定义. 零概率原子也可以取别的有限常数, 保持可测性并不改变积分.

例如四个等概率结果上, X 依次取 0, 2, 4, 10. 若观测只能辨认前两个结果和后两个结果, 条件期望便分别为 1 和 7. 整体期望仍为 4, 但预测已经利用观测区分了两组结果. 情景分析若只提供所属情景的信息, 也采用同样的组内平均.

没有额外信息时, $\mathcal{G} = \{\emptyset, \Omega\}$, 只有全空间这一个原子, 得到常数 $\mathbb{E}[X]$. 若 X 已经 $\mathcal{G}$ -可测, 它自身就满足两个定义条件, 因而 $\mathbb{E}[X | \mathcal{G}] = X$ a.s.

基本性质与均方投影 下面各项都可以通过可测性与事件上的积分等式验证. 全部随机变量取实值, 线性组合中的系数为实常数, 条件期望等式均按几乎必然相等理解. X 与 $\mathcal{G}$ 独立, 指 $\sigma(X)$ 中的事件与 $\mathcal{G}$ 中的事件满足独立性条件.

命题 3.46 (条件期望的基本性质).

令 $X, Y \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 在相应表达式有意义时, 有:

- **线性性:** $\mathbb{E}[aX + bY | \mathcal{G}] = a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]$.
- **单调性:** 如果 $X \leq Y$ a.s., 那么 $\mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[Y | \mathcal{G}]$ a.s.
- **保留期望:** $\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]$.
- **已知量可以提出:** 如果 Z 是有界的 $\mathcal{G}$ -可测随机变量, 那么 $\mathbb{E}[XZ | \mathcal{G}] = Z\mathbb{E}[X | \mathcal{G}]$.
- **塔性质:** 如果 $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$, 那么

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}].$$

- **独立性:** 如果 X 与 $\mathcal{G}$ 独立, 那么 $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X]$ a.s.

证明. 线性组合保持可测与可积, 在每个 $B \in \mathcal{G}$ 上积分后又保持定义等式, 所以唯一性给出线性性. 对非负可积变量 W , 若 $M = \mathbb{E}[W | \mathcal{G}]$ 在事件 $B = \{M < 0\}$ 上为负, 则 $\mathbb{E}[M; B] = \mathbb{E}[W; B] \geq 0$. 而 $M \mathbf{1}_B \leq 0$, 只能在该处几乎必然为零, 故 $\mathbb{P}(B) = 0$. 将此用于 $Y - X$ 并使用线性性, 得到单调性. 保留期望直接取定义中的 $B = \Omega$.

对提出已知量, 先取 $Z = \mathbf{1}_A$, $A \in \mathcal{G}$. 对每个 $B \in \mathcal{G}$,

$$\mathbb{E}[Z\mathbb{E}[X | \mathcal{G}]; B] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}]; A \cap B] = \mathbb{E}[XZ; B].$$

因而唯一性给出结论. 有限线性组合推广到简单 Z ; 对有界可测 Z , 取一致有界的简单函数逐点逼近, 分别以常数倍的 $|X|$ 与 $|\mathbb{E}[X | \mathcal{G}]|$ 控制, 再在每个 B 上使用控制收敛.

对塔性质, 令 $M = \mathbb{E}[X | \mathcal{G}]$. $\mathbb{E}[M | \mathcal{H}]$ 是 $\mathcal{H}$ -可测的, 且每个 $B \in \mathcal{H} \subseteq \mathcal{G}$ 都满足

$$\mathbb{E}[\mathbb{E}[M | \mathcal{H}]; B] = \mathbb{E}[M; B] = \mathbb{E}[X; B].$$

所以它是 $\mathbb{E}[X | \mathcal{H}]$ 的版本. 最后, 若 X 与 $\mathcal{G}$ 独立, 对每个 $B \in \mathcal{G}$, 乘积期望公式给出 $\mathbb{E}[X\mathbf{1}_B] = \mathbb{E}[X]\mathbb{P}(B)$. 常数 $\mathbb{E}[X]$ 因而满足定义. $\square$

塔性质中的包含方向很重要. 先按较丰富的信息 $\mathcal{G}$ 取平均, 再只保留较少的信息 $\mathcal{H}$, 与直接使用 $\mathcal{H}$ 相同. 若两组信息没有这种包含关系, 上述积分比较就没有同样的依据.

普通 Jensen 不等式也有完全对应的条件版本.

定理 3.47 (条件 Jensen 不等式).

令 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 为凸函数, 并假设 $X \in L^1$ 且 $\varphi(X) \in L^1$. 则

$$\varphi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\varphi(X) | \mathcal{G}] \quad \text{a.s.}$$

证明. 实线上处处有限的凸函数可以写成可列族支撑直线的上确界:

$$\varphi(x) = \sup_{j \geq 1} (a_j x + b_j).$$

例如在各有理点选取支撑直线, 由凸函数的连续性即可恢复整个函数. 对每个 j , 有 $a_j X + b_j \leq \varphi(X)$. 条件期望的单调性与线性性给出

$$a_j \mathbb{E}[X | \mathcal{G}] + b_j \leq \mathbb{E}[\varphi(X) | \mathcal{G}] \quad \text{a.s.}$$

将这可列个例外零测集合并, 再对 j 取上确界, 就得到所需不等式. 其左边又有任意一条支撑直线作为可积下界, 右边为可积上界, 因而 $\varphi(\mathbb{E}[X | \mathcal{G}])$ 也可积. $\square$

对 $1 \leq p < \infty$ 和 $X \in L^p$, 取 $\varphi(x) = |x|^p$, 得

$$|\mathbb{E}[X | \mathcal{G}]|^p \leq \mathbb{E}[|X|^p | \mathcal{G}] \quad \text{a.s.}$$

再取期望并使用保留期望性质, 就有 $\|\mathbb{E}[X | \mathcal{G}]\|_p \leq \|X\|_p$. $p = \infty$ 另用本质上界: 若 $|X| \leq M$ a.s., 单调性给出 $|\mathbb{E}[X | \mathcal{G}]| \leq M$ a.s. 取最小本质上界后, 同样得到无穷范数估计.

因此, 条件平均在每个 $1 \leq p \leq \infty$ 的范数中都不会增大大小. 这个结论也适用于两个变量的差, 可用来控制条件平均对输入误差的响应.

事件的条件概率可以作为指示变量的条件期望定义:

$$\mathbb{P}(A | \mathcal{G}) = \mathbb{E}[\mathbf{1}_A | \mathcal{G}].$$

单调性使它落在 $[0, 1]$ 内, 至多需要修改一个 $\mathcal{G}$ -可测零测集上的取值. 若 $\mathcal{G}$ 由 B, B^c 生成, 在正概率原子 B 上的值正是此前的 $\mathbb{P}(A | B)$.

给定一个随机变量 Y 时, 使用的是它能辨认的信息, 因而约定 $\mathbb{E}[X | Y] = \mathbb{E}[X | \sigma(Y)]$. 这仍是随机变量, 随实际观察到的 Y 改变, 与在某个指定正概率事件上得到的常数平均应分开.

平方可积时, 条件平均还满足一个准确的最优性质.

命题 3.48 (条件期望的均方投影).

若实值 $X \in L^2$, 令 $M = \mathbb{E}[X | \mathcal{G}]$. 则 $M \in L^2(\Omega, \mathcal{G}, \mathbb{P})$, 且对任意 $Y \in L^2(\Omega, \mathcal{G}, \mathbb{P})$,

$$\|X - Y\|_2^2 = \|X - M\|_2^2 + \|M - Y\|_2^2.$$

因而 M 是仅使用 $\mathcal{G}$ 信息时唯一到 a.s. 相等的最佳均方预测.

证明. 条件 Jensen 保证 $M \in L^2$. 定义先给出 $\mathbb{E}[(X - M)\mathbf{1}_B] = 0$ 对所有 $B \in \mathcal{G}$ 成立, 再由简单函数逼近推广到所有有界 $\mathcal{G}$ -可测变量 Z . 对任意 $Z \in L^2(\mathcal{G})$, 截断 Z 得到有界变量 $Z_n \rightarrow Z$ 于 L^2 . Cauchy-Schwarz 给出

$$|\mathbb{E}[(X - M)(Z_n - Z)]| \leq \|X - M\|_2 \|Z_n - Z\|_2 \rightarrow 0.$$

所以 $X - M$ 与整个 $L^2(\mathcal{G})$ 正交. 在 $X - Y = (X - M) + (M - Y)$ 中展开平方范数, 交叉项为零, 得到等式. 第二项在且仅在 $Y = M$ a.s. 时为零, 因而最优解唯一. $\square$

$L^2(\mathcal{G})$ 在 $L^2(\mathcal{F})$ 中还是闭子空间: 它作为自身的 L^2 空间完备, 而嵌入保持范数. 因而这里确实是 Hilbert 空间中的正交投影. 普通期望对应只允许常数预测的特例.

随机过程用滤过 $(\mathcal{F}_t)$ 记录逐步积累的信息. 若未来变量 X_{t+s} 可积, $\mathbb{E}[X_{t+s} | \mathcal{F}_t]$ 给出当前信息下的条件平均; 若还平方可积, 它同时具有上述最佳均方性质. Markov 过程和鞅将分别对这种条件信息关系提出进一步要求.

3.4.3 正则条件分布

条件平均没有记录所有可能结果. 当前对下一日价格的平均预测相同, 上涨 10% 或跌破某个价位的概率仍可能不同. 要同时计算各个取值事件, 就需要把条件概率组织成一整个概率测度.

定义 3.49.

设 $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{E})$ 为随机元素, $\mathcal{G} \subseteq \mathcal{F}$. X 关于 $\mathcal{G}$ 的**正则条件分布**是 Markov 核

$$K: \Omega \times \mathcal{E} \rightarrow [0, 1],$$

满足每个 $A \in \mathcal{E}$ 的 $K(\cdot, A)$ 都是 $\mathbb{E}[\mathbf{1}_{\{X \in A\}} | \mathcal{G}]$ 的版本. 核的含义是: 对每个 ω , $K(\omega, \cdot)$ 为概率测度; 对每个 A , $K(\cdot, A)$ 为 $\mathcal{G}$ -可测函数.

第一项把给定信息后的所有取值概率放在同一个测度中, 第二项保证这个测度随观测变化时仍可测. 与逐个事件各选一个条件期望版本相比, 核还要求这些选择彼此相容.

核也给出条件期望的积分表示. 若 f 可测且 $f(X)$ 可积, 则

$$\mathbb{E}[f(X) | \mathcal{G}](\omega) = \int_E f(x) K(\omega, dx) \quad \text{a.s.}$$

对指示函数, 这正是定义. 有限线性组合得到简单函数情形, 再以单调收敛推广到非负函数. 对可积的实值 $f(X)$, 先对 $|f|$ 积分确认内层积分几乎处处有限, 再分别处理正负部. 例外零测集上的值可取零, 得到可积版本.

非负函数的同一公式还允许结果为 $+\infty$. 这时将非负条件期望定义为截断后的条件期望递增极限; 对每个 $B \in \mathcal{G}$ 使用单调收敛, 就能验证相应积分关系.

给定随机元素 Y 时, 还希望将核写成实际观测值 y 的函数. 若可找到 $K: S \times \mathcal{E} \rightarrow [0, 1]$ 使 $\mathbb{P}(X \in A | \sigma(Y)) = K(Y, A)$ a.s., 就通常记为

$$K(y, A) = \mathbb{P}(X \in A | Y = y).$$

这是条件概率的一个核表示, 不使用除以 $\mathbb{P}(Y = y)$ 的比值. 因而连续观测中单点概率为零, 也仍可采用这种记号.

定理 3.50 (标准 Borel 值域中的正则条件分布).

若 $(E, \mathcal{E})$ 是标准 Borel 空间, 则随机元素 X 对任意子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$ 的正则条件分布存在. 若 Y 取值于标准 Borel 空间 $(S, \mathcal{S})$, 则可以选择 Markov 核 $K: S \times \mathcal{E} \rightarrow [0, 1]$, 对每个 $A \in \mathcal{E}$ 满足

$$\mathbb{P}(X \in A \mid \sigma(Y)) = K(Y, A) \quad \text{a.s.}$$

两个这样的核在 $\mathcal{L}(Y)$ -a.e. 的 y 上作为概率测度相等.

证明. 先令 X 实值. 对每个有理数 q 选取 $H_q = \mathbb{E}[\mathbf{1}_{\{X \leq q\}} \mid \mathcal{G}]$. 单调性给出 $0 \leq H_q \leq 1$ 以及 $q < r$ 时 $H_q \leq H_r$, 均 a.s. 成立. 有界单调序列的条件期望可以作相应单调极限: 对每个 $B \in \mathcal{G}$ 使用积分单调收敛, 再验证条件期望定义即可. 因而还可保证

$$\lim_{m \rightarrow \infty} H_{-m} = 0, \quad \lim_{m \rightarrow \infty} H_m = 1, \quad H_q = \inf_{r \in \mathbb{Q}, r > q} H_r$$

对各个有理 q 几乎必然成立. 所有这些要求只有可列多个, 可以将其例外集合合成一个 $\mathcal{G}$ -可测零测集 N .

对 $\omega \notin N$, 定义

$$F_\omega(x) = \inf_{q \in \mathbb{Q}, q > x} H_q(\omega).$$

它单调, 右连续, 在负无穷和正无穷分别趋于零和一, 因而由上一节的分布函数定理确定概率测度 $K(\omega, \cdot)$. 在 N 上统一取 δ_0 . 有理半直线上的核值是原来的 H_q , 所以具有所需可测性与条件积分关系. 满足这两项性质的 Borel 集合组成 λ -系, 又包含有理半直线 π -系, 因而 π - λ 定理将它们推广到全部 Borel 集. 这证明实值情形.

标准 Borel 空间可测同构于实线的某个 Borel 子集. 将 X 经该同构送入实线, 使用已构造的条件分布. 该分布几乎必然将全部质量放在此 Borel 子集上, 在例外零测集上改为子集内一个固定点的 Dirac 测度后, 再经逆同构搬回 E . 因而得到一般标准 Borel 值域的结论.

对 $\mathcal{G} = \sigma(Y)$, 每个实值 $\sigma(Y)$ -可测函数都能写成 Y 的可测函数, 所以可以将上述有理端点的 H_q 同时写成 $h_q(Y)$. 在 S 上删除这些可列条件失效的 $\mathcal{L}(Y)$ -零测集, 再作同样的分布函数构造与例外修补, 就得到以 y 为输入的核. 最后, 标准 Borel 空间具有可数的生成 π -系. 两个核在这些生成集上由条件期望唯一性同时相等等于一个共同零测集之外, 再以概率测度唯一性推广到全部集合, 得到所述的核唯一性. $\square$

这个构造依赖的是可数生成与标准 Borel 的可测同构性质, 不要求原概率空间本身是标准 Borel 空间. 相应结果及测度分解的表述见 [Kal21, Theorem 8.5, Theorem 3.4] 或 [Dur19, Theorems 4.1.17–4.1.18].

唯一性仍只到观测分布的零测集. 对一个满足 $\mathbb{P}(Y = y) = 0$ 的指定点, 可以改变该点上的概率测度而不改变条件积分关系. 若要赋予该点一个特别选定的条件分布, 还须使用连续性等额外条件.

实值变量 (X, Y) 若有非负联合密度 $f_{X,Y}$, 先取 $f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx$. Tonelli 保证这是边缘密度, 且有限正值的集合承载 Y 的全部概率. 在该集合上定义

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad 0 < f_Y(y) < \infty.$$

它对 x 的积分为一. 对其他 y 选取一个固定概率测度, 就能补成核. 对 Borel 集 A, B 使用 Fubini 或 Tonelli, 得到

$$\int_B K(y, A) f_Y(y) dy = \int_B \int_A f_{X,Y}(x, y) dx dy = \mathbb{P}(X \in A, Y \in B).$$

所以这个条件密度确实给出正则条件分布的版本, 其逐点选取也保留同样的零测集自由度.

在过程问题中, 未来价格的条件均值不能替代涨跌和其他取值事件的条件概率. 若状态空间标准 Borel, 可以用正则条件分布统一描述给定 $\mathcal{F}_s$ 以后 X_t 的规律.

Markov 性质进一步要求, 对固定 $s < t$, 全部已有信息提供的一步预测只需当前状态 X_s 就能取得. 在相应可测条件下, 写成转移核

$$\mathbb{P}(X_t \in A \mid \mathcal{F}_s) = P_{s,t}(X_s, A) \quad \text{a.s.}$$

核的存在用于组织条件概率, 只依赖当前状态则是额外的 Markov 要求. 选择哪些变量作为当前状态, 决定了这一要求是否适合所研究的过程.

3.5 随机变量的收敛与极限定理

3.5.1 收敛概念

从前推测度到随机变量的收敛 第3.2.1小节区分了随机变量与其分布 $\mathcal{L}(X) = X_*\mathbb{P}$. 讨论序列 X_n 的极限时, 这一区别仍然重要. 可以只比较各自分布, 也可以在共同概率空间中比较 $X_n - X$, 还可以固定一次实现, 查看整条数列是否收敛.

下面先分别定义这些要求, 再证明它们之间的联系. 连续映射和 Slutsky 处理对收敛序列作运算, 大数定律和中心极限定理则分别研究平均值的位置与缩放后的随机波动.

概率测度的弱收敛 先考虑实线上的概率测度 μ_n, μ . 质量从 $1/n$ 移到 0, 位置变化越来越小, 但集合 $\{0\}$ 上的概率会突然从零变成一. 因而要求所有 Borel 集合上的概率都收敛, 会排除这种自然的位置极限.

改用有界连续函数作观测, 可以同时避免跳变测试和无穷积分. 连续性保证微小的位置变化引起相应的函数值变化, 有界性则防止少量远端质量在测试中被任意放大.

定义 3.51.

对 $\mathbb{R}$ 上的概率测度 μ_n, μ , 若每个有界连续实函数 f 都满足

$$\int_{\mathbb{R}} f d\mu_n \rightarrow \int_{\mathbb{R}} f d\mu,$$

则称 μ_n 弱收敛到 μ , 记为 $\mu_n \Rightarrow \mu$.

这比较的是每个固定连续观测的积分, 没有要求对所有测试函数的误差一致趋于零. 此处收敛的对象为概率测度, 与 L^p 中函数的弱收敛应按各自定义使用.

集合概率仍能从中恢复一部分. 关键在于集合边界是否承载极限测度的质量: 质量落在边界时, 从两边接近会产生不同的归属; 边界质量为零时, 这种差异可以消失.

定理 3.52 (Portmanteau 定理的一些形式).

对 $\mathbb{R}$ 上的概率测度 μ_n, μ , 以下条件等价:

1. $\mu_n \Rightarrow \mu$;
2. 对每个开集 G , $\liminf_n \mu_n(G) \geq \mu(G)$;
3. 对每个闭集 F , $\limsup_n \mu_n(F) \leq \mu(F)$;
4. 对每个满足 $\mu(\partial A) = 0$ 的 Borel 集 A , $\mu_n(A) \rightarrow \mu(A)$.

证明. 先由第一项推出第三项. 空闭集无需处理, 对非空闭集 F 取

$$f_m(x) = \max\{1 - m d(x, F), 0\}.$$

距离函数连续, 所以 f_m 有界连续, 且 $\mathbf{1}_F \leq f_m \downarrow \mathbf{1}_F$. 固定 m 先令 $n \rightarrow \infty$, 得 $\limsup_n \mu_n(F) \leq \int f_m d\mu$; 再令 $m \rightarrow \infty$ 并用控制收敛, 得到闭集上界. 对补集使用总质量为一, 可见第二与第三项等价. 它们再对 $A^\circ \subseteq A \subseteq \bar{A}$ 给出两侧夹逼, 当边界为零测集时便得到第四项.

第二项也能推出第一项. 先取连续函数 $0 \leq f \leq M$. 层集 $\{f > t\}$ 是开集, 尾积分公式与 Fatou 给出

$$\begin{aligned} \liminf_n \int f d\mu_n &= \liminf_n \int_0^M \mu_n(f > t) dt \\ &\geq \int_0^M \mu(f > t) dt = \int f d\mu. \end{aligned}$$

对 $M - f$ 使用同一结论得到反向的上极限不等式, 因而积分收敛. 一般有界连续实函数加上常数即可化为非负情形.

最后由第四项推出第一项. 对同样的 $0 \leq f \leq M$, 连续性保证 $\partial\{f > t\} \subseteq \{f = t\}$. 一个概率测度至多在可数多个互不相交的层集 $\{f = t\}$ 上具有正质量, 所以对几乎每个 t , 第四项给出 $\mu_n(f > t) \rightarrow \mu(f > t)$. 这些概率都不超过一, 在有限区间 $[0, M]$ 上使用控制收敛和尾积分公式, 就得到 $\int f d\mu_n \rightarrow \int f d\mu$. $\square$

满足 $\mu(\partial A) = 0$ 的集合称为 μ 的**连续集** (continuity set). 同一证明适用于欧氏空间 $\mathbb{R}^d$, 后面的随机向量极限也可使用. 相关表述见 [Kal21, Theorem 5.25] 或 [Dur19, Theorem 3.2.11].

例 3.53.

令 $\mu_n = \delta_{1/n}$, $\mu = \delta_0$. 由 $1/n \rightarrow 0$ 可得 $(\mu_n \Rightarrow \mu)$, 但是对于 $A = \{0\}$, 始终有 $\mu_n(A) = 0$, 而 $\mu(A) = 1$. 这里没有任何矛盾, 因为 $\partial A = \{0\}$, 从而 $\mu(\partial A) = 1$. 所以 $\{0\}$ 并不是 μ 的连续集.

实线上的左半直线 $(-\infty, x]$ 只有边界点 x , 而 F 在 x 连续恰好对应 $\mu(\{x\}) = 0$. 因而弱收敛推出

$$F_n(x) \rightarrow F(x)$$

在极限分布函数的每个连续点成立.

反向也成立. 对有界连续 f , 先选连续点 $a < b$, 使 $\mu((a, b])$ 任意接近一. 分布函数收敛保证 $\mu_n((a, b])$ 也接近一. 在 $[a, b]$ 上取端点均为 F 连续点的足够细分割, 各小区间概率由分布函数差得到收敛, f 的一致连续性又使阶梯近似误差任意小. 区间外误差由 f 的上界和很小的尾概率控制, 所以 $\int f d\mu_n \rightarrow \int f d\mu$.

因此, F_n 在 F 的所有连续点收敛, 正好等价于 $\mu_n \Rightarrow \mu$. 不要求在极限分布有跳跃的点也收敛.

依分布收敛 将测度换成随机变量的分布, 就得到依分布收敛. 比较的仍然只是取值空间上的概率, 所以无须先安排变量之间逐样本的对应关系.

定义 3.54.

设实值随机变量 X_n 定义在 $(\Omega_n, \mathcal{F}_n, \mathbb{P}_n)$ 上, X 定义在 $(\Omega, \mathcal{F}, \mathbb{P})$ 上. 若

$$\mathcal{L}(X_n) \Rightarrow \mathcal{L}(X),$$

则称 X_n 依分布收敛到 X , 记为 $X_n \xrightarrow{d} X$.

不同的共同实现可以保留完全相同的各自分布, 却产生不同的差值. 下面用同分布正态变量把这一区别直接算出来.

例 3.55.

设 $X \sim \mathcal{N}(0, 1)$. 如果直接令 $X_n = X$, 那么每一个样本上 X_n 都和 X 完全相同.

但我们也可以令 $X, X_1, X_2, \dots$ 相互独立, 并且全部服从 $\mathcal{N}(0, 1)$. 此时对于所有 n 仍然有 $\mathcal{L}(X_n) = \mathcal{L}(X)$, 所以 $(X_n \xrightarrow{d} X)$.

然而这时 $X_n - X \sim \mathcal{N}(0, 2)$, 因此对于任意固定的 $\varepsilon > 0$, $\mathbb{P}(|X_n - X| > \varepsilon)$ 始终是同一个严格正的常数, 并不会趋于 0. 所以这一实现中 X_n 甚至不依概率收敛到 X .

要研究实际差值, 必须进一步规定变量怎样在同一概率空间中实现.

依概率收敛 以下讨论差值或逐样本收敛时, 默认 X_n, X 定义在同一 $(\Omega, \mathcal{F}, \mathbb{P})$ 上.

定义 3.56.

若每个 $\varepsilon > 0$ 都满足

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0,$$

则称 X_n 依概率收敛到 X , 记为 $X_n \xrightarrow{\mathbb{P}} X$.

固定一个误差阈值, 超过它的概率随 n 增大而趋于零, 就满足这项要求. 它比较的是当前联合实现中的差, 只给出两个边缘分布通常无法判断. 但极限为常数时, 与常数的误差只取决于另一个变量本身, 情形会简化.

命题 3.57.

对任意常数 c ,

$$X_n \xrightarrow{d} c \iff X_n \xrightarrow{\mathbb{P}} c.$$

证明. 若分布趋于 δ_c , 对闭集 $\{x : |x - c| \geq \varepsilon\}$ 使用 Portmanteau, 得其概率上极限不超过零, 因而 $\mathbb{P}(|X_n - c| > \varepsilon) \rightarrow 0$. 反过来, 对有界连续 f 和任意 $\eta > 0$, 由 f 在 c 连续选取 $\delta > 0$, 使 $|x - c| \leq \delta$ 时 $|f(x) - f(c)| \leq \eta$. 则

$$|\mathbb{E}[f(X_n)] - f(c)| \leq \eta + 2\|f\|_\infty \mathbb{P}(|X_n - c| > \delta).$$

先令 $n \rightarrow \infty$, 再令 $\eta \downarrow 0$, 就得到弱收敛的测试函数条件. $\square$

对一般极限, 可以先将联合分布 $\mathcal{L}(X_n, X)$ 通过 $(x, y) \mapsto |x - y|$ 前推, 得到误差分布. 将刚才的命题用于这个误差, 便有

$$X_n \xrightarrow{\mathbb{P}} X \iff \mathcal{L}(|X_n - X|) \Rightarrow \delta_0.$$

它将依概率收敛表达为误差质量向零集中, 但这个误差分布已经使用了两个变量的联合关系.

L^p 收敛 误差发生得少, 仍可能在发生时非常大. 若还要控制这些取值对积分的贡献, 就使用 L^p 范数. 对 $1 \leq p < \infty$ 及 $X_n, X \in L^p$, 条件

$$\mathbb{E}[|X_n - X|^p] \rightarrow 0$$

等价于 $\|X_n - X\|_p \rightarrow 0$, 称为 L^p 收敛. $p = 2$ 时就是均方收敛.

$p = \infty$ 的范数收敛单独使用本质上确界, 在一个共同零测集之外给出一致误差控制. 下文涉及 p 阶积分及尖峰计算时, 均采用有限范围 $1 \leq p < \infty$.

命题 3.58.

对 $1 \leq p < \infty$, 若 $X_n \rightarrow X$ 于 L^p , 则 $X_n \rightarrow X$ 于概率.

证明. 对任意 $\varepsilon > 0$, 将 Markov 不等式用于非负误差 $|X_n - X|^p$, 得

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p} \rightarrow 0.$$

$\square$

L^∞ 收敛也推出依概率收敛, 因为本质误差小于给定阈值以后, 超过该阈值的概率直接为零. 有限 p 的证明则表明, 误差矩不仅限制超过阈值的概率, 还同时计算超过以后有多大的误差.

几乎必然收敛 依概率收敛比较每个 n 的误差事件, 几乎必然收敛则固定样本点, 查看整条数列最终怎样变化.

定义 3.59.

若

$$\mathbb{P}\{\omega : X_n(\omega) \rightarrow X(\omega)\} = 1,$$

则称 X_n 几乎必然收敛到 X , 记为 $X_n \xrightarrow{\text{a.s.}} X$.

这里的收敛事件可测, 因为对所有精度最终一直满足误差要求, 可以写成可列次交与并. 同时保留整个序列和候选极限, 定义

$$\mathbf{X}(\omega) = ((X_k(\omega))_{k \geq 1}, X(\omega)) \in \mathbb{R}^{\mathbb{N}} \times \mathbb{R}.$$

各坐标可测, 所以它对乘积 σ -代数可测. 取序列空间中的集合

$$C = \{((x_k)_{k \geq 1}, x) : x_k \rightarrow x\}.$$

由实数收敛定义,

$$C = \bigcap_{m=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{k \geq N} \left\{ ((x_j)_{j \geq 1}, x) : |x_k - x| < \frac{1}{m} \right\}.$$

每个内部条件只使用有限坐标, 故 C 是 Borel 集, 并有

$$X_n \xrightarrow{\text{a.s.}} X \iff \mathcal{L}(\mathbf{X})(C) = 1.$$

前推测度仍能描述这项收敛, 但现在必须前推整条序列, 才能记录误差事件是否沿同一个样本无穷多次出现. 这正是后面路径分布所保留的一类信息.

几种收敛方式之间的关系 在共同概率空间中, 有基本关系

$$X_n \xrightarrow{\text{a.s.}} X \implies X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{d} X, \quad X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{\mathbb{P}} X.$$

第一个箭头由控制收敛直接得到: 对每个固定 $\varepsilon > 0$, $\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \rightarrow 0$ a.s., 且被常数一控制, 所以其期望趋于零. L^p 的箭头已经证明.

再证明依概率推出依分布. 固定有界连续 f , 先取足够大的 R , 使 $\mathbb{P}(|X| > R)$ 很小. 在 $[-R-1, R+1]$ 上, f 一致连续, 所以存在 $0 < \delta < 1$, 使 $|X| \leq R$ 且 $|X_n - X| \leq \delta$ 时函数值之差任意小. 余下事件的概率不超过 $\mathbb{P}(|X| > R) + \mathbb{P}(|X_n - X| > \delta)$, 其贡献由 $2\|f\|_{\infty}$ 控制. 先令 $n \rightarrow \infty$, 再减小尾概率和一致连续误差, 就得到期望收敛.

概率测度的总质量为一还给出: 对 $1 \leq q < p \leq \infty$,

$$X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{L^q} X,$$

因为误差满足 $\|X_n - X\|_q \leq \|X_n - X\|_p$.

反向推论通常失败, 但依概率收敛可以沿适当子列变成几乎必然收敛. 为此先控制一系列坏事件发生无穷多次的概率.

引理 3.60 (Borel–Cantelli).

对事件列 (A_n) , 若

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty,$$

则

$$\mathbb{P}(A_n \text{ i.o.}) = 0.$$

这里 i.o. 表示无穷多次发生, 即事件 $\bigcap_{m \geq 1} \bigcup_{n \geq m} A_n$.

证明. 对每个 m , 无穷多次发生的事件都包含在 $\bigcup_{n \geq m} A_n$ 中, 所以

$$\mathbb{P}(A_n \text{ i.o.}) \leq \mathbb{P}\left(\bigcup_{n \geq m} A_n\right) \leq \sum_{n \geq m} \mathbb{P}(A_n).$$

收敛级数的尾和趋于零, 令 $m \rightarrow \infty$ 即得结论. □

注 3.61 (独立事件的反向结论).

若 (A_n) 相互独立且概率和发散, 则 $\mathbb{P}(A_n \text{ i.o.}) = 1$. 对任意固定 m 及 $N \geq m$, 独立性给出

$$\mathbb{P}\left(\bigcap_{n=m}^N A_n^c\right) = \prod_{n=m}^N (1 - \mathbb{P}(A_n)) \leq \exp\left(-\sum_{n=m}^N \mathbb{P}(A_n)\right).$$

令 $N \rightarrow \infty$, 从第 m 项起永不发生的概率为零. 再对 m 取可列并, 得只有有限次发生的概率为零. 仅凭概率和发散不能得到这个结论, 因为高度重叠的事件可以反复计算同一部分样本.

定理 3.62.

如果 $(X_n \xrightarrow{\mathbb{P}} X)$, 那么存在一个子列 $(X_{n_k})_{k \geq 1}$, 使得 $(X_{n_k} \xrightarrow{\text{a.s.}} X)$.

证明. 由 $(X_n \xrightarrow{\mathbb{P}} X)$, 可以递归选取子列 (X_{n_k}) , 使得

$$\mathbb{P}(|X_{n_k} - X| > 2^{-k}) < 2^{-k}.$$

令 $A_k = \{|X_{n_k} - X| > 2^{-k}\}$. 则 $\sum_k \mathbb{P}(A_k) < \infty$, 因而由 Borel-Cantelli 引理可知, 几乎必然只有有限多个 A_k 发生. 因而 $(X_{n_k} \xrightarrow{\text{a.s.}} X)$. $\square$

更完整的子列判别是: $X_n \rightarrow X$ 于概率, 当且仅当每个子列都能再抽出几乎必然趋于 X 的子列. 正向对每个子列重复刚才的构造即可. 反向若依概率收敛失败, 就存在 $\varepsilon, \eta > 0$ 和一个子列, 使其各项都满足 $\mathbb{P}(|X_{n_k} - X| > \varepsilon) \geq \eta$. 它的任何进一步子列也保留这个下界, 却与几乎必然收敛推出依概率收敛矛盾.

原序列是否几乎必然收敛, 仍不能由一个收敛子列代替. 对有限 $1 \leq p < \infty$, L^p 收敛和整列几乎必然收敛之间通常也没有单向包含关系. 下面分别计算两个反例.

例 3.63 (几乎必然消失的尖峰).

固定 $1 \leq p < \infty$, 在 $(0, 1)$ 上采用 Lebesgue 概率测度, 定义

$$X_n = n^{1/p} \mathbf{1}_{(0, 1/n)}.$$

对每个固定 $\omega > 0$, 当 $n > 1/\omega$ 后, $X_n(\omega)$ 恒为零, 因而逐点趋于零. 但

$$\mathbb{E}[|X_n|^p] = n \cdot \frac{1}{n} = 1,$$

所以它不在 L^p 中趋于零.

非零区域越来越小, 高度同时增长, 两者在 p 阶积分中恰好抵消. 路径最终不再进入尖峰, 没有使每个时刻的积分成本随之消失. 反过来, 积分误差趋于零也可以与逐点不断来回变化并存.

例 3.64 (打字机序列).

在 $[0, 1)$ 上取 Lebesgue 概率测度. 将正整数唯一写为 $n = 2^m + k$, 其中 $m \geq 0, 0 \leq k < 2^m$, 定义

$$X_n = \mathbf{1}_{[k/2^m, (k+1)/2^m)}.$$

第 m 层依次扫过 2^m 个不交小区间. 对每个有限 $1 \leq p < \infty$,

$$\mathbb{E}[|X_n|^p] = 2^{-m} \rightarrow 0,$$

所以 $X_n \rightarrow 0$ 于 L^p . 但固定任意 $\omega \in [0, 1)$, 每层恰有一次取一, 从 $m \geq 1$ 起每层也有取零的项. 两种值都无穷多次出现, 因而每条这样的数列都不收敛. 在无穷范数中则始终有 $\|X_n\|_\infty = 1$, 不具有 L^∞ 收敛.

增加积分控制可以恢复有限 p 的范数收敛. 若 $X_n, X \in L^p$, $X_n \rightarrow X$ a.s., 且所有误差满足 $|X_n - X|^p \leq Y$ a.s., 其中 $Y \in L^1$, 则控制收敛给出 $\mathbb{E}[|X_n - X|^p] \rightarrow 0$. 变量属于 L^p 与误差矩趋于零都应检查, 不能只由误差可积推断变量各自可积.

还有一种不要求逐点共同上界的条件. 可积变量族 (U_n) 称为**一致可积** (uniformly integrable), 若

$$\lim_{K \rightarrow \infty} \sup_n \mathbb{E}[|U_n| \mathbf{1}_{\{|U_n| > K\}}] = 0.$$

它要求远端大值对积分的贡献能对整个族同时变小.

若 (X_n) 一致可积且 $X_n \rightarrow X$ 于概率, 则 Vitali 结论给出 $X \in L^1$ 和 $\mathbb{E}[|X_n - X|] \rightarrow 0$. 可以直接用截断说明: 一致可积先保证 $\sup_n \mathbb{E}[|X_n|] < \infty$, 抽取几乎必然收敛子列并用 Fatou, 得到 X 可积. 对固定 K , 截断函数 $T_K(x) = \max\{-K, \min\{x, K\}\}$ 满足

$$\mathbb{E}[|T_K(X_n) - T_K(X)|] \leq \varepsilon + 2K\mathbb{P}(|X_n - X| > \varepsilon),$$

故截断后的误差积分趋于零. 原变量与截断变量之差, 一边由一致可积控制, 另一边由 X 可积控制; 最后令 $K \rightarrow \infty$ 即得结论.

因此, 对 $X_n, X \in L^p$ 及有限 p , 若已知依概率收敛, 再对 $|X_n - X|^p$ 要求一致可积, 就得到 L^p 收敛. 下表中的 p 阶矩也都指 $1 \leq p < \infty$.

收敛方式	是否需要共同概率空间	控制的对象	典型记号	基本推出关系
依分布收敛	不需要	各自分布	$(X_n \xrightarrow{d} X)$	通常推出链中位置最弱
依概率收敛	需要	给定耦合下的误差概率	$(X_n \xrightarrow{\mathbb{P}} X)$	推出依分布
L^p 收敛	需要	给定耦合下误差的 p 阶矩	$(X_n \xrightarrow{L^p} X)$	推出依概率
几乎必然收敛	需要	几乎每条样本路径的尾部行为	$(X_n \xrightarrow{\text{a.s.}} X)$	推出依概率

这些要求服务于不同问题. 分布近似不需要控制原来某个配对方式中的误差, 仍然足以计算许多取值范围的概率; 逐条路径的结论则需要更多联合信息. 中心极限定理首先给出的正是前一种结论.

3.5.2 极限定理

连续映射定理与 Slutsky 定理 连续函数不会破坏已经取得的分布极限. 证明只需把测试函数与所用变换复合.

定理 3.65 (连续映射定理).

若 $X_n \xrightarrow{d} X$, 且 $g: \mathbb{R} \rightarrow \mathbb{R}$ 连续, 则

$$g(X_n) \xrightarrow{d} g(X).$$

证明. 对任意有界连续 f , 复合 $f \circ g$ 仍有界连续. 因而 $\mathbb{E}[f(g(X_n))] \rightarrow \mathbb{E}[f(g(X))]$, 这就是目标分布的弱收敛定义. $\square$

相同证明适用于欧氏空间之间的连续映射. 依概率收敛也保留连续变换: 每个子列都可再抽取几乎必然收敛的子列, 沿它逐点使用连续性, 再用子列判别即可.

还可以允许 g 在极限分布不落入的地方不连续. 若 g Borel 可测, 不连续点集 D_g 满足 $\mathbb{P}(X \in D_g) = 0$, 则同样有分布收敛. 对目标空间的闭集 F , 有 $\overline{g^{-1}(F)} \subseteq g^{-1}(F) \cup D_g$. 用 Portmanteau

控制这个闭包的概率上极限, 再由 D_g 为极限零测集, 就得到目标分布的闭集不等式. 一般表述见 [Kal21, Theorem 5.27].

对两个变量作加乘运算, 各自依分布收敛通常不够, 因为还缺少联合分布. 其中一个变量趋于常数时, 这个困难可以由紧性消除.

定理 3.66 (Slutsky 定理).

设每一对 (X_n, Y_n) 在共同概率空间中定义, $X_n \xrightarrow{d} X, Y_n \xrightarrow{\mathbb{P}} c$, 其中 c 为常数. 则

$$X_n + Y_n \xrightarrow{d} X + c, \quad X_n Y_n \xrightarrow{d} cX.$$

若 $c \neq 0$, 将商在 $\{Y_n = 0\}$ 上定义为任意可测有限值后, 还有

$$X_n/Y_n \xrightarrow{d} X/c.$$

不要求 X_n, Y_n 独立.

证明. 先证明 $(X_n, Y_n) \xrightarrow{d} (X, c)$. 弱收敛保证 X_n 的分布族紧: 由 Portmanteau 先选足够大的闭尾部, 使充分大的 n 的尾概率很小, 再扩大区间处理有限个早期项. 因对任意 $\eta > 0$, 可取 R 使 $\sup_n \mathbb{P}(|X_n| > R) < \eta$.

固定有界连续 $h: \mathbb{R}^2 \rightarrow \mathbb{R}$. 它在紧矩形 $[-R, R] \times [c-1, c+1]$ 上一致连续. 取 $0 < \delta < 1$, 使其中 $|y - c| \leq \delta$ 时 $|h(x, y) - h(x, c)| \leq \eta$. 于是

$$\mathbb{E}[|h(X_n, Y_n) - h(X_n, c)|] \leq \eta + 2\|h\|_\infty (\mathbb{P}(|X_n| > R) + \mathbb{P}(|Y_n - c| > \delta)).$$

令 $n \rightarrow \infty$, 再令 $\eta \downarrow 0$, 左边趋于零. 又因 $x \mapsto h(x, c)$ 有界连续, $\mathbb{E}[h(X_n, c)] \rightarrow \mathbb{E}[h(X, c)]$, 所以联合分布收敛.

加法和乘法连续, 应用连续映射定理即得前两项. 对商, 先将 $(x, y) \mapsto x/y$ 在 $y = 0$ 上取零. 这个 Borel 映射只可能在 $y = 0$ 处不连续, 而极限的第二坐标为非零常数 c , 所以可用刚才的几乎处处连续版本. 最后, $\mathbb{P}(Y_n = 0) \leq \mathbb{P}(|Y_n - c| > |c|/2) \rightarrow 0$, 在这个渐小概率事件上改取别的可测有限值, 不改变任何有界测试函数的极限. $\square$

这些步骤也见 [Dur19, Exercises 3.2.12–3.2.14], 连续映射与倒数变换见 [Dur19, Theorem 3.2.10]. 在统计标准化中, 若未知尺度 $\sigma > 0$ 有相合估计 $\hat{\sigma}_n \rightarrow \sigma$ 于概率, 就可以用 Slutsky 将固定分母换成估计分母, 而保留原来的分布极限.

大数定律 独立重复同一种实验时, 令 $X_1, X_2, \dots$ 独立同分布, 取样本平均

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

若均值有限, 大数定律说明平均怎样接近这个均值. 有限方差时, 先将误差平方展开, 就能得到一个直接证明.

定理 3.67 (弱大数定律, 有限方差版本).

若 $X_1, X_2, \dots$ 独立同分布, $\mathbb{E}[X_1] = \mu, \text{Var}(X_1) = \sigma^2 < \infty$, 则

$$\bar{X}_n \xrightarrow{\mathbb{P}} \mu.$$

证明. 期望线性性给出 $\mathbb{E}[\bar{X}_n] = \mu$. 平方展开中的不同项协方差由独立性为零, 因而

$$\mathbb{E}[|\bar{X}_n - \mu|^2] = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{\sigma^2}{n} \rightarrow 0.$$

所以实际上先得到 $\bar{X}_n \rightarrow \mu$ 于 L^2 , 再推出依概率收敛. 等价地, Chebyshev 直接给出 $\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \sigma^2/(n\varepsilon^2)$. $\square$

注 3.68.

有限方差使上面的证明只需一次平方展开, 却不是独立同分布弱大数定律的最弱常用条件. 仅有 $\mathbb{E}[|X_1|] < \infty$ 时, 下面的强大数定律仍成立, 并由几乎必然收敛推出依概率收敛.

定理 3.69 (强大数定律).

设 $X_1, X_2, \dots$ 独立同分布, 并且 $\mathbb{E}|X_1| < \infty$. 那么

$$(\bar{X}_n \xrightarrow{\text{a.s.}} \mathbb{E}[X_1]).$$

只有一阶绝对矩时, 原变量的方差可能无穷, 不能继续使用前面的平方误差计算. 标准证明先截断过大的 X_k , 用可求和的尾概率和 Borel–Cantelli 保证截断沿几乎每条路径只改变有限多项. 对中心化后的截断变量, 还要使用独立随机级数的收敛判据和 Kronecker 引理, 再处理截断均值的极限. 这条完整论证见 [Kal21, Theorem 5.23] 或 [Dur19, Theorem 2.4.1].

结论针对整条无限样本序列: 除去一个零概率的序列集合以后, 每条路径的平均最终都趋于理论期望. 它没有保证误差随样本数单调下降, 也没有仅凭一阶可积性给出统一的有限样本速度.

例 3.70.

假设不断独立重复同一种实验. 令 A_k 表示第 k 次实验中某个事件发生, 并假设 $\mathbb{P}(A_k) = p$. 定义 $X_k = \mathbf{1}_{A_k}$, 那么 X_k 独立同分布, 且 $\mathbb{E}[X_k] = p$.

此时

$$\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k}$$

正是这个事件在前 n 次实验中出现的经验频率. 强大数定律给出

$$\left(\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k} \xrightarrow{\text{a.s.}} p \right).$$

在独立同分布重复实验的框架下, 大数定律建立了经验频率和理论概率之间的数学联系. 这种联系不要求用长期频率定义概率; 它说明该模型中的长期经验频率几乎必然趋向概率.

中心极限定理 大数定律确定平均值的极限, 中心极限定理继续研究缩小过程中保留下来的随机波动. 在独立同分布且方差有限时,

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{Std}(\bar{X}_n) = \frac{\sigma}{\sqrt{n}}.$$

因此均方根误差按 $n^{-1/2}$ 缩小. 将偏差放大 $\sqrt{n}$ 倍并除以 σ , 才能在极限中保留单位尺度的波动.

定理 3.71 (Lindeberg–Lévy 中心极限定理).

若 $X_1, X_2, \dots$ 独立同分布, $\mathbb{E}[X_1] = \mu$, $0 < \text{Var}(X_1) = \sigma^2 < \infty$, 则

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} Z, \quad Z \sim \mathcal{N}(0, 1).$$

完整证明可通过特征函数进行. 对中心化且方差为一的单项变量, 有限二阶矩给出零点附近的展开 $1 - t^2/2 + o(t^2)$. 独立性使标准化和的特征函数成为相应的 n 次幂, 极限为 $e^{-t^2/2}$. 再由 Lévy 连续性定理将特征函数极限转成分布极限. 这些工具及证明见 [Kal21, Theorem 6.10] 或 [Dur19, Theorem 3.4.1].

令 Φ 为标准正态分布函数, 因为它处处连续, 结论等价于对每个固定 $x \in \mathbb{R}$,

$$\mathbb{P}\left(\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \leq x\right) \rightarrow \Phi(x).$$

这可以用于估计围绕均值, 宽度与 $\sigma/\sqrt{n}$ 可比的区间概率. 相应的记法是

$$\mathcal{L}(\bar{X}_n) \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

近似比较的是分布. 定理没有在原概率空间中指定一个正态变量, 使标准化误差与它逐样本或按 L^p 距离趋近. 要获得这种配对后的误差结论, 还须给出联合构造及相应估计.

这里必须保留标准化尺度. 仅要求未放大的 $\bar{X}_n - \mu$ 与 $\sigma Z/\sqrt{n}$ 之差趋于零, 两边本来就可能各自趋于零, 不能据此表达 CLT 的正态近似质量. 有意义的同尺度比较需要控制放大以后的差. 有限样本的分布误差速度也不是上述定理的一部分, 例如经典 Berry-Esseen 型 $n^{-1/2}$ 上界还使用有限三阶绝对矩.

例 3.72 (二项计数的正态近似).

取 $0 < p < 1$, 令 X_k 独立且服从 $\text{Bernoulli}(p)$, $S_n = \sum_{k=1}^n X_k$. 则 $S_n \sim \text{Bin}(n, p)$, 单项均值为 p , 方差为 $p(1-p)$. 强大数定律给出 $S_n/n \rightarrow p$ a.s., 中心极限定理进一步给出

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} Z, \quad Z \sim \mathcal{N}(0, 1).$$

因而固定的标准化区间概率可以用正态分布近似. p 很接近端点或考察极远尾部时, 具体样本量下的近似质量仍需另外核对.

例 3.73 (Monte Carlo 定价).

在已经选定的定价模型和风险中性测度 $\mathbb{Q}$ 下, 假设目标价格可写为贴现支付 H 的期望

$$V = \mathbb{E}_{\mathbb{Q}}[H], \quad \mathbb{E}_{\mathbb{Q}}[|H|] < \infty.$$

模拟产生具有 H 在 $\mathbb{Q}$ 下分布的独立副本, 以

$$\hat{V}_n = \frac{1}{n} \sum_{i=1}^n H^{(i)}$$

估计这个数. 强大数定律保证, 在模拟样本的概率空间中 $\hat{V}_n \rightarrow V$ a.s.

若还有 $0 < \text{Var}_{\mathbb{Q}}(H) = \sigma^2 < \infty$, 独立性直接给出估计量方差 σ^2/n , 所以标准误差为 $\sigma/\sqrt{n}$. 中心极限定理再给出

$$\frac{\sqrt{n}(\hat{V}_n - V)}{\sigma} \xrightarrow{d} Z, \quad Z \sim \mathcal{N}(0, 1).$$

方差公式说明尺度, CLT 说明该尺度下近似的分布形状, 两项作用应区分.

取 $n \geq 2$ 的样本方差

$$\hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (H^{(i)} - \hat{V}_n)^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{i=1}^n (H^{(i)})^2 - \hat{V}_n^2 \right).$$

有限二阶矩使强大数定律可分别用于 $H^{(i)}$ 及其平方, 所以 $\hat{\sigma}_n^2 \rightarrow \sigma^2$ a.s., 从而 $\hat{\sigma}_n \rightarrow \sigma$ a.s. Slutsky 给出

$$\frac{\sqrt{n}(\hat{V}_n - V)}{\hat{\sigma}_n} \xrightarrow{d} Z.$$

在样本标准差为零的事件上可将此比值取零; 因极限 $\sigma > 0$, 这些事件的概率趋于零, 不改变分布极限.

计算中使用 $\hat{\sigma}_n/\sqrt{n}$ 估计标准误差. 它反映模拟均值相对所选模型价格的抽样误差, 不负责衡量定价模型和真实市场之间的差异.

注 3.74.

上述 CLT 要求独立同分布且方差有限. 一系列真实金融收益可能有时间依赖和变化的波动, 厚尾也可能破坏矩条件, 使用时应先确定适用的极限定理. 即使标准化的分布极限成立, 随样本量不断向更远处移动的尾部阈值, 也不由固定 x 的 CDF 收敛自动给出精确概率, 通常还需额外的尾部或大偏差分析.

3.5.3 通向随机过程的补充

进阶补充: 耦合与 Wasserstein 距离 此前比较的 $X_n - X$ 使用了给定的配对. 现在固定两个边缘分布, 允许改变联合分布, 再比较最小能够取得的平均误差. 这就得到耦合与 Wasserstein 距离, 最优传输的系统讨论见 [Vil09].

定义 3.75.

若 $\mathbb{R}^2$ 上的概率测度 π 的两个边缘分别为 μ, ν , 就称 π 为二者的一个**耦合**. 所有耦合组成的集合记作 $\Pi(\mu, \nu)$.

这个集合总非空, 例如可以使用独立乘积 $\mu \otimes \nu$. 已在共同概率空间上实现的 (X, Y) 也给出一个耦合 $\mathcal{L}(X, Y)$, 但它未必让误差最小.

本段固定有限范围 $1 \leq p < \infty$. 对每种允许的配对计算 $|x - y|^p$ 的平均成本, 再取下确界和 p 次根.

定义 3.76.

设 $1 \leq p < \infty$, 并记

$$\text{Prob}_p(\mathbb{R}) = \left\{ \mu \mid \mu \text{ 是 } \mathbb{R} \text{ 上的 Borel 概率测度, } \int_{\mathbb{R}} |x|^p d\mu(x) < \infty \right\}.$$

对于 $\mu, \nu \in \text{Prob}_p(\mathbb{R})$, 定义

$$W_p(\mu, \nu) = \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathbb{R}^2} |x - y|^p d\pi(x, y) \right)^{1/p}.$$

耦合可以理解为把一处的概率质量配到另一处的办法, 成本同时计算质量大小与移动距离. 有限 p 阶矩保证这些配对的成本有限, 因为 $|x - y|^p \leq 2^{p-1}(|x|^p + |y|^p)$.

给定 $X, Y \in L^p$ 的联合实现只是可选方案之一, 所以

$$W_p(\mathcal{L}(X), \mathcal{L}(Y)) \leq \|X - Y\|_p.$$

左边可以重新选择配对, 右边则固定原来的配对. 因而边缘分布的 Wasserstein 距离趋于零, 不保证原空间中的误差范数趋于零. 前面的独立标准正态例子中, 两个边缘相同, Wasserstein 距离已经为零, 但差的分布仍为 $\mathcal{N}(0, 2)$.

一个边缘退化为常数时, 就没有可更换的配对了.

命题 3.77.

设 $1 \leq p < \infty$, $Z \in L^p$, $c \in \mathbb{R}$, 则

$$W_p(\mathcal{L}(Z), \delta_c) = \|Z - c\|_p.$$

证明. 第二个边缘集中在 c , 使任何耦合都将全部质量放在 $\mathbb{R} \times \{c\}$ 上. 再指定第一个边缘, 耦合就唯一为 $\mathcal{L}(Z) \otimes \delta_c$. 因而

$$W_p^p(\mathcal{L}(Z), \delta_c) = \int |x - c|^p d\mathcal{L}(Z)(x) = \mathbb{E}[|Z - c|^p].$$

取 p 次根即得等式. □

因此, 对共同概率空间中的 $X_n, X \in L^p$,

$$X_n \xrightarrow{L^p} X \iff W_p(\mathcal{L}(X_n - X), \delta_0) \rightarrow 0.$$

这里使用误差本身的分布, 没有把原来给定的联合实现换成别的配对. 接下来的定理则直接比较两个边缘分布在 Wasserstein 距离下怎样收敛.

定理 3.78.

固定 $1 \leq p < \infty$, 设 $\mu_n, \mu \in \text{Prob}_p(\mathbb{R})$. 则 $W_p(\mu_n, \mu) \rightarrow 0$ 当且仅当 $\mu_n \Rightarrow \mu$, 且

$$\int_{\mathbb{R}} |x|^p d\mu_n(x) \rightarrow \int_{\mathbb{R}} |x|^p d\mu(x).$$

Wasserstein 距离的距离公理与这一等价刻画见 [Vil09]. 其中矩条件的必要性可以直接从 Minkowski 看出: 对任意耦合, 两个坐标的 L^p 范数之差不超过差值范数, 因而

$$\left| \left(\int |x|^p d\mu_n \right)^{1/p} - \left(\int |x|^p d\mu \right)^{1/p} \right| \leq W_p(\mu_n, \mu).$$

完整的充分性还需要构造适当耦合, 不只是检查原来某个配对的误差.

弱收敛控制有界连续观测, 会忽略越来越少的远端质量所携带的无界成本. 追加 p 阶矩收敛以后, 这些质量虽然少, 也不能留下未消失的 p 阶运输成本. 下面的例子把这项区别直接算成一个常数.

例 3.79.

在 $(0, 1)$ 上定义 $X_n = n\mathbf{1}_{(0, 1/n)}$. 那么

$$\mathcal{L}(X_n) = \left(1 - \frac{1}{n}\right) \delta_0 + \frac{1}{n} \delta_n.$$

远离 0 的概率质量只有 $1/n \rightarrow 0$, 故 $(\mathcal{L}(X_n) \Rightarrow \delta_0)$. 但是

$$W_1(\mathcal{L}(X_n), \delta_0) = \mathbb{E}|X_n| = 1$$

所以这里存在弱收敛, 却不存在 W_1 收敛. 弱收敛只看到那部分质量越来越少, 而 Wasserstein 距离还会计算它已经跑到了多远的位置.

从随机变量到路径空间 随机过程首先是在同一概率空间上的一族随机变量. 若要一起研究连续性, 跳跃和首次到达等路径性质, 就将一次实现作为整条函数记录:

$$\omega \mapsto (t \mapsto X_t(\omega)).$$

选择合适的函数空间并验证这项映射可测以后, 过程就成为路径空间中的随机元素, 其分布仍按前推概率测度定义.

例如, 连续路径版本通常取值于 $C([0, T])$, 使用一致拓扑. 具有右连续左极限路径的版本通常取值于 $D([0, T])$, 常用 Skorokhod J_1 拓扑讨论弱收敛. 路径版本, 可测结构和拓扑要一起规定, 因为不同的路径接近方式会形成不同的连续测试函数.

只知道每个固定时刻的分布, 尚未记录同一条路径中各时刻的联系. 联合分布和路径分布保留了这些联系, 才能判断某次大偏差会不会反复出现, 某个水平是否会被达到, 或一系列过程的整条路径是否接近.

至此, 概率空间给出可讨论的事件, 随机变量提取观测, 分布与积分描述取值及平均, 条件期望处理已知信息, 各类收敛则分别控制分布, 误差和路径. 下一章将这些结果用于随时间展开的随机系统, 从有限维分布与样本路径开始建立过程理论.

第四章 随机过程基础

前一章讨论随机变量的分布, 期望和收敛. 从这一章开始, 我们关心的不再只是一次随机结果, 而是随机结果怎样随时间接续出现. 例如, 随机游走下一步会走到哪里? 一笔订单还要等多久才会到达? 价格是否曾经触及某个水平? 这些问题都需要研究随机过程.

给每个时刻指定一个分布, 还不足以回答这些问题. 我们还需要知道不同时刻怎样相互依赖, 以及一次实现会形成怎样的路径. 若问题涉及预测或决策, 还必须说明观察者在每个时刻已经知道什么: 事后看见的整段历史, 不能拿来决定事前的行动.

本章参考 [Bil95; Dur19; Kal21; Shr04b; Wil91], 先用离散时间的例子说明分布, 路径和信息之间的关系, 再讨论停时, Markov 性和鞅. Poisson 过程与 Brown 运动分别给出跳跃到达和连续波动的基本模型. 章末研究路径的变差, 为第五章中的随机积分, Itô 公式和随机微分方程作准备.

4.1 从路径到信息

随机游走可以把本章的问题串起来. 只问第十步的位置, 需要一个随机变量的分布; 同时问第五步和第十步的位置, 需要联合分布; 问前十步是否曾经越过某个水平, 则要看这段路径. 有限维分布和过程律, 就是从这些不同的问题出发引入的.

现在把自己放回游走尚未结束的时刻. 已经走过的部分是已知历史, 后面的增量仍然未知. 滤过来表达这一区别. 由此才能准确讨论: 下一步的持仓能依赖什么, 首次到达某个位置能否当场辨认, 以及过去的历史对未来预测究竟还有多少作用.

这些问题分别引出可预测性, 停时, Markov 性和鞅. 随后, Poisson 过程与 Brown 运动把讨论带到连续时间; 它们的路径怎样累积变化, 又会决定下一章该怎样定义积分. 下图列出这条阅读路线:




图 4.1: 随机过程基础的首次阅读路线.

本章会反复使用随机游走, 而不是每引入一个概念就另换一个例子. 金融例子也有具体用途: 价格历史说明已经获得的信息, 持仓说明决策与随后收益的先后关系, 首次触价说明停时, 订单到达说明计数过程. 它们帮助我们理解定义, 却不替实际市场证明模型假设. 独立增量, 正态分布或恒定到达强度是否适用, 仍须针对所研究的数据判断.

4.2 随机过程, 分布与样本路径

固定概率空间与随机变量族 下面先把所有随机对象放在同一个固定概率空间

$$(\Omega, \mathcal{F}, \mathbb{P})$$

上. 状态空间记为 $(E, \mathcal{E})$, 时间指标集记为 $\mathbb{T}$. 最常见的两种情况是离散时间 $\mathbb{T} = \mathbb{N}_0$ 和连续时间 $\mathbb{T} = [0, \infty)$.

定义 4.1 (随机过程).

一个取值于 $(E, \mathcal{E})$, 指标集为 $\mathbb{T}$ 的 **随机过程**是指一族随机元素

$$X = (X_t)_{t \in \mathbb{T}}, \quad X_t: \Omega \rightarrow E,$$

其中每个 X_t 都是 $\mathcal{F}/\mathcal{E}$ -可测的.

固定时刻 t 时, X_t 是一个随机变量或随机元素; 固定样本点 ω 时,

$$t \mapsto X_t(\omega)$$

则是一个普通函数, 称为 X 在 ω 上的**样本路径**. 这两个固定操作回答的是不同问题:

t 固定 : $\omega \mapsto X_t(\omega)$ 描述横截面上的随机性,

ω 固定 : $t \mapsto X_t(\omega)$ 描述一次实现的时间形状.

图4.2把这两个读法放在同一组可能的实现上. 沿一条线读, 看的是一次实现的时间变化; 在同一时刻取值, 看的是不同实现给出的状态.




图 4.2: 同一随机过程的两个读法. 三条折线是可能实现的示意; 蓝线突出一条样本路径, 橙点突出固定时刻在不同实现上的取值.

例 4.2 (随机游走).

令 $\xi_1, \xi_2, \dots$ 为独立同分布随机变量, 满足

$$\mathbb{P}(\xi_k = 1) = p, \quad \mathbb{P}(\xi_k = -1) = 1 - p.$$

定义

$$S_0 = 0, \quad S_n = \sum_{k=1}^n \xi_k.$$

那么 $S = (S_n)_{n \geq 0}$ 是整数值随机过程. 固定 n 时, S_n 是随机变量; 固定 ω 时, $0, S_1(\omega), S_2(\omega), \dots$ 是一条上下移动的折线路径.

当 $p = 1/2$ 时称为简单对称随机游走. 它会同时成为后面 Markov 链, 鞅和首次到达问题的例子.

一条现实价格记录也是一条实现 图4.3把 AAPL 的复权收盘价按时间排列, 展示了一段已经发生的价格历史. 若把价格放在随机过程模型中, 这段记录就是一次实现, 对应固定 ω 后的路径 $t \mapsto X_t(\omega)$. 图中能看见这一段历史怎样变化, 却看不见其他历史有多大可能发生; 后一个问题需要由过程的分布回答. 因此, 画出一条价格路径与给出一个价格模型, 是两件不同的事.



图 4.3: AAPL 复权收盘价的一条实现路径 (2019–2021). 数据来源见引用文献 [Yaha; Yahc].

为什么单时点分布不够 下面两个过程在每个时刻都有相同的分布, 随时间变化的方式却截然不同. 设 $Z_0, Z_1, \dots$ 独立同分布于 $\mathcal{N}(0, 1)$, 另取 $Z \sim \mathcal{N}(0, 1)$, 定义

$$X_n = Z_n, \quad Y_n = Z.$$

过程 X 每一期重新抽取一个独立的正态值; 过程 Y 只在开始时抽取一次, 此后始终保持这个值. 单看任意一个时刻, 两者都是标准正态分布, 无法区分. 只要同时观察两个时刻, 区别就出现了: 前者的两个值独立, 后者的两个值必然相等.

因此, 要描述时间依赖, 不能停留在各时刻的边缘分布, 而要研究多个时刻的联合分布.

定义 4.3 (有限维分布).

对任意 $n \geq 1$ 和任意 $t_1, \dots, t_n \in \mathbb{T}$, 随机向量

$$(X_{t_1}, \dots, X_{t_n})$$

的联合分布称为过程 X 的一个**有限维分布**. 全部有限维分布组成的族记作

$$\{\mathcal{L}(X_{t_1}, \dots, X_{t_n}) : n \geq 1, t_1, \dots, t_n \in \mathbb{T}\}.$$

也可以把整条路径看成一次随机抽取的结果. 此时取值空间不再是 E , 而是由所有函数 $\mathbb{T} \rightarrow E$ 组成的空间 $E^{\mathbb{T}}$:

$$X: \Omega \longrightarrow E^{\mathbb{T}}, \quad X(\omega) = (X_t(\omega))_{t \in \mathbb{T}}.$$

要谈这个随机元素的分布, 先要在路径空间上指定可测集合. 这里采用由有限个坐标投影生成的柱 σ -代数. 它从“在若干指定时刻, 过程的取值落入某个可测集合”这类事件出发, 再通过可数次集合运算生成其他事件.

每个 X_t 的可测性保证上述路径映射可测, 因此可以像处理普通随机变量一样, 取前推测度

$$\mathcal{L}(X) = \mathbb{P} \circ X^{-1}.$$

这就是 X 的**过程分布**, 也称**过程律**. 有限维分布是它在有限组坐标上的边缘分布; 反过来, 这些边缘分布也决定了柱 σ -代数上的整个测度.

定理 4.4 (有限维分布决定柱 σ -代数上的过程律).

如果两个过程 X 和 Y 具有相同的全部有限维分布, 那么它们在 $E^{\mathbb{T}}$ 的柱 σ -代数上具有相同的过程律.

证明. 全部有限维分布相同, 意味着两个过程律在每个有限坐标柱集合上取值相同. 这些柱集合构成一个生成柱 σ -代数的 π -系统, 而两个过程律都是概率测度. 由 π - λ 定理, 它们在整个柱 σ -代数上相同. $\square$

上面的定理从一个已经存在的过程出发. 现在反过来问: 若我们只给出了各组时刻的联合分布, 什么条件能保证确实存在一个过程具有这些分布? 最基本的要求是投影一致性. 例如, 指定三个时刻的联合分布以后, 忘掉第三个坐标, 必须得到原先指定的前两个时刻的联合分布, 不能另得一个答案. Kolmogorov 延拓定理说明, 在适当的状态空间上, 这个要求已经足够.

定理中的状态空间须为标准 Borel 空间, 即与某个 Polish 空间的 Borel 可测空间可测同构; Polish 指可分且可由完备度量给出拓扑. 常用的 $\mathbb{R}^d$, 可数离散空间, 以及采用一致拓扑的连续路径空间 $C([0, T])$ 和采用通常 Skorokhod 拓扑的 $D([0, T])$, 都在这一范围内. 要注意, 延拓定理解决的是过程律的存在, 并不同时保证所构造的路径连续或右连续.

定理 4.5 (Kolmogorov 延拓定理).

设 $(E, \mathcal{E})$ 是标准 Borel 空间. 对每个有限子集 $J \subseteq \mathbb{T}$, 设给定 E^J 上的概率测度 μ_J . 如果每当 $J \subseteq K$ 时, μ_J 都等于 μ_K 经自然坐标投影 $E^K \rightarrow E^J$ 所得的前推测度, 那么存在某个概率空间及其上的过程, 使 (μ_J) 成为该过程的有限维分布族.

证明. 先引用可数乘积上的射影极限定理: 对每个可数的 $U \subseteq \mathbb{T}$, 一致的有限维分布族 $(\mu_J)_{J \subseteq U, |J| < \infty}$ 可以在 E^U 上延拓为概率测度 P_U . 这一存在性用到了标准 Borel 条件, 见 [Kal21, Theorem 8.21]; 唯一性则由柱集合上的 π - λ 定理得到. 特别地, 不同可数坐标集上的 P_U 也彼此投影一致.

从可数指标推广到任意指标, 关键在于: 乘积 σ -代数中的每个集合, 实际上只依赖至多可数个坐标. 因为生成它的柱集合只涉及有限个坐标, 而取补集和可数并不会引入不可数多个新坐标. 因此, 对每个可测集合 A , 都可找到可数的坐标集 U_A , 并写成 $A = \pi_U^{-1}(A_U)$, 其中 $A_U \in \mathcal{E}^U$. 令

$$P(A) = P_U(A_U).$$

这个定义不能依赖所选的表示. 若 A 也可以用另一组坐标 V 表示, 就把两组坐标都放进 $U \cup V$; 在这个可数乘积空间中使用投影一致性, 两种计算给出的概率相同.

同样, 对两两不交的 $A_1, A_2, \dots$, 取 $U = \bigcup_n U_{A_n}$, 便能把所有集合放在同一个可数乘积空间中处理. 此时 P 的可列可加性就是 P_U 的可列可加性. 所以 P 确实是 $E^{\mathbb{T}}$ 的乘积 σ -代数上的概率测度.

最后以 $(E^{\mathbb{T}}, \mathcal{E}^{\mathbb{T}}, P)$ 为概率空间, 取坐标过程 $X_t(x) = x_t$. 根据构造, 它在每个有限坐标集 J 上的分布正是 μ_J . 任意指标集与标准 Borel 状态空间的完整论证见 [Kal21, Theorem 8.23]; 实数序列空间上的直接紧矩形证明见 [Dur19, Theorem A.3.1]. $\square$

注 4.6.

延拓定理把测度构造在所有坐标函数组成的空间上, 尚未把路径限制为连续函数. 因此, “这些有限维分布能够同时实现”与“能够选到连续的实现”不能混为一谈. 后一个问题通常要利用增量的矩估计, 再应用 Kolmogorov 连续性定理寻找连续修正. 下面先说明这里的“修正”究竟允许改变什么.

修正, 不可区分与路径性质 对单个随机变量, 在一个零概率集合上改变取值, 通常不会影响我们的结论. 对随机过程则必须多问一句: 各时刻允许修改的是不是同一个零概率集合? 若每个时刻各有自己的例外集, 那么把不可数多个时刻合起来以后, 例外未必仍然可以忽略. 修正与不可区分的区别, 正是这个量词次序的区别.

定义 4.7 (修正与不可区分).

设 $X = (X_t)_{t \in \mathbb{T}}$ 和 $Y = (Y_t)_{t \in \mathbb{T}}$ 定义在同一概率空间上.

1. 如果对每个固定的 $t \in \mathbb{T}$ 都有

$$\mathbb{P}(X_t = Y_t) = 1,$$

则称 X 和 Y 互为修正.

2. 如果存在 $\Omega_0 \in \mathcal{F}$, 满足 $\mathbb{P}(\Omega_0) = 1$, 并且对每个 $\omega \in \Omega_0$ 和所有 $t \in \mathbb{T}$ 都有

$$X_t(\omega) = Y_t(\omega),$$

则称 X 和 Y 不可区分.

不可区分要求找出一个共同的满概率事件, 使两条路径在其中处处相等, 因此一定推出互为修正. 若 $\mathbb{T}$ 可数, 把每个时刻的零概率例外集取并, 就能得到这样一个共同的例外集, 所以反方向也成立. 连续时间的问题在于时刻不可数: 测度的可列可加性不能保证不可数个零概率集合的并仍是零概率集合. 下面的例子恰好利用了这一点.

例 4.8 (每个时刻相同, 整条路径却不同).

取 $\Omega = [0, 1]$ 及 Lebesgue 概率测度, 并令

$$X_t(\omega) = \mathbf{1}_{\{\omega=t\}}, \quad Y_t(\omega) = 0, \quad t \in [0, 1].$$

对每个固定 t , 单点集合 $\{t\}$ 的概率为 0, 因而 $X_t = Y_t$ a.s. 所以 X 与 Y 互为修正.

但是对每一个 ω , 都有 $X_\omega(\omega) = 1$, 因而不存在任何样本点使两条路径在所有时刻都相同. 所以二者并不可区分.

命题 4.9 (连续修正的唯一性).

如果连续时间过程 X 和 Y 互为修正, 并且二者的样本路径都几乎必然连续, 那么 X 和 Y 不可区分.

证明. 互为修正保证两个过程在每个有理时刻几乎必然相等. 有理时刻只有可数多个, 因此可以同时排除它们的零概率例外集, 再与两条路径都连续的满概率事件取交, 得到一个共同的满概率事件.

固定这个事件中的任意 ω . 两条连续函数在所有有理时刻相等, 而有理时刻稠密, 所以它们在所有时刻都相等. 这里正是连续性把“逐时刻相等”加强成了“整条路径相等”. $\square$

因此, 从有限维分布构造过程时, 可以先不要求路径连续, 再寻找一个连续修正; 一旦找到, 连续修正在不可区分的意义下就是唯一的. 但原过程未必已经连续, 不能把“存在连续修正”直接写成“原过程的路径连续”. 后文把路径连续性直接列入 Brown 运动的定义; 若先构造具有相应协方差的 Gauss 过程, 则还须完成寻找连续修正这一步.

4.3 时间与信息

前一节允许我们把整条路径作为一个随机元素来研究, 但预测和决策不能事先使用整条路径. 站在时刻 t , 我们只能依据当时已经获得的信息. 要判断一个量是否已经可知, 一个决定是否使用了未来信息, 以及一个随机时刻是否已经到来, 都必须先明确这些信息的范围.

滤过, 自然滤过与适应过程 仍用 σ -代数表示可用信息, 只是现在要给每个时刻各指定一个. 随着观察继续进行, 能够判断的事件越来越多, 于是得到下面这个递增的 σ -代数族.

定义 4.10 (滤过与滤过概率空间).

一个滤过是指一族子 σ -代数 $(\mathcal{F}_t)_{t \in \mathbb{T}}$, 满足

$$s \leq t \implies \mathcal{F}_s \subseteq \mathcal{F}_t \subseteq \mathcal{F}.$$

四元组

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in \mathbb{T}}, \mathbb{P})$$

称为滤过概率空间.

事件属于 $\mathcal{F}_t$, 表示到时刻 t 已经能根据所掌握的信息判断它是否发生. 包含关系 $\mathcal{F}_s \subseteq \mathcal{F}_t$ 则表示过去已经能判断的事, 到后来仍然能判断. 滤过不是过程记号旁边可有可无的附属物: 同一过程面对掌握不同信息的观察者, 可能有不同的条件期望, 因而有不同的鞅性质.

两次抛硬币给出一个有限的例子. 记 H 为正面, T 为反面, 样本空间是 $\Omega = \{HH, HT, TH, TT\}$. 观察第一次以后, 我们能够区分 $\{HH, HT\}$ 与 $\{TH, TT\}$, 却还不能区分 HH 与 HT . 观察第二次以后, 四种结果才可以区分. 图 4.4 中的每个框表示当时仍无法区分的一组结果; 信息增加, 就是这些分组逐渐细分.




图 4.4: 信息增长表现为可区分结果的细分. 每一列的 σ -代数由该列各框及它们的并组成, 包括空集. 样本空间始终是同一个 Ω .

定义 4.11 (自然滤过).

过程 X 生成的自然滤过为

$$\mathcal{F}_t^X = \sigma(X_s : s \leq t).$$

自然滤过是使截至 t 的全部观测 X_s 都可测的最小信息集, 因此只记录过程自身的历史. 实际模型可以使用更大的滤过. 例如, 即使 X 只记录价格, 观察者也可能同时知道成交量, 新闻和订单流.

连续时间中还常对自然滤过作通常增广: 补入零概率集合, 并使滤过右连续. 这样便于陈述后面的连续时间定理. 这里要区分两种做法: 补全和右连续化是明确的数学处理, 额外加入其他观测则是在改变模型允许使用的信息; 不能把两者都笼统地当作无关紧要的记号调整.

定义 4.12 (适应过程).

若对每个 $t \in \mathbb{T}$, 随机变量 X_t 都是 $\mathcal{F}_t$ -可测的, 则称 X 关于滤过 $(\mathcal{F}_t)$ 适应.

适应性说的是: 到了时刻 t , 当前值 X_t 已经可知. 每个过程自然都适应于自己的自然滤过. 但这还没有说明一个决定是否来得及实施. 例如, 第 n 期结束后确定的持仓可以是 $\mathcal{F}_n$ -可测的, 却不能倒过来赚取这一期已经发生的收益. 为表达这种先后关系, 需要可预测性.

可预测性: 行动必须先于结果**定义 4.13 (离散时间可预测过程).**

设 $(H_n)_{n \geq 1}$ 为离散时间过程. 如果每个 H_n 都是 $\mathcal{F}_{n-1}$ -可测的, 则称 H 为可预测过程.

这里的“可预测”不是说能够预报未来价格, 而是说第 n 期使用的系数, 在第 $n-1$ 期结束时已经能够确定. 若 H_n 表示区间 $(n-1, n]$ 内的持仓, 它可以依赖此前的全部观测, 却不能依赖这一区间尚未发生的价格变化. $\mathcal{F}_{n-1}$ 与 $\mathcal{F}_n$ 只相差一个时间下标, 经济含义却完全不同.

例 4.14 (离散时间交易增益).

设 S_n 是价格过程, H_n 是第 n 期开始前决定的持仓. 每期的增益等于持仓数量乘以随后发生的价格变化, 因此截至 n 的累计交易增益为

$$(H \cdot S)_n = \sum_{k=1}^n H_k (S_k - S_{k-1}).$$

要把这个和解释为事前能够实施的交易, 须要求 H_k 为 $\mathcal{F}_{k-1}$ -可测. 对比下面的选择:

$$H_k = \text{sgn}(S_k - S_{k-1}).$$

它让上涨时持有正头寸, 下跌时持有负头寸, 于是每一项都变成价格变化的绝对值. 但选择头寸时已经使用了本期涨跌; 在涨跌事先未知的情形下, 这个过程并不可预测. 计算出来的非负增益只是使用未来信息的结果, 并没有给出可实施的交易方法.

连续时间的可预测性 连续时间没有紧邻当前的“上一时刻”, 不能直接照搬 $\mathcal{F}_{n-1}$. 不过, 分段常数的规则仍然容易说明: 在时刻 s 根据已经知道的信息作出决定, 然后在 $(s, t]$ 内保持不变. 连续时间的可预测性就从这种规则出发定义, 而不是要求预先知道整条未来轨迹.

定义 4.15 (连续时间可预测 σ -代数).

在 $[0, \infty) \times \Omega$ 上, 由下列集合生成的 σ -代数称为可预测 σ -代数:

$$\{0\} \times A, \quad A \in \mathcal{F}_0,$$

以及

$$(s, t] \times A, \quad 0 \leq s < t, \quad A \in \mathcal{F}_s.$$

对这个 σ -代数可测的过程称为可预测过程.

集合 $(s, t] \times A$ 同时说明何时采用一条规则, 以及在什么情形下采用它. 由于 $A \in \mathcal{F}_s$, 到了 s 就已经知道这条规则是否启用; 随后才发生区间 $(s, t]$ 中的变化. 用这些集合生成 σ -代数, 便把简单的分段规则扩展到更一般的过程.

适应且左连续的过程是可预测的, 连续适应过程尤其如此. 这里没有矛盾: 连续过程的当前值可以由此前越来越近的观测取得, 并不意味着我们提前知道了它未来的值. 第5.3节将从简单可预测过程开始构造随机积分.

注 4.16 (渐进可测性).

连续时间还要注意时间与样本点的联合可测性. 过程称为**渐进可测**, 是指对每个 t , 它在 $[0, t] \times \Omega$ 上的限制关于 $\mathcal{B}([0, t]) \otimes \mathcal{F}_t$ 可测. 与只逐个时刻要求适应相比, 这个条件同时处理了整段时间上的可测性. 适应且具有连续或右连续路径的过程是渐进可测的. 后文构造积分时还会明确要求相应的可预测性或渐进可测性, 以及可积性, 而不把“适应”当作全部条件.

停时, 首次到达与停止过程 许多问题没有预先指定结束日期, 而是约定发生某件事时就停止. 例如, 价格首次触及止损线, 第一笔订单到达, 或随机游走首次离开一个区间. 结束时刻因路径而异, 但规则应该允许我们在观察过程中判断是否该停, 而不是等看完未来以后再回头选一个时刻.

定义 4.17 (停时).

取值于 $\mathbb{T} \cup \{\infty\}$ 的随机变量 τ 称为关于 $(\mathcal{F}_t)$ 的**停时**, 如果对每个 $t \in \mathbb{T}$ 都有

$$\{\tau \leq t\} \in \mathcal{F}_t.$$

定义要求的是: 到了 t , 能够判断停止是否已经发生; 它不要求在开始时就知道将在哪一天停止. 允许 $\tau = \infty$, 则是为了容纳停止条件始终没有出现的路径. 在离散时间中, 这个条件等价于

$$\{\tau = n\} \in \mathcal{F}_n \quad \text{对每个 } n.$$

也就是说, 每一步走完以后, 我们能够当场判断是否恰好在这一步停止.

例 4.18 (首次到达时刻).

设 X 是适应过程, $B \in \mathcal{E}$, 并约定空集的下确界为 ∞ . 离散时间首次进入 B 的时刻为

$$\tau_B = \inf\{n \geq 0 : X_n \in B\}.$$

到了第 n 步, 检查前 n 步是否有一次落入 B , 就能判断是否已经到达, 因此

$$\{\tau_B \leq n\} = \bigcup_{k=0}^n \{X_k \in B\} \in \mathcal{F}_n.$$

这证明了 τ_B 是停时.

连续时间不能直接把这个有限并换成不可数并, 因为 σ -代数只保证对可数并封闭. 若 X 是具有连续路径的实值适应过程, 则对常数 a ,

$$\tau_a = \inf\{t \geq 0 : X_t \geq a\}$$

仍是停时. 此时是否在 t 以前到达, 等价于是否有 $\sup_{s \leq t} X_s \geq a$; 连续性又使这个上确界可以通过稠密的有理时刻计算, 必要时加入端点. 因此只需可数次观测, 就能证明相应事件属于 $\mathcal{F}_t$.

定义 4.19 (停时处的信息与停止过程).

对停时 τ , 定义

$$\mathcal{F}_\tau = \{A \in \mathcal{F} : A \cap \{\tau \leq t\} \in \mathcal{F}_t \text{ 对所有 } t\}.$$

$\mathcal{F}_\tau$ 表示停止时已经获得的信息. 过程 X 在 τ 处停止后得到

$$X_t^\tau = X_{t \wedge \tau},$$

称为**停止过程**.

$\mathcal{F}_\tau$ 的定义把随机时刻的问题改写成确定时刻的问题: 对于每个 t , 如果停止已经发生, 那么事件 A 是否发生也应该已经能够判断. 停止过程则更直观: 在 τ 以前照常运行, 从 τ 开始一直保持停止时的值.

离散时间中, 停止后的过程仍然适应. 连续时间中, 对这里使用的连续或右连续适应过程, 这一点也成立; 若只给出一般适应性而没有进一步的路径或联合可测性条件, 就不能直接略过证明.

注 4.20.

首次到达与最后一次到达有根本区别. 到达某个价位时, 我们能够知道它是不是第一次, 因为这只需查看过去; 通常却无法知道它是不是最后一次, 因为未来还可能再次到达. 因此“最后一次达到某个价位”通常不是停时. 停时并非任意一个随机选出的时间, 而是能够依照当时信息执行的停止规则.

4.4 Markov 过程: 当前状态能否代表过去

知道截至当前的全部历史以后, 我们原则上可以据此计算未来的条件分布. 但有时这段历史不必全部保留. 例如, 随机游走的下一步由当前位置加上一个新的独立增量得到; 已经知道当前位置, 再补上更早的行走记录, 并不会改变下一步的分布.

Markov 性把这种情形一般化: 给定当前状态以后, 过去的其他信息不再改变未来的条件分布. 这里重要的不是“过程没有过去”, 而是“当前状态已经包含预测未来所需的过去信息”. 先用转移核写出从一个状态走向另一些状态的概率, 再给出正式定义.

转移核与 Markov 性**定义 4.21 (转移核).**

设 $(E, \mathcal{E})$ 为状态空间. 一个从 E 到 E 的**转移核**是映射

$$K: E \times \mathcal{E} \rightarrow [0, 1],$$

满足:

1. 固定 $x \in E$ 时, $A \mapsto K(x, A)$ 是 E 上的概率测度;
2. 固定 $A \in \mathcal{E}$ 时, $x \mapsto K(x, A)$ 是可测函数.

$K(x, A)$ 表示当前状态为 x 时, 下一步落入集合 A 的条件概率.

定义 4.22 (离散时间 Markov 性).

适应过程 $X = (X_n)_{n \geq 0}$ 称为关于滤过 $(\mathcal{F}_n)$ 的**Markov 过程**, 如果存在转移核 K_n , 使对所有 $A \in \mathcal{E}$,

$$\mathbb{P}(X_{n+1} \in A \mid \mathcal{F}_n) = K_n(X_n, A) \quad \text{a.s.}$$

如果 K_n 不依赖于 n , 则称过程**时间齐次**, 并把共同的核记为 K .

在自然滤过下, 上式就是

$$\mathbb{P}(X_{n+1} \in A \mid X_0, \dots, X_n) = \mathbb{P}(X_{n+1} \in A \mid X_n).$$

左边使用全部历史预测下一步, 右边只使用当前位置; Markov 性要求两者给出相同的答案. 它并没

有要求过去与未来独立. 未来当然可以依赖现在, 而现在也依赖过去; 被排除的是在已经给定现在以后, 更早历史仍提供额外的预测信息.

这也说明 Markov 性与状态的选择有关. 如果只记录一个不足以概括预测信息的量, 遗漏的信息就可能通过历史继续起作用. 把必要的量加入状态, 有时能够恢复 Markov 性; 但这需要证明, 不能仅凭把更多变量放在一起就宣布成立.

例 4.23 (随机游走的转移核).

对前面的随机游走,

$$K(x, \{x+1\}) = p, \quad K(x, \{x-1\}) = 1-p.$$

下一步只由当前位置和新的独立增量决定, 因而 S 是时间齐次 Markov 链. 但当 $p \neq 1/2$ 时它具有漂移, 所以 Markov 性并不自动推出鞅性.

Chapman–Kolmogorov 方程 令 $K^m(x, A)$ 表示从 x 出发经过 m 步以后落入 A 的概率. 约定 $K^0(x, A) = \mathbf{1}_A(x)$.

定理 4.24 (Chapman–Kolmogorov 方程).

对时间齐次 Markov 链,

$$K^{m+n}(x, A) = \int_E K^m(x, dy) K^n(y, A), \quad m, n \in \mathbb{N}_0.$$

证明. 先在第 m 步的状态上取条件. 由 Markov 性, 若此时位于 y , 再经过 n 步落入 A 的概率就是 $K^n(y, A)$, 不必继续知道到达 y 以前的历史. 而从 x 出发, 第 m 步状态的分布为 $K^m(x, dy)$. 对这个中间状态取平均, 也就是应用条件期望的塔性质, 便得到右边的积分. 当 $m=0$ 或 $n=0$ 时, 结论由 $K^0(x, A) = \mathbf{1}_A(x)$ 同样成立. $\square$

因此, 右边不是把两个概率直接相乘, 而是先固定中间状态相乘, 再把所有可能的中间状态加总. 在有限状态空间上, 积分成为有限求和, 整个方程就是转移矩阵的乘法.

例 4.25 (两状态市场环境).

为演示计算, 假设一个模型只区分活跃和低迷两种环境, 记状态空间为

$$E = \{B, S\},$$

并假定每期都使用同一个转移矩阵

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix}.$$

行对应当前环境, 列对应下一期环境. 例如, 当前活跃时, 下一期仍活跃的概率为 0.8, 转为低迷的概率为 0.2.

经过两期后的概率由矩阵乘法给出:

$$P^2 = \begin{pmatrix} 0.70 & 0.30 \\ 0.45 & 0.55 \end{pmatrix}.$$

第一行第一列包含两条互斥的路线: 先保持活跃, 再保持活跃; 或先转为低迷, 再回到活跃. 因此

$$0.8 \times 0.8 + 0.2 \times 0.3 = 0.70.$$

这里的状态与概率都是为说明算法而给定的假设, 不是对真实市场的估计. 计算 P^2 只能告诉我们这个模型推出什么, 不能证明市场确实只有两种环境, 更不能证明转移概率长期不变.

连续时间的想法相同, 只是不再有一个固定长度的“下一步”. 我们要从任意确定时刻 s 预测任意较晚时刻 t , 因此使用一族转移核 $P_{s,t}$. 若过程时间齐次, 经过多长时间才是关键, 核便只依赖于 $t - s$.

定义 4.26 (连续时间 Markov 性).

设 $X = (X_t)_{t \geq 0}$ 是取值于 $(E, \mathcal{E})$ 且适应于 $(\mathcal{F}_t)_{t \geq 0}$ 的过程. 如果对每个 $0 \leq s \leq t$ 都存在从 E 到 E 的转移核 $P_{s,t}$, 使每个有界可测函数 f 都满足

$$\mathbb{E}[f(X_t) | \mathcal{F}_s] = P_{s,t}f(X_s) \quad \text{a.s.}, \quad P_{s,t}f(x) := \int_E f(y)P_{s,t}(x, dy),$$

则称 X 关于该滤过具有**连续时间 Markov 性**. 若 $P_{s,t}$ 只依赖于时间差 $t - s$, 即 $P_{s,t} = P_{t-s}$, 则称过程时间齐次.

这里用有界可测函数 f 表述条件, 并不比只考察事件的概率少说什么: 取 $f = \mathbf{1}_A$ 就恢复了概率形式. $P_{s,t}f(X_s)$ 表示从当前状态出发, 计算未来 $f(X_t)$ 的平均值; Markov 性保证这个平均值已经包含全部 $\mathcal{F}_s$ 信息对预测的作用.

对时间齐次过程, 设给定从各个状态出发的 Markov 家族 $(\mathbb{P}_x)_{x \in E}$, 其中 $\mathbb{P}_x(X_0 = x) = 1$, 并以 $\mathbb{E}_x$ 表示相应期望. 把转移核作用在函数上, 就得到

$$P_t f(x) = \mathbb{E}_x[f(X_t)], \quad P_{s+t} = P_s P_t.$$

半群等式仍是 Chapman–Kolmogorov 方程: 先把未来 t 单位时间后的函数值取平均, 再对前面 s 单位时间的变化取平均, 与一次计算 $s + t$ 单位时间后的平均值相同. 第 5.7 节将进一步研究这个平均值在极短时间内怎样变化, 由此引入生成元, Kolmogorov 方程和 Feynman–Kac 公式.

注 4.27 (强 Markov 性把 Markov 思想带回停时).

上面的连续时间定义只对预先指定的时刻作了保证. 但首次到达时刻是观察路径后才确定的, 不能直接把定义中的 s 换成 τ 就算证明完毕. 若在停时发生以后, 给定停止时的状态, 未来仍按照从该状态出发的转移规律演化, 就称为**强 Markov 性**.

在通常使用的滤过下, 标准 Markov 链, Poisson 过程和 Brown 运动都具有这一性质. 它使我们能够在首次到达以后重新开始分析, 例如研究下一次等待时间或反射后的路径. 一般连续时间过程中, 强 Markov 性仍须由额外假设或定理保证, 不能仅凭普通 Markov 性直接断言.

4.5 鞅: 条件平均下没有可预测漂移

鞅, 下鞅与上鞅 Markov 性问的是: 预测未来分布时, 需要保留多少历史? 鞅问的是另一件事: 使用当前的全部信息以后, 未来值的条件平均是否仍等于当前值? 前者限制条件分布依赖什么, 后者规定这个条件分布的均值.

因此, 两者不能互相替代. 一个 Markov 过程可以具有向上的平均漂移; 一个鞅的未来波动幅度或分布形状也可以依赖历史, 只要这种依赖没有使未来值的条件平均偏离当前值.

定义 4.28 (离散时间鞅).

设 $X = (X_n)_{n \geq 0}$ 适应于 $(\mathcal{F}_n)$, 并且每个 X_n 都可积.

1. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n \quad \text{a.s.},$$

则称 X 为**鞅**.

2. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] \geq X_n \quad \text{a.s.},$$

则称 X 为**下鞅**.

3. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] \leq X_n \quad \text{a.s.},$$

则称 X 为**上鞅**.

定义 4.29 (连续时间鞅).

设 $X = (X_t)_{t \geq 0}$ 适应于 $(\mathcal{F}_t)_{t \geq 0}$, 并且每个 X_t 都可积. 如果对所有 $0 \leq s \leq t$ 都有

$$\mathbb{E}[X_t | \mathcal{F}_s] = X_s \quad \text{a.s.},$$

则称 X 为关于该滤过的**连续时间鞅**. 把等号分别改为 $\geq$ 和 $\leq$, 就得到连续时间下鞅和上鞅.

离散时间的定义只写了一步, 但反复使用条件期望的塔性质, 就得到对所有 $m \leq n$,

$$\mathbb{E}[X_n | \mathcal{F}_m] = X_m.$$

所以, 不论向前看一步还是多步, 只要使用的仍是时刻 m 的信息, 条件平均都停留在 X_m . 这也是把鞅比作“公平游戏”的原因.

这里说的是条件平均, 而不是每条路径都不赚不亏, 也不是未来与过去独立. 概率测度决定怎样计算平均, 滤过决定计算平均时已经知道什么; 改变其中任何一个, 都可能改变鞅性. 对价格作出鞅判断时, 不能省略这两项设定.

例 4.30 (有漂移与无漂移随机游走).

对随机游走 $S_n = \sum_{k=1}^n \xi_k$, 使用它的自然滤过. 到了第 n 步, S_n 已经知道; 新的独立增量的平均值为 $2p - 1$, 所以

$$\mathbb{E}[S_{n+1} | \mathcal{F}_n] = S_n + (2p - 1).$$

特别地,

$$p = \frac{1}{2} \implies S \text{ 是鞅}.$$

当 $p > 1/2$ 时, 下一步的条件平均高于当前位置, S 是下鞅; 当 $p < 1/2$ 时则低于当前位置, S 是上鞅.

每一步扣去已知的平均增量 $2p - 1$, 便得到

$$M_n = S_n - n(2p - 1).$$

这个过程对任意 p 都是鞅. 扣去的只是平均漂移, 并没有消除路径上的随机起伏.

命题 4.31 (可预测变换).

设 M 是离散时间鞅, $H = (H_n)_{n \geq 1}$ 是有界可预测过程. 定义

$$(H \cdot M)_n = \sum_{k=1}^n H_k (M_k - M_{k-1}).$$

那么 $(H \cdot M)_n$ 也是鞅.

证明. 有界性保证 $H_k(M_k - M_{k-1})$ 可积, 可预测性则保证在第 k 步开始前, 系数 H_k 已经知道. 因此它可以从关于 $\mathcal{F}_{k-1}$ 的条件期望中提出:

$$\begin{aligned} \mathbb{E}[H_k(M_k - M_{k-1}) | \mathcal{F}_{k-1}] &= H_k \mathbb{E}[M_k - M_{k-1} | \mathcal{F}_{k-1}] \\ &= 0. \end{aligned}$$

最后一项为零, 是因为 M 为鞅. 变换后过程的每一步增量恰好就是左边括号中的乘积, 所以它仍然适应, 可积, 且每一步增量的条件平均为零, 即仍为鞅. $\square$

证明中可预测性的作用非常具体: 它让本期的系数能够在下一次随机变化以前确定, 从而可以提出条件期望. 若允许先看见增量再选系数, 这一步便不成立.

把命题解释为交易时, 它说明在给定测度和信息下, 有界的事前持仓不会把鞅增量变成具有正条件平均的增益. 它还不是完整的金融市场结论; 融资, 现金账户, 交易成本, 资产是否可交易, 以及策略能承担多大损失, 都须在市场模型中另行说明.

离散时间 Doob 分解 对有漂移的随机游走, 我们扣去了每一步的平均增量. 一般下鞅也可以这样处理, 只是每一步该扣多少, 可能依赖当时的历史. Doob 分解的做法是: 在第 k 步开始以前, 先计算这一增量的条件平均, 把它记入 A ; 实际增量减去这个平均以后, 剩下的部分就没有条件漂移.

定理 4.32 (离散时间 Doob 分解).

设 $X = (X_n)_{n \geq 0}$ 是可积下鞅. 定义

$$A_0 = 0, \quad A_n = \sum_{k=1}^n \mathbb{E}[X_k - X_{k-1} | \mathcal{F}_{k-1}],$$

并令

$$M_n = X_n - A_n.$$

那么 M 是鞅, A 是从 0 开始的可积可预测递增过程, 且

$$X_n = M_n + A_n.$$

在要求 $A_0 = 0$ 的条件下, 这个分解唯一.

证明. 下鞅性恰好保证每一步所扣的条件平均非负:

$$\mathbb{E}[X_k - X_{k-1} | \mathcal{F}_{k-1}] \geq 0.$$

因而这些量的累计 A 递增. 第 k 步增加多少, 在 $\mathcal{F}_{k-1}$ 下已经可知, 所以 A 可预测; 条件期望的可积性也保证每个 A_n 可积.

从 X 中扣去 A , 正好消除了每一步的条件平均:

$$\begin{aligned} \mathbb{E}[M_k - M_{k-1} | \mathcal{F}_{k-1}] &= \mathbb{E}[X_k - X_{k-1} | \mathcal{F}_{k-1}] \\ &\quad - (A_k - A_{k-1}) = 0. \end{aligned}$$

因此 M 是鞅.

再看唯一性. 若另有 $X = M' + A'$ 满足同样的要求, 则 $D = A - A' = M' - M$ 同时是可预测过程和鞅, 且 $D_0 = 0$. 由于 $D_k - D_{k-1}$ 在第 $k-1$ 步已经可知, 它的条件期望等于自身; 由于 D 是鞅, 同一个条件期望又必须为零. 所以每一步增量都为零, D 恒为零, 两个分解相同. $\square$

对上鞅应用同样的思路, 便得到

$$X_n = M_n - A_n,$$

其中 A 从 0 出发, 可预测且递增. 两种情形都把条件平均的累计与剩余波动分开了. 第 5.2 节中的半鞅分解将采用相似的思路, 用局部鞅处理随机波动, 用有限变差过程处理另一部分累计变化.

把鞅带到随机时刻 鞅在每个确定时刻保持期望, 但如果我们观察路径, 选择一个有利的时刻停止呢? 这时不能直接把定义中的时间下标替换成停时, 因为停止规则本身依赖过程.

有界停时的关键是: 是否继续承受下一步增量, 在这一步开始以前就已经决定. 因此, 停止仍是一种可预测地选取增量的方式. 无界停时则多出一个极限问题: 先在第 n 步强制停止, 再令 n 增大, 是否还能把期望传到极限? 后面所需的尾部条件正是为这一步服务.

定理 4.33 (有界停时的可选抽样).

设 $M = (M_n)_{n \geq 0}$ 是离散时间鞅, $\sigma \leq \tau$ 是两个有界停时. 那么

$$\mathbb{E}[M_\tau | \mathcal{F}_\sigma] = M_\sigma \quad \text{a.s.},$$

从而

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_\sigma].$$

对下鞅, 相应等号改为 $\geq$; 对上鞅改为 $\leq$.

证明. 取确定的 N 使 $\tau \leq N$. 由于只会选取 $M_0, \dots, M_N$ 中的值, M_σ 与 M_τ 都可积, 且 M_σ 为 $\mathcal{F}_\sigma$ -可测. 要证明条件期望等式, 只需对任意 $A \in \mathcal{F}_\sigma$ 验证相应积分相等.

先把两次停止之间的变化拆成单步增量:

$$M_\tau - M_\sigma = \sum_{k=1}^N \mathbf{1}_{\{\sigma < k \leq \tau\}} (M_k - M_{k-1}).$$

第 k 个增量是否计入, 只取决于第 $k-1$ 步时是否已经过了 σ , 以及是否尚未在 τ 停止. 这两件事当时都能判断. 严格地说, $\{\sigma < k\} = \{\sigma \leq k-1\}$, $\{\tau \geq k\} = \{\tau \leq k-1\}^c$, 而 $A \in \mathcal{F}_\sigma$ 又保证 $A \cap \{\sigma \leq k-1\} \in \mathcal{F}_{k-1}$. 所以 $A \cap \{\sigma < k \leq \tau\} \in \mathcal{F}_{k-1}$.

现在对第 k 个增量先取关于 $\mathcal{F}_{k-1}$ 的条件期望. 指示函数可以提出, 鞅增量的条件平均为零, 于是

$$\mathbb{E}[\mathbf{1}_A \mathbf{1}_{\{\sigma < k \leq \tau\}} (M_k - M_{k-1})] = 0.$$

有限求和得到 $\mathbb{E}[\mathbf{1}_A (M_\tau - M_\sigma)] = 0$. 这对每个 $A \in \mathcal{F}_\sigma$ 都成立, 因此 $\mathbb{E}[M_\tau | \mathcal{F}_\sigma] = M_\sigma$. 对下鞅或上鞅, 只需在同一位置保留相应方向的不等式. 更一般的离散可选抽样形式见 [Kal21, Theorem 9.12]. $\square$

注 4.34 (无界停时还要看尾部).

若 $\tau < \infty$ a.s., 则对几乎每条路径, $M_{\tau \wedge n}$ 最终都会等于 M_τ . 但逐路径收敛不保证期望收敛: 越来越少的路径可能承受越来越大的取值, 它们对期望的贡献不能只凭发生概率很小就忽略.

对离散时间鞅, 一组常用的充分条件是 $\tau < \infty$ a.s., 并且停止族

$$\{M_{\tau \wedge n} : n \geq 0\}$$

一致可积. 此时收敛可加强为 L^1 收敛, 所以能够从每个有界停时的等式传到极限, 得到

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_0].$$

另一组便于验证的充分条件是: 增量满足统一上界 $|M_n - M_{n-1}| \leq C$, 并且 $\mathbb{E}[\tau] < \infty$. 两者合起来给出可积控制 $|M_{\tau \wedge n}| \leq |M_0| + C\tau$, 因而可以使用控制收敛. 只知道增量有界, 或只知道停时几乎必然有限, 都不能代替这组条件.

非负性也不能自动保住等号. 若只知道 $M_n \geq 0$ 和 $\tau < \infty$ a.s., Fatou 引理一般只能推出

$$\mathbb{E}[M_\tau] \leq \mathbb{E}[M_0].$$

若停止族再一致可积, 才可恢复等号. 问题不在于停止规则是否合法, 而在于从截断停时走向无界停时时, 是否有足够的可积性允许交换极限与期望.

例 4.35 (赌徒破产与首次到达).

设 (S_n) 是简单对称随机游走, 从 $S_0 = i \in \{1, \dots, N-1\}$ 出发, 在首次到达 0 或 N 时停止:

$$\tau = \inf\{n \geq 0 : S_n \in \{0, N\}\}.$$

我们要计算先到达 N 而不是 0 的概率. 停止以后只剩两个可能值, 因此只要知道停止值的期望, 就能求出这个概率.

先对有界停时 $\tau \wedge m$ 应用可选抽样:

$$\mathbb{E}[S_{\tau \wedge m}] = i.$$

接着验证能否令 $m \rightarrow \infty$. 从区间内任意位置出发, 接下来连续 N 步向左的概率都是 2^{-N} , 且这必然使过程在这段时间内触及 0. 因而每经过 N 步, 仍未吸收的条件概率都有一个严格小于 1 的统一上界; 不断重复便知 τ 几乎必然有限.

又因为停止前不会越出区间, 始终有 $0 \leq S_{\tau \wedge m} \leq N$. 控制收敛因此给出

$$\mathbb{E}[S_\tau] = i.$$

最后, S_τ 只取 0 或 N , 所以其期望等于 N 乘以到达 N 的概率, 即

$$\mathbb{P}_i(S_\tau = N) = \frac{i}{N}.$$

这里不是直接对无界的 τ 使用定理, 而是先截断, 再明确验证极限所需的条件.

注 4.36.

翻倍下注之所以看起来能够保证获利, 是因为只看第一次赢时的结果: 这一笔收入可以覆盖此前损失. 但连续输时, 所需下注和已经承受的损失都在迅速增加. 对截断后的策略取极限, 不能忽略那些尚未赢过的路径; 它们正可能使停止族失去一致可积性. 因此“最终停止时赚钱”并不能推翻可选抽样, 反而说明必须检查定理的假设. 现实中的资金限额还会使策略在第一次赢以前就被迫结束.

4.6 计数过程与 Poisson 过程

有些问题关心的不是某个数值上下波动, 而是某类事件已经发生了多少次. 例如订单到达, 违约, 电话呼入或设备故障, 每发生一次, 累计次数就增加; 没有事件发生时, 累计次数保持不变. 计数过程用来描述这样的记录.

从订单到达到计数过程 以 N_t 表示截至 t 的累计次数, 它应当取非负整数值, 而且不随时间减少. 还要约定事件恰好发生在时刻 t 时, N_t 已经把这次事件计入; 这对应下面定义中的右连续性.

定义 4.37 (计数过程).

一个计数过程是过程 $N = (N_t)_{t \geq 0}$, 满足:

1. $N_0 = 0$;
2. 样本路径取非负整数值并且单调不减;
3. 样本路径右连续且有左极限.

如果每次跳跃的大小都为 1, 则称它是简单计数过程.

例如, N_t 可以表示截至 t 的订单到达数, 违约数, 电话呼入数或设备故障数. 单调性只表示累计事件不会被撤回, 并不表示到达强度恒定或不依赖历史.

定义 4.38 (Poisson 过程).

设 $\lambda > 0$. 计数过程 $N = (N_t)_{t \geq 0}$ 称为强度 λ 的 **Poisson 过程**, 如果:

1. $N_0 = 0$ a.s.;
2. 它具有独立增量;
3. 对任意 $0 \leq s < t$,

$$N_t - N_s \sim \text{Poisson}(\lambda(t - s)).$$

参数 λ 表示单位时间内的平均到达次数. 长度为 t 的区间内, 计数的分布及其前两阶矩为

$$N_t \sim \text{Poisson}(\lambda t), \quad \mathbb{E}[N_t] = \lambda t, \quad \text{Var}(N_t) = \lambda t.$$

这里不仅规定了平均次数, 还规定了方差必须等于平均值, 以及不同时段怎样相互依赖. 平稳增量说, 同样长的区间具有同样的计数分布; 独立增量说, 不相交区间内发生多少次互不影响. 一个递增的整数值过程并不会自动具有这些性质, 它们都是齐次 Poisson 模型增加的假设.

等待时间 定义第 n 次到达时刻和相邻到达之间的等待时间:

$$T_n = \inf\{t \geq 0 : N_t \geq n\}, \quad W_n = T_n - T_{n-1}, \quad T_0 = 0.$$

定理 4.39 (Poisson 到达与指数等待).

如果 N 是强度 λ 的 Poisson 过程, 那么 $W_1, W_2, \dots$ 独立同分布, 且

$$W_n \sim \text{Exp}(\lambda).$$

因而

$$\mathbb{P}(W_1 > t) = e^{-\lambda t}, \quad \mathbb{E}[W_1] = \frac{1}{\lambda}.$$

第 n 次到达时刻满足

$$T_n = W_1 + \dots + W_n \sim \text{Gamma}(n, \lambda),$$

这里采用 rate 参数化.

证明. 第一次到达晚于 t , 当且仅当截至 t 一次事件也没有发生, 因此

$$\mathbb{P}(T_1 > t) = \mathbb{P}(N_t = 0) = e^{-\lambda t}.$$

这就是强度为 λ 的指数分布的生存函数, 也说明第一次到达几乎必然有限.

对后续等待时间, 需要把过程重新开始的时刻放在随机的到达时刻, 而不只是确定时刻. 利用前文所述 Poisson 过程的强 Markov 性, 每次到达以后新增的计数过程, 都与截至该次到达的历史独立, 并且仍是强度 λ 的 Poisson 过程. 因而下一次等待又有同一个指数分布. 逐次应用便得到全部等待时间的独立同分布性. n 个独立的同参数指数变量之和具有 $\text{Gamma}(n, \lambda)$ 分布, 于是得到到达时刻的结论. $\square$

指数等待还有一个鲜明的性质:

$$\mathbb{P}(W_1 > s + t \mid W_1 > s) = \mathbb{P}(W_1 > t).$$

条件是已经等了 s 而事件仍未发生; 结论是从现在起还要等待的时间, 与刚开始等待时具有相同分布. 不是说等待没有经过, 而是已经经过多久不改变剩余等待的分布. 若订单流存在聚集, 午间效应或消息冲击, 这个无记忆假设就可能不合适.

叠加, 稀疏化与补偿

定理 4.40 (叠加与稀疏化).

1. 如果 $N^{(1)}, \dots, N^{(m)}$ 相互独立, 且分别是强度 $\lambda_1, \dots, \lambda_m$ 的 Poisson 过程, 那么

$$N_t = \sum_{j=1}^m N_t^{(j)}$$

是强度 $\lambda_1 + \dots + \lambda_m$ 的 Poisson 过程.

2. 如果把强度 λ 的 Poisson 过程中的每次到达独立地以概率 p 标记为第 I 类, 以概率 $1 - p$ 标记为第 II 类, 那么两类计数过程相互独立, 且强度分别为 $p\lambda$ 和 $(1 - p)\lambda$.

证明. 对叠加, 任意区间内的总到达数是独立 Poisson 随机变量之和, 所以仍为 Poisson 分布, 参数等于各参数之和. 不相交区间内的总计数仍然独立, 因而得到了所述 Poisson 过程.

对稀疏化, 取长度为 h 的区间. 给定总到达数为 n , 两类计数的联合概率生成函数是 $(pz + (1 - p)w)^n$. 再对 Poisson 总次数取平均, 得到

$$\exp(\lambda h(pz + (1 - p)w - 1)) = \exp(p\lambda h(z - 1)) \exp((1 - p)\lambda h(w - 1)).$$

右边分成两个 Poisson 概率生成函数的乘积, 所以两类计数独立, 参数分别为 $p\lambda h$ 与 $(1 - p)\lambda h$. 原过程在不相交区间上的独立增量, 加上各次标记的独立性, 又保证分出的两个过程具有所需的独立增量性质. $\square$

叠加对应把多个独立来源的事件合在一起; 稀疏化对应把每次到达独立地抽样, 分流或分类. 稀疏化中有一个容易忽略的区别: 给定总次数以后, 两类计数相互制约; 不固定总次数, 对 Poisson 总次数一起取平均后, 两类过程却可以独立. 若标记概率随历史, 价格或订单类型变化, 就不能直接沿用这个独立 Poisson 结论.

命题 4.41 (补偿 Poisson 鞅).

令 N 是强度 λ 的 Poisson 过程, $(\mathcal{F}_t^N)$ 为其自然滤过. 则

$$M_t = N_t - \lambda t$$

是关于 $(\mathcal{F}_t^N)$ 的鞅.

证明. 对 $0 \leq s < t$, 由独立增量, $N_t - N_s$ 与 $\mathcal{F}_s^N$ 独立, 且期望为 $\lambda(t-s)$. 因而

$$\begin{aligned} \mathbb{E}[M_t | \mathcal{F}_s^N] &= N_s - \lambda t + \mathbb{E}[N_t - N_s | \mathcal{F}_s^N] \\ &= N_s - \lambda t + \lambda(t-s) = M_s. \end{aligned}$$

□

N_t 随到达次数增加, 当然不是平均不变的过程. 扣去 λt , 就是扣去模型预期截至 t 应当累计的次数. 没有事件到达时, $N_t - \lambda t$ 以斜率 $-\lambda$ 下降; 发生到达时, 它向上跳跃. 两种变化在条件平均下恰好抵消, 因此得到鞅.

这与 Doob 分解的思路相同: 把可预测的平均累计从实际过程里分出来. 更一般的点过程可以让条件强度依赖时间和历史; 在相应条件下, 将这种强度沿时间积分, 就得到应当扣除的补偿子.

注 4.42 (订单到达模型适合问什么).

观察到平均每分钟 λ 笔订单, 只能帮助估计平均到达率, 还没有说明计数服从 Poisson 分布, 更没有说明相邻时段独立. 真实订单流中的日内季节性, 聚集, 自激, 买卖方向依赖和状态依赖, 都可能使齐次 Poisson 假设失效. 因此, 这个模型适合先作为比较基准: 看相同时长区间内的强度是否稳定, 计数的离散程度是否符合模型, 以及历史到达是否仍能预测后续到达.

4.7 Brown 运动

定义与 Gauss 增量 Poisson 过程在事件到达时跳跃, 其余时间保持不变. Brown 运动的路径没有跳跃, 却在任意短的时间尺度上仍有随机变化. 它用均值为零, 方差与区间长度成正比的独立 Gauss 增量, 给出了连续噪声的一个基本模型. 路径连续性也必须明确要求, 不能只从增量分布中略去.

定义 4.43 (标准 Brown 运动).

在滤过概率空间 $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$ 上, 实值过程 $W = (W_t)_{t \geq 0}$ 称为关于该滤过的 **标准 Brown 运动**, 如果:

1. $W_0 = 0$ a.s.;
2. W 适应于 $(\mathcal{F}_t)$;
3. 对任意 $0 \leq s < t$,

$$W_t - W_s \sim \mathcal{N}(0, t-s),$$

并且 $W_t - W_s$ 与 $\mathcal{F}_s$ 独立;

4. 样本路径几乎必然连续.

定义中的独立性是相对于 $\mathcal{F}_s$ 说的: 从 s 以后新发生的增量, 与时刻 s 已有的全部信息独立. 取自然滤过时, 这就是未来增量与过程自身的过去独立. 若把某个未来值提前放进滤过, 同一条坐标过程可能不再满足这个条件, 因此不能脱离滤过单独谈这里的 Brown 性.

把若干时刻按顺序排列, 每个 W_{t_k} 都能写成此前独立 Gauss 增量之和, 所以对任意 $t_1, \dots, t_n$,

$$(W_{t_1}, \dots, W_{t_n})$$

服从多元正态分布. 也就是说, Brown 运动是 Gauss 过程. 它的均值与协方差为

$$\mathbb{E}[W_t] = 0, \quad \text{Cov}(W_s, W_t) = \min(s, t).$$

协方差中的 $\min(s, t)$ 来自两个水平共享的那段历史: 较晚时刻比起较早时刻, 只多了一个与过去独立的增量.

反过来, 中心 Gauss 过程若具有这个协方差, 不相交区间的增量就不相关; 由于它们联合为 Gauss 分布, 这进一步给出独立性. 再选取连续修正, 便得到相对于自然滤过或其通常增广的标准 Brown 运动. 这里仍然需要“连续修正”和“相应滤过”这两项, 不能由协方差公式直接省去.

例 4.44 (增量与水平并不独立).

当 $0 < s < t$ 时, 增量 $W_t - W_s$ 与过去 $\mathcal{F}_s$ 独立, 但水平 W_t 与 W_s 并不独立, 因为

$$\text{Cov}(W_s, W_t) = s.$$

这里的独立性适用于不相交区间上的增量, 不适用于不同时刻的过程水平.

缩放, Markov 性与鞅性

命题 4.45 (Brown 缩放).

对任意常数 $c > 0$, 定义缩放后的滤过与过程

$$\tilde{\mathcal{F}}_t = \mathcal{F}_{ct}, \quad \tilde{W}_t = \frac{1}{\sqrt{c}} W_{ct}, \quad t \geq 0,$$

则 $\tilde{W}$ 是关于 $(\tilde{\mathcal{F}}_t)_{t \geq 0}$ 的标准 Brown 运动. 因而在过程律意义下,

$$(\tilde{W}_t)_{t \geq 0} \stackrel{d}{=} (W_t)_{t \geq 0}.$$

证明. 时间变换保留路径连续性, 并使 $\tilde{W}_t$ 适应于 $\tilde{\mathcal{F}}_t$. 对 $s < t$, 缩放后的增量为 $(W_{ct} - W_{cs})/\sqrt{c}$, 它与 $\mathcal{F}_{cs}$ 独立, 均值为零, 方差为 $c(t-s)/c = t-s$. 连同初值为零, 这正好验证了相对于 $\tilde{\mathcal{F}}_t = \mathcal{F}_{ct}$ 的 Brown 运动定义. $\square$

Brown 运动在时间扩大 c 倍以后, 空间再缩小 $\sqrt{c}$ 倍, 统计规律恢复原样. 这是过程律的相等, 不是说同一条路径经过缩放后会与原路径重合. 时间平方根缩放的根源在于增量方差随时间长度线性增加, 因此标准差随时间平方根增加. 用于真实收益率时, 仍须检查相应的增量独立性, 同分布性和波动率稳定等假设.

命题 4.46 (Brown 运动的 Markov 性与基本鞅).

标准 Brown 运动是时间齐次 Markov 过程, 当 $t > 0$ 时其转移核为

$$P_t(x, A) = \int_A \frac{1}{\sqrt{2\pi t}} \exp\left(-\frac{(y-x)^2}{2t}\right) dy.$$

此外,

$$W_t \quad \text{和} \quad W_t^2 - t$$

都是鞅.

证明. 对 $0 \leq s < t$, 写成

$$W_t = W_s + (W_t - W_s).$$

后一项独立于 $\mathcal{F}_s$, 且服从 $\mathcal{N}(0, t-s)$, 所以给定当前状态 W_s 后, 未来分布不再依赖更早历史, 这给出 Markov 性. 同时

$$\mathbb{E}[W_t | \mathcal{F}_s] = W_s.$$

再利用 $\mathbb{E}[(W_t - W_s)^2] = t - s$ 和交叉项条件期望为 0, 得到

$$\mathbb{E}[W_t^2 - t \mid \mathcal{F}_s] = W_s^2 - s.$$

□

反射原理与首次到达 设

$$\tau_a = \inf\{t \geq 0 : W_t = a\}, \quad a > 0.$$

连续性保证“达到或超过 a ”之前一定先命中 a .

定理 4.47 (反射原理).

对 $a > 0$ 和 $t > 0$,

$$\mathbb{P}\left(\sup_{0 \leq s \leq t} W_s \geq a\right) = 2\mathbb{P}(W_t \geq a) = 2\left(1 - \Phi\left(\frac{a}{\sqrt{t}}\right)\right),$$

其中 Φ 为标准正态分布函数. 等价地,

$$\mathbb{P}(\tau_a \leq t) = 2\left(1 - \Phi\left(\frac{a}{\sqrt{t}}\right)\right).$$

证明. 把截至 t 曾经命中 a 的路径分成两类: 终点在 a 以下, 或终点在 a 以上. 对第一类路径, 保留首次命中 a 以前的部分, 把命中以后的整段路径关于水平线 a 反射. 终点便从 a 以下变成 a 以上. 反射两次恢复原路径, 因此这是一个一一对应. 反过来, 终点高于 a 的路径由连续性必然已经命中过 a , 所以不会遗漏第二类中的路径.

一一对应本身还不足以说明两类路径等概率. 这里还要使用强 Markov 性: 从首次命中时刻起, 后续相对于 a 的增量重新具有 Brown 运动的规律; Brown 增量关于零对称, 所以把这些增量全部变号不改变概率律. 因而两类路径的概率相同.

W_t 在 a 处没有原子, 所以终点恰等于 a 不影响概率. 把两类相加, 便得到命中过 a 的概率是 $\mathbb{P}(W_t \geq a)$ 的两倍. 最后使用 $W_t \sim \mathcal{N}(0, t)$, 得到标准正态尾概率的表达式. □

例 4.48 (触及障碍与到期终值).

事件

$$\left\{\sup_{0 \leq s \leq t} W_s \geq a\right\}$$

问的是在整个区间内是否曾经达到 a , 而不是最终是否停在 a 以上. 一条路径可以先越过障碍, 再回到障碍以下, 所以仅看 W_t 无法判断这个事件. 反射原理并没有把两个事件说成同一个事件, 而是利用 Brown 运动的特殊性质, 把前者的概率化成一个可计算的终值尾概率. 首次违约, 止损规则和障碍型合约中也会出现“是否曾经触及”的问题; 使用这里的概率公式时, 仍须具有相应的 Brown 模型假设.

Brown 路径的规则与不规则 Brown 路径连续, 但它远比普通光滑曲线粗糙. 下面汇总后续会使用的若干路径性质.

定理 4.49 (Brown 运动的路径性质).

对标准 Brown 运动, 下列性质几乎必然成立:

1. 路径在每个有限区间上一致连续;
2. 路径处处不可微;
3. 路径在每个非退化区间上具有无限总变差;
4. 对每个 $0 < \alpha < 1/2$ 和每个固定的 $T < \infty$, 存在依赖于路径的有限常数 $C_{\alpha, T}$, 使

$$|W_t - W_s| \leq C_{\alpha, T} |t - s|^\alpha, \quad 0 \leq s, t \leq T.$$

这称为路径在紧区间上 α -Hölder 连续; 一般不能把指数提高到 $1/2$;

5. 沿二进分割 $t_k^{(n)} = kT/2^n$,

$$\sum_{k=0}^{2^n-1} \left(W_{t_{k+1}^{(n)}} - W_{t_k^{(n)}} \right)^2 \rightarrow T \quad \text{a.s.}$$

这些结论说明了几种不同程度的正则性, 所需的论证也不同. 第一条直接来自连续函数在紧区间上一致连续. 对于第四条, Gauss 增量具有任意阶矩, 且 p 阶绝对矩随时间间隔按 $p/2$ 次方缩放; 把高阶矩估计代入 Kolmogorov 连续性准则, 可以得到每个 $\alpha < 1/2$ 的 Hölder 连续性. 处处不可微则不能仅从“增量通常具有平方根尺度”推出, 还需要更精细的局部振荡估计. 精确结果见 [Kal21, Theorem 14.5 and Proposition 14.10] 以及 [Dur19, Theorems 7.1.5–7.1.6].

第五条可以直接从独立增量的矩计算看出. 沿 $[0, T]$ 的第 n 层二进分割, 平方增量和的期望为 T , 方差为 $2T^2 2^{-n}$. 方差关于 n 的和有限, 所以 Chebyshev 不等式与 Borel–Cantelli 引理给出几乎必然收敛到 T . 定理 5.6 将详细展开这一步, 并处理一般确定性分割及整个时间区间上的一致依概率收敛. 下一节还会证明, 连续有限变差路径的平方增量和只能趋于零; 与这里的非零极限比较, 就能推出 Brown 路径的无限总变差. 对有理端点区间取可数交, 再利用区间包含关系, 可把结论同时用于所有非退化区间.

非零二次变差与连续性并不冲突. 连续性使每个小区间上的增量趋于零, 但平方增量的数量也在增加. 长度为 Δt 的区间内, 增量平方的平均值就是 Δt ; 在总长度为 T 的区间上把它们加起来, 留下的正是时间量 T . 重要的是平方增量的累计, 而不是单个增量是否趋于零.

注 4.50 (模型噪声与经验数据).

Brown 运动的独立 Gauss 增量使许多计算可以明确完成, 但方便计算并不等于符合全部市场现象. 真实金融收益率中的厚尾, 跳跃, 波动率聚集, 状态切换和微观结构噪声, 都不能仅凭标准 Brown 运动的定义得到解释. 将 Brown 运动用作连续噪声时, 应说明研究的时间尺度, 以及模型怎样处理这些差异, 而不是把价格曲线看起来连续当作 Brown 假设已经成立的证据.

从随机游走到 Brown 运动 Brown 运动也可以从越来越细的随机游走中得到. 简单对称随机游走每步的方差为 1; 若在单位时间内安排 n 步, 未经缩放的总方差就会增长到 n . 因此, 在把每步时间缩短为 $1/n$ 的同时, 把空间步长缩小为 $1/\sqrt{n}$, 恰好能保留单位时间内的方差尺度.

具体地, 先在网格点定义

$$W_{k/n}^{(n)} = \frac{1}{\sqrt{n}} S_k, \quad k = 0, 1, \dots,$$

再在相邻网格点之间作线性插值, 得到连续的随机折线. 随着 n 增大, 步长和时间间隔同时缩小; 下面的定理说明这些随机折线的分布趋向 Brown 运动.

定理 4.51 (Donsker 不变性原理).

在任意固定 $T < \infty$ 上, 上述过程 $W^{(n)}$ 在路径空间 $C([0, T])$ 中依分布收敛到标准 Brown 运动, 其中 $C([0, T])$ 采用一致拓扑.

固定一个时刻, 普通中心极限定理已经能解释为什么会出现正态分布. Donsker 定理更进一步: 收敛的是整个随机函数在 $C([0, T])$ 中的分布, 而不只是某个时刻的取值分布. 它并没有断言在同一概率空间中, 每条随机游走路径都会逐路径收敛到某条 Brown 路径.

证明需要完成两件事. 首先, 对任意有限组时刻使用多维中心极限定理, 确定候选极限的有限维分布. 其次, 证明路径分布的紧性, 控制短时间内过大的振荡; 否则, 过程即使在每组固定观测时刻都表现正常, 也可能在这些时刻之间出现越来越剧烈的变化. 有限维收敛确定了极限应当是谁, 紧性则保证整条路径的分布不会逃离这个候选极限.

线性插值随机游走的完整证明见 [Dur19, Theorem 8.1.4]; 更一般的函数型极限定理版本见 [Kal21, Theorem 22.9].

4.8 有限变差与二次变差：为随机积分作准备

总变差 设 $x: [0, T] \rightarrow \mathbb{R}$ 是一条确定路径. 对分割

$$\pi = \{0 = t_0 < t_1 < \cdots < t_m = T\},$$

定义沿分割的绝对增量和

$$V_T(x; \pi) = \sum_{k=0}^{m-1} |x(t_{k+1}) - x(t_k)|.$$

定义 4.52 (有限变差路径).

路径 x 在 $[0, T]$ 上的总变差为

$$V_T(x) = \sup_{\pi} V_T(x; \pi),$$

上确界取遍所有有限分割. 如果 $V_T(x) < \infty$, 则称 x 在 $[0, T]$ 上具有**有限变差**.

总变差把每次向上和向下的移动都按正值计入, 因此衡量的是累计移动量, 而不是起点到终点的净变化. 单调函数, 分段光滑函数, 以及绝对连续且导数可积的函数都有有限变差.

有限变差的重要性在于它能控制 Stieltjes 积分和: 例如, 对连续被积函数, 可以利用积分器有限的总变差保证经典 Riemann–Stieltjes 积分存在. Brown 路径几乎必然没有这个性质, 因而不能依靠这套充分条件统一构造后面所需的积分. 这并不表示任何函数都不能沿 Brown 路径积分, 而是说必须换一种能够利用其随机性质的构造.

二次变差 现在不把增量取绝对值, 而是取平方, 再沿同一个分割求和:

$$Q_T(x; \pi) = \sum_{k=0}^{m-1} (x(t_{k+1}) - x(t_k))^2.$$

与总变差的定义不同, 这里不对所有分割取上确界, 而是选取一系列网格大小趋于 0 的分割 (π_n) , 观察平方和是否收敛. 若收敛, 就把极限称为沿这列分割的二次变差.

对一般路径, 极限可能不存在, 也可能随分割列改变, 因此“沿哪一系列分割”不能无条件省去. 对随机过程还要说明收敛方式: 几乎必然收敛, 依概率收敛和 L^p 收敛是不同的结论. 下一章将在连续半鞅中给出不依赖所选确定性分割序列的规范二次变差; 这里先保留最直接的分割和定义.

命题 4.53 (连续有限变差路径的二次变差为零).

如果 x 在 $[0, T]$ 上连续且具有有限变差, 那么对任意网格大小趋于 0 的分割列,

$$Q_T(x; \pi_n) \rightarrow 0.$$

证明. 记分割上的最大增量为

$$\delta_n = \max_k |x(t_{k+1}) - x(t_k)|.$$

由 x 在紧区间上的一致连续性, $\delta_n \rightarrow 0$. 同时

$$Q_T(x; \pi_n) \leq \delta_n \sum_k |x(t_{k+1}) - x(t_k)| \leq \delta_n V_T(x) \rightarrow 0.$$

□

连续有限变差路径的平方增量和趋于零, 而 Brown 运动恰好相反. 若以 $[W]_T$ 记沿二进分割得到的二次变差, 则

$$[W]_T = T.$$

这里要区分三种和：带符号的一阶增量和始终望远镜式地等于 $W_T - W_0$ ；一阶绝对增量衡量总移动量；平方增量则给出二次变差。不能因为单个增量，甚至分割上的最大增量都趋于零，就认为这些和也都趋于零。

普通链式法则的证明需要把各小区间的 Taylor 展开相加。对连续有限变差路径，二阶余项的累计可以消失；对 Brown 路径，平方增量却保留了非零极限。因此二阶导数所乘的那一项不能丢掉。这正是 Itô 公式与普通链式法则不同的原因。

为什么下一章需要随机积分 回到最初的累加问题。设在每个时刻 t_k ，我们根据当时的信息确定一个系数 H_{t_k} ，并在随后的区间内保持不变。把这个系数与随后发生的 Brown 增量相乘，再把各段相加，就得到

$$\sum_{k=0}^{m-1} H_{t_k} (W_{t_{k+1}} - W_{t_k}).$$

左端点的选择表达了明确的先后关系：先决定系数，后观察这一段的随机增量。对分段常数的简单可预测过程，这个有限和本身就可以作为积分的定义，尚不需要取极限。

困难在于怎样推广到一般的 H 。由于 Brown 路径没有有限总变差，不能照搬前面的路径估计；但可预测性保留了增量的零条件平均，独立增量又允许控制平方平均。第5.3节将把这些性质写成 Itô 等距，再用它证明简单过程的积分能够通过极限唯一地延拓。一般被积过程的积分由这种逼近得到，并不是未经条件检查就把任意左端点求和的极限称为积分。

有了积分以后，二次变差说明函数变换为何出现二阶项，Markov 性则帮助把未来的条件期望写成关于当前时间和状态的函数，并进一步联系到生成元和偏微分方程。对于既有漂移又有随机波动的过程，下一章还会引入局部鞅和半鞅：有限变差部分可以沿路径积分，局部鞅部分用随机积分处理，带跳情形则再计入跳跃的贡献。局部鞅，半鞅，协变差及相应积分的正式定义都在第五章中展开。

4.9 小结

描述一个随机过程，不能只列出各时刻的分布。时间之间的依赖决定联合分布，路径正则性决定能否讨论连续性和变差，滤过则决定预测，持仓和停止可以使用哪些信息。它们互相配合，却不能互相替代：路径连续不推出 Brown 性，Markov 性不推出鞅性，观察到平均到达率也不推出 Poisson 假设。

本章最后出现了下一章的核心困难：Brown 路径的总变差无限，平方增量却能稳定地累计成时间。若要沿这样的路径积分，就需要同时利用信息的先后关系和增量的平方平均，而不能只依靠普通光滑路径的微积分。Itô 积分及其二阶修正，正是从这里开始的。

第五章 随机分析基础

第4.7节和第4.8节已经说明, Brown 路径几乎必然连续而处处不可微, 在有限区间内有无限总变差, 平方增量和却能收敛到一个有限的非零值. 因此, 若要把沿路径的增量相乘并累加, 我们需要重新说明积分怎样定义, 以及哪些极限能够成立.

本章从这个问题出发构造 Itô 积分. 构造中会同时用到前一章的两个事实: 被积系数须遵守信息的先后顺序, 而 Brown 增量的平方平均可以精确计算. 积分建立以后, 二次变差又决定了变量替换时必须保留的二阶项. 随机微分方程, 测度变换和偏微分方程之间的联系, 都将从这些计算逐步得到.

以下固定有限期限 $T > 0$, 在满足通常条件的滤过概率空间

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{0 \leq t \leq T}, \mathbb{P})$$

上工作. 一维 Brown 运动记为 B , 多维 Brown 运动记为 W . 先研究连续路径, 再讨论跳跃. 本章作为状态或积分器的半鞅均取适应的 càdlàg 版本, 即右连续且有左极限; 被积过程另须满足相应的可预测性和可积性条件.

这些计算将在第6.5节中用于一个具体问题: 怎样选择股票持仓和现金账户, 复制欧式看涨期权的现金流.

5.1 从变差到随机微分

先考虑分段常数的被积过程: 在一段时间开始时确定系数, 再乘上随后发生的 Brown 增量. 这时积分只是有限求和. 真正需要证明的是, 当我们用越来越细的简单过程逼近一般被积过程时, 求和结果是否收敛, 以及是否依赖逼近方式. Itô 等距将回答这两个问题.

接着研究函数变换. 对小增量作 Taylor 展开以后, 一阶项形成随机积分, 平方增量则使二阶项在极限中保留下来, 得到 Itô 公式. 有了这个公式, 就能求解和比较几何 Brown 运动, OU 过程与 CIR 型过程, 看清不同的漂移和噪声系数怎样影响解.

再往后, 问题从求解过程转向计算概率和期望. Girsanov 定理说明改变概率权重以后漂移怎样变化; 生成元, Kolmogorov 方程和 Feynman-Kac 公式说明怎样用偏微分方程计算未来的期望. 图5.1列出了这些内容的先后关系, 章末再处理跳跃带来的修正.




图 5.1: 从二次变差到随机微分方程的阅读路线.

本章会经常使用 $dX_t = \dots$ 的写法. 它表示的是两边从初始时刻积分到 t 后成立的等式, 并没有给不可微的路径另造一个普通导数. 后面的运算都以相应积分的存在为前提, 概率测度则决定其中的 Brown 性和鞅性.

注 5.1 (本章使用的积分理论).

Brown 积分将从简单过程开始构造, 连续半鞅积分再把局部鞅积分与有限变差积分合在一起. 对一般 càdlàg 半鞅, 本章引用已有的积分理论, 说明计算时怎样使用跳前值和跳跃修正. 局部时, Tanaka 公式, 粗糙路径, Malliavin 微积分, 无限活动跳跃和一般鞅问题, 只在相关处说明用途, 不在这里展开各自的完整理论.

5.2 路径变差, 二次变差与半鞅

沿一条路径积分时, 需要控制分割不断加细后的增量和. 有限变差路径允许我们用绝对值直接估计这些和; Brown 路径没有这种控制, 但它的平方增量和有稳定的极限. 先把这两种累积方式分清楚, 才能看出随机积分应当利用什么性质.

总变差: 普通积分能够处理的路径 给定区间 $[0, t]$ 的分割

$$\pi = \{0 = t_0 < t_1 < \cdots < t_n = t\}, \quad |\pi| = \max_k (t_k - t_{k-1}),$$

我们先逐条路径衡量它累计移动了多少.

定义 5.2 (总变差与有限变差).

对实值函数 $x: [0, T] \rightarrow \mathbb{R}$, 定义它在 $[0, t]$ 上的总变差为

$$\mathrm{TV}_t(x) = \sup_{\pi} \sum_{k=1}^n |x(t_k) - x(t_{k-1})|,$$

其中上确界取遍 $[0, t]$ 的所有有限分割. 若 $\mathrm{TV}_T(x) < \infty$, 则称 x 为有限变差函数.

若过程 A 的样本路径以概率 1 在每个有限区间上都具有有限变差, 则称 A 为有限变差过程.

连续有限变差函数可以写成两个单调连续函数之差, 因而能够通过相应的符号测度定义 Lebesgue–Stieltjes 积分. 对过程 A , 可以固定样本点以后逐条路径完成这一构造. 最常见的例子是

$$A_t = A_0 + \int_0^t a_s \, ds, \quad \int_0^T |a_s| \, ds < \infty.$$

这里 a_s 可以是随机的, 但固定一条实现以后, 它仍是普通的时间积分. 有限变差类比这一例子更广, 还包含非绝对连续的路径.

二次变差与协变差 有限变差给出了对一阶绝对增量和的统一控制. Brown 路径的总变差却几乎必然无限, 所以不能依靠这个估计构造所有需要的积分. 换成平方增量以后, 情形会发生变化: 单个增量趋于零, 平方和却可能留下一个有限的非零极限.

对连续过程 X 和 $[0, t]$ 的确定性分割 π , 令

$$Q_t^\pi(X) = \sum_{k=1}^n (X_{t_k} - X_{t_{k-1}})^2.$$

为了同时比较各个时刻, 可以先分割整个 $[0, T]$. 计算时刻 t 的平方和时, 保留已经完成的区间, 并把最后一个尚未完成的区间截断到 t . 下面的收敛要求将控制整个时间区间上的误差, 不只控制某个固定时刻.

定义 5.3 (二次变差).

若对任意确定性分割序列, 当 $|\pi_n| \rightarrow 0$ 时, $Q^{\pi_n}(X)$ 在紧时间区间上一致依概率收敛到一个递增过程, 并且极限不依赖于所取的分割序列, 则把该极限记作

$$[X]_t = \lim_{|\pi| \rightarrow 0} \sum_{t_k \leq t} (X_{t_k} - X_{t_{k-1}})^2,$$

称为 X 的二次变差. 这里“紧时间区间上一致依概率收敛”意为对每个 $t \leq T$, 误差在 $[0, t]$ 上的上确界依概率趋于 0.

这个定义比沿某一系列分割取得极限更强: 对任意确定性的趋细分割序列, 都要得到同一个一致依概率极限. 连续半鞅具有这种二次变差. 一般连续过程则可能没有这样的极限, 或者只能沿特定分割列得到极限. 因而这里的 $[X]$ 已经包含对存在性和收敛方式的要求.

定义 5.4 (协变差).

若 $X, Y, X + Y, X - Y$ 的二次变差均存在, 定义

$$[X, Y]_t = \frac{1}{4}([X + Y]_t - [X - Y]_t).$$

对连续半鞅, 它也等于分割和

$$[X, Y]_t = \lim_{|\pi| \rightarrow 0} \sum_{t_k \leq t} (X_{t_k} - X_{t_{k-1}})(Y_{t_k} - Y_{t_{k-1}})$$

的一致依概率极限.

协变差把同一个小区间内的两个增量相乘再累加, 因此记录它们在时间上共同变化的部分. 它是双线性的, 并满足 $[X, X] = [X]$.

这里的协变差与普通协方差承担不同的计算. $\text{Cov}(X_t, Y_t)$ 对固定时刻的两个随机变量取期望, 得到一个由联合分布决定的数; $[X, Y]_t$ 则是沿路径累积后得到的随机量, 随时间构成一个过程. 两者虽然具有相同的量纲, 却不能在公式中相互替换.

命题 5.5 (连续有限变差过程的二次变差).

若 A 连续且在 $[0, T]$ 上有限变差, 则

$$[A]_t = 0, \quad [A, X]_t = 0$$

对任意连续半鞅 X 成立.

证明. 先固定一条连续且有限变差的路径. 对任意趋细分割,

$$\sum_k |\Delta A_k|^2 \leq \max_k |\Delta A_k| \sum_k |\Delta A_k|.$$

紧区间上的一致连续性使最大增量趋于零, 后一个因子则不超过总变差, 因此平方和趋于零.

对交叉增量和, 同样逐条路径估计:

$$\left| \sum_k \Delta A_k \Delta X_k \right| \leq \max_k |\Delta X_k| \text{TV}_T(A).$$

X 的连续性使右边趋于零. 这两个估计也同时控制所有截断到 $t \leq T$ 的分割和, 因而给出所需的一致收敛, 从而 $[A] = 0$ 且 $[A, X] = 0$. $\square$

Brown 运动的二次变差**定理 5.6 (Brown 运动的二次变差).**

对标准 Brown 运动 B ,

$$[B]_t = t, \quad 0 \leq t \leq T.$$

与此同时, 对每个 $t > 0$, Brown 路径在 $[0, t]$ 上的总变差几乎处处为无穷.

证明. 先计算固定时刻的误差, 再把估计推广到整个时间区间. 固定 t 和确定性分割 π . Brown 增量独立且满足 $\Delta B_k \sim \mathcal{N}(0, \Delta t_k)$, 因而

$$\mathbb{E} Q_t^\pi(B) = \sum_k \Delta t_k = t.$$

每个平方增量的方差由正态四阶矩给出: $\text{Var}((\Delta B_k)^2) = 2(\Delta t_k)^2$. 独立性允许把这些方差相加, 得到

$$\text{Var}(Q_t^\pi(B)) = 2 \sum_k (\Delta t_k)^2 \leq 2t|\pi| \rightarrow 0.$$

所以对每个固定 t , 平方增量和在 L^2 中收敛到 t .

定义要求的收敛还须同时控制所有时刻. 对整个 $[0, T]$ 的分割, 端点处的误差

$$\sum_{k \leq j} ((\Delta B_k)^2 - \Delta t_k)$$

关于 j 是离散鞅. Doob 最大不等式把最大端点误差的平方平均控制在终端方差的四倍以内, 而这个上界不超过 $8T|\pi|$, 因而趋于零. 至于分割端点之间的时刻, 只多出最后一个截断区间内的平方增量和相应时间长度. Brown 路径的一致连续性控制前者, $|\pi|$ 控制后者. 因此 $Q^\pi(B)$ 在 $[0, T]$ 上一致依概率收敛到 $s \mapsto s$.

为证明无限总变差, 固定 $t > 0$ 并改用 $[0, t]$ 的二进分割 π_n . 此时

$$\text{Var}(Q_t^{\pi_n}(B)) = 2t^2 2^{-n}.$$

这些方差的和有限, 所以由 Chebyshev 不等式与 Borel–Cantelli 引理, $Q_t^{\pi_n}(B) \rightarrow t$ 几乎必然成立. 另一方面, 若某条连续路径具有有限总变差, 前一命题的估计会给出

$$Q_t^{\pi_n}(B) \leq \max_k |\Delta B_k| \text{TV}_t(B) \rightarrow 0.$$

当 $t > 0$ 时, 这与刚得到的极限矛盾. 因而 Brown 路径在 $[0, t]$ 上具有有限总变差的概率为零. $\square$

增量的平方平均解释了这个结果的尺度: Brown 增量常写作 $|\Delta B| \asymp \sqrt{\Delta t}$, 这里指的是分布中的典型尺度, 并非对每条路径的逐点上下界. 平方以后, 每一项的平均值与时间间隔同阶; 把整个区间的平方增量相加, 便留下有限的时间量.

离散价格记录也可以做同样的平方和计算. 图5.2先计算相邻交易日的对数收益率 r_k , 再累加

$$Q_n = \sum_{k \leq n} r_k^2.$$

较大的正收益和负收益都会使曲线明显上升, 因为平方后不再区分涨跌方向. 图中记录的是这段历史在日线网格上的累计平方收益, 尚未进行网格趋细的极限操作. 它展示了二次变差估计实际累加的量, 也说明累计波动与累计收益是不同的计算.




图 5.2: AAPL 日线网格上的累计平方对数收益率 (2019–2021). 相邻日增量平方后逐步累加, 得到经验二次变差的离散近似. 数据来源见引用文献 [Yaha; Yahc].

连续局部鞅与半鞅 Brown 运动只是随机波动的一种情形. 更一般的过程可能在适当停止以后是鞅, 但放开停止时却缺少维持鞅等式所需的可积性. 局部鞅用一系列停时保留这些停止后的鞅性质.

实际方程还常包含另一类变化, 例如漂移, 利息或费用的累计, 它们在有限时间内可以具有有限变差. 半鞅把这两部分写在一起: $X = X_0 + M + A$, 其中 M 是局部鞅, A 是有限变差过程. 后面将分别对两部分定义积分, 再把结果相加.

定义 5.7 (局部鞅).

定义在 $[0, T]$ 上的适应 càdlàg 过程 M 称为局部鞅, 如果存在一系列递增停时 $\tau_n \leq T$, 满足 $\mathbb{P}(\tau_n = T) \rightarrow 1$, 并使停止过程 $M^{\tau_n} = (M_{t \wedge \tau_n})_{0 \leq t \leq T}$ 对每个 n 都是鞅. 这列停时称为局部化序列. 等价地, 可以把过程在 T 后停止, 再使用趋于无穷的局部化序列.

这里的局部化由停时完成, 可以随路径决定何时先停止. 每个停止过程都是鞅, 而停止越来越少地发生在终点 T 以前. 从这些停止过程回到原过程时, 极限未必能够穿过条件期望, 因此局部鞅未必是真鞅. 非负局部鞅至少是上鞅, 但其期望仍可能下降. 后面用随机指数构造概率密度时, 这一差别将直接决定总概率是否仍为 1.

定义 5.8 (半鞅).

适应的右连续有左极限过程 X 称为半鞅, 如果它可以写成

$$X_t = X_0 + M_t + A_t,$$

其中 $M_0 = A_0 = 0$, M 是局部鞅, A 是有限变差过程. 若 X, M, A 都连续, 则称 X 为连续半鞅.

Brown 运动, 适应的 càdlàg 有限变差过程, 以及后文标准条件下 SDE 的解, 都属于半鞅. 这个类之所以重要, 是因为对它们可以建立稳定的随机积分: 简单可预测过程的逼近能够传到积分结果, 而不因逼近方式不同产生任意的答案. 反过来, 这种积分稳定性也可以用来刻画半鞅, 这就是 Bichteler–Dellacherie 定理的思想. 本章先使用上述分解来构造和计算积分.

定理 5.9 (连续半鞅的二次变差只来自局部鞅部分).

若

$$X = X_0 + M + A, \quad Y = Y_0 + N + C$$

是连续半鞅分解, 其中 M, N 为连续局部鞅, A, C 为连续有限变差过程, 则

$$[X, Y] = [M, N], \quad [X] = [M].$$

特别地, 存在唯一从 0 出发的连续递增适应过程 $[M]$ 使 $M^2 - [M]$ 为局部鞅.

证明. 先使用连续局部鞅的括号构造: 存在从零出发的连续有限变差过程 $[M, N]$, 使 $MN - [M, N]$ 为局部鞅; 当 $M = N$ 时, $[M]$ 递增. 这一构造及其刻画见 [Kal21, Theorem 18.5]. 若有两个满足要求的候选过程, 它们的差同时是连续有限变差过程和局部鞅, 因而只能恒等于初值零. 这给出唯一性.

接着把 $X = X_0 + M + A$ 与 $Y = Y_0 + N + C$ 的交叉增量展开. 含有连续有限变差部分的项都消失, 因为对连续有限变差过程 A 和连续过程 X ,

$$\left| \sum_k \Delta A_k \Delta X_k \right| \leq \max_k |\Delta X_k| \text{Var}_{[0, t]}(A) \rightarrow 0.$$

其中 $\text{Var}_{[0, t]}(A)$ 表示路径的总变差, 并非概率意义的方差. 剩下的只有 M 与 N 的交叉增量和. 由括号的分割逼近 [Kal21, Proposition 18.17], 它收敛到 $[M, N]$, 所以 $[X, Y] = [M, N]$. 取 $Y = X$ 即得到 $[X] = [M]$. $\square$

对连续局部鞅, $M^2 - [M]$ 为局部鞅还给出了另一种理解: $[M]$ 是从平方过程里扣去以后能消除条件漂移的那一部分. 后面的积分理论将使这一性质变成具体计算. 例如, 若

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dB_s, \quad Y_t = Y_0 + \int_0^t c_s ds + \int_0^t d_s dB_s,$$

则

$$[X]_t = \int_0^t b_s^2 ds, \quad [X, Y]_t = \int_0^t b_s d_s ds.$$

平方和保留了噪声系数的平方, 交叉和保留了两个系数的乘积. 时间积分中的 a 和 c 则属于连续有限变差部分, 不出现在这些括号中.

连续性在这里很重要. 对带跳半鞅, 记 $\Delta X_s = X_s - X_{s-}$, 则

$$[X]_t = [X^c]_t + \sum_{0 < s \leq t} (\Delta X_s)^2.$$

这里 X^c 表示连续局部鞅部分, $[X^c]$ 是它贡献的连续二次变差. 其余部分来自实际跳跃的平方和. 因而带跳的有限变差过程也可能具有非零二次变差. 第5.8节将用 Poisson 过程说明这一点.

注 5.10 (半鞅之外的随机路径).

路径连续并不足以保证它属于半鞅. Hurst 指数不等于 $1/2$ 的分数 Brown 运动一般就不属于这一类. 对这类过程积分, 可能要使用 Young 积分, 粗糙路径或 Skorokhod 积分. 它们依赖的逼近和可积性条件不同, 因而也会给出不同的计算规则; 不能只沿用同一个积分符号, 就把这里的 Itô 公式一并搬过去.

5.3 从简单过程构造 Itô 积分

先从分段持仓开始 第5.2节说明了 Brown 增量的平方和怎样累积. 现在给每段增量乘上一个可以随历史改变的系数 H , 研究相应的积分.

先考虑分段常数情形. 在 t_k 时刻根据已经获得的信息确定 ξ_k , 然后在 $(t_k, t_{k+1}]$ 内保持这个系数不变. 这一段对积分的贡献自然定义为

$$\xi_k (B_{t_{k+1}} - B_{t_k}).$$

分段持仓可以帮助理解这个顺序: 本段持有多少, 须在本段价格变化发生以前决定. 这里先把同样的先后关系用于 Brown 增量, 不需要先给一般过程定义积分. 有限个这样的分段规则, 就组成简单可预测过程.

定义 5.11 (简单可预测过程).

给定确定性分割 $0 = t_0 < \cdots < t_n = T$, 若

$$H_t = \sum_{k=0}^{n-1} \xi_k \mathbf{1}_{(t_k, t_{k+1}]}(t),$$

其中 ξ_k 是 $\mathcal{F}_{t_k}$ -可测且平方可积的随机变量, 则称 H 为平方可积的简单可预测过程.

定义对 ξ_k 提出了两个不同的要求. $\mathcal{F}_{t_k}$ -可测性保证系数使用的是区间开始时的信息, 因而仍可利用随后 Brown 增量的零条件平均; 平方可积性则保证乘积具有有限的二阶矩. 前者决定条件期望怎样计算, 后者使后面的等距和极限有意义.

定义 5.12 (简单过程的 Itô 积分).

对上述 H , 定义

$$\int_0^t H_s dB_s = \sum_{k=0}^{n-1} \xi_k (B_{t \wedge t_{k+1}} - B_{t \wedge t_k}), \quad 0 \leq t \leq T.$$

式中的两个截断时刻处理了三种情况: 尚未开始的区间贡献为零, 已完成的区间贡献整个增量, 当前所在区间只累加到 t . 因此这个有限和已经定义了整个连续积分过程. 下一步将对被积过程作逼近, 在 $L^2(\mathbb{P})$ 中取得极限; 这与直接固定路径构造 Riemann-Stieltjes 积分采用了不同的控制方式.

Itô 等距与平方可积延拓 要把积分推广到一般过程, 需要一个能控制逼近误差的估计. Itô 等距给出的恰好是等式: 积分结果的二阶矩, 等于被积过程的平方先沿时间积分, 再取期望.

因此,自然的被积过程范数由

$$\mathbb{E} \int_0^T H_s^2 ds$$

决定. 如果两个简单过程在这个范数下接近, 它们的积分在 $L^2(\mathbb{P})$ 中就同样接近. 这一点将使积分成为可以由完备性延拓的线性算子.

定理 5.13 (Itô 等距).

对任意平方可积简单可预测过程 H ,

$$\mathbb{E} \left[\left(\int_0^T H_s dB_s \right)^2 \right] = \mathbb{E} \left[\int_0^T H_s^2 ds \right].$$

并且 $\mathbb{E}[\int_0^T H_s dB_s] = 0$.

证明. 记 $\Delta B_k = B_{t_{k+1}} - B_{t_k}$, 展开有限和的平方. 对角项可以先对 $\mathcal{F}_{t_k}$ 取条件期望. 此时 ξ_k 已知, 而新增量独立于过去, 二阶矩为 Δt_k , 所以

$$\mathbb{E}[\xi_k^2 (\Delta B_k)^2] = \mathbb{E}[\xi_k^2] \Delta t_k.$$

对交叉项取 $k < \ell$, 并对较晚的 $\mathcal{F}_{t_\ell}$ 取条件期望. 前一个增量及两个系数都已经可知, 只有 ΔB_ℓ 尚未发生, 它的条件平均为零, 因而交叉项的期望为零. 这里用的是条件平均为零, 并未要求各个加权增量彼此独立.

因此只剩对角项:

$$\mathbb{E} \left[\left(\sum_k \xi_k \Delta B_k \right)^2 \right] = \sum_k \mathbb{E}[\xi_k^2] \Delta t_k = \mathbb{E} \int_0^T H_s^2 ds.$$

不展开平方, 直接对每项作同样的条件期望计算, 就得到积分均值为零. □

令

$$\mathcal{H}^2 = \left\{ H \text{ 可预测} : \mathbb{E} \int_0^T H_s^2 ds < \infty \right\}, \quad \|H\|_{\mathcal{H}^2}^2 = \mathbb{E} \int_0^T H_s^2 ds.$$

这里把差的范数为零的过程视为同一个等价类, 即忽略 $dt \otimes \mathbb{P}$ 零测集上的差别. $\mathcal{H}^2$ 因而是一个 Hilbert 空间. 等距表明, 简单过程上的积分保持这一范数, 所以可以沿稠密子空间延拓.

定理 5.14 (L^2 延拓).

对每个 $H \in \mathcal{H}^2$, 存在简单可预测过程 $H^{(n)}$ 使 $\|H^{(n)} - H\|_{\mathcal{H}^2} \rightarrow 0$. 定义

$$\int_0^T H_s dB_s = L^2(\mathbb{P})\text{-}\lim_{n \rightarrow \infty} \int_0^T H_s^{(n)} dB_s.$$

该极限与逼近序列无关, 仍满足 Itô 等距. 积分过程

$$I_t = \int_0^t H_s dB_s$$

具有连续平方可积鞅版本, 并且

$$[I]_t = \int_0^t H_s^2 ds.$$

证明. 可预测 σ -代数由前一章给出的时间区间与已知事件生成. 对这些生成集合的指示函数作简单函数逼近, 再截断系数, 就得到简单可预测过程在 $\mathcal{H}^2$ 中的稠密性. 取 $H^{(n)} \rightarrow H$. 由 Itô 等距,

$$\mathbb{E} \left| \int_0^T (H_s^{(n)} - H_s^{(m)}) dB_s \right|^2 = \|H^{(n)} - H^{(m)}\|_{\mathcal{H}^2}^2.$$

右边趋于零, 所以积分在完备空间 $L^2(\mathbb{P})$ 中有极限. 对两列不同逼近也应用这个等式, 就知道它们得到同一结果.

为了同时得到所有时刻的积分, 记相应简单积分为 $I^{(n)}$. 它们是连续平方可积鞅, Doob 最大不等式给出

$$\mathbb{E} \sup_{t \leq T} |I_t^{(n)} - I_t^{(m)}|^2 \leq 4 \|H^{(n)} - H^{(m)}\|_{\mathcal{H}^2}^2.$$

因而能够选出一个几乎必然一致收敛的子列, 其极限路径连续. 条件期望在 L^2 中连续, 所以简单积分的鞅等式也传到极限, 得到 I 的鞅性.

最后验证括号. 对简单过程, 使用 Brown 运动的平方鞅逐段计算可知, $(I_t^{(n)})^2 - \int_0^t (H_s^{(n)})^2 ds$ 是鞅. 上面的最大矩估计使平方项在 L^1 中收敛; Cauchy-Schwarz 不等式又使累计平方积分在 L^1 中收敛到 $\int_0^t H_s^2 ds$. 因此 $I_t^2 - \int_0^t H_s^2 ds$ 仍为鞅. 由连续局部鞅括号的唯一性, $[I]_t = \int_0^t H_s^2 ds$. $\square$

若可预测过程 H 只满足

$$\int_0^T H_s^2 ds < \infty \quad \text{a.s.},$$

每条路径上的积分虽然有限, 它的期望却可能无限, 因此不能直接使用全局的 $\mathcal{H}^2$ 延拓. 可以先在累计平方达到 n 时停止, 并把停时截在 T . 停止后的累计平方不超过 n , 于是属于已经构造好的平方可积情形.

不同截断得到的积分在共同的停止区间上一致, 所以可以把它接起来. 由于每条路径的累计平方有限, 随着 n 增大, 停止会越来越来少地发生在 T 以前. 这样得到的 $\int H dB$ 是连续局部鞅. 要进一步得到真鞅, 仍需能够控制解除停止后的尾部.

对连续半鞅积分 对一般连续局部鞅 M , 可以把 Brown 等距中的时间测度换成 $d[M]$, 再进行同样的平方可积延拓和局部化. 有限变差部分则已有逐路径的 Stieltjes 积分. 因而若 $X = X_0 + M + A$ 是连续半鞅, 就可以分别积分后相加:

$$\int_0^t H_s dX_s = \int_0^t H_s dM_s + \int_0^t H_s dA_s.$$

例如, 对可预测的 H , 路径上满足 $\int_0^T H_s^2 d[M]_s < \infty$ 和 $\int_0^T |H_s| d\text{TV}_s(A) < \infty$, 就足以通过局部化定义这里的两项. 第一项利用局部鞅的平方变差控制, 第二项利用有限变差的绝对值控制. 漂移, 利息和费用等时间累计, 因而能够与随机波动出现在同一个积分里.

注 5.15 (一般半鞅积分的引用范围).

一般 càdlàg 半鞅积分还允许跳跃. 对每个适应的 càdlàg 半鞅 X , 以 $L(X)$ 记对它可积的可预测过程类, 并写作

$$H \in L(X) \quad \longmapsto \quad (H \cdot X)_t := \int_0^t H_u dX_u.$$

这里 $L(X)$ 表示可积过程的集合, 与第4.2节中表示过程律的 $\mathcal{L}(X)$ 不同. 本章对 Brown 积分完成构造, 对一般半鞅积分使用已有理论.

积分由 X 本身决定, 不随半鞅分解的选择而改变. 若 $X = X_0 + M + A$ 且右边两项有定义, 就有

$$H \cdot X = H \cdot M + H \cdot A.$$

在跳跃时刻, 积分的跳跃满足

$$\Delta(H \cdot X)_t = H_t \Delta X_t.$$

因此乘上本次跳跃的必须是事先确定的系数. 若用适应的 càdlàg 过程 $\bar{H}$ 记录每次调整后的头寸, 实际参与本次价格跳跃的持仓应写为 $H_t = \bar{H}_{t-}$. 这样, 跳跃发生后才作出的调整就不会被倒算成本次跳跃以前的持仓.

原则 5.16 (随机微分是积分等式的简写).

表达式

$$dX_t = a_t dt + b_t dB_t, \quad X_0 = x,$$

表示在相应可积条件下成立的积分等式

$$X_t = x + \int_0^t a_s ds + \int_0^t b_s dB_s, \quad 0 \leq t \leq T.$$

时间积分与随机积分分别说明两类增量怎样累积. 由于 Brown 路径不可微, 不能再把 dB_t 除以 dt , 当作普通函数的导数来解释这个方程.

同样, 常用的助记规则

$$(dB_t)^2 = dt, \quad dt dB_t = 0, \quad (dt)^2 = 0$$

记录的是分割和的极限: Brown 平方增量累积成时间, 连续有限变差的平方增量和及其与 Brown 增量的交叉和则趋于零. 第一个式子没有断言每个小区间都满足 $(\Delta B)^2 = \Delta t$. 它之所以能用于计算, 是因为相应的二次变差结论已经成立.

5.4 Itô 公式, 乘积公式与随机指数

有了积分, 就可以研究过程经过函数变换后怎样变化. 例如, 从 X 转向 X^2 , e^X , 或在 $X > 0$ 时转向 $\log X$, 都需要相应的链式法则.

普通链式法则在把小区间的展开相加后, 只留下了一阶项. 对 Brown 型路径, 平方增量的累计也有非零极限, 因而二阶项必须保留. Itô 公式给出的正是这个修正后的变量替换法则.

一维 Itô 公式 考虑 Itô 过程

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dB_s,$$

其中 a, b 渐进可测, 并且 $\int_0^T (|a_s| + b_s^2) ds < \infty$ 几乎必然成立. 对这里的 Brown 积分, 渐进可测系数可以用在 $ds \otimes \mathbb{P}$ 意义下相等的可预测代表处理, 再按上一节的局部化构造积分.

定理 5.17 (一维 Itô 公式).

若 $f \in C^{1,2}([0, T] \times \mathbb{R})$, 则

$$\begin{aligned} f(t, X_t) = f(0, X_0) &+ \int_0^t \left(\partial_s f(s, X_s) + a_s \partial_x f(s, X_s) + \frac{1}{2} b_s^2 \partial_{xx} f(s, X_s) \right) ds \\ &+ \int_0^t b_s \partial_x f(s, X_s) dB_s, \end{aligned}$$

只要各项通过局部化或可积性条件得到良好定义.

证明. 使用连续半鞅的代换公式 [Kal21, Theorem 18.18]. 空间变量的一阶变化给出 $\partial_x f dX$, 二阶变化给出 $\frac{1}{2} \partial_{xx} f d[X]$. 时间坐标是连续有限变差函数, 因而只贡献普通的 $\partial_t f dt$, 不贡献二次变差或交叉变差. 再代入 $dX_t = a_t dt + b_t dB_t$ 和 $d[X]_t = b_t^2 dt$, 就得到所述积分等式. 时间与一维 Brown 运动的版本, 以及多维 Brown 运动的版本, 分别见 [Dur19, Theorem 7.6.5, Theorem 7.6.7].

代换公式中二阶项的来源也可以从 Taylor 展开理解. 若在短区间内暂时把系数视为近似不变, 就写成

$$\Delta X \approx a \Delta t + b \Delta B.$$

将展开沿分割相加时, 一阶项形成时间积分和随机积分; 二阶项中的 Brown 平方增量和留下二次方差, 而时间平方项与时间和 Brown 的交叉项消失. 所以 $\frac{1}{2}f_{xx}(\Delta X)^2$ 最后贡献 $\frac{1}{2}f_{xx}b^2 dt$.

这个短区间近似说明了公式的来由, 完整证明还须处理一般系数和余项. 可先局部化到紧集, 再控制 Taylor 余项, 平方增量和以及随机积分的收敛. Kallenberg 的证明先用乘积公式建立多项式情形, 再同时逼近 f , f' 和 f'' , 利用有限变差积分的估计及随机积分的收敛通过极限, 见 [Kal21, proof of Theorem 18.18]. $\square$

公式中的三个时间项各有来源: $\partial_t f$ 来自函数本身随时间改变, $a\partial_x f$ 来自过程的漂移, $\frac{1}{2}b^2\partial_{xx}f$ 来自波动经过函数曲率后的累计影响. 最后一项 $b\partial_x f dB$ 则保留了变换后的随机波动.

完整例一: Brown 运动的平方 取 $X_t = B_t$ 和 $f(x) = x^2$. 一阶导数给出 $2B_s dB_s$, 二阶导数与二次变差则给出 $\frac{1}{2} \times 2 ds$. 因此

$$B_t^2 = 2 \int_0^t B_s dB_s + t.$$

整理后,

$$\int_0^t B_s dB_s = \frac{1}{2}(B_t^2 - t).$$

若照搬普通积分得到 $B_t^2/2$, 就漏掉了累计平方增量贡献的 $-t/2$.

这里还可以直接使用平方可积理论: $\mathbb{E} \int_0^t B_s^2 ds = t^2/2 < \infty$, 所以积分是真鞅, 均值为零. 于是等式同时验证了 $\mathbb{E}[B_t^2] = t$ 和 $B_t^2 - t$ 的鞅性.

完整例二: 指数与随机指数 Brown 运动的均值虽然不变, 对它取指数以后却会出现正漂移. 取 $f(x) = e^{\lambda x}$, $\lambda \in \mathbb{R}$, Itô 公式给出

$$e^{\lambda B_t} = 1 + \lambda \int_0^t e^{\lambda B_s} dB_s + \frac{\lambda^2}{2} \int_0^t e^{\lambda B_s} ds.$$

最后一项来自指数函数的二阶导数. 若希望消除这一漂移, 就应在指数中加入一个随时间减少的项:

$$Z_t = \exp\left(\lambda B_t - \frac{1}{2}\lambda^2 t\right).$$

对 $f(t, x) = \exp(\lambda x - \lambda^2 t/2)$ 再用 Itô 公式, 时间偏导恰好抵消二阶修正, 得到

$$Z_t = 1 + \int_0^t \lambda Z_s dB_s, \quad dZ_t = \lambda Z_t dB_t.$$

这个例子中还可以直接验证真鞅性. 给定 $\mathcal{F}_s$, Z_t/Z_s 只含新的 Gauss 增量; 其指数矩恰好抵消 $\exp(-\lambda^2(t-s)/2)$. 因而条件期望为 1, 即 $\mathbb{E}[Z_t | \mathcal{F}_s] = Z_s$, 特别地 $\mathbb{E}Z_t = 1$.

同样的二阶抵消适用于连续局部鞅. 若 $M_0 = 0$, 定义 **Doléans 随机指数**

$$\mathcal{E}(M)_t = \exp\left(M_t - \frac{1}{2}[M]_t\right).$$

Itô 公式给出

$$\mathcal{E}(M)_t = 1 + \int_0^t \mathcal{E}(M)_s dM_s.$$

所以它严格为正且为局部鞅. 与常数系数的 Brown 例子相比, 一般 M 未必具有足以保证期望不下降的可积性. 后面的 Girsanov 变换需要把这个随机指数作为概率密度, 因而还须证明其终端期望等于 1.

完整例三：几何 Brown 运动与对数修正 给定常数 $\mu, \sigma \in \mathbb{R}$ 和 $S_0 > 0$, 考虑

$$S_t = S_0 + \int_0^t \mu S_s ds + \int_0^t \sigma S_s dB_s.$$

漂移和噪声都与当前值成正比, 因此可以尝试指数形式. 前一个例子说明, 指数中的时间系数还须扣去二阶修正, 于是取

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma B_t \right).$$

直接应用 Itô 公式, 三项分别为

$$\left(\mu - \frac{1}{2} \sigma^2 \right) S_t dt, \quad \sigma S_t dB_t, \quad \frac{1}{2} \sigma^2 S_t dt.$$

两个时间项合起来正是 $\mu S_t dt$, 所以这个过程确实解原积分方程. 指数表示也同时给出 $S_t > 0$.

正性允许我们在正半轴上对 $\log S_t$ 使用 Itô 公式. 由于对数函数的二阶导数为负, 得到

$$d \log S_t = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dB_t,$$

从而

$$\log \frac{S_t}{S_0} = \left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma B_t.$$

这里 μ 是原方程中相对于当前值的漂移率, $\mu - \sigma^2/2$ 是对数过程的漂移率. 两者相差 $\sigma^2/2$, 是波动经过对数函数的曲率以后产生的结果, 不需要再加入一个经济假设.

多维 Itô 公式 对多个过程的函数作 Taylor 展开时, 二阶项不仅有各坐标增量的平方, 还有不同坐标增量的乘积. 因此, 多维 Itô 公式既需要二次变差, 也需要协变差. 即使驱动噪声的各坐标独立, 不同状态变量也可能同时使用同一个噪声坐标, 从而产生非零的交叉项.

定义 5.18 (m 维标准 Brown 运动).

在固定滤过概率空间上, $\mathbb{R}^m$ -值过程 $W = (W^1, \dots, W^m)$ 称为关于该滤过的 m 维标准 Brown 运动, 如果 $W_0 = 0$ a.s., W 适应且路径几乎必然连续, 并且对每个 $0 \leq s < t$, 向量增量 $W_t - W_s$ 与 $\mathcal{F}_s$ 独立且满足

$$W_t - W_s \sim \mathcal{N}(0, (t-s)I_m).$$

这个定义给出相互独立的一维 Brown 坐标. 对 $j, k \in \{1, \dots, m\}$,

$$[W^j, W^k]_t = \delta_{jk} t, \quad dW_t^j dW_t^k = \delta_{jk} dt.$$

其中 δ_{jk} 是 Kronecker delta, 第二式是第一式的微分助记法: 同一噪声坐标贡献时间, 不同独立坐标的交叉变差为零.

现在令 d 维过程 X 由这些噪声驱动:

$$dX_t^i = b_i(t, X_t) dt + \sum_{j=1}^m \sigma_{ij}(t, X_t) dW_t^j, \quad i = 1, \dots, d.$$

第 i 行的系数说明 X^i 怎样使用各个噪声坐标. 计算 X^i 与 X^k 的协变差时, 同一噪声坐标上的两个系数相乘, 再对所有噪声坐标求和, 得到 $a = \sigma \sigma^\top$, 即

$$d[X^i, X^k]_t = a_{ik}(t, X_t) dt.$$

定理 5.19 (多维 Itô 公式).

若 $f \in C^{1,2}([0, T] \times \mathbb{R}^d)$, 则

$$\begin{aligned} df(t, X_t) = & \left(\partial_t f + \sum_{i=1}^d b_i \partial_i f + \frac{1}{2} \sum_{i,k=1}^d a_{ik} \partial_{ik} f \right) (t, X_t) dt \\ & + \sum_{j=1}^m \left(\sum_{i=1}^d \sigma_{ij} \partial_i f \right) (t, X_t) dW_t^j. \end{aligned}$$

该微分式表示把两边从 0 积分到 t 所得到的积分等式.

证明. 在多维连续半鞅代换公式中, 一阶项为各个 $\partial_i f dX^i$ 之和, 二阶项为 $\frac{1}{2} \sum_{i,k} \partial_{ik} f d[X^i, X^k]$. 代入上面的漂移, 噪声和协变差表达式, 再按 dt 与各个 dW^j 分组, 就得到所述公式. 时间坐标仍是有限变差坐标, 只贡献 $\partial_t f dt$. $\square$

二阶项是函数 Hessian 与瞬时协变差矩阵的配对. 只要 a_{ik} 非零, 相应的混合二阶导数就参与修正. 因而实际计算应看 X 的协变差矩阵, 不能仅凭驱动 Brown 坐标独立就删去所有混合项.

乘积公式与分部积分 乘积的单步变化满足精确恒等式 $\Delta(XY) = X\Delta Y + Y\Delta X + \Delta X\Delta Y$, 其中右边的 X, Y 取区间左端点值. 普通分部积分中, 最后一类交叉增量和趋于零; 对连续半鞅, 它可能留下协变差. 后面把密度过程乘上价格过程, 或把贴现因子乘上未来收益时, 都会用到这一计算.

命题 5.20 (连续半鞅乘积公式).

若 X, Y 为连续半鞅, 则

$$X_t Y_t = X_0 Y_0 + \int_0^t X_s dY_s + \int_0^t Y_s dX_s + [X, Y]_t.$$

形式上可写成

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + d[X, Y]_t.$$

证明. 先对平方过程建立公式, 再用极化恒等式把平方公式改写为一般的乘积公式. 在分割逼近中, 两个一阶和分别收敛到随机积分, 交叉增量和收敛到 $[X, Y]$. 局部鞅部分使用括号构造与随机积分的收敛, 连续有限变差部分使用逐路径的 Lebesgue-Stieltjes 分部积分. 完整论证见 [Kal21, Theorem 18.16]. $\square$

若其中一个过程连续且有限变差, 交叉项就为零, 公式恢复为熟悉的部分积分形式. 这正是后面处理只含时间积分的贴现因子时所用的情形.

5.5 随机微分方程: 解的含义与基本模型

第5.3节和第5.4节从已经给定的过程出发, 研究怎样积分和作函数变换. 随机微分方程则先指定漂移和噪声系数, 再寻找满足这条规则的过程.

例如, 系数可以规定离某个中心越远, 回复漂移越强; 也可以规定当前值越大, 噪声幅度越大. 这些系数依赖尚未求出的 X_t , 所以写下方程还没有构造出解. 我们需要证明某个连续适应过程确实满足相应的积分等式, 并说明在初值和噪声固定以后, 解是否还有选择余地.

先写积分形式 考虑 d 维状态, m 维 Brown 噪声的方程

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t, \quad X_0 = \xi.$$

其中 $b: [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$, $\sigma: [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^{d \times m}$ 均为 Borel 可测函数.

定义 5.21 (SDE 的解).

一个连续适应过程 X 是上述 SDE 的解, 如果对每个 $t \leq T$, 几乎处处有

$$X_t = \xi + \int_0^t b(s, X_s) ds + \int_0^t \sigma(s, X_s) dW_s,$$

且两个积分均良好定义. 所谓满足 SDE, 始终是指满足这条积分等式.

强解, 弱解与两类唯一性 SDE 的存在性有两种不同问法. 一种已经给定初值和驱动 Brown 运动, 要求用它们生成解; 另一种允许连概率空间和 Brown 运动一起构造, 只要求最终满足方程及规定的初始分布. 这一区别产生了强解和弱解的名称.

定义 5.22 (强解与弱解).

强解问题预先给定概率空间, 滤过, Brown 运动 W 和初值 ξ , 并要求 X_t 适应于

$$\mathcal{G}_t = \sigma(\xi, W_s : 0 \leq s \leq t)$$

的完备化滤过. 因此, 截至 t 的解由初值及截至 t 的 Brown 路径可测地决定. 即使工作空间另有更大的滤过, 强解仍要求这一表示, 不借用额外的随机性来决定解.

弱解问题只给定系数和初始分布, 允许把概率空间, 滤过, Brown 运动与 X 一起构造, 使它们满足积分等式和规定的分布条件.

这里的强弱与路径是否光滑无关, 弱解同样必须满足前面的积分等式. 与两种存在性相对应, 唯一性也要说明比较的是路径本身还是路径的分布.

定义 5.23 (路径唯一性与分布唯一性).

若定义在同一滤过概率空间, 由同一个 W 驱动且具有同一初值的任意两个解 X, Y 都不可区分, 则称该 SDE 具有**路径唯一性**.

若任意两个具有规定初始分布的弱解, 作为路径空间随机元素具有相同分布, 则称该 SDE 具有**分布唯一性或依分布唯一性**.

路径唯一性把两条候选解放在同一个初值和同一个噪声实现下比较; 分布唯一性允许两次构造使用不同的概率空间, 只比较最后得到的路径概率律.

Yamada-Watanabe 定理把这些概念联系起来: 在标准 Brown 驱动的 SDE 框架中, 弱存在性加路径唯一性推出强存在性, 并给出分布唯一性. 弱存在性先保证至少能够造出一组满足方程的过程; 路径唯一性进一步保证, 初值和 Brown 噪声一旦确定, 解就不能再有额外的随机选择. 定理的实质是把这一事实严格转化为解关于初值和噪声的可测函数表示, 见 [Kal21, Theorem 32.14].

全局 Lipschitz 与线性增长条件 接下来需要条件来保证解存在且唯一. 全局 Lipschitz 条件控制系数对状态变化的敏感程度, 使我们能够估计候选解之间的差距. 线性增长条件则控制系数在远处的增长, 帮助排除有限时间内的爆炸. 两者结合, 得到下面常用的存在唯一性定理.

定理 5.24 (强解的存在唯一性).

假设存在常数 $L, K < \infty$, 使对所有 $t \in [0, T]$ 和 $x, y \in \mathbb{R}^d$,

$$|b(t, x) - b(t, y)| + \|\sigma(t, x) - \sigma(t, y)\| \leq L|x - y|,$$

且

$$|b(t, x)|^2 + \|\sigma(t, x)\|^2 \leq K(1 + |x|^2).$$

若 ξ 是 $\mathcal{F}_0$ -可测且 $\xi \in L^2$, 则 SDE 在 $[0, T]$ 上存在唯一强解, 并且

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |X_t|^2 \right] < \infty.$$

证明. 先考虑有界的 Lipschitz 系数. 从 $X_t^{(0)} = \xi$ 出发作 Picard 迭代, 每一步把上一条近似过程代入系数:

$$X_t^{(n+1)} = \xi + \int_0^t b(s, X_s^{(n)}) ds + \int_0^t \sigma(s, X_s^{(n)}) dW_s.$$

因为上一轮近似适应, 下一轮仍然只使用截至当前的噪声. Lipschitz 条件把系数之差控制为过程之差; 对时间积分使用 Cauchy-Schwarz 不等式, 对随机积分使用 Itô 等距与最大不等式, 就能把相邻两轮的平方最大误差控制为上一轮误差的时间积分. 反复迭代得到阶乘型上界, 从而近似过程在平方平均的最大范数下收敛. 同样的估计允许在两个积分中通过极限, 所以极限满足 SDE.

对同一初值和同一 Brown 运动驱动的两个解, 差的估计具有相同形式, 但初始差为零. Gronwall 不等式因此给出两解不可区分, 即路径唯一性.

对一般线性增长系数, 先在大球外截断, 应用上述构造. 不同截断的解在离开较小球以前相同, 因而可以按退出时刻拼接. 线性增长条件与 Gronwall 不等式给出独立于截断半径的估计

$$\mathbb{E} \sup_{t \leq T} |X_t|^2 \leq C_T(1 + \mathbb{E}|\xi|^2).$$

这个估计使在 T 以前离开半径越来越大的球的概率趋于零, 从而排除有限时间爆炸, 并给出结论中的最大矩界. 有界系数下的迭代构造和随后使用的估计见 [Kal21, Theorem 32.3, Proposition 32.6]. $\square$

若只要求局部 Lipschitz, 上述构造仍可在退出有界区域以前进行. 要把解延续到整个有限期限, 则须另外排除爆炸, 例如使用适当的 Lyapunov 估计.

几何 Brown 运动 第5.4节已经通过代入验证了

$$dS_t = \mu S_t dt + \sigma S_t dB_t, \quad S_0 > 0,$$

具有解

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma B_t \right).$$

现在可以进一步说明为什么没有另一个解: 系数 $b(x) = \mu x$ 和 $\sigma(x) = \sigma x$ 满足全局 Lipschitz 与线性增长条件, 所以上面的存在唯一性定理适用. 因而显式公式给出的就是唯一强解.

解始终为正, 则来自指数表示本身. 这一性质要由具体方程说明, 一般的存在唯一性定理并不规定解的取值范围. 接下来把漂移改为均值回复, 再把常数噪声改为平方根噪声, 就能看到系数怎样改变路径和边界行为.

Ornstein-Uhlenbeck 过程 令 $\kappa > 0$, $\theta \in \mathbb{R}$, $\sigma \geq 0$, 考虑

$$dX_t = \kappa(\theta - X_t) dt + \sigma dB_t.$$

当 X_t 高于 θ 时漂移向下, 低于 θ 时漂移向上, 偏离越大, 回复漂移也越大. 但 Brown 噪声仍然不断加入新的变化, 所以均值回复不等于每条路径最终停在 θ .

这是线性方程, 可以沿用积分因子法. 对 $e^{\kappa t} X_t$ 使用乘积公式, $e^{\kappa t}$ 的导数恰好抵消原漂移中的 $-\kappa X_t$. 由于积分因子连续且有限变差, 没有协变差修正, 得到

$$d(e^{\kappa t} X_t) = \kappa \theta e^{\kappa t} dt + \sigma e^{\kappa t} dB_t.$$

积分后整理为

$$X_t = \theta + (X_0 - \theta)e^{-\kappa t} + \sigma \int_0^t e^{-\kappa(t-s)} dB_s.$$

初值相对于中心的偏离按指数衰减. 每次较早的噪声冲击也乘上同样的衰减因子, 因而影响随时间减弱; 较新的冲击则保留更大的权重.

把起点从 0 移到 s , 给定 $\mathcal{F}_s$ 后, 后续随机积分均值为零, 所以

$$\mathbb{E}[X_t | \mathcal{F}_s] = \theta + (X_s - \theta)e^{-\kappa(t-s)}.$$

随机积分具有确定性的指数核. 对核的平方使用 Itô 等距, 得到条件方差

$$\text{Var}(X_t | \mathcal{F}_s) = \frac{\sigma^2}{2\kappa} \left(1 - e^{-2\kappa(t-s)}\right).$$

因此预测均值趋近 θ , 而预测方差趋近 $\sigma^2/(2\kappa)$, 并不会一般地趋于零.

若初值服从 $\mathcal{N}(\theta, \sigma^2/(2\kappa))$ 且独立于 Brown 运动的未来增量, 初值方差的衰减恰好由新噪声的累计补足, 每个时刻都保持这一分布. 这就给出了不变分布. 在应用中, 使用这个模型也就假定了回复中心和回复速度具有相应的稳定性; 参数若随环境改变, 上面的固定参数结论便不再原样适用.

CIR 型平方根扩散与零点行为 CIR 型过程仍使用回复漂移, 但把常数噪声幅度换成 $\sigma\sqrt{X_t}$. 令 $\kappa, \theta, \sigma > 0$, 考虑

$$dX_t = \kappa(\theta - X_t) dt + \sigma\sqrt{X_t} dB_t, \quad X_0 \geq 0.$$

靠近零时, 噪声幅度随平方根减小, 漂移则趋近正值 $\kappa\theta$. 两者怎样共同作用, 决定了过程能否真正到达零点.

这里不能直接应用前面的全局 Lipschitz 定理, 因为平方根函数在零附近不满足该条件. 一维 SDE 的专门比较与唯一性理论仍能证明存在唯一非负强解. 以下使用这一结论, 再区分非负与严格为正.

Feller 条件给出相应的零点行为:

1. 若 $2\kappa\theta \geq \sigma^2$ 且 $X_0 > 0$, 则过程几乎必然不会到达 0, 解始终严格为正;
2. 若 $0 < 2\kappa\theta < \sigma^2$, 则过程可以到达 0, 但标准非负解不会进入负半轴, 并在正漂移作用下瞬时离开边界;
3. 若把参数范围扩展到 $\theta = 0$, 则漂移和噪声在 0 处同时为零, 此时 0 成为吸收边界.

连续方程的非负性还不会自动传给离散算法. 普通 Euler 步把本步系数固定后加上一个 Gauss 增量, 这个增量可能使近似值越过零点, 即使真解没有这种行为. 因此数值计算需要使用保正格式或精确转移方法, 把近似值的取值范围与原方程相协调.

5.6 Girsanov 定理: 在有限期限内改变概率权重

第5.5节中的 Brown 性和漂移都相对于给定测度而言. 若改变样本路径的概率权重, 条件期望随之改变, 同一个过程的漂移也可能不同. Girsanov 定理说明怎样选择权重, 使原 Brown 运动加上一项时间积分以后, 成为新测度下的 Brown 运动.

要完成这件事, 首先需要真正的概率密度. 严格为正还不够, 它的期望必须等于 1. 随机指数提供候选密度, Novikov 条件则给出一条保证其期望保持为 1 的充分条件. 在此基础上, Girsanov 定理再确定新测度下的噪声和漂移.

密度过程与 Novikov 条件 令 ϑ 为可预测过程, 满足 $\int_0^T \vartheta_s^2 ds < \infty$ 几乎必然成立, 并取

$$Z_t = \mathcal{E} \left(- \int_0^t \vartheta_s dB_s \right)_t = \exp \left(- \int_0^t \vartheta_s dB_s - \frac{1}{2} \int_0^t \vartheta_s^2 ds \right).$$

指数中的第二项消除了函数变换产生的漂移, 因此 Z 是从 1 出发的正局部鞅, 也就是上鞅. 这只能先保证 $\mathbb{E}_{\mathbb{P}} Z_T \leq 1$. 若要用 Z_T 重新分配全部概率, 还须有 $\mathbb{E}_{\mathbb{P}} Z_T = 1$.

定理 5.25 (Novikov 充分条件).

若

$$\mathbb{E}_{\mathbb{P}} \left[\exp \left(\frac{1}{2} \int_0^T \vartheta_s^2 ds \right) \right] < \infty,$$

则 Z 是 $[0, T]$ 上的一致可积鞅, 特别地 $\mathbb{E}_{\mathbb{P}}[Z_T] = 1$.

证明. 应用连续局部鞅的 Novikov 判据 [Kal21, Theorem 19.24]. 把过程停止在 T , 记

$$M_t = - \int_0^{t \wedge T} \vartheta_s dB_s, \quad [M]_{\infty} = \int_0^T \vartheta_s^2 ds.$$

判据要求 $\mathbb{E} \exp([M]_\infty/2) < \infty$, 这正是这里的假设. 因而随机指数 $\mathcal{E}(M)$ 一致可积, 且期望保持为初值 1. 限制回 $[0, T]$ 就得到 Z 的结论, 并有 $Z_t = \mathbb{E}_{\mathbb{P}}[Z_T | \mathcal{F}_t]$. $\square$

Novikov 条件的作用是用累计平方的指数矩控制解除局部化时的尾部, 保住随机指数的期望. 它是充分条件, 不满足它并不能据此判定 Z 不是真鞅, 还可以使用其他方法证明. 但若已经知道 $\mathbb{E}Z_T < 1$, 那么 $Z_T d\mathbb{P}$ 的总质量确实小于 1, 不能把它直接当作新的概率测度.

Girsanov 定理及符号检查 得到密度过程后, 就可以判断原 Brown 运动加上怎样的漂移修正, 才会在新测度下成为 Brown 运动. 下文用 ϑ 表示漂移调整, 新测度下的 Brown 运动记为 $B^{\mathbb{Q}}$.

定理 5.26 (一维 Girsanov 定理).

假设上文定义的 Z 为真鞅, 并在 $\mathcal{F}_T$ 上定义

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = Z_T.$$

则 $\mathbb{Q}$ 与 $\mathbb{P}$ 在 $\mathcal{F}_T$ 上等价, 且

$$B_t^{\mathbb{Q}} = B_t + \int_0^t \vartheta_s ds$$

是 $\mathbb{Q}$ 下的标准 Brown 运动.

证明. Z_T 严格为正且期望为 1, 所以它定义了与 $\mathbb{P}$ 等价的概率测度 $\mathbb{Q}$. 接着使用由 Bayes 公式和随机分部积分得到的局部鞅变换: 连续 $\mathbb{P}$ -局部鞅 M 在扣去 $Z^{-1} \cdot [M, Z]$ 后, 成为 $\mathbb{Q}$ -局部鞅, 见 [Kal21, Theorem 19.20, Corollary 19.26].

对当前的随机指数, $dZ_t = -\vartheta_t Z_t dB_t$, 因而 $d[B, Z]_t = -\vartheta_t Z_t dt$. 取 $M = B$, 变换后的局部鞅正是 $B_t + \int_0^t \vartheta_s ds = B_t^{\mathbb{Q}}$. 加上的时间积分连续且有限变差, 所以二次变差仍为 t . 由连续局部鞅的 Brown 刻画, $B^{\mathbb{Q}}$ 是 $\mathbb{Q}$ 下的标准 Brown 运动.

引用中的另一种常见记号是 $Z = \mathcal{E}(V \cdot B)$, 对应 $\tilde{B} = B - \int V ds$. 本文取 $V = -\vartheta$, 因而 Brown 运动的修正项带正号. $\square$

终端密度也决定了此前各时刻的密度. 因为 Z 是真鞅, 对 $t \leq T$,

$$Z_t = \mathbb{E}_{\mathbb{P}}[Z_T | \mathcal{F}_t] = \left. \frac{d\mathbb{Q}}{d\mathbb{P}} \right|_{\mathcal{F}_t}.$$

只使用 $\mathcal{F}_t$ 中的信息时, 看不到终端密度的全部变化, 所以要对它取条件期望. 这解释了为什么需要整个密度过程, 而不只是一个终端随机变量.

漂移的改变可以直接代入计算. 假设在 $\mathbb{P}$ 下

$$dX_t = b_t dt + \sigma_t dB_t.$$

由 $dB_t = dB_t^{\mathbb{Q}} - \vartheta_t dt$, 同一个 X 在 $\mathbb{Q}$ 下满足

$$dX_t = (b_t - \sigma_t \vartheta_t) dt + \sigma_t dB_t^{\mathbb{Q}}.$$

噪声系数没有改变, 漂移减少了 $\sigma_t \vartheta_t$. 因而当 $\sigma_t \neq 0$ 时, 消去 b_t 所需的选择是 $\vartheta_t = b_t / \sigma_t$. 这个代数选择还须满足可预测性, 路径平方可积性及密度真鞅条件, 才真正对应一个概率测度变换.

例 5.27 (带常漂移的 Brown 运动).

在 $\mathbb{P}$ 下令 $X_t = B_t + \mu t$, 并取

$$Z_t = \exp\left(-\mu B_t - \frac{1}{2}\mu^2 t\right).$$

此时 $\vartheta_t = \mu$ 是常数, 有限期限上的 Novikov 条件成立. 因而在由 Z_T 定义的 $\mathbb{Q}$ 下, $B_t^{\mathbb{Q}} =$

$B_t + \mu t = X_t$ 是标准 Brown 运动. 在 $\mathbb{P}$ 下 X_t 的均值为 μt , 在 $\mathbb{Q}$ 下则为零. 这两个平均值可以不同, 因为它们使用不同的概率权重.

原则 5.28 (改变测度与保留路径).

测度变换保留同一可测空间上的坐标值 $X_t(\omega)$, 改变的是计算概率和期望时的权重. 因此同一条实现没有被移动, 过程的分布和漂移却可以改变. 在这里的有限期限内, $\mathbb{P}$ 与 $\mathbb{Q}$ 等价还保证两者具有相同的零概率事件, 但并不要求一般事件的概率相同.

多维情形使用向量 ϑ , 随机指数中的平方换成 $\|\vartheta_t\|^2$, 并有 $W_t^{\mathbb{Q}} = W_t + \int_0^t \vartheta_s ds$. 代回 SDE 后, 漂移的改变量为 $-\sigma_t \vartheta_t$. 因此能够消去的漂移方向必须位于扩散矩阵 σ_t 的值域中; 没有噪声作用的方向, 不能靠这种 Brown 测度变换任意调整漂移.

5.7 生成元, Kolmogorov 方程与 Feynman-Kac

即使已经知道过程满足哪个 SDE, 未来函数的期望仍可能不容易直接算出. 若过程具有 Markov 性, 给定时刻 t 的状态 x 后, 这个期望可以写成确定函数 $u(t, x)$, 不必再把此前整条历史作为自变量.

我们将用 Itô 公式研究 $u(s, X_s)$ 随时间怎样变化. 生成元给出状态变化对条件平均的瞬时贡献; 若 u 表示同一个终端结果的未来期望, 它沿过程的变化应当是鞅, 相应的漂移为零, 这就产生 Kolmogorov 后向方程. 再加入贴现或沿途累计的收益, 同一个论证便得到 Feynman-Kac 公式.

从 Itô 公式读出生成元 考虑时变 Markov 扩散

$$dX_s = b(s, X_s) ds + \sigma(s, X_s) dW_s, \quad a = \sigma \sigma^T.$$

对空间函数 $f \in C^2(\mathbb{R}^d)$, Itô 公式中的时间积分系数为

$$(\mathcal{L}_t f)(x) = \sum_{i=1}^d b_i(t, x) \partial_i f(x) + \frac{1}{2} \sum_{i,k=1}^d a_{ik}(t, x) \partial_{ik} f(x).$$

这定义了时刻 t 的生成元. 第一项计算漂移怎样改变 f , 第二项计算波动通过 f 的曲率怎样改变平均值. 在允许取期望和短时间极限的条件下, $\mathcal{L}_t f(x)$ 就是从 (t, x) 出发时, $f(X)$ 的条件平均每单位时间的初始变化率.

扣除这部分累计变化以后, Itô 公式只留下随机积分:

$$f(X_t) - f(X_0) - \int_0^t (\mathcal{L}_s f)(X_s) ds.$$

它在相应可积条件下是局部鞅, 并在足够的可积性下成为真鞅. 也可以反过来, 要求一组测试函数都满足这种鞅性质, 用以描述过程的分布; 这就是扩散鞅问题的出发点.

若函数还显式依赖时间, 则除状态变化以外, 还要加入函数自身的时间变化. 因而作用于 $u(t, x)$ 的算子是 $\partial_t + \mathcal{L}_t$.

Kolmogorov 后向方程 固定终点 T 和终端函数 g , 以 (t, x) 为起点的过程记作 $X_s^{t,x}$, 定义

$$u(t, x) = \mathbb{E}[g(X_T^{t,x})].$$

这个函数给出从不同起始时刻, 不同起始状态出发时, 同一个终端结果的平均值. 可以直接从现在计算这个平均值, 也可以先让过程运行一小段时间, 再对新状态下的剩余期望取平均. Markov 性和塔性质保证两种计算相同. 后向方程把这种时间一致性写成一个微分关系.

定理 5.29 (Kolmogorov 后向方程).

假设 SDE 具有非爆炸 Markov 解, 系数具有足够正则性, 且上述期望定义的 u 属于 $C^{1,2}$ 并满足使随机积分成为真鞅的增长条件, 则

$$\partial_t u(t, x) + \mathcal{L}_t u(t, x) = 0, \quad 0 \leq t < T,$$

并具有终端条件

$$u(T, x) = g(x).$$

证明. Markov 性与塔性质给出

$$u(t, x) = \mathbb{E}[u(t+h, X_{t+h}^{t,x})],$$

其中 $h > 0$ 足够小. 对 $u(s, X_s^{t,x})$ 在 $[t, t+h]$ 上使用 Itô 公式. 随机积分在假设下是真鞅, 取期望后为零, 因而

$$0 = \mathbb{E} \int_t^{t+h} (\partial_s u + \mathcal{L}_s u)(s, X_s^{t,x}) ds.$$

除以 h 再令 $h \downarrow 0$, 正则性与增长条件允许把极限移入期望, 得到 $(\partial_t u + \mathcal{L}_t u)(t, x) = 0$. 当起始时刻就是 T 时, 没有剩余演化时间, 所以 $u(T, x) = g(x)$.

反方向同样来自 Itô 公式. 若经典解满足 PDE, 则 $u(s, X_s^{t,x})$ 的漂移为零. 在相应可积性下它是真鞅, 因而其期望从 t 到 T 保持不变: $u(t, x) = \mathbb{E}[u(T, X_T^{t,x})] = \mathbb{E}[g(X_T^{t,x})]$. 这也说明为什么 PDE 解的增长条件会影响期望表示. $\square$

对一维 Brown 运动, 生成元为 $\mathcal{L} = \frac{1}{2} \partial_{xx}$, 因而

$$u(t, x) = \mathbb{E}[g(x + B_{T-t})]$$

在 g 的增长和正则性足以支持经典解时满足

$$\partial_t u + \frac{1}{2} \partial_{xx} u = 0, \quad u(T, x) = g(x).$$

终端函数已经给定, 我们从 T 向较早的起始时刻求 u , 所以称为后向热方程. 距离终点的时间越长, 期望就把 g 与方差越大的 Gauss 分布作平均.

前向方程问的是另一件事: 固定初始分布以后, 概率质量怎样随时间移动? 若边缘分布有密度 $p(t, x)$, 相应方程形式上为

$$\partial_t p = \mathcal{L}_t^* p,$$

其中

$$\mathcal{L}_t^* p = - \sum_i \partial_i (b_i p) + \frac{1}{2} \sum_{i,k} \partial_{ik} (a_{ik} p).$$

这个伴随算子来自把作用在测试函数上的导数通过分部积分移到密度上. 前向方程从初始密度求后续密度; 后向方程从终端函数求此前的条件期望. 两者对应不同的未知函数与初终值条件.

带权期望的 Feynman-Kac 公式 纯终端期望只计入 T 时刻的结果. 许多问题还要计入沿途持续发生的收益或成本, 并对不同时间的结果赋予权重. 以 $h(t, x)$ 表示这种运行项, 以 $c(t, x)$ 表示权重率, 定义

$$D_{t,s} = \exp \left(- \int_t^s c(r, X_r^{t,x}) dr \right).$$

$D_{t,s}$ 给出从 s 回到起始时刻 t 的累计权重. 当 c 是利率时, 它是沿路径的贴现因子; 当非负的 c 用作杀死率时, 它对应沿路径的存活权重. 一般的实值 c 也可以用于带权期望, 但不再都具有存活概率的解释.

Feynman-Kac 公式将终端项与运行项放进同一个期望. 推导仍然只用 Itô 公式和乘积公式: 先对剩余价值加权, 再把已经累计的运行项加回, 使总过程的漂移抵消.

定理 5.30 (Feynman–Kac 公式).

假设对每个 (t, x) , 扩散 $X^{t,x}$ 在 $[t, T]$ 上存在且不爆炸, 并且沿其路径有

$$\int_t^T (|c(s, X_s^{t,x})| + |h(s, X_s^{t,x})|) ds < \infty \quad \text{a.s.}$$

若 $u \in C^{1,2}$ 解终值问题

$$\begin{cases} \partial_t u + \mathcal{L}_t u - cu + h = 0, & 0 \leq t < T, \\ u(T, x) = g(x), \end{cases}$$

并且

$$\mathbb{E} \left[D_{t,T} |g(X_T^{t,x})| + \int_t^T D_{t,s} |h(s, X_s^{t,x})| ds \right] < \infty,$$

同时

$$\int_t^\cdot D_{t,s} (\nabla u \sigma)(s, X_s^{t,x}) dW_s$$

是 $[t, T]$ 上的真鞅, 则

$$u(t, x) = \mathbb{E} \left[D_{t,T} g(X_T^{t,x}) + \int_t^T D_{t,s} h(s, X_s^{t,x}) ds \right].$$

证明. 固定起点 (t, x) , 考虑随 s 变化的过程

$$D_{t,s} u(s, X_s^{t,x}) + \int_t^s D_{t,r} h(r, X_r^{t,x}) dr.$$

第一项是剩余部分的加权值, 第二项是截至 s 已经累计的运行项. 对第一项使用乘积公式. $D_{t,s}$ 连续且有限变差, 满足 $dD_{t,s} = -c(s, X_s^{t,x}) D_{t,s} ds$, 所以它与 $u(s, X_s^{t,x})$ 的协变差为零.

Itô 公式贡献 $\partial_s u + \mathcal{L}_s u$, 权重的变化贡献 $-cu$, 已累计运行项的增加贡献 h . 合起来的漂移为

$$D_{t,s} (\partial_s u + \mathcal{L}_s u - cu + h)(s, X_s^{t,x}) ds = 0.$$

剩下的随机积分正是定理中假设为真鞅的那一项. 因此整个过程的期望保持不变. 在 $s = t$ 时它等于 $u(t, x)$; 在 $s = T$ 时, 代入 $u(T, \cdot) = g$ 就得到所述期望表示. $\square$

这里证明的是一个表示结论: 已有的经典解若满足所列可积性和真鞅条件, 就等于这个带权期望. 因此这些条件下的解由期望式确定. 反过来, 先写下期望式以后, 它是否足够光滑, 是否确实解相应 PDE, 还须由扩散和 PDE 的正则性理论证明.

相关标准版本见 [Kal21, Theorem 34.1], 其中处理有界终端函数, 有界非负权重和时齐 Feller 扩散的无源情形; Brown 运动与有界势函数的版本见 [Dur19, Theorem 9.4.1–9.4.5]. 本文允许时变系数并加入源项 h , 上面的证明明确写出了为此增加的运行积分及其漂移抵消.

金融应用中, g 可以表示终端现金流, h 表示沿途现金流, c 表示相应贴现率. 公式把这些现金流的带权期望与 PDE 联系起来. 至于这个期望为什么等于某项资产的价格, 还要由可交易资产, 计价单位, 测度选择及无套利论证说明. 若价值函数不具有经典光滑性, 相应表示可能要用弱解或黏性解解释, 并借助比较原理和唯一性理论完成论证.

5.8 Poisson 随机测度与跳跃

连续扩散没有跳跃, 而违约, 财报跳空或订单到达等变化可能集中在某些时刻. 第4.6节已经用计数过程描述到达次数, 现在把它放进随机积分和二次变差的计算中.

若 N 相对于当前滤过是强度 $\lambda > 0$ 的 Poisson 过程, 则

$$\tilde{N}_t = N_t - \lambda t$$

是鞅. N 的每次跳跃大小为 1, 平方仍为 1; 扣除连续函数 λt 不改变这些跳跃. 因而

$$[N]_t = [\tilde{N}]_t = N_t, \quad \langle \tilde{N} \rangle_t = \lambda t.$$

第一种括号累计实际发生的跳跃平方. 第二种称为可预测二次变差: 它从零出发, 可预测且递增, 并使 $\tilde{N}^2 - \langle \tilde{N} \rangle$ 成为局部鞅. 这里它就是实际平方累计 N 的补偿过程 λt .

在一段没有到达的时间里, $[\tilde{N}]$ 保持不变, 而 $\langle \tilde{N} \rangle$ 仍按模型强度增加. 前者记录已经发生多少, 后者记录可预测的平均累计. 这个例子也说明, 有限变差过程的二次变差为零需要连续性: N 虽然在有限区间上有有限变差, 却有非零的跳跃平方和.

若每次到达还带有大小, 类别等标记, 只记录总次数就不够了. 以 E 为标记空间, Poisson 随机测度 $N(dt, dz)$ 同时记录到达时间和标记. 例如, $N((s, t] \times A)$ 统计这段时间内标记落入 A 的到达次数. 对有限强度的 A , 其 Poisson 参数为 $(t - s)\nu(A)$.

相对于当前滤过, 设补偿测度为 $\nu(dz) dt$, 写作

$$\tilde{N}(dt, dz) = N(dt, dz) - \nu(dz) dt.$$

对在时间与样本点上可预测, 在标记上可测, 且满足右边有限的被积函数 H , 有

$$\mathbb{E} \left[\left(\int_0^T \int_E H(s, z) \tilde{N}(ds, dz) \right)^2 \right] = \mathbb{E} \int_0^T \int_E |H(s, z)|^2 \nu(dz) ds.$$

补偿使简单积分的增量具有零条件平均, Poisson 计数的方差又等于其平均值, 所以得到与 Brown 等距相似的平方平均关系. 从简单函数出发再作平方可积延拓, 就能构造这类补偿积分. 区别在于此时按时间和标记的强度积分, 所得过程也允许跳跃.

同时包含连续噪声与跳跃的 SDE 可以写成

$$dX_t = b(t, X_{t-}) dt + \sigma(t, X_{t-}) dB_t + \int_E \gamma(t, X_{t-}, z) \tilde{N}(dt, dz).$$

γ 根据跳前状态和本次标记决定跳跃的影响. 取 X_{t-} 使系数使用跳跃发生以前的信息, 与第4.3节的可预测性相一致. 上式仍表示相应的积分等式, 跳跃积分须满足所采用构造的可积性条件.

函数经过一次有限跳跃后的变化, 应当直接计算为 $f(X_s) - f(X_{s-})$, 不能只保留一个局部导数近似. 因此对一般一维半鞅和 $f \in C^2(\mathbb{R})$, Itô 公式为

$$\begin{aligned} f(X_t) = f(X_0) &+ \int_0^t f'(X_{s-}) dX_s + \frac{1}{2} \int_0^t f''(X_{s-}) d[X^c]_s \\ &+ \sum_{0 < s \leq t} (f(X_s) - f(X_{s-}) - f'(X_{s-}) \Delta X_s). \end{aligned}$$

第一项积分已经计入跳跃的一阶贡献 $f'(X_{s-}) \Delta X_s$, 所以最后的求和只补上实际函数变化与一阶贡献的差. 连续的二阶修正则仍由 $[X^c]$ 给出. 这样每次跳跃和连续波动都恰好计入一次.

公式不要求跳跃次数有限. 局部化以后, 小跳的一阶余项可以用常数乘以跳幅平方控制, 而半鞅的跳幅平方和在有限区间内有限, 因而能够处理这些余项的累计. 无限活动情形下如何定义补偿积分, 则还需要相应的截断和极限理论.

Lévy-Itô 分解, 小跳补偿, 跳跃 SDE 的存在唯一性, 以及非局部生成元和跳跃版 Girsanov 定理, 将进一步发展这些计算. 使用具体模型时, 补偿的是哪些跳跃必须与方程中的漂移约定一致; 改变补偿写法时, 漂移也要随之调整.

5.9 连续扩散的计算次序

用一个矩计算把前面的工具连起来. 沿用本章的滤过概率空间和 Brown 运动, 取常数 μ, σ 及确定初值 $S_0 > 0$, 考虑乘法扩散 $dS_t = \mu S_t dt + \sigma S_t dB_t$. 我们要计算任意实数 p 对应的 $\mathbb{E}[S_t^p]$.

这条 SDE 表示前面已经写出的时间积分与 Brown 积分之和. 系数满足全局 Lipschitz 和线性增长条件, 因而存在唯一强解; 显式指数解又保证严格正性. 所以即使 p 为负, 也可以在正半轴上对 $f(x) = x^p$ 应用局部化后的 Itô 公式.

先从噪声系数读出 $d[S]_t = \sigma^2 S_t^2 dt$. 再把 $f'(x) = px^{p-1}$ 与 $f''(x) = p(p-1)x^{p-2}$ 代入, 得到

$$d(S_t^p) = \left(p\mu + \frac{1}{2}p(p-1)\sigma^2 \right) S_t^p dt + p\sigma S_t^p dB_t.$$

一阶导数把原漂移变成 $p\mu$, 曲率与二次变差共同给出 $\frac{1}{2}p(p-1)\sigma^2$. 这两个贡献在任何取期望以前就已经出现.

下一步才能去掉随机积分. 由指数解和 Gauss 变量的指数矩, S 在有限期限内具有所需的正负阶矩, 特别地 $\mathbb{E} \int_0^T S_s^{2p} ds < \infty$. 因而被积过程 $p\sigma S_s^p$ 平方可积, 随机积分是真鞅且期望为零.

将微分式还原为积分式并取期望, $m_p(t) = \mathbb{E}[S_t^p]$ 满足一个常系数线性积分方程, 其系数为 $p\mu + \frac{1}{2}p(p-1)\sigma^2$. 解出这个方程便得

$$\mathbb{E}[S_t^p] = S_0^p \exp \left(\left[p\mu + \frac{1}{2}p(p-1)\sigma^2 \right] t \right).$$

当 $p = 1$ 时曲率项消失, 得到原过程的均值增长; 当 $p = 2$ 时, 波动贡献保留在二阶矩中. 对负数 p , 公式仍成立的依据是解的正性和相应的矩可积性.

若问题还要求改变测度, 应先用密度过程确定新测度下的漂移, 再重复上述计算. 若目标是带终端条件的未来期望, 则把同一生成元用于后向方程; 若还有贴现或运行现金流, 就使用乘积公式处理权重, 得到 Feynman-Kac 的漂移抵消. 这些后续步骤由所求的量决定, 无须在每次简单计算中全部重做.

5.10 小结

随机分析在普通微积分之外增加了两件关键的事: 积分要遵守信息的先后顺序, 函数变换要保留路径的二次变差. 简单可预测过程使第一件事可以从有限求和开始, Itô 等距保证推广后的积分有确定含义, Itô 公式则把第二件事写成可计算的修正项.

此后, 求解 SDE, 改变概率测度和计算带权期望, 都沿用这些积分与变量替换规则. 连续有限变差部分按普通路径积分处理, 局部鞅部分按随机积分处理, 跳跃则计入实际函数变化的余项. 将这些计算用于金融市场时, 下一步是把具体现金流, 可交易资产和所用测度放入同一个模型, 再说明计算结果的定价含义.

第六章 从随机过程到金融交易

价格上涨以后, 回看图形很容易知道何时买入最有利. 交易却必须在结果尚未出现时决定. 本章先把这个时间顺序写清楚: 交易者依据已经知道的信息选择持仓, 再承受随后发生的价格变化和现金分配.

持有数量决定同一段价格变化会带来多少损益. 调整持仓又会改变现金余额, 借款和存款还会产生利息. 因此, 研究策略需要同时跟踪资产与现金, 不能只看买卖信号. 未平仓资产的价格变化已经会改变账面财富, 退出则把持仓换成实际出售所得; 成交与资金完成结算也未必发生在同一时刻.

第三章, 第四章和第五章已经提供了描述这些问题所需的工具. 滤过说明当时知道什么, 可预测过程说明持仓何时确定, 随机积分计算持仓与后续增量的累计. 本章先在二叉市场中解出复制持仓, 再推广到多期和连续时间, 最后把模型计算与实际成交比较. 标准理论见 [HP81; Shr04a; Shr04b].

注 6.1 (阅读顺序).

本章的推导使用前面的概率论与随机分析. 对股票, 债券, 衍生品和订单还不熟悉的读者, 可以先读第七章, 再回来看这些交易如何用持仓和现金流表示.

沿用第4.3节, 把一条完整的可能市场历史作为一个样本点. 同一个样本点包含各个时刻的价格, 消息和其他变化, 所以能够在同一概率空间中比较过去与未来. 新信息到来时, 改变的是已经能够判断的事件, 不必为每个时刻另换一个样本空间.

定义 6.2 (金融市场的随机基).

有期限金融模型建立在滤过概率空间

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{0 \leq t \leq T}, \mathbb{P})$$

上, 称其为模型的**随机基**. 滤过满足 $\mathcal{F}_s \subseteq \mathcal{F}_t$ 对 $s \leq t$ 成立, $\mathcal{F}_t$ 表示时刻 t 已经可用的信息, $\mathbb{P}$ 是模型对现实中各种路径发生概率的描述. 连续时间中, 下文采用相应定理所需的完备性和右连续性等通常条件.

价格过程 S 适应于滤过, 表示到了时刻 t , 所研究的当前价格已经可知. 持仓还要遵守更早的确定时点: 用来承担 $(t-1, t]$ 这一期涨跌的 θ_t , 必须是 $\mathcal{F}_{t-1}$ -可测的. 连续时间中, 相应要求就是随机积分被积过程的可预测性. 价格可见与持仓能否事前确定, 是两个不同条件.

若决定的是何时行权或停止, 就使用停时 τ : 对每个 t , 要有 $\{\tau \leq t\} \in \mathcal{F}_t$. 它保证到了当时能够判断行动是否已经发生. 自融资则是资金条件, 要求建仓后的买卖由组合内的资金和资产支付, 没有外部追加或提取. 这使财富变化能够与策略产生的损益对应起来.

本章用 B 表示严格为正且可交易的**计价资产**, 主要取现金或货币市场账户. 因而 S_t/B_t 表示一单位风险资产值多少单位 B . Brown 运动在本章记为 W , 以免与现金账户混淆.

还会出现第二种概率测度 $\mathbb{Q}^B$. 它与 $\mathbb{P}$ 等价, 并使以 B 计价的可交易累计收益成为鞅或局部鞅. $\mathbb{P}$ 用于研究现实中的预测和风险, $\mathbb{Q}^B$ 则用于把复制成本写成条件期望. 后者由市场价格关系决定, 并不因此成为现实频率的估计.

计价资产改变时, 定价测度也须相应改变. 例如使用到期日为 T 的零息债券 $P(t, T)$ 作为计价资产, 对应测度记为 $\mathbb{Q}^T$. 在一般随机利率模型中, 它与现金账户对应的 $\mathbb{Q}^B$ 未必相同.

下一节先用一个只有上涨和下跌两种终态的市场说明这些区别. 我们将直接解出股票和现金的持有数量, 再看为什么计算复制价格用到的概率不必等于现实上涨概率.

6.1 一时期二叉市场: 从状态到复制

只考虑今天与到期日两个时刻. 到期股票有较高和较低两种价格, 今天尚不知道会出现哪一种. 取

$$\Omega = \{\omega_u, \omega_d\}, \quad \mathbb{P}(\omega_u) = p, \quad \mathbb{P}(\omega_d) = 1 - p,$$

其中 $0 < p < 1$, 保证两种结果在现实测度下都有正概率. 信息取为

$$\mathcal{F}_0 = \{\emptyset, \Omega\}, \quad \mathcal{F}_1 = 2^\Omega.$$

因此初始持仓必须在两种结果之间作出同一个选择, 不能分别为上涨和下跌指定不同的事前持仓. 到期以后, 两种结果才被区分.

现金账户按确定倍数增长:

$$B_0 = 1, \quad B_1 = R, \quad R > 0.$$

股票的价格为

$$S_0 > 0, \quad S_1 = \begin{cases} uS_0, & \omega_u, \\ dS_0, & \omega_d, \end{cases} \quad 0 < d < u.$$

u, d, R 都是一期增长倍数, 可以直接比较; u 与 d 并不是发生概率. 这里把较高价格的一支称为上涨支, 较低的一支称为下跌支, 不另要求它们必须分处现价两侧.

以下允许按模型价格买入和卖空股票, 按相同条件存款和借款, 并忽略税费, 买卖价差, 违约和数量限制. 在这个模型中, 套利指初始净投入为零, 到期在所有可能结果下均不亏损, 并且至少在一种正概率结果下盈利的交易.

命题 6.3 (二叉市场的无套利条件).

在上述一时期模型中, 市场无套利当且仅当

$$d < R < u.$$

证明. 先证明必要性. 如果 $R \leq d$, 在时刻 0 借入 S_0 并买入一股股票, 初始净投入为零, 终端财富为

$$S_1 - RS_0 = \begin{cases} (u - R)S_0, & \omega_u, \\ (d - R)S_0, & \omega_d. \end{cases}$$

它在两个状态都非负, 并至少在上涨状态严格为正. 这是一项套利. 如果 $R \geq u$, 则卖空一股股票并把所得 S_0 投入无风险账户, 终端财富

$$RS_0 - S_1$$

在两个状态都非负, 并至少在下落状态严格为正, 同样构成套利. 因而无套利要求 $d < R < u$.

再证明充分性. 当 $d < R < u$ 时, 可以选一个权重 q , 让股票的贴现终值在这个权重下正好平均回今天价格:

$$q = \frac{R - d}{u - d}.$$

于是 $0 < q < 1$, 并且

$$\frac{S_0}{B_0} = q \frac{uS_0}{R} + (1 - q) \frac{dS_0}{R}.$$

令 $\mathbb{Q}^B(\omega_u) = q$, $\mathbb{Q}^B(\omega_d) = 1 - q$. 因为 $p, q \in (0, 1)$, 所以 $\mathbb{Q}^B \sim \mathbb{P}$. 任意零初始成本的自融资组合在 $\mathbb{Q}^B$ 下具有零贴现终端财富期望. 如果它的终端财富在 $\mathbb{P}$ 下几乎处处非负且以正概率严格为正, 等价性会使其在 $\mathbb{Q}^B$ 下也以正概率严格为正, 从而贴现期望严格为正, 产生矛盾. 因此不存在套利. $\square$

现在给出一份合约, 在两种终态分别支付 X_u 与 X_d :

$$X_1 = \begin{cases} X_u, & \omega_u, \\ X_d, & \omega_d. \end{cases}$$

两项都以到期货币金额计量. 我们要用同一组初始持仓, 使组合无论走到哪一支都恰好支付合约金额. 这就称为复制.

持有 Δ 股股票和 β 单位现金账户. 因为 $B_0 = 1$, β 也是初始现金金额, 负值表示借款. 到期需同时满足

$$\begin{aligned} \Delta uS_0 + \beta R &= X_u, \\ \Delta dS_0 + \beta R &= X_d. \end{aligned}$$

两式相减, 先用股票复制两种支付之间的差别; 再用现金账户补足共同部分. 由于 $u \neq d$, 得到唯一解

$$\Delta = \frac{X_u - X_d}{S_0(u - d)}, \quad \beta = \frac{uX_d - dX_u}{R(u - d)}.$$

建立这组持仓所需的初始资金为

$$\begin{aligned} V_0 &= \Delta S_0 + \beta \\ &= \frac{1}{R} (qX_u + (1 - q)X_d) \\ &= \frac{1}{R} \mathbb{E}^{\mathbb{Q}^B} [X_1]. \end{aligned}$$

第一行来自实际的模型持仓成本, 后两行只是将同一个数改写为贴现期望. 因而这里先有复制关系, 再由它得到定价概率的表达.

命题 6.4 (复制, 完备性与风险中性概率).

当 $d < R < u$ 时, 上述二叉市场中的每个二状态现金流都能由股票和无风险账户唯一复制. 因而市场完备, 复制成本是唯一无套利价格, 而

$$q = \frac{R - d}{u - d}$$

是以 B 为计价资产的唯一风险中性上涨概率.

上面的联立方程已经说明每个二状态支付都能唯一复制. 若合约价格高于复制成本, 可以卖出合约并买入复制组合; 若低于复制成本, 则反向交易. 到期的收付彼此抵消, 初始价差却为正, 所以无套利要求两者价格相同. 同时, 使贴现股票为鞅的权重必须满足 $qu + (1 - q)d = R$, 这唯一确定了 q .

整个复制计算没有用到现实上涨概率 p . 原因是组合逐个终态匹配支付, 不论哪一支更常出现, 匹配关系都成立. p 用于预测现实平均收益和风险, q 用于表达由股票与现金价格确定的复制成本. 两者可能数值相同, 但不能因此混用它们的来源和含义.

例 6.5 (一只一期看涨合约).

设

$$S_0 = 100, \quad R = 1.02, \quad u = 1.20, \quad d = 0.90.$$

执行价为 $K = 105$ 的一期欧式看涨合约支付

$$X_u = 15, \quad X_d = 0.$$

无套利条件 $0.90 < 1.02 < 1.20$ 成立, 风险中性上涨概率为

$$q = \frac{1.02 - 0.90}{1.20 - 0.90} = 0.4.$$

复制头寸是

$$\Delta = \frac{15}{120 - 90} = 0.5, \quad \beta = -\frac{45}{1.02} \approx -44.1176.$$

对应的交易是买入半股, 并在时刻 0 借入约 44.1176 单位货币. 到期需要偿还 45: 上涨状态组合支付 $0.5 \times 120 - 45 = 15$, 下跌状态支付 $0.5 \times 90 - 45 = 0$. 初始价格为

$$V_0 = 50 - 44.1176 \approx 5.8824,$$

也等于

$$\frac{1}{1.02} (0.4 \times 15 + 0.6 \times 0).$$

如果真实上涨概率 p 改变, 现实风险评估会改变; 只要这一组可复制资产价格和交易条件不变, 上述无套利价格不会因此自动改变.

注 6.6 (复制依赖哪些交易条件).

相同支付必须同价的论证, 用到了能够买入便宜的一边并卖出贵的一边. 若股票不能卖空, 借入和贷出的利率不同, 或数量与交割条件妨碍反向交易, 其中一边的套利操作就可能无法完成, 结论也可能只剩单边限制或价格区间. 因而解出 Δ, β 以后, 还要确认模型允许建立并维持这组持仓.

6.2 多期离散时间: 鞅, 自融资与基本定理

一时期市场只在开始时选一次持仓. 多期模型允许交易者在每期结束后观察新信息, 再选择下一期的持仓. 但顺序始终相同: 先在 $\mathcal{F}_{t-1}$ 下确定 θ_t , 然后这项持仓才承担 $(t-1, t]$ 的价格和分配变化.

交易日期为

$$\mathbb{T} = \{0, 1, \dots, T\},$$

其中 T 是最后一个离散日期. 市场包含严格为正的计价资产 B , 以及 d 只风险资产. 以下把 B 看作没有另行分配的现金或货币市场账户. 风险资产的适应价格向量记为 S_t , 采用当期分配完成后的除息价格; 当期每单位支付的现金分配记为 ΔD_t .

持有资产既可能通过价格变化取得收益, 也可能收到现金. 所以应把两者一起换算为计价资产单位:

$$\tilde{G}_t = \frac{S_t}{B_t} + \sum_{k=1}^t \frac{\Delta D_k}{B_k}.$$

这称为**贴现累计收益过程**. 每笔分配按它支付时的 B_k 换算, 不把所有历史现金一律除以当前 B_t . 若收到后存入计价资产, $\Delta D_k/B_k$ 正是当时能够购入并继续持有的账户单位数.

用 θ_t 表示第 t 期持有的风险资产数量, ψ_t 表示同一期的现金账户单位数, 合记为

$$\phi_t = (\psi_t, \theta_t), \quad t = 1, \dots, T.$$

要求 ϕ_t 为 $\mathcal{F}_{t-1}$ -可测, 即策略可预测. 初始财富取给定的有限金额. 下一步说明这些持仓怎样由组合自身的资金支付.

定义 6.7 (离散时间自融资策略).

对 $t = 1, \dots, T$, 把本期持仓按除息价格计值并收取当期分配后的财富定义为

$$V_t = \psi_t B_t + \theta_t \cdot (S_t + \Delta D_t).$$

如果在每个中间日期 $t = 1, \dots, T-1$, 这笔财富恰好用于下一期调仓, 即

$$\psi_{t+1} B_t + \theta_{t+1} \cdot S_t = V_t,$$

就称策略 ϕ 是**自融资的**. 初始财富为

$$V_0 = \psi_1 B_0 + \theta_1 \cdot S_0.$$

定义区分了同一日期内的两个时刻. V_t 先计入本期持仓的市值和刚收到的分配, 随后再用这笔财富支付下一期的股票与现金持仓. 自融资等式要求两边金额相等, 因而调仓本身没有从外部增加或取走财富.

把财富除以 B_t , 记 $\tilde{V}_t = V_t/B_t$. 第 t 期开始时已经有 $V_{t-1} = \psi_t B_{t-1} + \theta_t \cdot S_{t-1}$, 与期末财富比较便得

$$\tilde{V}_t - \tilde{V}_{t-1} = \theta_t \cdot \left(\frac{S_t}{B_t} - \frac{S_{t-1}}{B_{t-1}} + \frac{\Delta D_t}{B_t} \right).$$

现金账户以自身为单位计量, 本期持有的 ψ_t 单位在相减时消去. 对各期求和, 得到

$$\tilde{V}_t = \tilde{V}_0 + \sum_{k=1}^t \theta_k \cdot (\tilde{G}_k - \tilde{G}_{k-1}), \quad \tilde{V}_t = \frac{V_t}{B_t}.$$

每项都是已经确定的持仓乘以后来发生的累计收益增量. 可预测性因此恰好落在乘数 θ_k 上, 与第4.3节的交易增益相同. 现金分配须包含在增量中, 否则会把股息支付后的价格下降全部误算成持有损失.

命题 6.8 (贴现收益鞅推出无套利).

假设存在一个与 $\mathbb{P}$ 等价的概率测度 $\mathbb{Q}^B$, 使每只可交易风险资产的贴现累计收益过程 $\tilde{G}$ 都是 $\mathbb{Q}^B$ -鞅. 那么每个有界的可预测自融资策略的贴现财富 $\tilde{V}$ 也是 $\mathbb{Q}^B$ -鞅; 更一般地, 同一结论适用于其随机积分确为真鞅的可积策略. 特别地, 市场不存在由这类策略构成的套利.

证明. 由自融资恒等式,

$$\begin{aligned}\mathbb{E}^{\mathbb{Q}^B}[\tilde{V}_t - \tilde{V}_{t-1} | \mathcal{F}_{t-1}] &= \mathbb{E}^{\mathbb{Q}^B}[\theta_t \cdot (\tilde{G}_t - \tilde{G}_{t-1}) | \mathcal{F}_{t-1}] \\ &= \theta_t \cdot \mathbb{E}^{\mathbb{Q}^B}[\tilde{G}_t - \tilde{G}_{t-1} | \mathcal{F}_{t-1}] \\ &= 0.\end{aligned}$$

持仓在本期开始前已知, 所以可以提出条件期望; 有界性与资产收益的可积性保证乘积可积, 因而这个计算给出真正的鞅等式.

若零初始财富的策略构成套利, 其终端财富在 $\mathbb{P}$ 下非负, 且以正概率为正. 测度等价使这两项性质在 $\mathbb{Q}^B$ 下仍然成立. 又因 $B_T > 0$, 贴现终端财富也应具有严格正的期望. 但鞅性要求 $\mathbb{E}^{\mathbb{Q}^B}[\tilde{V}_T] = \tilde{V}_0 = 0$, 矛盾. $\square$

证明没有说每条交易路径的损益都为零. 它说的是, 事前选择持仓并不会改变各期增量的零条件平均, 因而无法用零成本得到处处不亏且有机会盈利的终端结果. 换成不有界的策略时, 需要另行保证随机积分仍为真鞅, 不能略去证明中的可积性.

命题 6.9 (有限树上的金融市场基本定理).

在有限时间, 有限状态树, 无摩擦, 节点上可双向交易的市场中, 假设树具有单一根节点, 因而 $\mathcal{F}_0 = \{\emptyset, \Omega\}$, 且所有模型内终端状态均由 $\mathbb{P}$ 赋予正概率. 那么:

1. 市场无套利, 当且仅当存在至少一个 $\mathbb{Q}^B \sim \mathbb{P}$, 使全部贴现累计收益过程成为 $\mathbb{Q}^B$ -鞅;
2. 在无套利成立以后, 市场对于全部有限值的 $\mathcal{F}_T$ -可测终端现金流完备, 当且仅当这样的 $\mathbb{Q}^B$ 唯一.

第一项是**存在性**: 没有套利, 就能够找到一组严格为正的路径权重, 使所有可交易资产的贴现累计收益满足鞅关系. 第二项是**唯一性**: 资产已经足以复制每个终端现金流时, 这些价格关系才会完全确定权重.

不完备市场中, 不同定价测度可能都与现有价格相容. 对可复制支付, 它们给出的贴现期望仍等于同一个复制成本; 对不可复制支付, 无套利通常不能单独选出一个价格. 若另选某个测度, 效用或风险准则, 应说明新增加了什么假设, 而不能把这一选择归结为基本定理已经给出的结论.

注 6.10 (从有限树到连续时间).

在无限状态或连续时间中, 还可能出现一系列策略, 每个都不构成套利, 但在极限中趋近于几乎不承担损失的正收益. 因此推广基本定理时, 需要控制这类极限, 例如使用“无免费午餐且风险趋于消失”条件. 对局部有界的半鞅价格, 相应结论涉及等价局部鞅测度; 一般半鞅情形还须采用更一般的表述, 不能把有限树结论逐字搬到连续时间.

6.3 停时与美式合约: Snell 包络

第6.1节和第6.2节研究怎样选持仓. 美式合约还允许选择何时行权. 这项决定同样只能使用当时的信息, 所以行权规则应当是停时, 不能在事后看完价格路径再挑一个最有利日期.

这里先在有限的离散日期 $0, 1, \dots, T$ 上研究这一问题, 并固定定价测度 $\mathbb{Q}^B$. 令适应过程 H_t 表示当时立即行权的现金支付, 换成计价资产单位后为

$$\tilde{H}_t = \frac{H_t}{B_t}.$$

假设每个 $\tilde{H}_t$ 都在 $\mathbb{Q}^B$ 下可积. 用 $\mathcal{T}_{t,T}$ 表示取值于 $\{t, t+1, \dots, T\}$ 的所有停时. 从时刻 t 出发, 最优贴现行权价值为

$$Y_t = \operatorname{ess\,sup}_{\tau \in \mathcal{T}_{t,T}} \mathbb{E}^{\mathbb{Q}^B}[\tilde{H}_\tau | \mathcal{F}_t].$$

每个候选条件期望都随当前信息而变, 所以这里的上确界也是随机变量. 本质上确界要求它几乎必然支配所有候选值, 并且是具有这一性质的最小者. 在有限状态树上, 可以直接在每个节点比较继续等待与立即行权, 用下面的递推算出它.

定义 6.11 (Snell 包络).

过程 Y 称为贴现支付过程 $\tilde{H}$ 的 **Snell 包络**, 如果它是支配 $\tilde{H}$ 的最小 $\mathbb{Q}^B$ -上鞅. 在有限离散时间里, 它可以由向后递推构造:

$$Y_T = \tilde{H}_T, \quad Y_t = \max \left\{ \tilde{H}_t, \mathbb{E}^{\mathbb{Q}^B}[Y_{t+1} | \mathcal{F}_t] \right\}.$$

证明. 递推首先保证 $Y_t \geq \tilde{H}_t$ 和 $Y_t \geq \mathbb{E}^{\mathbb{Q}^B}[Y_{t+1} | \mathcal{F}_t]$, 因而 Y 是支配支付的上鞅. 若另一上鞅也支配 $\tilde{H}$, 从 T 开始向前反推, 它在每个时刻都必须不小于递推给出的 Y_t . 这证明了最小性.

定义首次达到立即行权价值的时刻

$$\tau_t^* = \inf \{s \in \{t, \dots, T\} : Y_s = \tilde{H}_s\}.$$

由于 Y 与 $\tilde{H}$ 适应, 这是停时; 在 T 时二者必相等, 所以它不超过 T . 到达以前, 递推中的较大项是继续价值, 即 $Y_s = \mathbb{E}^{\mathbb{Q}^B}[Y_{s+1} | \mathcal{F}_s]$. 因而从 t 出发停止在 τ_t^* 的过程是鞅, 有

$$Y_t = \mathbb{E}^{\mathbb{Q}^B}[\tilde{H}_{\tau_t^*} | \mathcal{F}_t].$$

对其他允许的停时, 上鞅性与 $Y \geq \tilde{H}$ 给出其条件支付不超过 Y_t . 所以上确界由 τ_t^* 取得, 这也证明了递推与最优停止表达式相同. $\square$

递推比较的是今天立即行权的金额, 与保留权利后下一期最优价值的条件期望. 相等时已经可以停止, 因而上面的首次接触给出最早的最优停时. 在完备的有限市场中, 换回货币单位得到合约价格

$$V_t = B_t Y_t.$$

例 6.12 (一个节点上的行权判断).

假设某节点的立即行权贴现支付为 8, 继续价值为 6.5, 递推便取 $Y_t = 8$, 此时行权最优. 另一个节点若立即行权只能取得 3, 继续价值为 5.2, 就取 $Y_t = 5.2$ 并等待.

两项已经用同一种计价资产换算, 可以直接比较. 继续价值还包含下一期之后的最优选择, 并非只预测下一期最可能出现的股价.

注 6.13 (行权规则与合约安排).

停时说明决定何时作出, 合约规则说明决定如何生效. 实际行权还涉及通知窗口, 自动行权条件, 指派, 交割和结算. 用停时表示止损触发时, 也只能保证触发能够及时辨认, 不能保证跳空后仍按触发价格成交.

此外, 在不完备市场中, 选定某个 $\mathbb{Q}^B$ 后仍可以计算 Snell 包络, 但这一选择属于估值模型, 无套利未必保证所得价格唯一.

6.4 连续时间桥: 半鞅与随机积分增益

连续时间仍然要求先决定持仓, 再承受后续变化. 离散模型中的增益为

$$\sum_{k=1}^t \theta_k \cdot (\tilde{G}_k - \tilde{G}_{k-1}).$$

把交易网格加细时, 不能未经证明就把这些和当成普通路径积分. Brown 路径没有有限总变差, 持仓也可能随机变化. 第5.2节和第5.8节中的半鞅积分, 正是用来定义这种增量累加的.

沿用 $L(X)$ 表示对半鞅 X 可积的可预测过程类. 积分由 X 本身决定, 不依赖所选的半鞅分解. 本节在满足通常条件的随机基上工作, 采用如下市场假设: B 严格为正, 连续且有限变差; S 是适应的 càdlàg d 维除息价格半鞅; D 是从零出发, 适应, 连续且有限变差的累计每单位现金分配过程.

B 描述现金账户的增长, S 描述资产除去已分配现金后的价格, D 记录另外支付的现金. 这里对分配采用连续时间累计的理想化假设. 若股息在离散日期支付, 支付后现金余额还要跳增相应金额, 应按第6.7节那样记录实际收付, 不能省去现金跳变而直接套用这里的持仓写法.

把每笔分配按支付时的计价资产换算, 得到

$$\tilde{G}_t = \frac{S_t}{B_t} + \int_{(0,t]} \frac{1}{B_u} dD_u.$$

这与离散时间的贴现累计收益完全对应, 只是分配求和变成了 Stieltjes 积分.

用可预测过程 ψ 和 θ 分别表示现金账户与风险资产持仓, 要求 $\psi \in L(B)$, 并逐坐标要求 $\theta^i \in L(S^i) \cap L(D^i)$. 价格若在时刻 u 跳跃, 参与这次跳跃盈亏的 θ_u 必须事先确定. 若用适应的 càdlàg 过程 θ 记录调整后的库存, 积分中应使用跳前值 θ_{u-} .

组合价值按当时价格计算为

$$V_t = \psi_t B_t + \theta_t^\top S_t.$$

这个价值等式本身还没有保证自融资. 自融资进一步要求, 组合没有外部注资或提款, 财富只因持有资产的收益而改变:

$$V_t = V_0 + \int_0^t \psi_u dB_u + \int_0^t \theta_u^\top dS_u + \int_0^t \theta_u^\top dD_u.$$

三项分别计算现金账户增长, 风险资产价格变化和现金分配. 调仓所需资金已经在组合内部转移, 不再另外产生一笔收益.

由于 B^{-1} 连续且有限变差, 它与财富的协变差为零. 对 V/B 使用分部积分, 再用价值等式消去现金持仓, 便得到

$$\tilde{V}_t = \tilde{V}_0 + \int_0^t \theta_u^\top d\tilde{G}_u.$$

现金账户以自身为单位后不再有相对价格变化, 因而贴现财富的变化只剩风险资产的贴现累计收益.

定义 6.14 (连续时间自融资增益).

在上述可预测性和可积性条件下,

$$(\theta \cdot \tilde{G})_t = \int_0^t \theta_u^\top d\tilde{G}_u$$

称为持仓 θ 的贴现自融资交易增益.

若存在 $\mathbb{Q}^B \sim \mathbb{P}$ 使 $\tilde{G}$ 为局部鞅, 相应可积策略的增益也先得到局部鞅性质. 要进一步写成

$$\tilde{V}_t = \mathbb{E}^{\mathbb{Q}^B} [\tilde{V}_T | \mathcal{F}_t],$$

还须保证贴现财富是真鞅. 例如, 相应的平方可积估计或停止族的一致可积性可以支持这一步. 仅在积分式中看不见漂移, 还不足以直接交换极限与期望.

连续时间理论还会限制允许的策略, 例如要求财富有统一下界, 排除通过承担无限下行来维持翻倍下注. 这些可容许性条件与自融资不同: 前者限制能承担什么风险, 后者说明钱从哪里来. 实际离散成交及其费用, 将在本章后面的交易例子中另行计算.

例 6.15 (几何 Brown 运动中的测度变换).

设股票价格满足

$$dS_t = \mu S_t dt + \sigma S_t dW_t^\mathbb{P}, \quad S_0 > 0,$$

其中 μ 和 $\sigma > 0$ 为常数, $W^{\mathbb{P}}$ 是现实测度下的 Brown 运动. 漂移和随机波动都与当前价格成正比. μ 是相对价格变化的瞬时漂移率, 与对数价格的漂移率不同. 由上一章的计算, 解为

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t^{\mathbb{P}} \right).$$

所以价格严格为正且连续, 对数价格具有平稳独立的 Gauss 增量, 其漂移率为 $\mu - \sigma^2/2$.

现在假设没有股息, 市场无摩擦, 期限 T 有限, 现金账户按常数短率 r 增长, 即 $B_t = e^{rt}$. 要使贴现股票成为鞅, 希望在新的测度下把股票漂移改为现金增长率 r . 取

$$\vartheta = \frac{\mu - r}{\sigma}, \quad Z_t = \exp \left(-\vartheta W_t^{\mathbb{P}} - \frac{1}{2} \vartheta^2 t \right).$$

ϑ 把超出现金增长率的漂移除以波动强度, 给出所需的 Brown 漂移修正. 它是常数, 所以有限期限上的 Novikov 条件成立, Z 为期望等于 1 的真鞅. 因而

$$\left. \frac{dQ^B}{d\mathbb{P}} \right|_{\mathcal{F}_t} = Z_t$$

定义了与 $\mathbb{P}$ 等价的测度. 由第5.6节,

$$W_t^{Q^B} = W_t^{\mathbb{P}} + \vartheta t$$

是新测度下的 Brown 运动. 把 $dW_t^{\mathbb{P}} = dW_t^{Q^B} - \vartheta dt$ 代入, 原漂移变成 $\mu - \sigma\vartheta = r$, 得到

$$dS_t = rS_t dt + \sigma S_t dW_t^{Q^B}.$$

此时 S_t/B_t 是常数系数的指数鞅, 因而确实为 Q^B -真鞅. 同一个样本点上的股票路径没有改变, 改变的是计算期望所用的权重.

这一步证明了定价测度存在, 尚未单独证明市场完备. 若全部信息恰由这一维 Brown 运动的通常增广滤过给出, 且可交易资产为这只非退化股票和现金账户, 鞅表示定理才进一步给出相应的复制能力及测度唯一性. 若还存在不可交易的风险, 同样的漂移变换未必确定唯一测度.

这个例子将 Girsanov 定理用于第6.4节的贴现交易模型. 连续路径, 常数波动率和 Gauss 对数增量都属于所选假设; 它们没有描述跳价, 随机波动率, 非 Gauss 的收益尾部或报价和流动性的变化. 更一般的半鞅模型可以容纳其中一些现象, 但仍须重新说明相应的积分和定价条件.

注 6.16 (模型持仓怎样用于交易).

模型中的 θ_t 表示已经按模型条件建立的持仓. 将它用于实际交易时, 它至多先给出希望达到的数量, 还要通过订单成交才能实现. 已提交但未成交的订单不会产生相同的持仓收益, 已经成交的出售款也可能尚待结算. 因而比较模型与实绩时, 要用实际成交后的持仓计算, 不把目标数量直接当成已持有数量.

6.5 一个完整例子: 欧式看涨期权的复制与定价

沿用几何 Brown 运动市场, 现在直接构造一份欧式看涨期权的复制策略. 到期支付为 $(S_T - K)^+$, 其中 $K > 0$, $x^+ = \max(x, 0)$. 问题是今天投入多少资金, 此后怎样调整股票与现金, 才能在到期时恰好支付这个金额.

这与第6.1节的问题相同. 二叉模型在每种终态匹配支付, 连续时间则要在每个时刻匹配价值的变化, 并保证调整持仓不依靠额外注资. 下面完整展开标准 Black-Scholes 模型的计算 [Shr04b].

6.5.1 同一份合约, 同一个信息集

固定有限到期日 T , 设 $S_0 > 0$, r, μ 为实常数, $\sigma > 0$ 为常数:

$$dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}, \quad B_t = e^{rt}.$$

B 是现金账户, W 是 Brown 运动. 滤过取 $W^{\mathbb{P}}$ 的自然滤过的通常增广, 因而没有另加不可交易的信息风险. 股票无股息, 看涨合约只在 T 支付一次. 模型允许连续调仓, 股票份额任意细分, 买卖没有价差和费用, 借入与存入现金均按同一个 r 计息.

设期权价值为 $c(t, S_t)$. 先寻找在 $t < T$, $s > 0$ 上属于 $C^{1,2}$ 的函数, 并要求到期满足 $c(T, s) = (s - K)^+$. 光滑性只要求在到期以前成立, 稍后将用显式公式验证.

以 θ_t 表示股票数量, ψ_t 表示现金账户单位数, 现金金额为 $C_t = \psi_t B_t$. 复制组合须同时满足

$$V_t = \theta_t S_t + C_t, \quad dV_t = \theta_t dS_t + rC_t dt.$$

前式计算组合现在值多少, 后式规定这些价值变化只能来自持仓收益. 股票买多了, 钱就从现金账户扣除; 卖出股票后, 所得就回到现金账户. 仅在每个时刻凑出相同的组合市值, 还不能证明整段调整过程是自融资的.

6.5.2 Itô 公式给出复制持仓和定价方程

对候选价值 $c(t, S_t)$ 使用第5.4节的 Itô 公式:

$$dc(t, S_t) = \left(c_t + \mu S_t c_s + \frac{1}{2} \sigma^2 S_t^2 c_{ss} \right) dt + \sigma S_t c_s dW_t^{\mathbb{P}}.$$

所有偏导在 (t, S_t) 处取值. 复制组合的 Brown 系数为 $\theta_t \sigma S_t$, 必须与期权的 $\sigma S_t c_s$ 相等. 因为 $\sigma S_t > 0$, 股票数量被确定为

$$\theta_t = c_s(t, S_t), \quad C_t = c(t, S_t) - S_t c_s(t, S_t).$$

第二式保证组合市值等于期权价值.

还要使两个过程的漂移相等. 股票部分都含 $\mu S_t c_s$, 相减以后消去, 现金部分则按 rC_t 增长. 代入现金余额并整理, 得到

$$c_t + \frac{1}{2} \sigma^2 S_t^2 c_{ss} + r S_t c_s - r c = 0, \quad c(T, s) = (s - K)^+. \quad (6.1)$$

二阶项来自股票二次变差, r 的两项来自持仓融资和现金增长. 现实漂移 μ 消失的原因是股票持仓已经匹配了期权承受的同一股票变化, 而非假定现实中股票只按 r 增长. 因而在这个模型中, 复制价格不需要先估计现实平均涨幅.

6.5.3 把同一方程读成贴现条件期望

前面已经用 Girsanov 定理构造了现金账户对应的 $\mathbb{Q}^B$, 在它下面

$$dS_t = r S_t dt + \sigma S_t dW_t^{\mathbb{Q}^B}.$$

其生成元为 $\mathcal{L}f(s) = r s f'(s) + \frac{1}{2} \sigma^2 s^2 f''(s)$. 配上贴现率 r , 第5.7节中的方程正好成为式 (6.1). 因而自然考虑贴现终端支付的条件期望

$$c(t, S_t) = \mathbb{E}^{\mathbb{Q}^B} \left[e^{-r(T-t)} (S_T - K)^+ \mid \mathcal{F}_t \right]. \quad (6.2)$$

支付满足 $0 \leq (S_T - K)^+ \leq S_T$, 而几何 Brown 运动在有限期限上具有所需矩, 所以期望有限. 我们先算出这个候选函数, 再验证它的光滑性和定价方程. 到期支付在 K 处有折点, 不直接对这个不光滑的终端函数套用经典 Itô 公式.

给定 $S_t = s$, 令 $\tau = T - t > 0$. 新增量独立于 $\mathcal{F}_t$, 所以条件分布可以表示为

$$S_T = s \exp \left((r - \frac{1}{2} \sigma^2) \tau + \sigma \sqrt{\tau} Z \right), \quad Z \sim \mathcal{N}(0, 1).$$

下面只需计算一个截断的正态积分. 以 Φ 和 φ 表示标准正态分布函数与密度, 令

$$d_1 = \frac{\log(s/K) + (r + \frac{1}{2}\sigma^2)\tau}{\sigma\sqrt{\tau}}, \quad d_2 = d_1 - \sigma\sqrt{\tau}.$$

由指数表示, $S_T > K$ 等价于 $Z > -d_2$, 所以在有支付的事件上减去执行价这一部分, 贴现期望为 $Ke^{-r\tau}\Phi(d_2)$.

另一部分是同一事件上的股票价值, 不能只用当前股价乘以该事件概率. 使用配方恒等式 $e^{az-a^2/2}\varphi(z) = \varphi(z-a)$, 取 $a = \sigma\sqrt{\tau}$, 得到

$$e^{-r\tau}\mathbb{E}^{\mathbb{Q}^B}[S_T\mathbf{1}_{\{S_T>K\}} | S_t = s] = s \int_{-d_2}^{\infty} \varphi(z-a) dz = s\Phi(d_1).$$

两部分相减便得

$$c(t, s) = s\Phi(d_1) - Ke^{-r(T-t)}\Phi(d_2). \quad (6.3)$$

$\Phi(d_2)$ 是定价测度下到期实值的条件概率, 不是现实上涨概率. $\Phi(d_1)$ 来自带股票价值权重的积分, 下一步会看到它恰好也是复制所需的持股数量.

6.5.4 验证自融资, 再看现金账户

有了候选价格, 还须检查由它求出的持仓确实自融资. 对显式公式求导时, 恒等式 $s\varphi(d_1) = Ke^{-r\tau}\varphi(d_2)$ 使来自 d_1, d_2 的额外项抵消, 得到

$$\theta_t = \Phi(d_1(t, S_t)), \quad C_t = -Ke^{-r(T-t)}\Phi(d_2(t, S_t)), \quad \psi_t = C_t/B_t.$$

进一步计算有 $c_{ss} = \varphi(d_1)/(s\sigma\sqrt{\tau})$ 和 $c_t = -s\sigma\varphi(d_1)/(2\sqrt{\tau}) - rKe^{-r\tau}\Phi(d_2)$. 代入式 (6.1), 各项相消. 因而再次对 $V_t = c(t, S_t)$ 使用 Itô 公式, 确实得到 $dV_t = \theta_t dS_t + rC_t dt$.

这还不是只对某个中间时刻的验证. 对 $t < T$, 两个持仓过程连续且适应, 所以可预测; 股票数量在 0 与 1 之间, 现金余额绝对值不超过 $Ke^{|r|T}$. 结合股票的二阶矩, 各积分可以延续到到期时刻. 显式价格又在 $t \uparrow T$ 时趋于 $(S_T - K)^+$, 所以终端财富正好匹配支付.

由式 (6.2), 贴现价值是可积终值的条件期望, 因而为真鞅. 组合价值非负, 也满足通常的财富下界要求. 因此这是一条从初始资金开始, 全程自融资的复制策略, 不只是各时刻分别凑出的持仓市值.

取示意参数 $S_0 = K = 100$, $T = 1$ 年, $r = 5\%$, $\sigma = 20\%$. 此时 $d_1 = 0.35$, $d_2 = 0.15$, 初始持仓为

项目	数值
股票数量 θ_0	0.636831
股票市值 $\theta_0 S_0$	63.6831
现金余额 C_0	-53.2325
组合价值 $V_0 = c(0, 100)$	10.4506

投资者用初始资金 10.4506 加上借款 53.2325, 买入约 0.636831 股. 股票价值减去借款, 才是这笔复制组合的净价值.

以后股价和剩余期限改变, 所需股票数量也会改变. 增持消耗现金, 减持收回现金, 余额还按 r 计息. 所以现金账户不能简化为初始借款一直滚存, 必须同时记录全部调仓收付.

6.5.5 把连续复制接回离散交易账

若只在 $0 = t_0 < \dots < t_n < T$ 调仓, 用 θ_k, C_k 表示第 k 次调仓后的股票数量与现金余额. 到下一次调仓前, 股票数量固定, 现金先按利率增长. 假设在 t_{k+1} 按模型价格完成所需交易, 则

$$C_{k+1} = C_k e^{r(t_{k+1}-t_k)} - (\theta_{k+1} - \theta_k)S_{t_{k+1}} - \text{fee}_{k+1}.$$

增持时中间项为支出, 减持时为收入, 最后一项扣除交易费用. 这条等式仍然自融资, 但持仓已经不再连续调整.

即使每次都采用当时的 $\theta_k = \Phi(d_1(t_k, S_{t_k}))$, 两次交易之间的 Delta 仍会改变. 因而离散持仓的终端财富通常不能精确匹配期权支付, 费用也会进一步拉开差距. 最后一次调仓后一直持有到期, 若暂以 S_T 计算股票价值且没有额外退出费, 对冲误差为

$$\varepsilon_T = \theta_n S_T + C_n e^{r(T-t_n)} - (S_T - K)^+.$$

真正卖出股票时, 则用实际净出售所得替换 $\theta_n S_T$. 模型价格与成交价格不同时, 差异也应进入误差, 不能只计算调仓频率的影响.

第9.5节的完整 SMA 例子 (第203页) 使用另一种持仓规则, 但现金计算遵循同样的顺序: 先确定能够使用的信息, 再完成交易, 最后按实际持仓和费用计算财富.

由此可以看清各项数学工具如何共同起作用. Itô 公式确定匹配增量所需的股票数量, 自融资决定现金余额如何变化, Girsanov 变换把同一个复制成本写成贴现期望. 改用离散交易或其他价格模型后, 就应直接计算新的持仓与现金过程, 而不沿用连续复制误差为零的结论.

6.6 点过程示例: 订单到达与因果边界

前面直接给定了价格过程. 若想进一步研究报价怎样变化, 就要把订单提交, 撤单和成交也纳入观察. 先研究这些事件何时发生, 再问它们与价格变化有什么关系, 两个问题不能省成同步.

以 N_t 统计 $[0, t]$ 内一类明确事件的次数, 例如市场化买单. 若相对于当前滤过, N 是第4.6节中强度为 $\lambda > 0$ 的 Poisson 过程, 则

$$\begin{aligned}\mathbb{P}(N_{t+h} - N_t = 1 \mid \mathcal{F}_t) &= \lambda h + o(h), \\ \mathbb{P}(N_{t+h} - N_t \geq 2 \mid \mathcal{F}_t) &= o(h).\end{aligned}$$

第一式来自 $e^{-\lambda h} \lambda h$ 的小时间展开, 第二式说明同一短区间内多次到达的概率比 h 更小. λ 因而是每单位时间的到达次数尺度.

更一般的模型允许到达强度随历史改变. 取非负可预测过程 λ_t , 满足

$$\int_0^t \lambda_s ds < \infty \quad \text{a.s.}$$

对每个 $t \leq T$ 成立, 并要求

$$M_t = N_t - \int_0^t \lambda_s ds$$

是局部鞅. 这用补偿的方式定义条件强度: 从实际到达数中扣除按已有信息预测的累计到达量, 剩下的变化没有局部的条件漂移. 可预测性保证强度不使用尚未到达事件的信息, 但这种模型未必再有独立或平稳增量.

订单簿中应分别统计不同事件. 市场化买入, 市场化卖出, 限价单提交和撤单, 对盘口的作用并不相同. 若以 N_t^+, N_t^- 分别记录市场化买卖, 相应强度为 λ_t^+, λ_t^- , 则补偿过程为

$$M_t^\pm = N_t^\pm - \int_0^t \lambda_s^\pm ds.$$

每次事件还可以附带数量, 方向和场所等标记, 以免把一次小订单与一次大订单当成相同的价格影响.

例如, 考虑一个中间价的候选模型. 设 W 是当前滤过下的一维 Brown 运动, σ 可预测且对每个 $t \leq T$ 有 $\int_0^t \sigma_s^2 ds < \infty$ a.s. 令 T_k 为带标记事件的到达时刻, Z_k 为该次事件标记, 并在有限时间内只考虑有限次到达. 模型可以写为

$$m_t = m_0 + \int_0^t \sigma_s dW_s + \sum_{k: T_k \leq t} g(Z_k).$$

随机积分表示未单独列出的连续变化, 求和项表示所列事件对应的价格跳动. $g(Z_k)$ 必须以价格变化的单位计量, 才能与前两项相加. 这个模型让我们能够讨论到达次数, 标记与中间价的联合变化, 尚未说明一个给定规模的订单能按什么价格成交.

注 6.17 (买单更多, 是否就说明它导致涨价).

较高的 λ_t^+ 表示给定当前信息后, 买入事件预计更密集. 若它与涨价同时出现, 仍可能是同一条消息同时引起了买单和涨价, 也可能是涨价吸引了新的买单. 盘口深度不同, 同样的订单数量还可能对应不同价格变化.

因而从数据拟合出的 g 首先是条件关联的描述, 或某个明确模型中的参数. 要解释额外增加一笔买单会造成多少价格变化, 还要借助可区分共同原因的变化, 或提出并检验相应的因果假设.

如果观察到订单聚集, 自激, 日内季节性或明显的历史依赖, 常数强度 Poisson 模型就可能不够. Hawkes 过程, 一般带标记点过程或队列模型可以用于更细的描述. 但拟合到达规律与证明因果影响仍是不同任务; 实际执行价格也仍须结合订单簿中的可成交数量计算.

6.7 从报价到可实现损益: 同一策略的现金账

第6.2节和第6.4节暂时用同一个模型价格计算买卖和持仓价值. 实际交易中, 中间价可以用于观察资产价值, 最优报价表示当前愿意成交的价格, 整笔订单的平均执行价又可能不同. 下面沿一笔买入后卖出的交易, 分别计算它们对应的结果. 所有数字均为示例假设, 不代表真实资产或当前报价.

初始盘口为

$$b_0 = 100.00, \quad a_0 = 100.10, \quad m_0 = \frac{a_0 + b_0}{2} = 100.05.$$

b_0 是最优买价, a_0 是最优卖价, m_0 是二者的平均. 交易者观察报价后决定买入 $q = 100$ 单位. 假设最优卖价附近的数量不足以完成整笔订单, 实际平均买价为

$$x^{\text{buy}} = 100.12.$$

所以买入价款是

$$qx^{\text{buy}} = 100 \times 100.12 = 10,012,$$

不能仍用屏幕上最初看到的 100.10 计算整笔支出.

另付入场费用 2.00. 假设买入价款的 50% 由借款支付, 本金为 5,006, 其余价款和入场费由自有资金支付. 持有五天, 融资按年化单利 8% 和 365 天一年计算, 则

$$C^{\text{fund}} = 5,006 \times 0.08 \times \frac{5}{365} \approx 5.49.$$

以下金额按分取整, 期间没有现金分配和其他税费. 借款本金最后需要偿还, 但本金本身不是融资费用, 费用是这段时间产生的利息.

五天后观察到

$$b_H = 100.95, \quad a_H = 101.05, \quad m_H = 101.00.$$

先不卖出, 按中间价计算持仓价值, 并只扣已发生的入场费与融资费, 得到**标记损益**

$$\begin{aligned} \Pi_H^{\text{mark}} &= q(m_H - x^{\text{buy}}) - C^{\text{entry}} - C^{\text{fund}} \\ &= 100(101.00 - 100.12) - 2.00 - 5.49 \\ &= 80.51. \end{aligned}$$

它反映以中间价估计的当前净财富变化, 不等于现在已经收到这笔利润, 也尚未扣除未来卖出费用.

再问现在卖出大概能剩多少. 若假设全部 100 单位都能按最优买价 b_H 成交, 并支付退出费 2.00, 得到按最优报价估计的**清算损益**

$$\begin{aligned} \Pi_H^{\text{top quote}} &= q(b_H - x^{\text{buy}}) - C^{\text{entry}} - C^{\text{exit}} - C^{\text{fund}} \\ &= 100(100.95 - 100.12) - 2.00 - 2.00 - 5.49 \\ &= 73.51. \end{aligned}$$

中间价换成买价, 又加入退出费, 所以估计利润减少. 但这仍依赖最优买价能接下全部数量的假设.

最后实际提交卖单, 假定确认的平均卖价为

$$x^{\text{sell}} = 100.92.$$

退出费仍为 2.00, 没有额外结算成本时, **成交净损益**为

$$\begin{aligned}\Pi_H^{\text{exec}} &= q(x^{\text{sell}} - x^{\text{buy}}) - C^{\text{entry}} - C^{\text{exit}} - C^{\text{fund}} \\ &= 100(100.92 - 100.12) - 2.00 - 2.00 - 5.49 \\ &= 70.51.\end{aligned}$$

这里的价差已经来自实际买卖均价, 乘以数量得到整笔交易的价格盈利, 再减去用同一货币计量的全部费用. 三个计算都可以有用, 但分别回答持仓怎样估值, 假定立即出售值多少, 以及实际交易赚了多少钱.

再假设卖出款需要到下一营业日才完成结算. 成交确认以后, 出售价格已经确定, 账户先取得待收结算款, 尚不能把它当作已经交收完成的现金. 若资金因此多占用一天, 就应补计相应融资费用; 结算失败或费用更正也可能改变最终结果. 上面的 70.51 采用的是五天融资及无额外结算成本的示例假设.

图6.1把这些时点分开. 观察报价后才能下单, 成交后才有相应持仓, 退出成交后再完成清算与结算. 比较策略时, 应使用每一步实际发生的记录, 不能用最初的报价替代后续成交.




图 6.1: 从观察到的报价到已结算现金.

例 6.18 (从自有资金核对最终现金).

仍按五天融资且正常结算的上述假设, 初始买入价款和入场费合计为 10,014. 借入 5,006 后, 实际投入的自有资金为

$$V_0 = 10,012 + 2 - 5,006 = 5,008.$$

全部卖出后, 用卖出款支付退出费, 偿还借款本金及利息, 剩余现金为

$$V_H = 100 \times 100.92 - 2 - 5,006 - 5.49 = 5,078.51.$$

因而净财富变化为

$$V_H - V_0 = 5,078.51 - 5,008 = 70.51,$$

与成交净损益相同. 借款本金在开始时提供资金, 结束时归还, 不再作为额外亏损扣一次; 入场费已经计入初始投入, 也不从终点现金再扣一次.

这笔交易中的 100.10 是初始最优卖价, 100.12 是实际买入均价, 101.00 是期末中间价, 100.92 是实际卖出均价. 正因为它们不同, 才会出现 80.51, 73.51 和 70.51 三种结果. 回报率还要在选定其中合适的损益以后, 除以明确的资本基数, 并说明持有期限和资金占用.

自融资在这个例子中的含义并不抽象: 买入所用资金必须有来源, 卖出所得必须扣清尚欠的本金与费用, 中间分配也只能计入一次. 只追踪资产价格而不追踪现金和债务, 就无法完成这项核对.

6.8 把模型放回真实市场

本章的几个例子使用了不同程度的理想化. 二叉模型允许按给定价格双向交易, Black-Scholes 模型进一步允许无费用的连续调仓, 最后的往返交易则明确加入报价深度和融资成本. 它们回答的问题不同, 所以不能把某个模型中的精确复制结论, 直接解释为实际交易也没有误差.

把模型用于具体账户时,先确认它要求的持仓能否建立,当前资金能否承担期间义务,成交与结算是否符合计算采用的条件.已有持仓和未完成订单也会影响实际交易数量.研究给出的是在所述假设下的判断,订单仍须依据账户现状和相应权限另作决定.

后面转向市场本身:股票赋予什么权利,衍生品怎样支付,债券和利率怎样决定现金流的价值,订单又怎样完成交易.理解这些具体安排以后,才能判断应保留哪些模型假设,哪些现金流和成本必须另外计入.

第二部分

随机过程与金融市场

第七章 金融市场基础

第六章已经用股票与现金构造复制策略，并说明自融资怎样限制财富变化。现在回到具体市场，看这些计算中的资产和交易安排究竟是什么。

写下价格 S_t 以前，要知道买卖的是哪一类权利，每单位包含什么。写下利率 r_t 以前，要知道它对应哪种借贷安排。零息债券价格 $P(t, T)$ 表示在 T 取得一单位支付今天需要多少钱，持仓 θ_t 则必须落实为实际能够买卖的数量。相同符号用于不同合约时，还可能有不同的分配，融资和结算条件。

本章依次研究这些问题，背景材料主要参考 [Hul22; Shr04a; Shr04b; TS11]。数学模型总要省略一部分市场细节：连续价格模型可以先研究动态对冲，但若问题转向实际成交成本，买卖价差和订单数量就不能继续略去。关键是让所保留的假设足以回答当前问题。

先从股票开始。股票代表相应的股东权利，新股发行与已有股份转让又有不同的资金流向。从这一区别出发，可以理解一级市场与二级市场，以及为什么成交价格既受公司前景影响，也受资金需要和流动性影响。持有回报则还要把价格变化与期间分配合起来计算。

衍生品接着说明，无须直接持有标的，也可以通过合约改变价格暴露。远期和期货约定未来交易及盈亏收付，期权则允许买方选择是否行使权利。预测市场进一步把特定事件是否发生写成支付条件，由此讨论事件合约价格能够说明怎样的概率判断。这些外部市场信息也会在后面的研究图中使用。

指数和 ETF 处理的是多项资产怎样组合。按规则持有一篮子股票可以分散部分单一公司的风险，但共同的市场变化仍会影响组合。指数数值，跟踪指数的基金份额和围绕指数交易的合约，也需要分别理解。

随后研究债券与利率。债券约定一组未来支付，所以期限，贴现和信用风险会直接影响今天的价格。美债，信用利差和 CDS 从不同角度描述这些问题。美联储与短端美元资金市场又帮助说明融资利率怎样形成，美债为什么既用于投资，也用于抵押融资。

有了这些具体现金流，再讨论贴现与无套利，就能看清哪些价格关系来自可实施的交易比较。最后回到订单簿：报价不等于成交，不同数量可能得到不同均价，资金与资产还须完成交收。这一部分把纸面上的持仓计算接到实际交易成本。

下面的图列出阅读顺序。各节都从具体权利或交易出发，再说明需要怎样的价格与现金流计算。




图 7.1: 金融市场基础的阅读路线

理解这些安排以后，再看价格过程和自融资公式，就能知道每个增量对应哪笔持仓，哪次支付，以及哪些实际交易条件仍留在模型之外。

7.1 资产头寸，价格与策略回报

买入一股股票，首先是取得相应的股东权利。持有期间可能收到分红，以后也可能把股份卖给别人；若使用融资，还要承担利息和还款义务。因此，讨论一笔投资时，既要知道买到了什么，也要知道为此付出了什么。

本节先把这些交易关系说清楚，再用 S_t 描述价格随时间的变化。从价格走到投资回报，还需要加入持有数量，现金分配，费用和实际交易。相同的价格变化，对不同持仓和融资方式可以产生不同的结果。

7.1.1 从资产名称到具体持仓

股票, 债券, 黄金, 银行存款和平台账户余额都可以被称为资产, 但名称还没有说清持有人究竟拥有什么. 即使名称相同, 股份类别, 账户协议, 托管方式或适用法律不同, 持有人能够行使的权利和必须承担的义务也可能不同.

因此, 研究一笔持仓时, 应先知道每个单位代表什么, 持有多少, 以及持有人能否使用, 转让, 质押或赎回它. 还要查清这些权利由谁登记和执行, 在什么情况下会被限制, 冻结或终止, 出现争议时可以向谁追索. 这些问题会影响投资者最终能拿到什么, 不能等到算完估值以后再补上.

定义 7.1 (经济头寸).

本文所说的**经济头寸**, 包括具体持有人在给定账户和制度下拥有的权利及其数量, 也包括与这笔持有不能分开的义务和负担, 例如费用, 税, 融资, 追索和保证金要求. 权利可以来自实物占有, 合同, 股份, 账本记录, 账户安排或平台许可, 其内容须按照相应规则确定.

例 7.2 (券商账户中的普通股持仓).

设投资者在券商账户中持有某上市公司的 100 股普通股. 首先要确认是哪一类普通股, 每股附有什么分红, 表决和转让权利. 公司法和公司章程规定部分股东权利, 账户协议, 托管安排和市场规则则影响这些权利怎样行使, 以及股份怎样交易和结算.

计算收益时, 还须计入这 100 股对应的手续费, 税费及可能存在的融资负担. 只知道公司名称和股数, 尚未说明这笔持仓的全部经济关系.

这里的讨论用于描述具体投资, 不代替法律, 会计或监管各自采用的资产定义. 有经济用途的资源未必能够单独转让; 一项权利要进入市场, 还需要能够核实, 交付和结算. 资产也未必产生现金流或拥有活跃市场, 某些头寸的价格甚至可能为零或为负. 后面的收益率公式因此会另行写明正价格等适用条件.

后文主要研究权利较为标准化的金融资产, 尤其是证券.

定义 7.3.

在本文中, **证券** (security) 是把金融权利表示为相对标准化的单位, 并可以按照相应市场制度发行, 持有或转让的一类资产头寸. 股票和债券是典型的证券, 基金份额及部分其他金融工具在相应制度下也属于证券.

证券持有人拥有的是相应的金融权利. 股东持有股票及其附带的股东权利, 公司的厂房和银行账户仍归公司所有. 债券持有人则依合同享有向发行人请求支付的权利, 具体资产的所有权和担保安排仍须看合同与法律. 至于某种工具在监管上是否属于证券, 应按照所在法域的具体定义判断.

7.1.2 从持有权利到价值与价格

知道持有什么以后, 才能研究未来可以得到什么. 有的权利产生现金分配, 有的提供使用或消费服务, 有的使持有人能够参与治理, 抵押融资或完成结算. 持有结束时, 还可能出售, 赎回, 转换或清算. 与此同时, 维护, 费用, 融资和税等负担也会继续发生.

这些利益不能不加区别地相加. 股息可以直接按货币计量, 居住或控制权带来的好处则需要另外解释. 若要把非现金服务折成金额, 必须有相应证据, 并检查同一好处是否已经反映在现金流或出售价格里. 否则, 给服务取一个名字并列入估值表, 只会增加一个未经支持的数字.

接着才是价值判断. 持有人愿意付多少钱, 会受到可用信息, 已有财富, 其他投资机会, 融资条件和持有期限影响. 模型估值还依赖对未来经营, 风险和退出方式的假设. 因此, 两个人面对相同资产得到不同估值, 可能是经济条件不同, 也可能只是采用了不同的预测. 要比较他们的结论, 应比较这些具体差异.

市场价格回答的是另一个问题: 在某个时刻, 按照某种交易条件, 可以或已经以多少钱交换. 当前价格影响买入成本与放弃其他机会的代价, 也可以用来反问: 要使这个价格合理, 未来必须发生什么? 但由价格反推的假设, 仍要接受经营资料等独立证据的检验.

最后, 估值与成交价格之间存在差异, 还不等于已经赚到这笔差额. 投资者需要实际建立持仓, 承担持有期间的成本与风险, 再通过分配, 使用或退出取得利益. 本节后面将用现金收支和财富变化计算这一过程, 第8.1节则进一步讨论证据能够支持怎样的估值.

7.1.3 资产与交易市场

股票 先从股票看证券怎样连接公司与投资者。

定义 7.4.

股票 (stock) 是股份公司发行并代表股东权益的一类证券。股东通常享有公司未来分配和清算剩余财产的经济索取权, 并按照股份类别和适用规则享有投票, 参与治理及转让股份等权利。

股东拥有股票, 公司拥有机器, 专利和银行账户, 两者不能混同。股份的经济权益与投票权也未必按同样比例分配: 不同类别可以具有不同的控制权安排, 因此分析每股利益时要先确认股份类别。

股票发行以后, 股东还可以把这些权利转让给其他投资者。公司发行新股取得资金, 与投资者之间买卖已有股份, 因而形成了证券市场中两种不同的交易。

一级市场与二级市场 股份及类似股份的交易有更早的历史, 1602 年成立的荷兰东印度公司 (Vereenigde Oostindische Compagnie, VOC) 则是现代公开股票市场的重要历史起点之一。本节先关注其中一个基本区别: 购买新发行的股份, 与接手别人已经持有的股份, 资金流向并不相同。

定义 7.5.

一级市场 (primary market), 也称发行市场, 是新发行证券被出售和分配给投资者的市场。
二级市场 (secondary market) 是已发行证券在市场参与者之间继续转让和交易的市场。

公司发行新股时, 投资者支付认购资金, 公司取得资本, 投资者取得股份。这一过程可以经过投资银行或承销商, 不要求投资者直接向公司办理购买。判断它是否属于发行市场, 关键在于买的是新发行证券。

公司第一次向公众发行股票并进入公开资本市场, 通常称为**首次公开募股** (Initial Public Offering, IPO)。一笔 IPO 可能同时包含新股和原股东出售的存量股份。新股募集资金进入公司, 存量股份的出售所得则归出售股份的原股东。因此, 不能把整笔交易金额都理解成公司新获得的资本。

发行完成后, 股东可以在二级市场卖出股份。平时在交易所买卖上市公司股票, 大多数属于这种交易: 买方的钱付给卖方, 股份从卖方转到买方, 公司通常没有因此收到这笔买入款。

二级市场也会影响一级市场。投资者若预期买入以后很难转让, 初次认购时就会更谨慎。能够在需要时出售股份, 会提高持有证券的吸引力, 从而有助于发行融资。

交易动机与流动性 卖出股票未必意味着看坏公司。投资者可能需要现金偿债, 发现了其他投资机会, 想降低组合风险, 或者必须满足保证金要求。做市商和衍生品交易者也会为了对冲而交易。即使两个人对公司前景的判断相同, 只要资金需要, 持仓, 期限或风险承受能力不同, 也可能一个愿买, 一个愿卖。

股份允许转让, 还不等于随时都能按理想价格卖出。若急于出售时, 附近价格没有足够买单, 投资者就只能等待或降低价格。市场能否在需要的时间内接下所需数量, 是流动性问题。

定义 7.6.

一项资产或一个市场具有较高的**流动性**, 是指参与者能够在较短时间内完成足够数量的交易, 而不必作出过大的价格让步, 交易本身也不会造成过大的价格变化。

参与者多通常有助于寻找对手方, 但更重要的是当时愿意在哪些价格买卖多少。若许多人同时急于卖出, 买方却不愿在原价附近接手, 即使市场参与者很多, 流动性也会迅速恶化。

还要区分市场是否容易成交, 与某位投资者手里是否有足够现金。例如, 一位投资者仍看好 Apple (AAPL), 却需要立即筹钱偿债, 就可能接受低于自己估值的出售价格。他的出售决定同时反映了价值判断和资金约束。因此, 不能只从交易方向推断参与者对公司的看法。

报价, 成交与市场价格 报价表示愿意按什么条件交易, 成交则表示交易已经发生。在限价订单簿中, 每个报价都对应买卖方向, 价格和数量。以 b_t 表示最高的买入报价, 称为**最优买价** (best bid); 以 a_t 表示最低的卖出报价, 称为**最优卖价** (best ask)。买卖价差 (bid-ask spread) 为 $a_t - b_t$, 中间价 (mid price) 为 $m_t := (a_t + b_t)/2$ 。

中间价只是两个报价的平均, 最近成交价是上一笔交易的记录, 它们都不保证一笔新订单能够按这个价格完成. 实际执行价格还取决于订单方向, 数量以及当时可用的报价. 因此, 说某项资产的“当前价格”时, 应说明指的是挂牌价, 买价, 卖价, 中间价, 最近成交价, 还是实际成交价格.

比较价格还要比较交易条件. 应确认是否为同一类权利, 同一个经济单位和同一计价资产, 并核对时间, 交易场所, 账户资格, 结算和交付安排. 所报数量也有意义: 附近价格能接下的数量, 未必足以完成整个订单. 若实际成交数量为 q , 每单位成交价为 x , 忽略费用时的名义交易金额就是 qx , 不能把每单位价格与整笔金额混用.

注 7.7.

每笔已完成交易都有相同数量的买入和卖出. 价格上涨并不意味着成交的买入数量多于卖出数量. 当主动买单不断消耗当前卖价附近的可售数量, 后来的买方若仍要求立即成交, 就需要接受更高卖价. 主动卖单消耗买单时, 则可能迫使后续卖方接受更低价格.

双方接受同一个成交价, 也不要求他们认可同一个估值. 卖方可能已经觉得出售划算, 买方则认为买入以后仍有足够回报; 两者也可能只是面临不同的资金和持仓需要. 成交记录反映的是这些判断与约束在当时达成的交易.

从研究到收款, 还要分清几步. 分析师给出的评估价属于模型估计, 成交价决定交易金额, 扣除费用后的结算款才是卖方所得. 款项若仍以账户余额存在, 持有人还可能面对相应的提取和结算安排. 这些金额可以相互联系, 但不能把估值, 成交和最终可用现金当作同一件事.

7.1.4 价格与收益率

价格与市场预期 持有人通常可以选择继续持有. 若他不急需现金, 仍看好公司, 又没有更有吸引力的机会, 新买方就需要给出足以让他愿意出售的价格. 买方也会比较这个价格与自己预期能够取得的利益. 因而今天的成交, 已经包含双方对未来的判断.

对股票来说, 这种判断涉及未来盈利, 盈利能够持续多久, 经营所需的资本投入, 以及最终有多少利益归属于股东. 投资者还要考虑等待和承担风险需要得到怎样的补偿. 过去的业绩是判断这些问题的证据, 但买方购买的是此后的股东权益.

在这个意义上, 股票市场可以称为**预期市场**: 价格会提前反映参与者对未来的看法. 这并不保证看法正确. 新信息出现时, 价格反应取决于它怎样改变已有判断, 不能只看公布的结果本身是增长还是下降.

例如, 盈利增长 20% 是增长, 但若此前价格已经反映增长 30% 的预期, 新结果仍可能使价格下跌. 一家仍然亏损的公司, 若亏损情况明显好于预期, 股价也可能上涨. 经营变化的方向与相对于预期的差异, 是两个不同问题.

不过, 同一价格也可能由不同假设组合产生. 较高的盈利预期配上较高的要求回报率, 可能与较低的盈利预期配上较低的贴现率得到相近价格. 流动性, 风险溢价, 持仓和资金约束还会参与其中. 所以价格能够帮助我们追问市场要求什么条件, 却不足以单独恢复所有参与者对未来的完整概率判断.

从价格记录到价格过程 选定资产类别, 经济单位, 计价资产和所研究的价格以后, 用 S_t 表示时刻 t 的每单位价格. 例如 $S_t = 200$, 表示一单位资产的价格为 200 单位计价资产. 在比较不同时刻以前, 应让交易场所, 账户资格, 结算和交付等相关条件保持可比.

一个数 S_t 省略了这些交易条件, 所以必须由模型的文字说明补足. 简单模型还常进一步忽略买卖价差, 把买价, 卖价和实际执行价都视为同一个价格. 这样便于先研究收益和定价, 但计算真实订单的结果时, 就需要重新区分不同报价及其可成交数量.

价格始终相对于某种计价资产而言. 写出 200 还不够, 必须知道这 200 是用什么计量的. 后面讨论贴现与无套利时, 会用计价资产 (numéraire) 更系统地处理这一选择.

在未来尚未发生时, S_t 是随机变量; 随时间变化, 这些随机变量组成价格过程. 这个过程描述我们选定的价格怎样变化, 并没有同时解释所有形成价格的经营和交易活动.

现金流, 收益与收益率 先考虑用自有资金买入一单位资产并一直持有的情形. 持有者的收益不仅来自出售价格与买入价格的差额, 也来自期间收到的现金, 例如股票股息或债券票息.

以 D_t 表示这一单位截至 t 已累计支付的现金流, 并令 $G_t := S_t + D_t$. 若在 s 时刻按 $S_s > 0$ 全

额买入, 持有到 t , 暂不计交易费用, 税和融资成本, 则损益为

$$G_t - G_s = S_t - S_s + D_t - D_s.$$

右边分别是价格变化和本次持有期间收到的现金. D_s 以前已经支付的分配不属于这段持有期, 所以要从累计分配中扣去.

例 7.8 (除息).

假设股票除息前价格为 \$100, 每股支付 \$1 股息, 除息后以 \$99 交易. 价格本身确实下降了 1%, 但原股东同时收到每股 \$1 现金. 在忽略税费和其他市场变化的这个例子中, 股东持有的股票与现金合计没有减少, 因而总持有收益为零.

损益回答赚了多少钱. 为了比较不同初始投入, 再把损益除以投入资金, 就得到收益率.

定义 7.9.

在一单位, 全额支付, 买入并持有的上述假设下, 令 $S_s > 0$. 从 s 到 t 的简单价格收益率为

$$R_{s,t}^P := \frac{S_t - S_s}{S_s}.$$

加入持有期间收到的现金流, 得到总收益率

$$R_{s,t} := \frac{S_t - S_s + D_t - D_s}{S_s}.$$

因此, 长期比较股票表现时, 应分清原始价格 (raw price), 复权价格 (adjusted price) 与总回报 (total return) 分别记录了什么. 只看原始价格变化, 可能遗漏股东已经取得的现金分配.

这里的 D_t 只是现金分配的累计, 没有假定收到以后自动买入更多资产. 若把股息重新投入, 持有数量就会改变, 后续收益也会基于新的持仓产生. 这时应当研究包含再投资的总回报财富过程 (total-return wealth process).

对数价格变化与对数收益率 连续多期的增长要相乘. 若两期简单收益率分别为 R_1, R_2 , 初始 \$1 在两期后变成 $(1 + R_1)(1 + R_2)$; 直接相加收益率会遗漏复利项. 对数把这种乘法转换为加法, 因而经常用于描述跨期变化.

定义 7.10.

若 $S_s, S_t > 0$, 且比较的是同一组交易条件下的价格, 从 s 到 t 的对数价格变化定义为

$$r_{s,t} := \log \frac{S_t}{S_s}.$$

金融文献中也常称其为对数价格收益率.

因为 $r_{s,t} = \log(1 + R_{s,t}^P)$, 对 $s < u < t$ 有

$$r_{s,t} = r_{s,u} + r_{u,t}.$$

所以一段较长时间的对数变化, 可以由各小段直接相加. 等价地, $S_t = S_s e^{r_{s,t}}$, 其中 $r_{s,t}$ 表示整个区间的累计连续复利变化; 若要写成单位时间的连续复利率, 还须除以 $t - s$.

当变化较小时, $\log(1 + x) \approx x$, 简单价格收益率与对数价格收益率数值接近. 但这两个量仍有不同定义, 尤其在跨期累计时不能互换计算方法.

这里取对数的是价格之比. 若持有期间还有股息, 或者持仓因交易和再投资而改变, 就要对相应的财富过程研究复利增长. 此外, 对数要求所用数值严格为正, 对可能达到零或变成负数的价格不能直接套用这个定义.

7.1.5 策略, 头寸与财富

头寸与损益 投资者的实际损益同时取决于资产价格变化和持有数量.

定义 7.11.

对一项已经指定单位, 权利类别和持有位置的资产, 时刻 t 的**数量头寸**是指投资者在这一时刻净持有的单位数, 记作 θ_t .

当 $\theta_t > 0$ 时称为**多头头寸**; 当 $\theta_t < 0$ 时称为**空头头寸**; 当 $\theta_t = 0$ 时则表示没有净头寸.

用正负号记录持仓以后, 价格变化对损益的方向便直接进入计算. 多头通常从上涨中获利, 空头通常从下跌中获利. 但持仓方向不等于对公司的主观看法: 一笔空头也可能用于对冲其他持仓.

θ_t 只记录已持有的数量和方向. 它不代替对账户和合约的说明, 例如空头可能附有借券及返还义务. 还要区分当前持仓数量与某一笔订单数量: 下单是调整持仓的打算, 成交以后才改变实际持仓.

沿用前面忽略费用, 税和融资成本的假设, 若从 s 到 t 始终持有固定数量 θ , 就把每单位损益乘以数量:

$$P\&L_{s,t} = \theta(S_t - S_s + D_t - D_s).$$

数量在期间保持不变, 才能直接提出括号. 若期间不断买卖, 就必须按实际持仓和现金收支逐段计算.

仍然只考虑一次买入, 固定数量持有, 最后退出或按期末价格估计持仓价值的情形. 把费用也放进现金收支, 可以写成

$$\Pi_{0:H}^{\text{financial}} = \sum_{\tau=1}^H \Delta D_{\tau}^{\text{cash}} + V_H^{\text{terminal}} - C_0^{\text{entry,all-in}} - C_{0:H}^{\text{funding}} - O_{0:H}^{\text{other}}.$$

这就是期间净分配加期末所得, 再减去买入总支出, 融资成本和其他负担. $C_0^{\text{entry,all-in}}$ 已包含买入价及入场费用, $\Delta D_{\tau}^{\text{cash}}$ 则是整个固定持仓收到的净分配, 不能再乘一次持有数量.

期末项 V_H^{terminal} 有两种含义. 若已经退出, 应使用扣除退出费用后的实际净所得. 若仍然持有, 它只是按事先说明的方法估计的持仓价值, 还应说明是否计入退出费用和出售时的价格冲击. 账面上的期末估值与已经收到的现金不能混为一谈.

这些支出应按实际内容分开. 入场费用已经计入买入总支出, 就不再列入其他费用; 分配若已经扣税, 就不再为同一笔税作第二次扣减.

对多次买卖, 改变持仓并可能使用融资的策略 h , 更直接的办法是跟踪整个账户的净财富:

$$V_t^h = C_t^h + MV_t^h(\theta_t^h).$$

θ_t^h 是实际成交后确认的持仓, MV_t^h 是按已说明方法计算的未平仓头寸价值. 对普通现货, 可以用 $MV_t^h(\theta_t^h) = (\theta_t^h)^\top S_t$. 对合约, 则须按其价值计算方式处理, 不能把合约报价直接当成账户已经拥有的金额.

账户记录要逐笔纳入买卖款, 分配, 费用, 融资, 偿债及保证金相关收支. 为使上式表示净财富, C_t^h 中应同时反映现金和净融资负债; 若另行列示债务, 计算净财富时就要相应扣除. 只计入借款得到的现金而漏掉债务, 会把借来的资金误算成利润. 自由现金转入受限保证金账户, 则要在两个账户之间对应记录.

投资者还可能从策略外追加或取走资金. 以 A_t^h 表示累计外部净注资, 流入取正, 则

$$\Pi_{0:H}^{\text{financial}}(h) = V_H^h - V_0^h - (A_H^h - A_0^h).$$

净财富的增加减去外部投入, 才是策略本身产生的净损益. 终点净财富既包含现金, 也包含债务和未平仓持仓; 已经记入账户的分配或费用, 不应在这个总损益公式外再加减一次.

第6.2节和第6.7节将这一计算落实为逐期的自融资关系和现金记录. 信号与目标仓位说明打算怎样交易, 实际成交及之后的现金流才改变持仓和财富.

算出净损益以后, 还要说明用什么资本作比较. 对经济含义明确的正资本基数 K_0^h , 定义

$$R_{0:H}^{\text{financial}}(h) = \frac{\Pi_{0:H}^{\text{financial}}(h)}{K_0^h}.$$

同一笔损益, 除以资产总价值, 自有资金或其他资本基数, 会得到不同百分比. 因而报告策略回报率时, 买入, 持有, 融资, 退出和资本基数都应说清楚. 仅有资产名称和一段价格变化, 尚未给出完整的投资者回报.

若持有期间还实际享用了居住或其他非现金服务,应说明这些服务带来了什么利益.缺少可靠的货币换算依据时,就与金融损益分别报告,不把使用感受直接加成货币利润.

交易会改变持仓.从 θ_s 调整到 θ_t , 净变化是 $\theta_t - \theta_s$, 但实现这段变化可以包含不同的成交顺序与价格.后面研究执行时,将进一步讨论怎样把当前持仓调整到目标持仓,以及这个过程产生多少成本.

保证金与杠杆 投资者可以使用融资或某些合约,建立大于初始自有资金的市场暴露.与此同时,经纪商和交易对手通常需要一定的担保,以应对头寸亏损和不能履约的风险.

定义 7.12.

保证金 (margin) 是建立或维持某些交易头寸时,投资者须向经纪商,清算机构或其他交易对手提交或保留的现金或合格资产.它用于缓冲潜在损失和履约风险,应与资产头寸及实际借款分别核算.

假设投资者买入价值 \$100 的股票,使用 \$50 自有资金并向经纪商借入 \$50. 初始净财富投入只有 \$50, 但股票价格变化作用于全部 \$100 的持仓.

暂不计利息和费用.股票上涨 10% 时,持仓增值 \$10, 相对于 \$50 自有资金的收益率为 20%. 股票下跌 10% 时,同样的 \$10 亏损也占自有资金的 20%.

股票本身的价格收益率没有因为借款而改变.改变的是投资者承担这段价格变化所用的自有资金,以及融资成本和维持持仓所需的条件.这就是资产价格收益与投资者策略回报必须分开的直接例子.

定义 7.13.

杠杆 (leverage) 是指投资者所承担的市场风险暴露相对于自身净财富的放大程度.

在最简单的单资产情形下,如果资产头寸的市场价值为 $|\theta_t S_t|$, 投资者净财富为 $V_t > 0$, 那么可以粗略地用

$$L_t = \frac{|\theta_t S_t|}{V_t}$$

描述这一头寸相对于净财富的杠杆程度.

这个比例适合先描述单一资产的杠杆.多资产,空头或衍生品组合中,各持仓对同一种市场变化可能相互抵消,也可能相互加强,因而还要结合 Delta, duration 等风险暴露判断.名义金额相加只说明规模,没有完整说明净风险.

价格变化也会改变账户净权益.当头寸亏损而借款等义务仍然存在时,投资者的权益减少,原先提供的保证金便可能不再满足维持头寸的要求.

定义 7.14.

当账户中的保证金或者净权益下降到规定水平以下,交易机构要求投资者补充资金或者抵押物,这种要求称为**追加保证金** (margin call).

如果投资者没有及时满足要求,部分头寸可能被强制平仓.

因此,杠杆不仅放大期末的盈利或亏损,还会影响能否持有到期末.即使资产后来恢复上涨,投资者也可能在此前下跌时因保证金不足而被迫平仓.只比较初始价格和最终价格,会漏掉这种中途退出的可能性.

注 7.15.

股票融资与期货保证金承担不同作用.股票保证金账户往往包含实际贷款:投资者用自有资金加经纪商融资购买股票.期货初始保证金 (initial margin) 则主要是履约担保,建仓时并没有因为只交了一部分保证金,就按合约名义价值借入其余资金.此后的盈亏通过逐日盯市及变动保证金 (variation margin) 结算.

因此,保证金不能一概理解成购买资产的首付款,也不能把缴纳的保证金直接当成已经发生的亏损.它占用了多少资金,是否涉及借款,以后怎样结算,都要看具体交易安排.

同一工具也可以发挥相反的风险作用.期货或期权若抵消已有持仓的风险,可以降低组合的净

暴露; 若用少量保证金建立很大的单向暴露, 则可能显著放大风险. 判断依据是整个持仓及其融资关系, 不能只看工具名称.

投资组合与财富 对同时持有的 n 项资产, 分别记录数量和价格:

$$\theta_t = (\theta_t^1, \dots, \theta_t^n),$$

$$S_t = (S_t^1, \dots, S_t^n).$$

这些向量用于把各项持仓价值相加. 若 C_t 是现金与融资账户的净额, 在简单的现货模型中,

$$V_t = C_t + \sum_{i=1}^n \theta_t^i S_t^i = C_t + \theta_t \cdot S_t.$$

第 i 项是数量乘以每单位价格, 加上现金并计入融资负债, 得到组合净财富.

C_t 可以为负, 表示净融资负担. 受限的保证金资产也须计入相应账户, 但应与可立即支用的现金分开. 净财富与现在能够拿出多少现金, 并不是同一个数.

注 7.16.

假设只是把 \$10 从自由现金账户转入保证金账户, 尚未发生损失结算. 自由现金减少了, 但保证金账户增加了同额资产, 净财富没有因此减少 \$10. 真正改变财富的是随后发生的交易盈亏, 利息, 手续费或违约等结果. 资金受到使用限制与资金已经亏损, 必须分别记录.

对冲把不同持仓放在一起, 使某些市场变化带来的盈亏相互抵消. 持仓若不断调整, 还须把交易引起的账户转移, 投资损益和外部注资分开. 前面的自融资条件 (self-financing condition) 正式说明了没有外部资金流入时, 持仓调整怎样由组合自身的资金完成; 后文将继续使用这一关系讨论定价.

7.1.6 通往随机过程: 价格, 分配与财富

现在可以区分三个随时间变化的量. 价格过程 S_t 记录选定价格的变化, 分配过程 D_t 记录资产已经支付的现金, 策略财富 V_t^h 则取决于投资者实际怎样持仓, 融资和交易. 它们有关联, 但一个价格序列并没有包含另外两者的全部信息.

形成这些变化的经营和交易活动更加复杂. 公司经营, 权利规则, 订单流, 账户资格, 融资, 抵押和结算条件都可能起作用. 一个简单价格模型可以暂时省略其中许多因素, 只要在研究期限内, 这些省略不妨碍它回答当前问题. 若流动性或账户制度突然改变, 原先估计的价格规律就可能不再适用.

影响也会反过来发生. 价格下跌会减少财富和抵押能力, 可能触发追加保证金和出售持仓, 而这些交易又会影晌后续价格. 因而有些问题需要把融资条件和参与者行为一并研究, 不能只给价格指定一条固定的运动方程.

前面的滤过帮助说明决策时已经知道什么, Markov 状态帮助判断哪些历史信息还须保留, 跳跃过程和点过程可以描述集中发生的变化. 在这些基础上, 交易和控制问题再研究行动怎样影响财富. 下一节转向衍生品, 看不同风险怎样通过合约条款变成相应的现金流.

7.2 衍生品与或有现金流

第7.1节和第7.1.5小节讨论了直接持有资产时怎样计算收益. 若看好股票, 可以买入; 若已经持有并担心下跌, 可以卖掉一部分. 衍生品提供了另外的选择: 保留或不持有原资产, 通过一份合约约定未来怎样收付.

例如, 航空公司知道三个月后需要燃油, 却不知道届时采购价格. 它可以今天先约定未来的买入价格. 股票持有人也可以付一笔钱, 换取在价格下跌时按约定价格卖出的权利. 两种安排都改变了投资者承担的风险, 但产生现金流的方式不同.

本节从这些权利和义务出发, 再计算价格变化怎样变成实际盈亏. 通用背景参考 [Hul22; Opt; US 15].

定义 7.17.

金融合约 (financial contract) 是交易双方或多方对未来权利, 义务和现金流作出的具有约束力的约定. 它规定在什么时间或条件下, 由谁交付什么资产, 支付多少现金, 或行使什么权利.

这里使用的是金融建模中的基本含义. 实际履行还取决于适用法律, 市场规则, 清算和违约处理. 因而理解合约时, 既要看到约定支付多少, 也要看怎样完成支付或交付.

定义 7.18.

衍生品 (derivative) 是价值或未来现金流依赖于某项资产, 市场变量或未来事件的金融合约. 用来确定其价值或支付的参考对象称为**标的** (underlying).

标的可以是股票, 商品, 汇率或利率, 也可以是股票指数或波动率. 合约使用它作为计算依据, 不要求交易者同时买入或卖出原资产. 同一份合约既可能增加价格暴露, 也可能抵消已有风险, 取决于它与其他持仓的关系.

定义 7.19.

或有现金流 (contingent cash flow) 是金额或是否发生取决于未来市场情况或事件的现金流.

假设合约规定, 三个月后的股票价格超过 \$100 才支付, 支付金额按超过的部分计算. 规则今天就能写清楚, 最终金额却要等股票价格实现以后才能确定. 若到期支付只取决于 S_T , 就写成

$$X = \Phi(S_T).$$

这里 Φ 是合约已经约定的支付函数. 后面的远期和期权会给出它的具体形式. 计算支付以后, 还要计入取得合约的支出及持有期间的现金流, 才得到投资者的盈亏.

7.2.1 线性衍生品与期货

远期合约 航空公司可以先与交易对手约定未来的购买条件, 把尚不确定的采购价格固定下来. 这就是远期合约的基本用途.

定义 7.20.

远期合约 (forward contract) 是双方现在约定, 在未来时刻 T 按事先确定的价格 K 买卖一定数量标的资产的合约.

假设约定三个月后按 \$100 买入一股股票. 到时股票值 \$120, 多头可以用 \$100 取得价值 \$120 的股票, 经济上获得 \$20. 若股票只值 \$80, 多头仍须按约定支付 \$100, 经济上损失 \$20. 远期没有赋予多头只挑有利结果履约的选择权.

定义 7.21.

实物交割 (physical delivery) 是实际交付约定的标的资产, 同时支付相应价款. **现金结算** (cash settlement) 是按合约规则计算应付差额, 以现金结清, 不交付标的资产.

对一单位远期多头, 到期的净经济支付为

$$S_T - K.$$

现金结算时, 正值表示多头收钱, 负值表示多头付钱. 实物交割时, 则是支付 K 并取得价值为 S_T 的资产; 不能把净值 $S_T - K$ 误当成购买资产时实际需要支付的价款. 空头的净支付相反, 为 $K - S_T$.

这种由到期情况决定的支付称为**到期支付** (payoff). 它与合约今天值多少钱, 以及投资者持有合约最终赚多少钱, 仍有区别. 后者还可能涉及取得合约的成本, 融资和其他费用.

新建远期通常选择一个使合约初始价值为零的交割价, 这个交割价称为该期限的**远期价格** (forward price). 合约签订后, 约定的 K 不随市场变化, 旧合约的当前价值却可以变成正数或负数. 所以今天新签合约应采用的交割价, 与手中旧合约今天值多少, 是两个不同问题.

期货与实际对冲 远期可以逐笔商定条款, 期货则把数量单位, 到期和交割等条件标准化, 让参与者在统一市场中交易.

定义 7.22.

期货合约 (futures contract) 是按交易所规定的标准化条款交易, 由相应期货价格和结算价格的变化产生盈亏的衍生品合约.

与通常的远期相比, 期货还使用中央清算, 保证金和定期盈亏结算. 因而同样一段价格变化, 两者收到或支付现金的时点可能不同. 后面比较远期与期货价格时, 会再用到这个区别.

定义 7.23.

名义金额 (notional amount) 是合约中用于计算现金流或表示价格暴露规模的参考金额.
保证金 (margin) 是为履约而存入的资金或合格抵押品.

例如, 一份合约可以对应 \$100,000 的名义暴露, 建仓时却只要求存入其中一部分金额作为保证金. 这不表示交易者已经买下价值 \$100,000 的标的, 也不表示其余部分必然是一笔借款. 保证金用于承担合约亏损, 盈亏仍按整个合约数量和乘数计算.

定义 7.24.

在这里的期货结算语境中, **逐日盯市** (daily marking to market) 是按每日官方结算价计算持仓盈亏, 并通过相应结算款增加或减少账户资金的安排.

CME 的说明以每日官方结算价确定这项盈亏收付 [CMEc]. 已连续持有的头寸, 本日盈亏相对于上一结算价计算; 建仓当天则从实际开仓价算到当日结算价. 若持有 n 张多头, 每点乘数为 m , 用 F_d 表示第 d 日结算价, 则

$$\Delta\Pi_d = nm(F_d - F_{d-1}).$$

首日把 F_0 取为开仓价. 空头的盈亏符号相反.

例 7.25 (连续两天的期货结算与追加保证金).

以下合约规格和保证金规则全部是教学假设, 不对应任何真实交易所合约. 投资者买入 2 张线性期货, 每张每点为 \$10, 开仓价为 1,000 点. 假定每张初始保证金为 \$2,000, 维持保证金为 \$1,500, 因而一开始存入 \$4,000, 合计维持要求为 \$3,000. 还假定低于维持要求时须补回初始保证金总额, 两天内不改变持仓, 不计费用和利息, 没有其他现金收支或日内追保.

建仓时的名义金额为

$$2 \times 10 \times 1,000 = \$20,000.$$

投资者没有支付 \$20,000 购买标的, 而是以 \$4,000 保证金承担这两张合约的盈亏.

第一日结算价为 1,030, 多头盈利

$$\Delta\Pi_1 = 2 \times 10 \times (1,030 - 1,000) = \$600.$$

结算后保证金余额为 $4,000 + 600 = \$4,600$.

第二日结算价降至 940. 本日从上一结算价 1,030 开始计算, 所以

$$\Delta\Pi_2 = 2 \times 10 \times (940 - 1,030) = -\$1,800.$$

结算后, 补款前的余额为 $4,600 - 1,800 = \$2,800$.

时点	结算价	当日盈亏	补款前余额	追加资金	补款后余额
第一日	1,030	+600	4,600	0	4,600
第二日	940	-1,800	2,800	1,200	4,000

表中除价格以点计外, 金额均为美元. 第二日余额低于 \$3,000 的维持要求, 按本例约定须补回 \$4,000, 因此追加 $4,000 - 2,800 = \$1,200$. 不能只补与维持要求相差的 \$200, 因为本例的补款目标是初始保证金水平.

两天累计盈亏为

$$\Pi_{0:2} = 600 - 1,800 = -\$1,200 = 2 \times 10 \times (940 - 1,000).$$

追加保证金是投入资金, 不会使亏损消失, 也不是另一笔交易亏损. 补款后账户有 \$4,000, 投资者累计投入了 \$5,200, 差额仍为亏损 \$1,200. 若随后恰按 940 平仓且无费用, 就没有新的价格盈亏, 不能再扣一次从开仓算起的 \$1,200.

这个例子只在每天结算时列账, 不表示实际期货市场每天只检查一次风险. CME 清算安排包含日内与日终结算, 必要时还可以要求额外的日内保证金或变动保证金收付 [CMEa]. 每日结算的频率与日内风险监控的频率, 是两件事.

杠杆风险也因此取决于中间路径. 最终价格即使后来回到有利方向, 交易者仍可能在此前亏损时无力补款, 先被迫退出. 初始保证金既不是购买成本, 也不是对最大可能亏损的保证.

例 7.26 (航空公司的燃油对冲).

假设航空公司担心三个月后的燃油采购成本上涨, 可以提前建立数量和期限相匹配的期货多头. 它仍按原有供应体系向燃油供应商采购, 不必为了使用期货, 就改由交易所取得实际所需的燃油.

临近采购时, 可以用同一合约的反向交易结束原持仓, 称为平仓 (close out). 期货累计盈亏与供应商的采购款分别计算, 再合起来看净成本. 若 Π_T^{fut} 以盈利为正, 暂不计额外费用和融资成本, 则

$$\text{对冲后的净采购成本} = \text{实际采购支出} - \Pi_T^{\text{fut}} \approx \text{事先希望锁定的采购成本}.$$

燃油涨价时, 采购支出增加, 期货多头的盈利可以抵消其中一部分. 燃油降价时, 采购变便宜, 期货亏损则抵消部分节省. 对冲的目的在于让合计成本较稳定, 不要求期货账户在每种情况下都盈利.

等式后的近似取决于匹配程度. 实际采购的航空燃油与合约标的可能在品种, 地点和时间上不同, 两种价格不会始终同步. 即使方向大致一致, 变化幅度也可能不同.

定义 7.27.

基差风险 (basis risk) 是被对冲价格与所用衍生品价格不能完全同步变化, 因而在对冲后仍保留的风险.

因此, 企业还要研究残余价格差异和保证金资金需要. 期货可以减小采购成本的不确定性, 却未必同时消除基差与持有期间的现金压力.

例 7.28 (基差作为交易对象).

价格差异不仅可能是对冲留下的风险, 也可能是交易者主动研究的目标. 在**国债基差交易** (Treasury cash-futures basis trade) 中, 交易者可能买入可交割现券, 同时卖出国债期货, 关注两者相对于交割安排和持有成本是否存在价格差异 [AS23; BKM23].

多头现券和空头期货可以抵消一部分共同的利率方向风险, 但交易仍有 repo 融资, 期货保证金和流动性需要. 相对价格尚未按预期收敛以前, 资金压力就可能迫使其减仓. 后面的美债与 repo 内容会继续解释这种看似对冲充分的持仓为什么仍有路径风险.

永续合约 普通期货有固定到期日. 加密货币市场中的**永续合约** (perpetual futures 或 perpetual swap, 简称 perp) 则允许在没有固定到期日的情况下持续持有价格暴露. 其理论与基本安排见 [Ang+22; He+24].

定义 7.29.

永续合约是以标的资产或价格指数为参考, 通常没有固定到期日, 并通过保证金安排维持多头或空头持仓的衍生品合约.

以下只讨论以同一结算货币记账的一单位线性多头. 反向合约和 quanto 合约的保证金计价及盈亏函数不同, 须另行计算. 即使都叫永续, 不同产品与账户模式的风险和结算规则也可能不同.

没有固定到期日, 不等于持仓期间没有结算. 这里最容易混淆的是四件不同的事.

第一, 按标记价格持续重估持仓. 平台可以不断更新标记价格, 用它计算尚未结算的盈亏. 标记价格按产品规则确定, 与参考现货指数和最新成交价各有用途, 未必彼此相等. 对一单位线性多头, 若 M_t 是标记价格, P^{basis} 是当前盈亏计算基准, 未实现盈亏为

$$U_t = M_t - P^{\text{basis}}.$$

尚未发生周期盈亏结算时, 基准通常从实际开仓价格开始; 若产品会结算并重置基准, 就要使用重置后的值. 屏幕上的 U_t 是按标记价计算的持仓结果, 不保证整笔订单能够按这个价格成交.

第二, 及时检查保证金是否足够. 在只含这一笔持仓的简化账户中, 记余额为 B_t , 则账户权益为

$$E_t = B_t + U_t.$$

即使 B_t 暂时没有现金收付, 标记价下跌也会通过 U_t 减少权益. 风险系统可以据此判断是否需要限制交易, 要求补充担保或启动强平, 无须等到下一次资金费收付. Bybit 的相关说明采用标记价格进行强平判断, 因而最新成交价绘制的 K 线可能尚未碰到所显示的强平价格, 风险处置就已触发. 具体触发方式还取决于账户模式, 不能把这一平台的细节直接推广到所有永续产品 [Bybb].

第三, 按约定时点收付资金费. 普通到期期货最终通过交割或到期结算与标的结算价格联系起来. 永续没有同样的到期收敛时刻, 通常借助资金费改变多空持仓成本. 合约相对现货偏贵时, 资金费常使多头付给空头; 偏便宜时, 则可能反过来. 实际费率还取决于合约规定的利率项, 指数和上下限等规则 [Ang+22; He+24].

以 $f_k > 0$ 约定为多头支付, N_{t_k} 表示按合约规则计算的本次计费名义金额, 则多头在资金费时点的有符号收入写为

$$\Delta A_{t_k}^{\text{fund}} = -f_k N_{t_k}.$$

正收入表示收款, 负收入表示付款. 资金费补偿的是相应持仓成本和多空供需差异, 不等于把此前价格涨跌产生的全部盈亏结清.

第四, 将未实现盈亏结算到账户余额, 并重置计算基准. 有些永续产品还会周期性进行这一步. 例如, Bybit 的 USDC 永续结算说明将周期内的未实现盈亏计入余额, 并按结算标记价格重置后续盈亏计算所用的平均入场基准 [Byba]. 这足以说明, “无到期日” 并不决定盈亏结算频率. 周期盈亏结算与资金费即使发生在相近时点, 计算依据也仍然不同.

例 7.30 (资金费尚未收付, 权益已经下降).

以下数值与维持保证金规则均为教学假设, 不代表任何平台的实际强平公式. 假定投资者持有一单位线性永续多头, 实际开仓价为 \$1,000, 投入 \$100 保证金, 账户没有其他持仓, 抵押品价值不另行变化. 暂不计手续费, 资金费和其他收支, 且本段价格变化中尚未发生周期盈亏结算.

标记价格降到 \$960 时,

$$U_t = 960 - 1,000 = -\$40, \quad E_t = 100 - 40 = \$60.$$

余额仍显示 \$100, 不代表账户还具有 \$100 权益. 这笔尚未结算的亏损已经减少了可用于承担风险的净额.

再假定维持保证金始终等于当前标记名义金额的 5%, 且权益不高于维持要求时触发风险处置. 标记价为 \$960 时, 要求为 $960 \times 5\% = \$48$, 权益 \$60 仍高于它. 继续下跌时, 用 M^* 表示本例的触发价格, 则

$$100 + (M^* - 1,000) = 0.05M^*, \quad M^* = \frac{900}{0.95} \approx \$947.37.$$

因而价格只要使权益触及这个假定门槛,即使下一次资金费时间尚未到,也可能启动风险处置.这个数是本例的标记价格门槛,不是保证能够平仓的成交价格.实际执行还取决于当时的订单和流动性,实际平台也会采用自己的保证金及费用规则.

再从上述标记价为 \$960 的安全时点看周期结算.假如此时把浮亏 \$40 结算到账户,余额就从 \$100 变成 \$60,新计算基准变成 \$960,未实现盈亏重置为零.权益在结算前后都是 \$60: 结算前是 $100 - 40$, 结算后是 $60 + 0$. 价格没有再变动时,这一步没有新增第二笔 \$40 损失,也没有使损失消失.此后若继续下跌,新浮亏应从 \$960 算起,不能仍从 \$1,000 计算后再叠加已结算的亏损.

所以,实时重估不等于每秒现金结算,逐日结算也不等于日内不监控风险.传统期货可以在日内监控并追加结算,永续也可以有周期盈亏结算 [Byba; CMEa]. 比较产品时,应分别查清计算价格,风险检查,资金费和盈亏结算的安排,不能只用“实时”与“逐日”两个词概括全部差异.

最后回到总损益.若一单位多头以实际成交价 P_0^{perp} 开仓,在 t 时以实际成交价 P_t^{perp} 全部平仓,以 A_t^{fund} 表示期间累计的有符号资金费收入,忽略其他费用和资金时间价值,则

$$\Pi_t = (P_t^{\text{perp}} - P_0^{\text{perp}}) + A_t^{\text{fund}}.$$

期间已经结算的价格盈亏与最后一段价格盈亏合计,才得到括号中的差额.若从账户记录计算,已经计入余额的盈亏和资金费就不再另算一次.尚未平仓时,可以按标记价格估计总权益,但显示浮盈仍不等于已经锁定的成交利润.

资金费通过改变持仓成本吸引相反方向的交易,但不保证合约价格始终等于参考指数.市场单边需求,抵押品与融资限制,以及流动性变化,都可能使偏离持续.因而永续交易既要计算最终价差,也要考虑整段持有期间的资金费与保证金压力.

算力期货 期货可以按价格指数结算,不一定要向交易者交付实物.不过,把一项经营成本变成可用的合约,首先要说明究竟观察什么价格.

例 7.31 (算力期货).

考虑一家公司计划半年后租用大量 H100 或 B200 算力.它知道资源需求,却尚未确定未来租赁成本,与航空公司的燃油问题相似.这里用这一需求讨论合约设计,不据此假定某个现成市场已经具有足够流动性.

GPU 型号,集群规模,网络结构,数据中心位置,租赁期限和服务质量都会影响采购条件.因而先要选定可比较的单位,再收集符合条件的租赁报价,例如构造按每 GPU-hour 计量的价格指数.合约可以根据这个指数变化计算盈亏,而不直接交付 GPU 或算力服务.

指数和合约条款写出来以后,还需要有人持续报价并承接足够数量.若企业无法以可接受成本建仓或平仓,合约即使设计合理,也难以承担实际对冲任务.

技术迭代还会带来基差风险.半年后的实际需求可能已经从一种 GPU 转向另一种,或需要不同的集群配置.一份很好跟踪 H100 租赁价格的合约,未必能同样跟踪企业完成既定任务所需的有效算力成本.

因此,对冲工具是否有用,既取决于价格基准是否可核查,也取决于它是否贴近企业真正要支付的成本,以及是否能够实际成交.

股指期货 股票指数是按规则计算的数值.所谓“买入 S&P 500”,通常是买入跟踪它的交易所交易基金 (exchange-traded fund, ETF), 指数基金或其他产品,并没有取得一个可以直接交付的指数数值.但合约可以把这个数值用作现金结算依据.

定义 7.32.

股指期货 (stock index futures) 是以股票指数为标的,按合约规定的指数结算水平和乘数计算盈亏的期货合约.

指数本身不能像股票或商品那样交付,所以股指期货通常采用现金结算.设 $F_{0,T}$ 是建仓期货价格, I_T^{settle} 是到期结算指数,每点乘数为 m .对一张一直持有至到期的多头,忽略费用以及中间结算款的利息影响,累计损益为

$$m(I_T^{\text{settle}} - F_{0,T}).$$

这是各次价格差额结算相加后的结果, 与前面的两日期货例子相同. 多张合约再乘以张数, 空头则改变符号. 到期时通常只需完成最后一段结算, 不能把这项累计损益再支付一次.

例 7.33 (利用股指期货降低市场风险).

假设基金持有几百只股票, 仍看好这些公司的长期前景, 但担心接下来几个月市场因经济或利率变化而共同下跌. 它可以出售股票, 也可以保留原持仓并卖出适当数量的股指期货.

若股票组合与指数一同下跌, 空头期货的盈利就能抵消部分股票损失. 合约数量应根据组合对该指数变化的敏感程度确定, 组合与指数表现不同的部分则仍然保留. 因此, 卖出股指期货可以是降低整体风险, 不必表示基金已经看坏每一家持股公司.

要判断这样的对冲是否合适, 还须知道指数由什么组成, 与持仓有多大差异. 后面的市场指数, ETF 和被动投资内容将继续讨论 S&P 500, Nasdaq-100 等指数的构造.

远期和期货价格就是未来价格吗 合约围绕未来价格产生盈亏, 不等于今天的合约报价就是未来现货价格的平均预测. 对能够持有和复制的标的, 今天买入现货并持有到交割日的成本, 已经会约束远期价格.

先考虑一个简单的无套利模型. 资产现价为 $S_0 > 0$, 可以自由买卖和卖空, 持有期间没有股息或其他现金流, 没有交易成本, 并能按同一个确定的连续复利率 r 借贷. 对初始价值为零的新远期, 交割价满足

$$F_{0,T} = S_0 e^{rT}.$$

可以直接看出两边为什么必须相等. 若远期交割价更高, 就借入 S_0 买进现货, 同时卖出远期. 到期交付现货收到远期价款, 偿还 $S_0 e^{rT}$, 留下确定的正差额. 若远期交割价更低, 就卖空现货并将所得贷出, 同时买入远期; 到期按较低交割价取得资产还券, 同样留下正差额. 在这些交易均能实施的假设下, 无套利排除了两种偏离.

因此, 正利率使这一模型的远期价高于现货, 零利率使两者相等, 负利率使远期价低于现货. 这些方向来自融资成本, 本身没有预测到期现货一定上涨或下跌.

若资产支付股息, 现货持有人取得了远期持有人尚未取得的期间现金, 价格关系就要调整. 商品还可能有仓储, 保险和损耗成本, 持有库存也可能为经营提供便利, 称为**便利收益** (convenience yield). 这些收入与成本共同进入**持有成本** (cost of carry) 的分析, 具体关系仍取决于实际可实施的持有和交割方式 [Hul22].

期货还多了中途盈亏结算. 在确定利率等简单条件下, 同期限期货与远期价格可以相同. 利率随机时, 提前收到的盈利可以再投资, 提前支付的亏损则可能需要融资, 现金流时点与利率的关系会使两种价格不同.

现实世界的终价均值记为 $\mathbb{E}^{\mathbb{P}}[S_T]$. 它描述在所采用现实概率判断下, 未来价格平均是多少; $F_{0,T}$ 描述今天新远期的交割报价; S_0 则是现在的现货价格. 只有进一步比较远期报价与现实世界的终价均值, 才进入预期收益和风险补偿问题.

后面的风险中性定价会把价格写成相应测度下的折现期望. 那个期望服务于无套利定价, 与现实测度 $\mathbb{P}$ 下的预测均值仍须区分.

7.2.2 期权与非线性现金流

期权 远期要求按约履行. 若约定未来按 \$100 买入股票, 不能仅因届时股票跌到 \$50 就放弃义务. 期权买方取得的则是选择: 有利时按约行使, 不利时可以放弃.

定义 7.34.

期权 (option) 是赋予买方选择权的衍生品合约. 买方可以按照约定的时间和条件买入或卖出标的, 获得相应现金结算, 或放弃行权. 卖方承担与买方权利相对应的履约义务.

合约须写明**执行价格** (strike price) K , **到期日** (expiration date 或 maturity) T , 标的单位数和行权规则. 按规则使用权利称为**行权** (exercise). 其中, 单位数决定每单位计算要放大多少, 不能只看报价就判断整张合约需要支付多少钱.

定义 7.35.

看涨期权 (call option) 赋予买方按 K 买入标的或获得相应现金结算的权利. **看跌期权** (put option) 赋予买方按 K 卖出标的或获得相应现金结算的权利.

定义 7.36.

欧式期权 (European option) 只能在到期日 T 行权. **美式期权** (American option) 可以在到期日或以前符合合约规定的时刻行权.

European 和 American 在这里是行权规则的名称, 与在哪里交易无关. 先看一单位欧式期权的到期结果. 看涨期权在 $S_T > K$ 时具有正的行权价值, 在 $S_T \leq K$ 时没有正的行权价值, 所以支付为

$$(S_T - K)^+ = \max(S_T - K, 0).$$

看跌期权反过来, 在市场价格低于约定卖价时提供保护, 支付为

$$(K - S_T)^+ = \max(K - S_T, 0).$$

现金结算时, 它们可以直接表示净结算金额; 实物交割时, 它们表示交付和收款合起来的净经济价值.

定义 7.37.

买方为取得期权而支付的价格称为**权利金** (option premium).

到期支付没有减去买入权利的成本. 例如支付为零且最初付了 \$5, 就损失 \$5; 到期收到 \$10 而最初付了 \$7, 忽略费用和资金时间价值, 净利润才是 \$3. 因而“到期值得行权”与“买入期权已经回本”是不同判断.

例 7.38 (欧式看涨期权的支付, 盈亏与回本价格).

假设买入一张以美元现金结算的欧式看涨期权, 执行价为 \$100, 每单位权利金为 \$5, 每张合约包含 100 个标的单位. 单位数及其他条款均为教学假设, 不代表某个真实合约规格. 买方全额支付权利金并持有到期, 不计费用, 税和资金时间价值.

建仓支出为

$$100 \times 5 = \$500.$$

整张合约的到期支付和净盈亏分别为

$$X_T = 100(S_T - 100)^+, \quad \Pi_T = 100(S_T - 100)^+ - 500.$$

三种到期结果如下, 金额均为美元:

到期情况	标的价格 S_T	合约支付 X_T	净盈亏 Π_T
低于执行价	80	0	-500
高于执行价但未回本	103	300	-200
超过回本价格	120	2,000	1,500

第一种情况下, 期权没有到期支付, 权利金全部损失. 第二种情况下, 每单位具有 \$3 的正支付, 整张收到 \$300, 但此前支付了 \$500, 所以仍亏 \$200. 第三种情况下, 收到 $100 \times 20 = \$2,000$, 扣除权利金后赚 \$1,500.

盈亏平衡要求

$$100(S_T - 100) - 500 = 0, \quad S_T = \$105.$$

所以本例的到期回本价格为执行价加每单位权利金, 即 $100 + 5 = 105$. 合约到期出现正支付只需要超过 100, 净盈利则需要超过 105.

这个例子采用现金结算。若改为实物行权，正的净经济支付并不意味着只支付差额就能拿到标的：买方仍须按执行价支付全部交割价款，并取得相应数量的资产。比较实际账户收支时，必须把交割方式一并写清楚。

从线性暴露到非线性现金流 远期多头的支付为 $S_T - K$ 。标的价格每增加一美元，一单位远期的支付就增加一美元，因而是线性暴露。看涨期权在执行价以下支付为零，超过执行价以后才随价格增加，整个支付函数有一个折点。

这使期权不能只靠终价均值来分析。对可积终价，远期平均支付由 $\mathbb{E}[S_T] - K$ 决定；看涨期权的 $\mathbb{E}[(S_T - K)^+]$ 则还取决于价格有多大可能超过 K ，以及超过多少。

例 7.39 (相同均值，不同平均支付)。

用两个假设分布说明这一点。第一种分布中，到期价格必为 100；第二种分布中，到期价格以各 1/2 的概率等于 80 或 120。两者的均值都是 100。

取 $K = 100$ ，一单位远期多头在第一种分布中的平均支付为零，在第二种分布中也为 $(-20 + 20)/2 = 0$ 。看涨期权在第一种分布中支付为零，第二种分布中的平均支付却为

$$\frac{1}{2}(80 - 100)^+ + \frac{1}{2}(120 - 100)^+ = 10.$$

因此，相同的终价均值可以对应不同的期权平均支付。这里比较的是指定分布下的支付，尚未计入权利金和贴现，也没有据此确定市场期权价格。

到期支付与到期前的期权价值也要分开。支付函数在执行价处有折点，到期前价值则还取决于剩余时间以及未来价格的分布。在足够光滑的定价模型中，记价值为 V ，保持其他输入不变，对标的价格的一阶敏感度为

$$\Delta = \frac{\partial V}{\partial S},$$

称为 Delta。它说明标的发生小幅变化时，期权价值大致改变多少。Delta 随标的价格变化的速度为

$$\Gamma = \frac{\partial^2 V}{\partial S^2},$$

称为 Gamma。因而今天按某个 Delta 建立的对冲，标的移动以后未必仍然合适。

未来分布的波动和尾部也会影响期权价值。用股票或期货抵消主要方向风险以后，仍可能留下波动率及其他风险。后面的定价与动态对冲将逐步说明这些敏感度，这里先保留它们各自回答的问题 [Hul22]。

买方的权利与卖方的义务 选择权属于买方，对应的履约义务由卖方承担。对全额支付权利金并单独持有的普通看涨期权买方，忽略费用和融资，最多损失这笔权利金；标的上涨时，到期支付可以继续增加。实物行权后取得的股票则是新的持仓，其后续风险要另外计算。

没有对应对冲的看涨期权卖方相反。收入最多是最初收取的权利金，但若标的价格没有上界，履约损失也没有有限上界。初始收到一笔现金，不表示这笔现金已经成为没有后续义务的利润 [Opt; US 15]。

因此，分析期权风险时，要看买方还是卖方，看涨还是看跌，执行价，到期日和合约单位数，还要看它与已有持仓怎样配合。同一张期权单独持有时的风险，与加入股票或其他期权以后的组合风险，可能明显不同。

7.2.3 交易结构与风险理解

做市商 买入看涨期权时，对手方未必是一个完全看空标的的投资者。它也可能是做市商，先承接客户交易，再管理成交以后留下的风险。

定义 7.40。

做市商 (market maker) 是按相应市场制度持续或经常提供买卖报价，并通过暂时承担库存和价格风险提供流动性的交易者或机构。

定义 7.41.

买价 (bid) 是愿意买入的报价, 卖价 (ask) 是愿意卖出的报价. 卖价与买价之差称为买卖价差 (bid-ask spread).

例 7.42 (期权做市).

假设期权每单位报价为

$$\text{Bid} = 4.90, \quad \text{Ask} = 5.10.$$

在报价有效且数量足够时, 立即买入通常按卖价 5.10 成交, 立即卖出通常按买价 4.90 成交. 若报价不变, 买入后马上卖出, 每单位价差损失为 $5.10 - 4.90 = 0.20$, 还未计手续费. 整张合约的金额须再乘以相应单位数.

做市商先提供对手方, 使客户不必等另一个最终投资者同时产生相反需求. 但买卖需求未必立即配对, 成交以后可能留下一段库存, 所以价差也不是保证取得的净利润.

例如, 卖出普通看涨期权会增加负 Delta. 做市商若要抵消它, 可以买入股票或合适的期货. 不过, 它首先查看整个账户的净风险: 其他执行价, 到期日或相反方向的持仓可能已经抵消一部分暴露. 因而不能仅看到客户买入看涨期权, 就断言做市商必定按固定数量买入现货.

即使当时已经完成 Delta 对冲, 标的继续变化时, Gamma 也会使 Delta 改变, 可能需要再调仓. 跳价, 对冲误差, 流动性不足以及融资和清算要求, 都会影响这一过程 [Hul22]. 做市商管理的是这些风险与报价收益之间的关系, 用日常语言中的“庄家”概括它, 容易遗漏这一职能.

同一标的往往有许多执行价和到期日不同的期权, 各份合约的买卖需求并不同步. 做市商把这些交易集中到一个账户中比较和对冲, 可以减少逐个寻找完全匹配对手方的困难, 但并不保证每个合约在所有时候都有相同的流动性.

衍生品风险取决于头寸结构 没有原有采购或持仓需要, 却以很少保证金建立巨大的方向性期货头寸, 是在增加价格风险. 裸卖期权也可能以有限权利金换取很大的尾部损失. 相同工具若与原有业务或资产配合, 却可能减少净风险: 航空公司的期货多头抵消采购涨价, 股票组合的股指期货空头抵消部分共同下跌.

看跌期权的保护可以直接算出来.

例 7.43 (股票加看跌期权).

以下仍为教学假设, 按一股及一单位对应期权计算. 投资者以 \$100 买入股票, 同时支付 \$3 买入执行价为 \$95 的欧式看跌期权, 两者都持有至同一到期日. 假设没有股息, 费用, 税和融资成本, 忽略资金时间价值. 总初始投入为 $100 + 3 = \$103$.

到期时, 股票价值与看跌期权支付合计为

$$S_T + (95 - S_T)^+ = \max(S_T, 95).$$

因而组合净盈亏为

$$\Pi_T = \max(S_T, 95) - 103.$$

若股价跌到 \$80, 股票值 \$80, 期权支付 \$15, 合计 \$95, 净亏 \$8. 若股价涨到 \$120, 期权没有支付, 股票值 \$120, 净赚 \$17. 在这些假设下, 到期最大亏损是 \$8: 股票买价与执行价之差 \$5, 加上权利金 \$3.

保护减少了极端下跌时的损失, 代价是支付权利金, 上涨时也会少赚这笔成本. 这里的下界是两项持仓同时保留到期并按约履行时的经济结果, 不是任意中间时点都能立即提取的现金.

因此, 评价衍生品风险要把合约放回完整账户, 同时看已有持仓, 合约数量, 借款和流动性需要. 合约名称本身不能说明它是在增加风险, 还是在为已有风险提供保护.

衍生品为什么会需要随机过程 普通欧式期权的到期支付可以写成

$$X = \Phi(S_T).$$

若只求时刻 0 的价格, 已经确定贴现因子, 并知道适当定价测度下 S_T 的分布, 确实可以用一个终端期望完成静态定价. 这解释了为什么有些欧式定价公式最后只出现终价分布. 若贴现本身随机, 则还须处理它与支付的联合变化, 不能只给出终价边缘分布就结束.

但到期前还有价值变化, 提前平仓和动态对冲. 今天选择多少股票对冲, 明天应怎样调整, 都需要知道价格随时间怎样演化, 以及新信息出现后条件分布怎样改变. 这时要研究整个过程

$$(S_t)_{0 \leq t \leq T}.$$

前面的两日期货例子也说明了同一件事: 终点价差可以概括累计价格盈亏, 却不能概括中途需要支付多少保证金. 永续还会沿途收付资金费, 并可能在原定退出时间以前触发风险处置.

例 7.44 (路径依赖).

亚洲期权 (Asian option) 的支付可以取决于一段时间的平均价格, 障碍期权 (barrier option) 的支付则可能取决于价格是否曾经触及某个水平. 两条路径即使具有相同终价, 平均价格或是否触及障碍仍可能不同, 因而得到不同支付. 这类合约可以写成路径函数

$$X = \Phi((S_t)_{0 \leq t \leq T}).$$

美式期权又增加了行动时点的选择. 持有人在允许行权的时刻, 要比较立即行权取得的价值, 与保留权利继续等待的价值. 选择只能依据当时已有信息, 这正是**最优停时** (optimal stopping) 问题, 与前面介绍的停时和 Snell 包络相连.

所以, 随机过程既用于研究到期前价值和对冲怎样变化, 也用于处理直接依赖路径的支付或行权选择. 数学模型可以围绕支付函数展开, 实际账户计算则还要保留合约乘数, 结算, 保证金和成交条件. 漏掉这些条件, 即使支付函数写对了, 也可能把需要投入的资金和最终盈亏算错.

下一节将研究直接依赖事件发生与否的合约, 即预测市场中的或有现金流及其价格解释. 随后再回到指数, ETF 和被动投资, 说明指数数值怎样与可交易产品联系起来.

7.3 预测市场与市场隐含概率

第7.2节已经说明, 合约可以根据未来情况决定支付. 预测市场把条件写成一个具体问题: 某件事是否会在规定期限内发生, 并按什么资料和规则确认结果.

这给价格研究提供了一种补充. 股票涨跌可能同时反映盈利, 利率和交易需求的变化; 一份事件合约则直接说明它在为什么结果付钱. 读懂支付条件以后, 就能进一步问: 当前报价对应怎样的判断, 与我们根据其他资料作出的估计有何差别?

第8.4节将用这类外部信号核对公司研究. 那里的 Agent 协助整理证据和查找需要重审的假设, 合约价格仍须连同交易和结算条件解释.

7.3.1 从价格反解市场预期

财报发布后股价上涨, 可能是收入前景改善, 也可能是成本低于此前担心的水平. 股价下跌则可能反映利润率, 资本开支或监管判断的变化, 也可能与持仓和流动性有关. 价格告诉我们交易结果变了, 却没有同时告诉我们每项原因贡献多少.

困难在于不同假设可以产生相近价格. 较高的盈利预测配上较高的要求回报率, 可能与较低的盈利预测配上较低的要求回报率得到相近估值. 再加入资金需求和订单变化, 单凭涨跌就更难确定市场究竟采用了哪一种解释. 因而研究价格已经反映了什么, 需要用额外资料比较这些可能性.

期权提供了比单个现货价格更丰富的比较. 不同行权价和到期日的合约对不同终价范围支付, 可以反映市场怎样给波动和尾部风险定价. 在相应的无套利与光滑性条件下, Breeden-Litzenberger 关系能从欧式期权价格随行权价的变化中提取风险中性终端分布信息 [BL78; Hul22].

但终价分布仍没有标明每项经营原因. 隐含波动率上升可能与财报, 监管或宏观消息有关, 实际报价也可能受到流动性和做市库存影响. 期权帮助我们看清哪些价格结果变贵了, 要说明市场为什么担心这些结果, 仍需进一步查证具体事件.

7.3.2 从公司资料提出解释

可以先读财报, 业绩电话会记录和行业资料, 找出可能改变收入, 成本或经营期限的消息, 再分析它们对估值的影响. Agent 能够帮助整理这些材料, 但列出消息与证明价格因它变化, 仍是两项工作.

若先看见股价下跌, 再从材料中挑出所有负面语句, 很容易得到一段听起来合理的解释. 同一份财报却可能同时包含正面和负面变化, 某些消息也可能早已被市场知道. 要判断它们是否真正改变了预期, 应比较原来的假设, 消息出现的时间和后续经营证据, 而不只要求文字与事后涨跌方向一致.

预测市场增加了一种公司文本以外的观察. 若有针对某项审批或其他事件的合约, 可以查看相关消息出现时, 这份合约的报价是否也改变. 两种价格同时变化仍不足以单独证明因果, 但可以帮助研究者决定下一步应核查哪种解释.

7.3.3 把事件做成或有现金流

定义 7.45 (预测市场与事件合约).

预测市场 (prediction market) 是围绕未来事件或可验证结果交易合约的市场, 其中的合约称为**事件合约** (event contracts). 本节先研究一种二元合约: 按规则确认事件 A 发生时支付一单位结算货币, 否则支付零. 若在 T 完成判定和支付, 则

$$X_T^A = \mathbf{1}_A.$$

CFTC 对事件合约的介绍也以 yes-no 问题和固定支付说明这类安排 [Com]. 合约先把什么结果值得付款写清楚, 最终金额再由约定的判定结果确定. 事件的观察截止时间与实际结算时间可以不同, 阅读条款时应分别确认.

例如, “某项监管批准是否在规定日期以前发生”与“某家公司股价是否在规定日期以前超过某个水平”是两份不同的合约. 审批可能影响股价, 但股价还受到其他经营与市场因素影响. 两份合约因而不能只凭相关性共用一个发生概率.

事件合约的帮助在于, 报价明确对应一个待判定的问题. 与从股票涨跌猜测市场在担心什么相比, 我们至少先知道了买方取得的支付条件. 但这个条件必须按合约文本理解, 不能仅凭标题或日常语言中的事件印象判断.

注 7.46.

本节用或有现金流分析事件合约的经济关系, 法律分类仍取决于适用制度. 例如, CFTC 在 2022 年将 Polymarket 提供的若干事件型二元期权认定为其辖区下的 swaps, 并就未注册交易设施相关问题作出处罚 [Com22]. 这一历史认定不能代替对其他合约, 平台或法域规则的具体核对.

7.3.4 市场隐含概率

设一份合约在 T 支付 $\mathbf{1}_A$, 当前价格为 C_t^A . 由于支付只有零和一, 报价很容易被读成百分比. 但价格还包含等待支付和承担风险的代价, 应先说明怎样从金额转成概率.

以 $D(t, T) > 0$ 表示在 t 买到一份确定于 T 支付一单位同种货币的无风险零息债券所需的价格. 它是今天可以观察或在模型中确定的债券价格, 与未来才实现的随机贴现量不同. 对单位面值合约, 定义

$$\hat{p}_t^{\text{mkt}}(A) = \frac{C_t^A}{D(t, T)}.$$

若事件发生时支付固定面值 $a > 0$, 就应除以 $aD(t, T)$, 不能把不同面值的报价直接当作可比较的百分比.

定义 7.47 (市场隐含概率).

本节把事件合约价格按面值和相应期限的无风险支付价格归一化后得到的数值, 称为**市场隐含概率** (market-implied probability). 它首先是由报价计算的数值, 其概率解释取决于所采用的定价模型和交易条件.

在无摩擦且相关交易均可实施的模型中, 单位事件支付始终介于零和确定的一单位支付之间, 因而无套利价格也在零与 $D(t, T)$ 之间. 这说明归一化数值为什么可以落在概率的范围内, 却尚未证明它就是现实发生频率.

更明确地, 若正的随机定价核 $m_{t,T}$ 对这些支付给出一致定价, 且相应条件期望存在, 则

$$C_t^A = \mathbb{E}_{\mathbb{P}}[m_{t,T} \mathbf{1}_A | \mathcal{F}_t], \quad D(t, T) = \mathbb{E}_{\mathbb{P}}[m_{t,T} | \mathcal{F}_t].$$

第一式只保留事件发生时的支付, 第二式对所有结果的一单位支付定价. 定价核不仅给等待打折, 也可以对不同结果赋予不同权重. 除以第二式以后, 得到的是这些权重下的条件概率.

若用到期日为 T 的零息债券作计价资产, 对应测度记为 $\mathbb{Q}^T$, 就有

$$C_t^A = D(t, T) \mathbb{Q}^T(A | \mathcal{F}_t).$$

确定利率的简单模型中, 也可以把确定贴现因子提出现金账户定价测度下的期望. 随机利率下则应保留计价资产的区别, 不能把随机贴现量任意移出期望, 再把所得概率仍当成现金账户测度下的概率. 这一点与第六章中的测度变换一致.

实际交易还存在买卖价差, 费用, 参与限制和资金占用, 不一定只有一个能同时买卖的价格. 风险偏好及交易者各自的资金状况也会影响愿意支付多少. 因而市场隐含概率与现实概率之间的关系, 需要这些额外条件支持, 不能只由二元支付形式推出 [Man06; WZ04].

7.3.5 比较的究竟是哪一种判断

事件在现实中怎样发生, 研究者怎样估计它, 市场为相应支付报什么价格, 是三件不同的事. 研究者通常不知道完整的现实概率规律, 只能根据资料作出有待检验的估计. 市场报价又受到前面讨论的风险与交易条件影响, 所以它与研究估计的差别需要解释, 不能直接把其中一个宣布为真实概率.

公司情景还多了一层. 一项监管决定通过以后, 产品是否顺利销售, 成本是否受控, 股东能够取得多少利益, 仍有其他不确定性. 所以审批发生不等于公司必然进入 Bull 情景. Bear 也可能由需求, 竞争和融资等多种原因造成, 不能直接拿一个事件合约的报价充当整个 Bear 情景的权重.

阅读市场信息时, 还应看买卖报价, 各档数量, 成交量, 持仓量和最近更新时间. 这些数据帮助判断报价有多少实际交易支持, 以及完成一笔买卖需要付出什么成本. 它们不直接给出事件概率, 也不能仅凭成交活跃就确定预测准确.

例 7.48 (同一盘口中的不同价格).

假设单位面值事件合约的最优买价为 0.57, 最优卖价为 0.63, 最近成交价为 0.61. 中间价为 $(0.57 + 0.63)/2 = 0.60$, 但不保证能够按中间价成交. 在报价仍有效且数量足够时, 立即买入要付 0.63, 立即卖出得到 0.57. 最近的 0.61 只是上一笔成交记录, 还可能已经过时.

再作一个数量明确的教学假设: 0.63 的卖价足以买入 100 份, 每份事件发生时支付一单位货币, 否则为零, 忽略贴现和全部费用. 买入支出为 $100 \times 0.63 = 63$. 事件发生时收到 100, 净赚 37; 不发生时没有支付, 净亏 63.

若研究者估计事件概率为 p , 对应的期望净损益是

$$\mathbb{E}[\Pi_T] = 37p - 63(1 - p) = 100p - 63.$$

这一计算要求 $p > 0.63$ 才有正的毛期望, 不能拿中间价 0.60 作为实际买入成本. 加入费用后, 所需概率还会提高. 而 p 本身是否可靠, 仍须由研究证据支持.

若 0.63 一档只有少量卖单, 上述全部按同价买入的假设就不成立. 更大订单可能需要接受更高价格, 应以实际平均成交价重算支付与盈亏.

一份合约存在, 只说明这个问题已经被组织成可交易的条款. 是否有人持续报价, 报价能承接多少数量, 以及历史预测是否准确, 还要分别观察. 较深盘口和较窄价差能使价格比较更有用, 却不会使研究判断免于出错.

7.3.6 怎样把事件合约用于公司研究

把预测市场资料放进公司研究时, 先保留问题文本, 结算期限, 报价种类和时间. 这样以后才能知道引用的究竟是哪一份合约, 以及当时可以按什么条件交易.

随后分析事件对公司的具体作用. 某项监管决定可能改变销售资格, 收费方式, 成本或项目开始时间. 公司材料需要支持这些影响, 预测市场则提供另一项观察: 交易者目前怎样给该监管事件的支付定价. 两类证据可以相互对照, 但报价不能代替经营分析.

例如, 审批合约价格上升以后, 可以重新检查研究者对审批时间的判断. 若此前收入预测假定更晚才获准销售, 还可能需重算上市时间和相应收入. 但销量, 单价和利润率不会仅因合约报价上涨就自动提高, 仍应逐项保留自己的依据.

公司事件图 (Company Event Graph) 保存这些证据与假设之间的联系. 新消息出现时, 可以找到应重查的经营预测, 也能看清哪些判断尚未改变. 几家公司受到同一政策或供应链变化影响时, 市场图 (Market Graph) 再把相关研究联系起来, 帮助检查组合中的共同风险.

因此, 外部报价帮助提出和核对问题, 图帮助找回判断的来由. 最后的盈利, 估值和情景概率, 仍通过相应研究确定, 而不是按新闻数量或图中连线直接计算.

7.3.7 结算规则, 信息优势与监管问题

合约标题相近, 支付条件也可能不同. 一个问题可以要求事件在某日期以前发生, 另一个可以要求先发生某个前提, 或使用不同数据来源确认. 是否采用首次发布数据, 后续修订数据或指定裁决结果, 也会改变最后支付. 对比报价时, 应先核对这些条件, 再比较数字.

交易者掌握的信息也不相同. 企业内部人员, 政策制定者, 候选人或内容发布者, 可能与某些结算事件有直接关系. 这会使信息优势, 利益冲突和操纵问题更加具体. 不同市场的参与限制和监察规则又未必与证券市场相同, 需要按实际制度判断.

CFTC 在 2026 年关于预测市场的执法提示中, 讨论了非公开信息误用, 欺诈, wash sales 及其他禁止交易行为, 并列举 KalshiEX 上与候选人本人交易和 YouTube 频道内部人员相关的案例 [Com26]. 这些材料说明, 解释交易信息时也要了解参与者与事件的关系.

不过, 一笔大单或报价突然跳升本身不能确定是谁知道了什么. 公开消息, 库存调整, 跨市场交易, 薄弱盘口, 对结算条款的不同理解或陈旧报价, 都可能产生相似现象. 异常交易可以成为继续调查的线索, 指认违法或内幕行为则需要独立证据.

没有找到某项事件的预测合约, 也不能据此判断市场完全没有关注. 事件可能难以标准化, 交易需求不足, 受到平台规则限制, 或只是尚未被组织成一份合约. 公司研究仍可以根据其他资料继续进行.

7.3.8 预测市场作为随机过程

固定一份事件合约以后, 可以沿时间记录价格, 买卖价差, 各档数量和成交活动. 新资料出现时, 价格可能跳变; 交易需求和流动性改变时, 报价与成交也可能变化. 因而研究不只看最后是否支付, 也看市场如何一步步处理新信息.

前面的定价模型还给出一个清楚的概率论结论. 在同一个到期债券计价测度 $\mathbb{Q}^T$ 下, 若归一化价格确实等于事件的条件概率, 则对 $t \leq u \leq T$, 塔性质给出

$$\mathbb{E}^{\mathbb{Q}^T} [\hat{p}_u^{\text{mkt}}(A) | \mathcal{F}_t] = \hat{p}_t^{\text{mkt}}(A).$$

也就是说, 这条理想化的归一化价格过程在相应定价测度下是有界鞅. 等式允许观察到新消息后价格大幅改变, 只要求当前信息下对未来修正的条件平均为零. 它既没有要求原始价格不变, 也没有把现实测度换成定价测度.

实际记录中的买价, 卖价和最近成交价仍须分别处理, 不能无条件把每条报价序列都代入这个理想关系. 随机过程语言帮助我们明确在研究什么变化, 合约与交易资料则决定模型是否适用.

订单到达可以用点过程描述, 已公布的信息由滤过记录, 成交深度影响实际买卖成本. 将这些记录与最终结算结果比较, 才能逐步评估报价作为研究信号的用途.

事件合约把一个可验证结果写成支付条件, 股指期货和指数期权则把按规则计算的指数水平写入支付. 下一节转向指数, ETF 和被动投资, 看投资者怎样通过具体产品取得一篮子资产的投资表现.

7.4 指数, ETF 和被动投资

前面已经用股票指数计算期货和期权的支付. 指数本身是一套选择和计算规则, 投资者实际持有的则是股票, 基金份额或相关合约. 所谓“买入 S&P 500”或“持有 Nasdaq-100”, 因而需要进一步说明买的是哪种产品.

本节先从股票篮子出发, 计算分散投资能减少什么风险. 然后看指数怎样选择成分和分配权重, 基金怎样跟踪这些规则, ETF 份额又怎样在投资者与基金之间流转. 最后讨论被动管理相对于什么基准而言, 以及这些真实交易如何参与价格形成.

相关背景主要参考 [Gas10; Mar52; Nas; SP 26; SP a; SP b; US e; US f].

7.4.1 从单只股票到股票篮子

若全部资金都投在一家公司, 它的产品失败, 工厂事故或管理问题就会影响大部分投资财富. 同时持有多家公司, 可以减少其中一家对组合的影响, 因为这些经营问题未必同时发生.

定义 7.49.

分散化 (diversification) 是通过同时持有多项不完全同步变化的资产, 降低单个资产或局部风险对组合的影响.

效果不能只用持仓家数判断. 设各资产在同一期间的简单总收益率为 $R_1, \dots, R_n$, 有有限二阶矩. 取固定的期初多头资金权重 $w_i \geq 0$, 且 $\sum_i w_i = 1$. 不考虑期中再平衡和额外组合费用时,

$$R_p = \sum_{i=1}^n w_i R_i.$$

将这个加权求和的方差展开, 得到

$$\text{Var}(R_p) = \sum_i w_i^2 \text{Var}(R_i) + 2 \sum_{i < j} w_i w_j \text{Cov}(R_i, R_j).$$

第一项按权重平方累计各资产自己的波动, 第二项累计它们同时涨跌的部分. 分散到更多持仓可以减小单项权重, 但若这些资产经常一起变化, 交叉项仍会保留下来. 这就是为什么买入很多高度相似的股票, 可能没有分散掉真正关心的风险 [Mar52].

定义 7.50.

特有风险 (idiosyncratic risk) 主要来自某家公司或资产自身. **系统性风险** (systematic risk) 则由大量资产共同承担, 难以仅靠增加同类持仓的数量消除.

一家公司的新产品失败更接近特有风险, 经济衰退或整体融资条件收紧则可能同时影响许多公司. 两种区分还要结合所研究的组合: 半导体行业的共同冲击, 对半导体股票组合十分集中, 放进全球多资产组合以后则只影响其中一部分.

注 7.51.

这里的 systematic risk 是资产定价中共同风险的含义. systemic risk 则讨论金融体系的传染或失灵, 两个词不能因中文接近而混用.

分散化并不要求使用指数. 投资者自行选择 100 家公司, 或主动基金建立广泛持仓, 也可以减少单一公司的影响. 指数进一步规定选择哪些资产, 按多少权重计算, 以后怎样维护, 使不同人能够按同一套规则观察和比较一个篮子的表现.

7.4.2 指数怎样选择和计算一个篮子

定义 7.52.

市场指数 (market index) 是按照规定的成分选择, 加权, 维护与收益计算方法, 汇总一组资产市场表现的指标.

规则先决定哪些资产合格, 再决定纳入哪些, 各占多少. 以后遇到拆股, 增发, 回购或成分替换, 还要按规定更新. 股息是否计入收益, 也属于指数定义, 不能在比较表现时临时改变.

先看一个价格指数的基本计算:

$$I_t = \frac{\sum_{i=1}^n P_{i,t} Q_{i,t}}{D_t}.$$

$P_{i,t}$ 是价格, $Q_{i,t}$ 是计算采用的指数股数或相应权重参数, 分子是这些数量按当前价格计算的总值. 指数除数 D_t 把总值换成指数点数, 并按方法规定处理某些非市场涨跌引起的变化.

各项在分子中所占比例就是当时的权重:

$$w_{i,t} = \frac{P_{i,t}Q_{i,t}}{\sum_j P_{j,t}Q_{j,t}}.$$

所以给出 $Q_{i,t}$ 还没有固定以后每天的权重. 价格变化也会改变各项占比. 不同加权方法, 很大程度上就是怎样选择这些指数股数, 又在什么时候重设它们.

公司行动需要按其经济内容处理. 股票拆分时, 每股价格下降而股数按相反比例增加. 普通市值加权指数的相应总市值不变, 通常不必为这件事改变除数. 价格加权指数按相同名义股数计算, 拆分会直接减少价格之和, 就通常要调整除数, 避免把单位改变误算成市场损失.

增发, 回购, 特别股息和成分替换也各有规定. 指数提供商通过调整股数, 权重因子或除数, 将这些变化与市场价格收益区分开. 具体采用哪一步, 应以指数方法文件为准 [SP a].

权重规则与再平衡

定义 7.53.

市值加权指数 (market-capitalization-weighted index) 按可计入的市场价值分配权重. 若公司 i 的相应市值为 M_i , 最简单的权重为

$$w_i = \frac{M_i}{\sum_j M_j}.$$

许多指数采用自由流通调整市值, 按方法规定只计入相应的可流通股份. 这样计算的权重, 不一定等于公司全部股份总市值所占比例.

市值加权便于跟踪的一点是, 单纯价格变化通常不要求为维持比例再做同方向买卖. 当成分和计入股数不变, 某只股票上涨后, 指数中的市值占比提高, 原本按相同比例持有的组合也会因这笔股票升值而提高其权重. 基金不必仅因涨价就追加购买.

增发, 回购, 流通比例变化, 并购, 分拆和成分调整则会改变其他输入. 加上投资者申赎, 基金仍有实际交易需要, 所以市值加权并非永远不调仓.

定义 7.54.

价格加权指数 (price-weighted index) 按成分证券的每股价格决定相对影响, 可以理解为用相同名义股数汇总各证券价格, 再通过除数换成指数点数.

假设只有两只股票, A 为 \$300, B 为 \$100. 两者都涨 1% 时, 价格分别增加 \$3 和 \$1, 前者对价格之和的贡献更大. 这取决于每股报价, 与两家公司总市值谁更大不同. 拆股改变每股报价尺度, 因而价格加权指数特别需要相应维护.

定义 7.55.

等权指数 (equal-weighted index) 在规定的再平衡时点, 按其计算方法使各成分公司或证券恢复相同或近似相同的目标权重.

等权描述重设目标的办法, 不表示每个时刻都等权. 价格继续涨跌以后, 上涨较快的持仓会占更大比例, 这称为**权重漂移** (weight drift). 在下次再平衡以前, 权重可以偏离等权目标.

例如, 两项持仓初始各为 \$100. 一项涨到 \$120, 另一项仍为 \$100, 总值为 \$220, 权重成为 $120/220$ 与 $100/220$, 约为 54.55% 和 45.45%. 若此时无成本恢复等权, 每项应为 \$110, 就要卖出第一项 \$10, 用所得买入第二项 \$10. 这是调整已有资金的分配, 再平衡当下并没有凭空增加财富.

与市值加权相比, 定期恢复等权通常带来更多这类买卖, 并提高较小成分的相对权重. 实际成本还取决于流动性和执行方法. 此外, 一个行业若包含较多公司, 公司等权后仍可能占据较高行业权重; 公司等权并不等于行业等权.

几个真实指数 指数名称可以提示大致范围, 具体成分还要按方法文件选择. 以下保留所引用版本的条件, 以说明资格, 加权和维护如何共同起作用.

例 7.56 (S&P 500).

S&P 500 旨在表示美国大型股票市场。纳入公司须满足身份, 上市地点, 规模, 自由流通市值和流动性等资格, 指数委员会再按方法进行选择和维护。

以所引 2026 年 8 月的 S&P U.S. Indices 方法文件为例, 新进入 S&P 500 的公司总市值门槛为 \$22.7 billion, 最近一个季度的 GAAP 持续经营净利润须为正, 最近四个季度合计也须为正。对 Equity REIT, 文件允许依据 GAAP 持续经营净利润和/或已报告的 FFO 判断财务可行性 [SP b]。这些数值属于该版本的方法条件, 不能当成永远不变的入选门槛。

这里的 500 指公司数。一家公司若有多个合格股份类别同时入选, 实际证券行数可以超过 500。纳入以后, 主要按自由流通调整市值加权。

因此, S&P 500 不能简单理解成把所有美国股票按总市值排列后取前 500 行。公司资格, 股份类别和委员会维护都参与最终结果。

例 7.57 (Nasdaq Composite 和 Nasdaq-100).

Nasdaq 既是交易市场及相关基础设施的名称, 也出现在多个指数名称中。Nasdaq Composite 广泛覆盖 Nasdaq Stock Market 上市的合资格普通类型证券, 与其中上市股票的整体表现更接近。

Nasdaq-100 采用另一套选择方法。所引 2026 年方法文件将其设计为度量 Nasdaq 上市的 100 家大型非金融公司, 并使用修正市值加权 [Nas]。科技权重较高, 不表示只允许科技公司; 消费, 通信, 医药等非金融公司也可以入选。

年度重构包含资格与排名缓冲, 减少边缘公司仅因短期排名变化而反复进出。该 2026 年版本还允许满足其他适用条件, 且按 Full Market Capitalization 足以进入当前成分前 40 的证券, 通过 Fast Entry 或 3 月, 6 月, 9 月的季度调整加入, 而不要求同时删除另一家公司。因而某些时点的公司数可以暂时超过 100。

这些例子说明, 名称中的公司数量, 实际证券数量和特定时点的持仓行数, 未必完全相同。要复算指数, 必须使用相应时期的具体方法和成分资料。

S&P 500 Equal Weight 的动态权重 S&P 500 Equal Weight 使用与 S&P 500 相同的公司集合, 按季度规则恢复公司等权。若约有 500 家公司, 每家的目标约为 $1/500 = 0.2\%$ 。

等权单位是公司, 不一定是证券行。一家公司若有多个入选股份类别, 先在公司层面分得一份等权目标, 再按这些类别的自由流通市值分配到各行。因而不能看到某家公司两行证券, 就假定它取得两份完整公司权重。

季度之间, 价格仍会改变权重。若 3 月重设以后, 某些半导体或其他公司上涨较快, 到 6 月以前它们在组合中的占比就会提高。这种变化来自持仓升值, 不要求指数在上涨途中不断买入赢家。

2026 年 6 月的例子还区分了计算参考日与生效日。这一轮采用 6 月 10 日收盘价作为重算指数股数的价格参考, 不表示 6 月 10 日已经完成调仓。按 S&P Dow Jones Indices 在 6 月 5 日发布的公告, 成分变化于 6 月 22 日开盘前生效: Marvell 和 Flex 加入, Pool 和 Campbell's 删除 [SP 26]。6 月 19 日为 Juneteenth 休市日, 所以 6 月 18 日是生效前最后一个正常交易日。

重设的股数以规定参考价计算, 实际观察到的权重还会受参考日至生效期间价格变化影响。因而“恢复约 0.2%”是按方法完成的公司等权安排, 不意味着其后每个时刻或基金每笔成交都精确等于 0.2%。

本轮调整一方面会降低部分此前上涨较快公司的权重, 另一方面又加入 Marvell 和 Flex 两家 Information Technology 公司。要判断整个科技行业权重是升是降, 应汇总所有相关成分, 同时计入此前漂移和新增删除, 不能只挑几家被减重的公司作为行业结论。

随后若等权指数跑赢或跑输普通 S&P 500, 不能把全部差额归于这一次季度调整。两个指数原本就有不同的大公司集中度, 行业权重和公司规模倾向。调整前的权重漂移, 调整后的股票表现, 以及观察窗口和股息处理, 也都影响结果。

要估计 6 月调整的贡献, 先说明比较的是整套季度调整, 还是在成分不变时单纯恢复等权。前者包括 Marvell 与 Flex 加入及 Pool 与 Campbell's 删除; 后者需要另外保留原成分, 只改变权重, 两种模拟不能混用。

例如, 可以让一份假设组合在 6 月继续持有调整前已经漂移的数量, 另一份按实际季度规则调

整. 使用相同的后续价格, 期间和收益计算方式, 比较

$$R^{\text{EW,actual}} - R^{\text{EW,no rebalance}}.$$

它衡量的是在这组明确模拟假设下, 进行本轮调整与继续持有原组合的收益差异. 再比较

$$R^{\text{EW,no rebalance}} - R^{\text{Market Cap}},$$

则保留了调整以前就存在的持仓差别. 两项相加等于实际等权与市值加权的总收益差, 但第二项内部仍同时包含规模, 行业和集中度等多种影响.

这种计算有助于分清权重选择在给定价格路径上的后果. 若没有处理交易本身对价格的影响, 就还不能把它当成完全识别了市场中的因果效果. 是否值得长期采用等权, 也需要比较其他时期以及相应成本, 不能只依靠这一轮结果.

实际 ETF 又有自己的持仓和现金. 完全复制, 抽样, 衍生品使用, 申赎和执行安排都会使基金与指数不完全一致. 用某只等权 ETF 的历史持仓研究时, 应称其为基金持仓记录; 若要精确复算指数权重, 仍须使用指数提供商的数据.

市场与指数 “今天美国股市上涨了 1%” 通常省略了所指基准. S&P 500, Nasdaq Composite, Nasdaq-100, Dow Jones 和 S&P 500 Equal Weight 可以在同一天有不同表现, 因为它们选择和加权的股票不同.

某个指数上涨也不表示大多数股票都上涨. 少数高权重成分的变动, 可能足以改变总指数方向. 要了解市场内部怎样变化, 可以继续看行业, 成分涨跌和不同加权方法, 而不能要求一个指数点数同时保留所有细节.

价格指数, 总收益指数与净总收益指数 相同成分和权重, 还可能因股息处理不同而产生不同指数收益.

定义 7.58.

价格指数 (price index) 主要计算成分资产的价格变化. **总收益指数** (total return index) 按规则将现金股息再投资, 把这部分分配加入收益. **净总收益指数** (net total return index) 则先按规定假设扣除股息预提税, 再计算相应再投资收益.

例如, 股票由 \$100 降到 \$98, 同时支付 \$4 股息. 价格确实下跌 2%, 但在不计其他因素时, 原股东的总收益为

$$\frac{98 + 4 - 100}{100} = 2\%.$$

价格变化与持有结果之所以不同, 是因为一部分利益已经以现金分配出去. 多期总收益指数进一步规定这笔现金何时及怎样再投资.

净总收益中的税率是指数的统一假设, 未必等于某位投资者实际适用的税率, 也不表示已经扣除基金的全部费用. 比较基金与指数以前, 应让期间, 币种和分配处理一致, 否则看到的差额可能只是比较了不同收益.

7.4.3 从指数到基金和 ETF

怎样取得接近指数的投资表现 指数点数不能直接交付给投资者. 要取得相应收益, 可以自己按规定买入股票篮子, 购买跟踪它的基金, 或使用相关衍生品.

股指期货按指数变化计算线性盈亏, 指数期权则按非线性支付规则计算. 它们还分别涉及保证金, 到期或权利金等安排. 若希望通过基金份额长期持有有一个接近指数表现的组合, 就进入指数基金的问题. 所谓“持有十股 S&P 500”, 在账户上必须落实为具体基金份额或其他产品数量.

指数基金与跟踪误差

定义 7.59.

投资基金 (investment fund) 将投资者资金集中起来, 按规定目标持有和管理资产, 投资者通过基金份额取得相应经济权益. **指数基金** (index fund) 则以跟踪某个指定指数的表现为

主要目标.

最直接的跟踪办法是按指数成分和权重买入全部证券, 即完整复制. 成分过多或部分证券难以交易时, 可以抽样建立近似组合; 某些产品也使用衍生品取得相应收益. 投资者持有的是基金份额, 由基金按自身文件和安排完成这些交易.

跟踪目标不保证结果完全相等. 管理费, 交易成本, 税, 现金持有, 公司行动处理和复制方式都会产生差异, 证券借贷收入等则可能抵消其中一部分. 比较时先用相同期间和收益定义, 再计算下面两个量.

定义 7.60.

一段期间基金收益减去指数收益, 称为**跟踪差异** (tracking difference):

$$TD_{0,T} = R_{0,T}^{\text{fund}} - R_{0,T}^{\text{index}}.$$

定义 7.61.

各期基金相对指数收益之差的标准差, 称为这里采用的**跟踪误差** (tracking error):

$$TE = \text{sd} \left(r_t^{\text{fund}} - r_t^{\text{index}} \right).$$

跟踪差异回答最后领先或落后多少, 跟踪误差回答各期偏离有多不稳定. 假如每期都稳定落后相同幅度, 跟踪误差可以很小甚至为零, 但投资者仍然持续落后. 报告跟踪误差还应说明日度, 周度或月度频率, 以及如何年化.

例 7.62 (同一个指数, 多只跟踪基金).

多家机构可以各自管理跟踪 S&P 500 的基金. 它们使用同一指数作 benchmark, 却有不同费用, 规模, 现金和执行安排, 因而持仓和最终收益不必完全相同. 选择其中一只基金, 是选择一个实际管理和交易的产品, 并非直接购买指数数值.

ETF 指数基金可以采用不同的申赎和交易方式. ETF 说明的是基金份额怎样交易, 不单独决定基金是否跟踪指数.

定义 7.63.

交易所交易基金 (exchange-traded fund, ETF) 的份额可以在交易所二级市场买卖, 并通常允许授权参与者按规定以资产篮子或现金进行大额份额创建和赎回.

交易所挂牌只是其中一个特征, 封闭式基金等产品也能挂牌. ETF 还让合格机构直接用规定的资产或现金换取新份额, 或交回份额换取相应资产或现金. 这一安排把份额供给与基金持有的资产联系起来 [Gas10; US f].

因此, 指数描述计算规则, 指数基金描述跟踪目标, ETF 描述基金的组织与交易方式. 一只跟踪指数的 ETF 同时属于后两类; 主动管理 ETF 则不以复制某个指数为主要目标. 普通共同基金也可以采用指数跟踪策略.

在本段采用的美国证券基金语境中, 注册 ETF 受 Investment Company Act 下相应框架约束. 商品信托 (commodity trust), 商品投资池 (commodity pool) 和交易所交易票据 (exchange-traded note, ETN) 等, 也常与 ETF 一起归入广义交易所交易产品 (exchange-traded product, ETP), 但法律形式和投资者权利未必相同. 不能仅因都在交易所买卖, 就把它们当成相同基金结构 [US e; US f].

例 7.64 (买入跟踪 Nasdaq-100 的 ETF).

投资者买到的是具体 ETF 的基金份额, 基金再按自己的投资方法取得接近 Nasdaq-100 的表现. Nasdaq-100 是跟踪基准, Nasdaq Composite 是另一套较广的指数, Nasdaq Stock Market 则是交易市场. 一笔基金交易不会把这些名称变成同一种权利.

同一个指数也可以用作期货和期权的结算标的。基金通过资产和投资安排跟踪收益，衍生品则按合约直接计算现金流，两种取得指数相关收益的方式还各有费用，融资和结算条件。

ETF 的净值和市场价格 ETF 份额对应基金的净资产，同时又有投资者之间的交易价格。先把两者分别计算。

定义 7.65.

本节以**基金净值** (net asset value, NAV) 表示每份净资产价值。若基金资产价值为 A_t ，负债为 L_t ，已发行份额为 $N_t > 0$ ，则

$$\text{NAV}_t = \frac{A_t - L_t}{N_t}.$$

分子扣除基金负债，分母把净资产分到每份。这里定义的是每份数值，与基金全部净资产金额不同。资产采用什么估值，负债包括哪些已计费用，都依基金的核算规则确定。

ETF 在交易时间内持续报价和成交，官方 NAV 则通常在每个交易日结束后按规定方法计算。盘中的市场价格与上一份公布净值可能相隔一段时间，不能仅用两个数的差就认定有可交易套利。

部分产品公布盘中指示价值 (intraday indicative value, IIV)，参与者也可按底层报价估算篮子价值。这些估计的更新速度和方法各不相同，底层市场关闭或报价陈旧时尤其需要区别。官方净值，盘中估计与真正买卖篮子的价格，不必相等 [Gas10; US f].

定义 7.66.

授权参与者 (authorized participant, AP) 是与 ETF 基金签订相应协议，可以按规定直接进行大额份额创建和赎回的机构。

普通投资者通常与其他市场参与者买卖已有 ETF 份额。AP 则还能直接与基金交换一大组份额和规定篮子或现金。当 ETF 与可交易篮子之间出现足以覆盖成本的价差，这一选择会产生推动价格接近的交易。

例 7.67 (创建和赎回怎样比较两边价格).

以下数量和费用均为教学假设，不对应实际产品。假定一组创建单位为 50,000 份 ETF，对应篮子可以按总额 \$5,000,000 买入或卖出，即每份对应 \$100 的篮子价值。还假设整笔数量都可按给定价格成交并锁定价差，每轮交易，融资和创建或赎回等成本合计 \$10,000，没有其他成本。

先看 ETF 溢价到每份 \$101 的情况。AP 或通过 AP 操作的机构买入规定篮子，交给基金取得 50,000 份新 ETF，再按 \$101 卖出。卖出收入为

$$50,000 \times 101 = \$5,050,000,$$

扣除篮子买入款和本例全部成本，盈利为

$$5,050,000 - 5,000,000 - 10,000 = \$40,000.$$

基金收到资产并发行新份额，ETF 二级市场增加可售份额。交易者是在比较两种能够相互转换的持有方式，不必先预测整个股票市场上涨。

再看 ETF 折价到每份 \$99 的另一种情况。买入 50,000 份只需 \$4,950,000，将其交回基金赎回规定篮子，再把篮子卖出取得 \$5,000,000。按同样的成本假设，盈利为

$$5,000,000 - 4,950,000 - 10,000 = \$40,000.$$

这次基金收回并注销份额，交付资产，已发行份额减少。

例子中的关键条件是两边价格都能按所需数量执行，并完成规定转换。实际交易有买卖价差，融资，税费，券源和时间差，篮子也未必能立即全部买卖。所以通常存在一段足以容纳成本的价格区间，而不要求每笔 ETF 成交都恰好等于估计净值。

市场剧烈波动或底层缺少即时价格时,ETF 价格可能明显偏离官方 NAV 或盘中估值。这时应继续判断差额来自真实的可交易价差,还是估值时点和报价质量不同。仅有屏幕上的折溢价,尚未完成上例的现金核算。

普通二级市场交易则更简单:一位投资者把钱付给另一位持有人,接手已经存在的 ETF 份额。这笔交易本身没有要求基金发行或注销份额,也不要求基金立即买卖底层股票。

底层订单可能来自创建赎回的准备,基金再平衡和现金管理,或 AP 与做市商调整库存及对冲。即使进行了创建赎回,AP 也可以使用已有库存,借券或现金篮子安排,不一定当场逐项买卖全部证券。因而 ETF 成交,份额净申赎和底层交易应分别观察。

7.4.4 被动管理与价格形成

定义 7.68.

被动管理 (passive management) 以跟踪事先指定的基准为主要目标,按相应规则控制基金收益相对于基准的偏离。

被动描述基金相对于基准怎样管理,不直接描述投资者本人交易得多不多。一个人可以长期持有主动基金而很少买卖,也可以每天对指数 ETF 择时。后者使用被动管理的产品,却在执行主动的配置与交易策略。

规则化也不等于被动。系统化多因子基金即使完全按算法交易,若目标是主动偏离基准并争取超额收益,仍属于主动管理。判断依据是投资目标及其相对于基准的选择,不能只看有没有公式。

基准本身也包含决定。选择什么市场,排除哪些证券,如何加权,何时再平衡,都会影响结果;S&P 500 还有委员会的维护判断。投资者选择跟踪基金时,同时接受了这套方法。因而被动管理是相对于已选基准减少进一步偏离,并不意味着投资过程中完全没有选择。

被动资金仍然参与价格形成 市值加权基金通常不会仅因经理认为某家公司便宜,就主动提高其相对指数的权重。但它仍要处理申赎,成分调整,分配和现金,这些活动可能需要交易。投资者买卖基金份额也会与其他市场参与者形成真实成交。

这些订单进入与主动投资者,做市商和套利者相同的市场。最后以什么价格完成,取决于当时愿意承接的数量和报价。不主动判断单只股票的相对价值,并不表示交易不会影响供需。

价格又参与下一次指数权重计算。不过,在成分股数不变的市值加权组合中,股票上涨已经会使原持仓权重同步提高,无须仅因这个变化追加买入。更直接的交易需要来自资金流入流出,规则调整或其他必须改变持有数量的事项。讨论被动资金的价格影响时,应找到具体是哪一种交易,不把所有权重变化都解释成新的买单。

当许多资金采用同一指数,成分纳入或再平衡规则就可能集中影响交易需求,其他参与者也可能提前对此作出反应。影响大小取决于已有预期,实际资金和后续成交,没有仅由纳入名单就确定的涨幅。公司的长期利益仍需根据经营现金流,资本结构和股东权利研究。

指数由此既用于记录表现,也通过采用它的真实资金影响交易。要分析这种作用,应区分指数规则,基金申赎,份额二级交易和底层订单,而不把它们合成一次必然同时发生的买卖。

7.4.5 从指数走向债券

股票篮子可以减少单一公司的影响,但经济衰退,利率和融资变化仍可能让许多成分一起下跌。分散数量增加以后,投资者仍然主要持有企业的剩余索取权。

下一节换一种合同关系。普通债券把本金,利息,到期和偿付顺序写得更明确。与普通股相比,持有人通常不参与全部无上限的企业上行,换取约定支付和较优先的请求权。

约定并不保证没有风险。发行人可能违约,市场利率和通胀会改变支付的价值,中间现金再投资 and 实际出售也有各自条件。后面将从这些具体收付出发,讨论信用风险,期限与利率怎样进入债券价格。

7.5 债券、美债与利率

企业可以出售一部分权益来筹集资金,也可以向投资者借钱。前一种关系产生股票,后一种关系把我们带到债券。

最简单的借款关系就是投资者今天先把一笔钱交给借款人,借款人承诺按照事先约定的规则在未来还钱。当这种债权关系被标准化并做成能够继续交易的证券以后,我们就得到了债券。

固定收益, 美债市场以及国债基差交易的背景主要参考 [AS23; BK21; BKM23; CME24; TS11; US b; US c; US d].

定义 7.69.

债券 (bond) 是发行人为融资而发行的债务证券. 持有人依照合约享有未来收取本金, 利息或其他约定支付的权利.

发行时, 投资者提供资金, 发行人承担还款义务. 债券进入二级市场以后, 买方通常把钱付给原持有人, 接手这项请求权, 并非再次向发行人提供同额资金.

普通股分享企业扣除其他请求权后的剩余利益, 债券则先约定付款规则. 对没有违约或提前赎回的普通固定息债券, 票息和到期本金可以事先列出. 但浮息债券的票息取决于参考利率, TIPS 的支付随通胀调整, 可赎回债券可能提前结束, 可转债还包含与股票有关的选择. 合同能够先规定计算方法, 未必已经确定以后每笔金额.

普通债券约定的本金称为**面值** (face value 或 par value), 最终还款日称为**到期日** (maturity). 定期利息称为**票息** (coupon). 对固定息债券, **票面利率** (coupon rate) 通常按一年票息占面值的比例表示; 若一年付息多次, 每次金额还要按相应频率计算.

还款能力不足时, 谁先受偿会改变各债权人的回收. 因而清偿顺位和担保安排也是债券权利的一部分. 债券契约中的限制条款 (covenants) 可以约束继续举债或转移资产等行为, 减少发行人损害债权人利益的空间. 分析具体债券时, 这些条款应与现金流一起阅读.

7.5.1 货币的时间价值与零息债券

今天取得 \$100 与十年后取得 \$100, 可供使用的时间不同. 今天的资金可以消费, 支付债务或投入其他资产; 等待十年就放弃了期间这些用途. 未来物价变化也会影响届时的购买力.

利率给出了在特定条件下跨时间交换资金的比例. 假设可以按一年 5% 的确定利率投资, 今天的 \$100 到一年后成为 \$105. 反过来, 要在一年后取得 \$100, 今天需要

$$\frac{100}{1.05} \approx 95.24.$$

向后累计是复利, 把未来金额换算为今天的金额是贴现. 这个数来自所假定的投资机会, 不能仅凭有通胀就直接指定贴现率.

名义利率以货币金额计量, 实际回报还要考虑物价. 即使按约收到本金和利息, 若实际通胀超过名义收益, 购买力仍可能下降. 因而名义支付有保证与实际购买力不变, 是两个不同要求.

定义 7.70.

零息债券 (zero-coupon bond) 在存续期间不付票息, 到期一次支付约定金额.

先取无违约模型, 用 $P(t, T) > 0$ 表示在时刻 t 购买一份于 T 确定支付一单位货币的零息债券所需的价格, 并有 $P(T, T) = 1$. 它直接回答未来那一单位货币今天值多少, 因而也称为相应期限的**曲线贴现因子**.

固定今天的 t , 改变付款日 T , 就得到贴现曲线 $T \mapsto P(t, T)$. 一年后和十年后的支付分别使用各自期限的价格, 无须先把所有支付压成同一个利率.

例如, 一张债券在 $T_1, \dots, T_n$ 付票息 $C_1, \dots, C_n$, 最后还支付本金 F . 若这些支付确定, 没有违约和嵌入期权, 并使用同一套无套利贴现价格, 债券全价为

$$B_t = \sum_{i=1}^n C_i P(t, T_i) + F P(t, T_n).$$

此处 B_t 是这张债券的价格. 每项现金流都可以用相应数量的零息债券复制, 所以把各项成本相加. 到期票息和本金虽然同日支付, 金额仍须都计入.

当前可知的 $P(t, T)$ 与沿未来短率路径计算的 $\exp(-\int_t^T r_s ds)$ 不同. 随机利率下, 后一个数要等路径实现才能确定. 在相应定价测度和可积性条件下, 当前债券价格才可以写成这种随机贴现量的条件期望, 后文会继续说明.

注 7.71 (实际使用哪一条曲线).

美债和隔夜指数掉期 (overnight indexed swap, OIS) 等工具可以用来建立不同基准曲线. OIS 交换固定利率支付与按隔夜参考利率累计的浮动支付, 其报价因而提供相应期限的利率信息. 选择哪条曲线, 要看所研究现金流的币种, 抵押和结算条件. 美债收益率与抵押衍生品的贴现率未必相同, 不能仅因都用美元计价就混用.

7.5.2 债券价格, YTM 与市场报价

一张面值 \$1000 的债券每年付 \$50, 票面利率就是 5%. 固定息合约的这项约定不随二级市场价格改变. 但新投资者若以 \$900 买入, 就只付了 \$900 来取得剩余支付, 实际回报不能再用品面利率概括.

到期收益率 (Yield to Maturity, YTM) 把当前价格与约定的剩余现金流联系起来. 它是使这些现金流的贴现值恰好等于买入全价的统一内部收益率. 暂不处理实际日计数和非标准结算, 以年为时间单位并采用每年复利 m 次的约定, 则 y 满足

$$B_t = \sum_{i=1}^n \frac{C_i}{(1 + y/m)^{m(T_i - t)}} + \frac{F}{(1 + y/m)^{m(T_n - t)}}, \quad 1 + y/m > 0.$$

B_t 在这里是全价. 与上一节逐期使用 $P(t, T_i)$ 不同, YTM 让所有支付都使用同一个 y , 再反解到与市场价格相等. 它方便概括一张债券的报价, 不表示整条期限曲线真的处处等于这个利率.

沿用面值 \$1000, 年票息 \$50, 买价 \$900 的例子, 再明确假设只剩一年, 到期一次收到最后票息和本金, 没有违约及其他费用. 此时

$$900 = \frac{1050}{1 + y}, \quad y = \frac{1050}{900} - 1 \approx 16.67\%.$$

票面利率仍为 5%, 每年票息相对买价为 $50/900 \approx 5.56\%$, 一年持有至到期的收益却还包含本金从买价回到面值的差额. 这三个百分比分别计算不同的东西.

对固定的非负未来支付, 上式每项现值都随 y 增加而下降, 所以价格与 YTM 反向变化. 未来支付没有增加, 若投资者要求更高收益, 能接受的今天买价就会降低.

多期债券的 YTM 也不保证投资者最后取得同样的财富复合增速. 提前出售会引入未来售价, 违约或赎回会改变现金流. 若把 YTM 解释为持有到期的复合增长率, 还须处理期间票息怎样再投资. 仅仅持有到期, 不会自动把每次收到的票息按初始 YTM 继续投资.

实际报价还要区分**净价** (clean price) 与**全价** (dirty price). 在通常的固定息债券报价安排中, 买方在两个付息日之间购买债券, 以后会按规则取得整笔下一期票息. 结算时因此另外向卖方支付按日计数算出的**应计利息** (accrued interest):

$$\text{Dirty Price} = \text{Clean Price} + \text{Accrued Interest}.$$

这项支付在买卖双方之间分配本期持有对应的票息, 不改变发行人的原付息日. 具体除息和日计数仍按债券规则处理.

若屏幕上的 99.5 是每 \$100 面值的净价, 实际价款就要在 99.5 上加相应应计利息, 再按购买面值换算. 计算 YTM 和持有回报时, 应使用与实际现金支出相符的全价, 交易费用则另行计入.

7.5.3 即期利率, 远期利率与期限结构

零息债券价格可以换算成不同的利率表示. 对 $t < T$ 和 $P(t, T) > 0$, 采用连续复利, 定义**即期利率**或**零息利率**

$$P(t, T) = e^{-y(t, T)(T-t)}, \quad y(t, T) = -\frac{\log P(t, T)}{T-t}.$$

它把今天付出 $P(t, T)$, 到 T 收到一单位的增长, 换成年化连续复利率. 不同期限有不同价格, 所以也可以有不同的 $y(t, T)$.

还可以比较相邻到期日的价格. 从今天锁定在 T 附近一小段时间的资金交换, 其连续复利率由 $\log P(t, T)$ 对到期日的变化决定. 若该函数可微, 定义**瞬时远期利率**

$$f(t, T) := -\frac{\partial}{\partial T} \log P(t, T).$$

结合 $P(t, t) = 1$, 积分还原为

$$P(t, T) = \exp \left(- \int_t^T f(t, u) du \right).$$

若右端极限存在, 当前瞬时短率为 $r_t = f(t, t)$. 因而 $y(t, T)$ 汇总今天到 T 的整段增长, $f(t, T)$ 描述今天价格所隐含的未来局部交换条件, r_t 则取最短端.

远期利率由当前债券价格推出, 现实中未来短率的条件均值则依赖概率判断. 两者可以在某些简化模型下相同, 一般却不能直接互换; 风险补偿, 测度和凸性等差别需要另外处理.

注 7.72 (三种收益率曲线).

平价收益率曲线 (par yield curve) 问每个期限的票息应设为多少, 才使相应债券按面值定价. **零息收益率曲线** (zero-coupon curve) 或**即期曲线** (spot curve) 汇总 $y(t, T)$. **远期曲线** (forward curve) 汇总 $f(t, T)$. 它们可以由同一组贴现价格联系起来, 但纵轴上的利率含义不同.

例如, 美国财政部公布的 Treasury Par Yield Curve 采用平价收益率口径, 并非直接给出零息利率或远期利率. 从票息债券市场估计零息价格以后, 才能按相应方法进一步构造另外两条曲线 [US b].

期限较长时, 投资者面临更久的利率和通胀变化. 期限结构模型常把长期收益率分解为未来短率的平均预期与**期限溢价** (term premium). 后者反映承担期限风险等因素的补偿, 需要通过模型估计, 也可能为负.

因此, 曲线倒挂并没有单独给出唯一的未来政策路径. 短率预期, 期限溢价与债券供需都可能影响斜率. 要从曲线推断市场判断, 应说明采用了什么分解假设, 而不是把一条价格曲线直接当成现实预测.

久期, 凸性与每基点价值 固定现金流以后, 可以研究收益率稍有变化时价格怎样改变. 以 $B(y) > 0$ 表示采用给定复利约定的债券全价, 定义**修正久期** (modified duration)

$$D_{\text{mod}} := -\frac{1}{B} \frac{\partial B}{\partial y}.$$

它是价格相对变化对收益率的一阶敏感度, 前面的负号使普通固定支付债券的久期为正. Taylor 展开给出

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y.$$

收益率须以小数代入. 例如, 假设债券全价为 100, 修正久期为 8, 收益率上升 10 个基点, 即 $\Delta y = 0.001$, 则一阶估计价格下降 0.8%, 约为 0.80. 这是固定现金流和局部变动下的计算, 不是对未来价格路径的预测.

继续保留二阶项, 定义**凸性** (convexity) 为 $\text{Convexity} = B^{-1} \partial^2 B / \partial y^2$, 就有

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y + \frac{1}{2} \text{Convexity} (\Delta y)^2.$$

普通固定正现金流债券在相应收益率范围内具有正凸性. 变动幅度增大时, 一阶近似的误差更值得检查; 若存在赎回等期权, 还要考虑现金流本身是否随利率改变.

每基点价值 (DV01 或 PV01) 将相对敏感度换成货币金额. 一个基点为 $0.01\% = 10^{-4}$, 在这里的单一收益率近似下, 普通多头的绝对金额约为 $B D_{\text{mod}} 10^{-4}$. 上例每基点约为 $100 \times 8 \times 10^{-4} = 0.08$. 收益率上升时, 价格变化的符号为负; 报告持仓 DV01 时应同时说明采用的符号约定.

麦考利久期 (Macaulay duration) 则把各付款时间按其现金流现值占总价的比例加权平均. 在前面每年复利 m 次的固定支付模型中,

$$D_{\text{mod}} = \frac{D_{\text{Mac}}}{1 + y/m}.$$

零息债券只在到期支付, 所以麦考利久期恰好等于剩余期限. 有票息时, 一部分价值更早回到持有人手中, 同样到期日也可以有不同久期.

以上比较只改变一个收益率. 真实曲线可能短端上升而长端下降, 或在某些期限变化更大. 要研究这种风险, 还须分别计算不同期限点变化的影响, 不能只用一个总久期概括全部曲线变动.

7.5.4 美债

定义 7.73.

美国国债 (U.S. Treasury Securities) 是美国财政部为联邦政府融资发行的债务证券.

不同种类提供不同现金流. Treasury Bills 位于短端, 主要以到期支付为收益来源; Treasury Notes 和 Treasury Bonds 提供较长期的固定票息与本金; TIPS 使本金随通胀调整; 浮息票据 (Floating Rate Notes, FRNs) 则让票息随参考利率改变 [US d].

一只票息债券中包含多笔支付, 美债市场还允许把符合条件的支付拆开交易.

例 7.74 (STRIPS).

STRIPS 可以将合格 Treasury Note, Treasury Bond 或 TIPS 的各次利息和本金拆成独立交易的零息证券. 例如, 一张还剩十年, 每半年付息一次的 Treasury Bond, 包含二十笔票息和一笔到期本金, 可以分为二十一个支付组成部分. 最后票息与本金在同一天支付, 所以二十一个组成部分不表示二十一个不同日期 [US c].

名义美债的固定支付拆开后, 与前面用于贴现计算的单次确定现金流十分接近. TIPS 拆出的支付仍保留相应通胀调整, 零息并不使其金额变成固定名义数.

美债的作用还超过收取票息和本金. 下面先看它作为其他美元资产的价格比较基准, 再看金融机构怎样用它融资.

美元固定收益市场的基准资产 评价公司债时, 可以先与相近期限的美债或其他合适基准比较, 再研究额外信用与流动性条件需要多少补偿. 美债因此是美元固定收益市场的重要基准.

基准自身也有特殊用途. 流动性, 安全资产需求和抵押融资价值, 都可能提高投资者愿意支付的价格并压低收益率. 所以屏幕上的十年美债收益率不能用于所有美元现金流: 即使暂不考虑违约, 期限, 计价和抵押条件也可能不同.

财政部公布的官方平价曲线使用市场指示性买方报价拟合. 固定期限美债利率 (Constant Maturity Treasury rates) 是从相应曲线上取得的标准期限点, 不必恰好等于某只剩余期限完全相同的债券的实际成交 YTM. 需要逐项贴现时, 还要建立适合该问题的零息曲线 [US b].

普通名义美债承诺美元金额. 即使发行人足额支付, 长期通胀仍可能降低购买力. TIPS (Treasury Inflation-Protected Securities) 则通过调整本金来改变这项风险: 票面利率先固定, 票息按调整后的本金计算.

通缩期间, TIPS 本金可以向下调整, 到期偿还本金有原始面值下限. 这个下限保护的是合约到期本金, 不保证二级市场买价或提前出售价格. 投资者仍可能因买入价格, 利率和退出时间承受亏损 [US d].

同期限名义美债与 TIPS 的收益率差常被用来观察**通胀补偿** (inflation compensation). 它除了包含预期通胀, 还受到通胀风险补偿, 相对流动性与供需影响. 因而这个差额适合用来研究市场定价中的通胀因素, 不应直接当成对未来通胀的纯粹平均预测.

美债作为抵押品 持有美债的机构需要现金时, 可以出售债券, 也可以用它安排短期融资. 出借人若取得易于估值和出售的抵押品, 借款人不还款时就多了一条回收途径. 美债因其信用与市场流动性, 广泛用于这类交易.

典型安排是**回购协议** (repurchase agreement, repo): 一方先出售证券取得现金, 同时约定以后按规定价款买回. 从现金使用和到期偿还看, 它接近以证券担保的短期借款, 具体权利仍由回购合同确定.

若抵押品市值为 $V_0 > 0$, 出借现金为 C_0 , 可以定义抵押折扣

$$h = 1 - \frac{C_0}{V_0}.$$

于是 $C_0 = (1 - h)V_0$. 正的 haircut 让出借现金低于抵押品当前价值, 为后续价格下跌与处置成本留出缓冲. 对融资买入同一笔债券的交易者, 其余条件相同时, 折扣越小, 需要补足的自有资金越少.

缓冲很小也会使资金压力更敏感. 抵押品下跌, 折扣提高或出借人拒绝续作时, 原先能够融资的金额可能减少, 交易者就须补现金, 增加抵押或减仓. 因而美债信用较好, 不代表用高杠杆持有美债没有流动性风险.

Treasury repo 有不同市场和清算安排, haircut 并非处处相同. 某些双边交易也使用过零 haircut, 配合净额结算和其他风险管理措施. 判断一笔融资能够提供多大缓冲, 应看实际合同和清算方式, 不只看抵押品叫作美债.

国债基差交易 国债基差交易同时使用现券, 期货和 repo. **现券美债** (cash Treasury) 是已经发行并可买卖的债券, **国债期货** (Treasury futures) 则规定未来的交割安排和期间盈亏结算. 两者可能具有相近的利率暴露, 但取得和维持它们所需的现金不同.

一份可实物交割的国债期货通常允许空头从合格债券篮子中选择交割券. 不同券的票息和期限不同, 合约按**转换因子** (conversion factor, CF) 调整相应交割价款. 理解期货报价与某只现券的关系, 因而先要查交割规则, 不能把两边的报价直接相减 [CME24].

在价格单位已经对齐时, 一只候选券的原始基差常写为

$$b_t^{\text{raw}} = P_t^{\text{cash, clean}} - \text{CF} F_t^{\text{fut}}.$$

这里使用现券净价减去经转换因子调整的期货价. 因而期货相对变贵时, 这个差额会变小, 甚至为负.

不同资料可能采用相反符号. 例如 Federal Reserve 讨论的 option-adjusted basis net of carry (OABNOC) 采用收益口径, 正值对应期货相对现券偏贵, 有利于研究做多现券并做空期货的 long basis trade [Gli+24]. 所以看到正基差以前, 应先确认它实际在减什么, 是否已经扣除了持有成本和交割期权价值.

原始基差尚未计算全部现金. 买现券需要付全价并承担融资, 持有期间收到票息, 交割时还有应计利息和时间选择. 空头可以选择交割券, 也会改变期货与某一只固定现券之间的关系. 把这些因素放在同一期限上比较以后, 才能判断价差是否足以补偿成本与风险.

当交易者认为期货偏贵时, 可以买入适合交割的现券, 同时卖出相应期货. 为减少现券占用的自有资金, 再用买到的美债做 repo, 融入大部分购买款. 现券上涨时的收益与期货空头的损失可以抵消一部分共同利率风险, 交易主要依赖相对价格与持有成本的变化.

对冲了方向风险, 不表示两个账户的收付会自动同步. 期货空头需要按规则结算变动保证金; 现券融资到期需要续作; repo 对手方还可能要求补抵押, 调整折扣或提高利率. 即使最后交割会使相对价格受到很强约束, 中间仍然需要真实现金.

例如, 期货先相对上涨, 空头就须支付变动保证金. 现券相对下跌, 又可能减少能够取得的融资. 若此时 repo 不能按原条件续作, 交易者可能只能卖出现券筹钱, 同时买回期货退出对冲. 许多交易者一起这样做, 会增加现券卖压与期货买盘, 使尚未退出者面对的相对价格继续恶化.

OFR, Federal Reserve 和 BIS 的研究都讨论了 repo 续作, 期货保证金与高杠杆减仓之间的联系 [AS23; BK21; BKM23]. 此外, 交割券选择改变或模型估计错误, 也可能使原以为能取得的价差并不存在.

因此, 这类交易不仅要算预期收敛收益, 还要算持有期间需要多少现金, 哪些融资条件一变就必须减仓. 下一节将进一步解释这些美元短端资金从哪里来, repo, SOFR 和银行准备金怎样联系起来.

7.5.5 信用风险, 信用利差与 CDS

两只债券约定相近的支付时间, 发行人的还款能力却可能不同. 现金流稳定的企业与接近破产的企业即使写下同样的承诺, 投资者愿意付出的价格也会不同. 这就是**信用风险**进入债券价格的直接方式.

公司债收益率与选定基准之间的差额称为利差 (spread). 它可能补偿预期违约损失, 也可能包含承担不确定信用损失的风险补偿, 相对流动性及供需等影响. 因而较高利差不能全部换算成预计坏账.

还要说明怎样比较. G-spread 将债券 YTM 与相应政府债曲线点比较, I-spread 改用掉期曲线. Z-spread 则对每个现金流的零息贴现率加同一个利差, 直到总现值等于当前价格. 有嵌入期权时, OAS 在相应模型中进一步分离期权影响.

这些数值各有用途. 比较两张债券的利差以前, 应确认基准, 现金流和期权处理一致, 否则数字的变化可能来自计算方法而非发行人信用.

进一步计算信用支付时, 可以用**违约时间**

$$\tau: \Omega \rightarrow [0, \infty]$$

表示何时违约, $\tau = \infty$ 表示不发生违约. 在采用的信息下, 通常要求违约时间为停时, 即到了当时能够判断是否已经违约. 对 $T > t$, $\mathbb{P}(\tau > T | \mathcal{F}_t)$ 是当前信息下存续到 T 的条件概率.

违约后未必全部损失. **回收率** (recovery rate) 要先指定相对于什么金额计算, 例如面值, 违约前市值或某项无风险支付价值. 固定这项基数后, 在回收比例为 $0 \leq R \leq 1$ 的简化约定下, **违约损失率** (Loss Given Default, LGD) 为 $1 - R$. 不同回收约定会产生不同的定价公式.

若模型允许用**违约强度** (hazard rate) λ_t 描述局部到达, 在尚未违约的条件下可以写出小时间展开

$$\mathbb{P}(t < \tau \leq t + h | \tau > t, \mathcal{F}_t) = \lambda_t h + o(h), \quad h \downarrow 0.$$

λ_t 的单位是每单位时间, 并不是一个不带期限的违约概率. 上式只用于具备这种强度表示的模型, 不对任意违约时间都直接成立.

这样, 研究需要回答的具体问题就是: 债务人可能何时停止付款, 此前支付多少, 违约时还能回收多少. 这些判断决定实际现金流, 再由相应定价方法计算价值.

持有债券的投资者还可以另外购买信用保护, 把一部分违约损失交给另一方承担.

定义 7.75.

信用违约互换 (Credit Default Swap, CDS) 约定由信用保护买方按规则支付费用, 参考主体或债务发生指定信用事件时, 保护卖方向买方提供约定的保护支付.

这便于将信用风险与现券持有分开. 保护买方也可能没有持有相应债券, 所以 CDS 既能对冲现有风险, 也能用于单独交易信用变化. 它与普通保险在法律和合约安排上不同, 实际保护仍取决于信用事件定义和结算方式.

CDS 价格通常比一张现券更集中地反映信用保护的价值, 但仍须考虑回收, 风险补偿, 流动性, 融资及保护卖方自身能否履约. 不能把所有报价变化都解释成参考主体实际违约频率改变.

平价 CDS 利差 (par CDS spread) s_{CDS} 是使合约初始价值为零的持续费率. 它平衡买方以后支付的费用与卖方可能承担的损失. 看一个简化计算: 单位名义金额, 常数回收率 R , 定价测度下常数强度 $\lambda^{\mathbb{Q}}$, 确定常数利率 r , 费用连续支付至违约或到期, 违约时立即赔付, 且没有交易对手违约. 平价条件为

$$s_{\text{CDS}} \int_0^T e^{-(r+\lambda^{\mathbb{Q}})u} du = (1-R)\lambda^{\mathbb{Q}} \int_0^T e^{-(r+\lambda^{\mathbb{Q}})u} du.$$

左边按存续概率计算费率支付, 右边按违约到达与损失比例计算保护支付. 公共积分消去, 在这些假设下得到等式. 用于概括较一般合约时, 常写作近似关系

$$s_{\text{CDS}} \approx (1-R)\lambda^{\mathbb{Q}}.$$

实际离散缴费, 应计费用和回收约定都可能使简单表达需要调整.

这里的 $\mathbb{Q}$ 是所选无套利定价模型的测度, 因而反推出的是**风险中性违约强度**. 现实发生概率用 $\mathbb{P}$ 描述, 不必具有同一强度. 即使在常数强度模型内, 期限 T 的违约概率也是 $1 - e^{-\lambda^{\mathbb{Q}}T}$, 不能把每年的强度直接当成任意期限的概率.

市场合约还可能采用标准化固定票息, 并用交易开始时的**前端支付** (upfront payment) 补足与市值之间的差额. 因而平价利差便于比较信用定价, 实际要付的固定费用与前端金额仍须按合约分别计算.

7.5.6 从期限结构到随机过程

利率模型需要同时处理当前观察时间与未来付款时间, 因而使用整族价格

$$P(t, T), \quad 0 \leq t \leq T.$$

固定到期日 T , 让 t 向前走, 观察的是同一张债券从今天直到到期怎样变价. 固定今天 t , 改变 T , 观察的则是同一时刻各个未来期限的贴现价格. 前者是一条随时间演化的价格过程, 后者是一整条当前曲线.

这两个方向不能混同. 今天的十年利率与明天的十年利率, 还对应了不同的实际到期日; 今天买入一张十年债券, 明天持有的是剩余期限已经缩短的同一只债券. 期限结构模型需要把这些关系一致地处理.

短率模型先规定 r_t 怎样演化, 再推导各到期日的债券价格, Vasicek 和 CIR 属于这类思路. HJM 则直接研究远期曲线随观察时间怎样变化. 两种办法选择不同的建模起点, 最后仍须与同一市场中的现金流和无套利关系相容.

到这里, 债券的支付, 贴现和利率敏感度已经连在一起. 美债还把投资账户与抵押融资连接起来, 公司债和 CDS 则要求进一步研究违约后的收付.

下一节回到短端资金的实际来源: 一家银行为什么要借隔夜资金, 持有美债的机构怎样取得现金, 美联储准备金和不同隔夜参考利率又分别参与哪一步.

7.6 美联储, 美元体系与短端资金市场

长期债券要面对多年利率和通胀变化. 把期限缩短到隔夜, 今天借出资金, 下一个工作日收回, 等待时间虽然短了, 付款仍需要完成. 借款人能否及时取得现金, 出借人拿到什么保障, 都会影响这笔钱的价格.

银行可能因为客户向另一家银行付款而需要准备金. 证券交易商可能已经持有美债, 却需要现金支付其他交易. 企业或货币市场基金则可能有暂时不用的现金, 希望取得短期收益. 隔夜市场把这些需要联系起来, 不同信用, 抵押和准入条件又会形成不同利率.

本节先从存款和银行间付款讲起, 再看财政部收支怎样改变准备金, 以及现金持有人如何在无抵押借贷, repo 和其他短期工具之间选择. 最后说明美联储怎样通过管理利率影响这些选择, 再回到模型中的瞬时短率 r_t .

这些安排有各自的历史来源, 并非一次设计完成. 相关说明主要参考 Federal Reserve, New York Fed, FDIC, SEC, BIS 及教材和论文 [Ald+20; Alt; Boab; Boac; Boad; Boae; DD83; Fedd; Fedf; Fedg; Fedi; Hul22; HPW19; MT; TS11; US g].

阅读时可以始终问两件事: 这笔金额是谁对谁的负债, 此处的利率是管理者设定的报酬, 市场成交的统计, 还是用于计算的模型变量? 把这些问题放回每笔收付, 各个缩写就有了具体用途.

7.6.1 银行付款为什么需要中央银行

美联储体系

定义 7.76.

美联储 (Federal Reserve System, Fed) 是美国的中央银行体系. 它制定和实施货币政策, 提供中央银行结算和流动性服务, 监管部分金融机构, 并承担维护金融稳定等职责.

早期美国银行之间的资金调动受到地区分割等限制. 恐慌时, 客户突然希望把存款换成现金或转往更安全的机构, 支付需求会集中增加. 没有统一中央银行支持时, 清算所, 财政部和私人银行家只能临时协调资金.

1907 年恐慌从纽约信托公司和短期融资市场扩散, 推动了货币改革 [MT]. 1913 年联邦储备法建立美联储体系, 为提供更有弹性的货币和银行流动性安排奠定基础 [Boad; Fedi].

理解它的作用, 可以先把商业银行与银行间结算分开. 商业银行能向客户发放贷款并开立存款, 客户在不同银行之间支付时, 银行还要转移彼此接受的结算资产. 美联储提供的准备金账户和支付安排, 就用于完成这一层的收付.

组织上, 美联储包括位于 Washington, D.C. 的理事会 (Board of Governors), 十二家地区联邦储备银行, 以及负责相应公开市场政策决定的联邦公开市场委员会 (Federal Open Market Committee, FOMC). 全国性决策与地区机构并存, 体现了建立体系时对权力集中和地区参与的安排.

纽约联邦储备银行承担重要市场操作和参考利率发布工作. 后面讨论隔夜借贷, repo 和政策实施时, 会具体看到它怎样参与, 不必先把所有工具名称记成一张清单.

同样叫美元, 谁承担付款义务 一张美元纸币, 银行账户中的美元存款和银行持有的准备金, 都用同一货币单位计量, 但付款义务不完全来自同一个机构.

定义 7.77.

美联储票据 (Federal Reserve Note) 是美联储体系发行进入流通的美元纸币, 在美联储资产负债表上列为负债。

Federal Reserve Note 用于现金支付。前面的 Treasury Note 则是财政部发行的中期国债, 尽管英文都有 Note, 发行人和合约功能不同。

银行还可以在符合资格时持有美联储账户余额。

定义 7.78.

本节所称**准备金**主要指金融机构在美联储持有的**准备金余额** (reserve balances), 用于银行间支付结算和流动性管理。更广义的银行准备金概念还可能包括其他相应项目, 下文不将这些不同口径混用。

纸币和准备金余额都在中央银行负债端, 但持有人和使用方式不同。公众可以直接持有纸币, 准备金账户则限于符合条件的机构。

普通客户的商业银行存款是另一项关系。若客户账户有 \$10,000, 客户持有的是要求该银行按约支付的资产, 银行则欠客户 \$10,000。这笔存款并不等于客户直接在美联储拥有等额准备金。

对象	对谁是资产	对谁是负债	主要用途
美元纸币	持有人	美联储	现金支付
银行存款	储户	商业银行	支付, 储蓄
准备金余额	商业银行等机构	美联储	银行间结算, 流动性管理

正常情况下, 客户可以把账户里的 \$100 提取成现金, 或转到另一家银行, 所以日常使用中这些差别不显眼。但一旦研究流动性和违约, 就必须知道由谁付款, 需要经过哪个账户。同为美元计价, 并没有消除发行人和法律请求权的区别。

贷款, 跨行付款与挤兑 假设银行向客户发放金额 L 的贷款, 并把款项记入客户账户。银行同时增加一项对借款人的债权和一项对客户的存款负债:

银行资产	银行负债
+ 贷款 L	+ 存款 L

这一步说明贷款可以创造银行自己的存款, 没有说明银行同时创造了美联储准备金。

现在让借款人把这笔钱支付给另一家银行的客户。在两家银行通过准备金完成结算的简化例子中, 放贷银行的客户存款减少 L , 准备金资产也减少 L , 原来的贷款资产仍留在账上。收款银行的准备金增加 L , 同时为收款客户增加存款 L 。

这次转账改变了准备金在银行之间的分布, 并未仅凭转账增加银行体系的准备金总量。对放贷银行而言, 却已经发生真实的资金流出。若新贷款形成的支付持续流向外行, 它就要吸收存款, 借入批发资金, 做 repo, 出售资产或在符合条件时向央行借款, 才能继续完成结算。

挤兑把这种压力集中到短时间。存款人希望立即取款, 银行的长期贷款却未必能立即按账面价值卖出。一家按正常持有回收可能有足够资产的银行, 也可能因被迫低价出售而遭受损失。Diamond-Dybvig 模型讨论了这种期限转换与挤兑的关系 [DD83]。

相关制度分别作用于不同问题。贴现窗口向符合条件的存款机构提供抵押借款, 帮助取得流动性。1933 年建立的 FDIC 及存款保险安排减少了受保护储户抢先提款的动机 [Fedal]。资本和审慎监管则还要处理资产损失与偿付能力, 不能只靠临时借款解决所有问题。

2020 年, 美联储将法定准备金率降为零 [Boag]。这取消的是特定的法定比例要求。客户跨行付款仍需要结算, 银行仍须安排能够支付的准备金和其他流动性, 所以零法定比例不等于零准备金需求。

7.6.2 TGA 收支怎样改变准备金

客户从一家银行转到另一家银行，主要改变准备金分布。资金转入财政部在美联储的账户时，则可能改变银行体系准备金总量。

定义 7.79.

美国财政部一般账户 (Treasury General Account, TGA) 是财政部在美联储的主要运营账户，用于结算相应的财政收入，发债融资和政府支出。

假设客户用银行存款缴纳一笔税款。银行扣减客户存款，美联储扣减该银行的准备金账户，同时增加财政部的 TGA 余额。在其他项目不变时，银行体系准备金减少，TGA 增加。财政部以后从 TGA 向银行客户付款，则反向减少 TGA，增加收款银行准备金及客户存款。

这可以用资产负债表核对。将美联储资产负债表简化为

$$A_t^{\text{Fed}} = N_t + R_t + G_t + Q_t + O_t,$$

其中 A_t^{Fed} 为资产，右边分别为流通纸币 N_t ，准备金 R_t ，TGA 余额 G_t ，逆回购等负债 Q_t ，以及其余负债和资本 O_t 。两个时点相减，得到

$$\Delta R_t = \Delta A_t^{\text{Fed}} - \Delta N_t - \Delta G_t - \Delta Q_t - \Delta O_t.$$

若资产，纸币及其他项目短期近似不变，才进一步有

$$\Delta R_t \approx -\Delta G_t - \Delta Q_t.$$

这保留了一个重要条件：TGA 变化时，其他负债也可能变化。例如在纯粹的教学记账中，若 TGA 增加 100，逆回购负债同时减少 100，其余项目不变，两项对准备金的影响恰好抵消。所以不能只看到 TGA 上升就断言准备金必定同额下降，还要看资金来自哪里及其他操作。

税款，国债结算和政府集中支出因此会改变短端现金条件。债务上限僵局结束后的 TGA 补充，也可能在一段时间内影响资金供给。相关会计项目与市场影响见 [Boac; HPW19]。

资产负债表告诉我们余额必须怎样对应，却没有单独给出利率会升多少。同样数量的准备金流出，在原本充足或已经偏紧的环境中可能有不同影响，还取决于准备金分布和机构能否相互调动资金。研究短率时，应先算清这些收付，再估计市场如何响应。

7.6.3 短期美元资金可以放在哪里

现在换到出借人的位置。一家机构持有大额暂时不用的美元，不能假设全部金额都受零售存款保险保护，又希望取得短期利息。它要比较到期由谁还款，能否提前取用，有无抵押，自己是否具备参与资格。

银行存款与无抵押借贷主要依靠债务人履约。Repo 另外提供证券，T-bill 直接对应财政部支付，货币市场基金则让投资者通过份额持有一篮子短期资产。符合条件的机构还可以直接使用相应央行账户或工具。它们并没有一个不考虑期限和用途就适用的风险排序。

工具	直接债务人或持有方式	主要保障来源	仍须判断什么
未保险存款, fed funds	银行等借款机构	偿付能力与流动性	无抵押信用和支付风险
Prime MMF 份额	基金投资	短期限和分散持仓	私人信用，赎回与基金安排
Government MMF 份额	基金投资	政府证券及相关 repo 等	流动性，操作和非保证净值
Treasury repo	回购交易对手	国债抵押及相应折扣	抵押处置，对手方和结算
T-bill	美国财政部	主权支付与市场流动性	出售价格，结算和极端制度风险
准备金, ON RRP	联储账户或交易	央行负债或央行对手方	是否有资格及具体操作条件

下面从银行间借贷开始, 逐项看这些选择怎样形成实际利率.

无抵押隔夜借贷: Fed funds 与 EFFR 某家机构需要准备金完成付款, 另一家有可出借的余额, 两者可以进行隔夜融资. 这类交易把准备金从一处调到另一处, 不等于私人市场凭借借贷增加了准备金总量.

定义 7.80.

联邦基金市场 (Federal Funds Market) 是符合条件的机构围绕美联储账户余额进行无抵押隔夜融资的市场. 其中各笔交易约定的利率称为联邦基金利率.

出借人没有同时拿到一篮子美债, 所以需要判断借款机构的信用与支付能力. 双方自身的资产负债表成本和其他资金去处, 也会影响愿意接受的利率.

定义 7.81.

有效联邦基金利率 (Effective Federal Funds Rate, EFFR) 是纽约联储根据相应实际隔夜交易计算的成交量加权中位数.

这项统计按成交金额给予权重, 不是把每笔利率不加区别地平均, 更不是 FOMC 直接写下的某个单一成交价. FOMC 设定联邦基金利率目标区间, 美联储再通过政策工具改变机构的资金选择, 使市场成交围绕政策目标运行 [Fedd; Fede].

因此, 研究 EFFR 变化时, 可以同时查看政策安排和市场借贷条件. 某些机构当日更急需现金, 或出借资金受到限制, 都可能影响实际成交. 只有进一步取得数据和模型, 才能把变化具体分解为信用, 流动性或其他贡献.

货币市场基金与短期现金管理 企业, 保险公司和其他投资者也有暂时不用的美元, 但未必能直接参加每个银行间市场. 货币市场基金把这些资金集中起来, 由基金配置一篮子短期资产.

定义 7.82.

货币市场基金 (Money Market Fund, MMF) 主要投资短期限, 高流动性债务工具, 常用于短期现金管理.

投资者交入现金后取得基金份额, 基金再买入证券或出借短期资金. 收益和风险来自实际持有的资产, 所以先要知道它是哪一类基金.

政府型基金主要配置现金, 美国政府证券和相应政府证券支持的 repo. Prime 基金还可以投资银行存单, 商业票据等私人短期信用工具. 免税型基金主要持有短期市政债务. 这些范围对应不同债务人, 不能仅因都叫货币市场基金就假定风险相同.

注 7.83.

MMF 份额是基金投资, 不属于 FDIC 对合格银行存款的保险. 稳定的日常现金管理体验, 也不表示基金净值和赎回在所有情况下都有保证. 仍须看持仓信用, 期限, 流动性及赎回规则 [US g].

因此, 组合报告中的现金可能包括银行存款, T-bill, MMF 份额或 repo 等不同安排. 它们都可能适合短期停放资金, 但到需要付款时怎样变成可用现金, 以及由谁承担履约义务, 要分别核对.

Repo 与抵押融资 持有债券而暂时缺现金的机构, 可以与有现金的一方做 repo. 借款人取得现金继续使用, 出借人则在合同安排下取得证券作为保护.

定义 7.84.

回购协议 (Repurchase Agreement, Repo) 先出售证券取得现金, 并同时约定以后按规定价款买回. 从资金收付看, 它具有证券担保融资的经济作用.

例如, 今天交出美债取得 \$100, 次日付 \$100.01 买回, 多付的 \$0.01 就是融资利息. 若初始现金

为 $C_0 > 0$, 回购价款为 C_1 , 计息期间占一年的比例为 $\delta > 0$, 简单年化利率为

$$r^{\text{repo}} = \frac{C_1/C_0 - 1}{\delta}.$$

若进一步作教学假设, 这笔交易跨一个自然日并采用 $\delta = 1/360$, 则利率为 $0.0001 \times 360 = 3.6\%$. 隔夜到下一个工作日可能跨多个自然日, 实际年化须按合同日计数计算, 不能总把期间当成一天.

同一交易对交券取现的一方称为 repo, 从出借现金并取得证券的一方看称为 reverse repo. 名称改变的是观察方向, 不是又发生了另一笔资金.

出借现金未必等于抵押品全部市值. 设市值 $V_0 > 0$, 则

$$h = 1 - \frac{C_0}{V_0}$$

表示这里采用的 haircut. 若上述 \$100 现金对应 \$102 抵押品, 这一教学例子的折扣为 $1 - 100/102 \approx 1.96\%$. 多出的抵押价值用于缓冲价格下跌与处置成本, 不等于出借人没有剩余风险.

抵押品若难以出售或交易对手违约, 实际回收仍依赖合同, 结算和市场价格. 交易还可以结合保证金调整与净额结算等办法管理这些问题.

某只特定美债若很难取得, 出借人可能为了暂时拿到它, 接受较低的现金收益. 这称为该券处于特殊状态 (trading special). 因而 repo 利率同时反映现金条件与所交证券的需求, 不能把所有 repo 都当成完全同质的借款 [Fedf].

SOFR 与不同期限的利息计算

定义 7.85.

有担保隔夜融资利率 (Secured Overnight Financing Rate, SOFR) 是纽约联储根据相应美债 repo 隔夜成交计算并发布的参考利率, 用于衡量以美债担保取得隔夜现金的成本.

SOFR 的发展与伦敦银行间同业拆借利率 (London Interbank Offered Rate, LIBOR) 的问题有关. LIBOR 曾用于大量贷款和衍生品, 但相关基础交易稀薄及操纵风险使报价可靠性受到质疑. Alternative Reference Rates Committee (ARRC) 在 2017 年选择 SOFR 作为美元 LIBOR 的推荐替代利率 [Alt].

市场先发生 repo 交易, 纽约联储再汇总符合方法的记录. 数据包括三方 repo, General Collateral Finance Repo (GCF Repo), 以及部分经 Fixed Income Clearing Corporation (FICC) 清算的双边 Treasury repo. 对部分特殊券交易作相应筛选后, 计算成交量加权中位数 [Fedg]. 这些名称说明统计覆盖哪些融资交易, 不表示存在几项需要相加的政策利率.

EFFR 与 SOFR 因此都来自成交统计, 但前者观察无抵押联邦基金交易, 后者观察美债担保 repo. 债务人, 抵押品和市场资金需要不同, 两个统计结果不必相等.

一笔三个月贷款若约定使用隔夜 SOFR, 还要规定怎样从每天的短期利率算出整段利息. 简单的逐日复合采用

$$\prod_i (1 + \text{SOFR}_{t_i} \Delta_i),$$

其中 Δ_i 是该次利率适用的计息年数比例. 每一因子表示对应天数的增长, 相乘后才是整个期间的增长因子. 实际观察日, 非营业日和利率使用滞后等安排, 都要按合约确定.

这就区分了三种说法. **隔夜 SOFR** 是某个隔夜市场的参考利率; **复合 SOFR** 由一段期间使用的各次利率累计, 在采用未来实际利率的安排下, 开始时尚不知道最后结果; **前瞻期限 SOFR** (forward-looking Term SOFR) 则依据相关衍生品价格构造规定期限的利率, 见 [CMEb].

它们可以服务于不同合同, 但不能因为名称相同就替换. 计算利息前应先确认使用哪一种, 哪些日期的利率, 以及采用什么日计数.

IORB 与 ON RRP 怎样影响市场选择 美联储不必为每笔私人借贷直接指定利率. 它可以改变机构在中央银行取得的收益, 从而改变这些机构向别人出借资金时愿意接受的条件. 这在充裕准备金的实施框架中尤其重要.

定义 7.86.

准备金余额利率 (Interest on Reserve Balances, IORB) 是美联储向符合条件机构的准备金余额支付的管理利率。

准备金付息权限经历了法律变化. 2006 年的授权原计划在 2011 年生效, 2008 年危机期间提前到当年 10 月实施 [Boae]. 随后资产负债表扩张和大量准备金持有, 使准备金报酬成为影响短期资金选择的重要工具。

一家有资格取得 IORB 的银行, 可以比较把余额留在美联储的收益与借给另一机构的收益. 出借还承担信用和其他成本, 所以 IORB 成为它的重要机会成本. 管理利率改变, 银行愿意接受的其他短期利率也会受到影响。

但并非每个出借人都能取得 IORB. 某些政府支持企业和 Federal Home Loan Banks 没有这种付息资格, 仍可能接受低于 IORB 的联邦基金利率. 能够在两边配置资金的机构也有自己的资产负债表成本, 因而不保证差额被完全消除. EFFR 低于 IORB 并不与这种机会成本解释矛盾。

定义 7.87.

隔夜逆回购工具 (Overnight Reverse Repurchase Agreement Facility, ON RRP) 为符合条件的交易对手提供与美联储进行隔夜投资的安排, 报酬按规定的 ON RRP offering rate 计算。

符合条件的货币市场基金和政府支持企业等, 可以把它与市场中的 repo 或其他短期去处比较. 对不能取得 IORB 的部分非银行投资者, ON RRP 提供了另一种面对中央银行的资金选择, 从而帮助减轻货币市场利率的下行压力 [Boaf; Fedf]. 它同样有资格和操作条件, 不是所有现金持有人都能无限制参加。

因此, FOMC 目标区间说明政策希望联邦基金利率运行在哪里; IORB 和 ON RRP 报酬改变相关参与者的投资选择; EFFR 与 SOFR 则统计实际市场的成交结果. 政策使这些利率相互联系, 信用, 抵押品, 准入和资金分布又使它们可以存在差额。

不能把 EFFR, IORB 和 SOFR 写成普遍相等的利率. 研究差额时, 应回到对应交易: 谁能取得央行报酬, 谁正在借钱, 哪种抵押品紧缺, 哪些机构能够在市场之间调动资金。

7.6.4 离岸美元与链上美元

离岸美元与全球美元融资 美元债权和债务也大量存在于美国境外. 存放在境外银行的美元存款, 传统上称为欧洲美元或离岸美元存款 (Eurodollar). 这里的 Euro 不限定欧洲, 计价货币也没有变成欧元。

与美国境内存款一样, 境外银行的美元存款首先是该银行对客户的负债. 银行能否支付, 取决于整体资产, 资金来源和结算安排, 不等于每笔存款背后都为储户单独存放了同额美联储准备金。

承诺美元支付的银行需要安排美元来源. 它可以吸收美元存款, 向其他机构借款, 做 repo 或发行美元债务, 也可以通过外汇掉期 (FX swap) 临时取得美元. 例如一家欧洲机构主要持有欧元, 却需要三个月美元, 可以现在交出欧元取得美元, 同时约定到期反向交换. 两次汇率事先约定, 才使它比较这段融资的成本。

令 S_t 为一单位外币的即期美元价, $F_t(T)$ 为同样报价方式的远期价, Δ 为相应年数比例. 若两种货币在同一期限均可按给定简单利率借贷, 汇兑无摩擦, 并允许双向套利, 抵补利率平价为

$$\frac{F_t(T)}{S_t} = \frac{1 + r_t^s \Delta}{1 + r_t^f \Delta}.$$

可以从一单位外币比较两条路径. 今天换成 S_t 美元并投资, 到期有 $S_t(1 + r_t^s \Delta)$ 美元. 先投资外币, 再按已经锁定的远期价兑换, 则有 $(1 + r_t^f \Delta)F_t(T)$ 美元. 两边相等就得到上式, 并没有使用对未来即期汇率的预测。

实际借贷, 信用和资产负债表条件不同, 通过外汇掉期取得美元的成本可能偏离这种简单关系, 常用 cross-currency basis 描述 [Ald+20]. 比较其扩大或缩小时, 还应先确认报价方向及把基差加在哪一边的利率上。

2008 年和 2020 年的美元融资压力说明, 境外机构有大量美元付款义务, 不代表压力时能立即取得足够美元. 中央银行之间的安排可以提供额外渠道。

定义 7.88.

央行美元流动性互换 (central bank U.S. dollar liquidity swap) 是美联储与外国央行的货币交换安排. 美联储提供美元, 外国央行提供相应本币并约定以后反向交换, 再由外国央行按自己的操作向辖区机构提供美元.

美联储直接面对的是外国央行, 而不是每家境外商业银行. 外国央行负责转贷并承担借款机构的信用风险, 央行之间则按互换合同处理反向交换等义务 [Boa20b; Boab]. 这使美元流动性支持能够经由外国央行到达境外机构, 也说明美元短端压力不能只在美国国内银行体系中寻找原因.

法币储备型稳定币与链上美元 美元计价还可以通过链上代币延伸. 这里仅讨论与传统短端资产直接相连的法币储备型安排, 不概括所有稳定币设计.

定义 7.89.

法币储备型美元稳定币 (fiat-backed USD stablecoin) 由私人主体发行, 以美元计价, 通过储备资产和相应赎回安排争取使每单位代币价值接近 \$1.

发行人可以在传统金融体系持有银行存款, 短期美债或美债担保逆回购, 同时在链上发行代币. 因而链上转移虽然采用另一种记录方式, 支撑赎回的资产仍可能依赖银行, 证券与短期融资市场.

持有人取得的具体权利, 包括是否能够直接赎回和按什么条件赎回, 要看条款. 一枚私人发行的美元代币不会仅因以美元计价, 就成为一单位美联储准备金或受相同保障的银行存款.

若储备发生损失, 需要变现时缺少流动性, 或赎回出现障碍, 市场可能不愿继续按一美元接手, 形成**脱锚** (depeg). 分析这种风险, 应回到储备资产, 付款责任和赎回步骤, 而不只观察代币平时是否接近一美元.

7.6.5 从美元资金市场到短期利率模型

前面并没有找到一个所有机构都能按相同条件借入和贷出的美元利率. 管理利率改变资金选择, EFFR 和 SOFR 汇总不同市场的成交, T-bill, 银行融资和外汇掉期又有各自条件. 要研究具体价差, 应保留这些区别, 并说明准备金, 抵押品或资金限制怎样进入相应交易.

若先研究最基本的连续贴现, 可以作一个更简单的假设: 存在瞬时短率 r_t , 资金能够按它连续滚动. 取 r 渐进可测, 并在每个有限期限满足 $\int_0^T |r_s| ds < \infty$ a.s. 定义初值为一的**货币市场账户** (money-market account)

$$B_t = \exp \left(\int_0^t r_s ds \right).$$

逐条路径使用普通微积分, 得到

$$dB_t = r_t B_t dt, \quad B_0 = 1.$$

即使 r_t 随机, B 仍是严格为正的连续有限变差过程. 常数利率时它退化为 $B_t = e^{rt}$. 这里的货币市场账户是模型中的滚动账户, 不等于前面持有短期证券篮子的货币市场基金.

一笔隔夜成交跨有限时间, 发布利率又来自统计; r_t 则描述模型中的瞬时增长率. 可以用适当的隔夜利率帮助估计和校准它, 但须说明从实际数据到模型采用了哪些简化, 不能仅把 SOFR 改名为 r_t 就认为定义已经相同.

它与上一节的零息债券价格有明确联系. 若选择 B 作为计价资产, 并在相应定价测度 $\mathbb{Q}^B$ 下使 $P(\cdot, T)/B$ 成为真鞅, 利用到期支付 $P(T, T) = 1$, 就有

$$P(t, T) = \mathbb{E}^{\mathbb{Q}^B} \left[\frac{B_t}{B_T} \mid \mathcal{F}_t \right] = \mathbb{E}^{\mathbb{Q}^B} \left[\exp \left(- \int_t^T r_s ds \right) \mid \mathcal{F}_t \right].$$

因此, 当前债券价格是未来滚动贴现量的条件期望, 不是把尚未实现的短率路径当成已经知道. 真鞅和相应可积条件也正是能够写这项条件期望的前提, 见第6.4节.

若零息曲线在到期方向足够光滑并满足相应短端一致性, 则还可写为

$$r_t = - \frac{\partial}{\partial T} \log P(t, T) \Big|_{T=t}.$$

这把当前曲线最短端与滚动账户的瞬时增长联系起来. 它是一项模型关系, 本身没有替我们决定实际应采用哪种抵押和融资条件.

更细的应用还会区分贴现曲线, 浮息现金流的预测曲线, 机构自身融资成本, 抵押品报酬和跨币种价差. 保留多少差异取决于研究问题: 只研究简单复制时可以先作统一利率假设, 计算实际融资与结算时则需要把相关成本加回.

下一节将更集中地讨论无套利. 现在已经能够把不同日期的支付换算到同一时刻, 接下来就问: 在确实能够双向交易和复制的条件下, 两组相同未来现金流为什么应有相同的今天价格?

7.7 贴现与无套利

第7.1节, 第7.2节, 第7.3节和第7.4节已经说明不同资产与合约怎样产生收益. 第7.5节和第7.6节又给出了零息债券价格 $P(t, T)$, 短率 r_t 与货币市场账户 B_t . 现在用这些工具比较不同交易的价格.

先问时间不同怎样比较. 今天的一单位货币可以立即使用, 一年后的确定支付则要等待. 零息债券价格给出两者的交换比例, 这就是贴现.

再问两种取得同样支付的办法能否卖不同价格. 如果可以按给定条件买入便宜的一边, 卖出昂贵的一边, 并让以后的全部收付抵消, 初始差额就可以保留下来. 无套利要求排除这样的交易, 由此得到一价定律和复制价格.

因此, 推导价格以前应先写清持有数量, 付款时间和合约义务. 买卖, 融资与交付能否实际按模型条件完成, 决定了两边是否真的可以比较. 后面从无摩擦情形开始, 再看价差和融资限制怎样改变结论.

本节采用无套利定价与资产定价理论的标准方法 [Coc05; DS94; Duf01; HK79; HP81; Hul22; Shr04a; Shr04b], 并与前面已经推导的自融资和鞅关系相衔接.

7.7.1 贴现和计价资产

一只在 T 确定支付一单位货币的无违约零息债券, 今天的价格为 $P(t, T)$. 要在同一天取得确定金额 x , 可以持有 x 单位该债券, 成本就是

$$xP(t, T).$$

这里利用的是支付数量可以按相同比例放大的交易关系. 若允许相应借款和卖空, 负的 x 也可以表示到期付款义务.

确定常数利率 r 下, 连续复利给出

$$P(t, T) = e^{-r(T-t)},$$

所以未来的 x 折为今天的 $xe^{-r(T-t)}$. 随机利率下, 当前零息债券价格仍然可以用于这笔确定支付, 但不能把尚未知的未来短率路径直接当成已经锁定的投资利率.

另一个有用的做法是改变计量单位. 与其总问资产值多少美元, 也可以问它值多少单位某项可交易资产.

定义 7.90 (计价资产).

在给定期限内, 取严格为正, 可交易的自融资价值过程 N , 并将分配留在该投资中再投资, 或假设它没有另行支付的分配. 以 N 作为计价资产 (numéraire) 时, 资产价格 S_t 的相对价格为

$$\hat{S}_t = \frac{S_t}{N_t}.$$

严格正值保证可以作除法. 可交易和自融资则保证所选单位对应一种能够持有的投资, 而不只是任意正数序列. 相对价格的变化比较两项投资的价值, 选择计价资产本身尚未保证这个比值是鞅.

常用的计价资产是货币市场账户. 若短率 r 适应并满足所需可测性, 且在有限期限上路径绝对可积, 定义

$$B_t = \exp\left(\int_0^t r_s ds\right), \quad B_0 = 1.$$

它表示资金按每一时刻的短率连续滚动. 用它计量股票, 得到贴现价格

$$\tilde{S}_t = \frac{S_t}{B_t}.$$

同一段时间中, 股票即使按美元上涨, 也未必跑赢现金账户. 后面研究的是这种相对收益在合适定价测度下的性质; 不能把相对价格的鞅关系直接套给原始价格.

注 7.91 (贴现曲线的选择).

实际现金流的币种, 抵押和融资安排会影响应采用的曲线. 美债, OIS, 抵押品报酬和机构自身融资成本分别对应不同交易条件. 先确定哪一笔收付需要比较, 再选相应价格和计价资产, 才能解释贴现所得的金额.

7.7.2 套利和无套利

取交易期限 $[0, T]$, 以 V_t^ϕ 表示策略 ϕ 的净财富, 其中包括现金, 资产和融资负债. 策略遵守当时的信息限制, 并且自融资: 初始建仓以后, 调仓和中间收付都在同一组合内完成, 不从外部追加或取走资金.

还须先规定哪些策略可允许. 在有限模型中, 这包含交易方向和数量等条件; 在连续时间中, 通常还限制财富的下界, 排除靠无限借款维持的翻倍下注. 自融资说明钱从哪里来, 可允许性说明允许采用什么持仓和承担什么风险, 两者不能互相替代.

定义 7.92 (套利和无套利).

可允许的自融资策略 ϕ 若满足

$$V_0^\phi = 0, \quad V_T^\phi \geq 0 \quad \text{a.s.}, \quad \mathbb{P}(V_T^\phi > 0) > 0,$$

就称为**套利** (arbitrage). 若不存在这样的策略, 则市场满足**无套利** (no-arbitrage).

零初始净财富可以包含相互抵消的资产和借款, 并非不进行任何交易. 终端条件要求偿清相应义务以后仍然几乎必然不亏, 而且有正概率盈利. 中间财富是否可能下降以及需要多少资金缓冲, 仍由前面的可允许条件控制.

另一种常见写法把初始成本记为 $c_0 \leq 0$, 终端支付记为 $X_T \geq 0$, 并要求 $c_0 < 0$ 或 $\mathbb{P}(X_T > 0) > 0$ 至少一项成立. 它还包括今天已经净收一笔钱, 到期收付恰好抵消的交易. 若这笔初始收入可以投入严格为正的现金账户, 到期便保留正财富, 从而转成上面的零净投入形式.

预期收益较高的风险投资不必是套利, 因为它仍可能亏损. 无套利检查的是在规定交易条件下, 能否用零净投入取得这种终端不亏的机会. 改变卖空, 融资或持仓规则以后, 可实施的策略集合也会改变, 应在新的条件下重新判断.

7.7.3 一价定律

两种交易若最后给出完全相同的收付, 可以直接比较取得它们的成本. 这里的相同要求先把中间分配与融资都计入, 并对齐币种, 数量和结算条件, 不能只比较名称相近的资产.

命题 7.93 (一价定律).

假设市场无套利, 组合 A, B 的持有和融资安排均已确定, 中间现金流已完整计入各自的自融资财富. 两者能够按所写价格和数量双向交易, 单位, 币种, 交付, 税费与结算条件可比, 且买入一边, 卖空另一边并投资初始差额的组合策略也可允许. 若

$$V_T^A = V_T^B \quad \text{a.s.},$$

则

$$V_0^A = V_0^B.$$

证明. 若 $V_0^A < V_0^B$, 买入 A 并卖空 B , 初始净收入为 $V_0^B - V_0^A > 0$. 将全部收入投入严格为正的现金账户 N , 这三项合起来的初始净投入为零. 到期时 $V_T^A - V_T^B = 0$, 剩余财富为

$$(V_0^B - V_0^A) \frac{N_T}{N_0} > 0.$$

由假设, 整个策略可允许且自融资, 所以构成套利, 与无套利矛盾. 交换 A, B 可同样排除 $V_0^A > V_0^B$. $\square$

证明不需要预测哪一种未来更可能发生, 因为两边在每种可能结果下都相互抵消. 这正是复制方法的力量: 先找到相同支付, 再用已有资产价格确定成本.

证明也指出了交易条件的作用. 若昂贵的一边不能卖空, 或中间融资无法维持, 上述组合就不再是允许的交易. 此时要根据剩下能够实施的方向重新推导, 可能只得到单边价格限制. 后面的带摩擦例子会把这个区别直接算出来.

7.7.4 复制定价

定义 7.94 (复制).

给定仅在 T 支付的现金流 X_T , 若由可交易资产组成的可允许自融资策略 θ 满足

$$V_T^\theta = X_T \quad \text{a.s.},$$

就称该策略复制 (replicate) 了这一支付. 策略的初始财富 $V_0^\theta = v$ 是复制成本.

命题 7.95 (复制价格).

假设市场无套利, 目标合约与复制策略都能按所写数量双向交易, 组合交易及所需融资可允许并能够自融资完成. 两边的单位, 币种, 中间现金流, 交付, 抵押, 信用, 税费和结算条件相同, 或差异已通过可实施的交易完整计入复制成本 v . 若 $V_T^\theta = X_T$ a.s., 目标合约的唯一无套利价格为 v .

证明. 若合约价格高于 v , 卖出合约并买入复制策略; 若低于 v , 买入合约并反向建立复制策略. 两种情况下, 到期支付相互抵消, 初始都留下正差额. 将差额投入正值现金账户, 便得到一价定律证明中的套利. $\square$

下面在无摩擦, 可双向交易和融资的假设下计算两个例子. 关键都在于用已有资产凑出同一笔未来收付, 而非先预测未来价格.

远期交割价格 设现货价格为 S_0 , 持有期间无股息或其他持有成本, 零息债券价格为 $P(0, T) > 0$. 买入一单位现货, 同时借入 S_0 , 初始净投入为零. 若通过出售零息债券锁定到期还款, 需要出售 $S_0/P(0, T)$ 单位, 到期偿还

$$\frac{S_0}{P(0, T)}.$$

因此这组持仓的到期净值是 $S_T - S_0/P(0, T)$. 它与按该金额交割的一单位远期多头相同, 从而零初始价值的远期交割价为

$$F_{0,T} = \frac{S_0}{P(0, T)}.$$

这里锁定的是到期借款金额. 随机利率下, 每天滚动借入短期资金并不保证最后恰好欠这个数, 因而不能随意把两种融资办法互换.

更一般地, 交割价为 K 的远期多头可由一单位现货加上到期支付 K 的负债复制, 当前价值为 $S_0 - KP(0, T)$. 让这个价值为零, 就得到上面的 $F_{0,T}$. 确定常数利率下,

$$F_{0,T} = S_0 e^{rT}.$$

欧式看涨看跌平价 对同一无股息标的, 同一执行价 $K > 0$ 和到期日 T , 比较两组持仓. 第一组买入看涨期权和 K 单位零息债券, 第二组买入看跌期权和一单位股票. 到期恒有

$$(S_T - K)^+ + K = (K - S_T)^+ + S_T = \max(S_T, K).$$

股价高于 K 时, 两边都等于 S_T ; 不高于 K 时, 两边都等于 K . 因而一价定律给出

$$c_0 + KP(0, T) = p_0 + S_0, \quad c_0 - p_0 = S_0 - KP(0, T).$$

这是看涨看跌平价. 它只规定两个期权价格之间必须满足的关系, 尚未分别算出 c_0 和 p_0 . 若有股息或提前行权权利, 就要重新检查中间收付与可采用的交易, 不再直接使用上述两组终端支付的比较.

7.7.5 状态价格和风险中性概率

在一时期有限状态市场中, 可以把各种终态分别计价. 设可能结果为 $\omega_1, \dots, \omega_n$, 各自在现实测度下都有正概率. 一个支付由各状态下的金额确定:

$$X_T = (X_1, \dots, X_n).$$

这个向量用于逐项计算支付成本, 不仅是列出未来情况的名称.

先假设每一种只在单个状态付款的基本支付都可以交易或复制, 并允许按数量作线性组合.

定义 7.96 (状态价格).

一份在状态 ω_i 支付一单位货币, 在其余状态支付零的基本证券, 其当前价格 π_i 称为该状态的状态价格 (state price).

分别持有 X_i 单位第 i 种基本证券, 到期就得到目标支付. 因而

$$V_0 = \sum_{i=1}^n \pi_i X_i.$$

在这里的双向交易假设下, 无套利要求 $\pi_i > 0$. 若某项价格为零或负, 买入就能在一个正概率状态得到正支付, 在其他状态不亏, 与无套利矛盾.

各买一单位基本证券, 不论发生哪种结果都收一单位货币, 所以

$$P(0, T) = \sum_{i=1}^n \pi_i.$$

将状态价格除以这笔确定支付的价格, 定义

$$q_i = \frac{\pi_i}{P(0, T)}, \quad q_i > 0, \quad \sum_{i=1}^n q_i = 1.$$

它们构成概率分布, 记相应测度为 $\mathbb{Q}^T$. 价格因而可以改写成

$$V_0 = P(0, T) \sum_{i=1}^n q_i X_i = P(0, T) \mathbb{E}^{\mathbb{Q}^T}[X_T].$$

这里先从基本证券的交易价格得到 π_i , 再归一化为 q_i . 不能反过来把未经风险调整的现实概率直接填进来, 就认为已经解释了市场价格.

定义 7.97 (计价资产对应的定价测度).

上述 $\mathbb{Q}^T$ 对应到期日为 T 的零息债券计价, 称为 **T -forward 测度**. 现金账户计价所对应的测度则通常称为**风险中性测度**, 下文记为 $\mathbb{Q}^B$. 它们都用于将价格关系写成相应的期望, 但所用计价资产和概率权重应一并说明.

对无股息股票, 同样有

$$S_0 = P(0, T) \mathbb{E}^{\mathbb{Q}^T}[S_T].$$

而 $\mathbb{E}^{\mathbb{P}}[S_T]$ 描述现实概率判断下的平均终价. 例如, 确定利率下预期获得正风险溢价的股票, 现实平均终价可以高于同额资金投资零息债券的终值. 定价公式仍然成立, 因为它使用了不同权重. 两种测度在特殊情形下也可能相同, 应区分的是定义和用途, 并非要求它们永远不相等.

若基本状态支付并非都可复制, 有限市场的无套利仍可对应一组严格正的定价权重, 使现有可交易支付按上式定价, 但这组权重未必唯一. 它们对可复制支付给出相同成本, 对不可复制支付则可能给出不同数值. 因而不能在不完备市场中任选一组权重, 就把所有新合约都宣布为已经有唯一市场价格.

7.7.6 随机贴现因子

同一组价格也可以保留现实概率 $\mathbb{P}$, 把不同结果的定价权重放在一个随机乘数中. 在前面的有限模型里, 若 $p_i = \mathbb{P}(\omega_i) > 0$, 取 $M_{0,T}(\omega_i) = \pi_i/p_i$, 则

$$\mathbb{E}^{\mathbb{P}}[M_{0,T}X_T] = \sum_i p_i \frac{\pi_i}{p_i} X_i = \sum_i \pi_i X_i.$$

这没有改变价格, 只是把状态价格拆成现实概率与另一个权重的乘积.

定义 7.98 (随机贴现因子).

相对于给定市场和被定价的支付类, 若严格为正且可积的随机变量 $M_{0,T}$ 满足

$$V_0 = \mathbb{E}^{\mathbb{P}}[M_{0,T}X_T],$$

就称其为相应的**随机贴现因子** (stochastic discount factor), 也称定价核或 state-price density. 对每项使用该式的支付, 还要求 $\mathbb{E}^{\mathbb{P}}[|M_{0,T}X_T|] < \infty$.

任意正随机变量并不会自动给出现有资产的正确价格, 定义中的定价等式是必要条件. 对确定支付 $X_T = x$, 它给出

$$V_0 = x\mathbb{E}^{\mathbb{P}}[M_{0,T}] = xP(0, T).$$

因此随机贴现因子的均值等于确定支付的贴现价格, 其余变化则记录不同结果在定价上受到怎样的重视.

例如, 在相应资产定价模型中, 投资者资金最紧缺时收到的现金可能更有价值, 对应较高的定价权重. 这不是仅凭发生概率能够表达的差别. 在 $M_{0,T}$ 与 X_T 都平方可积时, 还可直接展开为

$$V_0 = P(0, T)\mathbb{E}^{\mathbb{P}}[X_T] + \text{Cov}_{\mathbb{P}}(M_{0,T}, X_T).$$

相同现实平均支付, 与定价权重的共同变化不同, 当前价格也可以不同.

在时刻 t 使用同样思路, 写成

$$V_t = \mathbb{E}^{\mathbb{P}}[M_{t,T}X_T | \mathcal{F}_t].$$

它与换测度方法可以严格对应. 设 Z_t^B 是 $\mathbb{Q}^B$ 相对于 $\mathbb{P}$ 的严格正密度过程, 并且无中间分配的目标价值满足所需真鞅与可积条件. 取

$$M_{t,T} = \frac{B_t}{B_T} \frac{Z_T^B}{Z_t^B},$$

由条件期望的换测度公式得到

$$\frac{V_t}{B_t} = \mathbb{E}^{\mathbb{Q}^B} \left[\frac{X_T}{B_T} \mid \mathcal{F}_t \right].$$

这里既有沿未来短率累计的 B_t/B_T , 也有改变概率权重的密度比. 随机利率下, B_T 通常不能从这个期望中提出.

若改用 T 到期零息债券计价, 相应关系为 $V_t = P(t, T)\mathbb{E}^{\mathbb{Q}^T}[X_T | \mathcal{F}_t]$. 两式可以给出同一个价值, 但使用的测度不同. 确定利率等特殊情形下它们可以相同, 一般则须保留上标以说明采用哪种计价资产.

事件合约也是同一个计算. 对支付 $\mathbf{1}_A$,

$$C_0^A = \mathbb{E}^{\mathbb{P}}[M_{0,T}\mathbf{1}_A].$$

这个金额是事件发生时的定价权重总和. 再除以 $P(0, T) = \mathbb{E}^{\mathbb{P}}[M_{0,T}]$, 才得到相应的归一化定价概率. 它与现实概率 $\mathbb{P}(A)$ 的关系, 取决于 $M_{0,T}$ 是否随事件结果改变, 以及所用报价是否符合这个定价模型.

7.7.7 带摩擦的套利边界与套利限制

无摩擦远期价格为 $F_{0,T} = S_0/P(0,T)$. 一旦买入和卖出使用不同价格, 借钱与存钱又采用不同利率, 前面的两个套利方向便会有不同成本.

设现货买价为 S_0^{bid} , 卖价为 S_0^{ask} , 借款与存款的确定连续复利率分别为 $r_{\text{borrow}} \geq r_{\text{lend}}$. 假设标的无分配和其他持有成本, 可以卖空, 卖空所得可全部投资, 两种利率都能锁到 T . 先令远期没有买卖价差, 可以按同一个零初始价值交割价 $F_{0,T}$ 买入或卖出.

买现货时要付卖价并承担借款成本. 若远期交割价高于 $S_0^{\text{ask}}e^{r_{\text{borrow}}T}$, 就可借钱买现货, 卖出远期, 到期用交割款还清借款后留有正差额. 这给出上界.

反向交易只能按买价卖出现货, 所得按存款利率增长. 若远期价低于 $S_0^{\text{bid}}e^{r_{\text{lend}}T}$, 就可卖空现货并投资所得, 买入远期, 到期按较低价取得标的还券. 这给出下界. 因而

$$\underbrace{S_0^{\text{bid}}e^{r_{\text{lend}}T}}_{F_{0,T}^{\text{lower}}} \leq F_{0,T} \leq \underbrace{S_0^{\text{ask}}e^{r_{\text{borrow}}T}}_{F_{0,T}^{\text{upper}}}.$$

价差和借贷利差让两个方向的复制成本分开, 区间内的价格差未必足以支付交易成本. 能够事先锁定的手续费或借券费用, 也可按到期金额分别加入对应方向的成本.

远期本身若也有买卖价差, 就要用能实际卖出的远期买价检验上界, 用能实际买入的远期卖价检验下界, 不能拿一个不可成交的中间报价同时执行两边交易.

这些边界已经假定融资和券源能够维持到期. 若只能短期续借, 或途中可能因保证金不足被迫平仓, 原先的操作就没有锁定全部后果. 这类限制研究者利用价格差的条件, 常称为**套利限制** (limits to arbitrage) [SV97]. 不能一方面假定融资完全锁定来推导确定收益, 另一方面又在实施时依赖尚不确定的续作.

期货相对现货偏贵时, 买现货并卖期货是常见的 cash-and-carry 方向; 便宜时则相反. 期货中途结算盈亏, 现货的融资和资产价值却未必同步提供可用现金. 即使最后交割有助于价格接近, 中间不利价差也可能引发追加保证金和减仓. 前面的国债基差例子已经把这些现金需要逐项说明.

永续合约没有同样的固定到期收敛日. 合约明显偏贵并且资金费由多头支付时, 买现货, 卖永续可以在对冲部分方向风险的同时取得资金费. 但未来费率可以改变, 基差和保证金仍会波动, 平台与执行也有风险. 这种收益取决于持有路径, 应按相对价值交易计算, 不能只把当前一次正资金费延长成确定利润.

ETF 创建赎回同样要求篮子份额能够按相应数量交易, 并完成转换. 若底层缺乏报价, 估计净值与 ETF 价格的差额就未必能按屏幕数值取得. 判断价差时, 应使用每条实际交易的收付, 而不是只比较两个理论中点.

做市商也可能参与这些交易, 但提供双向报价本身还承担库存, 逆向选择和对冲成本. 价差与返佣是可能的收入来源, 不是保证利润; 下一节将进一步计算成交与后续报价变化的关系.

因此, 无套利始终检查给定条件下真正可允许的策略. 某个市场价格偏离无摩擦公式, 可能是因为公式省略了实际成本和可交易限制, 并不立即给出满足本节套利定义的机会.

7.7.8 通往鞅和金融市场基本定理

一时期定价按终态匹配支付, 多期和连续时间还允许根据新信息调整持仓. 因而价格之间的一致性必须在整个交易过程中维持, 不能只检查几项静态合约.

第6.2节已给出有限状态树上的基本定理: 在相应无摩擦, 双向交易的有限模型中, 无套利等价于等价鞅测度存在; 市场完备则对应测度唯一. 连续时间中还要控制一系列策略在极限中趋近套利的问题. 对局部有界的半鞅贴现价格及标准可允许策略, 相应的无免费午餐且风险趋于消失条件与等价局部鞅测度相联系 [DS94]. 更一般半鞅需要相应的一般化表述.

资产若另有分配, 应对累计收益而非单独除息价格应用这一思路. 设 S 是除息价格, D 是累计每单位现金分配, B 是严格为正的连续有限变差现金账户, 并满足相应积分条件. 贴现累计收益为

$$\frac{S_t}{B_t} + \int_{(0,t]} \frac{1}{B_u} dD_u.$$

价格与分配使用同一计价单位, 才能表示持有资产的全部模型收益. 在合适的等价定价测度下, 这一过程具有局部鞅性质, 见第6.4节.

局部鞅足以与可允许性一起排除某些套利, 却未必给出等号形式的期望定价. 例如, 有固定下界的局部鞅财富是超鞅, 其期望不会超过初始财富; 零初始财富因而不能成为非负且以正概率为正的

终端财富. 要把价值写成终值的条件期望, 则还需要真鞅性质, 可由相应平方可积或一致可积条件保证, 不能只检查每个时点分别可积.

对期间没有分配且贴现价格为真鞅的资产, 才得到

$$\frac{S_t}{B_t} = \mathbb{E}^{\mathbb{Q}^B} \left[\frac{S_T}{B_T} \mid \mathcal{F}_t \right].$$

这与前面随机贴现因子的表达相同: 给定当前信息, 在相应计价资产和测度下计算未来支付.

注 7.99 (完备性决定能否仅靠复制定价).

每个所研究支付都可复制时, 市场称为完备. 在前述有限模型中, 这使定价测度唯一. 不完备时, 可复制支付仍有唯一复制成本, 不可复制支付则可能对应一段无套利价格范围. 对它再选一个具体价格, 需要额外说明风险偏好, 模型或其他定价假设.

确定现金流可以直接用当前贴现曲线相加. 支付依赖未来股价, 利率或整条路径时, 就需要相应的联合动态, 才能计算条件期望和复制持仓. Black-Scholes, 利率和波动率模型各自选择不同的动态假设, 但都须回到同样的现金流与自融资关系.

下一节把视角转向实际成交. 即使已经知道模型价格, 一笔指定数量的订单按什么价格完成, 还要看报价, 排队和其他参与者的交易.

7.8 交易, 订单簿与市场微观结构

第7.7节比较了合约支付与复制成本. 实际买卖时, 还要问整笔数量能按什么价格成交. 屏幕上有一档卖价, 不表示这一档足以卖给我们所需的全部数量; 愿意等候的限价单, 也未必能在希望的时点成交.

定义 7.100 (市场微观结构).

市场微观结构 (market microstructure) 研究参与者怎样在具体交易规则下提交订单和报价, 这些订单怎样成交, 以及信息, 库存, 流动性和交易制度怎样影响价格与成本.

本节沿着订单进入市场后的过程展开, 参考 [FPR23; Har02; Has07; Mad00; OHa95]. 先看市场单和限价单怎样使用现有报价, 再计算一笔订单扫过多个档位的支出. 之后讨论为什么有人愿意提供这些报价, 又为什么会撤回或调整它们.

沿用最优买价 b_t , 最优卖价 a_t 和中间价 $m_t = (a_t + b_t)/2$. 成交价则是具体买卖双方实际接受的价格. 买方和卖方可以有不同价值判断, 也可以因资金需求或对冲而交易. 因而成交记录既包含信息, 也反映当时的交易需要; 要解释它, 先看发生了怎样的订单与收付.

7.8.1 从一张订单进入市场开始

投资者决定买入以后, 还要向经纪商或相应交易系统发送指令. 经纪商可能先检查权限, 资金和风险条件, 再选择执行场所. 场所收到并接受订单, 才按自己的规则寻找对手方, 安排等候或返回结果.

有些机构直接接入场所, 有些订单在经纪商内部完成, 有些进入不展示完整盘口的系统. 无论经过哪条途径, 决定买入和实际买到之间都可能有时间差. 已发出的订单可以未被接受, 已被接受的订单也可以尚未成交.

交易场所与参与者

定义 7.101 (交易场所).

交易场所 (trading venue) 是按既定规则接收并执行交易指令的市场组织或系统. 公开限价订单簿, 另类交易系统, 暗池及经纪商或交易商的内部执行安排, 都可能提供不同形式的交易场所.

同一证券可以在多个场所交易. 一处的最优价格, 未必是所有可访问场所中的最优价格. 即使报价相同, 可成交数量, 费用, 排队规则和到达速度也可能不同.

经纪商接收并安排客户订单, 做市商和其他挂单者提供可执行报价, 套利或相对价值交易者则同时比较不同资产与场所. 场所负责按规则处理这些订单. 这些名称说明所做的工作, 并不把参与

者永久分成互不重叠的几类：普通投资者也可以挂单提供流动性，做市商也可能主动买入别人挂出的数量。

订单包含什么

定义 7.102 (订单).

订单 (order) 是按指定方向, 数量和执行条件请求买入或卖出资产的指令. 它可以被拒绝, 全部或部分成交, 也可以按规则保留未成交余量等待.

提交时应说明交易哪项证券, 买卖方向, 数量, 价格限制和有效期. 是否展示, 是否接受部分成交, 是否只在某个交易时段生效, 也会改变处理结果. 场所接受订单的时间, 则可能决定它在同价订单中的位置.

系统还要核对资金, 已有持仓, 风险限额和价格保护等条件. 因而按下买卖按钮以后, 应查看接收和成交回报, 不能把界面上的目标数量直接当成已持有数量, 也不能用发送前最后看到的价格代替最终成交价.

7.8.2 市场单, 限价单与订单簿

定义 7.103 (市场单, 限价单与撤单).

市场单 (market order) 请求尽快按可用的对手方报价执行, 实际价格由当时的数量和市场价格规则决定.

限价单 (limit order) 规定最差可接受价格: 买入成交不高于限价, 卖出成交不低于限价.

撤单 (cancellation) 请求取消尚未成交的剩余数量, 不撤回此前已经确认的成交.

限价单也可以立即成交. 若买入限价 $\ell \geq a_t$, 就能在相应报价仍有效且订单条件允许时接受现有卖盘; 卖出限价 $\ell \leq b_t$ 时同理. 这称为**可成交限价单** (marketable limit order). 超过可接受价格的余量, 则按有效期和其他规则继续等待或取消.

因此, 限价单是否提供流动性, 要看它到达时是留在簿上等待, 还是主动接受别人的报价. 市场单偏重即时成交, 可能用更差价格换取后续数量; 限价单保留价格限制, 代价是可能只完成一部分或一直没有成交. 市场中断或价格保护也会影响市场单, 所以市场单并不无条件保证全部完成.

撤单消息也要经过传输和处理. 在它生效以前, 原单仍可能成交. 修改价格或增加数量, 在许多采用时间优先的规则中会丢失原排队位置, 但具体处理仍取决于场所及订单类型. 计算剩余订单时, 应使用确认后的结果, 不把已经发送的撤改请求当成已经生效.

订单簿与各档数量

定义 7.104 (限价订单簿与深度).

限价订单簿 (limit order book) 按方向, 限价和优先次序组织尚未成交的订单. 同一价位上剩余可交易的数量称为该价位的**深度** (depth). 使用公开行情时, 下文的数量专指当前能够看到的显示深度.

将同价买单的剩余数量相加, 记为 $Q_t^b(p)$; 同价卖单的剩余数量相加, 记为 $Q_t^a(p)$. 在两侧非空且最优档位存在时,

$$b_t = \max\{p : Q_t^b(p) > 0\}, \quad a_t = \min\{p : Q_t^a(p) > 0\}.$$

最高买价是卖方立即卖出首先遇到的价格, 最低卖价是买方立即买入首先遇到的价格. 若某一侧为空, 就没有这一侧的最优报价, 相应中间价也不能照常计算.

按成交优先方向, 买价由高到低记为 $p_{1,t}^b, p_{2,t}^b, \dots$, 卖价由低到高记为 $p_{1,t}^a, p_{2,t}^a, \dots$. 因而 $p_{1,t}^b = b_t$, $p_{1,t}^a = a_t$. 各档显示数量分别记为 $Q_{k,t}^b, Q_{k,t}^a$, 后面的扫单和价差计算会直接用到这些数量.

注 7.105 (显示数量能说明什么).

盘口是当时的快照, 挂单者仍可能撤回或改价. 隐藏订单和冰山订单的未展示部分, 其他场所及公开簿外的交易也不在这张快照中. 所以据此计算一笔假设订单的成交, 需要说明在计算期间是否忽略了这些变化.

撮合优先规则

原则 7.106 (价格优先与时间优先).

在采用价格优先, 同价时间优先的连续订单簿中, 买单按更高限价优先, 卖单按更低限价优先. 同价且具有相同优先类别的订单, 较早被场所接受的先成交.

这使后来提交的 100.01 卖价排在较早提交的 100.02 卖价之前, 因为买方可以先按更低价格取得股票. 两张订单价格相同以后, 才比较接受时间.

以下排队例子采用这套规则. 它不是所有交易场所的共同算法: 某些衍生品采用按数量比例等方式分配, 开收盘集合竞价另有统一撮合安排, 隐藏或特殊订单也可能有不同优先类别 [Gou+13]. 计算自己前面还有多少数量时, 必须使用对应规则.

7.8.3 一次撮合与交易成本

在上述连续撮合规则中, 主动买单先接受最低卖价, 用完这一档数量才继续向上; 主动卖单则从最高买价向下执行. 因而一张大订单可以产生多笔不同价格的成交.

定义 7.107 (成交均价与滑点).

若订单全部成交, 数量 $Q > 0$ 分成 n 笔, 第 k 笔价格与数量为 p_k, q_k , 且 $\sum_k q_k = Q$, 成交均价为

$$\bar{p}(Q) = \frac{\sum_{k=1}^n p_k q_k}{Q}.$$

选定基准价格 p^* , 按正数表示买贵或卖便宜的约定, 每单位滑点为

$$\text{Slip}_{\text{buy}} = \bar{p}(Q) - p^*, \quad \text{Slip}_{\text{sell}} = p^* - \bar{p}(Q).$$

均价乘以成交数量, 才是总买入支出或卖出收入. 若只部分成交, 分母应改为实际已成交数量, 未完成部分另行记录.

滑点取决于基准. 与到达前最优对手价相比, 可以看到扫过后续档位增加了多少支出; 与当时中间价相比, 还包含最初跨越半个价差的成本. 用更早的决策价格, 则把等待和传输期间的价格变化也算在里面. 因而报告滑点必须同时说明基准时点和价格种类.

例 7.108 (一张市场买单怎样扫过订单簿).

以下采用价格优先的连续撮合, 订单允许部分成交. 暂不计费用, 隐藏流动性, 其他场所和撮合期间的新单及撤单, 将给定显示数量视为可执行. 初始订单簿为

方向	价格	显示数量
卖出	100.04	500
卖出	100.03	200
卖出	100.02	300
买入	100.01	400
买入	100.00	600
买入	99.99	800

因而

$$b_t = 100.01, \quad a_t = 100.02, \quad m_t = 100.015.$$

买入 550 股的市场单先取得 100.02 的 300 股, 再取得 100.03 的 200 股, 最后从 100.04 这一档取得 50 股. 总支出为

$$300 \times 100.02 + 200 \times 100.03 + 50 \times 100.04 = 55,014.$$

所以

$$\bar{p}(550) = \frac{55,014}{550} \approx 100.02545.$$

与所有股票都按初始最优卖价买入相比, 多付

$$55,014 - 550 \times 100.02 = 3.00,$$

即每股约 0.00545. 若与初始中间价比较, 则多付

$$55,014 - 550 \times 100.015 = 5.75.$$

两种成本相差 $550 \times 0.005 = 2.75$, 正是这 550 股跨越最初半个价差的金额.

成交以后, 前两档卖单用尽, 100.04 还剩 450 股, 新最优卖价为 100.04. 买侧没有变化, 因而此刻显示价差扩大为 $100.04 - 100.01 = 0.03$.

再回到同一初始订单簿, 将市场单改成限价 100.03 的 550 股买单. 它只能取得前 500 股, 支出 $300 \times 100.02 + 200 \times 100.03 = 50,012$, 已成交部分的均价为 100.024. 剩余 50 股不接受 100.04; 是继续挂单还是取消, 由有效期和其他订单条件决定.

上述价格变化首先来自现有卖单被逐档取走. 它没有单独说明公司的未来现金流变化了多少, 也没有说明卖盘多久会补回. 同样一张买单可以来自新信息, 对冲或指数调仓, 后面的模型将分别研究这些动机怎样影响报价.

成交方向与有符号订单流 每笔成交买卖数量相等. 所谓买方发起, 是买方主动接受已有卖单; 卖方发起则相反. 统计主动方向, 才能讨论哪一侧正在更积极地消耗报价, 而不是把买卖成交总量说成不相等.

定义 7.109 (成交方向).

第 i 笔成交数量为 $v_i > 0$, 取

$$\varepsilon_i = \begin{cases} +1, & \text{买方主动发起,} \\ -1, & \text{卖方主动发起.} \end{cases}$$

有符号成交量为 $q_i = \varepsilon_i v_i$.

对一段时间求和,

$$Q_{t,t+\Delta}^{\text{trade}} = \sum_{i: t_i \in (t, t+\Delta]} \varepsilon_i v_i.$$

正值表示主动买入的数量超过主动卖出的数量. 前面的 550 股市场买单可产生三笔买方发起成交, 符号相同, 合计有符号数量为 550, 不因拆成三笔回报就变成三张独立投资决策.

有的数据直接报告主动方, 有的只能根据成交相对买价, 卖价和中间价的位置推断. 价差内部成交和报价时间不同步, 都可能使这种分类出错 [LR91]. 对无法可靠分类的成交, 应保留不确定性, 而不让算法强行制造准确方向.

成交不平衡只统计已完成交易. 若还纳入限价单加入和撤销等队列变化, 就研究更广的订单流不平衡. 订单簿不平衡则只比较某个时刻两侧尚存多少数量. 例如, 在最优档位总显示量为正时,

$$J_t = \frac{Q_{1,t}^b - Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a}.$$

前例初始买侧 400 股, 卖侧 300 股, 因而 $J_t = 100/700 = 1/7$. 它说明当前最优买侧较厚, 没有包含更深档位, 隐藏数量和未来撤单. 下一步是否涨价, 还要研究这些后续变化.

报价价差, 有效价差与实现价差 只看买卖报价距离, 还不知道实际成交是在价差内部, 最优档位, 还是更远的价格. 对第 i 笔成交, 用 a_i, b_i 表示匹配的成交前最优报价, 定义**报价价差**

$$QS_i = a_i - b_i.$$

它以每单位价格计量, 尚未考虑这笔交易实际付出了什么.

若成交价为 p_i , 时刻为 t_i , 成交前中间价为 $m_{t_i^-}$, 则**有效价差** (effective spread) 为

$$ES_i = 2\varepsilon_i(p_i - m_{t_i^-}).$$

买得高于中间价或卖得低于中间价时, 结果为正. 系数 2 把一次交易的价格让步换成全价差的等效尺度, 并不表示已经实际完成一买一卖. 前例最初按 100.02 买入, 若成交前中间价仍为 100.015, 有效价差就是 $2 \times 0.005 = 0.01$.

再固定观察时距 $h > 0$, 用后来中间价重新比较该笔成交, 定义**实现价差** (realized spread)

$$RS_i(h) = 2\varepsilon_i(p_i - m_{t_i+h}),$$

以及这段时间的有符号中间价变化

$$PI_i(h) = 2\varepsilon_i(m_{t_i+h} - m_{t_i^-}).$$

在成交价与原中间价之间加减同一个 m_{t_i+h} , 立即得到

$$ES_i = RS_i(h) + PI_i(h).$$

例如买方主动成交以后, 中间价继续上涨, 则 $PI_i(h)$ 为正, 相应实现价差低于有效价差. 对当时卖出的流动性提供者, 这表示后来以更高中间价衡量, 原先留下的价格空间已经缩小, 甚至变成负数.

这个恒等式没有证明价格变化由该笔订单独立造成. 它也没有算出做市商实际利润: 对冲成交, 费用, 返佣, 融资和其他库存都可能改变结果. 实现价差应连同观察时距和这些限制理解 [HS97].

7.8.4 流动性的多个维度

一笔交易是否容易完成, 要同时看价格, 数量与等待时间. **紧度**比较买卖价差有多窄, **深度**比较附近价位能承接多少. **即时性**则问能否马上成交, 或需要付出多大价格让步才能不再等待.

假设市场 A 价差为 0.01, 但最优档位只有 100 股; 市场 B 价差为 0.05, 附近却能承接 100,000 股. 在其他条件可比时, 50 股订单可能更喜欢 A. 50,000 股订单则必须查看 A 的更深档位, 不能仅凭它的最优价差更窄就作同一判断.

大单完成以后, 还可以观察盘口多久恢复. 新订单能多快补回深度, 价差是否很快收窄, 属于**韧性**. 不断增大订单规模时, 均价和总成本怎样改变, 则关系到**交易容量**. 一个能够低成本交易小额资金的办法, 未必可以原样放大.

成交活跃也不保证容易成交. 大量主动卖单扫过不断撤退的买盘时, 成交量可以很高, 但卖方需要接受越来越差的价格. 所以数量统计要与报价和执行结果一起看.

最优队列还可以形成一个带方向的价格估计. 本节采用的队列加权**微价格** (microprice) 为

$$\mu_t = \frac{a_t Q_{1,t}^b + b_t Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a},$$

假设两侧报价存在且总显示量为正. 代入前面的 J_t 可以写成

$$\mu_t = m_t + \frac{a_t - b_t}{2} J_t.$$

所以买侧队列较大时, 它向卖价偏移, 卖侧较大时则向买价偏移. 前例初始盘口给出 $\mu_t \approx 100.01571$, 稍高于 100.015 的中间价.

这项加权估计概括最优队列的不平衡, 并不说明一定能按 μ_t 成交. 它对后续价格是否有用, 要在相应市场和时间尺度下检验, 也不能据此给出公司的基本面价值.

7.8.5 买卖价差为什么存在

按买价买到以后, 未必马上有人愿意按原卖价接手. 等待期间, 价格和信息会改变, 持仓还会占用资金. 因而价差要与成交后承担的风险和成本一起解释, 不能直接当作已经到手的利润.

订单处理, 交易费用与最小报价单位会影响报什么价, 市场竞争会影响能保留多大价差. 另外两项重要原因是信息不对称和库存. 先看为什么即使忽略库存和处理费用, 信息差异也可能使买卖报价不同.

信息交易与流动性交易

定义 7.110 (信息交易与流动性交易).

订单利用了当前报价尚未充分反映的信息时, 称为**信息交易** (informed trading). 微观结构模型中, 由现金需求, 对冲, 指数调仓等其他需要产生的订单, 常称为**流动性交易**或**噪声交易**.

噪声在这里是相对于所研究的价值信息而言, 并不表示交易动机不合理. 基金为支付赎回卖出股票, 可能没有看坏公司, 只是需要现金. 同一次执行又可能利用短期信息选择时机, 所以两类动机在现实中也会混合.

逆向选择 挂单者先报出愿意买卖的价格, 对手方再决定是否接受. 若对手方更早知道好消息, 就更愿意按尚未更新的卖价买入; 若更早知道坏消息, 就更愿意按旧买价卖出. 挂单者的成交由对手方选择, 因而容易在对自己不利的时候取得交易, 这就是**逆向选择** (adverse selection).

在 Glosten-Milgrom 类型的一期简化模型中, 令 V 为可积的未来结算价值, 利率取零, 或将 V 预先折算到报价时点. 做市商报价前的信息为 $\mathcal{F}_t$, 每次交易一单位. 竞争性, 风险中性的做市商忽略库存和处理成本, 并要求在成交方向已知的条件下预期利润为零, 则

$$a_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = +1, \mathcal{F}_t], \quad b_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = -1, \mathcal{F}_t].$$

卖价需要与有人主动买入这一条件下的平均价值相匹配, 买价则与有人主动卖出时匹配. 若买入更可能意味着好消息, 两个条件期望就会不同, 形成正价差 [GM85].

期望按照模型规定的价值与订单联合分布计算. V 是模型中的未知终值, 不是从一张盘口直接观测到的公司真实价值. 这个模型解释信息差异如何产生价差, 实际价差中还会有其他成本和库存因素.

库存风险 客户连续卖出, 做市商就会逐渐买入更多库存; 客户连续买入, 则会消耗做市商库存, 甚至形成空头. 即使对价值的判断不变, 已经承担的风险不同, 愿意继续报价的条件也可能改变.

一种局部线性报价规则用 $\hat{v}_t$ 表示参考价格, H_t 表示净库存, 正数为多头, 令

$$c_t = \hat{v}_t - \kappa_t H_t, \quad \kappa_t > 0.$$

在其他条件不变时, 每多持有一单位, 报价中心降低 κ_t . 若拟报的全价差为 $s_t \geq 0$, 自身两侧报价可以设为

$$b_t = c_t - \frac{s_t}{2}, \quad a_t = c_t + \frac{s_t}{2}.$$

多头库存较大时, 买价降低使别人更少愿意卖给它, 卖价降低则争取更多买方接走库存. 空头较大时方向相反. 这给出了库存如何直接影响报价的一个可计算假设, 相关库存模型见 [HS81].

这里的报价是这一做市商提交的价格, 不保证它恰好成为整个市场最优报价. κ_t 与 s_t 也要依据模型和风险条件确定, 并非所有场所共同遵守的常数. 做市商还可以减少某一侧数量, 或到其他市场用相关资产对冲, 而不只移动报价中心.

最终利润要把这些成交和对冲一起计入. 一侧成交后迟迟不能退出, 或者退出以前出现跳价, 都可能使损失超过原先的报价价差. 提供即时成交所取得的可能收入, 正是与这些库存和信息风险同时存在.

7.8.6 订单流与价格冲击

550 股例子中的均价上升, 来自现有卖单被消耗. 真实市场还会根据订单修改报价. 其他人看到连续主动买入, 可能认为有新信息, 也可能认为只是暂时的交易需求. 不同解释会影响是否补回原价附近的数量.

Kyle lambda Kyle 模型把知情者的订单选择与做市商从总订单中学习放在一起 [Kyl85]. 先看其中一次拍卖. 令 V 为未来价值, 采用零利率或已贴现的价值单位; 知情交易者提交带符号订单 X , 其他交易者的订单为 U . 做市商只看到

$$Y = X + U,$$

无法直接分辨其中多少来自信息. 在竞争性, 风险中性且无其他成本的模型中, 它按条件平均价值报价:

$$p = \mathbb{E}[V | Y].$$

在标准 Gauss 线性设定中, 取已中心化的 Y , 即 $\mathbb{E}[Y] = 0$, 并有 $\text{Var}(Y) > 0$. 若 V, Y 联合 Gauss, 条件期望具有线性形式

$$p = p_0 + \lambda Y, \quad p_0 = \mathbb{E}[V], \quad \lambda = \frac{\text{Cov}(V, Y)}{\text{Var}(Y)}.$$

在完整 Kyle 均衡中, X 本身还由知情者面对这条价格规则的选择决定, 因而 λ 需要与其订单策略一起求解, 并非任意指定的冲击常数.

定义 7.111 (Kyle lambda).

上述线性均衡中的价格斜率 λ 称为 **Kyle lambda**. 在固定模型和数量单位下, 净订单流多一单位, 报价改变 λ 单位价格. 当 $\lambda > 0$ 时, $1/\lambda$ 可用作这种模型中的深度尺度.

较大的 λ 表示同样订单量对应更大价格变化. 它与买卖价差不同: 前者是数量增加时价格怎样动, 后者是同一时刻买卖报价相隔多远. 实际数据中的斜率还会随资产, 时间间隔和交易条件改变, 不能脱离单位比较大小.

成交不平衡与经验价格冲击 在给定长度的时间窗口内, 可以用回归比较有符号成交量与中间价变化:

$$\Delta m_{t,t+\Delta} = \alpha_{\Delta} + \beta_{\Delta} Q_{t,t+\Delta}^{\text{trade}} + \eta_{t,\Delta}.$$

β_{Δ} 是这组数据与窗口下的拟合斜率. 即使写法与 Kyle 的线性定价相似, 它也没有单独验证知情者策略, 信息分布和均衡条件, 不能直接当成同一个结构参数.

成交量还漏掉未成交的队列变化. 买盘大量撤走, 即使尚未出现很大卖出成交, 下一笔卖单也可能面对更差价格. **订单流不平衡** (order flow imbalance, OFI) 因而还可以纳入最优报价变化, 限价单加入和撤销. 关于这种更广的短时订单簿度量, 见 [CKS14].

解释拟合关系时, 需要检查先后顺序. 消息可能同时引起买单和卖方撤单, 交易者也可能先预期涨价才下单. 若想回答主动增加某笔订单会使价格改变多少, 就要用额外的研究设计或明确结构假设分开这些原因. 同期回归首先描述共同变化, 不会仅凭一个斜率完成因果判断.

暂时冲击与永久冲击 前例的卖盘被扫空后, 若新卖单很快回到原价附近, 价差和中间价就可能部分恢复. 这种随后消退的价格影响称为**暂时冲击**. 若订单使市场持续提高对资产价值的判断, 补回的盘口可能出现在更高价格, 则包含较持久的信息影响, 通常称为**永久冲击**.

一种观察方法是固定成交后的时距 h , 在相应一阶矩存在时计算

$$R(h) = \mathbb{E}[\varepsilon_i(m_{t_i+h} - m_{t_i}^-)].$$

买入后上涨或卖出后下跌都记为正, 因而 $R(h)$ 汇总沿主动方向的平均价格响应. 若响应先大后小, 可以在给定模型中研究消退部分; 若较长窗口后仍保留, 则需要解释其持续来源.

等待期间却还有新消息, 新订单和同一母订单的后续子单. 所以某个 h 下仍未回落, 不等于已经证明单笔交易造成了永远不消失的影响. 暂时与永久的分解应连同模型和观察窗口报告, 不能只把较晚时点的响应全部命名为该笔交易的信息作用.

7.8.7 时间尺度与点过程

日线只留下开盘, 高低, 收盘和成交量, 不能重建一天中订单怎样先后到达. 订单簿的更新发生在不规则时刻, 活跃时很密集, 安静时则等待较久.

定义 7.112 (日历时间, 事件时间与成交时间).

日历时间 (calendar time) 用秒或毫秒等物理单位计时. **事件时间** (event time) 按预先选定的提交, 撤销, 修改, 成交或报价事件依次编号. **成交时间** (transaction time) 只按实际成交

的次序推进.

令 τ_n 为第 n 个所选事件的实际到达时刻, 在有限区间事件数有限的模型中,

$$N(t) = \sum_{n \geq 1} \mathbf{1}_{\{\tau_n \leq t\}}$$

统计截至 t 发生多少次, 相邻等待时间为

$$W_n = \tau_n - \tau_{n-1}.$$

每次事件后的平均变化与每秒平均变化不同, 因为每秒包含的事件数也会变. 使用数据时先确定时钟, 才能比较速率和响应.

对第 i 类事件分别建立计数 $N_i(t)$, 可以区分主动买卖, 挂单与撤单. 严格地说, 非负可预测过程 $\lambda_i(t)$ 若局部可积, 且

$$N_i(t) - \int_0^t \lambda_i(s) ds$$

为局部鞅, 就给出了相应的条件强度. 它用已有信息预测累计到达量, 实际数量减去预测量后留下补偿的随机变化.

在简单点过程, 无固定时刻跳跃并有适当小时间正则性的情况下, 可以将这种强度直观读成

$$\mathbb{P}(N_i(t + \Delta t) - N_i(t) = 1 \mid \mathcal{F}_{t-}) = \lambda_i(t)\Delta t + o(\Delta t).$$

这是局部概率展开, 不能对任意带有成批到达或定时跳跃的计数记录直接套用.

常数强度 Poisson 过程提供最简单的基准. 若数据显示开收盘季节性, 事件聚集或不同类型相互影响, 可以让强度随此前事件及当时可见的队列变化, 或采用 Hawkes 过程等模型 [BMM15; CST10].

例如, 一笔主动卖出后可能继续出现卖单, 也可能伴随买侧撤单和新买盘补入. 这些共同变化可以来自新闻, 拆单或其他尚未观察的原因. 拟合出自激或交叉激发, 首先说明到达的统计依赖, 具体经济解释仍需与其他证据对照.

数据的可见范围 要研究什么, 决定需要哪些记录. 成交与最优报价数据能比较执行价和价差, 多档快照还能观察深度, 逐消息数据则进一步显示订单加入, 修改和撤销. 自己的经纪商记录还可以区分发送, 接受, 成交回报等时点.

这些时间并不必然相同. 市场中已经发生的成交, 可能过一会儿才到研究者系统; 多条更新还可能乱序到达. 一张 550 股订单也可能像前例那样生成多笔成交, 不能仅凭三条成交记录断言来了三个独立交易者. 粗时间戳下, 多条消息看似同时发生, 实际顺序仍可能影响排队和可见信息.

单一场所还只覆盖部分交易. 合并多处行情有助于比较, 但合并后的记录同样需要处理延迟, 同步和未展示的数量.

注 7.113 (多个场所与非公开交易).

不同场所可以在费用, 速度和服务上竞争, 同时也分散了订单. 暗池等安排可能减少大额交易前的公开展示, 但未必保证成交, 研究者也看不到与公开簿相同的全部报价信息. 因而最佳显示价格与最佳实际执行结果应分别评估, 不能只凭一个场所的盘口概括全市场.

流动性枯竭与交易中断 挂单者也会更新风险判断. 新消息到达, 波动扩大或库存接近限额时, 它可以缩小数量, 拉开报价或撤单. 这使后续相同规模的主动订单需要扫过更多档位, 价格变化又可能促使更多挂单者减少风险.

因此, 原来适合小订单的盘口, 可以在短时间内变得难以承接稍大交易. 深度变化并非只发生在价格变化之后, 撤单本身也会改变下一笔订单面对的价格条件.

极短时间内的大幅异常下跌及可能随后出现的快速部分恢复, 通常称为**闪崩** (flash crash). 大额执行, 单边订单, 流动性撤退, 跨市场联系和算法风控之间的相互作用, 都可能参与其中, 见 [Kir+17]. 不能仅因为行情发生得快, 就把全部原因归给某一种订单或参与者.

交易暂停, 临时集合竞价和价格限制可以按规则中断或改变连续撮合, 给参与者重新报价的时间. 但未满足的买卖需求可能仍然存在. 重新开市以后以什么价格成交, 要由那时的订单和信息决定, 暂停本身不承诺恢复到原价.

7.8.8 从订单簿走向交易执行

同样的限价, 排在前面与后面具有不同的成交机会. 先研究一个所有数量可见, 同价先进先出的理想队列. 设本单在 t_0 被接受, 价格为 p , 数量为 $q > 0$, 前方已有数量 $A_{t_0}(p)$. 本单此后不撤销, 不改价, 后来的同价订单都排在它后面.

令 $D_t(p)$ 累计从 t_0 开始在这一价位发生的主动成交数量, 加上最初排在本单前方而后来撤销的数量. 后方订单的撤销不计入, 因为它没有让本单前进. 在这些假设下, 本单截至 t 的成交数量为

$$F_t^{\text{fill}} = \min \left\{ q, (D_t(p) - A_{t_0}(p))^+ \right\}.$$

只有前方数量被移除以后, 新的主动成交才会轮到本单. 因而在离散成交事件下,

$$\tau_{\text{first}} = \inf \{ t \geq t_0 : D_t(p) > A_{t_0}(p) \},$$

$$\tau_{\text{full}} = \inf \{ t \geq t_0 : D_t(p) \geq A_{t_0}(p) + q \},$$

并约定空集合的下确界为 ∞ . 恰好移除全部前方订单, 只表示轮到本单站在最前, 尚不等于本单已经成交, 所以首次成交使用严格不等号.

例如, 另作一个教学假设: 在价格 100.02 提交 100 股卖单, 前方有 300 股. 前方撤销 100 股后, $D = 100$, 本单仍未成交. 随后该价位被主动买入 250 股, 前方剩余 200 股先成交, 本单成交 50 股, 此时 $D = 350$. 再成交 50 股, $D = 400$, 本单全部完成. 若 100 股撤单原本在本单后面, 就不能计入这项推进量.

实际快照通常不知道撤单属于哪个排队位置, 隐藏和冰山数量也可能改变顺序. 因而以上公式给出的是明确队列假设下的成交计算, 现实排队位置还须由逐消息记录或估计取得.

成交快也不必更有利. 一张买入限价单可能正因为卖压突然增加而迅速成交, 随后价格继续下跌. 等候限价省下部分立即跨价差的成本, 同时承担未成交和逆向选择; 市场化成交则用价格让步减少等待. 选择取决于交易有多急, 价格风险有多大, 以及还剩多少数量.

大额母订单还可以分批执行. 若总数量 $Q > 0$ 分为同方向的子单, 全部完成时

$$\sum_{k=1}^n q_k = Q, \quad \bar{P}^{\text{exec}} = \frac{1}{Q} \sum_{k=1}^n q_k P_k^{\text{exec}}.$$

分批可以等待新流动性, 少扫一些远档, 但等待期间价格可能朝不利方向变化, 连续子单也可能让别人察觉交易需求.

用决策时的基准 P^{decision} 比较实际全部成交, 实施差额可以写为 [Per88]

$$\text{IS} = \varepsilon Q \left(\bar{P}^{\text{exec}} - P^{\text{decision}} \right) + \text{费用},$$

其中买入取 $\varepsilon = 1$, 卖出取 -1 , 正数表示相对于基准付出了成本. 前面的 550 股买单若以原中间价 100.015 为决策基准, 且没有费用, 实施差额就是 5.75. 这已经包含从该基准到实际均价的全部价差, 不再另扣同一笔点差或扫单滑点.

若订单未完成, 还应报告剩余数量, 并按明确的评价时点研究未成交的机会成本. 只展示已经成交的一小部分均价, 可能把难以完成的部分从结果中删掉.

实施差额也不是订单自身因果冲击的纯估计. 等待期间的最新消息, 市场整体变化和他人交易都会进入实际价格. 如何在快速成交的价格让步, 等待的价格风险与未完成之间选择, 是交易执行模型研究的问题 [AC01].

7.8.9 通往订单流和市场冲击模型

现在可以用具体事件解释订单簿怎样变化. 新限价单增加某档数量, 撤单移除尚未成交的余量, 主动订单按撮合规则消耗对侧队列. 某个最优档位耗尽后, 后一档成为新的最优价; 新报价进入价差内部, 则可能使价差收窄. 前面的 550 股例子已经逐步计算了其中一种变化.

要把这一过程建成随机模型,除了给出撮合规则,还要说明各种事件何时到达,数量怎样分布,参与者是否会根据新信息和库存调整行动.点过程描述到达,带标记数据保留方向和数量,队列规则决定每笔订单实际成交多少.只有把这些假设写清楚,才能进一步计算成交概率或价格响应.

当前盘口是否足以预测下一步,也属于模型问题.若到达率还依赖此前连续订单,隐藏库存或其他场所,单看当前几档深度就可能遗漏相关历史.不能仅因按事件更新了记录,就认定所得过程已经具有 Markov 性或已经解释价格变化的原因.

交易执行又把行动放回其中.更积极的订单可能更快完成,同时改变现有深度;选择等待可以减少立即成交的让步,却保留未完成数量的价格风险.因而后续的控制问题需要同时跟踪实际成交,剩余数量和现金成本.

用单一价格 S_t 研究基本定价时,可以暂时省略这些细节.当问题变成能买卖多少,会等多久以及最后支付多少,就需要回到报价和订单记录.市场微观结构所提供的,正是把这些可观察交易接到价格与成本计算上的办法.

第八章 基本面分析

第七章说明了资产赋予什么权利，市场怎样交易，融资和结算怎样影响现金。对一只具体股票，还需要继续研究公司怎样赚钱，未来可能赚多少，以及其中有多少最终归属于每一股。这些问题构成**基本面分析**的主要内容。

公司总利润增长，并不保证每股利益按同样速度增长。债务，优先请求权，费用，稀释和实际分配安排，都可能改变股东所得。同样，公司经营良好，也不等于任何买入价格都值得。投资者还要比较今天付出的价格与未来可能取得的分配和出售所得。

本章先讨论估值应该怎样依据证据展开。合同和经营资料可以支持哪些假设，哪些关键因素仍然不确定，会决定适用的方法与结论范围。不同合理假设得出相近结果时，可以给出中心估计；差异仍然很大时，就应保留区间或条件情景。尚未得到独立依据的价值，不能仅靠调整参数凑成一个目标价。

随后，第8.2节以晨星的经营预测方法为起点，把 DCF，可比公司与分部估值算到每股，再解释银行和地产为什么需要不同输入。各方法的短例子先给出能够复算的价值，Risk-Reward 再讨论经营判断变化以后会得到怎样的投资结果。

经营研究往往比代入公式更难。“竞争恶化”可能表现为降价，客户流失或获客成本增加，也可能尚未在经营中出现。研究者要找到具体证据，判断它首先改变哪项业务假设，再计算收入，成本和利润的变化。盈利下修以后是否还应降低估值倍数，则要另外说明理由，避免为同一影响重复扣减。

Risk-Reward 框架把这些判断放进 Bull, Base 和 Bear 等情景，比较不同条件下的结果。若进一步给出概率，就可以计算加权回报。这与第3.1节和第3.2节中用随机变量及分布描述可能结果的思想相同，但情景和概率本身仍须来自研究，不能由几项形式定义自动确定。

最后介绍本笔记采用的 Agentic R-D-G (Agentic R/D Graph)。它把证据，假设与预测之间的联系保留下来。新财报或其他消息出现时，研究者能够找到被加强或推翻的判断，保留仍有依据的部分，再重新计算情景结果。

因此，本章既关心估计出的数值，也关心这个数为什么成立，在什么条件下需要修改。组合如何使用这些结果，还要结合当前价格，已有持仓和能承担的风险继续判断。

8.1 从资产头寸到可识别价值

第7.1节已经区分了持有权利，市场价格与投资回报。基本面分析接着问：持有人今后能够取得哪些利益，为此需要承担什么成本，据此今天愿意付多少钱？

估值公式可以完成计算，但不会替我们确认股份类别，现金流归属或未来经营假设。所以开始估值时，先说明估的是哪一项权利，哪一个单位和哪一段期限，再判断现有证据能够把答案缩小到什么范围。有时可以给出有用的中心估计，有时只能给区间或条件情景。

工作框架的定位 本节讨论估值研究怎样展开，不另造一套替代现有理论的定价公式。贴现现金流法 (discounted cash flow, DCF)，无套利定价，一般均衡和可比估值，各自有适用条件。选择以前，先看我们掌握了什么证据，以及这些证据能支持方法中的哪些假设。

还要分清估值落在企业还是普通股层面。每股收益 (earnings per share, EPS) 记录归属于每股普通股的盈利。企业价值 (enterprise value, EV) 则面向企业经营资产和全部资本提供者，不能直接当成普通股股东拥有的价值。

市盈率 (price-to-earnings, P/E)，市净率 (price-to-book, P/B) 和市价/有形账面价值比率 (price-to-tangible-book, P/TBV)，都在股权或每股层面比较。EV/EBIT 将企业价值与息税前利润比较，EV/EBITDA 则使用息税折旧摊销前利润，两者都先从企业层面出发。

DCF 根据未来现金流及贴现率计算价值。分部加总估值 (sum-of-the-parts, SOTP) 则分别估计各项业务或资产，再汇总。这两种方法都可能用于企业层面或股权层面，取决于采用的现金流和分部价值属于谁。若先算企业价值，就须正确处理净债务和其他非普通股请求权，才能得到普通股价值；若已经算的是股权价值，也不能再扣一次相同的债务。

第7.1.2小节中的区别在这里继续有效。持有权利决定能够取得什么，模型据此估计价值，当前市场决定买卖成本，实际持有与退出才产生回报。估值有吸引力以后，仍需说明在研究期限内怎样取得分配或完成退出，才能进一步讨论投资机会。

价值必须带着条件说 同一项资产对不同持有者未必同样有用。财富，信息，其他机会，融资，税务和实际使用能力不同，都可能改变一个人愿意接受的最高买价或最低卖价，即他的保留价。这与在统一假设下给出的模型估值，应当分别说明。

研究中所说的 Fundamental Value，通常也是根据某种模型和一组假设算出的价值。增长，利润率，违约，贴现率等判断改变，结果就会改变。要比较两个估值，应先核对它们使用的资料时点，持有数量，计价资产和预测期限，再看经营与风险假设的差异。

期末怎样处理尤其重要。假定届时出售，就需要估计退出所得；假定继续经营，就需要说明终端价值覆盖了哪些后续利益；合同到期支付和清算回收又有各自的计算。若出售价格已经反映后续经营利益，就不能既计入出售所得，又把相同的后续现金流完整加一次。私人使用服务与现金终值并列时也要作同样检查。

因此，“这项资产值 100”应当能展开成一个有条件的判断：对指定的持有者和持仓，使用当前资料，按给定的经营，风险，期限和期末处理假设，模型估计为 100 单位计价资产。把这些条件写在估值旁边，分歧就能落到具体问题上，无须再把每项条件编码成一个下标。

估值首先是识别问题 把参数填进公式，通常就能得到一个数。更难的问题是，现有证据为什么支持这些参数，而不支持另一组会得出不同价值的参数。这里把这一问题称为估值的识别：证据究竟排除了多少种可能的答案？

如果有依据的不同假设都得到相近结果，可以给出中心估计或窄区间，并说明敏感性。如果多组合理假设对应的价值差别仍大，就应把区间或条件情景列出来。若只能排除一部分可能结果，也可以报告已经能够确定的范围，即部分识别。关键参数缺少依据时，计算更多小数位并不会增加认识。

证据还必须避免循环。市场价格可以作为研究材料，也可以用于反向估值。但若先把模型无法解释的价格差全部命名为某种服务价值，再将这个服务价值加回去证明原价格合理，就只是在重复起点。还需要不依赖这笔价格差的资料，支持服务确实存在以及大致值多少。

模型本身也可能存在分歧。持续经营与清算等不同假设都仍有理由时，应分别报告各自结果和适用条件。可以汇总它们覆盖的范围，但不能只给一个平均数，把决定差异的假设藏起来。

证据支持哪一种结论 研究结果应当与证据能够说明的事情相称。可以给出价格区间，也可以只说明某项价格要求哪些经营条件；不必把所有研究都收束成一个目标价。

现有证据能够说明什么	相应的研究结论
合理假设得到的价值较接近 能确定范围，但不同假设仍有较大差异	中心估计或窄区间，并报告主要敏感性 宽区间，部分识别或分别列示的条件情景
只能确定某类持有人的利益	私人保留价，使用价值或相应替代成本
能反推当前价格要求的条件	隐含增长，利润率，采用率或所需回报率
只能可靠研究交易与价格变化	价格动态研究，暂不作独立价值估计

没有得到估值时，还应说明原因。资料尚未收齐，是还缺权利，现金流，期限或其他必要输入；方法尚未使用，是研究还没有做完；已经整理合理输入并尝试适用方法，仍无法靠独立证据缩小价值范围，才是当前资料和方法下无法识别价值。这三种情况不能用同一句“无法估值”混过去。

同样，不知道某项风险怎样量化时，随意扩大价格区间或填入概率，只是把未知改写成了数字。应说明已经知道的方向和仍然缺少的依据。

有时供给，资金流，交易者行为和价格记录足以支持市场动态研究，却不足以独立估计价值。这仍然可以是有用结论。它本身既没有证明资产是泡沫，也没有证明某种交易值得做。

根据独立证据选择估值方法 资产类别可以提示我们去哪里找资料，但不能单凭标签选择公式。更有用的起点是：哪一部分利益能够获得最可靠的独立支持？合同规定的支付，可复制的现金流，企业可归属的盈利，或可观察的租金，会使不同方法更有用。

主要证据	可以采用的方法	还要查清的问题
合同支付, 到期, 偿付顺位和回收	现金流估计, 违约分析和状态树	谁负有付款义务, 违约时持有人能够取得多少
可以复制或转换的条件支付	无套利, 复制和考虑摩擦的价格区间	交付, 融资, 卖空与结算条件是否支持实际复制
能预测且能归属于持有人的经营剩余	DCF, 正常化盈利和每股价值估计	债务, 稀释, 治理及终端假设怎样影响股东所得
可观察租金, 替代品或重置方式	租金资本化, 替代成本和重置成本	用途, 独特性及转换条件是否真正可比
可以执行的延迟, 转换或退出权利	期权方法, 决策树和动态规划	选择权是否真实存在, 相关过程能否合理估计
网络, 协调或私人服务的独立资料	便利收益, 采用情景或私人保留价	服务利益能否独立说明, 是否只是在填补价格差
当前价格比其他估值输入更可靠	反向估值和压力测试	哪些假设能解释价格, 哪些仍需经营证据验证

表中的方法都需要证据支持其关键输入。例如, 有合同不等于支付必然兑现, 有替代品也不等于能够无成本替换。研究应继续追问决定实际所得的条件。当主要证据改变时, 最有用的方法也可以改变, 无须让同一套公式解释所有资产。

多方法的分工 多种方法可以互相检查, 但未必在估计同一个量。可以用证据最充分的方法形成主要估值, 再用清算回收, 复制或替代成本检查结果是否过于宽松。反向估值则换一个问题, 说明当前价格要求哪些条件成立。最后还要核对持有人能否实际行使权利或完成退出。

例如, DCF 给出 120, 可比估值给出 140, 反向估值显示现价要求长期增长 g 。把前两个数平均成 130, 并没有解释它们为何不同, 更没有利用第三项研究。应先检查 DCF 怎样把经营成果分配到每股, 终端假设是否可靠; 再看可比公司的权利, 成长和资本结构是否相近; 最后判断隐含增长 g 是否有独立经营证据支持。

有时第二种方法会支持主要估值, 有时会暴露一项遗漏或不合理假设。这种分工比单纯增加目标价数量更有用。

同一利益或成本也只能完整计入一次。治理改善若已经提高了预测现金流, 就不能再把相同利益作为一笔治理溢价加回。流动性成本若已从净退出所得扣除, 也不应再通过贴现率和额外折价为同一成本重复扣减。使用多个位置处理不同影响时, 应说明它们各自计算什么。

什么时候应该停止 停止可以发生在不同位置。若还不清楚持有哪一类权利, 适用哪些规则, 由谁执行或终止, 就应先查这些问题, 不急于给出货币估值。若企业或网络创造的利益还无法归到所研究的单位, 也不能用总利润, 总规模替代这一单位能够取得的利益。

估值已经能够形成结论, 交易研究仍可能缺少条件。买还是卖, 数量多少, 在哪个市场, 持有多久, 用什么结算, 会影响实际结果。买入成本, 费用和退出方式尚未确定时, 可以报告价值判断, 但不宜直接计算投资者的预期回报。估值差异若没有可执行的分配, 使用, 转换或退出办法, 也还不足以成为可兑现的投资机会。

停止时应说明究竟是缺资料, 尚未计算, 还是现有证据确实不能支持更窄的答案。同时检查已算入的利益和风险, 避免为填满表格而重复计价。

还有一种停止是研究已经足够回答当前问题。若新增资料不再改变持有权利, 主要方法, 关键情景或可支持的估值范围, 就应给出结论与剩余不确定性。没有必要为覆盖所有反例无限增加情景, 也不必把暂时无法回答的部分包装成精确数字。

普通股为什么是一个有用的特例 许多公开交易的普通股提供了较清楚的研究起点。股份类别和股东权利可以核对, 收入, 成本与资产负债表提供经营证据。再处理债务, 优先权, 稀释和回购等因素, 就能研究企业创造的利益最终有多少归属于每一股普通股。

当这种归属可以说明, 未来经营又有足够依据时, DCF, 正常化盈利或资产价值可以形成主要估值. 清算, 替代和可比关系用来检查结果, 当前股价则用来反推市场价格要求的成长, 利润率或回报条件.

经营前景不同, 每股盈利和现金流也会不同. 因而普通股研究应在各个合理情景下重新计算, 说明哪些因素改变了价值. 若还要把估值写成某个未来时刻的股价, 就须进一步判断届时的市场可能怎样定价, 以及持有人怎样退出. 模型估计的价值与未来成交价格, 并没有天然相等的关系.

先把几种常用方法算到每股, 再把不同经营假设放进 Risk-Reward 情景. 这样既能看清每个价格从哪里来, 也能在假设改变时重新计算.

8.2 常用估值方法: 从经营预测到每股价值

估值方法的区别, 首先在于从哪一种利益开始计算. 经营现金流先得到经营资产的价值, 普通股盈利直接从股东所得出发, 物业租金则先支持物业价格. 无论从哪里开始, 最后都要确认还有谁享有优先请求权, 剩余价值分到多少股.

以下各公司的数字均为相互独立的教学假设. 除特别说明, 总金额以百万美元计, 股数以百万股计, 算出的每股金额以美元计. 利率, 增长率和倍数都是为演算给定的输入, 不是适用于其他公司的默认参数.

8.2.1 晨星的 DCF: 竞争优势能够维持多久

晨星 (Morningstar) 的公开方法把企业经营分成三个阶段. 第一阶段逐年预测财务结果, 通常为五年或十年. 第二阶段研究竞争怎样使新增资本回报逐步接近资本成本. 第三阶段假设企业继续经营, 但新增投资不再创造超出资本成本的经济利润 [Mor26].

这里的新增资本回报称为 RNIC (return on new invested capital). 它衡量追加经营资本能够带来多少新增税后经营利润, 与全部历史资本的平均 ROIC 不同. 过渡也不必总是向下: 原先新增回报不足资本成本的业务, 在相应预测中也可能向上接近资本成本 [Mor24b].

例如, 追加资本 100, 预计下一完整年度增加税后经营利润 15, 对应新增资本回报 15%. 若相应资本成本为 10%, 这笔新增资本一年创造的超额经营利润为 $15 - 100 \times 10\% = 5$. 竞争使相同投入只能增加利润 10 时, 新投资仍然赚钱, 却刚好只补偿了资本的机会成本. 原有资产怎样盈利, 还应按其自身经营情况预测, 不会因此突然全部变成 10% 的回报.

护城河分析因此影响的是哪些收入和利润能够保住, 后来的再投资还能赚多少, 以及这种优势持续多久. 客户难以转换供应商, 就可能使定价和留存更稳定. 这些判断已经进入利润率和资本回报路径以后, 不再另加一笔没有对应现金流的护城河溢价.

晨星还区分公允价值估计与对该估计的把握. 不确定性反映可能价值结果的分散程度, 影响所要求的安全边际; 股票星级结合市价相对公允价值的位置与不确定性, 并非未来收益保证 [Mor24b]. 因而读一份估值时, 既要看的中心值, 也要看哪些经营判断使结果可能偏离它.

8.2.2 从经营现金流折现到每股价值

对收入, 成本和再投资可以逐年预测的非金融企业, DCF 能够把经营判断直接算成价值. 从税后经营利润开始, 加回已经扣除但不直接耗用当期现金的折旧摊销, 再减去资本开支和经营营运资本增加, 得到企业自由现金流 FCFF:

$$FCFF_t = EBIT_t(1 - \tau) + D\&A_t - Capex_t - \Delta NWC_t.$$

这里 τ 是采用的经营税率. 应收或存货增加会占用资金, 应付增加则可以减少经营营运资本的净投入. 资本开支既包括维持现有业务, 也包括实现预测增长所需的投入, 不能一面计入增长, 一面省去支持增长的资金 [Dam12].

FCFF 尚未扣除付给债权人的利息, 因而先属于全部资本提供者. 它应配合加权平均资本成本 WACC, 而非直接使用股权资本成本. WACC 按相应市场价值资本权重组合融资成本, 并与模型采用的税收和资本结构假设保持一致 [Mor24b].

下面只保留三年显式现金流和一个稳定段, 用来展示计算, 不完整复刻晨星的三阶段预测. 假设第一年收入为 1000, EBIT 利润率 20%, 经营税率 25%, 折旧摊销 30, 资本开支 60, 经营营运资本增加 20, 则

$$FCFF_1 = 1000 \times 20\% \times (1 - 25\%) + 30 - 60 - 20 = 100.$$

再假设相应经营与再投资预测给出第二年 FCFF 为 110, 第三年为 121, 全部在年末取得.

本例长期目标资本结构取股权 80%, 债务 20%, 股权资本成本 11%, 税前债务成本 8%, 并假定能够按 25% 税率取得相应利息税盾. 因而

$$k = WACC = 0.8 \times 11\% + 0.2 \times 8\% \times (1 - 25\%) = 10\%.$$

真实研究需要解释这些成本和权重来自什么证据. 本例给定它们, 是为了让后面的现值能够直接复算.

进一步假设第三年以后已经适合稳定经营, 扣除所需再投资后的 FCFF 每年增长 $g = 2\%$. 第四年现金流为 $121 \times 1.02 = 123.42$. 在 $g < k$ 下, 第三年末对第四年及以后现金流的估值为

$$TV_3 = \sum_{j=1}^{\infty} \frac{121(1+g)^j}{(1+k)^j} = \frac{121(1+g)}{k-g} = \frac{123.42}{0.10-0.02} = 1542.75.$$

终值使用的是下一期现金流, 因为第三年的 121 还属于显式预测. 终值又是第三年末的金额, 所以与第三年现金流一起贴现回今天:

$$\begin{aligned} EV_0 &= \sum_{t=1}^3 \frac{FCFF_t}{(1+k)^t} + \frac{TV_3}{(1+k)^3} \\ &= \frac{100}{1.10} + \frac{110}{1.10^2} + \frac{121 + 1542.75}{1.10^3} \\ &\approx 1431.82. \end{aligned}$$

这里的 EV 是经营企业价值. 终值只从第三年末向今天贴现一次, 没有再次把已经贴现的结果当成第三年金额. 它的现值约为 1159.09, 占经营价值八成以上, 所以稳定段何时开始和怎样再投资, 对本例尤为重要. 真实公司不能仅因预测表到第三年结束, 就被假定从此降到稳定增长.

假设经营之外还有可分配现金 80, 全部有息债务的当前价值为 300, 没有优先股, 少数股东权益或其他待扣请求权, 稀释调整后的股数为 20. 普通股总价值和每股价值分别为

$$V_0^{\text{eq}} = EV_0 + 80 - 300 \approx 1211.82, \quad v_0 = \frac{V_0^{\text{eq}}}{20} \approx 60.59.$$

日常经营必需的资金不能一面支持 FCFF 预测, 一面又全部作为多余现金加给股东. 加回的是尚未包含在经营价值中的非经营资产, 债务和其他优先请求权也按各自归属处理.

FCFF 没有先扣利息, 所以这里通过融资成本和企业到股权的换算处理债务. 若改为直接预测已经扣除利息并计入净借款 (新增借款减去偿还本金) 的普通股现金流 FCFE, 就应使用股权资本成本 k_e , 得到普通股价值后不再扣同一笔债务. 持续股权激励和稀释也须采用一致处理, 不能只因现金流表加回一项非现金费用, 就把相应股东成本忽略.

8.2.3 可比公司法: 每一倍在乘什么

可比估值借助其他公司的市场价格, 研究投资者目前愿意为每单位盈利或经营成果支付多少. 它适合有可比较业务和正常化盈利的公司. CFA Institute 区分按市场可比公司选择倍数, 与从增长, 风险和回报假设推导合理倍数这两种做法 [CFAb]. 行业中位数可以是调查起点, 但还不是对目标公司的定价理由.

先看 P/E. 它把普通股价格与归属于普通股的每股盈利比较, 因而要使用扣除利息及相应税费后的盈利. 如果采用今天股价除以下一年预测 EPS 的前瞻 P/E, 可比公司和目标公司都应使用同一预测期限. 把过去十二个月的倍数乘下一年度盈利, 会同时改变比较基础和估值.

另设一家公司, 下一年度正常化普通股净利润为 120, 稀释股数为 20, 因而 EPS 为 6. 暂取前瞻 P/E 为 18 倍进行当前估值, 则

$$v_0^{P/E} = \frac{120}{20} \times 18 = 108.$$

18 倍是本例的假设. 要在真实研究中采用它, 应解释可比公司的增长, 盈利风险和资本回报为什么接近, 再处理剩余差异. 一次性资产出售不能当成每年都有的盈利, 周期高峰利润也应先判断能维持多久. 盈利仍为负或主要来自不稳定项目时, P/E 通常不能提供同样清楚的比较.

EV/EBITDA 则先在企业层面计算, 不把企业倍数乘在普通股净利润上. 假设同一公司的下一年度 EBITDA 为 200, 采用 10 倍, 额外现金 80, 有息债务 400, 没有其他请求权, 则

$$EV_0 = 200 \times 10 = 2000, \quad v_0^{EV/EBITDA} = \frac{2000 + 80 - 400}{20} = 84.$$

EBITDA 没有扣折旧摊销, 也没有扣资本开支, 税和营运资本投入. 两家公司即使 EBITDA 相同, 一家需要不断更新设备, 另一家新增收入几乎不占用资产, 留给资本提供者的现金也可能不同. 比较倍数时还应对齐租赁, 利润正常化和债务的处理, 而不把加回折旧直接理解为无需再投资.

本例的 108 与 84 为什么不同, 可以反算检查. 每股 108 对应普通股价值 2160, 加债务 400 并减额外现金 80, 得企业价值 2480, 相对于 EBITDA 200 是 12.4 倍. 因而 18 倍 P/E 与 10 倍 EV/EBITDA 从一开始就没有表达相同估值水平. 要决定采用哪种判断, 应回到利润转成现金的能力和可比证据, 把两个价格平均成 96 并没有解决分歧.

8.2.4 分部估值: 各项业务分别算, 共同负担只扣一次

不同业务的增长, 风险和资本需要差异很大时, 一个全公司倍数可能掩盖主要差别. 分部加总估值 (SOTP) 先分别估值, 再把总部成本, 集团融资和其他资产归并. 每个分部可以使用适合其经营的办法, 但相加以前要确认得到的是经营企业价值还是股权价值.

一个公开实例是 Morgan Stanley 在 2024 年 5 月 16 日的 Project Lean 交易顾问材料. 其中同时采用整体无杠杆 DCF, 分部估值和 P/E 可比分析; Networks 以无杠杆现金流和 WACC 估值, Renewables 则使用股权现金流与股权资本成本, 汇总时处理口径转换. 材料明确说明并非证券研究报告 [Mor24a]. 这是具体项目选择不同方法的例子, 不表示所有机构对每家公司都采用同一模型.

考虑另一家有两项业务的公司. 业务 A 的预测 EBITDA 为 80, 采用 10 倍; 业务 B 的预测 EBIT 为 40, 采用 15 倍. 假设两项都是按同一估值时点计算的全部经营企业价值:

$$EV_A = 80 \times 10 = 800, \quad EV_B = 40 \times 15 = 600.$$

两项盈利均未分摊总部费用. 再假设总部每年需要 12 的税后经营现金支出, 长期不增长, 按 10% 贴现, 其现值为 $12/0.10 = 120$. 集团另有未包含在分部估值中的现金 100, 全部有息债务 400, 已估计的少数股东权益价值 80, 稀释股数 30, 无其他调整, 则

$$V_0^{\text{eq}} = 800 + 600 - 120 + 100 - 400 - 80 = 900, \\ v_0 = 900/30 = 30.$$

分部按 100% 的业务估值, 所以还要扣除属于少数股东的部分. 总部费用若已经进入分部盈利, 就不再资本化扣一次. 债务 400 已经包含应处理的集团及子公司有息债务, 也不在各层反复相减.

若某个分部直接用 FCFE 得到股权价值, 就不能把它当成尚未扣债的 EV 混入上式. 可以先把其他分部也换算成股权价值再相加, 最后只处理尚未计入的集团负担; 也可以将各项统一到企业价值. 采用哪一种都可以, 关键是每项资产和请求权只出现一次.

8.2.5 银行: 先研究资本要求允许分配多少

银行的存款和融资参与日常经营, 利息支出也是获取资金的重要成本. 把工业企业的 EBITDA 和净债务办法直接搬来, 容易先忽略融资对盈利的作用, 又把经营所需负债重复当成外部负担. 金融企业因此常从普通股盈利, 可分配现金与权益资本入手 [Asw].

贷款增长会占用资本, 信用损失又会削弱已有资本. 账面净利润不是全部都能立刻分给股东, 必须先满足持续经营和监管要求. 监管资本与会计股东权益也并非完全相同, 实际模型需要检查资产质量, 监管扣除和能够释放的资本.

剩余收益 (residual income) 在净利润中再扣除股东投入资本的机会成本. 它不是现金科目, 用途是判断公司是否创造了超过股东要求回报的盈利. 在会计与股利预测一致的条件下, 股权价值可以写为当前账面权益加未来剩余收益的现值 [CFAc].

设 BV_t 为普通股账面权益, NI_t 为归属普通股的净利润, d_t 为股利. 先假设没有新股发行或回购, 股数固定, 并满足干净盈余关系

$$BV_t = BV_{t-1} + NI_t - d_t.$$

若存在绕过净利润的其他综合收益等权益变化, 须先作一致调整. 用固定股权资本成本 k_e 评价这组股利预测, 将 $d_t = NI_t - (BV_t - BV_{t-1})$ 代入股利现值, 账面权益项作望远镜求和. 在相关级数收敛且 $BV_n/(1+k_e)^n \rightarrow 0$ 时, 得到

$$RI_t = NI_t - k_e BV_{t-1}, \quad V_0^{\text{eq}} = BV_0 + \sum_{t=1}^{\infty} \frac{RI_t}{(1+k_e)^t}.$$

这说明账面权益为什么不是天然的估值下限. 若未来盈利长期不足以补偿股权资本成本, 剩余收益现值可以为负, 模型价值便低于账面值.

进一步假设 ROE 恒定, 账面权益每年增长 g , 留存后的盈利可以分配, 并有 $0 \leq g < k_e$ 和 $g \leq \text{ROE}$. 此时 $RI_t = (\text{ROE} - k_e)BV_0(1+g)^{t-1}$, 等比求和给出模型支持的 P/B:

$$\frac{V_0^{\text{eq}}}{BV_0} = 1 + \frac{\text{ROE} - k_e}{k_e - g} = \frac{\text{ROE} - g}{k_e - g}.$$

这项稳定关系适合帮助解释倍数, 不要求真实银行以后始终维持相同 ROE. 转型, 信用周期和资本缺口明显时, 应逐年预测盈利与必要留存.

取教学数字 $BV_0 = 1000$, ROE 为 12%, $k_e = 10\%$, $g = 5\%$, 并假设相应资本积累足以满足本例的经营和监管需要. 第一年的净利润为 120, 留存 50, 可分配 70. 因而

$$\frac{V_0^{\text{eq}}}{BV_0} = \frac{0.12 - 0.05}{0.10 - 0.05} = 1.4, \quad V_0^{\text{eq}} = 1400.$$

若股数为 50, 每股价值为 $1400/50 = 28$. 直接折现以 5% 增长的首年股利 70, 也给出 $70/(0.10 - 0.05) = 1400$, 两种写法相符.

若只把持续 ROE 改为 8%, 保留其余假设, 合理 P/B 就变成 $(0.08 - 0.05)/(0.10 - 0.05) = 0.6$. 低于一倍账面价值可以是对低资本回报的合理定价, 不单独构成便宜的证据. 这里已经直接估计普通股价值, 不再像工业企业 EV 换算那样扣一次银行存款和债务.

8.2.6 地产与 REIT: 从物业租金算到每股净资产价值

对已经稳定出租的物业, 可以先用可持续租金和运营费用估计净经营收益 (net operating income, NOI). 现金 NOI 从实际可取得的物业收入出发, 扣除空置损失和物业经营费用, 不先扣债务利息与折旧. 房地产估值可以据此资本化, 再扣负债得到每股净资产价值 NAVPS[CFAa].

资本化率应与所用 NOI 的时期和定义一致. 下一年度 NOI 相同的两栋楼, 若租约, 位置, 空置风险或以后更新投入不同, 价格也可能不同. 因而资本化率需从可比物业和长期经营条件研究, 不是把股权资本成本直接换一个名称.

设一组物业下一年度稳定租金等收入为 80, 空置损失 5, 物业经营费用 25, 则现金 NOI 为 50. 暂取与这些物业条件相容的资本化率 5%, 估计物业价值为

$$\text{NOI}_1 = 80 - 5 - 25 = 50, \quad V_0^{\text{property}} = \frac{50}{0.05} = 1000.$$

假设公司另有额外现金 40, 债务 400, 并需立即支付 20 补足一项欠修工程. 这笔特殊支出尚未包含在上述 NOI, 资本化率所比较的物业条件或其他负债中. 无其他待计入的资产, 总部现金负担和请求权, 稀释股数 20, 则

$$\text{NAV}_0 = 1000 + 40 - 400 - 20 = 620, \quad \text{NAVPS}_0 = 620/20 = 31.$$

这里先重估物业, 再得到普通股净资产价值, 并未把财报中的历史成本净资产直接当成市场价值. 特殊工程 20 只扣一次, 如果所采用的物业价值已经按欠修情况打过折, 就应相应调整计算.

NOI 通常还不是全部可分配现金. 维护更新, 租户装修和租赁佣金等资本支出, 要在完整物业估值中得到处理. 直接资本化时, 可比物业的价格及资本化率可能已经反映通常的后续支出, 不再为同一成本另扣完整现值; 使用逐年 DCF 时, 则要明确列出这些现金支出. 开发期, 大量租约集中到期或空置率将明显变化的物业, 更需要逐年预测, 不能直接把某一年的收入永久资本化.

REIT 分析还会使用 FFO (funds from operations) 和 AFFO (adjusted funds from operations) 比较经营表现及相应倍数. 使用这些经调整指标前, 仍须核对具体加减项, 尤其是持续维护和租赁投入是否已扣. 一个高于会计净利润的调整数字, 并不因此全部成为股东能够提走的现金.

不同方法的分歧怎样使用 DCF 可以暴露长期现金流和贴现假设, 可比法显示市场对相近盈利目前付多少, SOTP 查清业务差异, 银行与物业方法则把资本留存和资产收益放到更合适的位置. 比较时先对齐估值日期, 归属和每股分母, 再追查差额来自哪项经营或定价判断. 方法多并不会使平均数自然更准确.

本节得到的每股价值都是当前假设下的估计. 要把它写成一年或三年后的成交价格, 还须预测届时盈利, 资本结构和市场愿意采用的价格, 并计入持有期间分配与费用. 下一节第8.3节将分别在上行, 中心和下行情景中完成这些计算, 再与今天的买入成本比较.

8.3 Risk-Reward 框架与情景分析

第七章介绍了不同资产和市场, 第8.1节则讨论证据能够支持怎样的估值. 现在进一步比较投资结果: 经营大致符合判断时可能赚多少, 好于预期时还有多少空间, 核心假设失败时又可能亏多少?

Risk-Reward 图把这些判断整理为 Bull, Base 和 Bear 等情景. 每个价格背后都应有一组经营, 财务和估值假设. 把假设与价格放在一起, 才能看出收益从何而来, 损失会怎样发生.

本节先研究一类权利明确的普通股: 投资者以正价格建立现货多头, 在相同期限上比较出售所得或未卖出持仓的期末估值. 这样可以先用价格变化计算收益. 空头, 杠杆, 衍生品或包含私人使用利益的投资, 则须根据各自的现金收支和资本投入计算, 不能直接沿用同一个分母.

Morgan Stanley 的一些公开材料也用 Risk-Reward 页面并列展示上行, 中心和下行情景, 有时还加入期权隐含概率 [Mor22]. 下面借用这种展示方式, 讨论单点目标价遗漏了什么, 再说明情景概率与风险中性定价概率的区别.

为区别于零息债券价格 $P(t, T)$, 股票现价记为 S_0 , 情景 s 在共同期限 T 下的代表性价格记为 $S_s(T)$. 后者是对未来出售价格或市场估值的条件判断. 分红等期间现金分配若不可忽略, 就应加入总收益; 回购等已经反映在每股结果中的影响, 不再重复加成持有人的现金收入.

单点目标价遗漏的信息 研究报告常用一个目标价概括结论. 若现价为 S_0 , 期限 T 的中心情景价格为 $S_{\text{Base}}(T)$, 潜在价格收益为

$$\frac{S_{\text{Base}}(T) - S_0}{S_0}.$$

这个计算回答了中心判断成立时的结果, 却没有说明判断失误的代价, 也没有说明好于预期时还有多少收益.

例如, 两家公司现价都是 100, 中心情景都是 120, 其余情景却可以很不一样:

	Bull Case	Base Case	Bear Case
A	160	120	90
B	130	120	50

只看中心情景, 两者都有 20% 的上涨空间. 但在列出的端点上, A 的上行更大, 下行更小, B 的核心判断失败时则可能承受更重的损失. 两个相同的目标价, 因而不能概括这两组不同的投资结果. 要继续比较, 还须判断这些端点如何产生, 以及各情景有多大可能发生.

增加 Bull 和 Bear 价格也不能只是把目标价上下各挪一段. 每个情景都应说明公司可能经历什么, 哪些盈利或估值假设随之改变. 有了这样的经济解释, 三个价格才是在比较不同的未来, 而不只是展示三个数.

定义 8.1 (Scenario).

一个情景 (Scenario) 是一组彼此一致, 并与现有独立证据相容的假设. 它说明在给定期限内, 经营, 财务和相关制度可能怎样变化, 这些变化怎样影响所研究股东能够取得的利益, 以及据此得到怎样的估值.

持有人, 股份类别, 计价资产和期限应先说明. 若进一步用情景计算未来退出结果, 还须说明届时可能按什么价格成交或估计未卖出的持仓价值. 这个情景在共同期限 T 下的代表性价格记为 $S_s(T)$.

Base Case 概括当前信息下的中心经营判断. Bull Case 说明哪些关键因素可能明显好于这个判断, Bear Case 则说明哪些假设可能失效, 以及由此会损失多少盈利或价值. 三者应使用相同的研究期限, 才便于比较.

少数情景怎样近似复杂的未来 第3.1节和第4.2节把样本点理解为一完整实现. 对公司研究而言, 一条未来路径可以同时包含需求, 竞争, 利率, 利润率和市场估值的变化. 三个情景显然无法逐一描述所有路径, 它们只是把对当前判断最重要的差别分成少数几类.

例如, “需求较弱”这一类内部仍会有许多不同结果. 用一个 Bear 价格代表整类, 就暂时略去了这些差别. 这种简化便于看清主要假设, 代价是丢掉情景内部的分散程度, 极端尾部 and 到达终点以前的波动.

若只列出三个条件价格, 还没有给出概率分布. 要计算加权回报, 须进一步用 p_s 表示研究者对情景 s 在真实世界中发生可能性的估计. 各情景需要互不重叠并覆盖所采用的近似模型, 概率才满足

$$p_s \geq 0, \quad \sum_s p_s = 1.$$

如果三组描述彼此重叠, 或另有重要情形尚未纳入, 就不能仅把三项权重凑成 1 来代替这个问题. 实际 Risk-Reward 页面可以只展示条件情景而不报告主观概率, 这时就停留在情景比较.

Base 是一个代表性的中心判断, 不等于概率加权后的期望. 期望还取决于其他情景的价格及概率. Bear 同样只是选定的下行情景, 通常不等于最坏结果或价格下界.

后面用代表性价格计算的期望收益, 是这份离散情景近似的结果. 即使每个代表价取为相应类别内的平均价, 也未必保留该类别内的上行和下行规模: 同一类内部可能既有盈利路径, 也有亏损路径. 因此, 三个点能帮助比较主要可能性, 不能代替对尾部和持有期间风险的研究.

从商业驱动到情景价格 情景价格应当从经营判断推出来. 与其先给股价一个上涨或下跌幅度, 不如先问公司在相应情形下会卖出多少, 收到多少收入, 留下多少利润, 再估计这些成果对每股意味着什么.

定义 8.2 (Driver Tree).

经营驱动分析 (Driver Tree) 把公司的业务活动与收入, 成本, 利润和现金流联系起来, 说明财务变化由哪些经营因素产生, 并据此进行预测.

企业层面的增长还要分配到具体股东. 偿付顺位, 少数股东权益, 净债务, 稀释, 回购和治理安排, 都可能改变普通股能够取得的剩余利益. 因此, 总利润增长以后, 还须检查每股盈利和现金流是否相应增长, 以及这些利益能否真正归属于所研究的股份类别.

不同公司需要研究不同因素. 支付网络要看支付金额, 跨境交易, 交易笔数, 收费率和客户激励; 零售企业要看客流, 客单价, 同店销售和毛利率; 银行则要看贷款, 净息差, 信用损失, 费用和资本回报. 这些经营量未必就是财报中的项目, 研究者需要说明它们怎样影响财报结果.

例 8.3 (支付网络).

支付活动增加, 不代表收入一定按同样比例增加. 还要看跨境交易占比, 每笔或每单位支付金额的收入, 以及向客户支付的激励. 如果新增业务需要更多激励, 业务量的增长就可能被净收费率下降抵消. 先把这些变化算进收入, 再考虑费用和利润, 才能判断每股收益怎样变化.

这样, Bear Case 就有了具体内容. 若需求下降导致业务量减少, 先计算少了多少收入; 若成本不能同步减少, 再计算利润率受到多大影响. 若问题来自竞争, 则可能需要下调价格, 提高客户激励或承担更多获客成本. 这些影响如何进入盈利, 要逐项说明, 不宜用一条笼统的“竞争风险”折价替代.

经营恶化也可能改变市场愿意支付的估值倍数, 但这是下一项判断. 公司赚得更少, 与投资者愿意为每单位盈利付得更少, 应分别给出理由. 情景分析由此能够回答: 哪些假设变了, 财务结果差在哪里, 以及为什么得到不同的情景价格.

让估值方法与独立证据相匹配 第8.2节已经展示了各方法从经营预测算到每股价值的过程. 放进情景分析时, 应分别更新相应的现金流, 盈利, 资本留存或资产价值, 再核对估值方法是否仍适用.

哪一项资料有可靠依据, 比单看行业标签更能决定这一选择.

若预测的经营利益能够明确归属于普通股, 就可以据此使用 DCF, 正常化盈利, 资产价值或分部估值. 若股份权利, 稀释或期末处理仍不清楚, 应先缩小估值结论或查清这些问题. 随意提高贴现率, 并不能说明股东到底能取得多少利益.

主要方法	使用它需要哪些经营和财务依据
P/E	盈利相对稳定, 资本结构不太扭曲, 每股收益能较好代表股东经济结果.
EV/EBIT 或 EV/EBITDA	能够先估计经营资产价值, 再处理净债务及其他资本结构差异.
DCF	能够说明现金流路径, 资本成本和长期假设, 并检查结果对这些假设的敏感性.
SOTP	各业务的增长, 利润率和风险有明显差异, 且可以分别估计再汇总.
P/B 或 P/TBV	资产负债表是经营的核心, 如银行, 同时需要研究资产质量和资本回报.

这些方法的基本工具见 [Dam12]. 在情景分析中, 主要方法负责形成估值, 其他方法用来检查范围和寻找遗漏. 清算回收或替代关系可以检验某些过于宽松的假设, 反向估值则说明现价要求什么条件. 它们有不同用途, 不宜只把几个估值结果取平均.

例如, 使用市盈率时, 情景 s 的模型估值为

$$F_s^{P/E}(T) = \text{EPS}_s \times M_s,$$

其中 EPS_s 是采用的每股盈利预测, M_s 是同一情景下判断合理的市盈率. 盈利减少会压低第一项; 增长放缓, 风险增加或竞争优势受损, 还可能使第二项降低. 两项同时下降, 就会产生盈利下修和估值压缩叠加的结果.

这个乘积首先是模型估计. 要用它作为未来价格 $S_s(T)$, 还须假定届时市场大致愿意按相应倍数给这项盈利定价. 未来成交价格取决于届时交易, 不会仅因研究者算出了一个价值就必然等于它.

同一公司的不同情景也可能适合不同方法. 一家银行在正常经营时可以主要研究盈利和资本回报, 严重信用压力下则可能需要更多依赖有形账面价值和回收判断. 只要说明经济条件为何改变, 方法随情景调整就是研究的一部分. 同一项利益或成本无论在哪种方法中已经计入, 都不应在交叉检查时再完整加减一次.

端点偏斜与概率加权 R/D 先沿用一单位现货多头的简单策略: 买入价格 $S_0 > 0$, 期限共同为 T , 暂不计费用, 融资和期间现金分配. 对一般策略, 则先用前一节的净损益 $\Pi_{0,T}^{\text{financial}}(h)$ 除以有经济含义的资本基数 K_0^h , 得到各情景回报, 再作下面的比较.

只看 Bull 和 Bear 两个端点, 可以计算上行空间

$$U_{\text{Bull}} = \frac{S_{\text{Bull}}(T) - S_0}{S_0},$$

以及下行幅度

$$L_{\text{Bear}} = \frac{S_0 - S_{\text{Bear}}(T)}{S_0}.$$

当 $L_{\text{Bear}} > 0$ 时, 比例 $U_{\text{Bull}}/L_{\text{Bear}}$ 比较了选定端点的潜在盈利和亏损. 它没有使用概率, 也没有计入中心情景. 因而比例相同的两项投资, 仍可能有完全不同的预期结果. 这是本文用于讨论情景形状的指标, 并非声称 Morgan Stanley 的页面都采用这一固定公式.

若进一步接受各情景的主观概率 p_s , 令

$$\rho_s = \frac{S_s(T) - S_0}{S_0},$$

并把正收益与负收益分别按概率加权:

$$R_{\mathbb{P}} = \sum_s p_s (\rho_s)^+, \quad D_{\mathbb{P}} = \sum_s p_s (-\rho_s)^+.$$

这里 $x^+ = \max(x, 0)$. $R_{\mathbb{P}}$ 累计盈利情景对平均回报的贡献, $D_{\mathbb{P}}$ 把亏损幅度取正后累计. 一个叫作 Base 的情景若仍然盈利, 也要计入 $R_{\mathbb{P}}$; 分类依据是收益的正负, 不只是 Bull 或 Bear 的名称.

这份情景近似给出的期限内金融期望收益率为

$$\mu_{\text{fin}, T} = \sum_s p_s \rho_s = R_{\mathbb{P}} - D_{\mathbb{P}}.$$

$D_{\mathbb{P}}$ 是概率加权的亏损幅度, 不是最大可能亏损, 也不是亏损发生时的条件平均损失. 这些量回答不同问题, 不能互相替代.

算术一旦确定, 真正的工作仍在输入上: 情景怎样从经营证据中形成, 代表价格是否合理, 概率又依据什么. 当前价格同样重要. 优秀公司若已经按接近 Bull 的价格交易, 剩余收益可能不大; 普通公司若价格已经反映相当悲观的假设, 反而可能有更有利的回报比较.

因此, 公司经营得好, 与按今天的价格买入值得, 是两项判断. 后者还要考虑利益能否归到每股, 实际持有成本和退出条件. 情景分析把这些判断放在一起比较, 但不会省去其中任何一项.

一个虚构的三情景例子 设一家虚构公司的现价为 $S_0 = 100$, 研究期限为一年. 暂不计期间现金分配和费用, 并假设一年后市场会按各情景对应的市盈率给预测盈利定价. 这项假设使每股盈利乘以倍数的结果可以在本例中用作代表性终价.

情景	p_s	EPS_s	M_s	核心假设
Bull	0.25	12	13	需求强于预期, 利润率扩张, 市场愿意给更高倍数.
Base	0.50	10	12	经营大致符合中心判断, 估值倍数保持正常.
Bear	0.25	7	10	需求转弱, 经营杠杆反向作用, 估值倍数压缩.

先在每一行情景内计算终价, 不急于把情景混合:

$$S_{\text{Bull}}(T) = 12 \times 13 = 156, \quad S_{\text{Base}}(T) = 10 \times 12 = 120, \quad S_{\text{Bear}}(T) = 7 \times 10 = 70.$$

由现价 100 出发, 选定端点的上行和下行分别为

$$U_{\text{Bull}} = \frac{156 - 100}{100} = 56\%, \quad L_{\text{Bear}} = \frac{100 - 70}{100} = 30\%.$$

二者之比为

$$\frac{U_{\text{Bull}}}{L_{\text{Bear}}} \approx 1.87.$$

到这里尚未使用表中的概率. 这个比例只比较 Bull 的 56% 盈利与 Bear 的 30% 亏损, 没有计算平均收益.

再接受表中的主观概率. 三个情景收益率依次为 56%, 20% 和 -30%. Bull 和 Base 都盈利, 因而概率加权上行为

$$R_{\mathbb{P}} = 0.25 \times 56\% + 0.50 \times 20\% = 24\%.$$

只有 Bear 亏损, 所以

$$D_{\mathbb{P}} = 0.25 \times 30\% = 7.5\%.$$

相减得到一年内的情景加权期望收益率:

$$\mu_{\text{fin}, T} = R_{\mathbb{P}} - D_{\mathbb{P}} = 16.5\%.$$

中心情景的收益是 20%, 加权期望却是 16.5%, 这直接说明 Base 不能替代期望. 同样, 7.5% 是亏损对平均回报的贡献, 不是说进入 Bear 时只亏 7.5%; 该情景的亏损仍是 30%.

这些数字在给定输入下可以复算, 但输入本身仍需研究. 为什么盈利可以升到 12 或降到 7? 为什么市场会采用 13 倍或 10 倍? 又是什么证据支持 0.25, 0.50, 0.25 的概率? 算术只把这些判断的后果算出来, 不能反过来证明判断可靠.

期权隐含概率与主观真实概率 期权市场为情景分析提供另一种比较. 不同行权价的合约对不同终价范围支付, 因而期权价格包含了市场怎样给这些结果定价的信息. 但从中得到的风险中性概率, 与研究者估计经营情景发生的真实世界概率不是同一个量.

在适用的无套利定价模型中, 假定利率为确定常数, 且支付满足相应可积条件, 欧式看涨期权可以写成

$$C_0(K, T) = e^{-rT} \mathbb{E}_{\mathbb{Q}} [(S_T - K)^+].$$

$\mathbb{Q}$ 是这里使用的风险中性定价测度. 在足够光滑的理想条件下, 考察价格随行权价怎样变化, 可以进一步恢复风险中性密度的信息. Breeden-Litzenberger 关系就是这一思路的经典表达 [BL78; Hul22].

真实世界概率 $\mathbb{P}$ 讨论结果实际怎样发生, 风险中性概率 $\mathbb{Q}$ 用于使合约价格等于相应的折现期望. 风险溢价和风险偏好使两者可能不同; 实际报价还会受到供需, 流动性和交易条件影响. 因此, 期权隐含概率不能直接填进公司 Bull, Base 和 Bear 的概率栏.

两种分组本身也未必一致. 期权首先按照终端价格决定支付, 基本面情景则按照需求, 竞争和盈利等条件组织. 使用期权信息时, 要先说明某个价格范围与哪些经营情景可能对应, 再比较自己的判断与市场定价.

这样比较仍然有用. 分析师可以判断分歧主要来自未来盈利, 还是来自波动幅度和尾部风险的价格. 保留两种概率各自的含义, 比直接选一个数字替换另一个更能说明问题.

从情景研究到交易决策 情景比较把经营研究与投资决策接在一起. 前面的研究要解释公司怎样赚钱, 每股能取得多少, 以及未来可能按什么价格交易. 后面的决策则要判断, 这组可能结果放进当前组合以后, 是否承受得起, 能否按设想建立和退出持仓.

因此, 一个较好的 R/D 还没有决定仓位. 同一项风险可能已经集中在其他持仓中, 可成交数量和退出成本也可能使大仓位与小仓位具有不同结果. 这些问题应在组合和执行中继续研究, 不宜把情景图直接当成买卖指令.

情景分析与前面概率论的联系, 在于用少数代表结果近似复杂的未来, 并在愿意给出概率时计算加权回报. 近似是否有用, 取决于它保留了哪些关键差异, 而不取决于图上是否恰好画了三个点.

但一张图通常只留下当时的价格和主要假设. 以后看到新财报或竞争消息, 还要能找到原来的证据, 判断究竟应修改哪项经营预测, 是否同时改变情景概率, 以及某项损失是否已经计入. 下一节的 Agentic R-D-G 用研究记录和图中的联系保存这些来由.

8.4 Agentic R/D Graph: 把研究判断组织成可更新的图

第8.3节用少数情景概括投资的可能结果. 这便于比较, 但过一段时间再看几个终价, 未必还记得当初为什么这样预测.

持续研究需要保存更多来由: 哪项资料支持某个经营假设, 假设怎样影响收入和利润, 新消息又推翻了哪一步. 本节把这些关系整理成研究图. 图的作用是让判断能够被找回和修改, 具体数值仍须通过经营分析与计算得到.

先看支付平台的一次证据更新 以下仍用虚构数字. 研究者最初以支付金额 100 乘以扣除客户激励后的净收入率 2%, 得到净收入 2. 后来看到支付金额增加到 110, 若净收入率仍为 2%, 就会预测收入升到 2.2.

随后披露客户激励增加, 净收入率实际降到 1.8%. 收入应重新计算为

$$110 \times 1.8\% = 1.98.$$

现在得到的收入不仅低于先前预测的 2.2, 也低于原来的 2. 业务量增长仍然成立, 但它不足以抵消净收入率下降. 因而要保留业务量的新证据, 替换净收入率假设, 并撤回原来的收入增长判断.

新信息	应怎样修改	哪些内容不随之改写
支付金额增至 110	更新相应经营预测中的支付金额	净收入率仍按已有证据判断
客户激励使净收入率降至 1.8%	重算净收入, 再检查费用和利润	已扣除的同一笔激励不再作为费用扣第二次
监管讨论升温, 暂无具体条款	保存来源, 明确尚待回答的问题	先核对适用业务和生效时间, 再判断哪些假设需要调整

研究图可以把支付金额, 净收入率和收入连接起来, 并在旁边保留证据来源和使用时点. 新资料出现后, 就能找到受影响的假设及其后的预测, 而不必从头猜测原来的收入数字如何得来.

是否调整情景概率是另一项判断. 净收入率下降可能要求修改某个情景中的收入, 也可能使研究者重新评估不同情景的可能性, 但两种修改各自需要理由. 一次下修不会自行规定 Bear 概率应增加多少.

从例子到研究图 前例中, 净收入来自两个经营假设. 如果只保存最终的 1.98, 下次更新就很难分辨究竟是业务量变了, 还是收费和激励变了. 把证据, 假设和计算关系一起保存, 才能解释数值为何改变.

定义 8.4 (Agentic R-D-G).

本笔记把这种研究组织方式称为 **Agentic R-D-G**, 也写作 Agentic R/D Graph. R 表示潜在回报, D 表示潜在下行, G 表示研究图. 图中记录证据, 事件, 经营因素, 公司反应和情景判断, 并说明它们为什么相互联系, 资料来自哪里, 何时需要重查. Agent 用于协助维护这些记录和发现需要重新判断的地方.

节点可以记录一项事实或一个假设, 连线则说明某个判断怎样依赖另一个判断. 例如, 客户激励增加影响净收入率, 净收入率又影响收入预测. 图保存的是研究者接受或正在检验的解释, 连上线本身并不证明解释成立.

与第4.3节的联系在于信息的时间顺序: 过去的判断应当用当时已经取得的资料解释. 回看研究时, 不能把后来才披露的事实混进早先的预测. 第4.2节区分了一条已经发生的路径与全部可能的路径; 研究记录也应区分事后的观察和事前考虑过的情景.

情景价格和概率仍须由经营证据与估值判断产生, 不能从节点数量或连线形状推出.

研究多家公司时, 还可以把涉及同一政策, 行业或上下游关系的记录联系起来. 这样既能保留各公司的具体差异, 也能检查几家看似不同的持仓是否受同一个因素影响.

从静态情景到可更新的判断 Bull, Base, Bear 和必要时的 Tail 概括可能结果. 为了以后能够更新, 还要记录各情景依赖哪些条件. 新资料出现时, 先检查它推翻或加强了哪一项条件, 再决定怎样修改情景.

有些消息改变的是同一情景内的结果, 例如净收入率下降使原来预测的盈利变少. 有些消息主要改变对几种情景发生可能性的判断. 还有些消息只是提出一个尚未解决的问题, 目前只能保留来源并说明以后要查什么. 把这三种作用区分开, 更新就不必每次都同时改动价格, 概率和风险折价.

预测市场的信息也应按这个办法使用. 合约报价变化说明交易者对特定结算事件的押注发生了变化, 可能值得继续调查. 但这件事怎样影响某家公司的销量, 费用或经营期限, 仍需公司研究给出解释.

引用已有市场研究时, 只取与当前问题相关的部分, 并保留原始来源和使用条件. 一项只能提示调查方向的消息, 不应在几次转述以后变成已经确认的盈利假设.

公司事件图, 预测市场与市场图 **公司事件图** (Company Event Graph) 从一家公司出发, 记录与它有关的证据, 上下游变化和经营反应. 它主要回答: 这件事为什么影响这家公司, 会影响哪个业务, 最后改变多少收入, 成本或其他财务结果?

预测市场 (Prediction Market) 提供不同的信息. Polymarket, Kalshi 等市场把未来事件做成合约, 交易记录包括价格, 盘口数量, 流动性和报价变化. 它们可以提示市场在关注什么, 有时也能支持特定条件下的概率解释.

不过, 合约支付取决于自己的结算规则和期限. 某个事件合约的价格, 不等于一家公司进入 Bull 或 Bear 的概率. 即使外部事件完全相同, 公司仍可能因业务构成和自身反应不同而有不同结果. 使用这类信息时, 先读清结算条件, 再检查流动性及事件对公司的具体影响, 最后判断它应如何改变原来的概率估计.

市场图 (Market Graph) 则记录跨公司, 跨资产的联系. 几家公司可能受到同一政策影响, 也可能处于同一供应链, 或依赖相似的融资条件. 把各公司的相关研究连接起来, 可以看见这些共同因素, 同时保留它们对各家公司作用不同的证据.

一种用法是研究共同的市场环境: 哪些需求, 政策和资金条件正在一起变化, 多项持仓是否把风险集中在同一处. 本文也把这种综合环境称为“市场季风”. 另一种用法是回到单家公司, 判断当前变化究竟主要来自公司自身, 还是来自行业或融资环境.

这些联系要靠逐项核对建立. 不同研究提到相似主题, 未必就在描述同一件事; 即使是同一事件, 也不能把一家公司的结论直接复制给另一家. 正式接受的研究与本轮尝试中的解释应分别保存, 这样以后引用时才知道哪些判断已经核查, 哪些仍待检验.

消息怎样改变经营假设 “竞争进一步加剧”还不是一项收入或利润预测. 对某家公司, 它可能意味着降价; 对另一家公司, 可能表现为客户激励增加, 份额流失, 获客成本上升或额外资本开支. 也可能目前只看到了市场情绪变化, 尚未看到经营结果改变.

研究者要先找出具体发生了什么. 在支付平台例子中, 已知变化是客户激励增加, 它降低了扣除激励后的净收入率. 这使我们有理由修改收入计算. 至于利润还会下降多少, 要继续检查费用, 不能仅凭“竞争加剧”就同时给所有财务指标打折.

同样的经营动作也可能有不同原因. 公司降价可能是竞争压力所迫, 也可能是在主动换取业务量. 无论原因如何, 每单位收费下降都要先进入计算; 是否被新增业务抵消, 再由业务量证据判断. 资本开支增加会压低近期自由现金流, 其是否带来足够的未来产能和利润, 则是另一个需要证据的问题.

商业模式决定应该检查哪些经营量, 时间跨度决定哪些影响已经发生, 哪些仍在以后. 当前价格帮助判断市场可能已经反映多少, 却不能反过来代替对经营影响本身的研究.

原则 8.5 (先解释变化, 再修改数字).

调整预测时, 写清新证据改变了哪项假设, 影响通过什么经营活动发生, 何时开始, 持续多久, 以及哪些事实会使这项解释不再成立. 能说明方向而暂时不能估计幅度时, 就保留这个差别, 不为使模型完整而随意填数.

节点, 连线与证据 把研究画成图以后, 每个节点要能让人知道它在说什么, 每条连线要能说明为什么前一项影响后一项. 可以按下面几类内容组织, 但这些类别只是为了便于查找, 不替代证据本身.

记录内容	例子	应当说明的问题
证据	财报, 电话会, 行业数据, 政策文件, 市场报价	来源和时间是什么, 直接观察到了什么?
事件与背景	需求变化, 政策变化, 竞争动作, 融资环境	什么事情改变了, 从何时开始影响公司?
经营因素	业务量, 价格, 净收费率, 利润率, 资本开支, 留存	新情况首先改变哪项经营假设?
公司反应	提价, 降价, 扩产, 回购, 削减成本, 调整渠道	哪些反应已经发生, 哪些只是研究者的预计?
预测与估值	收入, EPS, FCF, 倍数, 情景概率	哪个判断需要修改, 修改幅度依据什么?

同一张图会同时包含事实, 推断, 尚待验证的可能解释和未解决的问题, 必须把它们区分开. “管理层声称需求强劲”直接证明的是管理层作过这个陈述. 要进一步支持需求强劲, 还要看订单, 收入, 客户行为或其他独立资料, 不能把引述本身当成经营结论.

Driver Tree 说明公司通常怎样从业务活动产生收入和利润, 因而相对稳定. 公司事件图则说明在当前资料下, 哪些经营因素已经改变, 哪些预期仍有依据. 前者提供分析经营的顺序, 后者保存这次预测为什么采用具体的输入.

对支付平台, 支付金额和净收入率都参与收入计算, 收入再影响利润和每股收益. 若证据表明客户激励增加, 就检查净收入率及其后的预测. 假如这项影响先体现在 Bear 情景中, 图可以注明相关盈利预测需要复查, 但盈利应下调多少仍要计算. 若新证据也推翻了 Base 的原假设, 还应修改 Base, 不能仅凭最初给它贴了 Bear 标签就限定影响范围.

每条连线还应附上简短解释: 影响方向是什么, 有何时滞, 是一次性还是持续性, 支持和反对它的资料有哪些. 尚未证实的关系可以保留为待检验的可能性. 已经被反证的关系则应明确撤回, 并找出此前依赖它的判断. 这样读者才能沿着图重建推理, 而不只是沿箭头读一串名词.

一项影响怎样计入, 怎样避免重复 支付平台的客户激励已经从净收入率中扣除, 再以同额费用扣一次, 就会低估利润. 重复计算也可能更隐蔽: 同一风险在行业研究, 公司预测, Bear 情景和组合说明中反复出现, 每处又各扣一笔价值, 最后就把一次损失算成了几次.

因此, 记录新信息时, 应指出它已经影响了哪项计算. 是改变情景内的盈利, 改变情景概率, 还是增加持有期间的一笔费用? 若暂时只能说明有风险, 就保留问题和依据, 不强行制造一个金额.

这些不同作用可以按下表区分:

修改或记录什么	它回答的问题	怎样防止重复
情景内的数值	同一情景下会赚多少, 值多少	已计入的损失不再另加一次风险折价
情景概率	各种情景现在有多大可能发生	概率变化与情景内结果变化分别说明依据
现金收支和损失原因	期间有哪些分配与成本, 损失为何发生	已进入总回报或现金账的项目不再加減
暂时无法量化的风险	哪个重要问题仍缺少足够依据	保留缺口, 不用任意数值填满表格
以后复查的条件	出现什么信息时应重新判断	复查提醒不直接修改当前价格或概率
市场与组合背景	公司处在怎样的共同环境中	背景描述不再成为一笔笼统的额外下行

原则 8.6 (同一项损益只计入一次).

多份资料可以共同支持一项判断, 但不会使同一笔成本发生多次. 同一事件也可以同时产生不同的经济影响, 只要能够分别说明原因和计算位置, 就应分别计入. 需要避免的是重复计算同一利益或损失, 不是强迫每条新闻只能改变一个数字.

例如, 采用一项技术可能增加产品收入, 同时增加外部算力成本. 收入与成本是两种不同后果, 可以分别计算. 若三份报告都在描述同一次算力成本上涨, 它们则只是同一判断的多个来源, 不能算成三份亏损.

价格和概率也应这样区分. 新证据可能既改变某个情景中的盈利, 又改变研究者对该情景的信心. 若两者都调整, 就分别说明什么证据支持盈利幅度变化, 什么证据支持概率变化. 不能在下调盈利以后, 仅因同一消息又出现在风险清单中, 再机械增加一笔概率或价值惩罚.

保存情景, 更新现价, 重算结果 完成一次分析后, 应把经营判断与用于比较的当前价格分开保存. 两者更新的原因不同: 新财报可能改变盈利预测, 股价变化则可能只改变今天买入的潜在回报.

情景记录 (Scenario Packet) 保存已经审查的 Bull, Base, Bear 和必要时的 Tail. 除代表性价格或估值及主观概率外, 还要留下核心经营假设, 主要证据, 研究置信度, 适用期限和需要重查的条件. 支付平台的业务量与净收入率就属于这里的经营假设, 每项都应能找到当时采用的资料. 若另加 Tail, 还要检查是否与原来的情景重叠, 并相应整理概率.

现价记录 (Price State) 保存计算采用的价格和时间, 并说明它在当前情景价格之间的位置. 若价格变化达到需要重新检查的程度, 可以提出复查; 这条记录本身不等于限价单或目标仓位.

同一组情景保持不变时, 买入价格改变, 各情景回报及其 R/D 也会改变. 因此, 今天作比较时应重新计算, 不能直接沿用上次报告中的比率. 重新使用时还要核对研究期限和旧假设是否仍适用, 避免把较早时点的预测当成没有期限的常数.

复算资料 (Replay Bundle) 则把一次计算所需的内容保存在一起: 情景价格与概率, 当前价格, 期间现金分配和成本, 损失原因, 研究期限与资本基数. 若还研究更长期的恢复, 也保存恢复概率, 时间, 融资和退出条件. 用于组合比较的公司角色, 风险承受范围和最低收益要求, 同样要与当时版本一起留下.

这些资料应附上来源, 采用时点, 复核情况以及可用于什么问题. 这样重新计算时, 才能分辨结果变化来自新价格, 新证据, 还是研究者修改了假设. 只保存最后的 R/D , 无法回答这些问题.

上一节的 R_P 与 D_P 给出了基本的加权方法. 下面仍使用这套计算, 再把持有期间的净现金收益和损失原因说清楚. 研究图负责保留每项输入的来由, 数字则由相应的经营预测, 估值和现金计算产生.

先沿用以正的 S_0 为资本基数, 持有一单位现货多头的计算. 情景 s 的价格收益率为

$$r_s = \frac{S_s(T) - S_0}{S_0}.$$

以 c_s 表示同一期间的净持有期现金收益率, 即这里的净 carry. 它可以包含股息等分配以及相应成本, 但须与 r_s 使用相同货币, 期限和资本基数. 若某笔现金流已经进入终值的总回报计算或现金账, 就不再加入 c_s .

于是总情景金融收益率为

$$\rho_s = r_s + c_s.$$

对其他持仓或融资方式, 先按实际现金收支和资本投入得到 ρ_s , 再使用后面的加权公式. 不能在用了不同资本基数以后, 仍把价格涨跌幅直接当成投资者收益率.

给定互不重叠且覆盖所用情景近似的概率 p_s , 概率加权上行与原始金融下行为

$$R_{\text{fin},T} = \sum_s p_s(\rho_s)^+, \quad D_{\text{raw},T} = \sum_s p_s(-\rho_s)^+.$$

这里先把每个情景的价格收益和净现金收益相加, 再区分盈利与亏损. 因而不会把同一情景中的成本和收入分别算成互不相关的上下行.

研究者还可能判断, 一部分下跌来自暂时性因素, 另一部分来自较难恢复的经营损害. 这种分类有助于研究持有时间和恢复条件, 但不能减少期限 T 上的亏损. 若有依据作数量分解, 对每个下行情景取非负比例 $\lambda_{s,\text{temp}}$ 和 $\lambda_{s,\text{perm}}$, 使其和为 1, 则

$$D_{\text{temp},T} = \sum_s p_s(-\rho_s)^+ \lambda_{s,\text{temp}}, \quad D_{\text{perm},T} = \sum_s p_s(-\rho_s)^+ \lambda_{s,\text{perm}}.$$

两类只是对同一项下行的拆分, 所以

$$D_{\text{temp},T} + D_{\text{perm},T} = D_{\text{raw},T}.$$

缺少可靠分类依据时, 可以只讨论可能的损失原因, 不必为了完成分解而随意分配比例. 无论怎样解释原因, 原始金融下行都保留在计算中.

期限 T 内的金融期望收益率仍为

$$\mu_{\text{fin},T} = R_{\text{fin},T} - D_{\text{raw},T} = \sum_s p_s \rho_s.$$

当 $D_{\text{raw},T} > 0$ 时, 定义

$$R/D_{\text{fin},T} = \frac{R_{\text{fin},T}}{D_{\text{raw},T}}.$$

它比较这份情景近似中的加权盈利与加权亏损. 若所列情景没有亏损, 分母为零, 这个比率按此定义不能计算, 也不能据此认定实际投资没有下行风险.

若认为亏损在以后可以恢复, 就另行研究 $T' > T$. 应说明恢复有多大可能, 需要多久, 等待期间有哪些融资和流动性成本, 以及是否可能在恢复前被迫退出. 再用这个较长期限的情景现金流计算 $\mu_{\text{fin},T'}$ 和 R/D . 未来可能恢复, 不会把 T 时刻已经记录的损失变小.

这组计算是本笔记采用的比较方式. 它把收益, 概率, 持有成本和损失原因分开说明, 便于复算和复查, 并不自行证明情景判断可靠或某项交易值得实施.

为何使用 Agent 同时研究许多公司时, 困难不只在计算, 还在于记住哪些判断依赖哪些资料. 一条政策消息可能影响多家公司, 一份财报也可能推翻几处旧假设. 若这些关系散在许多报告中, 更新时容易遗漏, 也容易把同一风险重复算入.

Agent 可以帮助查找原始来源, 比较新旧资料, 找出相关假设和已经过期的结论. 固定程序适合核对格式, 查找明确重复和重算表格; 判断一条消息究竟是旧事件的新证据, 还是新的事件, 则需要理解内容. 同样, 一项风险是否已经反映在盈利或成本中, 也不能只靠关键词匹配.

原则 8.7.

本节中的 Agent 主要协助维护和复查研究. 它应指出哪个判断需要重做, 依据是什么, 并保留变更来由. 盈利, 估值和概率的修改仍须经过相应的研究判断, 不把图的节点数, 连线数或中心性直接换算成经济权重.

能够找到旧资料和旧假设, 是这项维护工作的基础. 每次使用一条已有结论, 应知道它来自哪次研究, 使用了哪一时期的证据, 原先只准备回答什么问题. 公司研究只引用与当前问题有关的部分, 避免把整张市场图中的猜测混成默认事实.

新证据到来后, 先判断它补充了旧事件, 提出了新事件, 还是使旧解释失效. 然后找到它直接改变的假设, 再检查曾经依赖这些假设的预测. 如果一条旧关系被撤回, 还要找出此前已经据此作出的调整; 只停止沿旧关系继续计算, 可能仍把过去错误加上的收益或损失留在估值中.

例如, 新需求数据可能主要要求重查业务量, 监管条款可能同时影响价格, 成本和准入, 财报也可能证明此前假定的传导没有发生. 图能够指出这些需要复查的位置, 但每处影响是否仍成立, 数值如何调整, 要重新判断, 不能让数值仅因相连就自动改变.

本笔记还区分本轮研究中的临时修正与正式共享的市场研究. 普通公司研究可以保存本轮的新解释, 但不直接改写已经接受的市场图. 更新共享版本时, 再集中核对来源, 新旧结论及受影响的研究, 把确认的变更保存为下一版. 这样既能开展当前分析, 也能避免未经核查的局部判断被其他公司反复引用.

图越大, 越需要这种维护, 但规模本身不增加结论的可靠性. 多条线指向一个判断, 可能只是同一来源被多次转述. 是否有独立证据, 解释是否经得起反证, 仍比连线数量更重要.

怎样开展一次具体研究 先保存本轮使用的资料及其日期. 对已经整理的资料, 也应能找到原始来源和处理方法. 然后围绕具体问题分析, 例如支付金额是否增加, 净收入率是否稳定, 某项成本是否已经扣除. 事实, 尚待回答的问题和研究者的推断分别记录.

若已有公司或市场研究包含相关内容, 可以引用已接受的版本. 新资料要求调整时, 先保存本轮修正及理由; 是否更新正式共享的市场图, 再按前面说明的维护方式处理. 只作背景或存在缺口的旧结论, 不因为被引用就升级为估值事实.

接着检验解释. 业务量增加是否真的带来收入增加? 净收入率变化能否由客户激励解释? 是否还有与这一解释冲突的资料? 先完成这些判断, 再把接受的证据和关系整理进本轮公司图. 图记录分析所得, 不负责先替研究者选择结论.

只有当研究中出现了明确的外部事件问题, 而预测市场的信息确实可能帮助回答时, 才追加相应查询. 应先知道查询的是哪个结算事件, 结果准备用来检验什么判断. 没有这样的疑问, 就不必为了完成形式步骤搜索公司名称; 保留已有相关记录并说明本轮没有追加查询即可.

形成情景后, 检查各项假设能否同时成立, 价格如何从盈利或现金流算出, 同一成本是否重复出现. 再结合当前价格重算 R/D 与金融期望收益率, 核对期限, 单位和资本基数是否一致.

最后留下足以复算的输入和足以解释修改的记录. 在支付平台例子中, 后来的人应当能够看见收入从 2.2 改为 1.98 是因为净收入率假设被新资料替换, 而不是以为业务量增长的证据也被撤回了.

研究怎样用于组合决策 公司研究交付情景记录, 采用的价格和复算资料. 组合管理据此在当前价格下重新比较回报, 再考虑公司在组合中的作用, 持仓集中度, 流动性和共同风险. 研究回答一项投资有哪些可能结果, 组合判断则进一步回答能承担多少, 是否与其他持仓重复.

原始市场图中可能同时包含已确认事实和待检验解释, 因而不整张直接拿来决定仓位. 若本轮确实需要市场环境或组合风险研究, 应先把有关资料核对并整理成具体判断, 再用于组合比较. 一次图的维护也不会仅因记录发生变化就产生交易.

组合需要某种结果, 不是修改公司证据的理由. 不能为了让某只股票更适合组合, 就调高情景价格, 降低亏损概率或改变损失分类. 若认为研究有误, 应回到证据和假设说明分歧. 同样, 图中的分数或节点数量不能机械变成 Kelly 比例, 固定仓位档位, 更不应成为自动填满仓位上限的依据.

决定持有多少以后, 还有实际执行. 订单应按单独的执行安排产生, 明确方向, 数量, 价格和其他必要条件. 研究中的复查价位只提示重新判断, Bull 和 Bear 价格只表示情景结果, 都不直接等于

买卖指令。

持续更新时，保持这些区别就能知道该改哪里。经营证据改变，重查相应盈利和情景；只有现价改变，在假设仍适用时重算回报；组合暴露改变，重查持仓是否合适。一项宏观主题不会因此覆盖公司已经核实的事实，市场盘口也不会替代对经营的分析。

这套记录的价值最终体现在具体修改上：能够找到旧判断的理由，撤回被推翻的部分，保留仍有依据的部分，并据此重新计算。保存这些关系，才能让研究随新信息继续推进，而不必每次重写全部结论或无条件沿用旧数字。

第九章 趋势交易与技术指标：从路径变换到可交易策略

看见价格高于均线，下一步应该做什么？可以买入，可以继续持有，也可以等偏离再大一些才行动。指标本身只给出一个数，交易规则还要决定如何使用它。

本章沿着第六章的持仓与现金计算继续讨论。先从当时已经取得的价格计算指标，再据此决定下一次交易。成交以后，实际持仓承受后续价格变化，买卖和融资则产生费用。只有把这些收支合起来，才知道规则赚了多少钱。即使一段价格总体上涨，在附近反复买入卖出也可能亏损。

SMA 和 EMA 平滑历史水平，MACD 比较不同速度的平滑结果，Bollinger Bands 与 ATR 描述不同的价格变化尺度，RSI 汇总正负变化幅度，VWAP 则按成交量汇总价格。我们将分别看清它们怎样计算，再用完整例子比较立即切换与等待更明确变化的进出场规则。

减少交易可以节省成本，也可能推迟买入或退出。这项取舍需要在相同价格路径和成交时钟下算出来，不能只凭指标曲线更平滑就判断策略更好。

9.1 从指标到账本

图9.1列出了计算顺序。首先确认价格何时可见，然后计算指标和信号。信号可以决定希望持有多少，但只有成交才改变实际持仓。后面的收益应当按实际持仓计算，同时扣除相应交易与融资成本。

算出一段历史损益以后，再问它来自什么：持续承担市场方向，利用了过去对未来的预测信息，还是恰好适合这一段样本？随机过程提供可比较的假设，样本外检验则考察规则在未参与选择的数据中怎样表现。




图 9.1: 趋势交易的一条最小阅读路线。

下面先解释指标和交易时钟，用三日 SMA 算出一次完整的持仓与现金变化。随后比较常见指标，并用随机游走和 AR(1) 说明哪些价格形状可能自然出现，哪些假设确实会改变未来条件均值。

第9.8节再把同一信号变成两条不同的交易规则，逐笔比较缓冲区节省的交易和推迟进出的代价。期货换月，未完成订单与逐笔现金收支等实际问题，集中放在第9.12节。

9.2 看到上涨以后，还要回答什么

假设某指数六个月上涨了 12%。这首先描述一段已经发生的**路径趋势**：价格总体向上，或某条平滑曲线具有正斜率。随机游走也能出现这样的片段，所以观察到上涨以后，还要另问它是否帮助预测下一段。

统计依赖讨论过去是否改变未来收益的条件分布。这需要预先规定研究哪些资产，用什么时间间隔，在哪些条件下比较。即使发现了差异，差异也可能很小，交易以后未必足以支付点差和费用。

潜在状态则是一种解释。例如，研究者认为某个未直接观察到的持久因素正在影响漂移，波动率或流动性，历史走势可以帮助判断它目前处于什么情况。这种解释要与其他可能产生相似走势的原因比较。一个模型能画出相似曲线，还没有证明真实市场正在按它运行。

最后，**可交易净优势**要求给出一条事前确定且能够执行的规则，并在扣除成本以后，相对于承担的风险和合适基准仍有样本外表现。它取决于实际买卖时点和数量，不能只从预测关系或一张上涨图得出。

这四个问题彼此相关，但答案可以不同。市场可以有很明显的事后走势，却没有额外的下一期均值信息；也可以有可测的预测关系，却被成本抵消。因此，本章先计算指标和交易，再分别讨论预测、解释和净收益。

9.3 离散交易时钟，信息集与可预测持仓

先定义所使用的价格记录 取决策时点 $t = 0, 1, \dots, T$, 用 S_t 表示当时已经取得的指定价格记录, V_t 表示同步可得的成交量. 先固定它们来自哪里, 按什么单位计量, 再计算指标. 收盘价, 最新成交价和中间价可以分别作为输入, 但不必等于整笔订单能够成交的价格.

日线数据尤其要说明是否调整拆股和现金分配. 原始收盘价, 拆股调整价和包含分配再投资的总回报序列, 计算出的均线和收益不一定相同. 跨市场使用数据时, 日期也必须按交易日历与时区理解, 不能把不同地方的同名日期当成同一信息时点.

图9.2展示了单位变化的影响. 将 AAPL 在 2020 年 4:1 拆分前后的名义报价直接拼接, 会出现约 75% 的下降. 这主要是每股单位改变, 并非股东财富发生同样损失. 20 日均线却会把这个断点当作价格变化, 直到旧观测逐渐移出窗口. 拆分调整消除了这一问题, 股息和总回报的处理仍须另外说明.




图 9.2: AAPL 2020 年 4:1 拆分前后的价格序列与 20 日 SMA. 灰色为按拆分比例复原的当时名义报价, 蓝色为拆分调整后的收盘价. 数据与拆分事件来源见引用文献 [Yaha].

期货还有合约换月带来的价格拼接问题. 合成连续序列可以用于计算信号, 实际盈亏却要回到当时持有的具体合约与换月成交, 详见第9.12.1小节.

若相关价格均严格为正, 定义

$$X_t = \log S_t, \quad \ell_t = X_t - X_{t-1} = \log \frac{S_t}{S_{t-1}}.$$

S_t 是价格, X_t 是对数价格, ℓ_t 是对数价格变化. 它们适合不同计算, 不统一简称为收益率. 后文的 r_t 则按具体问题表示简单收益, 总收益或超额收益. 多资产收益按资金权重相加时, 使用相应的简单收益, 不把对数变化当成可以精确加权的组合收益.

若窗口内报价达到零或变成负数, 上述对数就不可用. 可以按合约乘数计算价格差的货币损益, 或以明确资本基数定义收益. 给整条报价任意加一个常数虽然能使数值为正, 却会改变价格比率及信号, 不能据此修复经济计算.

指标适应, 持仓可预测 令 $\mathcal{F}_t$ 包含截至 t 已经能够使用的信息. 若指标由可测函数计算,

$$I_t = f_t(S_0, V_0, \dots, S_t, V_t),$$

那么 I_t 为 $\mathcal{F}_t$ -可测. 这正是第4.3节中的适应性: 当前指标已经可知. 是否能预测未来, 还不是这个可测性结论所回答的问题.

若只用这些指标决定下一段的目标持仓, 则可写成

$$q_{t+1}^* = g_t(I_0, \dots, I_t), \quad q_{t+1}^* \text{ 是 } \mathcal{F}_t\text{-可测的.}$$

规则可以只看当前指标, 也可以使用此前指标及由它们形成的持仓记录. 重要的是, 决定先于它将承担的那一段收益, 与第6.2节的可预测持仓一致.

目标不一定全部成交. 回测须根据执行价 P_{t+1}^{exec} 和成交数量得到实际持仓 q_{t+1} , 再从成交后计算收益. 不能既假定成交晚于决定, 又让新持仓取得决定以前已经发生的价格变化.

例 9.1 (收盘信号怎样用于下一次交易).

若正式收盘后才取得 S_t 并算出 I_t , 可以据此安排下一日开盘或之后的交易, 但不能保证回到刚才的 S_t 成交. 若使用收盘集合竞价, 就说明订单截止时间, 并只使用截止前已知的信息.

也可以用 I_{t-1} 决定第 t 日的交易. 两种安排都能研究, 但必须分别计算. 看完回测以后把成交时间移到更有利的位置, 等于换了一条规则.

注 9.2 (触发退出与实际卖出).

首次触及止损条件可以是停时, 因为当时能够判断条件是否成立. 但跳空, 停牌或盘口缺少买单时, 实际卖价可能越过触发价. 触发规则决定何时请求退出, 最终损失仍须用成交价计算.

策略收益的条件期望恒等式 设 r_{t+1} 是已明确含义的下一期简单收益, 总收益或超额收益, H_t 是事前确定的无量纲权重, 为 $\mathcal{F}_t$ -可测. 假设 H_t , r_{t+1} 和乘积 $H_t r_{t+1}$ 均可积. 先在当前信息下取条件期望, 再取期望, 得到

$$\mathbb{E}_{\mathbb{P}}[H_t r_{t+1}] = \mathbb{E}_{\mathbb{P}}[H_t \mathbb{E}_{\mathbb{P}}(r_{t+1} \mid \mathcal{F}_t)]. \quad (9.1)$$

可预测性使 H_t 能提出条件期望, 塔性质则把两次期望合起来, 见第3.4.2小节. 因而策略的平均毛收益取决于持仓怎样与下一期条件均值配合.

若实际上只有一个不变的条件均值,

$$r_{t+1} = \mu + \varepsilon_{t+1}, \quad \mathbb{E}_{\mathbb{P}}(\varepsilon_{t+1} \mid \mathcal{F}_t) = 0,$$

则在上述可积条件下,

$$\mathbb{E}_{\mathbb{P}}[H_t r_{t+1}] = \mu \mathbb{E}_{\mathbb{P}}[H_t].$$

这时历史指标不能预测下一步噪声. 若 $\mu > 0$ 且平均保持多头, 策略仍可能赚钱, 收益来自平均方向暴露. 所以判断择时有没有贡献, 应与买入持有或具有可比平均暴露的规则比较, 而不只与空仓比较.

这里使用现实测度 $\mathbb{P}$. 第7.7.5小节中的定价测度 $\mathbb{Q}$ 则使适当计价资产下的累计收益满足鞅或局部鞅关系, 用于无套利定价. 该累计收益包含除息价格和按同一计价方式累计的分配, 不能只看未调整的价格. 局部鞅要成为真鞅还需可积性条件.

现实中存在条件预测, 并不等于已经找到套利. 预测可能只是风险补偿的变化, 实际收益也仍承担亏损, 成本和融资要求. 本章讨论的是这些条件下怎样形成并检验策略, 不是用现实数据对简单随机游走的偏离代替无套利论证.

9.4 滤波的统一语言: 平滑, 时滞与尺度

滤波就是按一定规则重新组合历史观测. 以下以 Y_t 表示输入, 可以取价格, 对数价格, 收益或成交量, 但每次计算都要固定所用序列.

平滑用旧观测分担当前观测的权重, 所以曲线通常少一些短期起伏, 也要等新数据逐渐进入以后才改变方向. 差分强调变化, 标准化则改变比较尺度. 这些操作的效果可以直接从权重和公式看出, 不必先赋予它们预测含义.

简单移动平均 长度为 n 的简单移动平均 (simple moving average, SMA) 为

$$M_t^{(n)} = \frac{1}{n} \sum_{j=0}^{n-1} Y_{t-j}, \quad t \geq n-1.$$

这里明确包含当前观测, 对最近 n 个值等权平均. 一个值超过窗口以后, 权重立即归零. 前 $n-1$ 个时点若没有足够历史, 可以暂不输出; 若改用短窗口, 得到的是另一种启动方式.

对线性路径 $Y_t = a + bt$, 均线可以精确算成

$$M_t^{(n)} = a + b \left(t - \frac{n-1}{2} \right).$$

因此当前值与均线之差恰为 $b(n-1)/2$, 相当于在这条线性路径上落后 $(n-1)/2$ 期. 这个平均年龄来自窗口内 $0, 1, \dots, n-1$ 的均值.

实际路径并非直线, 不会总有一个固定的转向延迟. 但同样的权重原理仍在起作用: 窗口更长, 更多旧观测参与平均, 一次新变化对均线的影响就更小.

指数移动平均, 半衰期和有效窗口 取 $0 < \alpha \leq 1$, 指数移动平均 (exponential moving average, EMA) 为

$$E_t^{(\alpha)} = \alpha Y_t + (1 - \alpha) E_{t-1}^{(\alpha)}.$$

当前观测取得权重 α , 此前的全部平均取得权重 $1 - \alpha$. 展开为

$$E_t^{(\alpha)} = \alpha \sum_{j=0}^{t-1} (1 - \alpha)^j Y_{t-j} + (1 - \alpha)^t E_0^{(\alpha)}.$$

因此旧观测不会在某一日突然退出, 而是逐期衰减. 在无限历史表示下, 年龄 j 的权重为 $\alpha(1 - \alpha)^j$. 常用跨度 n 对应

$$\alpha = \frac{2}{n+1},$$

Wilder 平滑则使用 $\alpha = 1/n$. 报告一个 n 以前, 应先说明采用哪种关系.

对 $0 < \alpha < 1$, 权重减为一半所需的年龄为

$$h_{1/2} = \frac{\log(1/2)}{\log(1 - \alpha)}.$$

它可以不是整数. 当 $\alpha = 1$ 时, $E_t = Y_t$, 已经没有历史记忆, 不再代入含 $\log(1 - \alpha)$ 的公式.

无限历史权重的平均年龄为 $(1 - \alpha)/\alpha$. 令它等于 SMA 的 $(n-1)/2$, 得到

$$n_{\text{eff}} = \frac{2 - \alpha}{\alpha} = \frac{2}{\alpha} - 1.$$

同一个结果也可由方差等价得到: 对独立同方差观测, EMA 权重平方和为 $\alpha/(2 - \alpha)$, SMA 则为 $1/n$. 这解释了常用跨度公式, 也说明两者即使当前权重不同, 仍可具有相同的平均年龄和这项噪声方差. 有限样本的初始化影响尚未消退时, 这种比较只是近似.

初始化同样属于定义. 可以取 $E_0 = Y_0$, 或在已经取得前 n 个值以后用它们的均值开始递推, 也可以使用归一化权重. 第二种方法不能在那些观测尚未出现时提前生成指标. 回测应说明预热期和初始化, 因为初始值的影响会按 $(1 - \alpha)^t$ 保留下来.

图9.3在同一段 SPY 价格上比较 20 日 SMA 与跨度 20 的 EMA. 两者都混合了新旧价格, 转向只能随着新观测进入而逐步显现.

EMA 的当期权重更大, 但也保留了更长的衰减尾部; SMA 则在窗口边缘直接移除旧值. 因此, 两条线面对一次跳变和持续变化时可以有不同反应, 不能一概说同跨度 EMA 在每次转向都更早, 或在所有尺度上都保留更多噪声.

下图是价格减去各自滤波值的差, 正值表示价格在相应均线上方. 纵轴仍为价格差, 时间上的滞后要沿上图的时间轴观察.




图 9.3: SPY 在 2021-01-04–2022-12-30 的拆分与现金分配调整收盘价, 20 日 SMA 和跨度为 20 的 EMA. 黑色为价格, 蓝色为 SMA, 暖橙色虚线为 EMA; 下图给出价格与两种滤波值之差, 零线以上表示价格高于相应滤波值. 数据来源见引用文献 [Yahb; Yahc].

价格水平, 收益口径与稳定性 价格均线保留价格单位. 当资产从 10 涨到 1000 时, 偏离均线 \$1 的相对大小已经不同. 要比较不同价格尺度, 可以在 $M_t^{(n)} \neq 0$ 时计算

$$d_t = \frac{S_t - M_t^{(n)}}{M_t^{(n)}}.$$

也可以在价格严格为正时使用对数差, 或直接研究定义清楚的收益序列.

这些选择改变了问题. 相对距离比较百分比偏离, 收益研究相邻时点的增长, 绝对距离则仍适合某些按价格单位规定的交易规则. 无论选哪一种, 都还可能出现时变波动, 跳跃和历史依赖. 换成收益不会自行保证平稳, 需要根据后续计算使用的假设检验.

9.5 从滤波器到趋势规则

滤波器算出的是历史数据的概括. 规则还要决定怎样比较这个数, 以及比较后持有多少. 下面先列出几种方向信号, 具体的多空范围, 等号处理和成交时点将在完整例子中规定.

价格—均线规则 价格高于或低于其 SMA, 可以写成信号

$$z_t^{\text{PM}} = \text{sign}(S_t - M_t^{(n)}).$$

这里取通常的 $\text{sign}(0) = 0$. 再用 $q_{t+1}^* = g(z_t^{\text{PM}})$ 决定目标数量. 同一个负信号可以被解释为卖空, 减仓或空仓, 取决于 g 的定义. 均线若包含当前值, 当前变化也会同时推动均线, 因而比较的是包含这一更新后的距离.

快慢均线交叉 取 $\alpha_f > \alpha_s$, 快线给当前观测更大权重. 比较两条 EMA 可得

$$z_t^{\text{cross}} = \text{sign}(E_t^{(\alpha_f)} - E_t^{(\alpha_s)}).$$

两个平均都削弱部分较快变化, 相减以后强调它们对不同时间尺度的反应差异. 由于输入相同, 两条线不能当作两份独立证据; 同一个价格冲击会同时进入两者, 只是权重不同.

时间序列动量 对严格为正的价格, 可以直接比较现在与 k 期以前:

$$m_t^{(k)} = X_t - X_{t-k} = \log \frac{S_t}{S_{t-k}}, \quad z_t^{\text{mom}} = \text{sign}(m_t^{(k)}).$$

这等于窗口内对数变化的累计. 报价不适合取对数时, 应使用相应合约的算术损益或明确的收益序列, 而不任意平移价格. 后面还可以按事前波动率缩放持仓, 但那是在调整承担多少风险, 与方向信号怎样形成是两步.

突破与 Donchian 式区间 突破规则问当前观测是否超出此前区间. 因而先用不包含当前值的历史定义

$$U_{t-1}^{(n)} = \max_{1 \leq j \leq n} S_{t-j}, \quad L_{t-1}^{(n)} = \min_{1 \leq j \leq n} S_{t-j}.$$

若使用每根价格柱的最高价 H_t 与最低价 L_t , 通常的 Donchian 上下轨则为

$$U_{t-1, \text{std}}^{(n)} = \max_{1 \leq j \leq n} H_{t-j}, \quad L_{t-1, \text{std}}^{(n)} = \min_{1 \leq j \leq n} L_{t-j}.$$

收盘价区间与最高最低价通道使用不同输入, 应分别计算. 在第一种定义下, 向上突破是 $S_t > U_{t-1}^{(n)}$, 向下突破是 $S_t < L_{t-1}^{(n)}$.

若把 S_t 先放进上轨窗口, 再要求它严格大于这个窗口的最大值, 条件就永远不成立. 正确的时间索引保证我们比较当前与过去, 至于突破后继续上涨还是很快退回区间, 仍是后续收益的问题.

收益移动平均的连续仓位分解 有一种特别容易分析的规则: 直接用过去收益均值作为连续权重. 假设 r_t 弱平稳且有有限二阶矩, 均值为 μ , 自协方差为 $\gamma(i) = \text{Cov}(r_{t-i}, r_t)$. 定义

$$m_{t-1}^{(N)} = \frac{1}{N} \sum_{i=1}^N r_{t-i}.$$

若单位资本的一期毛收益确实取为 $m_{t-1}^{(N)} r_t$, 则

$$\mathbb{E}[m_{t-1}^{(N)} r_t] = \mu^2 + \frac{1}{N} \sum_{i=1}^N \gamma(i). \quad (9.2)$$

证明只需展开有限求和, 对每项使用 $\mathbb{E}[r_{t-i} r_t] = \mu^2 + \gamma(i)$, 然后除以 N . 这一分解见 [FSY19].

第一项来自平均方向暴露, 第二项才使用收益的时间相关性. 即使收益独立, 只要均值非零, 这条连续权重规则仍有 μ^2 的期望毛收益. 这与前面的条件期望恒等式一致, 不需要时变的预测信息.

但把权重改成均值的符号, 或加入缓冲区, 波动率缩放及杠杆上限, 就不能再把乘积按同样方式展开. 式 (9.2) 的结论属于这里明确定义的连续权重, 不直接适用于常见的零一持仓规则.

同名规则为什么会得到不同结果 只说使用动量或均线, 还无法复算交易. 价格输入相同, 取符号还是取幅度就会改变持仓; 信号相同, 风险缩放和成交时间也会改变收益. 比较两份结果时, 应先找出它们实际在哪一步不同:

维度	一种实验	另一种实验	不可混用的原因
输入	价格与价格均线比较	过去收益的均值或累计和	权重, 尺度与公司行为敏感性不同
仓位映射	$\{-1, 0, 1\}$ 符号或阈值仓位	随信号幅度变化的连续仓位	非线性符号策略不满足连续仓位分解
收益口径	原始价格收益	扣除现金利率或融资后的超额收益	平均漂移和可融资损益不同
比较基准	空仓或零收益	买入持有, 历史均值方向或常数暴露	相对空仓盈利不等于择时增值
风险分配	等名义, 等权配置	逆波动率缩放, 组合目标波动率	组合结果同时受风险预算和分散影响
成本口径	毛收益	扣除点差, 滑点, 冲击, 融资与费用的净收益	高频换手可能使两者结论相反

例如, 所谓 EMA 动量也可以先计算多组快慢均线差, 按运行中的波动尺度归一化, 再通过非线性函数合成, 见 [Baz+15]. 合成结果既可决定各资产自身的方向, 也可用于资产之间的排序. 因而复算时必须取得真正使用的公式和持仓办法, 不能把这类结果当成单一均线交叉的结果.

方向信号怎样变成实际持仓 下图把同一次交易中先后发生的步骤分开. 其中每一步都会影响最后的现金结果:




图 9.4: 从市场路径到含成本策略损益.

$z_t = 1$ 可以只表达方向为正, 并没有规定买一股还是买一百股. 目标数量还可能取决于已有持仓, 波动率和能够承担的风险; 成交数量又取决于实际订单.

先用全部成交的简单例子算清楚. 之后再在章末处理部分成交和未完成订单, 避免一开始就把目标持仓当成账户已经持有的数量.

一个不偷看未来的完整小例 考虑只持有一单位多头或空仓的规则. 每日收盘后计算

$$M_t^{(3)} = \frac{C_{t-2} + C_{t-1} + C_t}{3}.$$

若 $C_t > M_t^{(3)}$, 下一日目标为一单位; 若小于或等于均线, 目标为零. 目标在下一开盘 O_{t+1} 执行, 调整后的数量 q_{t+1} 承担直到 O_{t+2} 的价格变化.

本例假设所需数量都能按该开盘价完全成交, 所以 $q_{t+1} = q_{t+1}^*$. 单边成本为成交名义金额的 $\kappa = 0.1\%$, 不计利息, 分配及其他费用. 初始持仓 $q_2 = 0$, 可用现金为 200. 以下价格均为教学假设, 前两日收盘为 $C_0 = 100$, $C_1 = 101$. 表中均线仅为展示而保留两位小数, 判断使用未舍入值:

决策日 t	收盘 C_t	三日 SMA	$C_t - M_t^{(3)}$	q_{t+1}^*	下一开盘 O_{t+1}
2	103.00	101.33	1.67	1	103.20
3	102.00	102.00	0.00	0	101.80
4	104.00	103.00	1.00	1	104.30
5	105.00	103.67	1.33	1	105.10
6	104.00	104.33	-0.33	0	104.40

每行先在下一开盘调仓并支付费用, 再由新持仓承担后一段价格变化:

$$\Delta \Pi_{t+1} = q_{t+1}(O_{t+2} - O_{t+1}) - \kappa O_{t+1} |q_{t+1} - q_t|.$$

最后一行在 O_7 卖出并变为空仓, 本行只剩退出成本. 后面没有持仓, 因而不需要 O_8 就能结束这次计算:

决策 t	持仓 q_{t+1}	区间开盘	下一开盘	毛损益	成本	净损益
2	1	103.20	101.80	-1.40	0.1032	-1.5032
3	0	101.80	104.30	0.00	0.1018	-0.1018
4	1	104.30	105.10	0.80	0.1043	0.6957
5	1	105.10	104.40	-0.70	0.0000	-0.7000
6	0	104.40	—	0.00	0.1044	-0.1044
合计				-1.30	0.4137	-1.7137

也可以从现金核对结果. 以 B_t^{cash} 表示开盘调仓后的现金, 初始 $B_2^{\text{cash}} = 200$, 则

$$B_{t+1}^{\text{cash}} = B_t^{\text{cash}} - (q_{t+1} - q_t)O_{t+1} - \kappa O_{t+1} |q_{t+1} - q_t|.$$

在 O_3 买入后剩 96.6968, 在 O_4 卖出后为 198.3950. O_5 再买入后剩 93.9907, O_6 不交易, 现金不变. 最后在 O_7 卖出并扣费, 剩余 198.2863. 全部平仓后比初始现金少 1.7137, 恰好等于表中的净亏损.

这段收盘价总体上升, 规则却先在 103.20 买入, 后在 101.80 卖出, 又完成另一组买卖. 盈亏由实际持有的开盘区间决定. 空仓那一行也可能支付卖出费用, 持仓不变那一行则仍然承担涨跌.

这与第4.3节的可预测持仓及第6.2节的自融资增益相同, 只是明确采用收盘决策, 下一开盘成交. 部分成交和撤改单的处理见第9.12.2小节. 接下来先比较各指标究竟概括了哪些历史信息.

9.6 常见指标: 准确公式与有限含义

同一段走势可以用不同方法概括. MACD 比较快慢平均, Bollinger Bands 把偏离与窗口离散程度一起看, RSI 比较上涨与下跌幅度, ATR 汇总价格范围, VWAP 则汇总实际成交.

多个指标同时给出相似信号, 可能只是反复使用了相同价格变化. 下面先说明各自的计算, 尤其是窗口, 初始化和零分母等会直接改变结果的约定, 再讨论它们适合怎样的规则.

MACD: 两个指数滤波器之差 给定快速, 慢速和信号跨度 $n_f < n_s$ 与 n_{sig} , 令

$$\begin{aligned} \text{MACD}_t &= E_t^{(\alpha_f)}(S) - E_t^{(\alpha_s)}(S), \\ \text{Signal}_t &= E_t^{(\alpha_{\text{sig}})}(\text{MACD}), \\ \text{Hist}_t &= \text{MACD}_t - \text{Signal}_t, \end{aligned}$$

通常取 $\alpha_j = 2/(n_j + 1)$, 常见跨度为 (12, 26, 9). 这些参数规定观察多长的历史, 并不是对所有市场都有特殊意义的常数.

MACD 先计算快慢线的差, Signal 再对这个差作平滑, Hist 表示当前差值高于或低于它自己的平滑结果多少. 图上即使画成柱状, 也没有使用成交量, 不应把它看作为成交量直方图. 它也不能未经推导就称为价格加速度.

三个量都保留价格单位. 对不同价格尺度的资产比较大小时, 可以另定义百分比版本, 但应相应说明公式. 每层 EMA 还都有初始化影响, 不能只给三个跨度就忽略预热方式.

Bollinger Bands 与滚动标准化分数 这里明确采用窗口总体方差口径. 令

$$\begin{aligned} M_t^{(n)} &= \frac{1}{n} \sum_{j=0}^{n-1} S_{t-j}, \\ \hat{\sigma}_{t,n}^2 &= \frac{1}{n} \sum_{j=0}^{n-1} (S_{t-j} - M_t^{(n)})^2, \\ B_{t,\pm} &= M_t^{(n)} \pm k \hat{\sigma}_{t,n}. \end{aligned}$$

当 $\hat{\sigma}_{t,n} > 0$ 时, 滚动分数为

$$z_t^{(n)} = \frac{S_t - M_t^{(n)}}{\hat{\sigma}_{t,n}}.$$

本节方差分母取 n , 与使用 $n-1$ 的结果不同. 窗口价格完全相同时, 标准差为零, 标准化分数没有定义; 交易规则应规定此时不计算该信号或如何沿用此前决定, 而不是让除零结果决定持仓.

两倍标准差带也不是固定概率的预测区间. 这里的均值和标准差来自同一个滚动价格窗口, 当前值还参与了估计; 价格本身未必服从平稳正态分布. 因而越带不能直接解释为一个约 5% 概率事件.

带宽说明最近价格分散到什么程度, 越带说明当前值位于窗口的什么位置. 顺势规则可以在向上突破时买入, 逆势规则可以选择相反动作. 方向来自另行规定的交易假设, 不是带宽公式已经给出的答案.

RSI: 上涨与下跌幅度的 Wilder 平滑比 令 $\Delta S_t = S_t - S_{t-1}$, 并定义

$$G_t = \max(\Delta S_t, 0), \quad L_t = \max(-\Delta S_t, 0).$$

对长度 n , 先用前 n 个变化初始化

$$\bar{G}_n = \frac{1}{n} \sum_{j=1}^n G_j, \quad \bar{L}_n = \frac{1}{n} \sum_{j=1}^n L_j,$$

之后使用 Wilder 平滑

$$\begin{aligned} \bar{G}_t &= \frac{(n-1)\bar{G}_{t-1} + G_t}{n}, \\ \bar{L}_t &= \frac{(n-1)\bar{L}_{t-1} + L_t}{n}. \end{aligned}$$

为避免先计算比值造成零分母, 可以直接写成

$$\text{RSI}_t = 100 \frac{\bar{G}_t}{\bar{G}_t + \bar{L}_t}.$$

若平滑后的下降幅度为零而上涨幅度为正, RSI 取 100; 反过来取 0. 两者同时为零时, 公式分母为零, 本节另外约定 RSI 为 50. 沿用前值等其他约定会产生不同结果, 复算时不能混用.

RSI 较高表示近期平滑后的上涨幅度占比较大, 并没有直接估计下一期上涨的概率. 强趋势中这一比例可以长时间偏高或偏低, 所以高位不必立即转向.

若以 RSI 交易, 要明确是在高位继续顺势, 还是等待回落后退出, 抑或反向下注. “超过阈值”与“刚从下方穿过阈值”也会产生不同订单. 最后仍在约定的下一交易时点成交.

真实波幅与 ATR 令 H_t, L_t, C_t 分别为第 t 个价格柱的最高, 最低和收盘价. 真实波幅为

$$\text{TR}_t = \max \{H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|\}.$$

只用 $H_t - L_t$ 会漏掉整根价格柱相对于前收盘的跳空. 加入另外两项后, 即使本期内部波动很小, 跨期缺口也会进入 TR.

计算首个 TR 需要窗口前的收盘价 C_0 , 因而先由 H_1, L_1, C_0 得到 TR_1 . 累积到 n 个有效值后初始化

$$ATR_n = \frac{1}{n} \sum_{j=1}^n TR_j,$$

随后对 $t \geq n+1$ 使用

$$ATR_t = \frac{(n-1) ATR_{t-1} + TR_t}{n}.$$

这就是 $\alpha = 1/n$ 的 Wilder 平滑. 本节在预热期不输出 ATR, 缺少前收盘的首根价格柱记为缺失, 不悄悄用柱内高低差替代并加入初始平均.

ATR 仍以价格单位计量, 高值表示近期范围较大, 没有给出方向. 可在正价格下除以价格得到相对尺度, 但它仍不是未来最大亏损或实际订单滑点的上界. 拆股和异常价格柱若没有处理一致, 也会通过 TR 进入随后多期的 ATR.

VWAP: 成交基准而非自动预测器 VWAP 直接使用成交记录. 固定交易窗口 W 和纳入规则, 令 $\mathcal{E}_t(W)$ 是截至 t 已收到的合格成交. 对成交价 p_i 和数量 v_i , 定义

$$VWAP_t = \frac{\sum_{i \in \mathcal{E}_t(W)} p_i v_i}{\sum_{i \in \mathcal{E}_t(W)} v_i},$$

分母要求为正. 它等于这批成交的总金额除以总数量, 成交量更大的价格取得更大权重. 窗口按交易日还是执行时段重置, 都属于定义.

这个量适合回答指定期间市场大致在哪里成交, 因而可以作为执行比较基准. 买入和卖出对价格优劣的判断相反, 自己的大额订单也可能进入基准并改变价格, 所以不能只看是否低于 VWAP 就宣布执行较好.

若只有价格柱的典型价和总成交量, 得到的是近似 VWAP, 不能恢复柱内每笔交易. 成交筛选, 消息到达时间和柱级公式见第9.12.3小节. 用它产生方向信号时, 则需要另行规定为什么相对这个成交平均的位置值得交易.

一张分类表

指标	主要测量	没有直接测量	典型陷阱
SMA / EMA	历史水平的平滑位置与不同记忆长度	未来收益, 基本价值, 可执行价格	忽略初始化; 把降噪当预测; 用当前收盘信号假成交于当前收盘
MACD	快慢指数滤波器之差及其再平滑	成交量, 因果机制, 无条件“加速度”	跨价格尺度直接比较; 软件跨度与 α 口径不一致
Bollinger / z	当前价格相对滚动中心和离散程度的位置	固定尾部概率, 方向, 长期均衡价值	混用 n 与 $n-1$; 零方差; 把越带自动解释成反转
RSI	平滑后上涨与下跌幅度的相对占比	上涨概率, 绝对波动, 必然反转点	混用 Wilder 与标准 EMA; 零分母; 阈值方向未定义
ATR	含跳空的近期价格范围尺度	方向, 尾部上限, 给定订单的滑点	公司行为未调整; 把历史范围当未来保证
VWAP	指定窗口内成交价格的量加权中心	基本价值, 下一期方向, 自己的反事实执行价	忘记日内重置; 把柱代理当逐笔真值; 忽略订单对市场的影响

9.7 随机过程怎样给趋势规则提供基准

同一条规则可以放到不同的概率模型中计算. 这样能够区分哪些形状即使没有额外预测信息也会出现, 哪些收益依赖特定的历史相关性.

第4.5节提供零条件平均增量的基准, 第5.5节则说明怎样在连续时间描述漂移和噪声. 下面只用这些模型明确假设的后果, 是否适合真实数据仍要另行比较.

随机游走与 GBM：图形会自然出现 先令对数价格满足

$$X_t = X_{t-1} + \mu + \varepsilon_t, \quad \mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0.$$

取独立同分布的增量就得到熟悉的随机游走。即使如此，一次实现仍会有较长的上涨段，均线交叉和突破。图形是历史增量累积的结果，并不与下一步噪声不可预测相矛盾。

这里直接规定的是对数增量的条件均值。在独立同分布且相应指数矩存在时，下一期简单价格收益的条件分布也不会因过去图形改变。不能仅凭对数噪声条件均值为零，就在没有其他条件时对非线性收益作同样断言。

连续时间的对应基准是常数系数几何 Brown 运动：

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t,$$

其中 $S_0 > 0$, W 为当前滤过下的 Brown 运动。此处 μ 是价格相对变化的漂移，对数漂移为 $\mu - \sigma^2/2$ ，与上一个离散对数方程中的参数含义应分开。

该模型具有连续正价格和 Gauss 对数增量，没有加入跳跃，随机波动率或订单簿。它说明在这些假设下，历史形状不会额外改变下一段收益分布。真实数据若显示不同规律，应查明哪项假设不合适，而不是要求模型替现实作出最终判决。

AR(1) 收益：延续与反转的最小模型 令收益满足平稳 AR(1)

$$r_t - \bar{r} = \phi(r_{t-1} - \bar{r}) + \varepsilon_t, \quad |\phi| < 1,$$

且 $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0$ 。于是

$$\mathbb{E}[r_t | \mathcal{F}_{t-1}] = \bar{r} + \phi(r_{t-1} - \bar{r}).$$

$\phi > 0$ 时，上一期高于均值会使本期条件均值也高于长期均值，出现短期延续； $\phi < 0$ 时，条件均值向相反方向偏离。这次预测信息直接来自方程中的滞后项，不必从图形外观猜测。

但相关性大小还要与交易成本比较。很小的 ϕ 即使能够统计上辨认，对应的预期收益也可能不足以覆盖换手。数据频率改变以后，收益的相关性可能改变；从一段样本估计的参数，也需要在后续时期重新检验。

漂移，潜在状态，异方差与跳跃 还可以研究漂移是否随一个未直接观察的持久因素改变。若不同情况下的平均收益确实不同，历史观测就可能帮助判断目前更接近哪一种情况。但要完成这种预测，还须说明各情况怎样演变，观测怎样产生，以及参数怎样估计，不能仅给上涨阶段取一个名称就算建立了模型。

波动率变化提出另一类问题。同样的方向信号在低波动和高波动时可能承担不同风险，即使条件均值没有变化，也会影响适合的持仓规模。公告或流动性变化引起的跳跃，则可能使过去窗口的平均值很快失去代表性。

这些原因可以产生相近的指标。快线高于慢线，既可能来自持续上行，也可能只来自一次大幅跳升。要区分解释，应继续查看事件，成交和更细的价格记录，并说明什么结果会否定当前假设。

模型的用处是让这些说法可以推导和检验。接下来暂不选择哪一种解释是真实原因，而是研究一个交易者实际能够改变的地方：同一信号出现以后，是否必须马上改变持仓。

9.8 怎样减少反复交易：缓冲区与进出场规则

价格刚超过均线就买入，刚退回均线下方就卖出，会对阈值附近的小幅波动作出很多次反应。一种改变办法是把入场和出场条件分开：空仓时要求价格明显高于均线才买，已持有时则等到明显低于均线才卖。两个阈值之间不交易，保留原持仓。

这与把均线窗口加长不同。加长窗口会改变指标本身；缓冲区可以保留同一条指标，只改变持仓怎样响应它。代价也很直接：小变化被忽略时，真正的新趋势或反转在开始阶段也可能被忽略。

两条事先写清楚的规则 仍用每日收盘后的三日 SMA, 但这里另设一段假设价格. 以价格单位表示偏离

$$x_t = C_t - M_t^{(3)}, \quad M_t^{(3)} = \frac{C_{t-2} + C_{t-1} + C_t}{3}.$$

两条规则都只做多一单位或空仓, 初始持仓均为零. 收盘后计算, 下一开盘成交, 假设所需数量都完全成交. 用 q_{t+1} 表示在 O_{t+1} 调整后持有的数量, 它只承担此后的开盘到开盘变化.

零阈值规则在偏离为正时持有, 其余时候空仓:

$$q_{t+1}^{(0)} = \begin{cases} 1, & x_t > 0, \\ 0, & x_t \leq 0. \end{cases}$$

缓冲规则取 $b = 0.50$, 在达到正阈值时持有, 达到负阈值时空仓, 中间沿用上一持仓:

$$q_{t+1}^{(b)} = \begin{cases} 1, & x_t \geq b, \\ 0, & x_t \leq -b, \\ q_t^{(b)}, & -b < x_t < b. \end{cases}$$

所以等于 $+0.50$ 时进入或维持多头, 等于 -0.50 时退出或保持空仓. $x_t = 0$ 时, 零阈值规则取空仓, 缓冲规则保持已有持仓. 初值为 $q_0^{(0)} = q_0^{(b)} = 0$.

同一路径上的逐笔比较 假定 $C_{-2} = C_{-1} = 100$, 两个账户初始现金均为 200. 为便于核算, 本例每成交一单位收取固定成本 0.10, 买卖都收, 不计利息, 分配或其他费用. 这些价格和费用只是示例假设. 表中 $\Delta q_{t+1} = q_{t+1} - q_t$ 是下一开盘实际成交的带符号数量, 正数买入, 负数卖出.

t	C_t	$M_t^{(3)}$	x_t	O_{t+1}	$q_{t+1}^{(0)}$	$\Delta q_{t+1}^{(0)}$	$q_{t+1}^{(b)}$	$\Delta q_{t+1}^{(b)}$
0	100.30	100.10	0.20	100.40	1	1	0	0
1	99.70	100.00	-0.30	99.60	0	-1	0	0
2	100.30	100.10	0.20	100.40	1	1	0	0
3	99.70	99.90	-0.20	99.60	0	-1	0	0
4	100.30	100.10	0.20	100.40	1	1	0	0
5	103.00	101.00	2.00	103.10	1	0	1	1
6	103.30	102.20	1.10	103.40	1	0	1	0
7	102.70	103.00	-0.30	102.60	0	-1	1	0
8	99.70	101.90	-2.20	99.60	0	0	0	-1

每行的 C_t 和均线在决定时已经知道, O_{t+1} 是随后才发生的成交价格. 因而价格从收盘到下一开盘的变化, 不会被新建立的持仓提前赚取.

零阈值规则先完成两次小幅往返, 都在 100.40 买入, 99.60 卖出; 第三次在 100.40 买入, 最后于 102.60 卖出. 毛损益为

$$\Pi_{\text{gross}}^{(0)} = (99.60 - 100.40) + (99.60 - 100.40) + (102.60 - 100.40) = 0.60.$$

缓冲规则只在 $O_6 = 103.10$ 买入, 到 $O_9 = 99.60$ 才卖出, 所以

$$\Pi_{\text{gross}}^{(b)} = 99.60 - 103.10 = -3.50.$$

成本按实际成交数量计算:

$$C^{(j)} = 0.10 \sum_{t=0}^8 |\Delta q_{t+1}^{(j)}|, \quad j \in \{0, b\}.$$

零阈值规则有六次一单位成交, 缓冲规则有两次, 得到

规则	毛损益	成交成本	净损益	期末现金
零阈值	0.60	0.60	0.00	200.00
缓冲区	-3.50	0.20	-3.70	196.30

期末取 O_9 的交易完成以后, 两个账户都已空仓. 零阈值规则在 O_8 的卖出费和缓冲规则在 O_9 的卖出费均已计入. 最后一行只有退出或保持空仓, 不需要再给出 O_{10} .

省下的交易与付出的等待成本 最初两次小幅往返中, 零阈值规则每次亏 0.80 价差并付 0.20 买卖成本. 缓冲规则保持空仓, 避开合计 2.00 的损失. 这正是设置缓冲区希望解决的问题.

但后面的持续上涨从同样的小正偏离开始. 零阈值规则已在 100.40 买入, 缓冲规则等到 103.10 才买入, 少取得 2.70 的上涨. 下跌开始时, -0.30 还在缓冲区内, 它又保留多头, 最后比零阈值规则晚退出, 多承受 $102.60 - 99.60 = 3.00$ 的下跌. 这两项等待代价超过了前面避免的反复交易损失.

所以本例的缓冲规则虽然交易更少, 净结果反而落后 3.70. 缓冲区没有辨认哪次小变化是噪声, 哪次是真正转向; 它只是统一地选择等待. 窄区间反复波动时可能受益, 快速起涨或反转时则可能付出代价. 这段假设路径用来拆开计算这些作用, 不用于证明哪个阈值未来更赚钱.

入场和出场阈值也可以不对称, 例如空仓时要求更强确认, 持仓后采用较近的退出条件. 这会改变错过上涨与继续承受下跌的取舍, 应连同等号, 初始持仓和成交时钟重新规定, 再放到未用于选参数的数据中比较.

缓冲区还带来一个重要变化: 规则有记忆. 当当前偏离为 0.20 时, 原来空仓就继续空仓, 原来持有就继续持有. 只知道当前指标已经不足以确定动作, 还需要此前持仓. 下一节继续看, 即使不考虑持仓记忆, 同一个指标值又会遗漏哪些价格历史.

9.9 指标相同, 状态可以不同

上一节中, 当前信号相同, 先前持仓不同, 就可能采取不同动作. 还有另一种信息损失: 不同的价格路径本身也会给出相同指标.

考虑

$$A = (97, 98, 99, 101, 105),$$

$$B = (103, 99, 96, 97, 105).$$

两段五日收盘价的总和都是 500, 当前价格都是 105, 所以五日 SMA 均为 100, 相对偏离均为 5%. 只按这一偏离计算的无记忆信号会给出相同结果.

但第一段逐步上行, 第二段先下跌再大幅回升. 它们包含不同的逐日变化, 也可能对应不同的成交与消息. 五个收盘价本身没有说明回升是否来自隔夜跳空, 更没有直接证明某个持久因素存在.

若一个经过说明的模型让这两段历史对应不同的潜在情况, 下一期条件分布就可能不同. 在独立增量模型中, 过去路径的这种差别又未必有预测作用. 是否值得保留更多历史细节, 因而取决于它们是否帮助回答后续问题.

增加 ATR, 成交量或更高频数据可以补充信息, 也会增加估计和选择参数的机会. 应检验新增信息实际改善了什么, 而不把指标数量当成对市场理解的深度.

9.10 从漂亮回测到可信检验

先写净损益, 再谈收益表现 先从定义一致的毛损益扣成本. 若 $\Pi^{\text{mark/exit}}$ 根据未计执行摩擦的基准价格计算, D^{dist} 是尚未包含其中的实际分配, 可以写为

$$\begin{aligned} \Pi^{\text{net}} = & \Pi^{\text{mark/exit}} + D^{\text{dist}} - C^{\text{spread}} - C^{\text{slippage}} - C^{\text{impact}} \\ & - C^{\text{fees}} - C^{\text{funding}} - O^{\text{other}}. \end{aligned}$$

各项应互不重叠. 若已经用实际买卖均价计算价差损益, 点差和价格偏移已经体现在其中, 就不再另外扣一次. 分配若已通过总回报序列计入, 也不重复相加. 尚未退出的中间价估值则仍含未实现损益.

每次调仓只向一个方向成交时, 单位数量的换手为

$$\text{UnitTurnover} = \sum_t |q_{t+1} - q_t|.$$

若同一统计区间内先买后卖, 不能只看区间末的净数量变化, 应把各次成交分别计入. 对单位数求和得到的是交易数量, 还不是相对于资本的无量纲换手率.

对正成交价格 and 正净资产, 若一次调仓从 q_t 改为 q_{t+1} , 成交价为 S_t^{exec} , 调仓前净资产为 $A_{t-} > 0$, 一种名义换手率定义为

$$\text{Turnover}^{\text{notional}} = \sum_t \frac{S_t^{\text{exec}} |q_{t+1} - q_t|}{A_{t-}}.$$

合约还须按乘数换算, 跨币种金额按当时汇率换成同一货币. 对可能出现非正报价或其他特殊计价的合约, 应另外说明名义规模的定义, 不机械套用正价格公式.

换手帮助估计交易成本, 但同样名义金额在不同深度和不同方向上未必付出相同代价. 因而成交量之外, 还要看订单相对市场有多大.

第9.8节的两条规则交易量分别为六单位和两单位, 对应成本 0.60 与 0.20. 这项差别直接来自持仓规则. 但较少成本没有弥补晚买晚卖的价格损失, 所以应同时报告毛损益与成本, 不只展示换手下降.

实际策略还会因为合约换月或组合风险缩放而调仓. 这些交易与方向信号触发的买卖应分开记录, 才能知道成本从哪里来; 相关的换手和成本比较见 [BK20].

波动放大时, 点差和滑点也可能变差. 把整个样本的平均成本回填每一天, 会掩盖最需要退出时的交易困难. 资金规模增加后, 同一权重规则需要更大的订单, 执行结果也可能改变. 关于报价深度和订单规模, 见第7.8节与第7.8.8小节.

波动率缩放, 杠杆和路径风险 方向确定以后, 还可以按预计波动决定承担多少. 常见规则是

$$|w_{t+1}^*| \propto \frac{\sigma^{\text{target}}}{\hat{\sigma}_t},$$

其中 $\hat{\sigma}_t$ 只使用截至 t 的信息, 并要求为正. 波动估计较高时减少名义权重, 较低时增加, 再受持仓和杠杆上限限制. 估计为零或缺失时应另有处理, 不能让倒数产生无限仓位.

权重还不是合约张数. 实际数量要结合账户资本, 价格, 乘数和汇率换算, 然后取允许的交易单位. 风险缩放也会独自产生调仓, 即使方向信号一直没有改变.

例如, 令 $r_{i,t+1}$ 表示资产相对于同一现金账户的一期简单超额收益, $z_{i,t}$ 为方向, $w_{i,t} \geq 0$ 为对应的绝对名义权重. 在同一资本基数及相应融资假设下, 组合超额毛收益可以写为

$$R_{t+1}^{\text{port}} = \sum_{i=1}^d w_{i,t} z_{i,t} r_{i,t+1}.$$

这里的表现同时取决于方向, 风险分配和资产之间的共同变化. 若改用总收益, 还须计入现金或融资部分, 不能把超额收益公式直接当成完整账户收益.

要判断方向信号贡献了多少, 可以比较未缩放规则, 同类缩放的被动基准, 以及实际平均杠杆, 参见 [KTW16]. 只看最终组合的 Sharpe 比率, 无法把这些来源区分开.

目标波动也不保证成为实际波动. 历史估计存在滞后, 价格可以跳跃, 压力期的相关性也可能改变. 低波动时加大的持仓, 可能恰好在波动骤升时仍未降下来.

价格围绕阈值反复穿越, 使规则不断进入又退出, 通常称为 **whipsaw**. 第9.8节已经逐笔算出了这种往返怎样损失价差并支付成本, 也说明减少切换为什么可能使后来的反转损失更大.

另一种困难是趋势缓慢建立后突然反向跳跃. 旧窗口来不及更新, 较大的持仓还在承受变化, 融资条件也可能同时收紧. 若许多参与者使用相似规则, 集中退出还可能增加执行成本. ATR 和止损阈值描述历史尺度或行动条件, 不限制停牌或缺乏报价时最终能够承受的损失.

图9.5保留同一组 20 日和 100 日 SMA, 比较两个历史窗口. 2017 年中快线始终在慢线上方, 2015–2016 年中方向关系则翻转了 8 次. 若直接以这个关系决定多头或空仓, 后一窗口就会产生更多目标变更.

红点只表示信号关系改变. 是否每次都交易, 要看有没有缓冲区或其他进出场条件; 在何时, 以什么价格交易, 则取决于成交规则. 因而图用于观察反复穿越, 具体损益仍要像前面的算例一样从持仓和现金计算.



图 9.5: SPY 拆分与现金分配调整收盘价在两个历史窗口中的 20 日与 100 日 SMA. 上图对应 2017 年, 下图对应 2015—2016 年; 红点标记快线与慢线方向关系的翻转; 每个面板下方的蓝色条带表示 20 日 SMA 高于 100 日 SMA, 灰色表示该判断不成立. 数据来源见引用文献 [Yahb; Yahc].

样本外, 走步验证与参数冻结 先固定要研究的规则, 包括价格定义, 观察和成交时钟, 信号与持仓公式, 成本和评价方法. 参数只在训练期选择, 然后冻结, 用后续数据检验. 走步验证可以按时间推进, 在每次重新训练时只使用那以前已经取得的资料.

报告结果时, 同时给出毛收益, 各项成本, 换手和风险表现, 并保留表现不好的市场与参数. 缓冲区如果只是少交易, 就应看见相应成本减少; 若声称改善了进出场, 还要在毛结果和各类转向中看见支持.

反复查看测试结果再调阈值, 会让原来的测试期参与开发. 最后仍需保留真正没有用于选择的数据. 参数稳健也不只是在最好点旁边还能找到盈利值, 更要看合理范围内的规则是否有一致解释, 成本以后是否仍有相似效果.

数据偏差与多重检验 历史可投资集合应包含当时存在而后来退出的证券, 不能只从今天仍上市的名单回测过去. 指数成分, 财报和修订记录也须按当时可得版本使用, 否则规则会得到真实交易者当时不知道的信息.

时间对齐同样会改变结果. 不同市场的收盘发生在不同时间, 日线中的 20 期与分钟线中的 20 期不是同一记忆长度. 原始价格, 拆股调整价和总回报数据也应与实际分配计算一致, 不能一边使用含分红再投资的序列, 一边再加同一笔分红.

如果看过全部数据以后才挑资产, 起点, 窗口, 缓冲宽度或止损, 就已经进行了规则选择. 尝试越多, 越容易出现一个偶然较好的结果. 对最终赢家报告一个仿佛它事先固定的普通 p 值, 没有计入这次选择. 应披露尝试范围, 使用适当的多重比较处理和独立样本外检验, 并保留候选规则之间的依赖, 参见 [STW99].

即使结果稳健, 还要与相同风险尺度的常数方向或买入持有基准比较, 分辨平均暴露与时变预测的贡献 [Hua+20]. 统计上可以辨认的差异, 最后也仍须足以覆盖合理成本.

9.11 趋势研究与基本面估值怎样配合

趋势研究从价格和成交历史出发，讨论怎样形成并执行规则。第8.1节和第8.3节则从持有权利，经营证据和未来利益出发估值。两者可以配合，但回答的问题不同。

例如，公司研究可能说明长期利益值得某个买入价格，趋势规则则规定在什么历史条件下建立持仓。后者不会因为估值有吸引力就必然在短期赚钱；一条样本外有效的趋势规则，也没有单凭历史价格解释公司能创造多少利益。

两类结论合用时，应明确各自改变了哪项决定。估值用于比较潜在回报，趋势或执行规则用于规定进入与退出，风险预算决定数量。如果实际采用的办法与单独检验过的规则不同，还须检验组合后的策略，不能直接继承原来的业绩。

最终回报属于具体的持仓，融资和退出安排。同一信号在不同费用，杠杆和流动性条件下可以产生不同结果。真正发送订单以前，仍要依据当前账户，未完成交易与可执行报价作出相应决定，而不是把研究中的信号直接视为已经完成的交易。

9.12 实现补充：数据，活动订单与现金记录

前面的例子假定每次都全部成交。实际复算还会遇到合约换月，未完成订单和延迟到达的成交记录。下面分别说明这些情况怎样影响所用价格，待交易数量和现金余额，以免把图上的目标持仓误当成真实账户。

9.12.1 期货与远期的合约和换月记录

连续期货曲线通常由不同到期合约拼接而成。计算信号时可以使用这条曲线，计算盈亏时却要

知道当时实际持有哪一张合约，何时卖出旧合约并买入新合约。

因此，每段交易记录都应保留实际合约名称，到期日，乘数，报价与结算币种。换月规则必须只使用当时已知的信息。若用成交量或持仓量选合约，就不能先看完整历史，再把后来确定的最活跃合约回填到此前决策。

合成曲线还要说明是直接拼接，差额调整还是比例调整。这些处理会改变历史价格和指标，却不

代表投资者能按调整后的历史数值成交。实际收益应从具体合约价差，乘数，换月成交及明确资本基数计算。

抵押品收益，变动保证金，汇率变化和换月费用也分别记录。变动保证金若已经把一段价格盈亏计入现金，后面就不能再把同一段价差当成额外利润。合成曲线用于观察和发出信号，合约与现金记录用于核对实际结果。

9.12.2 活动订单与逐事件现金账

部分成交时，目标减去当前持仓不一定就是应追加的新订单，因为此前发出的余量可能仍在等待成交。再把同样数量下一次，就可能超出目标。

令 $q_t^{\text{confirmed}}$ 为已确认成交形成的持仓， $O_t^{\text{live/pending}}$ 记录仍有效或尚待确认而可能成交的订单。同一改单的新旧版本须按交易场所规则整理，不把互相替代的版本当作两张独立订单。对订单 j ，买入符号为 $\epsilon_j = 1$ ，卖出为 -1 ，剩余可能成交数量为 $\text{LeavesQty}_{j,t}$ 。合计余量为

$$L_t^{\text{live}} = \sum_{j \in O_t^{\text{live/pending}}} \epsilon_j \text{LeavesQty}_{j,t}.$$

若这些余量全部成交，持仓将达到

$$q_t^{\text{projected}} = q_t^{\text{confirmed}} + L_t^{\text{live}}, \quad \Delta q_t^{\text{new}} = q_{t+1}^* - q_t^{\text{projected}}.$$

前一个量用于安排后续订单，不当当成已经持有的数量计算盈亏。后一个差额也只是候选调整量；目标反向时，可能应先撤销旧单，而不是立刻发送相反的新单。

新单尚未收到接受或拒绝回报时，不能假定它不存在。撤单请求尚未确认时，原单也可能继续成交。部分成交回报到来，则同时增加已确认持仓并减少订单余量。改单被拒是否保留原单，要按具体场所规则处理，与新单被拒的后果分开。

确认这些数量以后，还要考虑交易单位，券源，保证金，价格限制与交易时段。限价和排队可能使订单只成交一部分。这些执行问题详见第7.8节和第7.8.8小节，以及 [AC01; Har02; Has07]。

若一段区间内持仓固定, 可以先按下面的近似计算:

$$\Delta\Pi_t = q_t(S_t - S_{t-1}) + q_tD_t - C_t^{\text{trade}} - C_t^{\text{funding}} - O_t^{\text{other}}.$$

q_t 在区间开始时已知, D_t 表示本区间每单位实际分配, 此处不是累计分配. 若价格只用于标记, 计算中仍有未实现盈亏; 若成本已经包含在实际成交价中, 则不再从费用项扣第二次.

发生多次成交或收付时, 可按第7.1.5小节和第6.7节逐次记录. 对事件 e , 成交数量 Δq_e^{fill} 买入取正, 卖出取负, 非成交事件取零. 交易价款的净现金流入为 K_e^{trade} , 则

$$\begin{aligned} q_e^{\text{confirmed}} &= q_{e-}^{\text{confirmed}} + \Delta q_e^{\text{fill}}, \\ C_e &= C_{e-} + K_e^{\text{trade}} - f_e^{\text{trade}} + d_e^{\text{cash}} + f_e^{\text{funding,net}} + m_e^{\text{VM}} + o_e^{\text{cash}} + \Delta A_e^{\text{external}}, \\ V_e &= C_e + MV_e. \end{aligned}$$

交易费 $f_e^{\text{trade}} \geq 0$ 单独扣除. 其余项按流入为正, 分别记录分配, 融资净收付, 变动保证金, 已说明内容的其他现金项和外部净注资. 每笔实际收付只放入一项.

普通现货的价款为 $K_e^{\text{trade}} = -p_e^{\text{exec}} \Delta q_e^{\text{fill}}$, 数量取该笔交易的实际成交量. 若成交与结算不在同一时刻, 成交先确认库存及应收应付, 结算时再收付价款. 等待结算的资产和负债也须计入净财富, 不能只看可用现金.

因此, MV_e 应包括未平仓持仓, 未结算应收应付, 以及未在现金中列出的相关资产与负债净值. 有融资时, 借款现金进入账户也要同时记录债务, 否则会把借来的钱算成利润. 只有在没有这些额外项目的简单现货账户中, 才可直接取 $MV_e = q_e^{\text{confirmed}} S_e^{\text{mark}}$.

期货建仓通常不收付合约全部名义价款, 该交易价款项为零, 保证金和变动保证金另按实际收付记录. 若 C_e 只含可用现金, 受限保证金须保留在其余资产中; 两者之间划转不改变总财富. 价格盈亏已经通过变动保证金结算以后, 剩余合约价值按相应结算基准计算, 不能再把期货报价乘张数加成账户资产.

未成交订单和撤改单请求不产生已成交持仓的盈亏. 最终按财富变化计算策略损益时, 再剔除外部净注资. 这与前面两个算例在全部平仓后比较期末现金和初始现金的做法相同, 只是把中间更多种收付逐一记录下来.

9.12.3 VWAP 的成交筛选与到达时间

一笔成交实际发生的时间 τ_i , 与系统收到记录的时间 a_i 可能不同. 在 t 时决策, 只能使用此前已经收到的消息. 因而对指定交易窗口 W , 合格成交集合定义为

$$\mathcal{E}_t(W) = \{i : a_i \leq t, \tau_i \in W, e_i(t) = 1\}.$$

$e_i(t)$ 表示根据当时已收到的成交条件, 撤销和更正消息, 这笔记录是否符合预先规定的纳入条件. 是采用综合市场还是单一场所, 是否纳入竞价, 场外成交和碎股, 都会影响加权结果.

按此集合计算前面的 VWAP, 并要求总成交量为正. 若只有价格柱, 可以用典型价 $TP_j = (H_j + L_j + C_j)/3$ 近似每柱成交价格, 得到

$$\widetilde{\text{VWAP}}_t = \frac{\sum_{j \leq t} TP_j V_j}{\sum_{j \leq t} V_j}.$$

求和仅使用指定窗口内已经可用的价格柱, 分母同样须为正. 这通常不等于逐笔 VWAP, 因为最高, 最低和收盘价没有保留柱内各价格实际成交了多少.

价格柱本身也应使用一致的成交筛选方式生成. 后来才到达的更正可以修订事后统计, 却不能回填成当时交易者已经知道的数据. 复算信号时保留这一区别, 才能让指标的可测性与实际信息取得时间一致.

9.13 小结

指标先概括已经发生的价格或成交, 规则再决定此后怎样持仓. 图9.4中的每一步都要落实到时间和数量: 何时知道信号, 何时成交, 实际持有多少, 收付哪些费用. 三日 SMA 例子把这些步骤算成了最终现金, 说明一段总体上涨的收盘价仍可能对应亏损交易.

第9.8节又在同一路径上改变了进出场办法。缓冲区保留上一持仓，避开几次阈值附近的往返，同时也可能买得更晚，卖得更迟。交易次数下降与净收益改善是两件事，必须把节省的成本和改变的价格损益一起比较。

随机游走与 AR(1) 帮助分辨历史形状和条件预测，波动率与持仓缩放则帮助分辨方向和风险规模。规则的实际贡献，最后仍要在参数选择之外的数据中，用一致的成交和成本假设检验。

第A.11节将继续讨论制度变化。交易规则，清算安排和公共支持改变以后，同一个指标公式可以仍然算得出来，它面对的价格规律和实际交易条件却可能已经不同。

附录 A 金融市场制度史：危机如何塑造今日结构

今天看到的金融市场没有一张先验完整蓝图，它在长期冲突，危机与修补中逐步形成。它更像一座长期有人居住的城市：旧街道决定新管线能够铺在哪里，每次火灾又迫使人们增加新的防火墙，水源和疏散通道。中央银行，存款保险，证券披露，交易所自律，中央清算，熔断机制，宏观审慎监管和稳定币储备规则，都带着某一次历史压力测试留下的痕迹。

先从荷兰商人的远洋融资和英国政府的借款看起，再进入美国的交易所，银行与证券市场。新的筹资办法让更多人参与投资，也使贷款，抵押和短期付款逐渐连接起来。后来的危机往往沿这些联系扩散，处置办法又改变了下一次交易的条件。

理解一次危机，要把最初的损失与后来为什么扩大分开。股价下跌先使持有人亏损；若持仓靠短期借款融资，债权人又同时要求还钱，投资者就可能被迫卖出其他资产。若这种压力进一步妨碍银行付款或核心市场融资，问题已经超过最初那只证券的估值。

因此，泡沫，暴跌和系统性危机不是同一件事。某项资产从很高价格回落，未必破坏支付体系；2020 年 3 月的美债市场失灵，也不需要先假定美债存在价值泡沫。Mishkin and White [MW02] 在比较美国股灾时强调的正是这种区别：政策需要处理的金融不稳定，取决于损失怎样传到其他机构和市场。

下面会具体追踪当事人怎样借钱，怎样要求付款，谁提供了临时资金，最后又由谁承担损失。同样的价格变化，在有存款保险，清算担保或央行融资的条件下，可以引起不同反应。制度史因而也帮助我们理解，为什么不同时期的价格数据未必服从同一套规律。

先把几项主要制度与后文的历史事件列在一起：

今天的结构	关键压力测试	留下的制度含义
央行货币与最后贷款人	英国十九世纪恐慌，美国 1907 年恐慌	把私人银行家与清算所临时承担的部分流动性功能，转入可重复且有法定授权的公共机制
存款保险与银行处置	美国 1930–1933 年银行危机，1980 年代储贷危机，2023 年地区银行危机	区分流动性支持，损失吸收，破产处置与存款人保护
联邦证券披露与交易所监督	1929 年股灾和大萧条	私人交易所继续运营，但在联邦法律，美国证券交易委员会 (SEC) 监督和自律组织框架下承担公共义务
全国市场与现代清算结算	1968–1970 年代证券后台处理危机 (paperwork crisis)，1975 年证券法修正	竞争性交易场所通过行情，路由，托管和清算基础设施连接起来
熔断，保证金与跨市场监测	1987 年股灾，2010 年闪电崩盘 (flash crash)，2021 年 meme stock 事件	把现货，期货，期权，经纪商和清算机构看成同一个动态系统
宏观审慎与非银监管	1998 年 Long-Term Capital Management (LTCM)，2007–2009 年危机，2020 年抢夺现金 (dash for cash)	监管对象从单家银行扩展到融资网络，中央对手方，基金杠杆和核心市场功能
数字私人货币的储备与赎回规则	2022 年加密资产动荡及稳定币挤兑风险	技术形式可以改变，面值承诺，储备透明度，托管和挤兑问题仍然存在

A.1 荷兰前史：股份怎样让长期投资可以转手

远洋贸易需要先支付船只，人员和货物的成本，经营结果却可能多年以后才揭晓。如果每次航行分别集资，投资者就要等待航程结束才能收回资金。1602 年成立的荷兰东印度公司 (Vereenigde

Oostindische Compagnie, VOC) 把多次航行纳入持续经营的公司, 可转让股份又让持有人能够在公司继续使用资本时自行退出。

关键是把两件事分开: 投资者想收回资金, 不必要求公司立即变卖船只或终止经营, 可以把股份卖给另一位投资者。公司保留经营所需资本, 买卖双方则转移对未来利益的请求权。股份逐渐还能支持信用交易和抵押融资, 二级市场与配套金融活动由此一起发展 [GJ04]。

这些股份最初是在公司账簿上登记的权益, 与后来标准化的无记名股票不同。VOC 的经营也依赖国家特许, 殖民垄断和强制权力。理解股份带来的融资便利, 不能把产生这些利益的政治和殖民关系从历史中删去。

交易扩大以后, 买方还要能可靠地向卖方付款。成色不同的硬币, 私人信用和远距离支付使金额难以比较。1609 年成立的阿姆斯特丹汇兑银行 (Bank of Amsterdam) 用账户转账支持大额结算, 在相当长时间内提供了较稳定的银行货币。商人可以转移账户余额, 不必每次搬运和检验同样一批硬币。

但结算信誉也取决于银行怎样管理资产。后来的隐蔽贷款, 财政支持不足和信心丧失, 使这家银行走向衰落。它留下的经验不是中央银行必然成功, 而是广泛使用的结算货币需要相应的资产管理和治理来维持 [FSW20]。

1636–1637 年的郁金香投机发生在另一种交易安排中。参与者越来越多地买卖未来交付花球的承诺, 不只交换现货。这些承诺可以继续转手, 却没有后来期货市场整套的保证金, 逐日结算和集中履约安排。报价迅速上升以后, 交易又突然萎缩, 原先的承诺究竟能否兑现便成为问题。研究认为, 其对荷兰整体经济的冲击远小于常见故事所描绘的程度 [MT17]。一项投机交易崩塌, 与整个金融体系陷入危机, 在这里仍须区分。

1720 年的股票投机则横跨伦敦、巴黎和阿姆斯特丹。英国南海公司和法国密西西比公司把政府债务转换, 特许权和股票发行联系起来, 其他贸易与保险公司的证券也受到影响。股价既包含对新经营机会的判断, 也受到融资条件, 可售股份数量和继续转卖预期的推动。

Frehen, Goetzmann, and Rouwenhorst [FGR09] 对不同证券价格的比较显示, 市场确实在区分并重新评价大西洋贸易和股份制保险等创新。这比把所有上涨都归为同一种非理性更具体。但真实机会的存在没有保证任意股价都合理, 新业务前景与过高的购买价格可以同时成立。

股份转让解决了长期投资者中途退出的问题, 银行货币帮助完成结算, 证券融资又让参与者以更少自有资金持有股份。市场因而能组织更多资本, 同时也让一项经营损失有机会沿借贷关系影响其他人。

A.2 英国前史：政府借款与最后贷款人的形成

1694 年, 英国政府为对法战争筹资, 投资者认购一家新银行的股份, 银行再把资金贷给政府。这家私人持股机构就是英格兰银行。它后来承担的中央银行职责, 并不是成立当天已经完整具备, 而是在政府融资, 银行业务和历次危机中逐渐形成 [Ban24]。

证券交易也先由私人组织起来。1698 年前后, 伦敦经纪人在咖啡馆发布股票和商品报价; 到 1801 年, 经纪人与交易商才建立受正式规则管理的交易所 [Lon]。集中报价和会员惯例使交易更容易完成, 政府随后逐步承认并监督这些安排。

1720 年的南海泡沫将证券市场与公共债务紧密联系。南海公司参与政府债务转换, 又以政治特许和未来贸易前景吸引股票投资。其中的 *asiento* 奴隶贸易权依赖国家强制和殖民扩张, 涉及对被奴役者的买卖, 不能仅写成一项普通商业创新 [UK 25]。股价因而同时受政府信用, 公司筹资和对特许利益的预期影响, 转售投机又进一步推动上涨。

Bubble Act 在繁荣期间就已通过。南海公司还希望借它限制竞争公司的筹资, 所以不能把这部法律讲成泡沫破裂以后才制定的现代投资者保护措施。对史料的研究也表明, 它对后来公司组织的限制没有通俗叙事所说的那样全面 [Har94]。这次事件使政府债务, 公司治理和政治关系难以再彼此分开研究。

十九世纪的恐慌提出了另一个紧迫问题。持有人都想把票据和存款换成现金, 银行却不可能立即收回全部贷款。1844 年 Bank Charter Act 强化了英格兰银行的纸币发行地位, 1847, 1857 和 1866 年的流动性危机仍然发生。1866 年大型票据经纪商 Overend Gurney 倒闭时, 英格兰银行没有救助这家被判断为资不抵债的机构, 却向其他市场参与者供给资金, 防止它的失败引起更广泛的付款中断。

后来所称的 Bagehot 原则, 概括了这种区别: 恐慌中向有良好抵押品的借款人充分供给流动性, 同时以较高利率减少没有必要的借款和对救助的依赖。历史贷款账簿显示, 英格兰银行十九世纪中

期的做法大体符合这条后来总结的路线, 具体危机与贷款仍有差异 [Ans+17].

临时贷款解决的是今天付不出现金. 若资产即使正常回收也不足以偿债, 增加一笔贷款只会同时增加现金和负债, 并没有填上原来的损失. 但在恐慌当天, 资产能够回收多少往往最难判断, 流动性不足与偿付能力不足也会互相加重: 为筹现金低价卖出, 可能使原本只是缺钱的机构真的遭受资本损失.

这一问题在 2022 年的英国 LDI 事件中再次出现. 政府财政声明引起长期国债急剧重定价, 部分采用杠杆的负债驱动投资 (liability-driven investment, LDI) 策略需要追加抵押品和保证金. 为取得现金而卖出国债, 又压低其他持有人抵押品的价格, 引起进一步追加和出售. 英格兰银行通过临时, 定向的国债购买缓解这一过程 [Ale+23; Ban22].

从 1866 年的票据市场到 2022 年的国债市场, 供款工具已经不同, 处置仍要区分两项任务: 防止集体求现破坏市场, 以及确认资产损失最后由谁承担. 临时支持能争取处置时间, 不能代替后一个决定.

A.3 从 Buttonwood 到 1907 年: 私人组织怎样交易与救急

美国证券市场先有经纪人的协议, 后有持续的联邦监督. 1792 年, 二十四名纽约经纪人与商人签署 Buttonwood Agreement, 约定彼此优先交易并设最低佣金. 1817 年建立的 New York Stock & Exchange Board 进一步规定会员和交易时段, 按固定时间逐只证券集中撮合, 即 call market [Newb].

这些规则既保护会员收入, 也帮助交易完成. 会员知道与谁交易, 遇到违约有共同处理办法, 报价也能在同一地方比较. 但它首先服务成员, 无法仅凭会员协议保护所有外部投资者, 更不能为全国金融体系提供紧急资金.

银行同样依赖局部协调. 单一银行制 (unit banking) 限制跨地区分支, 使银行不易分散当地风险; 州与联邦监管分开, 货币又难以随季节性需求及时增加. 纽约清算所能帮助成员银行结算, 在压力时发行清算凭证并相互支持, 却没有完整覆盖信托公司和全国支付需要 [Cal09; Fedh].

1907 年 10 月, United Copper 股票逼仓失败, 与之有关的中介信誉受损, 提款随后扩散到纽约信托公司. Knickerbocker Trust 停止支付以后, 更多持有人要求取得现金. 银行, 信托公司和证券融资市场同时受到压力, 可随时收回的经纪贷款 call money 利率急升. 经纪会员如果无法继续融资, 交易所也难以维持正常交易.

J. P. Morgan 利用私人关系收集银行与信托公司的财务资料, 判断哪些机构还有可回收资产, 哪些已经承担无法弥补的损失. 他再召集银行家共同出资, 支持交易所及被认为仍能存续的机构. 个人信誉在这里帮助互不信任的出资者采取共同行动, 但实际现金并非只来自他一个人.

纽约清算所同时发行贷款凭证, 成员银行协调限制存款兑付; 财政部则把政府资金存入银行. 信托公司没有参加同样的兑付限制, 更显出私人会员安排覆盖不全. 这些行动连同海外黄金流入等因素, 逐步缓和恐慌 [MT].

这次救助说明私人协调有能力, 也说明它不够可靠: 下一场恐慌未必还会有一位拥有相同财富, 信息和声望的人及时召集全市场. 1908 年 Aldrich-Vreeland Act 先安排紧急货币并设立 National Monetary Commission, 1913 年 Federal Reserve Act 再建立含十二家地区储备银行的美联储体系 [Fedi].

后来并非由美联储一并接下 Morgan 当时做过的所有判断. 提供流动性, 保护存款, 处置失败机构与监督证券市场逐渐分给不同机构. 下表将当时的临时工作与后来形成的分工对应起来:

1907 年的私人功能	今天主要由谁承担	不能被简单替代的部分
召集银行共同出资	Fed, Treasury, FDIC, 监管者和私人机构按权限协调	危机中的共同判断仍需要具体人员和可信关系
为有抵押品者供给现金	Fed 贴现窗口, 回购 (repo) 工具及紧急流动性设施	央行贷款不能自动修复负资本
判断机构是否可救	银行监管者, FDIC 处置机制, Treasury 和法院	资产在压力下的真实价值仍有不确定性
保护交易所融资和市场功能	Fed 市场操作, SEC 监督, 交易所规则和清算机构	私营做市商和交易商资产负债表仍是第一道缓冲
用个人信誉稳定预期	有法律授权, 披露和问责的公共承诺	公共承诺本身也可能产生道德风险和政治争议

美联储使银行间结算与紧急流动性供给能够在法定安排下重复进行, 不再每次都从头寻找私人出资联盟。证券监督, 存款保护和失败机构的损失处理, 则还需要其他法律与机构。

召集私人机构共同解决问题的做法也没有消失。1998 年, 纽约联储召集十四家私人机构为 Long-Term Capital Management (LTCM) 安排资本重组 [McD98]。公共机构参与协调与公共资金承担损失是两件事, 后面将继续说明这次重组。

A.4 1913–1935 年：央行怎样在危机中改变

1913 年的法律建立了能够提供弹性货币的机构, 还没有解决各类危机发生时该怎样行动。十二家地区储备银行, Washington 的理事会和后来形成的 FOMC, 兼顾地区参与和全国决策。这种安排有助于取得政治支持, 也可能使不同地区对风险和供款采取不同判断 [Fedi; GM13]。

第一次世界大战很快扩大了美联储的工作。财政部发行 Liberty Bonds 筹集战争资金, 美联储协助销售与支付, 银行和经纪商向家庭推广债券。数以千万计的家庭由此接触政府证券, 公共债务市场不再只面对少数专业投资者。这种普及同时包含投资机会, 公民动员和销售压力 [Gar]。

1920 年代, 大众证券参与又与新技术前景和保证金融资结合。股票上涨时, 借款放大持有收益; 价格下跌以后, 同一融资安排却会使投资者需要更快取得现金。1929 年 10 月崩盘后, 纽约联储通过公开市场操作增加银行准备金, 支持证券融资与支付继续进行 [RKG]。

但 1930–1933 年的银行危机仍不断加深。银行倒闭和提款压力削弱存款与信贷, 通缩增加既有名义债务的实际负担, 企业和家庭又进一步缩减支出。国际金本位限制政策选择, 美联储内部判断和行动也未能有效阻止恶化 [GM13]。因而大萧条不能仅用 1929 年股价跌了多少解释, 还要追踪银行, 债务与货币收缩怎样互相加强。

1933 年的改革分别处理发行信息和银行风险。Securities Act 要求新证券发行承担联邦披露责任, 让投资者能够取得规定信息。同年的 Banking Act 建立 FDIC, 并设置商业银行与证券业务之间的隔离。存款保险降低受保护储户抢先提款的需要, 业务限制则试图减少某些利益冲突和风险传递。

1934 年 Securities Exchange Act 建立 SEC, 对交易所, 经纪交易商和二级市场施加持续的联邦监督。1935 年 Banking Act 强化 Board of Governors 与 FOMC 的中央决策, 改善全国货币政策的协调。到 1940 年, Investment Company Act 和 Investment Advisers Act 又进一步规定基金与投资顾问的责任 [Ric+a; Ric+b; US i]。

这些法律没有用同一种办法解决所有问题。披露让公众更容易比较发行人, 存款保险处理挤兑动机, 监管和业务规则限制风险, 央行重组改善决策与供款。各项制度需要一起运作。

保护也会改变行为。储户既然更少担心损失, 对银行冒险的监督可能减弱; 被限制的融资业务可能转往其他机构; 集中决策也仍可能作错判断。以后发生的危机, 将继续检验这些改革具体保护了谁, 又遗漏了哪些活动。

A.5 私人交易所怎样受到公共监督

1934 年以后, 交易所仍由私人机构经营, 却不能只按会员之间的利益约定办事。作为注册全国性证券交易所 (registered national securities exchange), 它要在自律组织 (self-regulatory organization, SRO) 框架下制定规则和执行纪律, 并接受 SEC 的法定监督。投资者保护与公平有序交易由此成为其公共责任 [KR11; US i]。

私人经营保留了熟悉订单和市场的专业人员，联邦监督则要求他们对会员以外的人负责。两者也存在冲突：交易所希望客户多交易，增加收入，同时又必须约束这些客户的违规行为。后来的组织改革会不断尝试减少这种冲突，并没有把交易所直接变成政府部门。

战争融资和战后储蓄又扩大了市场规模。Treasury 市场随政府借款增长，1951 年 Treasury–Fed Accord 结束美联储对政府债券利率的战时固定支持安排，使财政部债务管理与货币政策重新分开 [HL]。

与此同时，家庭通过共同基金，保险和雇主养老金间接投资更多资产。一笔证券交易背后逐渐同时有资产管理人，经纪商，托管银行和清算机构参与。投资者人数和成交量增加以后，完成交易所需的后台工作也迅速增加。

1960 年代末，经纪商仍大量依靠纸质记录确认交易和交付股票证书。成交增长以后，后台来不及比对与结算，未完成交易越积越多，错误和资金压力也随之增加。一些经纪商倒闭，交易所甚至缩短交易时间，给后台时间处理积压 [US 68]。买卖双方已经谈妥价格，并不表示证券和款项已经顺利交收，这次危机把两者的区别直接暴露出来。

解决办法之一是减少证书反复搬运。1973 年成立的 Depository Trust Company (DTC) 集中保管证券，用账簿记录转移持有权益。1976 年成立的 National Securities Clearing Corporation (NSCC) 进一步集中交易比对，净额处理和结算义务。这些安排减少了每笔交易都分别搬运证书和支付全额款项的负担 [Dep]。

报价电子化在同期沿另一条路径发展。Nasdaq 于 1971 年作为电子报价网络上线，OTC 参与者更容易看到报价，但成交协商与匹配当时仍主要靠电话 [US 71]。因而电子显示报价，与后来自动撮合的限价订单簿，不是同时完成的一项改革。

1975 年又改变了竞争规则。SEC Rule 19b-3 自 5 月 1 日起结束交易所面向公众的固定佣金表，经纪商需要更直接地按价格竞争。6 月 4 日通过的 Securities Acts Amendments of 1975 要求 SEC 推进全国市场和全国清算结算体系，并强化对 SRO 的监督 [US 75]。

全国市场并不是由政府把所有交易收进一家交易所。彼此竞争的场所逐步通过合并行情，接入，订单路由和共同规则联系起来。与此同时，证券保管和清算继续集中，使在不同场所谈成的交易能够完成交收。

从 Buttonwood 的相互优先和最低佣金，到固定公众佣金被取消，早期会员的部分收入保护逐渐削弱。交易所仍可由私人经营，但必须在联邦监督和更广泛竞争中提供服务。1934 年监督改革，1975 年市场建设和后来的电子竞争，分别改变了这个过程的不同部分。

2006 年，NYSE 与电子交易平台 Archipelago 合并并完成去会员化 (demutualization)。原来由会员拥有的非营利交易所，转为上市控股集团中的营利性公司。所有者股份可以公开买卖，不表示交易所因此被国有化。

组织改变以后，赚钱与监管之间的冲突也更加直接：市场运营者既要争取客户，又要监督客户及竞争者的行为。SEC 批准时要求更明确地分开运营和监管职能 [US 06]。

按截至 2026 年 9 月 2 日的资料，SEC 全国性证券交易所名录列有 New York Stock Exchange LLC [US h]，NYSE 属于公开上市的 Intercontinental Exchange (ICE) 集团 [Newa]。这说明私人所有与公共监督可以同时存在：交易所经营交易业务，又须履行法定自律责任，并接入全国行情和清算体系。

A.6 1970–1999 年：利率错配，跨市场交易与高杠杆

银行保护和证券监督建立以后，风险继续随着融资和交易方式变化。二十世纪后半段的几次事件，分别说明长期贷款怎样被短期资金成本拖累，现货与期货怎样共同承受卖压，以及一家非银行机构怎样影响主要交易商。

储贷机构 (savings and loan institutions, S&Ls) 大量用短期存款支持长期固定利率住房贷款。利率上升以后，留住或补充存款所需的利息提高，旧贷款的收益却不能同步增加。资产价值和经营收入都受到压力，机构的经济资本已经恶化。

立即关闭失败机构，又会暴露存款保险基金不足和处置成本。宽松会计与监管宽容使部分机构继续营业，存款保险帮助它们继续吸收资金，扩大的投资权限还使一些机构承担更多高风险资产。原来的损失没有因为暂不确认而消失，反而可能在继续经营中扩大。

1989 年 Financial Institutions Reform, Recovery, and Enforcement Act (FIRREA) 废除已经资不抵债的 FSLIC，建立 Resolution Trust Corporation (RTC) 处置失败储贷机构，并将相应存款保险责任移交 FDIC。1991 年 FDIC Improvement Act (FDICIA) 又加强及时纠正措施 (prompt

corrective action) 和最低成本处置 (least-cost resolution) 等要求 [Fedb; Fedc].

这里的拖延不能仅用没人发现问题解释. 确认损失意味着必须回答谁出钱, 谁关闭机构, 谁承担职业和政治后果. 当各方都希望把决定推迟, 已经失败的经营也可能继续获得资金.

1987 年 10 月股灾发生在更紧密联系的证券市场中. 组合保险试图在价格下跌时减少风险资产, 程序交易与股指期货使调整可以更快完成. 但许多参与者同时卖出, 会增加其他市场和中介承受的压力. 现货与期货互相影响, 做市商要融资维持库存, 清算机构也要求足够保证金.

美联储迅速公开表示提供流动性, 后来的跨市场协调, 熔断和清算保障又针对这些付款与交易问题加强 [Car]. 熔断并不设定股票应该值多少, 它让极端波动时的连续交易暂缓, 给订单, 风险计算和资金安排争取时间.

1998 年的 LTCM 则说明, 机构规模不是衡量外部影响的唯一办法. 它与多家主要交易商建立大量衍生品和融资关系, 又持有高杠杆的相对价值交易. 若各对手方同时抢先退出, 相同资产可能被集中出售, 抵押品下跌又迫使其他人补充保证金.

纽约联储召集私人对手方安排资本重组, 没有直接动用公共资金买下 LTCM [McD98]. 协调的目的在于减少同时清仓造成的损失, 实际重组资金由私人机构承担. 一家基金由此也可能因为与谁交易, 大家持有什么相似资产, 而具有系统影响.

1999 年 Gramm-Leach-Bliley Act 又取消 Glass-Steagall 的部分业务隔离, 使银行, 证券和保险业务更容易进入同一集团. 监管随之更依赖集团资本, 内部风险管理和机构间协调 [BBW]. 后来的危机还涉及独立投资银行, 影子银行融资和住房贷款质量, 不能只用这一次法律变化解释.

这些事件共同说明, 既有规则改变以后, 参与者会重新选择在哪里借钱, 怎样持有资产和承担风险. 研究下一场危机时, 需要重新查看实际负债与交易关系, 而不能只沿用上一场危机涉及的机构名单.

A.7 2000–2010 年：从科技股损失到融资体系危机

互联网带来了真实的搜索和通信成本下降, 却没有同时告诉投资者每家新企业最终能赚多少钱. 公司如何收费, 竞争是否会压低利润, 技术优势能维持多久, 在繁荣期间都存在很大不确定性. 股票价格可以反映真实机会, 也可以对其付出过高代价.

Pastor and Veronesi [PV05] 研究投资者逐渐了解新技术生产率时的价格变化. Ofek and Richardson [OR01] 则强调投资者意见不同, 悲观者受到卖空限制, 以及锁定期结束后更多股票可以出售. 前者讨论怎样学习新技术价值, 后者讨论不同判断能否通过实际买卖进入价格. 两类分析都比在事后把所有买方视为同样盲目更具体.

2000–2002 年科技股下跌造成巨大财富损失, 却没有像大萧条或 2008 年那样演变成同等程度的银行支付与融资危机. 随后 Enron 和 WorldCom 等会计丑闻又暴露了另一项问题: 投资者依赖的财务报告和外部审计可能因管理层行为与利益冲突而失效.

2002 年 Sarbanes-Oxley Act 建立 Public Company Accounting Oversight Board (PCAOB), 加强审计独立性, 管理层财务报告责任和内部控制要求 [US 02]. 这些具体措施更直接回应会计与治理失败, 不能仅用科技股估值过高概括它们的起因.

2007–2009 年的损失却进入了更广的借贷关系. 住房抵押贷款被证券化以后, 相关资产由多类机构持有, 其中一些依靠 repo 和其他短期批发融资不断续借. 货币市场基金, 信用衍生品与主要交易商又把更多资产负债表联系起来.

住房价格下降和贷款损失使复杂证券更难估值, 出借人也难以判断对手方究竟亏了多少. 它们缩短融资, 提高抵押折扣或拒绝续作, 借款人就须补现金或卖资产. 集中出售压低其他持有人抵押品的价格, 引起更多减仓. 传统存款保险和贴现窗口没有完整覆盖这些影子银行融资, 许多短期债权人因此会像储户一样抢先撤回资金.

Financial Crisis Inquiry Commission 多数报告把监管失误, 公司治理与风险管理缺陷, 过度借贷和不透明衍生品等列为重要原因, 同时收录不同委员的反对意见 [Fin11]. 多条原因可以同时成立, 争论在于各自有多重要, 以及不同政策本可怎样改变结果. 以下制度回应主要针对已经显现的融资收缩和监管遗漏.

美联储的紧急支持因而不只围绕传统银行展开. 它建立贷款设施, 与外国央行交换美元流动性, 支持商业票据和资产支持证券融资, 并进行大规模资产购买. 这些办法分别向无法顺利续借或出售资产的市场提供资金, 试图阻止付款需求在整个体系中同时收紧.

严重危机中扩展央行工具并非完全没有历史先例, 跨国比较见 [MW14]. 更重要的区别是钱经过什么渠道到达谁, 有什么抵押或损失保护, 以及何时退出. 临时恢复融资以后, 还要改变使私人机

构过度依赖紧急支持的激励。

2010 年 Dodd-Frank Act 建立 Financial Stability Oversight Council (FSOC) 和 Office of Financial Research (OFR), 并加强系统重要机构监督, 处置及压力测试等安排。改革希望把银行, 证券, 保险和非银融资一起观察, 不再仅由每个监管者检查自己管辖的一小部分。FSOC 主要协调不同机构, 并没有成为直接监管所有金融公司的单一监管者 [US a]。

场外衍生品还分别增加报告, 清算和平台交易要求。以 CFTC 所辖互换为例, 监管报告包括已清算和未清算交易; 强制中央清算针对被认定须清算且不适用例外的互换; 平台交易要求又只覆盖其中满足 made available to trade 等规定且不适用相关例外的交易 [Com12; Com13; US 10]。因而不能把改革概括成所有场外衍生品都必须在同一种交易所撮合和清算。

中央对手方 (central counterparty, CCP) 可以集中比对与净额处理, 让交易和担保更容易监测。但原来由许多双边关系承担的一部分付款责任也集中到它身上。CCP 需要保证金, 违约基金和流动性安排, 自身遇到压力时还需要恢复与处置办法。清算改变了谁承担风险, 没有使风险凭空消失。

A.8 2010–2026 年：更快的交易与银行之外的融资

交易界面和机构名称改变以后, 付款问题仍然存在。数字通信让提款与卖出决定更快传播, 基金和衍生品让杠杆分布到银行之外, 零佣金经纪和社交媒体又改变了零售订单的来源。接下来几次事件各自暴露了这些变化中的不同问题。

2010 年闪崩：卖出和撤单互相加快。2010 年 5 月 6 日, 股指期货的大额自动卖出遇到已经紧张的流动性。高频参与者继续交易并调整库存, 其他流动性提供者撤单, 现货与期货之间的联系又把压力传到更多证券。许多价格在几分钟内急剧偏离, 随后快速恢复 [Sta10]。

卖出程序可以继续发送订单, 但另一侧可成交数量正在减少, 同样一笔数量因而需要接受更远的价格。联合调查讨论的是自动执行, 市场碎片化与流动性撤退的共同作用, 不只是某个程序单独运行得太快。

后续的 limit up–limit down, 熔断和跨市场数据建设, 分别尝试限制异常成交, 暂缓连续交易并改善监测。原来可以由人召集协调的处置, 面对毫秒级订单变化时已经来不及逐笔完成。

2020 年求现：为什么连美债也难卖。COVID-19 冲击初期, 共同基金, 外国官方机构, 对冲基金和其他持有人同时需要美元现金。它们卖出资产, 其中也包括信用和流动性通常较好的美债。交易商却不能无限增加库存和融资, 买卖价差扩大, 现券与期货的相对价格失常, Treasury 与 agency MBS 市场交易明显恶化 [Boa20a]。Agency MBS 指由联邦机构或政府支持企业担保的抵押贷款证券。

部分高杠杆国债基差交易也需要平仓, 但卖出并不只来自这一类基金。集体求现使安全资产也承受交易压力: 最终支付受到信任, 不等于今天有足够中介资金按接近原价接走全部数量。

美联储先以大规模购买, 回购操作和紧急工具支持市场。2021 年建立的常设回购便利 (standing repo facility, SRF), 则把一项隔夜后备融资安排变成常设工具 [Fed21]。持有合格证券的对手方因而有规定条件下的额外现金来源, 不必每次等到危机再临时设计同类操作。

后续改革还研究交易商能够承接多少库存, 杠杆基金和交易数据, 以及让更多参与者直接互相成交的 all-to-all trading。Treasury 中央清算是另一项工作。按截至 2026 年 9 月 2 日公布的时间表, 符合范围的 Treasury 现券交易合规日期为 2026 年 12 月 31 日, repo 的相应日期为 2027 年 6 月 30 日 [US j]。

这份时间表说明改革计划怎样推进, 不表示相关要求在上述观察日已经全部实施, 更不表示未来求现时中介承接和保证金问题已经解决。

2021 年 meme stocks: 手机上的买入与清算资金。GameStop 等股票吸引社交媒体和大量零售交易, 同时存在高卖空余额, 活跃期权和剧烈价格变化。一些经纪商随后限制继续买入。其中一项直接压力来自清算机构提高保证金: 客户已经成交的交易尚待结算, 价格剧烈变化使经纪商需要为这些义务提供更多资金 [US 21]。

零佣金界面没有显示这笔后台资金需要。经纪商还可能通过 payment for order flow (PFOF) 取得收入, 将客户订单交给场外批发做市商执行。因而显性佣金为零, 与客户最终得到怎样的成交价格不同问题。SEC 的工作人员报告同时讨论零售界面设计, 路由激励, 卖空, 期权和清算, 没有把事件只归于一个交易方向。

这场波动使交易与结算之间的时间差受到更广关注。2024 年 5 月 28 日, 大多数适用的美国证券交易从 T+2 转为 T+1 [US 23b]。更早交收缩短了待结算风险持续的时间, 有助于降低相应担保资金需要。这属于更广的结算改革, 不能将其全部归因于 GameStop 一项事件。

加密资产与稳定币：记录公开以后，还要看谁能付款。无抵押加密资产，稳定币，中心化交易平台和去中心化金融 (decentralized finance, DeFi) 并不提供同一种权利。用户可能直接控制私钥，也可能只是对平台有提取资产的请求；某种代币可能承诺赎回，也可能没有相同承诺。分析失败时，要先分清哪笔资产由谁保管，哪项付款由谁负责。

2022 年的 TerraUSD 失败说明，规则能够在链上观察，不代表维持币值和按面值退出所需的条件始终存在 [Fin22]。FTX 则暴露中心化平台的托管，负债和关联方风险。底层资产使用区块链，并没有使平台内部客户资产与自身经营风险自动隔离 [Com24]。

这两类失败的原因不同。对储备支持型稳定币，应查看实际储备质量，保管责任和赎回安排，不能从算法稳定币失败推出所有稳定币都采用同样的资产支持方式。

FSB 在 2023 年的全球框架中按相同活动与风险接受相应监管的思路，强调客户资产保护，利益冲突，跨境协作和稳定币治理 [Fin23]。美国 2025 年签署 GENIUS Act，建立支付型稳定币的联邦监管框架 [The25; US 25]。按截至 2026 年 9 月 2 日的资料，法律已经颁布，但尚未全面实施，配套最终规则仍在制定 [Off26]。

法律可以规定发行人保留什么资产和履行什么责任，实际赎回仍需要资金。如果持有人集中要求退出，储备需要变现，处置损失和等待时间就会影响继续持有的意愿。2026 年的美联储研究将稳定币，代币化货币市场基金和其他近似货币产品放在一起，继续比较流动性转换，阈值和传染问题 [Ana+26]。

这与阿姆斯特丹汇兑银行的历史有可比较之处：账户或代币得到广泛接受以后，使用者更依赖发行和保管机构保持兑付能力。纸簿，中央数据库和分布式账本改变记录与转移方式，但仍要说明储备在哪里，谁能提取，压力时怎样付款。

2023 年地区银行危机：久期损失遇到集中提款。Silicon Valley Bank (SVB) 的存款客户集中在科技和风险投资领域，大量金额不在通常存款保险范围内。银行把快速增加的存款投入更长期限的证券，没有充分管理相应利率风险。利率上升后，这些证券已经产生未实现损失，未出售只影响损失怎样进入账面，不会消除其经济影响。

资本筹集计划引起客户对偿付能力的担心，社交网络让相似客户迅速交换信息，线上银行又让它们能够集中提款。银行需要现金时，先前的长期投资已经不容易按原成本变现。美联储事后审查同时指出管理失败和监管没有及时升级处理的问题 [Boa23]。

监管者使用系统性风险例外 (systemic risk exception) 保护 SVB 和 Signature Bank 的全部存款人。美联储另设 Bank Term Funding Program (BTFP)，允许合格机构用按面值估值的合格高质量证券取得期限融资，减少因立即筹款而低价出售证券的需要 [Boaa; US 23a]。

两项措施分别作用于存款人和银行融资。存款保护没有救回股东价值，抵押借款也没有让证券的经济损失消失。BTFP 是临时工具，自 2024 年 3 月 11 日起不再发放新贷款。

事后 FDIC 比较了维持有限保险，全面保险，以及提高企业支付账户定向保障等方案 [Fed23]。更广保护可以减少抢先提款，也会改变存款人监督银行的动机及保险定价。报告讨论这些选择，并不等于所有存款从此都适用同一种永久保障。

ETF 与私人信贷：非银行机构怎样承受资金压力。非银行金融不能作为一个同质类别处理。ETF 持有人可以在交易所转让份额，授权参与者还可以通过创建赎回把份额与规定资产篮子或现金相互转换。常态下这种选择有助于价格接近资产价值，压力时实际买卖成本却可能增加。

债券报价稀疏，净值采用较旧估值时，ETF 的实时成交价还可能先反映新的信息。所以折价既可能包含交易与赎回压力，也可能反映净值更新滞后。应比较同一时点可交易的篮子与份额，不能只根据折价就确定哪一边错误 [US 19; US 20]。

私人信贷 (private credit) 则把部分企业融资放在银行之外的基金，business development companies (BDCs) 和保险关联载体中。BDC 是向企业提供贷款或股权资本的受监管投资公司。不同载体对投资者退出的承诺不同，资金压力也因此不同。

长期不按净值向投资者赎回的封闭式安排，可以让管理人不必为每天的退出请求出售贷款，但借款人仍可能违约，杠杆仍须偿还，估值和与银行或保险机构的联系也仍需研究。只在规定窗口提供周期性赎回的半流动性安排，又需要在这些时点准备现金。

本章所用 2024 年和 2026 年研究描述了私人信贷扩张及数据覆盖不均的问题 [Boa26; CH24]。这些情况值得持续检查，但尚未指定一场必然发生的系统性危机。要判断外部影响，仍须找到谁在借款，谁可以要求退出，以及损失会怎样传到其他机构。

从这些案例可以看到，数字化主要缩短了反应时间，新产品则改变了资产和负债放在哪里。若许多持有人同时求现，或同类抵押品下跌使多笔杠杆交易一起减仓，早期银行史中的挤兑和被迫出售

仍会以新的交易方式出现。

A.9 泡沫与危机留下了什么

下面按事件并列整理损失怎样扩大和后来采取了什么措施。同一时期的改革未必有同一个原因：证券集中保管回应后台交收困难，电子报价和佣金竞争则还各有自己的发展过程。

事件	主要传导机制	对现行结构的遗产
1636–1637 年郁金香投机	未标准化远期请求权，供给信息不透明，缺少保证金和集中履约机制；价格崩塌但系统性影响有限	提醒我们区分资产泡沫与金融系统危机，并检查交付，保证金和合同执行
1720 年跨国股票泡沫	政府债务转换，政治特许，新贸易和保险叙事，跨市场投机相互强化	公共债务，公司治理，发行规则和政治关系必须联合分析
1866 年 Overend Gurney 危机	大型票据中介倒闭，流动性需求扩散到整个伦敦货币市场	为后来由 Bagehot 总结的最后贷款人路线提供关键实践；实际操作仍随危机与贷款对象而异
1907 年美国恐慌	信托公司多在清算所会员边界之外，挤兑进入 call money 与 NYSE 融资	催化 Aldrich–Vreeland 应急货币，National Monetary Commission 与后来 Fed 对部分流动性和协调职能的制度化
1929–1933 年危机	股价崩跌与银行恐慌，通缩，信贷收缩和政策失误结合	FDIC, SEC, 联邦披露，银行业务边界与更集中的 Fed 决策结构
1968–1976 年后台危机与同期市场结构改革	成交增长超过纸质确认，股票证书和经纪商资本处理能力；会员制佣金与碎片化行情限制竞争	DTC 与 NSCC 属于后台危机的直接制度路径；Nasdaq, national market system 与竞争性佣金属于同期但不同的报价，竞争和法律改革路径
1987 年股灾	现货，期货，组合保险，做市与保证金跨市场反馈	现代熔断，跨市场监测，清算保障和 Fed 对市场功能的公开流动性承诺
1980 年代储贷危机	利率错配，存款保险道德风险，监管宽容和损失延迟确认	RTC, FIRREA, FDICIA, prompt corrective action 与更明确的处置成本约束

续下页

事件	主要传导机制	对现行结构的遗产
1998 年 LTCM	高杠杆, 相似交易和多家交易商对手方形成火售网络	系统重要性开始更多按网络和共同头寸理解, 公共召集与私人损失吸收并用
2000–2002 年科技股与会计危机	技术不确定性, 异质信念和融资热潮之后叠加独立的审计与治理失败	科技股崩跌深化估值教训; Enron 与 WorldCom 等公司丑闻更直接催化 PCAOB, 审计独立和内部控制改革
2007–2009 年全球金融危机	抵押贷款证券化, repo 与短期批发融资, 不透明衍生品和高杠杆影子银行	FSOC, OFR, 压力测试, 处置框架及特定场外衍生品中央清算; 风险被重组并部分集中, 没有消失
2010 年 flash crash	自动执行, 跨市场反馈与流动性同步撤退	limit up–limit down, 更新熔断与更细粒度市场数据
2020 年 dash for cash	多类持有人共同求现, 基金赎回, 保证金, 部分 basis trade 去杠杆与交易商承接能力约束共同作用	SRF, Treasury 市场数据与仍在实施的中央清算改革, 更重视 NBFIs 流动性和杠杆
2021 年 meme stocks	社交媒体驱动的零售参与, 期权, short interest, 场外执行和清算保证金集中相遇	对零售路由, PFOF, 数字参与设计和清算基础设施的持续审查; T+1 属于更广泛的结算改革
2022 年 crypto 动荡	算法稳定币挤兑与中心化平台的治理, 托管和关联方风险以不同方式暴露	按功能区分 unbacked crypto, payment stablecoins, 平台和 DeFi; 稳定币法律框架进入实施期
2022 年英国 LDI 压力	财政消息引发国债重定价, 杠杆化久期对冲的追加保证金和被迫售债放大跌势	NBFI 流动性缓冲, 压力测试与临时定向市场功能后盾
2023 年美国地区银行	未保险存款集中, 久期风险, 管理与监管缺陷, 线上提款和社交网络加速挤兑	BTFF 的临时经验, 存款保险边界争论和对利率风险, 抵押品准备及流动性监督的重估

表中改革的力度并不简单对应股价跌幅。投资者亏损以后若仍能自行承担, 支付和信贷可以继续运行; 若银行不能付款, 经纪商不能完成交收, 或核心抵押融资停止, 其他没有参与最初交易的人也会受到影响。后一种情况更容易推动重新安排流动性支持和损失处置。

这也解释了为什么后台处理危机可以引起重大改革, 而不必先有一场证券泡沫。改革回应的是已经失灵的具体活动, 不只是价格曲线看起来有多剧烈。

A.10 为什么平时难改, 危机时却能迅速行动

这些事件中反复出现一种情形: 风险已经显露, 各方却迟迟没有改变做法; 等到支付和融资同时受到威胁, 公共部门与私人机构又能迅速集中资金和人员。1985 年 San Francisco Fed 对美国金融改革的回顾, 就注意到许多重大改革由危机推动 [Fed85]。

这种反差可以从权力和成本怎样分配来理解。州与联邦银行监管, 国会委员会, 证券监管者和交易所各自负责一部分事务。一家机构发现问题, 未必有权改变其他机构的规则。跨市场改革需要同时取得多个决定, 平时较容易被其中某一方拖住。

改革的代价又往往立即落到具体的人身上。增加资本, 减少杠杆或加强披露, 会影响机构利润和可提供的信贷。避免未来危机的好处则分散给社会, 而且没有发生的损失很难清楚归功于某项政策。因而承担眼前成本的人有动力反对, 未来受益者却不容易形成同样集中的支持。

私人协调在平时确实也有用。清算所, 交易商联系和合同安排能迅速处理局部问题, 不必每次等待立法。但当所有人同时求现, 原本互相支持的成员也都需要现金, 私人安排覆盖之外的机构更难得到帮助。1907 年信托公司的处境说明, 一套平时运行良好的会员制度未必足以应付全市场提款。

储贷危机则显示另一种拖延。继续按旧价值记账, 又能依靠保险存款或其他资金维持, 就能把立即确认损失的决定推到以后。关闭机构需要承认保险基金不足, 安排处置并承担政治责任。即使有关人员知道情况不好, 他们也可能各自希望不要由自己首先作出这个决定。

危机改变了这种成本比较。银行停止付款, 企业发不出工资或美债无法顺利交易时, 不行动的损失突然变得具体。原先意见分散的机构可能因此接受同一个紧急目标, 财政资源, 央行资产负债表和私人运营能力才更容易被共同调动。

这些现象并非美国独有。荷兰的国家特许和英国央行职能的形成, 都包含私人组织与公共权力重新分工。美国的特点在于, 对集中金融权力的警惕, 州与联邦并存的监管, 强大的私人资本市场,

与财政部和美联储的资源同时存在. 平时协调可能缓慢, 危机时可动用的能力却很大.

能够集中资源, 仍然需要正确诊断. 1930–1933 年的政策失败与储贷处置的拖延说明, 有机构和权限不等于会及时采取合适行动. 2008 年后银行监管加强, 也没有使货币基金, 对冲基金和美债融资市场的压力一并消失; 2023 年的存款保护又重新提出保障范围与市场纪律的问题.

因此, 评价处置不能只看到市场恢复交易. 还应追踪损失由股东, 债权人, 保险基金还是公共部门承担, 临时支持是否退出, 新规则是否让相同融资转移到了其他地方. 跨时期研究强调的也是法律, 监管和政治安排如何共同改变参与者的选择, 而非某个机构一经设立即能保证稳定 [Cal09; KR11].

A.11 回到随机过程: 制度变化怎样影响条件分布

同样的抵押品跌幅, 可以引起不同的后续交易. 有稳定期限融资的持有人或许能够继续持有, 必须立即补足现金的持有人却可能出售. 清算和央行支持安排改变以后, 相近的价格与持仓也未必对应相同的下一步分布.

第4.4节的转移核和第3.4.3小节的条件分布, 可以把这个问题说得更精确. 以下采用离散时点 $t = 0, 1, \dots$, 只建立一项需要检验的局部模型, 不从历史叙述直接断言市场具有 Markov 性.

取标准 Borel 可测空间 $(X, \mathcal{E}_X)$ 和 $(Z, \mathcal{E}_Z)$. 用 $X_t \in X$ 表示选入模型的市场变量, 用 $Z_t \in Z$ 表示相关制度条件. 前者可以包括价格, 融资和保证金, 后者可以包括交易资格, 清算方式和可用支持. 合并为

$$Y_t = (X_t, Z_t).$$

这里合并两类变量, 是为了随后定义和比较条件分布. 是否包含了足够信息, 仍是模型假设.

设 Y_t 对完整信息滤过 $\mathcal{F}_t$ 可测. 若进一步假设, 给定 Y_t 以后, 更早历史不再改变下一步的条件分布, 则存在从增广状态空间到自身的可测概率核 Q_t , 使每个可测集合 C 满足

$$\Pr(Y_{t+1} \in C \mid \mathcal{F}_t) = Q_t(Y_t, C) \quad \text{a.s.}$$

适应性只保证当前变量已知, 这里的等式另行要求它们足以预测下一步. 不能仅因已经列入几项制度变量, 就省去这一要求.

若只关心下一期市场变量, 而不限定下一期制度落在哪里, 对 $B \in \mathcal{E}_X$ 定义

$$K_{t,z}(x, B) := Q_t((x, z), B \times Z).$$

这对下一期制度作了边缘化, 没有假定它到下一期仍不改变. 代入上面的 Markov 假设, 得到

$$\Pr(X_{t+1} \in B \mid \mathcal{F}_t) = K_{t,Z_t}(X_t, B) \quad \text{a.s.}$$

因此, 两个当前市场取值同为 x 的时期, 可以因制度取值不同而使用不同的一步预测核.

下标 t 允许核还受日历时间影响, 例如法规生效日期或交易时段. 只有在这些影响已经由所选状态充分概括, 并且可以使用同一个转移规律时, 才能把核写成不显含 t 的形式. 时间齐次也不等于平稳: 即使始终使用同一个核, 若初始分布不是相应不变分布, 各时点分布仍可能变化.

现在考虑观察者只有部分信息. 令 $\mathcal{G}_t \subseteq \mathcal{F}_t$ 为观察滤过, 先假设 X_t 对 $\mathcal{G}_t$ 可测, 但 Z_t 不能完全观察. 法规文本可以公开, 某些实际融资资格, 支持能否取得或政策反应条件却仍可能需要推断. 这里的隐藏变量是模型选入的这些未完全掌握的条件, 不表示所有法律都不可见.

标准 Borel 假设使我们可以选取 Z_t 给定 $\mathcal{G}_t$ 的正则条件分布,

$$\pi_t(dz) := \Pr(Z_t \in dz \mid \mathcal{G}_t).$$

它是随当前观测改变的概率分布. 由条件期望的塔性质,

$$\begin{aligned} \Pr(X_{t+1} \in B \mid \mathcal{G}_t) &= \mathbb{E}[\Pr(X_{t+1} \in B \mid \mathcal{F}_t) \mid \mathcal{G}_t] \\ &= \mathbb{E}[K_{t,Z_t}(X_t, B) \mid \mathcal{G}_t] \\ &= \int_Z K_{t,z}(X_t, B) \pi_t(dz) \quad \text{a.s.} \end{aligned}$$

最后一步利用 X_t 已在观察信息中确定, 只需对尚未确定的 Z_t 加权. 各项被积值都在零与一之间, 因而这里的条件期望和积分是有界的.

这给出了部分信息下的一步预测：对每一种仍可能的制度条件，先使用相应预测，再按当前判断的权重相加。若 X_t 本身也不能完整观察，就须改用 (X_t, Z_t) 的联合条件分布积分，不能把未知的 X_t 当成常数留在外面。

部分观察与状态选得不够，是两种不同困难。前者在完整状态满足 Markov 假设以后，研究观察者如何预测。后者则说明，即使知道当前所选的全部变量，更早历史仍然影响下一步，最初的 Q_t 表达就不成立。扩大状态可能帮助描述，但需要重新检查充分性，而不是靠增加变量名称获得保证。

即使完整的 Y_t 是 Markov 过程，单独观察的 X_t 也未必是。过去观测可能通过 π_t 继续影响预测，相同当前价格可以因历史不同而有不同后验权重。这足以产生多期历史依赖，但不必然意味着某一种特定的长记忆模型成立。

制度本身又会随着危机，立法和机构行动改变。若要真正构造 Q_t ，就要说明可能发生哪些变化，参与者依据什么信息行动，这些行动怎样影响下一期融资和交易。给事件取一个名称，并没有提供相应概率或完成模型估计。

历史比较因此至少有两个实际要求。一是确认比较的权利是否相同。披露，存款保护，托管和赎回改变以后，同名资产可能已经有不同的付款和损失承担安排，差异不一定只是某个波动率参数变了。二是检查融资联系。保证金增加，抵押折扣提高和同步赎回，可以使平时并不一起出售的资产在压力时同时被抛售。

对跨时期回溯，这意味着不能仅凭价格序列可以拼接，就把它们都当成同一组不变条件下的样本。1934 年的监督改革，1975 年的佣金与市场安排，以及 2008 年后逐步推进的衍生品清算改革，都可能改变参与者的行动和成本。趋势指标仍能概括旧价格，但不会单独告诉我们这些交易条件是否相同，参见第 9.10 节。

这些变化仍可以放在同一概率空间中建模，只是不能未经论证就假定同一条齐次规律或同一平稳分布适用于全部历史。制度史的作用，是帮助选出需要保留的条件，找到规则发生变化的时期，并解释为什么过去能够完成的交易在另一个时期可能得出不同结果。

从一张股份到一笔隔夜借款，价格背后都有人必须付款，有人保管资产，有人决定怎样清算和处置损失。历次危机改变了这些职责。理解这些改变，才能把历史数据中的涨跌与当时实际能够进行的投资联系起来。

参考文献

- [Ald+20] Iñaki Aldasoro et al. *Global Banks' Dollar Funding Needs and Central Bank Swap Lines*. Bank for International Settlements. July 16, 2020. URL: <https://www.bis.org/publ/bisbull27.htm> (visited on 08/17/2026).
- [Ale+23] Paul Alexander et al. *Financial Stability Buy/Sell Tools: A Gilt Market Case Study*. Bank of England. Nov. 20, 2023. URL: <https://www.bankofengland.co.uk/quarterly-bulletin/2023/2023/financial-stability-buy-sell-tools-a-gilt-market-case-study> (visited on 09/02/2026).
- [AC01] Robert Almgren and Neil Chriss. “Optimal Execution of Portfolio Transactions”. In: *Journal of Risk* 3.2 (2001), pp. 5–39. DOI: [10.21314/JOR.2001.041](https://doi.org/10.21314/JOR.2001.041).
- [Alt] Alternative Reference Rates Committee. *Transition from LIBOR*. Federal Reserve Bank of New York. URL: <https://www.newyorkfed.org/arrc/sofr-transition> (visited on 08/17/2026).
- [Ana+26] Kenechukwu Anadu et al. *A Framework for Understanding the Vulnerabilities of New Money-Like Products*. Finance and Economics Discussion Series 2026-002. Board of Governors of the Federal Reserve System, 2026. DOI: [10.17016/FEDS.2026.002](https://doi.org/10.17016/FEDS.2026.002). URL: <https://www.federalreserve.gov/econres/feds/a-framework-for-understanding-the-vulnerabilities-of-new-money-like-products.htm> (visited on 09/02/2026).
- [Ang+22] Guillermo Angeris et al. *A Primer on Perpetuals*. Sept. 7, 2022. arXiv: [2209.03307](https://arxiv.org/abs/2209.03307). (Visited on 08/17/2026).
- [Ans+17] Mike Anson et al. *The Bank of England as Lender of Last Resort: New Historical Evidence from Daily Transactional Data*. Staff Working Paper 691. Bank of England, 2017. URL: <https://www.bankofengland.co.uk/working-paper/2017/the-bank-of-england-as-lender-of-last-resort-new-historical-evidence-from-daily-transactional-data> (visited on 09/02/2026).
- [Asw] Aswath Damodaran. *Valuing Financial Service Firms*. URL: <https://pages.stern.nyu.edu/~adamodar/pdfiles/eqnotes/finsvc.pdf> (visited on 09/12/2026).
- [AS23] Fernando Avalos and Vladyslav Sushko. *Margin Leverage and Vulnerabilities in U.S. Treasury Futures*. Bank for International Settlements. Sept. 18, 2023. URL: https://www.bis.org/publ/qtrpdf/r_qt2309w.htm (visited on 08/17/2026).
- [BMM15] Emmanuel Bacry, Iacopo Mastromatteo, and Jean-François Muzy. “Hawkes Processes in Finance”. In: *Market Microstructure and Liquidity* 1.1 (2015), p. 1550005. DOI: [10.1142/S2382626615500057](https://doi.org/10.1142/S2382626615500057).
- [BK20] Nick Baltas and Robert Kosowski. “Demystifying Time-Series Momentum Strategies: Volatility Estimators, Trading Rules and Pairwise Correlations”. In: *Market Momentum: Theory and Practice*. Ed. by Stephen Satchell and Andrew Grant. John Wiley & Sons, Nov. 16, 2020, pp. 30–67. ISBN: 9781119599364. DOI: [10.1002/9781119599364.ch3](https://doi.org/10.1002/9781119599364.ch3). URL: <https://onlinelibrary.wiley.com/doi/10.1002/9781119599364.ch3> (visited on 09/02/2026).
- [Ban22] Bank of England. *Financial Stability Report: December 2022*. Bank of England, 2022. URL: <https://www.bankofengland.co.uk/financial-stability-report/2022/december-2022> (visited on 09/02/2026).
- [Ban24] Bank of England. *History*. Dec. 9, 2024. URL: <https://www.bankofengland.co.uk/about/history> (visited on 09/02/2026).
- [BK21] Daniel Barth and R. Jay Kahn. *Hedge Funds and the Treasury Cash-Futures Disconnect*. Office of Financial Research. Apr. 1, 2021. URL: <https://www.financialresearch.gov/working-papers/2021/04/01/hedge-funds-and-the-treasury-cash-futures-disconnect/> (visited on 08/17/2026).
- [BKM23] Daniel Barth, R. Jay Kahn, and Robert Mann. *Recent Developments in Hedge Funds' Treasury Futures and Repo Positions: Is the Basis Trade “Back”?* Board of Governors of the Federal Reserve System. Aug. 30, 2023. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/recent-developments-in-hedge-funds-treasury-futures-and-repo-positions-20230830.html> (visited on 08/17/2026).

- [BBW] James R. Barth, R. Dan Brumbaugh, and James A. Wilcox. *Gramm–Leach–Bliley Act of 1999*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/gramm-leach-bliley-act> (visited on 09/02/2026).
- [Baz+15] Jamil Baz et al. *Dissecting Investment Strategies in the Cross Section and Time Series*. Working Paper 2695101. SSRN, 2015. DOI: 10.2139/ssrn.2695101. URL: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2695101 (visited on 09/02/2026).
- [Bil95] Patrick Billingsley. *Probability and Measure*. 3rd ed. Wiley, 1995.
- [Boa20a] Board of Governors of the Federal Reserve System. *A Retrospective on the March 2020 Turmoil in Treasury and Mortgage-Backed Securities Markets*. 2020. URL: <https://www.federalreserve.gov/publications/2020-november-financial-stability-report-borrowing.htm> (visited on 09/02/2026).
- [Boa20b] Board of Governors of the Federal Reserve System. *Swap Lines FAQs*. Mar. 19, 2020. URL: <https://www.federalreserve.gov/newsevents/pressreleases/swap-lines-faqs.htm> (visited on 08/17/2026).
- [Boa23] Board of Governors of the Federal Reserve System. *Review of the Federal Reserve’s Supervision and Regulation of Silicon Valley Bank*. Board of Governors of the Federal Reserve System, 2023. URL: <https://www.federalreserve.gov/publications/2023-April-SVB-Executive-Summary.htm> (visited on 09/02/2026).
- [Boa26] Board of Governors of the Federal Reserve System. *Financial Stability Report: Funding Risks*. Board of Governors of the Federal Reserve System, May 2026. URL: <https://www.federalreserve.gov/publications/2026-may-financial-stability-report-funding-risks.htm> (visited on 09/02/2026).
- [Boaa] Board of Governors of the Federal Reserve System. *Bank Term Funding Program*. URL: <https://www.federalreserve.gov/financial-stability/bank-term-funding-program.htm> (visited on 09/02/2026).
- [Boab] Board of Governors of the Federal Reserve System. *Central Bank Liquidity Swaps*. URL: <https://www.federalreserve.gov/monetarypolicy/central-bank-liquidity-swaps.htm> (visited on 08/17/2026).
- [Boac] Board of Governors of the Federal Reserve System. *Factors Affecting Reserve Balances, H.4.1*. URL: <https://www.federalreserve.gov/releases/h41/> (visited on 08/17/2026).
- [Boad] Board of Governors of the Federal Reserve System. *Federal Reserve Act*. URL: <https://www.federalreserve.gov/aboutthefed/fract.htm> (visited on 08/17/2026).
- [Boae] Board of Governors of the Federal Reserve System. *Interest on Reserve Balances*. URL: <https://www.federalreserve.gov/monetarypolicy/reserve-balances.htm> (visited on 08/17/2026).
- [Boaf] Board of Governors of the Federal Reserve System. *Overnight Reverse Repurchase Agreement Operations*. URL: <https://www.federalreserve.gov/monetarypolicy/overnight-reverse-repurchase-agreements.htm> (visited on 08/17/2026).
- [Boag] Board of Governors of the Federal Reserve System. *Reserve Requirements*. URL: <https://www.federalreserve.gov/monetarypolicy/reservereq.htm> (visited on 08/17/2026).
- [Bog07] Vladimir I. Bogachev. *Measure Theory*. Springer, 2007.
- [BL78] Douglas T. Breeden and Robert H. Litzenberger. “Prices of State-Contingent Claims Implicit in Option Prices”. In: *The Journal of Business* 51.4 (1978), pp. 621–651. DOI: 10.1086/296025.
- [Byba] Bybit. *USDC Perpetual Session Settlement Mechanism*. URL: <https://www.bybit.com/en/help-center/article/USDC-Perpetual-Session-Settlement-Mechanism> (visited on 09/12/2026).
- [Bybb] Bybit. *Why Was My Position Liquidated When the Candlestick Did Not Touch My Liquidation Price?* URL: <https://www.bybit.com/en/help-center/article/Why-Was-My-Position-Still-Liquidated> (visited on 09/12/2026).
- [CH24] Fang Cai and Sharjil Haque. *Private Credit: Characteristics and Risks*. Board of Governors of the Federal Reserve System. Feb. 23, 2024. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/private-credit-characteristics-and-risks-20240223.html> (visited on 09/02/2026).

- [Cal09] Charles W. Calomiris. *Banking Crises and the Rules of the Game*. Working Paper 15403. National Bureau of Economic Research, 2009. DOI: [10.3386/w15403](https://doi.org/10.3386/w15403). URL: <https://www.nber.org/papers/w15403> (visited on 09/02/2026).
- [Car] Mark Carlson. *Stock Market Crash of 1987*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/stock-market-crash-of-1987> (visited on 09/02/2026).
- [CFAa] CFA Institute. *Investments in Real Estate through Publicly Traded Securities*. URL: <https://www.cfainstitute.org/insights/professional-learning/refresher-readings/2026/investments-real-estate-publicly-traded-securities> (visited on 09/12/2026).
- [CFAb] CFA Institute. *Market-Based Valuation: Price and Enterprise Value Multiples*. URL: <https://www.cfainstitute.org/insights/professional-learning/refresher-readings/2026/market-based-valuation-price-enterprise-value-multiples> (visited on 09/12/2026).
- [CFAc] CFA Institute. *Residual Income Valuation*. URL: <https://www.cfainstitute.org/insights/professional-learning/refresher-readings/2026/residual-income-valuation> (visited on 09/12/2026).
- [Che+26] Xin Cheng et al. *DSpark: Confidence-Scheduled Speculative Decoding with Semi-Autoregressive Generation*. July 6, 2026. arXiv: [2607.05147](https://arxiv.org/abs/2607.05147). URL: <https://arxiv.org/abs/2607.05147> (visited on 08/17/2026).
- [CME24] CME Group. *Calculating U.S. Treasury Futures Conversion Factors*. Jan. 19, 2024. URL: <https://www.cmegroup.com/articles/2024/calculating-us-treasury-futures-conversion-factors.html> (visited on 08/17/2026).
- [CMEa] CME Group. *CME Clearing: Principles for Financial Market Infrastructures Disclosure*. URL: <https://www.cmegroup.com/clearing/risk-management/files/cme-clearing-principles-for-financial-market-infrastructures-disclosure.pdf> (visited on 09/12/2026).
- [CMEb] CME Group. *CME Term SOFR Reference Rates*. URL: <https://www.cmegroup.com/market-data/cme-group-benchmark-administration/term-sofr.html> (visited on 08/17/2026).
- [CMEc] CME Group. *Mark-to-Market*. URL: <https://www.cmegroup.com/education/courses/introduction-to-futures/mark-to-market> (visited on 09/12/2026).
- [Coc05] John H. Cochrane. *Asset Pricing*. Revised. Princeton University Press, 2005.
- [Com12] Commodity Futures Trading Commission. *Clearing Requirement Determination Under Section 2(h) of the Commodity Exchange Act*. Final Rule. Commodity Futures Trading Commission, Dec. 13, 2012. URL: <https://www.cftc.gov/sites/default/files/idc/groups/public/@lrfederalregister/documents/file/2012-29211a.pdf> (visited on 09/02/2026).
- [Com13] Commodity Futures Trading Commission. *Process for a Designated Contract Market or Swap Execution Facility To Make a Swap Available to Trade*. Final Rule. Commodity Futures Trading Commission, June 4, 2013. URL: <https://www.cftc.gov/LawRegulation/FederalRegister/FinalRules/2013-12250.html> (visited on 09/02/2026).
- [Com22] Commodity Futures Trading Commission. *CFTC Orders Event-Based Binary Options Markets Operator to Pay \$1.4 Million Penalty*. Jan. 3, 2022. URL: <https://www.cftc.gov/PressRoom/PressReleases/8478-22> (visited on 08/17/2026).
- [Com24] Commodity Futures Trading Commission. *CFTC Obtains \$12.7 Billion Judgment against FTX and Alameda*. Aug. 8, 2024. URL: <https://www.cftc.gov/PressRoom/PressReleases/8938-24> (visited on 09/02/2026).
- [Com26] Commodity Futures Trading Commission. *CFTC Enforcement Division Issues Prediction Markets Advisory*. Feb. 25, 2026. URL: <https://www.cftc.gov/PressRoom/PressReleases/9185-26> (visited on 08/17/2026).
- [Com] Commodity Futures Trading Commission. *Understanding Prediction Markets and Event Contracts*. URL: <https://www.cftc.gov/LearnandProtect/PredictionMarkets> (visited on 08/17/2026).
- [CKS14] Rama Cont, Arseniy Kukanov, and Sasha Stoikov. “The Price Impact of Order Book Events”. In: *Journal of Financial Econometrics* 12.1 (2014), pp. 47–88. DOI: [10.1093/jffinec/nbt003](https://doi.org/10.1093/jffinec/nbt003).
- [CST10] Rama Cont, Sasha Stoikov, and Rishi Talreja. “A Stochastic Model for Order Book Dynamics”. In: *Operations Research* 58.3 (2010), pp. 549–563. DOI: [10.1287/opre.1090.0780](https://doi.org/10.1287/opre.1090.0780).

- [Dam12] Aswath Damodaran. *Investment Valuation: Tools and Techniques for Determining the Value of Any Asset*. 3rd ed. Wiley, 2012.
- [DS94] Freddy Delbaen and Walter Schachermayer. “A General Version of the Fundamental Theorem of Asset Pricing”. In: *Mathematische Annalen* 300.1 (1994), pp. 463–520. DOI: [10.1007/BF01450498](https://doi.org/10.1007/BF01450498).
- [Dep] Depository Trust & Clearing Corporation. *The 1970s: Immobilization, Book Entry and Netting*. URL: <https://www.dtcc.com/annuals/history/1970s/> (visited on 09/02/2026).
- [DD83] Douglas W. Diamond and Philip H. Dybvig. “Bank Runs, Deposit Insurance, and Liquidity”. In: *Journal of Political Economy* 91.3 (1983), pp. 401–419. DOI: [10.1086/261155](https://doi.org/10.1086/261155).
- [Duf01] Darrell Duffie. *Dynamic Asset Pricing Theory*. 3rd ed. Princeton University Press, 2001.
- [Dur19] Rick Durrett. *Probability: Theory and Examples*. 5th ed. Cambridge University Press, 2019.
- [Fed23] Federal Deposit Insurance Corporation. *Options for Deposit Insurance Reform*. Federal Deposit Insurance Corporation, 2023. URL: <https://www.fdic.gov/analysis/options-deposit-insurance-reform> (visited on 09/02/2026).
- [Fedf] Federal Deposit Insurance Corporation. *1930–1939*. URL: <https://www.fdic.gov/history/1930-1939> (visited on 08/17/2026).
- [Fedb] Federal Deposit Insurance Corporation. *1980–1989*. URL: <https://www.fdic.gov/history/1980-1989> (visited on 09/02/2026).
- [Fedc] Federal Deposit Insurance Corporation. *1990–1999*. URL: <https://www.fdic.gov/history/1990-1999> (visited on 09/02/2026).
- [Fed21] Federal Reserve Bank of New York. *Statement Regarding Repurchase Agreements*. July 28, 2021. URL: https://www.newyorkfed.org/markets/opolicy/operating_policy_210728 (visited on 09/02/2026).
- [Fedd] Federal Reserve Bank of New York. *Effective Federal Funds Rate*. URL: <https://www.newyorkfed.org/markets/reference-rates/effr> (visited on 08/17/2026).
- [Fede] Federal Reserve Bank of New York. *Monetary Policy Implementation*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation> (visited on 08/17/2026).
- [Fedf] Federal Reserve Bank of New York. *Repo and Reverse Repo Agreements*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation/repo-reverse-repo-agreements> (visited on 08/17/2026).
- [Fedg] Federal Reserve Bank of New York. *Secured Overnight Financing Rate Data*. URL: <https://www.newyorkfed.org/markets/reference-rates/sofr> (visited on 08/17/2026).
- [Fed85] Federal Reserve Bank of San Francisco. *U.S. Financial Reform: Historical Perspective*. Weekly Letter. Federal Reserve Bank of San Francisco, Mar. 22, 1985. URL: https://fraser.stlouisfed.org/files/docs/historical/frbsf/frbsf_let/frbsf_let_19850322.pdf (visited on 09/02/2026).
- [Fedh] Federal Reserve History. *Before the Fed: The Historical Precedents of the Federal Reserve System*. URL: <https://www.federalreservehistory.org/essays/before-the-fed> (visited on 09/02/2026).
- [Fedi] Federal Reserve History. *Federal Reserve Act Signed into Law*. URL: <https://www.federalreservehistory.org/essays/federal-reserve-act-signed> (visited on 08/17/2026).
- [FSY19] Fernando F. Ferreira, A. Christian Silva, and Ju-Yi Yen. *Detailed Study of a Moving Average Trading Rule*. 2019. arXiv: [1907.00212](https://arxiv.org/abs/1907.00212) [q-fin.ST]. URL: <https://arxiv.org/abs/1907.00212>.
- [Fin11] Financial Crisis Inquiry Commission. *The Financial Crisis Inquiry Report*. U.S. Government Printing Office, 2011. URL: <https://www.govinfo.gov/content/pkg/GPO-FCIC/pdf/GPO-FCIC.pdf> (visited on 09/02/2026).
- [Fin23] Financial Stability Board. *Global Regulatory Framework for Crypto-Asset Activities*. Financial Stability Board, 2023. URL: <https://www.fsb.org/2023/07/fsb-finalises-global-regulatory-framework-for-crypto-asset-activities/> (visited on 09/02/2026).

- [Fin22] Financial Stability Oversight Council. *Report on Digital Asset Financial Stability Risks and Regulation*. U.S. Department of the Treasury, 2022. URL: <https://home.treasury.gov/system/files/261/FSOC-Digital-Assets-Report-2022.pdf> (visited on 09/02/2026).
- [Fol99] Gerald B. Folland. *Real Analysis: Modern Techniques and Their Applications*. 2nd ed. Wiley, 1999.
- [FPR23] Thierry Foucault, Marco Pagano, and Ailsa Röell. *Market Liquidity: Theory, Evidence, and Policy*. 2nd ed. Oxford University Press, 2023. DOI: [10.1093/oso/9780197542064.001.0001](https://doi.org/10.1093/oso/9780197542064.001.0001).
- [FGR09] Rik G. P. Frehen, William N. Goetzmann, and K. Geert Rouwenhorst. *New Evidence on the First Financial Bubble*. Working Paper 15332. National Bureau of Economic Research, 2009. DOI: [10.3386/w15332](https://doi.org/10.3386/w15332). URL: <https://www.nber.org/papers/w15332> (visited on 09/02/2026).
- [FSW20] Jon Frost, Hyun Song Shin, and Peter Wierts. *An Early Stablecoin? The Bank of Amsterdam and the Governance of Money*. Working Paper 696. De Nederlandsche Bank, 2020. URL: <https://www.dnb.nl/publicaties/publicaties-onderzoek/working-paper-2020/696-an-early-stablecoin-the-bank-of-amsterdam-and-the-governance-of-money/> (visited on 09/02/2026).
- [Gar] Kenneth D. Garbade. *Liberty Bonds*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/liberty-bonds> (visited on 09/02/2026).
- [Gas10] Gary L. Gastineau. *The Exchange-Traded Funds Manual*. 2nd ed. Wiley, 2010.
- [GJ04] Oscar Gelderblom and Joost Jonker. “Completing a Financial Revolution: The Finance of the Dutch East India Trade and the Rise of the Amsterdam Capital Market, 1595–1612”. In: *The Journal of Economic History* 64.3 (2004), pp. 641–672. DOI: [10.1017/S002205070400292X](https://doi.org/10.1017/S002205070400292X).
- [Gli+24] Jonathan Glicoes et al. *Quantifying Treasury Cash-Futures Basis Trades*. Board of Governors of the Federal Reserve System. Mar. 8, 2024. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/quantifying-treasury-cash-futures-basis-trades-20240308.html> (visited on 08/17/2026).
- [GM85] Lawrence R. Glosten and Paul R. Milgrom. “Bid, Ask and Transaction Prices in a Specialist Market with Heterogeneously Informed Traders”. In: *Journal of Financial Economics* 14.1 (1985), pp. 71–100. DOI: [10.1016/0304-405X\(85\)90044-3](https://doi.org/10.1016/0304-405X(85)90044-3).
- [GM13] Gary B. Gorton and Andrew Metrick. *The Federal Reserve and Financial Regulation: The First Hundred Years*. Working Paper 19292. National Bureau of Economic Research, 2013. DOI: [10.3386/w19292](https://doi.org/10.3386/w19292). URL: <https://www.nber.org/papers/w19292> (visited on 09/02/2026).
- [Gou+13] Martin D. Gould et al. “Limit Order Books”. In: *Quantitative Finance* 13.11 (2013), pp. 1709–1742. DOI: [10.1080/14697688.2013.803148](https://doi.org/10.1080/14697688.2013.803148).
- [Har02] Larry Harris. *Trading and Exchanges: Market Microstructure for Practitioners*. Oxford University Press, 2002. DOI: [10.1093/oso/9780195144703.001.0001](https://doi.org/10.1093/oso/9780195144703.001.0001).
- [Har94] Ron Harris. “The Bubble Act: Its Passage and Its Effects on Business Organization”. In: *The Journal of Economic History* 54.3 (1994), pp. 610–627. DOI: [10.1017/S0022050700015059](https://doi.org/10.1017/S0022050700015059).
- [HK79] J. Michael Harrison and David M. Kreps. “Martingales and Arbitrage in Multiperiod Securities Markets”. In: *Journal of Economic Theory* 20.3 (1979), pp. 381–408. DOI: [10.1016/0022-0531\(79\)90043-7](https://doi.org/10.1016/0022-0531(79)90043-7).
- [HP81] J. Michael Harrison and Stanley R. Pliska. “Martingales and Stochastic Integrals in the Theory of Continuous Trading”. In: *Stochastic Processes and their Applications* 11.3 (1981), pp. 215–260. DOI: [10.1016/0304-4149\(81\)90026-0](https://doi.org/10.1016/0304-4149(81)90026-0).
- [Has07] Joel Hasbrouck. *Empirical Market Microstructure: The Institutions, Economics, and Econometrics of Securities Trading*. Oxford University Press, 2007. DOI: [10.1093/oso/9780195301649.001.0001](https://doi.org/10.1093/oso/9780195301649.001.0001).
- [He+24] Songrun He et al. *Fundamentals of Perpetual Futures*. Aug. 21, 2024. arXiv: [2212.06888](https://arxiv.org/abs/2212.06888). (Visited on 08/17/2026).
- [HL] Robert L. Hetzel and Ralph F. Leach. *The Treasury–Federal Reserve Accord*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/treasury-fed-accord> (visited on 09/02/2026).

- [HS81] Thomas Ho and Hans R. Stoll. “Optimal Dealer Pricing under Transactions and Return Uncertainty”. In: *Journal of Financial Economics* 9.1 (1981), pp. 47–73. DOI: [10.1016/0304-405X\(81\)90020-9](https://doi.org/10.1016/0304-405X(81)90020-9).
- [Hua+20] Dashan Huang et al. “Time Series Momentum: Is It There?” In: *Journal of Financial Economics* 135.3 (2020), pp. 774–794. DOI: [10.1016/j.jfineco.2019.08.004](https://doi.org/10.1016/j.jfineco.2019.08.004).
- [HS97] Roger D. Huang and Hans R. Stoll. “The Components of the Bid-Ask Spread: A General Approach”. In: *The Review of Financial Studies* 10.4 (1997), pp. 995–1034. DOI: [10.1093/rfs/10.4.995](https://doi.org/10.1093/rfs/10.4.995).
- [Hul22] John C. Hull. *Options, Futures, and Other Derivatives*. 11th ed. Pearson, 2022.
- [HPW19] Jeffrey Huther, Luke Pettit, and Mark Wilkinson. *Fiscal Flow Volatility and Reserves*. Board of Governors of the Federal Reserve System. Dec. 16, 2019. DOI: [10.17016/2380-7172.2470](https://doi.org/10.17016/2380-7172.2470). URL: <https://www.federalreserve.gov/econres/notes/feds-notes/fiscal-flow-volatility-and-reserves-20191216.html> (visited on 08/17/2026).
- [Kal21] Olav Kallenberg. *Foundations of Modern Probability*. 3rd ed. Springer, 2021.
- [KTW16] Abby Y. Kim, Yiunan Tse, and John K. Wald. “Time Series Momentum and Volatility Scaling”. In: *Journal of Financial Markets* 30 (2016), pp. 103–124. DOI: [10.1016/j.finmar.2016.05.003](https://doi.org/10.1016/j.finmar.2016.05.003). URL: <https://www.sciencedirect.com/science/article/pii/S1386418116301379> (visited on 09/02/2026).
- [Kir+17] Andrei Kirilenko et al. “The Flash Crash: High-Frequency Trading in an Electronic Market”. In: *The Journal of Finance* 72.3 (2017), pp. 967–998. DOI: [10.1111/jofi.12498](https://doi.org/10.1111/jofi.12498).
- [KR11] Alejandro Komai and Gary Richardson. *A Brief History of Regulations Regarding Financial Markets in the United States: 1789 to 2009*. Working Paper 17443. National Bureau of Economic Research, 2011. DOI: [10.3386/w17443](https://doi.org/10.3386/w17443). URL: <https://www.nber.org/papers/w17443> (visited on 09/02/2026).
- [Kyl85] Albert S. Kyle. “Continuous Auctions and Insider Trading”. In: *Econometrica* 53.6 (1985), pp. 1315–1335. DOI: [10.2307/1913210](https://doi.org/10.2307/1913210).
- [LR91] Charles M. C. Lee and Mark J. Ready. “Inferring Trade Direction from Intraday Data”. In: *The Journal of Finance* 46.2 (1991), pp. 733–746. DOI: [10.1111/j.1540-6261.1991.tb02683.x](https://doi.org/10.1111/j.1540-6261.1991.tb02683.x).
- [Lon] London Stock Exchange Group. *The History of LSEG*. URL: <https://www.lseg.com/en/about-us/history> (visited on 09/02/2026).
- [Mad00] Ananth Madhavan. “Market Microstructure: A Survey”. In: *Journal of Financial Markets* 3.3 (2000), pp. 205–258. DOI: [10.1016/S1386-4181\(00\)00007-0](https://doi.org/10.1016/S1386-4181(00)00007-0).
- [Man06] Charles F. Manski. “Interpreting the Predictions of Prediction Markets”. In: *Economics Letters* 91.3 (2006), pp. 425–429. DOI: [10.1016/j.econlet.2006.01.004](https://doi.org/10.1016/j.econlet.2006.01.004).
- [Mar52] Harry Markowitz. “Portfolio Selection”. In: *The Journal of Finance* 7.1 (1952), pp. 77–91. DOI: [10.2307/2975974](https://doi.org/10.2307/2975974).
- [MT17] James E. McClure and David Chandler Thomas. “Explaining the Timing of Tulipmania’s Boom and Bust: Historical Context, Sequestered Capital and Market Signals”. In: *Financial History Review* 24.2 (2017), pp. 121–141. DOI: [10.1017/S0968565017000154](https://doi.org/10.1017/S0968565017000154).
- [McD98] William J. McDonough. *Statement on the Long-Term Capital Management Rescue*. Federal Reserve Bank of New York. Oct. 1, 1998. URL: <https://www.newyorkfed.org/newsevents/speeches/1998/mcd981001.html> (visited on 09/02/2026).
- [MW02] Frederic S. Mishkin and Eugene N. White. *U.S. Stock Market Crashes and Their Aftermath: Implications for Monetary Policy*. Working Paper 8992. National Bureau of Economic Research, 2002. DOI: [10.3386/w8992](https://doi.org/10.3386/w8992). URL: <https://www.nber.org/papers/w8992> (visited on 09/02/2026).
- [MW14] Frederic S. Mishkin and Eugene N. White. *Unprecedented Actions: The Federal Reserve’s Response to the Global Financial Crisis in Historical Perspective*. Working Paper 20737. National Bureau of Economic Research, 2014. DOI: [10.3386/w20737](https://doi.org/10.3386/w20737). URL: <https://www.nber.org/papers/w20737> (visited on 09/02/2026).
- [MT] Jon R. Moen and Ellis W. Tallman. *The Panic of 1907*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/panic-of-1907> (visited on 08/17/2026).

- [Mor22] Morgan Stanley. *Vintage Values 2023*. Morgan Stanley Wealth Management. Aug. 24, 2022. URL: <https://www.morganstanley.com/content/dam/msdotcom/what-we-do/wealth-management-images/uit/vintage-values-research-report.pdf> (visited on 08/17/2026).
- [Mor24a] Morgan Stanley. *Project Lean: Discussion Materials, May 16, 2024, Exhibit (c)(16)*. May 16, 2024. URL: <https://www.sec.gov/Archives/edgar/data/1360587/000119312524165806/d842696dex99c16.htm> (visited on 09/12/2026).
- [Mor24b] Morningstar. *Morningstar Equity Analyst Note: Research Methodology for Valuing Companies*. Sept. 10, 2024. URL: <https://developer.morningstar.com/content/hidden-from-navigation/morningstar-stock-analyst-note.pdf> (visited on 09/12/2026).
- [Mor26] Morningstar. *Economic Moat Ratings: How to Measure a Company's Competitive Advantage*. Mar. 11, 2026. URL: <https://www.morningstar.com/business/insights/blog/equity-economic-moat-ratings> (visited on 09/12/2026).
- [Nas] Nasdaq. *Nasdaq-100 Index Methodology*. URL: https://indexes.nasdaqomx.com/docs/Methodology_NDX.pdf (visited on 08/17/2026).
- [Newa] New York Stock Exchange. *Listing at NYSE*. URL: <https://www.nyse.com/listings> (visited on 09/02/2026).
- [Newb] New York Stock Exchange. *The History of the New York Stock Exchange*. URL: <https://www.nyse.com/history-of-nyse> (visited on 09/02/2026).
- [OHa95] Maureen O'Hara. *Market Microstructure Theory*. Blackwell Publishers, 1995.
- [OR01] Eli Ofek and Matthew Richardson. *DotCom Mania: The Rise and Fall of Internet Stock Prices*. Working Paper 8630. National Bureau of Economic Research, 2001. DOI: 10.3386/w8630. URL: <https://www.nber.org/papers/w8630> (visited on 09/02/2026).
- [Off26] Office of the Comptroller of the Currency. *Comptroller Gould Discusses Digital Asset Innovation, GENIUS Next Steps*. Aug. 19, 2026. URL: <https://www.occ.treas.gov/news-issuances/news-releases/2026/nr-occ-2026-69.html> (visited on 09/02/2026).
- [Opt] Options Clearing Corporation. *Characteristics and Risks of Standardized Options*. URL: <https://www.theocc.com/company-information/documents-and-archives/options-disclosure-document> (visited on 08/17/2026).
- [PV05] Lubos Pastor and Pietro Veronesi. *Technological Revolutions and Stock Prices*. Working Paper 11876. National Bureau of Economic Research, 2005. DOI: 10.3386/w11876. URL: <https://www.nber.org/papers/w11876> (visited on 09/02/2026).
- [Per88] André F. Perold. "The Implementation Shortfall: Paper versus Reality". In: *The Journal of Portfolio Management* 14.3 (1988), pp. 4–9. DOI: 10.3905/jpm.1988.409150.
- [Ric+a] Gary Richardson et al. *Banking Act of 1933 (Glass-Steagall)*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/glass-steagall-act> (visited on 09/02/2026).
- [Ric+b] Gary Richardson et al. *Banking Act of 1935*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/banking-act-of-1935> (visited on 09/02/2026).
- [RKG] Gary Richardson, Alejandro Komai, and Michael Gou. *Stock Market Crash of 1929*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/stock-market-crash-of-1929> (visited on 09/02/2026).
- [SP 26] S&P Dow Jones Indices. *Marvell Technology and Flex Set to Join S&P 500; Others to Join S&P MidCap 400 and S&P SmallCap 600*. June 5, 2026. URL: <https://press.spglobal.com/2026-06-05-Marvell-Technology-and-Flex-Set-to-Join-S-P-500-Others-to-Join-S-P-MidCap-400-and-S-P-SmallCap-600> (visited on 08/17/2026).
- [SP a] S&P Dow Jones Indices. *Index Mathematics Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-index-math.pdf> (visited on 08/17/2026).
- [SP b] S&P Dow Jones Indices. *S&P U.S. Indices Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-sp-us-indices.pdf> (visited on 08/17/2026).
- [SV97] Andrei Shleifer and Robert W. Vishny. "The Limits of Arbitrage". In: *The Journal of Finance* 52.1 (1997), pp. 35–55. DOI: 10.1111/j.1540-6261.1997.tb03807.x.

- [Shr04a] Steven E. Shreve. *Stochastic Calculus for Finance I: The Binomial Asset Pricing Model*. Springer, 2004.
- [Shr04b] Steven E. Shreve. *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer, 2004.
- [Sta10] Staffs of the U.S. Securities and Exchange Commission and the Commodity Futures Trading Commission. *Findings Regarding the Market Events of May 6, 2010*. U.S. Securities, Exchange Commission, and Commodity Futures Trading Commission, 2010. URL: <https://www.sec.gov/news/studies/2010/marketevents-report.pdf> (visited on 09/02/2026).
- [STW99] Ryan Sullivan, Allan Timmermann, and Halbert White. “Data-Snooping, Technical Trading Rule Performance, and the Bootstrap”. In: *The Journal of Finance* 54.5 (1999), pp. 1647–1691. DOI: [10.1111/0022-1082.00163](https://doi.org/10.1111/0022-1082.00163).
- [The25] The White House. *The President Signed into Law S. 1582*. July 18, 2025. URL: <https://www.whitehouse.gov/briefings-statements/2025/07/the-president-signed-into-law-s-1582/> (visited on 09/02/2026).
- [TS11] Bruce Tuckman and Angel Serrat. *Fixed Income Securities: Tools for Today’s Markets*. 3rd ed. Wiley, 2011.
- [US 10] U.S. Congress. *Dodd–Frank Wall Street Reform and Consumer Protection Act, Public Law 111-203*. July 21, 2010. URL: <https://www.govinfo.gov/app/details/PLAW-111publ203> (visited on 09/02/2026).
- [US 25] U.S. Congress. *Guiding and Establishing National Innovation for U.S. Stablecoins Act, Public Law 119-27*. July 18, 2025. URL: <https://www.govinfo.gov/app/details/PLAW-119publ27> (visited on 09/02/2026).
- [US a] U.S. Department of the Treasury. *About the Financial Stability Oversight Council*. URL: <https://home.treasury.gov/policy-issues/financial-markets-financial-institutions-and-fiscal-service/fsoc/about-fsoc> (visited on 09/02/2026).
- [US b] U.S. Department of the Treasury. *Daily Treasury Rates*. URL: https://home.treasury.gov/resource-center/data-chart-center/interest-rates/TextView?type=daily_treasury_yield_curve (visited on 08/17/2026).
- [US c] U.S. Department of the Treasury. *STRIPS*. URL: <https://www.treasurydirect.gov/market-able-securities/strips/> (visited on 08/17/2026).
- [US d] U.S. Department of the Treasury. *Treasury Marketable Securities*. URL: <https://www.treasurydirect.gov/marketable-securities/> (visited on 08/17/2026).
- [US 23a] U.S. Department of the Treasury and Board of Governors of the Federal Reserve System and Federal Deposit Insurance Corporation. *Joint Statement by the Department of the Treasury, Federal Reserve, and FDIC*. Mar. 12, 2023. URL: <https://www.fdic.gov/news/press-releases/2023/pr23017.html> (visited on 09/02/2026).
- [US 68] U.S. Securities and Exchange Commission. *Thirty-Fourth Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1968. URL: https://www.sec.gov/about/annual_report/1968.pdf (visited on 09/02/2026).
- [US 71] U.S. Securities and Exchange Commission. *Thirty-Seventh Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1971. URL: <https://www.sec.gov/file/1971pdf> (visited on 09/02/2026).
- [US 75] U.S. Securities and Exchange Commission. *Forty-First Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1975. URL: https://www.sec.gov/about/annual_report/1975.pdf (visited on 09/02/2026).
- [US 02] U.S. Securities and Exchange Commission. *SEC Accomplishments: Fiscal Year 2002*. 2002. URL: <https://www.sec.gov/news/extra/intsfy2002.htm> (visited on 09/02/2026).
- [US 06] U.S. Securities and Exchange Commission. *Approval of SRO Rule Changes Necessary to Effectuate Merger of NYSE and Archipelago Holdings*. Feb. 27, 2006. URL: <https://www.sec.gov/news/press/2006-29.htm> (visited on 09/02/2026).
- [US 15] U.S. Securities and Exchange Commission. *Investor Bulletin: An Introduction to Options*. Mar. 18, 2015. URL: <https://www.investor.gov/introduction-investing/general-resources/news-alerts/alerts-bulletins/investor-bulletins-63> (visited on 08/17/2026).

- [US 19] U.S. Securities and Exchange Commission. *Exchange-Traded Funds, Rule 6c-11*. Sept. 25, 2019. URL: <https://www.sec.gov/rules/final/2019/33-10695.pdf> (visited on 09/02/2026).
- [US 21] U.S. Securities and Exchange Commission. *Staff Report on Equity and Options Market Structure Conditions in Early 2021*. U.S. Securities and Exchange Commission, 2021. URL: <https://www.sec.gov/files/staff-report-equity-options-market-struction-conditions-early-2021.pdf> (visited on 09/02/2026).
- [US 23b] U.S. Securities and Exchange Commission. *SEC Finalizes Rules to Reduce Risks in Clearance and Settlement*. Feb. 15, 2023. URL: <https://www.sec.gov/newsroom/press-releases/2023-29> (visited on 09/02/2026).
- [US e] U.S. Securities and Exchange Commission. *Exchange-Traded Funds (ETFs)*. Investor.gov. URL: <https://www.investor.gov/introduction-investing/investing-basics/glossary/exchange-traded-funds-etfs> (visited on 08/17/2026).
- [US f] U.S. Securities and Exchange Commission. *Investor Bulletin: Exchange-Traded Funds (ETFs)*. URL: <https://www.sec.gov/investor/pubs/sec-guide-to-etfs.pdf> (visited on 08/17/2026).
- [US g] U.S. Securities and Exchange Commission. *Money Market Funds*. URL: <https://www.investor.gov/introduction-investing/investing-basics/investment-products/mutual-funds-and-exchange-traded-5> (visited on 08/17/2026).
- [US h] U.S. Securities and Exchange Commission. *National Securities Exchanges*. URL: <https://www.sec.gov/about/divisions-offices/division-trading-markets/national-securities-exchanges> (visited on 09/02/2026).
- [US i] U.S. Securities and Exchange Commission. *Securities Laws and Regulations*. URL: <https://www.sec.gov/rules-regulations/statutes-regulations> (visited on 09/02/2026).
- [US j] U.S. Securities and Exchange Commission. *Treasury Clearing Implementation*. URL: <https://www.sec.gov/featured-topics/treasury-clearing-implementation> (visited on 09/02/2026).
- [US 20] U.S. Securities and Exchange Commission Research Staff. *U.S. Credit Markets Interconnectedness and the Effects of the COVID-19 Economic Shock*. U.S. Securities and Exchange Commission, Oct. 5, 2020. URL: https://www.sec.gov/files/us-credit-markets_covid-19_report.pdf (visited on 09/02/2026).
- [UK 25] UK Parliament. *Research into Historic Links to Transatlantic Chattel Slavery*. UK Parliament, 2025. URL: https://data.parliament.uk/DepositedPapers/Files/DEP2025-0405/Research_into_Historic_Links_to_Transatlantic_Chattel_Slavery_Report.pdf (visited on 09/02/2026).
- [Vil09] Cédric Villani. *Optimal Transport: Old and New*. Springer, 2009.
- [Wil91] David Williams. *Probability with Martingales*. Cambridge University Press, 1991.
- [WZ04] Justin Wolfers and Eric Zitzewitz. “Prediction Markets”. In: *Journal of Economic Perspectives* 18.2 (2004), pp. 107–126. DOI: [10.1257/0895330041371321](https://doi.org/10.1257/0895330041371321).
- [Yaha] Yahoo Finance. *Apple Inc. (AAPL) Historical Prices and Data*. URL: <https://finance.yahoo.com/quote/AAPL/history/> (visited on 09/02/2026).
- [Yahb] Yahoo Finance. *SPDR S&P 500 ETF Trust (SPY) Historical Prices and Data*. URL: <https://finance.yahoo.com/quote/SPY/history/> (visited on 09/02/2026).
- [Yahc] Yahoo Help. *What Is the Adjusted Close?* URL: <https://help.yahoo.com/kb/adjusted-close-sln28256.html> (visited on 09/02/2026).