

随机过程与金融市场

Ou Liu

2026-08-16

编写声明

本文由 Ou Liu 基于 BananaSpace 上的 随机过程与金融市场笔记整理修订而成. 作者负责内容取舍, 数学核验, 参考文献整理和最终表述.

文中涉及数学命题, 金融制度事实和市场机制时, 以正文给出的条件, 引用资料和后续修订为准.

目录

编写声明	ii
第一章 引言	1
1.1 为什么是随机过程	1
1.2 为什么前面还要学习测度论	1
1.3 金融市场作为一个长期例子	1
1.4 模型不是市场	2
1.5 阅读路线	2
第一部分 随机过程的数学基础	3
第二章 测度论基础	4
2.1 可测空间, 测度, Lebesgue 积分	6
2.2 符号测度, Hahn 分解与 Radon–Nikodym 导数	18
第三章 概率论基础	30
3.1 概率空间与随机变量	31
3.2 随机变量的分布	33
3.3 期望与矩	40
3.4 独立性, 条件概率与条件期望	44
3.5 随机变量的收敛与极限定理	50
第四章 随机过程基础	60
4.1 从路径到信息	60
4.2 随机过程, 分布与样本路径	60
4.3 时间与信息	63
4.4 Markov 过程: 当前状态能否代表过去	66
4.5 鞅: 条件平均下没有可预测漂移	68
4.6 计数过程与 Poisson 过程	71
4.7 Brown 运动	72
4.8 有限变差, 二次变差与下一章接口	75
4.9 小结	77
第五章 随机分析基础	78
5.1 从变差到随机微分	78
5.2 路径变差, 二次变差与半鞅	78
5.3 从简单过程构造 Itô 积分	82
5.4 Itô 公式, 乘积公式与随机指数	85
5.5 随机微分方程: 解的含义与基本模型	88
5.6 Girsanov 定理: 在有限期限内改变概率权重	90
5.7 生成元, Kolmogorov 方程与 Feynman–Kac	92
5.8 Poisson 随机测度与跳跃: 进阶接口	94
5.9 连续扩散的计算次序	95
5.10 小结	95
第六章 从随机对象到金融对象: 一张接口图	97
6.1 一时期二叉市场: 从状态到复制	98
6.2 多期离散时间: 鞅, 自融资与基本定理	101

6.3	停时与美式合约: Snell 包络	102
6.4	连续时间桥: 半鞅与随机积分增益	103
6.5	点过程示例: 订单到达与因果边界	105
6.6	从报价到可实现损益: 同一策略的现金账	106
6.7	从概念接口到现实策略	108
第二部分 随机过程与金融市场		109
第七章	金融市场基础	110
7.1	资产头寸, 价格与策略回报	111
7.2	衍生品与或有现金流	119
7.3	预测市场与市场隐含概率	129
7.4	指数, ETF 和被动投资	133
7.5	债券, 美债与利率	141
7.6	美联储, 美元体系与短端资金市场	148
7.7	贴现与无套利	156
7.8	交易, 订单簿与市场微观结构	163
第八章	基本面分析	174
8.1	从资产头寸到可识别价值	174
8.2	Risk-Reward 框架与情景分析	177
8.3	Agentic R/D Graph: 把研究判断组织成可更新的图	183
第九章	趋势交易与技术指标: 从路径变换到可交易策略	192
9.1	从指标到账本	192
9.2	先区分四种趋势	193
9.3	离散交易时钟, 信息集与可预测持仓	193
9.4	滤波的统一语言: 平滑, 时滞与尺度	196
9.5	从滤波器到趋势规则	197
9.6	常见指标: 准确公式与有限含义	201
9.7	随机过程怎样给趋势规则提供基准	203
9.8	研究文献支持到哪一步	204
9.9	指标相同, 状态可以不同	206
9.10	从漂亮回测到可信检验	206
9.11	与资产世界观和估值方法的接口	209
9.12	小结	209
附录 A	金融市场制度史: 危机如何塑造今日结构	210
A.1	荷兰前史: 可转让股份, 结算货币与早期泡沫	211
A.2	英国前史: 公共信用与中央银行职能的形成	212
A.3	从 Buttonwood 到 1907 年: 私人俱乐部及其边界	212
A.4	1913–1935 年: 建立央行不等于已经学会中央银行	213
A.5	Wall Street 的“转正”: 联邦监督下的私人市场	214
A.6	1970–1999 年: 每一次修补都会改变下一次风险的位置	215
A.7	2000–2010 年: 科技泡沫, 影子银行与宏观审慎转向	216
A.8	2010–2026 年: 更快的市场, 非银边界与数字私人货币	216
A.9	泡沫与危机留下了什么	218
A.10	危机前的迟缓与危机中的动员: 一种制度解释	220
A.11	回到随机过程: 历史会改变转移核	221
参考文献		224

第一章 引言

这是一份学习随机过程时逐步整理出来的笔记。

它不打算复刻某一套标准教材的完整体系，更像是一份边学边把路标插好的阅读记录。内容会随着主题逐步补充，证明也按上下文需要展开。主要目标很朴素：尽量用轻松直观的方式，把这些对象到底在研究什么讲明白。

此外，写作时会随手参考各种教材，讲义，论文以及其他资料。出处尽量补齐，但不保证构成一份完整书目。

1.1 为什么是随机过程

概率论最基本的研究对象是随机变量。一个随机变量可以用来描述某一次随机实验中我们关心的某个数值，比如一次抛硬币的结果，某一天的股票价格，或者一段时间内发生了多少次事件。

但现实中的很多随机系统不会只发生一次。

股票价格会不断变化，订单会不断进入市场，电话会不断打进客服中心，粒子会不断运动，一个系统的状态也会随着时间不断演化。

如果只固定在某一个时刻观察，当然仍然可以得到一个随机变量。但如果想研究整个系统随着时间究竟怎样变化，就自然需要同时考虑一整族随机变量 $(X_t)_{t \in T}$ 。这就是所谓的**随机过程**。

随机变量研究“一次观测得到什么”；随机过程进一步研究“这些随机观测随着时间怎样组织在一起”。

更意思的问题也从这里开始出现：不同时间上的随机变量之间有什么关系，过去的信息能够告诉我们多少关于未来的事情，一条随机路径是否连续，一个过程长期以后会不会进入某种稳定状态，以及大量随机扰动叠加以后最终会产生怎样的宏观规律。

1.2 为什么前面还要学习测度论

如果只是做一些有限样本空间上的初等概率计算，完全没有必要先学这么多测度论。

问题在于，一旦开始研究随机过程，样本空间很快就可能变成“所有可能的无限序列”，“所有可能的价格路径”，甚至“所有可能的连续函数”这样巨大而且无限维的空间。

此时一个样本点 ω 本身就可能代表一整条完整的随机路径，而我们需要讨论的事件也会涉及无穷次集合运算，极限以及各种函数空间。

因此现代概率论最终自然建立在测度论之上。

实际上，前面介绍的许多测度论概念，到了概率论里面都只是换了一套语言：测度变成概率，可测集变成事件，可测函数变成随机变量，前推测度变成分布，Lebesgue 积分变成期望。

L^p 空间也会在这里发挥非常直接的作用。随机变量的矩，方差，均方收敛以及大量极限定理，都依赖于 Lebesgue 积分和 L^p 空间提供的结构。

前面的测度论给概率论多加了一点抽象，换来的是一套更结实的语言。等样本空间变成价格路径，连续函数或无限序列时，这套语言不会立刻散架。

1.3 金融市场作为一个长期例子

主线仍是学习随机过程本身，不过股票市场是很方便反复观察的随机系统之一，后面会比较频繁地拿金融市场作为例子。

比如可以令 S_t 表示时刻 t 的股票价格。对于固定的 t ， S_t 只是一个随机变量；而整族 $(S_t)_{t \in T}$ 则构成一个随机过程。

截至时刻 t 已知的全部市场信息可以组织成一条滤过 (filtration, 也称滤链) $(\mathcal{F}_t)$ ；未来价格在当前信息下的条件分布，可以通过条件概率和条件期望进行描述；而“第一次跌破某个价格的时刻”则自然会引出停时。

再往后，随机过程在金融市场中的应用远远不只“预测股价”。

期权定价会引出 Brown 运动，鞅以及随机微分方程；波动率本身可以被建模成随机过程；订单流可以使用计数过程或者点过程进行研究；流动性，市场冲击以及交易执行也都具有明显的动态结构。

甚至很多传统的技术指标也可以重新放进这个框架里面理解。均线，指数移动平均 (exponential

moving average, EMA), 移动平均收敛/发散指标 (moving average convergence/divergence, MACD), 布林带 (Bollinger Band) 或者成交量加权平均价格 (volume-weighted average price, VWAP), 形式上都可以看成对于价格, 成交量或者订单流等随机过程进行某种平滑, 差分或者局部统计以后得到的函数.

这样看指标, 重点先落在一个更清楚的问题上: 它从原始市场路径里压缩出了什么信息? 最近价格水平, 变化速度, 局部波动, 成交密度, 还是订单流方向? 至于这些信息能否稳定帮助判断未来, 还要回到经验数据和市场结构.

1.4 模型不是市场

这里提前放一条很实用的提醒: 模型是地图, 不是地面.

随机过程模型会抽取现实系统的一部分结构, 但它不会把现实系统完整搬进公式.

比如我们可以假设股票价格服从几何 Brown 运动, 可以假设波动率服从某种随机波动率模型, 也可以假设订单流满足某种点过程. 这些模型在特定的定价, 风险管理或者交易执行问题中可能非常有用.

一个模型在某个问题上好用, 只能说明它抓住了那个问题里有用的结构. 到了别的问题上, 被它省略掉的交易制度, 流动性, 资金约束或参与者行为, 可能立刻变成主角.

因此金融市场部分会反复追问三件事: 模型保留了什么, 它能解决什么, 它从哪里开始失效. 把这三件事分清楚, 公式才不会盖过市场本身.

1.5 阅读路线

全书大致有两段路.

第一段先补数学脚手架. 我们从测度和概率论开始, 然后进入样本路径, 有限维分布, 滤过, 停时, Markov 过程, Poisson 过程, Brown 运动, 鞅与随机积分. 这些对象一开始会显得抽象, 但后面都会回到同一个问题: 怎样描述一个随时间展开, 带着信息流和随机扰动的系统.

第二段把这些对象放回金融市场. 资产头寸, 价格与策略回报, 衍生品现金流, 预测市场, 指数与 ETF, 债券和利率, 美元短端资金市场, 贴现与无套利, 订单簿与交易执行, 资产估值, 情景研究, 趋势交易和技术指标, 都会成为这条路上的例子.

Black-Scholes 模型的完整定价推导和随机波动率模型留待后续扩展. 当前版本先提供理解这些主题所需的数学接口, 无套利语言和衍生品现金流基础.

已有概率论基础的读法. 如果已经熟悉概率空间, 随机变量与分布, 期望, 独立性, 条件概率与条件期望, 随机变量收敛以及大数定律和中心极限定理, 可以直接从第四章进入. 碰到测度, 积分或 Radon-Nikodym 导数时, 再回到第二章和第三章补读. 如果概率基础较好但金融基础较少, 可以先读第七章, 再返回第六章看随机对象怎样接上金融对象.

这条路线以后还会长出新的岔路. 遇到更好的随机过程例子或金融应用, 就继续补到相应位置.

第一部分

随机过程的数学基础


第二章 测度论基础

想给随机路径写概率, 先不能急着算概率. 第一件事反而很朴素: 哪些对象算是我们可以提问的事件, 这些事件的大小又该怎样加起来?

这一部分的测度论背景主要参考 [Bog07; Fol99].

所测量的对象通常可以看成集合 X 的子集. 比如测量方块的体积, 就是在给 $\mathbb{R}^3$ 的一个子集“方块”赋予大小. 粗略地说, 我们先要从幂集 $\mathcal{P}(X)$ 中挑出一族允许测量的子集.

那问题就在于, 我们到底需要哪些集合可以被测量呢? 先考虑 $\mathbb{R}^2$ 中最朴素的情况. 对于一个矩形, 我们很容易定义它的面积, 比如 $R = [a, b] \times [c, d]$, 那它的面积就是 $(b - a)(d - c)$. 但是我们不想测矩形. 如果现在想测量一个圆盘 D 的大小, 一个自然的想法就是先把平面切成很多小方块, 然后用这些小方块去逼近这个圆盘.



A_n : 由有限多个小方块拼成的近似

如果这些方块足够小, 那我们可以把圆盘逼近得越来越精确. 为了避免边界问题, 先把 D 理解成开圆盘. 于是可以构造一系列集合 $A_1 \subseteq A_2 \subseteq \dots$, 其中每个 A_n 都只是有限个小矩形的并, 但是随着划分越来越细, 我们希望最后能够有

$$D = \bigcup_{n=1}^{\infty} A_n.$$

这时候问题就出现了. 每一个 A_n 都只是有限个我们已经会测量的小矩形拼起来的, 但要得到 D , 却要把这样的过程无限地做下去. 所以如果希望圆盘也是可以测量的, 自然就要要求: 只要 $A_1, A_2, \dots$ 都可以测量, 它们的可列并 $\bigcup_{n=1}^{\infty} A_n$ 也仍然可以测量.

类似地, 如果一个集合 A 可以测量, 那把它从整个空间 X 中挖掉以后剩下的部分 $A^c = X \setminus A$ 自然也应该是可以测量的. 而有了补集和可列并以后, 根据 De Morgan 律, 可列交其实也就自动有了:

$$\bigcap_{n=1}^{\infty} A_n = \left(\bigcup_{n=1}^{\infty} A_n^c \right)^c.$$

因此我们想找的就是 $\mathcal{P}(X)$ 中的一族集合 $\mathcal{F}$, 它至少应该满足:

1. $X \in \mathcal{F}$;
2. 如果 $A \in \mathcal{F}$, 那么 $A^c \in \mathcal{F}$;
3. 如果 $A_1, A_2, \dots \in \mathcal{F}$, 那么 $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$.

满足这些条件的集合族 $\mathcal{F} \subseteq \mathcal{P}(X)$, 就称为 X 上的一个 σ -代数.

σ -代数规定“哪些集合允许测量”. 它的用处很实在: 保证我们在逼近, 取极限和反复做集合运算时, 不会突然跑到无法测量的对象外面去.

接下来才真正给这些集合赋予“大小”. 对于每一个 $A \in \mathcal{F}$, 我们希望指定一个数 $\mu(A)$, 并让这种赋值符合关于“大小”的基本直觉:

1. 空集应该没有大小, 即 $\mu(\emptyset) = 0$;

2. 如果 $A_1, A_2, \dots$ 彼此不相交, 那么把它们拼起来以后的大小也应该等于它们各自大小的总和:

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

这样的函数 $\mu: \mathcal{F} \rightarrow [0, \infty]$ 就称为一个测度, 而 $(X, \mathcal{F}, \mu)$ 就称为一个测度空间.

到这里其实已经很接近概率论. 概率论同样给一些“事件”赋予大小. 一次实验所有可能的结果组成集合 Ω , 事件 A 是 Ω 的可测子集. 比如掷一次骰子时, 可以取 $\Omega = \{1, 2, 3, 4, 5, 6\}$, “掷出偶数”对应事件 $A = \{2, 4, 6\}$. $\mathbb{P}(A)$ 给这个事件赋予大小, 这个大小现在被解释成“事件发生的概率”.


事件同样可以取并, 取交和补集, 互不相交的事件也应满足可列可加性, 因而概率本身就是一种测度. 额外的归一化条件 $\mathbb{P}(\Omega) = 1$ 表示整个样本空间必然发生. 概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 因此是总测度为 1 的测度空间: 测度论研究一般意义的“大小”, 概率论把这个大小解释为概率, 并把全空间的大小归一化为 1.

给事件赋予概率只是概率论的起点. 很多时候我们真正关心的是随机变量, 以及随机变量的期望, 方差等量. 随机变量是概率空间上的可测函数, 因此接下来还要知道什么样的函数“可以被测量”, 以及应该怎样对这样的函数积分. 这便引出可测映射和 Lebesgue 积分.

从积分的角度来看, 我们其实又可以重新理解一遍为什么前面需要 σ -代数.

我们以前学 Riemann 积分时, 大概是在定义域上做划分. 比如对于 $f: [a, b] \rightarrow \mathbb{R}$, 把 $[a, b]$ 切成许多小区间, 在每个区间上取一个函数值作为高度, 用细长矩形逼近函数图像下的面积. 粗略地说, Riemann 积分是在“竖着切”.

Lebesgue 积分的想法某种程度上反了过来. 与其问“每一小段 x 上面的 $f(x)$ 有多高”, 我们可以按照函数值去看, 被 f 映到某一段高度里的那些 x 组成了多大的集合. 也就是说, 我们开始关心 $f^{-1}([a, b])$ 一类原像的测度.



但是这样一来又会出现一个关键问题. 如果想知道落在某一段函数值中的 x 组成的原像有多大, 首先要保证这个原像是一个能够测量的集合. 比如对于 $f: X \rightarrow \mathbb{R}$, “ $f(x) \leq a$ 的那些 x 有多大”对应集合 $f^{-1}((-\infty, a])$, 因此我们自然希望这个原像属于 X 上的 σ -代数 $\mathcal{F}$.

这就是可测映射的基本想法. 如果 $(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$ 都是可测空间, 那我们要求一个函数 $f: X \rightarrow Y$ 满足: 对于每一个 $B \in \mathcal{G}$, 都有 $f^{-1}(B) \in \mathcal{F}$. 换句话说, Y 中所有能够“辨认”的集合, 拉回到 X 后仍然是可以测量的.

所以 σ -代数在这里又出现了一次. 前面我们需要它, 是因为我们想要测量复杂的集合; 现在我们需要它, 是因为我们想要测量一个函数到底把多少东西送到了某一段取值里面.

有了这个条件以后, 我们就可以开始定义 Lebesgue 积分. 最简单的情况是一个非负简单函数 $s = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$, 其中 $a_i \geq 0$, 每一个 A_i 都是可测集, 并且可以通过细分把这些 A_i 看成两两不交. 那么它的积分自然可以定义成

$$\int_X s d\mu = \sum_{i=1}^n a_i \mu(A_i).$$

这里的意思其实很直接, 函数在 A_i 上的高度是 a_i , 而 A_i 的“大小”是 $\mu(A_i)$, 所以这一层贡献的大小就是 $a_i \mu(A_i)$.

对于一般的非负可测函数 f , 再用越来越精细的简单函数从下方逼近, 并把这些简单函数积分的上确界定义成 f 的 Lebesgue 积分. 从这个角度看, Lebesgue 积分就是把“测量集合”这件事进一步延伸到“测量函数”.

这也回到概率论. 随机变量 $X: \Omega \rightarrow \mathbb{R}$ 是可测函数; 当 X 可积时, 它的期望就是关于概率测度 $\mathbb{P}$ 的 Lebesgue 积分:

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

所以前面引入测度空间, 用途会在后面继续展开. 随机变量, 分布, 期望, 方差乃至随机过程的大量内容, 都会建立在“可测映射 + Lebesgue 积分”这套结构上.

2.1 可测空间, 测度, Lebesgue 积分

2.1.1 可测空间与 σ -代数

前面已经解释过为什么会需要 σ -代数, 现在来看正式定义. 这里我们先换一种方式, 从集合之间的运算看这个对象.

假设 $A, B \subseteq X$ 都是我们已经能够测量的集合. 那如果我们还想测量 $A \cup B$, 一个比较自然的办法就是把它拆成两部分: 一部分是 A 和 B 的交 $A \cap B$, 另一部分是只属于其中一个集合的地方, 也就是它们的对称差

$$A \Delta B = (A \setminus B) \cup (B \setminus A).$$

这两部分彼此不交, 而且刚好拼成整个 $A \cup B$, 也就是

$$A \cup B = (A \Delta B) \sqcup (A \cap B).$$

所以如果 μ 是我们想要的测度, 自然应该有 $\mu(A \cup B) = \mu(A \Delta B) + \mu(A \cap B)$. 为使“测量集合”对这种基本分解保持稳定, 若 A 和 B 都可测, 至少还应有 $A \cap B$ 和 $A \Delta B$ 可测.

下面先看一个偏代数, 但以后偶尔有用的等价视角. 在 $\mathcal{P}(X)$ 上, 我们可以把对称差 Δ 看成某种“加法”, 把交 $\cap$ 看成某种“乘法”. 比如 $A \Delta A = \emptyset$, 所以每个元素都是自己的“加法逆元”, 而 $A \cap A = A$, 所以这个乘法还是幂等的. 在这两个运算下, $\mathcal{P}(X)$ 构成一个布尔环 (Boolean ring).

因此我们也可以先采用下面这个等价定义来理解 σ -代数.

定义 2.1.

σ -代数是指集合族 $\mathcal{F} \subseteq \mathcal{P}(X)$, 其满足:

1. $X \in \mathcal{F}$;
2. 对于任意 $A, B \in \mathcal{F}$, 都有 $A \Delta B \in \mathcal{F}$;
3. 对于任意 $A_1, A_2, \dots \in \mathcal{F}$, 都有

$$\bigcap_{n=1}^{\infty} A_n \in \mathcal{F}.$$

这和通常使用补集和可列并给出的定义等价. 首先因为 $X \in \mathcal{F}$, 对于 $A \in \mathcal{F}$ 有 $A^c = X \Delta A \in \mathcal{F}$, 所以补集自动存在. 有了补集和可列交以后, 根据 De Morgan 律又有 $\bigcup_{n=1}^{\infty} A_n = (\bigcap_{n=1}^{\infty} A_n^c)^c \in \mathcal{F}$, 所以可列并也自动存在.

反过来, 如果按照通常的方式要求对于补集和可列并封闭, 那么交可以由 De Morgan 律得到, 而对称差也可以写成 $A \Delta B = (A \cap B^c) \cup (B \cap A^c)$, 所以两种定义描述的是同一个东西.

定义 2.2.

可测空间是指二元组 $(X, \mathcal{F})$, 其中 X 为集合, $\mathcal{F}$ 为 X 上的 σ -代数.

这里的 X 是所研究的空间. 在概率论中常用 Ω 表示 X , 并称为样本空间; $\mathcal{F}$ 规定其中哪些子集可以“测量”, 此时称为事件域, 其中的元素称为事件.

例 2.3.

对于任意集合 X , 总有两个最自然的 σ -代数, 即 $\{\emptyset, X\}$ 以及 $\mathcal{P}(X)$. 当 $X = \emptyset$ 时二者恰好相同.

如果考虑拓扑空间 (X, τ) , 那我们已经有了—族很自然的子集, 也就是开集. 既然拓扑本身就在描述这个空间中哪些集合在局部结构上是“自然”的, 那我们希望这些开集至少都是可以测量的.

一个拓扑 τ 通常不构成 σ -代数: 它对任意并和有限交封闭, 却未要求对补集封闭. 因此需要在 τ 的基础上补充集合, 直到生成一个 σ -代数.

定义 2.4.

由集合族 $\mathcal{A} \subseteq \mathcal{P}(X)$ 生成的 σ -代数是指

$$\sigma(\mathcal{A}) = \bigcap_{\substack{\mathcal{F} \supseteq \mathcal{A} \\ \mathcal{F} \text{ is a } \sigma\text{-algebra}}} \mathcal{F}.$$

因此 $\sigma(\mathcal{A})$ 是所有包含 $\mathcal{A}$ 的 σ -代数之交.

这里 $\sigma(\mathcal{A})$ 的确是一个 σ -代数, 因为任意一族 σ -代数的交仍然是一个 σ -代数. 而且由定义有 $\mathcal{A} \subseteq \sigma(\mathcal{A})$, 并且对于任意包含 $\mathcal{A}$ 的 σ -代数 $\mathcal{F}$, 都有 $\sigma(\mathcal{A}) \subseteq \mathcal{F}$. 所以 $\sigma(\mathcal{A})$ 正是包含 $\mathcal{A}$ 的最小 σ -代数.

定义 2.5.

拓扑空间 (X, τ) 的 Borel σ -代数是指

$$\mathcal{B}(X) = \sigma(\tau),$$

其中的元素称为 **Borel 集**.

比如在 $\mathbb{R}$ 上取通常的拓扑, 所有开区间 (a, b) 都是 Borel 集. 因为 Borel σ -代数对补集和可列运算封闭, 闭区间, 半开区间, 单点集以及许多更复杂的集合也都是 Borel 集. 具体地,

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(a, b) \mid a < b\}),$$

而且我们甚至不需要所有开区间, 比如

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(-\infty, a] \mid a \in \mathbb{R}\}).$$

所以如果一个空间本身已经带有拓扑, Borel σ -代数可以看作最自然的一种可测结构: 拓扑告诉我们哪些集合在空间结构上是自然的, 而 Borel σ -代数则把这些集合扩张成—族对于可数集合运算稳定的可测集合.

很多时候我们已经知道一个 σ -代数是由—族非常简单的集合生成的, 那自然会希望以后验证某个性质的时候也只需要在这些简单集合上检查, 而不用真的把整个 σ -代数里面所有集合都处理一遍. π - λ 定理正是处理这类问题的工具.

定义 2.6.

π -系是指对于有限交封闭的集合族 $\mathcal{P} \subseteq \mathcal{P}(X)$.

定义 2.7.

λ -系, 也称为 Dynkin 系, 是指集合族 $\mathcal{D} \subseteq \mathcal{P}(X)$, 其满足:

1. $X \in \mathcal{D}$;
2. 对于 $A, B \in \mathcal{D}$, 如果 $A \subseteq B$, 则 $B \setminus A \in \mathcal{D}$;

3. 对于两两不交的 $A_1, A_2, \dots \in \mathcal{D}$, 有

$$\bigsqcup_{n=1}^{\infty} A_n \in \mathcal{D}.$$

λ -系比 σ -代数弱不少, 因为它只要求对彼此不交的可列并封闭. 一个集合族若同时是 π -系和 λ -系, 就是 σ -代数.

定理 2.8 (π - λ 定理).

令 $\mathcal{P}$ 为 X 上的一个 π -系, $\mathcal{D}$ 为一个包含 $\mathcal{P}$ 的 λ -系. 如果 $\mathcal{P} \subseteq \mathcal{D}$, 则有

$$\sigma(\mathcal{P}) \subseteq \mathcal{D}.$$

证明. 记 $\lambda(\mathcal{P})$ 为包含 $\mathcal{P}$ 的最小 λ -系. 固定 $A \in \mathcal{P}$, 并令

$$\mathcal{D}_A = \{B \subseteq X : A \cap B \in \lambda(\mathcal{P})\}.$$

由 λ -系对相对补与不交可列并封闭, $\mathcal{D}_A$ 也是 λ -系. 又因为 $\mathcal{P}$ 是 π -系, 对 $B \in \mathcal{P}$ 有 $A \cap B \in \mathcal{P}$, 所以 $\mathcal{P} \subseteq \mathcal{D}_A$. 最小性给出 $\lambda(\mathcal{P}) \subseteq \mathcal{D}_A$.

现在固定 $B \in \lambda(\mathcal{P})$, 并令

$$\mathcal{E}_B = \{A \subseteq X : A \cap B \in \lambda(\mathcal{P})\}.$$

同理, $\mathcal{E}_B$ 是 λ -系; 上一步说明它包含 $\mathcal{P}$, 故它也包含 $\lambda(\mathcal{P})$. 因此 $\lambda(\mathcal{P})$ 对有限交封闭. 一个同时为 π -系和 λ -系的集合族对补集与任意可列并封闭, 因而是 σ -代数. 所以

$$\sigma(\mathcal{P}) = \lambda(\mathcal{P}) \subseteq \mathcal{D}.$$

这一两次固定集合的证明也见 [Kal21, Theorem 1.1]. □

π - λ 定理告诉我们, 如果一族生成元对于有限交已经足够稳定, 那么要把某个性质从这些生成元推广到整个 σ -代数, 很多时候只需要证明满足这个性质的集合构成一个 λ -系即可.

推论 2.9.

令 μ, ν 为 $(X, \mathcal{F})$ 上的有限测度, $\mathcal{P}$ 为满足 $\sigma(\mathcal{P}) = \mathcal{F}$ 的 π -系. 如果 $\mu(X) = \nu(X)$, 并且对于任意 $A \in \mathcal{P}$ 都有 $\mu(A) = \nu(A)$, 则有

$$\mu = \nu.$$

比如在 $\mathbb{R}$ 上, 因为半直线族 $\{(-\infty, a] \mid a \in \mathbb{R}\}$ 生成整个 $\mathcal{B}(\mathbb{R})$, 所以后面要证明两个概率分布相同的时候, 很多时候只需要比较这些半直线的概率即可. 这也就是为什么分布函数能够唯一确定一个概率分布.

正如拓扑空间之间存在连续映射一样, 可测空间之间也存在可测映射.

定义 2.10.

令 $(X, \mathcal{F})$ 以及 $(Y, \mathcal{G})$ 为可测空间. 称映射 $f: X \rightarrow Y$ 为**可测映射**, 是指其满足对于任意 $A \in \mathcal{G}$, 都有

$$f^{-1}(A) \in \mathcal{F}.$$

这很像连续映射定义的翻版. 连续映射要求开集的原像仍然是开集, 而可测映射要求可测集的原像仍然是可测集. 如果使用一点范畴语言, 也可以考虑范畴 **Meas**: 它的对象是可测空间, 态射是可测映射. 不熟悉这套语言也没有关系, 这里主要只是强调可测映射是可测空间之间合适的结构保持映射.

注 2.11.

稍后我们将会发现, 随机变量就是概率空间到 $\mathbb{R}$ 的可测映射.

2.1.2 测度

可测空间 $(X, \mathcal{F})$ 只规定哪些集合可以测量, 尚未指定它们的大小. 下一步是在 $\mathcal{F}$ 上定义函数, 为每个可测集赋予非负的“大小”.

这个赋值需要满足基本约束. 空集没有大小, 因而取值为 0. 如果把集合拆成若干彼此不相交的部分, 整体大小应等于各部分大小之和. 前面的 σ -代数允许可列次集合运算, 这里也相应要求可列可加性.

定义 2.12.

令 $(X, \mathcal{F})$ 为可测空间. 称函数 $\mu: \mathcal{F} \rightarrow [0, \infty]$ 为 X 上的一个 **测度**, 是指其满足:

1. $\mu(\emptyset) = 0$;
2. 对于任意一列两两不交的可测集 $A_1, A_2, \dots \in \mathcal{F}$, 都有

$$\mu\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

测度空间是指三元组 $(X, \mathcal{F}, \mu)$, 其中 $(X, \mathcal{F})$ 为可测空间, μ 为 $\mathcal{F}$ 上的测度.

第二个条件通常称为可列可加性或者 σ -可加性.

- 从可列可加性马上就可以得到有限可加性. 比如如果 $A \cap B = \emptyset$, 那么有 $\mu(A \sqcup B) = \mu(A) + \mu(B)$.
- 如果 $A \subseteq B$, 那么 $B = A \sqcup (B \setminus A)$, 所以 $\mu(B) = \mu(A) + \mu(B \setminus A)$, 从而有 $\mu(A) \leq \mu(B)$. 这称为测度的单调性.
- 如果进一步有 $\mu(A) < \infty$, 那么由同一个分解还可以得到 $\mu(B \setminus A) = \mu(B) - \mu(A)$. 这里之所以需要有限性, 是因为扩展实数中不能随便处理 $\infty - \infty$.
- 对于一般的两个可测集 A, B , 前面的对称差分解给出

$$\mu(A \cup B) = \mu(A \Delta B) + \mu(A \cap B).$$

- 将 A 和 B 分别拆开以后还可以得到熟悉的包含排除公式

$$\mu(A \cup B) + \mu(A \cap B) = \mu(A) + \mu(B).$$

还有一种后面会反复遇到的集合, 就是大小为 0 的集合.

定义 2.13.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称可测集 $N \in \mathcal{F}$ 为**零测集**, 是指其满足

$$\mu(N) = 0.$$

零测集虽然不一定真的是空集, 但是从测度的角度来看它已经和空集非常接近. 比如在 $\mathbb{R}$ 上取 Lebesgue 测度时, 每个单点集都是零测集, 因而任何可数集也都是零测集.

这里还有一个问题. 若 N 是零测集且 $A \subseteq N$, 直觉上 A 也应具有大小 0. 然而 A 未必属于原来的 σ -代数 $\mathcal{F}$, 此时 $\mu(A)$ 没有定义. 测度空间的完备性正用来区分这种情况.

定义 2.14.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称其为**完备测度空间**, 是指对于任意零测集 $N \in \mathcal{F}$ 以及任意子集 $A \subseteq N$, 都有 $A \in \mathcal{F}$.

在完备测度空间中, 零测集的所有子集都会自动成为可测集. 后面会看到, Lebesgue 测度是完备的, 其限制在 Borel σ -代数上的版本则不完备.

有了零测集以后, 我们也可以正式定义一个后面会经常出现的说法.

定义 2.15.

令 $(X, \mathcal{F}, \mu)$ 为测度空间. 称一个关于 $x \in X$ 的性质 **几乎处处成立**, 是指存在零测集 N , 使得这个性质对于所有 $x \in X \setminus N$ 都成立. 常记作 μ -a.e., 或者在没有歧义的时候直接写作 a.e.

比如 $f = g$ a.e. 就是说它们可以在一个零测集上不相同, 但是除此以外完全一样. 对于 Lebesgue 积分而言, 这种零测集上的差别通常是看不见的.

允许测度取值为 ∞ , 才能容纳无限大小的空间. 比如 $\mathbb{R}$ 上通常的长度满足 $\mu(\mathbb{R}) = \infty$, 但仍给出一个自然的测度.

定义 2.16.

令 $(X, \mathcal{F}, \mu)$ 为测度空间.

- 称 μ 为一个 **有限测度**, 是指其满足 $\mu(X) < \infty$.
- 称 μ 为一个 **σ -有限测度**, 是指存在一列可测集 $A_1, A_2, \dots \in \mathcal{F}$, 满足

$$X = \bigcup_{n=1}^{\infty} A_n, \quad \mu(A_n) < \infty.$$

有限测度一定是 σ -有限测度, 反之不成立. σ -有限表示整个空间即使有无限测度, 仍可由可列多个有限测度的部分覆盖.

比如 $\mathbb{R}$ 上的 Lebesgue 测度是无限测度, 同时又是 σ -有限的, 因为 $\mathbb{R} = \bigcup_{n=1}^{\infty} [-n, n]$ 而每个 $[-n, n]$ 都只有有限测度.

这个条件看似很弱, 却十分常见. 后面的 Radon-Nikodym 定理, Fubini 定理等结果都会再次用到它.

概率测度是特殊的有限测度, 因为对于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 总有 $\mathbb{P}(\Omega) = 1$.

若空间 X 还带有拓扑, 通常还希望测度与拓扑良好配合, 由此引出 Radon 测度.

定义 2.17.

令 X 为局部紧 Hausdorff 空间, μ 为定义在 $\mathcal{B}(X)$ 上的 Borel 测度. 称 μ 为 **Radon 测度**, 是指其满足:

1. 在紧集上有限;
2. 对于任意 Borel 集 A , 有内正则性

$$\mu(A) = \sup\{\mu(K) \mid K \subseteq A, K \text{ compact}\};$$

3. 对于任意 Borel 集 A , 有外正则性

$$\mu(A) = \inf\{\mu(U) \mid A \subseteq U, U \text{ open}\}.$$

这个定义要求集合的测度既能从内部用紧集逼近, 也能从外部用开集逼近. Radon 测度由此刻画测度与拓扑的相容性, 而非整个空间的总大小.

不同文献对一般拓扑空间上的 Radon 测度有略微不同的定义. 对后面主要遇到的 $\mathbb{R}^n$ 一类空间, 可将其理解为“局部有限且正则的 Borel 测度”. $\mathbb{R}^n$ 上的 Lebesgue 测度限制到 Borel σ -代数后, 就是最重要的 Radon 测度之一.

例 2.18.

在任意集合 X 上都可以定义计数测度

$$\mu(A) = \#A,$$

其中有限集取它的元素个数, 无限集则令 $\mu(A) = \infty$. 这是最简单的非平凡测度之一.

例 2.19.

固定一个点 $x \in X$, 可以定义 Dirac 测度 δ_x 为

$$\delta_x(A) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

整个测度都集中在点 x 上.

在概率论中, 概率 $\mathbb{P}$ 是满足额外条件 $\mathbb{P}(\Omega) = 1$ 的测度. 因此概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 可以看成总测度为 1 的测度空间.

Lebesgue 测度 接下来考虑一个重要例子: $\mathbb{R}^d$ 上的 Lebesgue 测度. 它严格实现前面关于“长度”, “面积”和“体积”的直觉.

按照我们一开始的想法, 要测量一个复杂的集合, 一个很自然的方法就是先从我们已经知道怎么计算大小的简单集合开始, 然后用这些简单集合去覆盖它. 在 $\mathbb{R}^d$ 中, 最方便的简单集合就是半开矩形.

定义 2.20 (体积函数).

半开矩形是指形如

$$[a, b) = \prod_{i=1}^d [\alpha_i, \beta_i)$$

的集合, 其中 $a = (\alpha_1, \dots, \alpha_d)$, $b = (\beta_1, \dots, \beta_d) \in \mathbb{R}^d$, 并且对于所有 $i = 1, \dots, d$ 都有 $\alpha_i \leq \beta_i$.

半开矩形 $[a, b)$ 的体积定义为

$$\lambda([a, b)) = \prod_{i=1}^d (\beta_i - \alpha_i).$$

如果存在某个 i 使得 $\alpha_i = \beta_i$, 那么 $[a, b) = \emptyset$, 此时自然有 $\lambda([a, b)) = 0$.

注 2.21.

原则上我们也可以从开矩形或者闭矩形出发, 但是半开矩形 $[a, b)$ 在集合运算上具有更好的性质. 所有半开矩形构成一个半环, 特别是两个半开矩形之差总可以写成有限多个彼此不交的半开矩形之并.

这里出现了一个更一般的问题. 目前只在简单矩形上定义了“大小”, 最终却希望在它们生成的 σ -代数上得到测度. 是否存在一般的扩张方法?

答案就是 Carathéodory 扩张定理.

首先, 半开矩形本身只构成一个半环, 所以我们可以考虑由有限多个彼此不交的半开矩形之并所构成的集合代数 $\mathcal{A}$. 对于 $A = \bigsqcup_{i=1}^n I_i \in \mathcal{A}$, 自然定义 $\lambda_0(A) = \sum_{i=1}^n \lambda(I_i)$. 这样我们就把矩形上的体积扩张到了一个集合代数上.

定义 2.22 (预测度).

令 $\mathcal{A}$ 为 X 上的一个集合代数. 称函数 $\mu_0: \mathcal{A} \rightarrow [0, \infty]$ 为一个预测度, 是指其满足 $\mu_0(\emptyset) = 0$, 并且对于任意两两不交的 $A_1, A_2, \dots \in \mathcal{A}$, 如果 $\bigsqcup_{n=1}^{\infty} A_n \in \mathcal{A}$, 则有

$$\mu_0\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu_0(A_n).$$

预测度已经具备测度所需的可加性, 但 $\mathcal{A}$ 尚未构成 σ -代数. Carathéodory 扩张定理把预测度扩张为 $\sigma(\mathcal{A})$ 上的测度.

定理 2.23 (Carathéodory 扩张定理).

令 $\mathcal{A}$ 为 X 上的一个集合代数, μ_0 为 $\mathcal{A}$ 上的预测度. 则存在定义在 $\sigma(\mathcal{A})$ 上的测度 μ , 使得

$$\mu|_{\mathcal{A}} = \mu_0.$$

如果进一步 μ_0 是 σ -有限的, 则这样的扩张唯一.

证明. 对任意 $E \subseteq X$ 定义外测度

$$\mu^*(E) = \inf \left\{ \sum_{n=1}^{\infty} \mu_0(A_n) : E \subseteq \bigcup_{n=1}^{\infty} A_n, A_n \in \mathcal{A} \right\}.$$

覆盖的拼接说明 μ^* 单调且可列次可加. 再令

$$\mathcal{M} = \{C \subseteq X : \mu^*(E) = \mu^*(E \cap C) + \mu^*(E \setminus C) \text{ 对所有 } E \subseteq X\}.$$

Carathéodory 判据的基本运算表明 $\mathcal{M}$ 是 σ -代数, 并且 $\mu^*|_{\mathcal{M}}$ 在不交可列并上可加. 预测度的可列可加性进一步给出 $\mathcal{A} \subseteq \mathcal{M}$ 且 $\mu^*(A) = \mu_0(A)$ 对每个 $A \in \mathcal{A}$ 成立. 因而 $\sigma(\mathcal{A}) \subseteq \mathcal{M}$, 把 μ^* 限制到 $\sigma(\mathcal{A})$ 就得到所需扩张.

若 $X = \bigcup_m E_m$, $E_m \in \mathcal{A}$ 且 $\mu_0(E_m) < \infty$, 先以 $B_m = E_1 \cup \dots \cup E_m$ 把覆盖改成递增的有限测度块. 两个扩张限制到 B_m 后, 在 $\{A \cap B_m : A \in \mathcal{A}\}$ 上一致, 因而由 π - λ 定理在 $\sigma(\mathcal{A})|_{B_m}$ 上一致; 再令 $m \rightarrow \infty$ 便得到全局唯一性. 外测度构造的完整核验见 [Kal21, Theorem 2.5]; σ -有限唯一性见 [Kal21, Lemma 1.18], 或参见 [Dur19, Theorem A.1.3]. $\square$

因此无须一开始就在所有复杂集合上定义测度. 先在一批足够简单且能生成目标 σ -代数的集合上定义大小, 再由 Carathéodory 定理完成扩张.

这个扩张的具体做法其实也和我们一开始“拿小方块覆盖复杂图形”的想法一致. 第一步是先不管一个集合到底是否真的可测, 直接给所有子集定义一个外部的大小.

定义 2.24 (Lebesgue 外测度).

Lebesgue 外测度是指函数 $\theta: \mathcal{P}(\mathbb{R}^d) \rightarrow [0, \infty]$, 其中对于任意 $A \subseteq \mathbb{R}^d$ 定义

$$\theta(A) = \inf \left\{ \sum_{n=1}^{\infty} \lambda(I_n) \mid A \subseteq \bigcup_{n=1}^{\infty} I_n, I_n \text{ 为半开矩形} \right\}.$$

这里用可列多个体积已知的半开矩形覆盖 A , 再对所有覆盖的总体积取下确界. 这从一开始“用很多小方块逼近复杂图形”的想法严格化了.

Lebesgue 外测度满足 $\theta(\emptyset) = 0$, 单调性, 以及可列次可加性

$$\theta \left(\bigcup_{n=1}^{\infty} A_n \right) \leq \sum_{n=1}^{\infty} \theta(A_n).$$

θ 此时只是外测度, 尚非定义在整个 $\mathcal{P}(\mathbb{R}^d)$ 上的测度. 上面的不等式一般不能改成等号, 因此还要从所有集合中选出满足可加性要求的集合.

定义 2.25 (Carathéodory 可测集).

令 θ 为 $\mathbb{R}^d$ 上的 Lebesgue 外测度. 称集合 $E \subseteq \mathbb{R}^d$ 为 θ -可测集, 是指其满足对于任意 $A \subseteq \mathbb{R}^d$ 都有

$$\theta(A) = \theta(A \cap E) + \theta(A \setminus E).$$

这个条件表示, E 能把任意集合 A 分成“在 E 里面”和“在 E 外面”两部分, 且切分不会增加或损失外测度.

令

$$\mathcal{L}(\mathbb{R}^d) = \left\{ E \subseteq \mathbb{R}^d \mid \forall A \subseteq \mathbb{R}^d, \theta(A) = \theta(A \cap E) + \theta(A \setminus E) \right\}.$$

Carathéodory 的结果表明, $\mathcal{L}(\mathbb{R}^d)$ 是一个 σ -代数, 而且 θ 限制到它上面后具有可列可加性.

定义 2.26 (Lebesgue 测度).

$\mathbb{R}^d$ 上的 **Lebesgue σ -代数**是指 $\mathcal{L}(\mathbb{R}^d)$, 其中的元素称为 **Lebesgue 可测集**.
 $\mathbb{R}^d$ 上的 **Lebesgue 测度**是指测度

$$\lambda_d = \theta|_{\mathcal{L}(\mathbb{R}^d)}.$$

于是我们最终得到了测度空间 $(\mathbb{R}^d, \mathcal{L}(\mathbb{R}^d), \lambda_d)$. 整个过程可概括为

矩形上的体积 $\rightarrow$ 预测度 $\rightarrow$ 外测度 $\rightarrow$ Carathéodory 可测集 $\rightarrow$ Lebesgue 测度.

在 $\mathbb{R}^d$ 上, Borel σ -代数与 Lebesgue σ -代数满足严格包含关系

$$\mathcal{B}(\mathbb{R}^d) \subsetneq \mathcal{L}(\mathbb{R}^d).$$

所有 Borel 集都 Lebesgue 可测, 还有一些 Lebesgue 可测集不属于 Borel 集.

两者之间的差别基本上就来自我们前面说的零测集. 将 Lebesgue 测度先限制在 $\mathcal{B}(\mathbb{R}^d)$ 上, 再把所有 Borel 零测集的任意子集都补进来, 得到的正好就是 $\mathcal{L}(\mathbb{R}^d)$. 所以 Lebesgue σ -代数也可以理解成 Borel σ -代数关于 Lebesgue 测度的测度完备化.

特别地, Lebesgue 测度是完备测度. 它限制在 Borel σ -代数上的版本是 Radon 测度, 但不完备.

2.1.3 Lebesgue 积分

现在, 我们来介绍 Lebesgue 积分. 下设 $(X, \mathcal{F}, \mu)$ 是一个测度空间.

Lebesgue 积分沿用前面的分层思路. Riemann 积分按定义域“竖着切”, Lebesgue 积分则更接近按函数值“横着切”. 先看只取有限多个值的函数: 每个高度对应一个可测集, 将“高度 $\times$ 集合的测度”求和即可.

定义 2.27 (非负简单函数及其积分).

非负简单函数是指可测集的指示函数的非负有限线性组合, 即形如 $s = \sum_{i=1}^n a_i 1_{E_i}$ 的函数, 其中 $a_i \geq 0$, $E_i \in \mathcal{F}$.

非负简单函数 s 的 Lebesgue 积分是指

$$\int_X s \, d\mu = \sum_{i=1}^n a_i \mu(E_i),$$

其中约定 $0 \cdot \infty = 0$. 将这些集合进一步拆成两两不交的部分以后, 由测度的可加性可以验证这个值只和 s 本身有关, 和它具体如何写成指示函数的线性组合无关.

一般的非负函数通常不能精确写成有限多个指示函数的线性组合. 可以用越来越精细的简单函数从下方逼近它.

定义 2.28 (非负可测函数及其积分).

非负可测函数是指可测函数 $f: X \rightarrow [0, \infty]$.

非负可测函数 f 的 Lebesgue 积分是指

$$\int_X f \, d\mu = \sup \left\{ \int_X s \, d\mu \mid s \text{ 是非负简单函数且 } s \leq f \right\}.$$

这个积分允许取值 $+\infty$.

这个定义的直觉很直接: 我们把所有能够放在 f 下面的简单函数都拿出来, 看它们的积分最多能够逼近到哪里, 然后把这个上确界定成 f 的积分.

对于一般实值函数, 只需要把正负两部分拆开.

定义 2.29 (Lebesgue 可积函数及其积分).

令 $f: X \rightarrow \mathbb{R}$ 为可测函数, 并记 $f_+ = \max\{f, 0\}$, $f_- = \max\{-f, 0\}$. 则 f_+ 和 f_- 都是非负可测函数, 并且 $f = f_+ - f_-$, $|f| = f_+ + f_-$.

称 f 为 **Lebesgue 可积函数**, 或简称**可积函数**, 是指 f_+ 和 f_- 都具有有限的 Lebesgue 积分. 此时定义

$$\int_X f \, d\mu = \int_X f_+ \, d\mu - \int_X f_- \, d\mu.$$

因此 f 可积也就等价于 $\int_X |f| \, d\mu < \infty$. 上面几个定义在重合的地方是一致的.

我们之后还会经常只在某个可测集上积分, 所以对于 $A \in \mathcal{F}$ 约定

$$\int_A f \, d\mu := \int_X f 1_A \, d\mu.$$

特别地, $\int_A 1 \, d\mu = \mu(A)$. 因而测度也可以看成指示函数的积分.

定义 2.30 (可积向量值函数及其积分).

令 V 为有限维 $\mathbb{R}$ -向量空间, 并赋予通常的 Borel σ -代数, $f: X \rightarrow V$ 为可测函数. 取 V 的一组基 $v_1, \dots, v_n$, 并写成 $f = \sum_{i=1}^n f_i v_i$.

称 f 为**可积函数**, 是指每个 f_i 都在实值可积函数定义的意义下可积. 此时定义

$$\int_X f \, d\mu = \sum_{i=1}^n \left(\int_X f_i \, d\mu \right) v_i.$$

由积分的线性性可以验证这个定义和基的选取无关.

特别地, $\mathbb{C}$ 可以被看成二维实向量空间, 所以复值函数的积分也包括在这里面.

一些例子 最典型的情况是 $\mathbb{R}^n$ 上的 Lebesgue 测度. 比如在一个有界矩形上, 如果 f 是 Riemann 可积函数, 那么它也是 Lebesgue 可积的, 并且两种积分给出的值相同. 不过对于广义 Riemann 积分就不能直接这么说, 因为广义 Riemann 积分可能依靠正负抵消而收敛, 但对应函数并不 Lebesgue 可积.

另一个很简单的例子是计数测度. 比如取 $X = \mathbb{N}$, μ 为计数测度, 那么

$$\int_X f \, d\mu = \sum_{n=1}^{\infty} f(n)$$

在有意义的时候就是普通的级数. 所以 Lebesgue 积分同时包含了我们以前认为有些不同的“积分”和“求和”.

基本性质与收敛定理 与前文相同, 下设 $(X, \mathcal{F}, \mu)$ 为测度空间.

命题 2.31 (单调性).

令 f, g 为非负可测函数或者实值可积函数. 如果 $f \leq g$ a.e., 则有

$$\int f \leq \int g.$$

特别地, 如果 $f = g$ a.e., 则有 $\int f = \int g$.

证明. 依次按照简单函数积分, 非负可测函数积分和实值可积函数积分的定义验证即可. $\square$

命题 2.32 (数乘).

令 f 为非负可测函数且 $a \geq 0$, 或者令 f 为实值可积函数且 $a \in \mathbb{R}$. 则有

$$\int af = a \int f.$$

证明. 依次按照简单函数积分, 非负可测函数积分和实值可积函数积分的定义验证即可. $\square$

接下来需要说明一个我们在定义 Lebesgue 积分的时候其实已经默认使用的事实, 也就是非负可测函数确实都可以由简单函数从下面不断逼近.

引理 2.33 (简单函数逼近).

令 $f: X \rightarrow [0, \infty]$ 为可测函数. 对于正整数 n , 定义

$$\varphi_n(x) = \begin{cases} 2^{-n} \lfloor 2^n f(x) \rfloor, & f(x) < n, \\ n, & f(x) \geq n. \end{cases}$$

则每个 φ_n 都是非负简单函数, 并且 $\varphi_1 \leq \varphi_2 \leq \cdots \leq f$, 且 $\varphi_n(x) \rightarrow f(x)$.

证明. 每个 φ_n 只取有限多个值, 而这些取值对应的原像都可以由 f 的区间原像写出, 所以 φ_n 是可测简单函数. 当 $f(x) < n$ 时有 $0 \leq f(x) - \varphi_n(x) < 2^{-n}$, 而如果 $f(x) = \infty$, 那么 $\varphi_n(x) = n \rightarrow \infty$. 其余性质直接验证即可. $\square$

这其实也就是我们前面说 Lebesgue 积分是在“横着切”的一个比较严格的版本. 我们把函数的值域按照越来越细的网格切开, 得到一系列阶梯状的简单函数, 然后让它们从下面逐渐贴近原来的函数.

定理 2.34 (单调收敛定理).

令 $f, f_1, f_2, \dots$ 为非负可测函数. 如果 $f_n \leq f_{n+1}$, 并且 $f_n \rightarrow f$ 逐点成立, 则有

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 由单调性, $(\int f_n)$ 单调递增且 $\int f_n \leq \int f$, 所以 $\lim_n \int f_n \leq \int f$.

反过来, 任取非负简单函数 $\phi \leq f$ 以及 $\alpha \in (0, 1)$, 令 $E_n = \{x \in X \mid f_n(x) \geq \alpha \phi(x)\}$. 则 E_n 递增且 $\bigcup_n E_n = X$, 因而

$$\int f_n \geq \int_{E_n} f_n \geq \alpha \int_{E_n} \phi.$$

对简单函数 ϕ 而言, $A \mapsto \int_A \phi d\mu$ 是一个测度, 所以由测度对于递增集合列的连续性有 $\int_{E_n} \phi \rightarrow \int \phi$. 因而 $\lim_n \int f_n \geq \alpha \int \phi$. 最后令 $\alpha \rightarrow 1^-$, 再对所有满足 $0 \leq \phi \leq f$ 的简单函数取上确界即可. $\square$

结合简单函数逼近引理和单调收敛定理, 每一个非负可测函数都可以由一系列递增的简单函数逼近, 而且这些简单函数的积分也同时趋于原函数的积分.

命题 2.35 (可列加性).

令 $f_1, f_2, \dots$ 为非负可测函数. 则有

$$\int_X \sum_{k=1}^{\infty} f_k d\mu = \sum_{k=1}^{\infty} \int_X f_k d\mu.$$

证明. 先考虑两个函数. 分别取递增简单函数序列 $\phi_n \uparrow f_1$ 和 $\psi_n \uparrow f_2$, 那么 $\phi_n + \psi_n \uparrow f_1 + f_2$. 由简单函数积分的加性以及单调收敛定理,

$$\int (f_1 + f_2) = \lim_n \int (\phi_n + \psi_n) = \int f_1 + \int f_2.$$

有限多个函数的情况由归纳得到. 最后令 $S_n = \sum_{k=1}^n f_k$, 则 $S_n \uparrow \sum_{k=1}^\infty f_k$, 再使用一次单调收敛定理即可. $\square$

引理 2.36 (Fatou 引理).

令 $f_1, f_2, \dots$ 为非负可测函数. 则有

$$\int \liminf_{n \rightarrow \infty} f_n \leq \liminf_{n \rightarrow \infty} \int f_n.$$

证明. 令 $g_k = \inf_{n \geq k} f_n$, 则 g_k 是非负可测函数, 并且 $g_k \uparrow \liminf_n f_n$. 由单调收敛定理,

$$\int \liminf_n f_n = \lim_{k \rightarrow \infty} \int g_k.$$

对任意 $j \geq k$ 有 $g_k \leq f_j$, 所以 $\int g_k \leq \inf_{j \geq k} \int f_j$. 令 $k \rightarrow \infty$ 即得结论. $\square$

定理 2.37 (控制收敛定理).

令 $f, f_1, f_2, \dots$ 为可测函数. 如果 $f_n \rightarrow f$ a.e., 并且存在可积函数 g 使得对于所有 n 都有 $|f_n| \leq g$ a.e., 则 f 可积, 并且

$$\int f = \lim_{n \rightarrow \infty} \int f_n.$$

证明. 由 $f_n \rightarrow f$ a.e. 以及 $|f_n| \leq g$ a.e., 可以得到 $|f| \leq g$ a.e., 所以 f 可积.

对非负函数 $g + f_n$ 和 $g - f_n$ 分别使用 Fatou 引理, 得到

$$\begin{aligned} \int g + \int f &\leq \int g + \liminf_{n \rightarrow \infty} \int f_n, \\ \int g - \int f &\leq \int g - \limsup_{n \rightarrow \infty} \int f_n. \end{aligned}$$

因为 $\int g < \infty$, 可以把它消掉, 从而有

$$\int f \leq \liminf_n \int f_n \leq \limsup_n \int f_n \leq \int f.$$

所以 $\int f_n \rightarrow \int f$. $\square$

乘积测度与 Fubini 定理 接下来我们考虑乘积空间. 令 $(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$ 为两个可测空间. 从范畴语言看, 我们希望它们在 $\mathbf{Meas}$ 中也有对应的积.

定义 2.38 (乘积可测空间).

可测空间 $(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$ 的乘积可测空间是指

$$(X \times Y, \mathcal{F} \otimes \mathcal{G}),$$

其中

$$\mathcal{F} \otimes \mathcal{G} = \sigma\{A \times B \mid A \in \mathcal{F}, B \in \mathcal{G}\}.$$

等价地, $\mathcal{F} \otimes \mathcal{G}$ 是使两个投影 $\pi_X: X \times Y \rightarrow X$ 和 $\pi_Y: X \times Y \rightarrow Y$ 同时可测的最小 σ -代数. 因此 $(X \times Y, \mathcal{F} \otimes \mathcal{G})$ 正是 $(X, \mathcal{F})$ 和 $(Y, \mathcal{G})$ 在 $\mathbf{Meas}$ 中的积.

现在再分别给两个空间放上测度 μ 和 ν . 如果我们已经知道 A 和 B 的大小, 那矩形 $A \times B$ 的大小自然应该是 $\mu(A)\nu(B)$, 而 Carathéodory 扩张定理正好可以把这个赋值扩张到整个乘积 σ -代数.

定义 2.39 (乘积测度).

令 $(X, \mathcal{F}, \mu)$ 和 $(Y, \mathcal{G}, \nu)$ 为 σ -有限测度空间. 乘积测度 $\mu \otimes \nu$ 是指定义在 $\mathcal{F} \otimes \mathcal{G}$ 上唯一满足

$$(\mu \otimes \nu)(A \times B) = \mu(A)\nu(B)$$

的测度.

乘积可测空间是 **Meas** 中的范畴积. 乘积测度一般不具备相应的范畴积性质; 特别是在概率论中, $\mu \otimes \nu$ 对应具有边缘分布 μ, ν 的独立联合分布.

比如 $\mathbb{R}^2 = \mathbb{R} \times \mathbb{R}$ 上的二维 Lebesgue 测度, 就可以理解成一维 Lebesgue 测度和自身的乘积.

有了乘积测度以后, 自然就会问一个很熟悉的问题: 如果 $f(x, y)$ 定义在 $X \times Y$ 上, 那我们能不能先对 y 积分, 再对 x 积分, 或者反过来?

对于非负函数, 答案由 Tonelli 定理给出.

定理 2.40 (Tonelli 定理).

令 $(X, \mathcal{F}, \mu)$ 和 $(Y, \mathcal{G}, \nu)$ 为 σ -有限测度空间, $f: X \times Y \rightarrow [0, \infty]$ 为 $\mathcal{F} \otimes \mathcal{G}$ -可测函数. 则有

$$\begin{aligned} \int_{X \times Y} f \, d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) \, d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) \, d\mu(x) \right) d\nu(y), \end{aligned}$$

其中允许积分取值 $+\infty$.

对非负函数, Tonelli 定理允许在积分可能为 $+\infty$ 时交换次序.

一般实值函数还要排除正负部分均积分到无穷所产生的 $\infty - \infty$. 最常用的条件是绝对可积.

定理 2.41 (Fubini 定理).

令 $(X, \mathcal{F}, \mu)$ 和 $(Y, \mathcal{G}, \nu)$ 为 σ -有限测度空间, $f: X \times Y \rightarrow \mathbb{R}$ 为可测函数. 如果

$$\int_{X \times Y} |f| \, d(\mu \otimes \nu) < \infty,$$

则对于 μ -a.e. $x \in X$, 函数 $y \mapsto f(x, y)$ 在 Y 上可积; 对于 ν -a.e. $y \in Y$, 函数 $x \mapsto f(x, y)$ 在 X 上可积. 在相应的例外零测集上, 把尚未定义的内层积分约定为 0, 并继续用同一记号表示由此得到的可测版本. 此时

$$\begin{aligned} \int_{X \times Y} f \, d(\mu \otimes \nu) &= \int_X \left(\int_Y f(x, y) \, d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) \, d\mu(x) \right) d\nu(y). \end{aligned}$$

Tonelli 与 Fubini 的证明主线 先取矩形指标函数 $f = \mathbf{1}_{A \times B}$. 两次积分都等于 $\mu(A)\nu(B)$; 再用单调类论证把结论从矩形推广到任意乘积可测集合的指标函数. 线性组合给出非负简单函数的结论. 对一般非负可测 f , 取简单函数 $f_n \uparrow f$, 并在乘积空间与两个内层积分中分别使用单调收敛定理, 便得到 Tonelli 等式以及内层积分的可测性.

对一般实值 f , 先把 Tonelli 用于 $|f|$. $\int |f| < \infty$ 说明几乎每个截面都绝对可积; 随后分别对 f^+ 与 f^- 使用 Tonelli 并相减, 得到 Fubini 等式. 因此, 能否交换积分顺序取决于非负性或绝对可积性, 不能只看公式外观. 完整证明见 [Kal21, Theorem 1.29] 或 [Dur19, Theorem 1.7.2].

所以 Tonelli 和 Fubini 其实是在处理同一件事情, 只是使用条件稍有不同. 如果函数非负, 那么优先考虑 Tonelli; 如果函数可能有正有负, 那就先检查 $|f|$ 是否可积, 然后使用 Fubini.

注 2.42.

对后面的概率论来说, 关键是先检查非负性或绝对可积性, 再决定能否交换积分顺序.

前推测度与积分 最后还有一个之后在概率论里面同样非常常用的东西, 就是把一个测度沿着可测映射搬到另一个空间上.

定义 2.43 (前推测度).

令 $(X, \mathcal{F}, \mu)$ 为测度空间, $(Y, \mathcal{G})$ 为可测空间, $F: X \rightarrow Y$ 为可测映射. μ 沿 F 的**前推测度**是指测度 $F_*\mu$, 其中

$$(F_*\mu)(A) = \mu(F^{-1}(A)), \quad A \in \mathcal{G}.$$

要计算集合 $A \subseteq Y$ 的前推测度, 只需回到 X 中考察哪些点被 F 映入 A .

命题 2.44 (前推测度下的积分).

令 $(X, \mathcal{F}, \mu)$ 为测度空间, $(Y, \mathcal{G})$ 为可测空间, $F: X \rightarrow Y$ 为可测映射, 并令 $\nu = F_*\mu$. 如果 g 是 Y 上的非负可测函数或者可积函数, 则有

$$\int_X (g \circ F) d\mu = \int_Y g d\nu.$$

这个公式到了概率论里面就尤其自然. 如果 $\xi: \Omega \rightarrow \mathbb{R}$ 是一个随机变量, 那么它的分布其实就是概率测度 $\mathbb{P}$ 沿 ξ 的前推

$$\mathbb{P}_\xi = \xi_*\mathbb{P}.$$

因此对于合适的函数 g ,

$$\mathbb{E}[g(\xi)] = \int_\Omega g(\xi) d\mathbb{P} = \int_{\mathbb{R}} g(x) d\mathbb{P}_\xi(x).$$

知道随机变量的分布后, 计算这类期望只需对其分布积分, 无须追溯它在哪个概率空间上实现. 这也是概率论常把分布作为研究对象的原因; 具体样本空间只在需要联合结构或额外信息时才重新进入问题.

2.2 符号测度, Hahn 分解与 Radon–Nikodym 导数

2.2.1 符号测度与 Radon–Nikodym 定理

前面要求测度只能取非负值. 若要考虑两个测度之差, 或更一般地允许集合带有正负两种“质量”, 就需要符号测度.

定义 2.45.

令 $(X, \mathcal{F})$ 为可测空间. **符号测度**是指定义在 $\mathcal{F}$ 上的函数

$$\nu: \mathcal{F} \rightarrow [-\infty, \infty],$$

其满足:

1. $\nu(\emptyset) = 0$;
2. 对于任意一列两两不交的 $A_1, A_2, \dots \in \mathcal{F}$, 都有

$$\nu\left(\bigsqcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \nu(A_n);$$

3. ν 不同时取 $+\infty$ 与 $-\infty$, 从而避免出现没有意义的 $\infty - \infty$.

符号测度不能再单纯理解成“大小”, 因为集合可以具有负测度. 可以尝试把整个空间切成两块, 让一块只产生非负测度, 另一块只产生非正测度.

定义 2.46.

令 ν 为 $(X, \mathcal{F})$ 上的符号测度.

- 称可测集 $P \in \mathcal{F}$ 为 ν 的**正集**, 是指对于任意可测集 $A \subseteq P$, 都有 $\nu(A) \geq 0$.
- 称可测集 $N \in \mathcal{F}$ 为 ν 的**负集**, 是指对于任意可测集 $A \subseteq N$, 都有 $\nu(A) \leq 0$.

定理 2.47 (Hahn 分解定理).

令 ν 为 $(X, \mathcal{F})$ 上的符号测度. 则存在互不相交的可测集 P, N , 使得

$$X = P \sqcup N,$$

其中 P 为 ν 的正集, N 为 ν 的负集.

Hahn 分解的证明结构 证明先用一个核心引理: 每个满足 $\nu(A) < 0$ 的可测集都包含一个仍具有负测度的负集. 引理的构造反复从 A 中移去正测度子集; 可列可加性保证剩余部分最终是负集, 且总测度仍为负. 随后在所有负集的测度中取下确界, 选择一系列逼近该下确界的负集并取它们的可列并 N . 负集的可列并仍为负集. 若 $P = X \setminus N$ 不是正集, 核心引理会在 P 中产生新的负集, 把它并入 N 后得到更小的测度, 与下确界构造矛盾. 这就得到 $X = P \sqcup N$. 包括无限值情形在内的完整论证见 [Kal21, Theorem 2.8] 或 [Dur19, Theorem A.4.5].

Hahn 分解说明, 虽然一个符号测度可以同时具有正负两部分, 但是总可以把空间切成“只产生正值”和“只产生负值”的两个区域.

有了 Hahn 分解以后, 我们可以进一步把符号测度本身也拆开.

定理 2.48 (Jordan 分解定理).

令 ν 为 $(X, \mathcal{F})$ 上的符号测度. 则存在唯一的两个非负测度 ν^+, ν^- , 使得

$$\nu = \nu^+ - \nu^-,$$

并且存在一个 Hahn 分解 $X = P \sqcup N$, 使得 ν^+ 集中在 P 上, ν^- 集中在 N 上.

其中 ν^+ 和 ν^- 分别称为 ν 的**正变差**与**负变差**.

证明. 给定 Hahn 分解 $X = P \sqcup N$, 定义

$$\nu^+(A) = \nu(A \cap P), \quad \nu^-(A) = -\nu(A \cap N).$$

正集与负集的定义保证二者非负; 符号测度的可列可加性保证它们都是测度. 对每个 $A \in \mathcal{F}$,

$$\nu(A) = \nu(A \cap P) + \nu(A \cap N) = \nu^+(A) - \nu^-(A).$$

且 ν^+ 与 ν^- 分别集中在互不相交的 P 与 N 上.

若还有 $\nu = \alpha - \beta$ 且 $\alpha \perp \beta$, 取互不相交的集中集 C, D , 使 α 集中在 C 上, β 集中在 D 上. 令

$$R = X \setminus (C \cup D), \quad C' = C \cup R.$$

由于 $\alpha(R) = \beta(R) = 0$, 把 R 并入 C 不改变集中性. 对任意可测集 $E \subseteq C'$ 有 $\beta(E) = 0$, 因而 $\nu(E) = \alpha(E) \geq 0$; 对任意可测集 $E \subseteq D$ 有 $\alpha(E) = 0$, 因而 $\nu(E) = -\beta(E) \leq 0$. 所以 $X = C' \sqcup D$ 也是一个 Hahn 分解.

将它与定义 ν^+, ν^- 时使用的 Hahn 分解 $X = P \sqcup N$ 比较. 交集 $P \cap D$ 同时是正集与负集, 故它的每个可测子集都有 ν -测度 0; $N \cap C'$ 也具有同一性质. 因此对任意 $A \in \mathcal{F}$,

$$\alpha(A) = \alpha(A \cap C') = \nu(A \cap C') = \nu(A \cap C' \cap P) = \nu(A \cap P) = \nu^+(A),$$

$$\beta(A) = \beta(A \cap D) = -\nu(A \cap D) = -\nu(A \cap D \cap N) = -\nu(A \cap N) = \nu^-(A).$$

于是 $\alpha = \nu^+$ 且 $\beta = \nu^-$, 分解唯一. □

Hahn 分解拆分空间; Jordan 分解在此基础上把符号测度拆成两个非负测度.

定义 2.49.

令 ν 为 $(X, \mathcal{F})$ 上的符号测度, ν^+, ν^- 为其正变差与负变差. ν 的全变差测度是指

$$|\nu| = \nu^+ + \nu^-.$$

于是一个符号测度自然对应三个非负测度 ν^+, ν^- 和 $|\nu|$. 其中前两个分别记录它的正负部分, 而 $|\nu|$ 则忽略正负号以后记录它总共具有多少“质量”.

奇异与绝对连续 为了描述不同测度之间的关系, 我们先固定一个很直观的说法.

定义 2.50.

令 μ 为 $(X, \mathcal{F})$ 上的测度, $A \in \mathcal{F}$. 称 μ 集中在 A 上, 是指其满足

$$\mu(X \setminus A) = 0.$$

从 μ 的角度看, A 以外的部分都可忽略.

定义 2.51.

令 μ, ν 为 $(X, \mathcal{F})$ 上的测度.

- 称 μ 与 ν 互相奇异, 是指存在互不相交的可测集 $A, B \in \mathcal{F}$, 使得 μ 集中在 A 上, ν 集中在 B 上. 常记作

$$\mu \perp \nu.$$

- 称 ν 关于 μ 绝对连续, 是指对于任意 $A \in \mathcal{F}$, 如果 $\mu(A) = 0$, 则有 $\nu(A) = 0$. 常记作

$$\nu \ll \mu.$$

这两个概念描述的是两种不同的关系. $\mu \perp \nu$ 表示两个测度的质量可以分别集中在互不重叠的地方, 而 $\nu \ll \mu$ 则表示 ν 不会在 μ 完全看不见的地方凭空出现质量.

注 2.52.

绝对连续有方向: $\nu \ll \mu$ 不能推出 $\mu \ll \nu$. 互相奇异则是对称关系, $\mu \perp \nu$ 与 $\nu \perp \mu$ 表示同一件事.

从这个定义来看, Jordan 分解中的 ν^+ 与 ν^- 正好满足

$$\nu^+ \perp \nu^-.$$

比如在 $\mathbb{R}$ 上, Dirac 测度 δ_0 与 Lebesgue 测度 λ 互相奇异. δ_0 完全集中在 $\{0\}$ 上, 而 Lebesgue 测度认为 $\{0\}$ 是零测集, 所以可以把两者分别集中在 $\{0\}$ 和 $\mathbb{R} \setminus \{0\}$ 上.

另一方面, 令 f 为非负可测函数, 并定义测度

$$\nu(A) = \int_A f \, d\mu.$$

那么由定义有 $\nu \ll \mu$, 因为只要 $\mu(A) = 0$, 就有 $\int_A f \, d\mu = 0$.

这种形式的测度可以理解成在原来的测度 μ 上乘上了一个“密度” f . 在 f 较大的地方, ν 相对于 μ 分配了更多质量; 在 $f = 0$ 的地方, ν 则完全没有质量.

那一个很自然的问题就是反过来是否成立: 如果我们只知道 $\nu \ll \mu$, 是否一定存在一个非负可测函数 f , 使得

$$\nu(A) = \int_A f \, d\mu$$

对于所有 $A \in \mathcal{F}$ 都成立?

答案就是 Radon–Nikodym 定理.

Radon–Nikodym 定理**定理 2.53 (Radon–Nikodym 定理).**

令 μ, ν 为 $(X, \mathcal{F})$ 上的 σ -有限测度. 如果 $\nu \ll \mu$, 则存在非负可测函数 $f: X \rightarrow [0, \infty]$, 使得对于任意 $A \in \mathcal{F}$, 都有

$$\nu(A) = \int_A f \, d\mu.$$

并且这样的 f 在 μ -a.e. 的意义下唯一.

我们把这个函数记作

$$f = \frac{d\nu}{d\mu},$$

称为 ν 关于 μ 的 **Radon–Nikodym 导数**.

这个记号和导数非常像. 直观上, $\frac{d\nu}{d\mu}$ 描述的就是“单位 μ 对应多少 ν ”, 也就是两个测度之间局部的密度比.

证明. 我们先考虑 μ, ν 都是有限测度的情况.

对于非负可测函数 f , 记

$$(f \cdot \mu)(A) := \int_A f \, d\mu.$$

现在考虑

$$\mathcal{H} = \{f \geq 0 \mid f \text{ 关于 } \mathcal{F} \text{ 可测且 } f \cdot \mu \leq \nu\}.$$

这里 $f \cdot \mu \leq \nu$ 是指对于任意 $A \in \mathcal{F}$ 都有 $(f \cdot \mu)(A) \leq \nu(A)$.

定义

$$\alpha = \sup_{f \in \mathcal{H}} \int_X f \, d\mu.$$

因为 $f \cdot \mu \leq \nu$, 所以 $\int_X f \, d\mu \leq \nu(X) < \infty$, 从而 $\alpha < \infty$.

取 $f_n \in \mathcal{H}$ 使得 $\int_X f_n \, d\mu \rightarrow \alpha$. 如果 $f, g \in \mathcal{H}$, 那么将 X 按照 $f \geq g$ 与 $f < g$ 分开以后容易验证 $\max\{f, g\} \in \mathcal{H}$. 因此令

$$g_n = \max\{f_1, \dots, f_n\},$$

则 $g_n \in \mathcal{H}$ 且对某个非负可测函数 g , 有 $g_n \uparrow g$.

由单调收敛定理,

$$\int_X g \, d\mu = \lim_{n \rightarrow \infty} \int_X g_n \, d\mu = \alpha.$$

对任意 $A \in \mathcal{F}$ 再使用一次单调收敛定理, 有

$$\int_A g \, d\mu = \lim_{n \rightarrow \infty} \int_A g_n \, d\mu \leq \nu(A),$$

所以 $g \in \mathcal{H}$.

现在令

$$\lambda = \nu - g \cdot \mu.$$

因为 $g \in \mathcal{H}$, 所以 λ 是一个非负有限测度. 而且由于 $\nu \ll \mu$ 以及 $g \cdot \mu \ll \mu$, 还有 $\lambda \ll \mu$.

我们只需要证明 $\lambda = 0$. 假设反之 $\lambda(X) > 0$. 因为 $\mu(X) < \infty$, 可以取足够小的 $\varepsilon > 0$, 使得

$$\lambda(X) - \varepsilon \mu(X) > 0.$$

考虑符号测度

$$\rho = \lambda - \varepsilon \mu.$$

由 Hahn 分解定理, 可以找到 ρ 的正集 P 满足 $\rho(P) > 0$. 因为 $\lambda \ll \mu$, 此时必然有 $\mu(P) > 0$, 而且对于任意可测集 $A \subseteq P$ 都有

$$\lambda(A) \geq \varepsilon \mu(A).$$

因此对于任意 $A \in \mathcal{F}$,

$$\begin{aligned}\int_A (g + \varepsilon 1_P) d\mu &= \int_A g d\mu + \varepsilon \mu(A \cap P) \\ &\leq \int_A g d\mu + \lambda(A \cap P) \\ &\leq \nu(A).\end{aligned}$$

所以 $g + \varepsilon 1_P \in \mathcal{H}$. 但是

$$\int_X (g + \varepsilon 1_P) d\mu = \alpha + \varepsilon \mu(P) > \alpha,$$

这和 α 的定义矛盾. 因此只能有 $\lambda = 0$, 从而

$$\nu = g \cdot \mu.$$

最后来看唯一性. 令 f, g 都满足 $f \cdot \mu = g \cdot \mu = \nu$. 在集合 $\{f > g\}$ 上有

$$\int_{\{f > g\}} f d\mu = \int_{\{f > g\}} g d\mu,$$

由于两边都是 $\nu(\{f > g\})$, 这里的积分是有限的. 对每个 $n \geq 1$, 在 $E_n = \{f \geq g + 1/n\}$ 上有

$$\int_{E_n} f d\mu \geq \int_{E_n} g d\mu + \frac{1}{n} \mu(E_n).$$

又由上面的等式可知两边积分相等, 因而 $\mu(E_n) = 0$. 因为 $\{f > g\} = \bigcup_{n \geq 1} E_n$, 所以 $\mu(\{f > g\}) = 0$. 同理有 $\mu(\{g > f\}) = 0$, 因此 $f = g$ a.e.

一般的 σ -有限情形只需要把 X 拆成可列多个彼此不交的可测集, 使得 μ 和 ν 在每一块上都有限, 分别应用上面的有限测度情形以后再把得到的密度拼起来即可. $\square$

Radon–Nikodym 定理把关于 μ 绝对连续的测度 ν 表示为 μ 乘上某个密度函数. 精确地说,

$$\nu(A) = \int_A \frac{d\nu}{d\mu} d\mu.$$

这个结果在概率论里面尤其重要. 如果随机变量 ξ 的分布 $\mathbb{P}_\xi$ 关于 Lebesgue 测度 λ 绝对连续, 那么

$$p_\xi = \frac{d\mathbb{P}_\xi}{d\lambda}$$

就是我们平常所说的概率密度函数.

于是对于任意 Borel 集 $A \subseteq \mathbb{R}$,

$$\mathbb{P}(\xi \in A) = \mathbb{P}_\xi(A) = \int_A p_\xi(x) dx.$$

严格地说, 概率密度是概率测度相对于 Lebesgue 测度的 Radon–Nikodym 导数; 区域的概率由密度积分得到.

Lebesgue 分解 既然我们已经有了“绝对连续”和“互相奇异”两种关系, 那一个自然的问题就是: 给定两个测度 μ, ν , 是否可以把 ν 拆成一部分关于 μ 绝对连续, 另一部分与 μ 互相奇异?

答案仍然是肯定的.

定理 2.54 (Lebesgue 分解定理).

令 μ, ν 为 $(X, \mathcal{F})$ 上的 σ -有限测度. 则存在唯一的两个测度 ν_{ac}, ν_s , 使得

$$\nu = \nu_{ac} + \nu_s,$$

并且

$$\nu_{ac} \ll \mu, \quad \nu_s \perp \mu.$$

证明. 令

$$\rho = \mu + \nu.$$

则 $\mu \ll \rho$ 且 $\nu \ll \rho$. 由 Radon-Nikodym 定理, 存在非负可测函数 f, g , 使得

$$\mu = f \cdot \rho, \quad \nu = g \cdot \rho.$$

由 $\rho = \mu + \nu$ 可知

$$f + g = 1 \quad \rho\text{-a.e.}$$

令 $A = \{f > 0\}$, 并定义

$$\nu_{ac}(E) = \nu(E \cap A), \quad \nu_s(E) = \nu(E \cap A^c).$$

由定义可见 $\nu = \nu_{ac} + \nu_s$.

如果 $\mu(E) = 0$, 那么 $\int_E f d\rho = 0$, 所以 $f = 0$ 在 E 上 ρ -a.e. 成立. 因而 $\rho(E \cap A) = 0$, 从而 $\nu_{ac}(E) = 0$. 所以 $\nu_{ac} \ll \mu$.

另一方面,

$$\mu(A^c) = \int_{A^c} f d\rho = 0,$$

而 ν_s 完全集中在 A^c 上, 所以 $\nu_s \perp \mu$.

唯一性可以这样看. 假设还有另一个分解 $\nu = \alpha + \sigma$, 其中 $\alpha \ll \mu$ 且 $\sigma \perp \mu$. 取 μ -零测集 N, M , 使得 ν_s 集中在 N 上, σ 集中在 M 上. 对任意可测集 E , 绝对连续性给出 $\nu_{ac}(E \cap (N \cup M)) = \alpha(E \cap (N \cup M)) = 0$, 而奇异部分在 $(N \cup M)^c$ 上为 0. 因此 $\nu_{ac}(E) = \alpha(E)$, 从而奇异部分也相同. $\square$

由 Radon-Nikodym 定理, 其中绝对连续的部分还可以写成

$$\nu_{ac}(A) = \int_A \frac{d\nu_{ac}}{d\mu} d\mu.$$

相对于 μ , 测度 ν 可以拆成两部分: 一部分由相对于 μ 的密度函数描述, 另一部分集中在 μ 完全看不见的地方.

放到概率分布里面也是一样. 相对于 Lebesgue 测度来说, 一个概率分布可以具有绝对连续部分, 也可以具有奇异部分. 离散的原子质量属于奇异部分的一种. 奇异部分也可能不离散, 例如奇异连续分布.

2.2.2 L^p 空间

下面转入一个相对独立但后面概率论会反复用到的主题: L^p 空间.

前面我们已经定义了 Lebesgue 积分. 积分理论并不只有 Lebesgue 积分一种, 如果单纯只是想给某个函数算积分, 那么很多时候 Riemann 积分或者其他积分理论也完全够用.

分析学经常要研究一整族函数, 比较它们之间的大小和距离, 再不断取极限. 单个函数能否积分只是其中一个问题.

比如对于可积函数 f , $\int_X |f| d\mu$ 可以用来衡量它整体有多大. 如果我们更加在意函数出现较大取值的部分, 那自然可以进一步考虑

$$\left(\int_X |f|^p d\mu \right)^{1/p}.$$

这里最后再开 p 次根也很自然, 因为 $|f|^p$ 将函数值本身的尺度做了 p 次方, 最后开根以后又重新回到了原来的尺度.

这推广了有限维向量空间中的 p -范数. 比如对于 $x = (x_1, \dots, x_n) \in \mathbb{R}^n$, 我们有

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

如果把 $\{1, \dots, n\}$ 赋予计数测度, 那么这里的求和本身就是 Lebesgue 积分. L^p 范数由此把有限维向量的 p -范数推广到一般测度空间上的函数.

这个定义还带来另一项重要性质.

比如在有界区间上, 如果只考虑 Riemann 可积函数, 然后同样使用 L^p 范数衡量函数之间的距离, 得到的函数空间一般并不完备: 一系列 Riemann 可积函数完全可能在 L^p 意义下成为 Cauchy 列, 但是它的极限却已经不再是 Riemann 可积函数.

而 Lebesgue 理论的一个巨大优点就在于, 当我们把 a.e. 相等的函数视为同一个函数以后, 对于 $1 \leq p \leq \infty$, 所得到的 L^p 空间都是 Banach 空间. 因此在 L^p 范数下取 Cauchy 极限不会离开这个空间.

完备性对分析学尤其重要, 因为分析学里面大量操作都需要不断取极限. 如果每次取完极限以后都需要担心结果已经离开了原来的函数空间, 那么很多理论都会变得非常难用.

Lebesgue 积分既“能够积分更多函数”, 又能与极限和函数空间结构良好配合, 后一点尤其适合现代分析. 特别地, 它使得 L^p 空间成为 Banach 空间, 而 L^2 还会进一步成为 Hilbert 空间.

到了概率论里面, 这套结构又有了一个非常直接的解释. 如果 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, 那么随机变量本身就是 Ω 上的可测函数. 当 $1 \leq p < \infty$ 时,

$$\|X\|_p^p = \mathbb{E}[|X|^p].$$

所以概率论里面所谓“随机变量具有有限的 p 阶绝对矩”, 就是在说它属于 $L^p(\Omega, \mathbb{P})$.

而 $p = \infty$ 的情况需要单独理解: $X \in L^\infty$ 表示 X 本质有界, 也就是存在有限常数 M 使得 $|X| \leq M$ $\mathbb{P}$ -a.e.; 在概率语言中称为几乎必然 (almost surely, a.s.).

而当我们研究随机变量序列的时候, $\|X_n - X\|_p \rightarrow 0$ 又会自然给出所谓的 L^p 收敛. 所以后面的矩, 方差, 均方收敛以及很多随机过程中的估计, 都会反复使用同一套 L^p 结构.

下设 $(X, \mathcal{F}, \mu)$ 为测度空间, 并记 $\mathbb{K} = \mathbb{R}$ 或 $\mathbb{C}$.

L^p 范数与 L^p 空间

定义 2.55 (L^p 范数).

令 $f: X \rightarrow \mathbb{K}$ 为可测函数.

- 当 $1 \leq p < \infty$ 时, f 的 L^p 范数是指

$$\|f\|_p = \left(\int_X |f|^p d\mu \right)^{1/p}.$$

- 当 $p = \infty$ 时, f 的 L^∞ 范数是指

$$\|f\|_\infty = \operatorname{ess\,sup}_{x \in X} |f(x)| = \inf\{a \geq 0 \mid |f| \leq a \text{ a.e.}\}.$$

对一般可测函数来说, 上面的量可能取 $+\infty$; 限制在有限值的函数类上后, 它仍然只是一个半范数. 取 a.e. 等价类后才成为范数. 因为 $\|f\|_p = 0$ 只能推出 $f = 0$ a.e., 而不能保证 f 逐点处处等于 0.

解决办法也很直接: 既然零测集上的区别对于积分来说本来就是看不见的, 那我们就把 a.e. 相等的函数视为同一个函数.

定义 2.56 (L^p 空间).

令 $1 \leq p \leq \infty$. $L^p(X, \mu; \mathbb{K})$ 是指所有满足 $\|f\|_p < \infty$ 的可测函数关于 a.e. 相等得到的商空间.

无歧义时, 也直接记作 $L^p(X)$ 或 L^p .

严格地说, L^p 中的元素是一整个 a.e. 相等的函数等价类, 没有指定某个具体代表元. 实际使用时, 我们一般还是直接拿其中一个代表元当作“这个函数”来写.

对于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$, 当 $1 \leq p < \infty$ 时, 这个定义可以直接翻译成

$$X \in L^p(\Omega, \mathbb{P}) \iff \mathbb{E}[|X|^p] < \infty.$$

而 $X \in L^\infty(\Omega, \mathbb{P})$ 则表示 X 本质有界.

特别地, L^1 中的随机变量具有有限的一阶绝对矩, 因而期望存在; L^2 中的随机变量具有有限二阶矩, 因而可以进一步讨论方差和协方差.

令 $X = \mathbb{Z}_{>0}$ 并取计数测度. 当 $1 \leq p < \infty$ 时, 就得到一个很重要的特例 ℓ^p 空间:

$$\ell^p = \left\{ (x_n)_{n \geq 1} \mid \sum_{n=1}^{\infty} |x_n|^p < \infty \right\},$$

其范数为

$$\|x\|_p = \left(\sum_{n=1}^{\infty} |x_n|^p \right)^{1/p}.$$

而 $p = \infty$ 时,

$$\ell^\infty = \left\{ (x_n)_{n \geq 1} \mid \sup_{n \geq 1} |x_n| < \infty \right\}, \quad \|x\|_\infty = \sup_{n \geq 1} |x_n|.$$

所以 Lebesgue 积分和无穷求和本身就是同一个测度论框架下的两种情况, L^p 和 ℓ^p 之间的关系也是如此.

L^p 收敛 既然 L^p 上已经有了一个范数, 那么我们就可以直接使用这个范数来定义函数之间的收敛.

定义 2.57.

令 $f, f_1, f_2, \dots \in L^p(X)$. 称 f_n 在 L^p 意义下收敛到 f , 是指 $\|f_n - f\|_p \rightarrow 0$. 常记作

$$(f_n \xrightarrow{L^p} f).$$

在概率空间上, 当 $1 \leq p < \infty$ 时, 这也就是

$$(X_n \xrightarrow{L^p} X) \iff \mathbb{E}[|X_n - X|^p] \rightarrow 0.$$

当 $p = \infty$ 时, 它表示 $X_n - X$ 的本质上确界趋于 0, 也就是在忽略零概率集合以后的一致收敛.

当 $1 \leq p < \infty$ 时, L^p 收敛描述随机变量整体误差的 p 阶矩趋于 0, 通常不能据此判断每个样本点上的逐点行为. L^∞ 收敛则表示本质上一致意义下的误差趋于 0.

特别地, L^1 收敛也常被称为平均收敛, 而 L^2 收敛则常被称为均方收敛. 后面我们还会看到几乎处处收敛, 依概率收敛, 依分布收敛等等不同的收敛概念, 这些概念各有不同的定义和推出关系.

基本不等式 L^p 空间最基本的两个不等式是 Hölder 不等式和 Minkowski 不等式.

定义 2.58.

令 $1 \leq p, q \leq \infty$. 称 p, q 为一对共轭指数, 是指其满足

$$\frac{1}{p} + \frac{1}{q} = 1.$$

定理 2.59 (Hölder 不等式).

令 p, q 为一对共轭指数, $f \in L^p(X)$, $g \in L^q(X)$. 则 $fg \in L^1(X)$, 并且

$$\|fg\|_1 \leq \|f\|_p \|g\|_q.$$

证明. 当 $1 < p, q < \infty$ 时, 如果 $\|f\|_p$ 或 $\|g\|_q$ 为 0, 相应函数几乎处处为 0, 不等式两边均为 0. 否则将二者归一化以后, 由 Young 不等式

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q}$$

有

$$\frac{|f(x)g(x)|}{\|f\|_p \|g\|_q} \leq \frac{1}{p} \frac{|f(x)|^p}{\|f\|_p^p} + \frac{1}{q} \frac{|g(x)|^q}{\|g\|_q^q}.$$

两边积分即可.

$p = 1, q = \infty$ 以及 $p = \infty, q = 1$ 的情况直接由 $|fg| \leq \|g\|_\infty |f|$ 得到. □

放到概率空间里面, Hölder 不等式就是

$$\mathbb{E}[|XY|] \leq \|X\|_p \|Y\|_q.$$

所以以后我们在证明两个随机变量的乘积可积, 或者估计各种矩的时候, 经常归结为 Hölder 不等式.

特别地, 当 $p = q = 2$ 时得到

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2]} \sqrt{\mathbb{E}[Y^2]},$$

这就是 Cauchy-Schwarz 不等式.

定理 2.60 (Minkowski 不等式).

令 $1 \leq p \leq \infty$, $f, g \in L^p(X)$. 则有

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p.$$

证明. $p = 1$ 和 $p = \infty$ 的情况直接验证即可.

设 $1 < p < \infty$, 并令 q 为 p 的共轭指数. 首先由 $|f + g|^p \leq 2^{p-1}(|f|^p + |g|^p)$ 可知 $f + g \in L^p(X)$, 所以下面的表达式都是有限的.

由

$$|f + g|^p \leq (|f| + |g|)|f + g|^{p-1}$$

以及 Hölder 不等式,

$$\begin{aligned} \int_X |f + g|^p d\mu &\leq (\|f\|_p + \|g\|_p) \| |f + g|^{p-1} \|_q \\ &= (\|f\|_p + \|g\|_p) \|f + g\|_p^{p-1}. \end{aligned}$$

消去 $\|f + g\|_p^{p-1}$ 即得结论. □

Minkowski 不等式也就说明了为什么在 $p \geq 1$ 的时候 $\|\cdot\|_p$ 真的是一个范数. 放到概率论里面, 它可以理解成随机变量整体 p 阶大小的三角不等式.

完备性 前面已经提到, Lebesgue 理论的一项重要结果是 L^p 在这个范数下完备. 下面给出正式说明.

定理 2.61 (Riesz-Fisher 定理).

令 $1 \leq p \leq \infty$. 则 $L^p(X, \mu)$ 关于 $\|\cdot\|_p$ 是一个 Banach 空间.

证明. 这里只证明 $1 \leq p < \infty$ 的情况. $p = \infty$ 的情况可以直接利用本质上一致收敛处理.

由 Banach 空间的标准判别法, 只需要证明: 如果

$$\sum_{k=1}^{\infty} \|f_k\|_p < \infty,$$

那么级数 $\sum_k f_k$ 在 L^p 中收敛.

令

$$G_n = \sum_{k=1}^n |f_k|, \quad G = \sum_{k=1}^{\infty} |f_k|.$$

由 Minkowski 不等式, $\|G_n\|_p \leq \sum_{k=1}^n \|f_k\|_p \leq B$ 对某个有限的 B 成立. 再由单调收敛定理,

$$\int_X G^p d\mu = \lim_{n \rightarrow \infty} \int_X G_n^p d\mu \leq B^p.$$

所以 $G \in L^p$, 特别地 $G < \infty$ a.e. 因而 $\sum_k f_k$ a.e. 绝对收敛, 记其和为 F .

令 $F_n = \sum_{k=1}^n f_k$. 因为 $F_n \rightarrow F$ a.e., 并且 $|F - F_n| \leq 2G$, 所以 $|F - F_n|^p \leq 2^p G^p$. 由控制收敛定理,

$$\|F - F_n\|_p^p = \int_X |F - F_n|^p d\mu \rightarrow 0.$$

因而 $F_n \rightarrow F$ 在 L^p 中成立. □

对于概率论来说, 因此, 一个在 L^p 意义下的 Cauchy 随机变量序列不会离开 L^p : 它一定存在某个仍然具有有限 p 阶矩的随机变量作为极限.

L^2 空间 在所有 L^p 空间里面, $p = 2$ 的情况尤其特殊, 因为它的范数来自内积.

定义 2.62.

$L^2(X, \mu)$ 上的内积是指

$$\langle f, g \rangle = \int_X f \bar{g} d\mu$$

在复值情形下的定义. 对于实值函数则直接去掉共轭.

由 Cauchy-Schwarz 不等式, 这个积分总是有限的, 并且 $\|f\|_2 = \sqrt{\langle f, f \rangle}$.

定理 2.63.

$L^2(X, \mu)$ 关于上述内积是一个 Hilbert 空间.

对于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$, 这个内积就是

$$\langle X, Y \rangle = \mathbb{E}[X \bar{Y}].$$

很多概率论里面看起来很特殊的概念, 都可以放进 Hilbert 空间语言中统一理解.

比如对于实值随机变量,

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \|X - \mathbb{E}[X]\|_2^2,$$

而协方差就是

$$\text{Cov}(X, Y) = \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

所以 $\text{Cov}(X, Y) = 0$ 就是说中心化以后的两个随机变量在 L^2 中正交.

这也是为什么 L^2 在概率论和随机过程中会特别常见. 除了讨论随机变量整体有多大, 还可以直接利用 Hilbert 空间中的正交, 投影等几何结构.

不同 L^p 空间之间的关系 一般测度空间上, 对于 $p < q$, L^p 和 L^q 并不存在统一的包含关系. 概率空间本身是有限测度空间, 所以情况会简单很多.

命题 2.64.

令 $(X, \mathcal{F}, \mu)$ 为有限测度空间, $1 \leq p < q \leq \infty$. 如果 $f \in L^q(X)$, 则 $f \in L^p(X)$, 并且

$$\|f\|_p \leq \mu(X)^{1/p-1/q} \|f\|_q.$$

特别地, 对于概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$, 因为 $\mathbb{P}(\Omega) = 1$, 所以上式直接变成

$$L^q(\Omega) \subseteq L^p(\Omega), \quad \|X\|_p \leq \|X\|_q.$$

所以在概率论里面, 高阶矩有限会自动推出低阶矩有限. 比如

$$X \in L^2 \implies X \in L^1,$$

因此, 只要随机变量具有有限二阶矩, 那么它的期望就一定存在.

更一般地, 如果 $\mathbb{E}[|X|^q] < \infty$, 那么所有更低阶的绝对矩也都会有限.

如果我们同时知道一个函数的两个不同阶矩, 那中间的阶数还可以通过插值控制.

定理 2.65 (插值不等式).

令 $1 \leq p < q < r \leq \infty$, $f \in L^p(X) \cap L^r(X)$. 如果 $\lambda \in (0, 1)$ 满足

$$\frac{1}{q} = \frac{\lambda}{p} + \frac{1-\lambda}{r},$$

则 $f \in L^q(X)$, 并且

$$\|f\|_q \leq \|f\|_p^\lambda \|f\|_r^{1-\lambda}.$$

证明. 当 $r < \infty$ 时, 写成

$$|f|^q = |f|^{\lambda q} |f|^{(1-\lambda)q},$$

再使用 Hölder 不等式即可.

$r = \infty$ 的情况直接由 $|f|^q \leq \|f\|_\infty^{q-p} |f|^p$ 得到. □

在概率论里面, 这个不等式可以直接理解成不同阶矩之间的插值. 如果我们已经控制了某个随机变量的 p 阶矩和 r 阶矩, 那么介于它们之间的 q 阶矩也会自动得到控制. 后面研究随机过程的矩估计时会经常遇到这种操作.

简单函数逼近 简单函数既用来定义 Lebesgue 积分, 也可以逼近一般的 L^p 函数.

命题 2.66.

令 $1 \leq p < \infty$. 则具有有限测度支撑的简单函数在 $L^p(X, \mu)$ 中稠密.

证明. 令 $f \in L^p$. 对于 $n \geq 1$, 先将 f 截断在

$$\left\{ \frac{1}{n} \leq |f| \leq n \right\}$$

上, 再对函数值作简单函数逼近, 可以得到简单函数 f_n , 满足 $f_n \rightarrow f$ a.e. 且 $|f_n| \leq |f|$.

另一方面, 因为

$$\mu\left(\left\{|f| \geq \frac{1}{n}\right\}\right) \leq n^p \int_X |f|^p d\mu < \infty,$$

所以每个 f_n 都可以取成具有有限测度支撑.

最后由 $|f_n - f|^p \leq 2^p |f|^p$ 以及控制收敛定理, 得到 $\|f_n - f\|_p \rightarrow 0$. □

对于概率论来说, 这个结论说明: 很多关于一般随机变量的问题, 我们都可以先对只取有限多个值的随机变量处理, 然后再通过 L^p 逼近推广到一般情况.

注 2.67.

在常见的 σ -有限测度空间上, 当 $1 < p < \infty$ 时, L^p 的连续对偶可以识别成 L^q , 其中 p, q 为共轭指数. 这个识别再次连接 Radon–Nikodym 导数与线性泛函, 在本笔记中作为后续泛函分析与定价对偶的接口.

第三章 概率论基础

第二章已经准备了可测空间, 测度, 前推测度和 Lebesgue 积分; 到这里终于可以开始讲概率了. 这一章的概率论基础主要参考 [Bil95; Dur19; Kal21; Wil91].

从现代观点看, 概率空间就是总质量为 1 的测度空间. 把可测集称为“事件”, 把测度称为“概率”, 就已经得到了概率论的基本语言.

很多熟悉的概率公式其实来自同一套东西: 事件的并, 交, 补集和可列可加性, 本质上都是前面集合运算与测度性质在概率语言下的解释.

但概率论有意思的地方不只是给集合赋一个 0 到 1 之间的数.

实际进行一次随机实验的时候, 最原始的结果往往会带有很多我们并不关心的信息. 比如连续抛十次硬币, 一个完整的实验结果可能是

$$(H, T, H, H, T, T, H, T, H, H),$$

但很多时候我们真正关心的可能只是“一共出现了多少次正面”. 于是相比于直接研究原来的样本点 ω , 我们通常更愿意通过某个函数把它投影到一个更加方便处理的空间里面. 这个函数就是随机变量.

随机变量这个名字多少有些误导. 它听起来像一个会自己乱跳的数, 实际上是概率空间上的可测函数

$$X: \Omega \rightarrow \mathbb{R}.$$

随机性来自输入的样本点 ω , 而 X 本身只是把每一个可能的实验结果转换成一个数.

这件事也解释了前面为什么要讲可测映射. 如果想讨论“ X 落在集合 A 中”的概率, 实际上就是在讨论事件 $X^{-1}(A)$. 只有当 X 可测时, 这些原像才属于事件域, 从而概率

$$\mathbb{P}(X \in A)$$

才有定义.

更进一步, 一旦有了随机变量 X , 我们经常就不再关心它原来的样本空间 Ω 到底长什么样. 概率测度 $\mathbb{P}$ 可以沿着 X 前推到取值空间上, 形成 X 的分布. 分布记录观测值在取值空间中怎样散布, 却不会保留原始样本空间的全部结构.

市场例子也是这样. 一整天的盘口变化可以看成是一个很复杂的样本点; 收盘收益率, 当日最高回撤或成交量, 则是从这条历史中读出来的随机变量. 换一个问题, 就会换一个读法.

另一方面, 我们前面定义的 Lebesgue 积分到了这里也会变成期望. 如果 X 是可积随机变量, 那么

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P}.$$

所谓期望, 本质上就是关于概率测度的 Lebesgue 积分. 类似地, 当 $1 \leq p < \infty$ 时, L^p 空间也会直接对应随机变量的不同阶绝对矩:

$$X \in L^p(\Omega, \mathbb{P}) \iff \mathbb{E}[|X|^p] < \infty.$$

而 L^∞ 则对应随机变量本质有界.

因此到这里, 前面的测度论大概可以翻译成概率论的语言:

$$\begin{aligned} \text{测度空间} &\longrightarrow \text{概率空间}, \\ \text{可测集} &\longrightarrow \text{事件}, \\ \text{测度} &\longrightarrow \text{概率}, \\ \text{可测映射} &\longrightarrow \text{随机变量}, \\ \text{前推测度} &\longrightarrow \text{分布}, \\ \text{Lebesgue 积分} &\longrightarrow \text{期望}. \end{aligned}$$

概率论当然不只是给测度论换一套名字. 真正新的问题会在我们同时考虑多个事件和多个随机变量时出现: 它们是否独立, 知道一部分信息以后概率应该怎样改变, 一个随机变量的条件期望是什么, 以及一系列随机变量到底以什么方式趋于另一个随机变量.

下面这张图只是把这些问题放在同一条路上: 先有样本和事件, 再把样本读成随机变量, 然后讨论分布, 期望, 信息和极限. 等时间指标 t 加进来, 随机过程就自然出现了.




图 3.1: 从样本和事件走向随机过程

再为一族随机变量加上时间指标, 就进入这本笔记的主要对象 — 随机过程.

3.1 概率空间与随机变量

这一节先把概率空间的三个组成部分钉牢, 再看随机变量如何从中提取信息.

概率空间描述一个“带有随机性的系统”: 样本空间收集所有可能的完整结果, 事件域规定哪些结果集合可以讨论, 概率测度描述不同事件发生的可能性.

3.1.1 概率空间

现在我们来正式定义概率空间.

定义 3.1.

概率空间是指三元组 $(\Omega, \mathcal{F}, \mathbb{P})$, 其中:

- Ω 为集合, 也称为**样本空间**;
- $\mathcal{F}$ 为 Ω 上的 σ -代数, 也称为**事件域**, 其中的元素称为**事件**;
- $\mathbb{P}$ 为定义在 $\mathcal{F}$ 上的**概率测度**, 也就是满足 $\mathbb{P}(\Omega) = 1$ 的测度.

概率论里面所谓的“概率”, 就是总质量被归一化成 1 的测度.

Ω 的子集只有属于事件域 $\mathcal{F}$ 时才称为事件. 对于 $A \subseteq \Omega$ 但 $A \notin \mathcal{F}$, $\mathbb{P}(A)$ 本身就没有定义.

不难发现, Ω 和 $\emptyset$ 都属于 $\mathcal{F}$, 因此它们都是事件. 我们称 Ω 为**必然事件**, 称 $\emptyset$ 为**不可能事件**.

这里还需要稍微区分一下“必然发生”和“概率为 1”. 如果事件 A 满足 $\mathbb{P}(A) = 1$, 那么我们通常说 A **几乎必然发生**. 这是因为它的补集 A^c 虽然满足 $\mathbb{P}(A^c) = 0$, 但却未必真的是空集. 类似地, $\mathbb{P}(A) = 0$ 也只能说明 A 是一个零概率事件, 不能据此推出 $A = \emptyset$. 它在模型中仍然可以存在, 只是几乎必然不会发生. 这种情形在连续型概率空间中尤其常见.

接下来我们来看两个最基本的例子.

例 3.2 (古典概型).

令 Ω 为非空有限集, 并取 $\mathcal{F} = \mathcal{P}(\Omega)$, 那么可以定义

$$\mathbb{P}(A) := \frac{\#A}{\#\Omega}.$$

由定义可见, $(\Omega, \mathcal{F}, \mathbb{P})$ 构成概率空间.

这里每一个样本点都具有相同的概率, 因而事件的概率就是“有利结果占所有可能结果的比例”. 这就是最经典的等可能模型.

例 3.3 (几何概型).

令 $\Omega \subseteq \mathbb{R}^d$ 为 Lebesgue 可测集, 并满足 $0 < \lambda_d(\Omega) < \infty$. 取

$$\mathcal{F} = \{A \cap \Omega \mid A \in \mathcal{L}(\mathbb{R}^d)\},$$

并定义

$$\mathbb{P}(A) := \frac{\lambda_d(A)}{\lambda_d(\Omega)}, \quad A \in \mathcal{F}.$$

那么 $(\Omega, \mathcal{F}, \mathbb{P})$ 构成概率空间.

这可以看作古典概型的连续版本. 古典概型使用元素个数 $\#A$ 衡量一个事件占整个样本空间的比例, 而几何概型则改用 Lebesgue 测度衡量一个区域所占的比例.

比如在区间 $[0, 1]$ 中均匀随机取一点, 那么取到 $[a, b] \subseteq [0, 1]$ 中的概率就是 $b - a$. 另一方面, 对于任意 $x \in [0, 1]$ 都有 $\mathbb{P}(\{x\}) = 0$, 但 x 仍然是样本空间中完全合法的一个结果. 这也再次说明, 零概率结果仍可能属于样本空间.

3.1.2 随机变量

概率空间本身可能极其复杂, 其中绝大部分信息与当前问题无关.

比如如果我们试图把股票市场建模成一个概率空间, 那么一种比较自然的想法是把一个样本点 $\omega \in \Omega$ 理解成市场的一次完整实现, 甚至直接理解成一整条可能的市场历史.

如果暂时只研究某一只股票每天的价格, 那么可以粗略地取 $\Omega = \mathbb{R}_+^{\mathbb{N}}$. 此时一个样本点 $\omega = (s_0, s_1, s_2, \dots)$ 就代表这只股票的一整条可能价格路径.

真实股票市场还会包含更多状态变量. 如果试图描述整个市场, 那么一个 ω 可能还需要包含成交量, 订单簿, 利率, 新闻, 其他资产价格以及许多额外信息. 于是原始的样本空间会非常庞大.

与之对应, 事件域 $\mathcal{F}$ 则描述我们能够讨论并赋予概率的事件. 比如“明天股价高于今天”, “未来一个月最大回撤超过 10%”, 或者“某个时刻以前股价曾经突破 200”都可以被视为事件.

如果我们只观察价格, 那么一种自然的做法就是令事件域由所有价格观测生成:

$$\mathcal{F} = \sigma(S_t : t \in \mathbb{N}),$$

其中 $S_t(\omega) = s_t$ 表示从完整路径 ω 中读出时刻 t 的价格.

实际研究时, 我们通常不直接处理整个 ω . 一整个市场世界里面的信息实在太多, 我们关心的往往只是从中提取出来的一些数值, 比如某只股票的价格, 收益率, 成交量, 甚至 MACD 之类的指标.

所以我们希望通过一个函数 $X: \Omega \rightarrow \mathbb{R}$ 把复杂的样本结果 ω 转换成一个想研究的数值. 这就是随机变量最基本的想法.

定义 3.4.

令 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间. **随机变量**是指可测映射

$$X: (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

“随机变量”这个名字多少有些误导. 随机变量 X 本身只是一个确定的可测函数, 具有随机性的是样本点 ω . 当随机系统最终实现为某个 ω 时, 我们实际观测到的数值就是 $X(\omega)$.

因此, 随机变量可以理解成对原概率空间的一次**观测**或者**信息提取**: 我们主动丢掉原空间中大量并不关心的信息, 只保留某一个希望研究的量.

要求 X 可测有直接的概率含义. 比如如果我们想讨论“ $X \leq a$ ”发生的概率, 对应的事件是 $\{X \leq a\} = X^{-1}((-\infty, a])$. 只有当这个原像属于 $\mathcal{F}$ 时, $\mathbb{P}(X \leq a)$ 才有定义.

而由于 $\mathcal{B}(\mathbb{R}) = \sigma\{(-\infty, a] \mid a \in \mathbb{R}\}$, 所以要验证一个函数 $X: \Omega \rightarrow \mathbb{R}$ 是随机变量, 只需验证对于任意 $a \in \mathbb{R}$ 都有 $\{X \leq a\} \in \mathcal{F}$.

回到刚才的股票例子, 时刻 t 的价格 $S_t: \Omega \rightarrow \mathbb{R}_+$ 就是一个随机变量. 如果 $S_{t-1} > 0$, 收益率

$$R_t = \frac{S_t - S_{t-1}}{S_{t-1}}$$

也只是价格随机变量经过确定变换以后得到的函数, 因而仍然是一个随机变量. 类似地, MACD 之类的技术指标也是对历史价格进行某种确定变换以后得到的数值, 所以在合适的可测性条件下, 它们同样可以被视为随机变量.

随机变量所携带的信息 既然随机变量可以理解成对于原概率空间的一次观测, 那自然还可以问: 仅仅知道 X 的值以后, 我们究竟获得了多少关于原样本点 ω 的信息?

定义 3.5.

令 $X: \Omega \rightarrow \mathbb{R}$ 为随机变量. 由 X 生成的 σ -代数是指

$$\sigma(X) := \{X^{-1}(A) \mid A \in \mathcal{B}(\mathbb{R})\}.$$

$\sigma(X)$ 可以理解成“仅仅通过观察 X 能够分辨出来的全部事件”. 由可测性有 $\sigma(X) \subseteq \mathcal{F}$, 从信息角度看, 随机变量会主动丢弃原概率空间中的一部分信息.

两个样本点 ω_1, ω_2 即使在原来的样本空间中完全不同, 只要 $X(\omega_1) = X(\omega_2)$, 那么仅仅通过观察 X 就无法再把它们区分开来.

比如对于股票价格随机变量 S_t , $\sigma(S_t)$ 描述的就是仅仅观察时刻 t 的价格以后能够获得的信息. 而如果我们观察截至时刻 t 的全部历史价格, 那么自然会得到 $\sigma(S_0, \dots, S_t)$. 后面我们还会把这种“随着时间不断增加的信息”系统地整理成所谓的滤过 (filtration, 也称滤链).

事件与随机变量 事件本身也可以被编码成一个非常简单的随机变量.

定义 3.6.

令 $A \in \mathcal{F}$ 为事件. A 的示性随机变量是指

$$\mathbf{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

一个事件由此可编码成只取 0 和 1 的随机变量. 后面还会看到 $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$, 即事件的概率等于其示性随机变量的期望.

随机向量与随机过程 随机变量也不一定非要只记录一个数. 如果 $X = (X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$ 是可测映射, 那么称 X 为一个**随机向量**.

更一般地, 如果 $(E, \mathcal{E})$ 是任意可测空间, 那么也可以考虑可测映射 $X: \Omega \rightarrow E$, 这种对象通常称为一个**随机元素**. 所以实值随机变量只是最基本的一种情况.

如果从某个固定时刻的 S_t 扩展到整族 $\{S_t\}_{t \in T}$, 就已经开始研究一个**随机过程**了.

之后所谓随机过程, 可以先理解成把“一个随机变量”推广成“一族带有时间参数的随机变量”. 新的困难也就在这里: 当我们同时研究很多随机变量以后, 除了每一个随机变量自身的分布以外, 还需要研究它们之间的依赖关系, 以及这些关系如何随着时间发生变化.

3.2 随机变量的分布

回忆上一节中, 我们将随机变量定义为从概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 到 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 的可测函数.

另一方面, 在前面的测度论中, 对于测度 $\mathbb{P}$ 以及可测映射 $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$, 我们已经定义了其前推测度

$$X_*\mathbb{P} := \mathbb{P}(X^{-1}(-)).$$

到了概率论里面, 当 X 是一个随机变量或者更一般的随机元素时, 我们通常把这个前推测度称为 X 的**分布**.

这里并没有引入新的测度论结构. 所谓随机变量的分布, 就是把原来定义在样本空间 Ω 上的概率测度, 通过随机变量 X 前推到它的值域以后得到的概率测度.

3.2.1 分布作为前推测度

根据前面的讨论, 我们可以直接得到下面的定义.

定义 3.7.

令 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$ 为随机元素. 称前推测度 $X_*\mathbb{P}$ 为 X 在概率测度 $\mathbb{P}$ 下的 **分布**, 记作 $\mathcal{L}(X)$ 或 μ_X .

因而对于任意 $A \in \mathcal{G}$, 有

$$(X_*\mathbb{P})(A) = \mathbb{P}(X \in A).$$

更一般地, 令 μ 为 $(E, \mathcal{G})$ 上的概率测度. 如果 $X_*\mathbb{P} = \mu$, 则称 X **服从分布** μ , 记作 $X \sim \mu$.

所以分布本身只是值域 $(E, \mathcal{G})$ 上的一个概率测度. 同一个概率测度可以由许多不同的概率空间和随机变量得到, 这类具体构造称为实现.

定义 3.8.

令 μ 为可测空间 $(E, \mathcal{G})$ 上的概率测度. 称概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 以及随机元素 $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{G})$ 为分布 μ 的一个**实现**, 是指其满足 $X_*\mathbb{P} = \mu$.

有时也直接称随机变量 X 为分布 μ 的一个实现.

所以分布与它的实现是两件不同的事情.

分布 μ 只记录值域上的概率规律, 而不会记录它究竟来自哪个样本空间, 也不会记录随机变量具体是怎样从这个样本空间中提取出来的. 因此同一个分布通常具有许多完全不同的实现.

每一个概率分布都有一个直接的实现.

例 3.9 (典范实现).

令 μ 为 $(E, \mathcal{G})$ 上的概率测度. 直接取概率空间 $(E, \mathcal{G}, \mu)$, 并令 $X = \text{id}_E$, 那么

$$X_*\mu = (\text{id}_E)_*\mu = \mu.$$

因此恒等随机元素 id_E 本身就是分布 μ 的一个实现.

因此, 概率测度本身可以看成恒等随机元素的分布. 一般随机变量的分布, 就是把原来的概率测度通过某个观测 X 前推到另一个空间以后得到的概率测度.

这说明了概率论为何常把注意力放在分布上, 而将具体实现留给问题的上下文.

定义 3.10.

令 $(\Omega, \mathcal{F}, \mathbb{P})$ 和 $(\Omega', \mathcal{F}', \mathbb{Q})$ 为概率空间, $X: \Omega \rightarrow E$ 和 $Y: \Omega' \rightarrow E$ 为取值于同一可测空间 $(E, \mathcal{G})$ 的随机元素.

称 X 与 Y **同分布**, 是指其满足

$$X_*\mathbb{P} = Y_*\mathbb{Q}.$$

通常记作 $X \stackrel{d}{=} Y$.

“同分布”只要求各自概率空间上的概率测度前推到值域后相同. X 和 Y 无须是同一个函数, 甚至无须定义在同一个概率空间上.

同时研究多个随机变量时, 只知道每个随机变量各自的分布还不等于知道它们放在一起以后的联合分布. 边缘分布本身无法决定随机变量之间的依赖结构. 这也是后面讨论独立性, 条件概率和随机过程时需要额外关心联合分布的原因.

分布函数 对于一般的随机元素 $X: \Omega \rightarrow (E, \mathcal{G})$, 它的分布 $X_*\mathbb{P}$ 已经是我们能够得到的最一般描述. 如果 E 只是一个任意可测空间, 通常并不存在一个像“分布函数”一样自然的普通函数能够完整记录这个分布.

值域为 $\mathbb{R}^n$ 时, 可以使用分布函数完整编码分布. 对于 $x = (x_1, \dots, x_n) \in \mathbb{R}^n$, 记

$$(-\infty, x] := \prod_{i=1}^n (-\infty, x_i].$$

我们可以直接记录分布在这些左下矩形上积累了多少概率质量.

定义 3.11.

令 $X = (X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$ 为随机向量. X 的**分布函数** (cumulative distribution function, CDF) 是指函数 $F_X: \mathbb{R}^n \rightarrow [0, 1]$, 其中

$$F_X(x_1, \dots, x_n) := \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

如果记 $\mu_X = X_*\mathbb{P}$, 那么也可以写成 $F_X(x) = \mu_X((-\infty, x])$. 当 $n > 1$ 时, F_X 也常称为 X 的**联合分布函数**.

当 $n = 1$ 时, 这退化为 $F_X(x) = \mathbb{P}(X \leq x)$.

分布函数与分布 $\mathbb{R}^n$ 上的分布函数可以完整确定随机向量的分布.

比如对于二维随机向量 (X, Y) , 如果已经知道 $F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$, 那么矩形 $(a, b] \times (c, d]$ 的概率就是

$$\begin{aligned} \mathbb{P}(a < X \leq b, c < Y \leq d) &= F_{X,Y}(b, d) - F_{X,Y}(a, d) \\ &\quad - F_{X,Y}(b, c) + F_{X,Y}(a, c). \end{aligned}$$

高维情况只是继续对每一个坐标做这样的差分.

对于矩形 $R = \prod_{i=1}^n (a_i, b_i]$, 记

$$\Delta_R F := \sum_{\varepsilon \in \{0,1\}^n} (-1)^{n-|\varepsilon|} F(c_\varepsilon),$$

其中 c_ε 的第 i 个坐标在 $\varepsilon_i = 1$ 时取 b_i , 在 $\varepsilon_i = 0$ 时取 a_i .

如果 F 真的是某个随机向量的分布函数, 那么 $\Delta_R F$ 恰好就是这个矩形的概率, 因此必然满足 $\Delta_R F \geq 0$.

定义 3.12.

称函数 $F: \mathbb{R}^n \rightarrow [0, 1]$ 为一个 **n 维分布函数**, 是指其满足:

1. 对于任意半开矩形 $R = \prod_{i=1}^n (a_i, b_i]$, 都有 $\Delta_R F \geq 0$;
2. 如果 $x^{(k)} \downarrow x$ 逐坐标成立, 则 $F(x^{(k)}) \rightarrow F(x)$;
3. 如果任意一个坐标趋于 $-\infty$, 则 $F(x_1, \dots, x_n) \rightarrow 0$;
4. 当所有坐标同时趋于 $+\infty$ 时, $F(x_1, \dots, x_n) \rightarrow 1$.

第一条通常称为 F 的 **n -递增性**. 当 $n = 1$ 时, 它恰好就是普通的单调不减. 但是在高维情况下, 单独要求 F 对每一个坐标单调不减是不够的, 我们还必须保证每一个矩形对应的“概率”都是非负的.

定理 3.13.

令 $F: \mathbb{R}^n \rightarrow [0, 1]$ 为函数. 则 F 是某个 $\mathbb{R}^n$ 值随机向量的分布函数, 当且仅当 F 是一个 n 维分布函数.

此外, 此时存在唯一的 Borel 概率测度 μ_F , 满足对于任意 $x \in \mathbb{R}^n$ 都有

$$\mu_F((-\infty, x]) = F(x).$$

证明. 如果 F 来自某个概率测度, 上面的性质都可以直接由测度的性质得到.

反过来, 可以先在半开矩形上令 $\mu_F(R) := \Delta_R F$. n -递增性保证这些矩形增量非负. 然后把这个赋值扩展到由有限个不交半开矩形组成的代数上; 右连续性和边界条件保证它给出一个概率预测度. 再利用 Carathéodory 扩张定理得到 $\mathcal{B}(\mathbb{R}^n)$ 上的概率测度.

唯一性则可以由 π - λ 定理得到, 因为左下矩形 $(-\infty, x]$ 生成整个 $\mathcal{B}(\mathbb{R}^n)$. $\square$

因此对于 $\mathbb{R}^n$ 上的概率分布, 分布函数和概率测度携带相同的信息.

推论 3.14.

令 F 为任意 n 维分布函数. 则存在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 以及随机向量 $X: \Omega \rightarrow \mathbb{R}^n$, 使得 $F_X = F$.

证明. 令 μ_F 为 F 对应的 Borel 概率测度. 直接取概率空间 $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mu_F)$ 以及恒等随机向量 $X = \text{id}_{\mathbb{R}^n}$ 即可. $\square$

对于随机向量 $X = (X_1, \dots, X_n)$, 各个坐标随机变量的分布称为**边缘分布**. 比如二维情况下, 可以通过 $F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y)$ 从联合分布函数中恢复 X 的边缘分布函数.

3.2.2 一些常见的分布

接下来我们来看一些常见的概率分布.

下面我们不按公式列表来记这些分布. 相比于公式本身, 我们更加关心这些分布是在什么样的随机机制下自然出现的, 以及不同分布之间到底有什么关系.

离散分布

定义 3.15.

令 X 为随机变量. 称 X 具有**离散分布**, 是指存在有限或者可数集 $S \subseteq \mathbb{R}$, 使得 $\mathbb{P}(X \in S) = 1$.

此时函数 $p_X(x) := \mathbb{P}(X = x)$ 称为 X 的**概率质量函数** (probability mass function, PMF).

于是对于任意 Borel 集 A , 都有 $\mathbb{P}(X \in A) = \sum_{x \in A} p_X(x)$. 因此描述离散分布只需要说明, 每一个可能取值上放了多少概率质量.

例 3.16 (单点分布).

令 $a \in \mathbb{R}$. 如果随机变量 X 满足 $\mathbb{P}(X = a) = 1$, 那么称 X 服从位于 a 的**单点分布**. 它的分布就是 Dirac 测度 δ_a , 即

$$\delta_a(A) = \begin{cases} 1, & a \in A, \\ 0, & a \notin A. \end{cases}$$

这是最简单的概率分布: 所有概率质量全部集中在一个点上.

例 3.17 (Bernoulli 分布).

令 $p \in [0, 1]$. 如果随机变量 X 只取 0 和 1 两个值, 并满足 $\mathbb{P}(X = 1) = p$, $\mathbb{P}(X = 0) = 1 - p$, 那么称 X 服从参数为 p 的 **Bernoulli 分布**, 记作 $X \sim \text{Bernoulli}(p)$.

Bernoulli 分布就是一次“成功或者失败”实验最直接的数学描述. 比如抛一次硬币时, 可以令正面对应 1, 反面对应 0.

例 3.18 (二项分布).

令 $n \in \mathbb{N}$, $p \in [0, 1]$. 如果进行 n 次相互独立且成功概率均为 p 的 Bernoulli 实验, 并令 X 表示其中成功的总次数, 那么

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

此时称 X 服从参数为 (n, p) 的**二项分布**, 记作 $X \sim \text{Bin}(n, p)$.

Bernoulli 分布描述单次实验; 二项分布描述重复 n 次相同实验后的成功总次数.

等到后面正式定义独立性以后, 这也可以写成: 如果 $X_1, \dots, X_n$ 相互独立并且都服从 Bernoulli(p), 那么 $X_1 + \dots + X_n \sim \text{Bin}(n, p)$.

例 3.19 (几何分布).

令 $p \in (0, 1]$. 不断进行相互独立且成功概率均为 p 的 Bernoulli 实验, 并令 T 表示直到第一次成功为止一共进行了多少次实验. 那么

$$\mathbb{P}(T = k) = (1 - p)^{k-1}p, \quad k = 1, 2, \dots$$

此时称 T 服从参数为 p 的**几何分布**, 记作 $T \sim \text{Geom}(p)$.

几何分布研究首次成功所需的实验次数, 与累计成功次数无关.

这里采用的是取值从 1 开始的约定. 也有一些地方将第一次成功以前失败的次数记为几何分布, 那时其取值会从 0 开始.

例 3.20 (Poisson 分布).

令 $\lambda > 0$. 如果随机变量 X 取值于 $\mathbb{N}_0 = \{0, 1, 2, \dots\}$, 并满足

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k \in \mathbb{N}_0,$$

那么称 X 服从参数为 λ 的**Poisson 分布**, 记作 $X \sim \text{Pois}(\lambda)$.

Poisson 分布通常用来描述某一段固定时间或者固定区域内“一共发生了多少次事件”.

一个比较自然的理解是, 将这一段时间切成 n 个非常小的区间, 每一个小区间内发生一次事件的概率约为 λ/n , 并暂时假设这些小区间之间彼此独立. 那么总事件数近似服从 $\text{Bin}(n, \lambda/n)$.

对固定的 k , 当 $n \rightarrow \infty$ 时,

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda} \frac{\lambda^k}{k!}.$$

所以 Poisson 分布可以粗略理解成“大量极小概率 Bernoulli 事件的计数极限”.

这段直觉已经用到了独立性, 稳定发生率以及极短时间内不会同时发生很多次事件之类的假设. 后面介绍泊松过程时会重新正式处理这些条件.

绝对连续分布 离散分布将全部概率质量集中在至多可数多个点上. 另一种非常重要的情况, 则是分布关于 Lebesgue 测度绝对连续.

定义 3.21.

令 $X: \Omega \rightarrow \mathbb{R}^n$ 为随机向量, $\mu_X = X_*\mathbb{P}$ 为其分布. 称 X 具有**绝对连续分布**, 是指

$$\mu_X \ll \lambda_n,$$

其中 λ_n 为 $\mathbb{R}^n$ 上的 Lebesgue 测度.

此时由 Radon-Nikodym 定理, 存在非负可测函数 $f_X: \mathbb{R}^n \rightarrow [0, \infty)$, 使得对于任意 $A \in \mathcal{B}(\mathbb{R}^n)$ 都有

$$\mathbb{P}(X \in A) = \int_A f_X(x) dx.$$

称 f_X 为 X 的**概率密度函数** (probability density function, PDF).

所以概率密度就是随机变量分布关于 Lebesgue 测度的 Radon–Nikodym 导数, 也就是

$$f_X = \frac{d\mu_X}{d\lambda_n}.$$

特别地, 在一维情况下, $F_X(x) = \int_{-\infty}^x f_X(t) dt$.

这里要区分两个概念: $f_X(x)$ 并不表示事件 $X = x$ 的概率. 对于绝对连续随机变量, 任意单点的概率都等于 0; 概率由密度在相应区域上的积分给出.

此外, 分布函数连续也并不等价于分布绝对连续. 确实存在分布函数处处连续, 但是分布却关于 Lebesgue 测度奇异的情况. 所以“存在概率密度”的条件是 $\mu_X \ll \lambda_n$.

例 3.22 (均匀分布).

令 $a < b$. 如果随机变量 X 的概率密度为

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x),$$

那么称 X 服从区间 $[a, b]$ 上的**均匀分布**, 记作 $X \sim \text{Unif}(a, b)$.

可以把它看作古典等可能模型的连续版本. 每一个单独的点虽然概率都为 0, 但是长度相同的区间具有相同的概率.

例 3.23 (指数分布).

令 $\lambda > 0$. 如果随机变量 T 的概率密度为

$$f_T(t) = \lambda e^{-\lambda t} \mathbf{1}_{[0,\infty)}(t),$$

那么称 T 服从参数为 λ 的**指数分布**, 记作 $T \sim \text{Exp}(\lambda)$.

指数分布通常描述连续时间中“等待下一次事件发生需要多久”.

因此它和几何分布具有非常自然的类比: 几何分布记录离散时间中要经过多少次实验才第一次成功, 而指数分布记录连续时间中要等待多久才第一次发生事件.

更进一步, 几何分布和指数分布都具有所谓的**无记忆性**. 比如对于指数分布, 当 $s, t \geq 0$ 时有

$$\mathbb{P}(T > s+t \mid T > s) = \mathbb{P}(T > t).$$

已经等待的时长不会改变从当前起继续等待的概率规律.

例 3.24 (Gamma 分布).

令 $\alpha > 0, \lambda > 0$. 如果随机变量 T 的概率密度为

$$f_T(t) = \frac{\lambda^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\lambda t} \mathbf{1}_{[0,\infty)}(t),$$

那么称 T 服从形状参数为 α , 率参数为 λ 的 **Gamma 分布**, 记作 $T \sim \text{Gamma}(\alpha, \lambda)$.

这里采用的是率参数 (rate parameter) 约定. 另一种常见记法使用尺度参数 (scale parameter) $\theta = 1/\lambda$.

Gamma 分布和 Poisson 分布之间有一个非常自然的关系.

在后面泊松过程的设定中, 假设事件以恒定速率 λ 发生, 并令 $N(t)$ 表示时间 t 以前发生的事件次数. 那么会有 $N(t) \sim \text{Pois}(\lambda t)$.

现在反过来, 令 T_k 表示第 k 次事件发生所需要的时间. 那么 $\{T_k > t\} = \{N(t) \leq k-1\}$, 因此

$$\mathbb{P}(T_k \leq t) = 1 - \sum_{j=0}^{k-1} e^{-\lambda t} \frac{(\lambda t)^j}{j!}.$$

对 t 求导以后得到

$$f_{T_k}(t) = \frac{\lambda^k}{(k-1)!} t^{k-1} e^{-\lambda t} \mathbf{1}_{[0, \infty)}(t).$$

由于 $\Gamma(k) = (k-1)!$, 这恰好就是 $\text{Gamma}(k, \lambda)$ 的概率密度.

Poisson 分布和 Gamma 分布来自同一个随机机制, 分别回答两个方向相反的问题: 固定时间 t 时, 问发生了多少次事件, 得到 Poisson 分布; 固定事件次数 k 时, 问等到第 k 次事件需要多久, 得到 Gamma 分布.

特别地, 当 $k = 1$ 时, Gamma 分布就退化指数分布. 所以指数分布也就是等待第一次 Poisson 事件发生所需要时间的分布.

例 3.25 (正态分布).

令 $\mu \in \mathbb{R}, \sigma > 0$. 如果随机变量 X 的概率密度为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right),$$


那么称 X 服从参数为 (μ, σ^2) 的 **正态分布** (normal distribution), 也称 Gauss 分布, 记作

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

当 $\mu = 0, \sigma = 1$ 时, 称其为**标准正态分布**, 记作 $\mathcal{N}(0, 1)$.

从概率密度的图像来看, 正态分布关于 $x = \mu$ 对称. 参数 μ 控制整个分布在实轴上的位置, 而 σ 控制分布展开的尺度: σ 越大, 概率质量铺得越开; σ 越小, 概率质量则越集中在 μ 附近.

比如下面画出了 $\mu = 0$ 时正态分布概率密度的大致形状, 并标出了距离均值 $\sigma, 2\sigma, 3\sigma$ 的位置.



后面定义期望和方差以后我们会看到, μ 恰好就是 X 的期望, 而 σ^2 恰好就是其方差, 因此 σ 就是标准差.

对于正态分布, 大约有 68.27% 的概率质量落在 $(\mu - \sigma, \mu + \sigma)$ 内, 95.45% 落在 $(\mu - 2\sigma, \mu + 2\sigma)$ 内, 而 99.73% 落在 $(\mu - 3\sigma, \mu + 3\sigma)$ 内.

因而在正态模型下, 落在 $\mu \pm 3\sigma$ 以外的概率约为 0.27%, 这也就是常说的“ 3σ 法则”.

正态分布还有一个非常方便的性质: 它在线性变换下仍然保持为正态分布. 如果 $X \sim \mathcal{N}(\mu, \sigma^2)$, 那么对于 $a \neq 0$ 和 $b \in \mathbb{R}$, 有

$$aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

特别地,

$$\frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1),$$

这个过程通常称为**标准化**.

此外, 如果 X 和 Y 相互独立, 并分别满足 $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$ 和 $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$, 那么

$$X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

正态分布之所以如此常见, 除了钟形曲线便于处理, 更重要的原因是, 大量相对独立的小随机扰动叠加以后, 在相当一般的条件下都会趋近于正态分布.

后面的中心极限定理会精确表述这一现象.

注 3.26 (多元正态分布).

正态分布也可以推广到随机向量.


令 $\mu \in \mathbb{R}^n$, Σ 为正定的 $n \times n$ 矩阵. 对应的 n 元正态分布记作 $\mathcal{N}(\mu, \Sigma)$, 其概率密度为

$$f(x) = \frac{1}{(2\pi)^{n/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right).$$

后面定义随机向量的期望和协方差以后会看到, μ 就是均值向量, 而 Σ 就是协方差矩阵.

从几何上来看, 一维正态分布中“离均值多少个标准差”的概念, 到高维以后会变成由 Σ 决定的椭球结构.

比如下面画出了一个二维正态分布的等密度区域. 椭圆的中心就是均值 μ , 而椭圆的方向以及沿各个方向展开的程度则由协方差矩阵 Σ 决定.



更具体地说, 正态密度的等值面满足

$$(x - \mu)^\top \Sigma^{-1}(x - \mu) = c,$$

因而在二维中就是椭圆, 在更高维中则是椭球.

更一般的多元正态分布还允许 Σ 只是半正定. 此时分布可能退化到某个低维仿射子空间上, 因而不具有关于整个 $\mathbb{R}^n$ 上 Lebesgue 测度的概率密度.

注 3.27.

上面的几个分布与其说是一堆需要记忆的公式, 不如说是在回答几类非常自然的问题:

Bernoulli 分布问一次实验是否成功; Binomial 分布问 n 次实验一共成功多少次; Geometric 分布问要做多少次实验才第一次成功; Poisson 分布问一段固定时间内发生多少次事件; Exponential 分布问等待第一次事件需要多久; Gamma 分布问等待第 k 次事件需要多久; Normal 分布则描述大量小随机扰动叠加以后出现的典型极限形状.

比单条公式更值得记住的, 是各分布所描述的随机机制.

3.3 期望与矩

3.3.1 期望与矩的基本语言

前面我们主要研究了随机变量的分布, 也就是一个随机变量可能取哪些值, 以及这些值按照怎样的概率规律出现.

完整的分布通常包含很多信息. 实际研究时, 我们经常先用几个数字概括其主要特征: 随机变量通常位于什么位置, 围绕这个位置的波动有多大, 或者分布有多偏. 许多这类信息可以用随机变量的矩描述, 其中最基本的是期望.

在前面的测度论中, 我们已经定义了可测函数关于测度的 Lebesgue 积分, 所以到了概率论里面并不需要重新发明一种新的“平均值”.

定义 3.28.

令 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, $X: \Omega \rightarrow \mathbb{R}$ 为随机变量. 如果 $X \in L^1(\Omega, \mathbb{P})$, 则 X 的**期望** (expectation) 是指

$$\mathbb{E}[X] := \int_{\Omega} X \, d\mathbb{P}.$$

这里定义的是有限期望. 对于非负随机变量 $X \geq 0$, 也常允许扩展值期望

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P} \in [0, \infty],$$

所以它可以等于 $+\infty$. 对于一般实值随机变量, 可以先写 $X = X^+ - X^-$; 只要 $\mathbb{E}[X^+]$ 和 $\mathbb{E}[X^-]$ 不同时为 $+\infty$, 扩展值意义下的期望就有定义. 而有限期望正好对应 $X \in L^1$.

期望就是概率测度下的 Lebesgue 积分, 可以理解为按概率测度对不同结果加权的“平均值”. 它一般不能通过把所有可能取值相加再除以个数来计算.

比如如果 X 只取可数多个值 $x_1, x_2, \dots$, 那么在期望存在时有 $\mathbb{E}[X] = \sum_i x_i \mathbb{P}(X = x_i)$; 如果 X 具有概率密度 f_X , 那么 $\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x) \, dx$. 初等概率论中的“离散情况求和, 连续情况积分”是同一个 Lebesgue 积分在不同分布下的两种表现形式.

回忆前面, 实值随机变量 X 的分布就是前推测度 $\mu_X = X_*\mathbb{P}$. 因此前推测度的积分公式直接告诉我们, 如果 $g: \mathbb{R} \rightarrow \mathbb{R}$ 为可测函数并且 $g(X)$ 可积, 那么

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \, d\mu_X(x).$$

所以只要研究的是 X 的函数, 它的期望只依赖于 X 的分布, 而与 X 究竟在哪个概率空间上实现没有关系. 特别地, 如果 $X \stackrel{d}{=} Y$, 那么只要相关期望存在, 对于任意合适的 g 都有 $\mathbb{E}[g(X)] = \mathbb{E}[g(Y)]$.

因为期望就是 Lebesgue 积分, 前面关于积分的大量性质也可以直接搬过来. 对于 $X, Y \in L^1$ 和 $a, b \in \mathbb{R}$, 有 $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$. 如果 $X \leq Y$ 几乎必然 (almost surely, a.s.), 则 $\mathbb{E}[X] \leq \mathbb{E}[Y]$. 对于事件 A 的示性随机变量, 有 $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$, 所以概率本身也可以被理解成一种最简单的期望. 由 $|\mathbb{E}[X]| \leq \mathbb{E}[|X|] = \|X\|_1$, 期望还是 $L^1(\Omega, \mathbb{P})$ 上的连续线性泛函.

前面介绍 L^p 空间时已经看到, 当 $1 \leq p < \infty$ 时有 $\|X\|_p^p = \mathbb{E}[|X|^p]$. 所以从 L^p 的角度来看, “随机变量具有有限的 p 阶绝对矩”就是在说 $X \in L^p(\Omega, \mathbb{P})$.

定义 3.29.

令 X 为实值随机变量, $k \in \mathbb{N}$. 如果 $X \in L^k$, 则称 $\mathbb{E}[|X|^k] = \|X\|_k^k$ 为 X 的 k 阶**绝对矩**; 相应地, $\mathbb{E}[X^k]$ 称为 X 的 k 阶**矩**, 也称为 k 阶**原点矩**.

与 L^k 范数直接对应的是绝对矩. 当 k 为偶数时 $X^k = |X|^k$, 因此 $\mathbb{E}[X^k] = \|X\|_k^k$; 当 k 为奇数时, X^k 会保留正负号, 一般不能直接用 L^k 范数表示.

类似地, $\mathbb{E}[|X - \mathbb{E}[X]|^k] = \|X - \mathbb{E}[X]\|_k^k$ 称为 k 阶**绝对中心矩**, 而 $\mathbb{E}[(X - \mathbb{E}[X])^k]$ 则称为 k 阶**中心矩**. 绝对矩衡量取值大小; 普通矩在奇数阶还会保留正负方向, 因而可能发生抵消. 阶数越高, 越大的取值获得的权重也就越大.

又因为概率空间满足 $\mathbb{P}(\Omega) = 1$, 对于 $1 \leq p < q$ 有 $L^q \subseteq L^p$, 所以高阶绝对矩有限会自动推出所有更低阶绝对矩有限.

3.3.2 二阶结构与尾部控制

L^2 空间, 协方差与方差 在所有的 L^p 空间里面, L^2 对概率论尤其重要, 因为它是一个希尔伯特 (Hilbert) 空间. 对于实值随机变量 $X, Y \in L^2(\Omega, \mathbb{P})$, 其内积就是 $\langle X, Y \rangle = \mathbb{E}[XY]$.

直接使用这个内积时, 随机变量自身的平均位置也会混在其中. 若关心随机变量围绕各自平均位置的共同波动, 可以先将它们中心化. 记 $X^\circ = X - \mathbb{E}[X]$, 那么 $\langle X^\circ, \mathbf{1} \rangle = 0$, 即中心化后的随机变量与常数函数正交.

$\mathbb{E}[X]\mathbf{1}$ 是 X 向常数函数子空间的正交投影. 因此期望还有一个自然的几何解释: 在所有常数 $c \in \mathbb{R}$ 中, $\mathbb{E}[X]$ 恰好使 $\|X - c\|_2$ 最小. 它是在均方误差意义下用常数逼近 X 的最优选择.

定义 3.30.

令 $X, Y \in L^2(\Omega, \mathbb{P})$. X 与 Y 的协方差是指

$$\text{Cov}(X, Y) := \langle X - \mathbb{E}[X], Y - \mathbb{E}[Y] \rangle.$$

协方差就是两个随机变量中心化以后在 L^2 中的内积. 对于实值随机变量, 这也就是 $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$, 展开以后得到

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

如果协方差为正, 大致表示二者相对于各自平均值的偏离倾向于同向; 如果为负, 则倾向于反向. 如果 $\text{Cov}(X, Y) = 0$, 那么中心化后的两个随机变量在 L^2 中正交, 此时称 X 与 Y **不相关**. 不相关只表示二阶线性结构下的正交, 一般不能推出独立.

有了协方差以后, 方差只是令两个随机变量相同得到的特殊情况.

定义 3.31.

令 $X \in L^2(\Omega, \mathbb{P})$. X 的方差是指

$$\text{Var}(X) := \text{Cov}(X, X) = \|X - \mathbb{E}[X]\|_2^2.$$

从 Hilbert 空间的角度来看, 方差就是中心化随机变量的长度平方. 因此 $\text{Var}(X) \geq 0$, 并且 $\text{Var}(X) = 0$ 当且仅当 $X = \mathbb{E}[X]$ a.s. 展开以后还有 $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$.

定义 3.32.

令 $X \in L^2(\Omega, \mathbb{P})$. X 的标准差是指

$$\text{Std}(X) := \sqrt{\text{Var}(X)} = \|X - \mathbb{E}[X]\|_2.$$

如果方差是中心化随机变量的长度平方, 标准差就是它的 L^2 长度. 这也解释了为什么要对方差开平方: 方差的量纲被平方了, 而标准差又回到了和原随机变量相同的尺度.

协方差仍然受到随机变量尺度的影响. 比如把 X 放大 100 倍, 协方差也会放大 100 倍. 所以如果希望得到一个与尺度无关的量, 自然应该进一步标准化.

定义 3.33.

令 $X, Y \in L^2(\Omega, \mathbb{P})$, 并假设二者方差均非零. X 与 Y 的相关系数是指

$$\rho(X, Y) := \frac{\text{Cov}(X, Y)}{\text{Std}(X)\text{Std}(Y)}.$$

如果令 $\tilde{X} = (X - \mathbb{E}[X])/\text{Std}(X)$, $\tilde{Y} = (Y - \mathbb{E}[Y])/\text{Std}(Y)$, 那么 $\rho(X, Y) = \langle \tilde{X}, \tilde{Y} \rangle$. 又因为 $\|\tilde{X}\|_2 = \|\tilde{Y}\|_2 = 1$, 所以相关系数其实就是 L^2 中两个单位向量之间的内积, 也就是所谓的“夹角余弦”. 因此由 Cauchy-Schwarz 不等式自然有 $|\rho(X, Y)| \leq 1$.

期望, 协方差, 方差, 标准差和相关系数都来自同一个 L^2 Hilbert 空间结构, 由此形成相互关联的一组公式.

尾部与尾部风险 前面介绍的期望, 方差以及各种矩, 都试图用少量数字概括完整的概率分布. 在许多问题中, 尤其是金融市场里, 除了随机变量通常位于哪里, 还要了解它进入极端区域时会发生什么.

分布中远离主要概率质量的部分通常称为分布的**尾部** (tail). 对于实值随机变量 X , 当 x 很大时, $\mathbb{P}(X > x)$ 描述右尾, $\mathbb{P}(X < -x)$ 描述左尾; 如果只关心偏离原点有多远, 也经常考察 $\mathbb{P}(|X| > x)$.

所谓“尾部有多重”, 指的是阈值向远端移动时, 极端事件的概率以多快的速度趋于 0.

定义 3.34.

令 X 为实值随机变量, F_X 为其分布函数. X 的**右尾函数**, 也称**生存函数**, 是指

$$\bar{F}_X(x) := \mathbb{P}(X > x) = 1 - F_X(x).$$

分布函数回答“走到 x 为止已经积累了多少概率”, 尾函数回答“走过 x 后还剩下多少概率”. 尾部下降得越快, 极端取值通常越少; 下降得越慢, 极端事件就越常见. 因此常用**轻尾**或**重尾**作非正式描述. 重尾在不同文献中有多种严格定义, 这里暂取宽松含义: 尾部概率下降得相对较慢.

尾部和矩之间的关系非常直接. 对于非负随机变量 X , 有

$$\mathbb{E}[X] = \int_0^\infty \mathbb{P}(X > t) dt,$$

两边允许同时为 $+\infty$. 这是因为逐点都有 $X(\omega) = \int_0^\infty \mathbf{1}_{\{X(\omega) > t\}} dt$, 再使用 Tonelli 定理交换积分即可.

更加一般地, 对于 $p > 0$ 有

$$\mathbb{E}[|X|^p] = p \int_0^\infty t^{p-1} \mathbb{P}(|X| > t) dt.$$

这个公式说明高阶矩为何更重视尾部. 当 p 增大时, t^{p-1} 会更强烈地放大极端取值. 如果分布的尾部下降太慢, 某些高阶矩就可能发散. 因而 $X \in L^p$ 也可理解为尾部下降得足够快, 使这个加权尾部积分有限.

比如正态分布的尾部下降得非常快, 所以它具有任意阶的绝对矩. 而如果一个随机变量具有类似 $\mathbb{P}(|X| > x) \sim Cx^{-\alpha}$ 的幂律尾部, 那么只有 $p < \alpha$ 的绝对矩有限, 当 $p \geq \alpha$ 时相应的矩会发散.

“期望和方差是多少”无法完整描述一个分布. 两个分布可以具有相同的期望和方差, 其中一个却在极端区域放置了更多概率质量. 只看前两阶矩很容易忽略这种差异.

反过来, 如果我们已经知道一些矩, 也可以利用它们控制尾部概率.

定理 3.35 (Markov 不等式).

令 $X \geq 0$ 为可积随机变量, $a > 0$. 则

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

证明. 因为 $X \geq a\mathbf{1}_{\{X \geq a\}}$, 取期望即可. □

更加一般地, 如果 $X \in L^p$, 那么对 $|X|^p$ 使用 Markov 不等式就得到

$$\mathbb{P}(|X| \geq a) \leq \frac{\mathbb{E}[|X|^p]}{a^p} = \frac{\|X\|_p^p}{a^p}.$$

矩和尾部之间存在一种很自然的双向关系: 尾部下降得有多快决定了哪些矩能够存在; 而控制住某个高阶矩以后, 又可以反过来限制极端事件的概率.

定理 3.36 (Chebyshev 不等式).

令 $X \in L^2(\Omega, \mathbb{P})$, $a > 0$. 则

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

Chebyshev 不等式把 Markov 不等式应用到中心化随机变量的平方上. 方差既是一个 L^2 长度平方, 也能控制随机变量远离平均位置的概率.

Markov 和 Chebyshev 不等式只使用少量信息, 实际给出的界往往很粗糙. 它们揭示的基本思路更重要: **控制矩可以转化成控制尾部概率**. 后面的大数定律以及许多随机过程中的概率估计都会用到这一点.

尾部在金融市场里尤其重要. 投资中既要考察正常情况下的结果, 也要追问当事情明显偏离原有预期时可能坏到什么程度.

比如令 V 表示某个未来时点资产的价值. 理论上我们想知道的是 V 的完整概率分布, 但现实中的基本面研究通常很难准确给出这样一个分布. 一种自然的做法就是先将可能结果划分成若干具有经济意义的情景, 例如乐观情景 (Bull), 基准情景 (Base), 悲观情景 (Bear) 和尾部情景 (Tail), 然后再分别给出这些情景发生的概率以及相应估值.

从概率论的角度来看, 情景分析可以看作对原分布的一种粗粒化. 如果事件 A_i 构成对于可能结果的分区, 并为每个区域选择一个代表性价值 V_i , 那么可以构造近似随机变量

$$\tilde{V} = \sum_i V_i \mathbf{1}_{A_i}, \quad \mathbb{E}[\tilde{V}] = \sum_i \mathbb{P}(A_i) V_i.$$

平常写的 $\sum_i p_i V_i$ 就是在计算这个粗粒化分布的期望. Bull, Base, Bear, Tail 是按研究目的对原本连续而复杂的分布所作的人为压缩, 不属于概率论的标准划分.

这里的尾部情景也最好不要简单理解成“比悲观情景再悲观一点”. 如果从概率论的尾部来看, Tail 想强调的是那些发生概率比较低, 但结果明显偏离通常区域, 并且一旦发生就可能造成巨大损失的事件.

因此金融里面所谓的尾部风险 (tail risk) 同时在问两件事: 掉进尾部的概率有多大, 以及一旦真的掉进去以后究竟可能有多糟. 这也是为什么仅仅知道期望和方差通常还远远不够.

后面讨论条件期望时会看到, 如果每个情景中的代表值 V_i 取成该情景下 V 的条件期望, 这种情景分解对总期望会成为严格等式. 金融部分还会由尾部研究引出风险价值 (Value at Risk, VaR), 预期短缺 (Expected Shortfall, ES) 以及更一般的尾部风险度量.

3.4 独立性, 条件概率与条件期望

3.4.1 独立性与条件概率

事件与随机变量的独立性 前面我们主要是在研究单个随机变量以及它自身的分布. 但是一旦同时考虑多个事件或者多个随机变量, 一个很自然的问题就是: 它们之间究竟有没有关系?

比如令 A 表示“未来一个月股票上涨”, B 表示“下一次财报超出市场预期”. 如果知道 B 已经发生后, 对 A 发生概率的判断完全没有变化, 便可认为 B 没有为 A 提供额外的概率信息. 这就是独立性.

定义 3.37.

令 $A, B \in \mathcal{F}$ 为事件. 称 A 与 B **相互独立**, 是指其满足

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

独立性有精确的概率含义: 一个事件是否发生, 不会为另一个事件提供额外的概率信息. “两个事件看起来没有关系”不能替代这一定义. 如果 $\mathbb{P}(B) > 0$, 那么上面的条件等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$.

当同时考虑很多事件时, 还需要区分两两独立和共同独立.

定义 3.38.

令 $(A_i)_{i \in I}$ 为一族事件. 称它们**相互独立**, 是指对于任意不同的 $i_1, \dots, i_n \in I$ 都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

如果只要求任意两个事件相互独立, 则称它们**两两独立**. 两两独立一般并不能推出整族事件相互独立, 因为若干个事件放在一起以后仍然可能出现额外的依赖结构.

对于随机变量来说, 独立性还可以从信息的角度重新理解. 前面已经看到, 随机变量 X 所携带的信息可以由 $\sigma(X)$ 描述, 所以一族随机变量相互独立, 就是它们各自携带的信息之间互不提供额外信息.

定义 3.39.

令 $(X_i)_{i \in I}$ 为定义在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的一族随机元素. 称它们**相互独立**, 是指任意有限子族都满足下面第一条. 在实值情形中, 第一条还等价于后两条:

1. 对于任意不同的 $i_1, \dots, i_n \in I$ 以及任意 $A_{i_k} \in \sigma(X_{i_k})$, 都有

$$\mathbb{P}\left(\bigcap_{k=1}^n A_{i_k}\right) = \prod_{k=1}^n \mathbb{P}(A_{i_k}).$$

2. 对于实值随机变量 $X_1, \dots, X_n$, 等价地, 任意 Borel 集 $B_1, \dots, B_n \subseteq \mathbb{R}$ 都满足

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i).$$

3. 如果记 $X = (X_1, \dots, X_n)$, 那么从分布的角度来看, 独立性又等价于联合分布分解成各个边缘分布的乘积:

$$\mu_X = \mu_{X_1} \otimes \cdots \otimes \mu_{X_n}.$$

因此独立性也可以理解成: 联合分布里面没有超出各个边缘分布之外的额外依赖结构.

特别地, 如果 $X, Y \in L^2$ 相互独立, 那么 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$, 因而 $\text{Cov}(X, Y) = 0$. 所以独立会推出不相关, 但是反过来一般并不成立. 只有在某些特殊情况里面, 比如 (X, Y) 联合正态时, 不相关才会推出独立.

条件概率与 Bayes 公式 现实中的许多事件彼此依赖. 已知一件事后, 对另一件事的概率判断可能改变, 条件概率用来描述这种变化.

定义 3.40.

令 $A, B \in \mathcal{F}$, 并满足 $\mathbb{P}(B) > 0$. A 在给定 B 发生条件下的**条件概率**是指

$$\mathbb{P}(A | B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

这个定义很好理解. 既然已经知道 B 发生, 原来的样本空间就被限制到了 B 中; 此时 A 能够发生的部分只剩下 $A \cap B$, 再除以 $\mathbb{P}(B)$, 就是把 B 中剩余的概率重新归一化成 1.

固定 B 以后, $A \mapsto \mathbb{P}(A | B)$ 本身又是一个概率测度. 因此条件概率可以理解成: 获得一部分新信息以后, 重新归一化得到的概率规律.

由定义立刻得到 $\mathbb{P}(A \cap B) = \mathbb{P}(A | B)\mathbb{P}(B)$. 交换 A, B 的位置以后, 就得到 Bayes 公式.

定理 3.41 (Bayes 公式).

令 $A, B \in \mathcal{F}$, 并满足 $\mathbb{P}(A), \mathbb{P}(B) > 0$. 则

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}.$$

Bayes 公式描述的是: 看到新的证据 B 以后, 怎样把原来对于事件 A 的概率判断更新为 $\mathbb{P}(A | B)$. $\mathbb{P}(A)$ 是看到信息 B 以前的判断, 而 $\mathbb{P}(A | B)$ 则是在知道 B 以后得到的新判断.

如果 (B_i) 构成 Ω 的一个可列分割, 并且 $\mathbb{P}(B_i) > 0$, 那么还有

$$\mathbb{P}(A) = \sum_i \mathbb{P}(A | B_i)\mathbb{P}(B_i),$$

这就是**全概率公式**.

它和前面 Bull, Base, Bear, Tail 的情景分析已经很接近. 如果这些情景对应一组互不相交并覆盖全部可能结果的事件 B_i , 那么总体概率就可以通过“各情景自身的概率”和“每个情景内部的条

件概率”重新拼回来. 而 Bayes 公式做的事情则正好反过来: 当我们得到新的财报, 行业或者宏观信息以后, 原来分配给 Bull, Base, Bear, Tail 的概率也应该随之发生变化.

例 3.42 (DSpark 中的条件概率).

一个比较现代的条件概率例子来自 DeepSeek 提出的 DSpark 系统 [Che+26]. 它属于投机解码 (speculative decoding) 一类方法: 成本较低的草稿模型 (draft model) 先生成一段候选文本, 再由成本较高的目标模型 (target model) 进行验证.

DSpark 中, 后续词元 (token) 的接受与前缀验证结果相互关联. 如果候选前缀已经没有通过验证, 后面的候选也就失去了继续验证的意义. 因此它需要估计一种沿前缀逐步条件化的接受概率.

令 A_k 表示“第 k 个草稿词元最终被目标模型接受”这一事件. DSpark 会估计条件接受概率

$$c_k \approx \mathbb{P}(A_k \mid A_1 \cap \cdots \cap A_{k-1}).$$

c_k 描述在前面的草稿词元已经全部通过验证的条件下, 当前词元继续被接受的概率.

因此由条件概率的乘法公式, 前 k 个词元全部通过验证的概率大约为

$$a_k := \prod_{i=1}^k c_i \approx \mathbb{P}(A_1 \cap \cdots \cap A_k).$$

DSpark 将 a_k 称为前缀存活概率 (prefix survival probability).

最后, 调度器会结合这些前缀存活概率和当前硬件负载, 判断这段草稿中有多少部分值得交给目标模型验证.

3.4.2 条件期望

定义与存在性 目前为止, 条件概率描述“已知某个事件 B 发生后”如何更新对其他事件的概率判断. 随机过程中的已知信息通常比单个事件丰富得多.

比如截至时刻 t , 我们可能已经观察到了整个股票价格历史, 以及成交量, 新闻, 订单流等等. 这些已经获得的信息更加自然地应该由一个子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$ 来描述.

于是问题变成: 给定随机变量 X , 如果现在只允许使用 $\mathcal{G}$ 中的信息, 我们应该怎样描述 X ?

为了方便, 对于随机变量 X 和事件 $B \in \mathcal{F}$, 记

$$\mathbb{E}[X; B] := \mathbb{E}[X \mathbf{1}_B] = \int_B X \, d\mathbb{P}.$$

现在固定 $X \in L^1(\Omega, \mathbb{P})$ 以及子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$. 我们希望找到一个随机变量 Y , 使它满足两件事:

1. Y 是 $\mathcal{G}$ -可测的;
2. 对于任意 $B \in \mathcal{G}$, 都有 $\mathbb{E}[Y; B] = \mathbb{E}[X; B]$.

这里第一条要求 Y 只能使用 $\mathcal{G}$ 中已经能够观察到的信息; 第二条则要求虽然 Y 丢掉了 X 中一部分暂时无法观察的信息, 但是在任何 $\mathcal{G}$ 能够分辨出来的事件上, 它都保留 X 原来的平均值.

我们先验证唯一性, 再用 Radon–Nikodym 定理解决存在性.

命题 3.43 (唯一性).

令 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 假设 $Y, Z \in L^1(\Omega, \mathbb{P})$ 都是 $\mathcal{G}$ -可测的, 并且对于任意 $B \in \mathcal{G}$ 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B] = \mathbb{E}[Z; B].$$

则 $Y = Z$ a.s.

证明. 令 $W = Y - Z$. 因为 W 为 $\mathcal{G}$ -可测, 所以 $B_+ = \{W > 0\}$ 和 $B_- = \{W < 0\}$ 都属于 $\mathcal{G}$.

由假设有 $\mathbb{E}[W; B_+] = 0$, 而 $W \mathbf{1}_{B_+} \geq 0$, 所以 $W \mathbf{1}_{B_+} = 0$ a.s. 由于 $W > 0$ 在 B_+ 上成立, 这推出 $\mathbb{P}(B_+) = 0$. 对 B_- 同理, 因而 $W = 0$ a.s. $\square$

剩下的问题只是这样的 Y 是否一定存在, 而答案正好由前面介绍过的 Radon–Nikodym 定理给出.

定理 3.44 (条件期望的存在性).

令 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 则存在 $\mathcal{G}$ -可测随机变量 $Y \in L^1(\Omega, \mathbb{P})$, 使得对于任意 $B \in \mathcal{G}$ 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

证明. 写 $X = X^+ - X^-$. 因为 $X \in L^1$, 所以可以在 $(\Omega, \mathcal{G})$ 上定义两个有限测度

$$\nu^+(B) := \mathbb{E}[X^+; B], \quad \nu^-(B) := \mathbb{E}[X^-; B].$$

由定义可见 $\nu^+, \nu^- \ll \mathbb{P}|_{\mathcal{G}}$. 因此由 Radon–Nikodym 定理存在非负 $\mathcal{G}$ -可测函数 Y^+, Y^- , 使得对于任意 $B \in \mathcal{G}$ 都有

$$\nu^\pm(B) = \int_B Y^\pm d\mathbb{P}.$$

又因为 $\mathbb{E}[Y^\pm] = \nu^\pm(\Omega) = \mathbb{E}[X^\pm] < \infty$, 所以 $Y = Y^+ - Y^-$ 属于 L^1 . 对任意 $B \in \mathcal{G}$,

$$\int_B Y d\mathbb{P} = \nu^+(B) - \nu^-(B) = \mathbb{E}[X; B],$$

也就是 $\mathbb{E}[Y; B] = \mathbb{E}[X; B]$. □

于是我们可以正式给这个几乎必然唯一的对象一个名字.

定义 3.45.

令 $X \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 称随机变量 $Y \in L^1(\Omega, \mathbb{P})$ 为 X 关于 $\mathcal{G}$ 的**条件期望**, 是指其满足:

1. Y 是 $\mathcal{G}$ -可测的;
2. 对于任意 $B \in \mathcal{G}$, 都有

$$\mathbb{E}[Y; B] = \mathbb{E}[X; B].$$

这样的 Y 存在且在 a.s. 意义下唯一, 记作

$$Y = \mathbb{E}[X | \mathcal{G}].$$

$\mathbb{E}[X | \mathcal{G}]$ 仍然是随机变量, 通常不再是一个数. 可以把 $\mathcal{G}$ 理解成当前能够观察到的信息; 条件期望把 X 压缩到这些信息上, 同时保留所有 $\mathcal{G}$ -可见的平均值.

如果 B 是满足 $\mathbb{P}(B) > 0$ 的事件, 我们也记

$$\mathbb{E}[X | B] := \frac{\mathbb{E}[X \mathbf{1}_B]}{\mathbb{P}(B)}.$$

条件期望的这个定义在 $\mathcal{G}$ 由一个分割生成时尤其直观. 假设非空集合 $B_1, \dots, B_n$ 两两不交并且并为 Ω , 并令 $\mathcal{G} = \sigma(B_1, \dots, B_n)$. 此时每个 B_i 都是 $\mathcal{G}$ 的一个**原子**: $\mathcal{G}$ 中的任意集合都只能由若干个 B_i 拼出来, 因而 $\mathcal{G}$ 根本无法继续区分同一个 B_i 中的样本点.

所以任何 $\mathcal{G}$ -可测实值随机变量都必须在每个 B_i 上取常值. 如果 $\mathbb{P}(B_i) > 0$, 那么条件期望在这个原子上的值只能是

$$\mathbb{E}[X | \mathcal{G}](\omega) = \mathbb{E}[X | B_i], \quad \omega \in B_i,$$

即

$$\mathbb{E}[X | \mathcal{G}] = \sum_{i: \mathbb{P}(B_i) > 0} \mathbb{E}[X | B_i] \mathbf{1}_{B_i} \quad \text{a.s.}$$

如果某个 B_i 的概率为 0, 那么条件期望在这个原子上取什么值都不会产生影响, 这也正是条件期望只能在 a.s. 意义下唯一的一个最简单例子.

在有限分割下, 条件期望就是把 X 在每一个当前能够辨认的原子里面取一次平均. 这和前面的 Bull, Base, Bear, Tail 情景分析也很接近: 如果 $\mathcal{G}$ 只能告诉我们当前落在哪一个情景中, 那么条件期望就在每个情景内部取对应的平均值.

两个极端情况也立即可以看出来. 如果 $\mathcal{G} = \{\emptyset, \Omega\}$, 那么整个 Ω 就只有一个原子, 所以 $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X]$ a.s.; 如果 $\mathcal{G} = \mathcal{F}$, 或者更一般地 X 本身已经是 $\mathcal{G}$ -可测的, 那么 $\mathbb{E}[X | \mathcal{G}] = X$ a.s.

基本性质与均方投影 条件期望具有下面这些基本性质.

命题 3.46 (条件期望的基本性质).

令 $X, Y \in L^1(\Omega, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. 在相应表达式有意义时, 有:

- **线性性:** $\mathbb{E}[aX + bY | \mathcal{G}] = a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]$.
- **单调性:** 如果 $X \leq Y$ a.s., 那么 $\mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[Y | \mathcal{G}]$ a.s.
- **保留期望:** $\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]$.
- **已知量可以提出:** 如果 Z 是有界的 $\mathcal{G}$ -可测随机变量, 那么 $\mathbb{E}[XZ | \mathcal{G}] = Z\mathbb{E}[X | \mathcal{G}]$.
- **塔性质:** 如果 $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$, 那么

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}].$$

- **独立性:** 如果 X 与 $\mathcal{G}$ 独立, 那么 $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X]$ a.s.

塔性质可以理解为: 先利用较丰富的信息 $\mathcal{G}$ 对 X 进行一次压缩, 再继续忘掉信息直到只剩 $\mathcal{H}$, 和一开始直接只保留 $\mathcal{H}$ 的结果一样.

普通 Jensen 不等式也有完全对应的条件版本.

定理 3.47 (条件 Jensen 不等式).

令 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 为凸函数, 并假设 $X \in L^1$ 且 $\varphi(X) \in L^1$. 则

$$\varphi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\varphi(X) | \mathcal{G}] \quad \text{a.s.}$$

比如当 $X \in L^p$ 且 $p \geq 1$ 时, 取 $\varphi(x) = |x|^p$, 就有 $|\mathbb{E}[X | \mathcal{G}]|^p \leq \mathbb{E}[|X|^p | \mathcal{G}]$. 再取一次普通期望便得到 $\|\mathbb{E}[X | \mathcal{G}]\|_p \leq \|X\|_p$. 所以条件期望在 L^p 中也是一种不会放大随机变量的压缩.

条件概率本身也可以重新包含进条件期望. 对于事件 $A \in \mathcal{F}$, 定义

$$\mathbb{P}(A | \mathcal{G}) := \mathbb{E}[\mathbf{1}_A | \mathcal{G}].$$

于是 $\mathbb{P}(A) = \mathbb{E}[\mathbf{1}_A]$ 和 $\mathbb{P}(A | \mathcal{G}) = \mathbb{E}[\mathbf{1}_A | \mathcal{G}]$ 正好完全平行. 类似地, 对于随机变量 Y , 我们通常把 $\mathbb{E}[X | \sigma(Y)]$ 简写成 $\mathbb{E}[X | Y]$; 因此所谓“给定 Y ”, 指的是给定 Y 所生成的信息 $\sigma(Y)$.

独立性, 条件概率和条件期望可以统一放在信息视角下理解:

- 独立表示获得这部分信息以后无需更新;
- 条件概率描述获得信息以后如何更新事件发生的概率;
- 条件期望则描述获得信息以后如何更新对于随机变量平均值的判断.

最后, 当 $X \in L^2(\Omega, \mathbb{P})$ 时, 条件期望还有一个很漂亮的几何解释. 所有 $\mathcal{G}$ -可测的平方可积随机变量组成闭子空间 $L^2(\Omega, \mathcal{G}, \mathbb{P})$, 而 $\mathbb{E}[X | \mathcal{G}]$ 恰好就是 X 向这个闭子空间的正交投影. 因此在所有只能使用 $\mathcal{G}$ 中信息构造出来的平方可积随机变量 Y 中, $\mathbb{E}[X | \mathcal{G}]$ 使 $\|X - Y\|_2$ 最小.

所以到了 L^2 中, 我们才可以很准确地说: 条件期望是在只允许使用信息 $\mathcal{G}$ 的情况下, 对于 X 的最佳均方预测. 普通期望 $\mathbb{E}[X]$ 无非是把允许使用的信息进一步缩小到常数函数以后得到的特殊情况.

到了随机过程里面, 随着时间增加的信息会被一条滤链 $(\mathcal{F}_t)_{t \in T}$ 记录下来. 因而 $\mathbb{E}[X_{t+s} | \mathcal{F}_t]$ 表示的就是在已经知道截至时刻 t 的全部信息以后, 对未来随机变量 X_{t+s} 作出的条件平均预测. 后面的马尔可夫过程和鞅都会不断回到这个观点.

3.4.3 正则条件分布

条件期望给出已知信息下的条件平均值, 许多问题还需要整个条件分布.

比如 $\mathbb{E}[S_{t+1} | \mathcal{F}_t]$ 只给出当前信息下下一时刻股票价格的平均值; 若还要知道上涨 10% 的概率, 跌破某个价格的概率或整个未来价格的分布, 就需要正则条件分布.

定义 3.48.

令 $X: (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{E})$ 为随机元素, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数. X 关于 $\mathcal{G}$ 的正则条件分布是指一个从 $(\Omega, \mathcal{G})$ 到 $(E, \mathcal{E})$ 的 Markov 核

$$K: \Omega \times \mathcal{E} \rightarrow [0, 1],$$

使得对于任意 $A \in \mathcal{E}$, $K(\cdot, A)$ 是 $\mathbb{P}(X \in A | \mathcal{G})$ 的一个版本.

所谓 Markov 核就是一种积分核:

- 固定 ω 时, $A \mapsto K(\omega, A)$ 是 $(E, \mathcal{E})$ 上的概率测度;
- 固定 A 时, $\omega \mapsto K(\omega, A)$ 则是 $\mathcal{G}$ -可测函数.

因此我们可以把 $K(\omega, dx)$ 理解成在当前信息状态 ω 下对于 X 得到的一整个概率分布.

条件期望可以重新从这个分布中积分出来. 对于合适的可测函数 f ,

$$\mathbb{E}[f(X) | \mathcal{G}](\omega) = \int_E f(x) K(\omega, dx) \quad \text{a.s.}$$

所以条件期望只是条件分布的一个积分结果, 而正则条件分布保存的是给定 $\mathcal{G}$ 以后关于 X 的整个概率规律.

特别地, 如果 $Y: \Omega \rightarrow (S, \mathcal{S})$, 那么“给定 Y ”指给定 $\sigma(Y)$. 在合适的条件下, 可以找到 Markov 核 $K: S \times \mathcal{E} \rightarrow [0, 1]$, 使得 $\mathbb{P}(X \in A | Y) = K(Y, A)$ a.s. 于是通常会简写成

$$K(y, A) = \mathbb{P}(X \in A | Y = y).$$

因此即使连续随机变量满足 $\mathbb{P}(Y = y) = 0$, 仍然可以讨论“给定 $Y = y$ 时 X 的分布”. 正则条件分布通常只在 μ_Y -几乎处处 (almost everywhere, a.e.) 的 y 上唯一. 对于满足 $\mu_Y(\{y\}) = 0$ 的具体 y , 若没有额外的连续性或其他结构, $K(y, \cdot)$ 未必有唯一的标准取法.

定理 3.49 (标准 Borel 值域中的正则条件分布).

若 $(E, \mathcal{E})$ 是标准 Borel 空间, 则对任意子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$, X 关于 $\mathcal{G}$ 的正则条件分布存在. 若 Y 还取值于标准 Borel 空间 $(S, \mathcal{S})$, 则可取一个 Markov 核 $K: S \times \mathcal{E} \rightarrow [0, 1]$, 使

$$\mathbb{P}(X \in A | \sigma(Y)) = K(Y, A) \quad \text{a.s.}$$

对每个 $A \in \mathcal{E}$ 成立. 该核只在 $\mathcal{L}(Y)$ -a.e. 的 y 上唯一.

这里的难点在于, 必须在一个共同零集之外让 $A \mapsto K(\omega, A)$ 同时成为概率测度. 逐个 A 选取条件期望版本并不足以保证这一点. 标准 Borel 空间的可数生成结构和测度分解 (disintegration) 完成了这一步. 完整结果见 [Kal21, Theorem 8.5, Theorem 3.4] 或 [Dur19, Theorems 4.1.17–4.1.18].

如果 (X, Y) 进一步具有联合密度, 那么熟悉的条件密度就是它的特殊情形:

$$f_{X|Y=y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad f_Y(y) > 0.$$

初等概率论中的“条件密度”是正则条件分布在具有密度时的一种表示, 无须另立概念.

正则条件分布在随机过程中尤其自然. 对于 $s < t$, 单个平均数 $\mathbb{E}[X_t | \mathcal{F}_s]$ 往往不够; 我们还会关心未来状态在当前全部信息下的整个条件分布 $\mathbb{P}(X_t \in A | \mathcal{F}_s)$.

马尔可夫过程的特殊之处在于: 这个原本依赖全部过去信息的条件分布, 只由当前状态 X_s 决定. 因此存在转移核 $P_{s,t}$, 使得

$$\mathbb{P}(X_t \in A | \mathcal{F}_s) = P_{s,t}(X_s, A) \quad \text{a.s.}$$

“未来只依赖现在”这句常见的口号, 准确含义是: 给定全部过去得到的未来正则条件分布, 只依赖于当前状态.

3.5 随机变量的收敛与极限定理

3.5.1 收敛概念

从前推测度到随机变量的收敛 第3.2.1小节已经把随机变量的分布定义为它诱导的前推概率测度, 并记作 $\mathcal{L}(X) = X_*\mathbb{P}$. 因此当我们有一列随机变量 $X_1, X_2, \dots$, 并希望讨论收敛过程 $(X_n \rightarrow X)$ 时, 一个很自然的想法就是研究这些随机变量所诱导的前推测度怎样变化.

这里先约定一个小记号: 当我们把“收敛”本身当作一个过程或者命题来讨论时, 会把箭头连同两端对象一起放在括号中, 例如 $(X_n \rightarrow X)$. 括号不表示额外结构, 只是强调我们现在讨论的是整个收敛过程.

这里先回答“随机变量究竟以什么意义收敛”, 再讨论这些收敛经过连续函数和常见代数运算以后怎样变化, 最后用大数定律和中心极限定理说明样本平均会收敛到哪里, 以及它在什么尺度上继续保留随机波动.

概率测度的弱收敛 我们先暂时忘掉随机变量, 直接考虑一列 $\mathbb{R}$ 上的概率测度 μ_n 和另一个概率测度 μ .

“弱收敛”沿用了分析学中的相近思想. 在拓扑空间中, 连续函数可以看成探测空间结构的自然观测; 在泛函分析中, Banach 空间里的弱收敛也是类似的思想: 它要求所有连续线性泛函作用后的数值收敛, 条件弱于范数意义下的强收敛.

概率测度的情形与此类似. 每个概率测度 μ 都给出一个作用在有界连续函数上的线性泛函

$$f \mapsto \int_{\mathbb{R}} f d\mu.$$

于是比较概率测度时, 可以考察这些测度对连续观测 f 给出的积分, 无须逐一比较所有集合上的取值. 这给出了概率测度弱收敛的基本想法.

一个直接但过强的要求是 $\mu_n(A) \rightarrow \mu(A)$ 对所有 Borel 集 A 都成立. 一个非常小的位置移动, 就可能使某些集合上的概率突然发生变化. 因此概率论中通常改用连续函数来观察这些测度.

定义 3.50.

设 μ_n, μ 为 $\mathbb{R}$ 上的概率测度. 如果对于任意有界连续函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 都有

$$\int_{\mathbb{R}} f d\mu_n \rightarrow \int_{\mathbb{R}} f d\mu,$$

则称 μ_n 弱收敛到 μ , 记作 $(\mu_n \Rightarrow \mu)$.

这个定义可以理解成: 如果所有有界连续观测的期望都渐近地无法区分 μ_n 和 μ , 那么在当前拓扑允许的连续观测下, 这两个概率测度已经越来越接近. 这里的“弱”与 L^p 空间中随机变量等价类的弱收敛精神相近, 两者对象不同: 这里讨论的是概率测度在连续测试函数下的收敛.

弱收敛虽然不保证所有 Borel 集上的概率都收敛, 但只要集合的边界不承载极限测度的质量, 就仍然可以得到集合概率的收敛.

定理 3.51 (Portmanteau 定理的一些形式).

对 $\mathbb{R}$ 上的概率测度 μ_n, μ , 以下条件等价:

1. $(\mu_n \Rightarrow \mu)$;
2. 对任意开集 G , 有 $\liminf_n \mu_n(G) \geq \mu(G)$;
3. 对任意闭集 F , 有 $\limsup_n \mu_n(F) \leq \mu(F)$;
4. 对任意满足 $\mu(\partial A) = 0$ 的 Borel 集 A , 有 $\mu_n(A) \rightarrow \mu(A)$.

证明中最有用的一步是从有界连续函数转向闭集. 对闭集 F 可取

$$f_m(x) = \max\{1 - m d(x, F), 0\},$$

则 $\mathbf{1}_F \leq f_m \leq 1$ 且 $f_m \downarrow \mathbf{1}_F$. 弱收敛与控制收敛因此给出

$$\limsup_n \mu_n(F) \leq \lim_m \int f_m d\mu = \mu(F).$$

开集结论由取补集得到; 若 $\mu(\partial A) = 0$, 对 $A^\circ \subseteq A \subseteq \bar{A}$ 同时使用开集与闭集不等式便得到概率收敛. 从这些集合不等式回到一般有界连续测试函数需要对函数层集积分, 完整等价证明见 [Kal21, Theorem 5.25] 或 [Dur19, Theorem 3.2.11].

满足 $\mu(\partial A) = 0$ 的集合称为 μ 的**连续集** (continuity set).

例 3.52.

令 $\mu_n = \delta_{1/n}$, $\mu = \delta_0$. 由 $1/n \rightarrow 0$ 可得 $(\mu_n \Rightarrow \mu)$, 但是对于 $A = \{0\}$, 始终有 $\mu_n(A) = 0$, 而 $\mu(A) = 1$.

这里没有任何矛盾, 因为 $\partial A = \{0\}$, 从而 $\mu(\partial A) = 1$. 所以 $\{0\}$ 并不是 μ 的连续集.

这也解释了为什么在实数上利用分布函数描述弱收敛时, 只要求在极限分布函数的连续点上收敛. 如果 $F_n(x) = \mu_n((-\infty, x])$, $F(x) = \mu((-\infty, x])$, 那么 $(\mu_n \Rightarrow \mu)$ 当且仅当对于 F 的每一个连续点 x , 都有 $F_n(x) \rightarrow F(x)$.

依分布收敛 现在重新回到随机变量. 因为依分布收敛只比较随机变量各自的分布, 所以这些随机变量甚至不需要定义在同一个概率空间上.

定义 3.53.

设

$$X_n: (\Omega_n, \mathcal{F}_n) \rightarrow \mathbb{R}, \quad X: (\Omega, \mathcal{F}) \rightarrow \mathbb{R},$$

并分别在这些空间上给定概率测度 $\mathbb{P}_n$ 和 $\mathbb{P}$. 如果 $(\mathcal{L}(X_n) \Rightarrow \mathcal{L}(X))$, 则称 X_n **依分布收敛** 到 X , 记作 $(X_n \xrightarrow{d} X)$.

依分布收敛就是随机变量所诱导的前推概率测度的弱收敛. 它只保留分布, 不记录随机变量在共同概率空间中如何对应.

例 3.54.

设 $X \sim \mathcal{N}(0, 1)$. 如果直接令 $X_n = X$, 那么每一个样本上 X_n 都和 X 完全相同.

但我们也可以令 $X, X_1, X_2, \dots$ 相互独立, 并且全部服从 $\mathcal{N}(0, 1)$. 此时对于所有 n 仍然有 $\mathcal{L}(X_n) = \mathcal{L}(X)$, 所以 $(X_n \xrightarrow{d} X)$.

然而这时 $X_n - X \sim \mathcal{N}(0, 2)$, 因此对于任意固定的 $\varepsilon > 0$, $\mathbb{P}(|X_n - X| > \varepsilon)$ 始终是同一个严格正的常数, 并不会趋于 0. 所以这一实现中 X_n 甚至不依概率收敛到 X .

各自的分布无法决定给定联合实现下两个随机变量之间的误差.

依概率收敛 从这里开始, 除非另有说明, 我们都假设 X_n 和 X 定义在同一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上.

定义 3.55.

如果对于任意 $\varepsilon > 0$ 都有

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0,$$

则称 X_n **依概率收敛** 到 X , 记作 $(X_n \xrightarrow{\mathbb{P}} X)$.

依概率收敛的意思就是: 当 n 越来越大时, X_n 与 X 出现明显误差的概率越来越小.

这里还会用到一个非常常见的特殊情况.

命题 3.56.

对任意常数 c , 有

$$(X_n \xrightarrow{d} c) \iff (X_n \xrightarrow{\mathbb{P}} c).$$

所以虽然一般来说依分布收敛比依概率收敛弱, 但当极限退化成一个确定常数时, 两者恰好重合.

这里已经不能只看 $\mathcal{L}(X_n)$ 和 $\mathcal{L}(X)$, 因为 $X_n - X$ 依赖于两个随机变量之间的联合关系. 当前概率空间给出了联合分布 $\mathcal{L}(X_n, X) = (X_n, X)_*\mathbb{P}$; 再通过映射 $(x, y) \mapsto |x - y|$ 前推, 就得到误差 $|X_n - X|$ 的分布.

把上面的命题用于误差变量 $|X_n - X|$, 就得到

$$(X_n \xrightarrow{\mathbb{P}} X) \iff (\mathcal{L}(|X_n - X|) \Rightarrow \delta_0).$$

依概率收敛描述误差的概率质量逐渐集中到 0.

L^p 收敛 依概率收敛只要求大误差发生的概率越来越小, 却不太在意那些极少发生的误差究竟有多大. 如果我们还想控制误差本身的大小, 就会自然回到前面已经学习过的 L^p 空间. 对于 $1 \leq p < \infty$, 若 $X_n, X \in L^p(\Omega, \mathcal{F}, \mathbb{P})$ 且

$$\mathbb{E}|X_n - X|^p \rightarrow 0,$$

则称 X_n 在 L^p 中收敛到 X , 记作 $(X_n \xrightarrow{L^p} X)$.

因为 $\|X_n - X\|_{L^p} = (\mathbb{E}|X_n - X|^p)^{1/p}$, 所以这就是 L^p 空间本身的范数收敛. 特别地, $p = 2$ 时称为均方收敛. 这种收敛在随机过程中尤其常见, 因为 L^2 是 Hilbert 空间.

$p = \infty$ 时也可以讨论 L^∞ 范数收敛, 它对应本质上一致意义下的误差趋于 0. 为了和“有限 p 阶矩”的语言保持一致, 下面主要讨论 $1 \leq p < \infty$ 的情形.

借助前推测度下的积分公式, 也可以把 L^p 收敛理解为: 误差分布不仅要向 0 集中, 其 p 阶尾部也要同时受到控制.

命题 3.57.

如果 $(X_n \xrightarrow{L^p} X)$, 那么 $(X_n \xrightarrow{\mathbb{P}} X)$.

证明. 对任意 $\varepsilon > 0$, 根据 Markov 不等式,

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}|X_n - X|^p}{\varepsilon^p} \rightarrow 0.$$

□

几乎必然收敛 依概率收敛每次固定一个 n , 看第 n 个误差事件有多大. 但我们还可以固定一个样本 ω , 然后观察整条数列 $X_1(\omega), X_2(\omega), \dots$ 最终是否真的收敛.

定义 3.58.

如果

$$\mathbb{P}(\{\omega : (X_n(\omega) \rightarrow X(\omega))\}) = 1,$$

则称 X_n 几乎必然收敛到 X , 记作 $(X_n \xrightarrow{\text{a.s.}} X)$.

如果还想用前推测度的语言来理解它, 那么这一次不能只保留某一个 X_n , 甚至不能只保留一对 (X_n, X) , 而要把整个随机序列一起保留下来.

考虑

$$\mathbf{X}(\omega) = ((X_k(\omega))_{k \geq 1}, X(\omega)) \in \mathbb{R}^{\mathbb{N}} \times \mathbb{R}.$$

在乘积 σ -代数下这是一个可测映射. 如果记

$$C = \{((x_k)_{k \geq 1}, x) : (x_k \rightarrow x)\},$$

它可以写成

$$C = \bigcap_{m=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{k \geq N} \left\{ ((x_j)_{j \geq 1}, x) : |x_k - x| < \frac{1}{m} \right\},$$

所以 C 是乘积空间中的 Borel 集. 那么

$$(X_n \xrightarrow{\text{a.s.}} X) \iff \mathcal{L}(\mathbf{X})(C) = 1.$$

所以几乎必然收敛仍可写成前推测度的性质, 此时前推的对象是整条随机序列. 这已经很接近后面随机过程中的路径分布.

几种收敛方式之间的关系 现在可以把前面的结果放在一起. 最基本的关系是

$$(X_n \xrightarrow{\text{a.s.}} X) \implies (X_n \xrightarrow{\mathbb{P}} X) \implies (X_n \xrightarrow{d} X), \quad (X_n \xrightarrow{L^p} X) \implies (X_n \xrightarrow{\mathbb{P}} X).$$

此外, 在概率空间上如果 $p > q \geq 1$, 那么由不同 L^p 空间之间的包含关系可知

$$(X_n \xrightarrow{L^p} X) \implies (X_n \xrightarrow{L^q} X).$$

这些箭头一般不能直接反向成立. 依概率收敛仍然能够抽出几乎必然收敛的子列. 这里自然会用到 Borel–Cantelli 引理.

引理 3.59 (Borel–Cantelli).

令 $A_1, A_2, \dots$ 为事件. 如果

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty,$$

那么

$$\mathbb{P}(A_n \text{ i.o.}) = 0.$$

这里 i.o. 是 infinitely often 的缩写, 表示“无穷多次发生”. 概率总和有限的事件几乎必然只会发生有限多次.

注 3.60.

Borel–Cantelli 引理还有一个常见的反向版本: 如果 (A_n) 相互独立并且 $\sum_n \mathbb{P}(A_n) = \infty$, 那么 $\mathbb{P}(A_n \text{ i.o.}) = 1$. 这里的独立性是额外条件, 不能省略.

定理 3.61.

如果 $(X_n \xrightarrow{\mathbb{P}} X)$, 那么存在一个子列 $(X_{n_k})_{k \geq 1}$, 使得 $(X_{n_k} \xrightarrow{\text{a.s.}} X)$.

证明. 由 $(X_n \xrightarrow{\mathbb{P}} X)$, 可以递归选取子列 (X_{n_k}) , 使得

$$\mathbb{P}(|X_{n_k} - X| > 2^{-k}) < 2^{-k}.$$

令 $A_k = \{|X_{n_k} - X| > 2^{-k}\}$. 则 $\sum_k \mathbb{P}(A_k) < \infty$, 因而由 Borel–Cantelli 引理可知, 几乎必然只有有限多个 A_k 发生. 因而 $(X_{n_k} \xrightarrow{\text{a.s.}} X)$. $\square$

还可以进一步证明: $(X_n \xrightarrow{\mathbb{P}} X)$ 当且仅当每一个子列都存在进一步子列几乎必然收敛到 X . 另外, L^p 收敛和几乎必然收敛之间一般不存在包含关系.

例 3.62.

固定 $p \geq 1$, 在 $(0, 1)$ 上定义

$$X_n = n^{1/p} \mathbf{1}_{(0, 1/n)}.$$

对任意固定的 $\omega > 0$, 当 n 足够大时都有 $X_n(\omega) = 0$, 所以 $(X_n \xrightarrow{\text{a.s.}} 0)$. 但是

$$\mathbb{E}|X_n|^p = n \cdot \frac{1}{n} = 1,$$

因而 X_n 并不在 L^p 中收敛到 0.

这与 Lebesgue 积分中见过的尖峰现象相同: 虽然每一点最终都趋于 0, 但越来越高的尖峰同时被压缩到越来越小的区域里, 使得 p 阶矩没有消失.

反方向也不成立.

例 3.63 (打字机序列).

在 $[0, 1)$ 上取 Lebesgue 概率测度. 对于 $n = 2^m + k$, 其中 $m \geq 0$ 和 $0 \leq k < 2^m$ 均为整数, 定义

$$X_n = \mathbf{1}_{[k/2^m, (k+1)/2^m)}.$$

对任意 $p \geq 1$, 都有 $\mathbb{E}|X_n|^p = 2^{-m} \rightarrow 0$, 所以 $(X_n \xrightarrow{L^p} 0)$.

但是对于每一个固定的 $\omega \in [0, 1)$, 在每一个层级 m 中都会恰好有一个 $X_n(\omega) = 1$, 同时其余很多项等于 0. 所以 $X_n(\omega)$ 会无穷多次取到 1 和 0, 并不收敛.

一个常用充分条件来自控制收敛定理: 如果除了 $(X_n \xrightarrow{\text{a.s.}} X)$ 以外, 还存在某个 $Y \in L^1$ 使得 $|X_n - X|^p \leq Y$ 几乎处处成立, 那么 $\mathbb{E}|X_n - X|^p \rightarrow 0$, 也就是 $(X_n \xrightarrow{L^p} X)$.

更一般地, 如果 (X_n) 一致可积 (uniformly integrable) 且 $(X_n \xrightarrow{\mathbb{P}} X)$, 那么 Vitali 定理给出 $\mathbb{E}|X_n - X| \rightarrow 0$; 对一般的 L^p 收敛, 可以对误差族 $\{|X_n - X|^p\}$ 要求一致可积.

可以把这几种收敛暂时整理成下面这张表:

收敛方式	是否需要共同概率空间	控制的对象	典型记号	基本推出关系
依分布收敛	不需要	各自分布	$(X_n \xrightarrow{d} X)$	通常推出链中位置最弱
依概率收敛	需要	给定耦合下的误差概率	$(X_n \xrightarrow{\mathbb{P}} X)$	推出依分布
L^p 收敛	需要	给定耦合下误差的 p 阶矩	$(X_n \xrightarrow{L^p} X)$	推出依概率
几乎必然收敛	需要	几乎每条样本路径的尾部行为	$(X_n \xrightarrow{\text{a.s.}} X)$	推出依概率

这里的“最弱”只是在通常推出关系中的位置. 依分布收敛仍然可以在某些问题里保留最关键的信息, 比如中心极限定理描述的首先就是分布极限.

3.5.2 极限定理

连续映射定理与 Slutsky 定理 定义各种收敛以后, 还需要知道这些极限经过常见运算以后会发生什么.

定理 3.64 (连续映射定理).

如果 $(X_n \xrightarrow{d} X)$, 并且 $g: \mathbb{R} \rightarrow \mathbb{R}$ 连续, 那么

$$(g(X_n) \xrightarrow{d} g(X)).$$

该结论是弱收敛在几乎处处连续映射下的稳定性; 一般版本与证明见 [Kal21, Theorem 5.27].

类似地, 如果 $(X_n \xrightarrow{\mathbb{P}} X)$, 那么也有 $(g(X_n) \xrightarrow{\mathbb{P}} g(X))$. 更一般地, 依分布收敛时并不真的要求 g 处处连续; 只要 g 是 Borel 可测映射, 且其不连续点集合 D_g 满足 $\mathbb{P}(X \in D_g) = 0$, 仍然有 $(g(X_n) \xrightarrow{d} g(X))$.

定理 3.65 (Slutsky 定理).

如果 $(X_n \xrightarrow{d} X)$, $(Y_n \xrightarrow{\mathbb{P}} c)$, 其中 c 为常数, 那么

$$(X_n + Y_n \xrightarrow{d} X + c), \quad (X_n Y_n \xrightarrow{d} cX).$$

如果 $c \neq 0$, 并且商 X_n/Y_n 已经定义好 (例如 $\mathbb{P}(Y_n = 0) = 0$, 或者在 $\{Y_n = 0\}$ 上任意定义),

还有 $(X_n/Y_n \xrightarrow{d} X/c)$.

这里并不要求 X_n 和 Y_n 独立.

证明先把 (X_n, Y_n) 的联合分布与 (X, c) 联系起来, 再把连续映射定理用于 $(x, y) \mapsto x + y, xy$ 和 x/y . 这些组成步骤见 [Dur19, Exercises 3.2.12–3.2.14]; 其中连续映射以及取倒数所需的映射步骤使用 [Dur19, Theorem 3.2.10].

这些结果以后在统计估计中会反复出现. 例如一个极限定理中如果含有未知参数 σ , 而我们能够构造相合估计量 $(\hat{\sigma}_n \xrightarrow{\mathbb{P}} \sigma)$, 那么 Slutsky 定理通常允许我们在标准化分母中把 σ 换成 $\hat{\sigma}_n$, 而不会改变最终的极限分布.

大数定律 前面的内容解决了“随机变量到底以什么意义收敛”. 接下来就可以研究概率论中最经典的问题之一: 如果不断重复同一种随机实验, 样本平均最后会发生什么?

设 $X_1, X_2, \dots$ 独立同分布, 并定义

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

如果 $\mathbb{E}[X_1] = \mu$, 直觉上大量随机波动相互平均后, $\bar{X}_n$ 应越来越靠近 μ . 大数定律精确表达了这一点.

定理 3.66 (弱大数定律, 有限方差版本).

设 $X_1, X_2, \dots$ 独立同分布, 并满足 $\mathbb{E}[X_1] = \mu, \text{Var}(X_1) = \sigma^2 < \infty$. 那么

$$(\bar{X}_n \xrightarrow{\mathbb{P}} \mu).$$

在当前假设下可以直接得到更强的 L^2 收敛. 因为独立性给出 $\text{Var}(\bar{X}_n) = \sigma^2/n$, 而 $\mathbb{E}[\bar{X}_n] = \mu$, 所以

$$\|\bar{X}_n - \mu\|_{L^2}^2 = \mathbb{E}|\bar{X}_n - \mu|^2 = \frac{\sigma^2}{n} \rightarrow 0.$$

因此 $(\bar{X}_n \xrightarrow{L^2} \mu)$, 再利用 L^2 收敛推出依概率收敛, 就得到上面的弱大数定律.

注 3.67.

这里给出便于利用方差计算证明的版本, 弱大数定律还有更一般的形式. 对独立同分布随机变量而言, 只要 $\mathbb{E}|X_1| < \infty$, 弱大数定律同样成立.

下面的强大数定律结论更强, 假设看起来却更弱. 原因在于上面的弱大数定律采用了一个便于直接证明但条件更强的版本.

定理 3.68 (强大数定律).

设 $X_1, X_2, \dots$ 独立同分布, 并且 $\mathbb{E}|X_1| < \infty$. 那么

$$(\bar{X}_n \xrightarrow{\text{a.s.}} \mathbb{E}[X_1]).$$

有限一阶矩版本的证明不能只靠方差计算. 标准路线先截断异常大的 X_k , 用 Borel–Cantelli 引理证明截断只改变有限多项, 再对中心化截断变量使用级数收敛与 Kronecker 引理, 最后用控制收敛处理截断均值. 完整证明见 [Kal21, Theorem 5.23] 或 [Dur19, Theorem 2.4.1].

对于几乎每一条无限长的样本序列, 其经验平均最终都会趋向理论期望.

例 3.69.

假设不断独立重复同一种实验. 令 A_k 表示第 k 次实验中某个事件发生, 并假设 $\mathbb{P}(A_k) = p$. 定义 $X_k = \mathbf{1}_{A_k}$, 那么 X_k 独立同分布, 且 $\mathbb{E}[X_k] = p$.

此时

$$\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k}$$

正是这个事件在前 n 次实验中出现的经验频率. 强大数定律给出

$$\left(\frac{1}{n} \sum_{k=1}^n \mathbf{1}_{A_k} \xrightarrow{\text{a.s.}} p \right).$$

在独立同分布重复实验的框架下, 大数定律建立了经验频率和理论概率之间的数学联系. 这种联系不要求用长期频率定义概率; 它说明该模型中的长期经验频率几乎必然趋向概率.

中心极限定理 大数定律告诉我们 $(\bar{X}_n \xrightarrow{\mathbb{P}} \mu)$, 在强大数定律的条件下甚至有 $(\bar{X}_n \xrightarrow{\text{a.s.}} \mu)$, 但还没有告诉我们样本平均究竟以怎样的尺度围绕 μ 波动.

如果 $\text{Var}(X_1) = \sigma^2 < \infty$, 那么 $\text{Var}(\bar{X}_n) = \sigma^2/n$, 所以 $\text{Std}(\bar{X}_n) = \sigma/\sqrt{n}$. 样本平均的典型误差具有 $1/\sqrt{n}$ 尺度, 比 $1/n$ 慢.

因此如果直接看 $\bar{X}_n - \mu$, 它会逐渐缩到 0; 但如果同时把它放大 $\sqrt{n}$ 倍, 就有可能留下一个不会退化成常数的极限分布.

定理 3.70 (Lindeberg-Lévy 中心极限定理).

设 $X_1, X_2, \dots$ 独立同分布, 并满足 $\mathbb{E}[X_1] = \mu$, $0 < \text{Var}(X_1) = \sigma^2 < \infty$. 令 $Z \sim \mathcal{N}(0, 1)$, 那么

$$\left(\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} Z \right).$$

其证明把标准化和的特征函数写成单个特征函数的 n 次幂. 有限二阶矩给出零点附近的二阶展开, 于是该幂趋向 $\exp(-t^2/2)$; Lévy 连续性定理再把特征函数收敛转换成依分布收敛. 由于这一依赖链超出本节已经建立的工具, 完整证明参见 [Kal21, Theorem 6.10] 或 [Dur19, Theorem 3.4.1].

所以大数定律和中心极限定理回答的是两个不同的问题. 大数定律告诉我们样本平均最终会走向哪里, 答案是 μ ; 中心极限定理则进一步描述在 $1/\sqrt{n}$ 的尺度上, 样本平均围绕 μ 还剩下怎样的随机波动, 答案是正态极限.

更具体地说, 如果记 Φ 为标准正态分布函数, 那么中心极限定理说的是

$$\mathbb{P} \left(\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \leq x \right) \rightarrow \Phi(x)$$

在每一个 $x \in \mathbb{R}$ 上成立.

因此当 n 很大时, 在分布近似的意义下可以写成

$$\mathcal{L}(\bar{X}_n) \approx \mathcal{N} \left(\mu, \frac{\sigma^2}{n} \right).$$

这里应避免把渐近分布误读成逐样本近似. 中心极限定理首先给出对应前推测度的弱极限. 它没有自动在原概率空间上构造出某个 $Z \sim \mathcal{N}(0, 1)$, 使得 $\bar{X}_n - \mu$ 在逐样本或 L^p 意义下接近 $\sigma Z/\sqrt{n}$. 而且有限方差版本的中心极限定理本身并不给出有限样本误差率; 如果需要 Berry-Esseen 型的 $n^{-1/2}$ 误差界, 还要额外加入有限三阶绝对矩等条件.

例 3.71.

设 $0 < p < 1$, $X_k \sim \text{Bernoulli}(p)$ 独立同分布, 并令 $S_n = X_1 + \dots + X_n$. 那么 $S_n \sim \text{Bin}(n, p)$, 且 $\mathbb{E}[X_k] = p$, $\text{Var}(X_k) = p(1-p)$.

强大数定律告诉我们 $(S_n/n \xrightarrow{\text{a.s.}} p)$. 若 $Z \sim \mathcal{N}(0, 1)$, 中心极限定理进一步给出

$$\left(\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} Z \right).$$

因此当 n 足够大时, 二项分布可以在适当区域内利用正态分布近似.

例 3.72 (Monte Carlo 定价).

在选定风险中性定价测度 $\mathbb{Q}$ 的模型中, 假设某个衍生品的贴现到期支付可以写成 $\mathbb{Q}$ -可积随机变量 H . 这个模型及所选定价测度下的价格为

$$V = \mathbb{E}_{\mathbb{Q}}[H].$$

如果我们在 $\mathbb{Q}$ 下模拟 H 的独立同分布副本 $H^{(1)}, \dots, H^{(n)}$, 并用

$$\hat{V}_n = \frac{1}{n} \sum_{i=1}^n H^{(i)}$$

估计 V , 那么大数定律给出 $(\hat{V}_n \xrightarrow{\text{a.s.}} V)$.

如果进一步有 $0 < \text{Var}_{\mathbb{Q}}(H) = \sigma^2 < \infty$, 若 $Z \sim \mathcal{N}(0, 1)$, 中心极限定理给出

$$\left(\frac{\sqrt{n}(\hat{V}_n - V)}{\sigma} \xrightarrow{d} Z \right).$$

实际计算中 σ 通常未知, 于是会使用样本标准差 $\hat{\sigma}_n$. 只要 $(\hat{\sigma}_n \xrightarrow{\mathbb{P}} \sigma)$, Slutsky 定理就允许我们写成

$$\left(\frac{\sqrt{n}(\hat{V}_n - V)}{\hat{\sigma}_n} \xrightarrow{d} Z \right).$$

所以 Monte Carlo 定价里常说的标准误差具有 $1/\sqrt{n}$ 尺度, 它来自大数定律, 中心极限定理和 Slutsky 定理的共同作用.

注 3.73.

中心极限定理不能解释为现实中的随机变量天然服从正态分布. 这里陈述的 Lindeberg-Lévy 版本依赖独立性, 同分布和有限方差等条件, 而真实金融市场中的收益率往往具有时间依赖, 波动率聚集, 厚尾, 跳跃和状态切换等结构.

即使某一种中心极限定理能够用于聚合收益率, 它首先描述的也是适当尺度下的典型渐进波动, 并不会自动保证极端尾部也能被正态分布准确描述. 极端风险通常还需要另外研究厚尾, 大偏差或者极值行为.

3.5.3 通向随机过程的补充

进阶补充: 耦合与 Wasserstein 距离 前面已经反复遇到同一个问题: 两个随机变量各自的分布并不能决定它们之间的误差, 因为还必须知道它们怎样被联合实现. 这一节可以先看作一个可选进阶, 目的只是统一“分布接近”和“给定耦合下误差接近”这两种视角; 最优传输和 Wasserstein 距离的系统背景可参考 [Vil09].

定义 3.74.

设 μ, ν 为 $\mathbb{R}$ 上的概率测度. 如果 π 是 $\mathbb{R}^2$ 上的概率测度, 并且它的两个边缘分布分别为 μ 和 ν , 则称 π 为 μ 和 ν 的一个耦合. 所有这样的耦合构成的集合记作 $\Pi(\mu, \nu)$.

如果 X 和 Y 已经定义在同一个概率空间上, 那么它们的联合分布 $\mathcal{L}(X, Y)$ 自然就是 $\mathcal{L}(X)$ 和 $\mathcal{L}(Y)$ 的一个耦合, 但通常还有其他耦合.

Wasserstein 距离做的事情就是允许我们在所有耦合中寻找运输成本最小的一个.

定义 3.75.

设 $p \geq 1$, 并记

$$\text{Prob}_p(\mathbb{R}) = \left\{ \mu \mid \mu \text{ 是 } \mathbb{R} \text{ 上的 Borel 概率测度, } \int_{\mathbb{R}} |x|^p d\mu(x) < \infty \right\}.$$

对于 $\mu, \nu \in \text{Prob}_p(\mathbb{R})$, 定义

$$W_p(\mu, \nu) = \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathbb{R}^2} |x - y|^p d\pi(x, y) \right)^{1/p}.$$

可以把 μ 想成原来的质量分布, ν 想成目标质量分布, 而 π 描述质量从哪里搬到哪里. Wasserstein 距离就是所有合法搬运方案中最小的 p 阶运输成本.

如果 $X, Y \in L^p$ 已经定义在同一个概率空间上, 当前概率空间给出的联合分布 $\mathcal{L}(X, Y)$ 只是所有可能耦合中的一个, 所以立刻得到

$$W_p(\mathcal{L}(X), \mathcal{L}(Y)) \leq \|X - Y\|_{L^p}.$$

需要特别注意的是, 这个不等式一般不能反过来理解. 即使

$$W_p(\mathcal{L}(X_n), \mathcal{L}(X)) \rightarrow 0,$$

也不一定有当前这个给定耦合下的 $\|X_n - X\|_{L^p} \rightarrow 0$. 前面独立正态随机变量的例子就是极端情况: 边缘分布完全相同, 但给定耦合下的误差并不趋于 0.

如果当前这个耦合恰好就是最优耦合, 那么可以取得等号. 有一种情况等号一定自动成立: 其中一个分布是 Dirac 测度.

命题 3.76.

设 $Z \in L^p$, $c \in \mathbb{R}$. 那么

$$W_p(\mathcal{L}(Z), \delta_c) = \|Z - c\|_{L^p}.$$

这是因为 δ_c 的全部质量都集中在 c , 所以 $\mathcal{L}(Z)$ 和 δ_c 之间只有一个可能的耦合, 即 $\mathcal{L}(Z) \otimes \delta_c$. 因而

$$W_p^p(\mathcal{L}(Z), \delta_c) = \int |x - c|^p d\mathcal{L}(Z)(x) = \mathbb{E}|Z - c|^p.$$

特别地, 取 $Z = X_n - X$ 和 $c = 0$, 就得到

$$(X_n \xrightarrow{L^p} X) \iff W_p(\mathcal{L}(X_n - X), \delta_0) \rightarrow 0.$$

Wasserstein 距离在 $\text{Prob}_p(\mathbb{R})$ 上满足距离公理, 其作用不限于改写 L^p 范数.

定理 3.77.

设 $\mu_n, \mu \in \text{Prob}_p(\mathbb{R})$. 那么 $W_p(\mu_n, \mu) \rightarrow 0$ 当且仅当 $(\mu_n \Rightarrow \mu)$, 并且

$$\int_{\mathbb{R}} |x|^p d\mu_n(x) \longrightarrow \int_{\mathbb{R}} |x|^p d\mu(x).$$

所以可以粗略理解成

Wasserstein 收敛 = 弱收敛 + p 阶绝对矩收敛.

这里的 p 阶绝对矩收敛可以直观理解成一种尾部控制: 概率质量不仅要在弱收敛意义下移动到正确位置, 跑到远处的少量质量也不能带来残留的 p 阶成本.

例 3.78.

在 $(0, 1)$ 上定义 $X_n = n\mathbf{1}_{(0, 1/n)}$. 那么

$$\mathcal{L}(X_n) = \left(1 - \frac{1}{n}\right) \delta_0 + \frac{1}{n} \delta_n.$$

远离 0 的概率质量只有 $1/n \rightarrow 0$, 故 $(\mathcal{L}(X_n) \Rightarrow \delta_0)$. 但是

$$W_1(\mathcal{L}(X_n), \delta_0) = \mathbb{E}|X_n| = 1$$

所以这里存在弱收敛, 却不存在 W_1 收敛. 弱收敛只看到那部分质量越来越少, 而 Wasserstein 距离还会计算它已经跑到了多远的位置.

从随机变量到路径空间 到这里, 我们已经从单个随机变量的分布出发, 逐渐遇到了联合分布, 耦合以及整条随机序列的路径结构. 这条线会直接延伸到随机过程.

一个随机过程 $(X_t)_{t \in [0, T]}$ 首先是一族随机变量. 但如果我们希望一次性研究整条样本路径, 就会考虑映射

$$\omega \mapsto (t \mapsto X_t(\omega)).$$

在合适的路径空间并验证相应可测性以后, 一个随机过程就可以被看成取值于函数空间的随机变量. 常见选择包括: 样本路径几乎必然连续的过程, 在选定连续版本后通常放在 $C([0, T])$ 中, 并采用一致拓扑; 具有右连续左极限路径的过程通常放在 $D([0, T])$ 中; 讨论路径空间上的弱收敛时, 还需要同时指定拓扑. 对 $D([0, T])$ 来说, 常见选择是斯科罗霍德 (Skorokhod) J_1 拓扑.

这时随机过程的分布指整个路径空间上的前推概率测度, 包含的信息多于任一固定时刻的 $\mathcal{L}(X_t)$.

从前推测度的角度看, 这一节其实一直在追问同一个问题: **我们究竟把原概率空间上的哪些信息前推到了新的状态空间中?** 如果只前推单个随机变量, 得到的是它的分布; 如果保留两个随机变量的联合分布, 得到的是一个给定耦合; 如果把整个随机序列或者随机过程一起前推, 得到的就是序列空间或者路径空间上的概率测度.

后面进入随机过程以后, 这条主线还会继续发挥作用.

第四章 随机过程基础

前一章研究单个随机变量, 随机变量列以及它们的极限. 从这一章开始, 我们把时间指标加入随机变量, 研究一个随机系统如何随时间演化. 时间一进来, 事情马上变成三件同时发生的事:

每个时刻的随机状态 + 信息随时间的增长 + 整条样本路径的形状.

价格历史, 订单到达和随机游走都可以先按这三件事来读. 这一章参考 [Bil95; Dur19; Kal21; Shr04b; Wil91], 先在离散时间里把信息, 行动时点和随机时刻说清楚, 再进入 Markov 性, 鞅, Poisson 过程和 Brown 运动. 连续时间里较麻烦的可测性结论会放在需要的位置; 随机积分, Itô 公式和随机微分方程留到第五章展开.

4.1 从路径到信息

第一次读这一章, 可以把每个概念都放回一个简单问题: 看见一条路径以后, 怎样描述它的分布, 怎样记录观察者到当前为止知道什么, 怎样保证行动先于结果, 又怎样在当前状态下预测未来. 具体要经过下面几组对象:

1. 在一个固定概率空间上区分随机过程, 样本路径, 有限维分布和过程分布, 并区分修正与不可区分;
2. 用滤过描述“截至当前知道什么”, 判断过程是否适应, 并理解可预测性为什么对应“行动以前已经确定”;
3. 识别停时和停止过程, 知道首次到达时刻为何是动态问题中的基本对象;
4. 用转移核写出 Markov 性和 Chapman–Kolmogorov 方程, 并计算有限状态 Markov 链;
5. 在离散时间中使用鞅, 上鞅, 下鞅, Doob 分解和有条件限制的可选抽样;
6. 考察 Poisson 过程的等待时间, 叠加, 稀疏化和补偿鞅;
7. 考察 Brown 运动的定义, Gauss 增量, 缩放, Markov 性, 鞅性, 反射原理和主要路径性质;
8. 从有限变差与二次变差的差异看出普通微积分为什么需要被随机分析取代.

初次阅读可以沿着下面的路线:




图 4.1: 随机过程基础的首次阅读路线.

随机游走会作为贯穿全章的离散时间例子. 价格历史可以用来理解信息, 持仓可以用来理解可预测性, 首次触及价位可以用来理解停时, 订单到达则可以用来理解计数过程. 这些例子先来说明数学结构. 等把它们放回真实市场时, 还要再问独立增量, 正态分布和常参数强度是否适合那一份数据.

4.2 随机过程, 分布与样本路径

固定概率空间与随机变量族 下面先把所有随机对象放在同一个固定概率空间

$$(\Omega, \mathcal{F}, \mathbb{P})$$

上. 状态空间记为 $(E, \mathcal{E})$, 时间指标集记为 $\mathbb{T}$. 最常见的两种情况是离散时间 $\mathbb{T} = \mathbb{N}_0$ 和连续时间 $\mathbb{T} = [0, \infty)$.

定义 4.1 (随机过程).

一个取值于 $(E, \mathcal{E})$, 指标集为 $\mathbb{T}$ 的 **随机过程**是指一族随机元素

$$X = (X_t)_{t \in \mathbb{T}}, \quad X_t: \Omega \rightarrow E,$$

其中每个 X_t 都是 $\mathcal{F}/\mathcal{E}$ -可测的.

固定时刻 t 时, X_t 是一个随机变量或随机元素; 固定样本点 ω 时,

$$t \mapsto X_t(\omega)$$

则是一个普通函数, 称为 X 在 ω 上的**样本路径**. 这两个固定操作回答的是不同问题:

t 固定 : $\omega \mapsto X_t(\omega)$ 描述横截面上的随机性,
 ω 固定 : $t \mapsto X_t(\omega)$ 描述一次实现的时间形状.

例 4.2 (随机游走).

令 $\xi_1, \xi_2, \dots$ 为独立同分布随机变量, 满足

$$\mathbb{P}(\xi_k = 1) = p, \quad \mathbb{P}(\xi_k = -1) = 1 - p.$$

定义

$$S_0 = 0, \quad S_n = \sum_{k=1}^n \xi_k.$$

那么 $S = (S_n)_{n \geq 0}$ 是整数值随机过程. 固定 n 时, S_n 是随机变量; 固定 ω 时, $0, S_1(\omega), S_2(\omega), \dots$ 是一条上下移动的折线路径.

当 $p = 1/2$ 时称为简单对称随机游走. 它会同时成为后面 Markov 链, 鞅和首次到达问题的例子.

一条现实价格记录也是一条实现 真实行情把“样本路径”这个抽象词变得很具体. 图4.2只把 AAPL 的复权收盘价画成一条已经实现的路径. 它不承担公司分析或交易信号的任务, 只承担一个更朴素的任务: 让读者看见“固定一个 ω 后, $t \mapsto X_t(\omega)$ 就是一条随时间展开的曲线”. 单独一条路径可以提出建模问题, 但还识别不了它背后的概率律, 也到不了证明某个指标具有预测能力那一步.



图 4.2: AAPL 复权收盘价的一条实现路径 (2019–2021). 本图只作为样本路径的示意图. 数据来源见引用文献 [Yaha; Yahc].

为什么单时点分布不够 设 $Z_0, Z_1, \dots$ 独立同分布于 $\mathcal{N}(0, 1)$, 再设 $Z \sim \mathcal{N}(0, 1)$, 并定义

$$X_n = Z_n, \quad Y_n = Z.$$

对每个固定的 n , X_n 和 Y_n 具有完全相同的分布. 但 X 的各期水平相互独立, Y 的整条路径却保持在同一个随机水平. 因此, 单时点边缘分布无法描述时间依赖; 至少要考察若干时刻的联合分布.

定义 4.3 (有限维分布).

对任意 $n \geq 1$ 和任意 $t_1, \dots, t_n \in \mathbb{T}$, 随机向量

$$(X_{t_1}, \dots, X_{t_n})$$

的联合分布称为过程 X 的一个**有限维分布**. 全部有限维分布组成的族记作

$$\{\mathcal{L}(X_{t_1}, \dots, X_{t_n}) : n \geq 1, t_1, \dots, t_n \in \mathbb{T}\}.$$

首次阅读时, 理解“有限维分布保留多个时点之间的依赖”即可继续. 下面关于过程律, 路径空间和延拓的内容回答怎样把全部时点放进同一个随机对象. 后续滤过, 停时和鞅的内容不以这些技术细节为前提, 可以留到第二遍细读.

把整条坐标族放在一起, 可以形式地写成

$$X: \Omega \longrightarrow E^{\mathbb{T}}, \quad X(\omega) = (X_t(\omega))_{t \in \mathbb{T}}.$$

在 $E^{\mathbb{T}}$ 上先取由有限个坐标投影生成的柱 σ -代数. 由于每个坐标 X_t 都可测, 上面的映射也可测, 它把 $\mathbb{P}$ 前推成 $E^{\mathbb{T}}$ 上的概率测度

$$\mathcal{L}(X) = \mathbb{P} \circ X^{-1}.$$

这称为 X 的**过程分布**或**过程律**. 有限维分布就是这个测度在有限个坐标上的边缘分布.

定理 4.4 (有限维分布决定柱 σ -代数上的过程律).

如果两个过程 X 和 Y 具有相同的全部有限维分布, 那么它们在 $E^{\mathbb{T}}$ 的柱 σ -代数上具有相同的过程律.

给出所有有限窗口的分布以后, 还有两件事没有自动完成. 第一, 这些有限窗口能不能拼成一条完整路径上的概率律. 第二, 拼出来以后能不能选到连续或右连续左极限的路径版本. Kolmogorov 延拓定理处理第一件事, 路径正则性还要另找条件.

这里需要一个状态空间条件. 标准 Borel 空间是与某个 Polish 空间的 Borel 可测空间可测同构的可测空间; Polish 表示拓扑可由某个完备度量刻画并且具有可数稠密子集. 本书常用的例子包括 $\mathbb{R}^d$, 可数离散空间, 连续路径空间 $C([0, T])$ 和右连续左极限路径空间 $D([0, T])$. Polish 空间和 Skorokhod 拓扑的细节可以留到需要路径空间弱收敛时再展开.

定理 4.5 (Kolmogorov 延拓定理).

设 $(E, \mathcal{E})$ 是标准 Borel 空间. 对每个有限子集 $J \subseteq \mathbb{T}$, 设给定 E^J 上的概率测度 μ_J . 如果每当 $J \subseteq K$ 时, μ_J 都等于 μ_K 经自然坐标投影 $E^K \rightarrow E^J$ 所得的前推测度, 那么存在某个概率空间及其上的过程, 使 (μ_J) 成为该过程的有限维分布族.

证明. 证明先处理可数坐标, 再从可数坐标扩到任意指标集. 对任意可数 $U \subseteq \mathbb{T}$, 一致族 $(\mu_J)_{J \subseteq U, |J| < \infty}$ 由可数乘积上的射影极限定理在 E^U 上确定概率测度 P_U ; 柱集合上的唯一性由 π - λ 定理给出. 标准 Borel 条件用于这里的构造; 可数乘积这一步见 [Kal21, Theorem 8.21].

现在考虑 $E^{\mathbb{T}}$ 的乘积 σ -代数. 其中每个可测集合 A 只依赖某个可数坐标集 U_A : 存在 $A_U \in \mathcal{E}^U$, 使 $A = \pi_U^{-1}(A_U)$. 定义

$$P(A) = P_U(A_U).$$

若同一集合还可由另一可数坐标集表示, 把两组坐标并到 $U \cup V$ 后使用投影一致性, 可知这个定义与表示无关. 对两两不交的 $A_1, A_2, \dots$, 所有集合共同只依赖可数坐标集 $U = \bigcup_n U_{A_n}$; 可列可加性于是化为 P_U 的可列可加性. 因而 P 是 $E^{\mathbb{T}}$ 上的概率测度.

最后取规范空间 $(E^{\mathbb{T}}, \mathcal{E}^{\mathbb{T}}, P)$ 及坐标过程 $X_t(x) = x_t$. 按构造, 它在每个有限坐标集 J 上的分布等于 μ_J . 任意指标集与标准 Borel 状态空间的完整论证见 [Kal21, Theorem 8.23]; 实数序列空间上的直接紧矩形证明见 [Dur19, Theorem A.3.1]. $\square$

注 4.6.

延拓定理保证可以构造具有这些有限维分布的过程, 对连续或右连续路径却没有作出保证. 从矩条件推出连续修正还要使用 Kolmogorov 连续性定理. 有限维一致性与路径正则性仍是两个问题.

修正, 不可区分与路径性质 随机变量通常只在几乎必然意义下唯一. 对过程而言, “每个时刻分别几乎必然相等”与“整条路径几乎必然相等”有不同的量词次序, 因而给出不同条件.

定义 4.7 (修正与不可区分).

设 $X = (X_t)_{t \in \mathbb{T}}$ 和 $Y = (Y_t)_{t \in \mathbb{T}}$ 定义在同一概率空间上.

1. 如果对每个固定的 $t \in \mathbb{T}$ 都有

$$\mathbb{P}(X_t = Y_t) = 1,$$

则称 X 和 Y 互为修正.

2. 如果存在 $\Omega_0 \in \mathcal{F}$, 满足 $\mathbb{P}(\Omega_0) = 1$, 并且对每个 $\omega \in \Omega_0$ 和所有 $t \in \mathbb{T}$ 都有

$$X_t(\omega) = Y_t(\omega),$$

则称 X 和 Y 不可区分.

不可区分一定推出互为修正. 当 $\mathbb{T}$ 可数时, 反方向也成立, 因为可数个零概率例外集的并仍然是零概率集. 但在连续时间中, $\mathbb{T}$ 不可数, 反方向一般不成立.

例 4.8 (每个时刻相同, 整条路径却不同).

取 $\Omega = [0, 1]$ 及 Lebesgue 概率测度, 并令

$$X_t(\omega) = \mathbf{1}_{\{\omega=t\}}, \quad Y_t(\omega) = 0, \quad t \in [0, 1].$$

对每个固定 t , 单点集合 $\{t\}$ 的概率为 0, 因而 $X_t = Y_t$ a.s. 所以 X 与 Y 互为修正.

但是对每一个 ω , 都有 $X_\omega(\omega) = 1$, 因而不存在任何样本点使两条路径在所有时刻都相同. 所以二者并不可区分.

命题 4.9 (连续修正的唯一性).

如果连续时间过程 X 和 Y 互为修正, 并且二者的样本路径都几乎必然连续, 那么 X 和 Y 不可区分.

证明. 在一个概率为 1 的事件上, 两个过程在所有有理时刻都相等, 并且两条路径都连续. 有理数在时间区间中稠密, 因而连续性把有理时刻上的相等延伸到所有时刻. $\square$

因此, 当我们说“这个过程具有连续路径”时, 需要分清是在谈原先给定的过程, 还是谈它存在的某个连续修正. 在后文中, “Brown 运动具有连续路径”会被直接纳入定义; 对只由有限维分布构造出的 Gauss 过程, 则还需要另行寻找连续修正.

4.3 时间与信息

前一节把随机过程当作一整条路径来描述. 从这里开始, 同一条路径要被放进时间顺序里: 哪些量在当前已经看见, 哪些决定必须在下一次随机变化以前作出, 哪些随机时刻可以在发生当下被识别. 这些问题都由滤过来承载.

滤过, 自然滤过与适应过程 随机过程随时间变化, 可用信息也随时间增长. 这些信息由递增的 σ -代数族描述.

定义 4.10 (滤过与滤过概率空间).

一个滤过是指一族子 σ -代数 $(\mathcal{F}_t)_{t \in \mathbb{T}}$, 满足

$$s \leq t \implies \mathcal{F}_s \subseteq \mathcal{F}_t \subseteq \mathcal{F}.$$

四元组

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in \mathbb{T}}, \mathbb{P})$$

称为滤过概率空间.

$\mathcal{F}_t$ 表示截至时刻 t 已经能够分辨的事件. 滤过递增表示信息可以累积, 但不能把已经知道的事情忘掉. 同一个坐标过程放在不同滤过下, 可能具有不同的鞅性质. 滤过因此属于模型设定的一部分.

定义 4.11 (自然滤过).

过程 X 生成的自然滤过为

$$\mathcal{F}_t^X = \sigma(X_s : s \leq t).$$

自然滤过只记录 X 自身过去和现在的历史. 实际模型的滤过可能更大, 例如还包含成交量, 新闻, 订单流或其他状态变量. 在连续时间理论中, 常把自然滤过补入零概率集合并作右连续化, 得到满足通常条件的滤过. 这些增广会影响技术陈述, “截至当前的信息” 仍是理解滤过的基本直觉.

定义 4.12 (适应过程).

若对每个 $t \in \mathbb{T}$, 随机变量 X_t 都是 $\mathcal{F}_t$ -可测的, 则称 X 关于滤过 $(\mathcal{F}_t)$ 适应.

适应表示当前状态能够由当前信息确定. 自然地, 每个过程都适应于自己的自然滤过. 仅有适应性时, 行动仍可能在当期价格变化发生以后才确定. 把决定时点进一步限制在变化发生以前, 就得到可预测性.

可预测性: 行动必须先于结果 离散时间中, 可预测性的含义最清楚.

定义 4.13 (离散时间可预测过程).

设 $(H_n)_{n \geq 1}$ 为离散时间过程. 如果每个 H_n 都是 $\mathcal{F}_{n-1}$ -可测的, 则称 H 为可预测过程.

H_n 可以理解为在区间 $(n-1, n]$ 中持有的头寸: 它必须在第 n 次价格变化出现以前, 根据 $\mathcal{F}_{n-1}$ 中的信息决定. 若只要求 H_n 为 $\mathcal{F}_n$ -可测, 策略便可以看到第 n 次收益以后再选择持仓, 因而失去事前可实施性.

例 4.14 (离散时间交易增益).

设 S_n 是价格过程, H_n 是第 n 期开始前决定的持仓. 截至 n 的累计交易增益写成

$$(H \cdot S)_n = \sum_{k=1}^n H_k (S_k - S_{k-1}).$$

可预测性要求 H_k 为 $\mathcal{F}_{k-1}$ -可测. 如果取

$$H_k = \text{sgn}(S_k - S_{k-1}),$$

那么这个“策略”使用了当期尚未发生的价格变化, 通常不具可预测性.

连续时间没有天然的“上一期”. 要表达“只用行动以前的信息”, 需要在时间和样本空间的乘积上指定哪些规则算作事前可见. 这里先别急着消化所有可测性细节: 下面的可预测 σ -代数是随机积分会用到的技术定义. 第一次阅读只要保留“区间开始时已经确定”这个离散近似直觉, 就可以先继续读停时, 第5.3节定义随机积分时再回来.

定义 4.15 (连续时间可预测 σ -代数).

在 $[0, \infty) \times \Omega$ 上, 由下列集合生成的 σ -代数称为可预测 σ -代数:

$$\{0\} \times A, \quad A \in \mathcal{F}_0,$$

以及

$$(s, t] \times A, \quad 0 \leq s < t, \quad A \in \mathcal{F}_s.$$

对这个 σ -代数可测的过程称为可预测过程.

读者在第一次阅读时可以保留下面的直觉: 连续时间可预测过程能够由“在一段时间开始时就已经知道的简单规则”逐步逼近. 特别地, 适应且左连续的过程是可预测的. 适应并不自动等于可预测; 两者之间的精确关系属于后续随机积分所需的可测性基础.

注 4.16 (渐进可测性).

连续时间中还常见**渐进可测**: 对每个 t , 过程在 $[0, t] \times \Omega$ 上的限制关于 $\mathcal{B}([0, t]) \otimes \mathcal{F}_t$ 可测. 适应且具有连续或右连续路径的过程通常是渐进可测的. 随机积分所需的被积过程条件比适应性更强; 第5.3节会用可预测性和可积性把条件明确写出.

停时, 首次到达与停止过程 许多动态问题在某个事件第一次发生时结束, 结束时点随路径而变. 例如价格第一次触及止损线, 排队中的第一笔订单到达, 或者随机游走第一次离开一个区间.

定义 4.17 (停时).

取值于 $\mathbb{T} \cup \{\infty\}$ 的随机变量 τ 称为关于 $(\mathcal{F}_t)$ 的**停时**, 如果对每个 $t \in \mathbb{T}$ 都有

$$\{\tau \leq t\} \in \mathcal{F}_t.$$

这个条件表示: 到时刻 t 为止, 只用当时已经拥有的信息, 就能判断 τ 是否已经发生. 它不要求在时间 0 就知道 τ 的具体值. 离散时间中, 上面的条件等价于

$$\{\tau = n\} \in \mathcal{F}_n \quad \text{对每个 } n.$$

例 4.18 (首次到达时刻).

设 X 是适应过程, $B \in \mathcal{E}$. 离散时间首次进入 B 的时刻

$$\tau_B = \inf\{n \geq 0 : X_n \in B\}$$

是停时, 因为

$$\{\tau_B \leq n\} = \bigcup_{k=0}^n \{X_k \in B\} \in \mathcal{F}_n.$$

在连续时间中, 如果 X 是实值适应过程且具有连续路径, 那么对常数 a ,

$$\tau_a = \inf\{t \geq 0 : X_t \geq a\}$$

也是停时. 连续性允许我们用有理时刻上的观测表达 $\{\sup_{s \leq t} X_s \geq a\}$.

定义 4.19 (停时处的信息与停止过程).

对停时 τ , 定义

$$\mathcal{F}_\tau = \{A \in \mathcal{F} : A \cap \{\tau \leq t\} \in \mathcal{F}_t \text{ 对所有 } t\}.$$

它表示在 τ 发生时已经获得的信息. 过程 X 在 τ 处停止后得到

$$X_t^\tau = X_{t \wedge \tau},$$

称为停止过程.

在离散时间中, 适应过程的停止过程仍然适应. 连续时间中, 在这里使用的连续或右连续适应过程情形下也成立; 更一般情形需要补充相应的可测性条件.

注 4.20.

“最后一次达到某个价位”通常不是停时. 要判断某次到达是不是最后一次, 需要知道未来是否还会再次到达, 这超出了当前信息. 这个反例点明了停时的判别标准: 随机时刻必须能够在发生当下被识别, 仅有时间量纲还不够.

4.4 Markov 过程: 当前状态能否代表过去

停时解决的是一个行动时点问题: 站在当前信息里, 我们能不能判断某个随机时刻已经发生. 一旦时刻确定下来, 下一个问题自然变成预测问题: 如果现在已经知道过程处在什么状态, 还需不需要把此前每一步历史都带进未来分布的计算?

Markov 性就是对这个问题的一种理想回答. 它并不是说过去没有发生过, 也不是说过去与未来彼此独立; 它说的是: 过去对未来的影响若已经完全压缩进当前状态, 那么给定当前状态以后, 更早的历史不再额外改变未来的条件分布. 为了把这句话写成数学对象, 需要先定义从当前状态到下一状态的概率规则.

转移核与 Markov 性

定义 4.21 (转移核).

设 $(E, \mathcal{E})$ 为状态空间. 一个从 E 到 E 的转移核是映射

$$K: E \times \mathcal{E} \rightarrow [0, 1],$$

满足:

1. 固定 $x \in E$ 时, $A \mapsto K(x, A)$ 是 E 上的概率测度;
2. 固定 $A \in \mathcal{E}$ 时, $x \mapsto K(x, A)$ 是可测函数.

$K(x, A)$ 表示当前状态为 x 时, 下一步落入集合 A 的条件概率.

定义 4.22 (离散时间 Markov 性).

适应过程 $X = (X_n)_{n \geq 0}$ 称为关于滤过 $(\mathcal{F}_n)$ 的 Markov 过程, 如果存在转移核 K_n , 使对所有 $A \in \mathcal{E}$,

$$\mathbb{P}(X_{n+1} \in A \mid \mathcal{F}_n) = K_n(X_n, A) \quad \text{a.s.}$$

如果 K_n 不依赖于 n , 则称过程时间齐次, 并把共同的核记为 K .

在自然滤过下, 这个定义可以读作

$$\mathbb{P}(X_{n+1} \in A \mid X_0, \dots, X_n) = \mathbb{P}(X_{n+1} \in A \mid X_n).$$

Markov 性要求给定当前状态以后, 更早的历史不再额外改变未来的条件分布. 过去与未来本身仍可以相关. 如果状态变量漏掉了会持续影响未来的因素, 原过程就可能不具有 Markov 性; 扩大状态空间有时能够恢复 Markov 性.

例 4.23 (随机游走的转移核).

对前面的随机游走,

$$K(x, \{x+1\}) = p, \quad K(x, \{x-1\}) = 1-p.$$

下一步只由当前位置和新的独立增量决定, 因而 S 是时间齐次 Markov 链. 但当 $p \neq 1/2$ 时它具有漂移, 所以 Markov 性并不自动推出鞅性.

Chapman–Kolmogorov 方程 令 $K^m(x, A)$ 表示从 x 出发经过 m 步以后落入 A 的概率. 约定 $K^0(x, A) = \mathbf{1}_A(x)$.

定理 4.24 (Chapman–Kolmogorov 方程).

对时间齐次 Markov 链,

$$K^{m+n}(x, A) = \int_E K^m(x, dy) K^n(y, A), \quad m, n \in \mathbb{N}_0.$$

这个公式只是把一段长度为 $m+n$ 的演化, 在中间时刻切成长度为 m 和 n 的两段. 第一段把 x 送到随机中间状态 y , 第二段再从 y 走到 A , 最后对所有中间状态积分.

例 4.25 (两状态市场环境).

设状态空间为

$$E = \{B, S\},$$

分别表示活跃和低迷两种环境, 转移矩阵为

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix}.$$

行表示当前状态, 列表示下一期状态. 两步转移矩阵由 Chapman–Kolmogorov 方程给出:

$$P^2 = \begin{pmatrix} 0.70 & 0.30 \\ 0.45 & 0.55 \end{pmatrix}.$$

例如, 从活跃状态出发两期后仍然活跃的概率为

$$0.8 \times 0.8 + 0.2 \times 0.3 = 0.70.$$

这个例子只演示状态转移计算; 真实市场环境是否能由两个状态概括, 是另一个模型识别问题.

离散时间先把“下一步”说清楚. 连续时间中, 我们还要能从任意确定时刻 s 预测任意较晚时刻 t . 这时同一个想法不再由一个核 K 表示, 而由一族转移核 $P_{s,t}$ 表示.

定义 4.26 (连续时间 Markov 性).

设 $X = (X_t)_{t \geq 0}$ 是取值于 $(E, \mathcal{E})$ 且适应于 $(\mathcal{F}_t)_{t \geq 0}$ 的过程. 如果对每个 $0 \leq s \leq t$ 都存在从 E 到 E 的转移核 $P_{s,t}$, 使每个有界可测函数 f 都满足

$$\mathbb{E}[f(X_t) | \mathcal{F}_s] = P_{s,t}f(X_s) \quad \text{a.s.}, \quad P_{s,t}f(x) := \int_E f(y)P_{s,t}(x, dy),$$

则称 X 关于该滤过具有**连续时间 Markov 性**. 若 $P_{s,t}$ 只依赖于时间差 $t-s$, 即 $P_{s,t} = P_{t-s}$, 则称过程时间齐次.

这个条件说明, 在任意确定时刻 s 给定当前状态 X_s 后, 更早的 $\mathcal{F}_s$ 信息不会继续改变任意未来时刻 t 的条件分布. 对时间齐次 Markov 过程, 通常用转移半群 $(P_t)_{t \geq 0}$ 表示这些核. 若先给定从每个初始状态出发的 Markov 家族 $(\mathbb{P}_x)_{x \in E}$, 满足 $\mathbb{P}_x(X_0 = x) = 1$, 并以 $\mathbb{E}_x$ 表示 $\mathbb{P}_x$ 下的期望. 对有界可测函数 f ,

$$P_t f(x) = \mathbb{E}_x[f(X_t)], \quad P_{s+t} = P_s P_t.$$

半群与第5.7节的生成元, Kolmogorov 方程和 Feynman–Kac 公式相连.

注 4.27 (强 Markov 性把 Markov 思想带回停时).

普通 Markov 性首先针对确定时刻. 前一节的首次到达时刻却通常是随机的. 如果在这类停时发生以后, 过程仍能从当时状态重新开始预测, 就得到**强 Markov 性**. 标准 Markov 链, Poisson 过程和 Brown 运动都具有强 Markov 性, 但一般过程的强 Markov 性不能仅凭一句普通 Markov 性无条件推出. 因此强 Markov 性要么作为额外假设给出, 要么由过程的具体构造另行验证.

4.5 鞅: 条件平均下没有可预测漂移

鞅, 下鞅与上鞅 Markov 性关心的是整张未来条件分布. 在很多金融问题里, 我们还会问一个更窄的问题: 如果只看未来值的条件平均, 当前信息是否已经给不出系统性的上升或下降方向? 这就引出鞅. 因此 Markov 性压缩的是未来的**条件分布**; 鞅压缩的是未来值的**条件期望**. 两者回答不同问题, 也可以同时成立或分别失败.

定义 4.28 (离散时间鞅).

设 $X = (X_n)_{n \geq 0}$ 适应于 $(\mathcal{F}_n)$, 并且每个 X_n 都可积.

1. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n \quad \text{a.s.},$$

则称 X 为鞅.

2. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] \geq X_n \quad \text{a.s.},$$

则称 X 为下鞅.

3. 若

$$\mathbb{E}[X_{n+1} | \mathcal{F}_n] \leq X_n \quad \text{a.s.},$$

则称 X 为上鞅.

定义 4.29 (连续时间鞅).

设 $X = (X_t)_{t \geq 0}$ 适应于 $(\mathcal{F}_t)_{t \geq 0}$, 并且每个 X_t 都可积. 如果对所有 $0 \leq s \leq t$ 都有

$$\mathbb{E}[X_t | \mathcal{F}_s] = X_s \quad \text{a.s.},$$

则称 X 为关于该滤过的**连续时间鞅**. 把等号分别改为 $\geq$ 和 $\leq$, 就得到连续时间下鞅和上鞅.

利用塔性质, 离散时间鞅条件等价于对所有 $m \leq n$,

$$\mathbb{E}[X_n | \mathcal{F}_m] = X_m.$$

“公平游戏”只是帮助记忆的比喻. 严格地说, 鞅性总是相对于指定概率测度和指定滤过而言; 现实资产的原始价格也不会因为写了一个鞅定义就自动成为鞅.

例 4.30 (有漂移与无漂移随机游走).

对随机游走 $S_n = \sum_{k=1}^n \xi_k$,

$$\mathbb{E}[S_{n+1} | \mathcal{F}_n] = S_n + (2p - 1).$$

因此:

$$p = \frac{1}{2} \implies S \text{ 是鞅};$$

当 $p > 1/2$ 时 S 是下鞅, 当 $p < 1/2$ 时 S 是上鞅. 无论 p 取何值, 中心化过程

$$M_n = S_n - n(2p - 1)$$

都是鞅.

命题 4.31 (可预测变换).

设 M 是离散时间鞅, $H = (H_n)_{n \geq 1}$ 是有界可预测过程. 定义

$$(H \cdot M)_n = \sum_{k=1}^n H_k (M_k - M_{k-1}).$$

那么 $(H \cdot M)_n$ 也是鞅.

证明. 因为 H_k 是 $\mathcal{F}_{k-1}$ -可测的, 且有界性保证相应乘积可积, 所以

$$\begin{aligned} \mathbb{E}[H_k (M_k - M_{k-1}) \mid \mathcal{F}_{k-1}] &= H_k \mathbb{E}[M_k - M_{k-1} \mid \mathcal{F}_{k-1}] \\ &= 0. \end{aligned}$$

对增量求和即可. □

这个命题说明, 可预测策略不会凭空从鞅增量中提取系统性的条件平均收益. 将它用于完整金融市场时, 还要加入融资, 现金账户, 交易成本, 可交易性和可容许性等条件.

离散时间 Doob 分解 下鞅允许存在非负的条件漂移. Doob 分解把这部分可预测漂移单独列出, 余项成为鞅.

定理 4.32 (离散时间 Doob 分解).

设 $X = (X_n)_{n \geq 0}$ 是可积下鞅. 定义

$$A_0 = 0, \quad A_n = \sum_{k=1}^n \mathbb{E}[X_k - X_{k-1} \mid \mathcal{F}_{k-1}],$$

并令

$$M_n = X_n - A_n.$$

那么 M 是鞅, A 是从 0 开始的可积可预测递增过程, 且

$$X_n = M_n + A_n.$$

在要求 $A_0 = 0$ 的条件下, 这个分解唯一.

证明. 下鞅性给出

$$\mathbb{E}[X_k - X_{k-1} \mid \mathcal{F}_{k-1}] \geq 0,$$

所以 A 递增. $A_k - A_{k-1}$ 是 $\mathcal{F}_{k-1}$ -可测的, 因而 A 可预测. 同时,

$$\begin{aligned} \mathbb{E}[M_k - M_{k-1} \mid \mathcal{F}_{k-1}] &= \mathbb{E}[X_k - X_{k-1} \mid \mathcal{F}_{k-1}] \\ &\quad - (A_k - A_{k-1}) = 0. \end{aligned}$$

所以 M 是鞅. 唯一性可由“同时是可预测有限变差过程和鞅的过程只能为常数”推出. □

对上鞅, 同样可以写成

$$X_n = M_n - A_n,$$

其中 A 为从 0 开始的可预测递增过程. 这个分解是第 5.2 节中“局部鞅部分加有限变差部分”这一半鞅结构的离散时间原型.

把鞅带到随机时刻 鞅在确定时刻之间保持条件期望. 如果把观察时刻改成随机的停时, 直觉仍然很有用, 但还要确认停止后的变量是否真的可积, 以及是否能把有界停时的结论安全地取极限.

定理 4.33 (有界停时的可选抽样).

设 $M = (M_n)_{n \geq 0}$ 是离散时间鞅, $\sigma \leq \tau$ 是两个有界停时. 那么

$$\mathbb{E}[M_\tau | \mathcal{F}_\sigma] = M_\sigma \quad \text{a.s.},$$

从而

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_\sigma].$$

对下鞅, 相应等号改为 $\geq$; 对上鞅改为 $\leq$.

证明. 取确定常数 N 使 $\tau \leq N$. 核心做法是把从 σ 到 τ 之间实际保留下来的鞅增量挑出来. 对任意 $A \in \mathcal{F}_\sigma$, 写

$$M_\tau - M_\sigma = \sum_{k=1}^N \mathbf{1}_{\{\sigma < k \leq \tau\}} (M_k - M_{k-1}).$$

因为 $\{\sigma < k\} = \{\sigma \leq k-1\}$, $\{\tau \geq k\} = \{\tau \leq k-1\}^c$, 并且 $A \cap \{\sigma \leq k-1\} \in \mathcal{F}_{k-1}$, 所以 $A \cap \{\sigma < k \leq \tau\} \in \mathcal{F}_{k-1}$. 鞅增量的条件均值为 0, 从而

$$\mathbb{E}[\mathbf{1}_A \mathbf{1}_{\{\sigma < k \leq \tau\}} (M_k - M_{k-1})] = 0.$$

对 k 求和得到 $\mathbb{E}[\mathbf{1}_A (M_\tau - M_\sigma)] = 0$. 由于这对每个 $A \in \mathcal{F}_\sigma$ 都成立, 条件期望的刻画给出 $\mathbb{E}[M_\tau | \mathcal{F}_\sigma] = M_\sigma$. 下鞅和上鞅只需把增量的条件等式换成相应不等式. 更一般的离散可选抽样形式见 [Kal21, Theorem 9.12]. $\square$

注 4.34 (无界停时还要看尾部).

如果 τ 无界, 仅仅知道 $\tau < \infty$ a.s. 通常不够. 对离散时间鞅, 一种完整的常用充分条件是: $\tau < \infty$ a.s. 且停止族

$$\{M_{\tau \wedge n} : n \geq 0\}$$

一致可积. 此时 $M_{\tau \wedge n} \rightarrow M_\tau$ 在 L^1 中成立, 因而

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_0].$$

另一个便于核查的完整充分条件是: 鞅增量存在统一常数上界 $|M_n - M_{n-1}| \leq C$, 并且 $\mathbb{E}[\tau] < \infty$; 这两个条件需要同时使用.

非负鞅的情形还要单独检查上述等号. 如果只知道 $M_n \geq 0$ 和 $\tau < \infty$ a.s., Fatou 引理一般只能给出

$$\mathbb{E}[M_\tau] \leq \mathbb{E}[M_0],$$

等号未必成立; 若停止族再满足一致可积性, 才可恢复等号. 所以鞅在随机时刻处能否保持期望, 关键常常不是停时本身, 而是停止以后那族随机变量的尾部是否受控.

例 4.35 (赌徒破产与首次到达).

设 (S_n) 是简单对称随机游走, 从 $S_0 = i \in \{1, \dots, N-1\}$ 出发, 并令

$$\tau = \inf\{n \geq 0 : S_n \in \{0, N\}\}.$$

对每个 m , $\tau \wedge m$ 有界, 所以可选抽样给出

$$\mathbb{E}[S_{\tau \wedge m}] = i.$$

这个有限区间中的吸收时刻 τ 几乎必然有限, 而且 $0 \leq S_{\tau \wedge m} \leq N$. 因此可以用控制收敛令 $m \rightarrow \infty$, 得到

$$\mathbb{E}[S_\tau] = i.$$

由于 S_τ 只可能等于 0 或 N ,

$$\mathbb{P}_i(S_\tau = N) = \frac{i}{N}.$$

注 4.36.

翻倍下注策略经常被用来制造可选抽样的伪反例. 这类策略通常涉及无界头寸, 无界损失, 缺乏一致可积性, 或者没有满足现实中的资金和可容许性约束. 出现“必胜”叙述时, 应先逐项检查停时, 可积性和策略边界. 没有条件的公平游戏直觉不足以支持结论.

4.6 计数过程与 Poisson 过程

前面几节主要围绕价格, 赌本或连续状态变量展开. 市场里还有另一类基本对象: 某件事到现在为止发生了多少次. 订单到达, 违约发生, 电话呼入和设备故障都不是连续波动, 而是一跳一跳累积起来的事件记录. 这就引出计数过程.

从订单到达到计数过程 若研究某类事件截至时刻 t 一共发生了多少次, 自然的状态变量是一个递增整数值过程.

定义 4.37 (计数过程).

一个计数过程是过程 $N = (N_t)_{t \geq 0}$, 满足:

1. $N_0 = 0$;
2. 样本路径取非负整数值并且单调不减;
3. 样本路径右连续且有左极限.

如果每次跳跃的大小都为 1, 则称它是简单计数过程.

例如, N_t 可以表示截至 t 的订单到达数, 违约数, 电话呼入数或设备故障数. 单调性只表示累计事件不会被撤回, 并不表示到达强度恒定或不依赖历史.

定义 4.38 (Poisson 过程).

设 $\lambda > 0$. 计数过程 $N = (N_t)_{t \geq 0}$ 称为强度 λ 的 **Poisson 过程**, 如果:

1. $N_0 = 0$ a.s.;
2. 它具有独立增量;
3. 对任意 $0 \leq s < t$,

$$N_t - N_s \sim \text{Poisson}(\lambda(t - s)).$$

于是

$$N_t \sim \text{Poisson}(\lambda t), \quad \mathbb{E}[N_t] = \lambda t, \quad \text{Var}(N_t) = \lambda t.$$

平稳增量表示分布只取决于区间长度, 独立增量表示不相交时间区间中的到达数相互独立. 这两点都是 Poisson 模型的额外假设; 一般计数过程未必具有这些性质.

等待时间 定义第 n 次到达时刻和相邻到达之间的等待时间:

$$T_n = \inf\{t \geq 0 : N_t \geq n\}, \quad W_n = T_n - T_{n-1}, \quad T_0 = 0.$$

定理 4.39 (Poisson 到达与指数等待).

如果 N 是强度 λ 的 Poisson 过程, 那么 $W_1, W_2, \dots$ 独立同分布, 且

$$W_n \sim \text{Exp}(\lambda).$$

因而

$$\mathbb{P}(W_1 > t) = e^{-\lambda t}, \quad \mathbb{E}[W_1] = \frac{1}{\lambda}.$$

第 n 次到达时刻满足

$$T_n = W_1 + \cdots + W_n \sim \text{Gamma}(n, \lambda),$$

这里采用 rate 参数化.

第一个等式可以直接看出:

$$\mathbb{P}(T_1 > t) = \mathbb{P}(N_t = 0) = e^{-\lambda t}.$$

指数分布还具有无记忆性:

$$\mathbb{P}(W_1 > s + t \mid W_1 > s) = \mathbb{P}(W_1 > t).$$

在 Poisson 模型中, 已经等待多久不会改变下一次到达还需等待多久的分布. 如果真实订单流存在聚集, 午间效应或消息冲击, 这一性质就可能不合适.

叠加, 稀疏化与补偿

定理 4.40 (叠加与稀疏化).

1. 如果 $N^{(1)}, \dots, N^{(m)}$ 相互独立, 且分别是强度 $\lambda_1, \dots, \lambda_m$ 的 Poisson 过程, 那么

$$N_t = \sum_{j=1}^m N_t^{(j)}$$

是强度 $\lambda_1 + \cdots + \lambda_m$ 的 Poisson 过程.

2. 如果把强度 λ 的 Poisson 过程中的每次到达独立地以概率 p 标记为第 I 类, 以概率 $1 - p$ 标记为第 II 类, 那么两类计数过程相互独立, 且强度分别为 $p\lambda$ 和 $(1 - p)\lambda$.

叠加适合描述多个独立来源汇总成总订单流; 稀疏化适合描述随机抽样, 随机路由或随机分类. 一旦标记概率依赖于历史, 价格或订单类型, 独立 Poisson 结论就要重新核验.

命题 4.41 (补偿 Poisson 鞅).

令 N 是强度 λ 的 Poisson 过程, $(\mathcal{F}_t^N)$ 为其自然滤过. 则

$$M_t = N_t - \lambda t$$

是关于 $(\mathcal{F}_t^N)$ 的鞅.

证明. 对 $0 \leq s < t$, 由独立增量, $N_t - N_s$ 与 $\mathcal{F}_s^N$ 独立, 且期望为 $\lambda(t - s)$. 因而

$$\begin{aligned} \mathbb{E}[M_t \mid \mathcal{F}_s^N] &= N_s - \lambda t + \mathbb{E}[N_t - N_s \mid \mathcal{F}_s^N] \\ &= N_s - \lambda t + \lambda(t - s) = M_s. \end{aligned}$$

□

λt 是计数过程的可预测平均累积部分, $N_t - \lambda t$ 则保留扣除该部分以后的随机波动. 这与离散时间 Doob 分解采用同样的分解思路. 在更一般的点过程模型中, 常数 λ 会被依赖时间和历史的条件强度替代; 相应的累积强度仍会扮演补偿子的角色.

注 4.42 (订单到达模型适合问什么).

真实市场中的订单到达常具有日内季节性, 聚集, 自激, 买卖方向依赖和状态依赖. 齐次 Poisson 过程是一个清楚的基准模型, 但“观察到平均每分钟 λ 笔订单”还不足以验证独立增量或指数等待时间. 建模时应分别检查强度稳定性, 离散程度和序列依赖.

4.7 Brown 运动

定义与 Gauss 增量 Poisson 过程通过跳跃累计离散事件. Brown 运动则是连续时间模型中最基本的连续噪声.

定义 4.43 (标准 Brown 运动).

在滤过概率空间 $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$ 上, 实值过程 $W = (W_t)_{t \geq 0}$ 称为关于该滤过的 **标准 Brown 运动**, 如果:

1. $W_0 = 0$ a.s.;
2. W 适应于 $(\mathcal{F}_t)$;
3. 对任意 $0 \leq s < t$,

$$W_t - W_s \sim \mathcal{N}(0, t - s),$$

并且 $W_t - W_s$ 与 $\mathcal{F}_s$ 独立;

4. 样本路径几乎必然连续.

如果取自然滤过, 第三条就是过去与未来增量独立. 如果人为扩大滤过并提前放入未来信息, 同一个坐标过程可能不再是关于扩大后滤过的 Brown 运动. 这再次说明滤过是定义的一部分.

Brown 运动是 Gauss 过程. 对任意 $t_1, \dots, t_n$,

$$(W_{t_1}, \dots, W_{t_n})$$

服从多元正态分布, 并且

$$\mathbb{E}[W_t] = 0, \quad \text{Cov}(W_s, W_t) = \min(s, t).$$

反过来, 一个中心 Gauss 过程如果具有这个协方差, 并且选取了连续修正, 那么该连续修正相对于自己的自然滤过 (或其满足通常条件的增广) 是标准 Brown 运动. 这个逆向结论并不保证它关于任意扩大后的滤过仍是 Brown 运动.

例 4.44 (增量与水平并不独立).

当 $0 < s < t$ 时, 增量 $W_t - W_s$ 与过去 $\mathcal{F}_s$ 独立, 但水平 W_t 与 W_s 并不独立, 因为

$$\text{Cov}(W_s, W_t) = s.$$

这里的独立性适用于不相交区间上的增量, 不适用于不同时刻的过程水平.

缩放, Markov 性与鞅性**命题 4.45 (Brown 缩放).**

对任意常数 $c > 0$, 定义缩放后的滤过与过程

$$\tilde{\mathcal{F}}_t = \mathcal{F}_{ct}, \quad \tilde{W}_t = \frac{1}{\sqrt{c}} W_{ct}, \quad t \geq 0,$$

则 $\tilde{W}$ 是关于 $(\tilde{\mathcal{F}}_t)_{t \geq 0}$ 的标准 Brown 运动. 因而在过程律意义下,

$$(\tilde{W}_t)_{t \geq 0} \stackrel{d}{=} (W_t)_{t \geq 0}.$$

这个缩放关系说明时间扩大 c 倍时, 典型波动尺度只扩大 $\sqrt{c}$ 倍. 它是扩散模型中“波动率按时间平方根缩放”的数学来源之一, 但把这个结论用于真实收益率以前, 还需要检验独立同分布增量和波动率稳定等假设.

命题 4.46 (Brown 运动的 Markov 性与基本鞅).

标准 Brown 运动是时间齐次 Markov 过程, 当 $t > 0$ 时其转移核为

$$P_t(x, A) = \int_A \frac{1}{\sqrt{2\pi t}} \exp\left(-\frac{(y-x)^2}{2t}\right) dy.$$

此外,

$$W_t \quad \text{和} \quad W_t^2 - t$$

都是鞅.

证明. 对 $0 \leq s < t$, 写成

$$W_t = W_s + (W_t - W_s).$$

后一项独立于 $\mathcal{F}_s$, 且服从 $\mathcal{N}(0, t-s)$, 所以给定当前状态 W_s 后, 未来分布不再依赖更早历史, 这给出 Markov 性. 同时

$$\mathbb{E}[W_t | \mathcal{F}_s] = W_s.$$

再利用 $\mathbb{E}[(W_t - W_s)^2] = t-s$ 和交叉项条件期望为 0, 得到

$$\mathbb{E}[W_t^2 - t | \mathcal{F}_s] = W_s^2 - s.$$

□

反射原理与首次到达 设

$$\tau_a = \inf\{t \geq 0 : W_t = a\}, \quad a > 0.$$

连续性保证“达到或超过 a ”之前一定先命中 a .

定理 4.47 (反射原理).

对 $a > 0$ 和 $t > 0$,

$$\mathbb{P}\left(\sup_{0 \leq s \leq t} W_s \geq a\right) = 2\mathbb{P}(W_t \geq a) = 2\left(1 - \Phi\left(\frac{a}{\sqrt{t}}\right)\right),$$

其中 Φ 为标准正态分布函数. 等价地,

$$\mathbb{P}(\tau_a \leq t) = 2\left(1 - \Phi\left(\frac{a}{\sqrt{t}}\right)\right).$$

反射构造如下: 对一条已经首次命中 a 的路径, 把命中时刻以后的整段路径关于水平线 a 反射. 这个映射在“曾命中 a 且终点低于 a ”的路径与“终点高于 a ”的路径之间建立一一对应; 再加上本来终点就不低于 a 的路径, 并利用正态分布在 a 处没有原子, 便得到公式中的因子 2. 路径映射和强 Markov 性是这一直觉成立的技术支撑.

例 4.48 (触及障碍与到期终值).

事件

$$\left\{\sup_{0 \leq s \leq t} W_s \geq a\right\}$$

取决于整条路径; 终值 W_t 本身不足以判断这个事件. 反射原理恰好把这个路径事件的概率转化为一个终值正态尾概率. 这类“是否曾经触及障碍”的问题以后会出现在首次违约, 止损规则和障碍型合约中.

Brown 路径的规则与不规则 Brown 路径连续, 但它远比普通光滑曲线粗糙. 下面汇总后续会使用的若干路径性质.

定理 4.49 (Brown 运动的路径性质).

对标准 Brown 运动, 下列性质几乎必然成立:

1. 路径在每个有限区间上一致连续;
2. 路径处处不可微;

3. 路径在每个非退化区间上具有无限总变差;
4. 对每个 $0 < \alpha < 1/2$ 和每个固定的 $T < \infty$, 存在依赖于路径的有限常数 $C_{\alpha,T}$, 使

$$|W_t - W_s| \leq C_{\alpha,T} |t - s|^\alpha, \quad 0 \leq s, t \leq T.$$

这称为路径在紧区间上 α -Hölder 连续; 一般不能把指数提高到 $1/2$;

5. 沿二进分割 $t_k^{(n)} = kT/2^n$,

$$\sum_{k=0}^{2^n-1} \left(W_{t_{k+1}^{(n)}} - W_{t_k^{(n)}} \right)^2 \rightarrow T \quad \text{a.s.}$$

连续性与 $\alpha < 1/2$ 的 Hölder 正则性可由 Kolmogorov 连续性准则得到; 处处不可微需要更精细的局部振荡估计. 精确结果可参见 [Kal21, Theorem 14.5 and Proposition 14.10] 以及 [Dur19, Theorems 7.1.5–7.1.6]. 第五条的完整平方增量证明将在第5.2节给出; 无限总变差随后由“连续有限变差路径的二次变差为 0”推出.

第五条给出 Brown 运动二次变差等于时间的典型形式. 连续性与这个结论可以同时成立: 单个小增量趋近于 0, 但长度约为 Δt 的区间上, Brown 增量的典型平方尺度正好是 Δt ; 把大约 $T/\Delta t$ 个平方增量加起来, 总量仍然保持在 T 的尺度.

注 4.50 (模型噪声与经验数据).

Brown 运动的独立 Gauss 增量非常便于计算, 但真实金融收益率常表现出厚尾, 跳跃, 波动率聚集, 状态切换和微观结构噪声. 因此 Brown 运动适合作为连续噪声的基准构件. 将它用于价格路径时, 要说明时间尺度与相应模型假设.

从随机游走到 Brown 运动 简单对称随机游走每一步的大小为 1. 如果把时间压缩为 $1/n$, 同时把空间压缩为 $1/\sqrt{n}$, 先在网格点定义

$$W_{k/n}^{(n)} = \frac{1}{\sqrt{n}} S_k, \quad k = 0, 1, \dots,$$

再在相邻网格点之间作线性插值, 就得到连续的随机折线.

定理 4.51 (Donsker 不变性原理).

在任意固定 $T < \infty$ 上, 上述过程 $W^{(n)}$ 在路径空间 $C([0, T])$ 中依分布收敛到标准 Brown 运动, 其中 $C([0, T])$ 采用一致拓扑.

相比固定时点的中心极限定理, 这个定理同时描述整条随机路径的分布极限. 证明分成两部分: 有限维分布由多维中心极限定理收敛, 路径紧性则排除越来越短时间内的失控振荡. 路径紧性补上了单时点中心极限定理未覆盖的部分. 线性插值随机游走的完整证明见 [Dur19, Theorem 8.1.4]; 更一般的函数型极限定理版本见 [Kal21, Theorem 22.9].

4.8 有限变差, 二次变差与下一章接口

总变差 设 $x: [0, T] \rightarrow \mathbb{R}$ 是一条确定路径. 对分割

$$\pi = \{0 = t_0 < t_1 < \dots < t_m = T\},$$

定义沿分割的绝对增量和

$$V_T(x; \pi) = \sum_{k=0}^{m-1} |x(t_{k+1}) - x(t_k)|.$$

定义 4.52 (有限变差路径).

路径 x 在 $[0, T]$ 上的总变差为

$$V_T(x) = \sup_{\pi} V_T(x; \pi),$$

上确界取遍所有有限分割. 如果 $V_T(x) < \infty$, 则称 x 在 $[0, T]$ 上具有有限变差.

单调函数, 分段光滑函数以及绝对连续且导数可积的函数都具有有限变差. 经典 Riemann–Stieltjes 积分对有限变差积分器有良好的存在理论. Brown 路径却几乎必然具有无限变差, 所以这套充分条件还定义不了后面需要的积分. 非有限变差路径仍可能可积, 但要采用适合随机路径的构造和条件.

二次变差 对同一分割 π , 考虑平方增量和

$$Q_T(x; \pi) = \sum_{k=0}^{m-1} (x(t_{k+1}) - x(t_k))^2.$$

取一系列网格大小趋于 0 的分割 (π_n) . 如果 $Q_T(x; \pi_n)$ 收敛, 其极限称为沿该分割列的二次变差. 对随机过程, 收敛方式可能是几乎必然, 依概率或 L^p ; 具体定理必须说明采用哪一种.

命题 4.53 (连续有限变差路径的二次变差为零).

如果 x 在 $[0, T]$ 上连续且具有有限变差, 那么对任意网格大小趋于 0 的分割列,

$$Q_T(x; \pi_n) \rightarrow 0.$$

证明. 记分割上的最大增量为

$$\delta_n = \max_k |x(t_{k+1}) - x(t_k)|.$$

由 x 在紧区间上的一致连续性, $\delta_n \rightarrow 0$. 同时

$$Q_T(x; \pi_n) \leq \delta_n \sum_k |x(t_{k+1}) - x(t_k)| \leq \delta_n V_T(x) \rightarrow 0.$$

□

若用 $[W]_T$ 记 Brown 运动沿二进分割所得的二次变差极限, 则

$$[W]_T = T.$$

沿网格越来越细的分割, 每个单独的 Brown 增量以及最大增量都趋于 0; 但一阶增量之和仍然望远镜式地等于 $W_T - W_0$, 并不会消失, 而平方增量的总和则留下新的非零极限. Itô 公式中的二阶导数项正由这个非零极限保留下来.

为什么下一章需要随机积分 设我们想把一个随时间更新, 且只能使用过去信息的过程 H 与 Brown 增量相乘并累加. 最自然的离散近似是

$$\sum_{k=0}^{m-1} H_{t_k} (W_{t_{k+1}} - W_{t_k}).$$

左端点 H_{t_k} 体现可预测性: 在区间 $(t_k, t_{k+1}]$ 的随机变化发生以前, 被积系数已经确定. 第 5.3 节会先对简单可预测过程定义这个极限, 再利用 Itô 等距扩张到更广的过程类.

第五章真正要做的事可以这样读:

滤过与可预测性 $\rightarrow$ 哪些被积过程可以使用,
 鞅与补偿 $\rightarrow$ 随机积分的条件平均结构,
 有限变差与二次变差 $\rightarrow$ 随机微分规则为何多出二阶项,
 Markov 性 $\rightarrow$ 生成元, 方程与条件期望.

更一般的连续时间金融模型通常由半鞅承载. 在这里所需层面, 半鞅把局部鞅波动与有限变差部分组合在一起, 同时允许跳跃. 局部鞅, 半鞅, 协变差和随机积分的正式定义都留到第五章, 避免在尚未建立积分以前循环定义这些对象.

4.9 小结

随机过程把一族随机变量连成随时间演化的整体. 完整描述至少涉及状态, 信息和路径三个层面:

- 有限维分布描述有限多个时刻的联合规律, 过程律则把整条坐标族视为一个随机元素;
- 滤过描述信息随时间增长, 适应表示当前可见, 可预测表示行动在结果以前确定;
- 停时描述能够在发生时被识别的随机时刻, 首次到达是最重要的例子;
- Markov 性说当前状态足以决定未来条件分布, 鞅性说当前值等于未来值的条件期望;
- Poisson 过程描述独立平稳的离散到达, 扣除 λt 后得到补偿鞅;
- Brown 运动具有连续路径, 它的增量服从 Gauss 分布且相互独立, 同时有无限总变差和非零二次变差;
- 二次变差保留下来的二阶效应, 是普通微积分进入随机分析时必须增加的新结构.

这些概念在金融语境中经常一起出现, 但它们承担的角色不同. 价格是否具有 Markov 性, 折现价格在哪个测度和滤过下具有鞅性, 订单到达是否可以由 Poisson 过程描述, 都是需要根据对象, 信息集和证据分别判断的模型问题.

第五章 随机分析基础

第4.7节和第4.8节已经看到 Brown 路径的两面性: 路径连续却几乎处处不可微, 一阶绝对增量不断累积, 平方增量则留下有限而非零的极限. 普通微积分不足以处理这样的路径.

这里的路从一次失效开始. 普通微积分在 Brown 路径面前先失效; 二次变差把失效中留下的二阶量记录下来; 第4.3节的可预测性规定积分时不能偷看未来; Itô 积分和 Itô 公式再把这些要求合成新的计算规则. 随后, 随机微分方程, 测度变换和偏微分方程沿着同一条路继续往前走. 这些结论首先是概率论中的计算语言; 要把它解释成价格, 风险中性测度或定价公式, 还要另外说明相应的市场假设.

为统一记号, 先固定有限期限 $T > 0$, 并在满足通常条件的滤过概率空间

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{0 \leq t \leq T}, \mathbb{P})$$

上工作. 一维 Brown 运动记为 B , 多维 Brown 运动记为 W . càdlàg, 局部鞅和一般半鞅积分属于严格接口; 第一次阅读可以先沿着“二次变差–Itô 积分–Itô 公式–SDE”走完主线. 作为状态或积分器的半鞅均取适应的 càdlàg 版本, 即右连续且有左极限; 被积过程只要求相应的可预测性和可积性.

这里先把数学工具本身讲清楚. 某个测度为什么值得采用, 某个条件期望什么时候可以解释成价格, 某个扩散是否适合描述真实对象, 会在后续金融语境中连同模型, 识别与市场假设一起讨论.

5.1 从变差到随机微分

这条路会经过下面几组对象:

1. 区分总变差, 二次变差和协变差, 并解释 Brown 路径为何不能使用普通微积分;
2. 从简单可预测过程出发构造 Itô 积分, 使用 Itô 等距完成 L^2 延拓;
3. 把随机微分记号还原成积分等式, 并正确使用一维, 多维 Itô 公式和乘积公式;
4. 区分随机微分方程的强解, 弱解, 路径唯一性和分布唯一性;
5. 对几何 Brown 运动, Ornstein–Uhlenbeck 过程和 CIR 型过程完成基本计算;
6. 检查 Girsanov 变换的密度过程和充分条件, 并区分测度变化与样本路径;
7. 从扩散的生成元得到 Kolmogorov 后向方程与 Feynman–Kac 表示;
8. 识别连续理论通向 Poisson 随机测度和跳跃半鞅的接口.

第一次阅读可以沿着图5.1先走完前四个节点, 再阅读测度变换和偏微分方程.




图 5.1: 从二次变差到随机微分方程的阅读路线.

局部鞅的技术细节, CIR 的零点行为以及跳跃接口可以留到第二遍. 每遇到形如 $dX_t = \dots$ 的表达式, 都应先问: 它所代表的积分等式是什么, 积分是否存在, 等式是在什么概率测度下成立.

注 5.1 (先把 Brown 积分修通).

这里详细处理 Brown 积分, 并把连续半鞅积分作为下一步接口. 一般 càdlàg 半鞅积分暂作为已经建立的标准理论引用. 局部时, Tanaka 公式, 粗糙路径, Malliavin 微积分, 无限活动跳跃和一般鞅问题只说明它们会在何处被调用, 不在这里展开完整理论.

5.2 路径变差, 二次变差与半鞅

进入随机积分以前, 先不要急着写 $\int H dB$. 真正的问题更基本: 一条路径被分割得越来越细时, 哪些累计量会留下来, 哪些会消失, 哪些会爆炸? 这个问题把普通有限变差路径和 Brown 路径分开, 也解释了为什么随机分析不能只是把普通微积分的符号照搬过来.

总变差: 普通积分能够处理的路径 给定区间 $[0, t]$ 的分割

$$\pi = \{0 = t_0 < t_1 < \cdots < t_n = t\}, \quad |\pi| = \max_k (t_k - t_{k-1}),$$

我们先逐条路径衡量它累计移动了多少.

定义 5.2 (总变差与有限变差).

对实值函数 $x: [0, T] \rightarrow \mathbb{R}$, 定义它在 $[0, t]$ 上的总变差为

$$\mathrm{TV}_t(x) = \sup_{\pi} \sum_{k=1}^n |x(t_k) - x(t_{k-1})|,$$

其中上确界取遍 $[0, t]$ 的所有有限分割. 若 $\mathrm{TV}_T(x) < \infty$, 则称 x 为有限变差函数.

若过程 A 的样本路径以概率 1 在每个有限区间上都具有有限变差, 则称 A 为有限变差过程.

连续有限变差路径可以写成两个单调连续函数之差, 并可作为经典 Lebesgue–Stieltjes 积分的积分器. 绝对连续过程

$$A_t = A_0 + \int_0^t a_s \, ds, \quad \int_0^T |a_s| \, ds < \infty,$$

是最常见的有限变差过程; 有限变差类中也有非绝对连续路径.

二次变差与协变差 有限变差路径之所以好处理, 是因为沿分割累加的一阶绝对增量不会失控. Brown 路径正相反: 分割越细, 绝对增量的总和越大, 普通的 Riemann–Stieltjes 思路在这里失效. 于是我们改看平方增量的累积. 单个增量平方比绝对增量小得多, 却可能在分割变细的极限里留下一个有限的量. 对连续过程 X 和确定性分割 π , 令

$$Q_t^\pi(X) = \sum_{k=1}^n (X_{t_k} - X_{t_{k-1}})^2.$$

若分割还覆盖整个 $[0, T]$, 则在任意 t 处把最后一个区间截断到 t 即可.

定义 5.3 (二次变差).

若对任意确定性分割序列, 当 $|\pi_n| \rightarrow 0$ 时, $Q^{\pi_n}(X)$ 在紧时间区间上一致依概率收敛到一个递增过程, 并且极限不依赖于所取的分割序列, 则把该极限记作

$$[X]_t = \lim_{|\pi| \rightarrow 0} \sum_{t_k \leq t} (X_{t_k} - X_{t_{k-1}})^2,$$

称为 X 的二次变差. 这里“紧时间区间上一致依概率收敛”意为对每个 $t \leq T$, 误差在 $[0, t]$ 上的上确界依概率趋于 0.

任意连续半鞅都具有上述规范二次变差. 对一般连续过程, 极限可能不存在, 也可能依赖分割序列; 因此不能仅凭符号 $[X]$ 就假定它已经定义.

定义 5.4 (协变差).

若 $X, Y, X + Y, X - Y$ 的二次变差均存在, 定义

$$[X, Y]_t = \frac{1}{4}([X + Y]_t - [X - Y]_t).$$

对连续半鞅, 它也等于分割和

$$[X, Y]_t = \lim_{|\pi| \rightarrow 0} \sum_{t_k \leq t} (X_{t_k} - X_{t_{k-1}})(Y_{t_k} - Y_{t_{k-1}})$$

的一致依概率极限.

协变差是双线性的, 且 $[X, X] = [X]$. 它记录两个过程在极小时间尺度上的共同波动. 固定时点随机变量之间的普通协方差 $\text{Cov}(X_t, Y_t)$ 研究另一种对象, 量纲也不同.

命题 5.5 (连续有限变差过程的二次变差).

若 A 连续且在 $[0, T]$ 上有限变差, 则

$$[A]_t = 0, \quad [A, X]_t = 0$$

对任意连续半鞅 X 成立.

证明. 对第一式, 任取趋细分割, 逐条路径有

$$\sum_k |\Delta A_k|^2 \leq \max_k |\Delta A_k| \sum_k |\Delta A_k|.$$

连续性使第一因子趋于 0, 有限变差使第二因子有界, 故平方和趋于 0. 第二式可由极化恒等式与连续半鞅二次变差的存在性得到; 也可对分割和使用 Cauchy-Schwarz 不等式. $\square$

Brown 运动的二次变差

定理 5.6 (Brown 运动的二次变差).

对标准 Brown 运动 B ,

$$[B]_t = t, \quad 0 \leq t \leq T.$$

与此同时, 对每个 $t > 0$, Brown 路径在 $[0, t]$ 上的总变差几乎处处为无穷.

证明. 先固定 t 和确定性分割 π . Brown 增量相互独立, 且 $\Delta B_k \sim \mathcal{N}(0, \Delta t_k)$, 所以

$$\mathbb{E} Q_t^\pi(B) = \sum_k \Delta t_k = t.$$

正态变量的四阶矩给出 $\text{Var}((\Delta B_k)^2) = 2(\Delta t_k)^2$, 故

$$\text{Var}(Q_t^\pi(B)) = 2 \sum_k (\Delta t_k)^2 \leq 2t|\pi| \rightarrow 0.$$

因此平方增量和对每个固定 t 在 L^2 中收敛到 t . 在分割端点上,

$$\sum_{k \leq j} ((\Delta B_k)^2 - \Delta t_k)$$

关于 j 是离散鞅; Doob 最大不等式与上面的方差估计给出端点误差的最大值依概率趋于 0. Brown 路径在 $[0, T]$ 上的一致连续性又控制了每个分割区间内最后一个被截断的增量, 故 $Q^\pi(B)$ 在 $[0, T]$ 上一致依概率收敛到 $s \mapsto s$.

再固定 $t > 0$ 并取 $[0, t]$ 的二进分割 π_n . 此时

$$\text{Var}(Q_t^{\pi_n}(B)) = 2t^2 2^{-n},$$

方差之和有限. Chebyshev 不等式与 Borel-Cantelli 引理因此给出 $Q_t^{\pi_n}(B) \rightarrow t$ 几乎处处. 同时, 任何连续有限变差路径都满足

$$Q_t^{\pi_n}(B) \leq \max_k |\Delta B_k| \text{TV}_t(B) \rightarrow 0.$$

两个极限在 $t > 0$ 时不可能同时成立, 因而 Brown 路径在 $[0, t]$ 上的总变差几乎处处为无穷. $\square$

这解释了随机微积分与普通微积分的分界. Brown 增量的典型尺度为 $|\Delta B| \asymp \sqrt{\Delta t}$, 其一阶绝对增量累积会爆炸, 但平方增量累积恰好留下有限的时间量.

实际价格只能在离散时间点上看到. 图5.2做的是最朴素的一步: 对每个交易日计算相邻两天的对数收益率 r_k , 再把 r_k^2 一项项加到总和里:

$$Q_n = \sum_{k \leq n} r_k^2.$$

于是曲线每天都只会向上走. 波动大的日子, 台阶明显抬高; 安静的日子, 它只是慢慢往上爬. 读到这里, 二次变差就不再只是一个极限符号: 它是一种沿着观察网格给路径波动记账的方法.




图 5.2: AAPL 日线网格上的累计平方对数收益率 (2019–2021). 相邻日增量平方后逐步累加, 得到经验二次变差的离散近似. 数据来源见引用文献 [Yaha; Yahc].

连续局部鞅与半鞅 到这里, Brown 运动已经告诉我们: 好的积分器未必有有限变差, 但它的二次变差仍可能有清楚结构. 实际日线图也提醒我们: 只要换观察网格, 平方增量的累计就会变成一个需要认真定义的对象. 接下来引入局部鞅和半鞅, 不是为了多加一个抽象名词, 而是为了找到一类足够宽, 又还能稳定做积分和括号计算的路径. 在金融语言里, 半鞅把可累计的漂移或成本, 和不可提前预测的波动, 放进同一个价格过程框架.

局部鞅把鞅计算限制在一列逐渐扩大的随机时间区间内, 随后再判断局部结论能否延伸到整个期限. 半鞅将有限变差的累计变化与局部鞅型波动合在一个过程里. Itô 积分和后面的金融增益在这一过程类上具有稳定的极限理论. 首次阅读若只关心 Brown 积分, 可以先记住 $X = X_0 + M + A$ 这一结构, 再在需要一般接口时回来补足定义.

定义 5.7 (局部鞅).

定义在 $[0, T]$ 上的适应 càdlàg 过程 M 称为局部鞅, 如果存在一列递增停时 $\tau_n \leq T$, 满足 $\mathbb{P}(\tau_n = T) \rightarrow 1$, 并使停止过程 $M^{\tau_n} = (M_{t \wedge \tau_n})_{0 \leq t \leq T}$ 对每个 n 都是鞅. 这列停时称为局部化序列. 等价地, 可以把过程在 T 后停止, 再使用趋于无穷的局部化序列.

局部鞅只在逐步扩大的随机时间区间内具备鞅所需的可积性. 非负局部鞅必为超鞅, 仍可能不是真鞅; 这一差别会在密度过程处再次出现.

定义 5.8 (半鞅).

适应的右连续有左极限过程 X 称为半鞅, 如果它可以写成

$$X_t = X_0 + M_t + A_t,$$

其中 $M_0 = A_0 = 0$, M 是局部鞅, A 是有限变差过程. 若 X, M, A 都连续, 则称 X 为连续半鞅.

Brown 运动, 有限变差过程以及后文标准条件下 SDE 的解都是半鞅. 半鞅是随机积分最稳定的积分器类别: 适当的可预测被积过程积分后仍保留良好的极限性质. 这一刻画的深层逆命题通常称为 Bichteler–Dellacherie 定理; 这里仅使用上述正向结构.

定理 5.9 (连续半鞅的二次变差只来自局部鞅部分).

若

$$X = X_0 + M + A, \quad Y = Y_0 + N + C$$

是连续半鞅分解, 其中 M, N 为连续局部鞅, A, C 为连续有限变差过程, 则

$$[X, Y] = [M, N], \quad [X] = [M].$$

特别地, 存在唯一从 0 出发的连续递增适应过程 $[M]$ 使 $M^2 - [M]$ 为局部鞅.

这里的严格构造先从连续局部鞅开始. Kallenberg 的 Theorem 18.5 构造 $[M, N]$, 并用 $MN - [M, N]$ 为局部鞅这一性质刻画其唯一性 [Kal21, Theorem 18.5]. 若有两个候选括号, 它们的差同时是局部鞅和连续有限变差过程, 因而只能是从 0 出发的常数过程. 从局部鞅推广到连续半鞅还需要一个路径层面的事实: 对任意连续有限变差过程 A 和连续过程 X , 分割和中的交叉项满足

$$\left| \sum_k \Delta A_k \Delta X_k \right| \leq \max_k |\Delta X_k| \text{Var}_{[0,t]}(A) \rightarrow 0.$$

结合括号的分割逼近 [Kal21, Proposition 18.17], 便得到有限变差部分不贡献二次变差或协变差, 从而 $[X, Y] = [M, N]$.

定理的最后一句也给出了连续局部鞅二次变差的内在刻画. 若

$$X_t = X_0 + \int_0^t a_s \, ds + \int_0^t b_s \, dB_s, \quad Y_t = Y_0 + \int_0^t c_s \, ds + \int_0^t d_s \, dB_s,$$

则后文的积分理论将给出

$$[X]_t = \int_0^t b_s^2 \, ds, \quad [X, Y]_t = \int_0^t b_s d_s \, ds.$$

对于带跳半鞅, 记 $\Delta X_s = X_s - X_{s-}$, 则

$$[X]_t = [X^c]_t + \sum_{0 < s \leq t} (\Delta X_s)^2,$$

其中 X^c 表示连续局部鞅部分所贡献的连续二次变差. 跳跃平方不能被忽略. 正文主体只处理连续情形, 跳跃公式在章末给出接口.

注 5.10 (半鞅之外的随机路径).

某些连续过程落在半鞅类之外. 例如 Hurst 指数不等于 $1/2$ 的分数 Brown 运动一般不属于半鞅, 不能直接套用这里的 Itô 积分. 它们可能需要 Young 积分, 粗糙路径或 Skorokhod 积分; 这些理论的积分含义彼此不同.

5.3 从简单过程构造 Itô 积分

先从分段持仓开始 第5.2节已经找到了合适的积分器: Brown 路径虽有无穷总变差, 但平方增量有稳定累计. 现在轮到被积过程 H . 读者可以先把 H 想成一条持仓规则: 在 $(t_k, t_{k+1}]$ 这段时间里持有多少风险暴露, 到区间结束时得到多少随机收益.

最容易写清楚的持仓规则是分段常数规则. 在 t_k 时刻先决定 ξ_k , 随后整段 $(t_k, t_{k+1}]$ 都持有这个数, 本段收益就是

$$\xi_k (B_{t_{k+1}} - B_{t_k}).$$

这一步把随机积分先变成一张有限求和账本: 每一项都是“已经决定的持仓”乘以“随后发生的 Brown 增量”. 简单可预测过程正是这张账本的数学写法.

定义 5.11 (简单可预测过程).

给定确定性分割 $0 = t_0 < \cdots < t_n = T$, 若

$$H_t = \sum_{k=0}^{n-1} \xi_k \mathbf{1}_{(t_k, t_{k+1}]}(t),$$

其中 ξ_k 是 $\mathcal{F}_{t_k}$ -可测且平方可积的随机变量, 则称 H 为平方可积的简单可预测过程.

ξ_k 在区间开始时已经确定, 因而没有使用该区间尚未发生的噪声. 这一点保留了 Brown 增量的条件均值为零, 也保留了积分作为随机收益时应有的鞅结构. 更一般的可预测过程以后用极限得到; 简单可预测过程是先能算清楚, 再能用来逼近的脚手架.

定义 5.12 (简单过程的 Itô 积分).

对上述 H , 定义

$$\int_0^t H_s dB_s = \sum_{k=0}^{n-1} \xi_k (B_{t \wedge t_{k+1}} - B_{t \wedge t_k}), \quad 0 \leq t \leq T.$$

这个定义先完成离散求和, 再把所得随机变量视为关于 t 的连续过程. 随后的推广在 $L^2(\mathbb{P})$ 中取极限; 经典 Riemann–Stieltjes 积分采用的则是逐路径构造.

Itô 等距与平方可积延拓 从简单过程往一般过程走, 需要一把判断“两个被积过程足够接近”的尺子. Itô 等距给出的正是这把尺子: 积分结果的平方均值, 等于被积过程平方后沿时间累计的均值. 因此只要 H 的能量

$$\mathbb{E} \int_0^T H_s^2 ds$$

有限, 就可以用简单持仓去逼近它, 并且不同逼近方式会落到同一个积分.

定理 5.13 (Itô 等距).

对任意平方可积简单可预测过程 H ,

$$\mathbb{E} \left[\left(\int_0^T H_s dB_s \right)^2 \right] = \mathbb{E} \left[\int_0^T H_s^2 ds \right].$$

并且 $\mathbb{E}[\int_0^T H_s dB_s] = 0$.

证明. 写 $\Delta B_k = B_{t_{k+1}} - B_{t_k}$. 展开平方后, 对角项满足

$$\mathbb{E}[\xi_k^2 (\Delta B_k)^2] = \mathbb{E}[\xi_k^2] \Delta t_k,$$

因为 ξ_k 关于 $\mathcal{F}_{t_k}$ 可测, 而 ΔB_k 独立于 $\mathcal{F}_{t_k}$. 若 $k < \ell$, 则在 $\mathcal{F}_{t_\ell}$ 下取条件期望, ΔB_ℓ 的条件均值为 0, 故所有交叉项期望均为 0. 于是

$$\mathbb{E} \left[\left(\sum_k \xi_k \Delta B_k \right)^2 \right] = \sum_k \mathbb{E}[\xi_k^2] \Delta t_k = \mathbb{E} \int_0^T H_s^2 ds.$$

对一次方使用同样的条件期望即可得到均值为 0. □

令

$$\mathcal{H}^2 = \left\{ H \text{ 可预测} : \mathbb{E} \int_0^T H_s^2 ds < \infty \right\}, \quad \|H\|_{\mathcal{H}^2}^2 = \mathbb{E} \int_0^T H_s^2 ds.$$

这里把范数为零的过程视为同一个等价类. 这个空间收集的正是可以用上面那把尺子控制的被积过程.

定理 5.14 (L^2 延拓).

对每个 $H \in \mathcal{H}^2$, 存在简单可预测过程 $H^{(n)}$ 使 $\|H^{(n)} - H\|_{\mathcal{H}^2} \rightarrow 0$. 定义

$$\int_0^T H_s dB_s = L^2(\mathbb{P})\text{-}\lim_{n \rightarrow \infty} \int_0^T H_s^{(n)} dB_s.$$

该极限与逼近序列无关, 仍满足 Itô 等距. 积分过程

$$I_t = \int_0^t H_s dB_s$$

具有连续平方可积鞅版本, 并且

$$[I]_t = \int_0^t H_s^2 ds.$$

证明. 简单可预测过程的稠密性是关于乘积测度 $\mathbb{P} \otimes dt$ 的标准逼近结论. 由 Itô 等距,

$$\mathbb{E} \left| \int_0^T (H_s^{(n)} - H_s^{(m)}) dB_s \right|^2 = \|H^{(n)} - H^{(m)}\|_{\mathcal{H}^2}^2,$$

因而积分序列在完备空间 $L^2(\mathbb{P})$ 中为 Cauchy 列. 等距同时说明不同逼近序列给出同一极限. 简单过程的相应性质配合 Doob 最大不等式, 控制整个时间区间上的逼近误差并选出连续版本, 由此得到鞅性和二次变差结论. $\square$

若 H 只满足

$$\int_0^T H_s^2 ds < \infty \quad \text{a.s.},$$

则每条路径上的累计能量仍是有限的, 期望层面的控制可能变弱. 处理方法是先在累计平方达到 n 时停止, 在每个停止后的有限能量世界里构造积分, 再令 $n \rightarrow \infty$. 由此得到连续局部鞅 $\int H dB$. 局部化把平方可积鞅的构造扩展到局部鞅.

对连续半鞅积分 Brown 积分处理的是纯噪声部分. 价格过程或状态过程通常还带有可累计的漂移, 利息, 费用或控制项. 这正是上一节引入半鞅分解的用处: 把路径拆成局部鞅型波动 M 和有限变差累计项 A , 然后分别使用随机积分和普通路径积分.

若 $X = X_0 + M + A$ 是连续半鞅, 则在相应局部可积条件下定义

$$\int_0^t H_s dX_s = \int_0^t H_s dM_s + \int_0^t H_s dA_s.$$

第一项是局部鞅积分, 第二项是逐条路径的 Lebesgue–Stieltjes 积分. 这两类积分合在一起, 使同一个记号能够同时记录普通累计量和 Brown 噪声收益.

注 5.15 (一般半鞅积分的引用范围).

这一段给出一般半鞅积分的接口. Brown 的 L^2 构造先让读者看清一维连续噪声上的积分; 完整半鞅理论进一步告诉我们: 每个适应的 càdlàg 半鞅 X 都带有一类可预测被积过程 $L(X)$. 这里的 $L(X)$ 表示“对 X 可积”, 第4.2节的 $\mathcal{L}(X)$ 表示过程的律, 二者用途不同. 本书把

$$H \in L(X) \quad \longmapsto \quad (H \cdot X)_t := \int_0^t H_u dX_u$$

作为已有的标准结果引用. 第4.7节中的 Brown 构造提供直觉和基本样板, 完整理论则保证这套积分能在一般半鞅上稳定工作. 这个积分由 X 本身决定, 不依赖于选取哪一个半鞅分解.

若 $X = X_0 + M + A$ 且右侧各项均有定义, 则

$$H \cdot X = H \cdot M + H \cdot A.$$

在跳时 t , 约定

$$\Delta(H \cdot X)_t = H_t \Delta X_t.$$

这里 H 的可预测性表示 H_t 是跳跃发生前已经确定的持仓. 如果头寸另以适应的 càdlàg 过程 $\bar{H}$ 记录, 实际积分器前的持仓写成 $H_t = \bar{H}_{t-}$. 首次阅读可以只考虑连续 X , 此时不涉及跳前值约定.

原则 5.16 (随机微分是积分等式的简写).

读到下面这类记号时,

$$dX_t = a_t dt + b_t dB_t, \quad X_0 = x,$$

的严格含义是

$$X_t = x + \int_0^t a_s ds + \int_0^t b_s dB_s, \quad 0 \leq t \leq T.$$

这类微分记号的作用是压缩书写. 真正参与定义和证明的是右侧两类积分, 所以后面的形式运算都要能翻译回这条积分等式.

稍后出现的助记规则

$$(dB_t)^2 = dt, \quad dt dB_t = 0, \quad (dt)^2 = 0$$

应理解为二次变差阶数的编码. 使用这些助记规则时, 最后仍回到积分等式核算每一项.

5.4 Itô 公式, 乘积公式与随机指数

Itô 积分有了定义以后, 下一个自然问题是怎样对随机过程做变量替换. 若 X 是价格, 利率或状态变量, 实际计算经常关心 $\log X$, X^2 , e^X 或某个价值函数 $u(t, X_t)$. 普通链式法则只记一阶增量; Brown 型路径的平方增量会留下累计量, 所以函数变换后会多出一个二阶修正项. Itô 公式就是随机分析中的链式法则.

一维 Itô 公式 考虑 Itô 过程

$$X_t = X_0 + \int_0^t a_s ds + \int_0^t b_s dB_s,$$

其中 a, b 渐进可测, 并且 $\int_0^T (|a_s| + b_s^2) ds < \infty$ 几乎处处成立.

定理 5.17 (一维 Itô 公式).

若 $f \in C^{1,2}([0, T] \times \mathbb{R})$, 则

$$\begin{aligned} f(t, X_t) = f(0, X_0) &+ \int_0^t \left(\partial_s f(s, X_s) + a_s \partial_x f(s, X_s) + \frac{1}{2} b_s^2 \partial_{xx} f(s, X_s) \right) ds \\ &+ \int_0^t b_s \partial_x f(s, X_s) dB_s, \end{aligned}$$

只要各项通过局部化或可积性条件得到良好定义.

空间变量上的严格依据是连续半鞅的代换公式 [Kal21, Theorem 18.18]. 时间变量由普通有限变差链式法则处理, 再把 $d[X]_t = b_t^2 dt$ 代入空间公式, 便得到上面的 $C^{1,2}$ 版本. Durrett 的

Theorem 7.6.5 给出时间与一维 Brown 运动的对应公式, Theorem 7.6.7 给出多维 Brown 运动版本 [Dur19, Theorem 7.6.5, Theorem 7.6.7].

下面的 Taylor 展开用于观察二阶项的来源. 对小区间,

$$\Delta X \approx a \Delta t + b \Delta B.$$

一阶项保留 $a\Delta t + b\Delta B$; 二阶项中 $(\Delta B)^2$ 的累计极限是 Δt , 而 $(\Delta t)^2$ 与 $\Delta t\Delta B$ 的累计极限为 0. 因此 Taylor 展开中的 $\frac{1}{2}f_{xx}(\Delta X)^2$ 留下 $\frac{1}{2}f_{xx}b^2\Delta t$. 严格证明还要先局部化到紧集, 控制 Taylor 余项, 证明平方增量和与交叉增量和的概率极限, 并验证随机积分项的收敛. Kallenberg 的证明采取另一条等价而更稳健的路线: 先由乘积公式证明多项式情形, 再同时逼近 f, f' 和 f'' , 最后分别用有限变差积分的控制与随机积分的收敛定理通过极限 [Kal21, proof of Theorem 18.18]. 这段 Taylor 计算的作用是把二阶项的来源放在眼前; 真正的定理证明由上述局部化, 余项控制和积分收敛完成.

完整例一: Brown 运动的平方 取 $X_t = B_t$ 和 $f(x) = x^2$. 因为 $f'(x) = 2x, f''(x) = 2$, Itô 公式直接给出

$$B_t^2 = 2 \int_0^t B_s dB_s + t.$$

也就是

$$\int_0^t B_s dB_s = \frac{1}{2}(B_t^2 - t),$$

若套用普通微积分的链式法则, $B_t^2/2$ 会漏掉修正项 $-t/2$. 由于随机积分的期望为 0, 还得到 $\mathbb{E}[B_t^2] = t$, 以及 $B_t^2 - t$ 是鞅.

完整例二: 指数与随机指数 取 $f(x) = e^{\lambda x}$, 其中 $\lambda \in \mathbb{R}$. 则

$$e^{\lambda B_t} = 1 + \lambda \int_0^t e^{\lambda B_s} dB_s + \frac{\lambda^2}{2} \int_0^t e^{\lambda B_s} ds.$$

为抵消最后的漂移项, 令

$$Z_t = \exp\left(\lambda B_t - \frac{1}{2}\lambda^2 t\right).$$

对 $f(t, x) = \exp(\lambda x - \lambda^2 t/2)$ 使用 Itô 公式, 得到

$$Z_t = 1 + \int_0^t \lambda Z_s dB_s, \quad dZ_t = \lambda Z_t dB_t.$$

Z 在有限期限内是真鞅, 且 $\mathbb{E}Z_t = 1$.

更一般地, 若 M 是从 0 出发的连续局部鞅, 定义它的 **Doléans 随机指数**

$$\mathcal{E}(M)_t = \exp\left(M_t - \frac{1}{2}[M]_t\right).$$

由 Itô 公式,

$$\mathcal{E}(M)_t = 1 + \int_0^t \mathcal{E}(M)_s dM_s.$$

它严格为正且为局部鞅, 但可能不是真鞅. Girsanov 变换还须确认这个局部鞅没有损失期望.

完整例三: 几何 Brown 运动与对数修正 给定常数 $\mu, \sigma \in \mathbb{R}$ 和 $S_0 > 0$, 考虑积分方程

$$S_t = S_0 + \int_0^t \mu S_s ds + \int_0^t \sigma S_s dB_s.$$

猜测并定义

$$S_t = S_0 \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma B_t\right).$$

对右侧指数函数使用 Itô 公式, 其时间项, 一次噪声项和二阶修正项分别为

$$\left(\mu - \frac{1}{2}\sigma^2\right) S_t dt, \quad \sigma S_t dB_t, \quad \frac{1}{2}\sigma^2 S_t dt.$$

前后两个时间项合并为 $\mu S_t dt$, 故它确实满足原积分方程.

反过来, 因为 $S_t > 0$, 对 $f(x) = \log x$ 使用 Itô 公式得到

$$d \log S_t = \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dB_t,$$

即

$$\log \frac{S_t}{S_0} = \left(\mu - \frac{1}{2}\sigma^2\right) t + \sigma B_t.$$

因此指数中的漂移为 $\mu - \sigma^2/2$, 与 μ 相差 $\sigma^2/2$. 这个差额来自二次变差, 无须另加经济假设.

多维 Itô 公式 一维公式说明二次变差会进入链式法则. 多个状态变量同时变化时, 还要记录不同坐标在同一瞬间怎样一起波动. 这就是协变差进入公式的地方: 如果两个坐标由同一组 Brown 风险源驱动, 函数的混合二阶导数也会参与漂移修正.

定义 5.18 (m 维标准 Brown 运动).

在固定滤过概率空间上, $\mathbb{R}^m$ -值过程 $W = (W^1, \dots, W^m)$ 称为关于该滤过的 m 维标准 Brown 运动, 如果 $W_0 = 0$ a.s., W 适应且路径几乎必然连续, 并且对每个 $0 \leq s < t$, 向量增量 $W_t - W_s$ 与 $\mathcal{F}_s$ 独立且满足

$$W_t - W_s \sim \mathcal{N}(0, (t-s)I_m).$$

这个定义特别推出各坐标是相互独立的一维标准 Brown 运动. 对 $j, k \in \{1, \dots, m\}$,

$$[W^j, W^k]_t = \delta_{jk}t, \quad dW_t^j dW_t^k = \delta_{jk} dt,$$

其中 δ_{jk} 是 Kronecker delta. 第二个等式是第一个等式的微分助记法.

对上述 W , 令 $X = (X^1, \dots, X^d)$ 满足

$$dX_t^i = b_i(t, X_t) dt + \sum_{j=1}^m \sigma_{ij}(t, X_t) dW_t^j, \quad i = 1, \dots, d.$$

记 $a = \sigma\sigma^\top$, 于是

$$d[X^i, X^k]_t = a_{ik}(t, X_t) dt.$$

定理 5.19 (多维 Itô 公式).

若 $f \in C^{1,2}([0, T] \times \mathbb{R}^d)$, 则

$$\begin{aligned} df(t, X_t) = & \left(\partial_t f + \sum_{i=1}^d b_i \partial_i f + \frac{1}{2} \sum_{i,k=1}^d a_{ik} \partial_{ik} f \right) (t, X_t) dt \\ & + \sum_{j=1}^m \left(\sum_{i=1}^d \sigma_{ij} \partial_i f \right) (t, X_t) dW_t^j. \end{aligned}$$

该微分式表示把两边从 0 积分到 t 所得到的积分等式.

混合二阶导数出现, 是因为不同坐标之间可能具有非零协变差. 即使 W 的坐标相互独立, 矩阵 σ 也可能使 X 的坐标在瞬时尺度上相关.

乘积公式与分部积分 乘积公式处理的是另一个常见动作：把两个随机量相乘，例如密度过程乘以价格过程，贴现因子乘以收益，或两个风险暴露的乘积。普通分部积分会少看二阶共同波动；随机分部积分把这部分单独记成协变差 $[X, Y]$ 。后面的 Girsanov 变换和 Feynman–Kac 推导都会用到这一步。

命题 5.20 (连续半鞅乘积公式).

若 X, Y 为连续半鞅，则

$$X_t Y_t = X_0 Y_0 + \int_0^t X_s dY_s + \int_0^t Y_s dX_s + [X, Y]_t.$$

形式上可写成

$$d(X_t Y_t) = X_t dY_t + Y_t dX_t + d[X, Y]_t.$$

该公式的严格出处是 Kallenberg 的 Theorem 18.16 [Kal21, Theorem 18.16]。证明先处理平方公式，再用极化恒等式得到一般的 X, Y ；局部鞅部分依赖括号构造和随机积分逼近，有限变差部分则退化为普通 Lebesgue–Stieltjes 分部积分。

普通分部积分没有最后一项，因为两个有限变差连续过程的协变差为零。随机分部积分多出的 $[X, Y]$ 记录了粗糙路径在二阶尺度上留下的信息。

5.5 随机微分方程：解的含义与基本模型

第5.3节和第5.4节已经说明怎样对给定过程做 Itô 计算。随机微分方程把方向反过来：先给出一条局部演化规则，说明当前位置下平均往哪里走，噪声强度有多大，再问是否真的存在一条适应路径按这条规则运动。这里的困难在于系数常常依赖 X_t 本身：路径还没造出来，方程已经在引用路径。所以先把“ dX_t ”翻译成积分等式，再问这条等式什么时候有解，解又由什么随机源决定。

先写积分形式 考虑 d 维状态， m 维 Brown 噪声的方程

$$dX_t = b(t, X_t) dt + \sigma(t, X_t) dW_t, \quad X_0 = \xi.$$

其中 $b: [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$, $\sigma: [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^{d \times m}$ 均为 Borel 可测函数。

定义 5.21 (SDE 的解).

一个连续适应过程 X 是上述 SDE 的解，如果对每个 $t \leq T$ ，几乎处处有

$$X_t = \xi + \int_0^t b(s, X_s) ds + \int_0^t \sigma(s, X_s) dW_s,$$

且两个积分均良好定义。所谓满足 SDE，始终是指满足这条积分等式。

强解，弱解与两类唯一性 解的存在问题还要说明它生活在哪个随机世界里。可以把 Brown 路径想成一盘已经给定的噪声磁带。强解问的是：给定初值和这盘噪声以后，解是否已经由它们决定。弱解问的是：能否搭出某个概率空间，某个 Brown 运动和某条过程路径，让积分方程成立。唯一性也分两层：路径唯一性比较同一盘噪声驱动的两条候选路径，分布唯一性比较不同构造得到的完整路径分布。

定义 5.22 (强解与弱解).

强解问题预先给定概率空间，滤过，Brown 运动 W 和初值 ξ ，并要求解 X_t 适应于

$$\mathcal{G}_t = \sigma(\xi, W_s : 0 \leq s \leq t)$$

的完备化滤过。因此， X 由初值和已经观察到的 Brown 运动路径的可测函数给出。若工作空间给定了更大的滤过，“强解”仍指这一可测函数表示；单纯适应于较大的滤过还没有说明解由原噪声生成。

弱解问题只给定系数和初始分布, 允许把概率空间, 滤过, Brown 运动和过程 X 一并构造, 只要求所得对象满足积分等式和规定的分布条件.

名称里的强弱只描述构造信息量.

定义 5.23 (路径唯一性与分布唯一性).

若定义在同一滤过概率空间, 由同一个 W 驱动且具有同一初值的任意两个解 X, Y 都不可区分, 则称该 SDE 具有**路径唯一性**.

若任意两个弱解作为路径空间随机元素具有相同分布, 则称该 SDE 具有**分布唯一性**或**依分布唯一性**.

路径唯一性比较同一个噪声实现下的两条解; 分布唯一性比较解的概率律. 两者的比较对象不同. Yamada–Watanabe 定理说明: 在标准 Brown 运动驱动的 SDE 框架中, 弱存在性加路径唯一性可以推出强存在性, 并带来分布唯一性; 精确的函数表示与任意初始分布版本见 [Kal21, Theorem 32.14]. 这里三项一起工作: 弱存在性提供可实现的解, 路径唯一性锁定同一噪声下的路径, 标准 Brown 驱动框架提供从弱解回到强解的结构.

全局 Lipschitz 与线性增长条件 知道了解的含义以后, 还需要一组可检查的条件来保证方程真的生成了一条路径. 全局 Lipschitz 条件控制两条候选路径不会越走越分开; 线性增长条件控制路径在有限时间内不会被系数推到无穷远. 这两条条件合在一起, 给出最常用的一阶存在唯一性定理.

定理 5.24 (强解的存在唯一性).

假设存在常数 $L, K < \infty$, 使对所有 $t \in [0, T]$ 和 $x, y \in \mathbb{R}^d$,

$$|b(t, x) - b(t, y)| + \|\sigma(t, x) - \sigma(t, y)\| \leq L|x - y|,$$

且

$$|b(t, x)|^2 + \|\sigma(t, x)\|^2 \leq K(1 + |x|^2).$$

若 ξ 是 $\mathcal{F}_0$ -可测且 $\xi \in L^2$, 则 SDE 在 $[0, T]$ 上存在唯一强解, 并且

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |X_t|^2 \right] < \infty.$$

证明以 Picard 迭代构造近似解, 利用 Itô 等距和最大不等式建立相邻迭代的可积性与一致收敛估计, 再用 Gronwall 不等式得到收敛与路径唯一性. Kallenberg 的 Theorem 32.3 先在有界且 Lipschitz 的渐进系数下完成这一构造; 对这里的时空系数, 可先用空间截断得到该情形, 再由路径唯一性拼接停止前的解. 线性增长估计与 Gronwall 不等式排除截断半径趋于无穷时的爆炸, 并给出上面的 L^2 最大矩估计. 这一证明依赖链见 [Kal21, Theorem 32.3, Proposition 32.6].

线性增长控制解在有限时间内不爆炸, 全局 Lipschitz 控制两个初值或两条候选解的偏离. 局部 Lipschitz 配合适当 Lyapunov 条件也可得到更一般结论, 但必须另外排除爆炸.

几何 Brown 运动 接下来三个例子各承担一个角色: 几何 Brown 运动展示乘法噪声和对数修正; OU 过程展示线性均值回复; CIR 型平方根扩散展示边界行为怎样由系数形状决定.

第5.4节已经验证

$$dS_t = \mu S_t dt + \sigma S_t dB_t, \quad S_0 > 0,$$

的解为

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma B_t \right).$$

系数 $b(x) = \mu x$, $\sigma(x) = \sigma x$ 满足全局 Lipschitz 与线性增长条件, 所以验证出的解也是唯一强解. 严格正性则由指数表示直接给出; 一般存在唯一性定理没有这一附加结论.

Ornstein–Uhlenbeck 过程 OU 过程把漂移写成回到中心 θ 的拉力, 噪声则不断加入新的 Brown 冲击. 它是线性 SDE, 因而可以用积分因子直接解出整条路径.

令 $\kappa > 0, \theta \in \mathbb{R}, \sigma \geq 0$, 考虑

$$dX_t = \kappa(\theta - X_t) dt + \sigma dB_t.$$

对 $e^{\kappa t} X_t$ 使用乘积公式. 由于 $e^{\kappa t}$ 是有限变差函数, 它与 X 的协变差为零, 于是

$$d(e^{\kappa t} X_t) = \kappa \theta e^{\kappa t} dt + \sigma e^{\kappa t} dB_t.$$

从 0 积分到 t 并整理, 得到

$$X_t = \theta + (X_0 - \theta)e^{-\kappa t} + \sigma \int_0^t e^{-\kappa(t-s)} dB_s.$$

若 $0 \leq s < t$, 则在给定 $\mathcal{F}_s$ 后,

$$\mathbb{E}[X_t | \mathcal{F}_s] = \theta + (X_s - \theta)e^{-\kappa(t-s)},$$

且条件方差为

$$\text{Var}(X_t | \mathcal{F}_s) = \frac{\sigma^2}{2\kappa} (1 - e^{-2\kappa(t-s)}).$$

若把初值取成 $\mathcal{N}(\theta, \sigma^2/(2\kappa))$ 且独立于 Brown 运动的未来增量, 则过程具有该不变分布. 均值回到 θ 是这个数学方程的性质; 具体应用中 θ 是否可识别, 是否稳定, 仍是模型问题.

CIR 型平方根扩散与零点行为 CIR 型扩散保留均值回复, 但让噪声强度随 $\sqrt{X_t}$ 变化. 这样做会把 0 变成真正需要讨论的边界: 靠近 0 时噪声变弱, 漂移又可能把过程推回正半轴.

令 $\kappa, \theta, \sigma > 0$, 考虑

$$dX_t = \kappa(\theta - X_t) dt + \sigma \sqrt{X_t} dB_t, \quad X_0 \geq 0.$$

扩散系数 $x \mapsto \sqrt{x}$ 在 0 附近不满足 Lipschitz 条件, 上一条全局 Lipschitz 定理管不到这个边界点. 利用一维 SDE 的专门比较与唯一性理论, 可以证明它存在唯一非负强解; 后面的讨论以这一专门结论为前提.

边界行为取决于 Feller 条件:

1. 若 $2\kappa\theta \geq \sigma^2$ 且 $X_0 > 0$, 则 0 几乎处处不可达, 解保持严格为正;
2. 若 $0 < 2\kappa\theta < \sigma^2$, 则 0 可以被到达, 但标准非负解不会穿入负半轴, 并在正漂移作用下瞬时离开边界;
3. 若把参数范围扩展到 $\theta = 0$, 则 0 成为吸收边界, 边界读法随之改变.

因此, 平方根扩散是否严格为正要看参数所在的情形. 普通 Euler 离散还可能产生负的数值步长; 这是离散算法与连续真解之间的额外问题, 通常要用保正格式或精确转移方法处理.

5.6 Girsanov 定理: 在有限期限内改变概率权重

第5.5节给出的是某个概率测度下的漂移和噪声. 有时我们希望换一种读法: 样本路径仍是同一批路径, 但路径权重改变以后, 原来写在漂移里的某一部分可以被并入新的 Brown 运动. Girsanov 定理处理的正是这种“同路不同权重”.

这个操作分两步. 第一步要造出一个总质量等于 1 的密度过程, 让重新加权后的总概率仍等于 1. 第二步再检查在新权重下哪个过程具有 Brown 运动的增量结构. Novikov 条件服务于第一步, Girsanov 定理本身完成第二步.

密度过程与 Novikov 条件 令 $\vartheta = (\vartheta_t)_{0 \leq t \leq T}$ 为可预测过程, 满足 $\int_0^T \vartheta_s^2 ds < \infty$ 几乎处处. 考虑随机指数

$$Z_t = \mathcal{E} \left(- \int_0^t \vartheta_s dB_s \right)_t = \exp \left(- \int_0^t \vartheta_s dB_s - \frac{1}{2} \int_0^t \vartheta_s^2 ds \right).$$

Z 总是正的局部鞅, 因而是超鞅; 但若要用 Z_T 定义概率测度, 还要有 $\mathbb{E}_{\mathbb{P}}[Z_T] = 1$.

定理 5.25 (Novikov 充分条件).

若

$$\mathbb{E}_{\mathbb{P}} \left[\exp \left(\frac{1}{2} \int_0^T \vartheta_s^2 ds \right) \right] < \infty,$$

则 Z 是 $[0, T]$ 上的一致可积鞅, 特别地 $\mathbb{E}_{\mathbb{P}}[Z_T] = 1$.

这是 Kallenberg 的 Novikov 判据应用于停止在 T 的连续局部鞅

$$M_t = - \int_0^{t \wedge T} \vartheta_s dB_s, \quad [M]_{\infty} = \int_0^T \vartheta_s^2 ds$$

所得的有限期限版本 [Kal21, Theorem 19.24]. 证明利用指数矩条件保证 $\mathcal{E}(M)$ 没有损失期望; 在此之后 $Z_t = \mathbb{E}_{\mathbb{P}}[Z_T | \mathcal{F}_t]$ 才能成立.

Novikov 条件是一条方便的真鞅检查. 条件成立时, Z_T 可以作为概率密度使用. 有些不满足 Novikov 条件的过程仍可能是真鞅; 反过来, 若只知道 Z 是局部鞅且 $\mathbb{E}Z_T < 1$, 那么 $Z_T d\mathbb{P}$ 的总质量小于 1, 得到的是次概率权重, 尚未得到新的概率测度.

Girsanov 定理及符号检查 密度过程准备好以后, 接下来要看 Brown 噪声怎样改名. 下面的符号约定先固定好: 漂移调整写进 ϑ , 新的 Brown 运动记为 $B^{\mathbb{Q}}$.

定理 5.26 (一维 Girsanov 定理).

假设上文定义的 Z 为真鞅, 并在 $\mathcal{F}_T$ 上定义

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = Z_T.$$

则 $\mathbb{Q}$ 与 $\mathbb{P}$ 在 $\mathcal{F}_T$ 上等价, 且

$$B_t^{\mathbb{Q}} = B_t + \int_0^t \vartheta_s ds$$

是 $\mathbb{Q}$ 下的标准 Brown 运动.

严格证明先用密度过程下的 Bayes 公式和随机分部积分, 把连续 $\mathbb{P}$ -局部鞅 M 变为 $M - Z^{-1} \cdot [M, Z]$ 这一 $\mathbb{Q}$ -局部鞅; 再验证二次变差保持为 t , 最后使用 Brown 运动的鞅刻画. 这条依赖链见 Kallenberg 的 Girsanov 变换定理与漂移消去推论 [Kal21, Theorem 19.20, Corollary 19.26]. Kallenberg 的推论采用 $Z = \mathcal{E}(V \cdot B)$ 和 $\bar{B} = B - \int V ds$ 的符号; 这里取 $V = -\vartheta$, 因而得到 $B^{\mathbb{Q}} = B + \int \vartheta ds$.

因为 Z 是真鞅, 对每个 $t \leq T$ 还有

$$Z_t = \mathbb{E}_{\mathbb{P}}[Z_T | \mathcal{F}_t] = \frac{d\mathbb{Q}}{d\mathbb{P}} \Big|_{\mathcal{F}_t},$$

因此 Z 在整个期限上都是密度过程, 终端密度只是它在 T 时刻的取值.

这个符号可以用代回原 SDE 的方式检查. 若在 $\mathbb{P}$ 下

$$dX_t = b_t dt + \sigma_t dB_t,$$

由于 $dB_t = dB_t^{\mathbb{Q}} - \vartheta_t dt$, 同一坐标过程满足

$$dX_t = (b_t - \sigma_t \vartheta_t) dt + \sigma_t dB_t^{\mathbb{Q}}$$

的 $\mathbb{Q}$ -下积分等式. 若希望消去原漂移 b_t , 且 $\sigma_t \neq 0$, 形式上应选 $\vartheta_t = b_t/\sigma_t$, 随后仍要检查可预测性, 平方可积性和密度真鞅条件.

例 5.27 (带常漂移的 Brown 运动).

在 $\mathbb{P}$ 下令 $X_t = B_t + \mu t$, 并取

$$Z_t = \exp\left(-\mu B_t - \frac{1}{2}\mu^2 t\right).$$

由于被积过程是有限期限上的常数, Novikov 条件成立. 在由 Z_T 定义的 $\mathbb{Q}$ 下, $B_t^{\mathbb{Q}} = B_t + \mu t = X_t$ 是标准 Brown 运动. 随机变量 $X_t(\omega)$ 作为路径上的坐标值没有被重写; 改变的是各条路径的概率权重.

原则 5.28 (改变测度与保留路径).

Girsanov 定理在同一个可测路径空间上, 用 Radon–Nikodym 密度把 $\mathbb{P}$ 改成 $\mathbb{Q}$. 同一个 ω 对应的坐标路径保持不变, 但不同路径的概率权重改变, 因而, “减去漂移后的过程是 Brown 运动” 这一分布陈述随测度改变. 每条实现路径在这一操作中都保持原位.

多维情形把 ϑ 改成向量, 密度指数中的平方改成 $\|\vartheta_t\|^2$, 并有 $W_t^{\mathbb{Q}} = W_t + \int_0^t \vartheta_s ds$. 漂移调整落在扩散矩阵能够产生的方向上; 这种变换消去的是扩散矩阵值域内的漂移.

5.7 生成元, Kolmogorov 方程与 Feynman–Kac

到这里, 我们已经能写 SDE, 变换过程, 也能在有限期限内改变路径权重. 接下来的问题是怎样计算未来函数的条件期望. 若扩散具有 Markov 性, 从时刻 t 和状态 x 出发的未来期望不必记住整段过去, 可以写成一个确定函数 $u(t, x)$.

生成元描述这个函数在一个极短时间步里怎样被 SDE 推动. Kolmogorov 方程把同一件事写成 PDE. Feynman–Kac 再把贴现, 杀死率或运行收益放进同一套计算. 这三者共同完成一次翻译: 把“沿随机路径看未来” 翻译成“求一个确定的终值问题”.

从 Itô 公式读出生成元 考虑时变 Markov 扩散

$$dX_s = b(s, X_s) ds + \sigma(s, X_s) dW_s, \quad a = \sigma\sigma^T.$$

对空间测试函数 $f \in C^2(\mathbb{R}^d)$, 定义时刻 t 的生成元

$$(\mathcal{L}_t f)(x) = \sum_{i=1}^d b_i(t, x) \partial_i f(x) + \frac{1}{2} \sum_{i,k=1}^d a_{ik}(t, x) \partial_{ik} f(x).$$

于是 Itô 公式表明, 在适当可积条件下,

$$f(X_t) - f(X_0) - \int_0^t (\mathcal{L}_s f)(X_s) ds$$

是局部鞅; 若它可积到足以消除局部化, 则是真鞅. 这一性质也是扩散的鞅问题接口.

对时间相关函数 $u(t, x)$, 对应的算子是 $\partial_t + \mathcal{L}_t$. 从条件期望推 PDE 时, 时间变化和状态变化要一起进入这个算子.

Kolmogorov 后向方程 有了生成元以后, 终端期望可以不靠逐条路径重新模拟. 固定终端收益函数 g , 把“从 (t, x) 出发, 到 T 时看到 $g(X_T)$ 的平均值” 记成 $u(t, x)$. 向后方方程表达的是时间一致性: 现在的 $u(t, x)$ 等于先走一小步, 再在新状态上继续读 u .

固定终点 T 和终端函数 g . 以 $X_t = x$ 为起点的解记作 $X_s^{t,x}$, 定义

$$u(t, x) = \mathbb{E}[g(X_T^{t,x})].$$

定理 5.29 (Kolmogorov 后向方程).

假设 SDE 具有非爆炸 Markov 解, 系数具有足够正则性, 且上述期望定义的 u 属于 $C^{1,2}$ 并满足使随机积分成为真鞅的增长条件, 则

$$\partial_t u(t, x) + \mathcal{L}_t u(t, x) = 0, \quad 0 \leq t < T,$$

并具有终端条件

$$u(T, x) = g(x).$$

证明. 由 Markov 性和塔式法则, 对足够小的 $h > 0$,

$$u(t, x) = \mathbb{E}[u(t+h, X_{t+h}^{t,x})].$$

对右侧使用 Itô 公式, 减去 $u(t, x)$, 除以 h , 再令 $h \downarrow 0$. 在定理的正则性和增长条件下可以交换极限与期望, 从而得到 $(\partial_t u + \mathcal{L}_t u)(t, x) = 0$; 终端条件直接来自定义.

反过来, 若一个经典解满足该 PDE, 则 Itô 公式说明 $u(s, X_s^{t,x})$ 的有限变差项为零. 可积性把余下的局部鞅升级为真鞅, 故 $u(t, x) = \mathbb{E}[u(T, X_T^{t,x})] = \mathbb{E}[g(X_T^{t,x})]$. $\square$

例如, 对一维 Brown 运动, $\mathcal{L} = \frac{1}{2}\partial_{xx}$, 所以

$$u(t, x) = \mathbb{E}[g(x + B_{T-t})]$$

满足后向热方程

$$\partial_t u + \frac{1}{2}\partial_{xx} u = 0, \quad u(T, x) = g(x),$$

前提是 g 的增长和正则性足以支持经典解. 这里从终端条件向较早时间求解, 故称为“后向”方程.

若固定初始分布以后, X_t 的边缘分布具有密度 $p(t, x)$, Kolmogorov 前向方程则形式上为

$$\partial_t p = \mathcal{L}_t^* p,$$

其中

$$\mathcal{L}_t^* p = - \sum_i \partial_i (b_i p) + \frac{1}{2} \sum_{i,k} \partial_{ik} (a_{ik} p).$$

前向方程从初始分布推进密度; 后向方程固定终端函数并改变起始时刻和状态. 二者的边界条件和符号方向要分开.

带权期望的 Feynman-Kac 公式 Kolmogorov 后向方程处理的是纯终端期望. 很多问题还会沿路径持续累计收益或成本, 并给未来现金流一个权重. 把权重写成 $D_{t,s}$, 把运行项写成 h , 同样对 $D_{t,s}u(s, X_s)$ 做 Itô 计算, 就得到 Feynman-Kac 公式.

令 $c(t, x)$ 为杀死率或权重率, $h(t, x)$ 为源项, 并定义

$$D_{t,s} = \exp \left(- \int_t^s c(r, X_r^{t,x}) dr \right).$$

定理 5.30 (Feynman-Kac 公式).

假设对每个 (t, x) , 扩散 $X^{t,x}$ 在 $[t, T]$ 上存在且不爆炸, 并且沿其路径有

$$\int_t^T (|c(s, X_s^{t,x})| + |h(s, X_s^{t,x})|) ds < \infty \quad \text{a.s.}$$

若 $u \in C^{1,2}$ 解终值问题

$$\begin{cases} \partial_t u + \mathcal{L}_t u - cu + h = 0, & 0 \leq t < T, \\ u(T, x) = g(x), \end{cases}$$

并且

$$\mathbb{E} \left[D_{t,T} |g(X_T^{t,x})| + \int_t^T D_{t,s} |h(s, X_s^{t,x})| ds \right] < \infty,$$

同时

$$\int_t^\cdot D_{t,s} (\nabla u \sigma)(s, X_s^{t,x}) dW_s$$

是 $[t, T]$ 上的真鞅, 则

$$u(t, x) = \mathbb{E} \left[D_{t,T} g(X_T^{t,x}) + \int_t^T D_{t,s} h(s, X_s^{t,x}) ds \right].$$

证明. 对

$$D_{t,s} u(s, X_s^{t,x}) + \int_t^s D_{t,r} h(r, X_r^{t,x}) dr$$

使用乘积公式和 Itô 公式. 其漂移为

$$D_{t,s} (\partial_s u + \mathcal{L}_s u - cu + h)(s, X_s^{t,x}) ds = 0.$$

在假设保证局部鞅为真鞅后, 从 t 到 T 取期望即得结论. $\square$

上面的陈述是验证与表示定理: 它假设经典解和真鞅条件. 这些对象的存在仍需另外证明. Kallenberg 的 Theorem 34.1 证明了有界终端函数, 有界非负权重和时齐 Feller 扩散的无源版本 [Kal21, Theorem 34.1]; Durrett 的 Theorem 9.4.1–9.4.5 则给出 Brown 运动与有界势函数的版本 [Dur19, Theorem 9.4.1–9.4.5]. 这里允许时变系数与源项 h . 证明中的额外工作, 就是对 $D_{t,s} u(s, X_s^{t,x}) + \int_t^s D_{t,r} h(r, X_r^{t,x}) dr$ 使用乘积公式重新推导相应漂移抵消, 因而没有套用条件不同的定理.

在金融应用里, c 常被具体化为短端利率或贴现率, g 是终端现金流, h 是运行现金流. 计价单位, 可交易资产, 测度选择和无套利条件提供经济解释; Feynman–Kac 公式提供的是随机期望与 PDE 之间的解析桥. 若经典光滑性失败, 表示式仍可能对应弱解或黏性解, 这时需要额外的 PDE 正则性, 比较原理与解的唯一性理论.

5.8 Poisson 随机测度与跳跃: 进阶接口

第4.6节先把离散到达写成计数过程; 连续扩散则把不确定性摊开在每一个瞬间. 有些随机变化却集中在离散时刻: 违约, 财报跳空, 到达事件或成交簿中的突发订单. 进入跳跃模型以后, 要同时记住两件事: 实际路径上已经跳了多少, 以及在跳跃发生前可以预测的平均到达强度是多少. 方括号 $[\cdot]$ 和尖括号 $\langle \cdot \rangle$ 正是为了分开这两种累计量.

若 N_t 相对于当前滤过是强度为 $\lambda > 0$ 的 Poisson 过程, 则

$$\tilde{N}_t = N_t - \lambda t$$

是鞅, 且

$$[N]_t = [\tilde{N}]_t = N_t, \quad \langle \tilde{N} \rangle_t = \lambda t.$$

方括号是实际跳跃平方的累计. 尖括号 $\langle \tilde{N} \rangle$ 是 **可预测二次变差**: 它是从 0 出发的可预测递增过程, 并使 $\tilde{N}^2 - \langle \tilde{N} \rangle$ 成为局部鞅. 这里它恰好等于 $[\tilde{N}] = N$ 的补偿过程 λt , 二者不可混同.

更一般地, 令 $N(dt, dz)$ 为标记空间 E 上的 Poisson 随机测度, 补偿测度为 $\nu(dz) dt$, 并记

$$\tilde{N}(dt, dz) = N(dt, dz) - \nu(dz) dt.$$

对满足适当可预测性和平方可积性的 H , 补偿积分具有等距

$$\mathbb{E} \left[\left(\int_0^T \int_E H(s, z) \tilde{N}(ds, dz) \right)^2 \right] = \mathbb{E} \int_0^T \int_E |H(s, z)|^2 \nu(dz) ds.$$

这与 Brown Itô 等距平行, 但积分路径带跳.

跳跃 SDE 可以形式上写为

$$dX_t = b(t, X_{t-}) dt + \sigma(t, X_{t-}) dB_t + \int_E \gamma(t, X_{t-}, z) \tilde{N}(dt, dz).$$

左极限 X_{t-} 保证积分核在跳跃发生前可预测, 这正是第4.3节在跳跃接口中的作用. 若 $f \in C^2(\mathbb{R})$, 则对一般一维半鞅, 跳跃版 Itô 公式为

$$\begin{aligned} f(X_t) = f(X_0) &+ \int_0^t f'(X_{s-}) dX_s + \frac{1}{2} \int_0^t f''(X_{s-}) d[X^c]_s \\ &+ \sum_{0 < s \leq t} (f(X_s) - f(X_{s-}) - f'(X_{s-}) \Delta X_s). \end{aligned}$$

最后一行逐次累计每个跳跃的一阶线性化余项; 在相应半鞅可积条件下, 公式并不要求跳跃次数有限.

Lévy-Itô 分解, 无限活动下的小跳补偿, 跳跃 SDE 的存在唯一性, 非局部生成元, 跳跃版 Girsanov 定理和数值离散均留作进阶主题. 使用这些接口时, 先写清补偿约定和可积性, 再决定跳跃项怎样进入积分, 括号和 Itô 修正.

5.9 连续扩散的计算次序

前面几节引入了许多工具. 真正计算一个连续扩散模型时, 它们不是同时摊在桌上任选, 而是按一条固定路线依次出现: 先确认方程说的是什么, 再确认路径存在, 然后拆半鞅, 算括号, 做变换, 最后处理期望或 PDE.

面对一个连续扩散模型, 先把形式微分还原为积分等式, 再按下面的顺序计算:

1. **还原积分式:** 写清初值, 时间区间, 滤过, 驱动 Brown 运动和测度;
2. **检查存在性:** 验证系数与初值是否满足适用的存在唯一性条件, 或明确调用的是哪条专门定理;
3. **拆分半鞅:** 区分有限变差部分和局部鞅部分;
4. **计算括号:** 由噪声系数求 $[X]$ 与 $[X, Y]$, 不要让漂移进入二次变差;
5. **选择变换:** 对目标函数使用 Itô 公式或乘积公式, 并保留二阶项;
6. **处理期望:** 先确认随机积分是真鞅, 或先停止再取极限, 不要直接把局部鞅的期望设为零;
7. **若改变测度:** 写出密度过程, 检查真鞅条件, 再按同一符号约定代回 SDE;
8. **若转成 PDE:** 写出生成元, 终端条件与权重符号, 并核验 Feynman-Kac 过程的漂移确实抵消.

以乘法扩散 $dS_t = \mu S_t dt + \sigma S_t dB_t$ 为例, 对任意实数 p 使用 $f(x) = x^p$, 得到

$$d(S_t^p) = \left(p\mu + \frac{1}{2}p(p-1)\sigma^2 \right) S_t^p dt + p\sigma S_t^p dB_t.$$

由显式解可验证所需矩可积性, 故随机积分期望为零, 并有

$$\mathbb{E}[S_t^p] = S_0^p \exp \left(\left[p\mu + \frac{1}{2}p(p-1)\sigma^2 \right] t \right).$$

这里每一步都能回到积分等式, 可积性和已说明的定理, 整个计算因而可以逐项核验.

5.10 小结

连续随机分析的主线可以压缩成三句话:

1. Brown 路径虽然连续, 却有无穷总变差和有限非零二次变差;

2. Itô 积分以可预测简单过程为起点, 经等距在 L^2 中闭合;
3. Itô 公式把二次变差转化成二阶修正, 并由此连接 SDE, 测度变换和 PDE.

半鞅给出了这些运算共同的稳定范围. SDE 要理解为积分方程; Girsanov 改变的是路径权重; Feynman–Kac 把带权条件期望与终值 PDE 连接起来, 但不会自动赋予它任何金融解释. 跳跃理论沿用同样的可预测性, 补偿和可积性纪律, 同时增加跳跃修正项.

第六章 从随机对象到金融对象：一张接口图

屏幕上最先出现的通常只是一条随时间展开的价格路径。价格路径只是观察对象；策略还要经过一系列信息与行动约束：到时刻 t ，交易者只能使用已经进入 $\mathcal{F}_t$ 的信息，据此决定下一段时间的持仓；随后发生的价格变化，现金分配和交易成本共同形成路径损益；退出成交与结算完成以后，这些损益才记入现金和财富账户。这一章就沿着这条顺序走：路径进入信息集，信息约束行动，行动承受后续变化，损益最后落到现金与财富。

第三章，第四章和第五章已经分别准备了概率空间，滤过，适应过程，可预测过程，停时，鞅，半鞅和随机积分。这些对象正好分别负责这条链上的不同位置。下面把它们放回具体金融任务，用离散时间和连续时间各走一遍“路径—信息—行动—损益—现金与财富”的完整过程。离散与连续时间无套利模型的标准展开可参见 [HP81; Shr04a; Shr04b]。

注 6.1 (金融初学者的阅读路线)。

如果价格，债券，头寸，衍生品和订单等金融对象仍然陌生，可以先读第七章的市场基础，再回到这里完成数学接口。第一次阅读时只需反复问五个问题：当前看见了什么路径，时刻 t 知道什么，此刻能够决定什么，下一段路径怎样改变财富，账面损益何时成为已结算现金。这里的形式推导只依赖前面的概率论与随机分析；第七章补充这些符号对应的资产权利，交易机制和制度语境。

要保证行动没有偷看未来，需要沿用第4.3节的滤过语言，把路径与信息放在同一个固定的随机基上：

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in \mathbb{T}}, \mathbb{P}).$$

这四个符号可以先按市场故事来读。 Ω 容纳所有可能的完整市场历史， $\mathcal{F}$ 收集我们允许讨论的事件， $\mathbb{P}$ 给这些历史分配现实概率， $(\mathcal{F}_t)$ 则记录观察者到时刻 t 已经能够区分哪些事情。参与者，制度或市场状态可以随时间改变，这些变化通常写成定义在同一个 Ω 上的随机过程。若每到一个时刻便更换样本空间 Ω_t ，跨时点的可测性和信息关系将失去统一基准。

定义 6.2 (金融市场的随机基)。

一个有限期限金融模型的**随机基**是

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{0 \leq t \leq T}, \mathbb{P}),$$

其中 $(\mathcal{F}_t)$ 是递增的子 σ -代数族。 $\mathcal{F}_t$ 表示时刻 t 已经能够使用的信息， $\mathbb{P}$ 表示模型对于现实路径概率的描述。

在连续时间里，通常还要求滤过满足完备性和右连续性等通常条件；后文需要用到这些条件时会再指出。

先放一张对照表。左栏是数学对象，中栏是信息或结构要求，右栏则把它放回金融链条中的位置。

数学对象	信息或结构要求	金融解释与边界
固定随机基 ($\Omega, \mathcal{F}, (\mathcal{F}_t), \mathbb{P}$)	$\mathcal{F}_s \subseteq \mathcal{F}_t$ 对 $s \leq t$ 成立	$\mathbb{P}$ 描述现实概率, $\mathcal{F}_t$ 描述时刻 t 的可用信息; 新信息扩大滤过, 不自动更换样本空间.
价格过程 S_t	S_t 对 $\mathcal{F}_t$ 可测, 即 S 适应于滤过	时刻 t 的模型价格只能依赖已经进入 $\mathcal{F}_t$ 的信息; 适应性不保证该价格能按给定数量实际成交.
持仓过程 θ_t	可预测; 离散时间里, 用于 $(t-1, t]$ 的 θ_t 是 $\mathcal{F}_{t-1}$ -可测	头寸必须在下一段价格变化发生以前决定; 这排除了看见未来价格以后再选择过去持仓.
自融资财富 V_t	调仓成本由组合内部的现金, 资产出售和分配支付	初始建仓以后不靠外部注资或提款制造损益; 股息, 利息, 费用和融资现金流必须进入同一现金账.
停时 τ	对每个 t , $\{\tau \leq t\} \in \mathcal{F}_t$	触发时点能够凭当时信息识别; 它可以描述行权, 止损触发或首次到达, 但不保证触发价就是成交价.
计价资产 B_t	严格为正并可交易; 这里主要把它理解成现金或货币市场账户	S_t/B_t 是以 B 为单位的相对价格; 计价资产的选择和定价测度的选择必须绑定.
现实测度 $\mathbb{P}$ 与定价测度 $\mathbb{Q}^B$	通常要求 $\mathbb{Q}^B \sim \mathbb{P}$, 且以 B 贴现的可交易累计收益在 $\mathbb{Q}^B$ 下为鞅或局部鞅	$\mathbb{P}$ 用于描述现实频率, 预测和风险; $\mathbb{Q}^B$ 用于相对于计价资产 B 做无套利定价. 二者用途不同, 也具有不同的概率含义.

原则 6.3 (先固定信息, 再谈策略).

一个价格过程可以是适应的, 而一个交易策略必须更严格地是非预见的. 在离散时间里, 用于赚取 $t-1$ 到 t 价格变化的持仓必须在时刻 $t-1$ 的信息下确定; 在连续时间里, 这对应随机积分被积过程的可预测性要求.

还要区分两个经常被混用的箭头:

现实动态($\mathbb{P}$) $\longrightarrow$ 预测, 频率与风险,

以及

无套利市场($B, \mathbb{Q}^B$) $\longrightarrow$ 相对价格与复制成本.

从 $\mathbb{P}$ 转到 $\mathbb{Q}^B$ 是把贴现和风险补偿重新编码进定价测度, 不能据此断言现实世界按 $\mathbb{Q}^B$ 的频率运行. 如果改用 T 到期零息债券 $P(t, T)$ 作为计价资产, 对应的测度应该另记为 $\mathbb{Q}^T$; 一般随机利率模型中不能把 $\mathbb{Q}^T$ 与 $\mathbb{Q}^B$ 默认为同一个测度.

这些定义仍然有些抽象. 下一节把所有不确定性压缩为一次上涨或下跌, 让价格, 当时可决定的持仓, 终端支付和财富第一次同时出现在同一张资产负债表里.

6.1 一时期二叉市场: 从状态到复制

先把市场压到只剩今天和到期日两个时刻. 今天不知道到期会上涨还是下跌, 但可以先写清每一种状态下资产和现金账户会变成什么. 现实世界只有两个终端状态

$$\Omega = \{\omega_u, \omega_d\}, \quad \mathbb{P}(\omega_u) = p, \quad \mathbb{P}(\omega_d) = 1 - p,$$

其中 ω_u 表示上涨状态, ω_d 表示下跌状态, p 是现实测度 $\mathbb{P}$ 下上涨状态的概率, 并且 $0 < p < 1$. 信息结构取为

$$\mathcal{F}_0 = \{\emptyset, \Omega\}, \quad \mathcal{F}_1 = 2^\Omega.$$

因此终态在时刻 0 尚未揭示, 初始持仓只能是 $\mathcal{F}_0$ -可测的确定性数量; 到时刻 1 才能区分上涨与下跌状态. 无风险账户 B 是计价资产. $B_0 = 1$ 表示今天的一单位现金, $B_1 = R$ 表示这单位现金到期增长为 R :

$$B_0 = 1, \quad B_1 = R, \quad R > 0,$$

股票 S 今天价格为 S_0 . 若到期进入上涨状态, 一股股票值 uS_0 ; 若进入下跌状态, 一股股票值 dS_0 :

$$S_0 > 0, \quad S_1 = \begin{cases} uS_0, & \omega_u, \\ dS_0, & \omega_d, \end{cases} \quad 0 < d < u.$$

这里 R , u 和 d 都是一期总增长倍数, u 和 d 不是概率, 所以它们量纲相同; S_0 和 S_1 的量纲都是每股多少单位计价货币. 假设股票和无风险账户都能按所写价格双向交易, 允许借贷和卖空, 并暂时忽略税费, 价差, 违约和数量约束.

命题 6.4 (二叉市场的无套利条件).

在上述一时期模型中, 市场无套利当且仅当

$$d < R < u.$$

证明. 先证明必要性. 如果 $R \leq d$, 在时刻 0 借入 S_0 并买入一股股票, 初始净投入为零, 终端财富为

$$S_1 - RS_0 = \begin{cases} (u - R)S_0, & \omega_u, \\ (d - R)S_0, & \omega_d. \end{cases}$$

它在两个状态都非负, 并至少在上涨状态严格为正. 这是一项套利. 如果 $R \geq u$, 则卖空一股股票并把所得 S_0 投入无风险账户, 终端财富

$$RS_0 - S_1$$

在两个状态都非负, 并至少在下落状态严格为正, 同样构成套利. 因而无套利要求 $d < R < u$.

再证明充分性. 当 $d < R < u$ 时, 可以选一个权重 q , 让股票的贴现终值在这个权重下正好平均回今天价格:

$$q = \frac{R - d}{u - d}.$$

于是 $0 < q < 1$, 并且

$$\frac{S_0}{B_0} = q \frac{uS_0}{R} + (1 - q) \frac{dS_0}{R}.$$

令 $\mathbb{Q}^B(\omega_u) = q$, $\mathbb{Q}^B(\omega_d) = 1 - q$. 因为 $p, q \in (0, 1)$, 所以 $\mathbb{Q}^B \sim \mathbb{P}$. 任意零初始成本的自融资组合在 $\mathbb{Q}^B$ 下具有零贴现终端财富期望. 如果它的终端财富在 $\mathbb{P}$ 下几乎处处非负且以正概率严格为正, 等价性会使其在 $\mathbb{Q}^B$ 下也以正概率严格为正, 从而贴现期望严格为正, 产生矛盾. 因此不存在套利. $\square$

现在给定一项一期到期现金流. 它可以理解为一份衍生品到期支付: 上涨状态支付 X_u , 下跌状态支付 X_d .

$$X_1 = \begin{cases} X_u, & \omega_u, \\ X_d, & \omega_d. \end{cases}$$

其中 X_u 和 X_d 都以时刻 1 的计价货币为单位. 用 Δ 股股票和 β 单位无风险账户复制它. 这里 Δ 是股票持股数, β 是现金账户单位数; $\beta < 0$ 表示借入现金, $\beta > 0$ 表示持有现金. 要让组合在两个终端状态都刚好等于合约支付, 需要解

$$\begin{aligned} \Delta uS_0 + \beta R &= X_u, \\ \Delta dS_0 + \beta R &= X_d. \end{aligned}$$

唯一解为

$$\Delta = \frac{X_u - X_d}{S_0(u - d)}, \quad \beta = \frac{uX_d - dX_u}{R(u - d)}.$$

因此复制成本是

$$\begin{aligned} V_0 &= \Delta S_0 + \beta \\ &= \frac{1}{R} (qX_u + (1-q)X_d) \\ &= \frac{1}{R} \mathbb{E}^{\mathbb{Q}^B} [X_1]. \end{aligned}$$

命题 6.5 (复制, 完备性与风险中性概率).

当 $d < R < u$ 时, 上述二叉市场中的每个二状态现金流都能由股票和无风险账户唯一复制. 因而市场完备, 复制成本是唯一无套利价格, 而

$$q = \frac{R - d}{u - d}$$

是以 B 为计价资产的唯一风险中性上涨概率.

这里没有使用现实上涨概率 p 来计算复制价格. p 会影响现实世界里的期望收益, 预测误差和风险判断; q 则是由股票和现金账户的相对价格推出的定价权重. 所以

$$q \neq p$$

通常反映现实概率与定价测度承担不同职能, 无须把它视为模型失败.

例 6.6 (一只一期看涨合约).

设

$$S_0 = 100, \quad R = 1.02, \quad u = 1.20, \quad d = 0.90.$$

执行价为 $K = 105$ 的一期欧式看涨合约支付

$$X_u = 15, \quad X_d = 0.$$

无套利条件 $0.90 < 1.02 < 1.20$ 成立, 风险中性上涨概率为

$$q = \frac{1.02 - 0.90}{1.20 - 0.90} = 0.4.$$

复制头寸是

$$\Delta = \frac{15}{120 - 90} = 0.5, \quad \beta = -\frac{45}{1.02} \approx -44.1176.$$

对应的交易是买入半股, 并在时刻 0 借入约 44.1176 单位货币. 到期需要偿还 45: 上涨状态组合支付 $0.5 \times 120 - 45 = 15$, 下跌状态支付 $0.5 \times 90 - 45 = 0$. 初始价格为

$$V_0 = 50 - 44.1176 \approx 5.8824,$$

也等于

$$\frac{1}{1.02} (0.4 \times 15 + 0.6 \times 0).$$

如果真实上涨概率 p 改变, 现实风险评估会改变; 只要这一组可复制资产价格和交易条件不变, 上述无套利价格不会因此自动改变.

注 6.7 (等式依赖可实施性).

二叉模型里的复制价格是一个模型内结论. 如果股票不能卖空, 借贷利率不同, 交易有数量限制或合约结算条件不一致, 上述双向复制论证可能只给出单边约束或价格区间. 一个代数解 Δ, β 并不自动等于现实中能够成交并持有到期的策略.

6.2 多期离散时间: 鞅, 自融资与基本定理

第6.1节把“何时知道”和“何时行动”隐藏在两个端点里. 把二叉树增加到多个时期以后, 每走完一段路径, 信息都会更新, 交易者也可以据此重新决定下一段持仓. 每一期都重复同一个时间顺序: 观察截至 $t-1$ 的路径, 在 $\mathcal{F}_{t-1}$ 下确定 θ_t , 再由这项持仓承受 $(t-1, t]$ 的价格与分配变化. 交易日期记为

$$\mathbb{T} = \{0, 1, \dots, T\},$$

这里的 T 是最后一个交易日期, 不是连续时间期限. 市场里有一只严格为正的计价资产 B_t , 可以先把它读成现金或货币市场账户. 还有 d 只风险资产. S_t 是它们在时刻 t 的除息价格向量, 也就是不把刚支付的现金分配塞进价格本身; ΔD_t 是在第 t 期每持有一单位资产实际收到的现金分配向量.

如果一单位风险资产既可能变价, 又可能在中途派现金, 只看 S_t/B_t 会漏掉分配. 所以把“当前除息价格”和“过去已经收到的分配”一起换算成 B 的单位, 得到贴现累计收益过程

$$\tilde{G}_t = \frac{S_t}{B_t} + \sum_{k=1}^t \frac{\Delta D_k}{B_k}.$$

这里向量 ΔD_k 的第 i 个分量是第 i 只资产在时刻 k 每单位持仓支付的计价货币, 所以 $\tilde{G}_t$ 的每个分量都表示: 截至时刻 t , 持有一单位该资产所对应的贴现价格加分配.

为了把信息顺序写清楚, 令 θ_t 表示在 $(t-1, t]$ 期间持有的风险资产数量, 令 ψ_t 表示同期持有的计价资产单位数. 策略

$$\phi_t = (\psi_t, \theta_t), \quad t = 1, \dots, T,$$

是可预测的, 意思是 ϕ_t 必须是 $\mathcal{F}_{t-1}$ -可测的. 也就是说, 第 t 期要承受多少风险, 在第 t 期价格和分配出现以前已经决定.

定义 6.8 (离散时间自融资策略).

对 $t = 1, \dots, T$, 把本期持仓按除息价格计值并收取当期分配后的财富定义为

$$V_t = \psi_t B_t + \theta_t \cdot (S_t + \Delta D_t).$$

如果在每个中间日期 $t = 1, \dots, T-1$, 这笔财富恰好用于下一期调仓, 即

$$\psi_{t+1} B_t + \theta_{t+1} \cdot S_t = V_t,$$

就称策略 ϕ 是**自融资的**. 初始财富为

$$V_0 = \psi_1 B_0 + \theta_1 \cdot S_0.$$

把财富除以 B_t , 就是在用现金账户作单位重新计量组合. 在这个单位下, 自融资条件可以整理成离散随机积分形式

$$\tilde{V}_t = \tilde{V}_0 + \sum_{k=1}^t \theta_k \cdot (\tilde{G}_k - \tilde{G}_{k-1}), \quad \tilde{V}_t = \frac{V_t}{B_t}.$$

右边的每个 θ_k 在 $\tilde{G}_k - \tilde{G}_{k-1}$ 发生以前已经确定. 这就是可预测性进入金融收益的准确位置. 这也把第4.3节的信息边界变成了交易账本中的持仓时点.

这条式子也解释了为什么前面要把分配放进 $\tilde{G}$: 策略收益来自持仓乘以后续累计收益增量, 而这个增量必须同时包含价格变化和持有期间收到的现金.

命题 6.9 (贴现收益鞅推出无套利).

假设存在一个与 $\mathbb{P}$ 等价的概率测度 $\mathbb{Q}^B$, 使每只可交易风险资产的贴现累计收益过程 $\tilde{G}$ 都是 $\mathbb{Q}^B$ -鞅. 那么每个有界的可预测自融资策略的贴现财富 $\tilde{V}$ 也是 $\mathbb{Q}^B$ -鞅; 更一般地, 同一结论适用于其随机积分确为真鞅的可积策略. 特别地, 市场不存在由这类策略构成的套利.

这个命题的读法很直接. 如果在某个定价测度下, 每一只可交易资产的贴现累计收益都没有可预测的条件平均漂移, 那么用事前决定的持仓把这些资产组合起来, 也不会凭空制造一条零成本的正收益路线.

证明. 由自融资恒等式和条件期望的线性性,

$$\begin{aligned}\mathbb{E}^{\mathbb{Q}^B}[\tilde{V}_t - \tilde{V}_{t-1} | \mathcal{F}_{t-1}] &= \mathbb{E}^{\mathbb{Q}^B}[\theta_t \cdot (\tilde{G}_t - \tilde{G}_{t-1}) | \mathcal{F}_{t-1}] \\ &= \theta_t \cdot \mathbb{E}^{\mathbb{Q}^B}[\tilde{G}_t - \tilde{G}_{t-1} | \mathcal{F}_{t-1}] \\ &= 0.\end{aligned}$$

第二行能够把 θ_t 提到条件期望外面, 因为它是 $\mathcal{F}_{t-1}$ -可测的. 如果某个零初始财富策略的终端财富在 $\mathbb{P}$ 下非负且以正概率严格为正, 等价性使它在 $\mathbb{Q}^B$ 下也具有这个性质, 从而 $\mathbb{E}^{\mathbb{Q}^B}[\tilde{V}_T] > 0$, 与鞅性质给出的 $\mathbb{E}^{\mathbb{Q}^B}[\tilde{V}_T] = \tilde{V}_0 = 0$ 矛盾. $\square$

命题 6.10 (有限树上的金融市场基本定理).

在有限时间, 有限状态树, 无摩擦, 节点上可双向交易的市场中, 假设树具有单一根节点, 因而 $\mathcal{F}_0 = \{\emptyset, \Omega\}$, 且所有模型内终端状态均由 $\mathbb{P}$ 赋予正概率. 那么:

1. 市场无套利, 当且仅当存在至少一个 $\mathbb{Q}^B \sim \mathbb{P}$, 使全部贴现累计收益过程成为 $\mathbb{Q}^B$ -鞅;
2. 在无套利成立以后, 市场对于全部有限值的 $\mathcal{F}_T$ -可测终端现金流完备, 当且仅当这样的 $\mathbb{Q}^B$ 唯一.

这个有限树结论区分了存在性与唯一性. **存在性**对应无套利: 至少有一种正的状态定价方式与现有资产价格相容. **唯一性**对应完备性: 每项模型内终端现金流都能复制时, 定价测度才被交易资产完全锁定. 市场不完备时, 多个 $\mathbb{Q}^B$ 可以同时与无套利相容. 可复制现金流仍有唯一复制价格, 不可复制现金流则不能仅靠无套利自动得到唯一价格; 选择某个测度, 效用, 风险准则或统计模型都属于额外输入.

注 6.11 (有限树边界).

上述“无套利当且仅当存在等价鞅测度”是有限树上的干净版本. 在无限状态或连续时间半鞅模型中, 简单的无套利条件可能太弱, 通常需要使用无免费午餐且风险趋于消失等更强条件, 并把结论写成等价局部鞅测度的存在. 这里不把有限维线性代数证明冒充成一般连续时间定理.

6.3 停时与美式合约: Snell 包络

第6.1节和第6.2节讨论的是“现在持有多少”. 同一条信息边界也适用于“现在是否行动”: 如果行动的时间本身取决于路径, 那么触发与否也只能由当时已经知道的信息判断. 欧式合约把行权日固定在 T . 美式合约则允许持有人在—组日期中选择行权时点. 这个选择不能知道未来以后再倒填, 所以合法行权规则必须是停时.

固定一个定价测度 $\mathbb{Q}^B$. 美式合约每天都要在两件事之间比较: 现在行权拿钱, 还是保留选择权等到以后. H_t 记录时刻 t 立即行权能够收到的现金支付; 它必须是 $\mathcal{F}_t$ -可测的, 因为行权时只能使用已经看见的信息. 把这笔现金除以计价资产 B_t , 得到贴现支付

$$\tilde{H}_t = \frac{H_t}{B_t},$$

同时要求 $\tilde{H}_t \in L^1(\mathbb{Q}^B)$ 对每个行权日期成立. 用 $\mathcal{T}_{t,T}$ 表示从今天 t 到到期 T 之间所有允许的行权时钟, 也就是所有取值于 $\{t, t+1, \dots, T\}$ 的停时. 从时刻 t 看见的最优贴现行权价值记为 Y_t :

$$Y_t = \operatorname{ess\,sup}_{\tau \in \mathcal{T}_{t,T}} \mathbb{E}^{\mathbb{Q}^B}[\tilde{H}_\tau | \mathcal{F}_t].$$

这里的 essential supremum 是一个 $\mathcal{F}_t$ -可测随机变量: 它在 a.s. 意义下支配所有候选条件价值 $\mathbb{E}^{\mathbb{Q}^B}[\tilde{H}_\tau | \mathcal{F}_t]$, 并在满足这一条件的随机变量中最小. 在这里的有限日期和有限树模型中, 首次阅读可以直接把它理解成下面逐节点向后取最大值的递推.

定义 6.12 (Snell 包络).

过程 Y 称为贴现支付过程 $\tilde{H}$ 的 **Snell 包络**, 如果它是支配 $\tilde{H}$ 的最小 $\mathbb{Q}^B$ -上鞅. 在有限离散时间里, 它可以由向后递推构造:

$$Y_T = \tilde{H}_T, \quad Y_t = \max \left\{ \tilde{H}_t, \mathbb{E}^{\mathbb{Q}^B} [Y_{t+1} | \mathcal{F}_t] \right\}.$$

递推式的两个量具有直接的金融含义:

$$\underbrace{\tilde{H}_t}_{\text{现在行权}} \quad \text{与} \quad \underbrace{\mathbb{E}^{\mathbb{Q}^B} [Y_{t+1} | \mathcal{F}_t]}_{\text{保留选择权}}.$$

如果前者较大, 模型选择立即行权; 如果后者较大, 继续持有选择权. 一个最早最优停时可以写成

$$\tau_t^* = \inf \{ s \geq t : Y_s = \tilde{H}_s \}.$$

在完备的有限市场中, 美式合约的模型内价格为

$$V_t = B_t Y_t.$$

例 6.13 (一个节点上的行权判断).

假设在某个节点, 立即行权的贴现支付为 8, 下一期 Snell 价值的条件期望为 6.5, 那么该节点的 $Y_t = 8$, 模型选择行权. 在另一个节点, 如果立即行权支付为 3, 继续价值为 5.2, 则 $Y_t = 5.2$, 模型选择等待.

这里比较的是当前支付与每个信息节点上经贴现并按定价测度求得的继续价值, 与“最可能的未来价格”无关.

注 6.14 (停时不等于成交保证).

τ 是停时只说明触发决定没有使用未来信息. 现实合约还可能有行权通知窗口, 提前指派, 自动行权阈值, 实物交割, 现金结算, 节假日和结算失败等规则. 止损触发以后也可能出现跳空和滑点. 因此数学上的最优停时只描述触发规则, 无法保证现实交易按 H_τ 成交.

在不完备市场中, 对某个选定 $\mathbb{Q}^B$ 计算的 Snell 包络是模型估值; 无套利本身未必把它锁成唯一市场价格.

6.4 连续时间桥：半鞅与随机积分增益

把交易时钟从有限个日期换成连续时间以后, 经济顺序没有改变: 先由当前信息决定持仓, 再让持仓承受随后到来的价格变化. 改变的是计算工具. 离散时间的自融资增益是和式

$$\sum_{k=1}^t \theta_k \cdot (\tilde{G}_k - \tilde{G}_{k-1}).$$

当调仓网格越来越细时, 不能简单假定这组和式会像普通 Riemann 积分一样收敛. Brown 路径具有无限总变差, 而交易头寸本身又会随机变化. 随机积分为这种极限提供了严格定义.

第5.2节和第5.8节导入了这里需要调用的标准半鞅积分理论. 记号 $L(X)$ 可以先按交易语言来读: 它收集那些能够作为事前持仓, 并且可以对价格账本 X 做随机积分的过程. 积分值由 X 本身决定, 不依赖于所选半鞅分解. 首次阅读可以额外假设下面的 S 和 D 都连续. 这样不会改变自融资思想, 只会暂时避开跳跃与跳前持仓约定.

设连续时间市场建立在满足通常条件的随机基上. 先读三个价格账本. B_t 是严格为正, 连续且具有有限变差的现金计价资产, S_t 是适应的 càdlàg d 维除息价格半鞅, D_t 是从 0 出发, 适应, càdlàg 且具有有限变差的 d 维累计单位现金分配过程. B 给出现金或货币市场账户的增长, S 只记录除息后的可交易报价, D 记录持有一单位风险资产期间实际收到的现金分配. 把除息价格和已经收到的分配都换成 B 的单位, 得到连续时间的贴现累计收益

$$\tilde{G}_t = \frac{S_t}{B_t} + \int_{(0,t]} \frac{1}{B_u} dD_u.$$

令 ψ_t 表示现金账户持仓, θ_t 表示风险资产持仓. 二者都取可预测形式, 意思是调仓决定要在随后价格变化和分配入账之前作出. 为了让下面的现金账本有数学意义, 要求 $\psi \in L(B)$, 且逐坐标有 $\theta^i \in L(S^i) \cap L(D^i)$. 在跳时 u , θ_u 表示跳跃发生前已经确定的持仓; 若库存另以适应的 càdlàg 过程 $\bar{\theta}$ 记录, 积分中使用的是 $\bar{\theta}_{u-}$. 组合的当时标记价值为

$$V_t = \psi_t B_t + \theta_t^\top S_t.$$

第6.2节的离散账本到这里变成连续积分, 但自融资条件仍是同一句话: 调仓不从外部拿钱, 也不把钱抽出组合. 因此组合价值只能由现金账户增长, 风险资产除息价格变化, 以及持有期间收到的单位分配共同推动:

$$V_t = V_0 + \int_0^t \psi_u dB_u + \int_0^t \theta_u^\top dS_u + \int_0^t \theta_u^\top dD_u.$$

这里最后一项把持有期间收到的分配纳入同一现金账. 由于 B 连续, 严格为正且具有有限变差, 分部积分把这条现金账本化为贴现形式

$$\tilde{V}_t = \tilde{V}_0 + \int_0^t \theta_u^\top d\tilde{G}_u.$$

定义 6.15 (连续时间自融资增益).

随机积分

$$(\theta \cdot \tilde{G})_t = \int_0^t \theta_u^\top d\tilde{G}_u$$

称为持仓 θ 相对于贴现累计收益过程 $\tilde{G}$ 的**自融资交易增益**. 可预测性负责信息边界, 可积性负责数学上能够定义这组增益.

半鞅是这里的重要对象边界: 它足够宽, 能同时容纳有限变差部分, 连续局部鞅和跳跃, 又足以让大类可预测策略的随机积分保持稳定. 在合适的连续时间无套利条件下, 可以寻找 $\mathbb{Q}^B \sim \mathbb{P}$, 使 $\tilde{G}$ 成为 $\mathbb{Q}^B$ -局部鞅. 但“局部鞅”不能不加检查地换成条件期望公式; 只有进一步满足可积性或一致可积等条件时, 才得到真鞅意义下的

$$\tilde{V}_t = \mathbb{E}^{\mathbb{Q}^B}[\tilde{V}_T | \mathcal{F}_t].$$

现实可行性还需要自融资恒等式以外的条件. 连续时间理论通常要限制策略的可允许性, 排除财富无限向下穿透, 无限杠杆或翻倍策略. 现实执行还要面对离散成交, 最小价格变动单位, 有限深度, 延迟, 费用, 融资和风控线.

例 6.16 (GBM 是强特例).

几何 Brown 运动模型写成

$$dS_t = \mu S_t dt + \sigma S_t dW_t^\mathbb{P}, \quad S_0 > 0,$$

其中最简单版本把 μ 和 $\sigma > 0$ 都设为常数. 这里 S_t 是时刻 t 的模型价格, μ 是在现实测度 $\mathbb{P}$ 下每单位时间的平均增长率, σ 是瞬时波动强度, $W^\mathbb{P}$ 是现实测度下的 Brown 噪声. 这条微分式的读法是: 价格的相对变化由一项平均增长和一项按 σ 缩放的随机冲击组成. 它的解为

$$S_t = S_0 \exp \left(\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t^\mathbb{P} \right).$$

因此价格严格为正, 路径连续, 对数收益具有平稳独立的 Gauss 增量.

现在加入无股息, 常数短率 r , 无摩擦和有限期限 T 的假设, 并令 $B_t = e^{rt}$. 这时 B 是现金账户, r 是现金账户的连续复利增长率. 取

$$\vartheta = \frac{\mu - r}{\sigma}, \quad Z_t = \exp \left(-\vartheta W_t^\mathbb{P} - \frac{1}{2} \vartheta^2 t \right).$$

这里 ϑ 把现实漂移 μ 与现金增长率 r 的差距换算成每一单位 Brown 风险对应的价格. Z_t 是密度过程: 它不改变已经写在样本空间里的路径, 而是改变这些路径在新测度下的权重. 因为 ϑ 是常数, Novikov 条件成立, 所以 Z 是真鞅. 由

$$\left. \frac{d\mathbb{Q}^B}{d\mathbb{P}} \right|_{\mathcal{F}_t} = Z_t$$

定义的 $\mathbb{Q}^B$ 与 $\mathbb{P}$ 等价, 且第5.6节的 Girsanov 定理给出

$$W_t^{\mathbb{Q}^B} = W_t^{\mathbb{P}} + \vartheta t.$$

这句话的含义是: 换到 $\mathbb{Q}^B$ 以后, 原来藏在价格方程里的风险溢价被吸收到 Brown 运动的漂移修正里. 把 $dW_t^{\mathbb{P}} = dW_t^{\mathbb{Q}^B} - \vartheta dt$ 代回原方程, 得到

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}^B},$$

从而 S_t/B_t 是 $\mathbb{Q}^B$ -鞅.

这里密度过程的真鞅性给出等价定价测度的存在; 这一步不以完备性为前提. 若滤过恰由这一维 Brown 运动生成, 且市场只含该非退化风险资产与现金账户, 鞅表示定理进一步给出完备性和 $\mathbb{Q}^B$ 的唯一性; 若滤过还包含不可交易风险, 定价测度则可能不唯一.

结合第6.4节, GBM 提供了从 Girsanov 变换到贴现价格鞅的简明例子. 它的假设排除了价格跳跃, 随机波动率, 厚尾, 离散报价, 交易暂停, 流动性状态变化和制度突变. 更一般的半鞅价格允许更丰富的路径结构; GBM 属于其中连续, 正值, 单因子且参数约束很强的特例.

原则 6.17 (模型策略与可执行策略分层).

数学模型输出的可预测过程 θ_t 是目标持仓或复制持仓; 它只有经过订单生成, 价格选择, 数量约束, 成交回报, 融资检查, 保证金和结算以后, 才可能变成现实头寸. 因此

$$\text{模型持仓} \neq \text{已发送订单} \neq \text{已成交头寸} \neq \text{已结算现金}.$$

6.5 点过程示例: 订单到达与因果边界

到第6.4节为止, 我们主要把价格路径当作已经给定的随机过程. 若进一步追问报价为什么更新, 订单提交, 撤单和成交等事件流就会进入模型. 不过, 描述事件何时到达与解释事件为何发生是两件不同的事. 第4.6节的 Poisson 过程可以用来描述随机到达, 但它只是订单流模型的一个起点. 这里 N_t 先只数一类已经说清楚的事件: 例如某类市场化买单在 $[0, t]$ 内一共出现了多少次. 常数 λ 是每单位时间的事件到达率. 如果 N 相对于当前滤过 $(\mathcal{F}_t)$ 是强度为 $\lambda > 0$ 的 Poisson 过程, 那么

$$\mathbb{P}(N_{t+h} - N_t = 1 \mid \mathcal{F}_t) = \lambda h + o(h),$$

$$\mathbb{P}(N_{t+h} - N_t \geq 2 \mid \mathcal{F}_t) = o(h),$$

其中第一行表示: 在很短的下一段时间里, 出现一次事件的条件概率近似为 λh ; 第二行表示两次或更多次事件在一阶尺度上更小. 所以 λ 的量纲是每单位时间的事件数. 更一般地, 可以令 λ_t 是非负可预测过程, 要求对每个 $t \leq T$ 都有

$$\int_0^t \lambda_s ds < \infty \quad \text{a.s.},$$

并要求补偿过程

$$M_t = N_t - \int_0^t \lambda_s ds$$

成为局部鞅. 这时 λ_t 是在给定现有信息以后对于下一小段时间事件到达率的条件刻画. 可预测性表示它必须由事件到来前已经可见的信息决定; 它不再意味着独立平稳增量, 也不必是常数 Poisson 过程.

在订单簿语境中, 应先指定 N 究竟在数什么: 市场化买单, 市场化卖单, 限价单提交, 撤单和成交是不同事件类型. 事件还可以携带方向, 数量和交易场所等标记. 例如用 N_t^+ 和 N_t^- 分别记录市场化买入与卖出事件, 其可预测强度为 λ_t^+ 和 λ_t^- , 则

$$M_t^\pm = N_t^\pm - \int_0^t \lambda_s^\pm ds$$

可以作为补偿后的到达噪声.

一个只用于展示接口的中间价模型可以写成如下形式. m_t 表示模型里的中间价, 不是给定数量的成交价. 令 W 是相对于当前滤过的一维 Brown 运动, σ 是可预测过程, 并满足对每个 $t \leq T$ 都有 $\int_0^t \sigma_s^2 ds < \infty$ a.s. 这里 $\int_0^t \sigma_s dW_s$ 收集未被单独列成事件的连续噪声或消息冲击. 令 T_k 是带标记事件流的第 k 个到达时刻, Z_k 是该事件的方向与数量标记, g 则把事件标记转换成中间价跳动. 于是可写

$$m_t = m_0 + \int_0^t \sigma_s dW_s + \sum_{k: T_k \leq t} g(Z_k),$$

其中 $g(Z_k)$ 的量纲是每单位资产多少计价货币, 因此和价格 m_t 的量纲一致. 这个式子表达的是一种候选联合动态: 连续噪声和带标记事件共同改变模型中间价. 它并未说明交易者能按 m_t 买入或卖出指定数量.

注 6.18 (强度与因果效应).

较高的 λ_t^+ 说明在给定模型滤过以后, 买入事件更密集. “提高买单强度会推高价格” 则是一项因果主张, 需要另行识别. 潜在消息, 波动率, 盘口深度和参与者状态可能同时影响到达率与价格变化; 事件方向本身也可能由价格变化触发.

同样, 从观测数据估计出的 g 是条件关联或结构模型中的参数. 把它解释为干预效应以前, 仍须完成因果识别. 要回答因果问题, 还需要额外的识别设计, 外生变化或结构假设.

真实订单通常具有聚集, 自激, 日内季节性和状态依赖, 所以 Hawkes 过程, 一般带标记点过程或队列模型可能比常数强度 Poisson 过程更贴近某些问题. 但模型更复杂并不会自动解决因果识别, 也不会把模型中间价变成给定数量的可执行价格.

6.6 从报价到可实现损益：同一策略的现金账

第6.2节和第6.4节的自融资公式使用了一个干净的价格过程. 现实路径通常先以买卖报价出现, 行动再依次经过订单, 成交, 持仓, 退出和结算. 同一条路径上的中间价标记, 顶部报价和实际成交价各自回答不同问题, 不能被当成同一个数字使用. 下面用一个虚构的往返交易把适应价格, 可预测决策, 路径损益, 自融资现金账和结算状态放在一起. 所有数字只为说明口径, 不对应任何真实资产或当前市场.

设时刻 0 的盘口为

$$b_0 = 100.00, \quad a_0 = 100.10, \quad m_0 = \frac{a_0 + b_0}{2} = 100.05.$$

这里 b_0 是当时可见的最优买价, a_0 是最优卖价, m_0 是只用于标记的中间价. 它们都是每一单位资产对应的货币价格. 交易者决定买入 $q = 100$ 单位资产. 符号 q 表示数量, 因此只有价格差乘以 q 以后才会变成总金额. 显示的最优卖价 a_0 只是边际报价; 订单穿过有限深度以后, 实际买入平均成交价为

$$x^{\text{buy}} = 100.12.$$

买入名义成本为

$$qx^{\text{buy}} = 100 \times 100.12 = 10,012.$$

假设入场费用为 2.00, 其中 50% 的买入名义成本由借款融资, 借款本金为 5,006. 按年化单利 8% 持有五天, 融资费用约为

$$C^{\text{fund}} = 5,006 \times 0.08 \times \frac{5}{365} \approx 5.49.$$

假设期间没有分配和税费.

五天后, 盘口变为

$$b_H = 100.95, \quad a_H = 101.05, \quad m_H = 101.00.$$

同一个头寸此时至少有三种不同的损益读数.

第一种是采用中间价的**标记损益**. 如果会计口径在尚未退出时只扣已经发生的入场费和融资费, 则

$$\begin{aligned} \Pi_H^{\text{mark}} &= q(m_H - x^{\text{buy}}) - C^{\text{entry}} - C^{\text{fund}} \\ &= 100(101.00 - 100.12) - 2.00 - 5.49 \\ &= 80.51. \end{aligned}$$

这项数值属于账面标记, 尚未形成收到的现金.

第二种是按显示最优买价估计的**报价清算损益**. 如果假设全部 100 单位都能以 b_H 卖出, 并加入 2.00 的退出费, 则

$$\begin{aligned} \Pi_H^{\text{top quote}} &= q(b_H - x^{\text{buy}}) - C^{\text{entry}} - C^{\text{exit}} - C^{\text{fund}} \\ &= 100(100.95 - 100.12) - 2.00 - 2.00 - 5.49 \\ &= 73.51. \end{aligned}$$

这仍然只是基于顶部报价的估计; 顶部显示数量可能不足.

第三种是实际提交卖单以后得到的**成交损益**. 假设卖出平均成交价为

$$x^{\text{sell}} = 100.92.$$

在成交回报已经确认, 费用无误且结算正常的前提下, 往返交易的金融净损益为

$$\begin{aligned} \Pi_H^{\text{exec}} &= q(x^{\text{sell}} - x^{\text{buy}}) - C^{\text{entry}} - C^{\text{exit}} - C^{\text{fund}} \\ &= 100(100.92 - 100.12) - 2.00 - 2.00 - 5.49 \\ &= 70.51. \end{aligned}$$

每个价格差的量纲是每单位资产多少货币, 乘以 q 后才得到货币损益; 各项费用也都以同一货币计量.

如果卖出交易在下一营业日才结算, 那么成交时形成的是一笔待收结算款. 成交价已经把市场风险大体锁定, 款项则要等正常交收完成后才成为可自由使用的已结算现金. 结算失败, 费用更正或融资多占用一天都会改变最终现金账. 图6.1把这条状态链条压成一行. 每走过一个节点, 可核验的事实都会增加一层: 报价, 订单, 成交和已结算现金各自留下不同记录.




图 6.1: 从观察到的报价到已结算现金.

例 6.19 (四个价格不能互换).

在上面的同一策略里, 初始最优卖价 100.10, 实际买入价 100.12, 期末中间标记 101.00 和实际卖出价 100.92 分属报价, 执行, 标记和退出执行四种类型. 把任意一个数替换成另一个数, 都会改变损益的经济含义.

同理, 80.51, 73.51 和 70.51 分别回答“按中间价记账是多少”, “假定顶部报价可全部执行是多少”和“实际平均成交后是多少”. 只有再固定资本基数和资金占用规则以后, 才能把其中

一个合适的损益进一步除成策略回报率。

原则 6.20 (可实现损益需要现金账闭合).

一条数学持仓路径只有在以下项目被分别记录以后, 才能变成可核对的策略损益:

成交数量与成交价 + 中间分配 - 交易费用 - 融资费用 - 其他负担 + 退出或结算所得.

标记价用于观察未平仓头寸, 执行价用于确认成交, 结算记录用于确认现金和资产已经完成交付. 三者不能合并成一个没有类型的“价格”.

6.7 从概念接口到现实策略

原则 6.21 (研究笔记与交易动作分开).

这一章整理概率论, 随机过程和金融数学之间的概念接口, 给读者一套把模型问题说清楚的语言. 买入, 卖出, 加仓, 减仓, 借贷或对冲都属于另一条交易流程. 文中的价格, 概率, 利率和费用均用于展示定义和算术.

现实策略若要进入订单阶段, 仍需独立核验实时账户状态, 持仓与未结订单, 合约条款, 可交易数量, 报价深度, 融资和券源, 保证金, 费用, 税务, 清算结算与风险限额, 并由具有相应权限的人作出明确决定和最终确认.

这组内容只补齐数学工具到金融对象的最小接口. 资产权利, 衍生品条款, 利率与融资体系, 订单簿, 做市, 执行算法, 保证金, 券源, 期权指派和清算结算制度将在后文详细讨论. 在后面的金融市场章节里, 同一个数学模型必须重新放回具体资产, 账户, 交易场所和制度语境中检验.

第二部分

随机过程与金融市场

第七章 金融市场基础

第六章已经用一张最小账本说明随机对象怎样进入金融模型。在把这些模型放回真实市场以前，最好先花一点时间认识市场本身。

后面会不断出现价格 S_t ，利率 r_t ，贴现因子 $P(t, T)$ ，头寸 θ_t ，以及各种期权，债券和交易策略。这些符号看起来很轻巧，但每一个都要落到现实里的单位，权利，义务，交易制度和现金流上。否则公式可以写得很顺，读者却不知道它到底在描述哪一个市场对象。

这里先关心后面随机过程和金融数学会反复用到的几件事。金融数学和市场工具的背景材料主要参考 [Hul22; Shr04a; Shr04b; TS11]。我们要问：一项资产头寸由什么单位和权利构成，它怎样发行和交易，价格与策略回报怎样形成，不同时间的现金流怎样比较，利率和债券怎样给时间以及信用风险定价，衍生品怎样把未来状态重新做成合约，订单和流动性又怎样参与成交价格。

这里先放一条原则。

原则 7.1 (Market 与 Model).

Market $\neq$ Model of Market.

真实金融市场与描述它的数学模型属于不同层次。

市场本身包含企业经营，利率，政策，资金需求，仓位，订单流，流动性，交易制度以及不同参与者对于未来的预期；一个数学模型则根据当前想研究的问题，从这些复杂关系里面选择一部分结构保留下来。

后面出现的价格过程，利率过程，Brown 运动，风险中性测度以及各种随机模型，都是从市场中抽出的工作地图。地图能不能好用，取决于它为当前问题保留了什么结构。

还有一层区分也很快会派上用场。资产名称，持有位置，权利与义务，状态结果，主体价值，模型价值，市场价格，策略回报和可投资性不是同一种东西。在写下 S_t 以前，我们要先知道它对应哪一种单位，账户，交易方向，交易场所，结算资产和交付条件。

我们会先从最基础的资产和股票开始。股票本身是一部分企业权益，但这些权益又能够被发行，转让和交易，于是自然产生一级市场，二级市场，流动性以及市场价格。而因为股票代表的是对于企业未来剩余价值的索取权，股票市场又天然成为一个预期市场。

先从股票开始，因为一单位股票会同时牵出企业经营，剩余索取权，市场预期和交易价格。接着进入衍生品：股票，指数，利率或其他状态可以被重新切成未来现金流，再写进交付规则和风险暴露明确的合约。

沿着或有现金流继续往前，预测市场把未来事件本身做成可以交易的合约。这会帮助我们理解事件合约，市场隐含概率，也给后面 Agentic R-D-G 中的 Event Graph 和 Market Graph 提供现实来源。

然后再回到指数和 ETF。许多股票被放进同一个规则化篮子以后，单个公司事件被分散，系统性风险和二级市场交易却仍然留在场内。

接下来再进入债券和利率。债券把“今天给别人一笔钱，换取未来的一组支付”做成了可以交易的证券，于是货币的时间价值，贴现，期限结构，美债，信用利差以及 CDS 都会自然出现。再往后，我们还需要理解美联储和美元资金市场怎样形成短端资金价格，以及美债为什么同时是债券市场的基准资产和整个抵押融资体系的重要基础。

在这些资产与合约铺好以后，贴现与无套利会把不同时间和不同状态的现金流放到同一张账本上比较。当单位，交付，融资和交易条件可比时，无套利约束会给价格施加很强的相对定价关系。最后，订单，订单簿和市场微观结构会把价格形成重新拉回真实交易现场：报价怎样进入市场，订单怎样撮合，流动性为什么会变化，以及订单流怎样影响成交价格和执行成本。

这样一来，这条路从具体资产头寸和金融权利出发，经过衍生品，预测市场，指数与 ETF，债券，短端美元资金市场和无套利定价，最后回到订单簿里的成交过程。这条路从现实市场逐渐走向随机模型，不只是术语罗列。下面的图把这条路压成一个简图：




图 7.1: 金融市场基础的阅读路线

等这些现实对象大致清楚以后, 我们再回过头来看随机过程, 那些原本看起来抽象的符号就会有更加明确的市场含义。

7.1 资产头寸, 价格与策略回报

沿着上一节的路线, 我们先从最基础的金融对象开始。

一上来就写“设资产价格为 S_t ”, 会把好几层不同的问题压在同一个符号里: 究竟是谁持有哪一种单位, 他在什么制度下拥有怎样的权利和义务, 这些权利在不同状态下产生什么结果, 谁怎样评价这些结果, 市场又按照什么交易与结算条款形成价格。只有把这些对象分开以后, 价格过程和收益率过程才知道自己究竟在描述什么。

7.1.1 从资产名称到具体持有位置

股票, 债券, 黄金, 银行存款和平台账户余额都可以被叫作资产, 但资产名称本身通常还不足以确定一个数学对象。同一种名称放在不同账户, 托管安排, 法域, 权利类别或结算制度中, 可能对应不同的控制方式, 对手方和最终结果。

例 7.2 (先用一笔普通股持仓对照抽象记号)。

设投资者在券商账户中持有某上市公司的 100 股普通股。在下面的记号里, b 是公司与股东登记关系, $\bar{u}$ 是指定类别的一股普通股, J 是公司法, 公司章程, 账户协议与交易市场规则, R_t^i 包括表决, 分红, 转让等当时有效的权利, Γ_t 包括登记, 托管, 交易与结算机制, $n_t^i = 100$, 而 L_t^i 包括手续费, 税费, 融资负担和账户限制。这个例子只给出第一遍阅读所需的具体映射; 不同股票账户的实际权利与负担仍由各自制度决定。

注 7.3 (第一遍可以把抽象元组当作核对表)。

初次阅读时只需记住, 一个可交易名称还要补上单位, 数量, 权利, 账户和负担。若下面的元组暂时妨碍主线, 可以先跳到本章的股票, 价格与收益例子, 再回到这里逐项核对。

给定主体 i 和时刻 t , 我们先把资产权利组件写成

$$\mathcal{A}_t^i = (b, \bar{u}, J, R_t^i, \Gamma_t),$$

再把不可忽略的附随义务放回去, 得到完整经济头寸

$$\mathcal{Z}_t^i = (\mathcal{A}_t^i, n_t^i, L_t^i).$$

定义 7.4 (资产组件与完整经济头寸)。

在本书采用的工作框架中, b 表示可以独立界定的承载物或关系, 例如实物, 合同, 组织, 账本记录, 账户状态或平台许可; $\bar{u}$ 规定经济单位, 权利类别和核算边界, 也就是先说明“一个单位”究竟是什么; n_t^i 表示主体 i 在这一完整头寸中实际包含的单位数量; J 表示使这个位置成立的法律, 合同, 协议, 平台或物理规则; R_t^i 表示主体当前拥有的请求, 使用, 排除, 治理, 转让, 质押, 赎回或其他控制权能; Γ_t 表示登记, 执行, 变更, 冻结, 终止, 恢复和救济机制。

资产组件 $\mathcal{A}_t^i$ 是这些规则所确认或实际执行的现时权利或控制权能集合；**完整经济头寸** $\mathcal{Z}_t^i$ 进一步包含实际数量 n_t^i ，以及与之不可分离的义务，费用，税，追索，保证金要求和其他负担 L_t^i 。

这套对象语法用于组织后文的问题。法律，会计与监管仍各自采用具体的资产定义。资产可能没有现金流或活跃交易，价格也可能为零或为负；其价值还取决于主体与模型，投资适用性则取决于具体约束。未来现金，服务，控制效果和转售价属于头寸可能产生的结果，资产的界定先于这些结果。

注 7.5 (可交易对象只是更大的资产世界的一部分)。

广义经济资源，法律资产，会计资产和可交易头寸彼此相交，同时各有边界。经济资源通过改变人的行动集合发挥作用；独立权利还要由法律或制度确认。现时权利要进入市场，还需具备可验证，可交付和可结算的路径。

在后面的金融市场章节中，我们会反复遇到一种权利高度标准化的资产头寸：证券。

定义 7.6.

在本文中，**证券** (security) 是指将某种金融权利以相对标准化的单位表示出来，并能够按照相应市场制度发行，持有或转让的一类资产头寸。

股票和债券是最典型的证券。基金份额以及一部分其他金融工具在相应制度下也可以属于证券。

证券首先代表一项金融权利。持有一家公司的股票意味着持有相应的股东权利；公司的厂房和银行账户仍由公司拥有。持有一张公司债券意味着持有发行人按照合同约定进行支付的请求权，具体公司资产的所有权仍取决于合同与法律安排。

同时，“证券”在不同国家和不同法律制度中还具有更加具体的监管定义。这里沿用这一基本金融概念讨论股票，债券，基金和证券交易市场；具体监管分类以所在法域的规则为准。

7.1.2 从权利到状态结果，价值与价格

资产头寸存在以后，下一步先要追踪这些权利和义务在未来状态 s 中会实际产生什么，再谈价值。可以把主体 i 的状态结果粗略写成

$$Y_s^i = (D_s, U_s^i, C_s^i, G_s^i, Q_s^i, O_s^i).$$

这里 D_s 是可交易的现金或资源分配， U_s^i 是实际使用或消费服务， C_s^i 是控制和行动集合变化， G_s^i 是抵押，结算，流动性或安全服务， Q_s^i 是处置，转换或终止回收， O_s^i 则记录费用，维护，融资，税和其他负担。

这些分量不能默认相加。只有存在独立证据支持的货币等价时，某项非现金服务才可以进一步货币化；否则把居住，治理，身份或流动性直接加到现金流上，只会制造量纲混乱和重复计价。

原则 7.7 (类型分离)。

本书将下面几类对象严格分开：

资产头寸 $\rightarrow$ 状态结果 $\rightarrow$ 主体保留价或模型价值 $\leftrightarrow$ 市场机制与价格 $\rightarrow$ 策略损益与回报。

这条链上的每一步都产生不同类型的对象。后文分别追踪头寸，状态结果，条件价值，市场价格与策略回报，并明确各步之间的映射。

价值必须说明是对谁，在什么信息，财富，期限，计价物，模型和终端边界下的价值。后面我们会把一种模型条件值写成

$$F_{i,t}^{\mathcal{M},\vartheta,B}(\mathcal{Z}).$$

它依赖完整头寸 $\mathcal{Z}$ ，模型 $\mathcal{M}$ ，模型参数 ϑ ，主体 i 和终端边界 B 。这些索引共同确定一个条件价值，同一资产可以对应多个条件价值。独立证据 $\mathcal{D}$ 位于模型参数之外，并通过后文的识别集合 $\Theta_{\mathcal{M},B,i,\mathcal{Z}}(\mathcal{D})$ 约束哪些参数值可以被接受。

价格则是市场中带交易条款的交换事实. 它可以约束机会成本, 显示当前供需和边际交易者的选择, 也可以作为反向估值的起点. 价值模型仍需接受独立证据的检验. 价格, 价值和回报之间的区别会贯穿这一节, 并在前面建立的随机过程语言和后面的估值章节中继续展开.

7.1.3 资产与交易市场

股票 我们先从最熟悉的证券之一——股票——开始.

定义 7.8.

股票 (stock) 是指股份公司发行并代表股东权益的一类证券.

持有一家公司的股票, 意味着持有相应的一束股东权利. 这些权利通常包括对于公司未来分配和清算剩余财产的经济索取权, 按照股票类别参与投票和公司治理的权利, 以及在相应市场和法律制度下转让股份的权利.

公司的机器, 专利和银行账户仍归公司所有; 股东持有的是股票及其附带的权利.

同时, 经济权益和公司控制权也不一定按照完全相同的比例分配. 不同类别股票可以把经济权益和投票权拆开配置, 使一家公司在公开交易股份以外仍然保留不同层次的控制权安排.

所以股票可以被理解成一束股东权利, 公司则可以通过不同的股票类别重新组合经济权益和控制权.

股票有意思的地方在于, 这份对于公司的权益本身还可以继续转让. 股票发行以后既完成公司融资, 也成为投资者之间可以继续交易的证券.

一级市场与二级市场 股份以及类似股份的交易在更早以前就已经存在, 不过现代公开股票市场一个很重要的历史起点是 1602 年成立的荷兰东印度公司 (Vereenigde Oostindische Compagnie, VOC). 这里暂时只需要记住: 股份募集资本以后, 这些权利还可以继续在投资者之间转让.

这里已经可以看到现代证券市场最基本的两层结构: 投资者既可以把资本交给发行人换取新发行的证券, 也可以把自己已经取得的证券继续转让给其他投资者.

定义 7.9.

一级市场 (primary market), 也称发行市场, 是指新发行的证券被出售和分配给投资者的市场; **二级市场 (secondary market)** 是指已经发行的证券在不同市场参与者之间继续进行转让和交易的市场.

一级市场最核心的功能是融资. 比如一家公司决定新发行一批股票, 投资者支付资金认购这些股票, 公司得到资本, 投资者则取得相应的股份. 现实中通常还有投资银行和承销商等中介. 区分一级市场的标准是证券处于发行环节, 无需投资者直接到公司购买.

一家公司第一次向公众发行股票并进入公开资本市场的过程通常称为**首次公开募股 (Initial Public Offering, IPO)**. IPO 通常放在一级市场的框架下讨论, 不过一笔 IPO 既可能包含公司新发行的股份, 也可能包含原有股东出售的存量股份. 前者募集的资金进入公司, 后者对应的资金则流向出售股份的原股东.

股票完成发行以后, 原来的股东又可以把股份卖给其他投资者, 这就进入了二级市场. 我们平时在证券交易所买卖某家上市公司的股票, 绝大多数时候进行的都是二级市场交易: 买方支付的资金通常流向愿意卖出股票的市场参与者; 上市公司只在发行等特定交易中获得资金.

概括地说, 一级市场主要解决公司怎样获得资本, 二级市场主要解决投资者怎样重新转让已经取得的证券. 二者相互作用: 如果一项证券发行以后几乎无法再次卖出, 投资者在一级市场第一次认购时也会更加谨慎. 活跃的二级市场会反过来提高证券在一级市场中的吸引力.

交易动机与流动性 二级市场为投资者提供了转让已持有资产的渠道.

一个人可能因为对于公司的判断发生变化而卖出股票, 也可能只是突然需要现金, 想购买另一项资产, 调整投资组合, 降低风险, 偿还债务或者满足保证金要求. 做市商和衍生品交易者还可能纯粹因为对冲需要进行买卖.

买卖双方的动机远比“看多”和“看空”丰富. 即使两个人对于一家公司的长期发展具有完全相同的判断, 也可能因为资金需求, 持仓结构, 风险承受能力, 投资期限以及杠杆约束不同而发生交易.

可转让性只提供制度通道, 实际成交还取决于当时能否在可接受价格附近找到交易对手.

假设市场里面只有很少几个交易者。当我们急着卖出一只股票时，可能恰好没有人在我们能够接受的价格附近愿意买入。此时我们只能继续等待，或者主动降低价格寻找新的买家。反过来，如果市场中长期存在大量愿意在相近价格附近交易的参与者，通常就更加容易找到合适的交易对手。

定义 7.10.

称一项资产或者一个市场具有较高的**流动性**，是指市场参与者能够在较短时间内完成足够数量的交易，而不需要作出过大的价格让步，也不会因为交易本身造成过大的价格变化。

所以从最直观的角度来看，流动性可以先理解成“在自己能够接受的价格附近找到交易对手并完成交易有多容易”。

参与者数量只是流动性的一个条件。如果大量参与者突然同时希望卖出，当前价格附近却缺少愿意接手的人，那么即使市场中有成千上万名交易者，流动性仍可能在很短时间内迅速恶化。

市场流动性和投资者自身的资金流动性是两件事。比如一个投资者仍然认为 Apple (AAPL) 的长期发展很好，但突然需要大量现金偿还债务或者投入其他地方，那么他仍可能被迫卖出股票。如果现金需求足够迫切，他甚至可能接受低于自己估值的成交价格。

一个人愿意接受的交易价格由信息，预期，资金需求，其他投资机会，风险偏好，仓位，杠杆，投资期限和流动性约束共同决定。对公司价值的判断只是其中一项输入。

报价，成交与市场价格 要准确描述价格形成，还要区分报价和已经发生的成交。

在最简单的限价订单簿中，市场参与者可以声明自己愿意按照什么价格买入或者卖出一定数量的资产。令 b_t 表示时刻 t 最高的买入报价，称为**最优买价** (best bid)；令 a_t 表示最低的卖出报价，称为**最优卖价** (best ask)。二者之差 $a_t - b_t$ 称为**买卖价差** (bid-ask spread)，而 $m_t := (a_t + b_t)/2$ 称为**中间价** (mid price)。市场还会记录最近一笔实际完成交易的成交价格；一笔新订单的实际执行价格又可能不同于以上任何一个数字。

因此，现实市场中的“当前价格”取决于所指的价格读数。

一条可以比较的价格记录至少需要带上

$$\chi = (\bar{u}, q^{\text{trade}}, \text{side}, \text{venue}, \text{account}, \text{settlement}, \text{delivery}, \text{kind}).$$

这里 χ 表示交易上下文：它要说明交易的是哪一种已界定单位 $\bar{u}$ ，本次报价，订单或成交涉及多少数量 q^{trade} ，以及买卖方向，交易场所，账户资格，结算资产，交付条件以及读数种类 kind。最后一个字段区分挂牌，bid, ask, mid, last 和 execution 等读数。若 x 表示每一单位 $\bar{u}$ 可以交换多少单位结算资产，那么时刻 t 的完整价格记录写成

$$p = (x, t, \chi).$$

除非另行注明总价，本节所说的价格数值 x 都是每单位交换比率； $q^{\text{trade}}x$ 才是忽略费用时的名义交易金额。挂牌价，最优买价，最优卖价，最近成交价和实际执行价都是不同条件下的价格记录；它们不能在缺少这些索引时被当成同一个数字。

注 7.11.

每一笔已经完成的交易都同时存在买方和卖方，而且成交数量必然相等。价格变化来自主动买卖意愿与当前价格附近可吸收流动性之间的失衡。当大量主动买单不断消耗当前卖价附近提供的股票时，后来的买方如果仍然希望立即成交，就需要接受更高的卖价；反过来也一样。

一笔成交只表明双方接受同一执行价格，其价值判断仍可不同。卖方可能认为按照当前价格出售已经足够划算，买方却认为即使按照同一个价格买入，未来仍然具有足够的潜在收益。

这笔成交只能说明一件事情：双方订单在当时的市场规则下形成了可执行匹配，并按照这个价格交换了股票和现金。

于是市场价格可以被理解成大量不同的信息，判断，需求和约束最终通过实际交易表现出来的结果。

分析师给出的评估价是模型价值，卖方扣除费用以后实际收到的是结算结果，尚未提现的账户余额可能是一项新的中间请求权。这些对象可以进入同一条兑现路径，但分别属于模型价值，结算结果和中间请求权。

7.1.4 价格与收益率

价格与市场预期 在大多数正常情况下, 股票持有者可以继续持有股份. 当投资者现金充足, 缺少更好的配置机会, 并且仍然看好所持公司的未来时, 继续持有就是合理选择.

这时如果新的投资者希望从现有持有人手中取得股票, 就需要给出一个足以让其中一部分人愿意放弃这部分未来权益的价格. 价格越高, 原本愿意继续持有的人中, 通常就会有更多人认为“现在卖掉已经足够划算”.

买方愿意支付这个价格, 是因为他判断按当前价格买入仍有吸引力.

于是股票价格天然开始包含市场对于未来的判断.

股票本身代表的是对于企业未来剩余价值的索取权, 所以一个投资者今天愿意为它支付多少钱, 不可能只取决于公司过去已经发生了什么. 他还必须考虑公司未来能够赚多少钱, 盈利能够持续多久, 企业还需要投入多少资本, 最终有多少价值能够归属于股东, 以及为了等待这些未来结果并承担相应风险, 自己需要获得多高的回报.

从这个意义上来说, 可以先把股票市场理解成一个**预期市场**.

这里所谓的“预期市场”, 是指今天的价格已经受到市场参与者对未来各种可能状态的判断影响. 它只描述价格形成的前瞻性; 预测准确度和公允价值仍是另外的问题.

股票价格对新信息与既有预期之间的偏差尤为敏感. “公司变好了还是变坏了”只描述结果的方向. 一家公司盈利增长 20% 也未必带来股价上涨, 因为市场此前可能已经按照增长 30% 定价; 反过来, 一家仍然亏损的公司只要实际结果明显好于此前预期, 股价同样可能上涨.

单一价格可以与多种预期组合相容. 它可能来自更高的盈利预期和更高的要求回报率, 也可能来自更低的盈利预期和更低的贴现率; 流动性, 风险溢价, 仓位和资金约束同样会参与价格形成.

因此市场价格是大量信息, 预期和现实约束在这一时刻通过交易压缩出来的结果. 从中恢复未来的完整概率分布还需要额外假设.

从价格记录到价格过程 有了这些背景以后, 我们终于可以正式引入数学模型中的价格.

固定交易上下文 χ , 也就是资产单位, 拟交易数量, 买卖方向, 场所, 账户, 结算资产和交付条件以后, 令 S_t^χ 表示这组约定下时刻 t 的每单位价格读数. 比如如果一单位资产当前大约能够按照 200 单位计价资产交换, 那么可以粗略记作 $S_t^\chi = 200$.

在最简单的模型里, 如果 χ 始终固定且不会造成歧义, 我们就省略上标, 把 S_t^χ 简写成 S_t .

这里已经进行了两次建模简化. 第一次是把一组带条款的价格记录投影成一个标量; 第二次是把买价, 卖价, 中间价, 最近成交价以及实际执行价格压缩成统一的 S_t . 在最简单的金融模型里这样做很方便, 但后面研究市场分割, 结算和交易执行时, 这种简化就不再足够.

价格还永远是相对于某种计价资产而言的. 200 单位计价资产是在说“用哪种东西来度量价格”. 后面讨论贴现和无套利时, 我们会把这种计价基准进一步抽象成计价资产 (numéraire).

站在未来尚未发生的时刻来看, S_t 是一个随机变量; 当时间不断变化以后, $(S_t)_{t \in T}$ 就形成了资产的价格随机过程. 后文将研究这个过程在所选模型中的时间和概率结构.

现金流, 收益与收益率 在最简单的一单位现货多头策略中, 金融损益同时来自价格变化和持有期现金流. 股票可能支付股息, 债券可能支付票息, 其他资产也可能在持有期间产生现金流.

令 D_t 表示截至时刻 t 一单位头寸累计向持有者支付的现金流, 并令 $G_t := S_t + D_t$. 如果投资者在时刻 s 按照 $S_s > 0$ 买入一单位, 全额支付以后一直持有到 t , 且忽略交易费用, 税和融资成本, 那么这项简单策略的持有期损益就是

$$G_t - G_s = S_t - S_s + D_t - D_s.$$

例 7.12 (除息).

假设一只股票在除息以前的价格为 \$100, 随后每股支付 \$1 股息, 并在除息以后以 \$99 交易. 如果只观察股票价格, 它似乎下跌了 1%; 但原来的股东同时取得了每股 \$1 的现金流.

在忽略税费以及其他市场变化的理想情况下, 除息前后的总持有收益保持不变.

为了比较不同价格尺度下的这类简单策略, 我们通常还会把损益除以最初投入的资金.

定义 7.13.

在上述一单位, 全额支付, 买入并持有的假设下, 令 $S_s > 0$. 从时刻 s 到 t 的简单价格收益率定义为

$$R_{s,t}^P := \frac{S_t - S_s}{S_s}.$$

如果进一步把持有期间收到的现金流计算进去, 则相应的总收益率定义为

$$R_{s,t} := \frac{S_t - S_s + D_t - D_s}{S_s}.$$

在这项简单策略中, “损益” 描述实际赚了多少钱, “收益率” 描述相对于明确资本基数赚了多少. 对于股票多头来说, 价格上涨和股息都可能构成金融损益的一部分, 因此长期研究还要区分原始价格 (raw price), 复权价格 (adjusted price) 和总回报 (total return) 之间的区别.

这里定义的 D_t 只是把该单位实际分配的现金流累计起来. 如果投资者收到股息以后立即重新投入, 那么财富又会按照新的头寸继续增长, 此时更加自然的对象是总回报财富过程 (total-return wealth process).

对数价格变化与对数收益率 除了简单收益率以外, 金融市场里面还经常使用对数收益率.

定义 7.14.

如果 $S_s, S_t > 0$, 则同一组价格条款下从时刻 s 到 t 的对数价格变化定义为

$$r_{s,t} := \log \frac{S_t}{S_s}.$$

它在金融文献中通常也称为对数价格收益率.

对数收益率与金融市场的复利结构很契合. 如果连续两期的简单收益率分别为 R_1, R_2 , 那么 \$1 最后变成 $(1 + R_1)(1 + R_2)$; 用 $1 + R_1 + R_2$ 会漏掉复利项. 财富增长具有乘法结构, 对数则把它转换为加法.

由于 $r_{s,t} = \log(1 + R_{s,t}^P)$, 如果 $s < u < t$, 就有

$$r_{s,t} = r_{s,u} + r_{u,t}.$$

同时 $S_t = S_s e^{r_{s,t}}$, 所以 $r_{s,t}$ 可以理解成区间 $[s, t]$ 对应的累计连续复利收益. 如果要换成单位时间的连续复利收益率, 还需要进一步除以 $t - s$.

当收益率比较小时, 由 $\log(1 + x) \approx x$, 简单收益率和对数收益率在数值上通常很接近.

其中 $\log(S_t/S_s)$ 只记录价格读数的对数变化. 完整策略回报还要纳入现金流, 头寸和交易规则. 如果持有期间存在股息等现金流, 研究投资者财富的复利增长时应该考虑相应的 total-return wealth process. 这个定义还要求价格严格为正, 所以对于可能达到零甚至取负值的金融变量也不再适用.

7.1.5 策略, 头寸与财富

头寸与损益 投资者的实际损益同时取决于资产价格变化和持有数量.

定义 7.15.

对一项已经指定单位, 权利类别和持有位置的资产, 时刻 t 的数量头寸是指投资者在这一时刻净持有的单位数, 记作 θ_t .

当 $\theta_t > 0$ 时称为多头头寸; 当 $\theta_t < 0$ 时称为空头头寸; 当 $\theta_t = 0$ 时则表示没有净头寸.

多头和空头首先描述头寸方向. 从数学上来看, 这相当于允许资产持有量成为一个有符号的数量. 多头通常从价格上涨中获利, 空头通常从价格下降中获利. 头寸方向与主观看法仍要分开: 做市商或者衍生品交易者完全可能为了对冲某种风险而建立空头头寸.

这里的 θ_t 是固定 $\bar{u}$ 和制度上下文以后由完整经济头寸 Z_t^i 投影得到的有符号持仓坐标. 只有在最简单的无负担多头情形下, 才可以令 $\theta_t = n_t^i$; 空头的负号通常还依赖 L_t^i 中的借券和返还义务.

它描述的是某一时刻的存量, 而 q^{trade} 描述一笔报价, 订单或成交涉及的交易数量. 因此 θ_t 只是完整经济头寸 $\mathcal{Z}_t^i$ 的数量坐标. 后者还包含账户, 权利, 执行机制和附随义务.

如果从 s 到 t 始终持有固定头寸 θ , 那么这一段时间产生的损益为

$$\text{P\&L}_{s,t} = \theta(S_t - S_s + D_t - D_s).$$

这个公式明确只描述“单次进入, 固定数量持有, 单次退出或期末标记”的情形. 期间若没有再平衡, 同一受限情形的现金口径可以写成

$$\Pi_{0:H}^{\text{financial}} = \sum_{\tau=1}^H \Delta D_{\tau}^{\text{cash}} + V_H^{\text{terminal}} - C_0^{\text{entry,all-in}} - C_{0:H}^{\text{funding}} - O_{0:H}^{\text{other}}.$$

这里 $C_0^{\text{entry,all-in}}$ 是实际从现金账户扣除的买入价款与入场费用之和. $\Delta D_{\tau}^{\text{cash}}$ 是整个固定头寸在第 τ 期实际收到的净现金分配, 已经包含持仓数量. V_H^{terminal} 必须声明为已经扣除退出费用的实际退出净现金, 或仍持仓时按指定规则得到的期末标记. 期末标记仍是按规则计算的持仓价值; 清算冲击和退出费用必须另行声明. 各项费用只进入一个类别, 以免重复扣除.

对于允许多次成交, 动态头寸, 融资和中间现金流的一般策略 h , 必须改用闭合的财富账户. 令

$$V_t^h = C_t^h + \text{MV}_t^h(\theta_t^h),$$

其中现金账户 C_t^h 逐笔记录买卖成交现金流, 分配, 交易费用, 融资与偿债, 保证金和变动保证金现金流, 而 θ_t^h 是已经确认的持仓. MV_t^h 是按已声明规则得到的未平仓头寸价值; 普通现货的线性标记是 $\text{MV}_t^h(\theta_t^h) = (\theta_t^h)^\top S_t$, 合约报价与头寸价值分离时, 需要改用该合约的价值映射. 若 A_t^h 是累计外部净注资, 以流入策略为正, 则一般金融净损益定义为

$$\Pi_{0:H}^{\text{financial}}(h) = V_H^h - V_0^h - (A_H^h - A_0^h).$$

终点财富必须同时包含现金, 债务和按已声明价格标记的未平仓头寸. 已经进入现金账本的成交, 分配或费用不得在损益式中再加减一次. 第6.2节和第6.6节的自融资恒等式和现金账本正是这一一般账户的逐期实现; 只有实际成交及其后续现金流会进入财富变化; 目标仓位和交易信号用于生成交易决策.

只有当资本基数 $K_0^h > 0$ 且经济含义明确时, 才进一步定义策略金融回报率

$$R_{0:H}^{\text{financial}}(h) = \frac{\Pi_{0:H}^{\text{financial}}(h)}{K_0^h}.$$

因此回报属于一个已经定义进入, 持有, 融资和退出规则的策略, 不属于“股票”“期货”或“黄金”这样的资产标签. 价格变化和现金分配只是策略损益的输入, 进入, 持有, 融资和退出规则共同生成最终回报.

如果持有人在期间实际消费了居住, 使用或其他非现金服务, 而又缺少把它们换算成同一计价物的独立证据, 就应分别报告金融损益与已消费服务, 避免把效用单位直接加进货币利润.

交易本身可以理解成对头寸的调整. 如果头寸从 θ_s 变成 θ_t , 净头寸变化就是 $\theta_t - \theta_s$. 后面讨论交易执行时, 问题会从“要不要买”进一步展开为: 如何沿一条合适的路径把当前头寸逐渐调整到目标头寸.

保证金与杠杆 现实市场允许投资者通过融资或提交抵押物建立超过初始自有资金的市场暴露, 这就引出了保证金.

定义 7.16.

保证金 (margin) 是指为了建立或者维持某些交易头寸, 投资者需要向经纪商, 清算机构或者其他交易对手提交或者保留的一部分现金或合格资产.

保证金的主要作用是为潜在损失和履约风险提供缓冲. 它属于交易履约安排, 与市场头寸和实际融资金额分别核算.

例如, 假设投资者想建立价值为 \$100 的股票多头头寸, 但只投入 \$50 自有资金, 剩余 \$50 由经纪商融资. 那么投资者虽然只有 \$50 的初始净财富投入, 却承担了 \$100 股票头寸的价格变化.

如果股票上涨 10%, 头寸价值增加 \$10; 相对于最初 \$50 的自有资金而言, 投资者的收益率就是 20%. 反过来, 如果股票下跌 10%, \$10 的亏损同样相当于自有资金的 20%.

同一价格记录计算出的价格收益率保持不变, 融资则改变了具体策略的资本基数, 融资成本, 路径约束以及价格变化对投资者财富的放大程度.

定义 7.17.

杠杆 (leverage) 是指投资者所承担的市场风险暴露相对于自身净财富的放大程度.

在最简单的单资产情形下, 如果资产头寸的市场价值为 $|\theta_t S_t|$, 投资者净财富为 $V_t > 0$, 那么可以粗略地用

$$L_t = \frac{|\theta_t S_t|}{V_t}$$

描述这一头寸相对于净财富的杠杆程度.

这里的定义只适用于最简单的情形. 对于包含多项资产, 空头以及衍生品的组合, 实际风险还要结合 Delta, duration 或者其他风险暴露来衡量; 名义头寸之和只提供粗略尺度.

保证金制度还有一个重要特点: 随着市场价格变化, 投资者自身在头寸中的净权益也会变化. 当资产价格朝不利方向移动以后, 原来的保证金可能已经不足以覆盖规定的风险缓冲.

定义 7.18.

当账户中的保证金或者净权益下降到规定水平以下, 交易机构要求投资者补充资金或者抵押物, 这种要求称为**追加保证金** (margin call).

如果投资者没有及时满足要求, 部分头寸可能被强制平仓.

杠杆除了放大亏损, 还会加入路径约束. 即使投资者认为资产长期最终会重新上涨, 他也可能因为中途价格波动导致保证金不足, 在恢复以前就被迫退出头寸.

注 7.19.

“Margin” 在不同市场中对应不同机制.

股票保证金账户中, margin 往往和经纪商融资直接联系在一起. 投资者用部分自有资金建立股票头寸, 其余部分由经纪商提供贷款.

期货 initial margin 主要充当履约担保. 建立期货合约时, 交易者没有按照合约名义价值借入一笔剩余资金; 此后合约按照市场价格逐日盯市, 盈亏通过 variation margin 在账户之间结算.

因此

$$\text{Margin} \neq \text{Down Payment} \neq \text{Loss}.$$

保证金是一种交易制度和风险管理机制; 它怎样运作, 必须结合具体市场来看.

同一个金融工具既可以降低风险, 也可以放大风险. 一项期货或期权头寸如果用来抵消原有资产风险, 可以降低整个组合的净风险暴露; 但如果投资者在没有相应基础头寸的情况下利用保证金建立很大的方向性头寸, 同一种工具又可能产生很高的杠杆.

投资组合与财富 现实中的投资者通常会同时持有很多资产. 如果市场中存在 n 项资产, 可以把投资者在时刻 t 的资产头寸写成

$$\theta_t = (\theta_t^1, \dots, \theta_t^n),$$

相应的价格向量记作

$$S_t = (S_t^1, \dots, S_t^n).$$

如果再令 C_t 表示现金头寸, 那么在最简单的情况下,

$$V_t = C_t + \sum_{i=1}^n \theta_t^i S_t^i = C_t + \theta_t \cdot S_t$$

就是投资组合在时刻 t 的市场价值。

这里的 C_t 也不一定必须为正。如果投资者通过借款为其他资产头寸融资，那么相应的现金或者融资账户可以表现为负头寸。如果一部分现金被提交为保证金，则还需要在具体模型中区分可自由使用的现金和受到限制的抵押资产。

注 7.20.

提交保证金通常只改变资产用途，不会立即造成等额财富损失。

如果 \$10 现金从自由现金账户转入保证金账户，这笔钱仍然属于投资者，但暂时受到使用限制。随后的交易损益，融资成本，手续费以及违约等经济事件才会改变净财富。

因此在研究财富过程时，最好把“资金被占用”和“财富发生损失”区分开来。

对冲通过配置若干个不同方向的头寸，让某些市场变化对整个组合的影响相互抵消。如果这些头寸还会随时间调整，就要区分市场变化产生的投资损益和投资者从外部投入或取出的资金。前面的随机过程到金融市场接口已经用自融资条件 (self-financing condition) 正式处理了这个问题；后文将继续讨论它在具体估值模型中的作用。

7.1.6 通往随机过程：价格是市场状态的读出

到这里可以明确价格过程的位置。设 X_t 表示一个更高维的市场状态，其中可能包含经营状态，权利规则，账户资格，财富与融资约束，采用率，抵押能力，订单流，流动性和结算状态。我们通常只观察或建模它的若干读出：

$$X_t \mapsto (S_t^\chi, D_t, V_t^h),$$

其中 χ 汇总价格记录所固定的交易条款， D_t 是分配过程， V_t^h 是策略 h 的财富过程。

只给 S_t 指定一个随机过程当然可能很有用，但它相当于把生成价格的权利，制度和市场机制都压进一个尚未展开的模型层。如果这些被省略的状态足够稳定，价格过程模型可能近似得很好；如果账户规则，流动性，抵押能力或结算制度发生跳变，同一个价格模型就可能突然失效。

反馈还会从价格返回状态。价格变化可能改变财富，保证金，抵押能力，参与者和采用率，进而反过来改变后续状态转移。这正是后面滤过，马尔可夫状态，跳跃过程，点过程和随机控制由此进入金融市场。

股票让我们看到不确定价格，现金流和财富过程。下一节转向衍生品，看这些风险怎样被重新写成合约现金流。

7.2 衍生品与或有现金流

第7.1节和第7.1.5小节先把资产单位，价格记录和头寸方向分开。这里再把未来状态重新写成合约现金流。如果认为一只股票会上涨，最直接的办法是买入股票；如果已经持有股票并且担心价格下跌，最直接的办法则是卖掉一部分。

现实市场还提供另一类做法。

市场参与者还可以彼此约定，在未来某个时间或者某些条件满足以后怎样进行交易，由谁向谁支付多少现金，或者由谁承担某项权利和义务。这种约定本身也可以具有市场价值，甚至进一步成为可以转让和交易的金融对象。

在第二部分的风险主线上，衍生品是一类横向工具，不属于从股票逐档走向低风险资产的下一类别。同一份期货或期权既可以放大风险，也可以转移和限制已有风险。本节关心它们如何把未来状态重写为合约现金流。

衍生品和期权部分的通用背景主要参考 [Hul22; Opt; US 15]。

介绍衍生品以前，先明确这里的合约含义。

定义 7.21.

在本文中，**金融合约** (financial contract) 是指交易双方或者多方之间，对于未来权利，义务或者现金流所作出的具有约束力的约定。

一份金融合约通常会规定在什么时间或者什么条件下，由谁向谁交付什么资产或者支付多少现金。

这个定义服务于后文的金融建模，不涵盖法律意义上 contract 的全部内容。现实中的金融合约还受具体司法制度，交易所规则，清算安排以及违约处理机制约束。建模时先关心合约建立后，不同

未来状态对应哪些权利, 义务和现金流.

假设一家航空公司知道自己三个月后需要购买大量燃油. 今天的燃油价格已经确定, 公司承担的是未来涨价风险. 如果等到三个月后再买, 到时的价格今天无法确定. 航空公司可以考虑先用合约约定三个月后的交易价格.

这类关于未来交易的约定构成了衍生品的基本雏形.

定义 7.22.

衍生品 (derivative) 是指其价值或者未来现金流依赖于某项资产, 市场变量或者未来事件状态的金融合约.

用来决定衍生品价值或者现金流的参考对象通常称为**标的** (underlying).

“衍生”涵盖的关系远比某项资产价格乘上一个系数广. 股票和商品可以作为标的, 汇率和利率也可以, 股票指数甚至波动率同样能成为参考对象. 交易者围绕标的未来可能出现的状态建立合约, 无须直接交易原资产.

因此衍生品最自然的理解方式, 是把未来状态和未来现金流重新联系起来.

定义 7.23.

或有现金流 (contingent cash flow) 是指其金额或者是否发生取决于未来某些市场状态或者事件的现金流.

比如一份合约可能规定: 如果三个月以后某只股票价格超过 \$100, 就按照某种规则支付一笔钱; 如果没有超过 \$100, 就不支付. 站在今天来看, 这笔未来现金流尚未确定.

如果合约在时刻 T 的最终支付只取决于标的资产价格 S_T , 后面我们经常会把它简单写成

$$X = \Phi(S_T).$$

这个表达式可以先读成

未来发生什么 $\rightarrow$ 合约支付什么.

金融市场做的很多事情, 就是把这样的映射本身做成可以交易的金融合约.

7.2.1 线性衍生品与期货

远期合约 刚才航空公司的问题可以先用最简单的远期合约来理解.

定义 7.24.

远期合约 (forward contract) 是指交易双方现在约定, 在未来某个时刻 T 按照事先确定的价格 K 买卖一定数量标的资产的合约.

假设我们现在约定三个月以后按照 \$100 买入一股股票. 如果三个月以后股票价格已经变成 \$120, 那么按照 \$100 买入对多头有利; 如果到时候股票只有 \$80, 多头仍然需要按照 \$100 买入, 相对于当时的市场价格就处于不利位置.

衍生品到期时究竟怎样完成合约, 还需要区分两种最常见的结算方式.

定义 7.25.

实物交割 (physical delivery) 是指合约到期以后, 交易双方按照约定实际交付标的资产并支付相应价款.

现金结算 (cash settlement) 是指根据合约规定计算应付金额并直接以现金结清差额, 无须实际交付标的资产.

以后我们把合约在到期时产生的净支付称为**到期支付** (payoff). 合约今天的市场价值和投资者最终的盈亏 (P&L) 是另外两层对象.

只考虑一单位标的的时, 远期多头在到期时按照 K 买入价值为 S_T 的标的, 因而它的净经济价值为

$$S_T - K.$$

如果采用现金结算, 这一数值可以直接表现为结算金额; 如果采用实物交割, 多头则支付 K 并收到价值为 S_T 的标的. 远期空头的到期支付刚好相反, 为 $K - S_T$.

这里还需要区分两个以后很容易混在一起的概念. 对于一份刚刚建立的远期合约, 交割价格 K 通常会被设定在使合约初始价值为零的位置. 这个使新远期合约初始价值为零的交割价格, 通常称为该期限下的**远期价格** (forward price).

之后市场发生变化时, 原来约定的 K 保持不变. 这份存量远期合约的市场价值则可能转为正值或者负值.

以下两个对象需要始终区分:

新的远期合约对应的远期价格 和 已经存在的远期合约的当前价值.

新的远期价格与存量远期合约的当前价值属于两个不同对象.

期货与实际对冲 远期的经济逻辑很简单. 如果每家公司都分别寻找交易对手, 自己约定数量, 到期时间, 交割方式以及信用安排, 交易会非常麻烦. 期货把这类未来价格交易标准化, 并放入统一的市场制度中.

定义 7.26.

期货合约 (futures contract) 是指按照交易所规定的标准化条款交易, 并根据未来标的价格或者相应结算价格产生盈亏的一类衍生品合约.

期货和远期都在今天建立关于未来价格的头寸. 期货进一步引入中央清算, 保证金制度和逐日盯市, 合约的交易方式与现金流时点也随之改变. 在最简单的模型中, 同期限的期货和远期价格可以十分接近; 更一般的市场环境则会使两者出现差异.

定义 7.27.

名义金额 (notional amount) 是衍生品合约中用于确定现金流或者风险规模的参考金额.

一份期货合约可能代表 \$100,000 的标的风险暴露, 投资者建立头寸时通常只需提交保证金.

定义 7.28.

保证金 (margin) 是指交易者为了保证衍生品合约履约而存入的资金或者合格抵押品.

保证金承担履约保障功能, 有别于购买标的资产的首付款. 投资者承担的风险仍由整个合约规模决定.

定义 7.29.

逐日盯市 (marking to market) 是指市场按照每日结算价格重新计算已有期货头寸的损益, 并将相应金额计入或者扣除保证金账户的结算机制.

较少的保证金可以控制较大的名义金额, 由此形成杠杆. 投资者占用一小部分保证金, 同时承担整个合约规模对应的价格变化. 即使投资者最终判断对了价格方向, 中间路径仍然会决定保证金压力. 如果价格在到达最终目标以前先大幅向不利方向移动, 投资者可能因为保证金不足而被要求补充资金, 甚至在价格恢复以前就被迫退出头寸.

金融市场中的风险往往同时取决于终点与中间走过的路径.

例 7.30 (航空公司的燃油对冲).

假设一家航空公司担心三个月以后燃油价格上涨, 它可以提前建立与未来采购风险相匹配的期货多头.

航空公司通常不会等期货到期后再通过交易所完成实际燃油采购. 实物采购和金融对冲是两条分开的链条: 公司按原有供应体系向炼油商或燃油供应商购买所需的航空燃油, 同时在期货市场建立金融头寸, 用期货损益抵消一部分实际采购价格的变化.

临近实际采购时, 公司通常可以通过建立相反方向的期货交易把原来的头寸**平仓** (close out), 然后继续通过正常供应渠道购买燃油.

如果把期货头寸的累计损益记为 Π_T^{fut} , 并约定盈利为正, 亏损为负, 那么对冲后的净采购

成本可以粗略写成

对冲后的净采购成本 = 实际采购支出 - $\Pi_T^{\text{fut}} \approx$ 事先希望锁定的采购成本.

油价意外上涨时, 增加的实际采购支出会由期货多头的正损益部分抵消; 油价下降时, 实际采购变得便宜, 期货头寸则可能亏损. 期货由此帮助企业稳定净采购成本, 同时保留原有的物流和供应链.

上式中的 $\approx$ 非常重要. 航空公司实际购买的航空燃油和期货合约所追踪的标的未必完全相同, 采购地点, 品种, 时间以及市场价格变化之间也很难始终严格同步.

定义 7.31.

基差风险 (basis risk) 是指实际需要对冲的价格与所使用衍生品的价格不能完全同步变化, 因而在建立对冲以后仍然留下的风险.

对冲通常会留下基差等剩余风险. 衍生品常把原来无法接受的风险换成规模更小或者更容易管理的风险.

例 7.32 (基差作为交易对象).

基差既是风险来源, 也可以成为交易对象.

美国国债市场中的**国债基差交易** (Treasury cash-futures basis trade) 就是典型例子. 交易者可能买入可交割现券, 同时卖出国债期货, 押注现券和期货之间的相对价格关系会按照交割机制和持有成本约束收敛 [AS23; BKM23].

这类交易押注两种高度相关工具的相对价格, 因而削弱了对“美国国债整体上涨还是下跌”的直接押注. 头寸同时承担 repo 融资, 期货保证金, 流动性和中途去杠杆风险. 完整机制放到下一节的美债与 repo 背景中再展开.

永续合约 上面的例子仍然属于有固定到期日的期货. 在加密货币市场中, 还非常常见一种具有期货式价格暴露, 同时取消固定到期日的合约: **永续合约** (perpetual futures 或 perpetual swap, 常简称 perp). 这类合约的理论背景和市场机制可以参考 [Ang+22; He+24].

定义 7.33.

永续合约是指一种以某个标的资产价格或者价格指数为参考, 允许交易者持续持有多头或空头价格暴露, 且通常没有固定到期日的保证金衍生品合约.

下面只讨论最常见的一单位线性永续合约. 现实中还可能存在反向合约或者 quanto 合约, 其保证金计价和盈亏函数会更加复杂, 需要另行建立相应的盈亏公式.

如果只看价格方向, 永续合约和期货很像: 多头希望标的价格上涨, 空头希望标的价格下跌. 普通期货有一个到期日 T , 临近到期时会通过交割或者现金结算把期货价格和结算价格联系起来. 永续合约没有这个强制收敛时刻, 永续合约因此需要另一套机制来影响合约价格和现货指数之间的偏离.

这套机制通常称为**资金费率** (funding rate). 在离散时间 $t_1, t_2, \dots$ 上, 交易所会根据永续合约价格相对于参考现货指数的偏离, 以及利率等约定项, 计算一个资金费率. 如果永续合约价格明显高于现货指数, 通常会出现正的资金费率, 多头向空头支付资金费用; 如果永续合约价格明显低于现货指数, 资金费率可能为负, 空头向多头支付资金费用.

粗略地说, 如果一单位名义金额的资金费率为 f_k , 且 $f_k > 0$ 约定为多头支付, 那么在第 k 个资金费率结算时点附近, 多头的有符号资金收入可以写成

$$\Delta A_{t_k}^{\text{fund}} \approx -f_k \times \text{名义金额}.$$

这里 $\Delta A_{t_k}^{\text{fund}} > 0$ 表示多头收到资金费用, $\Delta A_{t_k}^{\text{fund}} < 0$ 表示多头支付资金费用. 真实交易所会有更具体的指数构造, 费率上限, 结算频率以及保证金规则, 核心思想是:

价格偏离 $\rightarrow$ 资金费用 $\rightarrow$ 持仓成本变化 $\rightarrow$ 套利或方向性交易激励 $\rightarrow$ 价格锚定.

永续合约在普通期货的价格暴露之外增加了持续锚定机制。普通期货主要通过到期结算来建立期货价格和标的价格之间的关系；永续合约通过连续或者周期性的资金费用，把持有某一方向头寸的成本变成合约结构的一部分。永续合约的现金流由此沿着整条持仓路径不断发生，区别于到期时刻的一次支付。

因此永续合约特别适合作为随机过程的例子。一个交易者持有永续合约时，他的盈亏同时取决于未来某个时刻的标的价格，中间路径上的永续合约价格和指数价格之间的基差，资金费率的随机变化，保证金余额和强平边界，以及市场流动性，订单簿深度和价格跳跃。

如果用 P_t^{perp} 表示线性永续合约的市场价格， I_t 表示参考指数价格， A_t^{fund} 表示截至时刻 t 的有符号累计资金收入，那么一单位多头的简化损益可以粗略写成

$$\Pi_t = (P_t^{\text{perp}} - P_0^{\text{perp}}) + A_t^{\text{fund}}.$$

这里的 A_t^{fund} 是沿时间积累的随机过程。永续合约由此把价格过程，基差过程，资金费率过程和保证金路径共同纳入同一个动态系统中。

资金费率机制通过持仓成本和交易激励推动价格锚定。永续合约价格仍可能偏离现货价格。价格回归还取决于交易者是否愿意并能够同时交易现货和永续合约。如果市场单边情绪很强，杠杆需求集中，融资或抵押品约束收紧，交易所风险上升，或者流动性突然变差，永续合约价格仍然可能长期偏离指数价格，资金费率也可能成为持仓成本和市场拥挤程度的直接信号。因此在实际市场里，永续合约同时是一个方向性杠杆工具，一个观察市场多空需求和杠杆拥挤的窗口，也是一个天然带有路径依赖现金流的衍生品例子。

算力期货 期货最容易让人联想到原油，小麦或者黄金这些传统商品，其标的也可以是无法装上卡车或者轮船运走的价格指标。

例 7.34 (算力期货).

算力期货是一个仍在形成中的例子。这里只追踪算力价格的标准化及其进入衍生品市场的尝试，不对任何当前合约的流动性成熟度作出判断。

这类合约即使被设计出来，也仍然需要经历报价，成交量和持仓量逐渐形成的过程。

随着大模型训练和推理需要大量 GPU，对一些模型公司和云服务商来说，算力本身已经成为一项重要经营成本。假设一家公司知道自己半年以后需要大量 H100 或者 B200 算力，那么它面对的问题其实和航空公司未来需要燃油非常类似：未来资源需求已经确定，价格尚未确定。

算力缺少石油那样易于统一的计量单位。GPU 型号，集群规模，网络结构，数据中心位置，租赁期限以及服务质量都可能影响实际采购成本。算力进入标准化衍生品市场以前，必须先回答：到底用什么价格代表“算力价格”？

一种方法是收集 GPU 租赁市场中的报价，对不同交易条件进行标准化，再构造以每 GPU-hour 租赁成本表示的价格指数。市场有了这样一个相对稳定的价格基准以后，才能够进一步围绕这个指数设计标准化期货合约。

整个过程大致是

现实资源 → 价格基准 → 标准合约 → 形成流动性 → 可投入使用的对冲工具。

合约设计和正式上市只是起点。市场还需逐渐形成足够的成交量，持仓量和连续报价，企业才能以可接受的交易成本建立和退出头寸，并把合约用作有效的对冲工具。

算力期货还面对一种特殊的基差风险：技术迭代。一家企业半年后所需的设备可能已从 H100 变成 B200，下一代加速器或完全不同的 GPU 集群结构。即使一份期货能够很好地跟踪 H100 的租赁价格，它也未必能充分对冲企业未来的有效算力成本。

这个例子展示了期货市场的一项核心功能：从现实经营中抽取原本难以单独交易的价格风险，为它建立可观察的价格基准，再做成标准化的金融头寸。这一功能不以向交易者交付实物为必要条件。

股指期货 算力期货已经说明，期货标的可以超出能够直接交割的实物。股指期货把这件事情再往前推进一步。

S&P 500 是按照既定规则计算出来的指数数值, 无法像普通资产那样直接买卖. 投资者平时说“买入 S&P 500”时, 通常是在买入跟踪该指数的交易所交易基金 (exchange-traded fund, ETF), 指数基金或其他金融产品. 市场仍可以围绕这个指数的未来水平建立期货合约.

定义 7.35.

股指期货 (stock index futures) 是指以某个股票指数作为标的, 根据指数未来水平确定合约价值和结算金额的一类期货合约.

股指没有普通意义上可供交割的实物. 合约无法要求空头在到期以后交付“5000 点 S&P 500”, 因而通常使用现金结算.

如果用 $F_{0,T}$ 表示建立头寸时的期货价格, I_T^{settle} 表示到期时用于结算的指数水平, m 表示每一个指数点对应的合约金额, 那么忽略逐日结算产生的资金时间差异以后, 多头的累计损益可以粗略写成

$$m(I_T^{\text{settle}} - F_{0,T}).$$

例 7.36 (利用股指期货降低市场风险).

假设一家基金持有几百只股票. 基金经理可能仍然看好这些公司的长期前景, 同时担心接下来几个月整个股票市场因为经济衰退, 利率变化或者其他系统性事件一起下跌.

一种办法是把这些股票全部卖掉, 代价是交易成本和持仓结构的改变. 基金也可以继续持有股票, 同时卖出一定数量的股指期货, 从而降低组合对于整个市场方向变化的敏感程度.

基金组合和期货所追踪的指数存在偏差时, 对冲会留下剩余风险. 所需合约数量还取决于组合对于该指数变化的敏感程度.

空头头寸也可以承担风险管理功能. 一个基金经理完全可以长期看好自己的股票, 同时为了降低短期系统性风险而卖出股指期货.

股指期货也给我们留下了一个后续问题: **S&P 500, Nasdaq-100 或者其他市场指数, 到底怎样构造?** 这个问题会自然引向市场指数, ETF 和被动投资.

远期和期货价格就是未来价格吗 既然期货允许我们在今天建立关于未来价格的头寸, 一个自然的问题随之出现: **期货价格能否视为市场对于未来现货价格的预测?**

期货价格的首要含义来自无套利与持有成本关系.

下面先从远期价格开始考虑. 这是一段无套利关系预览; 贴现和无套利的正式语言会在后面再展开. 假设一项今天价格为 S_0 的资产可以自由买卖和卖空, 市场中没有交易成本, 资产在持有期间不支付股息或者其他现金流, 投资者可以按照同一个确定利率 r 借入和贷出资金, 并且采用连续复利. 如果一份新建立的远期合约以 T 为到期日, 并且交割价格被设定在使合约初始价值为零的位置, 那么无套利关系给出

$$F_{0,T} = S_0 e^{rT}.$$

这里的 $F_{0,T}$ 应理解成这份新远期合约的合理交割价格. 在上述简化假设下, 若 $r > 0$, 则 $F_{0,T} > S_0$; 若 $r = 0$, 则 $F_{0,T} = S_0$; 若 $r < 0$, 则 $F_{0,T} < S_0$. 这三个方向都由融资成本的符号决定, 不表示市场对未来现货涨跌的预测. 投资者今天可以借入或贷出资金并交易现货, 然后持有到时刻 T . 如果远期交割价格和这套复制操作的最终成本相差过大, 投资者就可能通过同时交易现货, 融资资产和远期合约构造套利.

$F_{0,T}$ 和 S_0 之间受**无套利和持有成本**关系约束, 持有成本的正负和大小不提供方向预测. 如果资产会支付股息, 中间现金流归现货持有人, 远期价格便需要相应调整. 对于商品, 持有实物还可能产生仓储, 保险和损耗成本; 与此同时, 拥有库存本身又可能给生产和经营带来便利, 这种价值通常称为**便利收益 (convenience yield)**. 这些因素可以统一放进**持有成本 (cost of carry)**中理解.

期货还需要考虑逐日盯市. 在利率确定等简单条件下, 同期限的期货价格和远期价格可以视为相同. 期货会逐日结算, 远期则主要在到期时结算; 利率随机变化时, 现金流时点的差异可能使两种价格分离.

那么市场对于未来价格的现实判断在哪里? 这就需要比较另一个对象:

$$\mathbb{E}^{\mathbb{P}}[S_T],$$

其中 $\mathbb{P}$ 表示描述现实世界价格变化的概率测度.

于是三个对象应该明确区分:

$$S_0, \quad F_{0,T}, \quad \mathbb{E}^{\mathbb{P}}[S_T].$$

三者彼此有关, 各自描述当前现货价格, 无套利远期价格与现实测度下的终端均值. 比较 $F_{0,T}$ 和 $\mathbb{E}^{\mathbb{P}}[S_T]$ 时, 才会涉及现实概率下的价格预期以及市场对于风险的补偿.

注 7.37.

期货价格的首要解释是受现货价格, 融资成本, 资产现金流和其他持有成本约束的相对价格.

后面介绍风险中性定价以后, 这个价格还可以和风险中性测度下的预期联系起来. 风险中性预期服务于无套利定价, 现实概率测度 $\mathbb{P}$ 下的均值则描述现实世界的平均预测.

7.2.2 期权与非线性现金流

期权 远期和期货有一个很明显的特点: 一旦建立合约, 双方都承担相应的合约义务. 如果我们约定未来按照 \$100 买入股票, 那么无论到时候股票是 \$150 还是 \$50, 原来的约定原则上都在那里.

有时投资者想要另一种安排: 如果未来状态对自己有利, 就使用这项权利; 如果不利, 就可以放弃.

这类合约称为期权.

定义 7.38.

期权 (option) 是指赋予买方选择权的一类衍生品合约. 买方可以在约定时间内或者到期时, 按照事先规定的条件买入, 卖出某项标的, 获得相应现金结算, 或者放弃行权.

与此同时, 期权卖方承担与这项权利相对应的合约义务.

一份期权需要规定几个基本条件: **执行价格** (strike price), 也就是期权合约事先规定的买卖价格, 后面通常记作 K ; **到期日** (expiration date 或 maturity), 也就是这项权利存在到什么时候, 后面通常记作 T ; 以及**行权规则**. 如果期权持有人按照合约规定使用这项权利, 这种行为称为**行权** (exercise).

根据这项权利究竟是买入还是卖出标的, 最基本的期权可以分成看涨期权和看跌期权.

定义 7.39.

看涨期权 (call option) 是指给予买方按照执行价格 K 买入标的, 或者获得相应现金结算的权利的期权.

看跌期权 (put option) 是指给予买方按照执行价格 K 卖出标的, 或者获得相应现金结算的权利的期权.

期权还需要规定什么时候允许行权.

定义 7.40.

欧式期权 (European option) 是指只能在到期日 T 行权的期权.

美式期权 (American option) 是指允许持有人在到期日或以前符合合约规定的时刻行权的期权.

这里的 European 和 American 只是行权规则的名称, 与期权的交易地域无关.

我们先看最简单的欧式期权.

假设一份欧式看涨期权的执行价格为 K . 到期时如果 $S_T > K$, 按照较低的 K 买入自然具有价值; 如果 $S_T \leq K$, 买方就没有必要行权. 因此它在到期时的到期支付为

$$(S_T - K)^+ = \max(S_T - K, 0).$$

类似地, 一份欧式看跌期权在到期时的到期支付为

$$(K - S_T)^+ = \max(K - S_T, 0).$$

这种“只有对自己有利时才行权”的选择权有相应的价格.

定义 7.41.

期权买方为了获得相应权利而支付给期权卖方的价格称为**权利金** (option premium).

到期支付和盈亏需要区分. 到期支付描述合约本身在到期状态下产生多少支付; 盈亏还要计入投资者最初支付或者收到的权利金.

比如一份看涨期权到期时满足 $(S_T - K)^+ = 0$, 只能说明它最终没有产生正的到期支付. 如果投资者最初支付了 \$5 的权利金, 那么他仍然损失了这 \$5. 反过来, 如果期权到期支付 \$10, 最初支付了 \$7 的权利金, 那么在暂时忽略资金时间价值, 交易费用和税务影响以后, 最简单的名义利润才是 \$3.

因此以后看到到期支付图时, 最好先问清楚: 这里画的是期权本身的到期支付, 还是把权利金也考虑进去以后的完整盈亏?

从线性暴露到非线性现金流 远期和期权之间还有一个更深的区别. 远期多头的到期支付为 $S_T - K$: S_T 每增加一美元, 到期支付也增加一美元. 它提供线性的价格暴露.

看涨期权的到期支付 $(S_T - K)^+$ 具有折点. 当 $S_T < K$ 时, 到期支付为零; 超过 K 以后, 到期支付才开始随着标的价格增加. 期权由此引入**非线性现金流**.

例 7.42 (相同均值, 不同分布).

假设两个未来价格分布具有相同的均值, 其中一个非常集中, 另一个允许价格大幅向上或者向下波动.

对于 $S_T - K$ 这样的线性到期支付, 两个分布的平均支付可能完全相同; 对于 $(S_T - K)^+$ 这样的非线性到期支付, 两者可能产生明显不同的期望支付.

期权因此把研究范围从平均价格扩展到未来价格分布的波动程度和尾部形状.

“期权就是一个二阶变量”这种概括混淆了到期支付与价值敏感度. 看涨期权的到期支付 $(S_T - K)^+$ 是分段线性函数. 二阶性质出现在对**期权价值随标的价格的变化**进行研究时.

如果期权价值记作 V , 那么它对标的价格的一阶敏感度称为 Delta, 也就是期权的方向敏感度:

$$\Delta = \frac{\partial V}{\partial S},$$

而 Delta 本身还会随着标的价格变化, 这种曲率由 Gamma, 也就是二阶敏感度描述:

$$\Gamma = \frac{\partial^2 V}{\partial S^2}.$$

这里暂时只需要知道这些量描述的是期权价值对于市场状态变化的敏感程度, 后面讨论期权定价和动态对冲时再正式介绍它们.

期权先引入非线性的现金流结构; 二阶风险则在研究头寸怎样随市场状态变化时出现.

期权价格由此会对波动率产生明显敏感度. 如果进一步通过股票或者期货把主要的方向性风险对冲掉, 市场参与者甚至可以在一定程度上把波动率风险相对独立地拿出来管理和交易. 一张普通期权仍会混合方向, 波动率和其他风险暴露.

买方的权利与卖方的义务 期权还有一个和普通资产非常不同的地方. 买方拥有权利, 就意味着另一边需要有人承担相应的义务.

对于看涨期权买方来说, 如果标的价格大幅下跌, 最坏的情况通常只是期权最终失效并损失已经支付的权利金; 如果标的价格大幅上涨, 到期支付可以继续增加. 一个没有相应对冲头寸的看涨期权卖方则恰好相反: 他最初获得的权利金有限, 标的价格持续上涨时潜在损失可能不断增加.

因此单独说“在做期权”几乎没有提供多少风险信息. 至少还需要知道这是看涨还是看跌, 是多头还是空头, 执行价格 K 在哪里, 到期时间 T 多长, 名义规模多大, 以及这份期权和投资者原来已经持有的头寸之间是什么关系.

因此要区分:

$$\text{Position Risk} \neq \text{Portfolio Risk}.$$

7.2.3 交易结构与风险理解

做市商 如果我们买入一张看涨期权, 另一边究竟是谁在卖? 是否一定存在另一个判断完全相反的投资者?

现实市场中, 相当一部分交易的另一边可能是做市商, 无须存在判断完全相反的最终投资者。

定义 7.43.

做市商 (market maker) 是指按照相应市场制度持续或者经常提供买入和卖出报价, 并通过暂时承担库存和价格风险为市场提供流动性的交易者或者机构。

做市商通常会同时给出两个价格。

定义 7.44.

买价 (bid) 是市场参与者愿意买入的报价; **卖价** (ask) 是市场参与者愿意卖出的报价. ask 与 bid 之间的差额称为**买卖价差** (bid-ask spread).

例 7.45 (期权做市).

比如某只期权当前可能存在

$$\text{Bid} = 4.90, \quad \text{Ask} = 5.10.$$

投资者希望立即卖出时, 通常需要按照 Bid 一侧成交; 希望立即买入时, 则通常按照 Ask 一侧成交。

做市商的重要作用之一, 是让市场参与者无须等待另一个最终投资者恰好在同一时刻产生完全相反的需求。

流动性由资本和风险承担支持. 假设做市商刚刚向客户卖出了一批看涨期权. 在其他条件不变时, 卖出看涨期权会给做市商带来负的 Delta 暴露. 如果它希望降低这部分方向风险, 就可能买入一定数量的标的股票或者相应期货。

做市商管理的是**整个投资组合的净风险**. 它无须为每一张客户订单立即建立一笔完全对应的股票交易, 因为账户中可能已经有其他执行价格, 其他到期日或方向相反的期权头寸. 做市商也可能使用股指期货, 其他期权或相关资产对冲。

因此

客户买入看涨期权 $\nrightarrow$ 做市商一定按固定数量买入现货。

更加准确的传导过程是

客户订单 $\rightarrow$ 做市商净风险变化 $\rightarrow$ 必要时重新对冲
 $\rightarrow$ 可能产生标的或期货订单。

Gamma 的存在意味着 Delta 本身还会随着价格变化, 一次对冲通常只在当时的市场状态附近有效. 标的价格继续移动以后, 做市商可能还需要调整自己的对冲头寸。

注 7.46.

把做市商称为日常语言中的“庄家”会掩盖其真实职能. 做市商在市场竞争与制度约束下报价, 通过管理库存和对冲风险争取收益, 同时承担成交后的价格风险。

做市商需要面对库存风险, 跳价风险, 对冲误差, 流动性枯竭以及交易对手与清算机制带来的其他约束. Bid-ask spread 中的一部分收益, 正是在补偿它提供即时流动性并暂时承担这些风险。

同一只股票可以同时存在大量不同执行价格 K 和不同到期时间 T 的期权. 如果每一个 (K, T) 合约都必须等到两个最终投资者恰好产生完全相反的需求才能成交, 很多合约几乎不可能拥有持续流动性. 做市商在中间承接这些不完全同步的需求, 再把不同合约产生的风险放进一个整体账户里面统一管理, 因而成为衍生品市场非常重要的参与者。

衍生品风险取决于头寸结构 期货和期权的风险取决于头寸结构和用途, 判断时需要结合完整头寸.

原本没有相应风险暴露的投资者如果利用很少的保证金建立巨大的方向性期货头寸, 就是在主动增加风险. 大量裸卖期权也可能带来非常不对称的尾部损失.

同一类工具也可以降低既有风险. 如果一家航空公司本来就面对未来燃油价格上涨的风险, 建立期货头寸可能降低它的经营风险; 如果一家基金持有大量股票, 卖出股指期货可能减少整个组合对于市场共同下跌的敏感程度; 如果一个股票投资者买入看跌期权, 则是在支付一笔确定的权利金, 换取对于极端下跌状态的保护.

注 7.47.

衍生品是一种重新切割, 转移和组合风险的工具.

它可以创造新的风险暴露, 可以借助杠杆放大风险, 也可以抵消已经存在的风险或者限制某些极端状态下的损失. 因此判断一项衍生品交易是否危险时, 需要把合约放回投资者完整的头寸和资产负债表中观察.

衍生品为什么会需要随机过程 到目前为止, 我们举的大部分期权例子最终都写成

$$X = \Phi(S_T).$$

一份欧式期权最终只依赖 S_T , 似乎只要研究终点分布就够了. 关键在于区分静态价格和动态定价两个层次.

如果已经额外给定贴现方式, 并且知道某个定价测度下 S_T 的终端边缘分布, 那么一份欧式终端支付在时刻 0 的静态价格确实可以压缩成一个终端期望. 这类欧式支付的静态定价可以不直接写出整条路径.

现实中的衍生品定价通常还会追问到期前的动态价值. 为了描述它在到期以前的价值怎样变化, 研究投资者应该怎样进行动态对冲, 或者处理路径依赖支付和提前行权问题, 我们仍然需要为整个价格过程

$$(S_t)_{0 \leq t \leq T}$$

建立模型.

普通欧式期权的最终到期支付只依赖终值 S_T , 动态价值过程和复制对冲则依赖价格过程的概率结构. 另一些衍生品的到期支付本身就依赖整条路径.

例 7.48 (路径依赖).

亚洲期权 (Asian option) 的支付可以取决于一段时间内的平均价格, 障碍期权 (barrier option) 则可能取决于标的价格曾经有没有碰到某个规定水平.

两条价格路径即使最后具有完全相同的 S_T , 中间走法不同, 合约最终支付也可能完全不同. 更一般的表示为

$$X = \Phi((S_t)_{0 \leq t \leq T}).$$

还有一类问题稍微不同. 前面已经定义过, 欧式期权只能在规定到期日行权, 美式期权则允许持有人在到期日或以前符合规则的時刻行权. 因此分析美式期权既需要描述价格过程, 也需要不断面对“现在行权, 还是继续等待”的决策.

这正是一个**最优停时** (optimal stopping) 问题, 因而会自然和前面随机过程基础中介绍的停时以及金融接口中的 Snell 包络联系起来.

衍生品定价需要随机过程模型, 原因有两个层次. 第一, 动态价值过程和复制对冲需要描述市场变量怎样随时间变化. 第二, 某些衍生品的最终支付或者行权决策直接依赖整个随机路径.

注 7.49.

在数学模型中, 我们以后经常会把一份衍生品压缩成

$$X = \Phi(S_T)$$

或者更加一般的路径函数.

这种写法非常方便. 现实中的期货和期权还包含具体合约条款, 保证金制度, 清算规则, 流动性以及市场交易机制.

到期支付函数是为当前问题保留的结构, 没有涵盖现实合约的全部特征.

到这里, 我们已经看到了一种非常重要的风险处理方式: 通过新的金融合约重新切割和转移已有风险. 这也留下了两个自然的接口.

第一个接口是事件本身. 如果一份合约的支付可以取决于股票价格, 利率或者指数, 那么它也可以进一步取决于某个未来事件是否发生. 下一节先沿着这条线, 讨论预测市场怎样把事件做成或有现金流, 以及为什么它会自然给出市场隐含概率.

第二个接口来自股指期货: 一个不能直接持有的指数, 为什么能够成为期货, 期权和长期投资产品共同围绕的对象? 这个问题会在预测市场之后, 由指数, ETF 和被动投资继续处理.

7.3 预测市场与市场隐含概率

第7.2节把衍生品理解成一种将未来状态重新写成或有现金流的金融合约. 当支付条件从资产价格转向某个未来事件是否发生时, 合约便进入预测市场的范畴.

这里引入预测市场, 为了回答一个更具体的问题:

怎样从当前市场价格中反解出市场究竟在 price in 什么?

这个问题在第8.3节中还会再次出现: 预测市场给 Event Graph 提供一种外部价格约束. 这里把预测市场视为可观察的价格信号, 用于识别和校准市场预期. 那里的 Agent 指用于整理, 生成, 路由和审计研究材料的自动化研究组件, 不同于经纪人, 交易所交易基金的授权参与者 (authorized participant, AP), 也不同于法律关系中的代理人.

7.3.1 从价格反解市场预期

股票价格包含市场对于未来的判断. 如果一家公司公布财报以后股价上涨, 我们可能会说市场提高了对于收入增长的预期; 如果股价下跌, 也可能解释成利润率不及预期, 资本开支过高, 监管风险上升, 估值倍数下降, 或者只是此前仓位过于拥挤.

价格是许多不同因素共同作用以后形成的压缩结果:

{未来现金流, 贴现率, 风险溢价, 仓位, 流动性, 订单流, ...}

→ 当前价格.

这个映射通常是多对一的. 许多完全不同的事件组合和市场叙事, 都可能产生相似的价格变化. 因此从价格反过来恢复市场叙事, 会构成一个识别不足的反问题.

期权可以提供一部分额外信息. 现货价格主要给出一个已经高度压缩的方向性结果, 而不同执行价格和到期时间的期权还能够提供隐含波动率, 偏度, 尾部风险和非线性暴露等更加丰富的信息. 经典的 Breeden-Litzenberger 关系说明, 在理想条件下可以从欧式期权价格曲面对风险中性终端分布提取信息 [BL78; Hul22].

期权曲面主要回答“市场怎样给不同价格状态定价”. 至于市场认为哪个具体事件会导致这些状态, 还需要期权价格之外的证据. 隐含波动率上升, 可能来自财报风险, 监管决定, 宏观数据, 流动性下降, 做市商仓位变化, 或者几种因素共同作用. 即使我们观察到明显的偏度变化, 仅凭期权价格也无法确定市场究竟在担心哪件事情.

期权减少了信息压缩, 解释仍然可能有多个版本.

7.3.2 从文本生成解释为什么仍然困难

另一种可能的方法是先阅读公司的财报, Call Transcript 和其他经营资料, 从中抽取若干候选事件 $E_1, \dots, E_m$, 再由前述研究 Agent 生成这些事件可能造成的价格影响, 并寻找能够解释一段价格路径的事件组合:

{财报, Call Transcript, 行业与政策信息} $\xrightarrow{\text{研究 Agent}}$ $\{E_1, \dots, E_m\}$ $\xrightarrow{\text{解释价格路径}}$ 候选市场叙事.

研究 Agent 通常能生成过多解释, 由此带来识别困难. 候选事件之间可能互相重叠, 同一条证据可能支持多种叙事, 多个事件也可能同时发生. 如果只是要求解释能够符合已经观察到的价格变化, 研究 Agent 很容易在事后构造出一套看起来相当合理的故事.

此时需要一组来自公司文本之外, 具有明确事件边界和外部市场约束的参照物. 继续增加叙事的帮助有限, 预测市场由此进入研究框架.

7.3.3 把事件做成或有现金流

定义 7.50 (预测市场与事件合约).

预测市场 (prediction market) 是围绕未来事件或者可验证结果建立交易合约的市场. 这些合约也常被称为**事件合约** (event contracts).

如果事件 A 在规定期限内按照结算规则被判定为发生, 一份二元事件合约支付 1; 否则支付 0. 它在结算时刻 T 的支付可以写成

$$X_T^A = \mathbf{1}_A.$$

CFTC 对 event contracts 的介绍中也采用了类似的直观语言: 许多事件合约围绕 yes-no 问题设计, 通常具有固定支付和到期或结算时点 [Com]. 从金融合约的角度来看, 事件合约只是衍生品的一种特别直接的形式: 它把一个自然语言中的未来问题, 转换成一份具有明确支付规则的或有现金流.

与股票或者普通期权相比, 事件合约在价格之外增加了一个相对明确的语义标签:

这个价格究竟对应哪一个事件?

例如, “某项监管批准是否会在时刻 T 以前发生” 和 “某家公司股价是否会在时刻 T 以前超过某个水平” 是两个不同的事件. 即使它们可能彼此相关, 也需要作为两个概率对象分别研究.

预测市场把原本混在资产价格中的一部分叙事, 拆成了可以分别观察的事件命题, 从而减少价格反演问题中的歧义.

注 7.51.

将预测市场看成事件型或有现金流, 是一种金融建模上的理解方式. 一份事件合约在法律上究竟属于衍生品, 博彩合约, 还是其他受监管产品, 仍然取决于具体司法辖区和市场制度.

在美国监管语境中, CFTC 曾将 Polymarket 提供的若干 event-based binary options 认定为其辖区下的 swaps, 并在 2022 年对其未注册交易设施相关问题作出处罚 [Com22].

7.3.4 市场隐含概率

假设一份事件 A 的合约在时刻 t 价格为 C_t^A , 到期发生时支付 1, 不发生时支付 0. 如果暂时忽略利率, 交易费用, 买卖价差, 风险厌恶和交易约束, 人们经常会把 C_t^A 直接读成一个概率.

更一般地, 如果从 t 到 T 的贴现因子为 $D(t, T)$, 可以定义一个经过贴现归一化的市场价格对象

$$\hat{p}_t^{\text{mkt}}(A) = \frac{C_t^A}{D(t, T)}.$$

定义 7.52 (市场隐含概率).

本文把由事件合约价格经过合约面值和贴现归一化以后得到的概率状数值称为**市场隐含概率** (market-implied probability).

它表示市场在特定合约条款, 参与者结构和交易条件下对事件 A 给出的价格对象. 事件的真实概率属于另一个需要单独估计的对象.

在足够理想的模型中, 这个价格可以被解释成某种定价测度下的条件概率. 如果把从 t 到 T 的贴现和风险调整统一记入随机定价核 $m_{t,T}$, 则有形式表达

$$C_t^A = \mathbb{E}_{\mathbb{P}}[m_{t,T} \mathbf{1}_A \mid \mathcal{F}_t].$$

在更加简化的无摩擦模型中, 也可以写成

$$C_t^A = D(t, T) \mathbb{Q}(A \mid \mathcal{F}_t),$$

其中 $\mathbb{Q}$ 是相应的定价测度.

“价格在数值上像概率” 描述的是经过归一化的定价对象, 现实世界的客观概率则由数据生成机制决定. 预测市场价格还会受到风险偏好, 资金约束, 手续费, 参与限制, 买卖价差, 流动性和结算规则影响. 关于 prediction-market price 应当怎样解释为概率, 文献中本来也有很多细节和争论 [Man06; WZ04].

7.3.5 四类需要区分的对象

下面区分四类含义不同的对象.

事件 A 的真实条件概率可以形式化地写成

$$p_t^*(A) = \mathbb{P}(A \mid \mathcal{F}_t),$$

真实的数据生成机制通常不为研究者所知.

根据公司证据和基本面研究得到的主观估计, 可以记成

$$\hat{p}_t^{\text{fund}}(A).$$

预测市场在自身合约规则下给出的价格对象是

$$\hat{p}_t^{\text{mkt}}(A).$$

而公司估值中 Bull, Base, Bear 等情景的权重, 则可以另外记成

$$\pi_t^{(i)}(s), \quad s \in \{\text{Bull, Base, Bear, Tail}\}.$$

这四者各有定义, 互相转换需要额外论证. 一个监管事件 A 即使发生, 也未必自动使公司进入 Bull 情景; 它可能只改变收入路径, 利润率, 资本开支或者贴现率中的某一项. 反过来, 公司进入 Bear 情景也可能由许多事件共同造成, 单一事件合约通常不足以决定整个情景.

预测市场还会提供另一组完全不同的信息:

$$\mathcal{L}_t^A = \{\text{bid, ask, spread, depth, volume, open interest, recency}\}.$$

这些是盘口和市场质量信息. 它们可以帮助判断价格是否具有足够的交易支持, 也可以反映市场对于某个问题投入了多少注意力. 概率信息主要来自价格及其定价解释, 流动性和成交量则描述市场质量.

例 7.53.

假设某份事件合约的最优买价为 0.57, 最优卖价为 0.63, 最近成交价为 0.61.

此时把它简单写成“市场概率为 61%”会隐藏很多信息. 0.61 可能只是已经过时的最近成交价; 0.60 是不可直接成交的中间价; 立即买入需要支付 0.63, 而立即卖出只能得到 0.57.

如果 0.63 的卖价上只有很少数量, 一笔稍大的买单还会继续吃掉更高价格的挂单. 盘口顶部的价格只反映该档位可成交的有限数量, 较大规模资金面对的是整张订单簿给出的成交价格.

注 7.54 (价格, 注意力与流动性).

市场中存在一份关于事件 A 的合约, 表明有人愿意围绕 A 建立一个可以交易的问题.

盘口较大或者成交活跃, 可以说明这个问题获得了较多市场注意力; 一个较窄的买卖价差和较深的盘口, 可以提高报价作为市场信号的可读性.

市场注意力, 流动性, 预测准确度和真实概率是四个不同维度. 每个维度都需要相应的证据和解释.

7.3.6 从事件合约到 Event Graph

预测市场为事件图提供了一组外部校准信号, 每个信号都带有问题定义和市场状态. 整个接口可以粗略写成

$$\begin{aligned} \text{财报与 Call Transcript} &\xrightarrow{\text{Agent 提取}} \text{公司事件与传导路径,} \\ \text{Prediction Market} &\xrightarrow{\text{问题, 价格与盘口}} \text{市场注意力与候选概率对象,} \\ \text{两类信息} &\xrightarrow{\text{校准与路由}} \text{Company Event Graph.} \end{aligned}$$

Agent 仍然需要判断事件之间是否存在上下游关系, 某个事件怎样影响公司的需求, 定价, 利润率, 资本开支或者融资条件, 以及这些传导边有没有独立证据. 这些因果关系需要独立证据支持. 预测市场提供一个外部的现实锚点: 市场上确实有人在围绕这个事件下注, 并且当前盘口给出了怎样的价格和注意力状态.

预测市场在图中的用途通常可以分成三层: 事件是否获得外部市场注意, 合约是否足够干净而能够形成候选市场概率对象, 以及概率或盘口变化是否值得触发进一步研究.

单家公司的局部 Event Graph 之后还可以沿着共同事件, 上下游关系和资产暴露彼此粘接, 形成更加全局的 Market Graph. 后文介绍 Agentic R-D-G 时会进一步说明, 这种图怎样用于观察市场季风与风险堆积, 以及怎样作为语境输入反过来校准单公司的基本面研究.

三类对象的分工如下: 预测市场提供信号, Event Graph 保存传导, Market Graph 组织语境; 估值结论仍由基本面证据, 传导分析与估值方法共同形成.

7.3.7 结算规则, 信息优势与监管问题

预测市场中的数字必须连同合约问题一起阅读. 同一个自然语言事件, 只要结算期限, 条件分母, 数据来源或者裁决机构不同, 就可能对应完全不同的合约. 因此在使用一个市场价格以前, 需要确认它对应的是最后成交价, 买卖价中点还是一侧报价, 并检查合约的结算规则, 期限, 条件性, 流动性和报价时效.

预测市场还面临信息不对称: 交易者可能拥有其他参与者尚未掌握的信息. 某些事件直接涉及企业内部人员, 政策制定者, 交易对手, 候选人, 内容发布者, 或者与事件高度接近的参与者. 而不同预测市场所处的监管制度, 信息披露义务, 市场监察能力和参与者限制又可能与传统证券市场明显不同. 因此非公开信息交易, 利益冲突和市场操纵都应被视为需要单独审计的风险.

CFTC 在 2026 年关于 prediction markets 的 enforcement advisory 中, 就专门提到 event contracts 中可能出现的非公开信息误用, 欺诈, wash sales 和其他禁止交易行为, 并列举了 KalshiEX 上与候选人本人交易, 以及与 YouTube 频道内部人员相关的案例 [Com26]. 预测市场信号可能同时混合群体判断, 信息优势, 监管边界和交易制度的影响.

一笔大额订单或者一次概率跳升支持多种解释. 它可能来自公开新闻, 做市商库存调整, 跨市场套利, 低流动性冲击, 结算规则理解差异, 操纵行为或者陈旧报价.

注 7.55 (预测市场信号的证据边界).

异常盘口可以形成“可能存在知情交易”的观察假设, 指认内幕交易或违法行为还需要市场运动之外的独立证据.

预测市场信号适合用于注意力识别, 研究路由, 观察和校准; 更强的事实判断仍然需要预测市场以外的独立证据.

缺少相关预测市场可能说明该事件不适合标准化, 缺少足够交易需求, 受到平台规则限制, 或者尚未被市场组织成一份合约.

7.3.8 预测市场作为随机过程

预测市场价格是一条持续更新的动态市场信号. 对于固定事件 A , 市场隐含概率, 买卖价差, 盘口深度和成交活动都会随时间变化. 因此更加完整的研究对象是

$$(\hat{p}_t^{\text{mkt}}(A), \mathcal{L}_t^A)_{0 \leq t \leq T}.$$

新的公开信息到来时, 价格可能跳跃; 市场参与者意见分歧扩大时, 价差和成交量可能发生变化; 临近结算时, 时间和规则不确定性又会以不同方式进入价格.

预测市场由此成为随机过程语言的一个自然应用: 事件合约价格构成价格过程, 订单到达构成点过程, 盘口深度构成流动性过程, 而市场能够使用的信息则形成相应的滤链.

研究同时关心事件最后是否发生, 以及市场对于事件的判断怎样随着信息到达而不断更新. 预测市场提供一条可以被观察, 质疑和校准的市场信念过程. 未来结果仍由现实事件决定.

衍生品由此延伸出两个方向. 预测市场把未来事件本身做成可以交易的现金流; 股指期货和指数期权则提示我们, 一个由规则计算生成的指数也可以成为大量金融合约围绕的对象. 下一节就转向指数, ETF 和被动投资.

7.4 指数, ETF 和被动投资

前面讨论股指期货时已经遇到指数.

S&P 500 是一套规则以及按规则计算的数值. 相应的投资敞口由期货, 期权, 基金或底层股票篮子承载. 市场参与者因而常说自己在“买入 S&P 500”, “持有 Nasdaq-100”, 甚至长期定投整个市场.

这些说法牵涉五个层次: 股票篮子的分散作用, 指数的构造规则, 指数敞口的投资载体, ETF 与指数的关系, 以及被动投资相对于基准的含义.

指数构造, 指数数学, ETF 结构和被动投资的背景主要参考 [Gas10; Mar52; Nas; SP 26; SP a; SP b; US e; US f].

7.4.1 从单只股票到股票篮子

假设一个投资者把全部资金都放进一家公司. 那么这家公司的产品失败, 工厂事故, 管理层问题或者其他只属于这家公司的事件, 都可能直接影响投资者几乎全部财富.

投资者同时持有多家公司时, 一家公司的经营问题通常不会在另外几百家公司中完全同步发生. 当许多不完全同步变化的资产被放进同一个投资组合以后, 一部分原本属于单个公司的风险就可能被分散.

定义 7.56.

分散化 (diversification) 是指通过同时持有多项不完全同步变化的资产, 降低单个资产或者局部风险来源对于整个投资组合的影响.

分散效果取决于这些股票共同变化的程度; 持仓数量只是其中一个输入.

假设一个投资组合中资产收益率分别为 $R_1, \dots, R_n$, 权重为 $w_1, \dots, w_n$, 并满足 $\sum_i w_i = 1$. 组合收益率为

$$R_p = \sum_{i=1}^n w_i R_i,$$

组合收益率的方差满足

$$\text{Var}(R_p) = \sum_i w_i^2 \text{Var}(R_i) + 2 \sum_{i < j} w_i w_j \text{Cov}(R_i, R_j).$$

第一项来自每项资产自己的波动, 第二项则告诉我们不同资产之间怎样共同变化. 如果很多资产的协方差都很高, 新增持仓带来的分散效果仍然有限.

定义 7.57.

特有风险 (idiosyncratic risk) 是指主要来自某一家公司, 某一项资产或者少数特定对象自身的风险.

系统性风险 (systematic risk) 是指大量资产共同暴露, 因而很难单纯通过增加同类持仓数量消除的风险来源.

一家公司的新产品失败更接近特有风险; 经济衰退, 整体融资条件突然收紧或者市场风险偏好发生巨大变化, 则更接近系统性风险.

注 7.58.

这里的 systematic risk 指资产定价意义下大量资产共同暴露的风险; systemic risk 则指金融体系的传染或失灵.

“特有”和“系统性”取决于组合范围. 一个只影响半导体行业的冲击, 对半导体股票组合来说可能是共同风险; 放进一个全球多资产组合以后, 它又可能只是局部风险.

投资者自行选择 100 家公司, 或由主动基金建立高度分散的组合, 同样可以实现分散化. 指数解决的是标准化表示问题:

用公开, 可重复, 可维护的规则表示一个资产篮子.

7.4.2 指数怎样构造市场表示

定义 7.59.

市场指数 (market index) 是指按照预先规定的样本范围, 成分选择, 加权, 维护以及收益计算规则, 将一组资产的市场表现压缩成一个或者少数几个数值的市场指标.

指数规则至少要规定资产资格, 成分选择, 权重, 公司行动处理, 成分与权重调整时点, 以及股息等现金流的收益口径.

一个简单的股票指数可以写成

$$I_t = \frac{\sum_{i=1}^n P_{i,t} Q_{i,t}}{D_t},$$

其中 $P_{i,t}$ 是第 i 项证券的价格, $Q_{i,t}$ 是指数计算中分配给它的指数股数或者相应权重参数, D_t 是指数除数 (index divisor).

相应地, 一项证券在指数中的实际权重为

$$w_{i,t} = \frac{P_{i,t} Q_{i,t}}{\sum_j P_{j,t} Q_{j,t}}.$$

$Q_{i,t}$ 是指数股数或权重参数; 实际权重由价格与 $Q_{i,t}$ 共同决定. 不同指数的主要差异, 很大程度上来自指数股数的确定方式, 以及之后什么时候重新调整它们.

指数提供商还需要处理拆股, 增发, 回购, 成分更换, 特别股息等公司行动. 这些事件有些代表真实投资收益或者资产变化, 有些却只是股份结构发生了机械变化.

注 7.60.

指数除数只在方法文件规定的公司行动下调整.

对普通市值加权指数来说, 股票拆股时每股价格下降, 股数同时按照相反方向增加, 公司市值没有变化, 除数通常保持不变. 价格加权指数采用另一种处理. 由于每家公司在指数计算中使用相同的名义股数, 拆股只会直接降低每股价格, 因此通常需要调整除数来避免指数点位产生没有经济含义的机械跳跃.

指数提供商利用指数股数, 权重调整因子和指数除数等工具, 区分公司行动和市场收益. 参数调整由具体指数的方法文件确定.

权重规则与再平衡 最常见的一类股票指数是市值加权.

定义 7.61.

市值加权指数 (market-capitalization-weighted index) 是指资产在指数中的权重主要由其市场价值决定的一类指数.

如果只考虑最简单的情形, 公司 i 的权重大致为

$$w_i = \frac{M_i}{\sum_j M_j},$$

其中 M_i 表示公司的可计入市场价值.

很多现实指数还会按照自由流通股份调整市值, 只计入普通市场参与者可自由买卖的相应股份.

市值加权有一个非常适合大规模指数跟踪的特点. 如果成分集合, 股数和其他指数参数都不发生变化, 某只股票因价格上涨而市值增加时, 原本按市值比例持有它的组合会随头寸升值自动提高其权重.

市值加权由此具有很强的自我调整性质. 基金仍会因增发, 回购, 自由流通比例变化, 并购, 分拆, 指数成分调整和申购赎回而交易.

另一种历史悠久的方法是价格加权.

定义 7.62.

价格加权指数 (price-weighted index) 是指成分证券对于指数的影响主要由其每股市场价格决定的一类指数.

假设指数中暂时只有两只股票, A 的价格为 \$300, B 的价格为 \$100. 如果两只股票都上涨 1%, 那么 A 上涨 \$3, B 只上涨 \$1, 所以 A 对指数点数变化的影响更大.

这两家公司的总市值谁更大没有直接关系. 这也解释了为什么价格加权指数会特别在意拆股等改变每股价格刻度的公司行动.

第三种很直观的方法就是等权.

定义 7.63.

等权指数 (equal-weighted index) 是指在规定的再平衡时点, 让各成分公司或者证券重新具有相同或者近似相同目标权重的一类指数.

“在规定的再平衡时点”是这个定义的限定条件. 等权只在离散的再平衡时点恢复. 一次再平衡以后, 股票继续涨跌, 上涨较快的公司权重会逐渐增加, 下跌较多的公司权重则会逐渐下降.

这种现象可以称为**权重漂移** (weight drift). 现实中的等权指数通常是定期恢复等权的动态组合; 两次再平衡之间允许权重偏离 $w_i = 1/N$.

如果一个行业拥有很多成分公司, 它在等权指数中的行业总权重也可能很高. 个股等权仍会形成不同的行业总权重和风险暴露.

另外, 等权指数通常还意味着更高的再平衡需求. 上涨较多的公司需要在下一轮重置时降低权重, 相对落后的公司则需要提高权重. 所以相对于市值加权, 等权指数通常具有更高的再平衡换手倾向; 实际基金的交易成本仍取决于复制方式, 成分流动性和执行安排, 而等权结构也自然增加对较小成分公司的相对暴露.

几个真实指数 几个常见指数呈现出不同的市场表示方法.

例 7.64 (S&P 500).

S&P 500 的目标是表示美国大型股票市场. 它由资格标准和指数委员会共同维护.

一家公司首先需要满足美国公司身份, 上市地点, 市场规模, 自由流通市值和流动性等资格要求. 对新加入公司还存在盈利要求. 按照截至 2026 年 8 月使用的 S&P U.S. Indices 方法文件, 新进入 S&P 500 的公司总市值门槛为 \$22.7 billion, 最近一个季度的 GAAP 持续经营净利润需要为正, 最近四个季度合计也需要为正; 对 Equity REIT, 方法文件允许依据 GAAP 持续经营净利润和/或已报告的 FFO 判断财务可行性 [SP b]. 这类门槛会随方法文件更新; 上述数值只适用于当前版本.

资格条件给出候选范围, 指数委员会持续作出纳入和维护决定.

这里的“500”指 500 家公司. 某些公司可能同时存在多个符合条件的上市股份类别, 因而指数中的证券行数量可以超过 500.

公司进入指数以后, S&P 500 主要按照自由流通调整市值加权.

因此, S&P 500 是按照 S&P 方法选择和维持的一组美国大型上市公司; “美国市值最大的 500 只股票”会遗漏资格和委员会规则.

Nasdaq 这个名称同时用于交易市场和多种指数.

例 7.65 (Nasdaq Composite 和 Nasdaq-100).

Nasdaq 首先是一个证券交易市场以及相关金融基础设施的名称, 同一名称下有多个指数.

Nasdaq Composite 是一个范围很广的指数, 大体覆盖 Nasdaq Stock Market 上市的合格普通类型证券, 因而更接近 “Nasdaq 上市股票整体表现如何”.

Nasdaq-100 则是另一套规则. 按照 2026 年的方法文件 [Nas], 它设计上用于度量 Nasdaq 上市的 100 家大型非金融公司, 并采用修正市值加权.

科技企业在 Nasdaq-100 中占比很高, 但消费, 通信, 医药和其他非金融企业同样可以进

入。

年度重构使用带缓冲机制的资格和排名规则, 以避免排名处于边缘的公司因为短期市值波动频繁进出指数。

此外, 2026 年现行方法还允许满足其他适用资格条件, 且按 Full Market Capitalization 足以跻身当前成分前 40 的证券通过 Fast Entry 或 3 月, 6 月, 9 月季度调整加入指数, 而不要求同步删除另一家公司。因此指数在某些时点可以暂时超过 100 家公司。

指数的实际行为由 methodology 决定; 名称只提供粗略线索。

S&P 500 Equal Weight 的动态权重 S&P 500 Equal Weight 展示了真实市场中的权重漂移与再平衡。它使用和 S&P 500 相同的公司集合, 并在季度再平衡时让每家公司重新获得近似相同的目标权重, 采用公司等权规则。

如果指数包含约 500 家公司, 每家公司的目标权重大致就是 $1/500$, 也就是约 0.2%。

这里的等权对象是**公司**。如果一家成分公司有多个股份类别同时进入指数, 这家公司总共获得一份等权目标, 再按照不同股份类别的自由流通市值分配到各证券行。

注 7.66.

S&P 500 Equal Weight 中的“Equal Weight”表示季度规则下周期性恢复约 0.2% 的公司权重。在两次再平衡之间, 公司价格继续变化, 因而权重也会继续漂移。

因此加权规则和再平衡规则需要合并阅读。

以 2026 年 6 月的季度再平衡为例。如果 3 月季度重置以后, 部分成分公司的价格相对上涨更快, 那么即使是在 S&P 500 Equal Weight 中, 它们的实际权重也会在 6 月季度重置前自然向上漂移。

Equal Weight 会在两次再平衡之间逐渐增加对赢家的实际暴露; 季度内的半导体股票权重也会偏离 0.2%。

2026 年 6 月这一轮季度重置使用 6 月 10 日的收盘价格作为重新计算指数股数的价格参考。6 月 10 日只是计算下一轮目标指数股数的参考日, 当日并未完成调仓。

按照 S&P Dow Jones Indices 在 2026 年 6 月 5 日发布的公告 [SP 26], 当季 S&P 500 的成分变化在 2026 年 6 月 22 日开盘前生效: Marvell 和 Flex 加入, Pool 和 Campbell's 被删除。因为 2026 年 6 月 19 日是 Juneteenth, 美国主要股票市场休市, 所以 6 月 18 日是 6 月 22 日生效前的最后一个正常交易日。

这次再平衡会把此前因价格上涨而明显偏离目标等权的公司重新向相同公司权重拉回。科技行业总权重仍取决于全部成分的价格漂移和成分变化。

若干此前上涨较快的科技和硬件公司会因恢复公司等权而降低个股权重; 成分变化又新增了 Marvell 和 Flex 两家 Information Technology 公司。整个科技板块最终的总权重变化还取决于其他成分的价格漂移以及新增公司的影响。

整个行业暴露需要汇总所有相关成分, 几只科技股票的个股权重只提供局部信息。

如果在某个后续窗口中观察到 Equal Weight 相对于普通 S&P 500 跑赢或跑输, 对季度再平衡的因果归因还需要进一步分解。两个指数的相对收益本来就同时受到观察窗口, 收益口径, mega-cap 集中度, 行业配置, 公司规模倾斜, 再平衡前的权重漂移以及再平衡以后不同股票表现的影响。

如果想识别 6 月季度调整贡献了多少收益, 更合理的办法是先说明自己想识别的是**整套季度调整还是在成分不变时单纯恢复等权**的影响。前者会同时包含 Marvell, Flex 加入以及 Pool, Campbell's 删除; 后者则需要构造一个保持原成分集合不变的额外反事实。

例如对于整套季度调整, 可以构造一个反事实组合: 假设 6 月不进行季度重置, 继续持有再平衡以前已经发生权重漂移的 Equal Weight 组合。于是可以比较

$$R^{\text{EW,actual}} - R^{\text{EW,no rebalance}},$$

把它理解成对于这轮季度调整本身贡献的一种近似观察。

另一个比较是

$$R^{\text{EW,no rebalance}} - R^{\text{Market Cap}}$$

则更多保留了原本存在的公司规模, 行业以及集中度差异。

2026 年 6 月的案例展示了现实指数收益的多重来源: 权重规则, 权重漂移, 再平衡和之后的市场路径. “Equal Weight 更好” 需要跨窗口证据; 单次收益比较只能给出总差异, 无法识别单个机制的因果贡献.

实际跟踪 S&P 500 Equal Weight 的 ETF 或基金会拥有自己的真实持仓. 基金以贴近指数表现为目标, 但持仓与指数权重的接近程度取决于完全复制, 抽样复制, 衍生品, 现金和执行安排. 基金是相对于指数的独立对象, 还会受费用, 申购赎回, 交易时间和跟踪误差影响.

以某只 Equal Weight ETF 的历史持仓研究 Equal Weight 时, 应将数据明确标为**基金持仓**的观察; 精确指数权重仍以指数提供商的数据为准.

市场与指数 “今天美国股市上涨了 1%” 通常是对某个具体指数涨幅的简写.

S&P 500, Nasdaq Composite, Nasdaq-100, Dow Jones 和 S&P 500 Equal Weight 完全可能在同一天给出明显不同的市场表现, 因为它们选择的资产范围, 成分, 权重和维护规则本来就不同.

注 7.67.

一个真实股票市场在时刻 t 可以包含成千上万项价格

$$S_t^1, \dots, S_t^n.$$

指数则通过一套选择, 加权和维护规则, 把这个高维市场状态压缩成一个数值 I_t .
所以

$$\text{Market} \neq \text{Index}.$$

指数用一套规则观察并表示市场, 只保留高维市场状态的一部分信息.

价格指数, 总收益指数与净总收益指数 相同的公司和权重还可以对应不同的股息处理方式.

定义 7.68.

价格指数 (price index) 主要反映成分资产市场价格本身的变化.

总收益指数 (total return index) 则进一步按照指数规则假设现金股息重新投资, 从而把股息纳入指数收益.

净总收益指数 (net total return index) 还会进一步按照规定的税率假设扣除相应股息预提税.

比如一只股票从 \$100 跌到 \$98, 同时支付 \$4 股息. 单纯价格收益率是 -2% , 但如果把股息也计算进去, 在暂时忽略其他因素时总收益率为

$$\frac{98 + 4 - 100}{100} = 2\%.$$

比较基金和指数的长期表现时, 须先确认使用价格收益, 总收益或净总收益中的哪一种. 不同收益口径对应不同的比较量.

7.4.3 从指数到基金和 ETF

指数敞口的载体 指数是一套规则和由此计算的数值. 投资者通过底层证券组合, 基金或衍生品获得指数敞口, “持有十股 S&P 500” 只是对这些载体的口语化简称.

上一节已经看到, 股指期货可以提供近似线性的指数暴露; 指数期权可以提供非线性的指数暴露; 市场中还存在其他能够交换指数收益的衍生品.

如果投资者希望长期持有一个接近指数本身收益的现货型组合, 一种最常见的方法则是指数基金.

指数基金与跟踪误差

定义 7.69.

投资基金 (investment fund) 是指将投资者资金集中起来, 按照规定的投资目标和管理方式持有一组资产, 并通过基金份额把相应经济权益分配给投资者的一种资产管理结构.

定义 7.70.

指数基金 (index fund) 是指以跟踪某个指定指数的表现为主要目标的投资基金。

最直接的做法是按照指数成分和权重完整买入所有底层证券, 也就是完整复制. 如果成分很多或者部分证券不容易交易, 基金也可以通过抽样等方法建立一个近似组合. 某些产品还可以借助衍生品获得指数敞口.

指数基金追求的是让基金收益尽量接近目标指数收益. 基金和指数仍然是两个独立对象.

定义 7.71.

本文把某一期间基金收益与指数收益之差定义为**跟踪差异** (tracking difference):

$$TD_{0,T} = R_{0,T}^{\text{fund}} - R_{0,T}^{\text{index}}.$$

定义 7.72.

如果进一步研究一系列期间超额收益的波动程度, 可以定义相应的**跟踪误差** (tracking error):

$$TE = \text{sd} \left(r_t^{\text{fund}} - r_t^{\text{index}} \right).$$

Tracking difference 关心一段时期以后基金领先或落后基准多少; tracking error 关心这种偏离在各期有多不稳定. 实际报告 tracking error 时, 还需要说明使用日度, 周度还是月度收益以及是否进行年化.

管理费, 交易成本, 税收, 现金拖累, 复制误差, 公司行动处理以及证券借贷收入等因素, 都可能使基金最终表现偏离指数.

例 7.73.

S&P 500 是一个指数.

市场上可以同时存在许多目标都是跟踪 S&P 500 的基金. 这些基金由不同机构管理, 拥有不同费用, 规模, 交易结构和具体执行方法, 但都可以使用同一个 S&P 500 作为 benchmark. 所以

$$\text{Index} \neq \text{Index Fund}.$$

ETF 基金可以采用不同的组织和交易方式, ETF 是其中一种重要结构.

定义 7.74.

交易所交易基金 (exchange-traded fund, ETF) 是指基金份额能够在交易所二级市场中买卖, 并通常通过授权参与者的大额创建和赎回机制调节份额供给的一类投资基金.

ETF 是一种基金产品结构和交易形式. 交易所挂牌只是它的一个特征, 封闭式基金等产品也具备这个特征; ETF 的关键额外结构是基金份额可以通过创建和赎回机制, 在一级市场与底层资产篮子或者现金之间进行大额转换.

一个注册 ETF 可以跟踪股票或债券指数, 可以采用被动管理, 也可以采用主动管理. 市场上追踪商品或其他资产的商品信托 (commodity trust), 商品投资池 (commodity pool) 和交易所交易票据 (exchange-traded note, ETN) 常被归入广义交易所交易产品 (exchange-traded product, ETP), 这些产品分别采用 commodity trust, commodity pool 或 ETN 等结构, 注册 ETF 则受 Investment Company Act 下的相应框架约束. 指数基金可以采用普通共同基金或 ETF 结构.

三者关系为

$$\text{Index} \neq \text{Index Fund} \neq \text{ETF}.$$

这里的 $\neq$ 表示这些词不可互换, 同时允许类别重叠. 一只跟踪指数的 ETF 可以同时是指数基金和 ETF; 一只主动管理 ETF 只属于后一个类别.

例 7.75.

投资者买入跟踪 Nasdaq-100 的 ETF 时取得基金份额. 基金通过自己的资产和管理机制尝试获得接近 Nasdaq-100 的投资表现.

Nasdaq-100 是指数; Nasdaq Composite 是另一套更加广泛的指数; Nasdaq Stock Market 又是证券交易市场本身. 这些对象彼此联系, 但处在完全不同的层次.

分散在许多公司里的股票篮子由此经过几次转换:

股票篮子 → 可以表示的指数 → 可以跟踪的基金 → 可以盘中交易的基金份额.

衍生品则提供了另一条路径. 股指期货和指数期权直接把指数水平写进合约现金流, 以合约形式提供指数敞口. 同一个指数既可以成为基金的跟踪基准, 也可以成为衍生品的结算标的.

ETF 的净值和市场价格 ETF 持有的资产和负债共同决定基金净资产价值.

定义 7.76.

基金净值 (net asset value, NAV) 是指基金资产价值扣除负债以后, 按照基金份额数量计算得到的每份净资产价值.

如果基金资产价值为 A_t , 负债为 L_t , 份额数量为 N_t , 那么

$$\text{NAV}_t = \frac{A_t - L_t}{N_t}.$$

ETF 份额在交易时段中可以像股票一样持续成交, 因而具有不断变化的盘中市场价格. 基金的官方 NAV 通常在每个交易日结束后按规定方法计算一次.

因此盘中至少需要区分 ETF 的实时市场价格与交易日结束以后正式计算的官方 NAV. 某些产品还会公布盘中指示价值 (intraday indicative value, IIV), 市场参与者也可能根据底层资产当前报价估算组合价值, 这些盘中估值的可用性和算法因产品而异; 官方 NAV 仍按基金文件规定的时点与方法计算.

如果 ETF 市场价格相对于底层资产价值出现明显偏离, 市场中的创建和赎回机制会提供重要的套利力量.

定义 7.77.

授权参与者 (authorized participant, AP) 是指和 ETF 基金签订相应协议, 能够按照规定直接进行大额基金份额创建和赎回的机构.

普通投资者通常在二级市场买卖 ETF 份额; 直接向基金进行大额创建和赎回的是 AP.

例 7.78 (ETF 的创建与套利).

假设一只 ETF 的盘中市场价格明显高于其底层资产篮子的可交易价值, 而且价差已经足以覆盖交易, 融资和创建成本.

AP, 或者能够通过 AP 完成创建的套利机构, 就可能买入规定的资产篮子, 创建新的 ETF 份额, 再把 ETF 份额在二级市场中卖出.

如果 ETF 明显折价, 相反方向的赎回和套利也可能发生.

这些交易会 give ETF 市场价格和底层资产价值之间建立一股收敛力量.

交易成本, 融资成本, 税收, 做空约束以及底层资产的流动性共同形成现实中的无套利区间. 只有足以覆盖这些成本的价差才具有套利空间.

当市场剧烈波动或者底层资产缺乏可靠即时价格时, ETF 的市场价格也可能暂时明显偏离官方 NAV 或者盘中估算价值.

ETF 二级市场交易可以只交换已经存在的基金份额, 基金无需同步买卖底层资产篮子. 创建赎回, 基金因为指数调整或现金管理进行的自身交易, 以及 AP 或做市商为管理库存或对冲套利风险而进行的交易, 都可能产生底层资产订单; ETF 二级成交与底层资产交易没有逐笔一一映射. 即使发生创建和赎回, AP 也可能使用库存, 借券, 现金篮子或者其他执行安排完成操作, 其时间和规模可以与底层篮子交易错开.

7.4.4 被动管理与价格形成

被动管理需要分别从基金和投资者两个层面理解。

定义 7.79.

被动管理 (passive management) 是指基金以跟踪某个预先指定的基准为主要目标, 按照既定规则控制相对该基准的偏离。

被动管理描述的是**基金相对于 benchmark 怎样行动**, 投资者本人的策略还取决于择时, 配置和交易频率。

一个投资者完全可以长期持有主动管理基金而几乎从不交易; 也可以每天择时买卖指数 ETF。后一种情况下, 他使用的是被动管理产品, 同时执行着主动的择时策略。

“按照公式交易”的主动或被动属性由其相对 benchmark 的目标决定。一个系统化多因子基金即使所有交易都由固定算法决定, 如果它的目标就是主动偏离 benchmark 并获得超额收益, 仍然属于一种主动策略。

因此这里的被动始终**相对于一个已经选择好的基准而言**。

注 7.80.

被动管理把投资决策移到了其他位置, 基准规则承接了其中一部分决策。benchmark 包含样本范围, 成分筛选, 权重规则, 缓冲机制, 再平衡频率以及治理方式。S&P 500 甚至还包含指数委员会的维护判断。

投资者选择被动指数基金时, 同时选择了愿意遵循的指数规则。

被动资金仍然参与价格形成 市值加权指数基金按指数规则确定相对持仓; 基金经理对单家公司高估或低估的判断通常不直接改变权重。被动资金对证券相对估值的自主判断因而较少。

被动资金仍然参与市场价格形成。基金的申购和赎回, 指数成分变化, 定期再平衡以及投资者自身的资金配置都会产生真实订单。这些订单和主动投资者, 做市商, 套利者以及其他市场参与者的订单一起进入市场。

订单与价格形成的关系可以写成

信息, 判断, 约束与资金流 $\rightarrow$ 全部市场订单 $\rightarrow$ 边际成交价格。

市场价格形成以后, 市值加权指数又会利用这些价格计算公司市值和指数权重; 指数权重再决定大量指数基金应该怎样持仓。于是市场和指数之间逐渐形成一个反馈关系:

Market $\rightarrow$ Index $\rightarrow$ Fund Position $\rightarrow$ Market.

注 7.81.

指数最初只是市场的一种表示方法, 但当大量真实资金开始按照指数规则行动以后, 指数本身也会成为市场机制的一部分。

企业长期价值仍由经营现金流, 资本结构和权利边界等因素约束; 指数纳入的价格影响则取决于资金流, 预期和后续市场路径。一套原本用于描述市场的规则, 由此通过真实资金流重新进入被描述的市场。

7.4.5 从指数走向债券

把一只股票扩展成高度分散的股票组合以后, 单个企业对于整个组合的影响通常能够明显下降。

分散化保留了大量股票共同承受的风险。经济衰退, 利率变化, 融资条件和整体风险偏好的变化仍可能让大量公司一起下跌。而且无论我们持有一只股票还是五百家公司的股票组合, 股东主要持有的仍然是企业的**剩余索取权**。

下一节转向债券, 主线是金融权利从剩余索取权转为合同请求权。

股票主要代表对于企业剩余现金流和剩余价值的索取权; 普通债券则会把本金, 利息, 支付顺序以及到期时间更多地写进合同。投资者因此放弃一部分不受上限约束的企业上行, 换取更加明确并且通常拥有更高偿付顺序的合同请求权。

合同约定的现金流仍受违约, 利率, 通胀, 再投资和流动性风险影响。

下一节将讨论金融权利从企业剩余索取权变成合同请求权以后, 风险如何转化为信用风险, 期限风险和利率风险.

7.5 债券, 美债与利率

回到融资关系这条主线, 前面介绍股票时, 一个主体通过出售部分权益获得资金. 它还可以选择更直接的办法: 借钱.

最简单的借款关系就是投资者今天先把一笔钱交给借款人, 借款人承诺按照事先约定的规则在未来还钱. 当这种债权关系被标准化并做成能够继续交易的证券以后, 我们就得到了债券.

固定收益, 美债市场以及国债基差交易的背景主要参考 [AS23; BK21; BKM23; CME24; TS11; US b; US c; US d].

定义 7.82.

债券 (bond) 是指发行人为筹集资金而发行的一类债务证券. 债券持有人向发行人提供资金, 并取得按照债券合约规定在未来收取本金, 利息或者其他支付的权利.

债券和股票代表两种不同的融资关系. 股东取得企业剩余价值的一部分索取权; 债券持有人取得的主要是一组事先约定好的债权支付规则. 从支付结构看, 债券把权益资产中很大一部分经营结果不确定性收束成了合约支付规则.

这里的“支付规则”可以包含状态依赖. 对于最普通的固定利率债券, 只要发行人没有违约或者提前赎回, 未来票息和本金通常可以事先确定; 浮动利率债券的票息会随参考利率变化, TIPS 的支付受通胀影响, 可赎回债券可能提前结束, 可转换债券的最终经济结果还会和股票价格发生关系.

应当区分

债券规定支付规则 $\neq$ 所有未来现金流都已经确定.

一张普通债券通常会规定几个最基本的东西: 最终需要偿还的本金称为**面值** (face value 或 par value), 最终偿还的时刻称为**到期日** (maturity), 在到期以前定期支付的利息称为**票息** (coupon), 票息与面值之间的比例则称为**票面利率** (coupon rate).

债券之间还可能具有不同的清偿顺位. 如果发行人最终无法偿还全部债务, 不同债权人能够按照什么顺序获得偿付会直接影响债券价值. 债券契约还可能包含各种 covenant, 限制发行人继续举债, 转移资产或者进行其他可能损害债权人利益的行为. 这些制度细节以后遇到具体信用债时再展开.

7.5.1 货币的时间价值与零息债券

如果有人今天借走 \$100, 只承诺十年以后还回 \$100, 大多数人都难以接受.

一个直接原因是通胀. 如果未来物价上涨, 十年后的 \$100 所能购买的东西可能远少于今天的 \$100. 即使剔除通胀, 今天拿在手里的资金也可以立即消费或投入其他资产获得收益; 把它借给别人, 就要在这段时间里放弃这些用途.

利率可以理解成**跨时间交换资金的价格**. 如果今天的 \$100 一年以后按照 5% 的利率增长为 \$105, 那么反过来看, 一年以后确定得到的 \$100 今天就只值大约 $100/1.05$. 从今天走向未来叫复利, 从未来折回今天叫贴现, 两者是同一个过程的两个方向.

通胀会参与利率的形成. 名义利率可以粗略分成实际利率和对于未来通胀的补偿. 最终实现的通胀率仍可能超过债券收益率, 由此产生负的实际利率.

零息债券是把这种跨时间交换数学化时最简单的对象.

定义 7.83.

零息债券 (zero-coupon bond) 是指存续期内没有票息, 到期时一次性支付约定金额的债券.

在最简单的无违约模型中, 令 $P(t, T)$ 表示时刻 t 一项在时刻 T 确定支付 1 单位计价货币的零息债券价格. 固定当前时刻 t 和到期日 T 后, 也常把它称为从 t 到 T 的**曲线贴现因子**. 特别地, $P(T, T) = 1$.

$P(t, T)$ 回答的问题是:

时刻 T 的一块钱,在时刻 t 值多少钱?

固定今天的时刻 t ,让到期日 T 不断变化,就会得到整条 $T \mapsto P(t, T)$.这条曲线比单独一个“市场利率”更基础,因为不同时间收到的现金流原则上应该使用各自对应的贴现因子.

这里的贴现因子是当前价格曲线上的一个对象.如果以后看到沿某条未来利率路径累计出来的 $\exp(-\int_t^T r_s ds)$,那是另一个随机贴现因子;二者在具体模型和测度选择下才会发生关系.

例如一张固定息债券在 $T_1, \dots, T_n$ 支付固定票息 $C_1, \dots, C_n$,并在 T_n 额外偿还本金 F .如果暂时不考虑违约,提前赎回和其他嵌入期权,那么其价格原则上应该写成

$$B_t = \sum_{i=1}^n C_i P(t, T_i) + F P(t, T_n).$$

一张票息债券因此可以看成许多不同期限的零息现金流叠加.

注 7.84.

这里的 $P(t, T)$ 已经是一个金融模型中的抽象对象.

真实市场中的贴现曲线取决于交易制度,抵押方式,资产选择和研究问题.实务中可以使用美债,隔夜指数掉期(overnight indexed swap, OIS)以及其他工具建立不同的基准曲线.OIS是固定利率与按隔夜参考利率复利得到的浮动支付之间的互换,其市场报价可用来构建一类利率基准曲线.

因此,每条曲线都是针对当前问题选取的模型对象,其经济含义由相应制度与工具共同确定.

7.5.2 债券价格, YTM 与市场报价

贴现曲线建立以后,再看日常市场中更常见的债券收益率.

票面利率和收益率必须区分.假设一张面值\$1000的固定息债券每年支付\$50,那么它的票面利率就是5%.这个数字由债券合约确定,二级市场价格变化不会自动改变它.

债券本身可以继续交易.如果这张债券在市场上的买入价格为\$900,新投资者便以\$900取得未来现金流.他的投资回报由买入价格和后续现金流共同决定,已经无法用5%的票面利率概括.

市场中经常使用**到期收益率**(Yield to Maturity, YTM).给定今天的债券价格和未来现金流后, YTM作为一个统一的内部收益率被反解出来,属于债券价格的摘要指标.

比如在忽略日计数和结算细节,并把 B_t 理解成全价(dirty price)的简化约定下,若每年复利 m 次, YTM y 大概就是满足

$$B_t = \sum_{i=1}^n \frac{C_i}{(1 + y/m)^{m(T_i - t)}} + \frac{F}{(1 + y/m)^{m(T_n - t)}}$$

的那个 y .

原本每一个 T_i 都有自己的贴现因子 $P(t, T_i)$, YTM用统一数字 y 把整条期限结构压缩成一个数.

因此

YTM = 债券价格的一种摘要.

债券定价更底层的对象仍是各期现金流及其贴现因子.

固定现金流债券的价格和收益率通常反向变化.如果市场中其他相近债券已经能够提供更高的收益率,原来按照较低条件支付现金流的债券就需要降低价格才能重新具有吸引力.

注 7.85.

YTM是在给定价格和现金流假设下反解出的指标.投资者提前出售债券,发行人违约或提前赎回,以及票息再投资收益率变化,都会使最终持有期收益率偏离最初观察到的YTM.

债券实际交易时还有一个非常基础的报价问题.合同票息仍然是在票息支付日支付;但在两个票息日之间,报价和结算制度会按照日计数规则把本期票息在买卖双方之间分配,这部分约定金额

称为应计利息 (accrued interest). 因此固定息债券通常需要区分净价 (clean price) 和全价 (dirty price), 二者满足

$$\text{Dirty Price} = \text{Clean Price} + \text{Accrued Interest}.$$

市场屏幕上看到的债券报价经常是 clean price, 实际结算金额还会包含相应的 accrued interest. 因此, “债券报价是 99.5” 只给出净价; 交割一百美元面值债券时还要加上应计利息.

7.5.3 即期利率, 远期利率与期限结构

从 $P(t, T)$ 出发, 可以进一步定义不同口径的 “利率”.

如果采用连续复利约定, 可以定义从时刻 t 到 T 的即期利率或者零息利率 $y(t, T)$, 使得

$$P(t, T) = e^{-y(t, T)(T-t)}, \quad y(t, T) = -\frac{\log P(t, T)}{T-t}.$$

$y(t, T)$ 描述的是: 在时刻 t , 一笔从现在一直锁定到 T 的零息投资对应怎样的年化连续复利收益率.

进一步, 如果 $T \mapsto P(t, T)$ 足够光滑, 可以定义瞬时远期利率

$$f(t, T) := -\frac{\partial}{\partial T} \log P(t, T),$$

于是 $P(t, T) = \exp(-\int_t^T f(t, u) du)$. 特别地, 瞬时短期利率可以写成 $r_t = f(t, t)$.

于是我们平常口语中统称为 “利率” 的东西至少分成三个层次: r_t 对应短期利率, $y(t, T)$ 对应从今天直到某个期限的即期利率, $f(t, T)$ 对应当前价格体系隐含的不同未来区间之间的远期利率.

这里的远期利率是当前债券价格体系隐含的交换比率. 期限溢价, 测度选择以及凸性调整等因素通常使它有别于

$$f(t, T) \neq \mathbb{E}_{\mathbb{P}}[r_T | \mathcal{F}_t].$$

现实市场中相应地存在多种 “收益率曲线”.

注 7.86.

三种常见曲线需要分别理解.

平价收益率曲线 (par yield curve) 描述不同期限的平价票息债券需要具有怎样的票面利率.

零息收益率曲线 (zero-coupon curve) 或**即期曲线** (spot curve) 描述 $T \mapsto y(t, T)$.

远期曲线 (forward curve) 则描述 $T \mapsto f(t, T)$.

三类曲线彼此相关, 各自描述不同口径. 在无套利定价中, 更基础的通常是零息债券价格 $P(t, T)$ 以及由它确定的贴现曲线.

比如美国财政部日常公布的官方美债平价收益率曲线 (Treasury Par Yield Curve) 属于平价收益率曲线. 零息曲线和远期曲线则可以利用市场上的票息债券价格进一步估计.

长期和短期债券的收益率通常有所不同.

把钱借出去三个月与锁定三十年对应不同的风险结构. 长期名义债券的投资者需要面对未来短期利率, 通胀, 经济环境以及资金机会成本的大量不确定性.

一种常见的期限结构分解把长期收益率粗略写成 “未来短期利率的平均预期 + term premium”. 其中的**期限溢价** (term premium) 无法从市场屏幕上直接观察, 需要通过期限结构模型分解得到, 而且可能为负.

收益率曲线倒挂可以同时来自未来短期利率路径的预期, term premium 的变化, 以及债券供求和市场结构等因素. 因此,

Yield Curve $\nRightarrow$ 唯一的市场预测.

债券期限越长, 还有一个通常越重要的问题: 对利率变化的敏感度.

如果暂时把债券价格看成某个收益率 y 的函数 $B(y)$, 可以定义**修正久期** (modified duration)

$$D_{\text{mod}} := -\frac{1}{B} \frac{\partial B}{\partial y}.$$

于是对于较小的收益率变化, 有一阶近似

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y.$$

久期 (duration) 可以理解成债券价格对于利率变化的一阶敏感度. 如果继续保留二阶项, 就会出现凸性 (convexity):

$$\frac{\Delta B}{B} \approx -D_{\text{mod}} \Delta y + \frac{1}{2} \text{Convexity}(\Delta y)^2.$$

实际风险管理里面还经常使用每基点价值 (DV01 或 PV01), 表示收益率变化一个基点 (basis point), 也就是 0.01% 时, 债券或者整个头寸的价值大约变化多少. 在最简单的局部近似下, 其绝对值大约为 $BD_{\text{mod}} \times 10^{-4}$.

到期时间和利率风险需要分别衡量. 两张同样三十年到期的债券, 如果票息结构不同, 久期完全可能不同. 对于零息债券, 麦考利久期 (Macaulay duration) 恰好等于其剩余到期时间.

现实中的整条期限结构会以多种方式移动, 单一久期只是局部压缩. 更细致的风险管理还要研究不同期限点各自的利率暴露.

7.5.4 美债

在美元债券市场里面, 最重要的一组债券就是美国国债.

定义 7.87.

美国国债 (U.S. Treasury Securities) 是指美国财政部为了给联邦政府融资而发行的一系列债务证券.

常见的可交易美债主要包括短期国债 (Treasury Bills), 中期国债 (Treasury Notes), 长期国债 (Treasury Bonds), 通胀保值债券 (TIPS) 以及浮息票据 (Floating Rate Notes, FRNs). 其中 Bills 主要位于短端, Notes 和 Bonds 提供更长期限的固定票息现金流, TIPS 把本金与通胀联系起来, FRNs 的票息则会随参考利率变化.

理解重点是美债在金融市场中承担的几个不同角色, 具体发行制度可以按需查阅.

STRIPS 是连接数学模型和真实市场的一类重要工具.

例 7.88 (STRIPS).

美债市场中的 STRIPS 可以把符合条件的 Treasury Note, Treasury Bond 或 TIPS 的本金和每一笔利息支付拆开, 使这些现金流分别成为独立交易的零息证券.

比如一张还剩十年到期, 每半年付息一次的 Treasury Bond, 原本包含二十笔票息和最后一笔本金. 拆分以后就可以得到二十一个具有不同支付日或者支付性质的零息证券.

因此 STRIPS 可以被看成真实美债市场中和我们前面抽象的零息债券非常接近的一类工具. 接下来从两个层次理解美债在金融市场中承担的角色.

美元固定收益市场的基准资产 美债构成了美元固定收益市场最重要的基准之一. 投资者评价一张十年公司债时, 通常先寻找相近期限的基准曲线, 再衡量承担额外信用和流动性风险所需的补偿.

美债收益率包含其高流动性, 安全资产属性和抵押品价值. 这些特殊用途会压低投资者要求的收益率. 后面模型中的无风险利率 (risk-free rate) 则由模型和市场制度确定, 具体应用需要按问题选择相应曲线, 直接套用屏幕上的十年美债收益率会混淆不同定价对象.

美国财政部日常公布的美债收益率曲线 (Treasury yield curve) 需要按它的构造方法理解. 官方曲线是一条平价收益率曲线, 利用市场中的指示性买方报价拟合得到; 相应的固定期限美债利率 (Constant Maturity Treasury rates) 也是从这条曲线上读取或插值得到的标准化期限点. 市场里未必恰好有一只债券以这个到期收益率 (YTM) 成交. 做无套利定价时, 往往还需要进一步建立适合当前问题的零息曲线 (zero curve).

长期名义美债还有一个特别重要的风险来源—通胀. 普通 Treasury Note 或 Treasury Bond 承诺名义美元支付. 美国政府按照合同足额偿付以后, 长期通胀仍可能明显侵蚀这些现金流的实际购买力.

TIPS (Treasury Inflation-Protected Securities) 用来处理这一问题. TIPS 的票面利率在发行时确定, 其本金随通胀指标调整, 票息再按照调整后的本金计算. 通缩期间本金可以向下调整; 如果持

有到期, 最终偿还本金设有原始面值下限. 这项下限针对到期本金, 二级市场买入者仍会承担价格亏损.

因此同期限普通美债和 TIPS 的收益率差经常被用来观察**通胀补偿** (inflation compensation). 这个差值同时混合了预期通胀, 通胀风险溢价, TIPS 流动性溢价以及市场供求等因素.

美债作为抵押品 美债也是现代美元金融体系中最重要的高质量抵押品之一.

金融机构通过无抵押借款融资时, 出借人承担较大的交易对手风险. 如果机构同时提供信用质量高, 市场价格透明且能够迅速出售的资产作为抵押, 出借人面对的风险就会明显降低.

美债恰好具有这些特点. 金融机构持有美债后, 还可以把它作为抵押品获得融资, 从而释放一部分资金流动性.

最典型的制度就是后面会详细介绍的**回购协议** (repurchase agreement, repo). 法律形式上, repo 是一方出售证券取得现金, 同时约定未来按照约定价格把证券买回来; 从经济效果来看, 它非常接近一笔以证券作为抵押的短期融资.

为了控制抵押品价格变化和交易对手风险, repo 可以使用 haircut 或 margin, 也就是抵押物价值需要高于实际取得的融资额. 如果抵押品市值为 V_0 , 实际取得的现金为 C_0 , 可以粗略写成

$$h = 1 - \frac{C_0}{V_0}.$$

较低的 haircut 会让同一笔现券头寸占用更少自有资金. 抵押品价格, 融资利率和展期条件发生变化时, 这类高杠杆头寸也更容易被迫补充资金或者缩减规模.

现实中的 Treasury repo 分成多个市场层次, haircut 制度也随市场而异: 有些市场长期使用正 haircut, 另一些双边交易中也曾大量存在零 haircut, 并通过净额结算, 组合保证金以及其他机制管理风险.

美债同时具有资产和抵押品两层价值. 银行, 券商, 做市商, 对冲基金以及清算体系中的大量交易都需要高质量抵押品, 美债正是整个体系中最重要抵押资产之一.

国债基差交易 前面在衍生品节提到的国债基差交易, 是由现金美债, 国债期货和 repo 融资共同构成的相对价值交易.

现券美债 (cash Treasury) 是已经发行并在现券市场交易的国债; **国债期货** (Treasury futures) 则是围绕未来交割或者结算建立的标准化合约. 二者都暴露于相近的美债利率风险, 同时具有不同的现金流和制度结构.

一份国债期货通常对应一篮子符合条件的可交割债券. 期货空头可以在规则允许的范围内选择实际交割的债券; 不同债券的票息和期限差异, 又需要通过 **conversion factor** 调整. CME 对 conversion factor 的说明可以看作理解这类合约交割制度的基础材料 [CME24].

对于一只候选交割券, 市场上常见的原始基差可以示意性地写成

$$b_t^{\text{raw}} = P_t^{\text{cash, clean}} - CF F_t^{\text{fut}},$$

其中 CF 是 conversion factor. 这里的符号约定是“现券价格减去调整后的期货价格”; 如果国债期货相对于现券偏贵, 这个 b_t^{raw} 反而可能变小甚至为负. Federal Reserve 讨论 option-adjusted basis net of carry (OABNOC) 时使用的是收益口径, 其中正 basis 表示期货相对现券偏贵, 适合做多现券并做空期货的 long basis trade [Gli+24]. 不同资料可能采用相反的 basis 符号约定, 阅读时应先确认定义.

可比的净基差还要处理应计利息, 持有期间票息, repo 融资成本, 交割时间以及空头拥有的交割选择权. 原始现券与期货报价之差经过这些调整以后, 才能用于判断相对价值机会.

Basis 比较的是持有并融资一只可交割现券的经济成本, 与通过期货取得相近交割暴露的经济成本.

一种典型结构是: 当交易者认为国债期货相对于可交割现券偏贵时, 买入现券, 同时卖出相应国债期货. 为了避免占用全部现券购买资金, 交易者再把买入的美债放进 repo 市场, 用这项美债作为抵押借回大部分现金. 于是头寸大致可以写成

$$\begin{aligned} &+ \text{cash Treasury,} \\ &- \text{Treasury futures,} \\ &\text{repo-financed cash position.} \end{aligned}$$

现券多头和期货空头会抵消相当一部分共同的利率方向风险。交易者主要押注两种高度相关的价格会向交割规则和持有成本约束允许的关系收敛，对“美债整体上涨还是下跌”的暴露则相对较小。

价差越小，交易越依赖杠杆才能得到足够可观的收益。交易能否等到收敛，则取决于中间路径。

现券需要持续获得 repo 融资；期货空头需要每日结算变动保证金；repo 出借人还可能提高 haircut，提高融资利率，要求补充抵押品或者拒绝展期。长期收敛的判断无法消除这些中间现金流压力。

如果压力期间基差先向不利方向偏离，现金流压力可能从不同腿上出现：若期货价格相对上升，期货空头需要支付变动保证金；若现券价格相对下跌，repo 出借人可能要求补充抵押品或者提高 haircut；若融资市场本身变紧，交易者还可能无法按原条件展期 repo。为了取得现金，他可能被迫卖出债券并买回期货空头。如果许多高杠杆交易者同时这样做，去杠杆本身又可能继续压低现券相对价格，推动基差进一步偏离。OFR, Federal Reserve 和 BIS 的相关研究都把 repo rollover, futures margin 和高杠杆去杠杆视为这类交易的重要脆弱性来源 [AS23; BK21; BKM23]。

adverse basis move $\rightarrow$ margin and funding calls $\rightarrow$ forced deleveraging
 $\rightarrow$ further adverse basis move.

国债基差交易依靠交割机制约束相对价格，同时承担融资展期风险，repo 利率和 haircut 风险，期货保证金流动性风险，现券市场流动性风险，交割券切换和模型误差，以及被迫在收敛以前退出的路径风险。

这个例子揭示了固定收益市场的一项重要规律：

最终可能收敛 $\neq$ 中间一定能够活下来。

这些问题已经开始进入美元资金市场本身。后面一节再正式讨论 repo, SOFR, 银行准备金以及美联储。

7.5.5 信用风险，信用利差与 CDS

有了基准债券以后，我们就可以进一步问：为什么同期限的公司债通常需要提供更高的收益率？分析在基准期限结构上加入发行人的信用风险。

最明显的区别是**信用风险**。美国政府，一家现金流稳定的大型企业和一家已经接近破产的企业，按照合同偿还债务的能力差异巨大。

一只公司债的收益率可以粗略分成基准收益率和利差 (spread)。利差混合了预期信用损失，信用风险溢价，流动性，供求以及其他因素。

“利差”本身还有多种计算口径。

注 7.89.

实际债券分析中必须同时说明利差的基准和计算方式。

G-spread 通常把债券 YTM 和插值得到的政府债收益率进行比较；I-spread 使用 swap curve 作为基准；Z-spread 则寻找一个统一利差加到整条 zero curve 上，使折现后的现金流等于当前价格；对于具有嵌入期权的债券，还经常使用 OAS 来进一步处理期权价值。

“这只债券的信用利差是多少”只有在说明算法和基准后才是一个完整的问题。

为了进一步数学化信用风险，可以把发行人违约本身看成一个随机事件。

令

$$\tau: \Omega \rightarrow [0, \infty]$$

表示发行人发生违约的时间，称为**违约时间**。那么站在时刻 t ，我们可以考虑 $\mathbb{P}(\tau > T \mid \mathcal{F}_t)$ ，也就是在当前信息下发行人能够存续到 T 的条件概率。

违约后债权人通常仍能回收一部分价值。这里需要先约定**回收率** (recovery rate) 的口径：它可以是相对于面值，违约前市值，或某个无风险债券价值的回收比例。在固定了暴露口径和回收约定以后，若回收比例记为 R ，相应的**违约损失率** (Loss Given Default, LGD) 可以写成 $\text{LGD} = 1 - R$ 。

在最简单的强度模型里面，还可以使用**违约强度** (hazard rate) λ_t 描述已经存续到时刻 t 的条件下，接下来一个很短时间里面发生违约的瞬时概率强度。直觉上可以写成

$$\lambda_t \approx \lim_{h \downarrow 0} \frac{\mathbb{P}(t < \tau \leq t + h \mid \tau > t, \mathcal{F}_t)}{h},$$

只要相应模型允许这样定义.

信用风险由此从一句模糊的“这个公司可能还不起钱”变成了随机违约时间, 存续概率 (survival probability), 回收率和违约强度等可以进一步建模的对象.

投资者可以保留债券头寸, 再通过另一份合约把部分信用风险转移给交易对手. 这种安排引出了信用违约互换 (Credit Default Swap, CDS).

定义 7.90.

信用违约互换 (Credit Default Swap, CDS) 是一种信用衍生品. CDS 的信用保护买方 (protection buyer) 按照合约向信用保护卖方 (protection seller) 支付费用; 如果参考主体或者参考债务发生约定的信用事件 (credit event), 保护卖方则按照合约承担相应的保护支付 (protection payment).

从经济直觉看, CDS 类似为一项信用风险购买保护. 它的制度结构有别于普通保险合同, 保护买方也可能没有持有相应债券. 因此, CDS 既可以对冲已有信用风险, 也可以直接建立对某个主体信用状况的多头或空头暴露.

相比于一张现金债券, CDS 把信用保护单独做成合约, 价格通常更集中地反映参考主体的信用风险. CDS 定价还会纳入回收率, 风险溢价, 流动性, 融资成本 (funding cost) 以及保护卖方自身的交易对手风险.

理论里面经常使用**平价 CDS 利差** (par CDS spread) s_{CDS} , 也就是让 CDS 合约初始价值为零的持续利差 (running spread). 在一个非常简化的常数回收率和常数违约强度模型里, 可以得到类似

$$s_{\text{CDS}} \approx (1 - R)\lambda^{\mathbb{Q}}$$

这样的关系.

这里的 $\mathbb{Q}$ 是后面无套利定价中会正式引入的风险中性测度. 从 CDS 价格反推出的 $\lambda^{\mathbb{Q}}$ 属于**风险中性违约强度**. 现实世界中发行人的物理违约频率由 $\mathbb{P}$ 测度描述. 二者的区别可写成

$$\text{CDS 利差} \neq \text{现实世界违约概率}.$$

从 CDS 利差得到“市场隐含违约概率”时, 计算已经加入回收率, 贴现, 风险溢价以及概率测度等一整套模型假设.

现实 CDS 的报价比这个理论形式更复杂. 为了标准化和清算, CDS 合约可以使用固定票息, 再在交易开始时通过前端支付 (upfront payment) 调整合约的初始市场价值. 因此, 平价利差是重要的信用市场指标, 实际合约的固定票息则可能采用标准化数值.

7.5.6 从期限结构到随机过程

利率市场的基础数学对象已经从单个“利率” r 扩展为整族零息债券价格:

$$P(t, T), \quad 0 \leq t \leq T.$$

这个对象具有双重时间结构.

固定到期日 T 时, $t \mapsto P(t, T)$ 刻画同一张在 T 到期的零息债券怎样随现实时间变化, 形成一条债券价格过程.

固定当前时刻 t 时, $T \mapsto P(t, T)$ 给出市场在这一时刻对于所有未来期限的定价, 形成一整条贴现曲线.

如果进一步把市场状态写出来, 随机对象可以写成

$$P(t, T, \omega).$$

利率随机过程天然包含两个时间维度: 股票模型最简单时可能只研究一个随时间变化的 S_t , 利率市场则要同时处理“当前时间 t ”和“到期时间 T ”.

后面的利率模型会用不同方式压缩这种复杂性.

比如短期利率模型会选择一个低维状态 r_t , 再从它推导不同期限的债券价格; Vasicek 和 CIR 都属于这一类思路. 另一类方法则会更加直接地研究整条远期利率曲线怎样随时间变化, HJM 框架就是典型例子.

建模时可以选择

完整利率市场 $\rightsquigarrow$ 短期利率状态,

也可以选择

完整利率市场 $\rightsquigarrow$ 远期曲线状态.

两条路线根据研究目的选取不同的状态压缩方式.

债券市场最基础的结构至此已经大致建立.

这一节的主线可以压缩成这样: 某个主体需要今天的资金, 于是发行债券, 用未来的一组支付规则交换投资者今天的资本; $P(t, T)$ 给不同时间的货币建立交换关系, 并进一步形成完整的期限结构; 不同期限又具有不同的利率和风险暴露; 美债同时承担美元债券市场的重要基准资产和高质量抵押品角色; 信用债又在基准期限结构之上加入发行人的信用风险, CDS 则进一步把这部分风险单独做成可以交易的合约.

下一节将处理一个重要问题:

美元短期利率在现实世界中究竟怎样形成?

银行之间为什么需要隔夜资金, 美债为什么能够被拿去换取现金, repo, 银行准备金, SOFR 和美联储又是什么关系?

7.6 美联储, 美元体系与短端资金市场

前面讨论债券期限结构时, 我们已经看到期限本身就是债券定价的重要因素之一. 三十年贷款和几个月贷款暴露于不同的不确定性. 期限越长, 未来利率, 通胀, 资金机会成本以及其他市场环境发生变化的空间通常就越大.

不过我们也可以反过来问一个更加基础的问题:

如果不断缩短一笔借款的期限, 最后会走到哪里?

在现实金融市场里面, 一个很自然的答案就是隔夜. 今天借出一笔美元, 下一个工作日就收回来. 相比几十年的长期债券, 这里已经很少有时间让长期通胀, 经济周期或者远期利率变化逐渐累积, 所以各种隔夜融资利率构成了美元利率体系最短的一端.

隔夜融资仍然包含风险. 如果只是把钱无抵押地借给另一个金融机构, 我们仍然需要考虑对方第二天能不能还钱; 如果使用抵押品, 又会涉及抵押品本身的价值, 流动性以及具体的交易制度.

美国的美元制度由一百多年的危机和改革逐层塑造: 1907 年银行恐慌暴露了中央银行缺位时的流动性缺口, 1913 年联邦储备法建立了美联储, 1930 年代的银行危机推动了联邦存款保险, 2008 年以后大规模资产购买和充裕准备金让准备金付息和央行隔夜投资工具变得核心, 而伦敦银行间同业拆借利率 (London Interbank Offered Rate, LIBOR) 的缺陷又推动了更多依赖真实成交的替代参考利率. 这里的制度性说明主要参考 Federal Reserve, New York Fed, FDIC, SEC, BIS 以及相关教材和论文 [Ald+20; Alt; Boab; Boac; Boad; Boae; DD83; Feda; Fedd; Fedf; Fedg; Fedi; Hul22; HPW19; MT; TS11; US g].

所以阅读时, 需要始终区分三个层次: 第一层是**制度和资产负债表**:

- 美国财政部一般账户 (Treasury General Account, TGA) 是财政部在美联储的运营账户;
- 准备金余额利率 (Interest on Reserve Balances, IORB) 是美联储向合格机构准备金余额支付的管理利率; 隔夜逆回购工具 (Overnight Reverse Repurchase Agreement Facility, ON RRP) 是合格对手方向美联储配置隔夜资金的政策工具; 央行流动性互换安排 (central bank liquidity swap lines) 是央行之间供给美元流动性的制度安排.

第二层是**市场工具和参考利率**:

- 联邦基金 (federal funds, fed funds) 是合格机构之间以准备金余额进行的无抵押隔夜融资; 货币市场基金 (money market fund, MMF) 是持有短期高流动性资产的基金结构; 短期国库券 (Treasury bill, T-bill) 是美国财政部发行的短期证券; 回购协议 (repurchase agreement, repo) 是以证券为抵押品的融资交易;
- 有效联邦基金利率 (Effective Federal Funds Rate, EFFR) 是无抵押联邦基金成交形成的隔夜参考利率; 有担保隔夜融资利率 (Secured Overnight Financing Rate, SOFR) 是以美债回购成交为基础的有抵押隔夜参考利率.

第三层才是**金融模型中的瞬时短期利率** r_t .

前两层产生真实市场中的资金流, 交易和数据. 第三层则把这些复杂结构压缩成一个可以用于贴现和定价的随机过程. 在适当条件下,

$$r_t = - \left. \frac{\partial}{\partial T} \log P(t, T) \right|_{T=t}.$$

这条公式非常漂亮, 但它背后的现实世界一点也不漂亮.

7.6.1 先有事故, 后有制度

美联储体系 在进入短端美元市场以前, 先看整个美元银行体系最核心的机构之一: 美联储.

定义 7.91.

美联储 (Federal Reserve System, Fed) 是指美国的中央银行体系. 它主要承担美国货币政策的制定和实施, 为银行体系提供中央结算和流动性基础设施, 监管其中一部分金融机构, 并承担维护金融体系稳定等职能.

美联储是对早期银行体系缺陷的制度回应. 十九世纪末和二十世纪初的美国银行体系地域分割严重, 货币和准备金很难在地区之间顺畅调动. 一旦发生恐慌, 资金需求会突然集中到现金和最安全的银行上, 而当时的金融体系只能依靠清算所, 财政部以及少数私人银行家临时组织救助.

1907 年恐慌就是这种旧系统的压力测试. 它从纽约信托公司和短期融资市场开始扩散, 并推动了后来建立中央银行的货币改革运动 [MT]. 1913 年联邦储备法随后建立了联邦储备体系, 目标之一正是提供更加安全, 有弹性且稳定的货币和金融系统 [Boad; Fedi].

所以美联储更合适的理解是: **它位于美元银行体系的中央银行层**. 商业银行可以在自己的资产负债表上发放贷款, 创造存款并处理客户支付, 但不同银行之间仍然需要一种彼此都接受的最终结算资产, 以及一套完成银行间支付的中央基础设施. 美联储就在这一层的中心.

从组织上看, 美联储体系由位于 Washington, D.C. 的理事会 (Board of Governors), 十二家地区性联邦储备银行 (Federal Reserve Banks), 以及联邦公开市场委员会 (Federal Open Market Committee, FOMC) 共同构成.

纽约联邦储备银行在市场操作中尤其重要. 后面介绍 EFRR, SOFR, repo, ON RRP 以及其他货币政策实施工具时, 都会不断遇到它.

这套组织结构体现了历史妥协: 全国性中央银行权力与地区储备银行, 银行体系的参与并存, 并在政治上避免让所有权力集中到 Wall Street 或 Washington 某一侧. 美联储因而形成了带有历史妥协的分布式中央银行系统.

现代美元的不同层次 有了美联储以后, 我们终于可以问一个更加基础的问题:

我们平时所说的“美元”, 到底是什么?

答案比“美国发行的钱”稍微复杂一点. 同样被称为美元的东西, 可能来自不同发行人的资产负债表.

定义 7.92.

美联储票据 (Federal Reserve Note) 是指由美联储体系发行进入流通的美元纸币. 从资产负债表来看, 美联储票据是美联储的负债.

这里的“Note”不要和前面介绍的 Treasury Note 混淆. Treasury Note 是美国财政部为了融资而发行的一类中期国债; Federal Reserve Note 则是美元纸币, 承担现金支付功能.

美联储的美元性质负债还包括准备金余额. 商业银行以及其他符合条件的金融机构还可以在美联储持有准备金余额.

定义 7.93.

银行准备金 (bank reserves) 是指商业银行为了支付结算和流动性管理而持有的高度流动性资产. 在本文讨论美元资金市场时, 如果没有特别说明, “准备金”主要是指金融机构存放在美联储的 **准备金余额** (reserve balances).

所以从中央银行这一层来看，美元已经可以表现成两种很不一样的东西：一种是公众能够直接持有的美元纸币，另一种是主要存在于金融机构之间的准备金余额。二者都是美联储的负债，只是持有人和用途不同。

而普通人在银行账户里面看到的 \$100 又是另一回事。比如一个人在某家商业银行的账户里面有 \$10,000，那么这 \$10,000 对储户来说是一项资产；但从这家银行的资产负债表来看，它是一笔银行对储户承担的负债。

从资产负债表来看，几种平时都会被我们称作“美元”的对象可以简单整理成：

对象	对谁是资产	对谁是负债	主要用途
美元纸币	持有人	美联储	现金支付
银行存款	储户	商业银行	支付, 储蓄
准备金余额	商业银行等机构	美联储	银行间结算, 流动性管理

所以这里有一个重要原则：同一个美元计价单位之下，发行人，法律请求权和风险仍然可以各不相同。

日常生活里面之所以几乎感觉不到这种区别，是因为美元纸币，商业银行存款以及银行间支付体系在正常情况下能够维持非常稳定的面值转换关系。银行账户里面的 \$100 通常既可以取成 \$100 现金，也可以按照 \$100 转到另一家银行。

日常使用的“一美元”背后，可能对应不同机构资产负债表上的不同请求权。

银行存款，准备金与挤兑 商业银行创造存款这件事，可以先从一个极简记账看起。如果银行发放一笔金额为 L 的贷款，它可以同时在资产端增加贷款，在负债端为借款人增加存款：

银行资产	银行负债
+ 贷款 L	+ 存款 L

这就是常说的“贷款创造存款”。

这句话指的是银行创造自己的存款负债。相应支付仍需要通过美联储准备金等结算资产完成。如果借款人随后把钱转给另一家银行的客户，原来的贷款仍然留在放贷银行的资产端，但存款已经跑到另一家银行。这时付款银行需要把相应结算资产转给收款银行，最核心的结算资产之一就是准备金。

因此：

贷款创造存款 $\nRightarrow$ 单家银行没有融资和流动性约束。

如果一家银行不断扩张贷款，而由此产生的存款又不断流向其他银行，它仍然需要通过吸收存款，批发融资，repo，出售资产或者向央行借款等方式补充流动性。

银行体系为什么需要这些层层补丁，根源之一在于存款的期限和流动性转换。储户希望存款随时能够按面值支付或取出，而银行资产端持有的贷款通常期限更长，流动性更差。如果大量储户同时要求提款，即使一家银行长期来看未必资不抵债，也可能被迫在很差的价格下出售资产。Diamond-Dybvig 模型正是分析银行挤兑和存款保险的经典理论框架之一 [DD83]。

美国后来逐步加上的补丁也就沿着这几个压力点展开：贴现窗口让合格存款机构可以用资产作抵押向美联储借款；1933 年建立的 FDIC 存款保险降低了受保险存款人的挤兑动机 [Fedal]；资本，流动性和审慎监管试图降低银行本身出问题的概率；而准备金和央行结算体系则维持银行之间的最终支付。

2020 年以后，美国法定准备金率被降为 0 [Boag]。准备金仍然是银行间支付结算，流动性管理以及货币政策实施的核心资产。这就像把旧系统里面某个参数调成了零，但底层运行时环境仍然离不开那套结算基础设施。

7.6.2 TGA 与准备金管道

银行准备金总量会随多项资产负债表流量变化。美联储的负债端还有另一个会直接影响准备金的重要账户。

定义 7.94.

美国财政部一般账户 (Treasury General Account, TGA) 是指美国财政部在美联储持有的主要运营账户. 美国政府的许多财政收入, 融资收入以及财政支出最终都会通过这个账户进行结算.

美联储不仅是中央银行, 也是美国财政部的财政代理人. 税款和发债收入可以流入 TGA, 政府支出, 国债付息和到期偿还则可以从 TGA 流出. 这听起来像财政部自己的现金管理问题, 但因为 TGA 位于美联储负债端, 它会直接改变银行体系中的准备金.

把美联储资产负债表极度简化为

$$A_t^{\text{Fed}} = N_t + R_t + G_t + Q_t + O_t,$$

其中 A_t^{Fed} 表示美联储资产, N_t 表示流通中纸币, R_t 表示准备金, G_t 表示 TGA, Q_t 表示逆回购等负债, O_t 汇总其他负债和资本. 于是

$$\Delta R_t = \Delta A_t^{\text{Fed}} - \Delta N_t - \Delta G_t - \Delta Q_t - \Delta O_t.$$

如果短期内其他项目近似不变, 就可以粗略记成

$$\Delta R_t \approx -\Delta G_t - \Delta Q_t.$$

这条会计关系不带有行为定律的含义, 只用来说明: 当税款或者国债认购资金从商业银行体系流入 TGA 时, 银行体系中的准备金通常会下降; 当财政部从 TGA 花钱时, 准备金又会回到银行体系.

TGA 通过准备金供给影响 fed funds, repo 和其他隔夜利率. 纳税日, 大规模美债结算, 财政集中支出, 以及债务上限僵局结束以后财政部重新补充 TGA, 都可能让短端美元资金突然变紧或变松 [Boac; HPW19].

这已经很像随机过程问题了: 准备金 R_t 会受日历效应, 财政流量, 政策操作和市场压力共同驱动, 其变化往往带有明显的日历效应和跳跃. 后面如果要写短端利率模型, 这些变量就可能变成状态变量, 跳跃项或者外生冲击.

7.6.3 沿风险梯子走过美元短端

下面从一个特定视角看短端美元资产: 一个持有大额美元现金, 无法完全依靠零售存款保险, 又希望短期停放资金的机构, 可以把钱放在哪里?

这个排序只是教学上的视角, 不构成严格的数学全序. 不同投资者的准入资格, 抵押品质量, 法律结构, 期限, 流动性和监管约束都会改变具体风险. 但它可以帮助我们从小风险的私人无抵押美元, 逐步走向抵押融资, 短期国债和央行负债.

工具	直接债务人或结构	主要保护	主要剩余风险
未保险银行存款, fed funds	商业银行或存款机构	银行资本和流动性	信用, 挤兑和无抵押风险
Prime MMF 份额	基金份额	分散化和短期限资产	组合信用, 赎回和基金结构风险
Government MMF 份额	基金份额	政府证券, 政府 repo 等	流动性, 操作和非保证净值风险
Treasury repo	私人交易对手	国债抵押品, haircut	对手方, 抵押品和法律操作风险
T-bill	美国财政部	主权信用和深度市场	利率, 结算和极端制度事件风险
准备金, ON RRP	联储银行	央行负债或央行交易对手	准入限制和操作规程

无抵押私人美元: Fed funds 与 EFFR Fed funds 市场最初服务于一个非常实际的问题: 有些银行在日终准备金不足, 另一些银行有多余准备金, 于是它们进行隔夜, 无抵押的美元借贷。

定义 7.95.

联邦基金市场 (Federal Funds Market) 是符合条件的金融机构围绕其美联储账户准备金余额进行无抵押隔夜美元借贷的市场之一。在这个市场中形成的利率通常统称为联邦基金利率。

联邦基金交易采用**无抵押结构**。借款人不需要像 repo 那样同时交出一批美债作为抵押品, 所以出借人除了考虑期限以外, 还要考虑交易对手信用风险和资产负债表约束。

定义 7.96.

有效联邦基金利率 (Effective Federal Funds Rate, EFFR) 是指 New York Fed 根据实际发生的隔夜联邦基金交易计算并公布的参考利率。EFFR 是成交量加权中位数, 因而首先是一个从真实市场成交中统计出来的利率。FOMC 直接规定的是联邦基金利率目标区间。

这一区别很重要。FOMC 给出的是联邦基金利率目标区间, EFFR 则是市场交易的统计结果。美联储通过政策工具影响市场参与者的机会成本, 让实际成交利率尽量运行在目标区间附近 [Fed; Fede]。

如果把某类无抵押隔夜利率写成一个示意性分解, 可以想成

$$y_t^{\text{unsec}} = m_t + s_t^{\text{credit}} + s_t^{\text{liquidity}} + s_t^{\text{balance sheet}} + \varepsilon_t.$$

这里 m_t 是政策锚, 其余项分别表示信用风险, 流动性, 资产负债表约束以及统计噪声。这个分解是直觉性的, 用来说明: 现实市场利率由政策锚和多项利差共同构成。

货币市场基金与短期现金管理 美元短端市场当然不只有银行。现实中大量企业, 基金, 保险公司和个人都会持有暂时不需要使用的美元。这些资金通常既不希望承担太大的价格波动, 又不愿意完全放弃短期利息, 所以会寻找短期限, 高流动性的现金管理工具。

定义 7.97.

货币市场基金 (Money Market Fund, MMF) 是主要投资于短期限, 高流动性债务工具的投资基金, 常被用于短期现金管理。

货币市场基金做的事情可以粗略理解为: 投资者把暂时不用的现金交给基金, 基金再把这些资金配置到各种短期金融工具里面。在 MMF 中, 投资者持有基金份额, 基金背后持有的是一篮子短期资产。

不同类型 MMF 的投资范围也不同。政府型货币市场基金主要投资现金, 美国政府证券以及以政府证券支持的 repo; 优质型货币市场基金还可能持有银行存单, 商业票据等私人短期信用工具; 免税型货币市场基金则主要投资短期市政债务。

注 7.98.

货币市场基金份额属于基金证券。FDIC 存款保险的覆盖对象是合格银行存款, 货币市场基金份额位于该保障范围之外。虽然许多货币市场基金希望提供非常稳定的现金管理体验, 但它们仍然属于基金投资, 具体风险取决于基金实际持有的资产和赎回机制的设计。

所以“现金”包含多种法律关系和资产形态。一个投资组合里面的现金可能进一步表现成银行存款, T-bill, MMF 份额或者 repo。这些工具都能承担现金管理功能, 各自对应不同的发行人, 信用结构, 流动性和收益 [US g]。

Repo 与抵押融资 上一节已经介绍过, 美债除了是一类债券以外, 还有一个和普通投资资产很不一样的功能: 它可以被广泛用作高质量抵押品。现在这件事情终于可以和美元短端资金市场连接起来。

定义 7.99.

回购协议 (Repurchase Agreement, Repo) 是指一方先出售证券取得现金, 同时约定在未来按照事先约定的价格重新买回这些证券的交易. 从经济效果来看, repo 非常接近一笔以证券作为抵押的短期融资.

比如一方今天交出美债并取得 \$100, 同时约定第二天支付 \$100.01 把美债买回来, 那么多出来的 \$0.01 就是这笔短期融资的利息. 如果初始现金为 C_0 , 到期回购金额为 C_1 , 计息年化比例为 δ , 则简单 repo rate 可以写成

$$r^{\text{repo}} = \frac{C_1/C_0 - 1}{\delta}.$$

同一份合约可以从两个方向看. 对于交出证券, 取得现金并承诺以后买回的一方, 这是 repo; 对于提供现金并暂时取得证券的一方, 同一笔交易则称为 reverse repo.

抵押品可以缓释信用风险, 同时会引入抵押品管理和处置问题. Repo 仍然会面对交易对手风险, 抵押品价格变化, 市场流动性以及结算风险, 所以现实交易还会利用 haircut, margin, 净额结算等方式进行风险管理. 如果抵押品市值为 V_0 , 初始现金为 C_0 , 常见的 haircut 可以写成

$$h = 1 - \frac{C_0}{V_0}.$$

还有一个细节很重要: repo 利率不只是在给现金融资定价, 抵押品本身也会参与价格形成. 如果某一只具体美债在市场上特别难以取得, 那么“暂时拿到这只美债”本身就会有额外价值. 现金提供者可能愿意接受异常低的 repo 回报来取得这只证券, 这种现象通常称为该券处于特殊状态 (trading special).

SOFR 与 LIBOR 之后的参考利率 有了美债 repo 市场以后, 我们可以引入现代美元金融市场里面最重要的参考利率之一: SOFR.

定义 7.100.

有担保隔夜融资利率 (Secured Overnight Financing Rate, SOFR) 是 New York Fed 根据大量美债 repo 隔夜实际成交数据计算并公布的参考利率. 它衡量的是以美国国债为抵押借入隔夜现金的大致成本.

SOFR 的重要性和 LIBOR 的历史问题有关. LIBOR 曾经广泛用于贷款, 债券和衍生品合约, 但它与真实市场成交的联系较弱, 并且在金融危机后暴露出操纵风险和底层交易稀薄等问题. Alternative Reference Rates Committee (ARRC) 因此在 2017 年选择 SOFR 作为美元 LIBOR 的推荐替代利率 [Alt].

SOFR 是对大量 repo 成交的统计汇总. Repo 市场先发生大量真实融资交易, New York Fed 再利用三方 repo, General Collateral Finance Repo (GCF Repo), 以及部分经 Fixed Income Clearing Corporation (FICC) 清算的双边 Treasury repo 数据, 并过滤一部分可能反映特殊券稀缺性的交易, 计算出成交量加权中位数 [Fedg]. 因此可以粗略理解成

$$\text{美债 repo 市场} \rightarrow \text{真实成交} \rightarrow \text{SOFR}.$$

这和前面的 EFFR 很相似: EFFR 是从联邦基金市场的无抵押隔夜交易中统计出来的, SOFR 则是从美债 repo 这种有抵押的隔夜融资交易中统计出来的. 两者都属于美元隔夜参考利率, 分别观察联邦基金市场和美债 repo 市场.

SOFR 本身只描述隔夜期限. 一个月, 三个月或更长期限的贷款与衍生品, 需要按照合约约定把隔夜 SOFR 转换为期限利率. 一种常见做法是把期间每天实际出现的隔夜 SOFR 按照相应计息天数逐日复合. 如果每天对应的 SOFR 为 SOFR_{t_i} , 时间长度为 Δ_i , 那么累计增长因子大概具有

$$\prod_i (1 + \text{SOFR}_{t_i} \Delta_i)$$

这样的形式.

所以至少还需要区分隔夜 SOFR (overnight SOFR), 复合 SOFR (compounded SOFR), 以及从衍生品价格中构造出来的前瞻期限 SOFR (forward-looking Term SOFR) [CME].

即使大家都在说“SOFR”, 也要追问: 究竟是在说今天实际形成的隔夜参考利率, 一段时间内复合出来的利率, 还是市场价格隐含的未来期限利率?

IORB 与 ON RRP 现在回到美联储怎样影响最短端资金价格. 在当前的充裕准备金框架中, 其中一个非常重要的工具是 IORB.

定义 7.101.

准备金余额利率 (Interest on Reserve Balances, IORB) 是美联储对符合条件的机构持有的准备金余额支付的利率.

IORB 本身也是历史补丁. 2006 年法律授权美联储对准备金支付利息, 原计划 2011 年生效; 2008 年金融危机期间, 这项权限被提前到 2008 年 10 月生效 [Boae]. 危机后美联储资产负债表大幅扩张, 银行体系持有大量准备金, 旧式的“稀缺准备金”利率控制方式不再足够. IORB 于是成为美联储影响银行短期资金机会成本的核心工具.

直觉上, 如果一家银行把准备金留在美联储就能够取得一定收益, 那么别人希望向它借隔夜资金时, 银行自然会比较: 继续把钱留在美联储, 还是按某个更低收益率借给对方. 所以 IORB 会成为银行配置短期资金的重要机会成本.

IORB 对全市场形成的是软下限, 因为联邦基金市场的资金提供者面临不同的 IORB 准入资格. 比如某些政府支持企业和 Federal Home Loan Banks 缺乏通过准备金余额取得 IORB 的资格, 因而仍然可能愿意按照低于 IORB 的利率提供隔夜资金. 这也是为什么 EFFR 可能低于 IORB.

对于很多非银行现金投资者来说, 另一个重要工具是 ON RRP.

定义 7.102.

隔夜逆回购工具 (Overnight Reverse Repurchase Agreement Facility, ON RRP) 是美联储向符合条件的交易对手提供的一种隔夜投资工具. 货币市场基金, 政府支持企业等合格机构可以通过这项工具把隔夜资金配置给美联储, 并按照美联储规定的 ON RRP offering rate 取得收益.

ON RRP 的历史动机也来自准入差异. 很多非银行现金投资者缺乏持有准备金余额并取得 IORB 的资格. 当市场利率过低时, ON RRP 给它们提供了另一种直接面对美联储配置隔夜资金的选择, 从而帮助限制隔夜利率的下行压力, 并为更广泛的货币市场利率提供下方支撑 [Boaf; Fedf].

因此这几个对象虽然经常同时出现, 角色却完全不同:

FOMC 目标区间 → 政策目标,
IORB / ON RRP → 政策实施工具,
EFFR / SOFR → 市场参考利率.

政策传导使下列三个利率互相影响, 同时保留各自对应的市场利差:

$$\text{EFFR}_t = i_t^{\text{IORB}} = \text{SOFR}_t.$$

IORB 和 ON RRP 提供政策锚, 准备金和抵押品供给决定市场环境, 真实交易再在不同市场中形成 EFFR, SOFR 以及其他参考利率.

7.6.4 美元体系的边界: 离岸美元与链上美元

离岸美元与全球美元融资 到这里, 我们介绍的主要还是美国本土的美元体系. 美元体系还延伸至美国境外.

全球大量银行, 企业和金融机构都会持有美元资产和美元负债. 其中相当一部分甚至直接存在于美国境外金融机构的资产负债表上. 传统上, 存放在美国境外银行中的美元存款经常被称为**欧洲美元**或者**离岸美元存款** (Eurodollar). “Euro”最初用来描述存在于美国境外银行体系中的美元存款, 地理范围涵盖欧洲以外地区, 计价货币仍是美元; 后来逐渐泛化为离岸美元体系的一部分.

这件事情和前面介绍商业银行存款时的逻辑类似. 如果一家位于美国境外的银行接受了一笔美元存款, 那么这笔存款首先仍然是这家银行对于储户承担的一项美元计价负债. 它由银行整体资产负债表和结算安排支持, 美联储准备金只在需要进入相应结算环节时发挥作用.

因此, 美元体系的规模和结构还取决于商业银行的资产负债表. 商业银行在美国境内和境外都可以通过自己的资产负债表产生大量美元计价的债权和债务关系.

离岸银行既然承诺按美元支付, 就必须回答一个现实问题: **到期支付时, 去哪里取得美元资金?**

常见办法包括吸收美元存款, 从其他金融机构借入美元, 进行 repo, 发行美元债务, 以及通过外汇掉期 (FX swap) 临时取得美元. 假设一家欧洲金融机构手里主要持有欧元, 但未来三个月临时需要美元. 它可以先用欧元换取美元, 同时约定三个月以后再按事先确定的价格把美元换回欧元. 从经济效果来看, 这就让它在这段时间内取得了美元融资.

如果用 S_t 表示一单位外币的即期美元价格, $F_t(T)$ 表示同一报价方式下的远期价格, 那么在没有信用, 流动性和资产负债表摩擦时, 抵补利率平价会给出类似

$$\frac{F_t(T)}{S_t} = \frac{1 + r_t^{\$} \Delta}{1 + r_t^f \Delta}$$

的关系. 现实中的偏离通常可以用 cross-currency basis 描述. Basis 扩大时, 往往说明通过外汇掉期取得美元的成本已经偏离了由两种利率机械推导出的水平 [Ald+20].

2008 年金融危机和 2020 年全球美元紧张都说明, 离岸美元体系的私人负债可以远大于当地机构随时能够取得的央行美元. 于是现代美元流动性互换安排就像美元体系边界上的补丁: 当境外美元融资市场出现压力时, 美联储可以通过外国央行把美元流动性输送到其辖区内的金融体系.

定义 7.103.

央行美元流动性互换 (central bank U.S. dollar liquidity swap) 是指美联储和外国央行之间的货币互换安排. 美联储向外国央行提供美元, 外国央行提供等值本币并约定未来反向交换; 外国央行再决定怎样把美元贷给本辖区机构.

美联储的直接交易对手是外国央行, 境外商业银行不直接参与这笔交易. 外国央行负责向本辖区机构转贷美元, 并承担这些机构的信用风险; 美联储则通过央行之间的合约安排降低外汇风险和私人机构信用风险 [Boa20b; Boab].

所以美联储虽然首先是美国的中央银行, 但由于美元本身具有全球融资货币地位, 美元流动性问题从来都不只是一件美国国内银行业的问题.

法币储备型稳定币与链上美元 近年来, 美元体系还出现了一个新的延伸: 美元稳定币. 这里不打算完整讨论所有稳定币机制, 只看最容易和传统美元短端市场连接起来的**法币储备型稳定币**.

定义 7.104.

法币储备型美元稳定币 (fiat-backed USD stablecoin) 是指由私人主体发行, 以美元作为计价基准, 并通过储备资产和赎回机制试图让每单位代币维持接近 \$1 价值的链上数字资产.

一枚稳定币与一单位美联储准备金或普通商业银行存款属于不同的请求权. 它的结构是: 发行人在传统金融体系中持有一篮子美元资产, 同时在区块链上发行相应的美元计价请求权. 这些储备资产可能包括银行存款, 短期美债, 美债担保逆回购等高流动性短期美元资产.

所谓“链上美元”仍然与传统美元市场相连. 它背后的资产负债表最终仍然可能回到

银行存款, 短期美债, 回购协议.

这也再次说明: 美元计价只说明记账单位; 美联储货币的身份则由发行主体和法律请求权决定. 如果储备资产, 赎回机制, 市场流动性或者投资者信任出现问题, 稳定币价格就可能偏离 \$1, 也就是所谓的脱锚 (depeg).

7.6.5 从美元资金市场到短期利率模型

到了这里, 我们终于可以重新回到本节开头的问题:

现实中这么复杂的美元资金体系, 为什么到了金融数学里面经常只剩下一个 r_t ?

前面已经见到了很多不同的利率. FOMC 的目标区间是政策目标; IORB 和 ON RRP offering rate 是美联储主动设置的政策工具; EFFR 是从联邦基金市场实际成交中统计出来的无抵押隔夜参考利率; SOFR 是从美债 repo 市场实际成交中得到的有抵押隔夜参考利率; 而 T-bill, 银行融资, repo, 离岸美元和外汇掉期又各有自己的资金价格.

所以现实里面存在一整套

美元资金曲线族,

其中每条曲线对应特定市场和资金条件.

一种更贴近现实的写法, 是把第 k 类观测利率表示为

$$y_t^{(k)} = m_t + \beta_k^\top X_t + s_{t,\text{credit}}^{(k)} + s_{t,\text{liquidity}}^{(k)} + \varepsilon_t^{(k)}.$$

这里 m_t 可以理解为政策锚, 而状态向量 X_t 可能包括

$$X_t = (R_t, G_t, Q_t, \chi_t^{\text{collateral}}, b_t^{\text{FX}}, \dots),$$

其中 R_t 表示准备金条件, G_t 表示 TGA, Q_t 表示 ON RRP 使用量, $\chi_t^{\text{collateral}}$ 表示抵押品稀缺程度, b_t^{FX} 表示离岸美元 basis.

但为了研究最基本的跨时间贴现和无套利关系, 金融数学通常会先做一次非常强的抽象: 假设存在一个瞬时短期利率过程

$$(r_t)_{t \geq 0},$$

并进一步定义一个按照这个短期利率连续滚动的货币市场账户 (money-market account)

$$B_t = \exp\left(\int_0^t r_s ds\right).$$

因此它满足

$$dB_t = r_t B_t dt.$$

直觉上, B_t 表示这样一个理想化账户: 每一个瞬间都能够按照当时的短期无风险利率把资金继续滚动下去. 如果 $r_t = r$ 为常数, 那么自然得到 $B_t = e^{rt}$.

这个 r_t 无法由某一个现实市场报价直接换个符号得到. EFFR 和 SOFR 都是有限期限交易经过统计以后得到的参考利率; r_t 则是金融模型中为了描述瞬时贴现而引入的状态变量. 二者在定义上不同, 但实证或者建模时可以把某个隔夜利率作为代理变量, 校准目标或者观测方程.

更加复杂的利率模型则会重新把现实差异加回来. 比如现代利率市场会区分用于贴现的曲线, 用于预测浮动现金流的曲线, 交易机构自身的融资成本, 抵押品报酬利率, 以及跨币种 basis 和抵押品稀缺性等价差.

因此所谓“无风险利率”从现实市场走到数学模型的过程中, 本身就已经经历了一次很强的建模压缩. 把整个美元资金体系写成一个 r_t , 是为研究跨时间贴现和无套利定价而主动保留的模型状态, 不代表现实世界里存在唯一的无风险利率.

到了这里, 从债券市场开始逐渐出现的

$$P(t, T), \quad r_t, \quad B_t$$

也终于连接到了一起. 其中 $P(t, T)$ 描述时刻 T 的一单位货币在时刻 t 的价格; r_t 描述模型中最短端的瞬时资金价格; B_t 描述资金按照这些短期利率不断滚动以后形成的价值过程.

后续进入贴现与无套利时, 我们将回答:

既然不同时间的资金已经可以通过这些对象进行比较, 那么两个具有相同未来现金流的交易策略, 今天为什么应该具有相同的价格?

7.7 贴现与无套利

第7.1节, 第7.2节, 第7.3节, 第7.4节, 第7.5节和第7.6节已经分别给出股票价格, 衍生品现金流, 预测市场事件合约, 指数和 ETF, 以及零息债券价格 $P(t, T)$, 短期利率 r_t 和货币市场账户 B_t . 这些对象看起来分散, 进入金融数学后却会被放进同一套语言: 不同时间和不同状态的现金流应该怎样定价?

这个问题本身已经选择了一个很强的建模截面：资产单位和权利已经明确，状态结果能够写成可比较的现金流，交易，融资，交付和结算规则也能够被纳入同一市场模型。在这些条件大致成立时，贴现与无套利是非常强的定价工具；条件缺失时，应先回到具体头寸和交易路径。贴现率只能比较已经定义清楚的权利和结算现金流。

贴现回答的是时间问题。今天的一单位货币和一年以后确定收到的一单位货币，需要先经过一条跨时间比较规则换算后才能相加。

无套利回答的是一致性问题。如果两套交易方式在未来每一种可能状态下都给出相同现金流，一价定律要求它们今天具有相同价格。否则投资者就可以买便宜的一边，卖贵的一边，把差价锁住。

这里主要参考无套利定价和资产定价理论中的标准处理 [Coc05; DS94; Duf01; HK79; HP81; Hul22; Shr04a; Shr04b]。这里先准备后文反复使用的直觉和符号；一般形式的基本定理可见上述文献。

7.7.1 贴现和计价资产

先从最简单的确定现金流开始。

如果时刻 t 市场中一只无违约零息债券的价格为 $P(t, T)$ ，并且它在时刻 T 确定支付一单位计价货币，那么 $P(t, T)$ 就是把时刻 T 的确定一单位现金流折回时刻 t 的价格。如果 T 时刻确定支付 x 单位货币，那么在这条贴现曲线下，它在时刻 t 的价值就是

$$xP(t, T).$$

当利率为确定常数 r 且采用连续复利时，这个贴现因子退化为

$$P(t, T) = e^{-r(T-t)}.$$

于是未来的 x 单位货币今天值

$$xe^{-r(T-t)}.$$

这正是债券那一节已经出现过的时间价值。但从现在开始，我们更关心的是另一个视角：贴现不仅是把未来金额折算成现在金额，也是在选择一个用来度量其他资产价格的基准。

定义 7.105 (计价资产).

给定一个严格为正的资产价格过程 $(N_t)_{t \geq 0}$ 。如果我们用 N_t 作为计价单位，那么资产 S_t 的贴现价格或相对价格定义为

$$\hat{S}_t = \frac{S_t}{N_t}.$$

这里 N 称为一个**计价资产** (numéraire)。

最常见的计价资产是货币市场账户。如果模型中存在短期利率过程 r_t ，并且

$$B_t = \exp\left(\int_0^t r_s ds\right),$$

那么 B_t 可以理解成资金不断按照短端利率滚动以后形成的账户价值。用 B_t 计价时，资产价格变成

$$\tilde{S}_t = \frac{S_t}{B_t}.$$

这一步看似只是换单位，但它会在后面变得非常重要。很多无套利定价命题关注经过合适计价资产归一化后的价格过程，并要求它具有某种鞅性质；它们通常不直接规定原始价格 S_t 应该怎样变化。

注 7.106 (贴现曲线的选择).

现实市场中，“用哪条曲线贴现”本身就是一个市场和制度问题。美债曲线，OIS 曲线，抵押品报酬利率，机构自身融资成本和跨币种 basis 都可能对应不同问题下的现金流比较方式。

所以数学模型里的 B_t 或 $P(t, T)$ 应该理解成经过抽象的定价基准；现实中适用的曲线由

具体市场制度和现金流条件共同决定。

7.7.2 套利和无套利

现在给出套利的准确定义。

考虑一个从时刻 0 交易到时刻 T 的市场。一组交易策略 ϕ 会产生价值过程 V_t^ϕ 。这里以及后文所说的策略都必须是可允许且自融资的：初始交易完成以后，资产买卖，中间现金流和融资账户彼此供给资金，在 $(0, T]$ 内不再依靠策略外部的注资或提款改变财富。

定义 7.107 (套利和无套利)。

一组可允许且自融资的交易策略 ϕ 称为**套利** (arbitrage)，如果

$$V_0^\phi = 0, \quad V_T^\phi \geq 0 \quad \text{a.s.}, \quad \mathbb{P}(V_T^\phi > 0) > 0.$$

它从零初始净财富出发，终端在几乎所有状态下都不会亏钱，并且在正概率状态下严格赚钱。

如果市场中不存在这样的可允许交易策略，就说这个市场满足**无套利** (no-arbitrage)。

有时也会直接把某项机会写成初始成本 $c_0 \leq 0$ ，终端支付 $X_T \geq 0$ 。这时严格获利条件必须是 $c_0 < 0$ 或 $\mathbb{P}(X_T > 0) > 0$ 至少有一项成立；该定义同时覆盖“初始时刻已经收到钱，终端恰好为零”的情形。如果市场允许把初始收入保留在相应融资账户中，这类表述可以重新组织成上面的零初始净财富，自融资形式。

投资者承担风险后可能赚钱，这不构成套利。套利排除的是下列组合：

不花钱 + 不承担下行风险 + 还有机会赚钱。

它可以通俗地理解为一张不亏钱的免费彩票。

在更严肃的连续时间模型中，还需要进一步刻画所谓“可允许策略”。否则可以写出一些靠无限杠杆，无限翻倍或者财富过程无限向下穿透的病态策略。无套利总是相对于给定市场，给定资产，以及给定允许交易规则而言。

7.7.3 一价定律

无套利最直接的后果是一价定律。

命题 7.108 (一价定律)。

假设市场满足无套利，组合 A 和 B 都能按照所写价格交易，并允许买入便宜组合，卖出或卖空昂贵组合，以及为初始差额进行相应融资。进一步假设二者的单位，币种，交付，税费和结算条件可比，中间现金流已经完整计入，且在时刻 T 的终端现金流几乎处处相同，即

$$V_T^A = V_T^B \quad \text{a.s.},$$

那么它们在时刻 0 的价格必须相同：

$$V_0^A = V_0^B.$$

证明。假设 $V_0^A < V_0^B$ 。那么可以在时刻 0 买入便宜的组合 A ，同时卖空昂贵的组合 B 。初始时刻获得正现金流 $V_0^B - V_0^A > 0$ 。把这笔现金流投入货币市场账户，到时刻 T ，两个组合的现金流完全抵消：

$$V_T^A - V_T^B = 0.$$

但货币市场账户已经把初始差额变成严格为正的终端财富。因而这给出一组初始净投入为零，终端财富严格为正的套利。这与无套利矛盾。反向不等式同理。□

一价定律看起来朴素，但它是金融数学里面非常强的约束。衍生品定价的很多公式依赖复制，即寻找另一组已经可以交易的资产，使它们在未来产生同样现金流。一旦找到了这种复制关系，价格就被无套利锁定。

这里每一项假设都承担实际工作. 如果一边无法卖空, 融资会被中途收回, 资产交付条件存在差异, 或者结算带有明显的时间和信用风险, 同一论证通常只能给出含摩擦的套利区间. 唯一价格需要更强的双向可实施条件.

7.7.4 复制定价

设某个衍生品在时刻 T 的到期支付为 X_T . 如果存在一组可允许且自融资的交易策略 θ , 它从时刻 0 开始的成本为 v , 并且终端财富满足

$$V_T^\theta = X_T \quad \text{a.s.},$$

那么 θ 就复制了这个衍生品.

定义 7.109 (复制).

如果一组由市场中可交易资产构成的可允许, 自融资策略能够在到期时产生和某个目标现金流完全相同的支付, 就说这组策略**复制** (replicate) 了这个现金流.

无套利立刻给出: 被复制的现金流价格必须等于复制组合的成本. 否则买便宜的, 卖贵的, 就会回到一价定律的套利构造.

命题 7.110 (复制价格).

假设市场满足无套利, 目标合约和复制策略都能按照所写价格与数量买入和卖出, 复制策略可允许且自融资, 所需融资也能够实际实施. 进一步假设两边的单位, 币种, 中间现金流, 交付, 抵押与信用条件, 税费和结算安排相同, 或者这些差异的全部成本已经计入复制成本 v . 如果该策略的终端财富满足

$$V_T^\theta = X_T \quad \text{a.s.},$$

那么具有同一到期支付 X_T 的目标合约在时刻 0 的唯一无套利价格为 v .

如果目标合约或复制腿只能单向交易, 卖空, 融资或交付受到约束, 或者仍有未计入的摩擦, 同一个比较通常只能给出单边价格约束或无套利区间, 唯一价格还需要上述双向可实施条件. 下面的远期价格与精确平价关系都默认继承上述双向可实施条件.

远期价格就是最简单的例子. 假设资产当前价格为 S_0 , 持有期间不支付股息, 并且市场中存在到期日为 T 的零息债券 $P(0, T)$. 如果今天借入 S_0 买入一单位现货, 那么到期时需要偿还的金额为

$$\frac{S_0}{P(0, T)}.$$

因此使远期合约初始价值为零的交割价格应该满足

$$F_{0,T} = \frac{S_0}{P(0, T)}.$$

当 $P(0, T) = e^{-rT}$ 时, 这就变成前面见过的

$$F_{0,T} = S_0 e^{rT}.$$

这个推导只使用了现货, 融资和远期之间的复制关系.

欧式看涨和看跌期权之间也有类似关系. 在无股息的简单模型中, 同一标的, 同一执行价格 K , 同一到期日 T 的欧式看涨期权和看跌期权满足

$$c_0 - p_0 = S_0 - KP(0, T),$$

其中 c_0 和 p_0 分别是看涨和看跌期权价格. 这是看涨看跌平价. 它来自两个到期现金流完全相同的组合: 一边是看涨期权加上 K 单位到期现金, 另一边是看跌期权加上一单位股票.

所以复制定价的精神可以概括为:

$$\text{相同未来现金流} \implies \text{相同当前价格}.$$

7.7.5 状态价格和风险中性概率

复制定价还可以换一种角度理解. 考虑一个一时期有限状态模型. 从时刻 0 到时刻 T , 世界最终会落入有限多个状态

$$\omega_1, \dots, \omega_n.$$

一个到期现金流可以写成向量

$$X_T = (X_1, \dots, X_n),$$

其中 X_i 表示状态 ω_i 发生时的支付.

如果市场中存在一组价格

$$\pi_1, \dots, \pi_n,$$

使得任意可定价现金流 X_T 的价格都可以写成

$$V_0 = \sum_{i=1}^n \pi_i X_i,$$

那么 π_i 就称为状态 ω_i 的状态价格.

定义 7.111 (状态价格).

状态价格 (state price) 是指一份在某个特定未来状态支付一单位货币, 而在其他状态支付零的基本证券在今天的价格.

状态价格不是现实概率. 它已经同时包含了概率, 贴现和风险补偿. 如果所有状态价格都为正, 并且一单位确定到期现金流的价格为

$$P(0, T) = \sum_{i=1}^n \pi_i,$$

那么可以把状态价格归一化为

$$q_i = \frac{\pi_i}{P(0, T)}.$$

于是

$$q_i > 0, \quad \sum_{i=1}^n q_i = 1.$$

这组 q_i 在形式上就是一个概率分布. 它定义了以到期日为 T 的零息债券 $P(t, T)$ 作为计价资产的定价测度, 记作 $\mathbb{Q}^T$; 这个测度也称为 T -forward 测度. 在它之下, 价格公式变成

$$V_0 = P(0, T) \sum_{i=1}^n q_i X_i = P(0, T) \mathbb{E}^{\mathbb{Q}^T}[X_T].$$

定义 7.112 (风险中性定价测度).

由状态价格经过贴现归一化以后得到的概率测度属于**风险中性定价测度**. 具体测度取决于所选计价资产; 上面的 $\mathbb{Q}^T$ 是以 $P(t, T)$ 为计价资产的 T -forward 测度. 在这个测度下, 用相应计价资产归一化后的可交易资产价格具有“平均不变”的定价形式.

这里最容易误解的一点是:

$$\mathbb{Q}^T \neq \mathbb{P}.$$

现实概率测度 $\mathbb{P}$ 描述我们认为现实世界怎样随机变化; 定价测度 $\mathbb{Q}^T$ 描述市场价格在无套利约束下, 相对于 T 到期零息债券怎样给未来状态现金流定价.

如果一只股票在现实世界里有风险溢价, 那么通常

$$\mathbb{E}^{\mathbb{P}}[S_T]$$

会高于简单滚动无风险资产得到的未来金额. 但在风险中性测度下, 无股息可交易资产的价格满足

$$S_0 = P(0, T) \mathbb{E}^{\mathbb{Q}^T} [S_T].$$

这个公式将风险溢价吸收到从 $\mathbb{P}$ 到 $\mathbb{Q}^T$ 的测度变换中, 同时允许股票在 $\mathbb{P}$ 下具有风险溢价.

风险中性定价在无套利市场中, 把风险补偿和贴现折进一个方便计算的概率测度里; 世界中的风险依然存在, 只是风险补偿已经收入测度变换.

7.7.6 随机贴现因子

还有一种更一般的写法, 是不急着把风险调整改写成新的概率测度. 给定现实概率测度 $\mathbb{P}$, 可以寻找一个随机变量 $M_{0,T}$, 使任意可定价的到期现金流 X_T 满足

$$V_0 = \mathbb{E}^{\mathbb{P}} [M_{0,T} X_T].$$

这里的 $M_{0,T}$ 称为随机贴现因子, 定价核或者 state-price density.

定义 7.113 (随机贴现因子).

随机贴现因子 (stochastic discount factor) 是一个严格为正且可积的随机变量, 它作为随机权重把未来随机现金流转换成当前价格. 它同时包含跨时间贴现和跨状态风险调整.

如果只考虑确定现金流, 例如 $X_T = x$, 那么

$$V_0 = x \mathbb{E}^{\mathbb{P}} [M_{0,T}] = x P(0, T).$$

进入价格的期望权重 $\mathbb{E}^{\mathbb{P}} [M_{0,T}]$ 在这里退化为普通贴现因子. 随机变量 $M_{0,T}$ 仍保留对不同状态赋予不同权重的信息. 但对于随机现金流, 它还会在不同状态上给出不同权重. 那些投资者更不愿意承受的状态, 通常会具有更高的边际价值, 相应状态中的现金流也会更贵.

用条件期望写, 从时刻 t 到时刻 T 的一般定价关系可以表示成

$$V_t = \mathbb{E}_t^{\mathbb{P}} [M_{t,T} X_T].$$

如果选用货币市场账户 B_t 作为计价资产, 并且存在与这个计价资产对应的风险中性定价测度 $\mathbb{Q}^B$, 同一关系也常写作

$$\frac{V_t}{B_t} = \mathbb{E}_t^{\mathbb{Q}^B} \left[\frac{X_T}{B_T} \right].$$

一般随机利率模型中, $\mathbb{Q}^T$ 与 $\mathbb{Q}^B$ 对应两个不同测度: 前者对应零息债券 $P(t, T)$, 后者对应货币市场账户 B_t . 只有当利率或两个计价资产的相对价格具有足够的确定性等特殊条件成立时, 二者才可能被识别; 测度上标在计价资产已固定且语境清楚时才可省略.

这正是后面风险中性定价会反复使用的形式. 它也解释了为什么预测市场那一节要小心区分事件概率和事件合约价格. 如果事件 A 的到期支付是 $\mathbf{1}_A$, 那么它今天的价格更一般地应该写成

$$C_0^A = \mathbb{E}^{\mathbb{P}} [M_{0,T} \mathbf{1}_A],$$

这是经 $M_{0,T}$ 加权的事件概率. 只有在贴现, 风险溢价, 流动性和合约摩擦都已经被处理以后, 我们才可能从价格中读出某种市场隐含概率.

7.7.7 带摩擦的套利边界与套利限制

到目前为止, 我们写下的公式都像是精确等式. 但真实市场里, 这些等式通常会变成区间.

以远期和现货为例. 在无交易成本, 无 bid-ask, 无保证金约束, 可以自由融资和卖空的模型中, 无套利给出

$$F_{0,T} = \frac{S_0}{P(0, T)}.$$

如果先加入可以事前写进交易策略的摩擦, 例如确定的买卖价差, 手续费, 借贷利差, 做空成本和税收, 精确等式通常会放宽为形式化的无套利边界:

$$F_{0,T}^{\text{lower}} \leq F_{0,T} \leq F_{0,T}^{\text{upper}}.$$

只要价格仍然落在这个区间里, 它可能已经偏离了最干净的理论中点, 但不一定存在可执行套利. 只有当偏离大到足以覆盖这些可执行成本时, 才可能在相应模型中构造套利.

保证金追加, 基差继续扩大, 融资突然收紧, 流动性枯竭, 强制平仓和平台风险则属于另一个层次. 这些因素直接限制交易者建立头寸并持有到理论关系收敛的能力. 这类问题通常称为**套利限制** (limits to arbitrage) [SV97].

原则 7.114 (套利边界和套利限制).

理论无套利关系常常给出无摩擦基准下的价格等式. 可事前计入并能够锁定的交易摩擦可能把等式放宽成无套利边界; 融资约束, 保证金, 流动性和路径风险则可能阻止交易者把价格拉回这组边界附近. 两者相关, 各自作用的层次有别.

这套区分可以解释为什么做市商大量卖出期货, 或者某一侧订单流突然变得很重时, 期货价格可以相对现货出现偏移. 这种偏移可能来自某些参与者的库存约束, 风险限额, 对冲需求或者融资成本暂时改变了价格所在的位置.

如果期货相对现货显著偏贵, 典型 cash-and-carry 方向是买入现货并卖出期货; 如果期货显著偏便宜, 反向交易则需要卖空现货并买入期货. 但这些交易都需要资产借贷, 融资, 保证金, 交易容量和持有到收敛的能力. 一旦中间基差继续向不利方向扩大, 交易者可能在最终收敛以前就被追加保证金或者风控线迫使出局.

PERP 更能说明这一点. 永续合约省去了到期交割环节, 通常依赖资金费率把合约价格和参考指数之间的偏离转化为多空双方之间的定期现金流. 当 PERP 明显高于现货指数时, 多头往往需要向空头支付 funding, 从而吸引

$$\text{long spot} + \text{short perp}$$

这类交易. 当 PERP 明显低于现货指数时, 方向则反过来.

这类交易仍然承担风险. 资金费率会变化, 基差可能继续扩大, 保证金可能被耗尽, 参考指数可能有构造问题, 交易所也可能出现风控, 强平和流动性问题. 因此 PERP 里的所谓套利, 通常应归入带有路径风险和平台风险的相对价值交易.

注 7.115 (做市商的流动性业务与套利).

做市商通过买卖报价向市场出售即时流动性, 价差和返佣可能形成毛收入; 对冲和库存管理则用于控制库存风险, 逆向选择风险和价格风险, 同时往往会产生新的交易与融资成本.

当跨市场价格出现明显偏离时, 做市商当然可能参与套利或者相对价值交易. 套利和相对价值交易只是它们活动的一部分; 做市业务仍然承担上述各类风险.

ETF 创建赎回和国债基差交易也是同一个道理. ETF 市场价格和底层篮子价值之间存在套利力量, 但 AP 需要承担交易成本, 底层资产流动性, 创建赎回流程和融资成本. 国债现券和期货之间有交割机制和基差收敛逻辑, 但高杠杆交易者可能在 repo 展期, haircut 上调, 期货保证金追加和强制去杠杆的中间路径中被迫退出.

因此, 无套利不要求市场价格永远贴着某条理论公式不动. 它所检查的是:

给定交易规则, 融资条件, 摩擦和风险约束,
是否存在一组不花钱, 不会亏, 且有机会赚钱的可执行策略?

如果答案是否定的, 市场就仍然可以被视为满足相应意义下的无套利. 即使价格表面上已经偏离了某个理想模型中的中点.

7.7.8 通往鞅和金融市场基本定理

最后把这一节和前面的随机过程, 随机分析及金融接口连接起来.

在离散时间或者连续时间模型中, 资产价格本身会随时间变化. 交易者可以动态调整头寸. 于是无套利的约束从两个终端现金流扩展到整个价格过程.

非常粗略地说, 金融市场基本定理告诉我们: 在合适技术条件下, 无套利和某种等价鞅测度的存在密切相关. 如果用货币市场账户 B_t 作为计价资产, 并用 D_t 表示资产截至时刻 t 已经支付的累计

现金流, 那么在对应的风险中性定价测度 $\mathbb{Q}^B$ 下, 贴现累计收益过程

$$\frac{S_t}{B_t} + \int_{(0,t]} \frac{1}{B_u} dD_u$$

在合适技术条件下是局部鞅. 当它进一步满足可积性并成为真鞅时, 才可以写成条件期望等式. 特别地, 对于期间没有现金流的资产, 这时有

$$\frac{S_t}{B_t} = \mathbb{E}_t^{\mathbb{Q}^B} \left[\frac{S_T}{B_T} \right].$$

注 7.116 (完备市场和不完备市场).

无套利排除免费午餐. 未来现金流的唯一价格还需要可复制性等更强条件.

如果每个相关现金流都可以由可交易资产复制, 市场称为完备, 定价测度通常唯一. 如果市场不完备, 可能存在多个与无套利相容的定价测度, 某些现金流只能得到无套利价格区间.

随机过程由此进入金融市场. 如果只讨论确定现金流, 贴现曲线已经足够. 但一旦现金流取决于未来状态, 取决于路径, 或者取决于交易者能否连续调整头寸, 我们就需要描述资产价格, 利率, 波动率, 订单流和流动性怎样随时间随机演化.

后面的金融市场应用部分中, 风险中性定价, Black-Scholes 模型, 利率模型和波动率模型都会不断回到这里:

贴现 + 无套利 + 随机过程 $\rightarrow$ 动态定价模型.

7.8 交易, 订单簿与市场微观结构

第7.7节讨论贴现和无套利时, 我们把资产价格写成一个统一的过程 S_t , 并关心不同资产和现金流之间应该满足怎样的价格关系. 这种抽象对于定价非常有用, 但它暂时省略了一个更加贴近交易现场的问题:

一笔订单进入市场以后, 究竟怎样变成报价, 成交和价格变化?

从“这项资产在模型中值多少”到“这笔订单最后按照什么价格成交”之间, 还隔着交易场所, 订单类型, 排队顺序, 买卖价差, 订单簿深度, 通信延迟, 其他参与者的行动以及市场本身的制度安排.

市场微观结构研究的正是这一层问题 [FPR23; Har02; Has07; Mad00; OHa95].

定义 7.117 (市场微观结构).

市场微观结构 (market microstructure) 研究市场参与者的潜在买卖意愿怎样在给定交易制度下转化为订单, 报价, 成交量和市场价格, 以及交易规则, 信息差异, 库存约束和流动性怎样影响这一过程.

在“资产, 价格与收益”一节中, 我们已经区分了最优买价 b_t , 最优卖价 a_t , 中间价 $m_t = (a_t + b_t)/2$ 和最近成交价. 这里沿着一张订单实际经过的路径, 把报价和成交放回真实交易制度中; 股票价格为什么包含市场预期已在前文讨论.

原则 7.118 (成交价的含义).

一笔成交的价格, 是买方和卖方在某个时刻, 某个场所和某套交易规则下实际完成交换的价格.

它可能包含关于资产未来价值的信息, 但也会受到交易紧迫性, 订单规模, 当前库存, 融资约束和订单簿状态影响. 因此

成交价格 $\neq$ 被直接测量出来的唯一真实价值.

一笔成交只说明双方的订单在当时的市场规则下形成了可执行匹配. 双方的价值判断仍可能存在差异.

7.8.1 从一张订单进入市场开始

在一个典型的电子证券市场中, 一张订单可能经历下面这条路径:

投资者或交易策略 → 经纪商与交易前检查
 → 订单路由 → 交易场所 → 撮合引擎
 → 成交, 留簿, 撤销或者拒绝.

这只是一条示意路径. 有些机构可以直接接入交易场所, 有些订单会由经纪商内部执行, 还有些订单会被发送到不公开展示完整订单簿的场所. 但无论具体路径怎样, 都需要先区分

作出投资决策 $\neq$ 提交订单 $\neq$ 订单已经成交.

订单首先只是一项交易指令. 它只有在通过相应检查, 到达一个可以执行交易的场所, 并且遇到满足条件的对手方以后, 才可能产生实际成交.

交易场所与参与者

定义 7.119 (交易场所).

交易场所 (trading venue) 是按照一组既定规则接收和执行交易指令的市场组织或者交易系统.

交易所的公开限价订单簿, 另类交易系统, 暗池, 以及由交易商或者经纪商提供的内部执行系统, 都可能构成不同形式的交易场所.

同一项证券可能同时在多个场所交易. 单一场所的最优报价可能与投资者通过多个场所观察到的整体最优报价不同. 不同场所还可能具有不同的费用, 速度, 优先规则, 隐藏流动性和参与者结构.

参与交易的人也不只有最终投资者. 经纪商负责接收和路由客户订单; 做市商和其他流动性提供者提交可以被别人执行的报价; 套利者或者相对价值交易者连接不同资产和不同场所之间的价格; 交易场所则按照自己的规则组织订单和成交.

这些角色可以随交易者当时的行为而转换. 普通投资者提交一张等待成交的限价单时, 也可能暂时成为流动性提供者; 做市商有时同样会主动执行别人留下的报价; 套利者也可能承担库存, 基差, 融资和执行风险.

订单包含什么 固定一项资产以后, 可以把一张经过简化的订单写成

$$o = (s, q, \ell, \tau, \kappa),$$

其中 s 表示买入或者卖出方向, $q > 0$ 表示数量, ℓ 表示价格限制, τ 表示订单被交易场所接受的时间, 而 κ 汇总有效期, 展示方式和其他执行条件. 现实订单还可能包含路由, 是否允许部分成交, 是否只在特定时段生效等更多字段.

定义 7.120 (订单).

订单 (order) 是市场参与者按照给定方向, 数量和执行条件, 请求买入或者卖出某项资产的指令.

一张订单可以被拒绝, 立即成交, 部分成交, 或者以未成交余额进入订单簿等待.

实际系统通常还会检查交易权限, 可用资金, 持仓和风险限额, 价格保护区间以及市场当前是否开放. 所以即使交易者已经按下“买入”或者“卖出”, 订单也不一定已经到达公开市场, 更不一定会按照屏幕上最后看到的价格成交.

7.8.2 市场单, 限价单与订单簿

定义 7.121 (市场单, 限价单与撤单).

市场单 (market order) 以尽快成交为主要目标, 接受按照当时可用的对手方报价逐级执行. 它提高了成交的即时性, 执行价格则由当时可用的订单簿深度决定.

限价单 (limit order) 指定交易者能够接受的最差价格. 买入限价单不会按照高于限价的价格成交; 卖出限价单不会按照低于限价的价格成交.

撤单 (cancellation) 是在订单尚未完全成交以前, 请求删除其剩余数量的指令. 撤单只作用于剩余未成交数量; 已成交部分已经进入清算和结算流程.

如果当前最优卖价为 a_t , 那么限价为 ℓ 的买单在 $\ell \geq a_t$ 时已经可以立即和卖盘成交. 类似地, 限价卖单在 $\ell \leq b_t$ 时已经可以立即和买盘成交. 这种订单通常称为**可成交限价单** (marketable limit order).

因此, 订单的主动与被动由它进入市场时的价格和订单簿状态决定. 一张价格足够积极的限价单也可以立即穿过价差; 一张原本留在订单簿中的限价单, 则可能在后来被新的对手方订单击中.

市场单主要承担**价格不确定性**: 它通常能够较快成交, 却可能逐级扫过多个价位. 限价单主要承担**成交不确定性**: 它限制了最差价格, 却可能只得到部分成交或者完全不成交.

撤单本身也需要传输和处理时间. 如果成交先于撤单生效, 相应成交仍然成立. 在很多市场中, 修改价格或者增加数量还会被视为撤销旧订单并提交新订单, 从而失去原来的时间优先位置.

订单簿作为市场状态

定义 7.122 (限价订单簿与深度).

限价订单簿 (limit order book) 是交易场所按照买卖方向, 限价和优先顺序组织尚未成交限价单的记录.

某个价位上尚未成交的订单数量称为这个价位的**订单簿深度** (depth).

令 $\mathcal{O}_t$ 表示时刻 t 仍然留在订单簿中的订单集合. 可以定义

$$Q_t^b(p) = \sum_{\substack{o \in \mathcal{O}_t \\ s(o)=\text{buy} \\ \ell(o)=p}} q_t^{\text{rem}}(o), \quad Q_t^a(p) = \sum_{\substack{o \in \mathcal{O}_t \\ s(o)=\text{sell} \\ \ell(o)=p}} q_t^{\text{rem}}(o),$$

其中 $q_t^{\text{rem}}(o)$ 是订单 o 的剩余数量. $Q_t^b(p)$ 和 $Q_t^a(p)$ 分别表示价位 p 上的买方深度和卖方深度. 于是前面已经出现的最优报价可以写成

$$b_t = \max\{p : Q_t^b(p) > 0\}, \quad a_t = \min\{p : Q_t^a(p) > 0\}.$$

上述 bid 和 ask 在订单簿中对应: b_t 是最高的非空买入价位, a_t 是最低的非空卖出价位. 如果把买方报价从高到低排列, 卖方报价从低到高排列, 还可以写成

$$p_{1,t}^b > p_{2,t}^b > \cdots, \quad p_{1,t}^a < p_{2,t}^a < \cdots,$$

其中 $p_{1,t}^b = b_t$, $p_{1,t}^a = a_t$. 令 $Q_{k,t}^b$ 和 $Q_{k,t}^a$ 分别表示相应价格档位当前显示的买入和卖出数量, 那么订单簿状态可以粗略写成

$$\mathcal{L}_t = \left((p_{k,t}^b, Q_{k,t}^b)_{k \geq 1}, (p_{k,t}^a, Q_{k,t}^a)_{k \geq 1} \right).$$

注 7.123 (订单簿与可观察供需).

屏幕上显示的订单簿只是一张当前快照. 订单可以被撤销或者修改, 市场还可能存在隐藏订单, 冰山订单, 多个交易场所以及公开订单簿之外的流动性.

因此显示深度只是当前快照, 不构成稳定不动的市场供给或需求曲线. 当价格开始变化时, 原本显示的订单可能消失, 新的订单也可能迅速出现.

撮合优先规则

原则 7.124 (价格优先与时间优先).

在采用价格优先和时间优先的连续限价订单簿中, 更有利于对手方的价格先执行. 对于买单, 更高的买入限价优先; 对于卖单, 更低的卖出限价优先. 当多张订单具有相同限价时, 较早被交易场所接受的订单先执行.

价格优先意味着后来到达的卖价 100.01 会排在较早到达的卖价 100.02 前面. 只有当价格相同时, 时间顺序才决定谁先成交.

价格和时间优先只是可选的撮合规则之一. 某些衍生品市场会按照数量比例分配成交, 开盘和收盘集合竞价也使用不同的撮合过程. 隐藏订单和特殊订单类型还可能具有自己的优先级 [Gou+13].

7.8.3 一次撮合与交易成本

一张主动买单进入以后, 撮合引擎会从最低卖价开始消耗卖方订单; 一张主动卖单则从最高买价开始消耗买方订单. 订单数量较大时, 一次订单可以产生多笔不同价格的成交.

定义 7.125 (成交均价与滑点).

假设一张数量为 Q 的订单产生价格和数量分别为 (p_k, q_k) 的 n 笔成交, 其中 $\sum_{k=1}^n q_k = Q$. 这张订单的成交均价定义为

$$\bar{p}(Q) = \frac{\sum_{k=1}^n p_k q_k}{Q}.$$

给定订单提交以前选定的基准价格 p^* , 可以按照“正数表示执行更差”的方向定义滑点:

$$\text{Slip}_{\text{buy}} = \bar{p}(Q) - p^*, \quad \text{Slip}_{\text{sell}} = p^* - \bar{p}(Q).$$

滑点的含义取决于基准价格的选择. 如果 p^* 选择订单到达前的最优对手价, 它主要衡量订单扫过多个价位造成的额外成本; 如果选择到达时的中间价, 其中还包含跨越半个买卖价差的成本; 如果选择更早的决策价格, 等待和路由期间的市场变化也会进入结果.

例 7.126 (一张市场买单怎样扫过订单簿).

为了单独看清撮合机制, 以下忽略隐藏流动性, 其他交易场所以及撮合期间到达或撤销的新订单, 并假设订单允许部分成交. 假设某只股票当前可见的部分订单簿为

方向	价格	显示数量
卖出	100.04	500
卖出	100.03	200
卖出	100.02	300
买入	100.01	400
买入	100.00	600
买入	99.99	800

此时

$$b_t = 100.01, \quad a_t = 100.02, \quad m_t = 100.015.$$

如果一张买入 550 股的市场单到达, 撮合顺序是

300 股 按照100.02 成交,
200 股 按照100.03 成交,
50 股 按照100.04 成交.

因而成交均价为

$$\bar{p}(550) = \frac{300 \times 100.02 + 200 \times 100.03 + 50 \times 100.04}{550} \approx 100.02545.$$

如果以订单到达前的最优卖价 100.02 为基准, 每股滑点约为 0.00545, 总额约为 3.00 单位计价货币.

撮合完成以后, 100.02 和 100.03 的卖单已经耗尽, 100.04 还剩 450 股, 因而新的最优卖价变成 100.04.

如果原订单是允许部分成交, 限价为 100.03 的 550 股买单, 它只能成交前 500 股. 剩余 50 股不会继续支付 100.04; 它是留在订单簿等待还是立即取消, 取决于订单的有效期和交易场所规则.

这个例子中最后一笔成交价从 100.02 走到 100.04, 首先说明的是一张主动买单耗尽了当前显示的卖方深度. 资产基本价值是否变化还需要其他证据. 新的卖单可能很快补回, 而这张买单也可能来自信息判断, 对冲, 指数调仓或者必须立即完成的资金需求.

成交方向与有符号订单流 每一笔成交都同时存在买方和卖方, 所谓“买方发起”或“卖方发起”描述哪一方主动跨过价差, 接受了订单簿中已经存在的报价. 每笔成交仍然同时有买方和卖方.

定义 7.127 (成交方向).

对第 i 笔成交, 令 $v_i > 0$ 表示成交数量, 并定义成交符号

$$\varepsilon_i = \begin{cases} +1, & \text{买方主动发起成交,} \\ -1, & \text{卖方主动发起成交.} \end{cases}$$

相应的有符号成交量为 $q_i = \varepsilon_i v_i$.

于是一个时间区间内的有符号成交订单流可以写成

$$Q_{t,t+\Delta}^{\text{trade}} = \sum_{i: t_i \in (t, t+\Delta]} \varepsilon_i v_i.$$

$Q_{t,t+\Delta}^{\text{trade}} > 0$ 表示这段时间内主动买入成交量较多, 而每笔成交本身仍同时包含一个买方和一个卖方.

有些交易数据会直接记录主动方, 有些数据则只能根据成交价相对于 bid, ask 和 mid 的位置进行推断. 成交发生在价差内部, 或者成交和报价的时间戳没有完全同步时, 这种推断可能出错 [LR91].

还需要区分三个相近但不同的概念: 成交不平衡只统计已经完成的主动买卖成交; 订单流不平衡还可以把限价订单的加入, 撤销和被成交考虑进去; 订单簿不平衡则描述某个时刻买卖两侧显示深度的差异.

例如最优报价上的队列不平衡可以写成

$$J_t = \frac{Q_{1,t}^b - Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a}.$$

$J_t > 0$ 只表示当前最优买价上的显示数量较多. 下一笔价格变化还受撤单, 更深档位和其他交易场所中流动性的影响; 这些信息都在 J_t 的统计范围之外.

报价价差, 有效价差与实现价差 最优报价给出的

$$QS_i = a_i - b_i$$

称为**报价价差** (quoted spread). 但成交不一定恰好发生在最优 bid 或 ask, 投资者的实际交易成本因而可能不同于报价价差.

令第 i 笔成交发生在时刻 t_i , p_i 表示成交价格, $m_{t_i^-}$ 表示成交前一刻的中间价, ε_i 表示成交方向. 定义

$$ES_i = 2\varepsilon_i(p_i - m_{t_i^-}),$$

称为有效价差 (effective spread). 系数 2 把一侧成交相对于 mid 的价格让步写成往返交易口径.

再选定一个日历时间长度 $h > 0$, 定义

$$RS_i(h) = 2\varepsilon_i(p_i - m_{t_i+h})$$

为实现价差 (realized spread), 同时定义成交后的有符号价格变化

$$PI_i(h) = 2\varepsilon_i(m_{t_i+h} - m_{t_i^-}).$$

于是存在恒等式

$$ES_i = RS_i(h) + PI_i(h).$$

这个分解把成交时相对于中间价支付的成本, 和随后同方向发生的报价变化分开了. 实现价差是观察窗口 h 下的成交成本分解项. 从它走到做市商实际利润, 还需要计入对冲, 手续费, 返佣, 库存, 融资和其他头寸产生的成本 [HS97].

7.8.4 流动性的多个维度

前面已经把流动性粗略解释成“能否在较短时间内完成足够数量的交易, 而不需要作出过大的价格让步”. 现在可以把这个概念拆得更细一些.

原则 7.128 (流动性的多个维度).

一个市场的流动性需要联合多项指标评估.
流动性至少涉及紧度, 深度, 即时性, 韧性和交易容量等不同维度.

紧度关心买卖报价之间有多近, 通常由报价价差或者有效价差描述.

深度关心当前价格附近能够吸收多少数量, 通常由订单簿各档数量或者价格冲击斜率描述.

即时性关心交易者需要等待多久, 或者需要作出多大价格让步才能立即完成交易.

韧性关心一笔大额订单或者一次冲击以后, 订单簿, 价差和市场深度能够多快恢复.

交易容量则关心订单规模不断增大时, 平均成交价格 and 总执行成本怎样恶化.

假设市场 A 的报价价差只有 0.01, 但最优报价上只有 100 股; 市场 B 的报价价差是 0.05, 但附近能够吸收 100,000 股. 对于一笔 50 股订单, 市场 A 可能更加流动; 对于一笔 50,000 股订单, 只看最优价差却可能得到完全错误的结论.

成交量和换手率只提供流动性的一个侧面. 很高的成交量可能来自市场双方稳定提供报价, 也可能来自恐慌期间的大量主动卖单不断扫过正在撤退的买盘. 后一种市场看起来非常活跃, 实际执行成本却可能正在快速上升.

还可以根据最优买卖两侧的数量构造微价格 (microprice)

$$\mu_t = \frac{a_t Q_{1,t}^b + b_t Q_{1,t}^a}{Q_{1,t}^b + Q_{1,t}^a}.$$

当买方队列更大时, μ_t 会更接近卖价; 当卖方队列更大时, 它会更接近买价. 微价格可以作为短期订单簿压力的一种统计摘要, 其解释范围限于具体市场和时间尺度下的订单簿状态. 公允价值判断和稳定预测需要另行建模.

7.8.5 买卖价差为什么存在

买卖价差有时被简单理解成做市商按照 bid 买入, 再按照 ask 卖出以后得到的利润. 实际中, 两边订单的到达时间和规模常有差异, 信息和价格也可能在持有库存期间发生变化.

价差通常同时反映几类因素: 处理订单和维持交易系统需要成本; 最小报价单位, 交易费用和市场竞争会影响报价; 流动性提供者需要暂时承担库存风险; 而且和自己成交的交易者可能拥有更加及时的信息.

信息交易与流动性交易

定义 7.129 (信息交易与流动性交易).

如果交易者的订单和当前价格尚未充分反映的信息相关, 就称这类交易为**信息交易** (informed trading).

如果交易主要由现金需求, 指数调仓, 对冲, 风险限额或者其他非价值预测动机驱动, 在微观结构模型中常把它称为**噪声交易**或者**流动性交易**.

“噪声”在这里只表示该订单所含的价值方向信息相对较弱. 这个标签描述模型角色, 对交易者的理性保持中性.

同一个交易者也可能同时具有多种动机. 一笔基金赎回产生的卖单可能主要来自流动性需求, 但负责执行的人仍然可能根据短期市场状态选择交易时机. 所以信息交易者和流动性交易者是模型角色, 会随当时的交易动机而改变, 因此应按具体动机识别.

逆向选择 假设流动性提供者根据现有信息给出 bid 和 ask. 如果某些交易者比它更早知道影响资产价值的信息, 这些交易者就会选择只在旧报价对自己有利时成交.

当好消息尚未进入报价时, 信息交易者更愿意按照旧 ask 买入; 当坏消息尚未进入报价时, 他们更愿意按照旧 bid 卖出. 流动性提供者因此更容易在报价已经过时成交, 这就是**逆向选择** (adverse selection).

在 Glosten–Milgrom 类型的简化模型中, 令 V 表示模型中的未来结算价值, $\mathcal{F}_t$ 表示做市商报价以前拥有的信息. 如果竞争性, 风险中性的做市商忽略库存和处理成本, 并按照条件期望实现零预期利润, 那么报价可以直观地写成

$$a_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = +1, \mathcal{F}_t],$$

以及

$$b_t = \mathbb{E}[V \mid \varepsilon_{\text{next}} = -1, \mathcal{F}_t].$$

如果主动买入更可能携带好消息, 主动卖出更可能携带坏消息, 那么信息不对称本身就能够产生正的买卖价差 [GM85].

这里的 V 是模型为研究信息结构引入的潜在变量, 无法在现实中直接观察. 该模型只刻画现实价差中由逆向选择形成的部分.

库存风险 做市商还需要管理已经积累的头寸. 如果客户连续向做市商卖出, 做市商会不断增加多头库存; 如果客户连续买入, 做市商则可能积累空头库存.

一个很粗的局部表达是

$$c_t = \hat{v}_t - \kappa_t H_t,$$

其中 $\hat{v}_t$ 是做市商根据当前信息形成的参考价格, H_t 是库存, 并约定 $H_t > 0$ 表示多头库存, $\kappa_t > 0$ 表示库存约束的强弱. 报价可以围绕这个中心写成

$$b_t = c_t - \frac{s_t}{2}, \quad a_t = c_t + \frac{s_t}{2}.$$

当做市商多头库存过多时, 降低报价中心会使继续买入变得不那么有吸引力, 同时提高把库存卖出去的机会. 它也可以减少某一侧报价数量, 或者通过其他市场和相关资产进行对冲 [HS81].

这只是库存模型的直觉表达, 不要求所有订单簿都满足该报价公式. 现实报价还会受到其他做市商, 普通限价订单交易者, 费用规则和风险限额影响.

注 7.130 (做市的收入与风险).

做市商出售的是即时成交能力, 同时承担库存, 逆向选择, 跳价, 对冲, 融资和操作风险. 报价价差记录两侧报价之间的距离. 做市商只有完成相反方向的成交并计入各项成本后, 才能确认实际利润. 做市商可能在一侧成交以后迟迟找不到另一侧订单, 也可能在重新对冲以前遭遇不利价格变化.

7.8.6 订单流与价格冲击

订单流的重要性来自两条渠道: 大订单会机械地消耗订单簿, 订单还可能携带信息. 其他参与者观察到成交方向, 数量和速度以后, 会重新判断自己面对的是暂时资金需求, 还是尚未充分进入价格的新信息.

Kyle lambda Kyle 模型把信息交易, 噪声交易和价格冲击放进了同一个序贯拍卖框架 [Kyl85]. 为了先看清核心机制, 这里抽取其中一次拍卖的线性定价表示.

令 V 表示模型中的未来价值, 信息交易者提交订单 X , 噪声交易者提交订单 U . 做市商只能观察到总订单流

$$Y = X + U,$$

其中的信息交易成分是潜在变量. 于是竞争性做市商按照观察到的 Y 更新价格:

$$p = \mathbb{E}[V | Y].$$

在线性均衡中, 这条定价规则可以写成

$$p = p_0 + \lambda Y.$$

其中 $p_0 = \mathbb{E}[V]$ 是做市商观察本次总订单流以前的先验价格.

定义 7.131 (Kyle lambda).

系数 λ 称为 **Kyle lambda**. 它表示在给定模型, 单位和时间尺度下, 有符号净订单流增加一单位时价格改变多少.

λ 越大, 同样数量的订单流对应的价格变化越大; $1/\lambda$ 因而可以被理解成一种市场深度.

Kyle lambda 和买卖价差衡量两个不同对象: 前者描述订单流和价格变化之间的斜率, 后者描述同时存在的买卖报价之间的距离.

经验 λ 的取值依赖资产, 样本, 单位, 时间尺度, 波动率, 市场深度和交易制度变化.

成交不平衡与经验价格冲击 在交易数据中, 人们有时使用局部关系

$$\Delta m_{t,t+\Delta} = \alpha_{\Delta} + \beta_{\Delta} Q_{t,t+\Delta}^{\text{trade}} + \eta_{t,\Delta}$$

估计有符号成交量和中间价变化之间的关系. 这里的 β_{Δ} 是给定样本和时间窗口中的简约形式斜率. 把它识别为结构模型中的 Kyle lambda 需要额外假设.

上式中的 $Q_{t,t+\Delta}^{\text{trade}}$ 只统计已经发生的成交. 经验研究中的订单流不平衡 (order flow imbalance, OFI) 还可以纳入最优报价的移动, 限价订单加入和撤单造成的队列变化; 它的信息范围比成交量更广. 在很短的时间尺度上, 最优报价附近的供需变化通常比单独使用成交量更接近订单簿承受的压力 [CKS14].

因果方向需要回归关系之外的识别设计. 信息交易者可能因为预见到未来价格变化而先行交易; 其他参与者也可能同时撤单或者重新报价. 所以“订单流和价格变化相关”应理解为一项样本联系, 其因果解释还需要区分信息, 撤单和重新报价等同时发生的机制.

暂时冲击与永久冲击 一张主动订单首先可能机械地消耗当前订单簿. 如果后续限价订单很快补回, 价差和中间价可能部分恢复. 这部分通常称为**暂时冲击**.

如果订单透露了市场此前不知道的信息, 其他参与者可能持续修改自己的判断和报价. 即使订单簿重新变厚, 价格也未必回到交易以前的位置. 这部分通常称为**永久冲击**或者**信息冲击**.

设第 i 笔成交发生在 t_i , 交易前中间价为 $m_{t_i^-}$. 可以考察给定时间距 h 下的有符号价格响应

$$R(h) = \mathbb{E} \left[\varepsilon_i \left(m_{t_i+h} - m_{t_i^-} \right) \right].$$

如果 $R(h)$ 随 h 增加逐渐回落, 可以把其中的回落部分理解成暂时成分; 如果它在较长时间以后仍然保留, 则可能包含更加持久的信息成分.

现实数据中的分解会混入观察窗口内的其他变化. 在等待 h 的过程中, 新消息和新订单仍然不断到达; 拆单策略还会使订单流本身具有持续性. 因此所谓“永久”始终是相对于某个模型和观察窗口而言, 相应识别范围也限于该模型和窗口.

7.8.7 时间尺度, 点过程与市场状态

日线数据通常把一天压缩成开盘价, 最高价, 最低价, 收盘价和成交量. 但在订单簿内部, 市场按不规则时刻到达的事件推进. 订单到达, 撤销和成交发生在不规则时刻, 而市场活跃程度本身也会不断变化.

定义 7.132 (日历时间, 事件时间与成交时间).

日历时间 (calendar time) 使用秒, 毫秒或者其他物理时间单位记录市场状态.

事件时间 (event time) 按照订单提交, 撤销, 修改, 成交或者报价变化的先后顺序为事件编号.

成交时间 (transaction time) 只保留实际成交, 按照第 $1, 2, \dots$ 笔成交推进时钟.

令 τ_n 表示第 n 个订单簿事件的日历时间, 并令

$$N(t) = \sum_{n \geq 1} \mathbf{1}_{\{\tau_n \leq t\}}$$

表示截至时刻 t 已经发生的事件数量. 相邻事件之间的等待时间为

$$W_n = \tau_n - \tau_{n-1}.$$

一分钟在安静市场中可能只包含几个事件, 在剧烈波动时却可能包含成千上万个事件. 所以“每个事件以后价格平均变化多少”和“每秒价格平均变化多少”回答的是不同问题.

可以分别令 $N_i(t)$ 统计第 i 类事件, 例如买入限价单, 卖出限价单, 主动买单, 主动卖单, 买方撤单和卖方撤单. 给定事件发生以前的信息 $\mathcal{F}_{t-}$, 第 i 类事件的条件强度 $\lambda_i(t)$ 可以通过

$$\mathbb{P}(N_i(t + \Delta t) - N_i(t) = 1 \mid \mathcal{F}_{t-}) = \lambda_i(t) \Delta t + o(\Delta t)$$

理解. 它描述的是在当前市场历史和订单簿状态下, 下一小段时间内某类事件发生的瞬时速率.

最简单的起点是把订单事件建模成 Poisson 过程. 但真实市场通常具有开盘和收盘季节性, 事件会成群出现, 不同类型的订单也会相互影响. 因此一个更现实的模型可能让强度依赖当前订单簿状态

$$\lambda_i(t) = f_i(\mathcal{L}_{t-}),$$

或者使用 Hawkes 过程描述事件之间的自激发和交叉激发 [BMM15; CST10].

例如一笔主动卖单以后, 短时间内可能出现更多主动卖单, 也可能引起买方限价单撤销或者新的买方报价进入. 统计上的事件聚集可以由多种经济机制产生: 共同新闻, 拆单策略和模型观察范围之外的市场状态都可能产生类似现象.

数据的可见范围 成交与报价数据记录成交和最优报价；订单簿快照记录若干档深度；逐消息数据进一步记录订单提交，修改和撤销。经纪商自己的订单数据还可能包含发送时间，确认时间，排队估计和实际执行结果。

即使数据足够详细，仍然需要小心时间戳精度，时钟同步，消息延迟和乱序问题。同一个进入订单可能产生多笔成交和多条订单簿更新；多个事件也可能共享同一个粗粒度时间戳。

单一场所的订单簿只覆盖整个市场的一部分。同一资产可能同时在多个交易所，另类交易系统，暗池和经纪商内部系统中交易。合并行情可以提供重要线索，但仍会受到延迟和隐藏流动性影响。

注 7.133 (碎片化与暗池).

市场碎片化可以让不同场所围绕费用，速度和服务竞争，但也会把流动性分散到不同地方。

暗池和其他非公开场所可能帮助大额订单减少交易前信息泄露，却通常不保证执行，也会降低研究者能够观察到的交易前信息。

因此“最好的显示价格”与“最好的实际执行结果”需要分开评估；单一场所的显示深度也无法覆盖全部可交易流动性。

流动性枯竭与交易中斷 显示在订单簿中的流动性只是有条件的交易意愿，新的信息到来，波动上升或者库存风险逼近限额时，交易者可以撤单，减少数量或者把报价移得更远。

于是市场可能形成反馈：

订单失衡或价格冲击 → 库存与风险限额收紧
 → 撤单，深度下降和价差扩大
 → 后续订单产生更大价格冲击。

如果这一过程在很短时间内造成异常剧烈的价格运动，并可能伴随快速的部分反转，通常会被称为**闪崩** (flash crash)。大额自动执行，单边订单流，流动性撤出，跨市场传导，风控行为和交易算法之间的反馈都可能共同参与闪崩的形成 [Kir+17]。

交易中斷，临时集合竞价和价格限制是市场面对极端状态时可能采用的制度工具。它们可以暂时停止连续撮合，让报价和风险系统重新评估市场状态，原有买卖失衡可能继续存在，重开价格也由当时新的订单和信息决定。

7.8.8 从订单簿走向交易执行

一张限价单被放进订单簿以后，只知道它的价格仍然不够。在价格优先，时间优先的市场中，同一价格上排在它前面的订单会先获得执行。

假设我们在时刻 t_0 提交一张价格为 p ，数量为 q 的限价单，并令 $A_{t_0}(p)$ 表示当时排在它前面的可见数量。在一个理想化的先进先出队列中，令 $D_t(p)$ 表示从 t_0 到 t 从队列前端有效消耗的累计数量。那么首次成交时间可以粗略写成

$$\tau_{\text{first}} = \inf\{t \geq t_0 : D_t(p) > A_{t_0}(p)\},$$

完全成交时间则可以写成

$$\tau_{\text{full}} = \inf\{t \geq t_0 : D_t(p) \geq A_{t_0}(p) + q\}.$$

普通订单簿快照通常只能粗略推断每一笔撤单原来在队列中的位置。隐藏数量，冰山订单，优先规则和消息延迟也会使真实排队位置难以观察。因此现实中的排队位置和执行概率经常只能估计。

一张限价单很快成交也不一定是好事。它可能恰好在新的卖压到来时买到股票，随后中间价继续下降。此时订单取得了执行，却同时遭遇逆向选择。

所以市场单和限价单之间的取舍取决于具体情境：

市场单： 较高成交确定性 + 价差与滑点，
 限价单： 价格保护 + 排队，未成交和逆向选择风险。

如果一张母订单的规模为 Q ，交易者还可以把它拆成若干子订单

$$q_1, \dots, q_n, \quad \sum_{k=1}^n q_k = Q.$$

拆单可以避免一次性扫过过多订单簿深度, 并等待新的流动性补充; 但执行得更慢也会延长价格风险暴露, 增加信号失效和交易意图泄露的可能。

如果全部订单已经完成, 平均执行价格为

$$\bar{P}^{\text{exec}} = \frac{1}{Q} \sum_{k=1}^n q_k P_k^{\text{exec}},$$

那么相对于决策价格 P^{decision} 的实施差额可以粗略写成 [Per88]

$$\text{IS} = \varepsilon Q \left(\bar{P}^{\text{exec}} - P^{\text{decision}} \right) + \text{费用},$$

其中 $\varepsilon = +1$ 表示买入, $\varepsilon = -1$ 表示卖出. 未完成订单还会引入剩余数量的机会成本.

实施差额是一个结果指标, 它同时吸收了市场冲击以外的价格变化. 在执行期间发生的公共信息, 市场整体变化和其他参与者的交易同样会影响价格.

怎样在市场冲击, 价格风险和未完成风险之间作出权衡, 正是后面交易执行模型需要处理的问题 [AC01].

7.8.9 通往订单流和市场冲击模型

现在可以把订单簿写成一个随事件变化的随机状态过程. 令

$$X_t = (b_t, a_t, Q_{1,t}^b, Q_{1,t}^a, Q_{2,t}^b, Q_{2,t}^a, \dots)$$

表示时刻 t 的订单簿状态. 第 n 个事件还可以携带标记

$$Z_n = (\text{类型}, \text{方向}, \text{价格}, \text{数量}, \text{场所}).$$

订单簿在事件到来时按照

$$X_{\tau_n} = \Phi(X_{\tau_n-}, Z_n)$$

发生跳变. 沿着事件时刻把这些跳变累加, 还可以直接写成

$$X_t = X_0 + \sum_{\tau_n \leq t} [\Phi(X_{\tau_n-}, Z_n) - X_{\tau_n-}].$$

这给出了标记点过程和订单簿状态过程之间最直接的接口. 它也说明最简单模型中的单一价格 S_t 究竟压缩掉了多少信息: 买价, 卖价, 价差, 多档深度, 订单流, 排队位置和交易制度在标量价格中只留下聚合后的结果.

从这里继续往前, 会出现三组自然的随机过程问题:

订单到达与撤销 → 事件强度和聚集性,
 订单流与订单簿状态 → 价格响应和市场冲击,
 随机成交与剩余头寸 → 交易执行和随机控制.

这时可以进一步把金融市场中的价格过程 S_t 解释为市场内生互动的结果. 在更细的时间尺度上, 价格, 订单流, 流动性和交易者行动会共同演化:

订单事件 → 订单簿状态 → 成交与库存 → 价格响应 → 执行成本.

市场微观结构追踪大量订单, 信息和约束在具体交易制度中相互作用后形成的可观察投影.

第八章 基本面分析

第七章回答的是：市场里有哪些可以交易的权利，它们怎样形成价格，又怎样通过利率，期限，抵押品和美元资金体系连接在一起。那部分更像是在搭建市场对象的地图。

进入股票研究或交易体系时，还需要另一层语言：一家公司怎样赚钱，哪些经营变量决定未来利润，其中哪些结果能够归属于我们实际持有的股票单位，独立证据能把价值约束到什么程度，这些判断在什么条件下才能变成估值，以及当前价格相对可能结果到底处在什么位置。这一层问题属于**基本面分析**，已经超出市场制度本身。

“公司经营很好”到“这只股票值得买”之间隔着好几道门。公司创造的资源需要穿过权利类别，优先顺位，稀释，治理，费用和实际提取路径，才能成为一单位股票的状态结果；状态结果还需要在给定模型，参数，主体，期限和终端边界下才能形成条件价值；价值与当前市场价格的差异最后还要经过一项具体策略才能兑现。

所以先建立一层估值识别框架：先问对象和单位是否明确，再问独立证据能够识别什么，最后才按最强证据锚选择方法。答案不一定非得是一个点估计；区间，条件情景，价格过程研究，甚至在信息不足或不可识别时停止，都可能比一个伪精确目标价更正确。

在很多基本量量化问题中，第一步的难点是把事件，语境和叙事翻译成合适的变量和值，通常比计算更棘手。例如“竞争格局恶化”不能直接丢进模型。它还需要进一步翻译为价格压力，市占率变化，客户留存率，利润率压缩或者估值倍数下调等可讨论的量。如果这一步翻译得不好，后面再复杂的公式也只是在精致地处理一个坏输入。

完成这层准备以后，接着进入 Risk-Reward 框架。原因很简单：它既保留了基本面研究中关于商业模式，驱动因素和估值的内容，又把这些判断压缩成 Bull, Base, Bear 等情景，从而自然接到第3.1节和第3.2节关于状态空间，随机变量和分布的语言。

相比直接从价格序列出发的量化分析方式，或者主要依赖价格趋势和交易信号的趋势交易，Risk-Reward 以及我们自创的 Agentic R-D-G (Agentic R/D Graph) 是这里更愿意作为主线展开的分析方式。它们把量化的入口前移：先把事件，语境，经营驱动，风险路径和情景价格组织成可以被持续更新的结构，然后再讨论概率，分布，风险暴露和交易决策。

所以这一章要练的是一件很具体的事：把现实中的商业判断整理成可以讨论，可以比较，也可以进一步接入风险管理和组合决策的对象。好的基本面分析先把问题问准，再让概率，情景和价格过程接上来。

8.1 从资产头寸到可识别价值

第7.1节讨论资产，价格和回报时，已经看到同一个资产名称下面可能藏着不同类别，不同账户，不同托管方式和不同附随义务。进入基本面分析后，第一步先问：谁在什么制度下持有什么头寸，它能产生什么结果，证据又允许我们把价值约束到什么程度。然后才能问“它值多少钱”。

这几步看起来比直接打开估值表慢一些，却能确保公式对应一个定义完整的估值对象。

工作框架的定位 这里提出本书采用的一套**工作框架**。它位于具体估值方法的上游，用来组织研究。贴现现金流法 (discounted cash flow, DCF)，无套利定价，一般均衡和可比估值仍各自提供具体理论与计算工具。

这些传统方法各自在自己的前提下仍然非常有力。为避免后文把缩写当成不透明的方法名称，这里先给出最小词汇表：

- 每股收益 (earnings per share, EPS) 是归属于每股普通股的盈利口径；企业价值 (enterprise value, EV) 是面向企业经营资产和全部资本提供者的价值口径；
- 市盈率 (price-to-earnings, P/E)，市净率 (price-to-book, P/B) 和市价/有形账面价值比率 (price-to-tangible-book, P/TBV) 是股权或每股层面的比较对象；
- 企业价值/息税前利润 (enterprise value to earnings before interest and taxes, EV/EBIT) 与企业价值/息税折旧摊销前利润 (enterprise value to earnings before interest, taxes, depreciation, and amortization, EV/EBITDA) 是企业层面的比较对象；
- 贴现现金流法 (DCF) 按所选现金流和贴现率估计条件价值；分部加总估值 (sum-of-the-parts, SOTP) 分别估计不同业务或资产后再按权利层级汇总。

P/E, P/B, P/TBV 和 EPS 直接落在股权或每股层面; EV/EBIT 和 EV/EBITDA 落在企业层面; DCF 与 SOTP 可以落在任一层面, 但必须先说明现金流或分部属于谁, 再把净债务和其他非普通股请求权正确连接到普通股。

首次阅读提示. 第一次阅读可以先抓住“定义对象, 检查证据, 选择方法, 必要时停止”这条主线. 后面的 F , Θ 和 $\mathcal{V}$ 只是在形式上保存这些条件, 可以在第二遍再逐项核对。

这里在这些方法的上游增加一层语法: 先把对象, 证据, 方法和停止条件分开, 再判断某一种传统方法是否有资格进入. 其核心是

$$\boxed{\text{对象语法}} + \boxed{\text{证据门槛}} + \boxed{\text{方法选择}} + \boxed{\text{停止规则}},$$

只有当对象与证据足以识别时, 这一组织方式才允许输出唯一内在价值。

具体来说, 我们先把含有附随义务的完整经济头寸记作 $\mathcal{Z}$, 再依次区分

资产头寸 $\rightarrow$ 状态结果 $\rightarrow$ 条件模型价值 $\rightarrow$ 市场价格 $\rightarrow$ 策略回报。

这些对象彼此有关, 每一支箭头都需要相应条件. 第7.1.2小节给出其中权利, 状态结果, 价值和价格的市场基础读法. 可交易性取决于市场制度, 价格差取决于当前市场价格, 兑现则取决于投资期限内可执行的转化路径。

价值必须带着条件说 在这套框架里, 价值必须附带语境, 无法当作资产对象上的固定字段. 即使面对同一个头寸, 不同持有者也可能因为财富, 信息, 替代机会, 融资条件, 税务状态或者实际使用能力不同, 而给出不同的保留价。

研究中常说的 Fundamental Value 通常是某个模型中的条件输出. 我们把它写成

$$F_{i,t}^{\mathcal{M},\vartheta,B}(\mathcal{Z}).$$

这个写法故意保留了几组索引:

- i 指明评价主体以及与主体有关的数量, 财富, 信息和约束;
- $\mathcal{M}$ 指明把未来状态结果转换成价值的模型;
- ϑ 指明增长, 利润率, 违约率, 贴现率等模型参数;
- B 指明期限, 计价物, 概率口径以及终端或清算边界。

终端边界尤其需要明确写出. 有限期限后的退出价格, 经营持续到无穷的终端价值, 合同到期支付, 清算回收和仍然存续的私人服务是不同的对象. 同时计入其中两项时必须说明关系, 以免重复计算同一利益。

因此“这项资产值 100”只是一个省略了大量条件的口语句子. 更完整的说法应该是: 在头寸 $\mathcal{Z}$, 主体 i , 模型 $\mathcal{M}$, 参数 ϑ 和边界 B 下, 模型给出的条件价值为 100 单位计价物. 保留这些条件可以让分歧落到具体位置。

估值首先是识别问题 估值公式只给出参数到价值的映射; 参数能否被识别还取决于证据. 令 $\mathcal{D}$ 表示不依赖待解释价值本身的证据, 并定义与这些证据相容的参数集合

$$\Theta_{\mathcal{M},B,i,\mathcal{Z}}(\mathcal{D}) = \{\vartheta : \mathcal{M}(\vartheta; \mathcal{Z}, i, B) \text{ 与 } \mathcal{D} \text{ 相容}\}.$$

相应的估值识别集合是

$$\mathcal{V}_{i,t}^{\mathcal{M},B}(\mathcal{D}; \mathcal{Z}) = \{F_{i,t}^{\mathcal{M},\vartheta,B}(\mathcal{Z}) : \vartheta \in \Theta_{\mathcal{M},B,i,\mathcal{Z}}(\mathcal{D})\}.$$

如果这个集合很窄, 点估计加敏感性分析可能是诚实的输出. 如果它有界但较宽, 区间, 条件情景或者部分识别反而更加合适. 如果关键参数缺少独立证据约束, 增加小数位只会制造虚假的精度。

这里的“独立”是识别前提. 市场价格可以进入研究, 但用价格残差反推一项看不见的服务价值, 再用它证明同一价格合理, 只能得到恒等式, 无法提供额外证据。

若存在多个都可以接受的模型或终端边界, 我们应分别报告各自的条件识别集合. 确实需要合并时, 可以写成这些集合的并集; 一个平均数字会掩盖模型分歧。

合法输出的多种形式 识别集合的形状决定了研究可以合法地说到哪里。常见输出可以整理成下面几类：

证据状态	合法输出
识别集合很窄	点估计或窄区间，并明确参数与敏感性
识别集合有界但较宽	宽区间，部分识别或带条件的情景集合
只对特定主体可以约束	私人保留价，使用价值或替代成本
当前价格只能约束模型条件	价格隐含增长，利润率，采用率或所需回报率
证据只支持研究市场动态	PRICE_PROCESS_ONLY

除此以外，研究还需要区分三个容易混淆的停止状态：

- INPUT_INCOMPLETE: 权利，单位，结果，终端或者必要参数仍缺少输入；
- NOT_RUN: 某个方法原则上有资格，但本轮尚未执行；
- NOT_IDENTIFIABLE: 单位和合理输入已经定义，有资格的方法也已经运行，独立证据仍然无法约束价值。

三者对应不同状态。缺资料属于输入问题，尚未运行属于流程状态，运行后仍缺乏约束才属于结构不可识别。此时随意放宽情景区间只会把未知包装成概率风险。

PRICE_PROCESS_ONLY 又稍有不同。它表示当前证据足以研究供给，流量，交易者，市场机制和价格动态，但尚不足以形成独立价值锚。这是一个合法的研究范围，与对象是否构成泡沫或是否只适合投机属于不同判断。

按最强独立证据锚选择方法 估值方法应由最强独立证据锚决定。“这是一只股票”或“这是一套房子”只帮助我们寻找证据；具体方法仍由证据支持程度决定。

最强独立锚	主要路线	关键边界
合同支付，到期，顺位与回收	现金流，违约与状态树	条款或回收不清楚时先回到权利图
可复制或可转换的状态支付	无套利，复制与含摩擦价格区间	交付，融资，卖空或结算不一致时不能声称唯一价
可归属且可预测的生产剩余	DCF，正常化盈利与单位捕捉桥	稀释，治理截留或终端不能约束时改用情景或停止
可观察租金，替代品或重置路径	租金资本化，替代成本与重置成本	独特性或转换条件不可比时降低权重
可执行的延迟，转换或退出选择权	期权，决策树与动态规划	权利不可执行或状态过程不能约束时不得强贴期权标签
网络，协调或私人服务证据	便利收益，采用情景或主体保留价	服务只能由价格残差得到时停止识别
只有当前市场价格较可靠	反向估值与压力测试	输出限于价格隐含条件；市场真实信念需要额外识别

方法选择要找到独立证据能够承重的路线，无需追求听起来最高级的模型。当证据改变时，主要方法也可以改变；这比让一套公式跨越所有资产更诚实。

多方法的分工 同时使用多种方法当然很有价值，但不同方法应该承担不同任务。一个简洁的组织方式是

主估值路线 $\cap$ 回收/复制/替代边界 $\cap$ 价格隐含条件 $\cap$ 制度与实施约束。

这里的交集表示方法之间的分工：主路线负责产生条件价值判断；边界路线负责排除过于宽松的结果；反向估值负责说明当前价格要求哪些条件同时成立；制度约束则检查权利和兑现路径是否真实可执行。

如果 DCF 给出 120，可比估值给出 140，反向估值显示现价要求长期增长 g 。三种输出承担不同任务，因此平均值 130 缺少自然的理论含义。更有用的问题是：DCF 的单位捕捉和终端是否站得住；可比公司的权利，成长和资本结构是否真的可比；隐含的 g 又是否被独立经营证据支持。

同一条价值腿还应只选择一个主要计价位置。已经进入未来现金流的治理效果，不再作为一项独立治理溢价完整加入；已经进入净退出所得的流动性成本，也不再同时通过贴现率和额外折价重复扣除。

什么时候应该停止 适时停止可以防止模型在证据之外继续说话，也是研究结论的一部分。本书采用下面几条简单规则：

1. INPUT_INCOMPLETE: 头寸的包装，类别，主体，法域或计价物未定义。
2. 谁能够执行，修改，冻结或终止权利仍不清楚时，不进入货币估值。
3. 底层结果无法连接到本单位时，不用总利润，总规模或网络规模代替单位利益。
4. 必要输入缺失，方法未运行与运行后不可识别，分别使用对应状态，不互相代替。
5. 没有方向，数量，场所，时间和结算资产时，不从价值直接计算预期回报。
6. 没有进入成本，持有期限，退出机制和费用时，只保留价值研究。
7. 价值差异没有可执行的提取，转换，消费或退出路径时，不把它升级成投资机会。
8. 同一利益或风险已经在主要位置计时，不在其他位置完整重复。
9. 新信息不再改变权利分类，识别状态，方法路线或关键情景时，就应完成并交付。

最后一条也很重要。资产世界非常异质，但研究不需要为了覆盖所有反例而无限扩张。只要当前问题的合法输出已经确定，继续增加装饰性情景通常不会提高决策质量。

普通股为什么是一个强而有用的特例 对许多公开交易的普通股来说，上述链条比在其他资产上更容易完成。股份类别和股东权利通常可以核验；企业经营会产生可观察的收入，成本和资产负债表结果；债务，优先权，稀释和回购又能把企业层结果连接到每一股普通股的剩余索取权。

在这些条件大致成立时，可归属的生产剩余往往成为最强独立锚。DCF，正常化盈利或资产价值可以承担主路线；清算，替代和可比关系可以提供边界；当前股价则适合用来反推市场价格要求的成长，利润率或者所需回报条件。

普通股的目标价依然带有条件。我们需要让不同经营世界产生不同单位结果，在每个世界中重新检查参数和终端边界，并且只有在未来退出市场和兑现路径明确时，才把条件模型价值进一步写成情景终值。

于是接下来的链条变成

普通股具体头寸 → 经营驱动与单位捕捉
→ 条件估值集合 → 情景终值与策略损益。

下一节的 Risk-Reward Framework 从这里开始：它把已经通过对象定义与识别检查的普通股研究，压缩成几个可比较的上行，中心和下行情景，价值仍来自前面通过对象定义与识别检查的研究。

8.2 Risk-Reward 框架与情景分析

第七章介绍了资产，衍生品，债券和短端美元资金市场。第8.1节进一步区分了资产头寸，状态结果，条件价值，市场价格和策略回报，并说明估值首先是一个识别问题。进入交易体系后，还要同时估计判断成立时的上行空间和判断失误时的下行损失。

只看单个投资机会时，这个问题可以先压缩成一张 Risk-Reward 图。图的价值来自情景价格背后的商业模式，经营驱动，财务结果和估值方法。Bull Case, Base Case 和 Bear Case 三个孤立的数字无法承载这些判断。Risk-Reward 图只是把这些判断压缩成一种更容易比较的形式。

这里主要讨论一个较强但很常见的特例：投资者面对一类权利已经明确的普通股，用正的进入价格建立现货多头，并在共同期限上比较若干可执行或可标记的退出结果。衍生品，空头，杠杆头寸，私人使用资产和不可识别对象不能机械套用这里的价格收益公式。

Morgan Stanley 的一些公开材料会用 Risk-Reward 页面组织个股情景分析, 并把上行情景, 中心情景, 下行情景以及期权隐含概率等信息放在同一处展示 [Mor22]. 这里借此讨论单点目标价遗漏了哪些决策信息, 以及该框架怎样连接前面介绍的随机变量, 分布和风险中性定价, 无意复刻某家机构的研究模板.

为了避免和债券章节中的零息债券价格 $P(t, T)$ 混淆, 这里用 S_0 表示当前股票价格, 用 $S_s(T)$ 表示共同研究期限 T 下情景 s 的代表性终值. 这里的 $S_s(T)$ 表示研究者对未来退出或市场标记价格的条件判断; 它只在给定研究条件下成立, 不表示脱离这些条件的资产固有价值. 如果分红, 回购或其他现金分配在研究期内很重要, 则应把下面的价格收益改成包含这些现金分配的总收益.

单点目标价遗漏的信息 股票研究最后经常会收敛成一个目标价. 假设股票当前价格为 S_0 , 研究者认为期限 T 下的中心情景终值为 $S_{\text{Base}}(T)$, 那么最直接的潜在上涨空间就是

$$\frac{S_{\text{Base}}(T) - S_0}{S_0}.$$

这个数字给出了中心情景相对现价的位置, 却遗漏了判断失误时的下方形状和情况好于预期时的上方厚度.

例如两家公司当前价格同为 100, 中心情景也同样是 120. 加入上行和下行情景后, 两种机会的结构可能相差很大:

	Bull Case	Base Case	Bear Case
A	160	120	90
B	130	120	50

只看 Base Case, 二者看起来都还有 20% 的上涨空间. 但公司 A 的上行更厚, 下行更浅; 公司 B 的中心情景虽然也高于现价, 但一旦核心假设失败, 损失可能很深.

原则 8.1 (单点目标价的边界).

在本书这套工作框架中, 单点目标价只给出特定头寸, 模型, 参数, 期限, 计价物和终端边界下的一项条件输出, 还没有回答上行来自哪里, 下行会怎样发生, 当前价格在这些可能结果之间处于什么位置, 以及这项差异能否由具体策略兑现.

Risk-Reward Framework 将单点估值展开为情景分布的粗略轮廓, 每个新增端点都须有相应的经济判断支撑.

定义 8.2 (Scenario).

给定评价主体 i , 完整资产头寸 $\mathcal{Z}$, 模型 $\mathcal{M}$, 独立证据 $\mathcal{D}$ 以及终端边界 B , 并选取与证据相容的情景参数

$$\vartheta_s \in \Theta_{\mathcal{M}, B, i, \mathcal{Z}}(\mathcal{D}),$$

一个 Scenario 是一组彼此一致的制度, 经营, 财务, 单位捕捉和估值假设. 它们共同描述一种可能的未来经济状态, 先产生条件状态结果和模型价值; 只有进一步说明未来退出或标记市场以后, 才产生相应的情景价格 $S_s(T)$.

Base Case 表示当前信息下最具代表性的中心经营世界; Bull Case 说明哪些关键变量可能明显好于中心判断; Bear Case 则说明哪些核心假设可能失效, 以及这种失效怎样破坏企业价值.

情景作为状态空间的粗粒化 从概率论的角度看, 实际的未来状态远多于三种. 沿用第3.1节和第4.2节, 所有可能的未来状态可组织成概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$. 每个样本点 $\omega \in \Omega$ 代表一条足够完整的未来路径: 宏观环境, 利率, 行业需求, 公司竞争地位, 利润率, 估值倍数和市场情绪都包含在其中.

完整地研究 Ω 几乎不可能. 情景分析做的是一次粗粒化: 它把复杂未来状态压缩成少数几个对当前决策最重要的类别. 例如可以定义一个可测映射

$$\kappa: \Omega \longrightarrow \{\text{Bear}, \text{Base}, \text{Bull}\}.$$

这里 $\kappa(\omega)$ 给出未来状态 ω 所属的经济情景, 并不直接给出未来价格. 于是

$$A_s = \{\omega \in \Omega : \kappa(\omega) = s\}, \quad s \in \{\text{Bear}, \text{Base}, \text{Bull}\},$$

其中 $A_s \in \mathcal{F}$. 如果这些事件互不相交且并为 Ω , 它们就给出了对未来状态空间的一组粗略划分.

由于 $\mathbb{P}$ 是真实世界概率测度, 记 $p_s = \mathbb{P}(A_s)$. 若三个情景构成划分, 则有

$$\sum_s p_s = 1.$$

实务里的 Risk-Reward 图未必显式给出这些主观概率, 通常只列出每个情景下的经济机制和情景价格.

设情景 s 下得到的代表性终值为 $S_s(T)$. 那么一张三情景图可以理解成用简单随机变量

$$\tilde{S}_T = \sum_s S_s(T) \mathbf{1}_{A_s}$$

近似一个复杂得多的未来终值 S_T . 这个近似会丢掉大量信息, 但它迫使研究者回答几个更有决策意义的问题: 中心情景是什么, 哪些变量会把公司推向上行情景, 哪些变量又会把公司拖入下行情景.

注 8.3.

Base Case 不等于数学意义上的期望值. 一般没有理由认为 $S_{\text{Base}}(T) = \mathbb{E}[S_T]$. 它更像是当前信息下最具代表性的中心经济情景, 而期望值还需要情景概率以及情景内部更细的分布信息.

注 8.4.

Bear Case 是研究者选定的下行情景, 通常仍高于数学意义上的下界或最坏情况. 三点离散化会隐藏每个情景桶内部的分散程度, 极端尾部, 以及到达终值以前的路径风险.

因此三个价格要连同三组内部一致的经济世界一起阅读:

具体头寸 $\rightarrow$ 权利与义务 $\rightarrow$ 经营状态 $\rightarrow$ 单位捕捉
 $\rightarrow$ 识别判断 $\rightarrow$ 条件模型价值 $\rightarrow$ 退出或标记价格
 $\rightarrow$ 策略损益.

从商业驱动到情景价格 每个 Bull, Base 和 Bear 情景都应该从企业的关键经营驱动出发, 使情景价格具有可检查的来源.

定义 8.5 (Driver Tree).

Driver Tree 指的是把企业经营活动逐层连接到收入, 利润率, 净利润, 每股收益和自由现金流的传导结构. 它沿经营链条解释利润变化的来源, 再据此估计明年的利润增幅.

Driver Tree 到公司层面还没有结束. 估值对象是某一类具体股票单位时, 还需要一条单位捕捉桥:

企业资源与现金流 $\rightarrow$ 本权利类别可归属部分 $\rightarrow$ 同权或完全稀释单位 $\rightarrow$ 每单位可提取结果.

优先顺位, 少数股东权益, 净债务, 稀释, 回购, 治理截留和实际分配能力都可能在这条桥上改变结果. 企业增长本身不能直接推出每股价值增长.

不同商业模式的 Driver Tree 完全不同. 支付网络公司可能更关心支付金额, 跨境交易量, 交易笔数, 单笔业务的收费率和客户激励; 零售企业可能更关心客流, 客单价, 同店销售和毛利率; 银行则可能更关心贷款增长, 净息差, 信用损失, 费用率和资本回报率. 这些变量本身未必直接等于财务报表项目, 但会沿着经营链条传到 Revenue, Margin, EPS 或 FCF.

例 8.6 (支付网络).

对支付网络公司来说, 分析从经过网络的支付活动规模开始, 跨境交易占比怎样变化, 每笔或每单位支付金额能够收取多少收入, 以及为了维持客户关系需要支付多少激励. 这些判断再进入收入, 费用, 利润率和每股收益预测.

这样做的好处是, 风险不再只是一个抽象的“股价可能下跌”. 如果 Bear Case 来自需求下降, 它应当沿着

$$\text{Volume} \downarrow \longrightarrow \text{Revenue} \downarrow \longrightarrow \text{Margin} \downarrow \longrightarrow \text{EPS} \downarrow$$

这样的路径传导. 如果 Bear Case 来自竞争恶化, 传导路径可能是价格下降, 客户激励上升, 利润率压缩, 最后再引起估值倍数下调.

因此一份有用的情景分析至少要说明: 哪几个关键 Driver 在不同情景下发生了变化, 这些变化怎样传到财务结果, 以及财务结果变化以后为什么应该对应不同估值.

估值方法服从最强独立证据锚 做完经营和财务预测以后, 先判断独立证据能够约束哪一种价值路线, 再把经营和财务结果转成价格. 没有一种估值公式对所有企业都最合适. 商业模式帮助我们寻找现金流, 盈利, 资产或分部这些证据锚, 但“这是一家银行”或“这是一家科技公司”本身并不能授权某个公式.

对普通股而言, 当可归属且可预测的生产剩余是最强独立锚, DCF, 正常化盈利, 资产价值和分部估值才成为有资格的主要方法. 如果权利类别, 稀释, 终端或单位捕捉仍无法约束, 结论应当收缩或停止; 提高折现率或放宽倍数区间无法补足这些输入.

主要方法	独立锚与更自然的使用场景
P/E	盈利相对稳定, 资本结构不太扭曲, 每股收益能较好代表股东经济结果的公司.
EV/EBIT 或 EV/EBITDA	需要先估计经营资产价值, 再单独处理净债务和资本结构差异的公司.
DCF	现金流路径和资本成本是核心问题, 且需要显式展开长期假设的公司.
SOTP	多块业务具有明显不同增长, 利润率和风险结构, 不能用单一倍数概括的公司.
P/B 或 P/TBV	银行等资产负债表本身就是商业模式核心的金融机构.

估值方法的基本工具可以参考公司金融和估值教材 [Dam12]. 在 Risk-Reward Framework 中, 这些工具把不同情景下的基本面假设转成有条件的模型价值. 多种方法之间也不宜简单取平均, 而应形成以下交叉约束:

主估值路线 $\cap$ 回收, 复制或替代边界 $\cap$ 价格隐含条件 $\cap$ 制度与实施约束.

一条价值腿只有一个主要计价位置; 其他方法用于边界, 反证和交叉检查.

例如对使用 P/E 估值的公司, 最简单的条件模型价值可以写成

$$F_s^{P/E}(T) = \text{EPS}_s \times M_s,$$

其中 M_s 是情景 s 下的合理市盈率. Bear Case 中经常不只是 EPS_s 下降, 还可能因为增长放缓, 风险上升或竞争优势受损, 导致 M_s 一起下降. 这就是盈利下修和估值压缩同时发生的情形.

若研究者进一步假设期限 T 的市场会按照同一锚进行标记, 才可以把 $F_s^{P/E}(T)$ 用作情景退出价格 $S_s(T)$ 的代表值. 这一步是从模型价值到未来市场价格的桥, 两者之间并无定义恒等关系.

同一家公司的不同情景甚至可以使用不同估值锚. 一家银行在正常环境下可能主要看未来盈利和资本回报率; 但在严重信用压力情景中, 市场可能先关心有形账面价值是否足够可靠. 情景改变后, 约束企业价值的经济条件也会改变, 估值锚随之调整并不构成前后矛盾.

端点偏斜与概率加权 R/D 下面的比例只服务于本节已经固定的教学策略：以正价格 S_0 建立一单位现货多头，在共同期限 T 按照可执行或可标记价格退出，并暂时忽略费用，融资和期间现金分配。一般策略应当先在上一章的框架中得到 $\Pi_{0,T}^{\text{financial}}(h)$ 和有经济含义的资本基数 K_0^h ，再比较各情景的策略回报；不能直接从资产标签和终值价格推出统一收益率。

设当前价格为 S_0 ，上行情景终值为 $S_{\text{Bull}}(T)$ ，下行情景终值为 $S_{\text{Bear}}(T)$ 。为了记号方便，可以定义端点上行空间

$$U_{\text{Bull}} = \frac{S_{\text{Bull}}(T) - S_0}{S_0},$$

以及端点下行幅度

$$L_{\text{Bear}} = \frac{S_0 - S_{\text{Bear}}(T)}{S_0}.$$

当 $L_{\text{Bear}} > 0$ 时， $U_{\text{Bull}}/L_{\text{Bear}}$ 可以作为一个非常粗糙的端点偏斜指标。

注 8.7.

这里的 $U_{\text{Bull}}/L_{\text{Bear}}$ 是本文为讨论 Risk-Reward 形状引入的压缩记号。它只描述当前研究假设下上行空间与下行损失的对称程度，与 Morgan Stanley 报告中的固定公式无关，也未涵盖完整的期望收益或下单规则。

如果研究者进一步愿意给情景分配真实世界主观概率 p_s ，也可以令

$$\rho_s = \frac{S_s(T) - S_0}{S_0},$$

并定义概率加权的上行与下行：

$$R_{\mathbb{P}} = \sum_s p_s(\rho_s)^+, \quad D_{\mathbb{P}} = \sum_s p_s(-\rho_s)^+.$$

令 $\tilde{\rho}_T = (\tilde{S}_T - S_0)/S_0$ ，于是粗粒化后的期望收益可以写成

$$\mathbb{E}_{\mathbb{P}}[\tilde{\rho}_T] = R_{\mathbb{P}} - D_{\mathbb{P}}.$$

难点集中在两次翻译：先从现实事件形成情景，再为各情景估计合理的概率和价格。

公司质量和投资吸引力属于不同维度。一家非常优秀的公司，如果当前价格已经接近 Bull Case，剩余上行可能并不吸引人。一家普通公司，如果当前价格已经接近一个相当悲观的 Bear Case，而 Base 和 Bull 仍然有充分空间，反而可能形成更好的 Risk-Reward。

所以 Business Quality 不等于 Investment Attractiveness。更完整的断裂是

经营质量 $\nrightarrow$ 高条件价值 $\nrightarrow$ 价值高于价格 $\nrightarrow$ 可兑现回报 $\nrightarrow$ 可投资性。

前者是在问公司经营和资源创造能力怎样，后者还要问单位捕捉，识别边界，当前价格，策略路径和实施约束是否共同成立。

一个虚构的三情景例子 为了避免真实公司案例随着时间迅速过期，这里使用一个完全虚构的例子。设公司当前价格为 $S_0 = 100$ ，研究期限为一年。为了集中展示算术，再假设每个情景下的市场都会用表中的 P/E 对相应 EPS 进行标记，因此本例把条件模型价值直接用作期限末代表性市场价格。研究者认为三种情景可以粗略整理为：

情景	p_s	EPS_s	M_s	核心假设
Bull	0.25	12	13	需求强于预期，利润率扩张，市场愿意给更高倍数。
Base	0.50	10	12	经营大致符合中心判断，估值倍数保持正常。
Bear	0.25	7	10	需求转弱，经营杠杆反向作用，估值倍数压缩。

于是三个情景终值分别为

$$S_{\text{Bull}}(T) = 12 \times 13 = 156, \quad S_{\text{Base}}(T) = 10 \times 12 = 120, \quad S_{\text{Bear}}(T) = 7 \times 10 = 70.$$

端点上行和下行分别是

$$U_{\text{Bull}} = \frac{156 - 100}{100} = 56\%, \quad L_{\text{Bear}} = \frac{100 - 70}{100} = 30\%.$$

因此端点偏斜为

$$\frac{U_{\text{Bull}}}{L_{\text{Bear}}} \approx 1.87.$$

如果进一步接受表中的主观概率, 三个情景收益率分别为 56%, 20% 和 -30%. 于是

$$R_{\mathbb{P}} = 0.25 \times 56\% + 0.50 \times 20\% = 24\%,$$

而

$$D_{\mathbb{P}} = 0.25 \times 30\% = 7.5\%.$$

所以粗粒化后的概率加权期望收益为

$$R_{\mathbb{P}} - D_{\mathbb{P}} = 16.5\%.$$

这些数字仍然只是模型输出. 审查应落在它们的来源上: EPS 为什么能到 12 或跌到 7, 合理倍数为什么会从 12 倍扩张到 13 倍或压缩到 10 倍, 以及 0.25, 0.50, 0.25 这组概率是否真的反映当前证据.

期权隐含概率与主观真实概率 有些 Risk-Reward 页面还会把情景价格和期权市场信息放在一起. 期权价格包含市场对未来价格分布的定价信息. 这里须区分风险中性定价分布与分析师对 Bull, Base 和 Bear 分配的主观概率.

在无套利定价框架中, 在确定常数利率, 无套利和 payoff 适当可积等简化假设下, 欧式看涨期权价格可以写成风险中性测度 $\mathbb{Q}$ 下 payoff 的折现期望:

$$C_0(K, T) = e^{-rT} \mathbb{E}_{\mathbb{Q}} [(S_T - K)^+].$$

在足够光滑的理想条件下, 不同行权价的期权价格甚至可以反推出风险中性密度的信息; 经典的 Breeden-Litzenberger 关系正是这种思想的表达 [BL78; Hul22].

$\mathbb{Q}$ 与现实世界概率测度 $\mathbb{P}$ 扮演不同角色. 二者之间的差异与风险溢价, 投资者风险偏好, 供求压力以及市场微观结构有关. Options-Implied Probability 指当前期权价格所隐含的定价分布信息; 它不能直接解释为市场对某个基本面情景的真实世界发生概率.

分析师主观情景描述基本面世界可能怎样展开; 期权市场告诉我们某些终端价格区域或尾部状态在市场定价中有多贵或多便宜. 两者合用可以区分基本面分歧, 波动率分歧, 以及对尾部风险定价的分歧.

作为交易体系的接口 Risk-Reward Framework 连接两组工作: 上游的商业模式研究, Driver Tree, 财务预测和估值, 以及下游的仓位大小, 流动性, 相关性, 组合风险和具体执行.

具体头寸与权利 → 经营驱动 → 单位捕捉 → 识别判断
→ 条件估值 → 情景退出价格 → 策略 Risk-Reward.

这个接口必须和上下游判断一起使用. 如果上游权利, Driver 或单位捕捉判断是空的, 那么 Bull, Base 和 Bear 只是三个装饰性的数字. 如果下游没有组合和执行纪律, 那么看起来漂亮的端点偏斜也无法自动变成好的交易.

这个框架也连接随机过程与金融市场. 它把一个复杂的未来路径空间压缩成少数几个经济情景, 把每个情景转换成可以比较的价格, 再让我们观察当前价格处在这些情景之间的什么位置. 在概率语言中, 现实市场中的基本面叙事由此变成一个粗糙但可讨论的随机对象.

Risk-Reward 图仍是一种相对静态的压缩. 它展示了当前研究者怎样理解几个主要情景, 但还没有完整保存: 这些情景来自哪些证据, 哪些事件通过什么机制改变了经营变量, 同一项风险有没有被重复计算, 以及新信息到来时应该修改哪一个环节.

下一节用 Agentic R-D-G 保存这些关系.

8.3 Agentic R/D Graph: 把研究判断组织成可更新的图

第8.2节把一个投资机会压缩成 Bull, Base, Bear 等少数情景, 再用情景价格和概率讨论上行与下行. 这种压缩便于横向比较, 却隐藏了情景从现实信息中生成的过程.

只保留最后几个情景价格, 久而久之便会丢失数字的证据来源和风险的传导机制. 新信息到来时, 也难以判断它应修改情景价格, 情景概率, 还是仅进入观察清单.

如果把研究本身也看成一个随时间更新的状态, 随机过程语言就有了用处: 第4.3节提供信息随时间增长的语言, 第4.2节提供过程和样本路径的语言. 时刻 t 的研究状态保存已经看见的证据, 新信息到来后, 状态被更新, 某些下游判断需要重读. Agentic R-D-G 只是把压缩后的情景重新展开成一张可追踪的研究图, 方便保存证据, 经营驱动和传导路径.

定义 8.8 (Agentic R-D-G).

这里把这种研究形式称为 Agentic R-D-G, 也写作 Agentic R/D Graph. 其中 R 表示潜在回报, D 表示潜在下行或风险, G 表示研究图.

它把预测市场信号, 市场事件, 语境, 公司局部反应, 经营驱动, 情景输入和风险路径组织成一组带有来源, 时间, 状态和责任边界的图, 让研究系统可以持续读取, 更新和回放研究过程.

Agentic R-D-G 属于研究状态表示, 不提供自动买卖信号或图评分. 图保存传导结构和输入来源; 最终估值, 情景概率, R/D, 组合判断和交易执行仍然由各自的研究与决策环节负责.

Agentic R-D-G 的范围超过单独一张 Event Graph. 下面的记号只为接回随机过程主线: 研究状态和价格一样, 都是在信息逐步展开时被观察和更新的对象. 在固定的滤过概率空间

$$(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$$

上, $\mathcal{F}_t$ 表示截至时刻 t 能够被区分和使用的信息. 普通价格 S_t 是定义在共同样本空间 Ω 上的 $\mathcal{F}_t$ -可测数值随机变量. 在把图空间赋予适当可测结构后, Market Graph 可以暂时记成一个 $\mathcal{F}_t$ -可测的图值随机对象

$$M_t: \Omega \longrightarrow \mathfrak{G}_{\text{mkt}}.$$

对某个市场状态 ω , $M_t(\omega)$ 以图的形式保留事件, 传导, 市场注意力, 风险堆积和资产暴露; 它是市场的研究表示.

在研究结构上, 单家公司和单个事件层面的研究可以看成局部 Event Graph; Market Graph 则可以从许多局部图沿着共同事件, 上下游关系, 行业主题和资产暴露粘接而成来理解. 这种粘接只是一幅帮助读者理解的图像. 实际研究流程可以直接从已有局部图和既有全局状态出发, 无须每次重建全局母图. 若要从 M_t 中读出市场季风, 风险堆积或者公司研究语境, 还需要交给具体的读出器或者研究归属环节.

从静态情景到可更新的研究状态 Risk-Reward 图先对未来状态空间作一次粗粒化:

$$\Omega \longrightarrow \{\text{Bull, Base, Bear, Tail}\}.$$

它给出企业在几个代表性未来世界中的条件价值.

Agentic R-D-G 进一步记录市场事件和外部信号怎样经由中间变量把公司推向这些世界, 以及当前证据支持哪些路径. 记录内容包括事件所改变的经营变量, 变化在情景价格, 情景概率和观察清单之间的归属, 以及新证据到来后需要复查的判断. 下面先区分公司事件图, 预测市场信号和市场图, 再讨论事件如何进入变量.

预测市场信号应单独建模:

$$\Delta Q_t \longrightarrow \{\text{market attention, market probability objects}\} \longrightarrow \text{路由/语境/校准}.$$

它显示外部市场关注的事件, 以及某个合约在自身结算规则下形成的价格对象. 公司传导边仍需基本面证据激活, 公司情景概率也需由相应研究环节生成.

Market Graph 可以按研究问题读出公司研究所需的局部语境. 全局图进入单家公司研究前, 须经过路由并接受用途约束, 不能作为任意吸收的背景知识.

Prediction Market, Market Graph 与 Company Event Graph 先把桌面上的三种东西分开放。

Company Event Graph 落到某一家公司 i , 围绕这家公司自身商业模式, Driver Tree, 上下游事件, 财务变量和情景对象展开的局部事件图. 它由公司证据, 上下游事实和传导机制判断来构造. Prediction Market 中相关上下游事件的盘口, 赔率, 成交量和市场关注度可以作为市场注意力或者候选概率对象进入路由和语境, 但不能单独证明事件发生, 也不能单独证明某条公司传导边已经被激活.

Prediction Market 或更一般的预测市场信号, 站在另一张桌面上. Polymarket, Kalshi 等市场把某些未来事件本身做成可以交易的合约, 因此能够提供两类信息: 一类是市场注意力, 也就是市场当前愿意围绕哪些事件下注; 另一类是市场目前的押注状态, 例如赔率, 盘口大小, 流动性和价格变化. 预测市场价格首先对应合约自身的结算规则. 公司情景概率与估值结论还要经过各自的研究过程.

例如某个预测市场可能给出事件 A 在其结算规则下的价格

$$q_t^{A, \text{mkt}},$$

这个价格不能直接等同于某家公司 Bull, Base 或 Bear 情景的概率. 它说明市场上存在一类关于 A 的外部注意力或概率对象, 可以用来校准研究问题的优先级, 或者作为候选证据交给既有的概率归属环节. 至于它能不能影响公司情景概率, 仍然要看合约结算规则, 期限, 条件性, 流动性, 以及公司基本面传导证据是否足够干净.

Market Graph 则保留更宽的市场语境. 在上面的随机过程记号下, 可以把它暂时看成定义在共同样本空间上的图值随机对象. 它由跨公司和跨资产的关系构成, 既不局限于某一家公司的事件图, 也不需要预设一张高高在上的母图. 对某个市场状态 $\omega \in \Omega$, 可以把 $M_t(\omega)$ 理解成一张记录了事件, 传导, 市场注意力, 资金条件和资产暴露的全局图.

这种全局图可以由局部图粘接出来. 同样把公司 i 的局部图记成一个 $\mathcal{F}_t$ -可测的图值随机对象

$$G_t^{(i)}: \Omega \longrightarrow \mathfrak{G}_i.$$

如果 $G_t^{(i)}(\omega)$ 表示它在同一市场状态下的局部 Event Graph, 那么可以粗略写成

$$M_t(\omega) \simeq \text{Glue}_t(\{G_t^{(i)}(\omega)\}_{i \in I_t}, \mathcal{R}_t(\omega), \mathcal{Q}_t(\omega)).$$

这里 $\mathcal{R}_t$ 表示公司之间共享的事件, 上下游关系, 共同因子和资产暴露; $\mathcal{Q}_t$ 表示预测市场提供的市场注意力, 带有结算规则和期限的赔率, 盘口大小和市场概率对象. 这个记号属于概念类比, 不是严格的层论对象. 在工程实现里, 被接受的图谱状态和本轮研究图还需要通过版本, 来源和用途边界分开保存.

Market Graph 的作用主要有两个, 都要通过具体读出或路由发生. 一方面, 它可以交给专门的市场季风读出器, 帮助我们观察市场的季风, 也就是当前哪些事件, 主题, 资金条件和风险暴露正在共同起作用, 以及风险是否在多个局部图之间堆积. 另一方面, 它可以被投影成语境输入, 为某一家公司的基本面研究提供对照语境, 从而区分个体噪声与已经连接行业, 政策, 资金或市场注意力结构的局部风险.

注 8.9.

Company Event Graph 提供的是以单家公司为中心组织的传导路径. Prediction Market 提供的是市场注意力, 押注状态和候选市场概率对象. Market Graph 可以理解成市场状态空间上的图值读出, 也可以在概念上由许多局部图粘接出来. 但它需要通过明确读出器或路由, 才能进入市场季风, 风险堆积或公司研究语境.

三者均位于估值与组合决策的上游, 不直接生产公司情景概率, R/D, 仓位或订单.

从事件和语境到变量 很多基本面量化问题的第一道难关是把事件或语境翻译成合适的变量和值.

假设出现了一条“竞争进一步加剧”的消息. 这句话本身还不能直接进入估值模型. 对于不同公司, 它可能意味着完全不同的东西: 价格下降, 客户激励上升, 市场份额流失, 获客成本提高, 资本开支增加, 或者只是短期市场情绪变差.

这种翻译可记作

$$(e, c) \xrightarrow{\Theta_t} \Delta x.$$

其中 e 表示事件, c 表示事件发生时的商业和市场语境, x 表示最终受到影响的经营或估值变量, 而 Θ_t 表示截至时刻 t 研究者对于传导机制的判断.

Θ_t 需要研究者识别, 不能预设为已知的机械函数. 这一步通常最考验对商业机制的理解.

同一条事件在不同语境中可能产生不同结果. 例如降价既可能意味着竞争恶化, 也可能意味着公司主动用价格换取规模; 资本开支上升既可能压低近期自由现金流, 也可能为未来产能和增长创造条件. 变量的选择取决于商业模式, 时间跨度和当前价格.

命题 8.10.

事件和叙事不能直接变成数字.

在进入情景价格或者概率以前, 必须先说明事件改变了什么状态变量, 通过什么机制发生, 大概具有怎样的方向, 时滞和持续时间, 以及什么证据会否定这条传导路径.

节点, 边与证据状态 为了避免把研究图画成一张漂亮但无法审查的思维导图, 图中的节点需要保留基本的认识论状态.

为了记号简单, 下面固定一个 $\omega \in \Omega$, 并在图值随机对象及其组件上省略 (ω) . 若没有特别说明, G_t 都指某家公司局部 Company Event Graph 的这个实现. 于是时刻 t 的公司局部图实现是一个带标签的有向图

$$G_t^{(i)} = (V_t, E_t, \tau_V, \tau_E, x_t, \mathcal{L}_t),$$

其中 V_t 是节点集合, E_t 是传导边集合, τ_V, τ_E 记录节点和边的类型, x_t 记录当前状态, $\mathcal{L}_t$ 则保存证据谱系, 允许用途和禁止用途. 节点可以大致分成下面几层:

层次	典型内容	主要问题
证据节点	财报, 电话会, 行业数据, 政策文件, 市场价格, 预测市场信号	谁在什么时间说了什么, 这是事实, 主张还是推断?
事件与语境节点	需求变化, 政策变化, 竞争动作, 融资环境变化	什么状态发生了变化, 变化从何时开始?
Driver 节点	Volume, Price, Take Rate, Margin, Capex, Retention	事件首先改变企业经营链条中的哪个变量?
公司反应节点	提价, 降价, 扩产, 回购, 削减成本, 调整渠道	公司会怎样响应外部变化?
经济终端节点	Revenue, EPS, FCF, Multiple, Scenario Probability	这条路径最终应该交给哪个经济变量的负责人?

证据节点还应该区分不同状态. 一个节点可以是已经观察到的事实, 也可以是根据事实作出的推断, 尚未被证据激活的理论路径, 或者暂时无法判断的未解决问题.

“管理层声称需求仍然强劲” 首先只是一个有来源的 claim; 只有当订单, 收入, 客户行为或者其他独立证据与之相符时, 它才可能进一步支持需求状态的判断.

Driver Tree 和 Company Event Graph 在这里承担不同任务. Driver Tree 更像一张相对稳定的经营骨架, 说明企业通常怎样从业务活动走向收入和利润. Company Event Graph 则是附着在骨架上的动态证据层, 说明当前究竟发生了什么, 以及哪些路径已经被证据激活.

例如对支付网络公司, Driver Tree 中可能长期存在

$$\text{Payment Volume} \longrightarrow \text{Revenue} \longrightarrow \text{Operating Profit} \longrightarrow \text{EPS}.$$

如果出现竞争加剧和客户激励上升的事件, 当前的活动路径可能变成

$$\begin{aligned} \text{Competition} \uparrow &\longrightarrow \text{Client Incentives} \uparrow \\ &\longrightarrow \text{Net Take Rate} \downarrow \\ &\longrightarrow \text{Revenue and Margin} \downarrow \\ &\longrightarrow \text{EPS}_{\text{Bear}} \downarrow. \end{aligned}$$

最后一条边只表示这项证据应该进入 Bear 情景的盈利变量, 无法据此直接确定 EPS_{Bear} 的数值.

一条完整的传导边至少应该说明: 传导机制是什么, 方向为正, 负还是混合, 可能存在多长时滞, 影响是一次性的还是持续的, 当前有哪些支持和反对证据, 以及这条边处于活动, 理论还是未解决状态. 因此一条边除箭头外, 还应至少带有类似

$$e = (\text{mechanism, sign, lag, persistence, status, 归属路径})$$

这样的标签.

Owner Route 与 Single Count 研究图常产生一种虚假的丰富感: 同一个风险在多个地方反复出现, 于是看起来好像有很多条独立的坏消息.

例如竞争恶化可能同时出现在行业分析, Driver Tree, Bear Case, 风险清单和组合风险说明中. 如果每出现一次就再扣一次价值, 或者再提高一次 Bear 概率, 同一件事情就被重复计算了.

定义 8.11 (Owner Route).

Owner Route 是一条经济影响的唯一主要归属路径. 这里的 owner 指负责作出某类经济判断的归属环节, leg 指一个已经标准化的经济影响单元.

图中的每个重要经济或风险影响单元都应该被交给一个明确的判断环节, 例如情景价格, 情景概率, 损失分类, carry, 无法可靠量化的风险登记, 未来观察触发器或者仅作参考.

图负责把证据送到这个归属环节, 但不代替归属环节作出数值判断.

常见的归属路径可以整理为:

归属路径	适合处理的问题	不应自动变成
scenario_level	改变某个情景中的盈利, 现金流或估值水平	第二次概率调整或额外风险扣减
scenario_probability	改变不同情景之间的概率分配	直接改变情景价格
loss_or_carry	区分损失机制或记录一次性的 carry	已经进入价格的第二份收益或损失
censored_register	记录重要但暂时无法可靠量化的风险	为了完整而强行制造一个数字
watch_trigger	指定未来需要重新观察的事件	当前概率, 当前结论或自动阻塞
context_only	保存组合或市场环境背景	通用的第二份 D

命题 8.12 (Single Count).

同一个标准化经济影响单元只能拥有一条主要经济路径.

多个来源可以共同支持同一个影响单元, 同一个根事件也可以通过彼此不同的机制产生多个影响单元; 但证据数量, 路径数量和图中的出现次数都不能自动制造额外的收益或风险.

可以把这个原则写成一个函数

$$\omega_t: L_t \longrightarrow \mathcal{O},$$

其中 L_t 是时刻 t 的标准化经济影响单元集合, $\mathcal{O}$ 是经济归属环节集合. 函数条件保证每个标准化经济影响单元在当前研究结构中只有一个主要归属. 如果同一个根事件真的产生了两个机制完全不同的影响, 就先拆成两个不同的影响单元, 再分别送入对应的经济路线.

例如同一项技术采用可能一方面提高产品收入, 另一方面增加外部算力成本. 只要两条路径的机制和经济变量确实不同, 它们可以分别进入收入和利润率. 但如果三份报告都在描述同一次成本上升, 这只是对同一个成本影响单元的交叉验证, 不能被算成三份下行风险.

Scenario Packet, Price State 与 Replay Company Event Graph 位于证据与最终研究结论之间. 它先把证据送到正确的归属环节, 再由这些归属环节形成几个可以长期保存和重新计算的对象.

定义 8.13 (Scenario Packet).

Scenario Packet 是一组经过审查的情景对象.

它保存 Bull, Base, Bear 和 Tail 的代表性价格或估值, 情景概率, 核心假设, 主要证据, 可证伪条件, 研究置信度, 有效期限以及需要重新审查的触发条件.

Scenario Packet 除情景价格外, 还保存 “在什么世界中为什么会得到什么结果”.

定义 8.14 (Price State).

Price State 记录截至某个时点的市场价格, 价格在当前情景结构中的相对位置, 研究所使用的价格时间戳, 以及维持研究, 重新审查或判定信息失效的边界.

Price State 仅属于研究状态; 限价单, 目标仓位和执行指令由后续环节生成.

由于市场价格会变, 即使 Scenario Packet 没有改变, 同一组情景相对于现价的 R/D 也可能明显变化. 因此基本面情景和当前价格状态需要分别保存.

定义 8.15 (Replay Bundle).

Replay Bundle 是用于重新计算 R/D 和 EV 的输入包.

它保存已经接受的情景价格与概率, 原始金融下行与损失机制分类, 与情景收益使用同一计价单位, 期限和资本基数的情景 carry, 更长期恢复路径的概率, 时间和约束假设, 研究期限, 公司在组合中的角色, 组合风险档位和最低收益要求, 以及对应的 Price State. 同时, 它还记录这些输入的来源, 版本, 复核状态, 有效期限, 刷新条件, 以及允许和禁止的下游用途. 这样以后重新计算时, 才能知道每个输入为什么可用, 又会在什么条件下失效.

它冻结可重放的输入和判断来源. 每次使用都须重新计算 R/D, 不能无条件继承过去的结果.

于是可以把一套研究状态粗略写成

$$\text{RDView}_t = \Psi(\Pi_t, P_t, a),$$

其中 Π_t 表示时刻 t 可用的 Scenario Packet, P_t 表示当时的 Price State, a 表示明确的计算约定和用途. 这里的 RDView_t 是一种临时视图: 它可以服务于研究验证或者组合比较, 但不应该脱离原始情景和版本关系, 变成永久有效的单一分数.

上一节的最小教学模型仍可作为这里的简化形式. 上一节的 R_P 和 D_P 只是为了说明概率加权上行和下行的基本思想. 真实研究里还会有更复杂的情景价格生成, 损失机制分类, carry, 置信度, 有效期和下游使用边界. Agentic R-D-G 保存这些判断的来源和归属, 便于复查, 数值仍由相应研究环节给出.

例如, 一条证据经过归属路径进入情景 s 的经营变量以后, 可以抽象地写成

$$x_s = F_s(d_s), \quad S_s(T) = \mathcal{V}_s(x_s; \theta_s).$$

这里 d_s 是情景 s 下被接受的经营驱动输入, F_s 是从经营驱动到财务变量的预测环节, $\mathcal{V}_s$ 是从财务变量到情景价格的估值环节. 图说明 d_s 的来源, 以及哪些证据应进入 F_s 或 $\mathcal{V}_s$. F_s 和 $\mathcal{V}_s$ 仍由基本面判断确定.

在作者的完整 R/D 体系中, 下行还会进一步按机制区分为暂时性损失和永久性损失. 这种分类解释损失路径, 但不改变指定研究期限上已经出现的金融损失金额. 设

$$r_s = \frac{S_s(T) - S_0}{S_0},$$

并令 c_s 表示情景 s 在同一研究区间 $[0, T]$ 内的净 carry 收益率. c_s 必须与 r_s 使用同一计价货币, 同一研究期限和同一资本基数. 若股息, 融资成本, 费用或其他现金流已经进入 $S_s(T)$ 的总回报口径或上游现金账本, 就不得再次进入 c_s . 定义总情景金融收益率

$$\rho_s = r_s + c_s.$$

则指定期限上的概率加权上行与原始金融下行分别为

$$R_{\text{fin},T} = \sum_s p_s(\rho_s)^+, \quad D_{\text{raw},T} = \sum_s p_s(-\rho_s)^+.$$

如果仍需记录损失机制, 可以令每个下行情景满足 $\lambda_{s,\text{temp}} + \lambda_{s,\text{perm}} = 1$, 并写成

$$D_{\text{temp},T} = \sum_s p_s(-\rho_s)^+ \lambda_{s,\text{temp}}, \quad D_{\text{perm},T} = \sum_s p_s(-\rho_s)^+ \lambda_{s,\text{perm}}.$$

这里必有

$$D_{\text{temp},T} + D_{\text{perm},T} = D_{\text{raw},T};$$

暂时性标签不能折减 $D_{\text{raw},T}$. 于是金融期望值为

$$\text{EV}_{\text{fin},T} = R_{\text{fin},T} - D_{\text{raw},T} = \sum_s p_s \rho_s.$$

当 $D_{\text{raw},T} > 0$ 时, 金融 R/D 才定义为

$$\text{R/D}_{\text{fin},T} = \frac{R_{\text{fin},T}}{D_{\text{raw},T}}.$$

若研究者认为某个损失以后能够恢复, 应另建 $T' > T$ 的恢复路径, 明确恢复概率, 所需时间, 期间融资与流动性成本, 以及被迫提前退出的条件, 再用 T' 的情景现金流重新计算金融 EV 和 R/D. 不能用一个折减系数回写并减少期限 T 上已经发生的损失.

注 8.16.

这一组公式属于本文作者体系中的一种实现方式, 不具有一般金融学定理的地位. 它把情景价格, 情景概率, 原始金融下行, 损失机制和情景 carry 分开放置, 使每个输入都能被追踪和重新审查.

一个极简支付平台例子 继续使用支付网络或支付平台的例子. 假设我们观察到三条信息:

信息	可能传导	Owner Route	处置
支付金额继续增长	Volume 上升, Revenue 上升	scenario_level	进入 Bull/Base 的收入和 EPS 假设
客户激励上升	Net Take Rate 下降, Margin 下降	scenario_level	进入 Bear 的利润率假设, 不再额外加一次 D
监管讨论升温	可能影响定价或业务范围, 但证据尚不充分	censored_register 或 watch_trigger	保留为需要观察的风险, 不强行制造精确概率

例 8.17.

在这个例子里, 同一项客户激励上升的风险如果已经通过利润率下降进入 Bear 情景价格, 就不应该再作为独立风险额外提高 Bear 概率, 或者再给 R/D 加上一份通用折扣。

如果监管讨论目前只有标题和市场传闻, 它可以成为观察触发器或无法量化风险登记, 但不应该为了让图看起来完整, 就被强行转成一个具体的损失数字。

这个小例子展示了 R-D-G 的用法: 图标明每条信息应该进入哪里, 哪些地方已经计入, 哪些地方仍然只是待观察的风险. 这些被接受的处置随后才会进入 Scenario Packet, Price State 或 Replay Bundle, 供之后重新计算临时的 R/D 视图。

为何使用 Agent 这个角色不应在图上随意添加节点, 更不能根据节点数量自动得出结论. 它的用处来自研究规模. 如果只研究一家公司, 研究者可以手工维护一张事件表, 偶尔更新几条假设. 但如果同时跟踪许多公司, 再把它们和宏观事件, 政策变化, 行业主题, 预测市场信号以及组合暴露连接起来, 图的规模很快就会变得难以手工维护。

研究图也远比普通关系图复杂. 节点和路径带有来源, 时间, 状态和经济归属路径, 整张图还要保存单次计数, 版本关系和重新审查条件. 它既要能画出来, 也要支持事后审计: 某个判断来自哪里, 什么时候进入图, 经过哪些中间路径, 有没有被重复计数, 以及哪些下游对象应该因为新信息而重新检查。

固定程序适合格式校验, 重复检查和确定性的表格转换. 语境则需要判断: 一条新闻可能是同一事件的新证据, 也可能构成新事件; 一条预测市场价格可能只表示市场注意力, 也可能满足某个概率归属环节的输入条件; 一条风险还可能已经进入情景价格, 或仍停留在观察清单。

原则 8.18.

Agentic R-D-G 中的 Agent 承担维护和审计职责. 经济判断仍由相应研究环节作出, 图上不设置自动打分器。

它的主要任务是维护大规模研究图的可追溯性, 检查证据来源, 版本关系, 归属路径, 单次计数和下游复查对象, 并把需要重新判断的变量交还给相应的研究归属环节。

这种结构的价值来自可追溯性: 图中的节点和边具有稳定标识, 证据带有来源和时间, 路径带有状态和归属路径, 而研究对象带有版本, 有效期和更新条件. Agent 因而可以定位新信息的影响范围, 无须每次从头重写整篇研究报告。

使用时须守住三条界线. 第一, 图谱只表示研究状态, 不描述市场运动定律. 第二, 单次研究只能读取经过来源, 版本, 允许用途和禁止用途约束的局部语境, 不能把全局图当作任意背景知识吸收. 第三, 若新证据可能改变已经接受的市场图谱状态, 须先固定证据, 再将其归类为旧事件的新证据, 新的候选事件, 或需要退役或替换的事件状态. 在普通研究中, 这种刷新只构成本轮研究范围内的临时校准, 不会改动已经接受的市场图. 只有在单独的图谱维护任务中, 经过来源核验, 版本审查和下游影响检查, 并将全部变更作为完整版本发布以后, 变化才进入下一版正式图谱。

上述过程只描述研究状态的更新次序: 从新证据开始, 识别受影响的节点和边, 再沿着图找到需要重新审查的下游对象. 如果 $\Delta V_{t+1}^{(i)}$ 表示公司 i 的局部图中被新信息直接改变的节点集合, 那么需要复查的对象可以粗略写成

$$\mathcal{D}_{t+1}^{(i)} \subseteq \text{Desc}_{G_t^{(i)}}(\Delta V_{t+1}^{(i)}) \cup \text{RouteChange}_{t+1}^{(i)}.$$

这里 $\text{RouteChange}_{t+1}^{(i)}$ 捕捉路径变更: 如果某个事件被退役, 替换或改变绑定, 还要检查旧路径和新路径的并集, 避免只沿旧图的后继对象走一遍而漏掉撤回影响. $\mathcal{D}_{t+1}^{(i)}$ 只定义需要复查的对象集合, 不触发数值沿图自动传播. 复查顺序是: 核验证据, 改变节点状态, 激活或关闭边, 标记受影响的下游对象, 再由对应归属环节重做判断。

例如一条新的行业需求数据可能只改变 Volume 路径; 一项监管政策可能同时影响定价, 成本和市场准入; 一份新的财报则可能直接否定某条原本活动的边。

Agent 在这里适合完成几件事情: 追踪证据来源, 寻找受影响的下游路径, 检查同一风险是否被重复计算, 发现已经过期或仍未解决的节点, 以及把需要重新判断的变量交还给正确的归属环节。

节点的中心性, 来源数量和路径数量不直接决定经济权重. 图的拓扑结构首先代表研究结构, 不天然等于概率, 价值或者风险大小。

与实际研究流程的对应 上述抽象对应一条受约束的研究流程。这里仅保留与本节概念有关的顺序。一次完整研究先冻结经过预处理的数据集，再把证据，未解决问题，来源和允许用途分配给具体的分析切片。如果本轮研究需要图谱语境，已经接受的 Event Graph 或 Market Graph 谱系会先被投影成有版本的图谱语境，再绑定到对应分析切片中。

实际研究的粗略流程为

原始证据 → 核验并固定本轮数据 → 按问题提取语境
 → 分析与反方检验 → 必要时核对预测市场
 → 更新本轮公司图 → 形成情景输入
 → 重新计算 → 验证。

如果写成局部记号，其中一条路径可以是

$\mathcal{E}_t^{(i)}, K_t^{(i)} \rightarrow \text{分析与对峙} \rightarrow \text{预测市场处置}$
 $\rightarrow G_{t,\text{run}}^{(i)} \rightarrow \text{归属交接}$
 $\rightarrow \Pi_t^{(i)} \rightarrow \text{RDView}_t^{(i)}.$

这里 $\mathcal{E}_t^{(i)}$ 表示公司证据， $K_t^{(i)}$ 表示从已接受市场图谱中按当前问题读出的局部语境， $G_{t,\text{run}}^{(i)}$ 是分析，对峙和预测市场处置以后形成的本轮公司图， $\Pi_t^{(i)}$ 表示公司 i 的情景输入包。这个顺序把分析置于图的生成之前。本轮公司图组织已经接受的证据和归属交接，经营 Driver 与经济输入仍由分析产生。

图谱范围判断在三种处理之间选择：读取既有语境，在研究范围内进行影子刷新，或单独进入图谱维护任务。如果确实需要刷新，也要先冻结增量数据，再进入图谱语境验收和最终绑定。

图谱语境必须带有明确边界。每一条被保留的语境都应说明：它来自哪一版已接受图谱，面向哪个研究问题，可以用到什么程度，以及哪些用途仍然被排除。如果一条语境没有明确服务的判断，或者只能作为背景，就应明确写成背景，缺口，重复项或本轮研究范围之外，不得直接进入估值。

Prediction Market 只在出现明确的事件型外部市场问题时介入。只有当分析和对峙以后确实出现新的或变化的事件型外部市场问题，而且这个问题有明确消费者时，才会进行额外的预测市场搜索。如果没有这样的事件问题，则保留已有图谱谱系，并记录未进行搜索的处置；形式上的公司关键词搜索没有研究价值。

流程末端由情景一致性，情景价格，回放输入包和验证负责守住经济判断的边界。图谱可以把证据送到相应归属环节，但不能自己创造情景价格，不能自己决定公司情景概率，也不能把某次保存下来的 R/D 或 EV 数字变成永久权威。长期保存的是可重放的输入，版本关系和使用边界；R/D 与 EV 更像是在给定 Price State 和 Scenario Packet 以后临时计算出来的视图。

边界与随机过程接口 Agentic R-D-G 的下游需要保留两道明确边界。

第一道是研究与组合管理的边界。研究层提供 Scenario Packet, Price State 和 Replay Bundle。组合层可以在当前组合状态和当前价格下重新计算临时的 R/D 与 EV 视图，然后结合组合角色，集中度，流动性和风险暴露作出判断。

原始 Market Graph 不直接作为组合管理输入。只有当专门的市场环境或组合风险汇总环节在本轮范围内时，它们才可以消费带有来源和用途边界的图谱语境，并输出组合层可以读取的市场语境。图谱维护本身不解释组合结论，也不触发仓位或交易动作。

组合层不得为了得到某个组合答案而修改研究层的情景价格，情景概率或者损失分类。图分数也不能机械转换成目标仓位，Kelly 比例，固定档位或者自动填满某个仓位上限。

第二道是组合判断与执行的边界。即使研究和组合判断已经完成，订单仍须由独立的执行流程生成。Price State 中的区间只描述研究边界；Watch Trigger 只启动复查；Scenario Packet 中的 Bull 或 Bear 价格只表示情景结果，均不直接生成交易指令。

注 8.19.

Prediction Market 的输出止于外部市场信号；Market Graph 的输出止于可路由的市场语境；Company Event Graph 的输出止于公司传导与归属；Scenario Packet 的输出止于情景输入；Replay Bundle 的输出止于可重放的计算输入。

各环节只能消费经过允许的输出生，不能用全局语境改写局部证据，也不能用市场盘口替代基本面判断。

回到本节开头的记号并恢复被省略的 ω 后, 价格 S_t , 指数水平或者几个情景标签都是从市场样本空间中读出的低维随机变量. 相比之下, $M_t(\omega)$ 是一个更高信息保留的图值读出. 公司 Event Graph $G_t^{(i)}(\omega)$ 可以看成全局市场状态在公司 i 上的局部观测; 把许多 $G_t^{(i)}(\omega)$ 粘接成 $M_t(\omega)$ 则像是把局部截面粘成一个整体对象.

在开头约定的共同概率空间和图空间可测结构下, 由于每个 M_t 和 $G_t^{(i)}$ 都是 $\mathcal{F}_t$ -可测的, 可以把 $(M_t)_{t \geq 0}$ 和 $(G_t^{(i)})_{t \geq 0}$ 看成图值随机过程. 这里暂不作完整形式化, 图中的边也不应解释为转移概率或 Markov 核. 研究结论在这里表现为动态状态: 它随信息流更新, 并保留审计和回放所需的状态.

Risk-Reward 负责压缩未来, Company Event Graph 负责解释公司传导, Prediction Market 提供市场注意力和合约价格对象, Market Graph 则帮助观察市场季风, 风险堆积, 并作为语境回流到公司研究. Risk-Reward 使结果可以比较; 两类图则使结果可以解释, 更新和审查.

第九章 趋势交易与技术指标：从路径变换到可交易策略

一条真实价格路径通常同时包含缓慢变化，短期波动，跳跃和测量噪声。技术指标所做的第一件事，是把这条路径压缩成较少的数字：某个近期水平，某种变化速度，一段局部波动，或者一个成交量加权位置。

可以跟着一条完整交易链来读这些数字。这条链延续了第六章中的“路径—信息—行动—损益—现金与财富”顺序：

价格记录 → 指标 → 信号 → 目标持仓 → 订单与成交 → 执行成本 → 净损益。

每一步都会改变结论。一个指标看起来很漂亮，到了目标持仓可能变得很小；一个信号方向正确，到了实际成交可能已经付出点差，滑点和冲击；一条路径总体向上，若价格在阈值附近反复穿越，也可能被频繁调仓成本磨成亏损。

简单移动平均 (simple moving average, SMA)，指数移动平均 (exponential moving average, EMA)，移动平均收敛发散指标 (moving average convergence divergence, MACD)，Bollinger Bands，相对强弱指标 (relative strength index, RSI)，平均真实波幅 (average true range, ATR) 和成交量加权平均价格 (volume-weighted average price, VWAP) 只是对平滑，差分，局部尺度和成交量汇总的不同组合。它们的公式说明压缩方式；预测和可交易性要到样本外，成本，融资，风险与执行检验中再回答。

9.1 从指标到账本

读这一章时，可以把下面几件事串成一条线：

1. 区分事后看见的趋势，可检验的统计依赖，潜在市场状态和扣除成本后的可交易净优势；
2. 把技术指标写成历史路径的适应变换，并把下一期持仓写成可预测决策；
3. 准确计算 SMA, EMA, MACD, Bollinger Bands, RSI, ATR 和 VWAP，同时说明每种口径的初始化与适用范围；
4. 把信号，目标持仓，调仓订单，实际成交，费用，融资，结算与最终损益逐层分开；
5. 使用随机游走，AR(1)，潜在状态，异方差和跳跃模型解释指标可能有用或失效的条件；
6. 并列阅读趋势与技术指标研究中的正面结果，样本外失效，漂移反例和模型条件；
7. 设计不偷看未来的样本外检验，并识别换手，滑点，数据窥探和多重检验造成的伪优势；
8. 明白趋势跟随是一项策略，不属于资产属性；指标研究与基本价值研究也相互独立。

第一次阅读只跟随图9.1中的一条价格记录：先看输入口径和信息时点，再看指标怎样产生信号与目标持仓，最后把订单，成交，成本和净损益一起放进账本。




图 9.1: 趋势交易的一条最小阅读路线。

随机过程模型，文献争议和样本外检验随后回答两个更深的问题：图形何时只是随机路径的正常形状，何时才值得继续研究成可执行策略。期货连续序列的数据模式，订单管理状态机和逐事件现金账本属于实现接口；第一遍可以只记住它们在交易链中的位置。

原则 9.1 (先把链条写完整).

先把指标放回交易链, 再讨论它可能支持什么结论. 若证据只说明某种价格动态, 结论就停在价格过程层面; 若要进入策略层面, 还要给出信息时点, 持仓映射, 成交规则, 成本账本和样本外表现.

9.2 先区分四种趋势

“这段价格正在上涨”可能混用四个不同命题.

定义 9.2 (路径趋势, 统计依赖, 潜在状态与可交易净优势).

给定截至时刻 t 的可观察历史, 我们区分:

1. **路径趋势**: 事后观察到某段价格大体单向移动, 或某个平滑量具有正斜率;
2. **统计依赖**: 在预先规定的总体, 时钟与条件下, 过去变量对未来收益分布含有可重复的信息;
3. **潜在状态**: 一个未被直接观察的持久状态影响漂移, 波动率, 流动性或跳跃强度;
4. **可交易净优势**: 一条事前固定, 可执行的规则在扣除点差, 滑点, 冲击, 费用和融资后, 仍具有与其风险相匹配的样本外表现.

例如, 某指数在六个月里上涨了 12%, 只能直接确认这段样本具有路径趋势. 若要声称过去走势含有统计信息, 还要在事前规定的资产集合和时期中检验未来条件分布. 若进一步把结果解释成某种持久市场状态, 还要说明该状态怎样影响收益, 波动率或流动性, 以及其他机制能否产生同样图形. 最后, 只有当一条事前规则能够成交, 并在扣除成本和风险以后仍有样本外表现时, 讨论才到达可交易净优势这一层. 同一张上涨图不能替代后面三层证据.

路径趋势最容易看见, 却是四层中最弱的一层. 一条独立增量的随机游走也会反复出现长短不一的上升段和下降段. 统计依赖比图形更强, 但可能小到不足以覆盖成本. 潜在状态提供一种可能的生成解释, 却通常不能由单一指标识别. 可交易净优势最接近交易者关心的结论, 也承担最多的实施条件.

这四层之间最容易出错的地方, 可以压成几条断点:

图上存在趋势 $\not\Rightarrow$ 未来收益可预测,
未来收益有统计依赖 $\not\Rightarrow$ 扣费后可交易,
某模型能产生趋势 $\not\Rightarrow$ 现实由该模型生成,
一段回测赚钱 $\not\Rightarrow$ 规则在样本外稳定.

最后一个断点尤其重要. 指标只是信号的原料; 从信号到损益还隔着持仓映射, 风险预算, 订单, 成交与结算. 多年交易经验往往主要体现在这些断点的处理上; 只记住更多指标名称远远不够.

9.3 离散交易时钟, 信息集与可预测持仓

先定义所使用的价格记录 令交易决策时点为 $t = 0, 1, \dots, T$. 现实中的“价格”至少还要指定单位, 方向, 数量, 场所, 账户, 时间和结算条款. 为了讲清指标, 这里暂时把经过这些条件筛选后, 可以在时刻 t 观察的统一价格记录记为 $S_t \in \mathbb{R}$, 把同步可得的成交量记为 V_t . 这种记号压缩暂时忽略口径差异; 最新成交价, 中间价, 收盘价和给定数量的可执行价仍各有含义.

若使用收盘数据, 还要说明是原始收盘价, 拆股调整价, 还是包含现金分配再投资的总回报序列. 公司行为处理方式改变时, 均线, 收益率, 突破和波动率都会改变. 跨市场比较还需要统一币种, 交易日历与时区. 指标公式替代不了清楚的输入定义.

图9.2给出一个直接例子. 若把拆分前后的名义报价不加调整地拼接, 2020 年的 4:1 拆分会看起来像一次约 75% 的价格崩跌, 并让 20 日均线在随后约一个窗口长度内缓慢消化这个机械断点. 拆分调整后的序列消除了股数单位变化, 但这仍不等于已经决定了现金分配, 税务和总回报的全部口径.




图 9.2: AAPL 2020 年 4:1 拆分前后的输入口径与 20 日 SMA。灰色为按 4:1 拆分比例复原的当时名义报价, 蓝色为拆分调整后的收盘价; 机械断点会制造虚假的收益, 突破和均线滞后。数据与拆分事件来源见引用文献 [Yaha]。

期货与远期数据还要先区分实际合约记录和合成连续序列。下面的数据模式只针对期货和远期的历史重放。如果读者目前只使用股票或指数日线, 可以直接跳到对数价格与收益口径。先处理合成连续曲线和当时真正可交易合约之间的关系, 然后再进入指标公式。一份可重放的最小数据模式可以写成

$$D_t^{\text{fut/fwd}} = (\text{kind}_t, \iota_t, T_t^{\text{exp}}, M_t, \text{ccy}_t, \mathcal{R}_t^{\text{PIT}}, \mathcal{A}_t^{\text{adj}}, S_t^{\text{signal}}, R_{t,t+1}^{\text{tradable}}).$$

这里 kind_t 声明记录是实际合约还是合成连续序列, ι_t 是当时选中的实际合约标识, T_t^{exp} 是到期日, M_t 是合约乘数或名义金额换算, ccy_t 是报价与结算币种。 $\mathcal{R}_t^{\text{PIT}}$ 是只使用时刻 t 已可得信息的换月规则, $\mathcal{A}_t^{\text{adj}}$ 明确不调整, 差额后复权, 比例复权或其他拼接方法。按事后完整成交量或持仓量选择整段历史主力合约会偷看未来。

合成连续序列可以服务于指标输入 S_t^{signal} ; 逐点成交仍要回到当时实际存在的合约。可交易收益 $R_{t,t+1}^{\text{tradable}}$ 要由当时实际持有的合约, 合约乘数, 真实换月成交与一个明确资本基数重建, 不能直接把后复权连续价格的变化当作可实现收益。同一数据模式还要保存抵押品收益, 变动保证金现金流, 外汇换算和换月交易成本; 这些现金流若已经进入可交易收益或现金账本, 就不能再次扣加。

当 $S_t > 0$ 时, 定义对数价格和一期对数价格变化

$$X_t = \log S_t, \quad \ell_t = X_t - X_{t-1} = \log \frac{S_t}{S_{t-1}}.$$

价格水平, 价格变化, 简单收益和含分配总收益是不同对象。后面的公式会明确输入是 S_t , X_t 还是 ℓ_t , 不把它们统称为“收益率”。后文用 r_t 讨论策略或文献中的收益时, 会另行说明它是简单收益, 总收益还是扣除融资后的超额收益; 组合收益公式不把对数价格变化当作可以按权重精确相加的简单收益。若某个报价在所用窗口内可能等于或小于零, X_t 和对数变化就没有定义。此时要按照工具合约选择价格差乘合约乘数得到的算术损益, 或以明确资本基数定义的总收益或超额收益序列。不能为得到对数而给整条报价路径任意加上常数, 因为这种平移会改变信号和经济含义。

指标适应, 持仓可预测 令 $\mathcal{F}_t$ 包含截至时刻 t 已经可用且时间戳可靠的信息. 技术指标可以统一写成

$$I_t = f_t(S_0, V_0, \dots, S_t, V_t),$$

其中 f_t 是定义在相应历史路径空间上的可测函数, 因而 I_t 是 $\mathcal{F}_t$ -可测的. 第4.3节给出这类信息集和适应性的抽象定义; 第6.2节则说明它怎样进入离散交易账本. 这个事实只说明指标没有使用时刻 t 以后才出现的数据, 不说明它能够预测未来.

若 q_{t+1}^* 表示希望在下一交易区间承担价格变化的目标持仓, 则合格规则应满足

$$q_{t+1}^* = g_t(I_0, \dots, I_t), \quad q_{t+1}^* \text{ 是 } \mathcal{F}_t\text{-可测的.}$$

下一段持仓要在下一段不确定价格变化发生以前决定. 这就是离散时间中可预测性的核心. 实际订单和成交还可能晚于决定时点, 所以成交后实际持仓 q_{t+1} 不必等于 q_{t+1}^* ; 回测还应记录成交数量和执行价 P_{t+1}^{exec} . 把 S_t 自动当作成交价会跳过执行层.

例 9.3 (当前收盘信号与当前收盘成交不是同一时点).

假设日线策略在交易所正式收盘以后取得 S_t , 再计算 I_t . 那么它可以决定下一交易日的订单, 却不能在普通连续交易已经结束后声称自己按同一个 S_t 成交. 一个诚实回测可以使用下一日开盘价, 下一日可执行报价, 或者在规则中明确收盘集合竞价的订单截止时间并只用截止前已经可用的信息.

另一种做法是用 I_{t-1} 决定时刻 t 收盘前的持仓. 两种时钟都可以, 关键是事前固定; 回测以后再移动成交时点, 实验对象就已经改变.

注 9.4 (停损规则定义触发, 退出价格另算).

由当前和历史价格触发的退出时刻可以构成停时, 但“价格第一次低于阈值”和“最终在阈值成交”是两件事. 跳空, 停牌, 流动性撤出, 订单排队和滑点都可能使实际退出价越过阈值. 因此停损限制的是规则继续持有的条件, 退出现金流还要由真实成交决定.

策略收益的条件期望恒等式 令 r_{t+1} 是已经明确口径的下一期简单, 总回报或超额收益, H_t 是用于承担这项收益的 $\mathcal{F}_t$ -可测无量纲仓位权重或标准化风险暴露. 假设 H_t, r_{t+1} 与 $H_t r_{t+1}$ 均可积. 在物理测度 $\mathbb{P}$ 下, 条件期望的塔式性质给出

$$\mathbb{E}_{\mathbb{P}}[H_t r_{t+1}] = \mathbb{E}_{\mathbb{P}}[H_t \mathbb{E}_{\mathbb{P}}(r_{t+1} \mid \mathcal{F}_t)]. \quad (9.1)$$

这个恒等式把两个经常混在一起的问题分开了: H_t 是否利用历史信息改变了下一期条件均值, 以及 H_t 是否只是承担了一个本来就存在的平均收益暴露. 这里使用的是第3.4.2小节的塔式性质; 它检验 $\mathbb{P}$ 下的条件预测, 不是第7.7.5小节中的无套利定价条件.

例如, 若

$$r_{t+1} = \mu + \varepsilon_{t+1}, \quad \mathbb{E}_{\mathbb{P}}(\varepsilon_{t+1} \mid \mathcal{F}_t) = 0,$$

则任何仅由历史构成的 H_t 都满足

$$\mathbb{E}_{\mathbb{P}}[H_t r_{t+1}] = \mu \mathbb{E}_{\mathbb{P}}[H_t].$$

历史指标没有增加超越常数漂移 μ 的条件预测信息; 但只要策略平均保持正的方向暴露, 它仍可能收获这一漂移或风险溢价. 于是“策略平均赚钱”本身既不能证明过去收益预测了未来收益, 也不能说明收益来自择时. 比较时至少要同时报告平均净暴露, 相对买入持有或常数方向基准的增量, 以及条件预测是否真的随 $\mathcal{F}_t$ 改变.

这里讨论预测时使用的是现实概率规律 $\mathbb{P}$. 无套利定价中使用的定价测度 $\mathbb{Q}$ 回答的是另一个问题: 在适当计价物和技术条件下, 以该计价物为单位的含分配累计收益过程应为 $\mathbb{Q}$ -局部鞅; 只有附加相应可积性以后才能升级为真鞅. 这里的对象是除息价格加上按同一计价口径累计的分配; “含分配价格”仍需给出单独定义. $\mathbb{Q}$ 下的局部鞅条件不能直接替代 $\mathbb{P}$ 下的收益预测检验; 现实数据偏离简单随机游走, 也不自动构成套利, 因为风险补偿, 交易成本, 融资限制, 模型误设和策略可容许性都仍需处理.

9.4 滤波的统一语言：平滑、时滞与尺度

技术指标中最常见的操作是滤波。令 Y_t 表示被滤波的输入；它可以是价格，对数价格，收益，成交量或其他已经定义的序列。这一节先不谈买卖。读者可以只问一个问题：指标到底从历史路径里取走了什么，又故意丢掉了什么。平滑会丢掉一部分短期噪声，但也会制造时滞；差分会突出变化，但也会放大噪声；标准化会消除尺度，但会引入窗口和方差估计口径。

简单移动平均 长度为 n 的简单移动平均 (simple moving average, SMA) 为

$$M_t^{(n)} = \frac{1}{n} \sum_{j=0}^{n-1} Y_{t-j}, \quad t \geq n-1.$$

它给最近 n 个观测相同权重，更早数据权重为零。窗口从 $t-n+1$ 到 t 是否包含当前观测必须写清。滚动实现还需要处理前 $n-1$ 个观测：可以输出缺失值，也可以使用较短窗口。不同的初始化方法会产生不同指标。

SMA 会降低高频抖动，代价是延迟。对于线性变化 $Y_t = a + bt$ ，长窗口均线大约落后当前值 $b(n-1)/2$ ；因为窗口中观测的平均年龄是 $(n-1)/2$ 。这解释了为什么加长窗口同时减少假动作和延后转向，两个效果不能只保留其中一个。

指数移动平均，半衰期和有效窗口 取 $0 < \alpha \leq 1$ ，指数移动平均 (exponential moving average, EMA) 递推为

$$E_t^{(\alpha)} = \alpha Y_t + (1 - \alpha) E_{t-1}^{(\alpha)}.$$

展开递推可以看见它的权重：

$$E_t^{(\alpha)} = \alpha \sum_{j=0}^{t-1} (1 - \alpha)^j Y_{t-j} + (1 - \alpha)^t E_0^{(\alpha)}.$$

无限历史近似下，年龄为 j 的观测权重为 $\alpha(1 - \alpha)^j$ 。常见“跨度”参数 n 使用

$$\alpha = \frac{2}{n+1},$$

而 Wilder 平滑使用 $\alpha = 1/n$ ；同一个数字 n 在两种口径中并不代表同样快慢。

EMA 的半衰期由权重下降一半的年龄给出：

$$h_{1/2} = \frac{\log(1/2)}{\log(1 - \alpha)}.$$

若用独立同方差观测下的方差等价，或者用与 SMA 相同的平均数据年龄来定义有效窗口，都得到

$$n_{\text{eff}} \approx \frac{2 - \alpha}{\alpha} = \frac{2}{\alpha} - 1.$$

这里的“有效”只是比较滤波器记忆长度的约定，不代表金融数据真的独立同分布。

EMA 总要有一个起点。令 $E_0 = Y_0$ 很方便，用前 n 个观测的均值初始化则更接近成熟窗口；也可以使用经过偏差修正的归一化权重。初始化差异会在最初若干半衰期内留下痕迹，所以回溯应给足预热期，并核对软件包的具体实现。

图9.3把同一个 20 日记忆尺度放到真实 SPY 路径上。两条滤波线都比原价格平滑，但转向发生时都只能在新数据逐步进入以后改变方向。EMA 把更大权重放在近期数据上，因而通常比同跨度 SMA 更快响应；这种更快响应同时意味着它会保留更多短期波动。下方面板的价格减滤波值把“时滞”变成可见的差额，也显示这个误差的方向会变化。




图 9.3: SPY 在 2021-01-04–2022-12-30 的拆分与现金分配调整收盘价, 20 日 SMA 和跨度为 20 的 EMA. 黑色为价格, 蓝色为 SMA, 暖橙色虚线为 EMA; 下图给出价格与两种滤波值之差, 用来显示平滑与时滞的权衡. 数据来源见引用文献 [Yahb; Yahc].

价格水平, 收益口径与稳定性 对价格水平做均线并没有数学错误, 但价格水平常带有趋势, 拆分, 币种与制度变化, 其均值和方差未必随时间稳定. 价格减均线的绝对差也随价格尺度扩大: 价格从 10 变成 1000 后, 同样的 \$1 偏离不再具有相同含义.

当 $M_t^{(n)} \neq 0$ 时, 常见改进包括使用相对距离

$$d_t = \frac{S_t - M_t^{(n)}}{M_t^{(n)}},$$

在价格严格为正时使用对数价格差, 或直接用收益 r_t 建模. 但收益序列也不自动平稳: 波动率聚集, 跳跃, 状态切换与微观结构噪声仍然会破坏简单假设. 选择输入本身就是研究问题, 超出了数据清洗的机械步骤.

9.5 从滤波器到趋势规则

滤波器本身只产生一条新的历史序列. 趋势规则多了一步: 把这条历史序列和某个阈值, 符号或排序规则比较, 再把比较结果映射为下一期目标持仓. 所以从这里开始, 读者要把“指标值是多少”和“下一期持有什么”分开看. 下面只写信号原型; 等号, 阈值, 空头是否允许, 缺失数据和最大持仓都应在正式策略中另行固定.

价格—均线规则 以价格 SMA 为例, 收盘后信号可以写成

$$z_t^{\text{PM}} = \text{sign}(S_t - M_t^{(n)}),$$

再令目标持仓 $q_{t+1}^* = g(z_t^{\text{PM}})$. 它测量当前价格相对近期平均水平的位置, 不直接测量未来漂移. 若均线包含 S_t , 当前冲击会同时影响比较式两边, 这是规则本身的一部分.

快慢均线交叉 令 $\alpha_f > \alpha_s$, 则快速 EMA 对新信息反应更快. 交叉信号为

$$z_t^{\text{cross}} = \text{sign}(E_t^{(\alpha_f)} - E_t^{(\alpha_s)}).$$

二者之差是同一输入经过两个低通滤波器后的差. 低通滤波器会压低较快波动并保留较慢变化, 所以这个差突出一段中间尺度的变化. 它不等于两个独立证据, 也不会消除共同输入中的噪声.

时间序列动量 当窗口内每个价格都严格为正时, 长度为 k 的对数时间序列动量可以定义为

$$m_t^{(k)} = X_t - X_{t-k} = \log \frac{S_t}{S_{t-k}}, \quad z_t^{\text{mom}} = \text{sign}(m_t^{(k)}).$$

若窗口包含零或负报价, 这个对数动量不可用. 应改用适合该工具的算术损益或超额收益序列, 例如期货价格差乘合约乘数后再除以明确的资本基数, 而不能任意平移报价来制造正数. 它直接比较当前价格与 k 期前价格. 实践中常把信号强度除以事前波动率估计, 但波动率缩放改变的是风险规模, 不会凭空提高方向预测准确率.

突破与 Donchian 式区间 如果信号在时刻 t 计算, 应先定义不包含当前价格的过去窗口

$$U_{t-1}^{(n)} = \max_{1 \leq j \leq n} S_{t-j}, \quad L_{t-1}^{(n)} = \min_{1 \leq j \leq n} S_{t-j}.$$

这是基于单一价格记录 S_t 的滚动极值区间. 标准 Donchian 通道通常分别用窗口内的最高价记录 H_t 和最低价记录 L_t 构造上下轨:

$$U_{t-1, \text{std}}^{(n)} = \max_{1 \leq j \leq n} H_{t-j}, \quad L_{t-1, \text{std}}^{(n)} = \min_{1 \leq j \leq n} L_{t-j}.$$

这里保留单一价格记录, 用于突出突破规则的时间索引; 两种输入口径仍需分别定义. 于是向上突破事件为 $S_t > U_{t-1}^{(n)}$, 向下突破为 $S_t < L_{t-1}^{(n)}$. 如果把 S_t 先放进窗口再要求 S_t 严格大于窗口最大值, 事件永远不会发生; 这是实现中很常见的索引错误. 突破说明当前观测超出最近区间, 不保证其后继续运行.

收益移动平均的连续仓位分解 一个有用但适用范围很窄的计算是把过去 N 期收益的平均值直接作为连续仓位. 令收益序列具有有限二阶矩并且弱平稳, 满足 $\mathbb{E}[r_t] = \mu$, $\gamma(i) = \text{Cov}(r_{t-i}, r_t)$, 并定义

$$m_{t-1}^{(N)} = \frac{1}{N} \sum_{i=1}^N r_{t-i}.$$

若策略一期毛损益恰为 $m_{t-1}^{(N)} r_t$, 则

$$\mathbb{E}[m_{t-1}^{(N)} r_t] = \mu^2 + \frac{1}{N} \sum_{i=1}^N \gamma(i). \quad (9.2)$$

第一项来自无条件平均收益, 第二项才汇总窗口内的序列协方差 [FSY19]. 即使收益独立, 所有 $\gamma(i) = 0$, 只要 $\mu \neq 0$, 这个连续仓位策略仍可能有正的期望毛收益; 这再次说明正收益不自动等于时变预测.

式 (9.2) 只适用于仓位等于收益移动平均这一连续映射. 若仓位是 $\text{sign}(m_{t-1}^{(N)})$, 带阈值的离散仓位, 价格均线信号或经过波动率缩放和杠杆截断的仓位, 期望损益会变成另一个非线性对象, 不能套用该分解.

同名趋势策略对应不同实验 文献和软件把很多不同实验都简称为动量, 均线或趋势跟随. 比较结果以前, 至少应逐项对齐:

维度	一种实验	另一种实验	不可混用的原因
输入	价格与价格均线比较	过去收益的均值或累计和	权重, 尺度与公司行为敏感性不同
仓位映射	$\{-1, 0, 1\}$ 符号或阈值仓位	随信号幅度变化的连续仓位	非线性符号策略不满足连续仓位分解
收益口径	原始价格收益	扣除现金利率或融资后的超额收益	平均漂移和可融资损益不同
比较基准	空仓或零收益	买入持有, 历史均值方向或常数暴露	相对空仓盈利不等于择时增值
风险分配	等名义, 等权配置	逆波动率缩放, 组合目标波动率	组合结果同时受风险预算和分散影响
成本口径	毛收益	扣除点差, 滑点, 冲击, 融资与费用的净收益	高频换手可能使两者结论相反

专业系统中的“EMA 动量”常由多条尺度不同的滤波线组合. Baz et al. [Baz+15] 给出一个具体例子: 先由三组快慢 EWMA 的差构造多尺度信号, 对各信号作运行波动尺度归一化, 再经过非线性响应函数和加权合成. 同一组合信号随后既可以映射成各资产自身的方向仓位, 也可以映射成横截面排序后的多空仓位; 其经验设计还区分日频二元信号与月频线性信号, 而报告的业绩没有扣除交易成本. 这些结果还不足以说明这种构造优于简单均线; 它们提醒我们分别报告信号公式, 仓位映射, 组合几何和调仓频率. 只说“使用 EMA”还不足以定义一项可以复现的策略.

信号, 持仓与成交是三层对象 一项完整策略至少有下面八层:




图 9.4: 从市场路径到含成本策略损益.

例如 $z_t = 1$ 可以只表示“方向为正”, 目标持仓却可能因波动率, 杠杆上限, 流动性和现有库存而在 0 到某个上限之间变化. 读到这里可以先停一下: 指标先变成目标持仓, 目标持仓再经过订单, 成交和现金账变成净损益. 下面的活动订单余量和逐事件账本用于防止重复下单与重复记账, 属于实现层接口. 它们不改变指标定义, 也不提供指标有效性的证据.

一个不偷看未来的完整小例 考虑一个只做多或空仓的示意规则. 每天收盘后计算三日 SMA:

$$M_t^{(3)} = \frac{C_{t-2} + C_{t-1} + C_t}{3}.$$

若 $C_t > M_t^{(3)}$, 目标持仓 $q_{t+1}^* = 1$; 否则 $q_{t+1}^* = 0$. 目标在下一日开盘 O_{t+1} 执行, 并持有到再下一日开盘. 为了只展示信息时钟, 本例额外假设目标数量都能在该开盘价完全成交, 因而实际持仓满足 $q_{t+1} = q_{t+1}^*$; 现实中这一步要由成交回报决定. 单边成交成本取成交名义金额的 $\kappa = 0.1\%$, 初始实际持仓 $q_2 = 0$. 接下来的数据只展示时钟和算术.

决策日 t	收盘 C_t	三日 SMA	$C_t - M_t^{(3)}$	q_{t+1}^*	下一开盘 O_{t+1}
2	103.00	101.33	1.67	1	103.20
3	102.00	102.00	0.00	0	101.80
4	104.00	103.00	1.00	1	104.30
5	105.00	103.67	1.33	1	105.10
6	104.00	104.33	-0.33	0	104.40

每个决策日对应的开盘到开盘净损益为

$$\Delta \Pi_{t+1} = q_{t+1}(O_{t+2} - O_{t+1}) - \kappa O_{t+1} |q_{t+1} - q_t|.$$

最后一行的新持仓为零, 所以不需要知道 O_8 才能计算其价格损益. 逐段结果为:

决策 t	持仓 q_{t+1}	区间开盘	下一开盘	毛损益	成本	净损益
2	1	103.20	101.80	-1.40	0.1032	-1.5032
3	0	101.80	104.30	0.00	0.1018	-0.1018
4	1	104.30	105.10	0.80	0.1043	0.6957
5	1	105.10	104.40	-0.70	0.0000	-0.7000
6	0	104.40	—	0.00	0.1044	-0.1044
合计				-1.30	0.4137	-1.7137

这个例子保留了五个容易在回测中消失的事实. 第一, 决策使用 C_t , 成交使用后来才出现的 O_{t+1} . 第二, 信号为正不保证下一段价格上涨. 第三, 从多头变空仓也要成交并付费. 第四, 持仓不变时没有调仓成本, 但仍承担价格风险. 第五, 几段收盘价总体向上并不保证具体执行路径盈利. 现实中还要加入买卖价差, 部分成交, 分红, 融资, 税与结算.

读完这个例子后, 就可以回头看实现层如何防止重复下单和重复记账. 只有在没有任何在途或活动订单时, 新订单数量才是目标持仓与已确认持仓之差. 令 $q_t^{\text{confirmed}}$ 是根据已确认成交得到的持仓. $\mathcal{O}_t^{\text{live/pending}}$ 是订单管理系统根据活动订单以及尚未确认的新单, 撤单和改单状态, 投影出的仍可能成交的有效订单分支集合. 对订单 j , 令 $\epsilon_j = +1$ 表示买入, $\epsilon_j = -1$ 表示卖出, $\text{LeavesQty}_{j,t}$ 表示尚可能成交的剩余数量, 并定义带符号的活动订单余量

$$L_t^{\text{live}} = \sum_{j \in \mathcal{O}_t^{\text{live/pending}}} \epsilon_j \text{LeavesQty}_{j,t}.$$

投影有效持仓与待发送的新订单数量应为

$$q_t^{\text{projected}} = q_t^{\text{confirmed}} + L_t^{\text{live}}, \quad \Delta q_t^{\text{new}} = q_{t+1}^* - q_t^{\text{projected}}.$$

一笔新订单在等待接受或拒绝回报时, 本地系统应把已发送数量视为潜在活动余量, 以免重复下单. 一笔撤单在撤单确认到达前仍可能成交, 所以原订单余量继续计入 L_t^{live} . 一笔改单在确认前要按场所语义只保留一个有效分支, 同时计入旧数量和替换数量会重复计算; 改单被拒时原订单通常仍然有效, 新订单被拒时才移除相应在途余量. 每个部分成交回报同时更新已确认持仓和订单余量. 经过这一状态机以后, Δq_t^{new} 还要经过手数取整, 卖空可借券, 保证金, 价格带, 风险限额和交易时段检查才可发送. 实际成交又可能因为限价, 深度和排队只完成一部分. 第7.8节和第7.8.8小节讨论的点差, 滑点与冲击, 正是在信号之后进入 [AC01; Har02; Has07].

若 q_t 是在区间 $(t-1, t]$ 持有的单位数, 一个最简离散自融资近似为

$$\Delta \Pi_t = q_t(S_t - S_{t-1}) + q_t D_t - C_t^{\text{trade}} - C_t^{\text{funding}} - O_t^{\text{other}},$$

其中 q_t 需要在时刻 $t-1$ 已知, D_t 是该单位在区间内实际取得的分配. 若使用标记价而非退出成交价, 要说明损益中仍含未实现标记. 进入价格, 退出所得, 费用和融资也要避免重复扣减.

真实实现应把这个近似展开成与第7.1.5小节和第6.6节一致的逐事件现金账本. 若成交事件 e 的带符号成交量为 Δq_e^{fill} , 买入为正, 卖出为负, 则可以写成

$$\begin{aligned} q_e^{\text{confirmed}} &= q_{e-}^{\text{confirmed}} + \Delta q_e^{\text{fill}}, \\ C_e &= C_{e-} - p_e^{\text{exec}} \Delta q_e^{\text{fill}} - f_e^{\text{trade}} + d_e^{\text{cash}} + f_e^{\text{funding,net}} + m_e^{\text{VM}} + o_e^{\text{cash}} + \Delta A_e^{\text{external}}, \\ V_e &= C_e + MV_e(q_e^{\text{confirmed}}). \end{aligned}$$

这里除交易费用 $f_e^{\text{trade}} \geq 0$ 外, 其余现金流都按实际流入为正记录. d_e^{cash} 是分配, $f_e^{\text{funding,net}}$ 是融资净现金流, m_e^{VM} 是变动保证金现金流, o_e^{cash} 汇总仍未归类但已定义的现金项目, $\Delta A_e^{\text{external}}$ 是外部净注资. MV_e 是按已经声明的标记规则得到的未平仓头寸价值; 对普通现货它可以是 $q_e^{\text{confirmed}} S_e^{\text{mark}}$. 期货报价代表合约价格尺度, 买入合约时通常无需支付等额资产价款; 逐日变动保证金已经入账时, 剩余合约价值要按清算规则标记; 再用期货报价乘持仓会重复计算同一损益. 目标仓位, 未成交订单和撤改单请求不直接进入现金账本; 只有成交或实际现金事件改变 $q_e^{\text{confirmed}}$ 或 C_e . 计算策略损益时按第7.1.5小节的口径从财富变化中剔除累计外部净注资, 并确保每笔成交, 费用, 分配和保证金现金流只入账一次.

9.6 常见指标: 准确公式与有限含义

接下来始终对同一份已经定义好的价格或成交记录提问. 这节的读法不是先问哪个指标最能赚钱, 而是先问每个数字到底在测量什么. SMA 和 EMA 问历史水平怎样被平滑, MACD 问两种记忆长度相差多少, Bollinger Bands 问当前位置相对近期离散尺度有多远, RSI 问近期正负变化幅度怎样分配, ATR 问价格柱和跳空覆盖了多大范围, VWAP 问指定窗口内成交量集中在哪些价格. 这些量回答不同问题, 即使同时画在一张图上, 也不因此成为相互独立的预测证据.

MACD: 两个指数滤波器之差 给定快速, 慢速和信号跨度 $n_f < n_s$ 与 n_{sig} , 令

$$\begin{aligned} \text{MACD}_t &= E_t^{(\alpha_f)}(S) - E_t^{(\alpha_s)}(S), \\ \text{Signal}_t &= E_t^{(\alpha_{\text{sig}})}(\text{MACD}), \\ \text{Hist}_t &= \text{MACD}_t - \text{Signal}_t, \end{aligned}$$

其中通常 $\alpha_j = 2/(n_j + 1)$. 常见跨度是 (12, 26, 9), 但这些数字只是约定, 没有自然常数的地位.

MACD 衡量快慢 EMA 的相对位置; Signal 再平滑 MACD; Histogram 是二者之差. Histogram 容易与成交量直方图混淆, 实际含义仍是前两者之差; 没有额外条件时也不是价格“加速度”. 由于 MACD 使用价格绝对单位, 不同价格尺度的证券不能直接比较; 可以改用百分比版本, 但那已经是另一个指标. 三个递推量都受初始化和预热期影响.

Bollinger Bands 与滚动标准化分数 这里明确采用窗口总体方差口径. 令

$$\begin{aligned} M_t^{(n)} &= \frac{1}{n} \sum_{j=0}^{n-1} S_{t-j}, \\ \hat{\sigma}_{t,n}^2 &= \frac{1}{n} \sum_{j=0}^{n-1} (S_{t-j} - M_t^{(n)})^2, \\ B_{t,\pm} &= M_t^{(n)} \pm k \hat{\sigma}_{t,n}. \end{aligned}$$

当 $\hat{\sigma}_{t,n} > 0$ 时, 滚动分数为

$$z_t^{(n)} = \frac{S_t - M_t^{(n)}}{\hat{\sigma}_{t,n}}.$$

有些软件使用分母 $n-1$, 有些使用 n ; 小窗口时差异不可忽略. 若窗口内价格完全相同, $\hat{\sigma}_{t,n} = 0$, 此时 z_t 未定义, 不应由程序产生无穷大信号.

“价格越过两倍标准差带”不等于“发生了正态分布下约 5% 的事件”. 窗口均值和方差由同一重叠价格样本估计, 价格水平也未必平稳或正态. 带宽主要描述近期价格离散程度; 向外突破既可被趋势规则解释成延续, 也可被均值回归规则解释成反转. 指标本身没有决定交易方向.

RSI: 上涨与下跌幅度的 Wilder 平滑比 令 $\Delta S_t = S_t - S_{t-1}$, 并定义

$$G_t = \max(\Delta S_t, 0), \quad L_t = \max(-\Delta S_t, 0).$$

对长度 n , 先用前 n 个变化初始化

$$\bar{G}_n = \frac{1}{n} \sum_{j=1}^n G_j, \quad \bar{L}_n = \frac{1}{n} \sum_{j=1}^n L_j,$$

之后使用 Wilder 平滑

$$\bar{G}_t = \frac{(n-1)\bar{G}_{t-1} + G_t}{n},$$

$$\bar{L}_t = \frac{(n-1)\bar{L}_{t-1} + L_t}{n}.$$

为避免先计算比值造成零分母, 可以直接写成

$$\text{RSI}_t = 100 \frac{\bar{G}_t}{\bar{G}_t + \bar{L}_t}.$$

当 $\bar{L}_t = 0 < \bar{G}_t$ 时 RSI 为 100; 当 $\bar{G}_t = 0 < \bar{L}_t$ 时为 0; 二者同时为零时这里约定为 50, 但不同数据供应商可能采用沿用前值等其他约定.

RSI 衡量近期正负价格变化幅度的相对占比. 它并不直接给出上涨概率或价格“超买”, “超卖”状态; 强趋势中 RSI 可以长时间停留在高位或低位. 若把阈值当交易规则, 仍需另行说明顺势还是逆势, 触发还是穿越, 下一期何时成交.

真实波幅与 ATR 令 H_t, L_t, C_t 分别为第 t 个价格柱的最高, 最低和收盘价. 真实波幅为

$$\text{TR}_t = \max\{H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|\}.$$

它把隔夜跳空纳入单期范围. 初始化口径先固定下来: 数据需要先提供窗口前收盘价 C_0 , 于是第一个有效真实波幅是由 (H_1, L_1, C_0) 得到的 TR_1 . 用 $\text{TR}_1, \dots, \text{TR}_n$ 初始化

$$\text{ATR}_n = \frac{1}{n} \sum_{j=1}^n \text{TR}_j,$$

再对 $t \geq n+1$ 按

$$\text{ATR}_t = \frac{(n-1)\text{ATR}_{t-1} + \text{TR}_t}{n}$$

更新. 在 $t < n$ 的热身期不输出 ATR 信号. 如果数据集首根价格柱没有前收盘价, 该柱的 TR 在本口径下记为缺失, 若静默改成 $H_0 - L_0$ 并把它算入初始化窗口, 口径已经改变. 这同样是 $\alpha = 1/n$ 的 Wilder 平滑; 它与跨度为 n 的标准 EMA 有不同的参数映射.

ATR 测量价格单位下的近期范围与跳空幅度, 不测方向. 除以价格可得到相对尺度; 未来最大损失, 可成交滑点或完整波动率模型仍需另行估计. 拆股与异常价格柱若未正确调整, 会产生虚假的巨大 ATR.

VWAP: 成交基准而非自动预测器 对一个明确交易时段 W 内的逐笔成交, 不仅要记录价格 p_i 和数量 v_i , 还要区分成交事件时间 τ_i 与研究系统可见该记录的时间 a_i . 固定 eligible-trade 规则以后, 定义截至决策时刻 t 可用的合格成交集合

$$\mathcal{E}_t(W) = \{i : a_i \leq t, \tau_i \in W, e_i(t) = 1\},$$

其中 $e_i(t)$ 只根据时刻 t 已到达的成交条件码, 撤销和更正消息确定. eligible-trade 规则要预先声明场所范围, 使用综合市场还是主市场口径, 是否包含开收盘竞价, 场外成交和碎股, 接受哪些成交条件码, 以及撤销和更正怎样生效. 在这些约定下, 成交量加权平均价格为

$$\text{VWAP}_t = \frac{\sum_{i \in \mathcal{E}_t(W)} p_i v_i}{\sum_{i \in \mathcal{E}_t(W)} v_i},$$

前提是分母为正. 它通常在每个交易日或指定执行窗口重置. 若只有价格柱数据, 常见代理是典型价 $TP_j = (H_j + L_j + C_j)/3$ 与柱成交量的加权平均:

$$\widetilde{VWAP}_t = \frac{\sum_{j \leq t} TP_j V_j}{\sum_{j \leq t} V_j}.$$

后者只能给出柱级近似 VWAP, 因为柱内成交价格与成交量的共同分布已经丢失. 柱数据本身也要由同一 eligible-trade 规则按当时可用记录聚合. 若把后来发布的撤销, 更正或最终清洗结果追溯应用到当时尚不可得的决策时点, VWAP 基准和由它产生的信号就含有前视信息.

VWAP 首先是一项指定窗口内“市场成交在哪里发生”的基准, 常用于评价执行结果. 它不自动预测下一笔价格. 自己的大额订单还可能改变成交量与价格路径, 因此相对 VWAP 的好坏必须结合方向, 订单规模, 市场参与率和基准选择解释.

一张分类表

指标	主要测量	没有直接测量	典型陷阱
SMA / EMA	历史水平的平滑位置与不同记忆长度	未来收益, 基本价值, 可执行价格	忽略初始化; 把降噪当预测; 用当前收盘信号假成交于当前收盘
MACD	快慢指数滤波器之差及其再平滑	成交量, 因果机制, 无条件“加速度”	跨价格尺度直接比较; 软件跨度与 α 口径不一致
Bollinger / z	当前价格相对滚动中心和离散程度的位置	固定尾部概率, 方向, 长期均衡价值	混用 n 与 $n - 1$; 零方差; 把越带自动解释成反转
RSI	平滑后上涨与下跌幅度的相对占比	上涨概率, 绝对波动, 必然反转点	混用 Wilder 与标准 EMA; 零分母; 阈值方向未定义
ATR	含跳空的近期价格范围尺度	方向, 尾部上限, 给定订单的滑点	公司行为未调整; 把历史范围当未来保证
VWAP	指定窗口内成交价格的量加权中心	基本价值, 下一期方向, 自己的反事实执行价	忘记日内重置; 把柱代理当逐笔真值; 忽略订单对市场的影响

9.7 随机过程怎样给趋势规则提供基准

前面已经形成一条基本链条: 指标怎样计算, 信号怎样变成目标持仓, 目标持仓又怎样进入成交和现金账. 下一步才轮到随机过程: 它不是替代回测, 而是提供几个清楚的基准世界, 帮助我们分辨一张趋势图究竟只是随机路径的常见形状, 还是可能指向可检验的条件信息. 第4.5节提供无可预测条件均值漂移的基准, 第5.5节则提供连续状态模型的基本写法.

随机游走与 GBM: 图形会自然出现 最简单的对数价格随机游走为

$$X_t = X_{t-1} + \mu + \varepsilon_t, \quad \mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0,$$

其中增量可以独立同分布. 在这个基准下, 过去价格仍会产生均线交叉, 突破, RSI 极值和看似整齐的趋势段; 这些形状来自随机路径的正常波动, 这本身还不是模型错误证据. 当 μ 为常数且增量独立时, 过去图形不会提供超出常数漂移以外的下一期条件均值信息.

连续时间中, 若 W 是相对于 $(\mathcal{F}_t)$ 的 Brown 运动, 则几何 Brown 运动

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t$$

也会产生丰富图形. 它适合作为正价格, 连续路径和乘法噪声的基准, 却不包含状态切换, 厚尾, 跳跃, 波动率聚集与订单簿. 模型下指标没有额外条件预测力, 不等于现实中必然没有; 它只是一个等待数据和机制去比较的基准世界.

AR(1) 收益：延续与反转的最小模型 令收益满足平稳 AR(1)

$$r_t - \bar{r} = \phi(r_{t-1} - \bar{r}) + \varepsilon_t, \quad |\phi| < 1,$$

且 $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0$. 于是

$$\mathbb{E}[r_t | \mathcal{F}_{t-1}] = \bar{r} + \phi(r_{t-1} - \bar{r}).$$

当 $\phi > 0$ 时, 偏离均值的收益在短期有延续; 当 $\phi < 0$ 时, 它更倾向反向. 这个模型说明过去收益何时可能有条件信息, 也说明“趋势”依赖时间尺度. 即使 $\phi > 0$, 信号强度仍可能小于点差与换手成本; 即使样本估计为正, 参数也可能随制度和参与者变化.

漂移, 潜在状态, 异方差与跳跃 更一般地可以写成

$$r_t = \mu(Z_t) + \sigma_t \varepsilon_t + J_t,$$

其中 Z_t 是不可直接观察的市场状态, σ_t 是时变波动尺度, J_t 是偶发跳跃. 若 Z_t 具有持久性, 历史路径可能帮助滤出当前状态; 若 σ_t 聚集, 同样大小的信号在不同时期承担不同风险; 若 J_t 来自公告, 流动性断裂或制度变化, 旧窗口平均可能迅速失效.

指标只能作为估计这些状态的一项输入. 不同机制也可能产生相同指标值: 稳定的信息扩散, 被迫去杠杆后的反弹, 做市库存调整 and 一笔价格跳跃, 都可能让快均线高于慢均线. 只有额外数据, 可证伪假设和样本外检验, 才能逐步区分解释.

原则 9.5 (模型提供基准, 现实机制需要证据).

一个模型能够复现均线交叉或收益持续性, 说明该机制足以产生这些现象; 现实中是否正由这个机制生成, 还要回到数据, 市场结构和拒绝条件. 反过来, 一个理想模型不支持技术指标, 也只是在该模型的假设下给出反例. 模型选择应跟随问题, 数据与拒绝条件.

9.8 研究文献支持到哪一步

趋势与技术指标文献并没有给出一个跨市场, 跨频率的统一判决. 读这些论文时, 最好先问它究竟走到了交易链的哪一层: 只是发现条件分布差异, 还是已经固定持仓映射, 是否扣除了成本, 有没有真正样本外. 不同研究使用不同预测对象, 规则族, 风险缩放, 成本口径和样本外基准; 看似相反的结果有时检验的是不同命题. 接下来把正面证据, 反例和模型解释并列放置, 只保留各研究设计能够支持的结论.

从图形信息到策略净收益 Lo, Mamaysky, and Wang [LMW00] 在 1962–1996 年 NYSE/AMEX 与 Nasdaq 股票日数据上, 用非参数核回归平滑价格路径并把若干图形形态转成可重复的识别规则. 论文的主设定取 $l = 35$ 和 $d = 3$, 因而每个识别窗口包含 38 个交易日; 其中 d 是形态完成到算法识别之间的识别滞后, 与交易者另设的“三日确认”规则无关. 论文在完成识别以后再考察下一日条件收益分布与无条件分布的差异. 其结果支持某些形态对条件收益分布含有增量信息, 但作者明确区分“统计信息”与“扣除成本后的超额交易利润”: 识别算法, 持有期, 损失函数与执行规则尚未被条件分布差异唯一确定. 因此这项研究支持的是条件分布差异, 下一步还要把规则, 持有期, 成本和执行补齐.

Neely et al. [Nee+14] 研究的是月度 S&P 500 股权风险溢价, 样本为 1950:12–2011:12. 他们把六个均线指标, 两个动量指标与六个成交量指标共十四项技术信号用于预测, 递归样本外期为 1966:01–2011:12. 相对历史均值预测基准, 十四个单指标的全样本样本外 R^2 都为正, 技术指标主成分的样本外 R^2 为 0.65%; 但改善主要集中在事后识别的 NBER 衰退月份, 扩张期的主成分预测反而落后于历史均值. 论文还在其均值—方差资产配置, 仓位约束与固定比例成本设定下得到正的确定性等价收益增量. 这项实验先把指标映射为风险溢价预测, 再据此配置连续股票权重; 它没有直接按二元指标满仓回测. 因此它是“特定月度对象, 特定预测基准和特定决策问题”的正面证据, 不能直接外推到个股日内指标, 另一成本制度或任何参数组合.

跨资产趋势跟随的正面证据及其设计条件 Moskowitz, Ooi, and Pedersen [MOP12] 的主样本包含 58 个流动性较高的股指, 货币, 商品和债券期货或远期市场, 覆盖 1985–2009 年. 论文的核心月度组合以过去 12 个月超额收益的符号决定下一月方向, 再按事前波动率作逆向缩放. 与此同时, 论文的预测回归在 1–12 个月滞后上报告收益延续证据. 因而“12 个月信号窗口”与“1–12 个月的证据范围”是两个不同对象, 不能把后者写成核心策略在 1–12 个月窗口之间切换. 这里的“时间序列动量收益”是信号, 逆波动率风险分配和跨市场分散共同作用的组合结果; 主结果没有扣除交易成本, 因而不能直接当作可实现净收益.

Hurst, Ooi, and Pedersen [HOP17] 把历史研究扩展到 67 个市场和 1880–2016 年, 组合 1, 3, 12 个月方向信号, 对头寸作等风险配置并把组合缩放到 10% 事前目标波动率. 论文还模拟扣除交易成本与 2/20 费用后的结果. 其长样本结论依赖早期市场序列和交易规则的历史重建; 估计成本与逐笔可执行成交仍有差距, 某些时期也没有完整展期成本. 由于 Ooi 和 Pedersen 与前述研究重合, 两篇论文也处在同一研究谱系中. 这项长样本工作属于同一作者与研究谱系的历史扩展, 独立性有限. 它增加了时间与市场覆盖, 同时把可复制性问题留给具体市场, 成本和执行口径.

数据窥探校正与盈利来源 在 Brock, Lakonishok, and LeBaron [BLL92] 的均线 and 交易区间突破规则背景上, Sullivan, Timmermann, and White [STW99] 把规则空间扩展到 7,846 项, 使用 White Reality Check 处理从整个规则族中挑选最佳结果造成的数据窥探. DJIA 的 1897–1986 年旧样本结论在规则族校正后仍有证据, 但据此选出的最佳规则在 1987–1996 年样本外时期失效. 针对 DJIA 收盘报价可能不同步的问题, 论文另作一日执行延迟检验: 第 t 日观察信号, 到第 $t+1$ 日才执行. 最佳规则的年均收益由 17.2% 降至 7.8%, 相应 Sharpe 检验不再显著. 这个一日延迟结果属于 DJIA 实验, 不能移植到另一组 S&P 500 期货检验. DJIA 部分没有纳入分红, 历史卖空可行性也存疑, 且缺少覆盖百年样本的真实交易成本序列. 论文另以 1984–1996 年 S&P 500 期货作比较, 部分理由正是分红不再构成同一问题, 做空更容易且成本相对有限; 该期货样本没有发现任一规则取得超额表现. 因而分红, 卖空和成本限制应归于 DJIA 结果的适用范围, 不能笼统套在两个实验上. 这里提及前一研究只为说明被重新检验的历史背景, 细节结论以后续完整再检验为界.

这项区分可以写成两个不同问题. 令 T_j 表示规则 j 的绩效检验统计量, T_j^{obs} 表示样本中的观测值, $\Pr_0$ 表示全部候选规则在联合零假设下的概率规律. 若规则 j 在看数据以前已经固定, 它的名义 p 值考察

$$\Pr_0(T_j \geq T_j^{\text{obs}}).$$

若研究者实际从规则族 $\mathcal{J}$ 中选择最大统计量, 相关概率应针对类似

$$\Pr_0\left(\max_{j \in \mathcal{J}} T_j \geq \max_{j \in \mathcal{J}} T_j^{\text{obs}}\right)$$

的选择事件, 并保留规则之间的依赖结构. 把最终赢家当成唯一事前规则所报告的普通 p 值, 回答不了第二个问题.

Huang et al. [Hua+20] 以 55 个期货与远期资产的 1985–2015 年月度超额收益, 重新检验“过去 12 个月收益预测下一月收益”的时间序列动量. 论文报告 55 个单资产中有 47 个的检验统计量达不到其 10% 显著性门槛, 汇总统计量在 bootstrap 校正后也不显著. 更关键的对照是 historical-sign 策略 (TSH): 它只根据资产历史样本均值的符号保持方向, 不需要过去 12 个月偏差对下一月的时变预测, 却得到与时间序列动量 (TSM) 相近的成本前表现. 策略比较没有扣除交易成本. 这个反例说明一条策略盈利可以来自平均风险溢价, 方向暴露和风险缩放; 从损益回推预测能力时, 需要先把这些来源拆开.

用模型分解机制, 再回到经验识别 Grebenkov and Serror [GS14] 在特定高斯价格模型中研究过去收益的 EMA 连续信号及其损益分布. 模型允许把持久趋势, 噪声, 记忆尺度和成本的作用分开; 在独立零均值收益这一基准下, 策略期望损益仍为零, 但“过去信号乘当前收益”的二次结构可以产生非高斯, 右偏的损益分布. 因此正偏或少数大盈利需要和现实中的趋势预测证据分开辨认, 文中的最优尺度也只在模型和参数条件下成立.

式 (9.2) 概括了 Ferreira, Silva, and Yen [FSY19] 对收益移动平均连续仓位的一项分解: 期望毛损益同时包含 μ^2 和序列协方差. 它有助于辨认漂移暴露, 但论文中的连续仓位对象不能直接替代常见的符号仓位策略, 也没有自动解决成本, 执行和非平稳性.

Zakamulin and Giner [ZG20] 进一步说明, 价格动量和价格—移动平均规则都能改写成过去收益的不同加权和. 两类指标高度相似甚至可以在随机游走样本中出现; 这种代数或样本路径相似性只能说明它们共享滤波结构, 仍不足以证明未来收益可预测. 论文在特定自回归设定下比较两类规则的预测稳健性, 其结论仍依赖所选动态模型, 不能被解释成某一指标普遍优越.

原则 9.6 (证据层级要按顺序走).

恒等式说明损益由什么组成, 模型说明某种机制足以产生什么现象, 历史样本说明某项设计曾经出现什么结果, 样本外和成本检验才逐步接近可执行结论. 上述文献在这些层级上既有互相支持也有直接冲突; 用一个层级的正面结果替代另一个层级尚未完成的检验, 会跳过真正需要回答的问题.

9.9 指标相同, 状态可以不同

考虑两个五日收盘路径:

$$A = (97, 98, 99, 101, 105),$$

$$B = (103, 99, 96, 97, 105).$$

二者当前价格都是 105, 五日 SMA 都是 100, 因而价格—均线偏离都等于 5%. 如果规则只看这个指标, 它们会产生相同信号.

然而路径 A 是逐步上行, 路径 B 先下跌再跳升; 二者的近期范围, 缺口, 订单流和可能的信息事件完全可以不同. 若 A 来自低波动的持久漂移状态, 而 B 来自高波动状态中的一次短暂流动性冲击, 它们的下一期条件分布不会因为同一个 5% 偏离而相同. 反过来, 仅凭这五个数字也不能断言上述状态确实存在.

这个反例说明指标是一种有损压缩. 压缩便于比较和执行, 也必然丢失路径细节. 增加 ATR, 成交量或更高频数据可以恢复一部分信息, 但同时增加参数, 估计误差和数据窥探空间; 不存在靠不断叠加指标就自动得到真实状态的保证.

9.10 从漂亮回测到可信检验

先写净损益, 再谈收益表现 正式研究至少应分列. 令 D^{dist} 表示持有期实际收到的分红, 利息或其他现金分配, 则

$$\begin{aligned} \Pi^{\text{net}} = & \Pi^{\text{mark/exit}} + D^{\text{dist}} - C^{\text{spread}} - C^{\text{slippage}} - C^{\text{impact}} \\ & - C^{\text{fees}} - C^{\text{funding}} - C^{\text{other}}. \end{aligned}$$

同一成本只扣一次. 若退出价格只是中间价标记, 它还不是已实现现金. 策略的换手

$$\text{UnitTurnover} = \sum_t |q_{t+1} - q_t|$$

在 q_t 表示单位数时, UnitTurnover 只表示“交易了多少单位”. 得到无量纲换手率还要结合账户资本与成交名义金额. 若时刻 t 的调仓把实际持仓从 q_t 改为 q_{t+1} , 账户调仓前净资产为 A_{t-} , 实际单位成交价为 S_t^{exec} , 一种货币名义换手口径是

$$\text{Turnover}^{\text{notional}} = \sum_t \frac{S_t^{\text{exec}} |q_{t+1} - q_t|}{A_{t-}},$$

合约还要乘合约乘数, 跨币种头寸还要按当时汇率换算. 无论采用哪种口径, 它都只是成本敏感度的第一近似, 真实冲击还依赖订单规模, 市场深度, 参与率和交易方向.

换手由信号设计内生决定. Baltas and Kosowski [BK20] 比较了不同波动率估计器与趋势强度映射所对应的换手, 并在期货成本模型中把换月成本与再平衡成本分开. 更平滑的估计器或仓位映射可能减少订单和估计成本, 对方向预测准确性却没有直接含义. 回测至少要把信号触发的再平衡, 合约到期带来的换月和组合层风险缩放分别记账, 再按对应市场与时期估计成本.

点差和滑点可能在波动放大时同时恶化; 用全样本平均成本回填每一天往往过于乐观. 容量随资金规模和市场深度变化: 资金规模增加会改变订单和市场之间的关系. 执行假设应与当时可见的报价, 成交量和交易制度相容, 参见第7.8节和第7.8.8小节.

波动率缩放, 杠杆和路径风险 为了让不同时间的名义风险更接近, 趋势策略常采用

$$|w_{t+1}^*| \propto \frac{\sigma^{\text{target}}}{\hat{\sigma}_t},$$

其中 w_{t+1}^* 是下一期目标名义权重或风险暴露, 再加持仓和杠杆上限. 若实际交易变量是资产单位数 q_{t+1}^* , 还要用账户资本, 价格, 合约乘数与汇率把权重换成单位数. 这里 $\hat{\sigma}_t$ 要只使用截至 t 的信息. 缩放可以减少高波动期的名义头寸, 它属于风险分配规则, 与方向信号分层. 对多资产组合, 可以把一期简单或超额毛收益概念性地写成

$$R_{t+1}^{\text{port}} = \sum_{i=1}^d w_{i,t} z_{i,t} r_{i,t+1},$$

其中 $z_{i,t}$ 是方向信号, $w_{i,t}$ 包含逆波动率权重, 资产间风险预算和组合层缩放. 最终表现同时来自信号, 风险分配与跨资产分散; 只看到组合夏普率就把全部结果归因于 $z_{i,t}$ 的方向预测, 会过度解释. 缩放也不保证实现波动率等于目标: 波动率估计会滞后, 跳跃会越过连续调整, 多资产相关性也可能在压力期变化.

这种区分具有直接的实证后果. Kim, Tse, and Wald [KTW16] 在 55 个期货市场的 1985–2013 年样本中, 同时比较缩放与未缩放的时间序列动量, 以及用相同思路缩放与未缩放的买入持有基准. 其结果提示, 已报告的大幅 alpha 可能有相当部分来自波动率缩放; 方向信号的独立贡献因而需要单列. 因此一项波动率缩放策略应同时报告未缩放信号, 采用同类缩放的被动基准, 平均杠杆与暴露上限; 否则风险配置带来的表现可能被误记为预测能力.

趋势策略的典型路径风险包括:

- **whipsaw**: 价格在阈值附近反复穿越, 方向损益不大而换手持续累积;
- **跳跃与反转**: 缓慢建立的趋势在单次跳跃中快速回吐;
- **杠杆与融资**: 低估波动率时放大头寸, 融资条件又可能在压力期收紧;
- **拥挤**: 相似规则在同一触发点调仓, 可能抬高成交成本并削弱原有分散;
- **尾部和停牌**: 历史 ATR 或停损阈值并不限制没有报价时的可实现退出损失.

图9.5把同一组快慢均线放到两个历史窗口. 2017 年中, 20 日 SMA 始终位于 100 日 SMA 之上; 2015–2016 年中, 同一个方向判据翻转了 8 次. 如果把“20 日 SMA 高于 100 日 SMA”映射成持有, 把反向关系映射成空仓或减仓, 每一个红点附近都会触发一次目标持仓变化. 真实交易还要把目标变化变成订单, 成交和成本. 当两条滤波线在阈值附近反复靠近和穿越时, 方向损益本来就不大, 点差, 滑点和费用却会随着换手一笔笔累积; 这就是 whipsaw 损失在现金账本里的样子.




图 9.5: SPY 拆分与现金分配调整收盘价在两个历史窗口中的 20 日与 100 日 SMA. 上图对应 2017 年, 下图对应 2015–2016 年; 红点标记快线与慢线方向关系的翻转. 数据来源见引用文献 [Yahb; Yahc].

样本外, 走步验证与参数冻结 一条可信的最小检验流程可以是:

1. 先固定价格定义, 交易时钟, 信号公式, 成交规则, 成本模型和评价指标;
2. 只用训练窗口选择参数, 然后冻结参数进入后续测试窗口;
3. 按时间向前滚动训练和测试窗口, 不把未来样本重新送回过去;
4. 同时报告毛结果, 逐项成本, 换手, 最大回撤, 尾部损失和不同市场状态下的表现;
5. 保留失败参数和失败市场, 不只展示最优窗口;
6. 在真正未参与开发的数据, 时期或市场上做最终确认.

走步验证并不会自动消除过拟合. 如果研究者反复查看测试结果再改规则, 测试集就已经变成训练集. 所谓“参数稳健”也不应只指最优点附近仍为正; 更应问一族合理参数是否共享同一机制, 成本后结果是否仍在统计和经济意义上稳定.

数据偏差与多重检验 至少检查以下问题:

- 幸存者偏差: 当前仍上市的证券不能代表历史上可投资的完整集合;
- 回看偏差: 指数成分, 财报, 公司行为调整或修订数据是否在当时已经可得;
- 时间戳错配: 不同交易所, 时区, 日历和收盘时间是否被强行对齐;
- 价格口径: 原始价格, 拆股调整价和总回报序列是否与交易现金流一致;
- 交易时钟: 日线, 分钟线, 成交时钟和事件时钟产生的“同一个参数”并不等价;
- 数据窥探: 是否在看到全部样本以后选择资产, 起点, 窗口, 阈值与止损;
- 多重检验: 同时尝试数百种指标时, 最好结果可能只是随机极值.

多重检验不是只报告一个普通 p 值就能解决. 研究应披露尝试过的规则族, 使用更严格的样本

外设计或适当的多重比较修正,并要求结果不仅统计显著,还要在合理执行成本后具有经济意义.尤其要区分“把最后选中的规则当成事前固定规则”所得的名义 p 值,与对整个候选规则族和选择过程校正后的概率; Sullivan, Timmermann, and White [STW99] 的 7,846 规则再检验正是这一差别的实例.还要把策略损益与条件预测分开: Huang et al. [Hua+20] 的历史均值方向对照表明,类似的策略表现可以在没有相应时变预测关系时出现.

9.11 与资产世界观和估值方法的接口

技术指标解释的是价格,成交量或订单流路径的某种变换.它们不会仅凭价格形状识别资产权利,未来状态结果,单位捕捉,内在价值或终端锚.即使一条趋势策略在样本外有效,也不由此推出资产“值得”当前价格;即使基本面估值很有把握,也不由此推出一条特定趋势规则会在当前执行窗口盈利.这一区分回到第8.1节和第8.2节:趋势研究解释价格路径,基本面研究解释状态结果和条件价值.

两类研究可以相互提供约束,但不应互相冒充:

估值研究: 头寸与权利 $\rightarrow$ 状态结果 $\rightarrow$ 条件价值,
趋势研究: 可观察路径 $\rightarrow$ 信号 $\rightarrow$ 策略净损益.

在独立证据只允许研究供求,流量,交易者与价格动态时,把结论停在价格过程层面是一种诚实的范围声明.它不表示“价格毫无锚”,也不表示“既然无法估值就应该投机”.价格仍是带交易条款的真实交换事实,但从价格过程研究升级到投资机会,仍需明确进入成本,持有期限,退出路径,容量,风险和可执行捕捉机制.

原则 9.7 (趋势跟随属于策略).

回报属于一个明确的持有,融资与退出策略,不属于资产标签.趋势跟随也是如此:同一资产可以被长期持有,做市,对冲或趋势交易;同一个趋势信号也会因持仓上限,执行场所,费用和 risk 预算不同而产生不同结果.指标不会把这些差异压缩成资产的一项固有属性.

注 9.8 (从研究页回到真实下单).

前面的公式,参数与数值例用于说明定义,时钟与计算口径.真正下单以前,还要把当前数据,具体头寸,可执行报价,账户与融资条件,组合风险以及授权流程逐项接上.研究笔记停在研究页上;订单只能来自单独的交易流程.

9.12 小结

这一章把技术指标放回一条完整链条:图9.4从带时间戳的市场路径出发,依次经过指标,信号,目标持仓,订单,成交与结算,最后才得到含成本策略损益. SMA 与 EMA 展示了平滑和时滞的基本权衡; MACD, Bollinger Bands, RSI, ATR 与 VWAP 则是差分,局部尺度,方向幅度,范围和成交量加权的不同组合.它们各自测量有限对象,没有任何一个指标同时测量未来方向,基本价值和可执行优势.

随机游走提醒我们不要把图形当证据, AR(1) 展示了短期延续或反转的最小条件,潜在状态,异方差与跳跃则说明现实机制可能更复杂.研究文献同时记录了跨市场正面结果,特定预测对象的样本外证据,规则族校正后的失效以及“盈利不等于时变预测”的反例.最终,一项趋势规则的可信度不取决于公式看起来多么熟悉,而取决于检验对象是否对齐,信息时点是否诚实,成本和风险是否完整,参数是否冻结,样本外证据是否经得住重复检验.理解这些范围,正是理解指标和趋势交易本身的一部分.

第A.11节把这里的潜在状态与局部数据生成机制进一步放进制度史:交易规则,清算边界和公共后盾改变时,同名指标面对的转移规律也可能已经改变.

附录 A 金融市场制度史：危机如何塑造今日结构

今天看到的金融市场没有一张先验完整蓝图，它在长期冲突，危机与修补中逐步形成。它更像一座长期有人居住的城市：旧街道决定新管线能够铺在哪里，每次火灾又迫使人们增加新的防火墙，水源和疏散通道。中央银行，存款保险，证券披露，交易所自律，中央清算，熔断机制，宏观审慎监管和稳定币储备规则，都带着某一次历史压力测试留下的痕迹。

开头先用荷兰和英国各一段前史说明现代市场的几种基本积木怎样出现，再把重点放在二十世纪美国，最后讨论二十一世纪的影子银行，算法交易，社交媒体驱动的零售交易和数字货币等新变体。沿历史顺序阅读时，每到关键事件都反复追问四个问题：

1. 当时出现了什么新的权利，融资方式或者交易组织？
2. 哪一种期限转换，杠杆，信息不对称或者结算关系使冲击能够扩散？
3. 私人协调为什么失效，公共权力又在什么时点进入？
4. 危机结束以后，哪一层规则真正留在了今天的市场里？

读到每一次危机时，可以依次辨认触发事件，放大机制，当时的处置和最终留下的制度。同一事件往往同时牵动几条制度链，因而触发，放大，处置和遗产不能被一个因果动词概括。

还要先区分泡沫，暴跌和系统性危机。资产价格可能脱离后来能够实现的现金流或者服务价值，但价格回落未必会击穿银行负债，支付系统或核心融资市场。反过来，2020年3月的美债市场功能失灵也不以美债存在价值泡沫为前提。研究美国历次股灾以后，Mishkin and White [MW02] 同样强调，货币当局需要辨认的是金融不稳定及其传导渠道，不能把每一次价格下跌都当作同一种政策对象。

原则 A.1 (制度本身是市场状态)。

一项资产的价格过程不只取决于资产未来结果和市场参与者的信念。它也取决于当时允许谁发行，谁交易，谁借入，谁可以获得最后流动性，交易怎样清算，亏损由谁承担以及危机时哪些规则能够改变。

所以金融制度史直接进入价格模型的解释边界。制度决定资产单位，权利，义务，交易路径和状态转移，因而也是生成价格数据的机制的一部分。

可以先把几层现行结构和它们最直接的历史来源放在一起，后面的事件就不会变成一串孤立年份。

今天的结构	关键压力测试	留下的制度含义
央行货币与最后贷款人	英国十九世纪恐慌, 美国 1907 年恐慌	把私人银行家与清算所临时承担的部分流动性功能, 转入可重复且有法定授权的公共机制
存款保险与银行处置	美国 1930–1933 年银行危机, 1980 年代储贷危机, 2023 年地区银行危机	区分流动性支持, 损失吸收, 破产处置与存款人保护
联邦证券披露与交易所监督	1929 年股灾和大萧条	私人交易所继续运营, 但在联邦法律, 美国证券交易委员会 (SEC) 监督和自律组织框架下承担公共义务
全国市场与现代清算结算	1968–1970 年代证券后台处理危机 (paperwork crisis), 1975 年证券法修正	竞争性交易场所通过行情, 路由, 托管和清算基础设施连接起来
熔断, 保证金与跨市场监测	1987 年股灾, 2010 年闪电崩盘 (flash crash), 2021 年 meme stock 事件	把现货, 期货, 期权, 经纪商和清算机构看成同一个动态系统
宏观审慎与非银监管	1998 年 Long-Term Capital Management (LTCM), 2007–2009 年危机, 2020 年抢夺现金 (dash for cash)	监管对象从单家银行扩展到融资网络, 中央对手方, 基金杠杆和核心市场功能
数字私人货币的储备与赎回规则	2022 年加密资产动荡及稳定币挤兑风险	技术形式可以改变, 面值承诺, 储备透明度, 托管和挤兑问题仍然存在

A.1 荷兰前史: 可转让股份, 结算货币与早期泡沫

现代证券市场的一条重要源流出现在十七世纪初的阿姆斯特丹。远洋贸易需要在今天投入船只, 人员和货物, 却要等多年以后才能知道航程是否成功。如果每一次航行都单独融资和清算, 投资者面对的是期限长, 信息少, 难以中途退出的头寸。1602 年成立的荷兰东印度公司 (Vereenigde Oostindische Compagnie, VOC) 把多次航行放进一个持续经营的共同资本池, 而可以转让的股份又使投资者无需等待企业最终清算便能退出。

持续经营的共同资本池和可转让股份, 同时改变了企业, 投资者和中介的选择。企业获得了比单次合伙更稳定的长期资本; 投资者无需等到远洋经营结束, 便能出售原本锁在其中的请求权; 中介又可以把股份用于信用交易和抵押融资。Gelderblom and Jonker [GJ04] 的研究表明, 活跃的二级市场及其配套信用技术正是围绕可转让 VOC 股份逐步发展起来的。这一市场始终嵌在国家特许, 殖民垄断和强制权力之中。股份最初只是在公司账簿中登记的权益, 距离标准化的现代无记名股票还有很长一段路。

股份能够转让以后, 大规模交易还需要一种可信的结算单位。如果报价同时依赖成色不一的硬币, 私人信用和远距离支付, 价格便很难比较。1609 年成立的阿姆斯特丹汇兑银行 (Bank of Amsterdam) 用账户转账支持大额支付, 并在较长时期内为商业结算提供稳定的银行货币。后来出现的隐蔽贷款, 财政支持不足和信心崩塌, 使它的历史无法被画成一条通往现代央行的直线。它更持久的意义在于揭示了一个至今仍然有效的结构: 市场价格若要扩展为大规模交易, 必须依赖一层被广泛接受的结算资产和治理安排 [FSW20]。

1636–1637 年的郁金香投机表明, 著名泡沫不能套进同一模板。交易重点从现货花球逐渐移向未来交付请求权以及可反复转手的承诺, 市场却没有现代期货交易所的逐日盯市, 保证金和集中清算。价格急涨和市场消失确有其事, 但现有研究认为, 它对荷兰整体经济的冲击远小于通俗叙事的描写 [MT17]。这段历史更值得记住的是, 未标准化的远期承诺, 不透明供给和薄弱履约安排, 足以让一段时期内的报价显著偏离最终可交付物。

1720 年横跨伦敦, 巴黎和阿姆斯特丹的股票泡沫更接近现代资本市场问题。英国南海公司和法国密西西比公司把政府债务重组, 特许经营权, 新贸易叙事和大规模股票发行放在同一个结构里。当年的投机还扩散到英国, 法国与荷兰的多种证券。Frehen, Goetzmann, and Rouwenhorst [FGR09]

对横截面价格的研究并不支持“所有投资者无差别失去理性”这种单一解释：市场确实在大西洋贸易和股份制保险等真实创新重新定价，但一个具有经济可能性的故事仍然可以被融资，稀缺供给和转售预期推到不可持续的价格。

这段荷兰前史留下四种延续至今的结构：较稳定的长期资本，可转让股份，证券抵押融资和公共结算货币。它们扩大了风险分担和资本形成能力，也让同一项资产请求权可以在信用链条中被反复使用。创新带来的便利与信用链条中的脆弱性，从一开始便相伴而生。

A.2 英国前史：公共信用与中央银行职能的形成

如果说阿姆斯特丹突出的是公司股份和商业结算，英国的关键贡献则是把国家公共信用，中央银行和证券市场逐渐连接起来。英格兰银行在 1694 年成立时首先是一家私人持股银行，其成立直接服务于政府对法战争融资。投资者认购银行股份，银行再向政府提供贷款。政府借款，银行负债和私人资本因此进入同一张制度资产负债表 [Ban24]。

英格兰银行的中央银行职能是在长期实践中逐步累积的，伦敦证券交易也经历了从咖啡馆报价到正式交易所的演变。1698 年前后，经纪人在咖啡馆发布股票和商品价格；到 1801 年，一批经纪人与交易商才建立受正式规则约束的证券交易所 [Lon]。市场最初依靠商人，经纪人和会员规则组织，公共权力随后逐步承认，约束并借用这套私人能力。

1720 年南海泡沫把公共债务，政治特许和公司叙事汇入同一项证券估值。南海公司参与大规模政府债务转换，其股价又依赖政治特许和对未来贸易的想象。其中的 *asiento* 奴隶贸易权建立在国家强制与殖民扩张之上，不能被淡化为普通企业机会 [UK 25]。因而，当时的价格上涨同时吸收了金融工程，政府信用，稀缺特许和转售投机四种力量。

Bubble Act 在繁荣期间已经通过，因而不宜视为崩盘后突然出现的现代投资者保护法。史料还显示，South Sea Company 希望借这部法律压制竞争性公司的筹资，它的长期组织效应也比通俗叙事所说的更有限 [Har94]。泡沫破裂后，公共债务管理，公司治理，证券发行和政治关系之间的联动，成为更难回避的问题。

十九世纪的几次银行恐慌又把另一个问题推到中心：当大量持有人同时要求把私人短期请求权换成最终结算资产时，谁有能力扩大现金供给？1844 年 Bank Charter Act 强化了英格兰银行在纸币发行中的中心地位，但规则本身并没有消除 1847、1857 和 1866 年的流动性危机。1866 年大型票据经纪商 Overend Gurney 倒闭时，英格兰银行拒绝救助被判断为资不抵债的机构，同时又必须向更广的市场提供流动性以阻止恐慌扩散。

这段经验后来被压缩成所谓 Bagehot 原则：在恐慌中对有良好抵押品的借款人充分供给流动性，同时使用高于平时的利率减少不必要借款和道德风险。历史账簿研究显示，英格兰银行在十九世纪中期危机中的实际操作大体符合这条后来总结出的路线，但不同危机和不同贷款之间仍有重要差异 [Ans+17]。

这段英国经验为美国史带来一项关键区分。最后贷款人要在两类问题之间划线：

- 流动性问题：资产可能有长期价值，但机构无法在今天取得现金；
- 偿付能力问题：即使给足时间，资产仍不足以覆盖负债。

恐慌当天，二者往往很难被准确区分，这道判断边界也会随着市场结构改变而以新的形式出现。2022 年英国政府的财政声明触发长期国债急剧重定价，部分采用杠杆，以长期负债匹配为目标的 liability-driven investment (LDI) 策略随后遭遇抵押品和保证金追加要求，被迫售债又放大价格下跌。英格兰银行采取临时，定向的国债购买，目标是切断“价格下跌-追加保证金-被迫出售-价格继续下跌”的反馈环 [Ale+23; Ban22]。从 1866 年到 2022 年，支持工具从票据贴现扩展到核心市场操作，但判断边界始终存在：既要阻止系统性火售，又不能把私人投资者的资产风险永久转给公共部门。

A.3 从 Buttonwood 到 1907 年：私人俱乐部及其边界

在联邦监管出现以前，美国证券市场已经形成一套私人规则。1792 年，二十四名纽约经纪人与商人签署 Buttonwood Agreement，约定彼此优先交易并设定最低佣金。1817 年，他们建立 New York Stock & Exchange Board，进一步规定会员资格，交易时段，以及按固定时段逐只证券集中撮合的 call market [Newb]。

交易所兼具私人俱乐部和市场基础设施的两面性。有限席位和会员自治首先服务于成员利益，同时也提供了身份审查，合同惯例，报价集中和违约惩戒。这套私人秩序能够组织交易，但对非会员，系统性外部性和公共信息承担的责任仍然有限。

银行体系的覆盖缺口更加明显。十九世纪的政治传统长期警惕中央银行，银行牌照和监管权又分散在州与联邦之间。unit banking，即限制银行跨地区设立分支的单一银行制，妨碍银行跨地区分散风险；货币供给也难以在季节性资金需求上升时及时伸缩。纽约清算所可以让成员银行共同发行清算凭证并互相支持，但援助范围主要限于成员机构，信托公司和全国支付体系仍在覆盖之外。这套碎片化结构构成了 1907 年恐慌的制度背景 [Cal09; Fedh]。

1907 年 10 月，一次失败的 United Copper 股票逼仓打击了相关中介的信誉，挤兑随后扩散到纽约信托公司。Knickerbocker Trust 停止支付以后，对现金的需求迅速进入银行，信托公司和证券融资市场。纽约证券交易所的 call money（可随时收回的经纪贷款）利率一度升到极端水平，交易所本身也面临因会员无法融资而被迫关闭的风险。

危机中，J. P. Morgan 先利用私人网络收集银行和信托公司的资产负债表信息，尝试区分暂时缺现金与已经资不抵债的机构。随后，他把银行家召集到同一房间，要求他们共同为交易所和仍有生存能力的机构提供资金。在缺少公共最后贷款人的环境里，他的个人声望也成为协调预期的焦点。与此同时，纽约清算所发行贷款凭证，会员银行对存款兑付采取协调性限制，财政部则把政府资金存入银行体系。信托公司没有参加这套兑付限制，私人清算安排的覆盖边界由此暴露出来。把危机缓解归功于 Morgan 一人，会遮蔽私人银行家，清算所，财政部和交易所临时组成的救火联盟 [MT]。

这些安排与海外黄金流入等因素共同缓和并最终帮助结束恐慌，也留下了一个清楚的制度缺口：全国金融体系无法把最后流动性的规模，对手方范围和公共利益判断，长期寄托在一位私人银行家的财富，健康，信息和意愿上。1908 年 Aldrich–Vreeland Act 先提供紧急货币安排并设立 National Monetary Commission，1913 年 Federal Reserve Act 再建立带有十二家地区储备银行的联邦储备体系 [Fedi]。

1907 年留下了一组后来被制度化并重新分配的功能。公共制度承接了这些功能，没有照搬一个私人职位。要看清今天的制度分工，不妨先把当年的私人协调拆成几项功能。

1907 年的私人功能	今天主要由谁承担	不能被简单替代的部分
召集银行共同出资	Fed, Treasury, FDIC, 市场监管者和私人机构按权限协调	危机中的共同判断仍需要具体人员和可信关系
为有抵押品者供给现金	Fed 贴现窗口，回购 (repo) 工具及紧急流动性设施	央行贷款不能自动修复负资本
判断机构是否可救	银行监管者，FDIC 处置机制，Treasury 和法院	资产在压力下的真实价值仍有不确定性
保护交易所融资和市场功能	Fed 市场操作，SEC 监督，交易所规则和清算机构	私营做市商和交易商资产负债表仍是第一道缓冲
用个人信誉稳定预期	有法律授权，披露和问责的公共承诺	公共承诺本身也可能产生道德风险和政治争议

Fed 把 1907 年临时协调中的一部分能力转化为可重复，可抵押，可扩张并具有公开授权的制度：弹性央行货币，银行间最终结算，以及以银行体系为中心的最后流动性基础。证券监管，存款保险，破产处置和私人损失承担，则继续由其他公共和私人机构分工处理。1998 年，New York Fed 召集十四家私人机构，为 Long-Term Capital Management (LTCM) 安排私人资本重组。危机中的召集功能并未消失，只是进入了公共机构参与，授权更清楚且更可问责的框架 [McD98]。

A.4 1913–1935 年：建立央行不等于已经学会中央银行

Federal Reserve Act 解决的是“美国是否应当有一个能够提供弹性货币的中央银行体系”。它没有一次解决“这个体系在不同危机中应当怎样行动”。Fed 的十二家地区储备银行，Washington 的理事会和后来逐步形成的 FOMC，本身就是反集中化政治传统与全国流动性需求之间的妥协。这种分布式结构帮助法案获得政治支持，也在后来暴露了地区判断不一致和中央决策能力不足的问题 [Fedi; GM13]。

第一次世界大战很快改变了 Fed 与资本市场的关系。美国财政部通过 Liberty Bonds 大规模为战争融资，Fed 则协助销售，支付和金融体系动员。数以千万计的家庭第一次直接接触政府债券，银

行，经纪商和宣传网络共同把原本更专业化的证券市场推向大众。这既扩大了公共债务市场和投资者基础，也说明金融参与的普及可以同时包含公民动员，销售压力与群体叙事 [Gar]。

1920 年代的股票繁荣把消费信贷，保证金贷款，新技术叙事和大众证券参与结合起来。1929 年 10 月股价崩跌以后，New York Fed 通过公开市场操作向银行体系提供准备金，帮助证券融资和支付系统继续运作。然而，1930–1933 年的银行倒闭，通缩和实体经济收缩仍在加深。仅有一个名义上的中央银行体系还不足以应对危机；授权，信息，决策结构和行动理念必须共同发挥作用 [GM13; RKG]。

大萧条的深度来自多条传导链的叠加。股价崩跌损害了财富和信心，银行恐慌，货币收缩，国际金本位约束，企业与家庭资产负债表恶化以及政策失误，又把冲击传向支付，信贷和就业。价格泡沫只是其中一环，负债结构决定了损失能否扩散为更广泛的经济危机。

1933–1935 年的多项立法共同完成了多层制度重组；这一重组随后在 1940 年延伸到基金与投资顾问。

- 1933 年 Securities Act 把新证券发行的联邦披露责任放到中心。
- 1933 年 Banking Act 建立 FDIC，并设置商业银行与证券业务之间的隔离。
- 1934 年 Securities Exchange Act 建立 SEC，把交易所，经纪交易商和二级市场纳入持续联邦监督。
- 1935 年 Banking Act 强化 Board of Governors 和 FOMC 的中央决策地位。
- 1940 年 Investment Company Act 与 Investment Advisers Act 又把基金结构和投资顾问纳入更明确的法律框架。

这些改革的分工很具体。存款保险缓解银行挤兑中的协调失败，资本和业务限制约束风险承担，证券披露降低发行人与公众投资者之间的信息不对称。SEC 为市场规则引入持续的公共监督，Fed 重组则改善中央银行内部的协调 [Ric+a; Ric+b; US i]。

每一道新防线也会改变参与者的行为。存款保险降低储户挤兑动机，同时可能减弱储户监督并鼓励被保险机构承担更多风险；业务分隔减少部分利益冲突和传染路径，相似活动却可能迁移到监管边界之外；更集中的央行决策提高全国行动能力，也会扩大政策错误的影响范围。危机后的制度重建往往是在旧结构上增加一层防线，风险则随之改变位置和形态。

A.5 Wall Street 的“转正”：联邦监督下的私人市场

Wall Street 的“转正”表现为私人交易所逐渐取得带有公共义务的法律身份，过程中政府没有接管交易所。美国最后形成的是公私混合结构：交易所继续由私人组织运营并制定大量一线规则，同时以 registered national securities exchange 的身份，进入联邦法律下的 self-regulatory organization (SRO) 框架，其规则，纪律和市场运行接受 SEC 的法定监督。1934 年以后，会员自治不再只是会员之间的合同，还必须服务于投资者保护和公平有序市场等公共目标 [KR11; US i]。

这种混合结构保留了私人市场的专业知识和适应速度，也留下一个无法彻底消除的冲突：交易所既希望增加成交，会员和收入，又要约束会为它带来收入的参与者。美国市场由此形成了私人经营，行业自律与联邦监督不断重新划界的混合结构。

公私混合的监管框架确立以后，市场的下一项挑战转向基础设施容量：不断扩大的市场能否被现有系统承接。第二次世界大战和战后时期改变了市场的投资者基础。战争融资扩大了 Treasury 市场，1951 年 Treasury–Fed Accord 结束了 Fed 为政府债券利率提供战时固定支持的安排，使债务管理与货币政策重新获得更清晰的边界 [HL]。与此同时，共同基金，保险资金和雇主养老金逐渐把家庭储蓄汇入机构化投资组合。Wall Street 逐渐不再只是少数经纪会员直接面对企业发行人，而变成发行人，资产管理人，托管银行，养老金，经纪商，交易所和清算机构共同组成的链条。

市场扩容很快暴露了后台处理能力的上限。1960 年代末的证券后台处理危机中，成交量增长超过了经纪商后台用纸质凭证处理确认，交割和股票证书的能力。未结算交易堆积，错误增加，一些经纪商倒闭，交易所甚至缩短交易日以便后台追赶。这场危机没有以资产价格泡沫为起点，却说明市场可以在价格机制仍然运转时，因为运营和结算能力不足而接近失灵 [US 68]。

后台危机直接推动证券集中保管，账簿记账和净额结算加快发展。同期，OTC 报价电子化沿另一条市场信息与竞争路径推进。Depository Trust Company (DTC) 在 1973 年建立，通过集中保管与账簿记账减少股票证书的反复搬运；National Securities Clearing Corporation (NSCC) 在 1976 年建立，把跨场所的交易比对，净额与结算义务进一步集中。Nasdaq [US 71] 于 1971 年以电子报价网络上线，当时成交协商与匹配主要靠电话，与今天的自动撮合限价簿有明显差别。

1975 年发生了两项相关但不同的变化。SEC Rule 19b-3 自 5 月 1 日起结束交易所面向公众的

固定佣金表，经纪服务开始更直接地接受价格竞争。6 月 4 日通过的 Securities Acts Amendments of 1975 随后确认竞争方向，要求 SEC 推动 national market system 和全国清算结算体系，并加强对 SRO 的监督 [US 75]。此后逐步形成的 national market system 以合并行情，跨市场接入，订单路由和共同规则连接彼此竞争的场所；政府没有运营一个全国单一交易所。上述后台机构的形成过程另见 Depository Trust & Clearing Corporation [Dep]。

这些变化真正削弱了早期会员俱乐部的经济核心。从 Buttonwood 的最低佣金和相互优先交易约定，到后来会员制交易所的固定公众佣金表与排他性准入，佣金约束和会员资格长期构成俱乐部秩序的一部分；到 1975 年以后，交易场所仍然可以私人经营，却必须在全国市场，竞争性佣金，公共行情和联邦监督中证明自己的功能。Wall Street 的“转正”因而经历了 1934 年公共监管，1975 年全国市场和后来电子竞争的多次重构，无法归结为某一天取得许可证。

2006 年 NYSE 与电子交易平台 Archipelago 合并并完成去会员化 (demutualization)，又把会员拥有的非营利交易所变成上市控股集团中的营利性公司。这里的“上市”指其所有者股份可以公开交易；公共部门并不持有或运营它。SEC 在批准时要求把市场运营和监管职能作更明确的组织隔离，正是因为“营利性市场同时监管客户与竞争者”会产生新的利益冲突 [US 06]。截至 2026 年 9 月 2 日，SEC 的 national securities exchange 名录仍列有 New York Stock Exchange LLC [US h]。NYSE 同时属于公开上市的 Intercontinental Exchange (ICE) 集团 [Newa]。今天的 NYSE 位于十八世纪私人俱乐部与政府部门这两个端点之间。它是由私人资本运营，承担法定自律义务，接入全国行情与清算网络并受 SEC 监督的市场基础设施。

A.6 1970–1999 年：每一次修补都会改变下一次风险的位置

二十世纪后半段的美国金融史没有沿着“监管越来越多，危机越来越少”的单一路线前进。四个节点把风险迁移的不同侧面依次推到台前：1987 年暴露跨市场反馈，储贷危机暴露资产负债期限错配和延迟确认损失，LTCM 暴露共同头寸与交易对手网络，1999 年的业务边界改革则把更多金融活动放进同一集团。贯穿其中的主线是：金融功能不会因为旧渠道受到约束而消失，它会迁移到新的资产负债表，产品和法律边界。

1987 年 10 月股灾是现代跨市场联动的一次压力测试。股票现货，股指期货，组合保险和程序交易在快速下跌中互相影响，做市商与清算机构同时面对融资和保证金压力。Fed 迅速公开表示将为经济和金融体系提供流动性，随后市场又增加跨市场协调，熔断和清算保障安排 [Car]。危机以后形成的熔断和协调安排并不承诺阻止价格下跌，它们是在极端波动时给订单，保证金和清算系统留出重新同步的时间。

储贷危机展示了拖延确认损失会怎样改变最终代价。许多 savings and loan institutions (S&Ls) 用短期存款为长期固定利率住房贷款融资。利率上升以后，负债成本提高而资产收益被锁定，大量机构的经济资本已经恶化。然而，关闭机构会立即暴露保险基金不足，机构破产和政治成本。监管宽容，宽松会计，以及在存款保险保护下扩大的高风险资产权限，于是让部分机构能够继续筹资并进一步放大亏损。等到危机规模再也无法隐藏，1989 年 Financial Institutions Reform, Recovery, and Enforcement Act (FIRREA) 废除已经资不抵债的 FSLIC，建立 Resolution Trust Corporation (RTC) 处置失败储贷机构，并把储贷存款保险责任移交 FDIC。1991 年 FDIC Improvement Act (FDICIA) 又加强 prompt corrective action 和 least-cost resolution 等约束 [Fedb; Fedc]。许多人已经看见问题。更关键的是，谁先确认损失，谁就必须立刻面对财政、职业和政治后果。正是这种激励把不可持续状态向后拖延，直到集中处置成为代价更高却无法回避的选择。

1998 年 LTCM 则把高杠杆，相似头寸和交易对手网络放到中心。基金资产规模小于银行体系，但它与多家主要交易商有大量衍生品和融资关系。若各交易商同时抢先平仓，相同资产会遭遇火售，抵押品价格下跌又会制造新的保证金缺口。New York Fed 没有直接投入公共资金购买 LTCM；它召集主要私人对手方组织资本重组 [McD98]。LTCM 的系统重要性来自网络位置和共同头寸，并不只由机构的法律标签或资产总额决定。

二十世纪末，放松业务边界与金融集团化同时推进。1999 年 Gramm–Leach–Bliley Act 取消了 Glass–Steagall 部分业务隔离，使商业银行，证券和保险业务更容易进入同一金融集团。独立投资银行，影子银行融资和抵押贷款质量都参与了后来危机的形成，因而 2008 年危机不能由这一部法律单独解释。这部法律更明确地标志着一个制度方向：政策更依赖集团层面的资本，风险管理和监管协调，而不再主要依靠把不同金融活动放进相互隔离的盒子 [BBW]。

从 1970 年代到世纪末可以看出一个反复出现的迁移过程：

旧规则压住一种风险 → 市场把功能移到新载体 → 新载体在压力中暴露 → 监管边界再次扩大。

监管并不因此注定失败，创新也不因此天然有害。这条链真正说明的是，任何规则都会改变参与者的选择，制度修补也会随之改变下一段历史的数据生成机制。

A.7 2000–2010 年：科技泡沫，影子银行与宏观审慎转向

互联网繁荣延续了 1720 年已经出现的一种结构：真实的技术创新与过高的证券价格可以同时存在。互联网确实长期降低了搜索和通信成本，但新企业的单位经济，竞争终局和可持续利润在当时高度不确定。Pastor and Veronesi [PV05] 把技术革命中的价格繁荣理解为投资者对新技术平均生产率逐步学习时产生的系统性不确定性；Ofek and Richardson [OR01] 则强调异质信念，卖空约束以及 lockup 到期后可出售股份增加对互联网股票价格的影响。这些研究共同反对一种过度轻松的事后叙事：今天知道哪些企业失败，并不等于当时所有乐观判断都没有信息基础。

2000–2002 年科技股下跌造成巨额财富损失，却没有像 1930 年代或 2008 年那样直接摧毁整个银行支付体系。随后 Enron, WorldCom 等会计丑闻暴露了另一层问题：上市公司管理层，审计机构和投资者之间的监督链条可能被利益冲突破坏。2002 年 Sarbanes-Oxley Act 建立 Public Company Accounting Oversight Board (PCAOB)，加强审计独立性，管理层财务报告责任和内部控制要求 [US 02]。由此可以分出两条因果链：科技泡沫解释一部分估值与融资热潮，会计丑闻才是 Sarbanes-Oxley 具体公司治理改革的直接政治催化剂。

2007–2009 年全球金融危机比互联网股灾更具系统性，因为风险位于住房抵押贷款，证券化，短期批发融资，货币市场基金，repo，信用衍生品和大型金融机构之间的负债网络。住房价格下降只是冲击之一。真正使危机扩大的机制包括：高杠杆机构需要不断滚动短期融资，复杂证券难以估值，交易对手无法判断彼此损失，抵押品折价上升触发被迫减仓，而传统存款保险和贴现窗口并没有完整覆盖这些影子银行负债。

关于危机原因并不存在一个没有争议的单因结论。Financial Crisis Inquiry Commission 的多数报告强调监管和监督失败，公司治理与风险管理缺陷，过度借贷，不透明场外衍生品和问责缺失；报告同时保留了不同委员的反对意见 [Fin11]。这一分歧本身就是方法论提醒：历史事件可以确认一条传导链存在，却未必能够从一次复合危机中识别每条原因的唯一权重。

危机处理把 Fed 的角色从传统银行最后贷款人进一步扩展到市场化融资系统。紧急贷款设施，与外国央行的美元流动性互换，对商业票据和资产支持证券融资的支持，以及大规模资产购买，都试图阻止私人货币和抵押融资同时收缩。这些措施常被称为“史无前例”，但跨国历史比较表明，严重危机中，中央银行越过日常工具边界已有历史先例；关键在于工具是否针对系统性传导，是否有损失保护和退出条件，以及危机以后是否修复了产生道德风险的规则 [MW14]。

2010 年 Dodd-Frank Act 把监管视野从单家机构的安全进一步推向全系统稳定。它建立 Financial Stability Oversight Council (FSOC) 和 Office of Financial Research (OFR)，扩大对系统重要机构和金融市场基础设施的监督，并引入更完整的处置与压力测试框架。在危机以前，没有单一监管者负责跨越银行，证券，保险和非银融资观察系统风险。FSOC 是对这种碎片化缺口的协调性回应，其职责以协调为主，无法直接监管所有金融机构 [US a]。

场外衍生品改革则分成报告，清算和平台交易几个层次。以 CFTC 所辖互换 (swaps) 为例，监管报告覆盖已清算和未清算交易；中央清算只适用于监管者认定必须清算且不适用例外的互换；平台执行又只适用于其中被监管认定须在合规平台交易 (made available to trade) 且不适用相关例外的互换 [Com12; Com13; US 10]。

中央清算值得单独保持两面性。它把原来不透明的双边交易网络压缩成更可净额和监测的结构，但也把风险集中到 central counterparty (CCP)。风险因而没有在“进入中央清算”的一刻消失。它从众多双边连接移到少数关键节点，这些节点也就必须拥有严格的保证金，违约基金，流动性与恢复处置安排。制度改革改变了风险的位置和可见性，却没有取消随机损失本身。

A.8 2010–2026 年：更快的市场，非银边界与数字私人货币

二十一世纪的新变体并没有废除旧机制。它们主要改变了速度，参与者范围，资产载体和传导网络。过去需要几天形成的挤兑可以在手机上几小时完成；过去留在银行资产负债表内的杠杆可以出现在基金，衍生品和 repo 中；过去由经纪会员控制的订单可以被零佣金界面，社交媒体和做市商批发流量重新组织；过去的私人银行券问题又以稳定币和代币化基金的形式回来。

2010 年闪电崩盘：速度本身成为状态变量。2010 年 5 月 6 日，股指期货中的大额自动卖出与已经紧张的流动性相互作用，高频参与者的交易，撤单和跨市场传导使许多证券在几分钟内出现极端价格，随后又快速恢复。联合调查把原因归结为一组反馈：自动执行，市场碎片化和流动性提供者同时退场 [Sta10]。后续 limit up–limit down，熔断和更细的跨市场数据建设，这些改革承认了一个现实：毫秒级市场不能只靠人工临场协调。

2020 年抢夺现金：安全资产也会发生市场功能危机。COVID-19 冲击初期，共同基金，外国官方机构，hedge funds 和其他持有人都需要美元现金。卖出压力甚至进入被视为全球安全资产基准的美国国债。交易商资产负债表无法无条件吸收所有库存，bid–ask spread 扩大，现券与期货基差失常，Treasury 与由联邦机构或政府支持企业担保的抵押贷款证券（agency mortgage-backed securities, agency MBS）市场功能显著恶化 [Boa20a]。高杠杆 basis trades 的平仓是其中一条传导路径，但现有证据不支持把整个事件归结为这一类交易者。美债的安全资产地位并没有因此消失；暴露的是安全资产二级市场在集体求现和中介容量受限时也会失去流动性。

危机最急迫的阶段，Fed 先用大量购买，回购操作和多种紧急工具帮助市场恢复功能。随后，改革重点逐渐转向减少未来对紧急救助的依赖。2021 年建立的常设回购便利（standing repo facility, SRF）把隔夜回购后备流动性变成常设工具 [Fed21]。其他工作继续检查交易商资产负债表承接能力（dealer capacity），交易数据和杠杆基金，允许更多买卖双方不经固定 dealer-to-client 层级直接相互成交的 all-to-all trading，以及 Treasury 中央清算。截至 2026 年 9 月 2 日，SEC 公布的合规时间表要求符合范围的 Treasury 现金交易自 2026 年 12 月 31 日起进入中央清算，repo 交易的相应日期为 2027 年 6 月 30 日 [US j]。这些措施仍在实施，它们代表一套正在形成的制度变化，还不能被当作已经解决问题的结论。

2021 年 meme stocks：大众参与撞上市场后台基础设施。GameStop 等股票同时出现社交媒体驱动的关注和零售参与，极高成交量，大幅价格变化，高 short interest，期权交易和经纪商风险控制压力。一些零售经纪商限制客户继续买入，直接原因之一是清算机构在极端波动下提高保证金要求。SEC staff report 因此把注意力同时放在 payment for order flow (PFOF)，off-exchange wholesalers，数字化参与设计，卖空，期权和清算结算上 [US 21]。

这场波动也让“免费交易”背后的经济结构变得可见。零售经纪商可以不向客户收取显性佣金，却把订单流交给批发做市商并取得收入；客户得到的执行质量，经纪商的路由激励和公开市场的价格发现因而需要分别检查。它也把交易日到结算日之间的清算敞口重新放到公众视野中。随后实施的 T+1 属于更广泛的结算风险改革，不能归因于 GameStop 一项事件。2024 年 5 月 28 日，大多数适用的美国证券交易从 T+2 转到 T+1，减少交易日至结算日之间累积的对手方敞口和保证金需求 [US 23b]。

加密资产与稳定币：旧的私人货币问题进入新技术载体。无抵押加密资产，stablecoins，centralized exchanges 和 decentralized finance (DeFi) 分别对应不同的头寸与权利结构。它们分别包含协议状态，私钥控制，平台请求权，储备资产，赎回承诺和治理规则。TerraUSD 表明，即使协议机制可以在链上观察，也不保证稳定性或者按面值赎回 [Fin22]。FTX 则表明，加密资产平台的中心化托管，负债和关联方风险不会因为底层资产使用区块链而自动透明或隔离 [Com24]。这两类失败也不能合并成“所有稳定币都没有储备”的结论。对于储备支持型 stablecoins，资产质量，托管和赎回规则仍然需要分别检查。

监管回应也开始从全球原则进入具体制度。FSB 在 2023 年形成的全球框架强调“same activity, same risk, same regulation”，并把客户资产保护，利益冲突，跨境协作和稳定币治理作为重点 [Fin23]。美国在 2025 年把 GENIUS Act 签署为法律，建立 payment stablecoins 的联邦监管框架 [The25; US 25]。截至 2026 年 9 月 2 日，payment stablecoin 法定框架已经颁布，但尚未全面实施，配套最终规则仍在制定 [Off26]。法律分类为发行和监管划定了边界，却不会因此消除挤兑机制。2026 年 Fed 研究把稳定币，tokenized money market funds 和其他 money-like products 放在同一分析框架下，继续检查流动性转换，阈值效应，传染和投资者反应 [Ana+26]。

到了这里，历史又与 1609 年的阿姆斯特丹汇兑银行遥相呼应。无论账户记录写在纸簿，中央数据库还是分布式账本上，一个声称接近面值的私人货币都需要回答：储备是什么，谁保管，谁能赎回，赎回要多久，压力时谁提供流动性，规则由谁改变。技术可以改变结算边界和可编程性，却不能删除资产负债表和治理。

2023 年地区银行危机：数字化挤兑加速旧风险。资产负债表问题并不新，新的是挤兑发生的速度。Silicon Valley Bank (SVB) 依赖高度集中的科技与 venture capital 客户和大量未保险存款，又把快速增长的存款投入期限更长的证券，却没有充分管理利率风险。利率上升造成未实现损失，资本

筹集计划触发信心恶化以后，社交网络和线上银行提款以过去少见的速度集中发生。Fed 的事后审查同时确认了银行管理失败和监管未及时升级的问题 [Boa23]。

监管者使用 systemic risk exception 保护 SVB 与 Signature Bank 的全部存款人，Fed 又建立 Bank Term Funding Program (BTFFP)，允许合格机构以高质量证券按面值取得期限融资。这些措施旨在并有助于降低被迫出售与传染风险，也再次把一项边界问题推到公众面前：危机中，哪些存款会得到保护？存款保护并没有挽救股东，BTFFP 也只是临时设施，自 2024 年 3 月 11 日起不再发放新贷款 [Boaa; US 23a]。FDIC 随后比较维持有限保障，全面保障和对企业支付账户提供更高定向保障等方案，但这些选项涉及金融稳定，市场纪律和保险定价之间的真实取舍 [Fed23]。

ETF 与私人信贷：非银金融包含多类资产负债表。 ETF 的交易份额可以由 authorized participants 通过 creation and redemption mechanism 与底层组合相连。常态下套利通常使市场价格接近 net asset value (NAV)，但压力期间 spread 和折溢价可以扩大；当底层债券报价稀疏且 NAV 使用滞后价格时，ETF 的实时价格还可能先于 NAV 反映信息。所以 ETF 既可能传导赎回和库存压力，也可能成为价格发现的场所，它在屏幕上的流动性不能被直接等同于底层资产流动性 [US 19; US 20]。

私人信贷 (private credit) 则把一部分企业贷款放到银行之外的基金，为企业提供贷款或股权资本的受监管投资公司 (business development companies, BDCs)，以及保险关联载体中。长期不向投资者按净值赎回的 closed-end vehicles 可以用资本锁定降低日常挤兑风险，却不能消除借款人信用，杠杆，估值不透明和与银行或保险机构连接的风险；只在窗口提供周期性赎回的 semi-liquid vehicles 又会引入不同的流动性边界。截至 2026 年，这个规模不断增长且数据覆盖不均的市场更适合被看作潜在脆弱点，还不能预先写成下一场系统性危机 [Boa26; CH24]。

这些二十一世纪案例可以概括为四种变化：

1. **速度变体：**自动交易，即时通信和数字提款缩短了反应时间。
2. **边界变体：**风险从银行转向基金，CCP, ETF, private credit, 做市商，平台和其他 non-bank financial intermediaries (NBFIs)。
3. **抵押品变体：**危机越来越通过保证金，haircut, dealer capacity 和火售传导。
4. **货币变体：**稳定币和代币化现金工具重新组合私人发行，公共储备和技术结算。

无论名称怎样变化，旧问题仍然存在。只要一个结构承诺短期可赎回却持有更长期或不透明的资产，只要多个杠杆头寸在同一抵押品上被迫平仓，只要市场价格依赖少数中介持续扩张资产负债表，历史上的挤兑和火售机制就仍然可能出现。

A.9 泡沫与危机留下了什么

开头的表从现行结构回望历史；本表则从事件出发，比较损失的传导机制与后来进入现行结构的安排。它追问两个问题：局部损失通过什么机制被放大，以及危机以后哪些安排逐渐进入现行结构。

事件	主要传导机制	对现行结构的遗产
1636–1637 年郁金香投机	未标准化远期请求权, 供给信息不透明, 缺少保证金和集中履约机制; 价格崩塌但系统性影响有限	提醒我们区分资产泡沫与金融系统危机, 并检查交付, 保证金和合同执行
1720 年跨国股票泡沫	政府债务转换, 政治特许, 新贸易和保险叙事, 跨市场投机相互强化	公共债务, 公司治理, 发行规则和政治关系必须联合分析
1866 年 Overend Gurney 危机	大型票据中介倒闭, 流动性需求扩散到整个伦敦货币市场	为后来由 Bagehot 总结的最后贷款人路线提供关键实践; 实际操作仍随危机与贷款对象而异
1907 年美国恐慌	信托公司多在清算所会员边界之外, 挤兑进入 call money 与 NYSE 融资	催化 Aldrich–Vreeland 应急货币, National Monetary Commission 与后来 Fed 对部分流动性和协调职能的制度化
1929–1933 年危机	股价崩跌与银行恐慌, 通缩, 信贷收缩和政策失误结合	FDIC, SEC, 联邦披露, 银行业务边界与更集中的 Fed 决策结构
1968–1976 年后台危机与同期市场结构改革	成交增长超过纸质确认, 股票证书和经纪商资本处理能力; 会员制佣金与碎片化行情限制竞争	DTC 与 NSCC 属于后台危机的直接制度路径; Nasdaq, national market system 与竞争性佣金属于同期但不同的报价, 竞争和法律改革路径
1987 年股灾	现货, 期货, 组合保险, 做市与保证金跨市场反馈	现代熔断, 跨市场监测, 清算保障和 Fed 对市场功能的公开流动性承诺
1980 年代储贷危机	利率错配, 存款保险道德风险, 监管宽容和损失延迟确认	RTC, FIRREA, FDICIA, prompt corrective action 与更明确的处置成本约束

续下页

事件	主要传导机制	对现行结构的遗产
1998 年 LTCM	高杠杆，相似交易和多家交易商对手方形成火售网络	系统重要性开始更多按网络和共同头寸理解，公共召集与私人损失吸收并用
2000–2002 年科技股与会计危机	技术不确定性，异质信念和融资热潮之后叠加独立的审计与治理失败	科技股崩跌深化估值教训；Enron 与 WorldCom 等公司丑闻更直接催化 PCAOB，审计独立和内部控制改革
2007–2009 年全球金融危机	抵押贷款证券化，repo 与短期批发融资，不透明衍生品和高杠杆影子银行	FSOC, OFR, 压力测试，处置框架及特定场外衍生品中央清算；风险被重组并部分集中，没有消失
2010 年 flash crash	自动执行，跨市场反馈与流动性同步撤退	limit up–limit down, 更新熔断与更细粒度市场数据
2020 年 dash for cash	多类持有人共同求现，基金赎回，保证金，部分 basis trade 去杠杆与交易商承接能力约束共同作用	SRF, Treasury 市场数据与仍在实施的中央清算改革，更重视 NBFIs 流动性和杠杆
2021 年 meme stocks	社交媒体驱动的零售参与，期权，short interest，场外执行和清算保证金集中相遇	对零售路由，PFOF，数字参与设计和清算基础设施的持续审查；T+1 属于更广泛的结算改革
2022 年 crypto 动荡	算法稳定币挤兑与中心化平台的治理，托管和关联方风险以不同方式暴露	按功能区分 unbacked crypto, payment stablecoins, 平台和 DeFi；稳定币法律框架进入实施期
2022 年英国 LDI 压力	财政消息引发国债重定价，杠杆化久期对冲的追加保证金和被迫售债放大跌势	NBFIs 流动性缓冲，压力测试与临时定向市场功能后盾
2023 年美国地区银行	未保险存款集中，久期风险，管理与监管缺陷，线上提款和社交网络加速挤兑	BTFF 的临时经验，存款保险边界争论和对利率风险，抵押品准备及流动性监督的重估

这张表还提示一个重要区别：资产价格大跌并不会自动带来制度重构。郁金香投机和互联网股票下跌主要改变了人们对估值，合同和披露的理解。当价格损失进一步穿过负债，支付或清算网络，形成系统性外部性时，中央银行，存款保险或清算体系才更可能被重新设计。因此，改革强度更多取决于损失怎样传导，而不只取决于资产价格从峰值跌了多少。

A.10 危机前的迟缓与危机中的动员：一种制度解释

沿着这条时间线，一种反复出现的节奏会变得清楚：风险在局部阶段没有得到充分处理，有时还被既有规则或市场扩张继续放大；等到损失成为共同可见的系统性问题以后，公共部门与私人机构才迅速集中资源。这种印象有历史依据。1985 年 San Francisco Fed 回顾美国金融改革时就指出，许多重大改革具有 crisis-oriented 的性质 [Fed85]。

但这种节奏不能简单归结为固定的民族性格。更可分析的问题是：哪些制度安排使平时的改革困难，又使危机中的集中行动成为可能？五项机制并不互相排斥，它们往往同时存在并彼此强化。

1. **否决点很多。** 联邦制，州与联邦双重银行体系，国会委员会，多个监管机构和交易所自律使平时的权限分散。一个机构即使发现风险，也未必有权改变整个系统。
2. **平时的改革成本集中，收益分散。** 更高资本，更严格抵押品，更少杠杆或者更透明披露会立刻减少某些机构的利润和某些选民的信贷；避免未来危机的收益则不可见，难归因且要由全社会分享。
3. **私人秩序确实常常有效。** 会员规则，清算所，dealer networks 和合同创新在大多数日子里能够比立法更快地解决问题。正因为局部协调平时有效，社会才更容易低估它在共同挤兑和火售面前的覆盖边界。
4. **损失可以被延迟确认。** 只要资产仍能按旧账面价值持有，负债仍能在存款保险或短期融资下续作，关闭机构就会立即暴露财政，职业和政治成本。储贷危机说明监管宽容并不要求监管者看不见问题；各方只需要暂时都不愿成为首先确认损失的人。
5. **危机会形成共同可见性和共同议程。** 当支付，就业，Treasury market 或大批存款人同时受到威胁时，“不行动的损失”会突然变得可见并跨越党派与行业边界。原来彼此分散的法律权限，财政能力，中央银行资产负债表，私人专业知识和运营网络于是能够围绕同一个时间表集中起来。

为了便于记忆, 把这些机制之间常见的作用方向压缩成一条示意链. 这条示意链只表示常见作用方向, 各场危机的具体路径可能不同:

私人创新与局部自治 → 增长, 复杂性与监管套利 → 信息分散和损失延迟确认
 → 流动性或结算外部性 → 危机共同可见性与政治联盟
 → 快速制度建设 → 风险迁移到新的边界.

最后一个箭头尤其重要: 制度建设可能降低一种风险, 但风险也可能转移到新的机构, 合约或资产负债表边界.

美国之外也存在这些机制. 美国的特殊之处在于几项制度特征同时存在: 对集中金融权力的长期警惕, 州与联邦并存的监管传统, 深厚而高度私人化的资本市场, 以及危机时可以迅速调动的 Treasury, Fed, Congress 和行政能力. 这使政策体系在平时更多依靠竞争, 自律和事后责任, 在危机时又能够以庞大的安全资产市场和中央银行资产负债表为支点集中行动.

荷兰的公共特许与私人股份市场, 以及英国由私人银行逐步形成的中央银行职能, 同样显示公私边界会在危机中被重新划定. 所以这里讨论的是一种普遍机制. 美国的制度组合使它表现得格外清楚.

解释危机中为什么能够迅速动员, 并不等于为动员结果背书. 1930–1933 年说明拥有中央银行并不保证诊断和执行正确; 储贷危机说明延迟处置可能放大最终成本. 即使行动缓解了眼前危机, 它也未必消除风险: 2008 年后的改革提高了银行韧性, 但 money funds, hedge funds, CCPs 和 Treasury plumbing 仍可能承受压力; 2023 年的应急保护也留下了存款保险边界与市场纪律问题. 快速行动可能阻止灾难性协调失败, 也可能转移损失, 固化道德风险或者制造下一轮监管套利.

比“危机来临时美国总能解决”更稳健的结论是: 美国制度经常依靠危机窗口克服平时的否决点, 但危机窗口只能提高形成行动联盟的概率, 不能保证政策正确, 公平或者一次完成. 跨时期研究也表明, 金融稳定取决于成套的法律, 监管与政治规则怎样改变参与者激励; 单个机构的设立无法决定结果 [Cal09; KR11].

A.11 回到随机过程: 历史会改变转移核

前两节讨论的是制度怎样改变损失的传导. 换成随机过程语言, 对应的问题落在条件分布上: 同一个可见市场状态在不同制度状态下, 可能具有不同的下一步条件分布. 第4.4节提供转移核语言, 第3.4.3小节提供条件分布语言; 这里新增的是把制度状态也放进状态空间.

这里只建立一组局部记号. 取两个标准 Borel 可测空间 $(X, \mathcal{E}_X)$ 和 $(Z, \mathcal{E}_Z)$. 令 $X_t \in X$ 表示模型选取的市场状态, 例如价格, 成交, 波动率, 融资利差, 保证金和资产负债表; 令 $Z_t \in Z$ 表示当时的制度状态, 包括资产权利, 交易规则, 对手方资格, 清算方式, 央行工具, 存款保险和危机处置权限. 对数价格可以是 X_t 的一个坐标, 制度状态也可以成为更大潜在状态的一部分. 把二者合成增广状态

$$Y_t = (X_t, Z_t).$$

先看完整信息层次. 设滤过 $(\mathcal{F}_t)$ 包含完整状态信息, 且 Y_t 对 $\mathcal{F}_t$ 可测. 可测性只说明当前状态属于已知信息, 还不足以推出 Markov 性. 如果进一步假设 Y_t 对下一步条件分布充分, 就可以用一个允许随时间变化的可测转移核 Q_t 写成

$$\Pr(Y_{t+1} \in C \mid \mathcal{F}_t) = Q_t(Y_t, C) \quad \text{a.s.}$$

其中 C 是增广状态空间中的任意可测集合. 这是一项额外的条件 Markov 建模假设, 不能作为一般恒等式使用.

现在把下一期制度状态边缘化. 对任意市场状态可测集合 B , 定义

$$K_{t,z}(x, B) := Q_t((x, z), B \times Z).$$

在这个假设下, 可以得到

$$\Pr(X_{t+1} \in B \mid \mathcal{F}_t) = K_{t,Z_t}(X_t, B) \quad \text{a.s.}$$

核的下标 t 保留了法规生效日，市场时段或其他日历效应带来的时间非齐次性。只有在这些作用已经由 Z_t 概括时，可以省略下标 t ，把右边简写为 $K_{Z_t}(X_t, B)$ 。这个简写表达的是“给定当前市场状态和制度状态以后，下一步怎样分布”，它既不声称真实市场无条件地具有 Markov 性，也不自动意味着时间齐次。

再看观察者只能看到部分状态的层次。令 $\mathcal{G}_t \subseteq \mathcal{F}_t$ 表示观察滤过，先假设当前市场状态 X_t 对 $\mathcal{G}_t$ 可测。制度状态 Z_t 可能是潜在的，观察者只能维护它的过滤分布

$$\pi_t(dz) := \Pr(Z_t \in dz \mid \mathcal{G}_t).$$

标准 Borel 假设使这里可以选取正则条件分布。观察者的一步预测于是成为不同制度核的条件混合：

$$\begin{aligned} \Pr(X_{t+1} \in B \mid \mathcal{G}_t) \\ = \int_{\mathcal{Z}} K_{t,z}(X_t, B) \pi_t(dz) \quad \text{a.s.} \end{aligned}$$

直观地说，观察者并不知道当前究竟处在哪一种制度状态，只能按现有信息赋予各状态不同权重，再把相应的一步分布加权起来。若 X_t 本身也不能被完整观察，则应改为对 (X_t, Z_t) 的联合后验分布积分，而不能只对制度状态 Z_t 做混合。

部分观察与状态不充分是两个不同问题。前者说明真实状态没有被观察者完整看到；后者说明即使知道当前选定的状态，下一步条件分布仍可能依赖更长历史。若增广状态仍不充分，上面的条件 Markov 表示就不成立。

制度怎样更新可以用结构关系示意为

$$Z_{t+1} = \Phi(Z_t, E_{t+1}, A_{t+1}),$$

其中 E_{t+1} 是危机，技术或政治事件， A_{t+1} 是私人协调，监管，立法和中央银行行动。 Φ 只是一张制度更新草图，用来提醒我们事件与行动都会改变制度状态。在没有进一步指定事件与行动的条件分布，行动规则和信息顺序时，它不会自行证明增广过程具有 Markov 性，也不会单独定义转移核 Q_t 。

这些公式的作用，是把三件事分开：完整状态下一步分布的建模假设，观察者在部分信息下的预测，以及制度本身随事件和行动更新的结构草图。有了这一区分，前面的历史至少提醒我们注意五件事。

1. **平稳性通常只是局部假设。** 1934 年前后的股票市场，1975 年前后的佣金与订单路由，2008 年前后的衍生品清算，并不一定共享同一个数据生成机制。
2. **相同名称未必代表相同资产头寸。** 披露责任，清算优先顺位，存款保障，托管和赎回规则改变以后，资产的权利，义务和可实现状态结果也可能改变。历史有时会越过参数层面，直接改变模型试图描述的对象。
3. **尾部事件具有内生反馈。** 保证金上升，haircut 扩大，dealer 缩表和同步赎回会使原本弱相关的头寸在压力中共同出售。危机状态下的相关性可能越过历史样本给出的水平。
4. **Markov 性依赖状态是否足够完整。** 即使增广过程 Y_t 在完整信息下满足上述条件 Markov 假设，只观察 X_t 得到的过程也未必具有 Markov 性。潜在制度状态的过滤分布 π_t 会保留过去观测带来的信息，因而观察过程可能表现出长记忆，突变或无法解释的状态切换 (regime shift)。扩大状态空间可以改善描述，但不能保证所有制度变量都可观察或可识别。
5. **跨制度回溯可能混合不同的转移核。** 一条趋势信号 (trend signal) 或技术指标 (technical indicator) 可以总结已经实现的价格路径，却不能单独判断流动性后盾，清算边界或市场参与者是否已经改变。指标仍然有描述和执行价值，但其历史胜率必须连同制度区间与交易成本一起解释。这正是第9.10节在样本外检验中需要保留的边界。

原则 A.2 (现行结构是被保留下来的历史)。

不能把跨越两百年的市场观察简单看成同一个固定随机过程不断增加样本。资产权利，私人组织和公共后盾在危机后不断改变，因而历史数据更接近由一连串局部过程生成。每次改革都可能截断一种尾部风险，同时改变激励，并把风险迁移到新的资产负债表，抵押品或交易速度上。

这也解释了为什么理解金融市场不能只从价格回到现金流, 还要从价格回到具体资产头寸及其制度. 历史事件改变谁拥有请求权, 谁控制记录, 谁必须交付现金, 谁可以暂停交易, 谁在压力中提供最终结算资产以及谁承担损失. 这些变化共同决定未来样本怎样被生成. 这样看, 现行金融结构可以被看成一份不完整的危机档案: 它记录了哪些问题曾被处理, 也保留了风险可能迁移到哪里的线索.

参考文献

- [Ald+20] Iñaki Aldasoro et al. *Global Banks' Dollar Funding Needs and Central Bank Swap Lines*. Bank for International Settlements. July 16, 2020. URL: <https://www.bis.org/publ/bisbull27.htm> (visited on 08/17/2026).
- [Ale+23] Paul Alexander et al. *Financial Stability Buy/Sell Tools: A Gilt Market Case Study*. Bank of England. Nov. 20, 2023. URL: <https://www.bankofengland.co.uk/quarterly-bulletin/2023/2023/financial-stability-buy-sell-tools-a-gilt-market-case-study> (visited on 09/02/2026).
- [AC01] Robert Almgren and Neil Chriss. "Optimal Execution of Portfolio Transactions". In: *Journal of Risk* 3.2 (2001), pp. 5–39. DOI: 10.21314/JOR.2001.041.
- [Alt] Alternative Reference Rates Committee. *Transition from LIBOR*. Federal Reserve Bank of New York. URL: <https://www.newyorkfed.org/arrc/sofr-transition> (visited on 08/17/2026).
- [Ana+26] Kenechukwu Anadu et al. *A Framework for Understanding the Vulnerabilities of New Money-Like Products*. Finance and Economics Discussion Series 2026-002. Board of Governors of the Federal Reserve System, 2026. DOI: 10.17016/FEDS.2026.002. URL: <https://www.federalreserve.gov/econres/feds/a-framework-for-understanding-the-vulnerabilities-of-new-money-like-products.htm> (visited on 09/02/2026).
- [Ang+22] Guillermo Angeris et al. *A Primer on Perpetuals*. Sept. 7, 2022. arXiv: 2209.03307. (Visited on 08/17/2026).
- [Ans+17] Mike Anson et al. *The Bank of England as Lender of Last Resort: New Historical Evidence from Daily Transactional Data*. Staff Working Paper 691. Bank of England, 2017. URL: <https://www.bankofengland.co.uk/working-paper/2017/the-bank-of-england-as-lender-of-last-resort-new-historical-evidence-from-daily-transactional-data> (visited on 09/02/2026).
- [AS23] Fernando Avalos and Vladyslav Sushko. *Margin Leverage and Vulnerabilities in U.S. Treasury Futures*. Bank for International Settlements. Sept. 18, 2023. URL: https://www.bis.org/publ/qtrpdf/r_qt2309w.htm (visited on 08/17/2026).
- [BMM15] Emmanuel Bacry, Iacopo Mastromatteo, and Jean-François Muzy. "Hawkes Processes in Finance". In: *Market Microstructure and Liquidity* 1.1 (2015), p. 1550005. DOI: 10.1142/S2382626615500057.
- [BK20] Nick Baltas and Robert Kosowski. "Demystifying Time-Series Momentum Strategies: Volatility Estimators, Trading Rules and Pairwise Correlations". In: *Market Momentum: Theory and Practice*. Ed. by Stephen Satchell and Andrew Grant. John Wiley & Sons, Nov. 16, 2020, pp. 30–67. ISBN: 9781119599364. DOI: 10.1002/9781119599364.ch3. URL: <https://onlinelibrary.wiley.com/doi/10.1002/9781119599364.ch3> (visited on 09/02/2026).
- [Ban22] Bank of England. *Financial Stability Report: December 2022*. Bank of England, 2022. URL: <https://www.bankofengland.co.uk/financial-stability-report/2022/december-2022> (visited on 09/02/2026).
- [Ban24] Bank of England. *History*. Dec. 9, 2024. URL: <https://www.bankofengland.co.uk/about/history> (visited on 09/02/2026).
- [BK21] Daniel Barth and R. Jay Kahn. *Hedge Funds and the Treasury Cash-Futures Disconnect*. Office of Financial Research. Apr. 1, 2021. URL: <https://www.financialresearch.gov/working-papers/2021/04/01/hedge-funds-and-the-treasury-cash-futures-disconnect/> (visited on 08/17/2026).
- [BKM23] Daniel Barth, R. Jay Kahn, and Robert Mann. *Recent Developments in Hedge Funds' Treasury Futures and Repo Positions: Is the Basis Trade "Back"?* Board of Governors of the Federal Reserve System. Aug. 30, 2023. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/recent-developments-in-hedge-funds-treasury-futures-and-repo-positions-20230830.html> (visited on 08/17/2026).
- [BBW] James R. Barth, R. Dan Brumbaugh, and James A. Wilcox. *Gramm-Leach-Bliley Act of 1999*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/gramm-leach-bliley-act> (visited on 09/02/2026).

- [Baz+15] Jamil Baz et al. *Dissecting Investment Strategies in the Cross Section and Time Series*. Working Paper 2695101. SSRN, 2015. DOI: [10.2139/ssrn.2695101](https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2695101). URL: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2695101 (visited on 09/02/2026).
- [Bil95] Patrick Billingsley. *Probability and Measure*. 3rd ed. Wiley, 1995.
- [Boa20a] Board of Governors of the Federal Reserve System. *A Retrospective on the March 2020 Turmoil in Treasury and Mortgage-Backed Securities Markets*. 2020. URL: <https://www.federalreserve.gov/publications/2020-november-financial-stability-report-borrowing.htm> (visited on 09/02/2026).
- [Boa20b] Board of Governors of the Federal Reserve System. *Swap Lines FAQs*. Mar. 19, 2020. URL: <https://www.federalreserve.gov/newsevents/pressreleases/swap-lines-faqs.htm> (visited on 08/17/2026).
- [Boa23] Board of Governors of the Federal Reserve System. *Review of the Federal Reserve's Supervision and Regulation of Silicon Valley Bank*. Board of Governors of the Federal Reserve System, 2023. URL: <https://www.federalreserve.gov/publications/2023-April-SVB-Executive-Summary.htm> (visited on 09/02/2026).
- [Boa26] Board of Governors of the Federal Reserve System. *Financial Stability Report: Funding Risks*. Board of Governors of the Federal Reserve System, May 2026. URL: <https://www.federalreserve.gov/publications/2026-may-financial-stability-report-funding-risks.htm> (visited on 09/02/2026).
- [Boaa] Board of Governors of the Federal Reserve System. *Bank Term Funding Program*. URL: <https://www.federalreserve.gov/financial-stability/bank-term-funding-program.htm> (visited on 09/02/2026).
- [Boab] Board of Governors of the Federal Reserve System. *Central Bank Liquidity Swaps*. URL: <https://www.federalreserve.gov/monetarypolicy/central-bank-liquidity-swaps.htm> (visited on 08/17/2026).
- [Boac] Board of Governors of the Federal Reserve System. *Factors Affecting Reserve Balances, H.4.1*. URL: <https://www.federalreserve.gov/releases/h41/> (visited on 08/17/2026).
- [Boad] Board of Governors of the Federal Reserve System. *Federal Reserve Act*. URL: <https://www.federalreserve.gov/aboutthefed/fract.htm> (visited on 08/17/2026).
- [Boae] Board of Governors of the Federal Reserve System. *Interest on Reserve Balances*. URL: <https://www.federalreserve.gov/monetarypolicy/reserve-balances.htm> (visited on 08/17/2026).
- [Boaf] Board of Governors of the Federal Reserve System. *Overnight Reverse Repurchase Agreement Operations*. URL: <https://www.federalreserve.gov/monetarypolicy/overnight-reverse-repurchase-agreements.htm> (visited on 08/17/2026).
- [Boag] Board of Governors of the Federal Reserve System. *Reserve Requirements*. URL: <https://www.federalreserve.gov/monetarypolicy/reservereq.htm> (visited on 08/17/2026).
- [Bog07] Vladimir I. Bogachev. *Measure Theory*. Springer, 2007.
- [BL78] Douglas T. Breeden and Robert H. Litzenberger. "Prices of State-Contingent Claims Implicit in Option Prices". In: *The Journal of Business* 51.4 (1978), pp. 621–651. DOI: [10.1086/296025](https://doi.org/10.1086/296025).
- [BLL92] William Brock, Josef Lakonishok, and Blake LeBaron. "Simple Technical Trading Rules and the Stochastic Properties of Stock Returns". In: *The Journal of Finance* 47.5 (1992), pp. 1731–1764. DOI: [10.1111/j.1540-6261.1992.tb04681.x](https://doi.org/10.1111/j.1540-6261.1992.tb04681.x).
- [CH24] Fang Cai and Sharjil Haque. *Private Credit: Characteristics and Risks*. Board of Governors of the Federal Reserve System. Feb. 23, 2024. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/private-credit-characteristics-and-risks-20240223.html> (visited on 09/02/2026).
- [Cal09] Charles W. Calomiris. *Banking Crises and the Rules of the Game*. Working Paper 15403. National Bureau of Economic Research, 2009. DOI: [10.3386/w15403](https://doi.org/10.3386/w15403). URL: <https://www.nber.org/papers/w15403> (visited on 09/02/2026).
- [Car] Mark Carlson. *Stock Market Crash of 1987*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/stock-market-crash-of-1987> (visited on 09/02/2026).

- [Che+26] Xin Cheng et al. *DSpark: Confidence-Scheduled Speculative Decoding with Semi-Autoregressive Generation*. July 6, 2026. arXiv: 2607.05147. URL: <https://arxiv.org/abs/2607.05147> (visited on 08/17/2026).
- [CME24] CME Group. *Calculating U.S. Treasury Futures Conversion Factors*. Jan. 19, 2024. URL: <https://www.cmegroup.com/articles/2024/calculating-us-treasury-futures-conversion-factors.html> (visited on 08/17/2026).
- [CME] CME Group. *CME Term SOFR Reference Rates*. URL: <https://www.cmegroup.com/market-data/cme-group-benchmark-administration/term-sofr.html> (visited on 08/17/2026).
- [Coc05] John H. Cochrane. *Asset Pricing*. Revised. Princeton University Press, 2005.
- [Com12] Commodity Futures Trading Commission. *Clearing Requirement Determination Under Section 2(h) of the Commodity Exchange Act*. Final Rule. Commodity Futures Trading Commission, Dec. 13, 2012. URL: <https://www.cftc.gov/sites/default/files/idc/groups/public/@lrfederalregister/documents/file/2012-29211a.pdf> (visited on 09/02/2026).
- [Com13] Commodity Futures Trading Commission. *Process for a Designated Contract Market or Swap Execution Facility To Make a Swap Available to Trade*. Final Rule. Commodity Futures Trading Commission, June 4, 2013. URL: <https://www.cftc.gov/LawRegulation/FederalRegister/FinalRules/2013-12250.html> (visited on 09/02/2026).
- [Com22] Commodity Futures Trading Commission. *CFTC Orders Event-Based Binary Options Markets Operator to Pay \$1.4 Million Penalty*. Jan. 3, 2022. URL: <https://www.cftc.gov/PressRoom/PressReleases/8478-22> (visited on 08/17/2026).
- [Com24] Commodity Futures Trading Commission. *CFTC Obtains \$12.7 Billion Judgment against FTX and Alameda*. Aug. 8, 2024. URL: <https://www.cftc.gov/PressRoom/PressReleases/8938-24> (visited on 09/02/2026).
- [Com26] Commodity Futures Trading Commission. *CFTC Enforcement Division Issues Prediction Markets Advisory*. Feb. 25, 2026. URL: <https://www.cftc.gov/PressRoom/PressReleases/9185-26> (visited on 08/17/2026).
- [Com] Commodity Futures Trading Commission. *Understanding Prediction Markets and Event Contracts*. URL: <https://www.cftc.gov/LearnandProtect/PredictionMarkets> (visited on 08/17/2026).
- [CKS14] Rama Cont, Arseniy Kukanov, and Sasha Stoikov. “The Price Impact of Order Book Events”. In: *Journal of Financial Econometrics* 12.1 (2014), pp. 47–88. DOI: 10.1093/jjfinec/nbt003.
- [CST10] Rama Cont, Sasha Stoikov, and Rishi Talreja. “A Stochastic Model for Order Book Dynamics”. In: *Operations Research* 58.3 (2010), pp. 549–563. DOI: 10.1287/opre.1090.0780.
- [Dam12] Aswath Damodaran. *Investment Valuation: Tools and Techniques for Determining the Value of Any Asset*. 3rd ed. Wiley, 2012.
- [DS94] Freddy Delbaen and Walter Schachermayer. “A General Version of the Fundamental Theorem of Asset Pricing”. In: *Mathematische Annalen* 300.1 (1994), pp. 463–520. DOI: 10.1007/BF01450498.
- [Dep] Depository Trust & Clearing Corporation. *The 1970s: Immobilization, Book Entry and Netting*. URL: <https://www.dtcc.com/annuals/history/1970s/> (visited on 09/02/2026).
- [DD83] Douglas W. Diamond and Philip H. Dybvig. “Bank Runs, Deposit Insurance, and Liquidity”. In: *Journal of Political Economy* 91.3 (1983), pp. 401–419. DOI: 10.1086/261155.
- [Duf01] Darrell Duffie. *Dynamic Asset Pricing Theory*. 3rd ed. Princeton University Press, 2001.
- [Dur19] Rick Durrett. *Probability: Theory and Examples*. 5th ed. Cambridge University Press, 2019.
- [Fed23] Federal Deposit Insurance Corporation. *Options for Deposit Insurance Reform*. Federal Deposit Insurance Corporation, 2023. URL: <https://www.fdic.gov/analysis/options-deposit-insurance-reform> (visited on 09/02/2026).
- [Feda] Federal Deposit Insurance Corporation. *1930–1939*. URL: <https://www.fdic.gov/history/1930-1939> (visited on 08/17/2026).
- [Fedb] Federal Deposit Insurance Corporation. *1980–1989*. URL: <https://www.fdic.gov/history/1980-1989> (visited on 09/02/2026).

- [Fedc] Federal Deposit Insurance Corporation. *1990–1999*. URL: <https://www.fdic.gov/history/1990-1999> (visited on 09/02/2026).
- [Fed21] Federal Reserve Bank of New York. *Statement Regarding Repurchase Agreements*. July 28, 2021. URL: https://www.newyorkfed.org/markets/opolicy/operating_policy_210728 (visited on 09/02/2026).
- [Fedd] Federal Reserve Bank of New York. *Effective Federal Funds Rate*. URL: <https://www.newyorkfed.org/markets/reference-rates/effr> (visited on 08/17/2026).
- [Fede] Federal Reserve Bank of New York. *Monetary Policy Implementation*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation> (visited on 08/17/2026).
- [Fedf] Federal Reserve Bank of New York. *Repo and Reverse Repo Agreements*. URL: <https://www.newyorkfed.org/markets/domestic-market-operations/monetary-policy-implementation/repo-reverse-repo-agreements> (visited on 08/17/2026).
- [Fedg] Federal Reserve Bank of New York. *Secured Overnight Financing Rate Data*. URL: <https://www.newyorkfed.org/markets/reference-rates/sofr> (visited on 08/17/2026).
- [Fed85] Federal Reserve Bank of San Francisco. *U.S. Financial Reform: Historical Perspective*. Weekly Letter. Federal Reserve Bank of San Francisco, Mar. 22, 1985. URL: https://fraser.stlouisfed.org/files/docs/historical/frbsf/frbsf_let/frbsf_let_19850322.pdf (visited on 09/02/2026).
- [Fedh] Federal Reserve History. *Before the Fed: The Historical Precedents of the Federal Reserve System*. URL: <https://www.federalreservehistory.org/essays/before-the-fed> (visited on 09/02/2026).
- [Fedi] Federal Reserve History. *Federal Reserve Act Signed into Law*. URL: <https://www.federalreservehistory.org/essays/federal-reserve-act-signed> (visited on 08/17/2026).
- [FSY19] Fernando F. Ferreira, A. Christian Silva, and Ju-Yi Yen. *Detailed Study of a Moving Average Trading Rule*. 2019. arXiv: 1907.00212 [q-fin.ST]. URL: <https://arxiv.org/abs/1907.00212>.
- [Fin11] Financial Crisis Inquiry Commission. *The Financial Crisis Inquiry Report*. U.S. Government Printing Office, 2011. URL: <https://www.govinfo.gov/content/pkg/GPO-FCIC/pdf/GPO-FCIC.pdf> (visited on 09/02/2026).
- [Fin23] Financial Stability Board. *Global Regulatory Framework for Crypto-Asset Activities*. Financial Stability Board, 2023. URL: <https://www.fsb.org/2023/07/fsb-finalises-global-regulatory-framework-for-crypto-asset-activities/> (visited on 09/02/2026).
- [Fin22] Financial Stability Oversight Council. *Report on Digital Asset Financial Stability Risks and Regulation*. U.S. Department of the Treasury, 2022. URL: <https://home.treasury.gov/system/files/261/FSOC-Digital-Assets-Report-2022.pdf> (visited on 09/02/2026).
- [Fol99] Gerald B. Folland. *Real Analysis: Modern Techniques and Their Applications*. 2nd ed. Wiley, 1999.
- [FPR23] Thierry Foucault, Marco Pagano, and Ailsa Röell. *Market Liquidity: Theory, Evidence, and Policy*. 2nd ed. Oxford University Press, 2023. DOI: 10.1093/oso/9780197542064.001.0001.
- [FGR09] Rik G. P. Frehen, William N. Goetzmann, and K. Geert Rouwenhorst. *New Evidence on the First Financial Bubble*. Working Paper 15332. National Bureau of Economic Research, 2009. DOI: 10.3386/w15332. URL: <https://www.nber.org/papers/w15332> (visited on 09/02/2026).
- [FSW20] Jon Frost, Hyun Song Shin, and Peter Wierts. *An Early Stablecoin? The Bank of Amsterdam and the Governance of Money*. Working Paper 696. De Nederlandsche Bank, 2020. URL: <https://www.dnb.nl/publicaties/publicaties-onderzoek/working-paper-2020/696-an-early-stablecoin-the-bank-of-amsterdam-and-the-governance-of-money/> (visited on 09/02/2026).
- [Gar] Kenneth D. Garbade. *Liberty Bonds*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/liberty-bonds> (visited on 09/02/2026).
- [Gas10] Gary L. Gastineau. *The Exchange-Traded Funds Manual*. 2nd ed. Wiley, 2010.

- [GJ04] Oscar Gelderblom and Joost Jonker. “Completing a Financial Revolution: The Finance of the Dutch East India Trade and the Rise of the Amsterdam Capital Market, 1595–1612”. In: *The Journal of Economic History* 64.3 (2004), pp. 641–672. DOI: [10.1017/S002205070400292X](https://doi.org/10.1017/S002205070400292X).
- [Gli+24] Jonathan Glicoes et al. *Quantifying Treasury Cash-Futures Basis Trades*. Board of Governors of the Federal Reserve System. Mar. 8, 2024. URL: <https://www.federalreserve.gov/econres/notes/feds-notes/quantifying-treasury-cash-futures-basis-trades-20240308.html> (visited on 08/17/2026).
- [GM85] Lawrence R. Glosten and Paul R. Milgrom. “Bid, Ask and Transaction Prices in a Specialist Market with Heterogeneously Informed Traders”. In: *Journal of Financial Economics* 14.1 (1985), pp. 71–100. DOI: [10.1016/0304-405X\(85\)90044-3](https://doi.org/10.1016/0304-405X(85)90044-3).
- [GM13] Gary B. Gorton and Andrew Metrick. *The Federal Reserve and Financial Regulation: The First Hundred Years*. Working Paper 19292. National Bureau of Economic Research, 2013. DOI: [10.3386/w19292](https://doi.org/10.3386/w19292). URL: <https://www.nber.org/papers/w19292> (visited on 09/02/2026).
- [Gou+13] Martin D. Gould et al. “Limit Order Books”. In: *Quantitative Finance* 13.11 (2013), pp. 1709–1742. DOI: [10.1080/14697688.2013.803148](https://doi.org/10.1080/14697688.2013.803148).
- [GS14] Denis S. Grebenkov and Jeremy Serror. “Following a Trend with an Exponential Moving Average: Analytical Results for a Gaussian Model”. In: *Physica A: Statistical Mechanics and its Applications* 394 (2014), pp. 288–303. DOI: [10.1016/j.physa.2013.10.007](https://doi.org/10.1016/j.physa.2013.10.007).
- [Har02] Larry Harris. *Trading and Exchanges: Market Microstructure for Practitioners*. Oxford University Press, 2002. DOI: [10.1093/oso/9780195144703.001.0001](https://doi.org/10.1093/oso/9780195144703.001.0001).
- [Har94] Ron Harris. “The Bubble Act: Its Passage and Its Effects on Business Organization”. In: *The Journal of Economic History* 54.3 (1994), pp. 610–627. DOI: [10.1017/S0022050700015059](https://doi.org/10.1017/S0022050700015059).
- [HK79] J. Michael Harrison and David M. Kreps. “Martingales and Arbitrage in Multiperiod Securities Markets”. In: *Journal of Economic Theory* 20.3 (1979), pp. 381–408. DOI: [10.1016/0022-0531\(79\)90043-7](https://doi.org/10.1016/0022-0531(79)90043-7).
- [HP81] J. Michael Harrison and Stanley R. Pliska. “Martingales and Stochastic Integrals in the Theory of Continuous Trading”. In: *Stochastic Processes and their Applications* 11.3 (1981), pp. 215–260. DOI: [10.1016/0304-4149\(81\)90026-0](https://doi.org/10.1016/0304-4149(81)90026-0).
- [Has07] Joel Hasbrouck. *Empirical Market Microstructure: The Institutions, Economics, and Econometrics of Securities Trading*. Oxford University Press, 2007. DOI: [10.1093/oso/9780195301649.001.0001](https://doi.org/10.1093/oso/9780195301649.001.0001).
- [He+24] Songrun He et al. *Fundamentals of Perpetual Futures*. Aug. 21, 2024. arXiv: [2212.06888](https://arxiv.org/abs/2212.06888). (Visited on 08/17/2026).
- [HL] Robert L. Hetzel and Ralph F. Leach. *The Treasury–Federal Reserve Accord*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/treasury-fed-accord> (visited on 09/02/2026).
- [HS81] Thomas Ho and Hans R. Stoll. “Optimal Dealer Pricing under Transactions and Return Uncertainty”. In: *Journal of Financial Economics* 9.1 (1981), pp. 47–73. DOI: [10.1016/0304-405X\(81\)90020-9](https://doi.org/10.1016/0304-405X(81)90020-9).
- [Hua+20] Dashan Huang et al. “Time Series Momentum: Is It There?” In: *Journal of Financial Economics* 135.3 (2020), pp. 774–794. DOI: [10.1016/j.jfineco.2019.08.004](https://doi.org/10.1016/j.jfineco.2019.08.004).
- [HS97] Roger D. Huang and Hans R. Stoll. “The Components of the Bid-Ask Spread: A General Approach”. In: *The Review of Financial Studies* 10.4 (1997), pp. 995–1034. DOI: [10.1093/rfs/10.4.995](https://doi.org/10.1093/rfs/10.4.995).
- [Hul22] John C. Hull. *Options, Futures, and Other Derivatives*. 11th ed. Pearson, 2022.
- [HOP17] Brian Hurst, Yao Hua Ooi, and Lasse Heje Pedersen. “A Century of Evidence on Trend-Following Investing”. In: *The Journal of Portfolio Management* 44.1 (2017), pp. 15–29. DOI: [10.3905/jpm.2017.44.1.015](https://doi.org/10.3905/jpm.2017.44.1.015).
- [HPW19] Jeffrey Huther, Luke Pettit, and Mark Wilkinson. *Fiscal Flow Volatility and Reserves*. Board of Governors of the Federal Reserve System. Dec. 16, 2019. DOI: [10.17016/2380-7172.2470](https://doi.org/10.17016/2380-7172.2470). URL: <https://www.federalreserve.gov/econres/notes/feds-notes/fiscal-flow-volatility-and-reserves-20191216.html> (visited on 08/17/2026).

- [Kal21] Olav Kallenberg. *Foundations of Modern Probability*. 3rd ed. Springer, 2021.
- [KTW16] Abby Y. Kim, Yiuman Tse, and John K. Wald. “Time Series Momentum and Volatility Scaling”. In: *Journal of Financial Markets* 30 (2016), pp. 103–124. DOI: [10.1016/j.finmar.2016.05.003](https://doi.org/10.1016/j.finmar.2016.05.003). URL: <https://www.sciencedirect.com/science/article/pii/S1386418116301379> (visited on 09/02/2026).
- [Kir+17] Andrei Kirilenko et al. “The Flash Crash: High-Frequency Trading in an Electronic Market”. In: *The Journal of Finance* 72.3 (2017), pp. 967–998. DOI: [10.1111/jofi.12498](https://doi.org/10.1111/jofi.12498).
- [KR11] Alejandro Komai and Gary Richardson. *A Brief History of Regulations Regarding Financial Markets in the United States: 1789 to 2009*. Working Paper 17443. National Bureau of Economic Research, 2011. DOI: [10.3386/w17443](https://doi.org/10.3386/w17443). URL: <https://www.nber.org/papers/w17443> (visited on 09/02/2026).
- [Kyl85] Albert S. Kyle. “Continuous Auctions and Insider Trading”. In: *Econometrica* 53.6 (1985), pp. 1315–1335. DOI: [10.2307/1913210](https://doi.org/10.2307/1913210).
- [LR91] Charles M. C. Lee and Mark J. Ready. “Inferring Trade Direction from Intraday Data”. In: *The Journal of Finance* 46.2 (1991), pp. 733–746. DOI: [10.1111/j.1540-6261.1991.tb02683.x](https://doi.org/10.1111/j.1540-6261.1991.tb02683.x).
- [LMW00] Andrew W. Lo, Harry Mamaysky, and Jiang Wang. “Foundations of Technical Analysis: Computational Algorithms, Statistical Inference, and Empirical Implementation”. In: *The Journal of Finance* 55.4 (2000), pp. 1705–1765. DOI: [10.1111/0022-1082.00265](https://doi.org/10.1111/0022-1082.00265).
- [Lon] London Stock Exchange Group. *The History of LSEG*. URL: <https://www.lseg.com/en/about-us/history> (visited on 09/02/2026).
- [Mad00] Ananth Madhavan. “Market Microstructure: A Survey”. In: *Journal of Financial Markets* 3.3 (2000), pp. 205–258. DOI: [10.1016/S1386-4181\(00\)00007-0](https://doi.org/10.1016/S1386-4181(00)00007-0).
- [Man06] Charles F. Manski. “Interpreting the Predictions of Prediction Markets”. In: *Economics Letters* 91.3 (2006), pp. 425–429. DOI: [10.1016/j.econlet.2006.01.004](https://doi.org/10.1016/j.econlet.2006.01.004).
- [Mar52] Harry Markowitz. “Portfolio Selection”. In: *The Journal of Finance* 7.1 (1952), pp. 77–91. DOI: [10.2307/2975974](https://doi.org/10.2307/2975974).
- [MT17] James E. McClure and David Chandler Thomas. “Explaining the Timing of Tulipmania’s Boom and Bust: Historical Context, Sequestered Capital and Market Signals”. In: *Financial History Review* 24.2 (2017), pp. 121–141. DOI: [10.1017/S0968565017000154](https://doi.org/10.1017/S0968565017000154).
- [McD98] William J. McDonough. *Statement on the Long-Term Capital Management Rescue*. Federal Reserve Bank of New York. Oct. 1, 1998. URL: <https://www.newyorkfed.org/newsevents/speeches/1998/mcd981001.html> (visited on 09/02/2026).
- [MW02] Frederic S. Mishkin and Eugene N. White. *U.S. Stock Market Crashes and Their Aftermath: Implications for Monetary Policy*. Working Paper 8992. National Bureau of Economic Research, 2002. DOI: [10.3386/w8992](https://doi.org/10.3386/w8992). URL: <https://www.nber.org/papers/w8992> (visited on 09/02/2026).
- [MW14] Frederic S. Mishkin and Eugene N. White. *Unprecedented Actions: The Federal Reserve’s Response to the Global Financial Crisis in Historical Perspective*. Working Paper 20737. National Bureau of Economic Research, 2014. DOI: [10.3386/w20737](https://doi.org/10.3386/w20737). URL: <https://www.nber.org/papers/w20737> (visited on 09/02/2026).
- [MT] Jon R. Moen and Ellis W. Tallman. *The Panic of 1907*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/panic-of-1907> (visited on 08/17/2026).
- [Mor22] Morgan Stanley. *Vintage Values 2023*. Morgan Stanley Wealth Management. Aug. 24, 2022. URL: <https://www.morganstanley.com/content/dam/msdotcom/what-we-do/wealth-management-images/uit/vintage-values-research-report.pdf> (visited on 08/17/2026).
- [MOP12] Tobias J. Moskowitz, Yao Hua Ooi, and Lasse Heje Pedersen. “Time Series Momentum”. In: *Journal of Financial Economics* 104.2 (2012), pp. 228–250. DOI: [10.1016/j.jfineco.2011.11.003](https://doi.org/10.1016/j.jfineco.2011.11.003).
- [Nas] Nasdaq. *Nasdaq-100 Index Methodology*. URL: https://indexes.nasdaqomx.com/docs/Methodology_NDX.pdf (visited on 08/17/2026).
- [Nee+14] Christopher J. Neely et al. “Forecasting the Equity Risk Premium: The Role of Technical Indicators”. In: *Management Science* 60.7 (2014), pp. 1772–1791. DOI: [10.1287/mnsc.2013.1838](https://doi.org/10.1287/mnsc.2013.1838).

- [Newa] New York Stock Exchange. *Listing at NYSE*. URL: <https://www.nyse.com/listings> (visited on 09/02/2026).
- [Newb] New York Stock Exchange. *The History of the New York Stock Exchange*. URL: <https://www.nyse.com/history-of-nyse> (visited on 09/02/2026).
- [OHa95] Maureen O'Hara. *Market Microstructure Theory*. Blackwell Publishers, 1995.
- [OR01] Eli Ofek and Matthew Richardson. *DotCom Mania: The Rise and Fall of Internet Stock Prices*. Working Paper 8630. National Bureau of Economic Research, 2001. DOI: 10.3386/w8630. URL: <https://www.nber.org/papers/w8630> (visited on 09/02/2026).
- [Off26] Office of the Comptroller of the Currency. *Comptroller Gould Discusses Digital Asset Innovation, GENIUS Next Steps*. Aug. 19, 2026. URL: <https://www.occ.treas.gov/news-issuances/news-releases/2026/nr-occ-2026-69.html> (visited on 09/02/2026).
- [Opt] Options Clearing Corporation. *Characteristics and Risks of Standardized Options*. URL: <https://www.theocc.com/company-information/documents-and-archives/options-disclosure-document> (visited on 08/17/2026).
- [PV05] Lubos Pastor and Pietro Veronesi. *Technological Revolutions and Stock Prices*. Working Paper 11876. National Bureau of Economic Research, 2005. DOI: 10.3386/w11876. URL: <https://www.nber.org/papers/w11876> (visited on 09/02/2026).
- [Per88] André F. Perold. "The Implementation Shortfall: Paper versus Reality". In: *The Journal of Portfolio Management* 14.3 (1988), pp. 4–9. DOI: 10.3905/jpm.1988.409150.
- [Ric+a] Gary Richardson et al. *Banking Act of 1933 (Glass-Steagall)*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/glass-steagall-act> (visited on 09/02/2026).
- [Ric+b] Gary Richardson et al. *Banking Act of 1935*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/banking-act-of-1935> (visited on 09/02/2026).
- [RKG] Gary Richardson, Alejandro Komai, and Michael Gou. *Stock Market Crash of 1929*. Federal Reserve History. URL: <https://www.federalreservehistory.org/essays/stock-market-crash-of-1929> (visited on 09/02/2026).
- [SP 26] S&P Dow Jones Indices. *Marvell Technology and Flex Set to Join S&P 500; Others to Join S&P MidCap 400 and S&P SmallCap 600*. June 5, 2026. URL: <https://press.spglobal.com/2026-06-05-Marvell-Technology-and-Flex-Set-to-Join-S-P-500-Others-to-Join-S-P-MidCap-400-and-S-P-SmallCap-600> (visited on 08/17/2026).
- [SP a] S&P Dow Jones Indices. *Index Mathematics Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-index-math.pdf> (visited on 08/17/2026).
- [SP b] S&P Dow Jones Indices. *S&P U.S. Indices Methodology*. URL: <https://www.spglobal.com/spdji/en/documents/methodologies/methodology-sp-us-indices.pdf> (visited on 08/17/2026).
- [SV97] Andrei Shleifer and Robert W. Vishny. "The Limits of Arbitrage". In: *The Journal of Finance* 52.1 (1997), pp. 35–55. DOI: 10.1111/j.1540-6261.1997.tb03807.x.
- [Shr04a] Steven E. Shreve. *Stochastic Calculus for Finance I: The Binomial Asset Pricing Model*. Springer, 2004.
- [Shr04b] Steven E. Shreve. *Stochastic Calculus for Finance II: Continuous-Time Models*. Springer, 2004.
- [Sta10] Staffs of the U.S. Securities and Exchange Commission and the Commodity Futures Trading Commission. *Findings Regarding the Market Events of May 6, 2010*. U.S. Securities, Exchange Commission, and Commodity Futures Trading Commission, 2010. URL: <https://www.sec.gov/news/studies/2010/marketevents-report.pdf> (visited on 09/02/2026).
- [STW99] Ryan Sullivan, Allan Timmermann, and Halbert White. "Data-Snooping, Technical Trading Rule Performance, and the Bootstrap". In: *The Journal of Finance* 54.5 (1999), pp. 1647–1691. DOI: 10.1111/0022-1082.00163.
- [The25] The White House. *The President Signed into Law S. 1582*. July 18, 2025. URL: <https://www.whitehouse.gov/briefings-statements/2025/07/the-president-signed-into-law-s-1582/> (visited on 09/02/2026).

- [TS11] Bruce Tuckman and Angel Serrat. *Fixed Income Securities: Tools for Today's Markets*. 3rd ed. Wiley, 2011.
- [US 10] U.S. Congress. *Dodd–Frank Wall Street Reform and Consumer Protection Act, Public Law 111-203*. July 21, 2010. URL: <https://www.govinfo.gov/app/details/PLAW-111publ203> (visited on 09/02/2026).
- [US 25] U.S. Congress. *Guiding and Establishing National Innovation for U.S. Stablecoins Act, Public Law 119-27*. July 18, 2025. URL: <https://www.govinfo.gov/app/details/PLAW-119publ27> (visited on 09/02/2026).
- [US a] U.S. Department of the Treasury. *About the Financial Stability Oversight Council*. URL: <https://home.treasury.gov/policy-issues/financial-markets-financial-institutions-and-fiscal-service/fsoc/about-fsoc> (visited on 09/02/2026).
- [US b] U.S. Department of the Treasury. *Daily Treasury Rates*. URL: https://home.treasury.gov/resource-center/data-chart-center/interest-rates/TextView?type=daily_treasury_yield_curve (visited on 08/17/2026).
- [US c] U.S. Department of the Treasury. *STRIPS*. URL: <https://www.treasurydirect.gov/market-able-securities/strips/> (visited on 08/17/2026).
- [US d] U.S. Department of the Treasury. *Treasury Marketable Securities*. URL: <https://www.treasurydirect.gov/marketable-securities/> (visited on 08/17/2026).
- [US 23a] U.S. Department of the Treasury and Board of Governors of the Federal Reserve System and Federal Deposit Insurance Corporation. *Joint Statement by the Department of the Treasury, Federal Reserve, and FDIC*. Mar. 12, 2023. URL: <https://www.fdic.gov/news/press-releases/2023/pr23017.html> (visited on 09/02/2026).
- [US 68] U.S. Securities and Exchange Commission. *Thirty-Fourth Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1968. URL: https://www.sec.gov/about/annual_report/1968.pdf (visited on 09/02/2026).
- [US 71] U.S. Securities and Exchange Commission. *Thirty-Seventh Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1971. URL: <https://www.sec.gov/file/1971pdf> (visited on 09/02/2026).
- [US 75] U.S. Securities and Exchange Commission. *Forty-First Annual Report of the Securities and Exchange Commission*. U.S. Securities and Exchange Commission, 1975. URL: https://www.sec.gov/about/annual_report/1975.pdf (visited on 09/02/2026).
- [US 02] U.S. Securities and Exchange Commission. *SEC Accomplishments: Fiscal Year 2002*. 2002. URL: <https://www.sec.gov/news/extra/intsfy2002.htm> (visited on 09/02/2026).
- [US 06] U.S. Securities and Exchange Commission. *Approval of SRO Rule Changes Necessary to Effectuate Merger of NYSE and Archipelago Holdings*. Feb. 27, 2006. URL: <https://www.sec.gov/news/press/2006-29.htm> (visited on 09/02/2026).
- [US 15] U.S. Securities and Exchange Commission. *Investor Bulletin: An Introduction to Options*. Mar. 18, 2015. URL: <https://www.investor.gov/introduction-investing/general-resources/news-alerts/alerts-bulletins/investor-bulletins-63> (visited on 08/17/2026).
- [US 19] U.S. Securities and Exchange Commission. *Exchange-Traded Funds, Rule 6c-11*. Sept. 25, 2019. URL: <https://www.sec.gov/rules/final/2019/33-10695.pdf> (visited on 09/02/2026).
- [US 21] U.S. Securities and Exchange Commission. *Staff Report on Equity and Options Market Structure Conditions in Early 2021*. U.S. Securities and Exchange Commission, 2021. URL: <https://www.sec.gov/files/staff-report-equity-options-market-struction-conditions-early-2021.pdf> (visited on 09/02/2026).
- [US 23b] U.S. Securities and Exchange Commission. *SEC Finalizes Rules to Reduce Risks in Clearance and Settlement*. Feb. 15, 2023. URL: <https://www.sec.gov/newsroom/press-releases/2023-29> (visited on 09/02/2026).
- [US e] U.S. Securities and Exchange Commission. *Exchange-Traded Funds (ETFs)*. Investor.gov. URL: <https://www.investor.gov/introduction-investing/investing-basics/glossary/exchange-traded-funds-etfs> (visited on 08/17/2026).

- [US f] U.S. Securities and Exchange Commission. *Investor Bulletin: Exchange-Traded Funds (ETFs)*. URL: <https://www.sec.gov/investor/pubs/sec-guide-to-etfs.pdf> (visited on 08/17/2026).
- [US g] U.S. Securities and Exchange Commission. *Money Market Funds*. URL: <https://www.investor.gov/introduction-investing/investing-basics/investment-products/mutual-funds-and-exchange-traded-5> (visited on 08/17/2026).
- [US h] U.S. Securities and Exchange Commission. *National Securities Exchanges*. URL: <https://www.sec.gov/about/divisions-offices/division-trading-markets/national-securities-exchanges> (visited on 09/02/2026).
- [US i] U.S. Securities and Exchange Commission. *Securities Laws and Regulations*. URL: <https://www.sec.gov/rules-regulations/statutes-regulations> (visited on 09/02/2026).
- [US j] U.S. Securities and Exchange Commission. *Treasury Clearing Implementation*. URL: <https://www.sec.gov/featured-topics/treasury-clearing-implementation> (visited on 09/02/2026).
- [US 20] U.S. Securities and Exchange Commission Research Staff. *U.S. Credit Markets Interconnectedness and the Effects of the COVID-19 Economic Shock*. U.S. Securities and Exchange Commission, Oct. 5, 2020. URL: https://www.sec.gov/files/us-credit-markets_covid-19_report.pdf (visited on 09/02/2026).
- [UK 25] UK Parliament. *Research into Historic Links to Transatlantic Chattel Slavery*. UK Parliament, 2025. URL: https://data.parliament.uk/DepositedPapers/Files/DEP2025-0405/Research_into_Historic_Links_to_Transatlantic_Chattel_Slavery_Report.pdf (visited on 09/02/2026).
- [Vil09] Cédric Villani. *Optimal Transport: Old and New*. Springer, 2009.
- [Wil91] David Williams. *Probability with Martingales*. Cambridge University Press, 1991.
- [WZ04] Justin Wolfers and Eric Zitzewitz. “Prediction Markets”. In: *Journal of Economic Perspectives* 18.2 (2004), pp. 107–126. DOI: [10.1257/0895330041371321](https://doi.org/10.1257/0895330041371321).
- [Yaha] Yahoo Finance. *Apple Inc. (AAPL) Historical Prices and Data*. URL: <https://finance.yahoo.com/quote/AAPL/history/> (visited on 09/02/2026).
- [Yahb] Yahoo Finance. *SPDR S&P 500 ETF Trust (SPY) Historical Prices and Data*. URL: <https://finance.yahoo.com/quote/SPY/history/> (visited on 09/02/2026).
- [Yahc] Yahoo Help. *What Is the Adjusted Close?* URL: <https://help.yahoo.com/kb/adjusted-close-sln28256.html> (visited on 09/02/2026).
- [ZG20] Valeriy Zakamulin and Javier Giner. “Trend Following with Momentum versus Moving Averages: A Tale of Differences”. In: *Quantitative Finance* 20.6 (2020), pp. 985–1007. DOI: [10.1080/14697688.2020.1716057](https://doi.org/10.1080/14697688.2020.1716057).